2021美团技术年货

CODE A BETTER LIFE

美团 美团

序

新年将至，年味渐浓。虽然疫情的阴霾还没彻底消散，但是相信很多人都对2022年的春天充满了期待。期待春暖花开，期待国泰民安，期待能早一天在阳光下自由地呼吸。

老规矩，一年一度的美团技术年货如期而至。

在2022年春节到来之际，我们精选过去一年公众号50多篇技术文章以及20多篇国际顶会论文，整理制作成一本厚达1200多页的电子书，作为新年礼物赠送给大家。

这本电子书内容覆盖算法、前端、后端、数据、安全、测试等多个领域， 希望能对同学们的工作和学习有所帮助。

大家如果觉得有价值，也欢迎转给更多有相同兴趣、积极上进的同事和朋友们，一起切磋，共同成长。

最后，祝大家阖家欢乐，健康平安。新的一年，「虎」力全开，走出个「龙行虎步」，闯出个「虎虎生威」！

目录

算法 1

美团外卖特征平台的建设与实践 1

美团基于知识图谱的剧本杀标准化建设与应用 24

美团商品知识图谱的构建及应用 40

常识性概念图谱建设以及在美团场景中的应用 60

美团外卖美食知识图谱的迭代及应用 83

美团知识图谱问答技术实践与探索 95

本地生活综合性需求图谱的构建及应用 116

外卖商品的标准化建设与应用 138

多业务建模在美团搜索排序中的实践 151

美团搜索多业务商品排序探索与实践 165

情感分析技术在美团的探索与应用 178

细粒度情感分析在到餐场景中的应用 198

预训练技术在美团到店搜索广告中的应用 217

美团智能客服核心技术与实践 235

广告深度预估技术在美团到店场景下的突破与畅想 254

小样本学习及其在美团场景中的应用 274

美团外卖广告智能算力的探索与实践 300

外卖套餐搭配的探索和应用 317

自动驾驶轨迹预测算法：NeurIPS 挑战赛冠军方案 332

KDD 2021 | 美团联合多高校提出多任务学习模型，已应用于联名卡获客场景 341

ACL 2021 | 一文详解美团技术团队 7 篇精选论文 353

ACL 2021 | 美团提出基于对比学习的文本表示模型，效果相比 BERT-flow 提升 8% 368
CVPR 2021 | 基于 Transformer 的端到端视频实例分割方法 382
ICLR 2021 | 美团 AutoML 论文：鲁棒的神经网络架构搜索 DARTS- 396
SIGIR 2021 | 广告系统位置偏差的 CTR 模型优化方案 409

前端 424
让 Flutter 在鸿蒙系统上跑起来 424
FlutterWeb 在美团外卖的实践 437
FlutterWeb 性能优化探索与实践 459
设计稿（UI 视图）自动生成代码方案的探索 479
美团外卖终端容器无关化研发框架 497
一款可以让大型 iOS 工程编译速度提升 50% 的工具 519
从预编译的角度理解 Swift 与 Objective-C 及混编机制 531
美团民宿跨端复用框架设计与实践 588
美团跨端一体化富文本管理技术实践 609

后端 625
如何优雅地记录操作日志? 625
基于 SSD 的 Kafka 应用层缓存架构设计与实现 653
美团图数据库平台建设及业务实践 665
OCTO 2.0：美团基于 Service Mesh 的服务治理系统详解 684
GraphQL 及元数据驱动架构在后端 BFF 中的实践 695
速度与压缩比如何兼得？压缩算法在构建部署中的优化 727
百亿规模 API 网关服务 Shepherd 的设计与实现 745
TensorFlow 在推荐系统中的分布式训练优化实践 766
美团 Serverless 平台 Nest 的探索与实践 789

算法平台在线服务体系的演进与实践 809
美团终端消息投递服务 Pike 的演进之路 831
新一代 CTR 预测服务的 GPU 优化实践 851
美团弹性伸缩系统的技术演进与落地实践 865

数据 · 安全 · 测试 887
美团外卖实时数仓建设实践 887
美团酒旅数据治理实践 900
实践之后，我们来谈谈如何做好威胁建模 923
Fairplay DRM 与混淆实现的研究 945
Spock 单元测试框架介绍以及在美团优选的实践 964
美团 App 页面视图可测性改造实践 1000

论文 1017
ConSERT: A Contrastive Framework for Self-Supervised Sentence Representation Transfer 1017
DisenKGAT: Knowledge Graph Embedding with Disentangled Graph Attention Network 1028
Task-Oriented Clustering for Dialogues 1038
ASAP: A Chinese Review Dataset Towards Aspect Category Sentiment Analysis and Rating Prediction 1048
From Paraphrasing to Semantic Parsing: Unsupervised Semantic Parsing via Synchronous Semantic Decoding 1059
Distant Supervision based Machine Reading Comprehension for Extractive Summarization in Customer Service 1071
User Consumption Intention Prediction in Meituan 1076

Learning Self-Modulating Attention in Continuous Time Space with Applications to Sequential Recommendation 1088

Signed Graph Neural Network with Latent Groups 1099

Structure Guided Lane Detection 1109

Twins: Revisiting the Design of Spatial Attention in Vision Transformers 1116

Partial Feature Selection and Alignment for Multi-Source Domain Adaptation 1130

A Deep Learning Method for Route and Time Prediction in Food Delivery Service 1140

A Semantic Segmentation based POI Coordinates Generating Framework for On-demand Food Delivery Service 1151

Learning Motion-Appearance Co-Attention for Zero-Shot Video Object Segmentation 1161

Topic-aware Heterogeneous Graph Neural Network for Link Prediction 1171

AdaSGN: Adapting Joint Number and Model Size for Efficient Skeleton-Based Action Recognition 1181

End-to-End Video Instance Segmentation with Transformers 1191

Trash to Treasure: Harvesting OOD Data with Cross-Modal Matching for Open-Set Semi-Supervised Learning 1201

Feature Decomposition and Reconstruction Learning for Effective Facial Expression Recognition 1211

Rethinking BiSeNet For Real-time Semantic Segmentation 1221

Selective Wavelet Attention Learning for Single Image Deraining 1231

算法

美团外卖特征平台的建设与实践

作者：英亮　陈龙　刘磊　亚劼　乐彬

1. 背景

美团外卖业务种类繁多、场景丰富，根据业务特点可分为推荐、广告、搜索三大业务线以及数个子业务线，比如商家推荐、菜品推荐、列表广告、外卖搜索等等，满足了数亿用户对外卖服务的全方面需求。而在每条业务线的背后，都涉及用户、商家、平台三方面利益的平衡：用户需要精准的展现结果；商家需要尽可能多的曝光和转化；平台需要营收的最大化，而算法策略通过模型机制的优化迭代，合理地维护这三方面的利益平衡，促进生态良性发展。

随着业务的发展，外卖算法模型也在不断演进迭代中。从之前简单的线性模型、树模型，到现在复杂的深度学习模型，预估效果也变得愈发精准。这一切除了受益于模型参数的不断调优，也受益于外卖算法平台对算力增长的工程化支撑。外卖算法平台通过统一算法工程框架，解决了模型 & 特征迭代的系统性问题，极大地提升了外卖算法的迭代效率。根据功能不同，外卖算法平台可划分为三部分：模型服务、模型训练和特征平台。其中，模型服务用于提供在线模型预估，模型训练用于提供模型的训练产出，特征平台则提供特征和样本的数据支撑。本文将重点阐述外卖特征平台在建设过程中遇到的挑战以及优化思路。

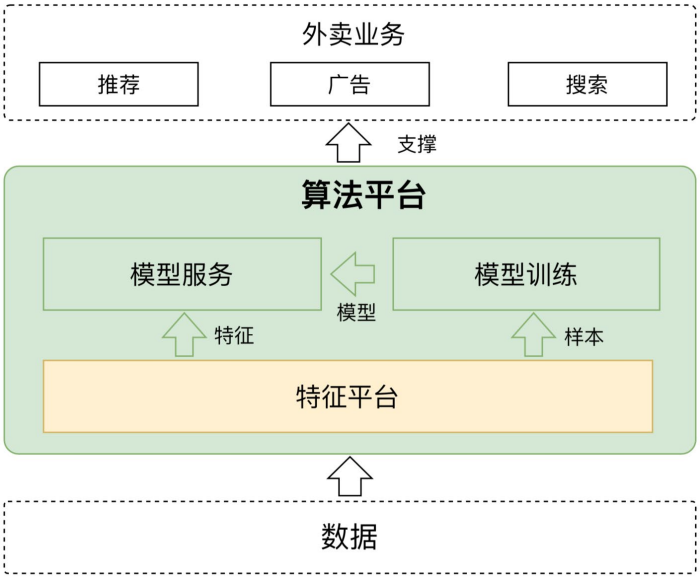

诚然，业界对特征系统的研究较为广泛，比如微信 FeatureKV 存储系统聚焦于解决特征数据快速同步问题，腾讯广告特征工程聚焦于解决机器学习平台中 Pre-Trainer 方面的问题，美团酒旅在线特征系统聚焦于解决高并发情形下的特征存取和生产调度问题，而外卖特征平台则聚焦于提供从样本生成 -> 特征生产 -> 特征计算的一站式链路，用于解决特征的快速迭代问题。

随着外卖业务的发展，特征体量也在快速增长，外卖平台面对的挑战和压力也不断增大。目前，平台已接入特征配置近万个，特征维度近 50 种，日处理特征数据量几十 TB，日处理特征千亿量级，日调度任务数量达数百个。面对海量的数据资源，平台如何做到特征的快速迭代、特征的高效计算以及样本的配置化生成？下文将分享美团外卖在平台建设过程中的一些思考和优化思路，希望能对大家有所帮助或启发。

2. 特征框架演进

2.1 旧框架的不足

外卖业务发展初期，为了提升策略迭代效率，算法同学通过积累和提炼，整理出一套通用的特征生产框架，该框架由三部分组成：特征统计、特征推送和特征获取加载。

如下图所示：

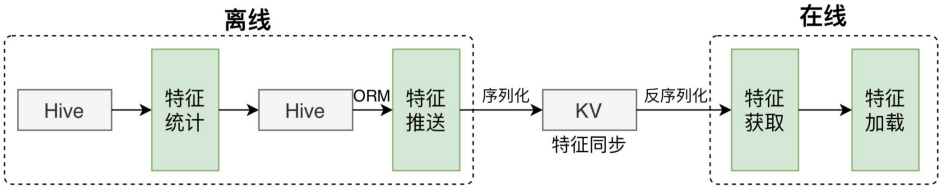

- **特征统计**：基于基础数据表，框架支持统计多个时段内特定维度的总量、分布等统计类特征。
- **特征推送：**框架支持将 Hive 表里的记录映射成 Domain 对象，并将序列化后的结果写入 KV 存储。
- **特征获取加载：**框架支持在线从 KV 存储读取 Domain 对象，并将反序列化后的结果供模型预估使用。

该框架应用在外卖多条业务线中，为算法策略的迭代提供了有力支撑。但随着外卖业务的发展，业务线的增多，数据体量的增大，该框架逐渐暴露以下三点不足：

- **特征迭代成本高：**框架缺乏配置化管理，新特征上线需要同时改动离线侧和在线侧代码，迭代周期较长。
- **特征复用困难：**外卖不同业务线间存在相似场景，使特征的复用成为可能，但框架缺乏对复用能力的很好支撑，导致资源浪费、特征价值无法充分发挥。
- **平台化能力缺失**：框架提供了特征读写的底层开发能力，但缺乏对特征迭代完整周期的平台化追踪和管理能力。

2.2 新平台的优势

针对旧框架的不足，我们在 2018 年中旬开始着手搭建新版的特征平台，经过不断的摸索、实践和优化，平台功能逐渐完备，使特征迭代能力更上一层台阶。

特征平台框架由三部分组成：训练样本生成（离线）、特征生产（近线）以及特征获取计算（在线），如下图所示：

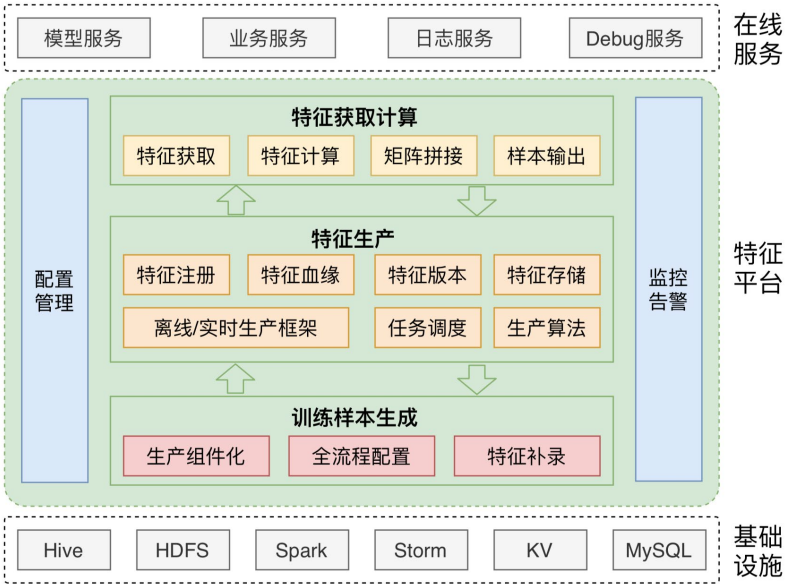

- **训练样本生成**：离线侧，平台提供统一配置化的训练样本生成能力，为模型的效果验证提供数据支撑。
- **特征生产**：近线侧，平台提供面对海量特征数据的加工、调度、存储、同步能力，保证特征数据在线快速生效。
- **特征获取计算**：在线侧，平台提供高可用的特征获取能力和高性能的特征计算能力，灵活支撑多种复杂模型的特征需求。

目前，外卖特征平台已接入外卖多条业务线，涵盖数十个场景，为业务的策略迭代提供平台化支持。其中，平台的优势在于两点：

- **业务提效**：通过特征配置化管理能力、特征 & 算子 & 解决方案复用能力以及离线在线打通能力，提升了特征迭代效率，降低了业务的接入成本，助力业务快速拿到结果。
- **业务赋能**：平台以统一的标准建立特征效果评估体系，有助于特征在业务间的借鉴和流通，最大程度发挥出特征的价值。

3. 特征平台建设

3.1 特征生产：海量特征的生产能力

特征同步的方式有多种，业界常见做法是通过开发 MR 任务 /Spark 任务 / 使用同步组件，从多个数据源读取多个字段，并将聚合的结果同步至 KV 存储。这种做法实现简单，但存在以下问题：

- **特征重复拉取**：同一特征被不同任务使用时，会导致特征被重复拉取，造成资源浪费。
- **缺乏全局调度**：同步任务间彼此隔离，相互独立，缺乏多任务的全局调度管理机制，无法进行特征复用、增量更新、全局限流等操作，影响特征的同步速度。
- **存储方式不够灵活健壮**：新特征存储时，涉及到上下游代码 / 文件的改动，迭代成本高，特征数据异常时，需长时间重导旧数据，回滚效率较低。

围绕上述几点问题，本文将从三个方面进行特征生产核心机制的介绍：

- **特征语义机制**：用于解决平台从数百个数据源进行特征拉取和转化的效率问题。
- **特征多任务调度机制**：用于解决海量特征数据的快速同步问题。
- **特征存储机制**：用于解决特征存储在配置化和可靠性方面的问题。

3.1.1 特征语义

特征平台目前已接入上游 Hive 表数百个、特征配置近万个，其中大部分特征都需天级别的更新。那平台如何从上游高效地拉取特征呢？直观想法是从特征配置和上游 Hive 表两个角度进行考虑：

特征配置角度：平台根据每个特征配置，单独启动任务进行特征拉取。

- 优点：控制灵活。
- 缺点：每个特征都会启动各自的拉取任务，执行效率低且耗费资源。

上游 Hive 表角度：Hive 表中多个特征字段，统一放至同一任务中拉取。

  - 优点：任务数量可控，资源占用低。

- 缺点：任务逻辑耦合较重，新增特征时需感知 Hive 表其它字段拉取逻辑，导致接入成本高。

上述两种方案都存在各自问题，不能很好满足业务需求。因此，特征平台结合两个方案的优点，并经过探索分析，提出了特征语义的概念：

- **特征语义**：由特征配置中的上游 Hive 表、特征维度、特征过滤条件、特征聚合条件四个字段提取合并而成，本质就是相同的查询条件，比如：Select **KeyInHive**,f1,f2 From **HiveSrc** Where **Condition** Group by **Group**，此时该四个字段配置相同，可将 F1、F2 两个特征的获取过程可合并为一个 SQL 语句进行查询，从而减少整体查询次数。另外，平台将语义合并过程做成自动化透明化，接入方只需关心新增特征的拉取逻辑，无需感知同表其它字段，从而降低接入成本。

特征平台对特征语义的处理分为两个阶段：语义抽取和语义合并，如下图所示：

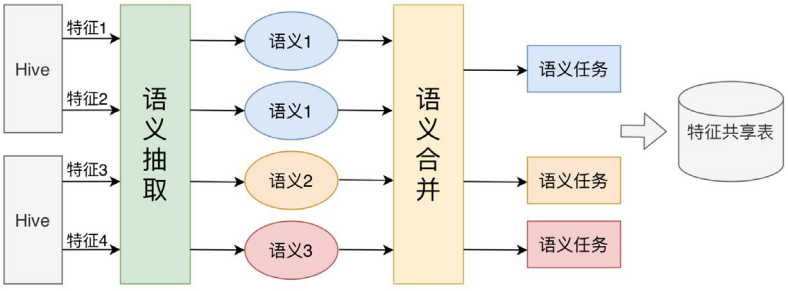

- **语义抽取**：平台解析特征配置，构建 SQL 语法树，通过支持多种形式判同逻辑（比如交换律、等效替换等规则），生成可唯一化表达的 SQL 语句。
- **语义合并**：如果不同特征对应的语义相同，平台会将其抽取过程进行合并，比如：Select KeyInHive, **Extract1 as f1, Extract2 as f2** From HiveSrc Where Condition Group by Group，其中 Extract 即特征的抽取逻辑，f1 和 f2 的抽取逻辑可进行合并，并将最终抽取到的特征数据落地至特征共享表中存储，供多业务方使用。

3.1.2 特征多任务调度

为了保证每天数十 TB 数据量的快速同步，特征平台首先按照特征的处理流程：获取、聚合和同步，分别制定了特征语义任务、特征聚合任务和特征同步任务：

- **特征语义任务**：用于将特征数据从数据源拉取解析，并落地至特征共享表中。
- **特征聚合任务**：用于不同业务线（租户）按照自身需求，从特征共享表中获取特定特征并聚合，生成全量快照以及增量数据。
- **特征同步任务**：用于将增量数据（天级）和全量数据（定期）同步至 KV 存储中。

同时，特征平台搭建了多任务调度机制，将不同类型的任务进行调度串联，以提升特征同步的时效性，如下图所示：

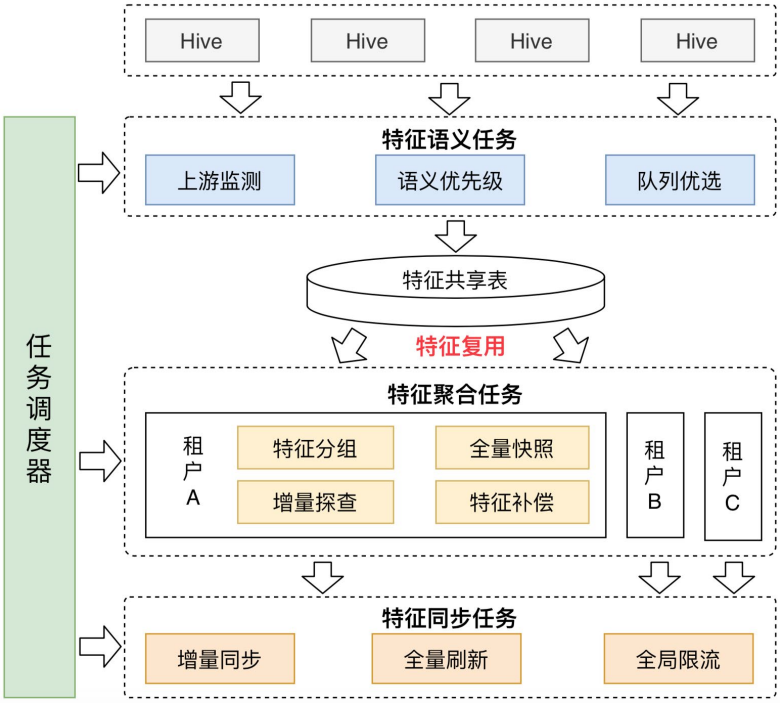

- **任务调度器**：按照任务执行顺序，循环检测上游任务状态，保证任务的有序执行。
- **特征语义任务调度**：当上游 Hive 表就绪后，执行语义任务。
  - 上游监测：通过上游任务调度接口实时获取上游 Hive 表就绪状态，就绪即

拉取，保证特征拉取的时效性。

- 语义优先级：每个语义都会设置优先级，高优先级语义对应的特征会被优先聚合和同步，保证重要特征的及时更新。
- 队列优选：平台会获取多个队列的实时状态，并优先选择可用资源最多的队列执行语义任务，提升任务执行效率。

- **特征复用**：特征的价值在于复用，特征只需接入平台一次，就可在不同业务间流通，是一种业务赋能的体现。
  - 特征统一存储在特征共享表中，供下游不同业务方按需读取，灵活使用。
  - 特征的统一接入复用，避免相同数据的重复计算和存储，节省资源开销。
- **特征聚合任务调度**：当上游语义任务就绪后，执行聚合任务。
  - 多租户机制：多租户是平台面向多业务接入的基础，业务以租户为单位进行特征管理，并为平台分摊计算资源和存储资源。
  - 特征分组：特征分组将相同维度下的多个特征进行聚合，以减少特征 Key 的数量，避免大量 Key 读写对 KV 存储性能造成的影响。
  - 全量快照：平台通过天级别聚合的方式生成特征全量快照，一方面便于增量数据探查，另一方面也避免历史数据的丢失。
  - 增量探查：通过将最新特征数据与全量快照的数值对比，探查出发生变化的特征，便于后续增量同步。
  - 特征补偿：因就绪延迟而未被当天同步的特征，可跨天进行补偿同步，避免出现特征跨天丢失的问题。
- **特征同步任务调度**：当上游聚合任务就绪后，执行同步任务。
  - 增量同步：将经全量快照探查到的增量数据，同步写入 KV 存储，大大降低数据写入量，提升同步效率。
  - 全量刷新：KV 存储中的数据由于过期时间限制，需定期进行全量刷新，避免出现特征过期导致的数据丢失问题。
  - 全局限流：通过监测同步任务的并行度以及 KV 存储状态指标，实时调整全局同步速度，在保证 KV 存储稳定性前提下，充分利用可用资源来提升特征同步效率。

3.1.3 特征存储

3.1.3.1 特征动态序列化

特征数据通过聚合处理后，需存储到 HDFS/KV 系统中，用于后续任务 / 服务的使用。数据的存储会涉及到存储格式的选型，业界常见的存储格式有 JSON、Object、Protobuf 等，其中 JSON 配置灵活，Object 支持自定义结构，Protobuf 编码性能好且压缩比高。由于特征平台支持的数据类型较为固定，但对序列化反序列化性能以及数据压缩效果有较高要求，因此选择 Protobuf 作为特征存储格式。

Protobuf 的常规使用方式是通过 Proto 文件维护特征配置。新增特征需编辑 Proto 文件，并编译生成新版本 JAR 包，在离线 & 在线同时发布更新后，才能生产解析新增特征，导致迭代成本较高。Protobuf 也提供了动态自描述和反射机制，帮助生产侧和消费侧动态适配消息格式的变更，避免静态编译带来的 JAR 包升级成本，但代价是空间成本和性能成本均高于静态编译方式，不适用于高性能、低时延的线上场景。

针对该问题，特征平台从特征元数据管理的角度，设计了一种基于 Protobuf 的特征动态序列化机制，在不影响读写性能前提下，做到对新增特征读写的完全配置化。

为方便阐述，先概述下 Protobuf 编码格式。如下图所示，Protobuf 按“键 – 值”形式序列化每个属性，其中键标识了该属性的序号和类型。可以看出，从原理上，序列化主要要依赖键中定义的字段序号和类型。

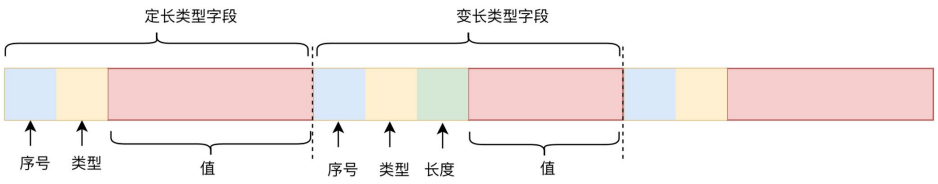

因此，特征平台通过从元数据管理接口查询元数据，来替换常规的 Proto 文件配置方式，去动态填充和解析键中定义的字段序号和类型，以完成序列化和反序列化，如下图所示：

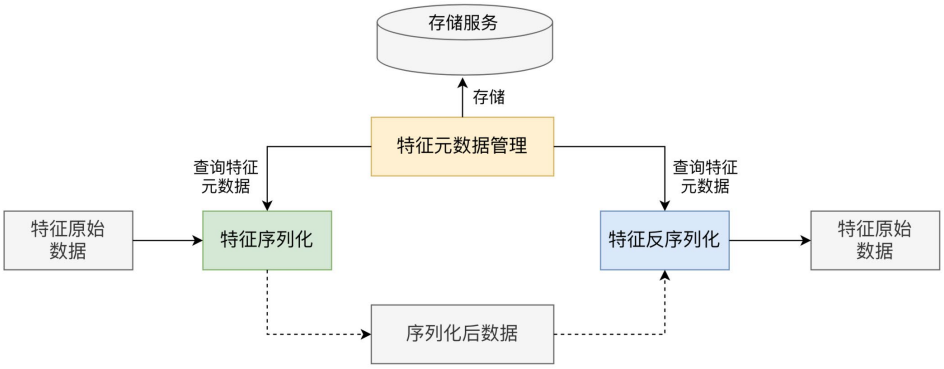

- **特征序列化**：通过查询特征元数据，获取特征的序号和类型，将特征序号填充至键的序号属性中，并根据特征类型决定键的类型属性以及特征值的填充方式。
- **特征反序列化**：解析键的属性，获取特征序号，通过查询特征元数据，获取对应的特征类型，并根据特征类型决定特征值的解析方式（定长 / 变长）。

3.1.3.2 特征多版本

特征数据存储于 KV 系统中，为在线服务提供特征的实时查询。业界常见的特征在线存储方式有两种：单一版本存储和多版本存储。

- 单一版本存储即覆盖更新，用新数据直接覆盖旧数据，实现简单，对物理存储占用较少，但在数据异常的时候无法快速回滚。
- 多版本存储相比前者，增加了版本概念，每一份数据都对应特定版本，虽然物理存储占用较多，但在数据异常的时候可通过版本切换的方式快速回滚，保证线上稳定性。

因此，特征平台选择特征多版本作为线上数据存储方式。

传统的多版本方式是通过全量数据的切换实现，即每天在全量数据写入后再进行版本切换。然而，特征平台存在增量和全量两种更新方式，不能简单复用全量的切换方式，需考虑增量和全量的依赖关系。因此，特征平台设计了一种适用于增量 & 全量两种更新方式下的版本切换方式（如下图所示）。该方式以全量数据为基础，白天进行增量更新，版本保持不变，在增量更新结束后，定期进行全量更新（重写），并进行版本切换。

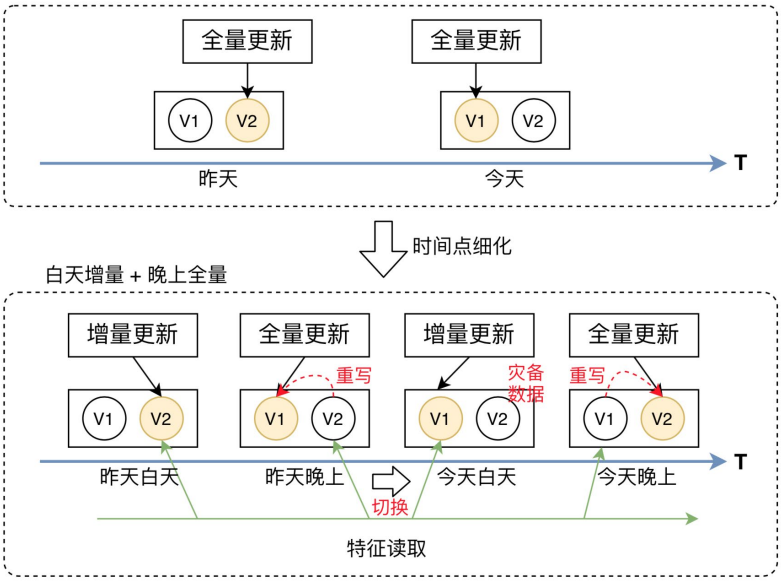

3.2 特征获取计算：高性能的特征获取计算能力

特征获取计算为模型服务、业务系统、离线训练提供特征的实时获取能力和高性能的计算能力，是特征平台能力输出的重要途径。

旧框架中，特征处理分散在业务系统中，与业务逻辑耦合严重，随着模型规模增长和业务系统的架构升级，特征处理性能逐渐成为瓶颈，主要存在以下问题：

- **需要代码开发**：特征处理的代码冗长，一方面会造成易增难改的现象，另一方面相同逻辑代码重复拷贝较多，也会造成复用性逐渐变差，代码质量就会持续恶化。
- **潜在性能风险**：大量实验同时进行，每次处理特征并集，性能会互相拖累。
- **一致性难以保证**：离线训练样本和在线预估对特征的处理逻辑难以统一。

因此，我们在新平台建设中，将特征处理逻辑抽象成独立模块，并对模块的职责边界做了清晰设定：通过提供统一 API 的方式，只负责特征的获取和计算，而不关心业务流程上下文。在新的特征获取和计算模块设计中，我们主要关注以下两个方面：

- **易用性**：特征处理配置的易用性会影响到使用方的迭代效率，如果新增特征或

更改特征计算逻辑需要代码改动，势必会拖慢迭代效率。

- **性能**：特征处理过程需要实时处理大量特征的拉取和计算逻辑，其效率会直接影响到上游服务的整体性能。

围绕以上两点，本文将从下述两个方面分别介绍特征获取计算部分：

- **模型特征自描述 MFDL**：将特征计算流程配置化，提升特征使用的易用性。
- **特征获取流程**：统一特征获取流程，解决特征获取的性能问题。

3.2.1 模型特征自描述 MFDL

模型特征处理是模型预处理的一部分，业界常用的做法有：

- 将特征处理逻辑和模型打包在一起，使用 PMML 或类似格式描述。优点是配置简洁；缺点是无法单独更新模型文件或特征配置。
- 将特征处理逻辑和模型隔离，特征处理部分使用单独的配置描述，比如 JSON 或 CSV 等格式。优点是特征处理配置和模型文件分离，便于分开迭代；缺点是可能会引起特征配置和模型加载不一致性的问题，增加系统复杂度。

考虑到对存量模型的兼容，我们定义了一套自有的配置格式，能独立于模型文件之外快速配置。基于对原有特征处理逻辑的梳理，我们将特征处理过程抽象成以下两个部分：

- **模型特征计算**：主要用来描述特征的计算过程。这里区分了原始特征和模型特征：将从数据源直接获取到的特征称之为原始特征，将经过计算后输入给模型的特征称之为模型特征，这样就可以实现同一个原始特征经过不同的处理逻辑计算出不同的模型特征。
- **模型特征转换**：将生成的模型特征根据配置转换成可以直接输入给模型的数据格式。由于模型特征计算的结果不能被模型直接使用，还需要经过一些转换逻辑的处理，比如转换成 Tensor、Matrix 等格式。

基于该两点，特征平台设计了 MFDL（Model Feature Description Language）来完整的描述模型特征的生成流程，用配置化的方式描述模型特征计算和转换过程。其

中，特征计算部分通过自定义的 DSL 来描述，而特征转换部分则针对不同类型的模型设计不同的配置项。通过将特征计算和转换分离，就可以很方便的扩展支持不同的机器学习框架或模型结构。

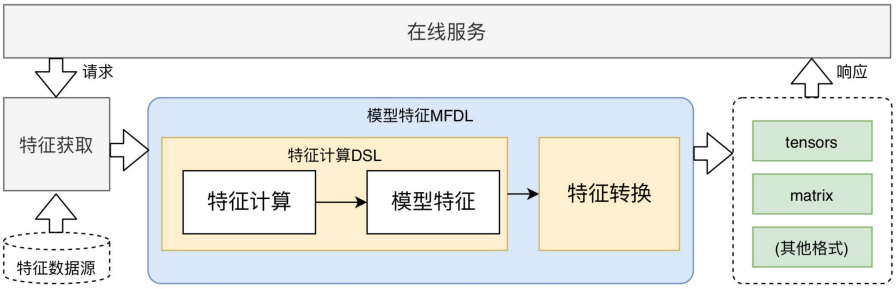

在 MFDL 流程中，特征计算 DSL 是模型处理的重点和难点。一套易用的特征计算规范需既要满足特征处理逻辑的差异性，又要便于使用和理解。经过对算法需求的了解和对业界做法的调研，我们开发了一套易用易读且符合编程习惯的特征表达式，并基于 JavaCC 实现了高性能的执行引擎，支持了以下特性：

- **特征类型**：支持以下常用的特征数据结构：
  - **单值类型（String/Long/Double）**：数值和文本类型特征，如商家好评率。
  - **Map 类型**：交叉或字典类型的特征。
  - **List 类型**：Embedding 或向量特征。
- **逻辑运算**：支持常规的算术和逻辑运算，比如 a>b?(a−b):0。
- **函数算子**：逻辑运算只适合少量简单的处理逻辑，而更多复杂的逻辑通常需要通过函数算子来完成。业务方既可以根据自己的需求编写算子，也可快速复用平台定期收集整理的常用算子，以降低开发成本，提升模型迭代效率。

特征计算 DSL 举例如下所示：

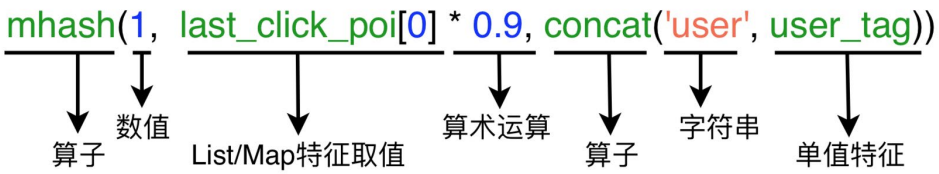

基于规范化的 DSL，一方面可以让执行引擎在执行阶段做一些主动优化，包括向量化计算、并行计算等，另一方面也有助于使用方将精力聚焦于特征计算的业务逻辑，而不用关心实现细节，既降低了使用门槛，也避免了误操作对线上稳定性造成的影响。

由于 MFDL 是独立于模型文件之外的配置，因此特征更新迭代时只需要将新的配置推送到服务器上，经过加载和预测后即可生效，实现了特征处理的热更新，提升了迭代效率。同时，MFDL 也是离线训练时使用的特征配置文件，结合统一的算子逻辑，保证了离线训练样本 / 在线预估特征处理的一致性。在系统中，只需要在离线训练时配置一次，训练完成后即可一键推送到线上服务，安全高效。

下面是一个 TF 模型的 MFDL 配置示例：

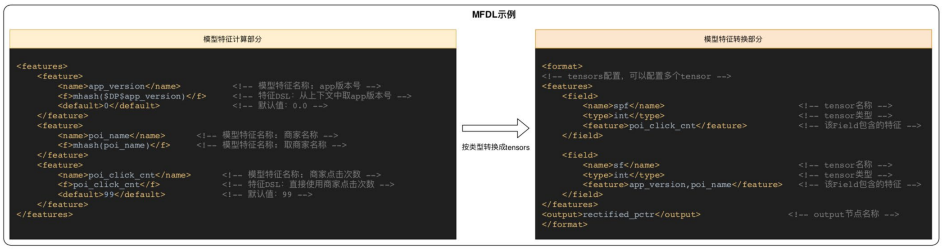

3.2.2 特征获取流程

MFDL 中使用到的特征数据，需在特征计算之前从 KV 存储进行统一获取。为了提升特征获取效率，平台会对多个特征数据源异步并行获取，并针对不同的数据源，使用不同的手段进行优化，比如 RPC 聚合等。特征获取的基本流程如下图所示：

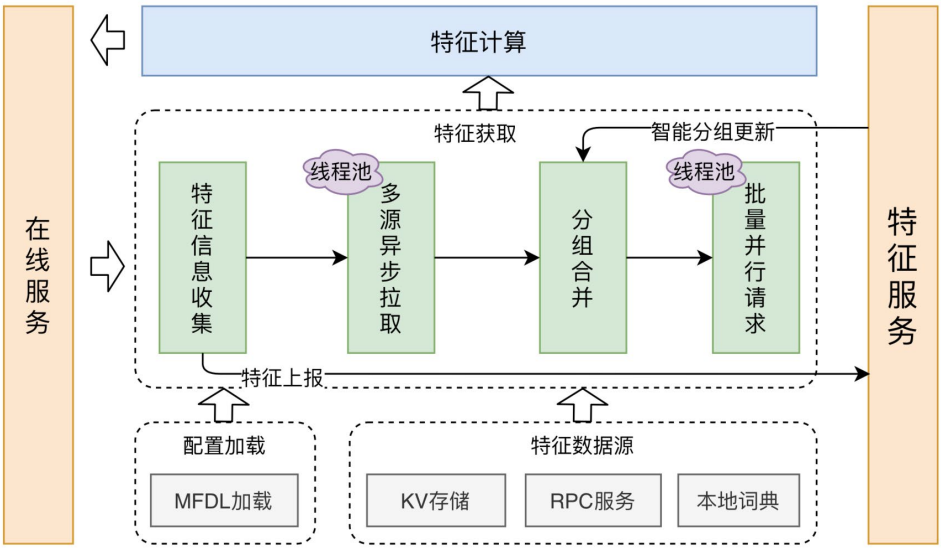

在特征生产章节已经提到，特征数据是按分组进行聚合存储。特征获取在每次访问 KV 存储时，都会读取整个分组下所有的特征数据，一个分组下特征数量的多少将会直接影响到在线特征获取的性能。因此，我们在特征分组分配方面进行了相关优化，既保证了特征获取的高效性，又保证了线上服务的稳定性。

3.2.2.1 智能分组

特征以分组的形式进行聚合，用于特征的写入和读取。起初，特征是以固定分组的形式进行组织管理，即不同业务线的特征会被人工聚合到同一分组中，这种方式实现简单，但却暴露出以下两点问题：

- **特征读取性能差**：线上需要读取解析多个业务线聚合后的特征大 Value，而每个业务线只会用到其中部分特征，导致计算资源浪费、读取性能变差。
- **影响 KV 集群稳定性**：特征大 Value 被高频读取，一方面会将集群的网卡带宽打满，另一方面大 Value 不会被读取至内存，只能磁盘查找，影响集群查询性能（特定 KV 存储场景）。

因此，特征平台设计了智能分组，打破之前固定分组的形式，通过合理机制进行特征分组的动态调整，保证特征聚合的合理性和有效性。如下图所示，平台打通了线上线

下链路，线上用于上报业务线所用的特征状态，线下则通过收集分析线上特征，从全局视角对特征所属分组进行智能化的整合、迁移、反馈和管理。同时，基于存储和性能的折中考虑，平台建立了两种分组类型：业务分组和公共分组：

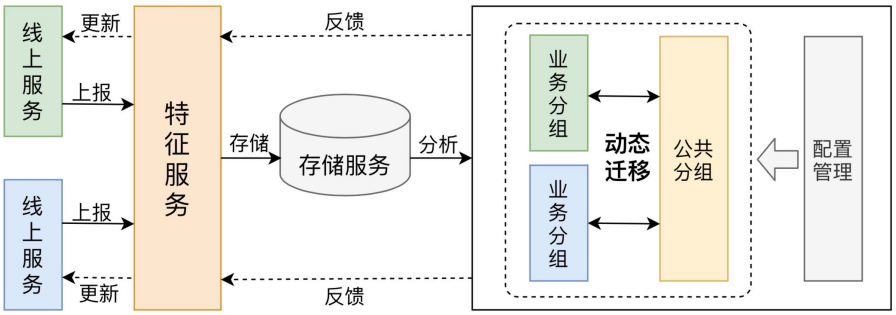

- **业务分组**：用于聚合每个业务线各自用到的专属特征，保证特征获取的有效性。如果特征被多业务共用，若仍存储在各自业务分组，会导致存储资源浪费，需迁移至公共分组（存储角度）。
- **公共分组**：用于聚合多业务线同时用到的特征，节省存储资源开销，但分组增多会带来 KV 存储读写量增大，因此公共分组数量需控制在合理范围内（性能角度）。

通过特征在两种分组间的动态迁移以及对线上的实时反馈，保证各业务对特征所拉即所用，提升特征读取性能，保证 KV 集群稳定性。

3.2.2.2 分组合并

智能分组可以有效的提升特征获取效率，但同时也引入了一个问题：在智能分组过程中，特征在分组迁移阶段，会出现一个特征同时存在于多个分组的情况，造成特征在多个分组重复获取的问题，增加对 KV 存储的访问压力。为了优化特征获取效率，在特征获取之前需要对特征分组进行合并，将特征尽量放在同一个分组中进行获取，从而减少访问 KV 存储的次数，提升特征获取性能。

如下图所示，经过分组合并，将特征获取的分组个数由 4 个（最坏情况）减少到 2 个，从而对 KV 存储访问量降低一半。

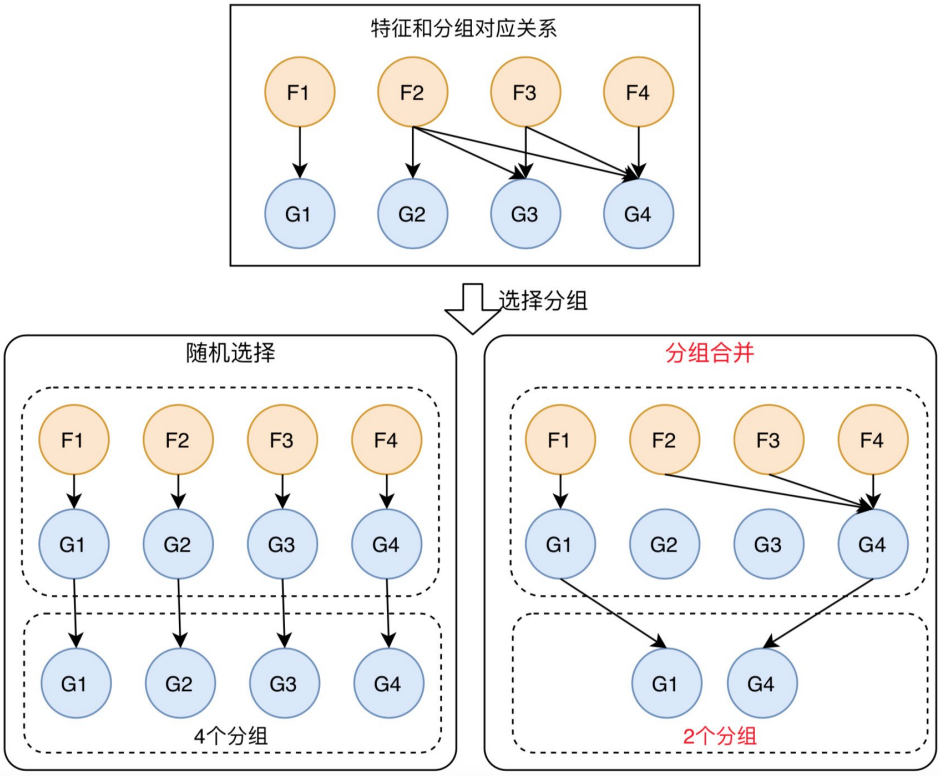

3.3 训练样本构建：统一配置化的一致性训练样本生成能力

3.3.1 现状分析

训练样本是特征工程连接算法模型的一个关键环节，训练样本构建的本质是一个数据加工过程，而这份数据如何做到“能用”（数据质量要准确可信）、“易用”（生产过程要灵活高效）、“好用”（通过平台能力为业务赋能）对于算法模型迭代的效率和效果至关重要。

在特征平台统一建设之前，外卖策略团队在训练样本构建流程上主要遇到几个问题：

- **重复性开发**：缺少体系化的平台系统，依赖一些简单工具或定制化开发 Hive/Spark 任务，与业务耦合性较高，在流程复用、运维成本、性能调优等方面都表现较差。
- **灵活性不足**：样本构建流程复杂，包括但不限数据预处理、特征抽取、特征样

本拼接、特征验证，以及数据格式转换（如 TFRecord）等，已有工具在配置化、扩展性上很难满足需求，使用成本较高。

- **一致性较差**：线上、线下在配置文件、算子上使用不统一，导致在线预测样本与离线训练样本的特征值不一致，模型训练正向效果难保障。

3.3.2 配置化流程

平台化建设最重要的流程之一是“如何进行流程抽象”，业界有一些机器学习平台的做法是平台提供较细粒度的组件，让用户自行选择组件、配置依赖关系，最终生成一张样本构建的 DAG 图。

对于用户而言，这样看似是提高了流程编排的自由度，但深入了解算法同学实际工作场景后发现，算法模型迭代过程中，大部分的样本生产流程都比较固定，反而让用户每次都去找组件、配组件属性、指定关系依赖这样的操作，会给算法同学带来额外的负担，所以我们尝试了一种新的思路来优化这个问题：**模板化 + 配置化**，即平台提供一个基准的模板流程，该流程中的每一个节点都抽象为一个或一类组件，用户基于该模板，通过简单配置即可生成自己样本构建流程，如下图所示：

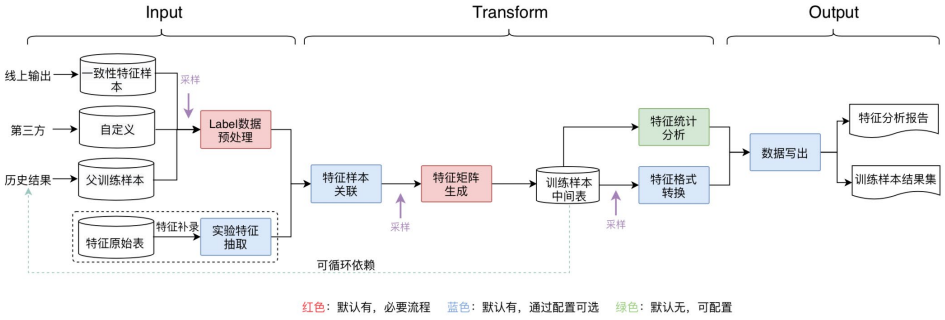

整个流程模板包括三个部分：**输入（Input）、转化（Transform）、输出（Output）**，其中包含的组件有：Label 数据预处理、实验特征抽取、特征样本关联、特征矩阵生成、特征格式转换、特征统计分析、数据写出，组件主要功能：

- **Label 数据预处理**：支持通过自定义 Hive/Spark SQL 方式抽取 Label 数据，平台也内置了一些 UDF（如 URL Decode、MD5/Murmur Hash 等），通过

自定义 SQL+UDF 方式灵活满足各种数据预处理的需求。在数据源方面，支持如下类型：

- 一致性特征样本：指线上模型预测时，会将一次预测请求中使用到的特征及 Label 相关字段收集、加工、拼接，为离线训练提供基础的样本数据，推荐使用，可更好保障一致性。
- 自定义：不使用算法平台提供的一致性特征样本数据源，通过自定义方式抽取 Label 数据。
- 父训练样本：可依赖之前或其他同学生产的训练样本结果，只需要简单修改特征或采样等配置，即可实现对原数据微调，快速生成新的训练数据，提高执行效率。

- **实验特征抽取**：线下训练如果需要调研一些新特征（即在一致性特征样本中不存在）效果，可以通过特征补录方式加入新的特征集。
- **特征样本关联**：将 Label 数据与补录的实验特征根据唯一标识（如：poi_id）进行关联。
- **特征矩阵生成**：根据用户定义的特征 MFDL 配置文件，将每一个样本需要的特征集计算合并，生成特征矩阵，得到训练样本中间表。
- **特征格式转换**：基于训练样本中间表，根据不同模型类型，将数据转换为不同格式的文件（如：CSV/TFRecord）。
- **特征统计分析**：辅助功能，基于训练样本中间表，对特征统计分析，包括均值、方差、最大 / 最小值、分位数、空值率等多种统计维度，输出统计分析报告。
- **数据写出**：将不同中间结果，写出到 Hive 表 /HDFS 等存储介质。

上面提到，整个流程是模板化，模板中的多数环节都可以通过配置选择开启或关闭，所以整个流程也支持从中间的某个环节开始执行，灵活满足各类数据生成需求。

3.3.3 一致性保障

（1）为什么会不一致?

上文还提到了一个关键的问题：一致性较差。先来看下为什么会不一致?

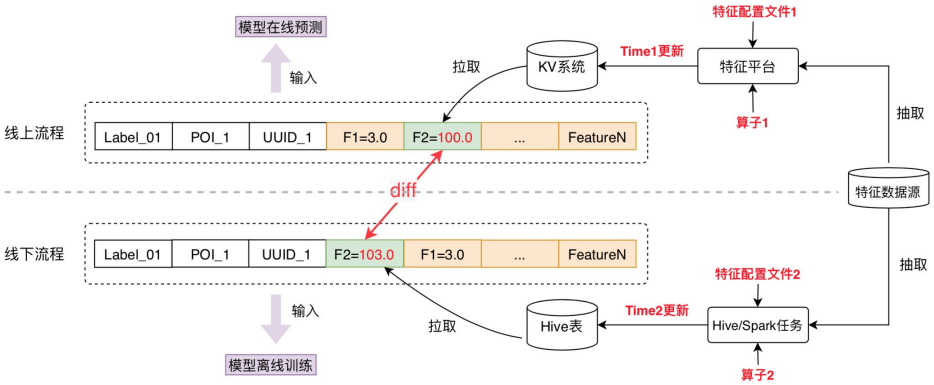

上图展示了在离线训练和在线预测两条链路中构建样本的方式，最终导致离线、在线特征值 Diff 的原因主要有三点：

- **特征配置文件不一致**：在线侧、离线侧对特征计算、编排等配置描述未统一，靠人工较难保障一致性。
- **特征更新时机不一致**：特征一般是覆盖更新，特征抽取、计算、同步等流程较长，由于数据源更新、重刷、特征计算任务失败等诸多不确定因素，在线、离线在不同的更新时机下，数据口径不一致。
- **特征算子定义不一致**：从数据源抽取出来的原始特征一般都需要经过二次运算，线上、线下算子不统一。

（2）如何保证一致性?

明确了问题所在，我们通过如下方案来解决一致性问题：

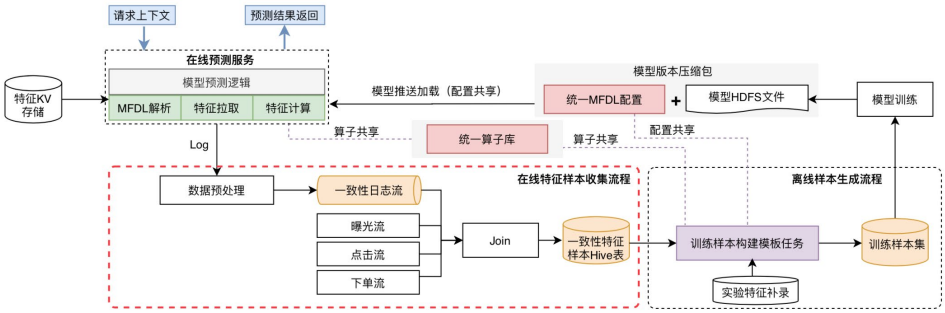

- **打通线上线下配置**

线下生成训练样本时，用户先定义特征 MFDL 配置文件，在模型训练后，通过平台一键打包功能，将 MFDL 配置文件以及训练输出的模型文件，打包、上传到模型管理平台，通过一定的版本管理及加载策略，将模型动态加载到线上服务，从而实现线上、线下配置一体化。

- **提供一致性特征样本**

通过实时收集在线 Serving 输出的特征快照，经过一定的规则处理，将结果数据输出到 Hive 表，作为离线训练样本的基础数据源，提供一致性特征样本，保障在线、离线数据口径一致。

- **统一特征算子库**

上文提到可以通过特征补录方式添加新的实验特征，补录特征如果涉及到算子二次加工，平台既提供基础的算子库，也支持自定义算子，通过算子库共用保持线上、线下计算口径一致。

3.3.4 为业务赋能

从特征生产，到特征获取计算，再到生成训练样本，特征平台的能力不断得到延展，逐步和离线训练流程、在线预测服务形成一个紧密协作的整体。在特征平台的能力边界上，我们也在不断的思考和探索，希望能除了为业务提供稳定、可靠、易用的特征数据之外，还能从特征的视角出发，更好的建设特征生命周期闭环，通过平台化的能力反哺业务，为业务赋能。在上文特征生产章节，提到了特征平台一个重要能力：特征复用，这也是特征平台为业务赋能最主要的一点。

特征复用需要解决两个问题：

- **特征快速发现**：当前特征平台有上万特征，需要通过平台化的能力，让高质量的特征快速被用户发现，另外，特征的“高质量”如何度量，也需要有统一的评价标准来支撑。

- **特征快速使用**：对于用户发现并筛选出的目标特征，平台需要能够以较低的配置成本、计算资源快速支持使用（参考上文 3.1.2 小节“特征复用”）。

本小节重点介绍如何帮助用户快速发现特征，主要包括两个方面：主动检索和被动推荐，如下图所示：

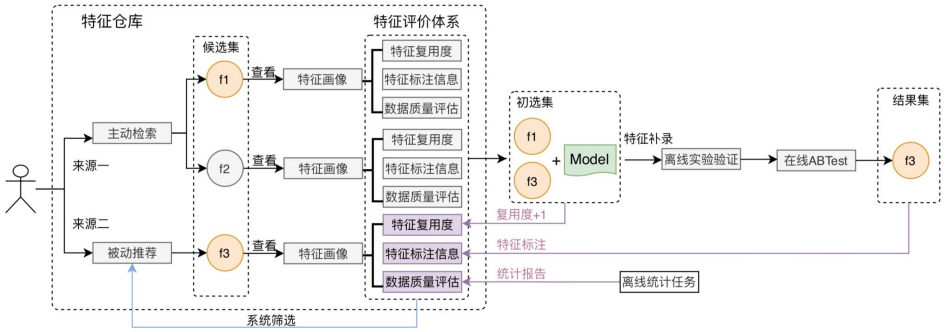

- 首先，用户可以通过主动检索，从特征仓库筛选出目标特征候选集，然后结合特征画像来进一步筛选，得到特征初选集，最后通过离线实验流程、在线 ABTest，结合模型效果，评估筛选出最终的结果集。其中特征画像主要包括以下评价指标：
  - 特征复用度：通过查看该特征在各业务、各模型的引用次数，帮助用户直观判断该特征的价值。
  - 特征标注信息：通过查看该特征在其他业务离线、在线效果的标注信息，帮助用户判断该特征的正负向效果。
  - 数据质量评估：平台通过离线统计任务，按天粒度对特征进行统计分析，包括特征的就绪时间、空值率、均值、方差、最大 / 小值、分位点统计等，生成特征评估报告，帮助用户判断该特征是否可靠。
- 其次，平台根据特征的评价体系，将表现较好的 Top 特征筛选出来，通过排行榜展现、消息推送方式触达用户，帮助用户挖掘高分特征。

为业务赋能是一个长期探索和实践的过程，未来我们还会继续尝试在深度学习场景中，建立每个特征对模型贡献度的评价体系，并通过自动化的方式打通模型在线上、

线下的评估效果，通过智能化的方式挖掘特征价值。

4. 总结与展望

这篇文章分别从特征框架演进、特征生产、特征获取计算以及训练样本生成四个方面介绍了特征平台在建设与实践中的思考和优化思路。经过两年的摸索建设和实践，外卖特征平台已经建立起完善的架构体系、一站式的服务流程，为外卖业务的算法迭代提供了有力支撑。

未来，外卖特征平台将继续推进从离线 -> 近线 -> 在线的全链路优化工作，在计算性能、资源开销、能力扩展、合作共建等方面持续投入人力探索和建设，并在更多更具挑战的业务场景中发挥平台的价值。同时，平台将继续和模型服务和模型训练紧密结合，共建端到端算法闭环，助力外卖业务蓬勃发展。

5. 作者简介

英亮、陈龙、刘磊、亚劼、乐彬等，美团外卖算法平台工程师。

6. 招聘信息

美团外卖广告工程团队长期招聘后台高级工程师 / 技术专家，负责广告多个方向（推荐 / 搜索 / 召回 / 预估 / 创新）的系统研发工作，坐标北京。欢迎感兴趣的同学加入我们。可投简历至：changyingliang@meituan.com（邮件主题请注明：美团外卖广告工程团队）

美团基于知识图谱的剧本杀标准化建设与应用

作者：李翔　陈焕　志华　晓阳　王奇

剧本杀作为爆发式增长的新兴业务，在商家上单、用户选购、供需匹配等方面存在不足，供给标准化能为用户、商家、平台三方创造价值，助力业务增长。本文介绍了美团到店综合业务数据团队从 0 到 1 快速建设剧本杀供给标准化的过程及算法方案。我们将美团到店综合知识图谱（GENE，GEneral NEeds net）覆盖至剧本杀行业，构建剧本杀知识图谱实现供给标准化建设，包括剧本杀供给挖掘、标准剧本库构建、供给与标准剧本关联等环节，并在多个场景进行应用落地，希望给大家带来一些帮助或启发。

一、背景

剧本杀行业近年来呈爆发式增长态势，然而由于剧本杀是新兴行业，平台已有的类目体系和产品形态，越来越难以满足飞速增长的用户和商户需求，主要表现在下面三个方面：

- **平台类目缺失**：平台缺少专门的“剧本杀”类目，中心化流量入口的缺失，导致用户决策路径混乱，难以建立统一的用户认知。
- **用户决策效率低**：剧本杀的核心是剧本，由于缺乏标准的剧本库，也未建立标准剧本和供给的关联关系，导致剧本信息展示和供给管理的规范化程度低，影响了用户对剧本选择决策的效率。
- **商品上架繁琐**：商品信息需要商户人工一一录入，没有可用的标准模板用以信息预填，导致商户在平台上架的剧本比例偏低，上架效率存在较大的提升空间。

为了解决上述痛点，业务需要进行剧本杀的供给标准化建设：首先建立“剧本杀”新类目，并完成相应的供给（包括商户、商品、内容）的类目迁移。以此为基础，以剧本为核心，搭建标准剧本库，并关联剧本杀供给，继而建立剧本维度的信息分发渠道、评价评分和榜单体系，满足用户“以剧本找店”的决策路径。

值得指出的是，供给标准化是简化用户认知、帮助用户决策、促进供需匹配的重要抓手，标准化程度的高低对平台业务规模的大小有着决定性影响。具体到剧本杀行业，供给标准化建设是助力剧本杀业务持续增长的重要基础，而标准剧本库的搭建是剧本杀供给标准化的关键。由于基于规格如「城限」、背景如「古风」、题材如「情感」等剧本属性无法确定具体的剧本，但剧本名称如「舍离」则能起唯一标识的作用。因此，标准剧本库的搭建，首先是标准剧本名称的建设，其次是规格、背景、题材、难度、流派等标准剧本属性的建设。

综上，美团到店综合业务数据团队与业务同行，助力业务进行剧本杀的供给标准化建设。在建设过程中，涉及了剧本名称、剧本属性、类目、商户、商品、内容等多种类型的实体，以及它们之间的多元化关系构建。而知识图谱作为一种揭示实体及实体间关系的语义网络，用以解决该问题显得尤为合适。特别地，我们已经构建了**美团到店综合知识图谱（GENE，GEneral NEeds net）**，因此，我们基于 GENE 的构建经验快速进行剧本杀这一新业务的知识图谱构建，从 0 到 1 实现剧本杀标准化建设，从而改善供给管理和供需匹配，为用户、商户、平台三方创造出更大的价值。

二、解决方案

我们构建的 GENE，围绕本地生活用户的综合性需求，以行业体系、需求对象、具象需求、场景要素和场景需求五个层次逐层递进，覆盖了玩乐、医美、教育、亲子、结婚等多个业务，体系设计和技术细节可见美团到店综合知识图谱相关的文章。剧本杀作为一项新兴的美团到店综合业务，体现了用户在玩乐上的新需求，天然适配 GENE 的体系结构。因此，我们将 GENE 覆盖至剧本杀新业务，沿用相同的思路来进行相应知识图谱的构建，以实现相应的供给标准化。

基于知识图谱来实现剧本杀标准化建设的关键，是以标准剧本为核心构建剧本杀知识图谱。图谱体系设计如图 1 所示，具体地，首先在行业体系层进行剧本杀新类目的构建，挖掘剧本杀供给，并建立供给（包括商户、商品、内容）与类目的从属关系。在此基础上，在需求对象层，进一步实现标准剧本名称这一核心对象节点和其剧本属性

节点的挖掘以及关系构建，建立标准剧本库，最后将标准剧本库的每个标准剧本与供给和用户建立关联关系。此外，具象需求、场景要素、场景需求三层则实现了对用户在剧本杀上的具象的服务需求和场景化需求的显性表达，这部分由于与剧本杀供给标准化建设的联系不多，在这里不做展开介绍。

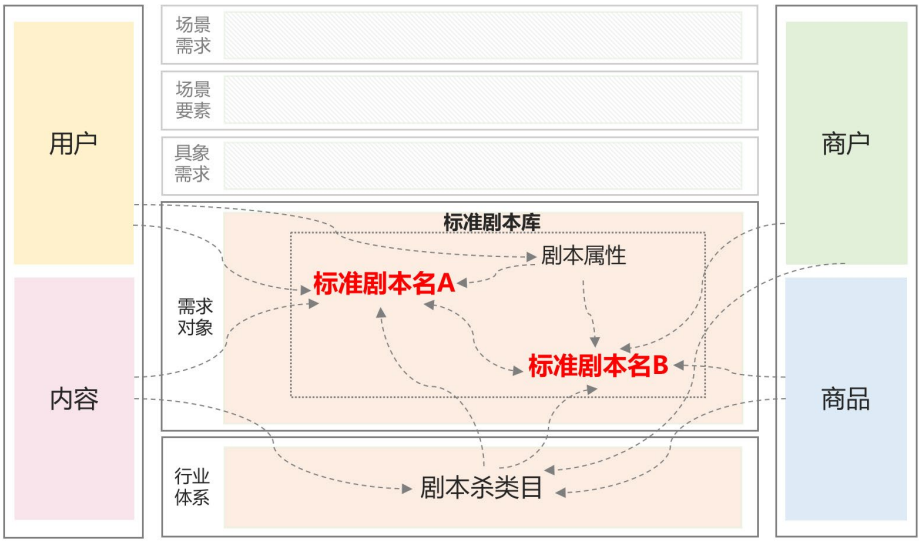

图 1

剧本杀知识图谱中用于供给标准化部分的具体样例如下图 2 所示。其中，标准剧本名称是核心节点，围绕它的各类标准剧本属性节点包括题材、规格、流派、难度、背景、别称等。同时，标准剧本之间可能构建诸如“同系列”等类型的关系，比如「舍离」和「舍离 2」。此外，标准剧本还会与商品、商户、内容、用户之间建立关联关系。

我们基于剧本杀知识图谱的这些节点和关系进行供给标准化，在图谱构建过程中，包括了**剧本杀供给挖掘、标准剧本库构建、供给与标准剧本关联**三个主要步骤，下面对三个步骤的实现细节以及涉及的算法进行介绍。

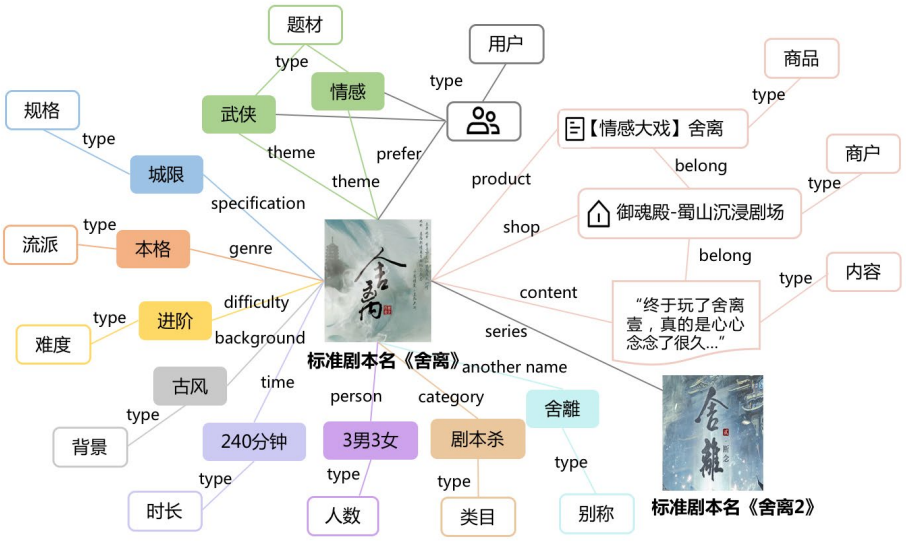

图 2

三、实现方法

3.1 剧本杀供给挖掘

剧本杀作为新兴的业务，已有的行业类目树中并没有相应的类目，无法直接根据类目获取剧本杀的相关供给（包括商户、商品和内容）。因此，我们需要首先进行剧本杀供给的挖掘，即从当前与剧本杀行业相近类目的供给中挖掘出剧本杀的相关供给。

对于剧本杀的商户供给挖掘，需要判断商户是否提供剧本杀服务，判别依据包括了商户名、商品名及商品详情、商户 UGC 三个来源的文本语料。这个本质上是一个多源数据的分类问题，然而由于缺乏标注的训练样本，我们没有直接采用端到端的多源数据分类模型，而是依托业务输入，采用无监督匹配和有监督拟合相结合的方式高效实现，具体的判别流程如下图 3 所示，其中：

- **无监督匹配**：首先构造剧本杀相关的关键词词库，分别在商户名、商品名及商品详情、商户 UGC 三个来源的文本语料中进行精确匹配，并构建基于 BERT[1] 的通用语义漂移判别模型进行匹配结果过滤。最后根据业务规则基于

各来源的匹配结果计算相应的匹配分数。

- **有监督拟合**：为了量化不同来源匹配分数对最终判别结果的影响，由运营先人工标注少量商户分数，用以表征商户提供剧本杀服务的强弱。在此基础上，我们构造了一个线性回归模型，拟合标注的商户分数，获取各来源的权重，从而实现对剧本杀商户的精准挖掘。

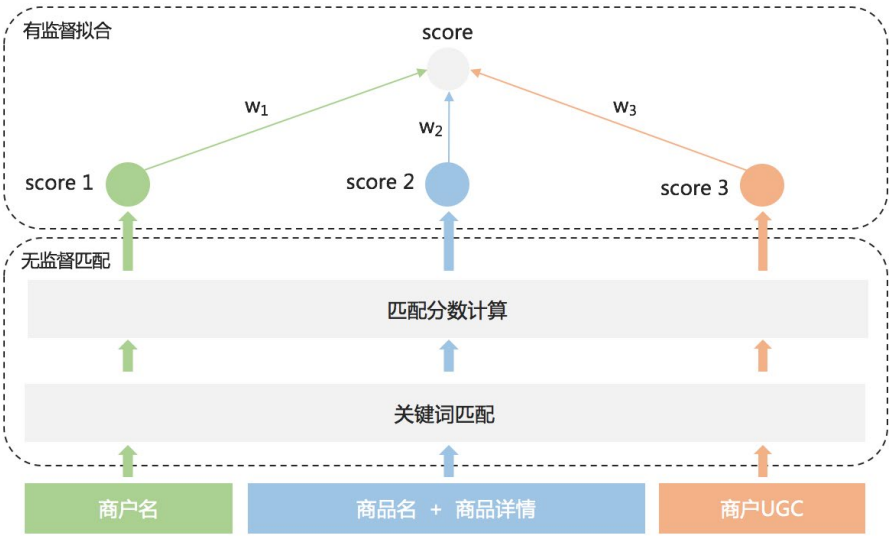

图 3

采用上述方式，实现了桌面和实景两种剧本杀商户的挖掘，准确率和召回率均达到了要求。基于剧本杀商户的挖掘结果，能够进一步对商品进行挖掘，并创建剧本杀类目，从而为后续剧本杀知识图谱构建及标准化建设打好了数据基础。

3.2 标准剧本库构建

标准剧本作为整个剧本杀知识图谱的核心，在剧本杀供给标准化建设中扮演着重要的角色。我们基于剧本杀商品相似聚合的方式，结合人工审核来挖掘标准剧本，并从相关发行方获取剧本授权，从而构建标准剧本库。标准剧本由两部分构成，一个是标准剧本名称，另一个是标准剧本属性。因此，标准剧本库构建也分为标准剧本名称的挖掘和标准剧本属性的挖掘两个部分。

3.2.1 标准剧本名称的挖掘

我们根据剧本杀商品的特点，先后采用了规则聚合、语义聚合和多模态聚合三种方法进行挖掘迭代，从数十万剧本杀商品的名称中聚合得到数千标准剧本名称。下面分别对三种聚合方法进行介绍。

规则聚合

同一个剧本杀商品在不同商户的命名往往不同，存在较多的不规范和个性化。一方面，同一个剧本名称本身就可以有多种叫法，例如「舍离」、「舍离壹」、「舍离 1」就是同一个剧本；另一方面，剧本杀商品名除了包含剧本名称外，商家很多时候也会加入剧本的规格和题材等属性信息以及吸引用户的描述性文字，例如「《舍离》情感本」。所以我们首先考虑剧本杀商品的命名特点，设计相应的清洗策略对剧本杀商品名称进行清洗后再聚合。

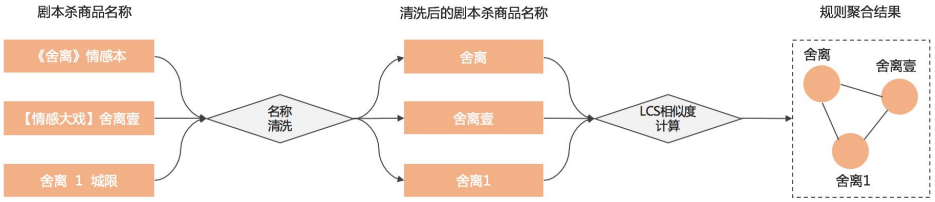

图 4

我们除了梳理常见的非剧本词，构建词库进行规则过滤外，也尝试将其转换为命名实体识别问题 [2]，采用序列标注对字符进行“是剧本名”与“不是剧本名”两个类别的区分。对于清洗后的剧本杀商品名称，则通过基于最长公共子序列（LCS）的相似度计算规则，结合阈值筛选对其进行聚合，例如「舍离」、「舍离壹」、「舍离 1」最后均聚在一起。整个流程如上图 4 所示，采用规则聚合的方式，能够在建设初期帮助业务快速对剧本杀商品名称进行聚合。

语义聚合

规则聚合的方式虽然简单好用，但由于剧本名称的多样性和复杂性，我们发现聚合结果中仍然存在一些问题：1）不属于同一个剧本的商品被聚合，例如「舍离」和「舍离

2」是同一个系列的两个不同剧本，却被聚合在一起。2）属于同一个剧本的商品没有聚合，例如，商品名使用剧本的简称缩写（「唐人街名侦探和猫」和「唐探猫」）或出现错别字（「弗洛伊德之锚」和「佛洛依德之锚」）等情况时则难以规则聚合。

针对这上述这两种问题，我们进一步考虑使用商品名称语义匹配的方式，从文本语义相同的角度来进行聚合。常用的文本语义匹配模型分为交互式和双塔式两种类型。交互式是把两段文本一起输入进编码器，在编码的过程中让其相互交换信息后再进行判别；双塔式模型是用一个编码器分别给两个文本编码出向量，然后基于两个向量进行判别。

由于商品数量众多，采用交互式的方法需要将商品名称两两组合后再进行模型预测，效率较为低下，为此，我们采用双塔式的方法来实现，以 Sentence-BERT[3] 的模型结构为基础，将两个商品名称文本分别通过 BERT 提取向量后，再使用余弦距离来衡量两者的相似度，完整结构如下图 5 所示：

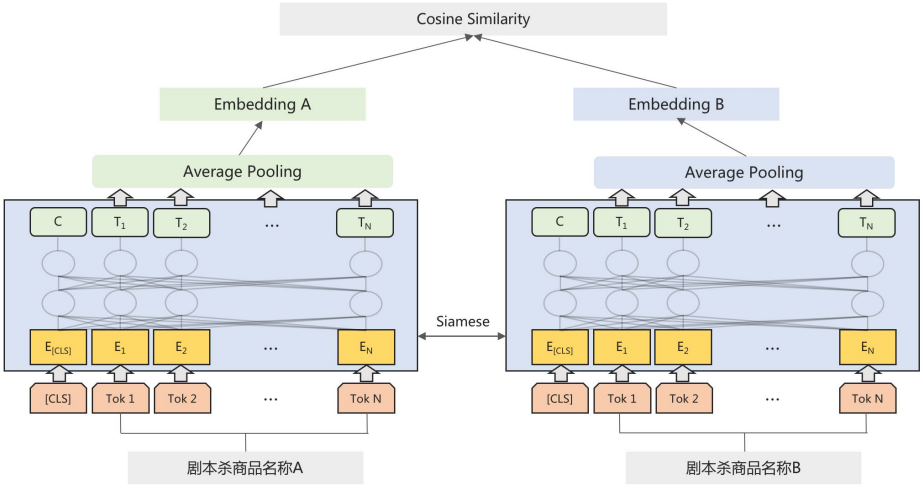

图 5

在训练模型的过程中，我们首先基于规则聚合的结果，通过同聚簇内生成正例和跨聚簇交叉生成负例的方式，构造粗粒度的训练样本，完成初版模型的训练。在此基础上，进一步结合主动学习，对样本数据进行完善。此外，我们还根据上文提到的规则聚合出现的两种问题，针对性的批量生成样本。具体地，通过在商品名称后添加同系

列编号，以及使用错字、别字和繁体字替换等方式来实现样本的自动构造。

多模态聚合

通过语义聚合的方式实现了从商品名称文本语义层面的同义聚合，然而我们通过对聚合结果再分析后发现还存在一些问题：两个商品属于同一个剧本，但仅从商品名称的角度是无法判别。例如，「舍离 2」和「断念」从语义的角度无法聚合，但是它们本质上是一个剧本「舍离 2 · 断念」。虽然这两个商品的名称各异，但是它们的图像往往是相同或相似的，为此，我们考虑引入商品的图像信息来进行辅助聚合。

一个简单的方法是，使用 CV 领域成熟的预训练模型作为图像编码器进行特征提取，直接计算两个商品的图像相似度。为了统一商品图像相似度计算和商品名称语义匹配的结果，我们尝试构建一个剧本杀商品的多模态匹配模型，充分利用商品名称和图像信息来进行匹配。模型沿用语义聚合中使用的双塔式结构，整体结构如下图 6 所示：

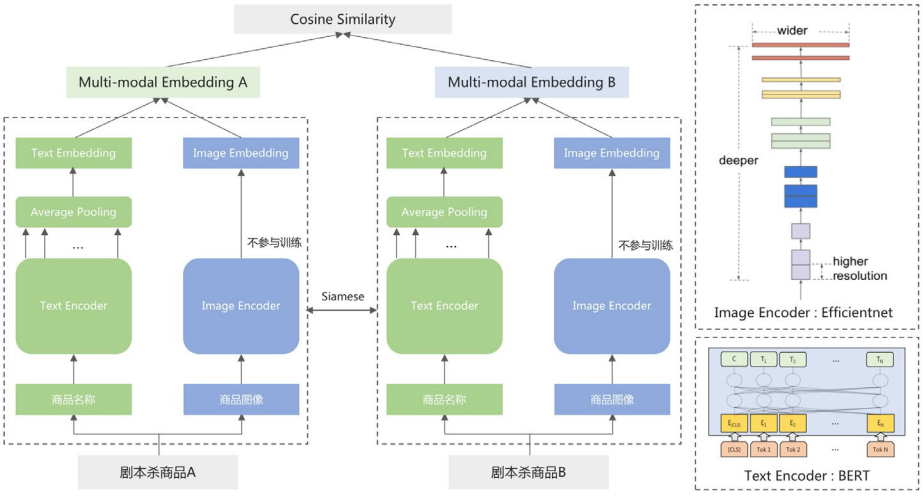

图 6

在多模态匹配模型中，剧本杀商品的名称和图像分别通过文本编码器和图像编码器得到对应的向量表示后，再进行拼接作为最终的商品向量，最后使用余弦相似度来衡量商品之间的相似度。其中：

- **文本编码器**：使用文本预训练模型 BERT[1] 作为文本编码器，将输出平均池化后作为文本的向量表示。
- **图像编码器**：使用图像预训练模型 EfficientNet[4] 作为图像编码器，提取网络最后一层输出作为图像的向量表示。

在训练模型的过程中，文本编码器会进行 Finetune，而图像编码器则固定参数，不参与训练。对于训练样本构建，我们以语义聚合的结果为基础，以商品图像相似度来圈定人工标注样本的范围。具体地，对于同聚簇内商品图像相似度高的直接生成正例，跨聚簇交叉的商品图像相似度低的直接生成负例，而对于剩余的样本对则交由人工进行标注确定。通过多模态聚合，弥补了仅使用文本匹配的不足，与其相比准确率提升了 5%，进一步提升了标准剧本的挖掘效果。

3.2.2 标准剧本属性的挖掘

标准剧本的属性包括了剧本的背景、规格、流派、题材、难度等十余个维度。由于商户在剧本杀商品上单的时候会录入商品的这些属性值，所以对于标准剧本属性的挖掘，本质上是对该标准剧本对应的所有聚合商品的属性的挖掘。

在实际过程中，我们通过投票统计的方式来进行挖掘，即对于标准剧本的某个属性，通过对应的聚合商品在该属性上的属性值进行投票，选择投票最高的属性值，作为该标准剧本的候选属性值，最后由人工审核确认。此外，在标准剧本名称挖掘的过程中，我们发现同一个剧本的叫法多种多样，为了对标准剧本能有更好的描述，还进一步为标准剧本增加了一个别称的属性，通过对标准剧本对应的所有聚合商品的名称进行清洗和去重来获取。

3.3 供给与标准剧本关联

在完成标准剧本库构建后，还需要建立剧本杀的商品、商户和内容三种供给，与标准剧本的关联关系，从而使剧本杀的供给实现标准化。由于通过商品和标准剧本的关联关系，可以直接获取该商品对应商户和标准剧本的关系，所以我们只需要对商品和内容进行标准剧本关联。

3.3.1 商品关联

在 3.2 节中，我们通过聚合存量剧本杀商品的方式来进行标准剧本的挖掘，在这个过程中其实已经构建了存量商品和标准剧本的关联关系。对于后续新增加的商品，我们还需要将其和标准剧本进行匹配，以建立两者之间的关联关系。而对于与标准剧本无法关联的商品，我们则自动进行标准剧本名称和属性的挖掘，经由人工审核后再加入标准剧本库。

整个商品关联流程如下图 7 所示，首先对商品名称进行清洗再进行匹配关联。在匹配环节，我们基于商品和标准剧本的名称及图像的多模态信息，对两者进行匹配判别。

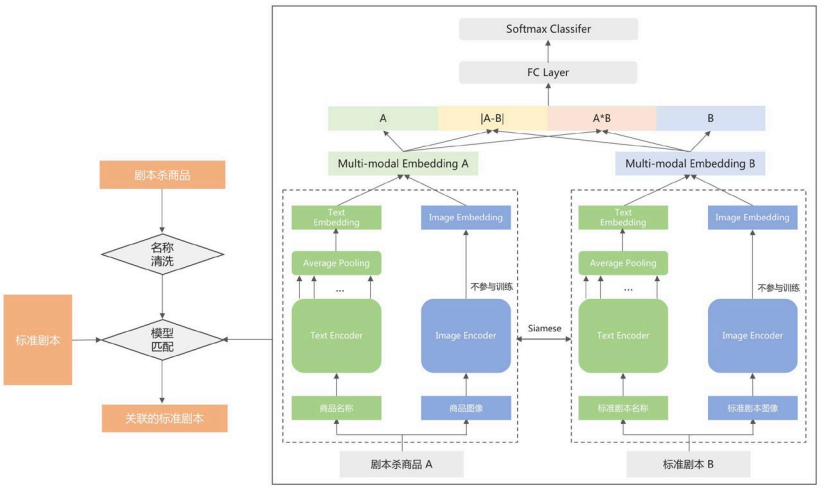

图 7

与商品之间的匹配不同，商品与标准剧本的关联不需要保持匹配的对称性。为了保证关联的效果，我们在 3.2.1 节的多模态匹配模型的结构基础上进行修改，将商品和标准剧本的向量拼接后通过全连接层和 softmax 层计算两者关联的概率。训练样本则直接根据存量商品和标准剧本的关联关系构造。通过商品关联，我们实现了绝大部分剧本杀商品的标准化。

3.3.2 内容关联

对于剧本杀内容关联标准剧本，主要针对用户产生的内容（UGC，例如用户评价）这

一类型的内容和标准剧本的关联。由于一段 UGC 文本通常包含多个句子，且其中只有部分句子会提及标准剧本相关信息，所以我们将 UGC 与标准剧本的匹配，细化为其子句粒度的匹配，同时出于效率和效果的平衡的考虑，进一步将匹配过程分为了召回和排序两个阶段，如下图 8 所示：

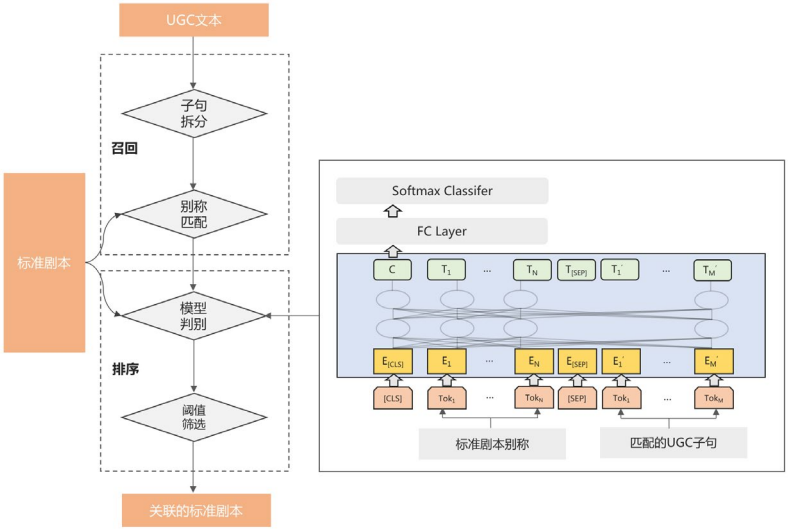

图 8

在召回阶段，将 UGC 文本进行子句拆分，并根据标准剧本名称及其别称，在子句集合中进行精确匹配，对于匹配中的子句则将进入到排序阶段进行精细化的关联关系判别。

在排序阶段，将关联关系判别转换为一个 Aspect-based 的分类问题，参考属性级情感分类的做法 [5]，构建基于 BERT 句间关系分类的匹配模型，将实际命中 UGC 子句的标准剧本别称和对应的 UGC 子句用 [SEP] 相连后输入，通过在 BERT 后增加全连接层和 softmax 层来实现是否关联的二分类，最后对模型输出的分类概率进行阈值筛选，获取 UGC 关联的标准剧本。

与上文中涉及的模型训练不同，UGC 和标准剧本的匹配模型无法快速获取大量训练样本。考虑到训练样本的缺乏，所以首先通过人工少量标注数百个样本，在此基础上，除了采用主动学习外，我们还尝试对比学习，基于 Regularized Dropout[6] 方

法，对模型两次 Dropout 的输出进行正则约束。最终在训练样本不到 1K 的情况下，UGC 关联标准剧本的准确率达到上线要求，每个标准剧本关联的 UGC 数量也得到了大幅提升。

四、应用实践

当前剧本杀知识图谱，以数千标准剧本为核心，关联百万供给。剧本杀供给标准化建设的结果已在美团多个业务场景上进行了初步的应用实践。下面介绍具体的应用方式和应用效果。

4.1 类目构建

通过剧本杀供给挖掘，帮助业务识别出剧本杀商户，从而助力剧本杀新类目和相应剧本杀列表页的构建。剧本杀类目迁移、休闲娱乐频道页的剧本杀入口、剧本杀列表页均已上线，其中，频道页剧本杀 ICON 固定第三行首位，提供了中心化流量入口，有助于建立统一的用户认知。上线示例如图 9 所示（(a) 休闲娱乐频道页剧本杀入口，(b) 剧本杀列表页）。

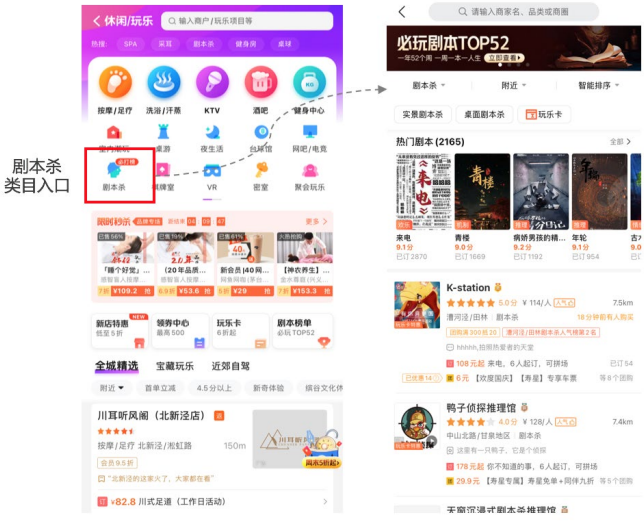

图 9

4.2 个性化推荐

剧本杀知识图谱包含的标准剧本及属性节点，以及其与供给和用户的关联关系，可应用于剧本杀各页面的推荐位。一方面应用于剧本列表页热门剧本推荐（图 10(a)），另一方面还应用于剧本详情页的商品在拼场次推荐（图 10(b) 左）、可玩门店推荐（图 10(b) 左）和相关剧本推荐模块（图 10(b) 右）。这些推荐位的应用，帮助培养了用户在平台找剧本的心智，优化了用户认知和选购体验，提高了用户和供给的匹配效率。

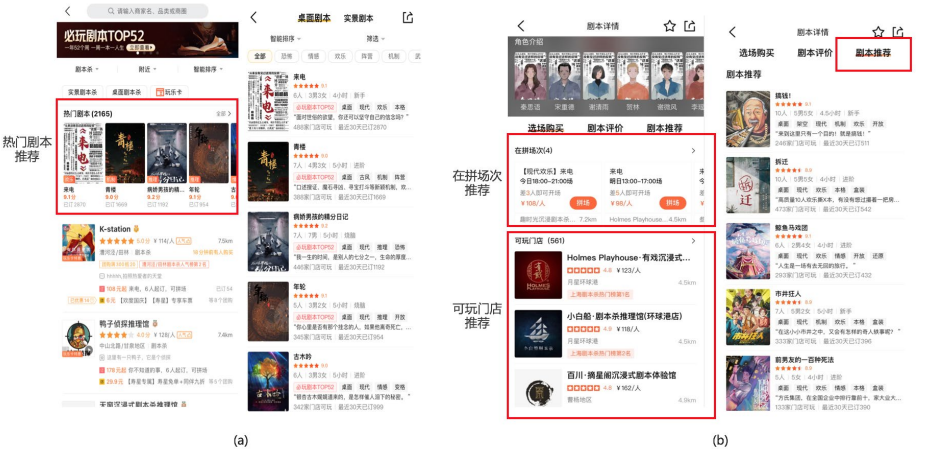

图 10

以剧本列表页的热门剧本推荐模块为例，剧本杀知识图谱包含的节点和关系除了可以直接用于剧本的召回，还可以进一步在精排阶段进行应用。在精排中，我们基于剧本杀知识图谱，结合用户行为，参考 Deep Interest Network（DIN）[7] 模型结构，尝试对用户访问剧本的序列和访问商品的序列进行建模，构建双通道 DIN 模型，深度刻画用户兴趣，实现剧本的个性化分发。其中商品访问序列部分，通过商品与标准剧本的关联关系将其转为为剧本序列，与候选剧本采用 Attention 方式进行建模，具体模型结构如下图 11 所示：

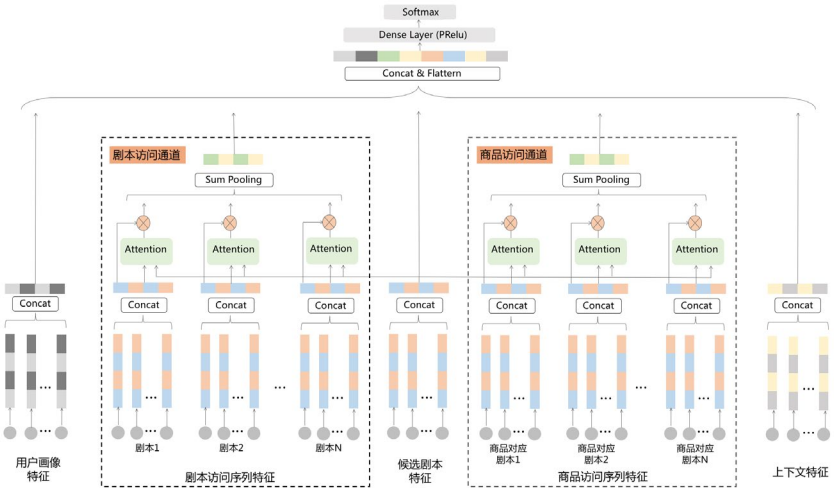

图 11

4.3 信息外露和筛选

基于剧本杀知识图谱中的节点和关系，在剧本杀列表页和在剧本列表页增加相关标签筛选项，并外露剧本的属性和关联的供给信息，相关应用如下图 12 所示。这些标签筛选项和信息的外露，为用户提供了规范的信息展示，降低了用户决策成本，更加方便了用户选店和选剧本。

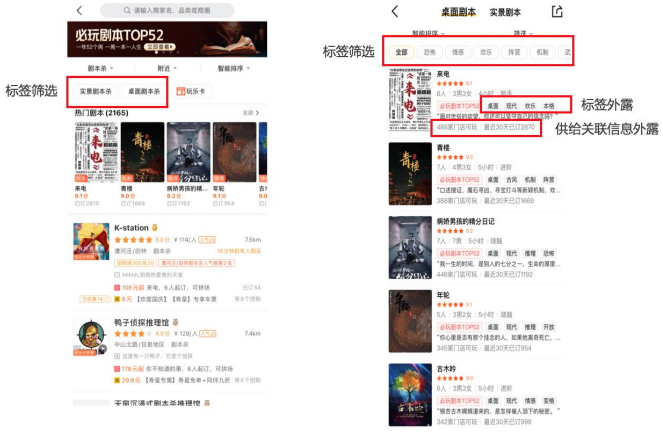

图 12

4.4 评分和榜单

在剧本详情页，内容和标准剧本的关联关系参与到剧本的评分计算中（图 13(a)）。在此基础上，基于剧本维度，形成经典必玩和近期热门的剧本榜单，如图 13(b) 所示，从而为用户的剧本选择决策提供了更多的帮助。

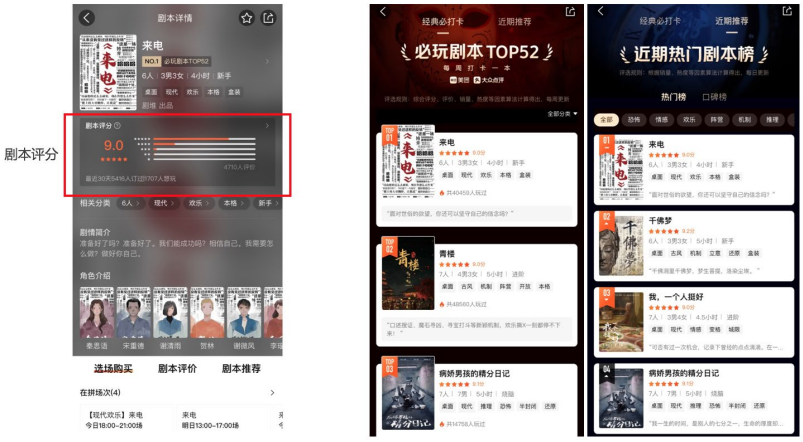

(a) (b)

图 13

五、总结展望

面对剧本杀这一新兴行业，我们快速响应业务，以标准剧本为核心节点，结合行业特点，通过剧本杀供给挖掘、标准剧本库构建、供给与标准剧本关联，构建相应的知识图谱，从 0 到 1 逐步推进剧本杀的供给标准化建设，力求以简单而有效的方法来解决剧本杀业务的问题。

目前剧本杀知识图谱已在剧本杀多个业务场景中取得应用成果，赋能剧本杀业务持续增长，显著提升了用户体验。在未来的工作中，我们将不断进行优化和探索：

- **标准剧本库的持续完善**：优化标准剧本名称和属性以及相应的供给关联关系，保证标准剧本库的质与量俱佳，并尝试引入外部的知识补充当前的标准化结果。
- **剧本杀场景化**：当前剧本杀知识图谱主要以“剧本”这类用户的具象需求对象

为主，后续将深入挖掘用户的场景化需求，探索剧本杀和其他行业的联动，更好的助力剧本杀行业的发展。

- **更多的应用探索**：将图谱数据应用于搜索等模块，在更多的应用场景中提升供给匹配效率，从而创造出更大的价值。

参考文献

[1] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
[2] Lample G, Ballesteros M, Subramanian S, et al. Neural architectures for named entity recognition[J]. arXiv preprint arXiv:1603.01360, 2016.
[3] Reimers N, Gurevych I. Sentence-bert: Sentence embeddings using siamese bert-networks[J]. arXiv preprint arXiv:1908.10084, 2019.
[4] Tan M, Le Q. EfficientNet: Rethinking model scaling for convolutional neural networks[C]//International Conference on Machine Learning. PMLR, 2019: 6105-6114.
[5] Sun C, Huang L, Qiu X. Utilizing BERT for aspect-based sentiment analysis via constructing auxiliary sentence[J]. arXiv preprint arXiv:1903.09588, 2019.
[6] Liang X, Wu L, Li J, et al. R-Drop: Regularized Dropout for Neural Networks[J]. arXiv preprint arXiv:2106.14448, 2021.
[7] Zhou G, Zhu X, Song C, et al. Deep interest network for click-through rate prediction[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018: 1059-1068.

作者简介

李翔、陈焕、志华、晓阳、王奇等，均来自美团到店平台技术部到综业务数据团队。

招聘信息

美团到店平台技术部 - 到综业务数据团队，长期招聘算法（自然语言处理 / 推荐算法）、数据仓库、数据科学、系统开发等岗位同学，坐标上海。欢迎感兴趣的同学发送简历至：licong.yu@meituan.com。

美团商品知识图谱的构建及应用

作者：雪智　凤娇　姿雯　匡俊　林森　武威

背景

美团大脑

近年来，人工智能正在快速地改变人们的生活，背后其实有两大技术驱动力：**深度学习**和**知识图谱**。我们将深度学习归纳为隐性的模型，它通常是面向某一个具体任务，比如说下围棋、识别猫、人脸识别、语音识别等等。通常而言，在很多任务上它能够取得很优秀的结果，同时它也有一些局限性，比如说它需要海量的训练数据，以及强大的计算能力，难以进行跨任务的迁移，并且不具有较好的可解释性。在另一方面，知识图谱作为显式模型，同样也是人工智能的一大技术驱动力，它能够广泛地适用于不同的任务。相比深度学习，知识图谱中的知识可以沉淀，具有较强的可解释性，与人类的思考更加贴近，为隐式的深度模型补充了人类的知识积累，和深度学习互为补充。因此，全球很多大型的互联网公司都在知识图谱领域积极进行布局。

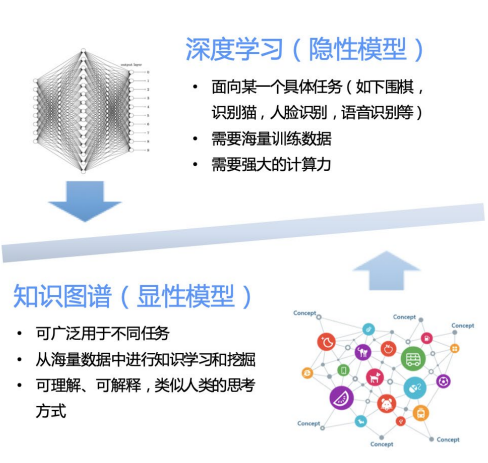

	深度学习	知识图谱
场景示例	人脸识别	语音助手
目前进展	在一些任务上已经接近或超过人类	在知识量上超过人类，在知识推理上不如人类
任务范围	面向具体任务，难以迁移	广泛适用于不同任务
可解释性	较难解释	可解释性强
数据量	海量训练数据	海量知识数据
未来趋势	未来深度融合	

图 1　人工智能两大驱动力

美团连接了数亿用户和数千万商户，背后也蕴含着丰富的日常生活相关知识。2018年，美团知识图谱团队开始构建美团大脑，着力于利用知识图谱技术赋能业务，进一步改善用户体验。具体来说，美团大脑会对美团业务中涉及到的千万级别商家、亿级别的菜品 / 商品、数十亿的用户评论，以及背后百万级别的场景进行深入的理解和结构化的知识建模，构建人、店、商品、场景之间的知识关联，从而形成生活服务领域大规模的知识图谱。现阶段，美团大脑已覆盖了数十亿实体，数百亿三元组，在餐饮、外卖、酒店、金融等场景中验证了知识图谱的有效性。

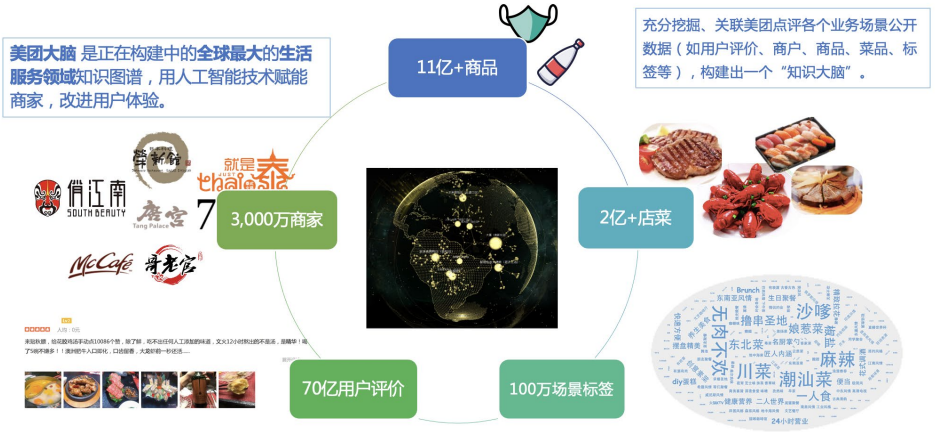

图 2　美团大脑

在新零售领域的探索

美团逐步突破原有边界，在生活服务领域探索新的业务，不仅局限于通过外卖、餐饮帮大家“吃得更好”，近年来也逐步拓展到零售、出行等其他领域，帮大家“生活更好”。在零售领域中，美团先后落地了美团闪购、美团买菜、美团优选、团好货等一系列相应的业务，逐步实现“万物到家”的愿景。为了更好地支持美团的新零售业务，我们需要对背后的零售商品建立知识图谱，积累结构化数据，深入对零售领域内商品、用户、属性、场景等的理解，以便能更好地为用户提供零售商品领域内的服务。

相比于围绕商户的餐饮、外卖、酒店的等领域，零售商品领域对于知识图谱的建设和

应用提出了更大的挑战。一方面，商品数量更加庞大，覆盖的领域范围也更加宽广。另一方面，商品本身所具有的显示信息往往比较稀疏，很大程度上需要结合生活中的常识知识来进行推理，方可将隐藏在背后的数十维的属性进行补齐，完成对商品完整的理解。在下图的例子中，“乐事黄瓜味”这样简单的商品描述其实就对应着丰富的隐含信息，只有对这些知识进行了结构化提取和相应的知识推理后，才能够更好的支持下游搜索、推荐等模块的优化。

图 3　商品结构化信息的应用

商品图谱建设的目标

我们针对美团零售业务的特点，制定了多层级、多维度、跨业务的零售商品知识图谱体系。

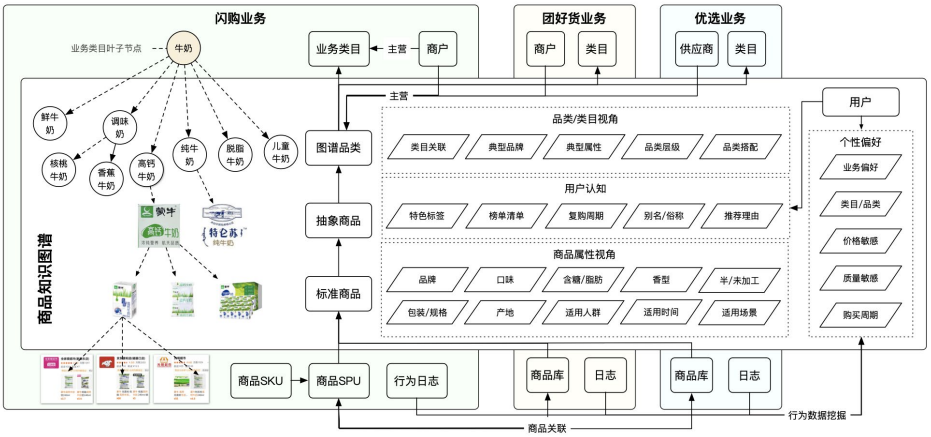

图 4　商品知识图谱体系

多层级

在不同业务的不同应用场景下，对于“商品”的定义会有所差别，需要对各个不同颗粒度的商品进行理解。因此，在我们的零售商品知识图谱中，建立了五层的层级体系，具体包括：

– L1– **商品 SKU/SPU**：对应业务中所售卖的商品颗粒度，是用户交易的对象，往往为商户下挂的商品，例如“望京家乐福所售卖的蒙牛低脂高钙牛奶 250ml 盒装”。这一层级也是作为商品图谱的最底层的基石，将业务商品库和图谱知识进行打通关联。

– L2– **标准商品**：描述商品本身客观事实的颗粒度，例如“蒙牛低脂高钙牛奶 250ml 盒装”，无论通过什么渠道在什么商户购买，商品本身并没有任何区别。商品条形码则是在标准商品这层的客观依据。在这一层级上，我们可以建模围绕标准商品的客观知识，例如同一个标准商品都会具有同样的品牌、口味、包装等属性。

– L3– **抽象商品**：进一步我们将标准商品向上抽象的商品系列，例如“蒙牛低脂高钙牛奶”。在这一层级中，我们不再关注商品具体的包装、规格等，将同系列的商品聚合为抽象商品，承载了用户对于商品的主观认知，包括用户对商品系列的别名俗称、品牌认知、主观评价等。

– L4– 主体品类：描述商品主体的本质品类，列如“鸡蛋”、“奶油草莓”、“台式烤肠”等。这一层作为商品图谱的后台类目体系，以客观的方式对商品领域的品类进行建模，承载了用户对于商品的需求，例如各品牌各产地的鸡蛋都能够满足用户对于鸡蛋这个品类的需求。

– L5– 业务类目：相比于主体品类的后台类目体系，业务类目作为前台类目体系会依据业务当前的发展阶段进行人工定义和调整，各个业务会根据当前业务阶段的特点和需求建立对应的前台类目体系。

多维度

- **商品属性视角**：围绕商品本身，我们需要有海量的属性维度来对商品进行描述。商品属性维度主要分为两类：一类是通用的属性维度，包括品牌、规格、包装、产地等；另一类是品类特有的属性维度，例如对于牛奶品类我们会关注脂肪含量（全脂 / 低脂 / 脱脂牛奶）、存储方式（常温奶、冷藏奶）等。商品属性主要是刻画了商品的客观知识，往往会建立在标准商品这一层级上。
- **用户认知视角**：除了客观的商品属性维度以外，用户往往对于商品会有一系列的主观认知，例如商品的别名俗称（“小黑瓶”、“快乐水”）、对于商品的评价（“香甜可口”、“入口即化”、“性价比高”）、商品的清单 / 榜单（“进口食品榜单”、“夏季消暑常备”）等维度。这些主观认知往往会建立在抽象商品这一层级上。
- **品类 / 类目视角**：从品类 / 类目的视角来看，不同品类 / 类目也会有各自不同的关注点。在这一层级上，我们会建模各个品类 / 类目下有哪些典型的品牌、用户关注哪些典型属性、不同品类的复购周期是多长时间等。

跨业务

美团大脑商品知识图谱的目标是希望能够对客观世界中的商品知识进行建模，而非局限于单个业务之中。在商品图谱的五层体系中，标准商品、抽象商品、品类体系都是与业务解耦的，围绕着客观商品所建立的，包括围绕这些层级建立的各维度数据也均是刻画了商品领域的客观知识。

在应用于各个业务当中时，我们将客观的图谱知识向上关联至业务前台类目，向下关联至业务商品 SPU/SKU，则可以完成各个业务数据的接入，实现各个业务数据和客观知识之间的联通，提供更加全面的跨业务的全景数据视角。利用这样的数据，在用户方面我们可以更加全面的建模、分析用户对于业务、品类的偏好，对于价格、品质等的敏感程度，在商品方面我们可以更准确的建模各品类的复购周期、地域 / 季节 / 节日偏好等。

商品图谱建设的挑战

商品知识图谱的构建的挑战主要来源于以下三个方面：

1. **信息来源质量低**：商品本身所具有的信息比较匮乏，往往以标题和图片为主。尤其在美团闪购这样 LBS 的电商场景下，商户需要上传大量的商品数据，对于商品信息的录入存在很多信息不完整的情况。在标题和图片之外，商品详情虽然也蕴含着大量的知识信息，但是其质量往往参差不齐，并且结构各异，从中进行知识挖掘难度极高。
2. **数据维度多**：在商品领域有众多的数据维度需要进行建设。以商品属性部分为例，我们不仅需要建设通用属性，诸如品牌、规格、包装、口味等维度，同时还要覆盖各个品类 / 类目下特定关注的属性维度，诸如脂肪含量、是否含糖、电池容量等，整体会涉及到上百维的属性维度。因此，数据建设的效率问题也是一大挑战。
3. **依赖常识 / 专业知识**：人们在日常生活中因为有很丰富的常识知识积累，可以通过很简短的描述获取其背后隐藏的商品信息，例如在看到“乐事黄瓜”这样一个商品的时候知道其实是乐事黄瓜味的薯片、看到“唐僧肉”的时候知道其实这不是一种肉类而是一种零食。因此，我们也需要探索结合常识知识的语义理解方法。同时，在医药、个护等领域中，图谱的建设需要依赖较强的专业知识，例如疾病和药品之间的关系，并且此类关系对于准确度的要求极高，需要做到所有知识都准确无误，因此也需要较好的专家和算法相结合的方式来进行高效的图谱构建。

商品图谱建设

在了解了图谱建设的目标和挑战后，接下来我们将介绍商品图谱数据建设的具体方案。

层级体系建设

品类体系建设

本质品类描述了商品本质所属的最细类别，它聚合了一类商品，承载了用户最终的消费需求，如“高钙牛奶”、“牛肉干”等。本质品类与类目也是有一定的区别，类目是若干品类的集合，它是抽象后的品类概念，不能够明确到具体的某类商品品类上，如“乳制品”、“水果”等。

品类打标：对商品图谱的构建来说，关键的一步便是建立起商品和品类之间的关联，即对商品打上品类标签。通过商品和品类之间的关联，我们可以建立起商品库中的商品与用户需求之间的关联，进而将具体的商品展示到用户面前。下面简单介绍下品类打标方法：

1. **品类词表构建**：品类打标首先需要构建一个初步的商品品类词表。首先，我们通过对美团的各个电商业务的商品库、搜索日志、商户标签等数据源进行分词、NER、新词发现等操作，获得初步的商品候选词。然后，通过标注少量的样本进行二分类模型的训练（判断一个词是否是品类）。此外，我们通过结合主动学习的方法，从预测的结果中挑选出难以区分的样本，进行再次标注，继续迭代模型，直到模型收敛。
2. **品类打标**：首先，我们通过对商品标题进行命名实体识别，并结合上一步中的品类词表来获取商品中的候选品类，如识别“蒙牛脱脂牛奶 500ml”中的“脱脂牛奶”、“牛奶”等。然后，在获得了商品以及对应的品类之后，我们利用监督数据训练品类打标的二分类模型，输入商品的 SPU_ID 和候选品类 TAG 构成的 Pair，即，对它进行是否匹配的预测。具体的，我们一方面利用结合业务中丰富的半结构化语料构建围绕标签词的统计特征，另一方面利用命名实体识别、基于 BERT 的语义匹配等模型产出高阶相关性特征，在此基础上，我们将上述特征输入到终判模型中进行模型训练。

3. 品类标签后处理：在这一步中，我们对模型打上的品类进行后处理的一些策略，如基于图片相关性、结合商品标题命名实体识别结果等的品类清洗策略。

通过上述的三个步骤，我们便可以建立起商品与品类之间的联系。

品类体系：品类体系由品类和品类间关系构成。常见的品类关系包括同义词和上下位等。在构建品类体系的过程中，常用的以下几种方法来进行关系的补全。我们主要使用下面的一些方法：

1. **基于规则的品类关系挖掘**。在百科等通用语料数据中，有些品类具有固定模式的描述，如“玉米又名苞谷、苞米棒子、玉蜀黍、珍珠米等”、“榴莲是著名热带水果之一”，因此，可以使用规则从中提取同义词和上下位。
2. **基于分类的品类关系挖掘**。类似于上文中提到的品类打标方法，我们将同义词和上下位构建为的样本，通过在商品库、搜索日志、百科数据、UGC 中挖掘的统计特征以及基于 Sentence-BERT 得到的语义特征，使用二分类模型进行品类关系是否成立的判断。对于训练得到的分类模型，我们同样通过主动学习的方式，选出结果中的难分样本，进行二次标注，进而不断迭代数据，提高模型性能。
3. **基于图的品类关系推理**。在获得了初步的同义词、上下位关系之后，我们使用已有的这些关系构建网络，使用 GAE、VGAE 等方法对网络进行链路预测，从而进行图谱边关系的补全。

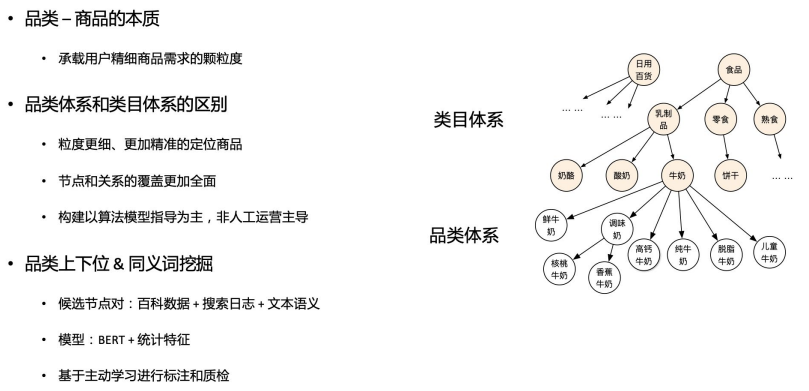

图 5　商品图谱品类体系的构建

标准 / 抽象商品

标准商品是描述商品本身客观事实的颗粒度，和销售渠道和商户无关，而商品条形码是标准商品这层的客观依据。标品关联即将同属于某个商品条形码的业务 SKU/SPU，都正确关联到该商品条形码上，从而在标准商品层级上建模相应的客观知识，例如标准商品对应的品牌、口味和包装等属性。 下面通过一个案例来说明标品关联的具体任务和方案。

案例：下图是一个公牛三米插线板的标准商品。商家录入信息的时候，会把商品直接关联到商品条码上。通过商户录入数据完成了一部分的标品关联，但这部分比例比较少，且存在大量的链接缺失，链接错误的问题。另外，不同的商家对于同样的标品，商品的标题的描述是千奇百怪的。我们的目标是补充缺失的链接，将商品关联到正确的标品上。

图 6　商品图谱标品关联任务

针对标品关联任务，我们构建了商品领域的同义词判别模型：通过远监督的方式利用商户已经提供的少量有关联的数据，作为已有的知识图谱构造远监督的训练样本。在模型中，正例是置信度比较高的标品码；负例是原始数据中商品名或者图像类似但不属于同一标品的 SPU。构造准确率比较高的训练样本之后，通过 BERT 模型进行同义词模型训练。最后，通过模型自主去噪的方式，使得最终的准确率能够达到 99%

以上。总体能做到品牌，规格，包装等维度敏感。

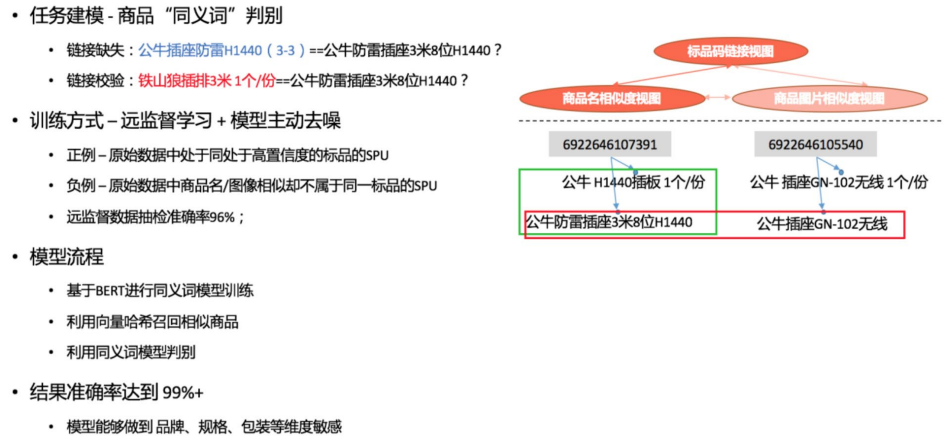

图 7　商品图谱标品关联方法

抽象商品是用户认知的层面，作为用户所评论的对象，这一层对用户偏好建模更加有效。同时，在决策信息的展示上，抽象商品粒度也更符合用户认知。例如下图所示冰淇淋的排行榜中，罗列了用户认知中抽象商品对应的 SKU，然后对应展示不同抽象商品的特点、推荐理由等。抽象商品层整体的构建方式，和标准商品层比较类似，采用标品关联的模型流程，并在数据构造部分进行规则上的调整。

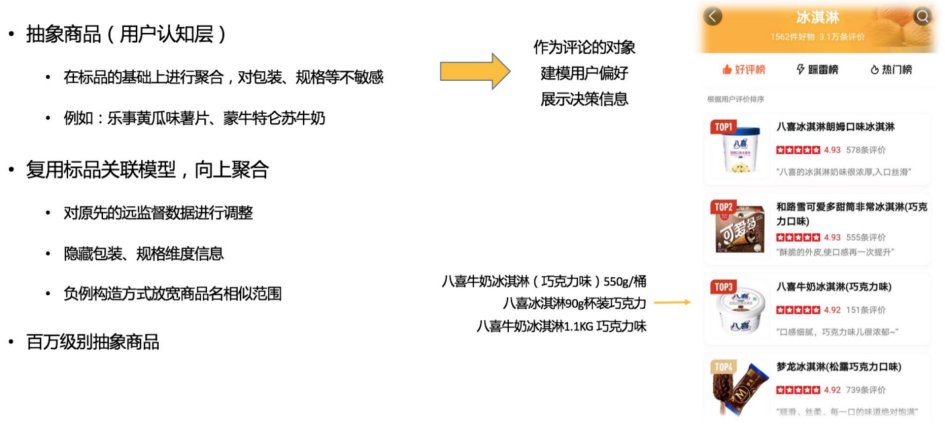

图 8　商品图谱抽象商品聚合

属性维度建设

对一个商品的全面理解，需要涵盖各个属性维度。例如“乐事黄瓜味薯片”，需要挖掘它对应的品牌、品类、口味、包装规格、标签、产地以及用户评论特色等属性，才能在商品搜索、推荐等场景中精准触达用户。商品属性挖掘的源数据主要包含商品标题、商品图片和半结构化数据三个维度。

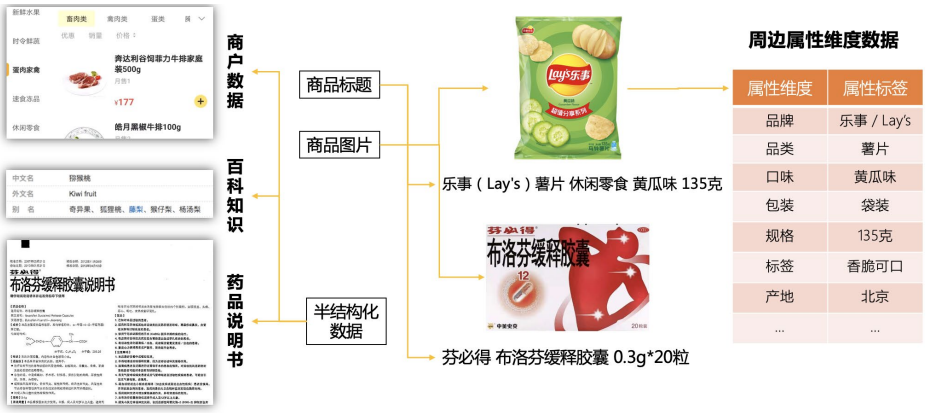

图 9　商品图谱属性建设

商品标题包含了对于商品最重要的信息维度，同时，商品标题解析模型可以应用在查询理解中，对用户快速深入理解拆分，为下游的召回排序也能提供高阶特征。因此，这里我们着重介绍一下利用商品标题进行属性抽取的方法。

商品标题解析整体可以建模成文本序列标注的任务。例如，对于商品标题“乐事黄瓜薯片”，目标是理解标题文本序列中各个成分，如乐事对应品牌，黄瓜对应口味，薯片是品类，因此我们使用命名实体识别（NER）模型进行商品标题解析。然而商品标题解析存在着三大挑战：（1）上下文信息少；（2）依赖常识知识；（3）标注数据通常有较多的噪音。为了解决前两个挑战，我们首先尝试在模型中引入了图谱信息，主要包含以下三个维度：

- **节点信息**：将图谱实体作为词典，以 Soft-Lexicon 方式接入，以此来缓解 NER 的边界切分错误问题。

- **关联信息**：商品标题解析依赖常识知识，例如在缺乏常识的情况下，仅从标题“乐事黄瓜薯片”中，我们无法确认“黄瓜”是商品品类还是口味属性。因此，我们引入知识图谱的关联数据缓解了常识知识缺失的问题：在知识图谱中，乐事和薯片之间存在着“品牌－售卖－品类”的关联关系，但是乐事跟黄瓜之间则没有直接的关系，因此可以利用图结构来缓解 NER 模型常识知识缺少的问题。具体来说，我们利用 Graph Embedding 的技术对图谱进行的嵌入表征，利用图谱的图结构信息对图谱中的单字，词进行表示，然后将包含了图谱结构信息的嵌入表示和文本语义的表征进行拼接融合，再接入到 NER 模型之中，使得模型能够既考虑到语义，也考虑到常识知识的信息。
- **节点类型信息**：同一个词可以代表不同的属性，比如“黄瓜”既可以作为品类又可以作为属性。因此，对图谱进行 Graph Embedding 建模的时候，我们根据不同的类型对实体节点进行拆分。在将图谱节点表征接入 NER 模型中时，再利用注意力机制根据上下文来选择更符合语义的实体类型对应的表征 ，缓解不同类型下词语含义不同的问题，实现不同类型实体的融合。

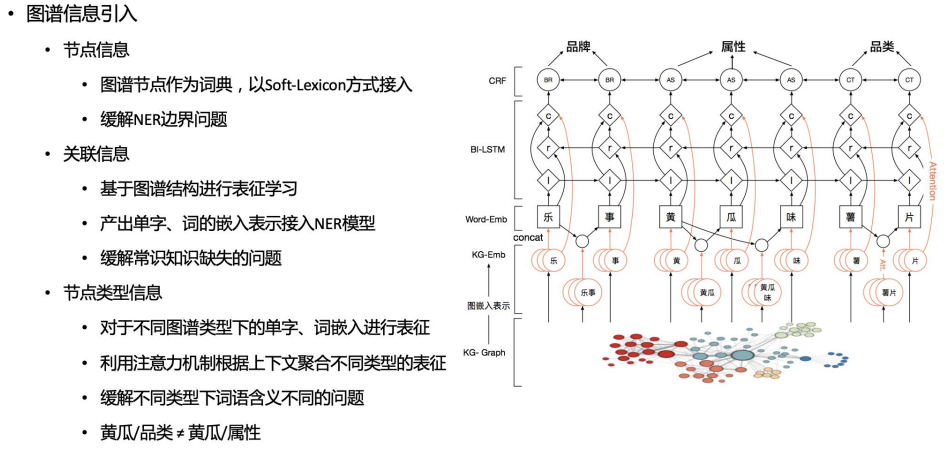

图 10　商品图谱标题解析

接下来我们探讨如何缓解标注噪音的问题。在标注过程中，少标漏标或错标的问题无法避免，尤其像在商品标题 NER 这种标注比较复杂的问题上，尤为显著。对于标注数据中的噪音问题，采用以下方式对噪音标注优化：不再采取原先非 0 即

1 的 Hard 的训练方式，而是采用基于置信度数据的 Soft 训练方式，然后再通过 Bootstrapping 的方式迭代交叉验证，然后根据当前的训练集的置信度进行调整。我们通过实验验证，使用 Soft 训练 +Bootstrapping 多轮迭代的方式，在噪声比例比较大的数据集上，模型效果得到了明显提升。具体的方法可参见我们在 NLPCC 2020 比赛中的论文《Iterative Strategy for Named Entity Recognition with Imperfect Annotations》。

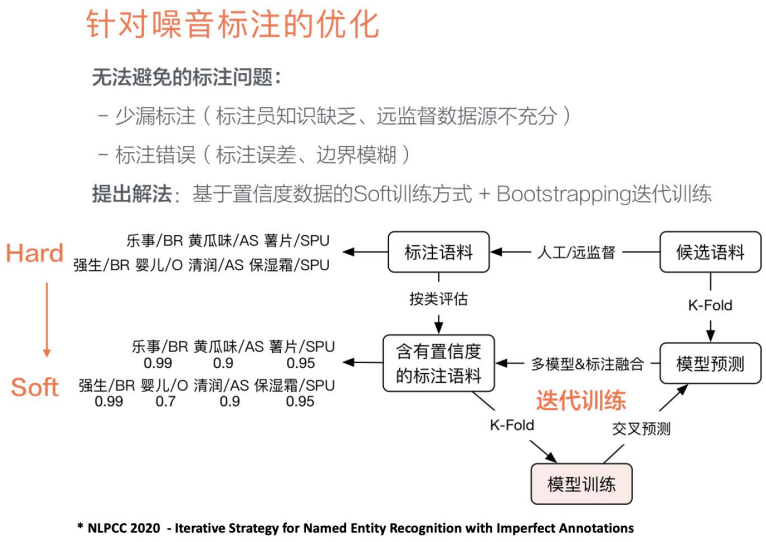

图 11　基于噪音标注的 NER 优化

效率提升

知识图谱的构建往往是针对于各个领域维度的数据单独制定的挖掘方式。这种挖掘方式重人工，比较低效，针对每个不同的领域、每个不同的数据维度，我们都需要定制化的去建设任务相关的特征及标注数据。在商品场景下，挖掘的维度众多，因此效率方面的提高也是至关重要的。我们首先将知识挖掘任务建模为三类分类任务，包括节点建模、关系建模以及节点关联。在整个模型的训练过程中，最需要进行效率优化的其实就是上述提到的两个步骤：(1) 针对任务的特征提取；(2) 针对任务的数据标注。

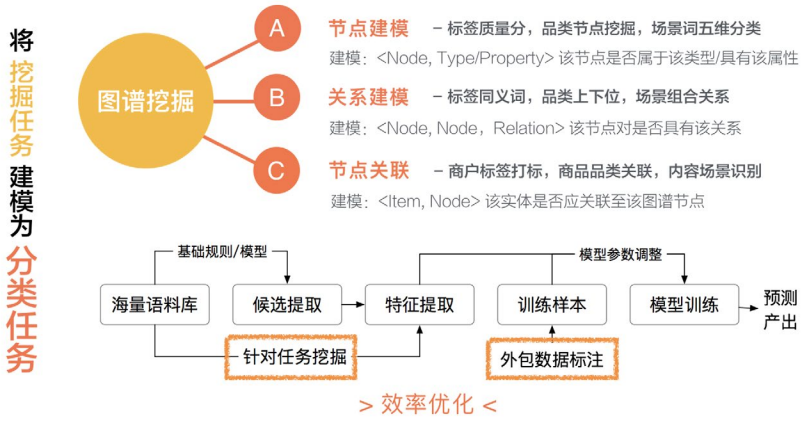

图 12　知识挖掘任务建模

针对特征提取部分，我们摒弃了针对不同挖掘任务做定制化特征挖掘的方式，而是尝试将特征和任务解耦，构建跨任务通用的图谱挖掘特征体系，利用海量的特征库来对目标的节点 / 关系 / 关联进行表征，并利用监督训练数据来进行特征的组合和选择。具体的，我们构建的图谱特征体系主要由四个类型的特征组构成：1. 规则模板型特征主要是利用人工先验知识，融合规则模型能力。2. 统计分布型特征，可以充分利用各类语料，基于不同语料不同层级维度进行统计。3. 句法分析型特征则是利用 NLP 领域的模型能力，引入分词、词性、句法等维度特征。4. 嵌入表示型特征，则是利用高阶模型能力，引入 BERT 等语义理解模型的能力。

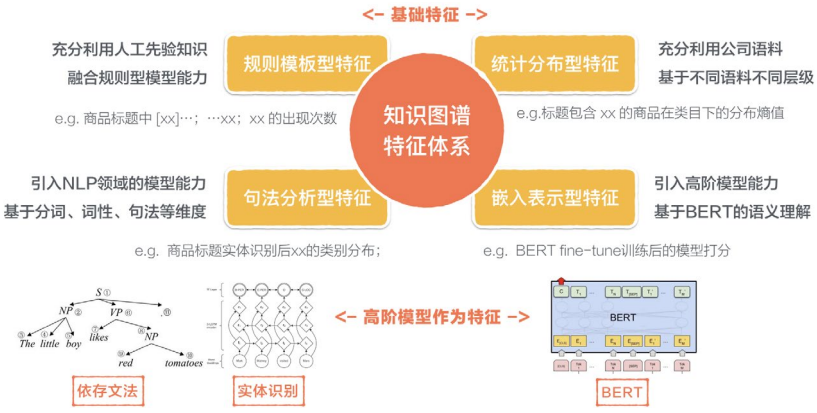

图 13　知识挖掘特征体系

针对数据标注部分，我们主要从三个角度来提升效率。1. 通过半监督学习，充分的利用未标注的数据进行预训练。2. 通过主动学习技术，选择对于模型来说能够提供最多信息增益的样本进行标注。3. 利用远程监督方法，通过已有的知识构造远监督样本进行模型训练，尽可能的发挥出已有知识的价值。

人机结合 – 专业图谱建设

当前医药健康行业结构性正在发生变化，消费者更加倾向于使用在线医疗解决方案和药品配送服务，因此医药业务也逐渐成为了美团的重要业务之一。相比于普通商品知识图谱的建设，药品领域知识具有以下两个特点：(1) 具有极强的专业性，需要有相关背景知识才能判断相应的属性维度，例如药品的适用症状等。(2) 准确度要求极高，对于强专业性知识不允许出错，否则更容易导致严重后果。因此我们采用将智能模型和专家知识结合的方式来构建药品知识图谱。

药品图谱中的知识可以分为弱专业知识和强专业知识两类，弱专业知识即一般人能够较容易获取和理解的知识，例如药品的使用方法、适用人群等；而强专业知识则是需要具有专业背景的人才能够判断的知识，例如药品的主治疾病、适应症状等。由于这两类数据对专家的依赖程度不同，因此我们分别采取不同的挖掘链路：

- **弱专业知识**：对于药品图谱的弱专业知识挖掘，我们从说明书、百科知识等数据源中提取出相应的信息，并结合通过专家知识沉淀出来的规则策略，借助通用语义模型从中提取相应的知识，并通过专家的批量抽检，完成数据的建设。
- **强专业知识**：对于药品图谱的强专业知识挖掘，为了确保相关知识百分百准确，我们通过模型提取出药品相关属性维度的候选后，将这些候选知识给到专家进行全量质检。在这里，我们主要是通过算法的能力，尽可能减少专业药师在基础数据层面上的精力花费，提高专家从半结构化语料中提取专业知识的效率。

在药品这类专业性强的领域，专业知识的表述和用户习惯往往存在差异。因此我们除了挖掘强弱专业知识外，还需要填补专业知识和用户之间的差异，才能将药品图谱更好的与下游应用结合。为此，我们从用户行为日志以及领域日常对话等数据源中，挖

掘了疾病、症状和功效的别名数据，以及药品通用名的俗称数据，来打通用户习惯和专业表述之间的通路。

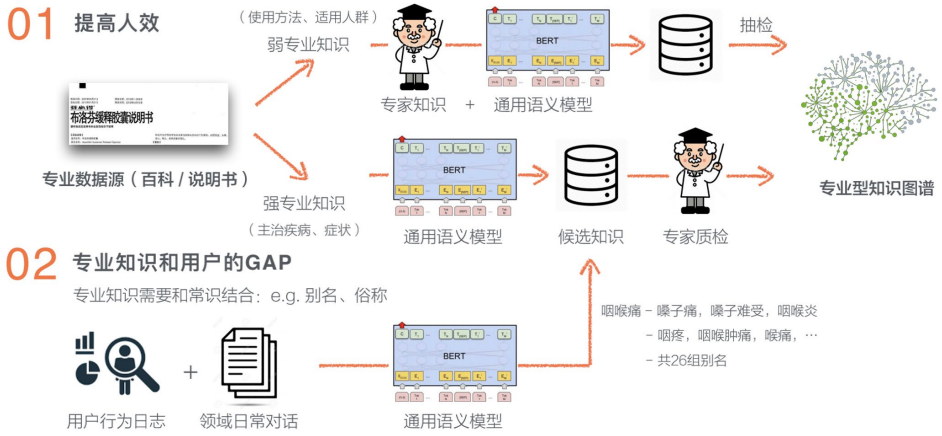

图 14　人机结合的专业知识挖掘

商品图谱的落地应用

自从谷歌将知识图谱应用于搜索引擎，并显著提升了搜索质量与用户体验，知识图谱在各垂直领域场景都扮演起了重要的角色。在美团商品领域中，我们也将商品图谱有效的应用在围绕商品业务的搜索、推荐、商家端、用户端等多个下游场景当中，接下来我们举几个典型的案例进行介绍。

结构化召回

商品图谱的数据，对于商品的理解很有帮助。例如，在商品搜索中，如用户在搜索头疼腰疼时，通过结构化的知识图谱，才能知道什么药品是有止疼功效的；用户在搜索可爱多草莓、黄瓜薯片时，需要依赖图谱的常识知识来理解用户真正需求是冰淇淋和薯片，而不是草莓和黄瓜。

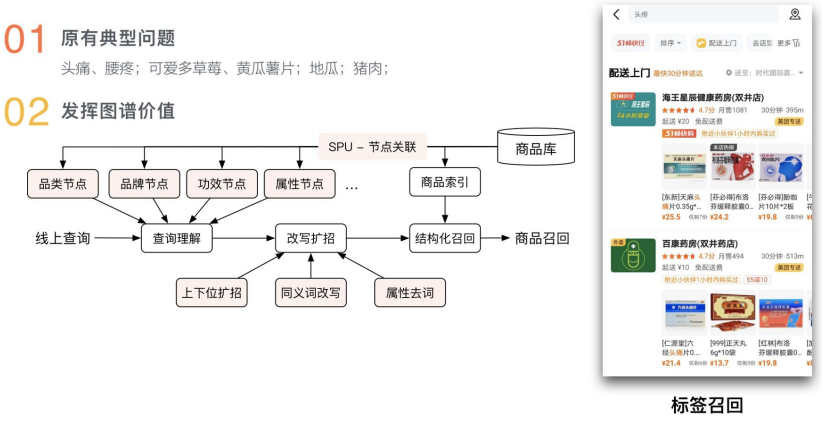

图 15　基于图谱的结构化召回

排序模型泛化性

图谱的类目信息、品类信息、属性信息，一方面可以作为比较强有力的相关性的判断方法和干预手段，另一方面可以提供不同粗细粒度的商品聚合能力，作为泛化性特征提供到排序模型，能有效地提升排序模型的泛化能力，对于用户行为尤为稀疏的商品领域来说则具有着更高的价值。具体的特征使用方式则包括：1. 通过各颗粒度进行商品聚合，以 ID 化特征接入排序模型。2. 在各颗粒度聚合后进行统计特征的建设。3. 通过图嵌入表示的方式，将商品的高维向量表示和排序模型结合。

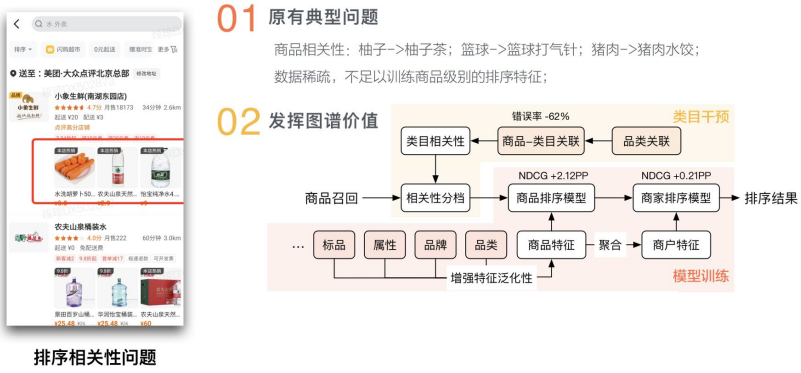

图 16　基于图谱的排序优化

多模态图谱嵌入

现有的研究工作已经在多个领域中证明了，将知识图谱的数据进行嵌入表示，以高维向量表示的方式和排序模型结合，可以有效地通过引入外部知识达到缓解排序 / 推荐场景中数据稀疏以及冷启动问题的效果。然而，传统的图谱嵌入的工作往往忽视了知识图谱中的多模态信息，例如商品领域中我们有商品的图片、商品的标题、商家的介绍等非简单的图谱节点型的知识，这些信息的引入也可以进一步提升图谱嵌入对推荐 / 排序的信息增益。

- 多模态知识图谱
  - 传统图谱仅考虑：Entity、Relation
  - 多模态图谱还考虑：图片、文本、位置等
- 多模态信息价值
  - 商品图片、电影剧照、餐厅风格
  - 简介、标签、用户评论
  - 非图谱方式使用
    - 直接作为Item侧特征接入推荐系统
    - 优势：实现方式基础、简单
    - 劣势：信息无法得到有效传播

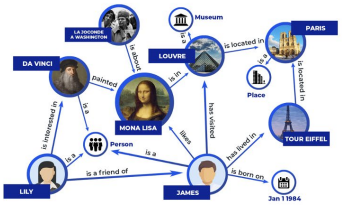

* CIKM 2020 - Multi-Modal Knowledge Graphs for Recommender Systems

图 17　基于多模态图谱的推荐 – 背景

现有的图谱嵌入方法在应用到多模态图谱表征的时候会存在一些问题，因为在多模态场景下，图谱中边的含义不再是单纯的语义推理关系，而是存在多模态的信息补充的关系，因此我们也针对多模态图谱的特点，提出了 MKG Entity Encoder 和 MKG Attention Layer 来更好的建模多模态知识图谱，并将其表征有效的接入至推荐 / 排序模型中，具体方法可以参考我们在 CIKM 2020 发表了的论文《Multi-Modal Knowledge Graphs for Recommender Systems》。

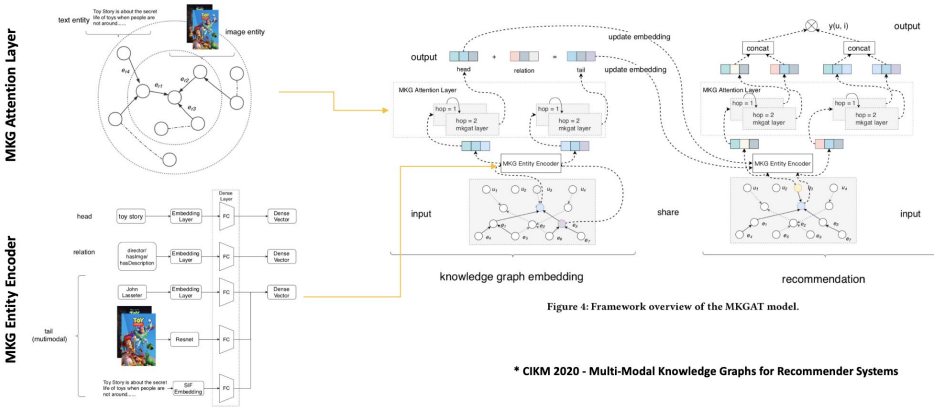

Figure 4: Framework overview of the MKGAT model.

* CIKM 2020 - Multi-Modal Knowledge Graphs for Recommender Systems

图 18　基于图谱的排序优化 – 模型

用户 / 商家端优化

商品图谱在用户端提供显式化的可解释性信息，辅助用户进行决策。具体的呈现形式包括筛选项、特色标签、榜单、推荐理由等。筛选项的维度受当前查询词对应品类下用户关注的属性类别决定，例如，当用户搜索查询词为薯片时，用户通常关注的是它的口味、包装、净含量等，我们将会根据供给数据在这些维度下的枚举值展示筛选项。商品的特色标签则来源于标题、商品详情页信息与评论数据的提取，以简洁明了的结构化数据展示商品特色。商品的推荐理由通过评论抽取与文本生成两种渠道获得，与查询词联动，以用户视角给出商品值得买的原因，而榜单数据则更为客观，以销量等真实数据，反应商品品质。

在商家端，即商家发布侧，商品图谱则提供了基于商品标题的实时预测能力，帮助商家进行类目的挂载、属性信息的完善。例如，商家填写标题“德国进口德亚脱脂纯牛奶 12 盒”后，商品图谱提供的在线类目预测服务可将其挂载到“食品饮料 – 乳制品 – 纯牛奶”类目，并通过实体识别服务，得到商品的“产地 – 德国”，“是否进口 – 进口”，“品牌 – 德亚”，“脂肪含量 – 脱脂”，“规格 –12 盒”的属性信息，预测完成后，由商家确认发布，降低商家对商品信息的维护成本，并提升发布商品的信息质量。

作者简介

雪智，凤娇，姿雯，匡俊，林森，武威等，均来自美团平台搜索与 NLP 部 NLP 中心。

招聘信息

美团大脑知识图谱团队大量岗位持续招聘中，实习、校招、社招均可，坐标北京 / 上海，欢迎感兴趣的同学加入我们，利用自然语言和知识图谱技术，帮大家吃得更好，生活更好。简历可投递至：caoxuezhi@meituan.com。

常识性概念图谱建设以及在美团场景中的应用

作者：宗宇　俊杰　慧敏等

一、引言

在自然语言处理中，我们经常思考，怎么样才能做好自然语言的理解工作。对我们人类来说，理解某一个自然语言的文本信息，通常都是通过当前的信息，关联自己大脑中存储的关联信息，最终理解信息。例如“他不喜欢吃苹果，但是喜欢吃冰淇淋”，人在理解的时候关联出大脑中的认知信息：苹果，甜的，口感有点脆；冰淇淋，比苹果甜，口感软糯、冰凉，夏天能解暑；小孩更喜欢吃甜食和冰淇淋。所以结合这样的知识，会推理出更喜欢冰淇淋的若干原因。但是现在很多自然语言理解的工作还是聚焦在信息的层面，现在的理解工作类似于一个贝叶斯概率，从已知的训练文本中寻找符合条件的最大化文本信息。

在自然语言处理中做到像人一样去理解文本是自然语言处理的终极目标，所以现在越来越多的研究上，引入了一些额外的知识，帮助机器做好自然语言文本的理解工作。单纯的文本信息只是外部客观事实的表述，知识则是在文本信息基础之上对外部客观事实的归纳和总结，所以在自然语言处理中加入辅助的知识信息，让自然语言理解的更好。

建立知识体系则是一种直接的方式，能够帮助自然语言理解得更准确。知识图谱就是围绕这个思想提出，期望通过给机器显性的知识，让机器能够像人一样进行推理理解。所以在 2012 年 Google 正式提出了知识图谱（Knowledge Graph）的概念，它的初衷是为了优化搜索引擎返回的结果，增强用户的搜索质量及体验。

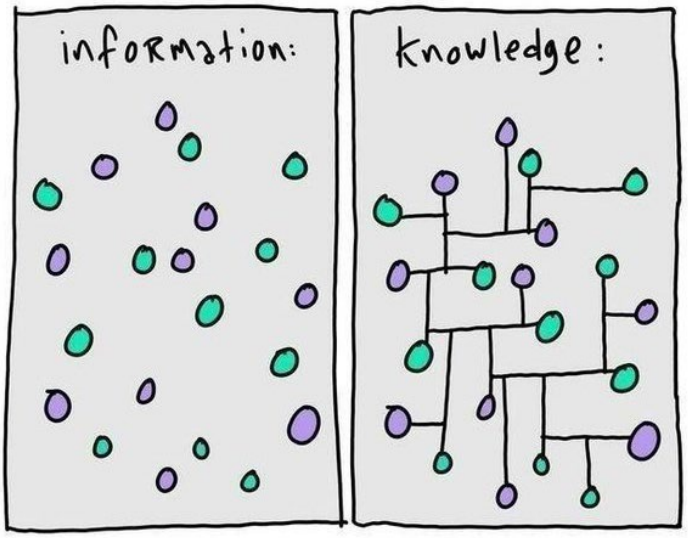

图 1　信息和知识

二、常识性概念图谱介绍

常识性概念图谱就是建立概念与概念之间的关系，帮助自然语言文本的理解。同时我们的常识性概念图谱侧重美团场景，帮助提升美团场景中的搜索、推荐、Feeds 流等的效果。

按照理解的需求，主要是三个维度的理解能力：

1. **是什么**，概念是什么，建立核心概念是什么的关联体系。例如“维修洗衣机”，“维修”是什么，“洗衣机”是什么。
2. **什么样**，核心概念某一方面的属性，对核心概念某一方面的细化。“带露台的餐厅”、“亲子游乐园”、“水果千层蛋糕”中“带露台”、“亲子”、“水果千层”这些都是核心概念某一个方面的属性，所以需要建立核心概念对应属性以及属性值之间的关联。
3. **给什么**，解决搜索概念和承接概念之间的 Gap，例如“阅读”、“逛街”、“遛娃”等没有明确对应的供给概念，所以建立搜索和供给概念之间的关联网络，解决这一类问题。

总结下来，涵盖“是什么”的概念 Taxonomy 体系结构，“什么样”的概念属性关系，“给什么”的概念承接关系。同时 POI（Point of Interesting）、SPU（Standard Product Unit）、团单作为美团场景中的实例，需要和图谱中的概念建立连接。

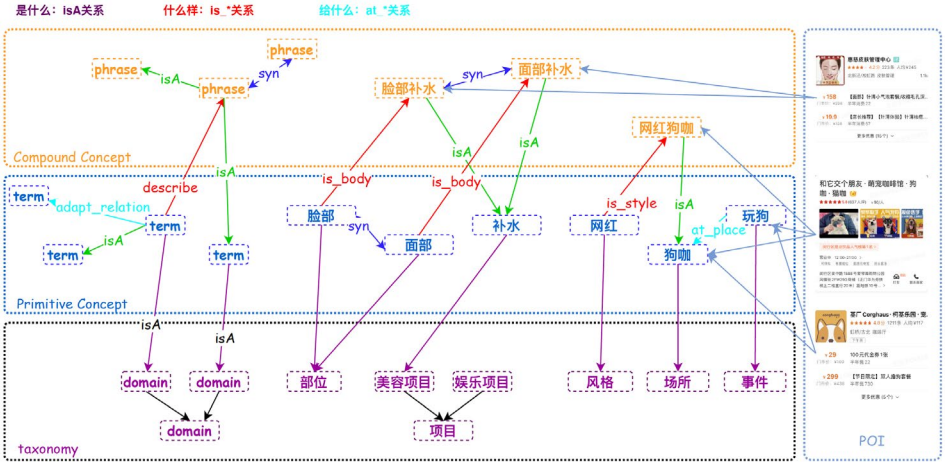

图 2　常识性概念图谱关系

从建设目标出发，拆解整体常识性概念图谱建设工作，拆分为三类节点和四类关系，具体内容如下。

2.1 图谱三类节点

Taxonomy 节点：在概念图谱中，理解一个概念需要合理的知识体系，预定义好的 Taxonomy 知识体系作为理解的基础，在预定义的体系中分为两类节点：第一类在美团场景中可以作为核心品类出现的，例如，食材、项目、场所；另一类是作为对核心品类限定方式出现的，例如，颜色、方式、风格。这两类的节点的定义都能帮助搜索、推荐等的理解。目前预定义的 Taxonomy 节点如下图所示：

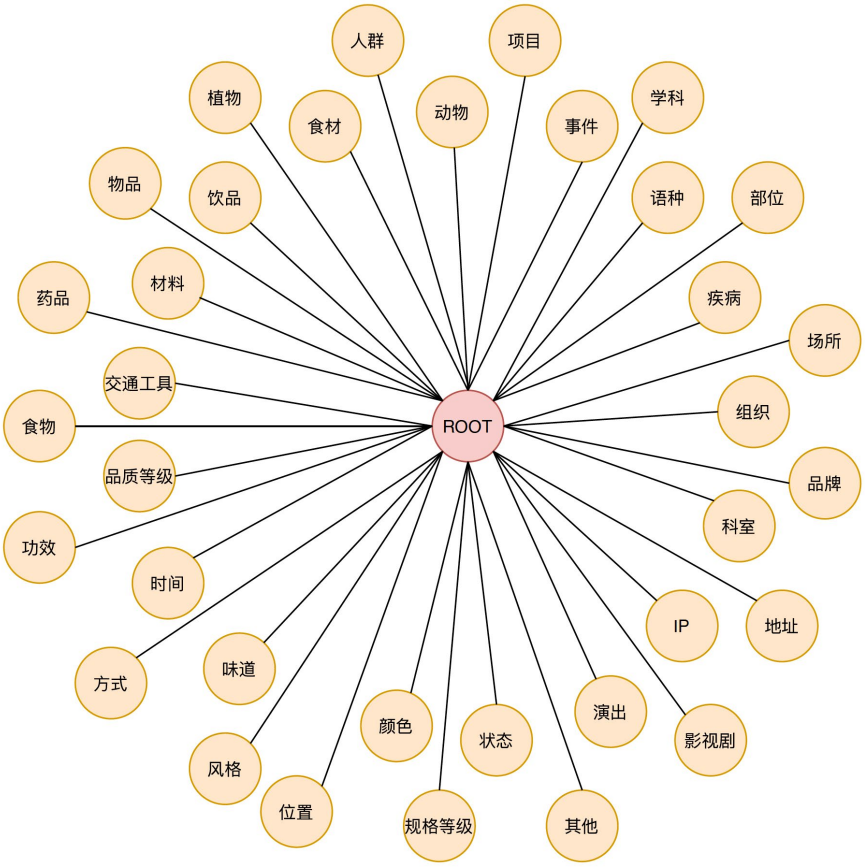

图 3　图谱 Taxonomy 预定义体系

原子概念节点：组成图谱最小语义单元节点，有独立语义的最小粒度词语，例如网红、狗咖、脸部、补水等。定义的原子概念，全部需要挂靠到定义的 Taxonomy 节点之上。

复合概念节点：由原子概念以及对应属性组合而成的概念节点，例如脸部补水、面部补水等。复合概念需要和其对应的核心词概念建立上下位关系。

2.2 图谱四类关系

同义 / 上下位关系：语义上的同义 / 上下位关系，例如脸部补水 –syn– 面部补水等。定义的 Taxonomy 体系也是一种上下位的关系，所以归并到同义 / 上下位关系里。

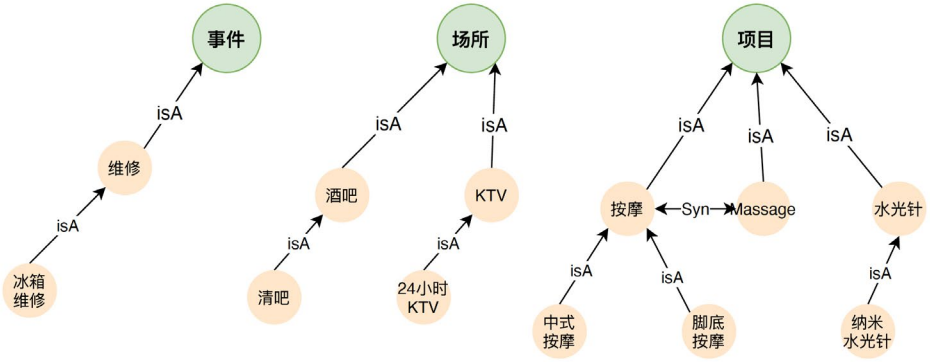

图 4　上下位、同义关系示例

概念属性关系：是典型的 CPV（Concept-Property-Value）关系，从各个属性维度来描述和定义概念，例如火锅 – 口味 – 不辣，火锅 – 规格 – 单人等，示例如下：

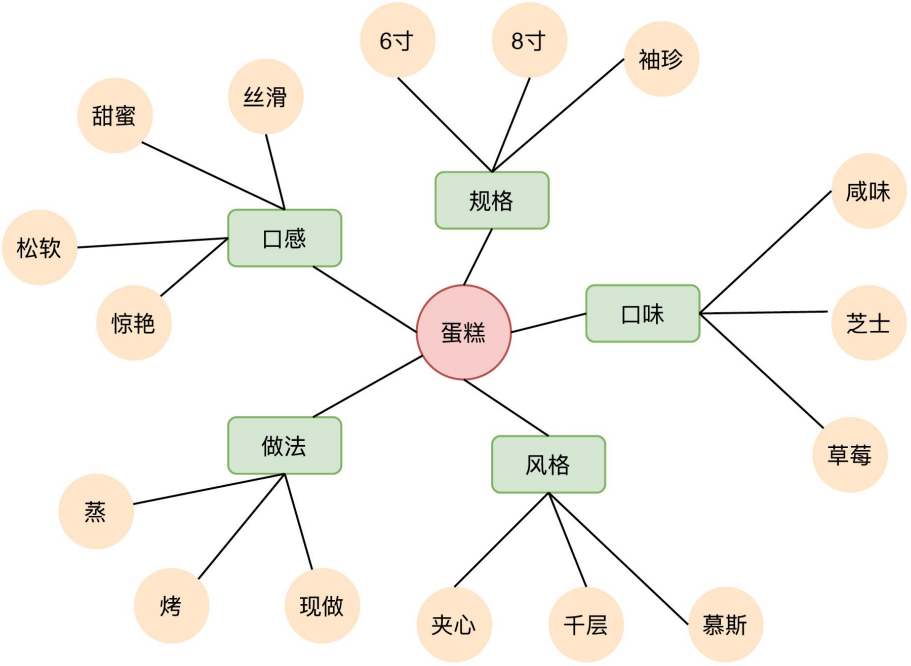

图 5　概念属性关系示例

概念属性关系包含两类。

预定义概念属性：目前我们预定义典型的概念属性如下：

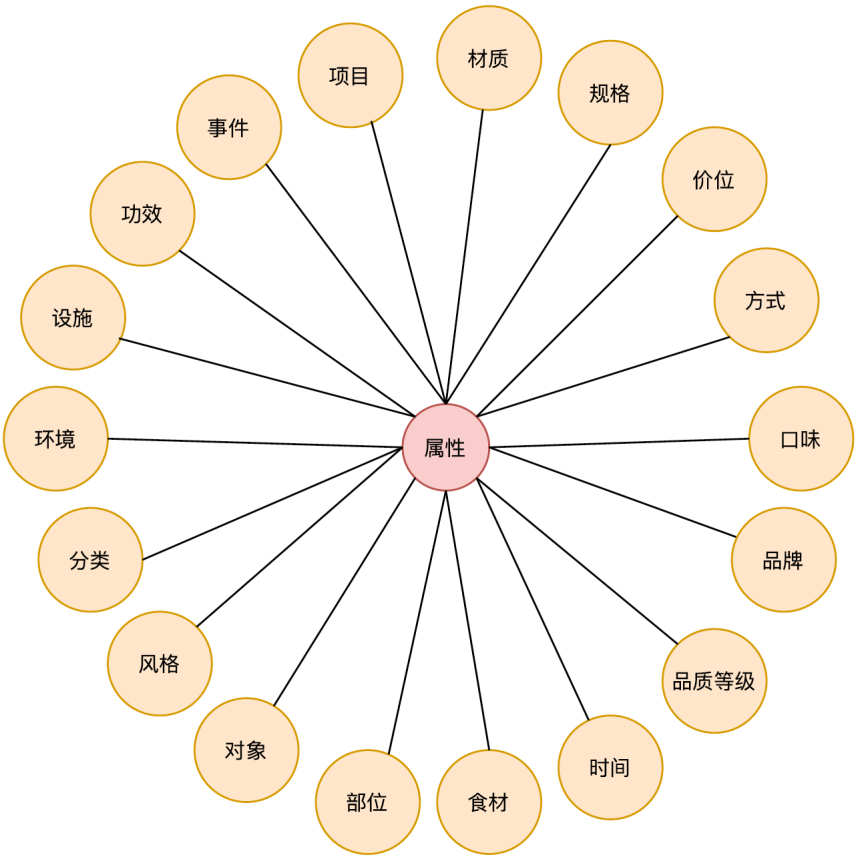

图 6　预定义属性

开放型概念属性：除了我们自己定义的公共的概念属性外，我们还从文本中挖掘一些特定的属性词，补充一些特定的属性词。例如，姿势、主题、舒适度、口碑等。

概念承接关系：这类关系主要建立用户搜索概念和美团承接概念之间的链接，例如踏春 – 场所 – 植物园，减压 – 项目 – 拳击等。

概念承接关系以「事件」为核心，定义了「场所」、「物品」、「人群」、「时间」、「功效」等能够满足用户需求的一类供给概念。以事件“美白”为例，“美白”作为用户的需求，可以有不同的供给概念能够满足，例如美容院、水光针等。目前，定义的几

类承接关系如下图所示：

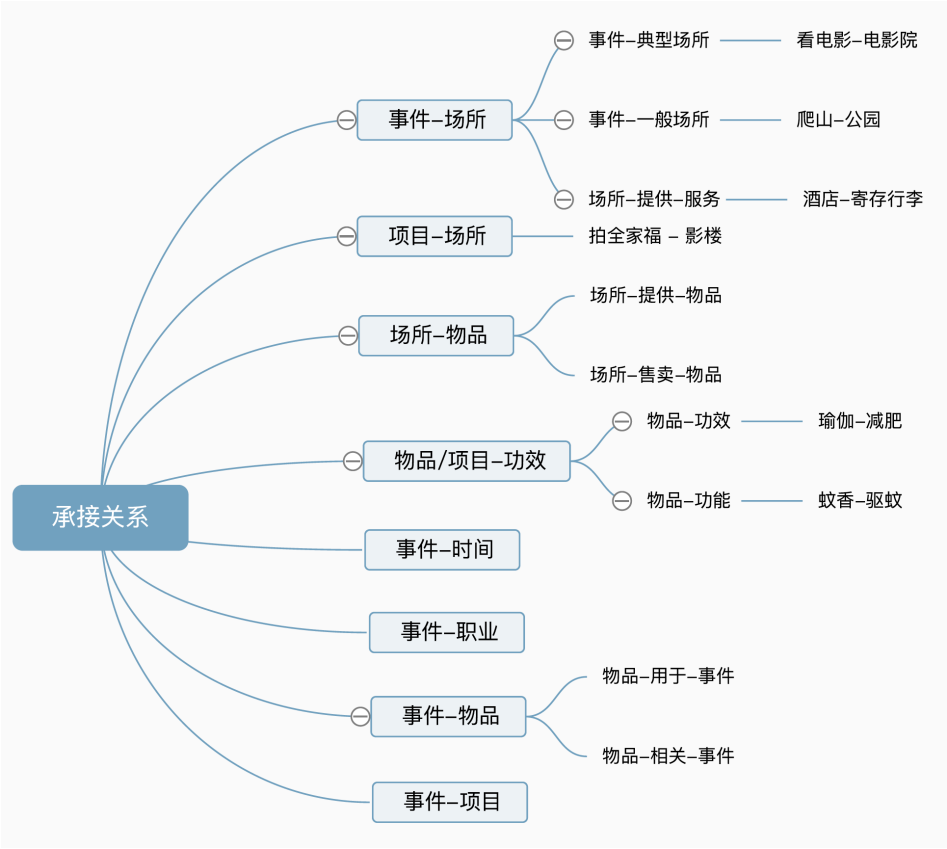

图 7　概念承接关系类型

POI/SPU– 概念关系：POI 作为美团场景中的实例，实例 – 概念的关系作为知识图谱中最后的一站，常常是比较能发挥知识图谱在业务上价值的地方。在搜索、推荐等业务场景，最终的目的是能够展示出符合用户需求的 POI，所以建立 POI/SPU– 概念的关系是整个美团场景常识性概念图谱重要的一环，也是比较有价值的数据。

三、常识性概念图谱构建

图谱构建整体框架如下图所示：

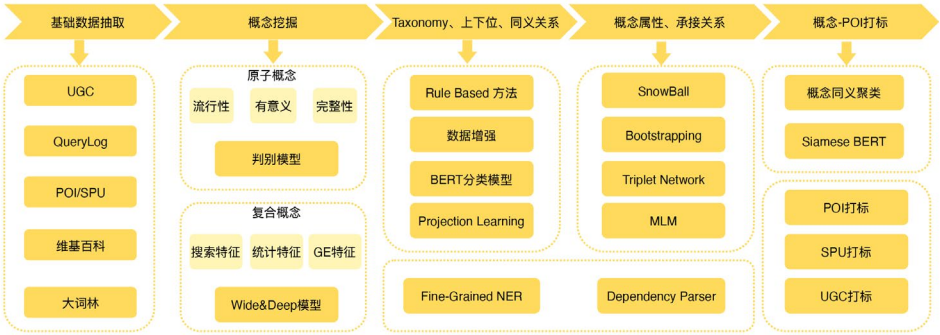

图 8　概念图谱建设整体工作

3.1 概念挖掘

常识性概念图谱的各种关系都是围绕概念构建，这些概念的挖掘是常识性概念图谱建设的第一环。按照原子概念和复合概念两种类型，分别采取相应的方法进行挖掘。

3.1.1 原子概念挖掘

原子概念候选来自于 Query、UGC（User Generated Content）、团单等文本分词后的最小片段，原子概念的判断标准是需要满足流行性、有意义、完整性三个特性的要求。

1. **流行性**，一个概念应是某个或某些语料内流行度较高的词，该特性主要通过频率类特征度量，如“桌本杀”这个词搜索量很低且 UGC 语料中频率也很低，不满足流行性要求。
2. **有意义**，一个概念应是一个有意义的词，该特性主要通过语义特征度量，如“阿猫”、“阿狗”通常只表一个单纯的名称而无其他实际含义。
3. **完整性**，一个概念应是一个完整的词，该特性主要通过独立检索占比（该词作为 Query 的搜索量 / 包含该词的 Query 的总搜索量）衡量，如“儿童设”是一个错误的分词候选，在 UGC 中频率较高，但独立检索占比低。

基于原子概念以上的特性，结合人工标注以及规则自动构造的训练数据训练 XGBoost 分类模型对原子概念是否合理进行判断。

3.1.2 复合概念挖掘

复合概念候选来自于原子概念的组合，由于涉及组合，复合概念的判断比原子概念判断更为复杂。复合概念要求在保证完整语义的同时，在美团站内也要有一定的认知。根据问题的类型，采用 Wide&Deep 的模型结构，Deep 侧负责语义的判断，Wide 侧引入站内的信息。

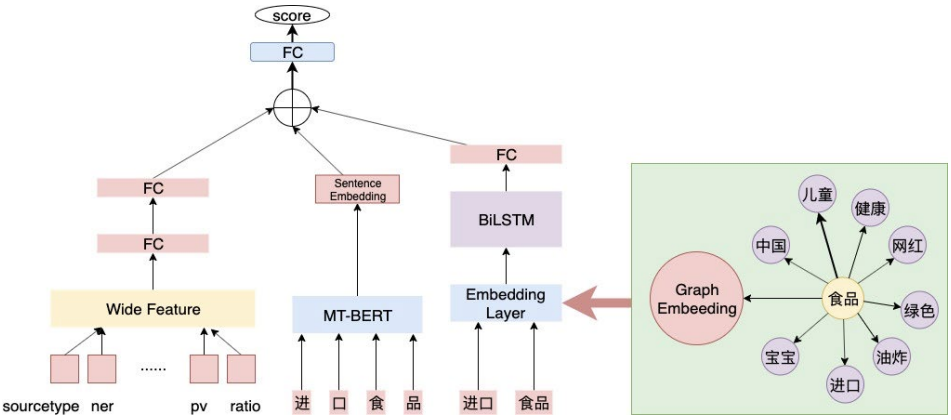

图 9　复合概念挖掘的 Wide&Deep 模型

该模型结构有以下两个特点，对复合概念的合理性进行更准确的判断：

1. **Wide&Deep 模型结构**：将离散特征与深度模型结合起来判断复合概念是否合理。
2. **Graph Embedding 特征**：引入词组搭配间的关联信息，如“食品”可以与“人群”、“烹饪方式”、“品质”等进行搭配。

3.2 概念上下位关系挖掘

在获取概念之后，还需要理解一个概念“是什么”，一方面通过人工定义的 Taxonomy 知识体系中的上下位关系进行理解，另一方面通过概念间的上下位关系进行理解。

3.2.1 概念 -Taxonomy 间上下位关系

概念 -Taxonomy 间上下位关系是通过人工定义的知识体系理解一个概念是什么，由

于 Taxonomy 类型是人工定义好的类型，可以把这个问题转化成一个分类问题。同时，一个概念在 Taxonomy 体系中可能会有多个类型，如“青柠鱼”既是一种“动物”，也属于“食材”的范畴，所以这里最终把这个问题作为一个 Entity Typing 的任务来处理，将概念及其对应上下文作为模型输入，并将不同 Taxonomy 类别放在同一空间中进行判断，具体的模型结构如下图所示：

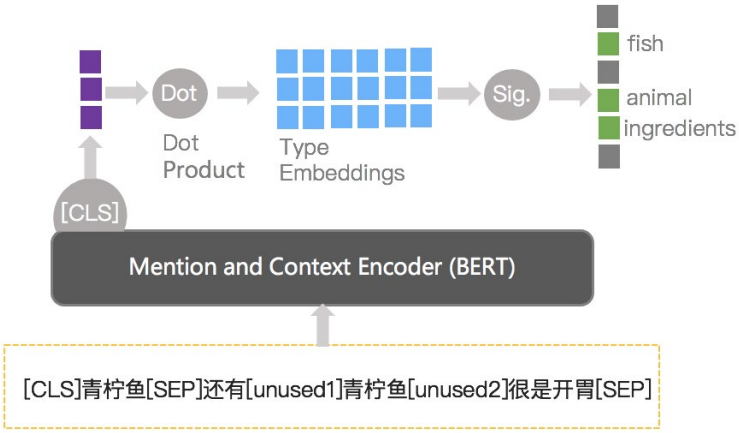

图 10　BERT Taxonomy 关系模型

3.2.2 概念 – 概念间上下位关系

知识体系通过人工定义的类型来理解一个概念是什么，但人工定义的类型始终是有限的，如果上位词不在人工定义的类型中，这样的上下位关系则没办法理解。如可以通过概念 –Taxonomy 关系理解“西洋乐器”、“乐器”、“二胡”都是一种“物品”，但没办法获取到“西洋乐器”和“乐器”、“二胡”和“乐器”之间的上下位关系。基于以上的问题，对于概念 – 概念间存在的上下位关系，目前采取如下两种方法进行挖掘：

基于词法规则的方法：主要解决原子概念和复合概念间的上下位关系，利用候选关系对在词法上的包含关系（如西洋乐器 – 乐器）挖掘上下位关系。

基于上下文判断的方法：词法规则可以解决在词法上存在包含关系的上下位关系对的判断。对于不存在词法上的包含关系的上下位关系对，如“二胡 – 乐器”，首先需要进行上下位关系发现，抽取出“二胡 – 乐器”这样的关系候选，再进行上下位关系判

断，判断“二胡 – 乐器”是一个合理的上下位关系对。考虑到人在解释一个对象时会对这个对象的类型进行相关介绍，如在对“二胡”这个概念进行解释时会提到“二胡是一种传统乐器”，从这样的解释性文本中，既可以将“二胡 – 乐器”这样的关系候选对抽取出来，也能同时实现这个关系候选对是否合理的判断。这里在上下位关系挖掘上分为候选关系描述抽取以及上下位关系分类两部分：

1. **候选关系描述抽取**：两个概念从属于相同的 Taxonomy 类型是一个候选概念对是上下位关系对的必要条件，如“二胡”和“乐器”都属于 Taxonomy 体系中定义的“物品”，根据概念 –Taxonomy 上下位关系的结果，对于待挖掘上下位关系的概念，找到跟它 Taxonomy 类型一致的候选概念组成候选关系对，然后在文本中根据候选关系对的共现筛选出用作上下位关系分类的候选关系描述句。
2. **上下位关系分类**：在获取到候选关系描述句后，需要结合上下文对上下位关系是否合理进行判断，这里将两个概念在文中的起始位置和终止位置用特殊标记标记出来，并以两个概念在文中起始位置标记处的向量拼接起来作为两者关系的表示，根据这个表示对上下位关系进行分类，向量表示使用 BERT 输出的结果，详细的模型结构如下图所示：

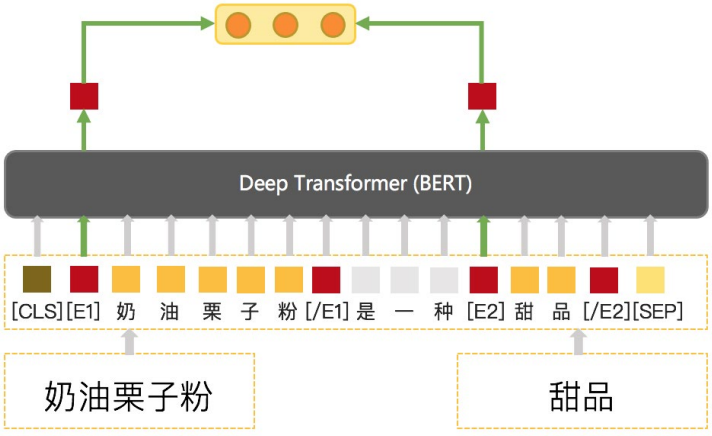

图 11　BERT 上下位关系模型

在训练数据构造上，由于上下位关系表述的句子非常稀疏，大量共现的句子并没有明确的表示出候选关系对是否具有上下位关系，利用已有上下位关系采取远程监督方式

进行训练数据构建不可行，所以直接使用人工标注的训练集对模型进行训练。由于人工标注的数量比较有限，量级在千级别，这里结合 Google 的半监督学习算法 UDA（Unsupervised Data Augmentation）对模型效果进行提升，最终 Precision 可以达到 90%+，详细指标见表 1：

Data Size	BERT			BERT + UDA		
	Precision (%)	Recall (%)	F1 (%)	Precision (%)	Recall (%)	F1 (%)
1300	88.46	80.23	84.15	90.67	79.07	84.47
200	69.07	77.91	73.22	80.82	68.60	74.21

表 1　使用 UDA 在不同训练数据量下的提升效果

3.3 概念属性关系挖掘

概念含有的属性可以按照属性是否通用划分为公共属性和开放属性。公共属性是由人工定义的、大多数概念都含有的属性，例如价位、风格、品质等。开放属性指某些特定的概念才含有的属性，例如，“植发”、“美睫”和“剧本杀”分别含有开放属性“密度”、“翘度”和“逻辑”。开放属性的数量远远多于公共属性。针对这两种属性关系，我们分别采用以下两种方式进行挖掘。

3.3.1 基于复合概念挖掘公共属性关系

由于公共属性的通用性，公共属性关系（CPV）中的 Value 通常和 Concept 以复合概念的形式组合出现，例如，平价商场、日式料理、红色电影高清。我们将关系挖掘任务转化为依存分析和细粒度 NER 任务（可参考《美团搜索中 NER 技术的探索与实践》一文），依存分析识别出复合概念中的核心实体和修饰成分，细粒度 NER 判断出具体属性值。例如，给定复合概念「红色电影高清」，依存分析识别出「电影」这个核心概念，「红色」、「高清」是「电影」的属性，细粒度 NER 预测出属性值分别为「风格（Style）」、「品质评价（高清）」。

依存分析和细粒度 NER 有可以互相利用的信息，例如“毕业公仔”，「时间（Time）」和「产品（Product））」的实体类型，与「公仔」是核心词的依存信息，可以相互促进训练，因此将两个任务联合学习。但是由于两个任务之间的关联程度并不明

确，存在较大噪声，使用 Meta-LSTM，将 Feature-Level 的联合学习优化为 Function-Level 的联合学习，将硬共享变为动态共享，降低两个任务之间噪声影响。

模型的整体架构如下所示：

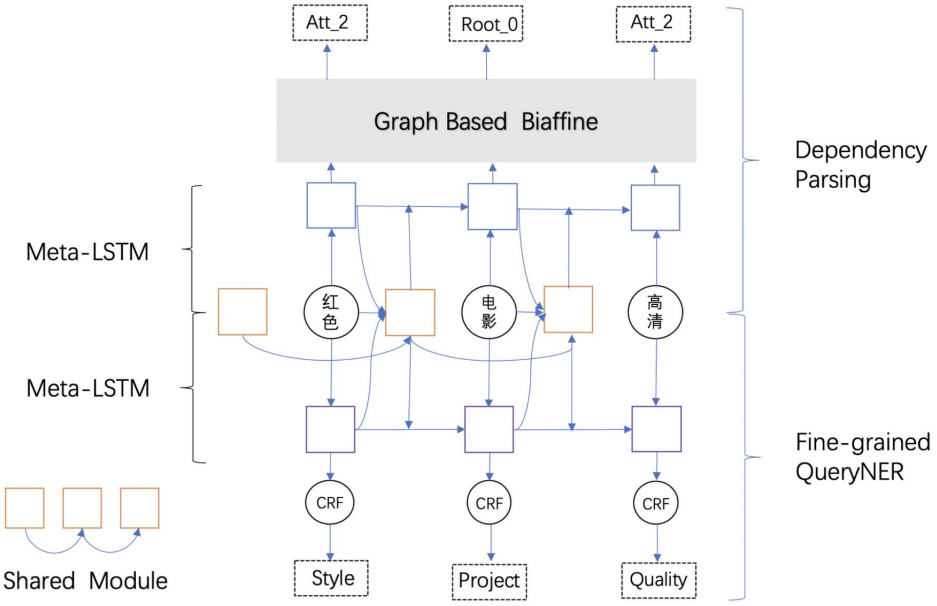

图 12 依存分析 – 细粒度 NER 联合学习模型

目前，概念修饰关系整体准确率在 85% 左右。

3.3.2 基于开放属性词挖掘特定属性关系

开放属性词和属性值的挖掘

开放属性关系需要挖掘不同概念特有的属性和属性值，它的难点在于开放属性和开放属性值的识别。通过观察数据发现，一些通用的属性值（例如：好、坏、高、低、多、少），通常和属性搭配出现（例如：环境好、温度高、人流量大）。所以我们采取一种基于模板的 Bootstrapping 方法自动从用户评论中挖掘属性和属性值，挖掘流程如下：

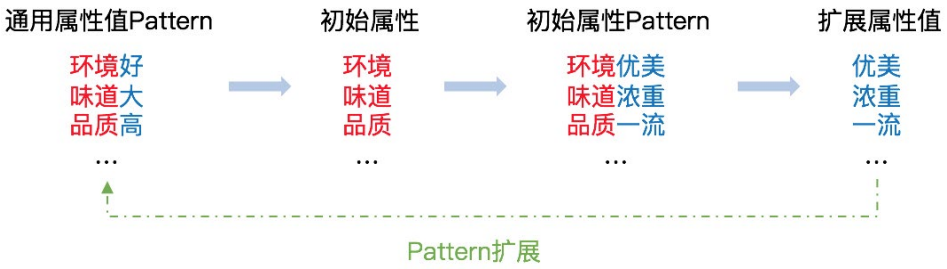

图 13　开放属性挖掘流程

在挖掘了开放属性词和属性值之后，开放属性关系的挖掘拆分为「概念 – 属性」二元组的挖掘和「概念 – 属性 – 属性值」三元组的挖掘。

概念 – 属性的挖掘

「概念 – 属性」二元组的挖掘，即判断概念 Concept 是否含有属性 Property。挖掘步骤如下：

- 根据概念和属性在 UGC 中的共现特征，利用 TFIDF 变种算法挖掘概念对应的典型属性作为候选。
- 将候选概念属性构造为简单的自然表述句，利用通顺度语言模型判断句子的通顺度，保留通顺度高的概念属性。

概念 – 属性 – 属性值的挖掘

在得到「概念 – 属性」二元组后，挖掘对应属性值的步骤如下：

- **种子挖掘**。基于共现特征和语言模型从 UGC 中挖掘种子三元组。
- **模板挖掘**。利用种子三元组从 UGC 中构建合适的模板（例如，“水温是否合适，是选择游泳馆的重要标准。”）。
- **关系生成**。利用种子三元组填充模板，训练掩码语言模型用于关系生成。

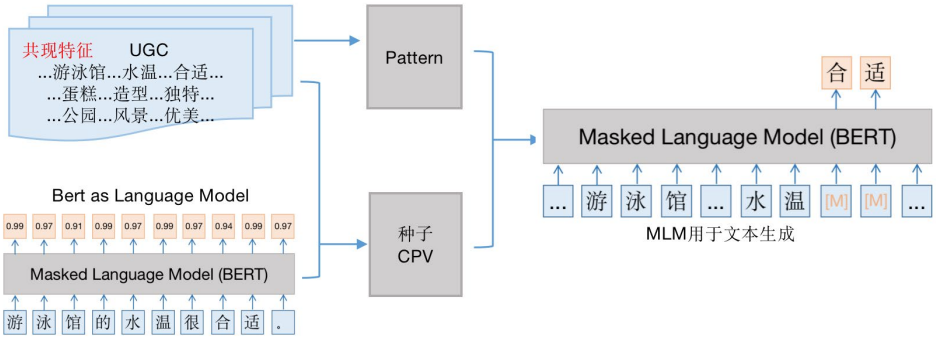

图 14 概念属性关系生成模型

目前，开放领域的概念属性关系准确率在 80% 左右。

3.4 概念承接关系挖掘

概念承接关系是建立用户搜索概念和美团承接概念之间的关联。例如，当用户搜索“踏青”时，真正的意图是希望寻找“适合踏青的地方”，因此平台通过“郊野公园”、“植物园”等概念进行承接。关系的挖掘需要从 0 到 1 进行，所以整个概念承接关系挖掘根据不同阶段的挖掘重点设计了不同的挖掘算法，可以分为三个阶段：①初期的种子挖掘；②中期的深度判别模型挖掘；③后期的关系补全。详细介绍如下。

3.4.1 基于共现特征挖掘种子数据

为了解决关系抽取任务中的冷启动问题，业界通常采用 Bootstrapping 的方法，通过人工设定的少量种子和模板，自动从语料中扩充数据。然而，Bootstrapping 方法不仅受限于模板的质量，而且应用于美团的场景中有着天然缺陷。美团语料的主要来源是用户评论，而用户评论的表述十分口语化及多样化，很难设计通用而且有效的模板。因此，我们抛弃基于模板的方法，而是根据实体间的共现特征以及类目特征，构建了一个三元对比学习网络，自动从非结构化的文本中挖掘实体关系之间潜在的相关性信息。

具体来说，我们观察到不同商户类目下用户评论中实体的分布差异较大。例如，美食类目下的 UGC 经常涉及到“聚餐”、“点菜”、“餐厅”；健身类目下的 UGC 经常涉

及到“减肥”、“私教”、“健身房”；而“装修”、“大厅”等通用实体在各个类目下都会出现。因此，我们构建了三元对比学习网络，使得同类目下的用户评论表示靠近，不同类目的用户评论表示远离。与 Word2Vec 等预训练词向量系统类似，通过该对比学习策略得到的词向量层天然蕴含丰富的关系信息。在预测时，对于任意的用户搜索概念，可以通过计算其与所有承接概念之间的语义相似度，辅以搜索业务上的统计特征，得到一批高质量的种子数据。

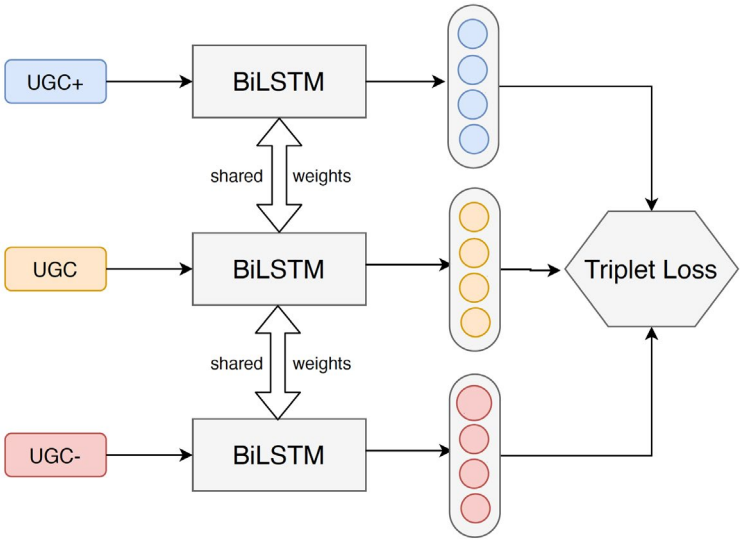

图 15　概念承接关系挖掘的 Triplet Network

3.4.2 基于种子数据训练深度模型

预训练语言模型近两年来在 NLP 领域取得了很大的进展，基于大型的预训练模型微调下游任务，是 NLP 领域非常流行的做法。因此，在关系挖掘中期，我们采用基于 BERT 的关系判别模型（参考《美团 BERT 的探索和实践》一文），利用 BERT 预训练时学到的大量语言本身的知识来帮助关系抽取任务。

模型结构如下图所示。首先，根据实体间的共现特征得到候选实体对，召回包含候选实体对的用户评论；然后，沿用 MTB 论文中的实体标记方法，在两个实体的开始位置和结束位置分别插入特殊的标志符号，经过 BERT 建模之后，将两个实体开始位

置的特殊符号拼接起来作为关系表示；最后，将关系表示输入 Softmax 层判断实体间是否含有关系。

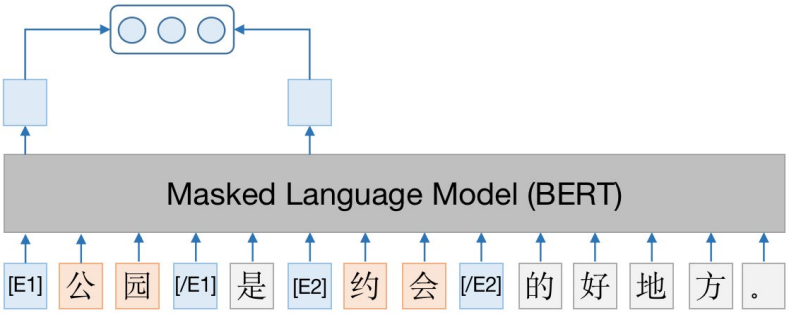

图 16　概念承接关系判别模型

3.4.3 基于已有的图谱结构进行关系补全

通过上述两个阶段，已经从非结构化的文本信息中构建出了一个初具规模的概念承接关系的图谱。但是由于语义模型的局限性，当前图谱中存在大量的三元组缺失。为了进一步丰富概念图谱，补全缺失的关系信息，我们应用知识图谱链接预测中的 TransE 算法以及图神经网络等技术，对已有的概念图谱进行补全。

为了充分利用已知图谱的结构信息，我们采用基于关系的图注意力神经网络（RGAT，Relational Graph Attention Network）来建模图结构信息。RGAT 利用关系注意力机制，克服了传统 GCN、GAT 无法建模边类型的缺陷，更适用于建模概念图谱此类异构网络。在利用 RGAT 得到实体稠密嵌入之后，我们使用 TransE 作为损失函数。TransE 将三元组（h,r,t）中的 r 视为从 h 到 t 的翻译向量，并约定 h+r ≈ t。该方法被广泛适用于知识图谱补全任务当中，显示出极强的鲁棒性和可拓展性。

具体细节如下图所示，RGAT 中每层结点的特征由邻居结点特征的均值以及邻边特征的均值加权拼接而成，通过关系注意力机制，不同的结点和边具有不同的权重系数。在得到最后一层的结点和边特征后，我们利用 TransE 作为训练目标，对训练集中的每对三元组（h,r,t），最小化 ||h+r=t||。在预测时，对于每个头实体和每种关系，图谱所有结点作为候选尾实体与其计算距离，得到最终的尾实体。

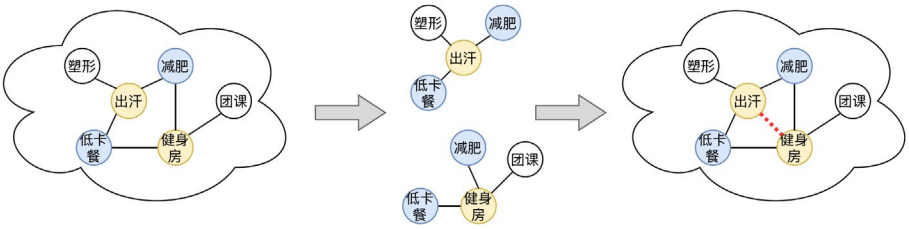

图 17　概念承接关系补足图示

目前概念承接关系整体准确率 90% 左右。

3.5 POI/SPU– 概念关系建设

建立图谱概念和美团实例之间的关联，会利用到 POI/SPU 名称、类目、用户评论等多个维度的信息。建立关联的难点在于如何从多样化的信息中获取与图谱概念相关的信息。因此，我们通过同义词召回实例下所有与概念语义相关的子句，然后利用判别模型判断概念与子句的关联程度。具体流程如下：

- **同义词聚类**。对于待打标的概念，根据图谱同义词数据，获取概念的多种表述。
- **候选子句生成**。根据同义词聚类的结果，从商户名称、团单名称、用户评论等多个来源中召回候选子句。
- **判别模型**。利用概念 – 文本关联判别模型（如下图所示）判断概念和子句是否匹配。

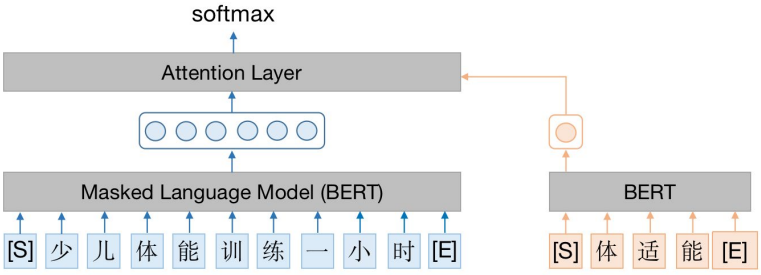

图 18　概念打标判别模型

- **打标结果**。调整阈值，得到最终的判别结果。

四、应用实践

4.1 到综品类词图谱建设

美团到综业务涵盖知识领域较广，包含亲子、教育、医美、休闲娱乐等，同时每个领域都包含更多小的子领域，所以针对不同的领域建设领域内的知识图谱，能够辅助做好搜索召回、筛选、推荐等业务。

在常识性概念图谱中除了常识性概念数据，同时也包含美团场景数据，以及基础算法能力的沉淀，因此可以借助常识性图谱能力，帮助建设到综品类词的图谱数据。

借助常识性图谱，补充欠缺的品类词数据，构建合理的品类词图谱，帮助通过搜索改写，POI 打标等方式提升搜索召回。目前在教育领域，图谱规模从起初的 1000+ 节点扩展到 2000+，同时同义词从千级别扩展到 2 万 +，取得了不错的效果。

品类词图谱建设流程如下图所示：

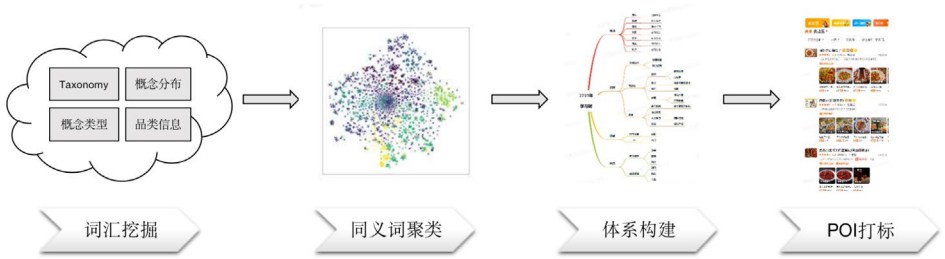

图 19　到综品类词图谱建设流程

4.2 点评搜索引导

点评搜索 SUG 推荐，在引导用户认知的同时帮助减少用户完成搜索的时间，提升搜索效率。所以在 SUG 推荐上需要聚焦两个方面的目标：①帮助丰富用户的认知，从对点评的 POI、类目搜索增加自然文本搜索的认知；②精细化用户搜索需求，当用户在搜索一些比较泛的品类词时，帮助细化用户的搜索需求。

在常识性概念图谱中，建立了很丰富的概念以及对应属性及其属性值的关系，通过一

个相对比较泛的 Query，可以生成对应细化的 Query。例如蛋糕，可以通过口味这个属性，产出草莓蛋糕、芝士蛋糕，通过规格这个属性，产出 6 寸蛋糕、袖珍蛋糕等等。

搜索引导词 Query 产出示例如下图所示：

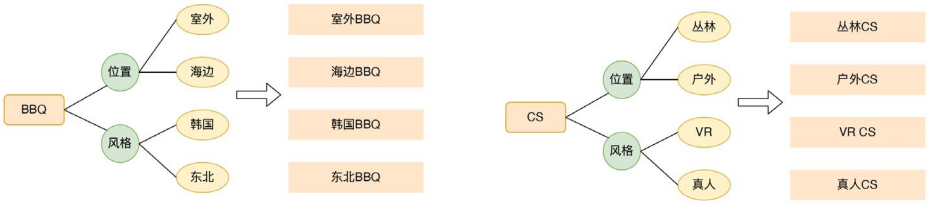

图 20　推荐 Query 挖掘示例

4.3 到综医美内容打标

在医美内容展示上，用户通常会对某一特定的医美服务内容感兴趣，所以在产品形态上会提供一些不同的服务标签，帮助用户筛选精确的医美内容，精准触达用户需求。但是在标签和医美内容进行关联时，关联错误较多，用户筛选后经常看到不符合自己需求的内容。提升打标的准确率能够帮助用户更聚焦自己的需求。

借助图谱的概念 -POI 打标能力和概念 -UGC 的打标关系，提升标签 - 内容的准确率。通过图谱能力打标，在准确率和召回率上均有明显提升。

- **准确率**：通过概念 - 内容打标算法，相比于关键词匹配，准确率从 51% 提升到 91%。
- **召回率**：通过概念同义挖掘，召回率从 77% 提升到 91%。

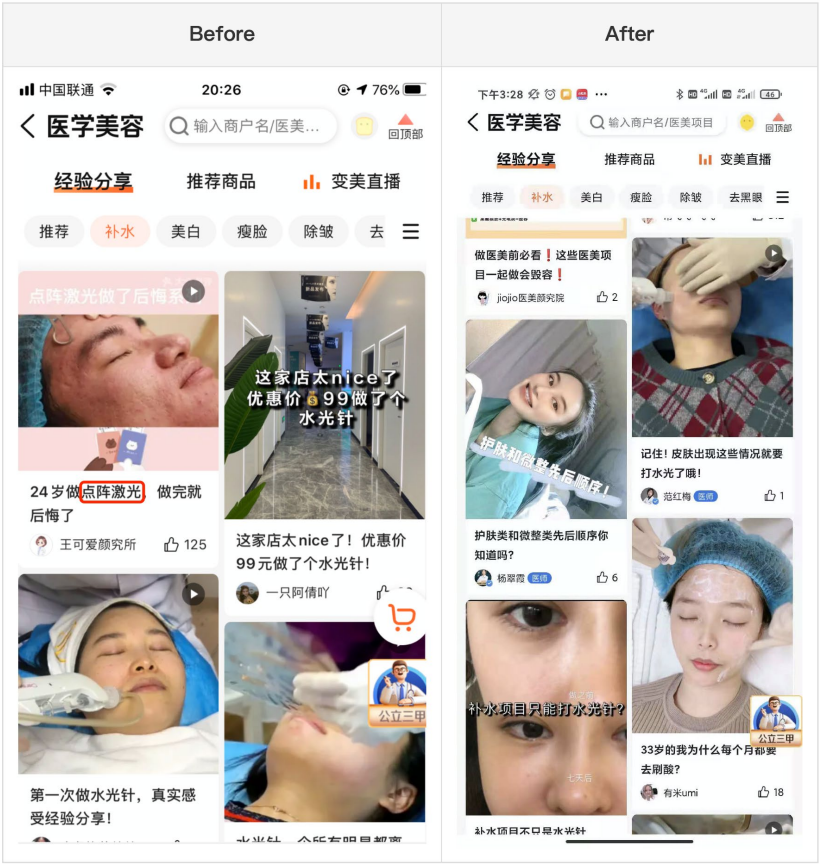

图 21　医美内容打标效果示例

五、总结与展望

我们对常识性概念图谱建设工作以及在美团场景中的使用情况进行了详细的介绍。在整个常识性概念图谱中，按照业务需要包含三类节点和四类的关系，分别介绍了概念挖掘算法、不同种类的关系挖掘算法。

目前，我们常识性概念图谱有 200 万 + 的概念，300 万 + 的概念之间的关系，包含上下位、同义、属性、承接等关系，POI- 概念的关系不包含在内。目前，整体关系准确率在 90% 左右，并且还在不断优化算法，扩充关系的同时提升准确率。后续我们的常识性概念图谱还会继续完善，希望能够做到精而全。

参考资料

[1] Onoe Y, Durrett G. Interpretable entity representations through large-scale typing[J]. arXiv preprint arXiv:2005.00147, 2020.

[2] Bosselut A, Rashkin H, Sap M, et al. Comet: Commonsense transformers for automatic knowledge graph construction[J]. arXiv preprint arXiv:1906.05317, 2019.

[3] Soares L B, FitzGerald N, Ling J, et al. Matching the blanks: Distributional similarity for relation learning[J]. arXiv preprint arXiv:1906.03158, 2019.

[4] Peng H, Gao T, Han X, et al. Learning from context or names? an empirical study on neural relation extraction[J]. arXiv preprint arXiv:2010.01923, 2020.

[5] Jiang, Zhengbao, et al. "How can we know what language models know?." Transactions of the Association for Computational Linguistics 8 (2020): 423-438.

[6] Li X L, Liang P. Prefix-Tuning: Optimizing Continuous Prompts for Generation[J]. arXiv preprint arXiv:2101.00190, 2021.

[7] Malaviya, Chaitanya, et al. "Commonsense knowledge base completion with structural and semantic context." Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 34. No. 03. 2020.

[8] 李涵昱 , 钱力 , 周鹏飞 . "面向商品评论文本的情感分析与挖掘 ." 情报科学 35.1 (2017): 51-55.

[9] 闫波 , 张也 , 宿红毅 等 . 一种基于用户评论的商品属性聚类方法 .

[10] Wang, Chengyu, Xiaofeng He, and Aoying Zhou. "Open relation extraction for chinese noun phrases." IEEE Transactions on Knowledge and Data Engineering (2019).

[11] Li, Feng-Lin, et al. "AliMeKG: Domain Knowledge Graph Construction and Application in E-commerce." Proceedings of the 29th ACM International Conference on Information & Knowledge Management. 2020.

[12] Yang, Yaosheng, et al. "Distantly supervised ner with partial annotation learning and reinforcement learning." Proceedings of the 27th International Conference on Computational Linguistics. 2018.

[13] Luo X, Liu L, Yang Y, et al. AliCoCo: Alibaba e-commerce cognitive concept net[C]//Proceedings of the 2020 ACM SIGMOD International Conference on Management of Data. 2020: 313-327.

[14] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.

[15] Cheng H T, Koc L, Harmsen J, et al. Wide & deep learning for recommender systems[C]//Proceedings of the 1st workshop on deep learning for recommender systems. 2016: 7-10.

[16] Liu J, Shang J, Wang C, et al. Mining quality phrases from massive text corpora[C]//Proceedings of the 2015 ACM SIGMOD International Conference on Management of Data. 2015: 1729-1744.

[17] Shen J, Wu Z, Lei D, et al. Hiexpan: Task-guided taxonomy construction by hierarchical tree expansion[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018: 2180-2189.

[18] Huang J, Xie Y, Meng Y, et al. Corel: Seed-guided topical taxonomy construction by concept learning and relation transferring[C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2020: 1928-1936.
[19] Liu B, Guo W, Niu D, et al. A user-centered concept mining system for query and document understanding at tencent[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019: 1831-1841.
[20] Choi E, Levy O, Choi Y, et al. Ultra-fine entity typing[J]. arXiv preprint arXiv:1807.04905, 2018.
[21] Xie Q, Dai Z, Hovy E, et al. Unsupervised data augmentation for consistency training[J]. arXiv preprint arXiv:1904.12848, 2019.
[22] Mao X, Wang W, Xu H, et al. Relational Reflection Entity Alignment[C]// Proceedings of the 29th ACM International Conference on Information & Knowledge Management. 2020: 1095-1104.
[23] Chen J, Qiu X, Liu P, et al. Meta multi-task learning for sequence modeling[C]// Proceedings of the AAAI Conference on Artificial Intelligence. 2018, 32(1).

作者简介

宗宇、俊杰、慧敏、福宝、徐俊、谢睿、武威等，均来自美团搜索与 NLP 部 -NLP 中心。

招聘信息

美团搜索与 NLP 部 /NLP 中心是负责美团人工智能技术研发的核心团队，使命是打造世界一流的自然语言处理核心技术和服务能力，依托 NLP（自然语言处理）、Deep Learning（深度学习）、Knowledge Graph（知识图谱）等技术，处理美团海量文本数据，为美团各项业务提供智能的文本语义理解服务。

NLP 中心长期招聘自然语言处理算法专家 / 机器学习算法专家，感兴趣的同学可以将简历发送至 wangzongyu02@meituan.com。

美团外卖美食知识图谱的迭代及应用

作者：杨林　郭同　海超　懋地

0. 写在前面

菜品是外卖交易过程的核心要素，对菜品的理解也是实现外卖供需匹配的重点。本期推送，我们将通过三篇文章系统地介绍了美团外卖美食知识图谱的构建和应用。第一篇文章会介绍外卖知识图谱的体系全貌，包括菜品类目、标准菜品、美食基础属性（食材、口味等）和美食业务主题属性。同时外卖的菜品属于非标品。第二篇，我们将重点介绍外卖菜品标准化建设思路、技术方案和业务应用。由于外卖的业务特点是搭配成单，所以在第三篇我们会针对性地介绍外卖套餐搭配技术的迭代以及应用实践。希望对从事相关工作的同学能够带来一些启发或者帮助。

本文系外卖美食知识图谱系列的第一篇文章，这篇文章系统地介绍了美团外卖美食知识图谱的标签体系结构，包括菜品类目标签、标准菜品名、美食基础属性（食材、口味、菜系等）和美食业务主题属性（商家招牌、类目经典等）。在技术层面，举例对标签体系的具体构建方法进行介绍，例如基于 BERT 预训练的分类模型。在应用方面，介绍了美食知识图谱在美团外卖业务的具体应用，包括支撑套餐搭配的菜品表征、提升搜索和商家推荐等业务的用户体验。

1. 背景

知识图谱，旨在描述真实世界中存在的各种实体和实体之间的关系。在美团外卖业务中，美食商品是美团向用户提供服务的基础，美食知识图谱的建设，可以帮助我们向用户提供更加准确、更加丰富、更加个性化的美食服务。另外，美团外卖业务向用户提供“到家”吃饭的服务，到店餐饮业务则向用户提供“到店”吃饭的服务，而外卖和到店的商家和菜品有相当程度的重合，菜品数据的对齐，为我们进行线上（外卖场景）线下（到店场景）数据的对比分析也提供了一个很好的“抓手”。

本文介绍了外卖美食知识图谱的建设，基于对外卖业务数据（外卖交易数据、商家录入的商品标签信息、专业描述 PGC、用户评论 UGC、商品图片等）和站外数据（百科、菜谱等）的挖掘和分析，形成了针对外卖美食的分类体系（美食类目标签）和标准化体系（标准菜品名标签），并进一步针对不同类型的美食商品，构建包含口味、食材等众多美食基础属性体系。同时，依托美团外卖的业务特性，构建美食商品在外卖业务中涉及的主题属性体系，例如商家招牌、商家主营、类目经典等。目前，外卖美食知识图谱的标签结构如下图 1 所示：

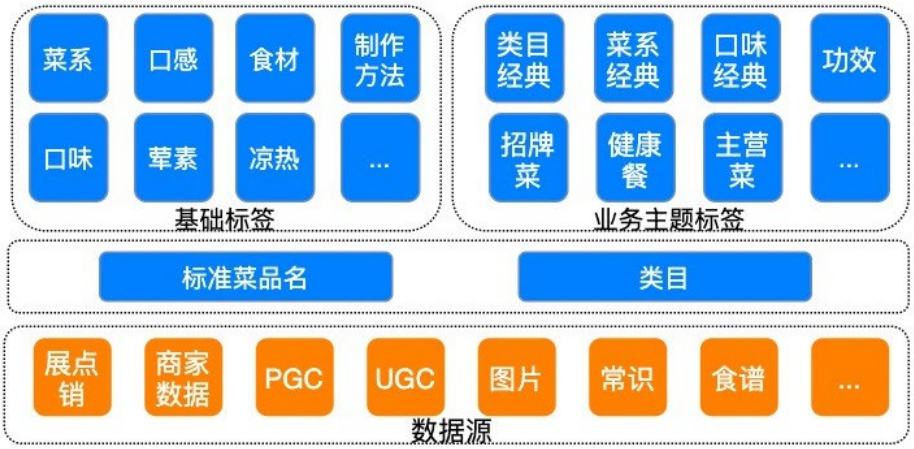

图 1　美食知识图谱标签体系

外卖美食知识图谱包含以下四种维度的标签（以“宫保鸡丁”为例，如下图 2 所示）：

- **类目标签**：包括主食、小吃、菜品等类目，并在每个类目下，形成了层级化的三百多种细分类目。例如“宫保鸡丁”的类目是“菜品”。类目标签是美食商品的基础分类信息，根据类目的不同，美食商品的基础属性也不同。例如“菜品”类目存在“荤素”、“菜系”之分，而“酒水饮品”类目则没有这种属性标签。
- **标准菜品名标签**：标准菜品名标签主要为标准商品信息，例如“宫保鸡丁（招牌必点）”的标准商品是“宫保鸡丁”。因商家输入商品的多样性，标准菜标签的建设，实现了相同美食的聚合。
- **基础属性**：根据美食商品的类目不同，构建包括美食的食材、菜系、口味、制

作方法、荤素等基础属性。例如“宫保鸡丁”的菜系是“川菜”，食材有“鸡胸”和“花生”，荤素标签是“荤”。基础属性的挖掘对我们理解商品起到关键作用，在商品的筛选、展示、商品表征等业务需求方面，提供基本的数据特征。

- **主题属性**：主题属性主要体现美食的业务主题，包括美食在外卖的交易行为、美食在商家的定位、美食在用户反馈中的好评度等。例如某商家的“宫保鸡丁（招牌必点）”是该商家的“招牌菜”。

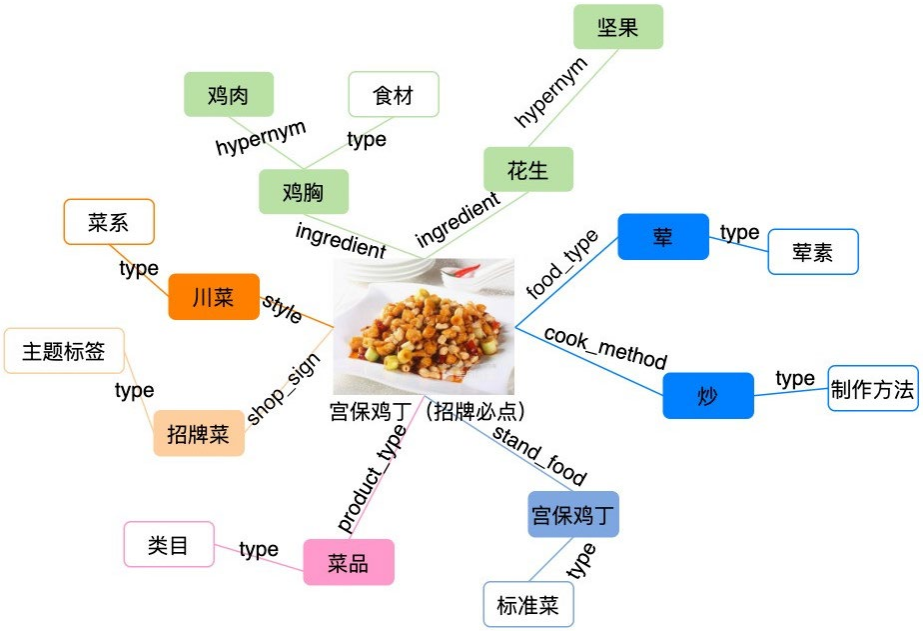

图 2　外卖美食知识图谱样例

菜品对齐，涉及到菜品数据，来自外卖在线菜品、点评推荐菜品、美团商家套餐等。

2. 需求及挑战

目前，外卖美食知识图谱已经应用于美团外卖的多个场景，例如推荐、搜索、套餐搭配、运营分析等。业务的深入发展，对美食知识图谱的建设和迭代也提出了更加复杂的要求，例如：

- 美食商品越来越多样，相应的美食知识图谱则需要越来越精细和准确。例如美

食知识图谱的类目标签从零开始，建设了包含一百多种类目的类目标签体系。但随着业务发展，部分类目存在明显的可细化空间。

- 图谱标签的挖掘，偏向于静态标签的挖掘，对于相同图谱标签下的美食，缺少业务相关的主题属性描述。例如同样包含“花生”的“酒鬼花生”，相比“宫保鸡丁”，更能代表“花生”相关的美食。
- 外卖美食知识图谱主要描述外卖美食商品，而同一商家的美食商品，也可能会出现在该店的线下收银等业务中。通过对齐不同业务的美食商品，可以在美食实体层面，完善美食知识图谱对商家美食的描述，从而指导商品和商家运营。

为满足业务需求，我们对类目标签和基础属性进行了迭代和优化；同时，构建了业务相关的主题属性。另外，我们将外卖菜品和到餐菜品进行了实体对齐。其中，挖掘主题属性，即挖掘业务相关的图谱知识，是一个需要综合考虑外卖业务和商品本身属性的复杂过程。外卖菜品和到餐菜品的对齐，则需要综合考虑菜品多样性表述和菜品主体归一。

外卖美食知识图谱的迭代难点主要体现在以下几点：

- 业务相关的主题属性挖掘，并没有现成的体系可以参考，在构建过程中，涉及大量的分析和体系设计工作。
- 主题属性的挖掘，最重要的是需要从用户的需求出发，分析用户对商品的需求点，并将其反映在商品的图谱层面，形成相应的主题属性标签。同时，商家的商品信息是一个动态变化的过程，例如销量、供给、商品标签等，前后两天的信息可能就会完全不同。因此业务性主题属性的挖掘，一方面需要建设相对完善的体系，另一方面也需要适配业务数据的动态变化过程，也就在图谱挖掘和需求匹配上带来了极大的挑战。
- 商家录入菜品时，对菜品存在多样性表述，例如同一道菜在分量、口味、食材等方面存在的差异。菜品对齐时，则需要对这些多样性表述进行平衡，例如是否忽略分量因素等。但目前并没有现成的对齐标准可以参考。

3. 外卖美食知识图谱的迭代

因篇幅受限，本文主要对其中菜品类目，不同类目、口味、食材、荤素、做法下的经典美食，健康餐等图谱标签的挖掘进行介绍。其中，在图谱标签挖掘中涉及到的数据来源和采用的技术，大致如下表所示：

标签	技术
菜品类目	BERT 分类模型
不同类目、口味、食材、荤素、做法下的经典美食	数据统计、实体识别、关系识别、产品定义（综合考虑销量和供给量）
健康餐	分类模型 + 产品定义（符合一定食材、做法、功效的商品）

3.1 菜品类目

菜品类目标签的挖掘，主要解决美食菜品是什么类别的问题。实现这一目标的挑战有两方面：首先是类目体系如何建立，其次是如何将商品链接到相应的类目节点。在最开始的体系构建时，我们从美食商品的特点以及业务的具体需求出发，从零开始建立起包含一百多种类别的层次化类别体系，部分实例如图 3（左）所示。同时，构建基于 CNN+CRF 的分类模型，对美食商品进行类目分类，如图 4（左）所示。

然而，随着业务的发展，已有分类目已经无法支持现有业务的需求。例如：原先的类目体系，对热菜描述不够详细，譬如没有区分热菜的做法等。为此，我们与外卖的供给规划部合作，将类目体系扩充到细分的三百多种类目标签，划分更加详细，覆盖也更加全面，部分实例如图 3（右）所示。

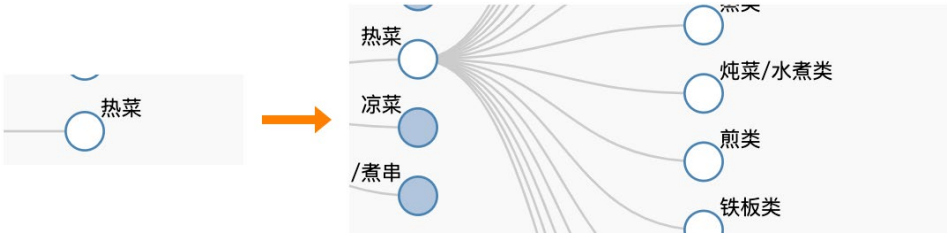

图 3　类目体系的迭代

类目的细分，要求模型更加精确。在进行类目识别时，可用的数据包括菜品名、商

家店内侧边栏分类名称、商家名等。考虑到可使用的信息大多为文本信息，并且，商家录入的文本并没有一定的规范，菜品名也多种多样，为提高模型精度，我们将原先的 CNN+CRF 的分类模型进行了升级，采用模型容量更大的 BERT 预训练+Fine-Tuning 的模型。模型结构如下图 4（右）所示。

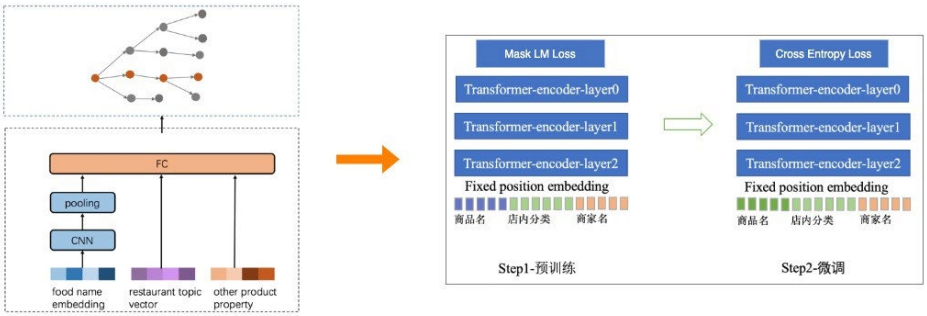

图 4　类目模型迭代

3.2 不同类目、口味、食材、荤素、做法下的经典美食标签

我们在建设主题属性时，首先在基础属性标签维度，综合考虑商品的销量和供给情况，对菜品进行选优。例如类目下的经典美食等。但在建设过程中，我们发现菜系的经典美食识别，假如依据销量和供给进行识别，则识别结果倾向于菜系下的“家常菜”，因此将经典菜系美食进行单独识别。

类目经典美食等指的是销量较高、供给量丰富的类目美食商品，例如主食经典美食、小吃经典美食。口味、食材、做法经典美食标签等也是相似的定义。

在建设过程中，我们发现，假如直接在商品维度进行识别，因为商品的更新频率相对较高，对新录入的暂时没有销量或者暂时销量低的美食商品不友好，销量水平需要考虑在线时间的影响。因此我们使用标准菜品进行类目、口味经典等的识别，并通过标准菜品，泛化到具体的美食商品上。

其中，“标准菜品”借用其它类电商业务中的“标品”概念，虽然绝大部分菜品的生产都不是标准化的过程，但是这里我们只关注主要的共性部分，忽略次要的差异部

分。例如“西红柿鸡蛋”、“番茄炒蛋”都是同一类菜品。从结果上看，目前我们聚合出来的“标准菜品”达到几十万的量级，并且能够覆盖大部分美食商品。

借助标准菜品，我们将类目、口味、食材、荤素、做法等标签聚合到标准菜品维度，并将销量、供给量进行标准菜品维度计算，这样就解决了商品在线时间长短的问题。在具体打标过程中，例如类目经典，我们基于销量和供给，在类目维度对标准菜进行排序，并选择 Top n% 标准菜进行打标，作为类目经典下的商品。例如在“面食”类目下，“西红柿鸡蛋面”的销量和供给量均在 Top n% 的水平，因此就认为“西红柿鸡蛋面”是一个面食类经典美食。

3.3 健康餐

这里的健康餐主要指低脂低卡餐，即低卡路里、低脂肪、高纤维、制作简单、原汁原味、健康营养的食物，一般为蔬菜水果（如罗勒、甘蓝、秋葵、牛油果等），富含优质蛋白的肉类（如三文鱼、虾、贝类、鸡胸等），谷物（主要以粗粮为主，如燕麦、高粱、藜麦等）。烹饪方法也坚持“少油，少盐，少糖”的原则，主要做法为蒸、煮、少煎、凉拌等。

健康餐的识别，主要挑战在于本身的样本较少，但是因为健康餐的特殊性，商家在进行商品录入时，一般会对其进行描述，例如指出这个美食商品是“健康”的、“低卡”的、“健身”类型的，因此我们构建了一个分类模型，对健康餐进行识别。可使用的数据，包括商品名、商家导航栏、商家名称、商家对商品的描述等。而商家类目与商品的类目处于迭代状态，因此并没有对这部分信息进行使用。

识别过程如下：

- **训练数据构建**：因健康餐本身的占比相对较少，因此首先总结和健康餐相关的关键词，使用关键词进行文本匹配，采样概率相对较高的健康餐数据，进行外包数据标注。此处，我们总结出“沙拉、谷物饭、谷物碗、低油、低卡、无糖、减脂、减肥、轻食、轻卡”等关键词。
- **模型构建**：同一个商品因其中使用的配料不同，在健康餐识别方面也会不同，

例如菜名为“招牌沙拉”的商品，假如沙拉中添加了芝士，则有可能商品就不会被识别成健康餐。为了综合考虑商家录入的商品信息，使用商品名、商家名、导航栏名称、商家录入的商品描述等。这四种数据为不同尺度的数据源，商品名等为相对较短的文本，因此在模型构建时，考虑使用类似 Text-CNN[1] 的结构进行字级别的特征提取；商品描述则是相对较长的文本，因此在构建时，考虑使用类似 Transformer[2] 的结构进行特征提取，使用 Multi-head Attention 的机制，提取长文本中，“字”层面的特征。具体结构如下：

- 采用了两种结构：Multihead-attention（Transformer）和 Text-CNN。实验发现，采用两种结构联合的方式，比采用单一结构准确率高。
- 在建模时，均使用字级别特征处理，避免因为分词造成的误差，同时也避免未登录词的影响。

- **数据迭代增强**：因为使用关键词进行样本构建，在模型训练时，模型会朝着包含这些关键词的方向学习，因此存在漏召回的情况。在这里，我们进行了一定的训练数据增强，例如在评估时，选取可识别出健康餐的商家，对该商家中漏召回的数据进行训练数据补充；同时，对部分特征明显的关键词，进行补充并扩充正例。通过对训练样本的多次扩充，最终完成健康餐的高准确率识别。

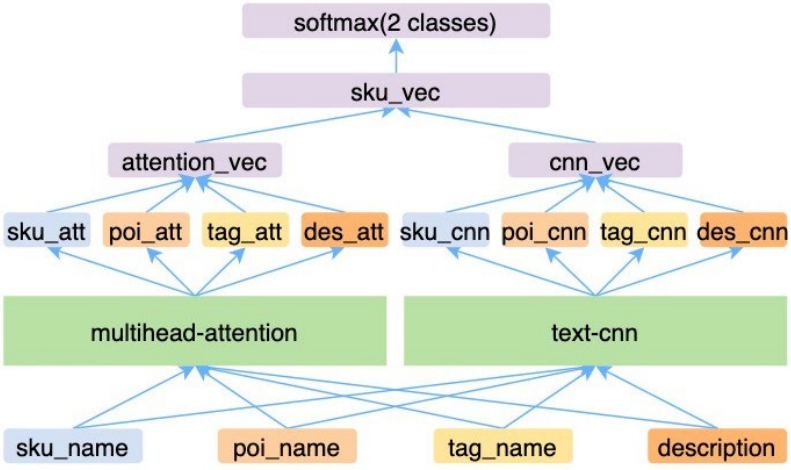

图 5　健康餐识别模型

3.4 菜品实体对齐

考虑到同一商家菜品在不同业务线的菜品名可能略有差异，我们设计了一套菜品名匹配的算法，通过拆解菜品名称的量词、拼音、前后缀、子字符串、顺序等特征，利用美食类目识别、标准菜品名抽取、同义关系匹配等进行菜品实体对齐。例如：碳烧鸽 = 炭烧鸽、重庆辣子鸡 = 重庆歌乐山辣子鸡、茄子肉泥盖饭 = 茄子肉泥盖浇饭、番茄炒蛋 = 西红柿炒蛋等。目前，形成如下图的菜品归一体系：

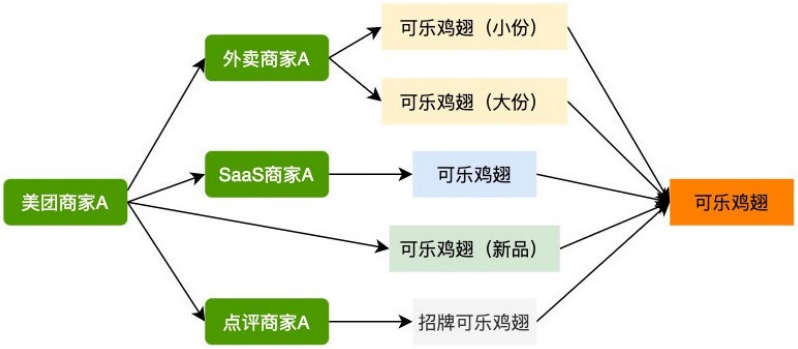

图 6　菜品归一体系

4. 应用

这里对外卖美食知识图谱的应用，进行举例说明。主要涉及套餐搭配、美食商品展示等。

4.1 套餐搭配 – 表征菜品

为满足用户的搭配成单需求，进行套餐搭配技术的探索。套餐搭配技术的关键在于，对美食商品的认知，而外卖美食知识图谱，则提供了最全面的数据基础。我们基于同商家内的商品信息和历史成单信息，对商品的搭配关系进行拟合，参考指针网络 [2] 等结构，构建了基于 Multi-Head Attention[3] 的 Enc-Dec 模型，具体的模型结构如下：

- **Encoder**：对商家菜单进行建模，因菜单为无序数据，因此采用 Attention 的方式进行建模。商品的信息主要包括商品名、商品图谱标签、交易统计数据等

三部分。

- 对菜名、商品标签分别进行 Self-Attention 计算，得到菜名和商品标签对应的向量信息，然后与交易统计数据进行 Concat，作为商品的初步表示。
- 对商品的初步表示进行 Self-Attention 计算，以对同商家的商品有所感知。

- **Deocoder**：对搭配关系进行学习，基于当前已选择的商品，对下一个可能的搭配进行预估。
  - 在搭配输出时，使用 Beam-Search 进行多种搭配结果的输出。
  - 为了保证输出搭配中的商品的多样性，添加 Coverage 机制 [2]。
- 训练之后，将 Encoder 部分分离，进行离线调度，可实现每天的向量产出。

具体的模型结构如下图所示：

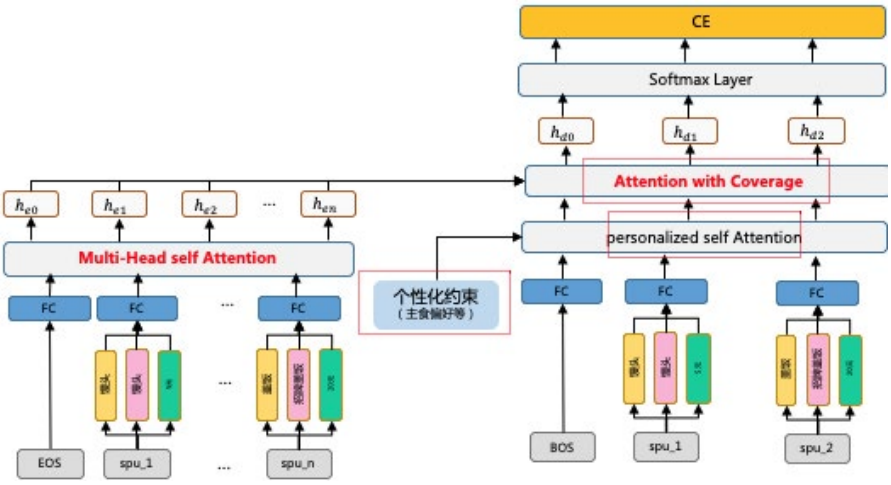

图 7　套餐搭配模型

基于外卖美食知识图谱构建的套餐搭配模型，在多个入口（“满减神器”、“对话点餐”、“菜品详情页”等）取得转化的提升。

4.2 交互式推荐

通过分析外卖用户的需求，发现用户存在跨店相似商品对比的需求，为打破商家界限的选购流程特点，提供便捷的跨店对比决策方式。交互式推荐，通过新的交互模式，

打造推荐产品的突破点。在用户的交互过程中，根据用户的历史偏好、实时的点击行为，向用户推荐可能喜欢的美食商品。如下图 8（左）所示，在向用户进行同类美食的推荐时，美食知识图谱中的标准菜品标签提供了主要的数据支撑。

4.3 搜索

搜索作为外卖核心流量入口，承载了用户明确的外卖需求。用户通过输入关键词，进行菜品检索。在实际使用中，从搜索的关键词类型看，可能是某个具体的菜品，也可能是某种食材、某种菜系。在美食知识图谱中，图谱标签的高准确率和高覆盖，有助于提升搜索入口的用户体验，最新的实验也表明了这一点（新增部分食材、菜系、功效等标签，在搜索的线上实验效果正向）。

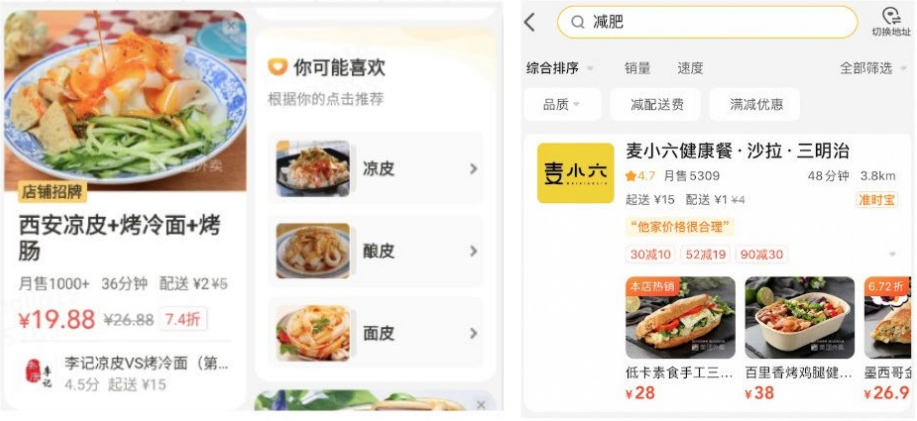

图 8　交互式推荐和搜索

5. 未来规划

5.1 场景化标签的挖掘

美食与我们的生活息息相关，美团外卖每天为千万用户提供美食方面的服务。然而，用户的需求是多种多样的，在不同的环境、不同的场景下，对美食的需求也不尽相同。目前美食知识图谱挖掘，在场景相关的标签较为缺失，例如某些节气、节日等图谱知识；特定天气情况下的图谱知识；特定人群（增肌人群、减肥人群）等的图谱知

识。接下来我们会在场景化标签的挖掘方面进行探索。

在挖掘方法方面，目前的挖掘数据主要为文本信息。在商品图片、描述、结构化标签等信息的融合方面，挖掘不够深入，模型的效果也有待提升。因此在多模态识别模型方面，我们也会进行相应的探索。

5.2 基于图谱的推荐技术研究

美团外卖在理解美食的基础上，向用户进行美食推荐，以更好地满足用户对美食的需求。外卖美食知识图谱和外卖业务数据，作为实现这一点的数据基础，包含上亿的节点信息和十几亿的关系数据。通过对用户的商品搜索、点击、购买等行为进行建模分析，可以更加贴合用户的需求，向用户进行商品推荐，例如，将美食知识图谱和外卖行为数据融合，以用户为起点，进行随机游走，向用户推荐相关的美食。在接下来的图谱应用方面的探索中，我们也会更加深入的探索基于美食知识图谱和用户行为的推荐技术。

6. 参考文献

[1] Kim Y. Convolutional neural networks for sentence classification[J]. arXiv preprint arXiv:1408.5882, 2014.

[2] See A, Liu P J, Manning C D. Get to the point: Summarization with pointer-generator networks[J]. arXiv preprint arXiv:1704.04368, 2017.

[3] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in neural information processing systems. 2017: 5998-6008.

[4] Hamilton W, Ying Z, Leskovec J. Inductive representation learning on large graphs[C]//Advances in Neural Information Processing Systems. 2017: 1024-1034.

7. 作者简介

杨林、郭同、海超、懋地等，均来自美团外卖技术团队。

美团知识图谱问答技术实践与探索

作者：如寐　梁迪　思睿　鸿志　明洋　武威

1. 背景与挑战

问答系统（Question Answering System, QA）是人工智能和自然语言处理领域中一个倍受关注并具有广泛发展前景的方向，它是信息检索系统的一种高级形式，可以用准确、简洁的自然语言回答用户用自然语言提出的问题。这项研究兴起的主要原因是人们对快速、准确地获取信息的需求，因此被广泛应用于工业界的各种业务场景中。美团在平台服务的售前、售中、售后全链路的多个场景中，用户都有大量的问题需要咨询商家。因此我们基于问答系统，以自动智能回复或推荐回复的方式，来帮助商家提升回答用户问题的效率，更快地解决用户的问题。

针对不同问题，美团的智能问答系统包含多路解决方案：

- **PairQA**：采用信息检索技术，从社区已有回答的问题中返回与当前问题最接近的问题答案。
- **DocQA**：基于阅读理解技术，从商家非结构化信息、用户评论中抽取出答案片段。
- **KBQA（Knowledge-based Question Answering）**：基于知识图谱问答技术，从商家、商品的结构化信息中对答案进行推理。

本文主要分享在 KBQA 技术落地中的实践与探索。

在用户的问题中，包括着大量关于商品、商家、景区、酒店等相关基础信息及政策等信息咨询，基于 KBQA 技术能有效地利用商品、商家详情页中的信息，来解决此类信息咨询问题。用户输入问题后，KBQA 系统基于机器学习算法对用户查询的问题进行解析、理解，并对知识库中的结构化信息进行查询、推理，最终将查询到的精确答案返回给用户。相比于 PairQA 和 DocQA，KBQA 的答案来源大多是商家数据，可

信度更高。同时，它可以进行多跳查询、约束过滤，更好地处理线上的复杂问题。

实际落地应用时，KBQA 系统面临着多方面的挑战，例如：

- **繁多的业务场景**：美团平台业务场景众多，包涵了酒店、旅游、美食以及十多类生活服务业务，而不同场景中的用户意图都存在着差别，比如“早餐大概多少钱”，对于美食类商家需要回答人均价格，而对于酒店类商家则需要回答酒店内餐厅的价格明细。
- **带约束问题**：用户的问题中通常带有众多条件，例如“故宫学生有优惠吗”，需要我们对故宫所关联的优惠政策进行筛选，而不是把所有的优惠政策都回答给用户。
- **多跳问题**：用户的问题涉及到知识图谱中多个节点组成的路径，例如“XX 酒店的游泳池几点开”，需要我们在图谱中先后找到酒店、游泳池、营业时间。

下面将详细讲述我们是如何设计高准确、低延时的 KBQA 系统，处理场景、上下文语境等信息，准确理解用户、捕捉用户意图，从而应对上述的挑战。

2. 解决方案

KBQA 系统的输入为用户 Query，输出为答案。总体架构如下图 1 所示。最上层为应用层，包括对话以及搜索等多个入口。在获取到用户 Query 后，KBQA 线上服务通过 Query 理解和召回排序模块进行结果计算，最终返回答案文本。除了在线服务之外，知识图谱的构建、存储也十分重要。用户不仅会关心商户的基本信息，也会询问观点类、设施信息类问题，比如景点好不好玩、酒店停车是否方便等。针对上述无官方供给的问题，我们构建了一套信息与观点抽取的流程，可以从商家非结构化介绍以及 UGC 评论中抽取出有价值的信息，从而提升用户咨询的满意度，我们将在下文进行详细介绍。

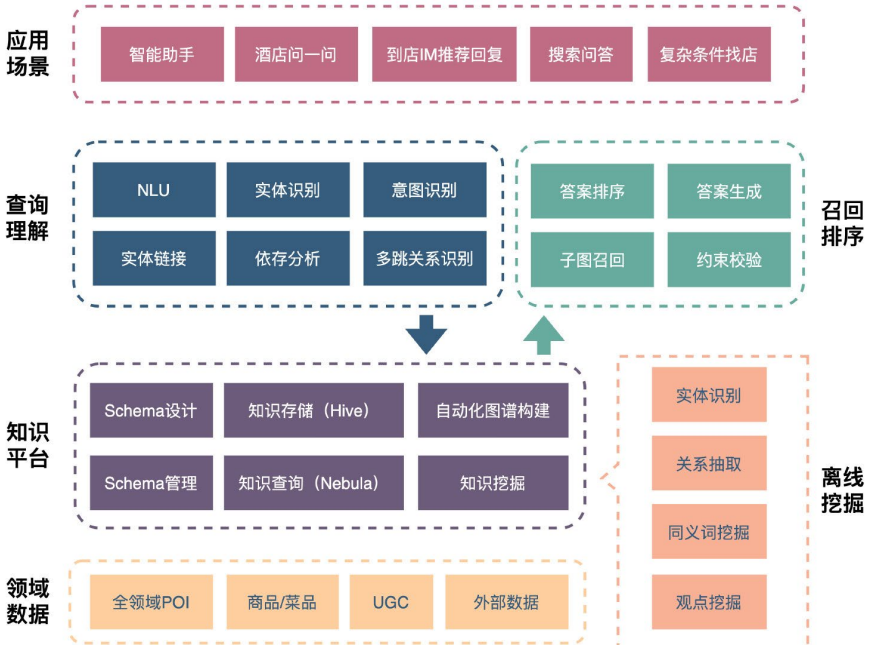

图 1　KBQA 系统架构图

对于 KBQA 模型，目前的主流解决方案有两种，如下图 2 所示：

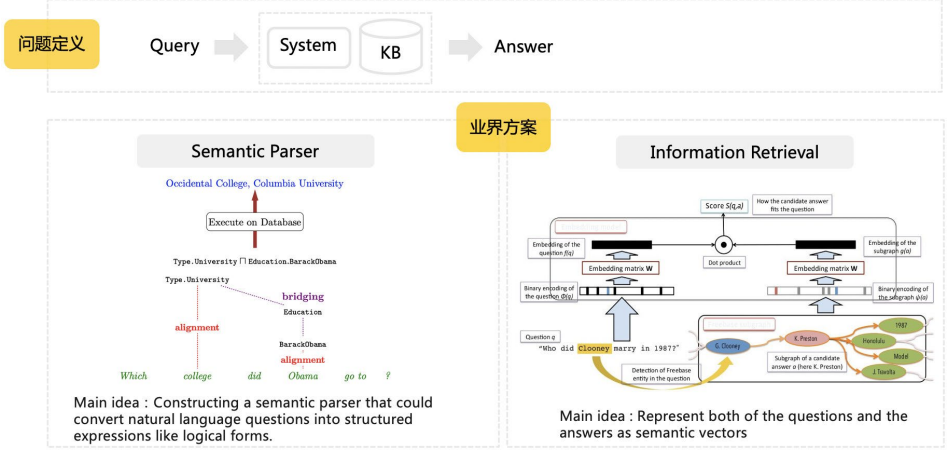

图 2　KBQA 解决方案分类

- **基于语义解析（Semantic Parsing-based）**：对问句进行深度句法解析，并

将解析结果组合成可执行的逻辑表达式（如 SparQL），直接从图数据库中查询答案。

- **基于信息抽取（Information Retrieval）**：先解析出问句的主实体，再从 KG 中查询出主实体关联的多个三元组，组成子图路径（也称多跳子图），之后分别对问句和子图路径编码、排序，返回分数最高的路径作为答案。

基于语义解析的方法可解释性更强，但这种方法需要标注大量的自然语言逻辑表达式，而信息抽取式的方法更偏向端到端的方案，在复杂问题、少样本情况下表现更好，但若子图过大，会显著降低计算的速度。

因此，考虑到两者的优势，我们采用将两者结合的方案。如下图 3 所示，整体的流程分为四大步骤，以“故宫周末有学生票吗”为例：

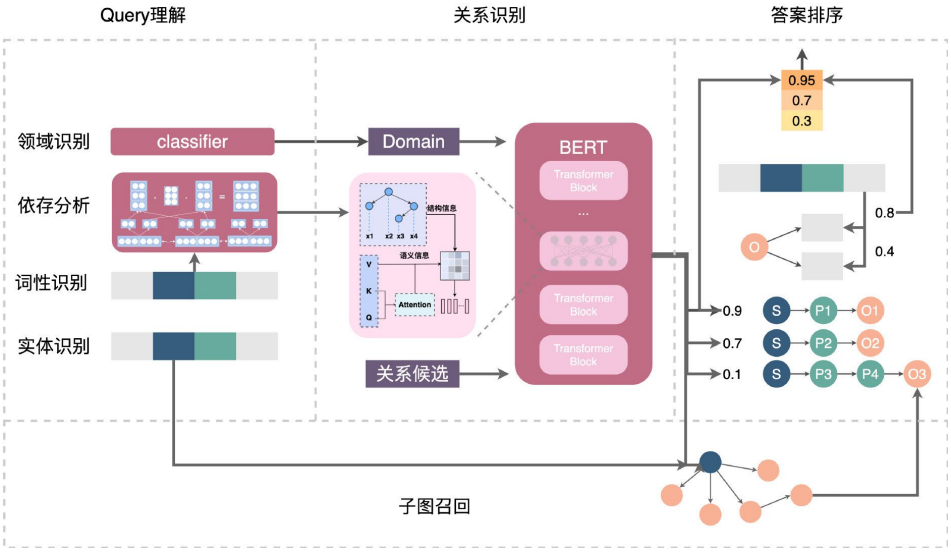

图 3　美团 KBQA 解决方案

- **Query 理解**：输入原始 Query，输出 Query 理解结果。其中会对对 Query 进行句法分析，识别出用户查询的主实体是“故宫”、业务领域为“旅游”、问题类型为一跳（One-hop）。
- **关系识别**：输入 Query、领域、句法解析结果、候选关系，输出每个候选的分

数。在这个模块中，我们借助依存分析强化 Query 的问题主干，召回旅游领域的相关关系，进行匹配排序，识别出 Query 中的关系为“门票”。

- **子图召回**：输入前两个模块中解析的主实体和关系，输出图谱中的子图（多个三元组）。对于上述例子，会召回旅游业务数据下主实体为“故宫”、关系为“门票”的所有子图。
- **答案排序**：输入 Query 和子图候选，输出子图候选的分数，如果 Top1 满足一定阈值，则输出作为答案。基于句法分析结果，识别出约束条件为“学生票”，基于此条件最终对 Query-Answer 对进行排序，输出满足的答案。

下面将介绍我们对于重点模块的建设和探索。

2.1 Query 理解

Query 理解是 KBQA 的第一个核心模块，负责对句子的各个成分进行细粒度语义理解，其中两个最重要的模块是：

- 实体识别和实体链接，输出问句中有意义的业务相关实体和类型，如商家名称、项目、设施、人群、时间等。
- 依存分析：以分词和词性识别结果为输入，识别问句的主实体、被提问信息、约束等。

实体识别是句法分析的重要步骤，我们先基于序列标注模型识别实体，再链接到数据库中的节点。对于该模块我们主要做了以下优化：

- 为了提升 OOV（Out-of-Vocabulary）词的识别能力，我们对实体识别的序列标注模型进行了知识注入，利用已知的先验知识辅助新知识的发现。
- 考虑到实体嵌套的问题，我们的实体识别模块会同时输出粗粒度和细粒度的结果，保证后续模块对于 Query 的充分理解。
- 在问答的长 Query 场景下，利用上下文信息进行实体的链接，得到节点 id。

最终，该模块会输出句子中各个重要成分的类型，如下图 4 所示：

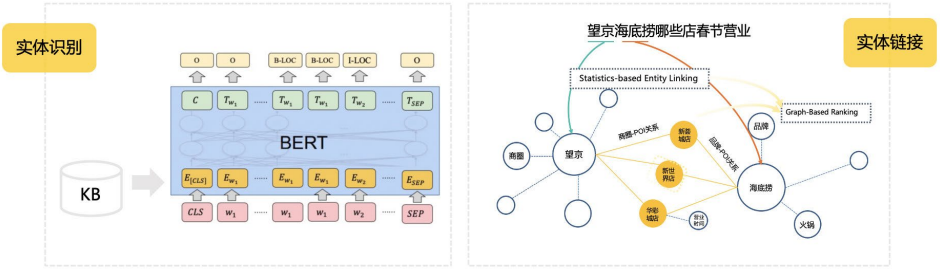

Query	NER结果	实体链接结果
颐和园学生门票多少钱	颐和园=POI、学生=PEOPLE、门票=TICKET	颐和园=000101
望京附近环境安静的咖啡厅	望京=AREA、附近=RANGE、环境安静=TAG、安静=TAG、咖啡厅=POI	望京=0341

图 4　Query 理解流程及结果

依存分析是句法分析的一种，它的目的是识别句子中词与词的非对称支配关系，在输出的结果中用有向弧表示，该弧线由从属词（dep）指向支配词（head）。对于 KBQA 任务，我们定义了五种关系，如下图 5 所示：

关系名称	关系含义
ROOT	主实体
ATT_HEAD	主实体约束
SUB_HEAD	主实体主体
HEAD_INFO	主关系
ATT_INFO	关系约束
INFO_NONE	无意义词

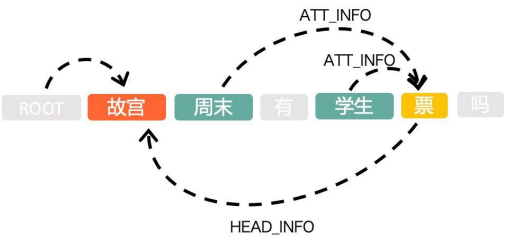

图 5　依存类型定义

依存分析主要有两种方案：基于转移的（Transition-based）和基于图的（Graph-based）。基于转移的依存分析将依存句法树的构建建模为一系列操作，由模型预测每一步的动作（shift、left_arc、right_arc），不断将未处理的节点入栈并赋予关系，最终构成句法树。基于图的方法则致力于在图中找出一棵最大生成树，也就是句子整体依存关系的全局最优解。考虑到基于图的方法是对全局进行搜索，准确率更高，我们采用较为经典的“Deep Biaffine Attention for Neural Dependency Parsing”模

型，它的结构如下图 6 所示：

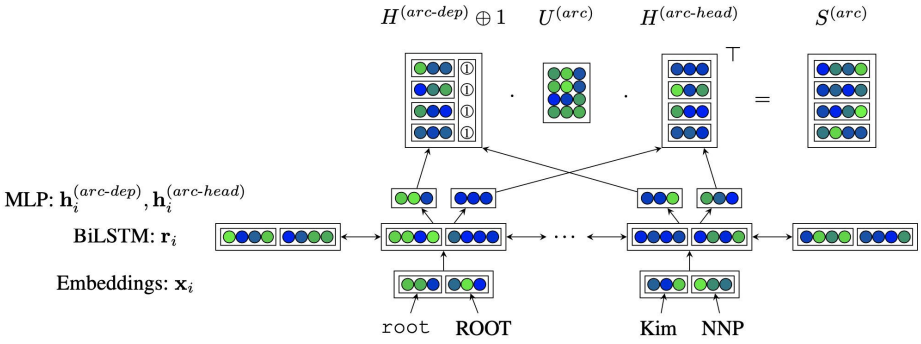

图 6　依存分析模型结构

该模型先通过 BiLSTM 对词与词性的拼接向量进行编码，之后采用对用两个 MLP 头分别编码出 h(arc-head) 和 h(arc-dep) 向量，去除冗余信息。最终将各个时刻的向量拼接起来得到 H(arc-head) 和 H(arc-dep)，且在 H(arc-dep) 上拼接了一个单位向量，加入中间矩阵 U(arc) 进行仿射变换，得到 dep 与 head 的点积分数矩阵 S(arc)，找到每个词依存的 head。

有了依存分析的结果，我们可以更好地识别关系、复杂问题，具体的特征使用方法将在下文进行介绍。

2.2 关系识别

关系识别是 KBQA 中另一个核心模块，目的是识别出用户 Query 所问的关系（Predicate），从而与主实体（Subject）联合确定唯一子图，得到答案（Object）。

在实践中，考虑到图谱中边关系的数量会不断增加，我们将关系识别建模为文本匹配任务，输入用户 Query、Query 特征和候选关系，输出关系匹配的分数。为了解决开头提到的多领域问题，我们在输入的特征中加入了领域信息，从而在领域表示中存储一定的领域相关知识，让模型更好地判断。同时，为了提升复杂 Query 的理解，我们在输入中还融入了句法信息，让模型可以更好地理解带约束、多跳的问题。

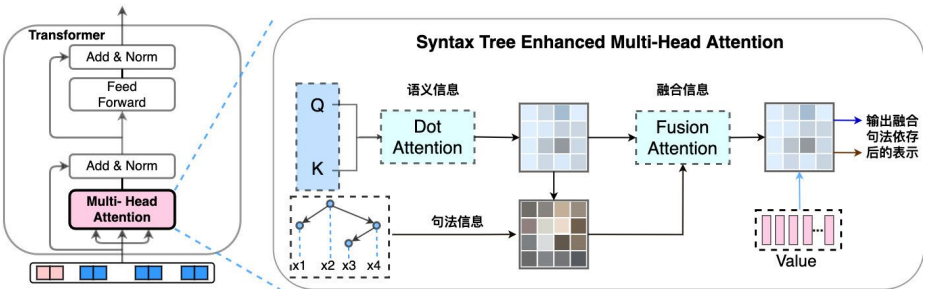

图 7　关系识别模型结构

随着大规模预训练语言模型的出现，BERT 等大模型在匹配任务上取得了 SOTA 的结果，通常业界通用的方法主要归类为以下两种：

- **表示型**：也称“双塔模型”，它的主要思想是将两段文本转换成一个语义向量，然后在向量空间计算两向量的相似度，更侧重对语义向量表示层的构建。
- **交互型**：该方法侧重于学习句子中短语之间的对齐，并学习比较他们之间的对齐关系，最终将对齐整合后的信息聚合到预测层。由于交互型模型可以利用到文本之前的对齐信息，因而精度更高、效果更好，所以在本项目中我们采用交互型模型来解决匹配问题。

为了充分利用 BERT 的语义建模能力，同时考虑实际业务的线上延时要求，我们在推理加速、数据增强、知识增强方面做了以下三点优化：

- **层次剪枝**：BERT 每层都会学到不同的知识，靠近输入侧会学到较为通用的句法知识，而靠近输出则会学习更多任务相关的知识，因此我们参考 DistillBERT，采取 Skip 等间隔式层次剪枝，只保留对任务效果最好的 3 层，比单纯保留前三层的剪枝在 F1-score 上提升了 4%，同时，实验发现不同剪枝方法效果差距可达 7%。
- **领域任务数据预精调**：剪枝后，由于训练数据有限，3 层模型的效果有不小的下降。通过对业务的了解，我们发现美团的“问大家”模块数据与线上数据的一致性很高，并对数据进行清洗，将问题标题和相关问题作为正例，随机选取字面相似度 0.5-0.8 之间的句子作为负例，生成了大量弱监督文本对，预精调

后 3 层模型在准确率上提升超过 4%，甚至超过了 12 层模型的效果。

- **知识增强**：由于用户的表达方式多种多样，准确识别用户的意图，需要深入语意并结合语法信息。为了进一步提升效果，同时解决部分 Case，我们在输入中加入了领域与句法信息，将显式的先验知识融入 BERT，在注意力机制的作用下，同时结合句法依存树结构，准确建模词与词之间的依赖关系，我们在业务数据以及五个大型公开数据集上做验证，对比 BERT Base 模型在准确率上平均提升 1.5%。

经过上述一系列迭代后，模型的速度、准确率都有了大幅的提升。

2.3 复杂问题理解

在真实场景中，大部分问题可以归为以下四类（绿色为答案节点），如下图 8 所示：

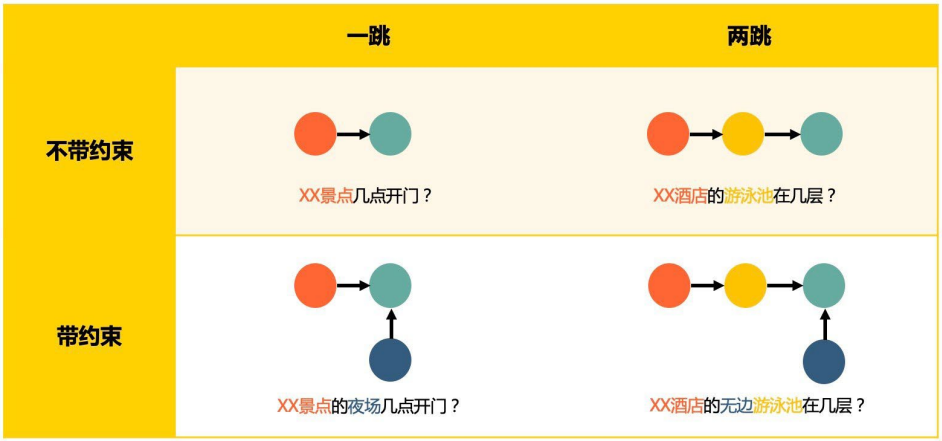

图 8　复杂问题分类

问题的跳数根据实体数量决定，单跳问题通常只涉及商户的基本信息，比如问商户的地址、电话、营业时间、政策等，在知识图谱中都可以通过一组 SPO（三元组）解答；两跳问题主要是针对商户中某些设施、服务的信息提问，比如酒店的健身房在几层、早餐几点开始、以及接送机服务的价格等，需要先找到商户 -> 主实体（设施 / 服务 / 商品等）的路径，再找到主实体的基本信息三元组，也就是 SPX、XPO 两个三元组。约束问题指主实体或答案节点上的约束条件，一般为时间、人群或是定语。

下面介绍针对不同类型的复杂问题，我们所进行的一些改进。

2.3.1 带约束问题

通过对线上日志的挖掘，我们将约束分为以下几类，如下图 9 所示：

图 9　约束问题分类

对于带约束问题的回答涉及两个关键步骤：**约束识别**和**答案排序**。

通过 KBQA 系统中的依存分析模块，我们可以识别出用户在实体或关系信息上所加的约束限制，但约束的说法较多，且不同节点的约束类型也不一样，因此我们在构造数据库查询 SQL 时先保证召回率，尽量召回实体和关系路径下的所有候选节点，并在最终排序模块对答案约束进行打分排序。

为了提升效率，我们首先在知识存储层上进行了优化。在复合属性值的存储方面，Freebase 提出 Compound Value Type (CVT) 类型，如下图 10 所示，来解决这类复合结构化的数据的存储与查询问题。比如欢乐谷的营业时间，对于不同的场次是不一样的。这种复合的属性值可以用 CVT 的形式去承接。

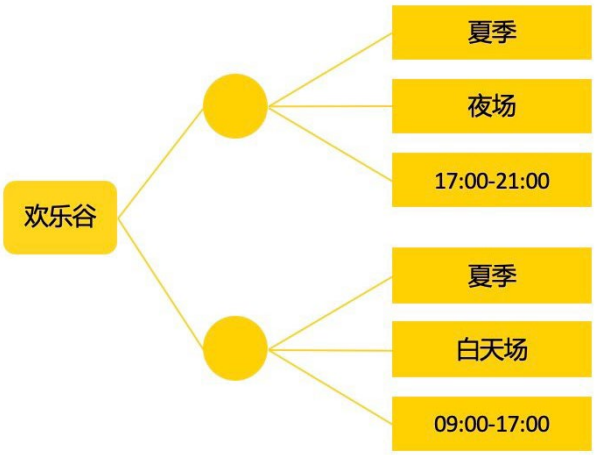

图 10　CVT 类型示例

但是，CVT 存储方式增加查询复杂度、耗费数据库存储。以图“欢乐谷营业时间 CVT”为例：

- 该信息以通常成对 CVT 形式存储，一个 CVT 涉及 3 个三元组存储。
- 对于“欢乐谷夏季夜场几点开始”这样的问题，在查询的时候，涉及四跳，分别为，< 实体 -> 营业时间 CVT>, < 营业时间 CVT -> 季节 = 夏季 >, < 营业时间 CVT -> 时段 = 夜场 >,< 营业时间 CVT -> 时间 >。对业界查询快速的图数据库比如 Nebula 来说，三跳以上的一般查询时间约为几十毫秒，在实际上线使用中耗时较长。
- 一旦属性名称、属性值有不同的但是同意的表达方式，还需要多做一步同义词合并，从而保证查询时能匹配上，没有召回损失。

为了解决上述问题，我们采用 Key-Value 的结构化形式承载属性信息。其中 Key 为答案的约束信息，如人群、时间等可以作为该属性值的约束的信息，都可以放在 Key 中，Value 即为要查的答案。对于上文的例子，我们将所有可能的约束维度的信息组成 Key，如下图 11 所示：

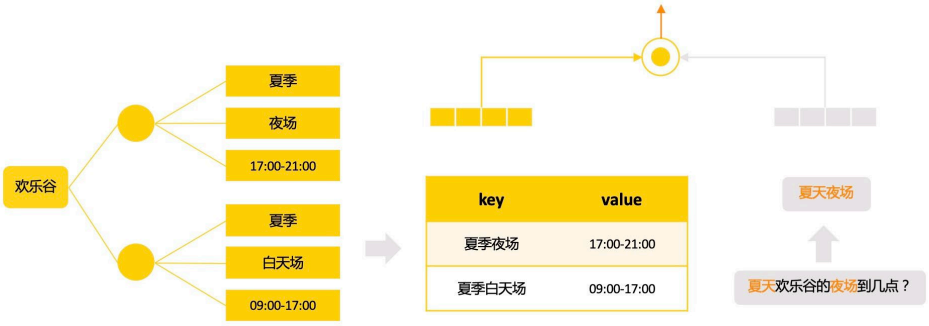

图 11　约束问题解决方案

之后，为了解决约束值说法过多的问题，在实际查询过程中，在找不到完全匹配的情况下，我们用属性值的 Key 和问题中的约束信息进行匹配计算相关度，相关度最高的 Key，对应的 Value 即为答案。因此，Key 的表示方法可以为多种形式：

- **字符串形式**：用文本相似度的方法去计算和约束文本的相关性。
- **文本 Embedding**：如对 Key 的文本形式做 Embedding 形式，与约束信息做相似计算，在训练数据合理的情况下，效果优于字符串形式。
- **其他 Embedding 算法**：如对虚拟节点做 Graph Embedding，约束文本与对应的虚拟节点做联合训练等等。

这种形式的存储方式，相当于只存储一个三元组，即 < 实体 –> 营业时间 KV>，查询过程压缩成了一跳 + 文本匹配排序。基于语义模型的文本匹配可以在一定程度上解决文本表达不同造成的不能完全匹配的问题。对语义模型进行优化后，可以尽量压缩匹配时间，达到十几毫秒。

进行复杂条件优化后，先通过前置模块识别到实体、关系和约束，组成约束文本，再与当前召回子图的 Key 值候选进行匹配，得到最终的答案。

2.3.2 多跳问题

多跳问题是天然适合 KBQA 的一类问题，当用户询问商户中的设施、服务、商品等实体的信息时，我们只需要先在图谱中找到商户，再找到商户下的实体，接着找到下面的基本信息。如果使用 FAQ 问答的解法，就需要为每个复杂问题都设置一个标准

问，比如“健身房的位置”、“游泳馆的位置”等。而在 KBQA 中，我们可以很好地对这类问题进行压缩，不管问什么实体的位置，都问的是“位置”这条边关系，只是起始实体不同。

在 KBQA 系统中，我们先依赖依存分析模块对句子成分间的依赖关系进行识别，之后再通过关系识别模块判断句子所询问的关系跳数以及关系，具体流程如下图 12 所示：

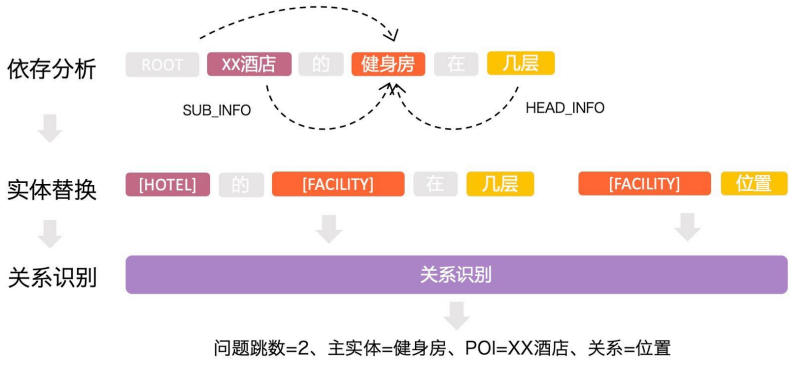

图 12　多跳问题解决方案

借助实体识别的类型，我们可以将句子中的重要成分进行替换，从而压缩候选关系配置的个数、提升关系识别准确率。在对句子进行了充分理解后，系统会基于主实体、关系、跳数对子图进行查询，并输入给答案排序模块进行更细粒度的约束识别和打分。

2.4 观点问答

除了上述基本信息类的查询 Query 外，用户还会询问观点类的问题，比如“迪士尼停车方便吗?”、“XX 酒店隔音好吗?”等。对于主观观点类问题，可以基于 FAQ 或阅读理解技术，从用户评论中找出对应的评论，但这种方法往往只能给出一条或几条评论，可能会太过主观，无法汇总群体的观点。因此我们提出了观点问答方案，给出一个观点的正反支持人数，同时考虑到可解释性，也会给出多数观点的评论证据，在 App 中的实际展示如下图 13 所示：

图 13　观点问答截图

为了自动化地批量挖掘用户观点，我们拆解了两步方案：观点发现和 Evidence 挖掘，如下图 14 所示。

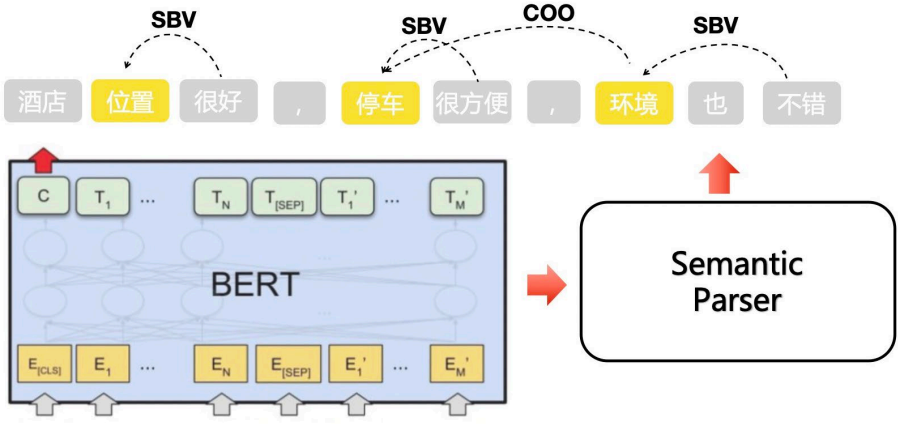

图 14　观点挖掘步骤

第一步，先通过观点发现在用户评论中挖掘出多种观点。我们采用基于序列标注的模型发掘句子中的实体和观点描述，并使用依存分析模型对实体 – 观点的关系进行判断。

第二步，在挖掘到一定数量的观点后，再深入挖掘评论中的证据（Evidence），如下图 15 所示。虽然在第一步观点发现时也能找到部分观点的出处，但还有很多用户评论的观点是隐式的。比如对于“是否可以带宠物”，用户不一定在评论中直接指明，而是说“狗子在这里玩的很开心”。这就需要我们对评论语句进行深度语义理解，从而归纳其中的观点。在方案的落地过程中，最初我们使用了分类模型对观点进行分类，输入用户评论，用编码器对句子进行理解，之后各个观点的分类头判断观点正向程度。但随着自动化挖掘的观点增多，为了减少人工标注分类任务的成本，我们将其转换成了匹配任务，即输入观点标签（Tag）和用户评论，判断评论语句对该观点的支撑程度。最后，为了优化速度，我们对 12 层 Transformer 进行了裁剪，在速度提升 3 倍的情况下效果只降了 0.8%，实现了大批量的观点离线挖掘。

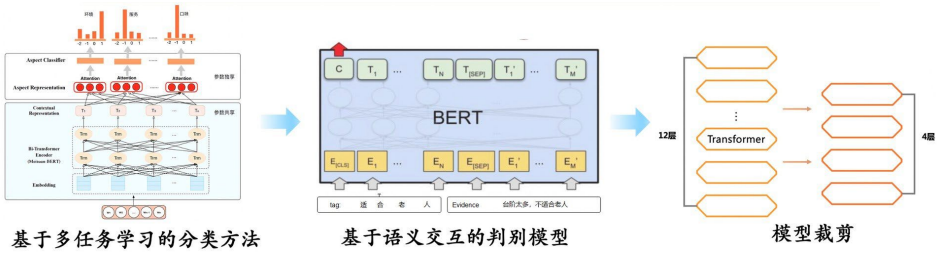

图 15　观点证据挖掘步骤

2.5 端到端方案的探索

在上文中，我们针对多跳、带约束等复杂问题设计了不同的方案，虽然可以在一定程度上解决问题，但系统的复杂度也随之提高。基于关系识别模块的预训练思路，我们对通用的、端到端的解决方案进行了更多的探索，**并在今年的 EMNLP 发表了《Large-Scale Relation Learning for Question Answering over Knowledge Bases with Pre-trained Language Models》论文**。

对于 KBQA，目前学术界有很多研究专注于图学习方法，希望用图学习来更好地表示子图，但却忽略了图谱节点本身的语义。同时，BERT 类的预训练模型是在非结构化文本上训练的，而没接触过图谱的结构化数据。我们期望通过任务相关的数据来消除两者的不一致性，从而提出了三种预训练任务，如下图 16 所示：

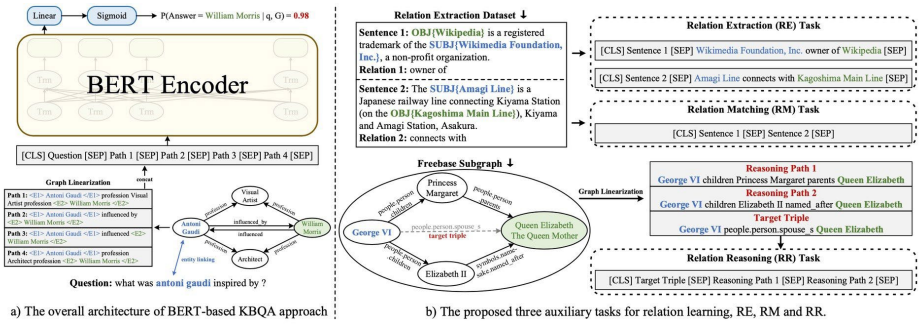

图 16　关系识别预训练任务

- **Relation Extraction**：基于大规模关系抽取开源数据集，生成了大量一跳（[CLS]s[SEP]h, r, t[SEP]）与两跳（[CLS]s1，s2 [SEP]h1，r1，t1 (h2)，r2，t2 [SEP]）的文本对训练数据，让模型学习自然语言与结构化文本间的关系。
- **Relation Matching**：为了让模型更好的捕捉到关系语义，我们基于关系抽取数据生成了大量文本对，拥有相同关系的文本互为正例，否则为负例。
- **Relation Reasoning**：为了让模型具备一定的知识推理能力，我们假设图谱中的 (h, r, t) 缺失，并利用其他间接关系来推理 (h, r, t) 是否成立，输入格式为：[CLS]h, r, t[SEP]p1 [SEP] … pn [SEP]。

经过上述任务预训练后，BERT 模型对于 Query 和结构化文本的推理能力显著提升，并且在非完全 KB 的情况下有更好的表现，如下图 17 所示：

Model	dev set		test set
	Hits@1	F1	Hits@1
Baselines			
KV-Mem†	-	38.6	46.7
GraftNet‡	-	62.4	66.7
PullNet†	-	-	68.1
EmbedKGQA†	-	-	66.6
NSM†	-	67.4	**74.3**
Our implementation			
BERT	71.0	63.4	71.2
$\text{BERT}_{+\text{RE}}$ *pre-train*	68.1	62.1	72.8*
$\text{BERT}_{+\text{RM}}$ *pre-train*	71.8	63.4	72.6*
$\text{BERT}_{+\text{RR}}$ *pre-train*	69.8	61.8	71.7*
$\text{BERT}_{+\text{RE,RM,RR}}$ *pre-train*	69.4	62.5	72.3*
$\text{BERT}_{+\text{RE}}$ *joint*	67.3	57.4	72.4*
$\text{BERT}_{+\text{RM}}$ *joint*	72.2	64.5	**72.9***
$\text{BERT}_{+\text{RR}}$ *joint*	67.3	62.9	71.2
$\text{BERT}_{+\text{RE,RM,RR}}$ *joint*	71.8	60.0	72.0*

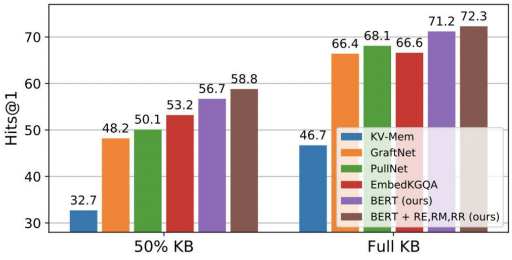

图 17　模型效果

3. 应用实践

经过一年多的建设，当前 KBQA 服务已经接入美团的旅游、酒店、到综等多个业务，辅助商家及时回答用户问题，并提升了用户的满意度和转化率。

3.1 酒店问一问

酒店是用户出行的必备需求之一，但一些中小商家没有开通人工客服入口，无法及时回答用户信息。为满足用户对详情页内信息的快速查找，智能助理辅助未开通客服功能的酒店商家进行自动回复，提升用户下单转化率。用户可询问酒店以及房型页的各类信息，如下图 18 所示：

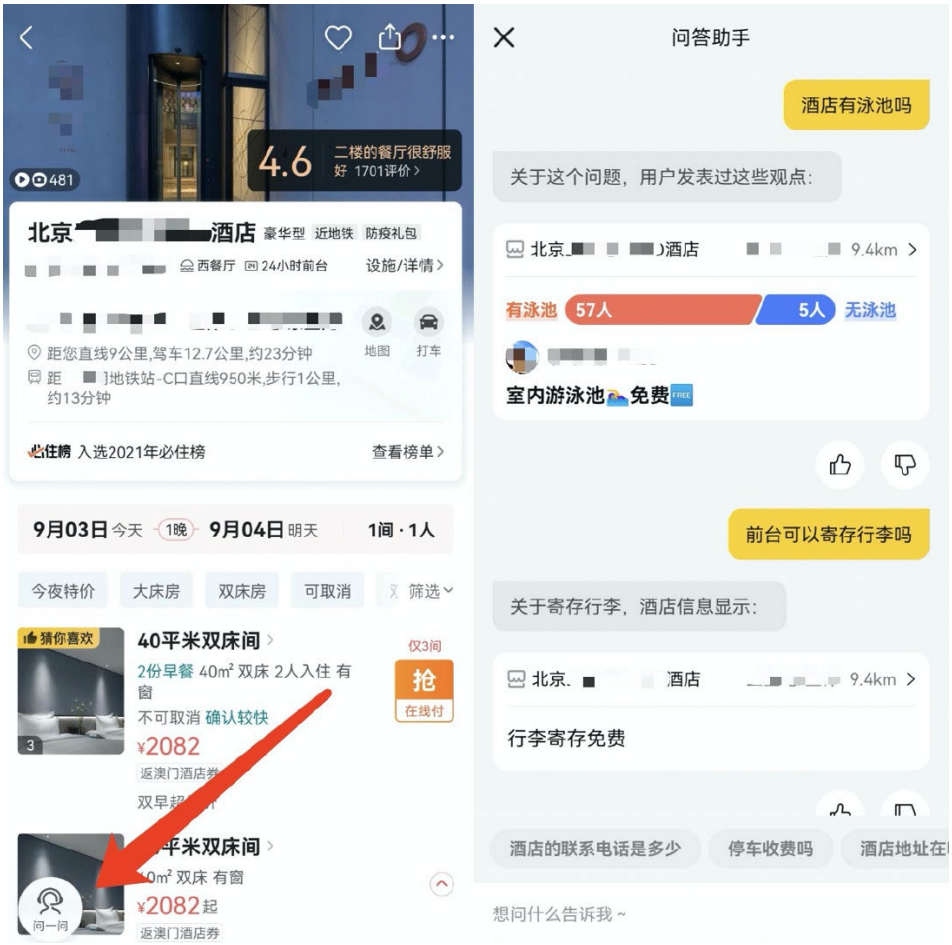

图 18　酒店问一问产品示例

3.2 门票地推

门票地推致力于帮助旅游商家解决主要的卖票业务，在景区高峰时段，线上购票相比于排队更加便捷，然而仍有很多用户保持着线下购票的习惯。美团通过提过二维码以及简单的交互，提升了商户卖票以及用户购票的便捷程度。同时，我们通过在购票页内置「智能购票助手」，解决用户购票过程中的问题，帮用户更快捷地买到合适的门票，如下图 19 所示：

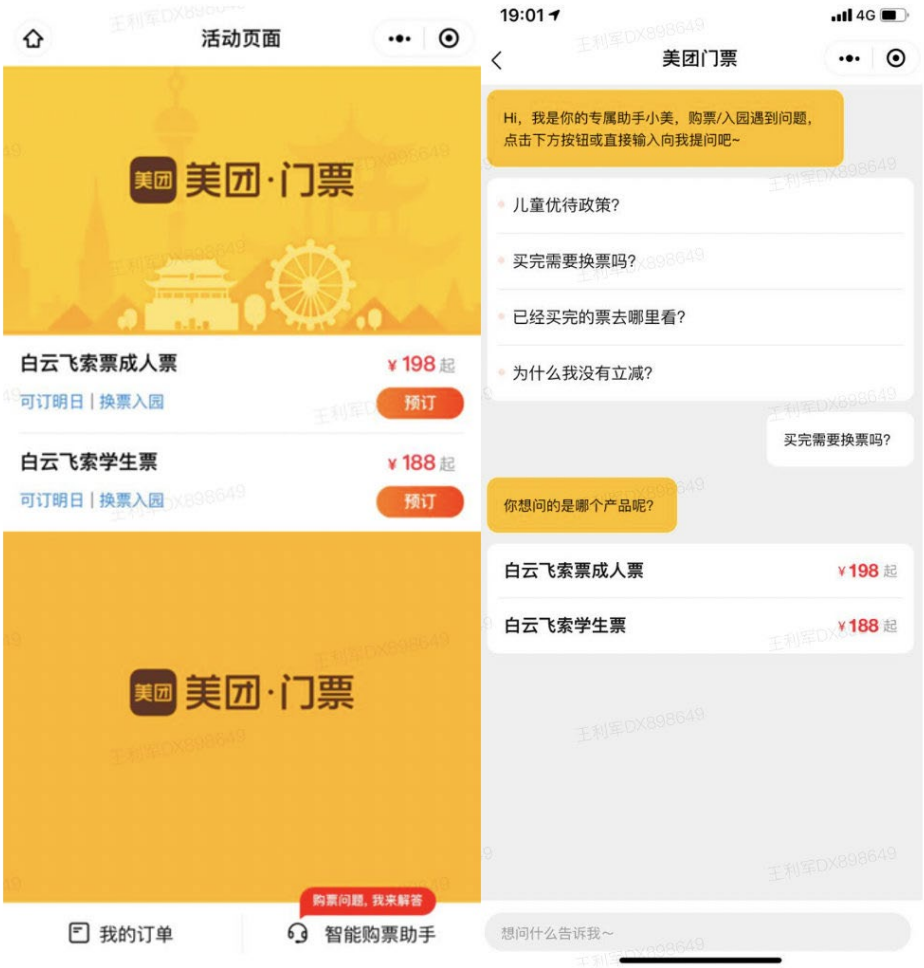

图 19　门票地推产品示例

3.3 商家推荐回复

除了出行场景外，用户在浏览其他本地服务商家时也会有很多问题，比如“理发店是否需要预约?”、“店家最晚几点关门?”，这些都可以通过商家客服进行咨询。但商家本身的人力有限，难免在高峰时期迎接不暇。为了降低用户的等待时间，我们的问答服务会为商家提供话术推荐功能，如下图 20 所示。其中 KBQA 主要负责解答商家、团购相关的信息类问题。

图 20　商家推荐回复产品示例

4 总结与展望

KBQA 不仅是一个热门的研究方向，更是一个复杂的系统，其中涉及到实体识别、句法分析、关系识别等众多算法，不仅要关注整体准确率，更要控制延时，对算法和工程都提出了很大的挑战。经过一年多的技术的探索，我们团队不仅在美团落地多个应用，并在 2020 年获得了 CCKS KBQA 测评的 A 榜第一、B 榜第二和技术创新奖。

同时我们开放出了部分美团数据，与北大合作举办了 2021 年的 CCKS KBQA 测评。

回到技术本身，虽然目前我们的 KBQA 已能解决大部分头部问题，但长尾、复杂问题才是更大的挑战，接下来还有很多前沿技术值得探索，我们希望探索以下方向：

- **无监督领域迁移**：由于 KBQA 覆盖美团酒店、旅游到综等多个业务场景，其中到综包含十多个小领域，我们希望提升模型的 Few-Shot、Zero-Shot 能力，降低标注数据会造成的人力成本。
- **业务知识增强**：关系识别场景下，模型核心词聚焦到不相关的词将对模型带来严重的干扰，我们将研究如何利用先验知识注入预训练语言模型，指导修正 Attention 过程来提升模型表现。
- **更多类型的复杂问题**：除了上述提到的带约束和多跳问题，用户还会问比较类、多关系类问题，未来我们会对图谱构建和 Query 理解模块进行更多优化，解决用户的长尾问题。
- **端到端 KBQA**：不管对工业界还是学术界，KBQA 都是一个复杂的流程，如何利用预训练模型以及其本身的知识，简化整体流程、甚至端到端方案，是我们要持续探索的方向。

也欢迎对 KBQA 感兴趣的同学加入我们团队，一起探索 KBQA 的更多可能性！简历投递地址：wangsirui@meituan.com。

作者简介

如寐、梁迪、思睿、鸿志、明洋、武威，均来自搜索与 NLP 部 NLP 中心知识图谱组。

本地生活综合性需求图谱的构建及应用

作者：李翔

一、背景

1.1 业务现状

以“帮大家吃得更好，生活更好”为使命，美团覆盖了外卖、餐饮、酒店、民宿、旅游、门票、电影 / 演出、休闲 / 玩乐、丽人、医疗、亲子、教育、结婚、生活服务等数百个行业，满足数以亿计用户的多样化生活服务需求。为了持续增加平台价值，除了推动用户和商户在数量和质量上的不断提升之外，更高效地匹配用户需求和商户供给也是重要抓手之一。

为了提升匹配的效率，我们需要更充分、深入地理解用户需求和商户供给，并且尝试从用户视角出发来组织和管理供给。当前，“行业 – 类目 – 商户 – 商品”是一种较为常见的供给组织和管理方式，然而随着业务和行业的快速发展，这种组织方式带来的痛点日渐突显，举例来说：

- 部分指向性不明确的用户需求，较难得到适合的匹配结果。例如“周末陪宝宝去哪儿玩?”由于平台的匹配结果不理想，用户往往只能在线下完成类目决策，决定带宝宝去农家乐烧烤，再到平台上搜索相应的农家乐团购。
- 部分需求跨多个类目，匹配过程不够流畅。例如“周末和朋友去哪里放松一下?”用户在线下完成类目决策后，可选类目包括 KTV、酒吧、密室、桌游等，但各类目的承载页面相互独立，用户需要在承载页面间来回切换。
- 在部分指向明确的类目中，用户仍然难以找到满足自己需求的供给。例如在医美类目下，因为缺乏相关知识，用户往往并不了解商户提供的形形色色的服务项目分别具有什么功效，适合什么部位，应该使用什么材料，无法高效地找到适合自己的服务供给。

上述问题的本质原因在于供给的组织方式主要是从行业视角出发，没有充分考虑到用户视角。在当前以满足用户需求为首要目标的市场环境下，我们需要迭代完善现有的供给组织方式。

1.2 问题解析

为了解决上述问题，我们尝试从一个外部视角，结合第一性原理去进行剖析。在整个人类社会中，按照马斯洛需求层次[1]的理论，人的需求是可以被归纳及分层的。如果将人类社会看作一个系统，人类在其中一个称为“市场”的子系统中，通过交易来满足自己的需求。

人类从需求层次出发，在市场中完成交易，最终需求得以满足，那么在市场中交易的过程可以被拆解为“起心动念 -> 考虑 -> 选择评估 -> 交易购买 -> 履约 / 服务”。并且，经由前三个阶段，用户的需求逐渐从粗粒度演变为细粒度，从抽象过渡到具象。下面将结合具体的例子来进行解读：

- **需求层次**：在马斯洛需求层次中有一个情感层次，对应了人类丰富多样的情感需求，包含亲情、友情、爱情等等。作为一个母亲，与自己的宝宝之间往往存在一种强烈的母子情，并且希望不断去强化这种情感。
- **起心动念**：为此，母亲往往都会尽力花较多的时间去陪伴宝宝。通过增加陪伴方式的维度，变为“陪宝宝玩”；通过增加时间、空间等维度，变为“周末陪宝宝去哪儿玩?”
- **考虑**：对于上述问题，母亲会找出很多种方案，比如户外烧烤、农家采摘、主题公园等等。当她决定选用户外烧烤这一方案时，便会转化为具体的商品需求，如购买烤架。
- **评估选择**：母亲于是在可触达的供给范围中进行选择。正如人们常说的货比三家，选择的依据会各不相同，如价格、质量、口碑等等。
- **交易购买**：当完成选择之后，母亲便会进行交易，以换取商品或服务。
- **履约服务**：即商品到货、完成服务等等。

市场是人类社会的一个子系统，电商平台则是市场中的一个子系统。同时，电商平台是一种线上化的子系统，它提供了搜索、推荐等形式的供给检索能力。当前的一个现状是：用户往往在线下完成了“起心动念”到“考虑”的过程，转化为具体的商品 / 服务需求，随后进入电商平台完成“选择评估”到“履约服务”的后续过程（如下图 1 所示）。而电商平台往往聚焦于后三个阶段的能力提升，容易忽略前两个阶段。

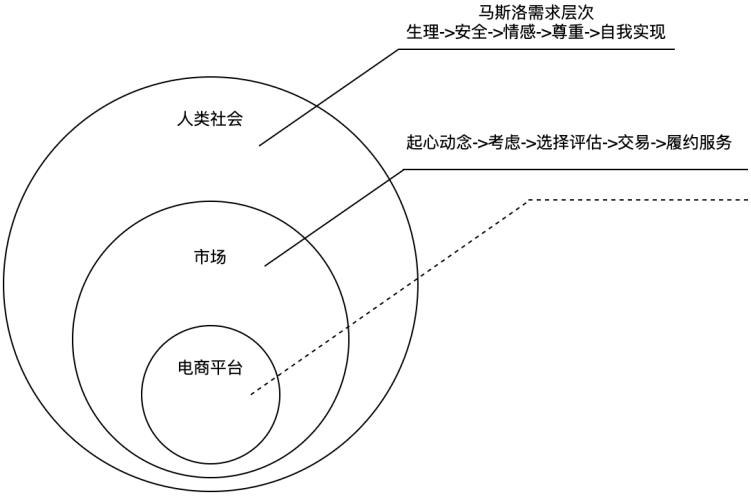

图 1

因此，用户较难形成在平台上完成“起心动念”和“考虑”的心智，而大部分电商平台按“行业 – 类目 – 商户 – 商品”的方式对供给进行组织和管理。最终，用户和电商平台之间形成了一种相互掣肘的关系。

事实上，相对于“烤架”这种明确的商品需求，用户还有很多抽象的、模糊的、不明确的需求，依然停留在前两个阶段。例如，周末陪宝宝去哪儿玩？周末和朋友去哪里放松一下？结婚前怎样才能让自己变得更美？暑假如何培养孩子的动手能力？同时，这样的需求往往跨越多个类目，或者在同类目下存在多种选择。

电商平台只有打破既有的掣肘关系，向用户提供前两个阶段（起心动念、考虑）的能力，才能进一步满足用户的需求。用户的决策成本进一步降低，决策过程更加连贯，

用户体验也能得到相应的提升，同时用户在市场中的交易过程也能够进一步实现线上化。

以“行业 – 类目 – 商户 – 商品”作为参考，**如果电商平台能够识别出用户在前两个阶段的需求，并且在其和供给之间建立新的关联关系，辅以搜索、推荐等检索能力，用户便有可能在线上完成前两个阶段**。而知识图谱作为一种揭示实体之间关系的语义网络，用以解决上述问题显得尤为合适。

二、解决方案

2.1 解决思路

延续 1.2 中的例子，这位母亲将“周末陪宝宝去哪儿玩?”的需求转化为具体的“户外烧烤”需求，延伸至更为具体的“烤架”和“农家乐团购”需求。此时，母亲便会分别前往各类实物电商平台以及以美团为代表的生活服务电商平台进行“选择评估”。两种电商平台分别在实物供给池或服务供给池中采用搜索、推荐之类的召排技术定位到具体的商品 / 服务，并反馈给这位母亲。

对于 1.2 中的所述，技术团队期望达成的目的，目前比较有代表性的参考案例是阿里巴巴电商认知图谱 AliCoCo[2]。它基本构建思路是从用户视角出发，先进行各种类型的原子词挖掘，再进一步对原子词进行组合和挖掘出相关候选短语，再从中识别出真实的用户需求，最后关联至相应的供给。它的层次结构如图 2 所示：

- **分类层**：构建完备的分类体系，包含了的大千世界的各种分类，既有通用的空间、时间等类别，也有电商中涉及的颜色、功能以及最为重要的品类等类别。
- **原子概念层**：在分类层诸多类别的基础上进行扩展，包含了各种类别下的原子概念（例如空间 –> 户外、事件 –> 烧烤、时间 –> 圣诞节、颜色 –> 红色、功能 –> 保暖、品类 –> 连衣裙）及原子概念之间的关系。
- **电商概念层**：在原子概念层之上，包含了由原子概念组成或直接挖掘的短语粒度的用户购物需求，即电商概念（例如户外烧烤），从而将用户购物需求显式地用一个符合自然语言的短语表示。

- **商品层**：包含了商品与各种原子概念、电商概念之间的关联关系（例如户外烧烤 –> 烤架、黄油、锡纸）。

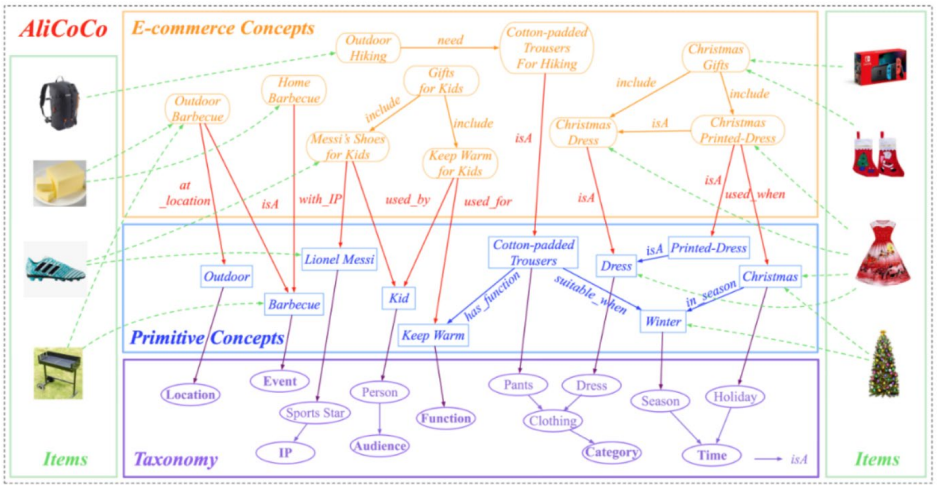

图 2

基于上述图谱，这位母亲可以直接在天猫上表达“户外烧烤”的需求，而非更具体的“烤架”；天猫也会将烤架以外其他和户外烧烤相关的重要商品反馈给这位母亲。从对应关系来看，AliCoCo 的电商概念层对应至“考虑”阶段，商品层对应至“选择评估”阶段。显然，由于 AliCoCo 的存在，天猫能够从“考虑”阶段开始介入用户的交易过程。

由此推论，我们应该可以将图谱构建得更为完整，以覆盖“起心动念”阶段。在此阶段，人类的需求，按马斯洛需求层次，通过增加一个或多个维度约束，而被逐渐具象化。对于这样的维度约束，我们统称为“场景约束”。因此，我们将“考虑”阶段对应的需求称为“具象需求”；将“起心动念”阶段对应的需求称为“场景需求”。为此，我们希望构建一个**本地生活综合性需求图谱**（**GENE**：lifestyle **GE**neral **NE**eds net），如下图 3 所示。对于本地生活场景下所涉及的数百个综合性行业，我们认为新的供给组织方式更能贴近用户需求，也是从用户视角去解决供需匹配的问题。

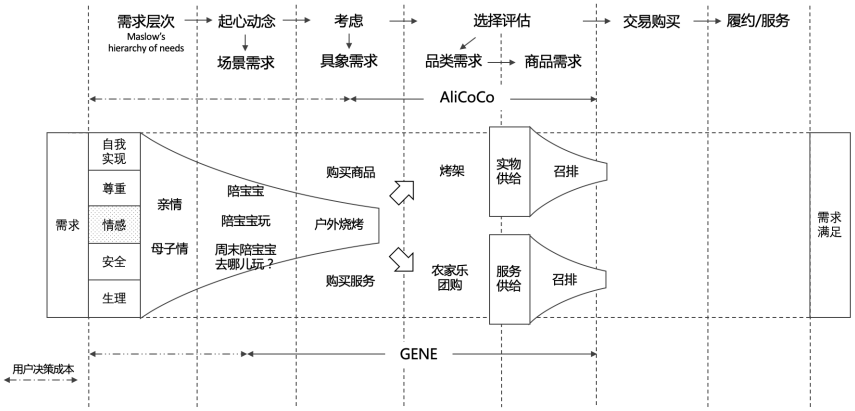

图 3

2.2 具体方案

延续 2.1 中的构建思路，我们尝试构建一套多层次的图谱结构，并将“具象需求”和“场景需求”拆分为独立的层次，既避免了两种类型的需求合在同一层级中而引起混淆，又能对用户场景化的需求进行更详尽的拆解、更丰富的刻画。本地生活综合性需求图谱（GENE），主要由六部分构成，包含场景需求层、场景要素层、具象需求层、需求对象层、行业体系层和供给层，如下图 4 所示：

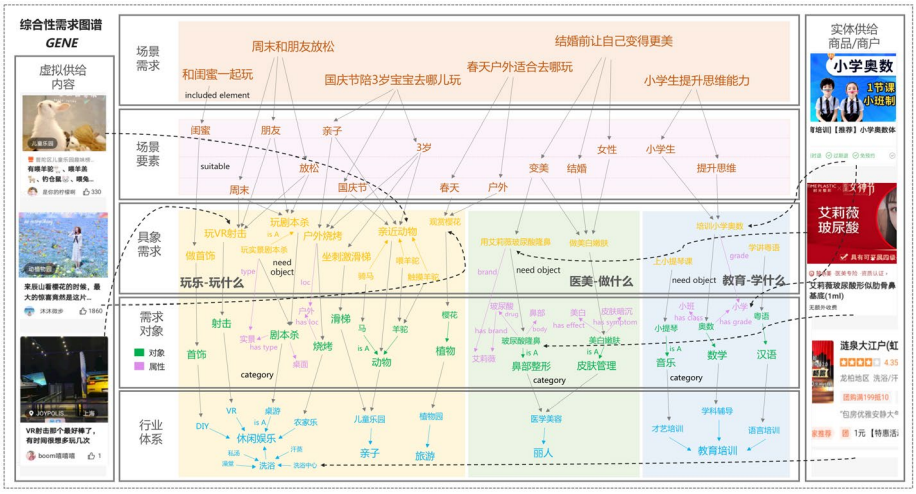

图 4

在场景需求层，我们用 Human-Readable 的短句来表征场景化的用户需求，如“国庆节陪 3 岁宝宝去哪玩”、“结婚前让自己变得更美”、“小学生提升思维能力”等。一个场景需求的表述中，通常会包含人物、目的、时间、空间、方式等要素，以“国庆节陪 3 岁宝宝去哪玩”为例，“3 岁宝宝”是人物，“陪宝宝玩”是目的，“国庆节”是时间。

在场景要素层，为了更好地表达场景需求，我们将这些短句进行拆解，细化成多个细粒度的词汇，用这些词汇对场景需求中的人物、目的、时间、空间、方式等要素进行完整的覆盖和系统的组织，我们将其称为“场景要素”。

在具象需求层，由于场景需求的表述往往并不显式地指向某个具体的服务 / 供给，而是隐含了一批潜在的适合这一场景的服务 / 供给。例如，在“国庆节陪 3 岁宝宝去哪玩”这个例子中，户外烧烤、喂羊驼、玩滑梯、骑小马等都是适合这一场景需求的具体服务。所以我们需要将所有这些具体的服务通过短语的形式显式的展现出来，这些短语直接反应了用户具体的服务需求，被称之为“具象需求”。

在需求对象层，为了进一步的理解具象需求，我们将具象需求分为具体的服务需求所对应的对象，我们称之为“需求对象”，以及该服务中用户和对象之间的交互行为。例如，对于具象需求喂羊驼，可以分为羊驼（需求对象）和喂（服务交互），由于本地生活服务的多样性，围绕羊驼这一需求对象，除了喂羊驼外，还可以产生触摸羊驼、骑羊驼和看羊驼表演等多种具象需求。这一层除了包含需求对象节点外，也会涵盖需求对象的属性信息，以对需求对象进行更详尽地描述。例如对于具象需求户外烧烤，可分为烧烤（需求对象）、户外（需求对象属性）和体验（隐含的服务交互）。

在行业体系层，由于用户的场景需求和具象需求往往会跨越多个传统的服务类目，为了给用户需求确定一个具体的业务范围，我们还需要构建出各行业涉及的类目体系，作为上述各层构建的业务基础。

在供给层，包含内容这类虚拟供给和商户与商品这类实体供给，这些供给将会和具象需求和场景需求等节点进行关联，从而为用户需求提供相对应的供给支撑。例如，一个提供户外烧烤的供给将会关联上具象需求“户外烧烤”，并进一步关联上场景需求

“国庆节陪 3 岁宝宝去哪玩”。

综上所述，在本地生活综合性需求图谱中，用户场景化的需求和具体的服务需求被分别表达成短句级别的场景需求和短语级别的具象需求。这两种需求分别通过场景要素和需求对象进行表达。最后，不同类型的供给都会和场景需求和具象需求相关联，从而以用户需求为纽带，提升供给和用户的匹配效率。

三、实现方法

当前，本地生活综合性需求图谱已经初步涵盖了用户在玩乐、医美和教育三个本地生活相关行业中的多元化需求。我们在图谱的构建过程中，自底向上按照行业体系层、需求对象层、具象需求层、场景要素层、场景需求层的顺序逐层进行构建，并将各层的节点与各种类型的供给建立关联关系。下文将以玩乐行业为例，对图谱每一层的构建细节以及涉及的算法进行介绍。

3.1 行业体系层

3.1.1 行业类目树的构建

在玩乐行业中，行业体系层包含了能够提供玩乐服务的类目，类目信息通过一个树形结构来表征。由于玩乐行业体系的构建，对专家知识的要求非常高，并且这部分的设计对后续各层的知识挖掘至关重要，因此我们没有直接进行人工定义，而是以当前我们成熟的行业类目树为基础，通过对其进行剪枝和分裂来构建。

首先在类目树中筛选出和玩乐相关的一级类目节点，包括“休闲娱乐”、“亲子”、“旅游”、“餐饮”等。对于每个一级类目，我们进一步筛选其和玩乐相关的下一级类目直至叶子类目，并剪去与玩乐无关的类目。此外，我们还对剪枝后的类目树中可以细分的玩乐相关的叶子类目进行分裂，例如将“洗浴”细分为“私汤”、“洗浴中心”等，最终得到完整的玩乐行业类目树。

3.1.2 类目的供给关联

确定了类目树后，我们还需要获取实体供给（商户和商品）和虚拟供给（内容，例如

UGC）与类目的从属关系，从而为后续的一系列挖掘提供数据支持。由于商品和内容均可链接到商户，所以我们只需要获取商户与类目的从属关系即可。玩乐类目树是对我们已有的类目进行剪枝和分裂得到的，除了分裂出的新类目外，其余类目和商户的关系均可直接继承原有的结果。对于新分裂的类目，我们则需要重新构建商户和其之间的从属关系。

要判断一个商户属于哪个类目，最直观的依据就是商户名、商品名及商品详情，然而很多商户的商户名和商品包含的信息往往较少，增加了类目判别的难度。为了确保商户类目判别的准确性，我们引入更多的商户信息，包括商户 UGC 和商户画像，设计了一个多源异构数据融合判别模型，整体模型结构如下图 5 所示：

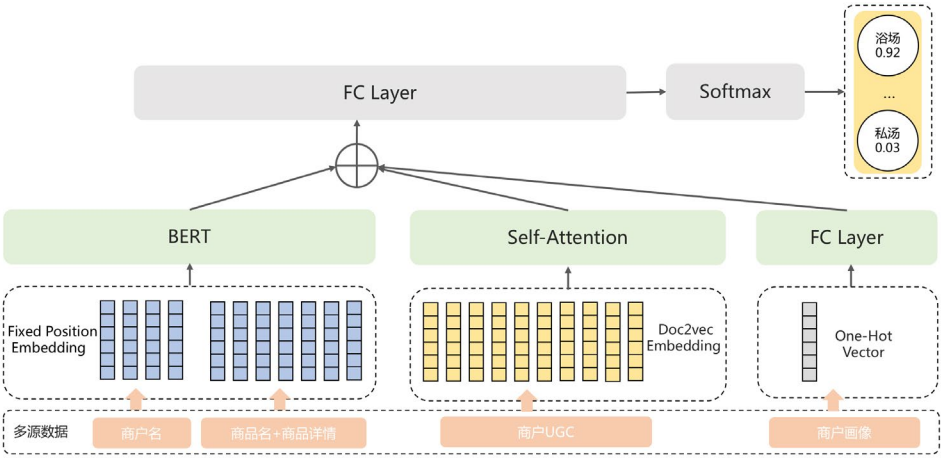

图 5

其中，不同来源数据的特征提取和处理方式如下：

- 商户名、商品名及商品详情：均为文本数据，直接通过 BERT[3] 提取文本特征后输出。
- 商户 UGC：由于商户的 UGC 往往数量非常多，为了对其信息进行有效利用，首先通过 Doc2Vec[4] 的方式进行 Encode 得到 UGC 的特征后，再通过一个 Self-Attention[5] 模块进行特征处理后输出。
- 商户画像：转成 One-Hot 特征后，通过全连接层进行非线性映射后输出。

上述三种特征相连接后进行融合，通过全连接层和 softmax 层实现最终的类目判别。基于多源数据的融合建模，商户信息得到了充分利用。以洗浴细分类目为例，仅利用商户名、商品名及商品详情数据，基于 BERT 判别，准确率为 92%，而基于多源融合模型判别后，准确率提升到 98%。

3.2 需求对象层

在需求对象层，我们希望能够挖掘出玩乐行业体系中各类目涉及的玩乐对象词作为该层的节点，这些词能够描述出用户在实际玩乐过程中的交互对象，这是用于组成具象玩乐需求的基础。为了确保玩乐对象挖掘的全面性，我们采用多源多方法的形式。

在数据上，我们采用来自商户和用户的相关文本作为挖掘语料。在方法上，我们采用两种方式来挖掘玩乐对象词：

- 第一种是无监督的扩充，在开始挖掘前运营会首先根据经验，提供一些玩乐对象词作为种子输入，我们提前利用语料构建无监督的 Skip-Gram 结构的 Word2Vec 模型，对业务输入的种子词提取词向量，并结合余弦相似度，快速扩充相关的对象词。
- 第二种是有监督的标注，我们将其定义序列标注问题，采用基于 BERT+CRF 的模型，在语料中自动识别出新的对象词。

在实践过程中，为了更高效的挖掘，我们将无监督环节扩充和质检后的对象词在语料中进行文本匹配，并将匹配结果转化为有监督标注环节的训练样本；同时对于有监督标注的结果，经过运营质检后，也会将其作为无监督扩充的输入，通过两个环节相结合，我们完成玩乐对象的挖掘，完整流程如下图 6 所示。此外，在运营人工审核玩乐对象词的过程中，对于一些业务已知的核心玩乐对象，也会直接输入业务侧已经沉淀的相关特征作为其属性，进一步完善玩乐对象的信息，例如对于“剧本杀”这一玩乐对象，增加相应的“实景”和“桌面”等类型属性。

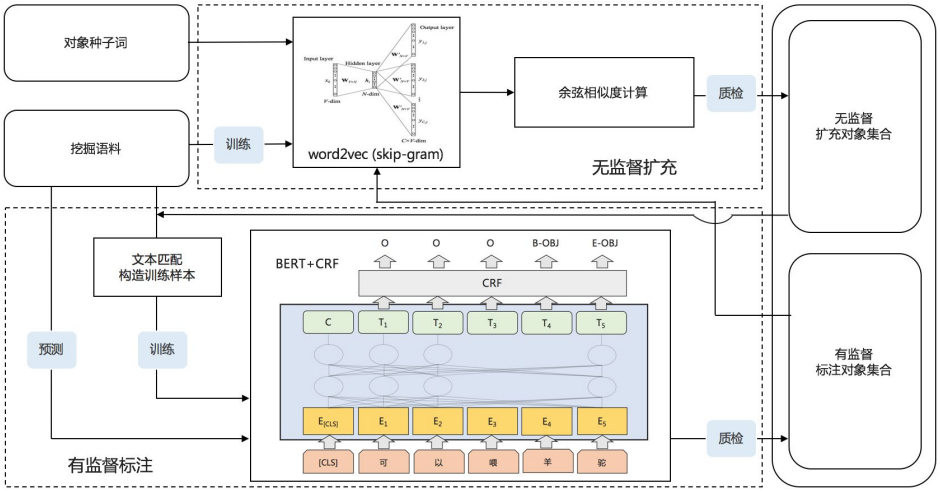

图 6

在获取对象词后，我们还需要知道对象词属于哪个类目，以便下一步的具象需求挖掘及供给关联，为此我们构建对象词和类目之间的关系。通过各类目下的语料文本中提及对象词的次数来衡量两者关系，是最直观且准确率最高的方法。因此，我们直接使用对象词在每个类目下的语料中进行文本匹配，通过词频高低来确定关系。同时，我们进一步构建对象词之间的上下位和同义关系，当前常见的有通过投影和分类（如 BERT 句间关系模型）等方法来进行关系判别等有监督方法。在实际过程中，我们采用规则辅助人工的方式，基于对象词的统计特征及 Pattern 共现的结果指导人工快速完成构建。

3.3 具象需求层

3.3.1 具象需求挖掘

具象需求层可以看成是用户在玩乐行业中的具体服务需求的集合，每个具象玩乐需求是该层的一个节点，由玩乐对象叠加用户与对象之间的多元化的交互行为及对象描述信息得到，它通过短语的形式表达出用户对于玩乐服务供给的本质诉求。具体玩乐需求挖掘的流程流程可以分为两个步骤：

- **候选短语生成**：围绕玩乐对象词，生成大量包含玩乐对象的短语，作为具象玩

乐需求候选集。

- **短语质量判别**：建立一个语义判别模型从候选集中提取真实的具象玩乐需求。

候选短语生成

在步骤 1 中，首先我们以需求对象词为核心，采用与玩乐对象挖掘相同的语料，进行候选短语的生成。常用的短语挖掘算法如 AutoPhrase[6]，是以 Ngram 来进行短语组合，而这种形式对于有需求对象的短语显得过于冗余，所以我们考虑基于句法结构来进行短语挖掘。

为了使生成短语符合句法的要求，我们以预设的句法关系为模板进行挖掘。在大规模语料中为了更高效地挖掘句法关系，我们基于更轻便的 ELECTRA[7] 预训练模型获取句子各成分的 Embedding 后，再利用 BiAffine[8] 预测其句法关系。通过依存句法分析，我们在各个类目的语料中挖掘出包含相应的玩乐对象且符合句法关系的短语。此外，需求对象层中对象的属性也会被用作对象描述进行短语生成。最终所有挖掘的短语，经过词频等统计特征粗筛后将作为具象玩乐需求的候选集，挖掘示例如图 7(a) 所示。

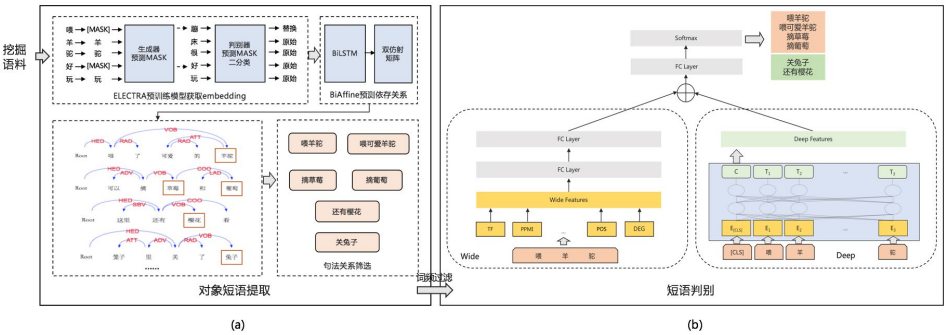

图 7

短语质量判别

在步骤 2 中，经过步骤 1 获取的候选集短语虽然符合预设的句法关系，但是从语义上仍然存在大量与用户实际需求不符的表述，通过抽检分析我们发现符合要求的短语不足 10%。如何从海量的候选短语中挑选出反映真实的用户具象玩乐需求的短语成为

亟需解决的问题。

AutoPhrase 通过基于短语统计特征的判别模型进行短语打分，然而仅通过统计特征难以识别语义质量低的短语，为此我们进一步基于统计和语义特征联合建模，构建一个 Wide&Deep[9] 结构的判别模型，对候选集合中的短语是否为具象玩乐需求进行判别，我们希望判别模型能过滤掉大量的低质短语，从而为运营节省大量的人力成本。判别模型的整体结构如图 7(b) 所示，其中：

- Wide 部分，提取候选短语的全局和上下文的统计特征，通过全连接层进行非线性映射后输出。
- Deep 部分，提取候选短语的深度语义特征，通过 BERT 完成相应特征的提取后输出。

上述 Wide 和 Deep 部分输出的特征相连接后进行融合，优势互补，经过全连接层和 softmax 层来实现最终的短语判别。在实践过程中，除了直接使用已经积累的短语标签作为正样本外，我们还通过预设一些常识性的 Pattern 从候选集中构造正样本，例如观赏 [植物]、触摸 [动物]，并对候选集采样构造负样本，完成初版模型的训练，之后结合主动学习，经过多轮迭代，模型最终达到 92% 的召回率和 85% 的准确率。通过质量判别后保留的短语则会交由运营人工审核提炼后成为最终的具象玩乐需求。

3.3.2 具象需求的供给关联

在具象需求层中，由于具象玩乐需求是由玩乐对象得到的，所以两者之间天然地建立了对应关系。而对于具象玩乐需求之间的上下位和同义关系，则可以基于其对象之间的关系及其句法关系，在人工审核的环节来辅助人工完成构建。除此之外，更重要的是需要将具象玩乐需求与实体供给（商户和商品）及虚拟供给（内容，例如 UGC）进行关联。

我们将这个问题抽象为一个语义匹配的问题，通过具象玩乐需求与其对应的类目的供给的文本信息进行匹配来实现，其中，商户使用商户名文本信息，商品使用商品名和商品详情文本信息，UGC 使用其自身文本信息。由于 UGC 和商品属于商户的一部

分，所以具象玩乐需求与 UGC/ 商品的关系也会加入其与商户关系的构建中。整体匹配流程如下图 8 所示，我们首先进行具象玩乐需求与 UGC/ 商品的匹配，在此基础上再结合商户名文本的匹配结果，一起通过规则聚合后关联到商户。

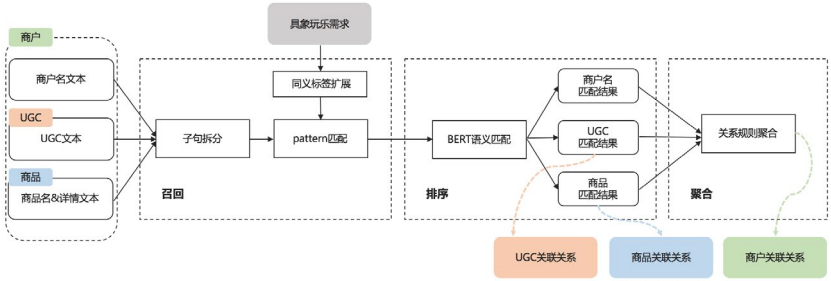

图 8

由于具象玩乐需求数量众多，同时供给的文本信息通常包含多个子句，出于效率和效果的平衡考虑，我们将匹配过程分为了召回和排序两个阶段。

在召回阶段，我们粗筛出和具象玩乐需求可能有潜在关联的子句。对于具象玩乐需求，我们基于构建的同义关系，扩展具象需求的同义标签，并将其与子句文本进行粗粒度 Pattern 匹配，对于匹配中的子句则将进入到排序阶段进行精细化的关联关系计算。

在排序阶段，我们构建基于 BERT 句间关系分类的语义匹配模型，通过在 BERT 后增加全连接层和 softmax 层来实现分类。模型通过对召回阶段得到的粗筛样本进行预测，识别两者在语义上的匹配关系（关联 / 不关联）。最终供给关联关系的平均召回率和准确率分别达到 90% 和 95%。

3.4 场景要素层

3.4.1 场景要素拆解

场景要素层包含了组成用户场景化需求的场景要素。如文初提及，要描述一个场景，需要交代特定的人物、时间、空间、目的等要素。例如，对于“国庆节陪 3 岁宝宝去哪儿玩?”这个场景化需求，我们可做如下拆解：时间 – 国庆节，人物 –3 岁宝宝，目的 – 亲情陪伴（陪宝宝玩）。所以我们按照上述方式，对场景要素进行拆解，以期对场

景要素的挖掘和梳理尽可能的全面与系统。

3.4.2 场景要素挖掘

完成了场景要素拆解后，下一步就是要分别在每个拆解的类别中进行场景要素的挖掘。场景要素作为具象需求的场景化的信息，往往来自于用户的直观感受，所以挖掘的语料我们选择与具象玩乐需求关联的 UGC 的上下文语料。与需求对象挖掘的方法类似，我们将每个类别的已提炼总结的场景要素作为种子词，通过相关要素扩充和序列标注的方式完成场景要素的挖掘。

确定场景要素后，接下来的关键是完成场景要素与具象玩乐需求的关系构建，即对于每个场景要素，找出其适合的具象玩乐需求，如春季适合观赏樱花、孩子适合亲近动物。我们通过对 UGC 文本分析后发现，UGC 中用户说到某一具象玩乐需求的同时，往往也会交代一些相关的场景要素信息，所以我们继续选择与具象玩乐需求关联的 UGC 的上下文语料，作为关系构建的数据来源。

最初我们采用基于 Pattern 的方法，通过归纳可用于判断场景要素和具象玩乐需求关系的 Pattern，从语料中直接抽取包含两者的文本。但由于用户表达的多样性，不仅准确率无法保证，同时有限的 Pattern 也影响了召回，因此我们进一步尝试使用基于模型判别的方法提升泛化性，完善关系的构建。

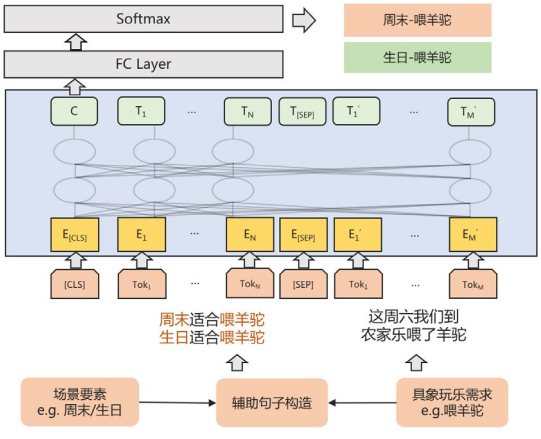

图 9

由于我们使用的语料中的具象玩乐需求是已知的，如果将场景要素看成是具象玩乐需求的属性，那么问题就可以看成是一个属性级（Aspect-Based）的分类问题。参考属性级情感分类的做法 [10]，我们通过预设句子模板的方式，结合场景要素和具象玩乐需求构造出辅助句子，将属性级分类转换为一个类 QA 的句对分类问题。例如，对于已经关联了“喂羊驼”这一具象玩乐需求的某个语料：“这个周六我们到农家乐喂了羊驼”，其中一个辅助句子为“周末适合喂羊驼”。

我们采用 BERT 句间关系分类模型来实现句对分类，如图 9 所示。辅助句子与语料文本通过 [SEP] 相连后输入模型进行判别，模型输出判别结果（适合 / 不适合）。最后我们根据在所有语料上的关系提取结果，对每个场景要素和具象需求之间的关系进行投票计算评分后来确定两者的关系。

3.5 场景需求层

3.5.1 场景需求组装

在场景需求层，我们会将场景要素层和具象需求层的信息进行组装，从而生成大量的场景需求。组装出的场景需求，既可能仅含场景要素，如“国庆节陪 3 岁宝宝去哪儿玩?”不含任何具象需求，又可以同时包含场景要素和具象需求，如“周末去郊外摘草莓”中，周末、郊外是场景要素，摘草莓是具象需求。

3.5.2 场景需求判别

对于组装得到的场景需求，最重要的是保证其合理性，例如“周末”和“亲子”就是合理的玩乐场景，而“闺蜜”和“亲子”则是矛盾的玩乐场景。为此，我们首先需要计算场景要素之间的关系评分，从而指导场景需求的组装。场景要素只有依托具象需求，搭配上适合的玩法，参与组装的场景需求才有意义。因此，对于场景要素之间的合理关系构建，我们尝试以场景要素和具象需求的关系得分作为依据，通过关系传递评估两个场景要素之间的相关性。

在 3.4.2 节中，我们已经量化了场景要素和具象需求之间的关系评分，一个最直观的想法是通过场景要素 – 具象需求 – 场景要素的关系传递来进行计算场景要素之间关系

的计算。如图 10(a) 所示，以具象需求“喂羊驼”为纽带，可以获取“亲子”和“闺蜜”两个场景要素的关系得分。

我们首先构建场景要素和具象需求的关系评分矩阵，考虑到玩法数量满足长尾分布的情况，对矩阵进行具象需求维度的列归一化处理，同时为了保证场景要素 – 场景要素矩阵的自相关系数为 1，对归一化后的场景要素 – 具象需求矩阵进行 L2 行范数归一化处理，因此该归一化矩阵与自身转置的矩阵乘得到的新矩阵即可作为场景要素 – 场景要素的关系评分矩阵。

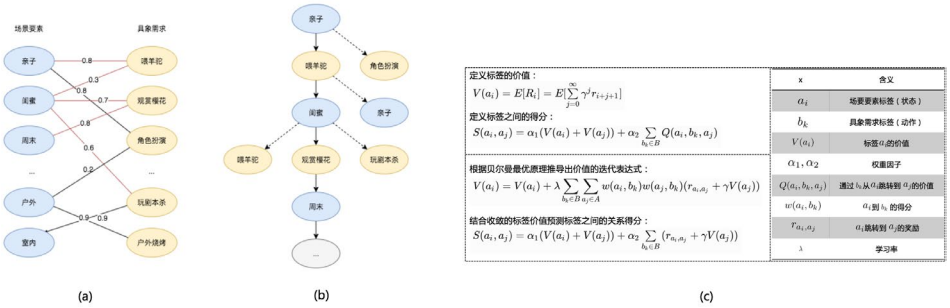

图 10

通过上述方法可以很快得到场景要素之间的关系评分，然而该方法仅以场景要素 – 具象需求 – 场景要素的关系传递模式，计算场景要素在具象需求上的直接共指强弱，导致场景要素关系的覆盖不足。为此，我们扩展为更长的节点关系链传递模式，这种节点之间的传递关系是服从马尔可夫性质的，如图 10(b) 所示。但是随着传递路径的增长，计算成本会呈指数级增长。所以我们采用强化学习 [11] 中的 One-Step 时序差分方法进行求解，以“累计回报的期望最大化”的概念作为节点的价值，以场景要素节点集合作为强化学习概念中的状态空间，具象需求节点集合作为动作空间。

例如当我们处在“亲子”场景要素这个状态下，可以通过选择“喂羊驼”或者“角色扮演”来跳转到下一个状态“闺蜜”或“户外”。该状态跳转过程的决策函数，根据当前场景要素状态关联的所有具象需求中随机抽取一个具象需求节点作为决策行为，抽取概率与得分正相关；状态转移概率则为在该具象需求节点决策下，随机跳转到与

之相关联的场景要素，跳转概率与得分正相关。

同时，对于特定的互斥关系，我们根据实际的业务应用需求制定奖励矩阵实现多样化的场景要素关系评分模型。这样我们将节点关系传递模型转化为了马尔可夫决策模型，结合贝尔曼最优原理推导出的价值迭代表达式和节点对关系得分预测公式，如图 10© 所示。根据图示的公式，在保持策略不变的前提下采用自举迭代的思想计算节点的价值，并进一步计算场景要素之间的关系评分，既能够保证更充分的利用已有的关系网络信息，提高关系覆盖，又能通过奖励矩阵的约束关系降低互斥关系的影响，灵活适应不同业务的需求。

最后基于场景要素之间的关系评分，我们从组装的场景需求集合中选择评分高的场景需求，并根据预设的模板生成最终的场景需求表达，例如“周末和朋友放松”、“和闺蜜一起玩”、“国庆节带孩子户外烧烤好去处”。这些场景需求通过其包含的场景要素 / 具象玩乐需求，可以链接到相应的具象玩乐需求，进而关联相关的供给，从而给用户提供场景化玩乐的解决方案。

四、应用实践

本地生活综合性需求图谱，涵盖了用户的场景需求和具象需求，一方面更前置地参与用户决策，在“起心动念”、“考虑”、“选择评估”等多个阶段影响用户，降低其决策成本，另一方面，提供更多样化的供给选择，高效地进行供需匹配。应用方式上，应用于搜索、推荐等各类业务形态。

经过近一年的建设，当前综合性需求图谱包含数十万核心具象需求和场景需求节点，以及数千万的关系，并在美团的亲子、休闲娱乐、医美、教育培训等多个业务进行了初步的应用实践，下面举例介绍具体的应用方式和应用效果。

4.1 亲子

亲子原频道页用户需求和供给之间匹配效率低下，其中 ICON 按照亲子传统类目划分，无法满足用户不同类型的需求（图 11(a) 左），而底部猜喜的供给形态单一，且体

现用户需求的优质供给不足，决策信息不足（图 11(b) 左），因此对亲子频道页进行改版。为了贴合亲子的业务特色，我们将亲子玩乐相关的需求节点和关系，应用于频道改版后的多个流量位，为其提供标签和供给数据的支撑。

图 11

其中，对于 ICON，基于高频的场景和具象需求，跨类目生成需求 ICON，如“亲近动物”、“带娃泡汤”等（图 11(a) 中）及相应二级页（图 11(a) 右），这些 ICON 包含了原本多个类目中的相似需求，在用户“考虑”阶段为其提供决策信息。

对于底部推荐，我们围绕亲子玩乐的具象需求进行供给优化，将其关联的内容作为优质供给进行推荐，并为每个供给提取包含相应具象需求的文本，作为推荐理由外露，这些句子从用户实际需求的角度展示信息，极大地吸引了用户（图 11(b) 右）。此外，还进一步根据浏览和交易行为，以供给为媒介建立具象需求与用户的关联关系，应用于个性化推荐的召回和排序的优化。改版后的亲子频道页，满足了用户多样化的推荐需求，极大地改善了用户体验。

4.2 休闲娱乐

在休闲娱乐频道页，我们围绕场景需求和具象需求进行了一系列应用。一方面，基于玩乐的场景需求组织新的场景 ICON，如满足用户户外游玩的“踏青赏花”、满足用户在室内潮流玩乐的“室内潮玩”、满足喜欢晚上玩乐用户的“夜生活”、满足和朋友

同事聚会玩乐的“团建聚会”，这些 ICON 从用户场景化的玩乐出发，打破了传统类目的限制，让用户和供给的匹配更加流畅，每个 ICON 的二级页面则会展示每个场景的具象玩法需求及关联的商户和内容。

另一方面，在频道页场景导航模块中，尝试利用场景需求来进一步展示场景化的玩乐信息，包括“一人乐”、“家庭暖”、“过生日”等十多个玩乐场景主题，并针对这些场景的具象需求关联的商户进行推荐。这些场景化的应用（图 12(a)），在“起心动念”阶段即作用于用户，提升了用户的决策效率。

图 12

此外，部分具象需求经过改写可以直接用于相应类目的列表页商户的快筛，例如实景剧本杀 / 桌面剧本杀，换装 / 汉服体验 / 撸宠必去 / 飞行模拟等（图 12(b) 左和中），而我们在行业体系层中类目的细分结果，亦可以成为商户的快筛，例如洗浴类目的细分（图 12(b) 右），这些快筛的应用，更加方便了用户选店。

五、总结展望

在本地生活服务中，如何不断提高供给和用户之间的匹配效率，是摆在我们面前的一道难题。我们尝试以用户关注对象为切入点，通过深挖用户需求并以其为纽带来关联供给和用户。为了全方位挖掘和理解用户需求，我们努力探索并尝试构建本地生活综合性需求图谱，以行业体系层、需求对象层、具象需求层、场景要素层、场景需求层的顺序逐层构建，并为各种类型的供给建立关联关系。

目前，综合性需求图谱的结果可应用于搜索、推荐等各类业务形态，并已在美团多个业务场景中取得实践成果。不过，我们还处在探索的初级阶段，接下来还有很长的迭代之路要走，在此我们提出一些后续的思考和展望：

- **更广的行业覆盖**：一方面加深对已有的玩乐、医美和教育行业的建设，挖掘更多的节点和关系，更好的理解用户需求；一方面向丽人、结婚等更多的行业进行横向覆盖；此外还将进一步扩展到用户决策的全链路，构建服务体验图谱，覆盖履约服务环节，分析其中的用户需求和反馈，更好地赋能商家提升用户体验。
- **更多的数据引入**：当前图谱的构建主要是以平台的用户和商户的文本语料为主，下一步将利用图像等更多模态的数据，并尝试引入外部的知识，对当前的节点和关系进行完善和补充。
- **更深的图谱应用**：现阶段图谱在搜索和推荐上的实践主要集中在标签及其关联供给的直接应用，后续考虑进一步深化图谱的应用，充分利用场景需求和场景要素的信息，为推荐侧更准的用户意图识别提供支撑，从而提升供给和用户的匹配效率，发挥出知识图谱更大的价值。

参考文献

[1] Maslow A H. A theory of human motivation[J]. Psychological review, 1943, 50(4): 370.

[2] Luo X, Liu L, Yang Y, et al. AliCoCo: Alibaba e-commerce cognitive concept net[C]. Proceedings of the 2020 ACM SIGMOD International Conference on Management of Data. 2020: 313-327.

[3] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.

[4] Le Q, Mikolov T. Distributed representations of sentences and documents[C]. International conference on machine learning. PMLR, 2014: 1188-1196.

[5] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. arXiv preprint arXiv:1706.03762, 2017.

[6] Shang J, Liu J, Jiang M, et al. Automated phrase mining from massive text corpora[J]. IEEE Transactions on Knowledge and Data Engineering, 2018, 30(10): 1825-1837.

[7] Clark K, Luong M T, Le Q V, et al. Electra: Pre-training text encoders as discriminators rather than generators[J]. arXiv preprint arXiv:2003.10555, 2020.

[8] Dozat T, Manning C D. Deep biaffine attention for neural dependency parsing[J].

arXiv preprint arXiv:1611.01734, 2016.
[9] Cheng H T, Koc L, Harmsen J, et al. Wide & deep learning for recommender systems[C]. Proceedings of the 1st workshop on deep learning for recommender systems. 2016: 7-10.
[10] Sun C, Huang L, Qiu X. Utilizing BERT for aspect-based sentiment analysis via constructing auxiliary sentence[J]. arXiv preprint arXiv:1903.09588, 2019.
[11] Sutton R S, Barto A G. Reinforcement learning: An introduction[J]. 2011.

作者简介

李翔、陈焕、志伟、晓阳、艳婷、旭乐、曹臻等，均来自美团到店平台技术部到综业务数据团队。

招聘信息

美团到店平台技术部 – 到综业务数据团队，长期招聘算法（自然语言处理 / 推荐算法）、数据仓库、数据科学、系统开发等岗位同学，坐标上海。欢迎感兴趣的同学发送简历至：licong.yu@meituan.com。

外卖商品的标准化建设与应用

作者：刘柳　懋地　崇锦　晓星

1. 背景及目标

商品作为外卖交易过程中的核心要素，决定了供需匹配的精准度，直接影响交易行为是否可以达成。外卖平台美食、甜点、饮品类在线商品有亿级之多，其中很多是属性信息一致的相同商品。建立对商品的标准化描述、聚合相同商品，是很多业务场景的诉求。

- **供销分析场景**：想分析一下望京的商家都售卖哪些菜品，有多少商家卖“西红柿炒鸡蛋”？
- **遇到的问题**：由于菜品是非标品，并且商家对菜品命名的个性化程度也较高，因此在外卖平台，同一个菜品名出现不同的命名方式；例如“西红柿炒鸡蛋”有西红柿炒蛋、小番茄炒蛋、西红柿鸡蛋、京城三绝 ~ 番茄炒蛋【正价小份菜】等，没有办法简单通过关键字进行聚合。
- **主题推荐场景**：想出一个菜品粒度的主题，快速筛选“小龙虾”、“烤鱼”、“鸡公煲”、“黄焖鸡”等热门菜品?
- **遇到的问题**：商品分类的颗粒度不够精细，无法快速找到适合颗粒度的菜品。
- **商家上单场景**：像“鱼香肉丝”这样普遍的菜品，每个商家上单都需要录入食材、口味、做法、菜系、荤素等标签，录入成本较高，能不能像淘宝一样，选择“iPhone 12”，它的属性就能够自动关联。
- **遇到的问题**：没有将菜品的属性标准化，菜品和属性之间没有关联关系。

基于上述业务应用的痛点，启动外卖商品的标准化建设。目标是建立商品的标准化名称，实现对相同商品的聚合，从而为业务提供合理粒度的概念划分，赋能运营端供销分析、用户端个性化召回排序、商家端标签生产。

2. 业界调研

对于业界的参考，主要参考淘宝标准化 SPU 建设。SPU 在淘宝体系中决定了商品是什么，是商品信息聚合的最小单位，由关键属性 + 绑定属性来构成。

- **关键属性**：用来约束和定义一个商品的，比如 iPhone X，决定他的就是“苹果”这个品牌和“X”这个系列。
- **绑定属性**：是关键属性的补充和细化，比如当 iPhone X 已经明确了这个产品后，其他的属性也确定，比如网络模型，屏幕尺寸等，进一步补充这些属性内容，逐步明确了一个产品。

可见淘宝对于 SPU 的建设，实际上是对属性的建设，例如格力空调 S1240，通过“格力”品牌、“空调”类目、“S1240”型号来标准化、唯一化。

但对于餐饮行业，对于核心属性食材“牛肉”、做法“炒”、口味“辣”，都无法确定是什么菜，更谈不上唯一化；但如果通过“小炒黄牛肉”来标准化，行业 / 用户对其有普遍的认知，较固定的食材口味做法，适合用来进行标准化。因此淘宝是标准化属性，而餐饮是标准化菜品名称，所以我们称之为标准菜品名。

3. 问题分析及挑战

淘宝的标准化主要针对标品，而餐饮标准化都是针对非标品，难度较大，面临着个性化问题、录入不规范、粒度无行业标准、认知局限性等挑战。

3.1 个性化问题

餐饮商家可以较低成本的自定义生产，个性化程度较高，同一个菜品在不同商家的命名可能不同，需要大量的同义词聚合，而同义词的召回是最大的难点（如何将潜在的同义词挖掘出来进行标注）。例如，京城三绝 – 番茄炒蛋【正价小份菜】、西红柿炒蛋（小份）、小番茄炒蛋、西红柿炒土鸡蛋（小份），都表示“西红柿炒蛋”这个商品。

3.2 录入不规范

商家在录入商品名称时，存在缺失关键信息的问题，例如“缤纷水果”是水果拼盘、

饮品还是披萨，“韭菜鸡蛋”是包子还是饺子。除商品名称外，需要借助商家分类，商品左侧栏 tag 等相关信息，对名称进行推理和补全。

3.3 粒度无行业标准

在进行标准化处理时，没有统一的标准，粒度难以把控：过粗容易产生非菜品错误（例如：“香辣鸡腿”–>“鸡腿”），过细则标准名内聚性偏弱（例如：“传统黄焖鸡【大碗】”本身粒度过细，需要提炼到“黄焖鸡”）。

3.4 认知局限性

中华美食文化博大精深，对于一些不为大众所熟知的小众或者地方特色菜品，需要具有一定的专业背景知识，例如“炒鸡”也是一个标准的名称，还并非商家没有填写完整。

4. 方案

商品标准化的整体方案如图所示：首先，基于美食、甜点饮品类商家全量在线的亿级商品，通过名称清洗、置信度判别、人工检验，获得近菜名主干；通过同义词挖掘，对主干名进一步聚合压缩，映射到标准名主词上；对于单个商品，进行名称纠错、清洗，通过模型匹配，建立商品 – 标准名的映射；为了满足不同业务场景的聚合粒度要求，通过上下级关系挖掘、深度遍历，进一步构建标准名层级树。分别对名称聚合、匹配映射、层级构建三个模块，涉及的算法模型进行介绍。

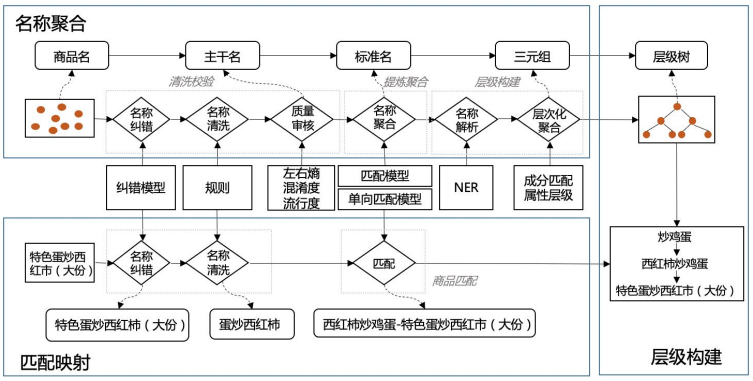

图 1　商品名标准化整体方案

4.1 名称聚合

清洗后的主干名仍然存在很多同义说法，比如土豆烧牛肉、牛肉烧土豆、洋芋烧牛肉、小土豆烧牛肉，表示相同的商品。目标通过挖掘这种潜在的同义关系，进一步提升名称的内聚性。在迭代过程中，先后采用了规则匹配和语义匹配的方法，挖掘潜在同义词；聚合后，根据流行度判别其中的主词，并将原始主干词映射至标准名主词上。分别对两种同义词挖掘方法介绍如下。

4.1.1 规则匹配

一期首先采用了规则匹配的方法，利用 NER 模型对主干名进行成份识别，结合知识图谱构建的属性同义词表，判别两个主干名是否是同义关系。

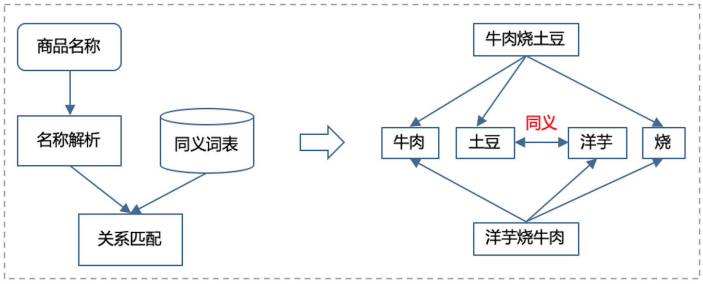

图 2　规则匹配

如图所示，其中“牛肉烧土豆”通过名称解析得到牛肉 – 食材，烧 – 做法，土豆 – 食材；“洋芋烧牛肉”通过名称解析得到洋芋 – 食材，烧 – 做法，牛肉 – 食材。对比两个主干名的成份词，其中土豆和洋芋是一对同义词，其余成份相同，进而获得二者之间是同义关系。

通过这种方式，挖掘了十万级同义词。根据标准名覆盖的商品供给数计算流行度值，将更流行度高的作为主词；人工校验后补充到标准名体系，提升了名称的聚合度。

4.1.2 语意匹配

由于规则匹配挖掘到的同义词有限，比如“担担面”和“担担汤面”，根据 NER 模型，担担面和汤面都会被识别成类目。如此，两个主干名是无法建立同义关系的。

我们二期调研了一些匹配模型，借鉴搜索算法组的经验，采用 BERT+DSSM 的语义匹配模型进行同义关系的扩覆盖。如图所示，首先基于一期积累的同义词，通过组内生成正例、跨组交叉生成负例的方式，构造百万级样本，训练了一版基础模型；为了进一步优化模型性能，通过主动学习和数据增强两种方式，对样本数据进行了迭代。

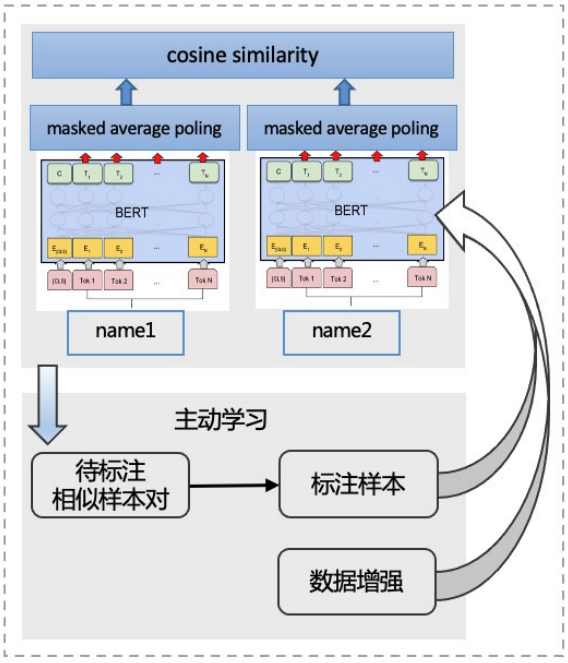

图 3　语义匹配

主动学习的方式是先利用基础模型，圈定一批待标注的相似样本，交与外包标注，将标注正确的样本补充至已有同义词中，标注错误的样本作为负例加入训练集，用于模型的优化迭代。通过主动学习的方式，补充了万级样本，模型准确率取得了明显提升。

进一步分析结果，我们发现了一批很有特点的 Bad Case，比如红烧狮子头和红烧狮子头盖饭、香椿拌豆腐和拌豆腐等，它们都属于字面相似度很高，但核心成份不同的匹配错误。基于这个特点，先根据字面距离圈定了一批字面相似度高的样本，再利用名称解析模型对它们进行成份识别，找出其中的负例。通过这种方式，在不增加标注成本的情况下，自动补充了十万级样本，进一步提升了模型准确率。

利用语义匹配模型，新增了十万级同义词，进一步提升了标准名的内聚性。

4.2 匹配映射

在挖掘到的标准名词表和同义词基础上，为亿级在线商品建立“商品 – 标准名”映射（如“招牌蛋炒小番茄（大份）”映射到“西红柿炒鸡蛋”），以实现对相同商品的标准化描述与聚合。采用“文本 + 图像”相结合的匹配模型，覆盖了绝大部分的美食、甜点饮品类商家的在线商品。

4.2.1 文本匹配

文本匹配流程如图 4 所示，整体上包括召回、排序两个阶段。首先，对商品名称中的规格、分量等描述信息进行清洗，将清洗后的商品名和标准名进行 2–Gram 切片，通过关联相同切片的方式召回待匹配的标准名；基于召回的标准名，通过计算 Jaccard 距离，保留其中 Top 20 的标准名；在此基础上，利用 BERT 向量化模型，生成商品名和标准名的向量表示，通过计算 Jaccard 字面距离以及 Cosine 向量相似度，获取其中综合得分最高的标准名。

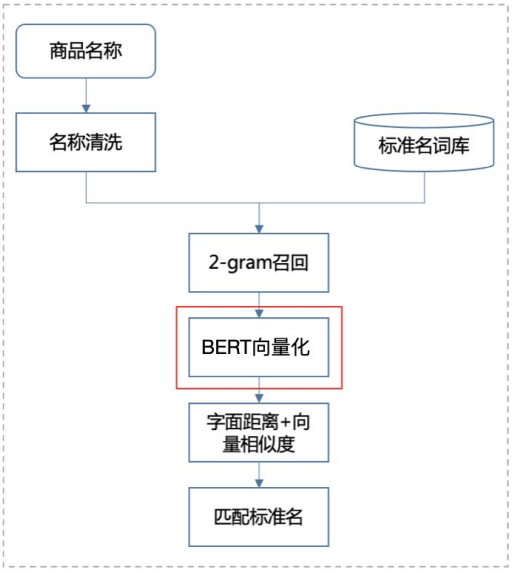

图 4　文本匹配流程

其中，BERT 向量化模型是基于上文提到的同义语义匹配模型，通过级联一维类型编码的方式，对标准名和商品名加以区分，改造成非对称的标准名匹配模型。之所以进行这一改造，是因为与同义匹配不同，标准名匹配是非对称的，如应该将“香锅盔”匹配上相对抽象的标准名“锅盔”，而不是匹配上一个更加具体的标准名“五香锅盔”。改造后，匹配准确率提升显著。

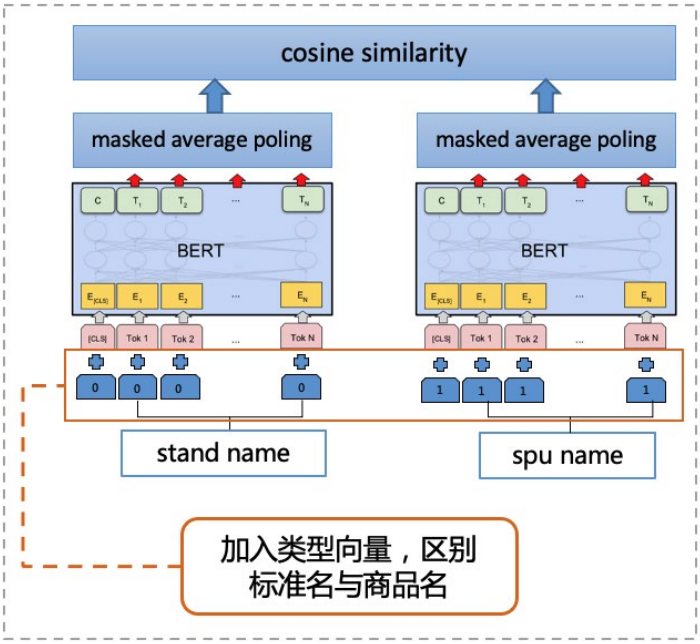

图 5　BERT 向量化模型

4.2.2 图像匹配

由于菜品名称长度有限及商家命名不规范，会导致仅从菜品名称中获取的信息有限，而无法建立到标准名的匹配。通过引入商品图片信息，提升对文本信息不全商品的匹配准确和覆盖。

图像匹配采用的是多分类模型，根据标准名层级聚合（详见 3 层级构建）后的顶级、二级，选择待匹配的标准名标签，并根据文本匹配结果构造样本集。由于采用大规模非人工标注样本，不可避免地要解决样本噪声问题。在本场景下，噪声主要有两个主

要来源：一是文本信息不全，导致样本标签错误；二是由于顶级、二级聚合程度高，导致分类粒度过粗，需要细分多个标签。针对这些问题，采用样本和模型迭代优化的方式，根据基础样本集训练初版模型，利用模型挖掘噪声数据，人工校验后进行模型微调。如此迭代，实现低标注成本的模型优化。

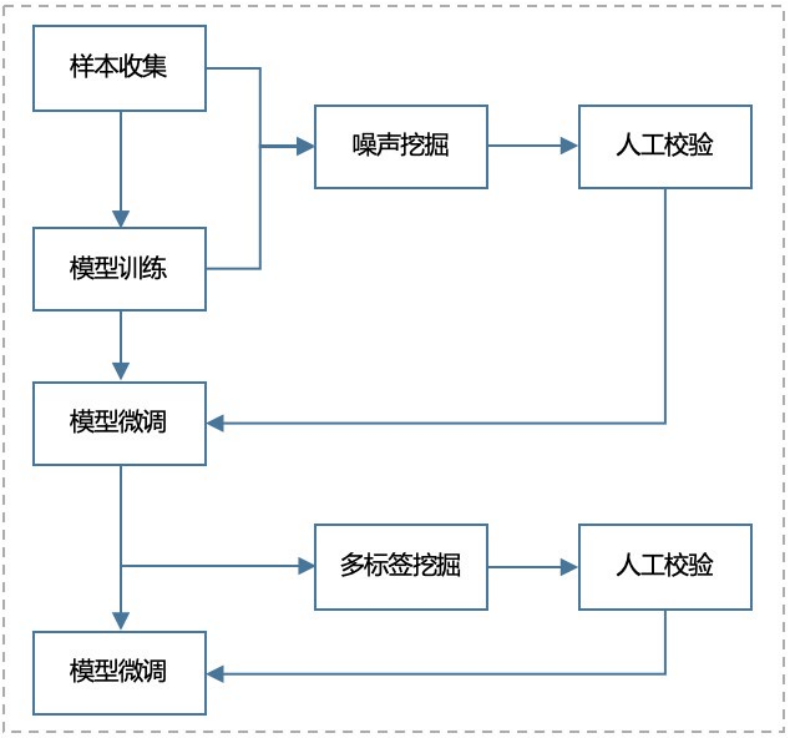

图 6　图像模型迭代流程

图像分类模型选取了对 MBConv 模块的参数进行精细化调整的 Basebone 网络 Efficientnet，通过调整网络的分辨率、深度、宽度，确定最优组合。噪声挖掘方法首先通过 Metric-Learn 的方法，学习获得每个类别的聚类中心，及类内样本与聚类中心距离的均值、方差、中位数，对其进行排序挖掘出类内离散度较大的类别；再借助分类模型在验证集上的预测、O2U-Net 和 Forgetting Event 挖掘样本噪声。通过上述方法优化模型，提升对噪声样本的鲁棒性。

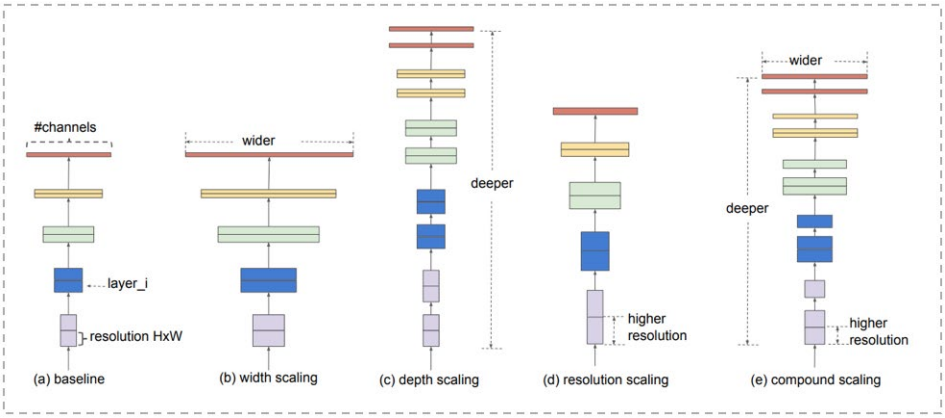

图 7　Efficientnet 网络宽度、深度、输入分辨率的变化组合

4.3 层级构建

推荐场景下，为了保证用户的个性化和多样性体验，需要对商品进行合理粒度的聚合。对于商品列表排序场景，现有的类目过粗会导致多样性不足，标准名过细又会导致结果重复。目标是建立一个层级化商品体系，为业务提供合理的聚合粒度。通过关系挖掘、层级遍历，构造万级顶点的层级树，支持了商品列表、美食排行榜、交互式推荐等业务的上线和优化。构建方法包括规则匹配和模型判别，分别对这两类方法进行介绍。

4.3.1 规则匹配

规则匹配方法是基于已有的 NER 模型和属性词表，通过结构化匹配的方法，挖掘到十万级上下级关系，进一步遍历生成万级顶点的标准名层级树。这种方法比较简单且基于已有工作，开发周期短，在项目初期快速支持上线，并取得了明显的业务收益。

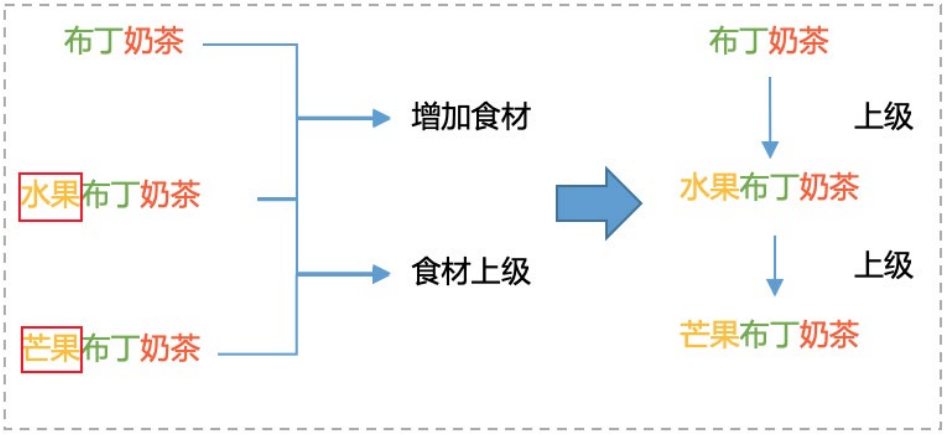

图 8　规则判别

4.3.2 模型判别

规则匹配方法由于 NER 模型错误和属性词关系缺少，导致挖掘到的关系有限，需要通过判别模型进一步提升泛化性。基于 BERT 的关系分类模型如图 8 所示，对待分类一对标准名用 [SEP] 进行拼接，并在开头增加 [CLS] 标识符；将拼接结果编码后，传入 BERT 模型，取出 [CLS] 位的 Embedding；再接一个全联接层和 Softmax 层，输出关系分类结果。标准名关系包括：同义、上级、下级、无关系，一共四个类别。

样本数据包括简单例和难例两部分，其中：简单例基于已有同义词、上下级，以及同义词组间交叉生成无关系，一共构造百万级样本；在此基础上，进一步利用已有的向量化模型，召回相似度较高的标准名对，交与外包标注其类别。第二类样本更加贴近实际分类场景，且属于混淆度较高的分类难例。

利用第一类样本预训练初版模型，并在此基础上，利用第二类样本对模型进行微调，进一步提升了分类模型准确率。经人工校验，进一步补充了万级词关系。

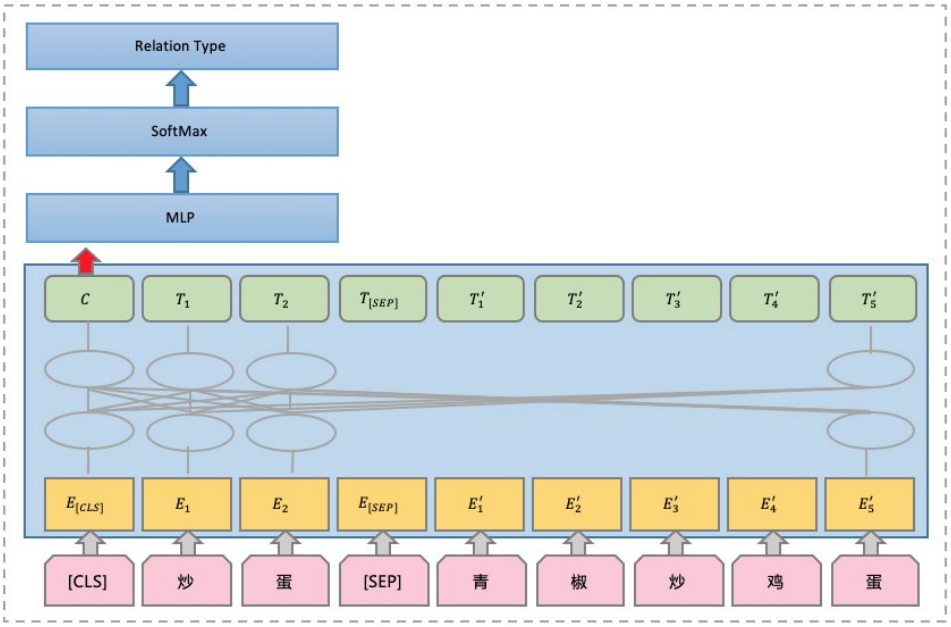

图 9　分类模型

5. 在外卖业务中的应用

标准名作为品类和商品的中间层，为业务提供了更加丰富、合理的聚合粒度，支持了流量转化的策略优化，以及系列产品形态的开发上线。商品列表通过接入标准名层级，实现对商品合理粒度的聚合，解决了线上商品重复的问题；标准名作为基础数据，支持了美食排行榜的开发和上线，帮助提升用户的决策效率；针对用户当前访问的商品，利用标准名召回相关商品，实现交互式推荐。标准名作为重要的基础数据，支持了产品形态多元化、推荐策略优化，对于提升用户粘性、流量转化，搭建商家用户友好的平台生态，具有重要的价值和意义。

图 10　标准名相关应用

6. 总结与展望

目前已完成基本的体系建设，并成功应用于不同的场景、取得业务收益。已经建成的标准名层级体系，覆盖了外卖绝大多数的在线商品。标准名作为基础和特征数据，应用到用户端的商品列表、美食排行榜等业务场景，支持策略优化、带来流量收益；同时，也通过服务接口的形式，跨部门支持 SaaS 点餐推荐的模型优化，以提升用户体验和业务收益。

标准名作为重要的商品特征数据，应用的业务场景广泛。在未来的工作中，需要持续迭代优化，保证标准名自身的准确性和质量；同时加深业务理解，根据业务需要优化层级体系，为业务提供更加合理的聚合粒度，提升转化收益；此外，重点建设一批用户感知强、供给覆盖高的标准名，降低业务方的接入成本和提高收益。

6.1 词表及同义词优化

标准名词表体量大、同义关系复杂，词表建设不是一蹴而就的，需要长期的迭代和优化。针对标准名词表中存在的非菜品、不规范等错误，以及同义词聚合不足、过度的问题，采用算法圈定 + 人工标注的方式，通过模型挖掘潜在同义词、圈定问题词组；人工校验后，进行批量补充和修改，持续优化词表、同义词。

6.2 层级结构合理化

目前标准名层级是通过规则和模型的方式直接生成的，人工参与度较低，与业务场景的结合不够深入。后续会结合业务需要，明确剪枝、聚合粒度准则，合理化层级结

构，优化层级的合理性。从而更加灵活、高效地支持不同的业务应用，提升落地效果。

6.3 核心标准名建设

标准名有 20 万之多，为业务应用造成一定的选择成本、带来不便。结合业务需要，圈定其中用户感知强、供给覆盖高、优质的标准名，作为核心标准名进行重点建设。核心标准名轻量且精炼，更加贴近业务需要，可以帮助业务方降低接入成本、提高收益。

7. 参考文献

[1] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.

[2] Lample G, Ballesteros M, Subramanian S, et al. Neural architectures for named entity recognition[J]. arXiv preprint arXiv:1603.01360, 2016.

[3] Chen Q, Zhu X, Ling Z, et al. Enhanced lstm for natural language inference[J]. arXiv preprint arXiv:1609.06038, 2016.

[4] Huang P S, He X, Gao J, et al. Learning deep structured semantic models for web search using clickthrough data[C]//Proceedings of the 22nd ACM international conference on Information & Knowledge Management. 2013: 2333-2338.

[5] Tan M , Le Q V . EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks[J]. 2019.

8. 作者简介

刘柳、懋地、崇锦、晓星等，均来自美团外卖技术团队。

多业务建模在美团搜索排序中的实践

作者：肖垚　培浩

引言

美团的使命是“帮大家吃得更好，生活更好”，美团 App 承载的业务包括外卖、到店餐饮、买菜、优选、酒店、旅游、休闲娱乐等各类生活服务。美团首页的搜索是美团 App 上各类生活服务最大的流量分发入口，每天为数千万的用户提供各种服务。美团搜索排序是一个典型的多业务混合排序建模问题，一个典型的多业务搜索场景是当用户搜索地点，如“望京”的时候，用户的需求不是很明确，此时搜索的结果页如下图 1 所示，下方的商家列表中会包含望京附近餐饮、电影、休闲娱乐、酒店等多种业务的结果，这就是一个多业务混合排序场景。

图 1　美团搜索结果页面

而多业务场景存在如下几点挑战：

- 因业务之间存在共性和特性，如何让模型兼顾这两种特性，实现更好的数据学习。比如到店餐饮对距离特征非常敏感，而旅游景点业务对距离特征相对不敏感。
- 业务天然存在高频和低频特性（比如外卖和旅游），导致模型的训练数据中多业务样本数量不平衡。
- 各个业务往往有自己不同的主目标，如何满足不同业务的目标，最终能够提升搜索的用户体验。

本文分享了美团搜索中的多业务排序建模优化工作，我们主要聚焦在到店商家多业务场景，后续的内容会分为以下四个部分：第一部分是对美团搜索排序分层架构进行简单介绍；第二部分会介绍多路融合层上的多业务融合建模；第三部分会介绍精排模型的多业务排序建模；最后一部分是总结和展望。希望能对从事相关工作的同学有所启发或者帮助。

排序流程简介

美团搜索系统流程如下图 2 所示，整体流程分为数据层、召回层、排序层和展示层。其中排序层分为以下几个子部分：

- **粗排层**：使用相对简单的模型对召回候选集进行初步过滤，实现排序效果和性能的 Trade-off。
- **多路融合层**：使用查询词特征、上下文场景特征构建配额模型，进行不同业务候选集的数量控制，实现用户需求的精确理解。
- **精排层**：使用亿级别特征的深度学习模型，捕捉各种显式和隐式信号，实现 Item 排序分数的精准预估。
- **重排层**：使用小模型和各种机制对精排后的结果进行调序，实现精细定向的优化。
- **异构排序层**：使用深度学习模型对异构聚块进行排序，实现多业务的高承载。

多层排序架构设计主要是为了平衡排序效果和性能。本文后续提到的多业务建模优化工作主要从多路融合层和精排层进行介绍。

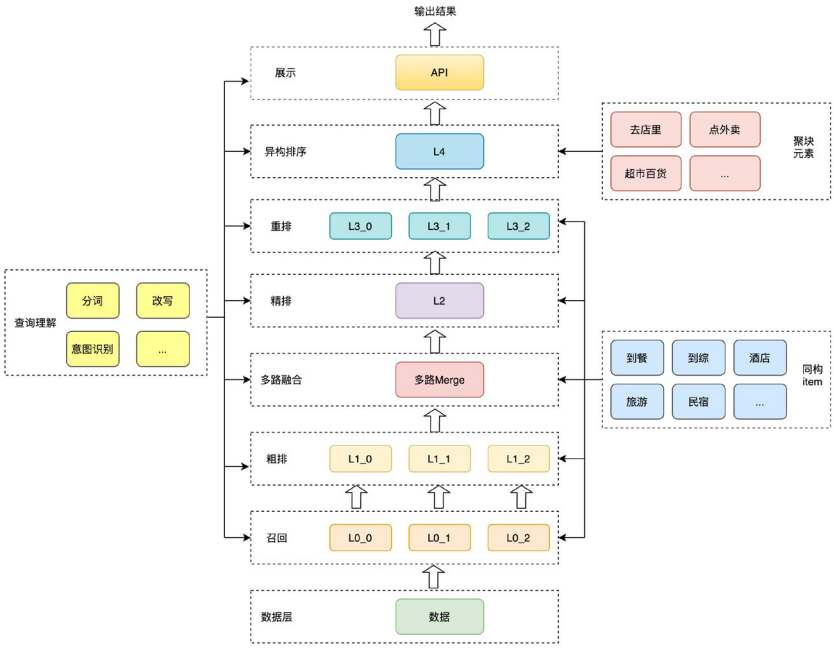

图 2　系统架构图

多业务建模实践

多业务配额模型（多路融合层）

随着美团业务的发展，美团搜索接入了到餐、到综、酒店、旅游等业务。对于业务意图模糊的搜索词，比如用户搜索“五道口”，需要根据用户、查询词、场景等多种因素来综合判断用户的业务意图。为了融合不同业务的召回结果，给 L2 精排一个比例合适的候选集，我们设计了一个多业务配额模型来平衡多业务召回的比例。这种基于配额对多路召回结果进行合并的做法在搜索、推荐场景中十分常用，比如淘宝首页搜索、美团推荐等。

为了多路召回的灵活接入，适配美团搜索业务的发展，我们不断迭代搜索配额模型。

下面将详细介绍美团多业务配额模型的迭代过程，文章后续部分会将多业务配额模型（Multi-Business Quota Model）简称为 MQM。

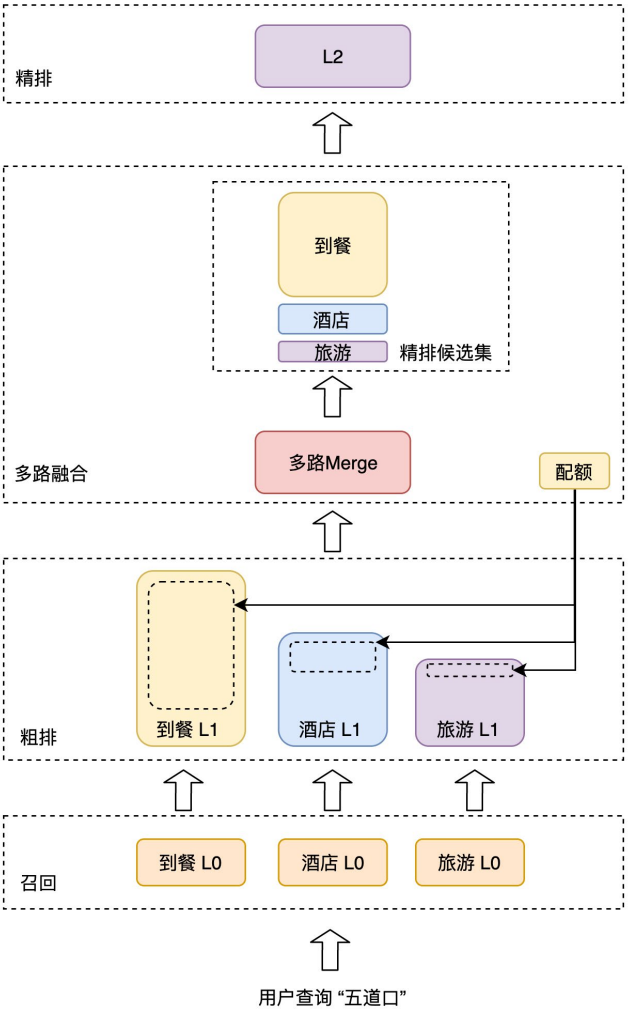

图 3　多路融合过程

一维目标多业务配额

考虑到大搜结果存在多路不同业务的召回，为了刻画用户搜索 Query 对三路业务召回的意图强弱，我们采用多目标的建模方式，以每一路召回是否被点击、下单为

目标进行建模，实现了多业务配额初版模型 MQM-V1。该模型输出各路召回的点击、下单联合概率，作为最终的配额分布。在特征层面，我们使用 Query 维度特征、Context 维度特征、Cross 维度特征、User 维度特征，来刻画用户在不同场景的实时个性化需求。MQM-V1 模型结构如下图 4 所示。

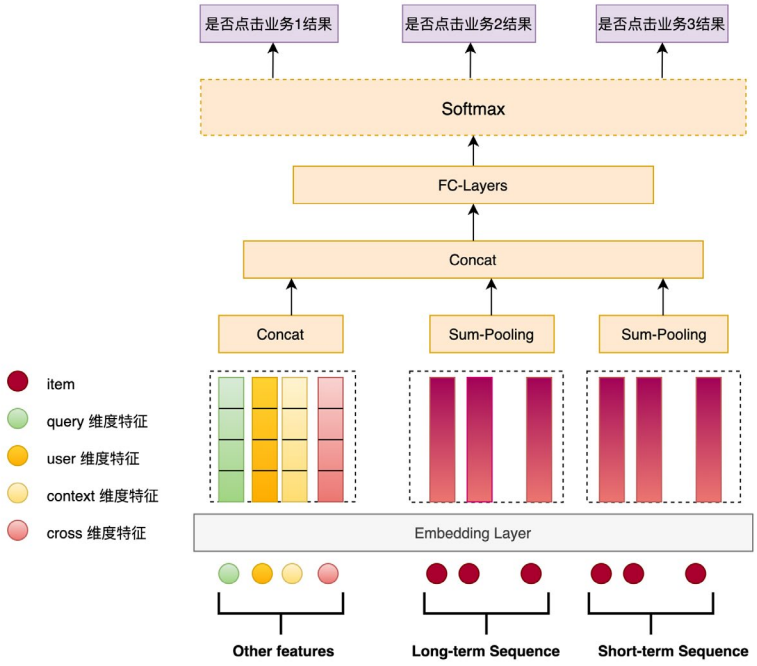

图 4　MQM-V1 模型结构图

MQM-V1 版本上线后，整体线上点击率 +0.53%，各业务访购率基本持平。

二维目标多业务配额

随着大搜召回策略的不断迭代，大搜不仅引入了按业务拆分的召回方式，而且引入了向量检索、地理位置近邻检索等跨多业务的异构召回方式，导致大搜召回策略不断增加，多业务配额模型也面临新召回源带来的冷启动问题。同时，为了加强多业务配额模型的个性化，我们参考借鉴了 [6] 中用户行为序列建模的方法。综上，该版本 MQM-V2 与 MQM-V1 区别如下：

- 建模目标上，从以召回方式点击的一维目标升级到召回方式叉乘业务的二维目标，使得多路融合的粒度也更细、精度更高。
- 行为序列建模模块引入 Transformer Layer。
- 为了解决新召回源接入的冷启动问题，我们引入了人工经验层，包括业务先验和历史统计，综合模型输出决定每一路召回的配额。

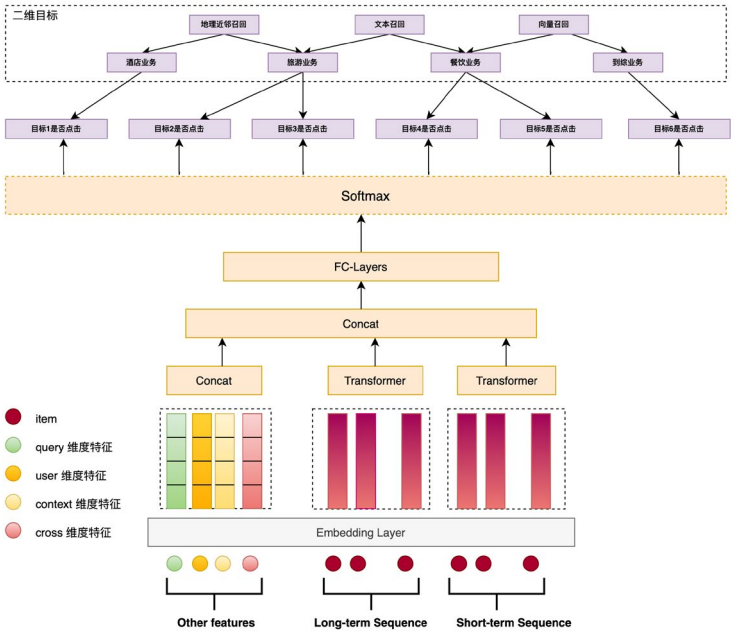

图 5　MQM-V2 模型结构图

MQM-V2 版本上线后，各业务指标率均有提升，其中旅游访购率 +2%，到餐访购率 +0.57%，到综、酒店访购率持平。

多业务排序模型（精排层）

从美团搜索精排模型升级为 DNN 模型，一直到 2019 年底，美团搜索的精排模型结构是业界主流的 Embedding&MLP 的范式结构，期间我们也尝试过业界提出的模型结构比如 PNN[1]、DeepFM[2]、DCN[3]、AutoInt[4]、FiBiNet[5] 等等。

随着迭代的进行，我们发现针对特定业务的优化难以在精排模型发挥作用，为了兼顾

各个业务的特性，支持各个业务更加有效的针对性迭代优化，需要探索出一种模型结构来适配美团搜索这样的多业务场景。下面会具体介绍精排模型在多业务建模上的发展史，文章后续部分将多业务精排模型（Multi-Business Network）简称为 MBN。

独立子网络拆分

考虑到酒店和旅游在美团大搜排序策略的流量里面占比较少，而针对小流量的相关优化在目前统一的 Embedding&MLP 模型结构里面很难体现，我们尝试了如图 6 所示的人工自定义多塔模型 MBN-V1 结构：主网络复用目前的模型结构。具体情况介绍参考 [6] 中的行为序列建模部分，增加酒店和旅游独立子网络；酒店子网络的输入包括酒店独有特征和主网络的打分输出，旅游子网络的输入包括旅游独有特征、主网络的打分输出、主网络最后一层 FC，酒店和旅游子塔输入不同是因为业务逻辑不同导致数据分布差异大，这是实践出的结果，最终的输出是对三个输出的加权求和。

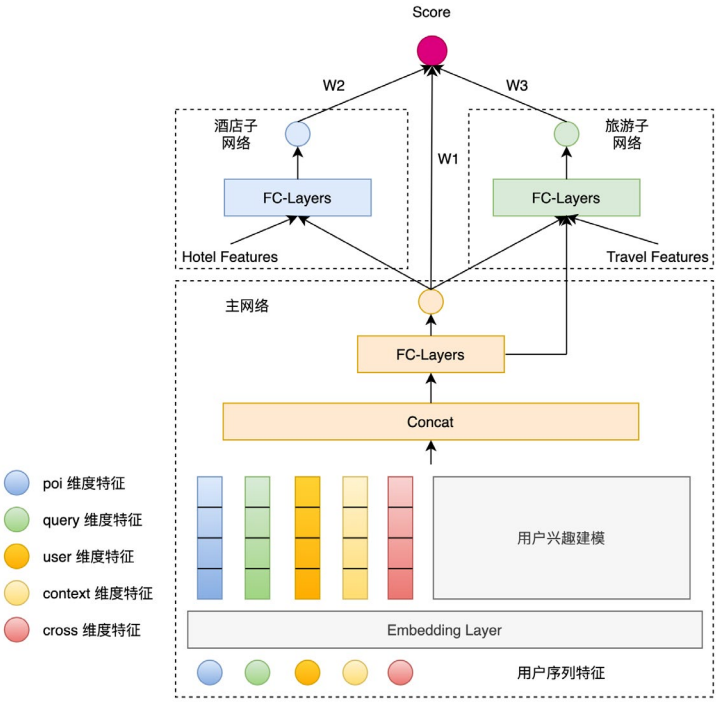

图 6　MBN-V1 模型结构图

针对加权求和的权重部分，我们采取了两种方式对权重进行设定：

- 第一种，采用硬切分的方式，就是说权重向量是一个 One-hot 稀疏向量：对酒店商家进行预测，只选取酒店子网络的输出，其余类推。
- 第二种，采用软切分的方式，把多业务配额模型的输出作为权重值。

线上实验发现第二种方法比第一种好，我们认为采用硬切分会导致子塔分支的参数只能被对应业务的数据更新，而各业务的数据占比不均导致学习不佳，而软切分会达到一种知识迁移的作用。最终线上的效果相比统一的 Embedding& MLP 模型，整体旅游取得了正向效果：其中整体点击率 +0.17%，其余业务访购率效果基本持平。

子网络权重自学习

基于第一版多业务精排模型取得了初步正向效果，我们继续添加美食业务子塔，同时考虑到 MBN-V1 依赖配额模型的输出，这样会导致配额模型的变更可能会对精排模型的效果产生影响，针对这些因素我们上线了第二版多业务模型 MBN-V2，模型结构如图 7 所示。相比 MBN-V1 的区别如下：

- 添加美食业务的独立子网络。
- 解耦精排模型和配额模型，在精排模型中集成权重生成子网络，该子网络的输入主要是一些 Query 维度，Context 维度的特征。

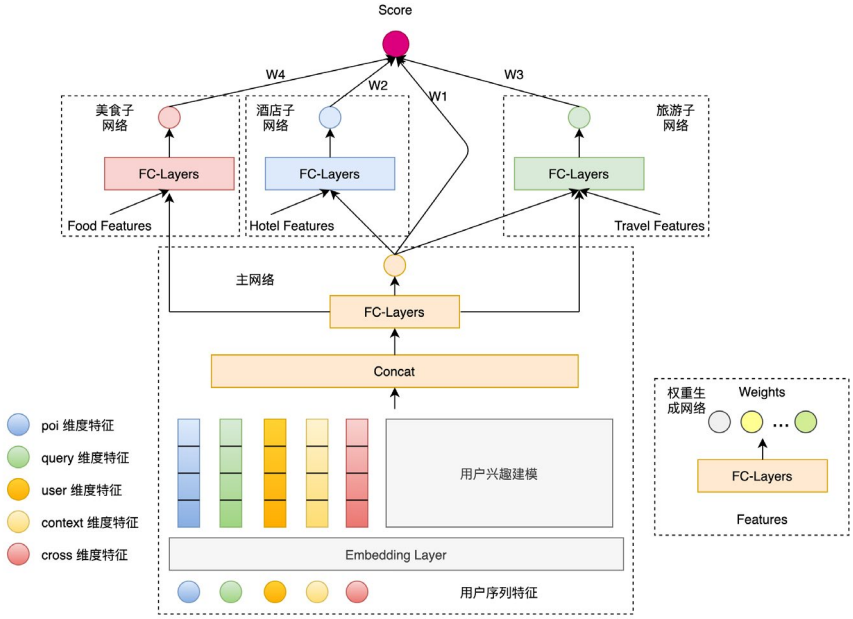

图 7　MBN-V2 模型结构图

线上实验效果：MBN-V2 相比 MBN-V1，整体点击率 +0.1%，业务访购率效果基本持平。

子网络特征自适应

在第二版模型的基础上，我们进一步添加到综业务子塔，随着子网络的变多，目前对于子网络的输入采用人工设计，这种方式需要花费大量的时间进行离线实验。考虑到目前的多业务子塔结构十分类似业界的多任务学习，我们也尝试引入业界的多任务学习结构；同时，我们针对 MBN-V2 中的权重子网络输出进行分析发现其输出的权重对不同业务商户的输出差不多，那么会带来业务的针对性优化不明显。基于上述部分，我们迭代了第三版多业务精排 MBN-V3，结构如下图 8 所示，改进点如下：

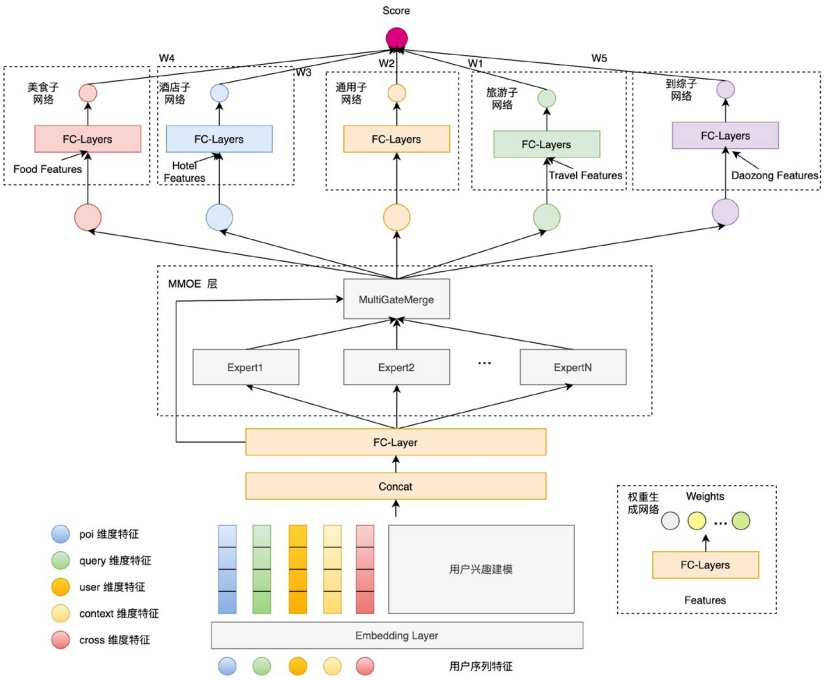

图 8　MBN-V3 模型结构图

- 补充到综子网络，采用 MMoE[7] 多任务学习结构，来自动学习特征表征输出给上层子网络，从而取代人工设计子网络的输入。
- 精排模型的损失函数除了采用用户线上反馈计算的主 LambdaLoss 外，额外添加了业务的分类交叉熵 Loss，达到预测某业务 Item 得分时，对应的业务子塔权重最大的目的。

线上实验效果：MBN-V3 相比 MBN-V2，整体点击率效果持平、美食业务访购率 +0.36%，到综业务访购率 +1.07%，酒店业务访购率 +0.27%，旅游业务访购率 +0.35%。

多业务特征表达优化

虽然 MMoE 多任务学习结构在业界很多场景得到了应用，在我们的多业务建模场景也取得了有效验证，但是我们持续跟进业界前沿，并且结合业务场景进行落地。

我们尝试了腾讯提出的 PLE[8] 结构，迭代出多业务精排 MBN-V4。 PLE 可以看成

是 MMoE 的改进版，它对于每一个任务有自己特定的专家层，不同任务之间有共享的专家层，相比 MMoE 是所有专家输出的加权求和，PLE 子任务的输入是子任务独有的专家和共享专家输出的加权求和，更容易学出业务的特性；同时基于性能考虑，我们选取了单层 PLE 也即 CGC 结构，结构如下图 9 所示：

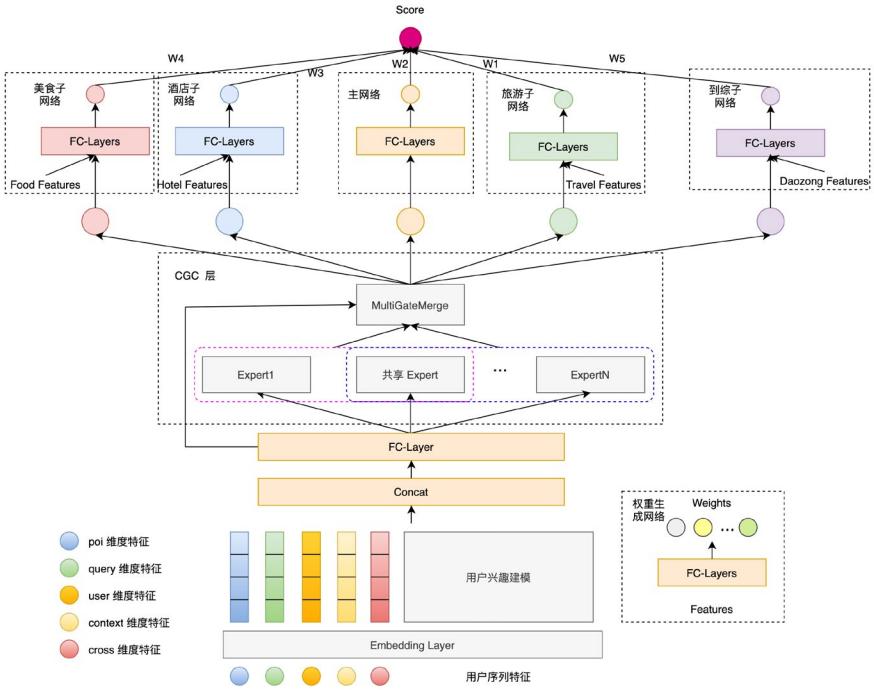

图 9　MBN-V4 模型结构图

线上实验效果：MBN-V4 相比 MBN-V3，整体点击率 +0.1%，美食业务访购率 +0.53%，其余业务访购率波动持平；我们对 MMoE 和 CGC 的专家权重进行可视化如下图 10 所示，分析发现：CGC 结构的专家层权重相比 MMoE 在同一业务多条样本之间的专家权重方差更小，更加稳定，说明 CGC 相比 MMoE 在特征表示上更加有优势。

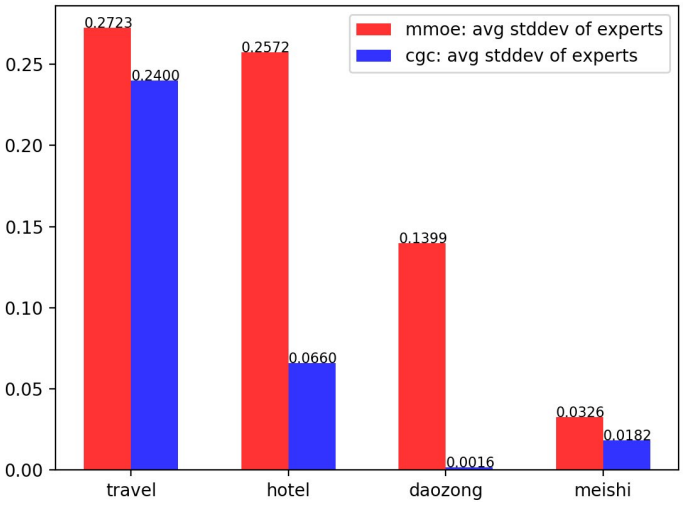

图 10　MMoE、CGC 专家权重分析

总结和展望

2019 年底开始，为了解决实际的多业务召回排序问题，美团搜索进行了大量探索，从工程到算法到产品形态各个层面丰富对多业务的支持。其中排序算法层面主要在多路召回融合层和精排层进行优化。

多路融合层主要完成搜索结果从结果相关到结果优质的筛选过程，需要解决不同召回方式（文本召回、推荐召回、向量召回）和不同业务召回结果的融合截断问题，直接决定了用户能浏览到的结果候选集。这其中最重要的问题就是判断用户对各个业务的需求强弱以及各业务的召回质量，对每个业务结果和召回结果确定合适的精排准入标准。

多业务配额模型通过整合用户实时需求、Query 的历史统计信息、搜索上下文信息和每个召回源质量情况，给出了每路召回、每个业务的应进入精排的比例。该模型保证了不同场景下精排候选集的结果多样性和优质性，实现了新业务、新召回方法接入的少侵入性，降低业务、召回接入成本。同时也为精排层分业务的网络结构提供了融合各个业务子网络结果的先验权重。

精排层在多路融合层的基础上进一步对多业务搜索结果进行精细化排序建模打分。用户的需求和美团业务一样是多样的，为了能充分建模各种场景下的需求，精排多业务排序模型从底层数据（丰富分业务的特征）、模型结构到业务目标融合都进行了多轮迭代。其中模型结构和相应的目标融合直接对各种大小业务、场景和相应的业务目标进行了分片建模，有效地缓解了小业务小场景在统一建模中被大业务样本淹没的问题。同时该模型支持新老业务的快速迭代，各业务可以方便独立地迭代特征、模型结构和相应的目标。

上述优化覆盖了线上全流量，在搜索用户体验和各业务价值均有明显提升，但还有很多工作可以持续优化。

- **业务独有特征利用**：目前我们采用对某些业务添加业务独有特征，其余业务对于这些缺失的独有特征给默认值，但是这样会带来很多冗余的计算量，这部分不管从效果还是性能方面都存在优化空间。
- **样本不平衡学习**：不同业务的数据量在美团搜索上差异大，如何让模型更好的学习出小业务的分布，我们正在探索迁移学习和 Meta-Learning 等方法。
- **多目标优化**：美团搜索既要兼顾用户的搜索体验，也要服务美团各个业务的战略目标，所以各个业务的主优化指标不一定一致，多目标优化也是一个持续探索的方向。

本文叙述的工作集中在美团多业务商家搜索排序上，同时随着优选、买菜、团好货、闪购等商品类业务的发展，我们也正在进行商品类多业务混排以及商家商品异构多业务混排工作。

参考资料

[1] Product-based neural networks for user response prediction
[2] DeepFM: A Factorization-Machine based Neural Network for CTR Prediction
[3] Deep & Cross Network for Ad Click Predictions
[4] AutoInt: Automatic Feature Interaction Learning via Self-Attentive Neural Networks
[5] FiBiNET: Combining Feature Importance and Bilinear feature Interaction for Click-Through Rate Prediction

[6] Transformer 在美团搜索排序中的实践
[7] Modeling Task Relationships in Multi-task Learning with Multi-gate Mixture-of-Experts
[8] Progressive Layered Extraction (PLE): A Novel Multi-Task Learning (MTL) Model for Personalized Recommendations

作者简介

培浩、肖垚、晓江、家琪、陈胜、云森、永超、利前等，均来自美团平台搜索与 NLP 部。

美团搜索多业务商品排序探索与实践

作者：曹越　瑶鹏　诗晓　李想等

引言

美团的使命是“帮大家吃得更好，生活更好”，我们给广大消费者提供买菜、优选、闪购、外卖、到店餐饮、酒店旅游、休闲娱乐等各类商品和服务。首页搜索是美团App 上十分重要的模块，每天服务于数千万用户。随着美团零售商品类业务的不断发展，美团搜索在商品类业务上的相关技术也在不断迭代，排序模块作为整个搜索系统的重要组成部分，极大地影响着用户最终的搜索体验。

近些年，深度学习在排序领域得到广泛的应用，本文分享了美团搜索在零售商品类业务上的排序经验。内容主要分为以下三个部分：第一部分，我们对商品搜索多业务排序面临的挑战进行简单的介绍；第二部分会介绍商品搜索相关排序技术的一些实践经验；最后一部分是总结与展望。

搜索排序的挑战

美团搜索多业务商品排序，面临的挑战主要包括以下几个方面：

1. 各业务供给和履约差异较大，采用统一模型对各类业务商品进行统一的混合排序建模，模型兼顾不同业务的共性和特性难度大。
2. 不同业务的消费频次和业务规模不同，导致各业务在模型训练数据中的分布差异较大。
3. 排序结果进行业务聚合展示情况下，业务间的顺序和首位业务结果展示数目共同影响着用户的搜索体验，两者独立优化只可能得到体验目标的次优解，由于两者的任务差异大，进行联合优化难度较大。

下面主要介绍我们在商品多业务排序上针对上述挑战点所做的一些探索与实践。

排序探索与实践

混排建模

在美团搜索商品多业务排序场景下，排序需要对不同商品业务：闪购、买菜、优选、团好货等进行统一混合排序，不同业务之间既有共性也有自己的特性。下面介绍我们针对商品多业务排序相关的一些实践。

图 1　多业务商品排序示意图

多子塔结构

此前，我们在商家多业务排序场景中已经积累了很多的实践经验，详情可参考《多业务建模在美团搜索排序中的实践》一文，所以直接将多子塔结构应用到商品多业务

排序场景。商品混排的 item 集合涵盖五个业务，模型结构中具有五个子塔：闪购子网络、买菜子网络、外卖子网络、优选子网络和团好货子网络；与此同时，我们引入 ESMM[2] 模型结构来更好的学习下单信息。整体模型结构如下图 2 所示：

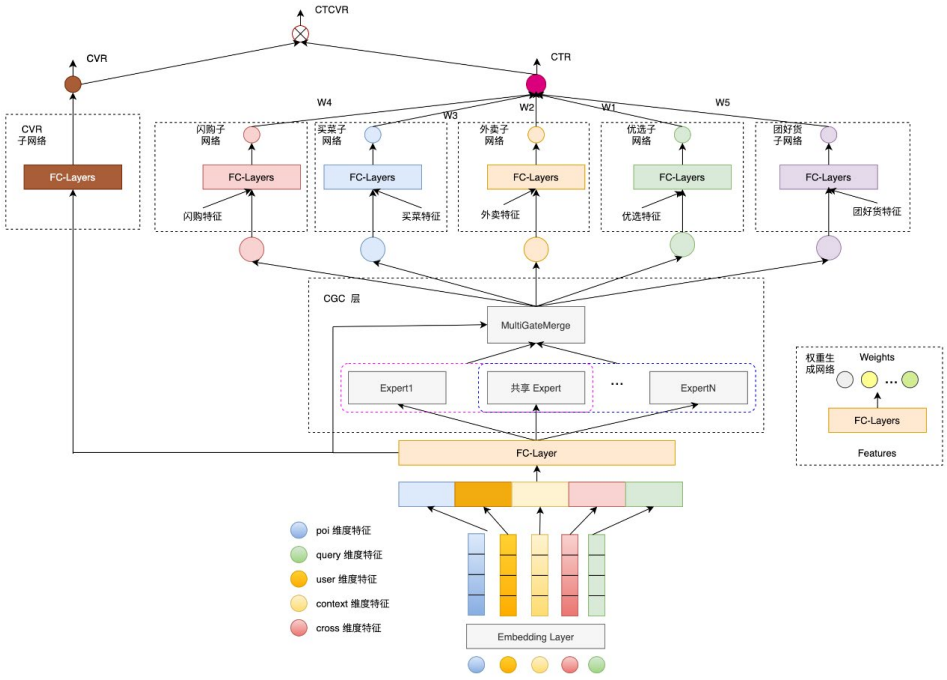

图 2　多子塔模型结构示意图

实践表明，模型离线指标相比基线提升明显；经过线上 AB 实验测试，点击率提升了 20BP（基点），访购率提升了 37BP。

多业务特征选择

目前在多业务子塔结构中，我们采用了一个大的特征候选集来兼顾各业务的需求：底层特征输入是闪购、买菜、外卖、优选、团好货多个业务的特征并集，业务之间互相缺失的特征给予默认值。这种实现，导致特征的数量繁多且杂乱，可能会给模型的训练带来很多的噪声。例如对于优选业务，实际可能只有 10% 的特征起到作用，剩下 90% 的特征对这个业务来说就是噪声。

目前，业界提出的相关特征选择方案，如 AutoFIS [20]、AutoFeature [21] 等等，都是针对单个场景、单个模型来选择的，而我们的目的是针对一个特征集合，让模型学会不同场景下特征重要性的不同。因此，这些方案无法直接应用到我们的场景中。为了缓解上述提到的问题，我们初步尝试了一些方法用于多业务的特征选择。

Group Lasso 正则化

Group Lasso [3] 是 Lasso 的一个扩展。Group Lasso 首先对特征进行分组，然后对组内的特征采用 L2 正则化，组间的特征集合采用 L1 正则化。由于 L1 正则化的稀疏性，因此最后产出的特征集合是稀疏的，也就达到了特征选择的目的。形式化表述，我们在训练目标中加入下述公式（1）正则项：

$$\min \mathcal{L}_{grls} = \lambda_1 \sum_{k=1}^{K} || \theta_k ||_2 + \lambda_2 || \theta ||_1 \quad (1)$$

其中 K 为特征组的数目，θ_k 为第 k 组特征的 Embedding 矩阵，λ_1 和 λ_2 为权重超参数。在上式中，我们对所有特征集合应用 L1 正则化，从而产出一个稀疏的解，也就达到了我们特征选择的目的。

该版模型相比多子塔模型，离线 NDCG 基本持平。

特征选择门

在上述 Group Lasso 方案中，虽然我们达到了特征选择的目的，但选出的特征对应不同业务的权重是相同的。在多业务排序场景下，不同特征对不同业务的重要性显然不一样，例如“配送时间”这个特征对闪购业务比较重要，但对于团好货影响不是很大。为了分业务建模特征重要性，我们借鉴 Group Lasso 的思想，提出了一个自适应多业务特征选择模块。

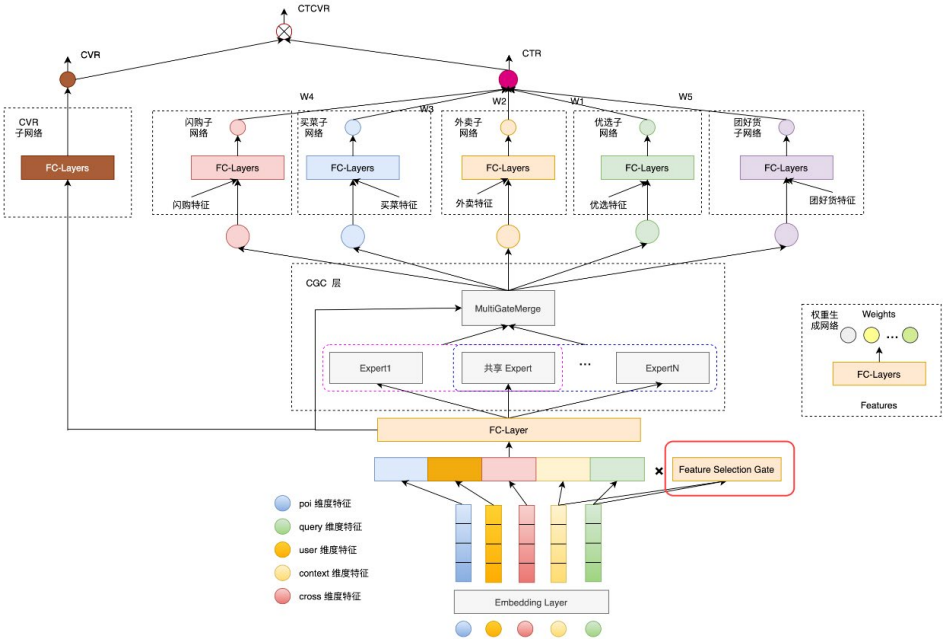

图 3　多子塔特征选择门结构

整体模型结构如上图 3 所示，我们通过一个特征选择门来计算每个特征的权重。特征选择门将 Query 以及上下文相关信息的 Embedding 表征经过一层线性映射以及 Softmax 激活函数，得到归一化的特征的权重向量：

$$g_t = softmax(W_t x_{query} + b_t) \tag{2}$$

其中 $g_t \in R^{h_2}$ 是第 t 个业务的特征权重向量，$W_t \in R^{h_2 \times h_1}$ 是第 t 个业务的投影矩阵，$b_t \in R^{h_2}$ 是对应的 Bias 向量。而后用这个权重向量点乘经过 Embedding 编码后的模型输入：

$$\hat{x}_t = g_t \odot x = \sum_{k=1}^{K} g_{t,k} x_k \tag{3}$$

对于不同的业务，我们用不同的门控 g_t 乘上输入，从而达到了分业务加权的目的。

这版模型相比 Group Lasso 正则化版本，离线 NDCG 提升了 16BP。

多业务概率图模型及训练

在特征选择门方案中，我们针对不同的业务选用了不同的门控来实现自适应特征选择。但是该方案有一个关键的问题：训练和推理阶段，我们怎么知道该选用哪个业务的门控向量 g_t？因此，模型首先需要能够识别当前请求的意图。

此外，多塔子结构的实践本质是想让业务更好地学出自己的特性。在图 2 和图 3 所示的多业务结构中，如果调参不当，很容易出现退化或者模式坍塌的现象。一个极端情况是，所有子塔中只有一个子塔得到了充分的训练，模型所有的输出都依赖于这个子塔，这与我们多业务建模的初衷相违背。

为了实现意图识别以及更好地训练多业务子塔，我们接着提出了一个概率图的框架，用一个隐变量 zz 来学习用户当前需求对应到每个业务的分布，系统性地用一个概率图将输入、业务、以及输出联系起来。模型结构示意图如下图 4 所示，我们在模型中额外引入一个先验网络 p 和一个后验网络 q，先验网络的目标是根据用户、查询词、上下文等输入信息预测采用哪个子塔，即建模 $p(z \mid x)$，后验网络的目标是根据输入以及用户的行为来建模后验概率 $p(z \mid x,y)$。训练目标是优化条件概率分布的一个证据下界（Evidence Lower Bound）：

$$\begin{aligned}\log p(y \mid x) &= \log \int_z p(y \mid x,z)\, p(z \mid x) dz \\ &\geq E_{q(z|x,y)}[\log p(y \mid x,z)] - D_{KL}[q(z \mid x,y) \,\|\, p(z \mid x)] \end{aligned} \tag{4}$$

这个公式第一项表示的含义是在训练时，我们从后验网络中拿到对应业务的分布 z，然后根据 z 来判断模型走哪个子塔并进行训练。第二项表示的含义是让先验网络和后验网络的输出尽可能接近，从而在推理阶段也能够根据先验塔的输出来判断走哪个子塔。这个后验网络只会在训练阶段使用。在具体实现上，我们将后验网络简化成一个规则决策模型：根据用户的行为反馈来预测对应的业务。

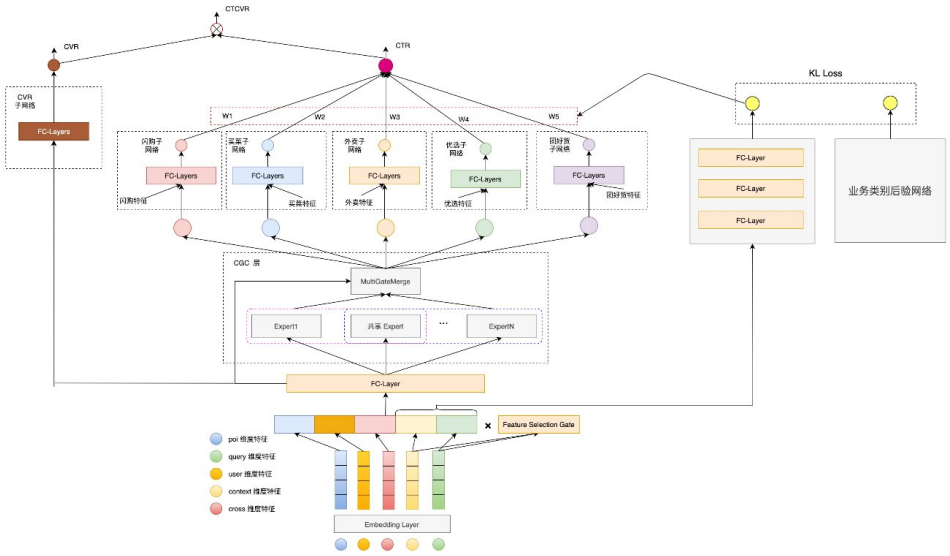

图 4　多业务概率图模型

引入概率图建模后离线 NDCG 提升了 39BP；最终我们将该版本进行线上 AB 测试：线上点击率提升了 25BP。

在多业务建模方面，除了上面的工作我们还陆续尝试了使用 Uncertainty 对分业务 Loss 进行加权 [4]、多业务 Hierarchy 结构 [5] 等，但均没有取得明显效果提升。

此外，我们也调研了阿里妈妈近期提出的 Star[6] 模型，Star 模型主要有以下几点贡献：1. 提出了一个星形（Star）的架构；2. 提出了分片归一化（Partitioned Normalization）的方案；（3）将域的信息显式加入到输出中（辅助网络）。我们尝试过将分片归一化、辅助网络的方案应用到我们的场景中，但均没有取得明显的效果。

聚合建模

当对各业务结果进行如图 5 所示的聚合展示时，聚块的位置顺序和聚块大小（即聚块内 item 的数量）共同决定用户的搜索体验。过去很长一段时间的技术方案是先使用排序模型预测业务的先后顺序，然后根据业务预测分数的相对差值通过人工规则来设置聚块大小。这种方案将聚块顺序和聚块大小分两步进行串行建模，距用户体验最优

解存在较大差距；其次，聚块排序与聚块大小的串行耦合会降低模型的迭代效果：前者的模型迭代替换，会导致后者规则相关的阈值设定不再合适。

图 5　结果聚合展示示意图

针对聚合展示样式带来的技术挑战，我们提出 GSRM (Grouping Search Results Model) 模型，该模型结构如下图 6 所示。这是一个多任务模型，同时进行聚块位置和大小的预测。聚块位置预测任务我们建模成 CTR 预估的分类问题，输出结果代表业务偏好强弱进行聚块的的位置排序；聚块大小预测任务我们建模成一个回归问题，输出聚块展示结果数。模型的底层输入特征包含查询词维度、用户维度、上下文维度、item 维度、以及各个维度的交叉特征。下面重点介绍两个工作：第一个是用户行为序列建模，第二个是聚块大小预测建模。

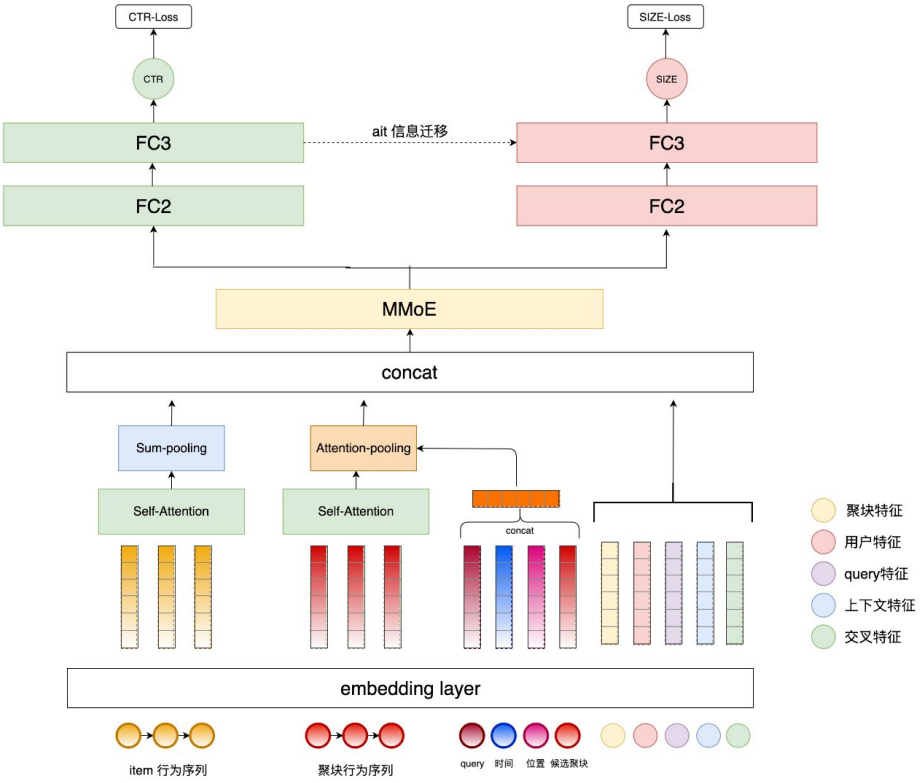

图 6　聚块展示模型示意图

异构双序列建模

众所周知，在深度学习 CTR 预估时代，在模型中引入用户行为序列特征能够极大提升模型的效果。业界关于端到端行为序列建模的工作，主要分为以下三类：第一类是基于注意力机制的模型，代表性工作如 DIN[7]、DIEN[8]、DSIN[9] 以及 BST[10] 等等；第二类是基于记忆网络的模型，代表性工作如 HPMN[11] 和 MIMN[12]；第三类是基于检索的模型，代表性工作如 UBR4CTR[13] 和 SIM[14]。这些工作对美团搜索多业务商品排序有很大的落地实践指导。

考虑到在聚合展示样式下，用户的行为具有异构性：用户既与聚块发生交互行为，也与聚块内的 item 发生交互行为，所以该业务排序场景相比业界大部分排序场景的用户行为序列建模不同，它属于异构行为序列建模。如上图 6 的模型结构所示，模型

使用了用户的 item 行为序列和聚块行为序列，其中我们使用更加丰富的用户全美团 App 业务序列来替换美团搜索聚块行为序列。

得益于我们在美团搜索商家个性化排序上积累的实践经验（参见《Transformer 在美团搜索排序中的实践》一文），两种序列都首先通过 Self-Attention 方式进行编码，得到一个更好的 Embedding 表示；然后对 item 行为序列直接进行 Sum-pooling，对聚块序列进行 Attention-pooling；考虑到在美团 O2O 场景下，用户的业务偏好兴趣与时间和地点有极强的关系，我们将查询词、时间和位置等上下文信息和候选聚块一同作为 Attention 中的 Target 来更好的刻画不同时空场景下用户的兴趣。

模型补充 Context-Aware 的异构双序列建模，离线 NDCG 提升了 10BP；线上 AB 测试也取得稳定正向的效果：点击率提升了 12BP，访购率提升了 9BP。

为了深入理解行为序列建模的效果，我们对 Context-Aware 部分的 Attention 权重进行可视化如下图 7 所示，发现对于用户最终发生行为的聚块，对应到行为序列中同类别聚块的权重也更大，说明 Context-Aware 能较好捕获用户当前请求的兴趣，在抽取兴趣时能够较好抑制其他行为的噪声。

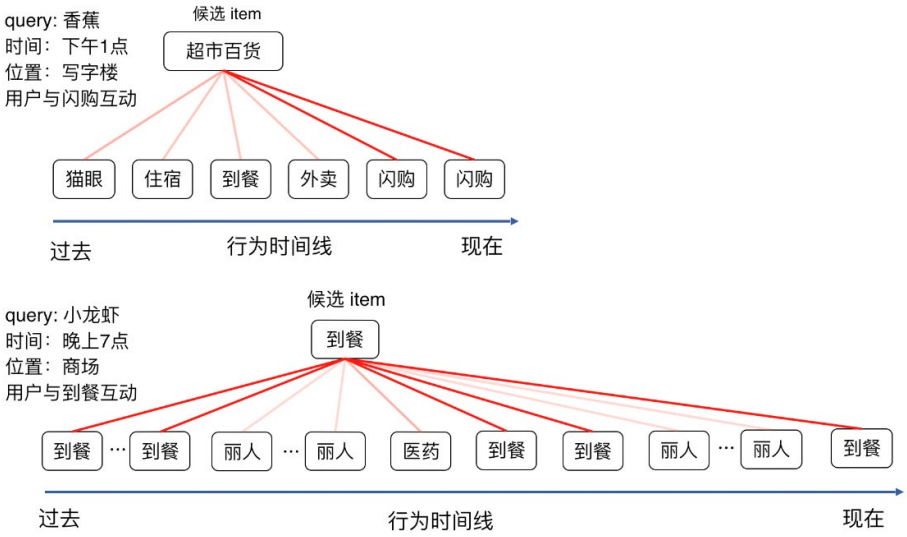

图 7　Target-Attention 权重示意图

聚块大小预测建模

针对聚块大小预测的回归任务，考虑到和之前的预估分类任务差异较大，我们在特征共享层采用目前业界常用的 MMoE[16] 多任务参数共享结构，同时从业务场景来看，当偏好预估认为某个业务很强时，应该给与相对多的业务结果数，所以我们借鉴了 AITM[17] 的工作，迁移偏好预估塔中的隐藏层信息到聚块大小预估塔中，整体模型如上图 6 所示。

模型训练损失函数如公式 (5) 所示，其中 pos 表示聚块的位置信息。

$$Loss = \lambda_1 * Loss_{ctr} + \lambda_2 * \varphi(pos) * Loss_{size} \quad \varphi(pos) = \begin{cases} 1 & pos = 0 \\ 0 & pos \neq 0 \end{cases} \tag{5}$$

其中偏好预估损失函数 $Loss_{ctr}$ 采用 LambdaLoss[18]，如下面公式（6）所示：

$$Loss_{ctr} = \sum_{y_i > y_j} \Delta NDCG(i, j) \log_2(1 + e^{-\sigma(\hat{y}_i - \hat{y}_j)}) \tag{6}$$

聚块大小预估损失函数 $Loss_{size}$ 采用 HuberLoss[19]，如下面公式（7）所示：

$$Loss_{size} = \begin{cases} \frac{1}{2}(label_{size} - pred_{size})^2 & \text{for} \mid label_{size} - pred_{size} \mid \leq \delta \\ \delta(\mid label_{size} - pred_{size} \mid - \frac{1}{2}\delta) & \text{otherwise.} \end{cases} \tag{7}$$

两个损失函数的权重 λ_1 和 λ_2 根据人工经验设定。针对聚块大小 Loss，考虑到实际我们只调整首位的聚块大小，所以聚块大小 Loss 只对首位聚块生效。其中的 $label_{size}$ 会依据用户的行为反馈进行适当设计：当用户点击“查看更多”或者“聚块标题”时，会对线上历史展示个数适当放大；当用户在非首位下单时，会对首位聚块大小进行适当缩小；当用户在首位下单时，会综合考虑用户的浏览个数、最后点击位置以及历史展示大小进行调整。

对聚块大小进行联合预测，离线 NDCG 持平，线上 AB 测试结果：访购率提升了 3BP。

总结和展望

本文介绍了我们在多业务商品排序上的探索与实践经验。关于多业务统一排序，基于过去商家多业务排序的经验，继续从特征选择、引入概率图模型优化模型训练来持续提升多子塔结构的效果。可以看出，我们的工作具有较好的延续性和迭代性；同时当结果采用聚合展示样式时，我们采用 GSRM 聚合模型技术策略来与之适配。这些工作也都取得了不错的效果。

未来，我们会在以下几个方面展开进一步的工作：

1 针对如何使模型更好地学习不同业务的特性和共性，将在特征自适应选择和参数共享两个方面持续迭代模型结构。

2. 针对上层的业务子塔结构，不同的业务可能适用不同的参数量，将结合 AutoML 技术对多业务结构中的子网络进行优化。

3. 针对目前人工设计多任务 Loss 权重带来的调参工作量，将探索对多任务 Loss 权重自适应调整的方法。

4. 针对用户对单个 item 的决策行为受周围展示 item 信息影响，而目前的排序方法没有较好建模这个信息，将探索考虑 Context 信息多业务混排方法。

参考资料

[1] 多业务建模在美团搜索排序中的实践

[2] Ma X, Zhao L, Huang G, et al. Entire space multi-task model: An effective approach for estimating post-click conversion rate[C]//The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. 2018: 1137-1140.

[3] Friedman et al., A note on the group lasso and a sparse group lasso.

[4] Kendall et al., Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics. In CVPR, 2018.

[5] Guo et al., Dynamic Task Prioritization for Multitask Learning. In ECCV, 2018.

[6] Sheng et al., One Model to Serve All: Star Topology Adaptive Recommender for Multi-Domain CTR Prediction. In CIKM, 2021.

[7] Zhou G, Zhu X, Song C, et al. Deep interest network for click-through rate prediction[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. ACM, 2018: 1059-1068.

[8] Zhou G, Mou N, Fan Y, et al. Deep interest evolution network for click-through rate prediction[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33: 5941-5948.
[9] Feng Y, Lv F, Shen W, et al. Deep Session Interest Network for Click-Through Rate Prediction[J]. arXiv preprint arXiv:1905.06482, 2019.
[10] Chen Q, Zhao H, Li W, et al. Behavior sequence transformer for e-commerce recommendation in Alibaba[C]//Proceedings of the 1st International Workshop on Deep Learning Practice for High-Dimensional Sparse Data. 2019: 1-4
[11] Kan Ren, Jiarui Qin, Yuchen Fang, Weinan Zhang, Lei Zheng, Weijie Bian, Guorui Zhou, Jian Xu, Yong Yu, Xiaoqiang Zhu, et al. Lifelong sequential modeling with personalized memorization for user response prediction. In SIGIR, 2019.
[12] Qi Pi, Weijie Bian, Guorui Zhou, Xiaoqiang Zhu, and Kun Gai. Practice on long sequential user behavior modeling for click-through rate prediction. In KDD, 2019.
[13] Jiarui Qin, W. Zhang, Xin Wu, Jiarui Jin, Yuchen Fang, and Y. Yu. User behavior retrieval for click-through rate prediction. In SIGIR, 2020.
[14] Search-based User Interest Modeling with Lifelong Sequential Behavior Data for Click-Through Rate Prediction.
[15] Transformer 在美团搜索排序中的实践
[16] Ma J, Zhao Z, Yi X, et al. Modeling task relationships in multi-task learning with multi-gate mixture-of-experts[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018: 1930-1939.
[17] Xi D, Chen Z, Yan P, et al. Modeling the Sequential Dependence among Audience Multi-step Conversions with Multi-task Learning in Targeted Display Advertising[J]. arXiv preprint arXiv:2105.08489, 2021.
[18] Burges C J C. From ranknet to lambdarank to lambdamart: An overview[J]. Learning, 2010, 11(23-581): 81.
[19] https://en.wikipedia.org/wiki/Huber_loss
[20] Liu et al., AutoFIS: Automatic Feature Interaction Selection in Factorization Models for Click-Through Rate Prediction, In ADS-KDD, 2020.
[21] Khawar et al., AutoFeature: Searching for Feature Interactions and Their Architectures for Click-through Rate Prediction, In CIKM, 2020.
[22] Tang et al., Progressive Layered Extraction (PLE): A Novel Multi-Task Learning (MTL) Model for Personalized Recommendations, In Recsys, 2020.

作者简介

曹越、瑶鹏、诗晓、李想、家琪、可依、晓江、肖垚、培浩、达遥、陈胜、云森、利前均来自美团平台搜索与 NLP 部。

情感分析技术在美团的探索与应用

作者：任磊　佳昊　金刚等

背景

移动互联网的发展和普及已达到空前规模，亿万网民在互联网上可以获得信息、交流信息，发表自己的观点和分享自己的体验，表达各种情感和情绪，如批评、赞扬以及喜、怒、哀、乐等。作为国内领先的生活服务电子商务平台，美团连接起了百万商户和亿级用户，积累了数十亿真实用户评论。用户评论不仅为消费者选店决策提供参考，也是商家获取消费者反馈的渠道。对用户评论进行情感分析可以帮助美团深入理解商家服务水平和用户偏好，为改进平台服务与获取优质内容提供了最直观的反馈，同时也在美团搜索、个性化推荐、商业智能、内容安全等十多个业务场景中有着广泛应用。

以大众点评 App 为例，用户既可以发表对商家的星级打分（一星到五星），也可以对商家服务或产品发表详细评论。我们对大众点评商户近半年的评论进行了统计分析，用户情感倾向在不同星级商家中的分布如图 1 所示，商家整体星级打分反映出用户对该商家的整体情感倾向，但同时我们发现高星商户的评论中存在大量负向情感内容，低星商户的评论中也存在不少正向情感内容。究其原因在于用户评论中存在大量星级评分与对应评论情感倾向不一致的情况，如图 2 中展示的两条用户评论，高星级评论中存在负向情感内容，低星级评论中也存在正向情感内容。

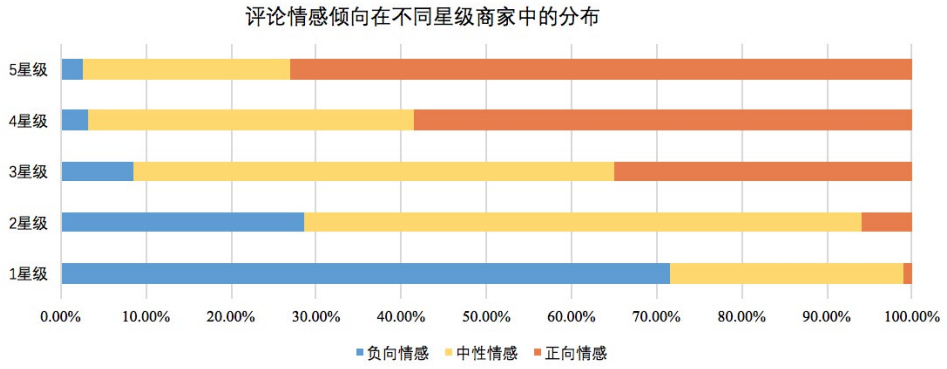

图 1　评论情感倾向在不同星级商家中的分布

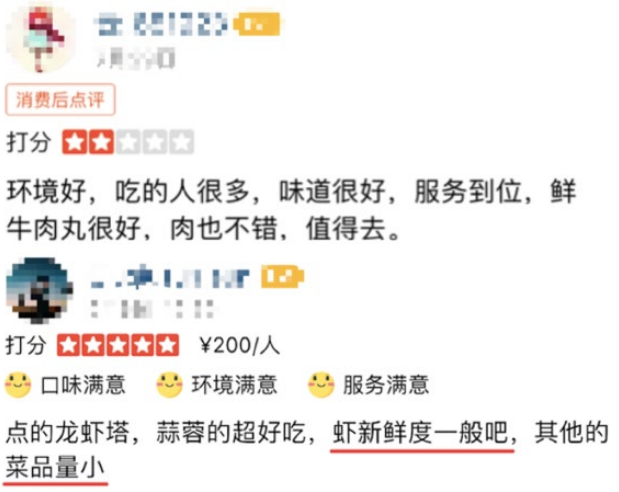

图 2　用户星级评分与评论情感倾向不一致

图 3 展示了大众点评 App 上一家「五星级」咖啡厅，用户对口味、环境、服务各项评分都很高。我们对其所有用户评论分析后发现好评主要集中在口味、服务、性价比等属性，但也有不少用户抱怨说咖啡厅的位置难找，不好停车，座位比较拥挤，空间小等。整体星级评分并不能全面体现用户对商家的真实评价。因此，除了对用户评论内容进行整体情感判断外，我们还需要对用户评论进行更细粒度的情感分析才能精准地挖掘用户对商家的反馈，进而改善商家服务，提升用户体验。

图 3　商家详情页

2021 年 5 月，美团 NLP 中心开源了迄今规模最大的基于真实场景的中文属性级情感分析数据集 ASAP[1]，该数据集相关论文 [2] 被自然语言处理顶会 NAACL2021 录用，同时该数据集加入中文开源数据计划千言 [3]，将与其他开源数据集一起推动中文信息处理技术的进步。借此机会，本文回顾了美团情感分析技术的演进和在典型业务场景中的应用，整体技术框架如图 4 所示。

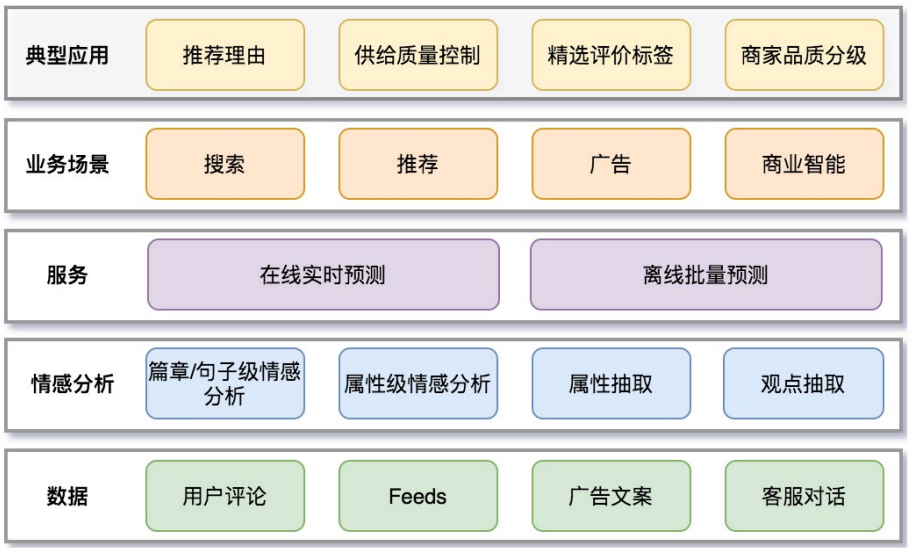

图 4　美团情感分析整体技术框图

情感分析介绍

情感分析的目标是分析文本中表达或蕴含的正向（褒义）、负向（贬义）或中立的情感倾向。根据所处理文本的粒度，情感分析可以分为篇章 / 句子级情感分析和属性级情感分析 [4]，与属性级情感分析密切相关的还有观点三元组分析。

篇章 / 句子级情感分析的目标是判断整篇文档或整句子的情感倾向（即正向、负向或中立）。

属性级情感分析与篇章 / 句子级情感分析不同，需要同时考虑目标信息（属性）及其对应的情感。例如“这家餐厅装修很有格调，饭菜也很好吃，就是位置很不显眼，找

了好久才找到，并且服务员态度也不够满意。”如果从整体看，很难说这句话应该被判断成褒义还是贬义，因为在评论中，用户称赞了餐厅的装修和菜品属性，但是吐槽了餐厅的位置和服务属性。为了得到更全面和精确的情感信息，我们需要识别粒度更细的属性级情感。这种任务学术上被称为 ABSA（Aspect Based Sentiment Analysis，基于属性的情感分析），可以划分为 ACSA（Aspect Category Sentiment Analysis，基于属性类别的情感分析）和 ATSA（Aspect Term Sentiment Analysis，基于属性项的情感分析）[5]，其中 ACSA 是识别在相应预定义属性类别（Aspect Category）上的情感倾向，如上述评论在属性类别“菜品口味”上表达正向情感，在属性类别“服务态度”上表达负向情感。ATSA 中是识别针对文本中出现的相应属性（Aspect Term）的情感倾向，如上述评论中针对属性“饭菜”表达正向情感，针对属性“服务员”表达负向情感。本文所述属性级情感分析主要指 ACSA 任务。

观点三元组分析包括属性抽取（Aspect Extraction）、观点抽取（Opinion Extraction）以及属性 – 观点对（Aspect-Opinion）的情感倾向分析三个任务，在学术上称为 Aspect Sentiment Triplet Extraction[6] 或者 Opinion Triplet Extraction[7]。属性抽取和观点抽取属于信息抽取的范畴，属性 – 观点对的情感倾向分析属于分类任务。属性抽取任务中抽取的属性（Aspect Term），是上述 ATSA 任务的基础，观点抽取任务是抽取人们针对属性所表达的观点，例如评论“宫保鸡丁这道菜真是棒极了，太好吃了！”中的属性“宫保鸡丁”，观点“真是棒极了，太好吃了！”；属性 – 观点对的情感倾向分析是识别基于该属性表达观点的情感倾向，例如“宫保鸡丁——真是棒极了，太好吃了！”情感倾向为正向。

篇章 / 句子级情感分析及应用

篇章 / 句子级情感分析即给定一段文本，通过模型给出该文本整体的情感强度或情感倾向。根据模型输出类型划分，主要分为回归方案和分类方案，其中回归方案的输出为连续的情感强度 [0 ~ 1]（趋向 0 代表负向程度，趋向 1 代表正向程度），分类方案的输出为离散的情感倾向（正向、负向、中立）三分类。调研多个业务场景对情感分析的需求，同时考虑模型在应用中的通用性和灵活性，我们最终采用了回归模型方

案。为了建立精准的情感分析能力，在数据标注时我们将情感强度划分为离散的七档评分——[非常负向 , 负向 , 轻微负向 , 中性 , 轻微正向 , 正向 , 强烈正向]，并采用 Min-Max Normalization 将标注 Label 归一化到 [0 ~ 1]。

在这个任务上，业界主流技术方案主要有 TextCNN[8]、Att-BLSTM[9] 以及 BERT[10] 为代表的预训练模型。其中 Att-BLSTM 提出利用注意力机制获取句子中最重要的信息，且在学习长距离语义上优于 TextCNN，因此第一版模型框架采用了图 5 所示的 Att-BLSTM 方案。2018 年以来以 BERT 为代表的预训练模型在多项 NLP 任务中取得巨大进展，BERT 在特征抽取上具有较强优势，如浅层的句法特征以及深层的语义特征。基于上述考虑，我们用自研 MT-BERT[11] 模型对 Att-BLSTM 架构中的编码器进行升级，并在多个业务评测上取得了显著效果提升，部分实验结果见图 6。

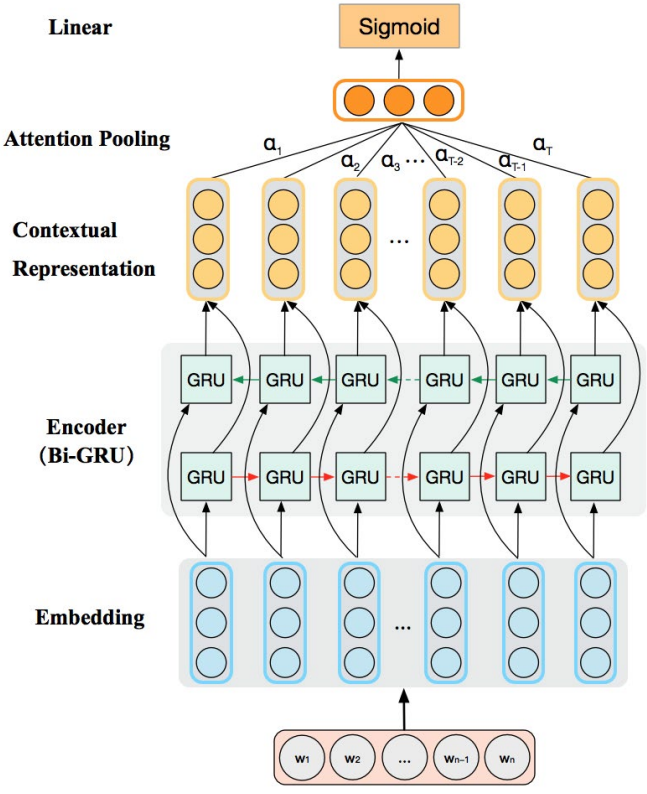

图 5　篇章 / 句子级情感分析模型架构

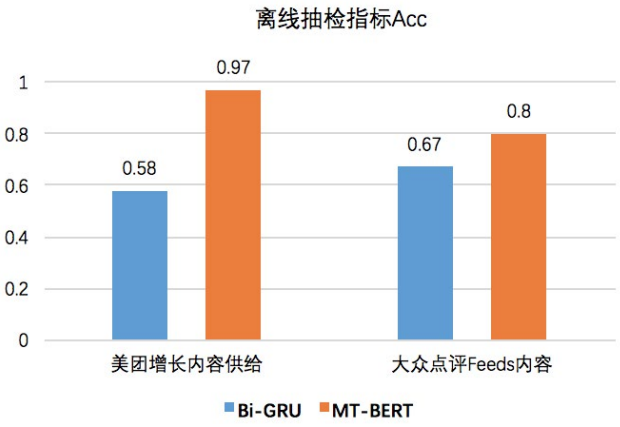

图 6　篇章 / 句子级情感分析模型迭代效果指标

篇章 / 句子级情感分析在美团业务中有着广泛应用，如广告和推荐业务中的文本安全管控和商家运营情感监测等。如图 7（a）所示，美团 App 和大众点评 App 首页信息流文案大部分抽取自用户真实评论，需要从内容供给上严格控制文本质量，通过句子级情感分析对供给内容中的负向内容进行过滤，提升终端用户体验。此外，在商业智能场景中，句子级情感分析还可以帮助商家优化运营策略，如图 7（b）所示，美团商业大脑通过情感分析能力可以监控用户对商家评价的情感曲线以及评论情感占比等指标来改善商家运营。

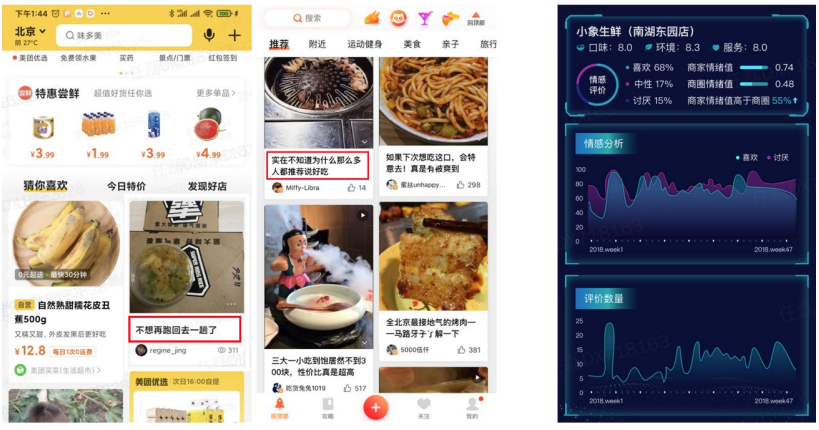

(a)文本安全管控场景　　(b)商家运营情感监测场景

图 7　篇章 / 句子级情感分析在美团业务场景的应用

属性级情感分析及应用

篇章 / 句子级情感分析只是针对文本整体表达或蕴含的情感倾向分析，无法获取针对评价观点对象（属性）上的情感倾向。为了得到更细粒度的情感分析结果，我们需要针对美团业务场景构建属性级情感分析能力，即给定一段文本，通过模型给出该文本在指定属性上的情感倾向。

数据收集与分析：针对大量用户评论进行统计分析，同时参考 SemEval 数据集 [12]，并与业务产品专家沟通美团业务特点后，我们将餐饮业务下的属性设计为菜品、环境、价格、服务、位置，共 5 类。数据分析中发现美团业务下的用户评论趋于多样化和细粒度化。以该真实用户评论“... 装修看起来很高大上的样子，但是因为主厅在举办婚礼非常混乱，感觉特别吵 ...”为例，用户对装修和噪声两个环境细分属性表现出相反情感倾向。因此我们将属性从上述 5 个类别细分到 18 个子类别，最终设计为两级属性体系，如图 8 所示。

图 8　两级属性体系

为了构建高质量数据集，我们进行了详细数据分析和调研业界标准，最终制定了面向用户评论的属性级情感分析标注规则。对于每条评论，标注人员需要先判断预定义的属性是否在该评论中被提及，再判断被提及属性上的情感倾向。因此对于每个属性共有 4 种标签——[未提及 , 负向 , 中立 , 正向]。

我们对 ASAP 数据集中属性及其对应的情感倾向分布做了统计，如图 9 所示。本次标注主要面向餐饮商家下的用户评论，所以 94.7% 的评论都提及菜品口味这一属性。除此之外，用户们还比较关心服务人员态度，价格水平，装修情况等属性。

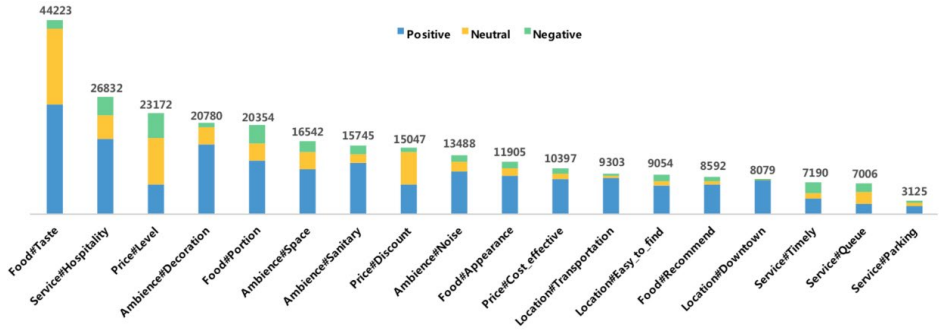

图 9　ASAP 数据集中属性以及对应的情感倾向分布

与属性级情感分析开源数据集 SemEval RESTAURANT[13] 相比，ASAP 在数据量上远远超出，可以支撑深度神经网络模型的探索。相对于单句级别的 RESTAURANT，包含多子句评论级别的 ASAP 具有更长的平均长度，因此往往包含更丰富的属性信息。在 ASAP 数据集中平均每条评论包含 5.8 个属性，是 RESTAURANT 数据集的 4.7 倍，相对于 RESTAURANT 数据集具有更大的挑战性。

表1 ASAP和SemEval RESTAURANT的统计数据和label分布

Dataset	Split	Reviews	Average sentences per review	Average aspects per review	Average length	Positive	Negative	Neutral	1-star	2-star	3-star	4-star	5-star
ASAP	Train	36, 850	8.6	5.8	319.7	133, 721	27, 425	52, 225	1, 219	1, 258	5, 241	13, 362	15, 770
	Dev	4, 940	8.7	5.9	319.9	18, 176	3, 733	7, 192	151	166	784	1, 734	2, 105
	Test	4, 940	8.3	5.7	317.1	17, 523	3, 813	7, 026	165	173	717	1, 867	2, 018
RESTAURANT	Train	2, 855	1	1.2	15.2	2150	822	498	-	-	-	-	-
	Test	749	1	1.3	15.6	645	215	94	-	-	-	-	-

属性级情感分析多任务学习框架：在该类问题上，业界主流技术方案根据模型结构不同可以分为两种，分别为基于非预训练模型的方案和基于预训练模型的方案。基于非预训练模型的方案中，Att-BLSTM[9] 需要为每个属性单独训练一个模型，无论模型训练还是模型应用都比较复杂；ATAE-LSTM[14] 通过属性向量（Aspect Embedding）引入属性信息，同时提出基于注意力（Attention）机制让模型聚焦到对应的属性相关信息上来提升模型准确率；CapsNet[15] 可以用于 ABSA 任务中学习属性（Aspect）和文本（评论）之间关系。基于预训练模型的方案中，QA-BERT[16] 将 ABSA 任务转化为问答形式的句间分类任务，每个属性都和文本构成句对作为输入，实际应用中属性数量较多时，计算量较大；CapsNet-BERT[17] 在 CapsNet 方案的

基础上将语义编码层（Encoder）从 Bi-GRU 升级为 BERT。上述模型都只考虑了属性与文本的关系，把每个属性都单独处理，没有考虑不同属性间的关系。

通过数据分析部分可知，ASAP 数据集在不同属性上的分布非常不均衡，这会导致模型训练时数据量小的属性上更容易出现过拟合，不同属性上的情感倾向表达有共性同时也有各自特定的表达方式。模型设计时需要结合业务数据特点同时兼顾计算效率，最终我们采用了多任务学习框架来兼顾属性间关系，同时处理一条评论的多个属性，模型整体设计为两层，分别为共享层和任务相关层，如图 10 所示。

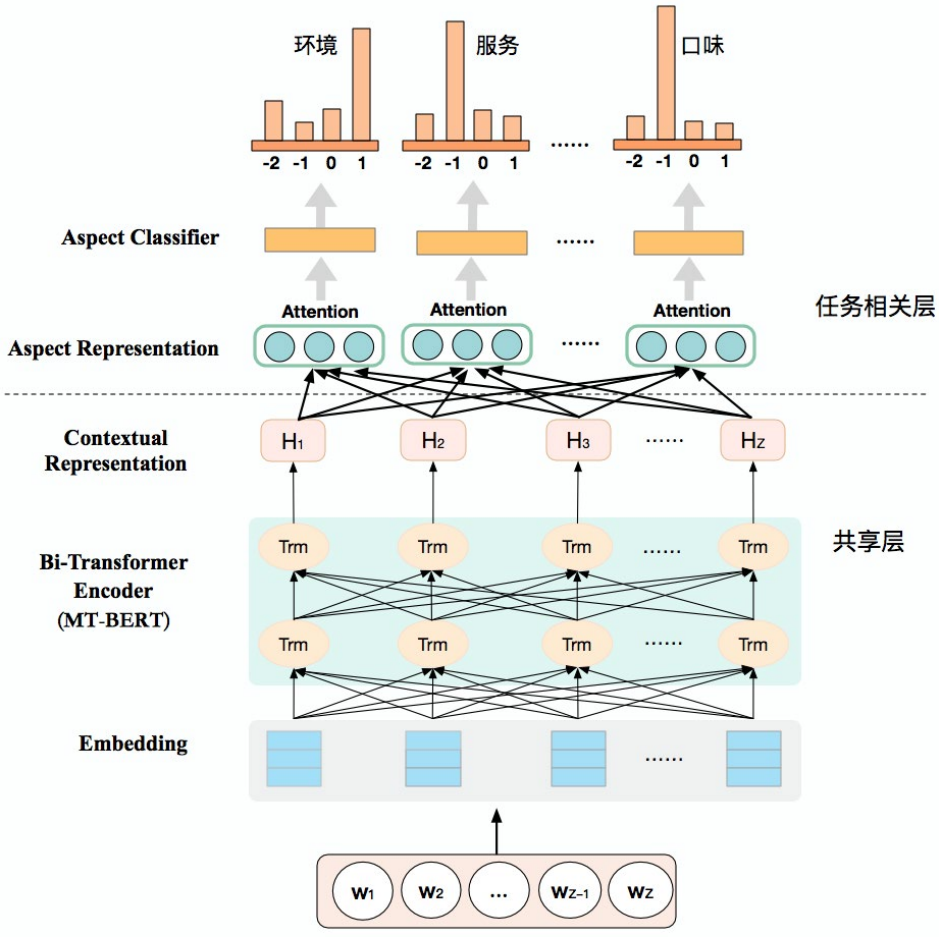

图 10　美团属性级情感分析模型架构

共享层为语义编码层（Encoder），目标是学习文本在不同属性上的上下文深度语义表征。通过参数共享实现知识的迁移可缓解数据不均衡带来的问题，同时对新增属性的扩展具有较好的兼容性。

$$H = Encoder(R) \tag{1}$$

其中，$H = \{h_1, h_2, ..., h_Z\}$ 为评论 $R = \{w_1, w_2, ..., w_Z\}$ 经过语义编码层（EncoderEncoder）编码后得到的向量，Z 代表评论的长度。

任务相关层包括注意力层和分类层，注意力层设计上我们借鉴了 ATAE-LSTM 中注意力池化的方法，让模型可以聚焦到整条评论中和指定属性最相关的句子或者片段，减少其他属性等无关信息的干扰，提升该属性上的情感倾向判断准确率。

$$M_i^a = \tanh(W_i^a * H) \tag{2}$$

$$\alpha_i = softmax(\omega_i^T * M_i^a) \tag{3}$$

$$r_i = \tanh(W_i^p * H * \alpha_i^T) \tag{4}$$

其中，α_i 是注意力权重向量，对句子中不同重要程度的词语给予不同的权重。r_i 是评论针对第 i 个属性经过注意力池化后得到的加权表征。

最后模型经过 Softmax 分类器，

$$\hat{y}_i = softmax(W_i^q * r_i + b_i^q) \tag{5}$$

对于给定的评论 RR，属性级情感分析的损失如下：

$$L_{ACSA} = \frac{1}{N}\sum_{i=1}^{N}\sum_{C} y_i * \log \hat{y}_i \tag{6}$$

其中，N 为属性（Aspect）数量，C 是分类类别数。

随着预训练语言模型技术的快速发展，结合团队自研的预训练模型 MT-BERT 不断迭代，我们在上述多任务框架的基础上，对参数共享层的语义编码（Encoder）部分做了持续的迭代，由最初的 Bi-GRU 到 Google-BERT-Base，再到 MT-BERT-

Base，以及目前的 MT-BERT-Large，模型在 Benchmark 上的指标得到了进一步的提升，如图 11 所示。

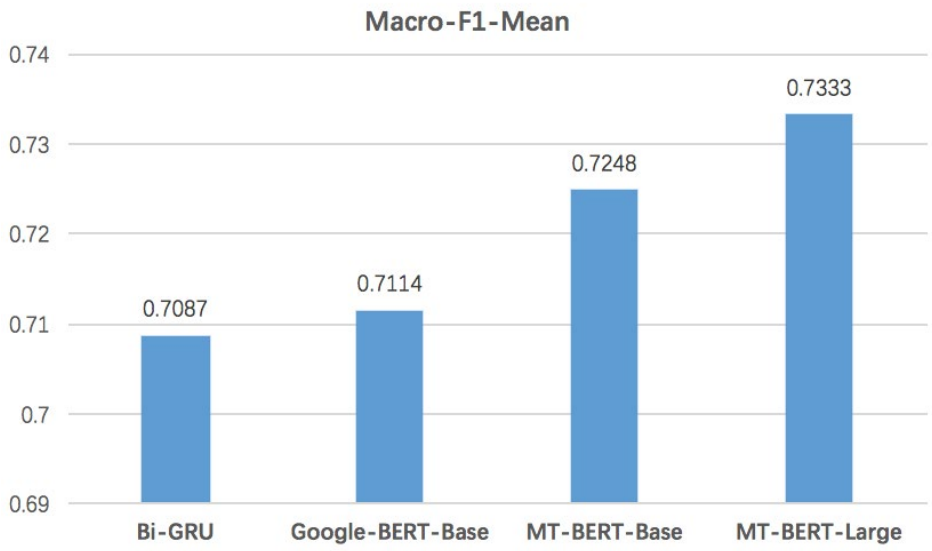

图 11　美团属性级情感分析模型迭代指标

典型应用：属性级情感分析在美团业务中有非常多的应用场景，如精选点评、个性化推荐、智能搜索、商家运营等。大众点评 App 的精选点评模块是属性级情感分析的典型应用场景之一，如图 12 所示。精选点评模块作为点评 App 用户查看高质量评论的入口，其中精选点评标签承载着内容结构化聚合的作用，支撑着用户高效查找目标评论内容的需求。鉴于属性级情感分析能够挖掘用户评论在不同属性上表达的情感倾向，根据其构建的属性级情感标签能够较好的帮助用户筛选查看，同时外露更多的商家信息，帮助用户高效的从评论中获取消费指南。

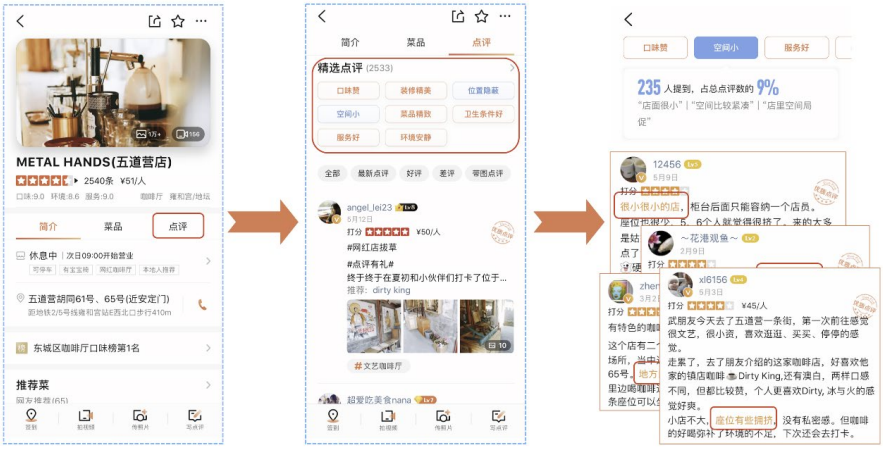

图 12　大众点评精选点评模块产品形态

美团商业大脑运营分析是属性级情感分析在美团商业智能典型应用场景，如图 13 所示。美团商业大脑是美团搭建起的面对生活服务业商家提供大数据分析决策支持的知识图谱平台，通过细致刻画商家服务现状、商家竞争力分析，以及商圈洞察等方式，为商户提供精细化经营建议。美团商业大脑通过对用户评论进行全方属性级情感分析与归纳总结，从而可以发现商家在市场上的竞争优势 / 劣势、用户对于商家的总体印象趋势、商家菜品的受欢迎程度变化，并对商家提供前瞻性经营方向，智能化指导商家精准优化经营模式。

图 13　美团商业大脑商家运营分析

观点三元组分析及应用

在观点三元组抽取任务中，工业界目前主流的方案是基于 Pipline 的方案，即先分别抽取属性和观点，然后抽取两者关系，最后通过句子级情感分析获得属性和观点对的情感倾向。Pipline 方案的优点是整个任务可以模块化，复用关系抽取、情感分析等通用能力，且各模块可以单独迭代优化；缺点是误差会在 Pipline 模块中传导累积，后序模块对前序模块的准确度有较强的依赖性，且计算效率低。

在学术界，最新的一些工作 MTL[7] 和 GTS[18] 等提出了多任务学习的解决方案。结合美团业务特点同时兼顾计算效率的考虑，最终我们选择了多任务学习的方案，模型架构如图 14 所示。模型整体由四部分组成：Pretrained Language Model、Aspect Tagger、Opinion Tagger、Sentiment Parser，其中 Pretrained Language Model 为基于预训练语言模型的编码器，兼容 BERT、RoBERTa[19]、ELECTRA[20] 等主流预训练模型，Aspect Tagger 执行属性序列标注任务，Opinion Tagger 执行观点描述序列标注任务，Sentiment Parser 执行属性与观点描述关系依赖及其情感分析解析任务，主要为一个 Biaffine Scorer[21]。

如图 14 中的例子所示，Aspect Tagger 将“虾滑”和“墨鱼滑”这两个属性抽取出来，而 Opinion Tagger 则对应地将“很不错”和“并不新鲜”这两个观点描述抽取出来，Sentiment Parser 给出句子中的所有字之间的情感依赖关系（即正向、负向、中立、无关）四分类。我们利用抽取出来的属性和观点描述在所有字之间的情感依赖关系上进行索引和记录，最终可以得到“虾滑”和“很不错”之间的 2*3=6 个情感依赖关系中最多的关系为正向情感，而“虾滑”和“并不新鲜”之间的 2*4=8 个情感依赖关系中最多的关系为无关。类似地，我们可以推断出“墨鱼滑”和”并不新鲜“之间的关系为负向情感。模型训练时，模型整体对三个子任务损失进行联合优化。

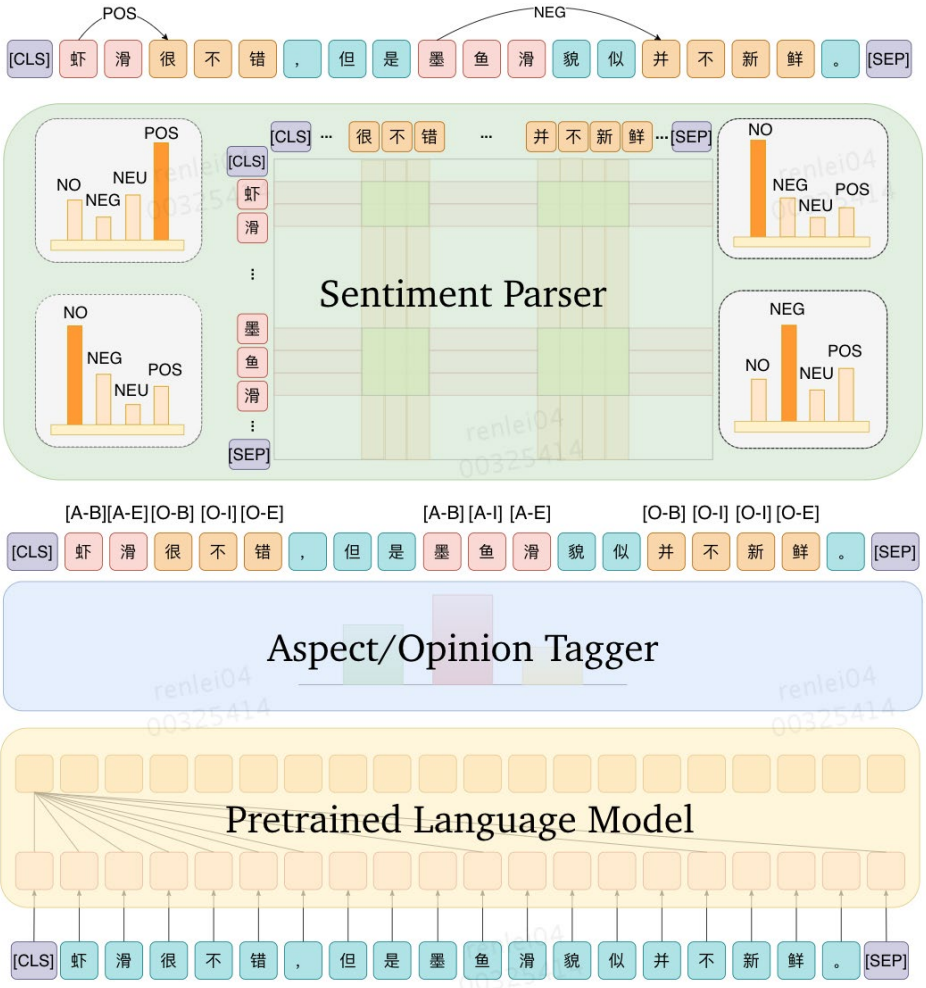

图 14　观点三元组抽取多任务学习模型架构

此外，我们对 Pretrained Language Model 模块进行了优化，由最初的 Google BERT-Base，到自研 MT-BERT-Base，再到目前的 MT-BERT-Large，模型在 Benchmark 上的指标得到了进一步的提升，如图 15 所示。由于观点三元组分析既包括分类任务也包括抽取任务，评价指标上我们采用了 EM-F1 和 Fuzzy-F1，其中 EM-F1 需要任意两个观点三元组（属性，观点描述，情感）中三个元素全部正确整体才算一次命中，Fuzzy-F1 会考虑抽取片段的重合度（包括属性和观点描述），

EM-F1 比 Fuzzy-F1 更加严格。

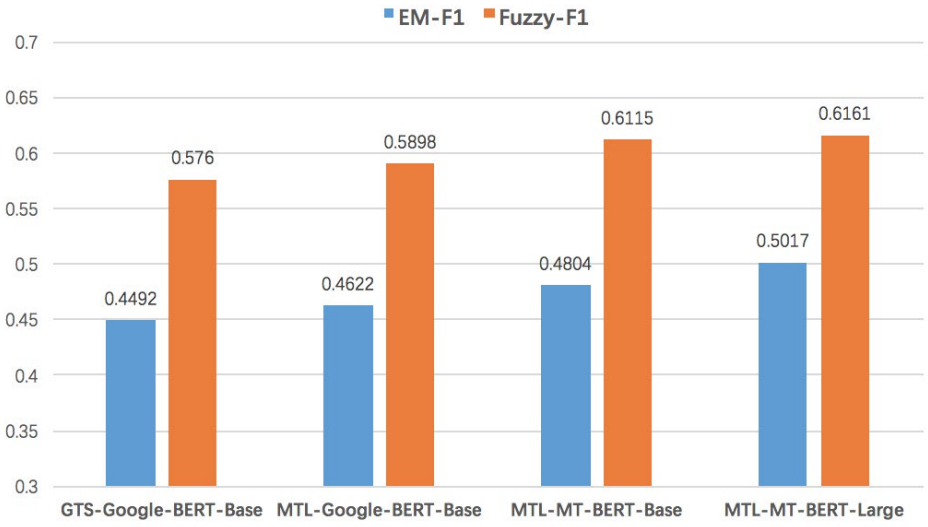

图 15　观点三元组抽取模型指标迭代

通过观点三元组分析技术可以构建基于属性的情感观点知识库，其中每个属性（商品或服务）节点都会被一个或多个带情感依赖的观点描述指向，如图 16 所示。通过【属性 + 正向观点】的模板方法可以构造推荐文案，例如”酸汤鱼片：酸酸甜甜，妙不可言”，可以用于美团 App 和大众点评 App 首页推荐或广告文案场景，同时可以根据用户对属性（商品或服务）的偏好，展示个性化推荐文案，帮助用户更加高效的获取信息。同时这些基于属性（商品或服务）的情感观点信息可以帮助商家更加精细化的运营。

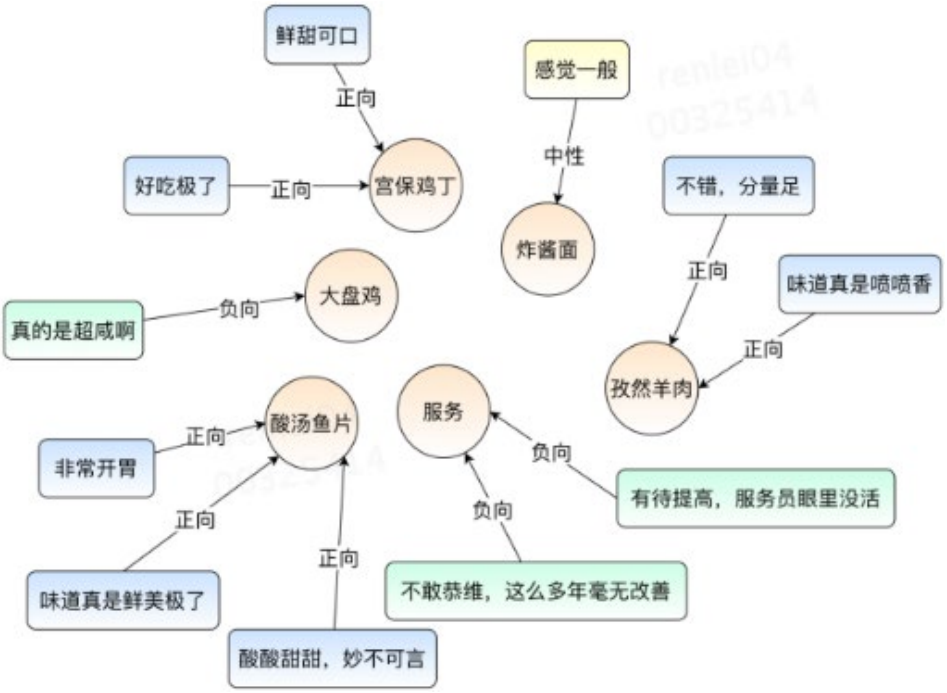

图 16　基于属性（商品或服务）的情感观点知识库样例展示

情感分析服务化

很多美团业务场景对情感分析有迫切需求，例如推荐理由、Feeds 内容、广告文案、精选评价标签、商家运营、对话系统等场景都需要识别文本在整体或属性上的情感倾向。针对美团业务特点我们构建了在线实时预测服务和离线批量预测服务。

在线实时预测服务主要针对需要实时计算的场景，如对话系统需要实时识别用户对话内容的情感倾向，提供 Thrift 接口调用方式，方便美团内部业务服务调用；离线批量预测服务主要针对需要离线批量计算的场景，如每日新生产的 Feeds 内容需要批量进行情感分析后才能进入线上内容供给池。依托于美团机器学习平台 MLP 搭建了情感分析离线计算服务，业务使用方仅需要简单的配置输入 / 输出数据表以及计算队列即可便捷调用，同时该服务支持了定时调度，可以便捷接入到业务方整体的调度流程中。目前情感分析服务已经为美团内部十多个业务场景提供服务。

图 17　在线实时预期

图 18　离线批量预测

总结与展望

本文总结了美团情感分析技术的演进和在典型业务场景中的应用，包括篇章 / 句子级情感分析、属性级情感分析和观点三元组分析，其中属性级情感分析工作向业界开源了迄今规模最大的基于真实场景的中文属性级情感分析数据集 ASAP，该数据集相关论 文《ASAP: A Chinese Review Dataset Towards Aspect Category Sentiment Analysis and Rating Prediction》被自然语言处理顶会 NAACL2021 录用。在技术迭代上，紧跟预训练语言模型技术的快速发展，结合团队自研的 MT-BERT 模型不

断迭代升级。在业务应用上，依托情感分析技术能力构建了在线实时预测服务和离线批量预测服务，截至目前情感分析服务已经为美团内部十多个业务场景提供服务。

属性级情感分析已经在美团多个场景落地应用，但对于某些领域跨度较大的新场景（比如从餐饮领域到休闲娱乐领域），我们总是需要人工预定义新的属性，并进行一定数量的数据标注。预定义属性需要对每个业务都有深入的理解，在实际中，很难把每个业务的属性都预定义得非常全面，尤其是某些占比不高但具有业务特色的属性。这些成本会对属性级情感分析在新业务场景的快速落地有一定程度的影响。我们也在探索迁移学习、少样本学习、属性自动挖掘等技术在情感分析上的应用，以加速情感分析在新领域快速应用，来满足美团业务的快速发展需求。

参考文献

[1] https://github.com/Meituan-Dianping/asap.

[2] Bu J, Ren L, Zheng S, et al. ASAP: A Chinese Review Dataset Towards Aspect Category Sentiment Analysis and Rating Prediction. In Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2021.

[3] https://www.luge.ai/

[4] Zhang, L. , S. Wang , and B. Liu . “Deep Learning for Sentiment Analysis : A Survey.” Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery (2018):e1253.

[5] Liu, Bing. “Sentiment analysis and opinion mining.” Synthesis lectures on human language technologies 5.1 (2012): 1-167.

[6] Peng, Haiyun, et al. “Knowing what, how and why: A near complete solution for aspect-based sentiment analysis.” In Proceedings of the AAAI Conference on Artificial Intelligence. Vol. 34. No. 05. 2020.

[7] Zhang, Chen, et al. “A Multi-task Learning Framework for Opinion Triplet Extraction.” In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: Findings. 2020.

[8] Yoon Kim. 2014. Convolutional neural networks for sentence classification. arXiv preprint arXiv:1408.5882.

[9] Peng Zhou, Wei Shi, Jun Tian, Zhenyu Qi, Bingchen Li,Hongwei Hao, and Bo Xu. 2016. Attention-based bidirectional long short-term memory networks for relation classification. In Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), pages 207 - 212.

[10] Devlin, Jacob, et al. “Bert: Pre-training of deep bidirectional transformers for

language understanding." arXiv preprint arXiv:1810.04805 (2018).
[11] 杨扬、佳昊等 . 美团 BERT 的探索和实践 .
[12] Pontiki, Maria, et al. "Semeval-2016 task 5: Aspect based sentiment analysis." International workshop on semantic evaluation. 2016.
[13] Pontiki, M. , et al. "SemEval-2014 Task 4: Aspect Based Sentiment Analysis." In Proceedings of International Workshop on Semantic Evaluation at (2014).
[14] Yequan Wang, Minlie Huang, and Li Zhao. 2016. Attention-based lstm for aspect-level sentiment classification. In Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, pages 606 - 615.
[15] Sara Sabour, Nicholas Frosst, and Geoffrey E Hinton. 2017. Dynamic routing between capsules. In Advances in neural information processing systems, pages 3856 - 3866.
[16] Chi Sun, Luyao Huang, and Xipeng Qiu. 2019. Utilizing bert for aspect-based sentiment analysis via constructing auxiliary sentence. arXiv preprint arXiv:1903.09588.
[17] Qingnan Jiang, Lei Chen, Ruifeng Xu, Xiang Ao, and Min Yang. 2019. A challenge dataset and effective models for aspect-based sentiment analysis. In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), pages 6281 - 6286.
[18] Wu, Zhen, et al. "Grid Tagging Scheme for End-to-End Fine-grained Opinion Extraction." In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: Findings. 2020.
[19] Liu, Yinhan, et al. "Roberta: A robustly optimized bert pretraining approach." arXiv preprint arXiv:1907.11692 (2019).
[20] Clark, Kevin, et al. "Electra: Pre-training text encoders as discriminators rather than generators." arXiv preprint arXiv:2003.10555 (2020). 0- [21] Timothy Dozat and Christopher D. Manning. 2017.Deep biaffine attention for neural dependency parsing. In 5th International Conference on Learning Representations, ICLR 2017.

作者介绍

任磊、佳昊、张辰、杨扬、梦雪、马放、金刚、武威等，均来自美团平台搜索与 NLP 部 NLP 中心。

招聘信息

美团搜索与 NLP 部 /NLP 中心是负责美团人工智能技术研发的核心团队，使命是打造世界一流的自然语言处理核心技术和服务能力。

NLP 中心长期招聘自然语言处理算法专家 / 机器学习算法专家，感兴趣的同学可以将简历发送至 renlei04@meituan.com。具体要求如下。

岗位职责

1. 预训练语言模型前瞻探索，包括但不限于知识驱动预训练、任务型预训练、多模态模型预训练以及跨语言预训练等方向；
2. 负责百亿参数以上超大模型的训练与性能优化；
3. 模型精调前瞻技术探索，包括但不限于 Prompt Tuning、Adapter Tuning 以及各种 Parameter-efficient 的迁移学习等方向；
4. 模型 inference/training 压缩技术前瞻探索，包括但不限于量化、剪枝、张量分析、KD 以及 NAS 等；
5. 完成预训练模型在搜索、推荐、广告等业务场景中的应用并实现业务目标；
6. 参与美团内部 NLP 平台建设和推广

岗位要求

1. 2 年以上相关工作经验，参与过搜索、推荐、广告至少其一领域的算法开发工作，关注行业及学界进展；
2. 扎实的算法基础，熟悉自然语言处理、知识图谱和机器学习技术，对技术开发及应用有热情；
3. 熟悉 Python/Java 等编程语言，有一定的工程能力；
4. 熟悉 Tensorflow、PyTorch 等深度学习框架并有实际项目经验；
5. 熟悉 RNN/CNN/Transformer/BERT/GPT 等 NLP 模型并有过实际项目经验；
6. 目标感强，善于分析和发现问题，拆解简化，能够从日常工作中发现新的空间；
7. 条理性强且有推动力，能够梳理繁杂的工作并建立有效机制，推动上下游配合完成目标。

加分项

熟悉模型训练各 Optimizer 基本原理，了解分布式训练基本方法与框架；
对于最新训练加速方法有所了解，例如混合精度训练、低比特训练、分布式梯度压缩等

细粒度情感分析在到餐场景中的应用

作者：储哲 王璐 润宇 马宁 建林 张琨 刘强

一、背景

作为一家生活服务在线电子商务平台，美团致力于通过科技链接消费者和商户，努力为消费者提供品质生活。到店餐饮（简称到餐）作为美团的核心业务之一，是满足用户堂食消费需求、赋能餐饮商户在线运营的重要平台，在服务百万级别的餐饮商户和亿级别 C 端用户的过程中，积累了海量的用户评论信息（User Generated Content, UGC），包含了用户到店消费体验之后的真情实感，如果能够有效提取其中的关键的情感极性、观点表达，不仅可以辅助更多用户做出消费决策，同时也可以帮助商户收集经营状况的用户反馈信息。

近年来，大规模预训练模型（BERT）、提示学习（Prompt）等 NLP 技术飞速发展。文本分类、序列标注、文本生成各类自然语言处理任务的应用效果得到显著提升，情感分析便是其中最常见的应用形式之一。它的任务目标在于通过 NLP 技术手段对输入文本进行分析、处理、归纳、推理，给出文本情感极性判定的结果。

按照情感极性判定粒度，可以细分为篇章 / 整句粒度情感分析、细粒度情感分析（ABSA, Aspect-based Sentiment Analysis）[1]。一般而言，细粒度情感分析的任务目标主要围绕属性（Aspect Term）、观点（Opinion Term）、情感（Sentiment Polarity）三要素展开，可以拆分为属性抽取、观点抽取以及属性 – 观点对的情感倾向判定三个级联任务 [2-5]。例如，对于给定的用户评论“这家店环境不错，但服务很糟糕”，预期的输出结果为（环境，不错，正向）、（服务，糟糕，负向）。

图 1　ABSA 子任务 [5]

到餐算法团队结合到餐业务供给侧、平台侧、需求侧的业务场景，为核心业务链路的智能化提供高效、优质的算法解决方案，通过算法能力辅助业务降本提效。本文结合到餐 B/C 端业务场景，探索细粒度情感分析技术在用户评价挖掘方向的应用实践。

二、目标回顾

2.1 业务问题

秉承“帮大家吃得更好，生活更好”的使命，到餐面向消费者提供包括套餐、代金券、买单、预订等在内的丰富产品和服务，并通过黑珍珠餐厅指南、大众点评必吃榜等榜单，以及搜索、查询、评价等，帮助消费者更好地作出消费决策。同时，为商家提供一站式的营销服务，帮助餐饮商户沉淀口碑、获取用户、增加复购等，进而轻松管理餐厅。

随着餐饮连锁化加速、行业竞争格局激烈，商户管理宽幅和难度逐步加大，商户的经营要求更加精细，数据管理意识更加迫切。用户历史评论中蕴含着大量用户消费后的反馈，是情感分析的重要组成部分，不仅能够描述消费感受，同时也能反映出就餐环境的好坏。因此，做好情感分析有利于帮助餐饮门店提升服务质量，也能够更好地促进消费体验。

(a) (b) (c)

图 2　评论示例：(a) 菜品评价，(b) 服务评价，(c) 食安评价

UGC 评价分析，主要是从评论文本中挖掘出菜品、服务、食品安全（简称食安）等方面相关信息，获取用户在各个维度的细粒度情感，细致刻画商家的服务现状，如上图 2 所示。对于餐饮商户，菜品、服务、食安评价分析问题可以拆解如下：

- 菜品评价，主要包括用户评论中的菜品识别、评价属性提取、菜品观点提取、观点情感分类；
- 服务评价，主要包括用户评论中评价属性提取、服务方面观点提取、观点情感分类；
- 食安评价，主要包括用户评论中评价属性提取、食安方面观点提取、观点情感分类。

其中问题 2 和 3 是典型的三元组抽取任务，即识别服务或食安方面的（属性，观点，情感）。对于问题 1，在服务、食安评价问题的基础上，菜品评价需要识别评论中提及的菜品，相比业界四元组（属性，观点，属性类别，情感）[6] 抽取任务，到餐场景下主要为（菜品，属性，观点，情感）四元组的识别。

2.2 技术调研

在美团内部，我们针对 UGC 评价分析问题，调研了相关工作成果，主要为基于 MT-BERT 预训练模型开发了多任务模型，试图解决情感分析中的 ACSA (Aspect-Category Setiment Analysis) 问题以及（属性，观点，情感）三元组抽取问题，并实现了句子粒度的情感分类工具开发，同时开源了基于真实场景的中文属性级情感分析数据集 ASAP[7-9]。但对于美团到餐业务来说，我们需要基于具体场景提出针对性的解决方案，如四元组抽取任务，不能直接复用其他团队的相关技术和工具，因此有必要建设服务于到餐业务场景的细粒度情感分析技术。

在业界，我们也调研了行业其他团队如腾讯、阿里在细粒度情感分析方面的相关研究。2019 年腾讯 AI Lab 和阿里达摩院合作 [3]，提出了基于两个堆叠的 LSTM 和三个组件（边界引导、情感一致性和意见增强）的模型，将“BIOES”标注体系与情感正向（Positive）、中性（Neutral）、负向（Negative）结合形成统一标签，可以同时识别属性和情感。同年，阿里达摩院提出了 BERT+E2E-ABSA 模型结构，进一步解决属性和情感的联合抽取问题 [10]，同时提出（属性，观点，情感）[2] 三元组抽取任务，并给出了两阶段解决框架，首先分别识别出属性（情感融合为统一标签）和观点，然后判断属性 - 观点是否配对。

自此，业界后续研究开始向三元组联合抽取展开 [11-14]。2021 年 2 月，华为云 [6] 提出（属性，观点，属性类别，情感）四元组抽取多任务模型，其中一个任务识别属性和观点，另一个任务识别属性类别和情感。2021 年 4 月，腾讯 [15] 引入 Aspect-Sentiment-Opinion Triplet Extraction（ASOTE）任务，提出了一个位置感知的 BERT 三阶段模型，解决了（属性，观点，情感）三元组抽取问题。

调研机构	行业	预训练模型	细粒度情感分析问题	阅读理解问题	三元组问题	四元组问题	联合抽取问题
阿里达摩院 [2,10]	电子商务	√	√	X	√	X	√
华为云 [6]	云服务	√	√	X	X	√	√
腾讯 [15]	社交	√	√	X	√	X	X
美团到餐	本地生活	√	√	√	√	√	√

从学术界来看，更关注于如何更好地进行实体抽取、情感分类以及多任务的联合抽取，可能会忽略工业界落地更关注的计算时效性（如多维度标注与情感维度整合，增加计算、存储资源消耗，在有限资源下时长延迟）、效果准确性（如任务模块端到端开发，忽略业务的个性化，直接复用导致准确性降低）等方面要求，导致相关技术方法并不能直接应用于业务场景，需要进一步开发完善才能实现业务的落地。

如上表所示，针对以上调研，我们借鉴了美团搜索与 NLP 部在三元组细粒度情感分析方面的经验，拆解到餐四元组抽取问题，并结合学界最先进的阅读理解、注意力机制等方面的实体抽取、情感分类经验，设计开发了应用于到餐业务的细粒度情感分析解决方案。

2.3 技术目标

如上文所述，菜品评价主要关注菜品、评价属性、菜品观点和观点情感，而服务、食安评价问题，主要关注服务或食安方面的评价属性、观点和情感。就细粒度情感分析任务而言，可以看出，前一个问题涉及四元组信息，而后两个问题仅涉及三元组信息。

假设给定一个长度为n的句子x_i，令$T_n=\{(d,a,o,s)\}$和$T_m=\{(a,o,s)\}$，$T_n=\{(d,a,o,s)\}$表示句子x_i中标注的菜品实体$(d,\underline{dish})$、评价属性$(a,\underline{aspect})$、观点$(o,\underline{opinion})$和情感极性$(s,\underline{sentiment})$，其中情感包括{正向，中性，负向，未提及}。$T_m=\{(a,o,s)\}$表示句子$x_i$中标注的服务或食安方面的评价属性、观点和情感。

对于菜品评价，训练集为$D_n=\{(x_i,T_n)\}$，似然函数为：

$$L(D_n)=\prod_{i=1}^{|D_n|}\prod_{(d,a,o,s)\in T_n}P((d,a,o,s)|x_i), \qquad (1)$$

进一步，对数似然函数为：

$$\begin{aligned} l(D_n)&=\sum_{i=1}^{|D_n|}\sum_{(d,a,o,s)\in T_n}logP((d,a,o,s)|x_i)\\ &=\alpha\sum_{i=1}^{|D_n|}\sum_{d\in T_n}logP(d|x_i)+\beta\sum_{i=1}^{|D_n|}\sum_{d\in T_n}\sum_{a\in T_n|d}logP(a|d,x_i)+\gamma\sum_{i=1}^{|D_n|}\sum_{d\in T_n}\sum_{a\in T_n|d}\left(\lambda_1\sum_{o\in T_n|d,a}logP(o|d,a,x_i)+\lambda_2\sum_{s\in T_n|d,a}logP(s|d,a,x_i)\right) \end{aligned} \qquad (2)$$

其中，超参数$(\alpha,\beta,\gamma,\lambda_1,\lambda_2)\in[0,1]$。由公式(2)可推测，四元组细粒度情感分析问题可以拆解为：给定文本的菜品实体抽取、描述菜品的评价属性抽取、评价属性对应的观点抽取以及情感分类。

对于服务、食安评价，训练集为$D_m=\{(x_i,T_m)\}$，似然函数为：

$$L(D_m)=\prod_{i=1}^{|D_m|}\prod_{(a,o,s)\in T_m}P((a,o,s)|x_i), \qquad (3)$$

进一步，对数似然函数为：

$$\begin{aligned} l(D_m)&=\sum_{i=1}^{|D_m|}\sum_{(a,o,s)\in T_m}logP((a,o,s)|x_i)\\ &=\alpha\sum_{i=1}^{|D_m|}\sum_{a\in T_m}logP(a|x_i)+\beta\sum_{i=1}^{|D_m|}\sum_{a\in T_m}\left(\lambda_1\sum_{o\in T_n|a}logP(o|a,x_i)+\lambda_2\sum_{s\in T_n|a}logP(s|a,x_i)\right) \end{aligned} \qquad (4)$$

其中，超参数$(\alpha,\beta,\lambda_1,\lambda_2)\in[0,1]$。由公式(4)可推测，三元组问题可以拆解为：给定文本的服务或食安属性抽取、评价属性对应的观点抽取以及情感分类。

特别地，公式(2)和(4)最后一项成立的原因是给定属性a条件下，o与s是条件独立的，即$P(o,s|a,x_i)=P(o|a,x_i)*P(s|a,x_i)$，目标是最大化对数似然函数。总而言之，基于联合概率分布拆解，能够将复杂问题拆分为多个简单问题建模。基于以上分析，建立菜品、服务、食安维度等细粒度情感分析模型。算法的目标就是通过菜品评价、服务评价以及食安评价的建模，从UGC文本中挖掘用户评论信息，如用户消费偏好、用户就餐环境以及场景反馈等。值得一提的是这里提到的四元组(d,a,o,s)和三元组(a,o,s)，不仅仅解决以上场景的问题，而是具有更强的泛化性，对于类似场景的细粒度情感分析也同样适用。

在细粒度情感分析中，训练、测试数据$D_n=\{(x_i,T_n)\}$主要来源于UGC标注数据。其中，假设UGC文本间标注是独立的，则任意取一定数据的UGC文本进行测试，其余标注为训练样本，进行模型训练。技术评估指标是任务的准确率、召回率以及多类别平均F1值。此外，业务层面主要依赖于文本抽取标签的Badcase率反映算法的准确性。

2.4 主要挑战

由于三元组问题可以看作是四元组问题的子问题，不失一般性，下文将重点阐述四元组相关技术挑战。

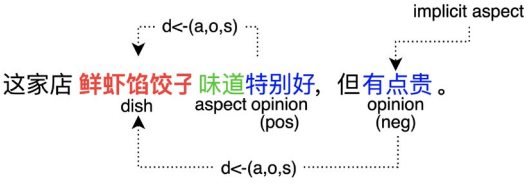

图 3　到餐细粒度情感分析中的 UGC 示例

如图3的示例所示，提取的四元组为"鲜虾馅饺子-口味-特别好-正向"和"鲜虾馅饺子-(?)-有点贵-负向"。在到餐场景中，UGC文本细粒度情感分析较复杂，主要存在挑战：给定一条评论，可能包含多个四元组(d, a, o, s)且存在实体间一对多或者多对一的关系，以及可能存在a缺失情况；如何准确识别用户所有细粒度评论情感倾向？对于以上挑战，可以拆解为如下问题。

问题1：如何准确识别可能存在的多个四元组?

对于一条存在多个四元组的评论，通过序列标注，直接同时识别多个四元组是不现实的。为此，我们在标注数据预处理时，将评论中四元组分别抽取，各自组成一条独立样本，进行训练、预测。此外，如上文所述，四元组的实体间存在一对多或者多对一的关系，而且实体间的间距通常不固定，存在远程抽取的可能。针对这一问题，一个较有效的实践经验是进行分层分块抽取，即pipeline识别。基于pipeline的方法，如公式(2)所示，则需要分别处理：给定文本，菜品实体抽取 $(P(d|x_i))$、描述菜品的评价属性抽取 $(P(a|d,x_i))$、评价属性对应的观点抽取 $(P(o|d,a,x_i))$ 以及情感分类 $(P(s|d,a,x_i))$。

定义交叉熵损失函数为：

$$f_{CE}(\hat{y}_{i,k}, y_{i,k}) = -\frac{1}{n}\sum_{i=1}^{n}\sum_{k}\hat{y}_{i,k}log(y_{i,k}) \qquad (5)$$

其中，$\hat{y}_{i,k}$表示每个模块真实label分布，k表示分类类别数。

那么，当前问题的损失函数集合为

$$\begin{aligned} L(D_n)|_{i=1,2,...,|D_n|} &= \left(L_{d|x_i}, L_{a|d,x_i}, L_{o|d,a,x_i}, L_{s|d,a,x_i}\right) \\ &= \left(f_{CE}(\hat{P}_{d|x_i}, P_{d|x_i}), f_{CE}(\hat{P}_{a|d,x_i}, P_{a|d,x_i}), f_{CE}(\hat{P}_{o|d,a,x_i}, P_{o|d,a,x_i}), f_{CE}(\hat{P}_{s|d,a,x_i}, P_{s|d,a,x_i})\right) \end{aligned} \qquad (6)$$

其中，目标$min\ L(D_n)$，将分别针对每一个任务进行逐个最小化。

问题2：如何解决aspect有缺失的四元组识别?

如图3所示，真实场景可能存在四元组的评价属性缺失。针对这类问题，我们将问题拆解为三个任务：给定评价文本，菜品实体抽取 $(P(d|x_i))$、评价观点抽取 $(P(o|d,x_i))$ 以及观点和情感的分类 $(P(c_a, s|d,o,x_i))$ ，其中c_a是隐藏评价属性的类别。则损失函数为：

$$\begin{aligned} L(D_n)|_{i=1,2,...,|D_n|} &= (L_{d|x_i}, L_{o|d,x_i}, L_{c_a,s|d,o,x_i}) \\ &= \left(f_{CE}(\hat{P}_{d|x_i}, P_{d|x_i}), f_{CE}(\hat{P}_{o|d,x_i}, P_{o|d,x_i}), f_{CE}(\hat{P}_{c_a,s|d,o,x_i}, P_{c_a,s|d,o,x_i})\right) \end{aligned} \qquad (7)$$

问题 3：如何同时对四元组抽取、识别，减少 pipeline 方法的错误累计影响?

减少 pipeline 方法的错误累计影响，典型的解决方案是提出同时处理信息抽取和分类任务，即多任务学习。传统的方法是直接尝试多任务学习的思路，但过程中忽略了实体间依赖的关系，甚至远程关联关系 [2]。当前也在尝试直接将四元组转化成多任务学习过程，将来期望通过建立实体间 pair 或 triplet 关系，进行联合抽取、识别。

综上，对于**问题 1** 和**问题 2**，我们会按照 pipeline 识别的结果，再利用策略进行抽取结果的优化；对于**问题 3**，整合实体、关系及分类任务，进行联合学习，将有助于减少 pipeline 方法的错误累计影响。

三、细粒度情感分析实践

3.1 Pipeline 方法

如上文 2.3 的问题 2 所述，我们采用 pipeline 的方法，将四元组抽取问题拆解为三个任务，分为实体识别、观点抽取、观点类别和情感分类，如下图 4 所示：

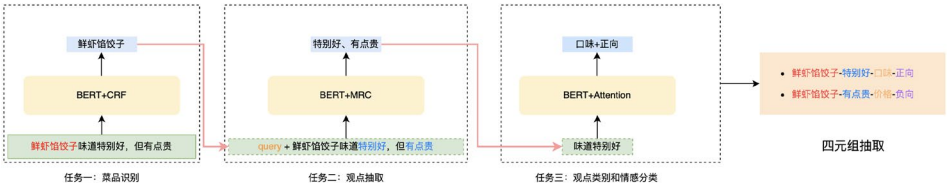

图 4 三阶段模型

3.1.1 实体识别

自 2018 年 BERT[16] 出现以后，NER 模型由传统的 LSTM+CRF 替换为 BERT+CRF（或者 BERT+LSTM+CRF），一度是业界 NER 任务的 SOTA 模型，近两年来 NER 任务主要从以下两个方面进行改进：

- 加入额外的特征 [17-19]：如字特征、词特征、词性特征、句法特征、知识图谱表征；
- 转换任务形式 [20-21]：将 NER 任务转化为问答（QA, Question Answering）任务或者机器翻译任务。

考虑到引入额外特征需要构建人工词典，以及转化问答任务形式依赖于人工模板，成本较高，因此采用 BERT+CRF 模型。

学习率调整，模型策略调优。在实验过程中，我们发现 BERT+CRF 相比简单的 BERT+Softmax 效果提升甚微，究其原因，由于预训练模型经过微调之后可以学习到具有明显区分度的特征，导致增加 CRF 层对实体识别结果几乎没有影响。然而，一个好的 CRF 转移矩阵显然对预测是有帮助的，可以为最后预测的标签添加约束来保证预测结果的合理性。进一步实验后发现，通过调整 BERT 和 CRF 层的学习率，如 BERT 使用较小的学习率而 CRF 层使用 100 倍于 BERT 的学习率

（即 e2/e1>100，如图 5 所示），最终 BERT+CRF 的效果相比 BERT+Softmax 有了较明显的提升。此外，在传统 NER 模型 LSTM+CRF 基础上，我们也实验了 BERT+LSTM+CRF，但效果居然有些许下降，而且预测时间也增加了，因此最终没有引入 LSTM 层。

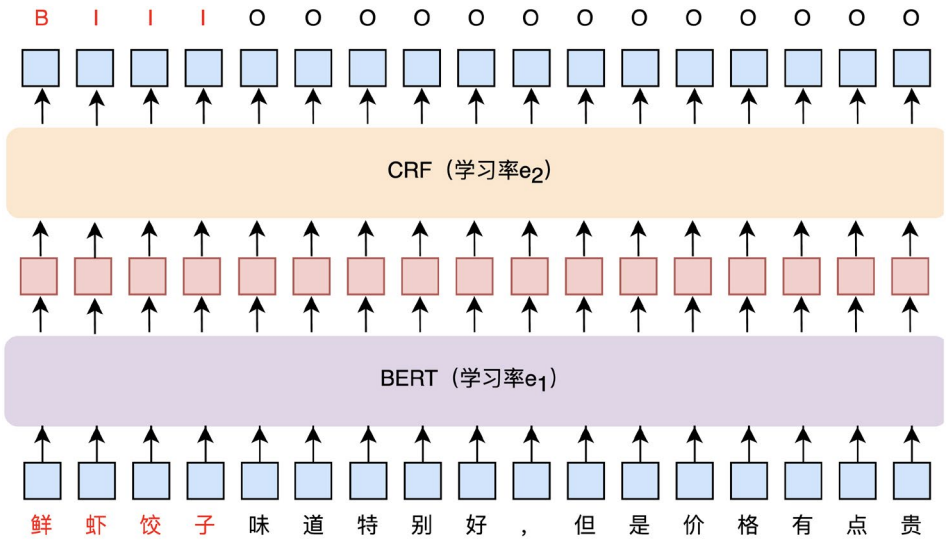

图 5　BERT+CRF（BIO 标记）

3.1.2 观点抽取

观点抽取任务在业界也称为 Target-oriented Opinion Words Extraction（TOWE），旨在从评论句子中抽取出给定目标对应的观点词。观点抽取也可以看作是一种 NER 任务，但若评论涉及多个实体和观点，如何准确抽取所有“实体 - 观点”关系是一个技术挑战。借鉴 MRC（Machine Reading Comprehension）任务的思想，通过构建合理的 Query 引入先验知识，辅助观点抽取。

QA 任务形式，观点抽取建模。如图 6 所示，模型整体由预训练层和输出层两部分组成。输出层我们使用了常规 QA 任务输出，包括开始标签（Start Label）和结束标签（End Label），但需要人工设计 Quey。参考论文 [20] 经验，以图 3 为例，实验发现 Query 设计为“找出鲜虾馅饺子口味、口感、分量、食材、卖相、价格、卫生以及整

体评价”效果最好，可能融入了观点描述信息，更加有助于观点抽取。考虑到 QA 任务天然有类别不平衡的问题，因此损失函数引入针对类别不平衡的 Focal Loss，用于提升观点抽取模型的效果。由于观点抽取也可以看作是 NER 任务，故我们尝试将输出层设计为 CRF 层，但实验效果并不理想，可能由于观点语句长度不一且比较个性化，影响模型识别。另一方面，考虑到 Google 中文预训练模型 BERT 是以字粒度为切分，没有考虑到传统 NLP 中的中文分词，在预训练层我们将 BERT 模型替换为哈工大开源的中文预训练模型，如 BERT-wwm-ext、RoBERTa-wwm 等，最终模型效果取得进一步提升。

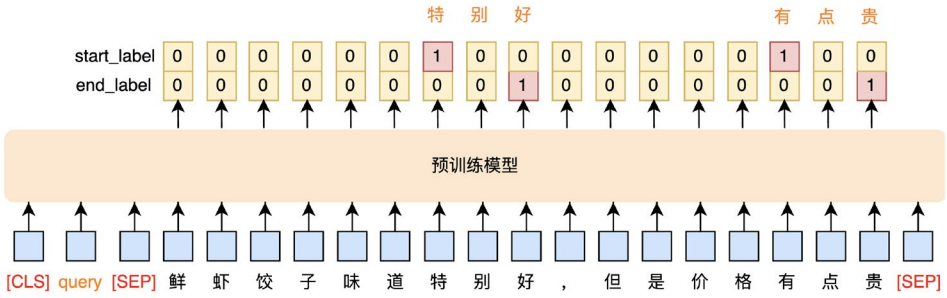

图 6　BERT+MRC（通过开始标签和结束标签，抽取出观点词：特别好、有点贵）

3.1.3 观点类别和情感分类

观点类别和情感分类可以看作两个分类任务，其中菜品评价四元组任务的观点类别包含口感、口味、分量、食材、卖相、价格、卫生、菜品整体等 8 个标签，而情感包含正向、中性、负向、未提及等 4 个标签，都是业务预定义好的。考虑到用户评论提及某个菜品的观点可能涉及多个维度，若每个维度单独建模，需要构建多个模型，较复杂且维护困难。结合 ATAE-LSTM[22] 和 NLP 中心 [7-9] 情感分析的经验和到餐业务特点，模型整体结构设计为多任务多分类学习框架。

多任务多分类模型，联合建模观点类别和情感。如图 7 所示，模型整体分为两个部分，分别为 BERT 共享层和 Attention 独享层，其中 BERT 共享层学习观点 Embedding 表示，Attention 独享层学习观点在各个观点类别的情感倾向。考虑到评论中各部分会聚焦不同的观点维度，通过引入 Attention 结构，使得模型更加关注特定维度相关的

文本信息，进而提升整体效果。

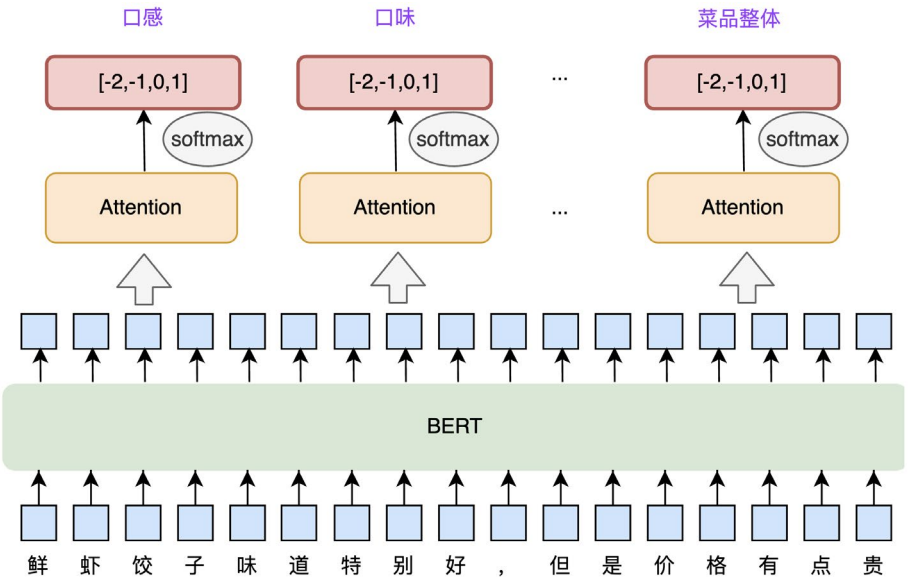

图 7　BERT+Attention

3.2 联合学习

pipeline 方法的优点是将目标问题拆分为多个子模块问题，对子模块分别优化，通过后处理能在一定程度上解决实体间多对多关系的问题。然而，pipeline 方法也会存在一些致命缺陷，主要包括：

- 误差传播，实体识别模块的错误会影响到观点抽取模型的性能；
- 忽略了任务之间的关联性，如实体和观点往往一起出现，如果可以知道观点，那么也能判断出所描述的实体，而 pipeline 方法显然不能利用这些信息；
- 信息冗余，由于需要对识别出来的实体都要进行观点抽取，以及提取出的观点都要进行分类，产生一些无效的匹配对，提升错误率。

参考业界情感分析联合学习现状，主要为（属性，观点，情感）三元组联合抽取。结合到餐业务场景特点（如挑战 2.3 的问题 2 所述），整体设计为两阶段模型，第一阶段为对菜品实体、观点和情感联合训练，第二阶段为对观点进行分类，进而得到四元组

识别的结果。

3.2.1 三元组联合抽取

目前在学术界，三元组（属性，观点，情感）联合抽取的方法主要包括序列标注方法[11]、QA 方法[5,12]、生成式方法[13,14]等。结合菜品分析场景和 pipeline 方法中观点抽取模块的经验，我们采取了 QA 式的联合抽取方法，主要参考模型 Dual-MRC[5]。

Dual-MRC 模型的改进，三元组联合抽取建模。在模型设计过程中，由于 Dual-MRC 模型分类情感倾向是对某个属性的整体评价，即一个属性只对应一个情感。然而，在到餐业务场景中，新增了菜品实体的识别，同时 UGC 评论中存在对同一个菜品实体包含不同观点及情感倾向。如图 3 所示，“味道特别好”表达了对“鲜虾饺子”正向情感，而“有点贵”显然表达了负面情感。因此，我们对 Dual-MRC 模型进行了改造，将观点和情感标签整合成统一标签。如图 8 所示，到餐 Dual-MRC 整体结构基于双塔 BERT 模型，通过引入两个 Query，左边负责抽取菜品实体，右边负责抽取观点和观点情感，从而实现三元组联合抽取。

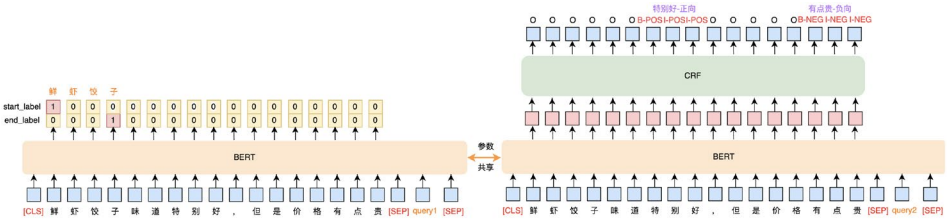

图 8　结合到餐业务特点改进的 Dual-MRC 模型

模型结构说明：

- 整体是由两个部分组成，左边 BERT 抽取菜品实体，右边 BERT 抽取观点和观点情感，将观点和情感构成统一标签 B-{POS，NEU，NEG}，I-{POS，NEU，NEG} 以及 O，其中未提及情感被整合到 O 标签中；
- 参考 pipeline 方法经验，构建两个 Quey，左边 Quey1 构建为“找出评论中的菜品”，右边 Quey2 构建为“找出鲜虾馅饺子口味、口感、分量、食材、卖相、价格、卫生以及整体评价”；

- 训练阶段，对于左边标注的每个菜品实体，都需要重复右边流程，两边模型共享参数进行训练；预测阶段，由于实体不可知，采用 pipeline 方式，首先左边部分抽取出所有的菜品实体，然后对于每个实体输入到右边部分，抽取出观点和观点情感。

在此基础上，我们也探索了四元组联合抽取的可能，具体操作为对右边 Query2 进行改造，如“找出鲜虾馅饺子口味评价”，对于每个观点类别都需要构建 Query 进行预测，从而实现四元组联合抽取。但考虑计算量级较大且耗时较长，最终将观点类别另做预测。

3.2.2 观点类别分类

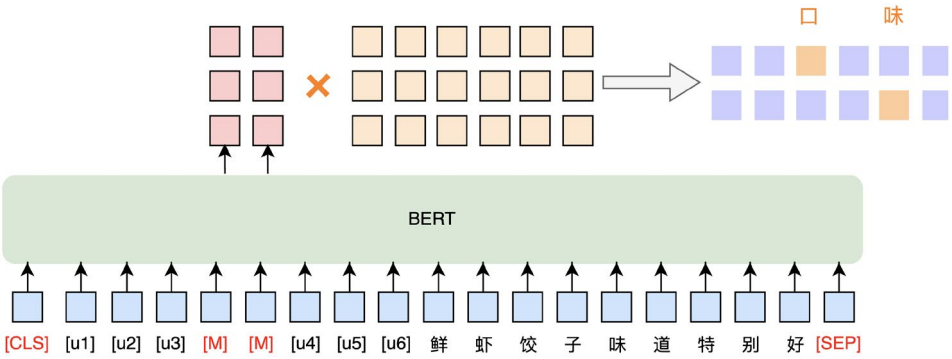

图 9　BERT+P-tuning

观点类别分类，显然是一个文本分类问题，通常做法是基于 BERT 分类，取 [CLS] 位置的 Embedding，接一个全连接层和 Softmax 层即可。在到餐业务场景中，主要面临少样本问题，参考业界 NLP 少样本解决方法，以基于对比学习的 R-drop[23] 方法和基于 Prompt[24] 的第四范式为代表。我们在 BERT 模型结构基础上，分别实验了 Prompt 模板方法（如图 9 所示）和 R-drop 数据增强（如图 10 所示）。其中，Prompt 模板主要借鉴 P-tuning[25] 的思想，采取自动化构建模板的方式，基于 MLM 任务解决问题。

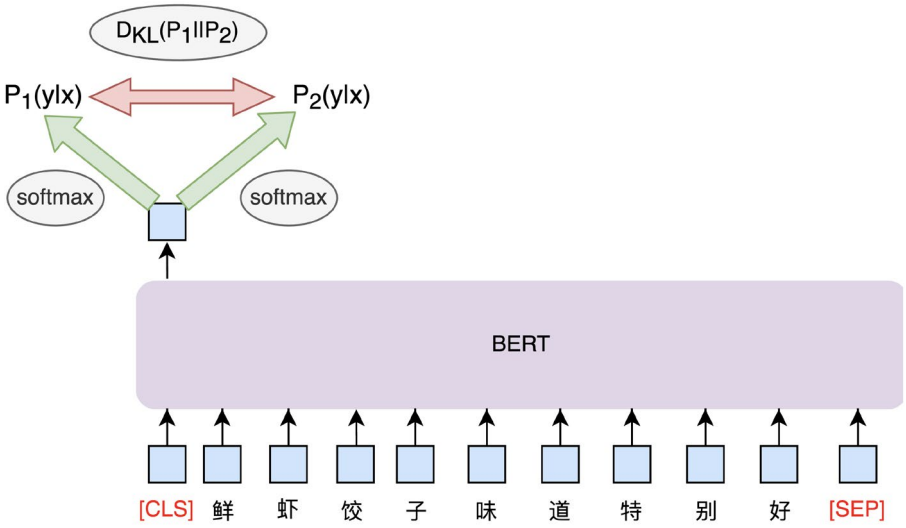

图 10　BERT+R-drop

图 9 中 [u1]~[u6] 代表 BERT 词表里边的 [unused1] ~ [unused6]，即使用未出现的 Token 构建模板，Token 数目为超参数。实验结果发现，基于 BERT 的预训练模型，结合 P-tuning 或 R-drop 结构，分类效果都能得到一定的提升，且 P-tuning 的效果略优于 R-drop，后续还会持续探索少样本解决方法。

四、在到餐业务中的应用

4.1 模型效果对比

利用到餐的 UGC 标注数据，对于四元组识别进行了整体效果测评，最终以整体四元组的精确率和召回率计算 F1 值作为性能评估指标。如图 11 所示，采用经典的 BERT+CRF 模型进行实体抽取，在到餐评论标注数据仅达到 0.61 的 F1，经过学习率等调参（Baseline Tuning）优化之后，F1 值提升 2.61%。如上文所述，在观点抽取模块中，将序列标注问题转化成问答（QA）问题后，采用 BERT+MRC 模型，F1 显著提升至 0.64，提升了 5.9%，表明问题转化获得较大收益。此外，采用哈工大中文预训练 BERT 仍取得一定幅度的提升，F1 提升至 0.65。注意，图 11 中的模型迭代表示四元组问题中重点优化模块的模型，最终评测四元组整体效果来进行对比分析。

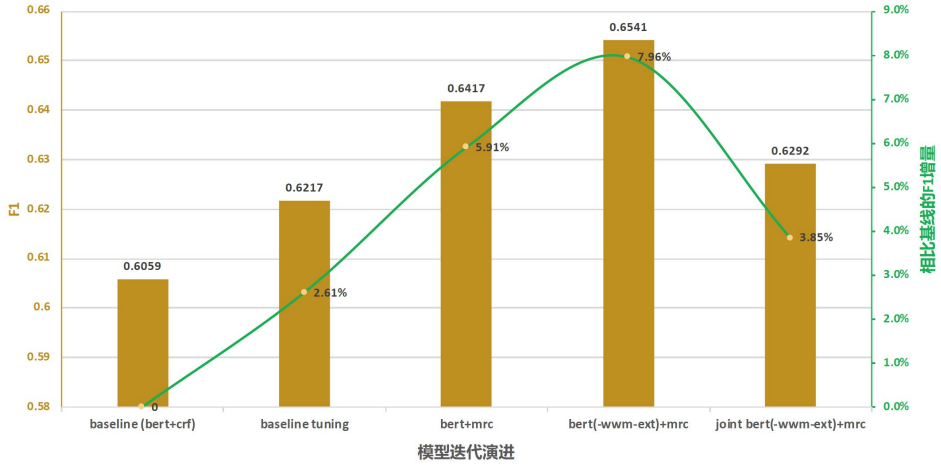

图 11　在到餐场景细粒度情感分析效果演进

4.2 业务应用场景

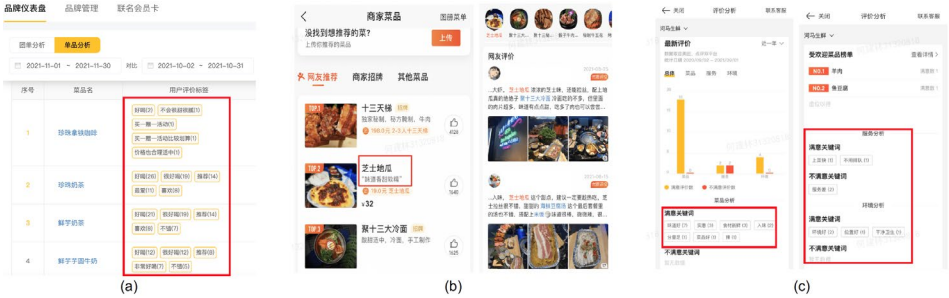

图 12　到餐场景细粒度情感分析的应用：(a) 品牌仪表盘，(b) 到餐商户菜品信息优化，(c) 开店宝评价管理

品牌仪表盘

品牌仪表盘作为旗舰店能力的重要环节，提供品牌层面的数据服务，助力生意增长。产品定位为头部餐饮品牌的数据中心，具备基础的数据披露能力，通过量化业务效果，指导商户经营决策。由于大客在平台沉淀了丰富的线上信息（大量的交易 / 流量 / 评论数据），可挖掘分析空间较大。应用细粒度情感分析技术从评论数据中挖掘菜品维度、服务维度、食品安全维度相关信息，量化商户经营表现，指导经营动作。关于菜品的用户反馈监控，品牌商户更关注菜品、口味、口感等维度的用户反馈。如上文

所述模型迭代后，菜品情感、口味情感、口感情感识别准确率都得到一定的提升。

到餐商户菜品信息优化

随着到餐加强了菜品信息建设，主要包括在生产层面上，整合了商户各来源菜品数据，建设了商户菜品中心，并优化了 C 端菜品 UGC 上传功能，有效补充 UGC 菜品生产；在消费层面上，整合了商户通菜品和网友推荐菜菜品，并基于菜品信息的完善，优化了 C 端菜品信息的内容聚合及展示消费。同时配合到餐业务，持续通过评价信息生产建设赋能，更多的引导用户从评价生产层面进行商户菜品的描述介绍。主要针对到餐商户菜品关联的评价信息，进行信息联动与展示层面的优化，相比迭代前，有评价菜品覆盖率得到较大的提升。

开店宝评价管理

商家通过提供餐饮服务来获取用户，用户消费后通过评价给商家以反馈，促使商家去不断优化，提供更好的服务，从而获取更多的用户，达到正向循环。评价分析的意义在于建立起评价和餐饮服务之间的通道，实现评价对服务的正向促进循环。通过分析评价内容，帮助商家发现餐厅在菜品、服务、环境等方面，做得好和做得不好的地方，进而针对性的改善。相比迭代前，菜品、服务、环境维度关联评论数得到很大的提升。

五、未来展望

经过近一年的建设，情感分析相关能力不但成功应用到到餐商户经营、供应链等业务，而且优化了多源菜品信息，辅助品牌商户进行用户反馈监控，提升商户服务能力。在联合学习探索上，目前主要将四元组问题转化为两阶段模型，如图 11 所示，F1 值有所下降，仅达到 0.63。究其原因，可能是在三元组联合抽取模型中，忽略了实体间的关系，尤其长程关系（如上文 2.4 的问题 3 所述），导致性能不足预期。接下来，将进一步提升情感分析四元组抽取能力，挖掘 UGC 中用户的核心需求以及重要反馈。在技术方面，将持续进行模型迭代演进，主要涉及：

- **持续优化现有模型，保证质量的同时也要提升效率**

  实验结果还有很大的改进空间，需要进一步探索模型优化方法，如优化预训练模型，使用 MT-BERT 等，以及在联合抽取中进一步引入实体间关系，来提升四元组抽取的性能。

- **深度探索情感分析领域，建设四元组联合抽取模型**

  主要通过改造 Query 实现四元组抽取，但是计算量级较大，需要探索模型结构优化，减少冗余的计算量，使其满足四元组联合抽取。

- **建设细粒度情感分析通用框架**

  到餐场景涉及多个情感分析场景，需要建设灵活方便的通用框架，有助于快速支持业务，以及减少资源消耗。

未来，团队将持续优化应用技术，解决到餐业务场景中的情感分析需求。细粒度情感分析是具有挑战和前景的任务，到店餐饮算法团队将和各位读者共同持续探索和研究。

六、参考文献

[1] Liu, B. 2012. Sentiment analysis and opinion mining. Synthesis lectures on human language technologies 5(1):1 – 167.

[2] Peng, H. Xu, L. Bing, L. Huang, F. Lu, W. and Si, L.2020. Knowing What, How and Why: A Near Complete Solution for Aspect-Based Sentiment Analysis. In AAAI, 8600 – 8607.

[3] Li, X. Bing, L. Li, P. and Lam, W. 2019a. A unified model for opinion target extraction and target sentiment prediction. In AAAI, 6714 – 6721.

[4] Zhao, H. Huang, L. Zhang, R. Lu, Q. and Xue, H. 2020. SpanMlt: A Span-based Multi-Task Learning Framework for Pair-wise Aspect and Opinion Terms Extraction. In ACL, 3239 – 3248.

[5] Y. Mao, Y. Shen, C. Yu, and L. Cai. 2021. A joint training dual-mrc framework for aspect based sentiment analysis. arXiv preprint arXiv:2101.00816.

[6] 华为云细粒度文本情感分析及应用

[7] 杨扬、佳昊等 . 美团 BERT 的探索和实践 .

[8] 任磊，步佳昊等 . 情感分析技术在美团的探索与应用 .

[9] Bu J, Ren L, Zheng S, et al. ASAP: A Chinese Review Dataset Towards Aspect Category Sentiment Analysis and Rating Prediction. In Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational

Linguistics: Human Language Technologies. 2021.
[10] Xin Li, Lidong Bing, Wenxuan Zhang, and Wai Lam. Exploiting BERT for end-to-end aspect-based sentiment analysis. In W-NUT@EMNLP, 2019.
[11] Xu, L. Li, H. Lu, W. and Bing, L. 2020. Position-Aware Tagging for Aspect Sentiment Triplet Extraction. In EMNLP, 2339 – 2349.
[12] Chen, S. Wang, Y. Liu, J. and Wang, Y. 2021a. Bidirectional Machine Reading Comprehension for Aspect Sentiment Triplet Extraction. In AAAI.
[13] Yan, H. Dai, J. Qiu, X. Zhang, Z. et al. 2021. A Unified Generative Framework for Aspect-Based Sentiment Analysis. arXiv preprint arXiv:2106.04300.
[14] Wenxuan Zhang, Xin Li, Yang Deng, Lidong Bing, and Wai Lam. 2021. Towards Generative Aspect-Based Sentiment Analysis. In ACL/IJCNLP 2021, 504 – 510.
[15] Li Yuncong, Fang Wang, Zhang Wenjun, Sheng-hua Zhong, Cunxiang Yin, & Yancheng He. 2021. A More Fine-Grained Aspect-Sentiment-Opinion Triplet Extraction Task. arXiv: Computation and Language.
[16] Devlin, J. Chang, M.-W. Lee, K. and Toutanova, K. 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In NAACL-HLT, 4171 – 4186.
[17] Yue Zhang and Jie Yang. 2018. Chinese ner using lattice lstm. arXiv preprint arXiv:1805.02023.
[18] Li, X. Yan, H. Qiu, X. and Huang, X. 2020. FLAT: Chinese NER Using Flat-Lattice Transformer. arXiv preprint arXiv:2004.11795 .
[19] Tareq Al-Moslmi, Marc Gallofr é Ocaña, Andreas L. Opdahl, and Csaba Veres. 2020. Named entity extraction for knowledge graphs: A literature overview. IEEE Access 8 (2020), 32862 – 32881.
[20] X. Li, J. Feng, Y. Meng, Q. Han, F. Wu, and J. Li. 2020. A unified MRC framework for named entity recognition. In ACL, 5849 – 5859.
[21] Jana Strakova, Milan Straka, and Jan Hajic. 2019. Neural architectures for nested ner through linearization. In Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, 5326 – 5331.
[22] Yequan Wang, Minlie Huang, Li Zhao, and Xiaoyan Zhu. 2016. Attention-based lstm for aspect-level sentiment classification. In Proceedings of the conference on empirical methods in natural language processing, 606 – 615.
[23] Liang X, Wu L, Li J, et al. R-Drop: Regularized Dropout for Neural Networks[J]. arXiv preprint arXiv:2106.14448, 2021.
[24] P. Liu, W. Yuan, J. Fu, Z. Jiang, H. Hayashi, and G. Neubig. 2021. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing. arXiv preprint arXiv:2107.13586.
[25] X. Liu, Y. Zheng, Z. Du, M. Ding, Y. Qian, Z. Yang, and J. Tang. 2021. Gpt understands, too. arXiv preprint arXiv:2103.10385.

七、术语解释

术语	解释
ABSA	细粒度情感分析，Aspect-based Sentiment Analysis
NER	命名实体识别，Named Entity Recognition
TOWE	面向目标的观点词抽取，Target-oriented Opinion Words Extraction
MRC	阅读理解，Machine Reading Comprehension
MLM	语言掩码模型，Masked Language Model
BERT	基于变换器的双向编码器表示，Bidirectional Encoder Representations from Transformers
CRF	条件随机场，Conditional Random Fields
LSTM	长短期记忆，Long Short-Term Memory
R-drop	基于 dropout 的正则策略，regularization strategy upon dropout

八、作者介绍

储哲、王璐、润宇、马宁、建林、张琨、刘强，均来自美团到店事业群 / 平台技术部。

九、招聘信息

美团到店平台技术部的到餐业务数据策略组菜品知识图谱方向主要负责将菜品知识应用到到餐相关业务，使命是为到餐业务提供高效、优质、智能的应用算法解决方案。基于海量的到餐业务数据，应用前沿的实体抽取、关系挖掘、实体表征学习、细粒度情感分析、小样本学习、半监督学习等算法技术，为到餐业务提供算法能力支持。

业务数据策略组菜品知识图谱方向长期招聘自然语言处理算法专家 / 机器学习算法专家，感兴趣的同学可以将简历发送至 hejianlin@meituan.com。

预训练技术在美团到店搜索广告中的应用

作者：邵雯　杨扬　春喜　任磊　晓俊　金刚

引言

美团到店搜索广告负责美团、大众点评双平台站内搜索流量的商业变现，服务于到店餐饮、休娱亲子、丽人医美、酒店旅游等众多本地生活服务商家。在美团搜索场景中广告的展示样式非常原生，用户使用美团服务不会明显区分广告和自然结果，而广告用户体验损失则会显著影响搜索流量。因此，搜索广告除了优化流量变现效率等商业指标外，也需要重点优化用户体验，不断降低不相关广告对用户体验的损害，这样才能保证整个平台生态长期健康地发展。

在优化用户体验的目标下，如何正确的衡量用户体验，定义不相关广告是首要解决的问题。在搜索广告中，受结果列表页广告位置偏差、素材创意等因素影响，我们无法单一使用点击率（CTR）等客观性指标来衡量用户体验，尤其首位、首屏等排序靠前广告的相关性问题被认为是影响用户体验的主要因素。因此，我们首先建立了美团场景下的搜索广告相关性标准和评估体系，主要通过例行采样和人工评估的方式对搜索广告结果进行相关、一般和不相关的分档标注，进而驱动我们的广告相关性模型和策略迭代。然后，使用广告排序前五位的 Badcase 率（即 Badcase@5）作为搜索广告的相关性评估指标。

问题与挑战

在定义出广告相关性问题和评估指标后，使用相关性模型进行搜索关键词（Query）和候选广告（Doc）的相关性打分，类似于 NLP 文本匹配任务，但实际建模中也发现若干困难。美团搜索结果以商户门店（POI）粒度展示，即 Doc 除了 POI 文本外，还包含一系列的团单或商品描述，内容非常丰富但也带来较多冗余或歧义，且不同业务的文本表达差异较大，比如结婚类商品“朱颜【出门出阁红色秀禾】，南国【中式婚

礼嫁衣红色秀禾]”，给广告内容编码带来挑战。

其次，美团广告商户大多没有选择竞价关键词，且 POI 和团单标题并未面向搜索优化，Doc 内容与 Query 可能存在文本表达偏差。比如“满月酒”和“嗨派星球宝宝宴 · 游轮派对，生日宴个性气球拱门”，需要处理这类信息缺失的问题。我们最初采用 ESIM[1] 交互式模型，但实践中发现该模型对我们复杂广告内容的表征能力有限，正负样本区分能力不足，在过滤不相关广告的同时对相关广告的误伤率较高。自 2018 年底以来，以 BERT[2] 为代表的预训练模型在多项 NLP 任务上都取得了突破，我们也开始探索预训练技术在搜索广告相关性上的应用。

业界及美团的解决方案

针对搜索语义匹配任务，Google[3] 和 Bing[4] 的搜索团队已经基于 BERT 来编码 Query 和候选 Doc，进而改善相关性的效果。预训练模型在美团内部的 NLP 场景中也有不少落地实践，美团搜索已经验证了预训练模型在文本相关性任务上的有效性 [5]。

而针对预训练在语义匹配任务中的应用，业界也提出不少的解决方案。中科院计算所郭嘉丰等人提出 PROP[6] 和 B-PROP[7] 等针对搜索任务的预训练方法，主要思想是引入文档中代表词预测 ROP（Representative wOrds Prediction）任务。纽约大学石溪分校曹庆庆等人提出 DeFormer[8] 分解预训练语言模型来做问答等语义匹配任务，在 BERT 的低层分别对问题和文档各自编码，再在高层部分拼接问题和文档的表征进行交互编码，让文档和问题在编码阶段尽可能地独立，从而提升模型的整体效率。百度刘璟等人提出 RocketQA[9] 和 RocketQAv2[10] 等面向端到端问答的检索模型训练方法，通过跨批次负采样、去噪的强负例采样以及数据增强技术大幅提升了双塔模型的效果。陈丹琦等人提出 SimCSE[11]，采用自监督来提升模型的句子表示能力，从而提升语义匹配的效果。

另一方面，2020 年至今，预训练从“大炼模型”迈向了“炼大模型”的阶段，通过设计先进的算法，整合尽可能多的数据，汇聚大量算力，集约化地训练超大模型，持续提升模型效果。不论是公开论文结果还是美团内部实践，均已证明：更大规模的预

训练模型能带来更好的下游任务效果。因此，美团广告平台与美团搜索与 NLP 部进行了合作，尝试利用预训练模型来优化搜索关键词和广告结果的相关性，进一步降低首屏广告 Badcase，提升用户体验。

本文分为算法探索、应用实践和总结规划三个部分，对预训练技术在搜索广告相关性的落地方案进行介绍。在算法探索部分介绍了我们在训练样本上的数据增强、预训练（Pre-training）和微调（Fine-tuning）阶段的模型结构优化；在应用实践部分，本文介绍了以知识蒸馏为主的模型压缩方法、相关性服务链路优化方案，以及所取得的业务效果；最后，我们总结了相关性方面的优化方法，并对未来技术探索进行了展望。希望这些经验和思考能够给从事相关研究的同学带来一些帮助或启发。

算法探索

在美团搜索广告场景中，相关性计算可以看做用户搜索意图（Query）和广告商户（POI/Doc）之间的匹配问题，实践中我们采用了能够从多角度衡量匹配程度的集成方法，具体方案为分别基于 Query 和 POI 的结构化信息匹配、文本匹配和语义匹配等方法进行打分并且进行分数融合。其中，结构化信息匹配主要是对 Query 分析结果与 POI 进行类目、属性等信息的匹配；文本匹配方面借鉴了搜索引擎中的传统相关性方法，包括 Query 和 POI 的 term 共现数、Query term 覆盖率、TF-IDF、BM25 打分等；语义匹配包括传统的隐语义匹配（如基于 LDA 或者 Word2Vec 计算相似度）和深度语义匹配方法。在广告相关性服务中，我们采用学习能力更强的深度语义匹配模型。

深度语义匹配通常分为表示型和交互型两类：表示型模型一般基于双塔结构分别得到两段输入文本的向量表示，最后计算两段文本表示的相似度；该方法的优点是 Doc 向量可提前离线计算缓存，且匹配阶段计算速度很快，适合线上应用；缺点是只在模型最后阶段进行交互，对文本之间匹配关系学习不足。而交互型模型在初期即对两段输入文本进行交互，匹配阶段可以采用更复杂的网络结构，以学习文本间细粒度匹配关系；这种方法往往可以达到更高的精度，主要挑战在于线上应用的性能瓶颈。

美团搜索广告相关性服务的基线模型采用 Transformer+ESIM 的交互式模型结构，在满足性能的前提下有效解决了部分相关性问题，但是实际应用中仍然存在一些不足，主要包括：1. 训练数据中存在标签错误、正负样本分布不一致等问题；2.Doc 除了基础门店信息外还关联了大量商品和团单内容，如果直接将这些信息拼接成长文本作为 Doc 输入，由于模型结构限制往往需要对 Doc 文本进行截断，因而导致信息丢失；3. 基线模型对于长文本的表征能力有限，相关性判别能力不足，很难在控制变现效率影响的同时解决更多的 Badcase。

为了解决这些问题，我们基于 BERT 在训练数据、特征构造和模型方面进行若干探索和实践。下文将逐一展开介绍。

数据增强

由于 BERT 模型微调阶段所需数据量相比 ESIM 模型更少，并且对数据覆盖全面度、标签准确度、数据分布合理性等因素更为敏感，在进行模型结构探索前，我们先按照如下思路产出一份可用性较高的数据。搜索广告涉及的业务众多且差异性大，包含的团单和商品种类多元，我们希望 BERT 的微调数据尽可能覆盖各个场景和主要服务。如果全部人工标注人力和时间成本较高，而用户点击转化行为能一定程度反映出广告是否相关，所以训练数据主要基于曝光点击日志构造，对于部分困难样本加以规则及人工校验。我们根据业务特性对训练数据的主要优化包括以下几点。

正样本置信加权

正样本主要通过点击数据得到，我们对 4 个月内的 Query-POI 点击数据进行统计，并且基于曝光频次和 CTR 进行数据清洗以减少噪声。实际采样流程中，假设对于某个 Query 需要取 N 个 POI 构造 N 条正样本，采样过程中令 POI 被采样的概率与其点击数成正比，这样做主要是基于点击越多相关性越高的认知，既可以进一步保证标签置信，又有利于模型学习到 POI 之间不同的相关程度。

在实验中我们也尝试了另外两个正样本采样方法：1) 对某个 Query 随机取 N 个 POI，2) 对某个 Query 取点击最多的 N 个 POI。实践发现方法 1 会采样到较多的弱

相关样本，而方法 2 得到的大多为强相关样本，这两种方式均不利于模型拟合真实场景的数据分布。

负采样分层

我们按照模型学习的困难程度，从低到高设计了三种负样本采样方式：

- **全局随机负样本**：大多为跨业务的负样本（比如烧烤和密室逃脱），模型学习最容易，可以有效识别跨类目的恶劣 Badcase；
- **一级类目内负样本**：Query 和 POI 属于相同一级类目（比如美食、丽人等），但是属于不同细化类目（比如祛痘和医学美容），这部分样本可以为模型学习增加一定难度，提高模型判别能力；
- **三级类目内负样本**：Query 和 POI 属于相同的细化类目，但是 POI 并不提供 Query 相关的服务（比如光子嫩肤和水光针商户），这部分属于困难负样本，可以提升模型对语义相近但服务不相关的 Badcase 的判别能力，更大程度保障用户体验；但是在三级类目下采样可能取到较多相关样本，所以这部分样本还需要经过基于服务核心词的规则过滤以及人工校验。

采样平滑及分布一致性

- **采样平滑**：在正样本构建过程中对 Query 采样频次做了平滑，避免高频 Query 采样过多，导致模型忽略对中长尾 Query 样本的学习。
- **样本分布一致性**：在负样本构建中，对于每种负样本均需要保证各 Query 出现概率与其在正样本中概率相等，避免样本分布不一致性导致模型学习有偏。

文本关键词提取

美团搜索广告场景下，Query 中可能包含地址词、品牌词、服务核心词等多种成分，Query 文本一般较短，90% 以上的 Query 长度小于 10；POI 的主要文本特征包括门店名称和商品信息，而广告主的商品数量普遍较多，直接拼接商品标题会导致 POI 文本过长，有 26% 的 POI 文本长度超过 240。

由于相关性模型的主要目标是学习 Query 和 POI 之间的服务相关性，大量冗余文本

信息会影响模型性能和学习效果，我们对 Query 和 POI 文本进行如下处理以提取关键文本信息：

- **对于 Query 文本**：基于命名实体识别（NER）和词权重结果过滤掉地址词、分店名等成分，保留服务核心词；
- **对于 POI 文本**：对所有商品标题进行关键词抽取，得到一组能反映商户核心服务的关键词，将其拼接作为 POI 文本。相比直接拼接原始商品文本，长度大幅下降，仅有 5% 的 POI 长度超过 240，并且 POI 文本质量更高，模型学习效果更好。

最终，我们的微调样本包括约 50 万条数据，涵盖餐饮、休娱、亲子和丽人等 20 个主要类目，其中正负样本比例为 1:5，三种负样本比例为 2:2:1。

模型优化

基于多任务学习的多业务模型

由于美团搜索广告涉及餐饮、休娱亲子、丽人医美等大量业务场景，并且不同场景之间差异较大。从过去的实践经验可知，对于某个业务场景下的相关性优化，利用该业务数据训练的子模型相比利用全业务数据训练的通用模型往往效果更佳，但这种方法存在几个问题：1) 多个子模型的维护和迭代成本更高；2) 某些小场景由于训练数据稀疏难以正确学习到文本表示。

受到多业务子模型优缺点的启发，我们尝试了区分业务场景的多任务学习，利用 BERT 作为共享层学习各个业务的通用特征表达，采用对应不同业务的多个分类器处理 BERT 输出的中间结果，实际应用中根据多个小场景的业务相似程度划分成 N 类，亦对应 N 个分类器，每个样本只经过其对应的分类器。多业务模型的主要优势在于，能够利用所有数据进行全场景联合训练，同时一定程度上保留每个场景的特性，从而解决多业务场景下的相关性问题，模型结构如下图 1 所示：

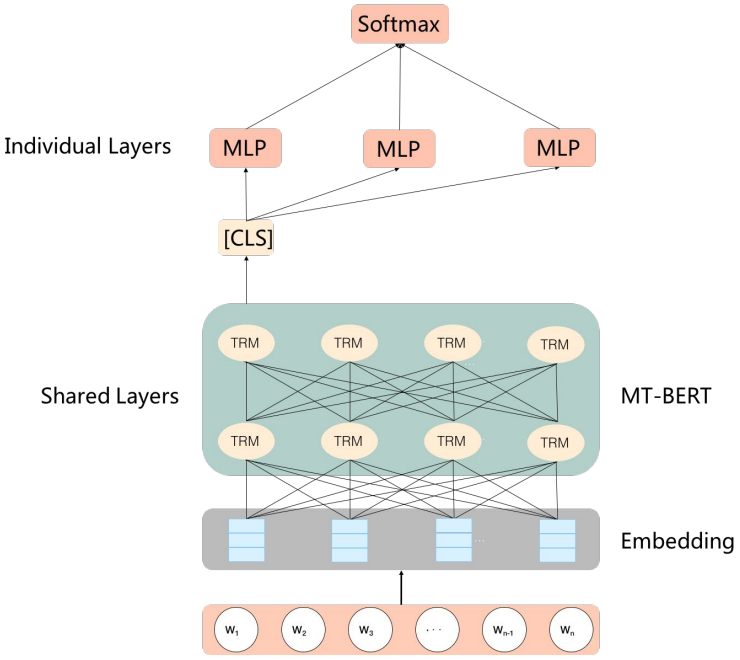

图 1　多业务模型结构

引入品类信息的预训练

由于美团商户 POI 和商品标题可能缺乏有效信息表达，有时仅根据 Query 和 POI 商品文本很难准确判断两者之间的语义相关性。例如【租车公司，< 上水超跑俱乐部；宝马，奥迪 > 】，Query 和 POI 文本的相关性不高，而该商户的三级品类是“养车 – 用车租车 – 租车”，我们认为引入品类信息有助于提高模型效果。

为了更合理的引入品类信息，我们对 BERT 模型的输入编码部分进行改造，除了与原始 BERT 一致的 Query、Doc 两个片段外，还引入了品类文本作为第三个片段，将品类文本作为额外片段的作用是防止品类信息对 Query、Doc 产生交叉干扰，使模型对于 POI 文本和品类文本区别学习。

下图 2 为模型输入示意图，其中红色框内为品类片段的编码情况，Ec 为品类片段的片段编码（Segment Embedding）。由于我们改变了 BERT 输入部分的结构，无法直接基于标准 BERT 进行相关性微调任务。我们对 BERT 重新进行预训练，并对预

训练方式做了改进，将 BERT 预训练中用到的 NSP（Next Sentence Prediction）任务替换为更适合搜索广告场景的点击预测任务，具体为“给定用户的搜索关键词、商户文本和商户品类信息，判断用户是否点击”。预训练数据采用自然及广告搜索曝光点击数据，大约 6 千万样本。

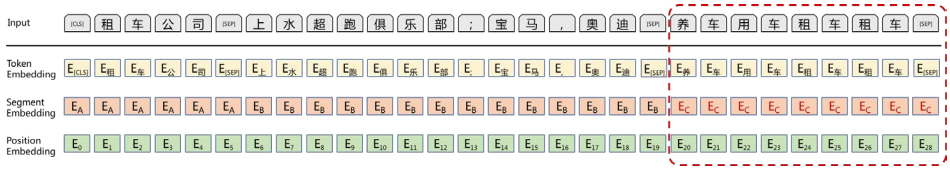

图 2　BERT 输入部分引入 POI 品类信息

模型优化离线效果

为了清晰准确地反映模型迭代的离线效果，我们通过人工标注的方法构建了一份广告相关性任务 Benchmark。基线 ESIM 模型、BERT 模型以及本文提到的优化后 BERT 模型在 Benchmark 上的评估指标如下表 1 所示：

Model	Accuracy	AUC	F1-Score
ESIM（基线，旧训练数据）	67.73%	76.94%	72.62%
MT-BERT-Base	74.88%	82.65%	75.85%
MT-BERT-Base- 多业务	75.41%	83.03%	76.49%
MT-BERT-Base- 引入品类信息	77.33%	83.85%	77.93%
MT-BERT-Large- 引入品类信息	77.87%	85.06%	79.14%

表 1　广告相关性任务模型优化迭代指标

我们首先利用上文介绍的数据增强后的训练样本训练了 MT-BERT-Base 模型（12 层 768 维），与 ESIM 模型相比，各项指标均显著提升，其中 AUC 提升 6.6PP。在 BERT 模型优化方面，多任务学习和引入品类信息这两种方式均能进一步提升模型效果，其中引入品类信息的 MT-BERT-Base 模型效果更佳，相比标准的 MT-BERT-Base 模型 AUC 提升 1.2PP。

在 BERT 模型规模方面，实验发现随着其规模增长，模型效果持续提升，但是预训练和部署成本也相应增长，最终我们选取了大约 3 亿参数量的 MT-BERT-Large 模型（24 层 1024 维），在同样引入品类信息的条件下，相比 MT-BERT-Base 模型 AUC 增长 1.21PP，相比 ESIM 模型 AUC 增长 8.12PP。

应用实践

在模型的实践落地过程中，我们也遇到若干挑战，并且针对性的设计了优化方案。第一个挑战是 BERT 模型的前向耗时无法满足线上性能要求，我们通过知识蒸馏和低精度量化方法对模型进行压缩，并且采用离线缓存与实时预测结合的方式进一步提升了服务性能。

另一个挑战是，在广告业务场景下，需要综合考虑平台变现效率、用户体验、商户供给及转化等因素，如何使相关性分数在广告整体链路中发挥出更好的作用。我们目前采用了低质量广告过滤、重排阶段考虑相关性因子以及 TOP 位次广告门槛控制等策略。下文对应用实践方面的具体方案进行介绍。

模型压缩

由于 BERT 模型的庞大参数量和前向预测耗时，直接部署上线会面临很大的性能挑战，通常需要将训练好的模型压缩为符合一定要求的小模型，业内常用模型压缩方案包括模型裁剪、低精度量化和知识蒸馏等。知识蒸馏 [12] 旨在有效地从大模型（教师模型）中迁移知识到小模型（学生模型）中，在业内得到了广泛的研究和应用，如 HuggingFace 提出的 DistillBERT[13] 和华为提出的 TinyBERT[14] 等蒸馏方法，均在保证效果的前提下大幅提升了模型性能。

经过在搜索等业务上的探索和迭代，美团 NLP 团队沉淀了一套基于两阶段知识蒸馏的模型压缩方案，包括通用型知识蒸馏和任务型知识蒸馏，具体过程如下图 3 所示。在通用型知识蒸馏阶段，使用规模更大的预训练 BERT 模型作为教师模型，对学生模型在无监督预训练语料上进行通用知识蒸馏，得到通用轻量模型，该模型可用于初

始化任务型知识蒸馏里的学生模型或直接对下游任务进行微调。在任务型知识蒸馏阶段，使用在有监督业务语料上微调的 BERT 模型作为教师模型，对学生模型在业务语料上进行领域知识蒸馏，得到最终的任务轻量模型，用于下游任务。实验证明，这两个阶段对于模型最终效果的提升都至关重要。

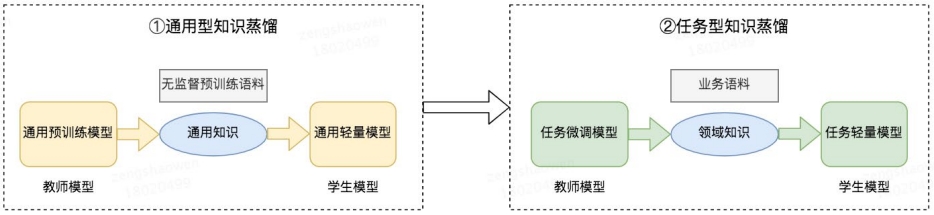

图 3　两阶段知识蒸馏

在美团搜索广告场景下，首先我们基于 MT-BERT-Large（24 层 1024 维）在大规模无监督广告语料上进行第一阶段通用型知识蒸馏，得到 MT-BERT-Medium（6 层 384 维）通用轻量模型，在下游的广告相关性任务上进行微调。MT-BERT-Medium 属于单塔交互结构，如图 4(a) 所示。

目前，每个 Query 请求会召回上百个 POI 候选，交互模型需要分别对上百个 Query-POI 对进行实时推理，复杂度较高，很难满足上线条件。常见解决方案是将交互模型改造成如图 4(b) 所示的双塔结构，即分别对 Query 和 POI 编码后计算相似度。由于大量候选 POI 编码可以离线完成，线上只需对 Query 短文本实时编码，使用双塔结构后模型效率大幅提升。我们使用通用型蒸馏得到的 MT-BERT-Medium 模型对双塔模型中 Query 和 POI 的编码网络进行初始化，并且在双塔在微调阶段始终共享参数，因此本文将双塔模型记为 Siamese-MT-BERT-Medium（每个塔为 6 层 384 维）。双塔结构虽然带来效率的提升，但由于 Query 和 POI 的编码完全独立，缺少上下文交互，模型效果会有很大损失，如表 2 所示，Siamese-MT-BERT-Medium 双塔模型相比 MT-BERT-Medium 交互模型在相关性 Benchmark 上各项指标都明显下降。

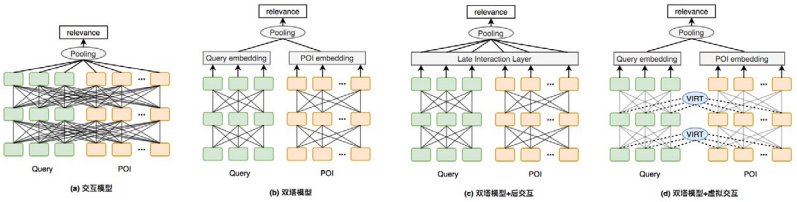

图 4　相关性模型结构对比

为了充分结合交互结构效果好和双塔结构效率高的优势，Facebook Poly-encoder[15]、斯坦福大学 ColBERT[16] 等工作在双塔结构的基础上引入不同复杂程度的后交互层（Late Interaction Layer）以提升模型效果，如图 4© 所示。后交互网络能提升双塔模型效果，但也引入了更多的计算量，在高 QPS 场景仍然很难满足上线要求。针对上述问题，在第二阶段任务型知识蒸馏过程中，我们提出了虚拟交互机制（Virtual InteRacTion mechanism, VIRT），如图 4(d) 所示，通过在双塔结构中引入虚拟交互信息，将交互模型中的知识迁移到双塔模型中，从而在保持双塔模型性能的同时提升模型效果。

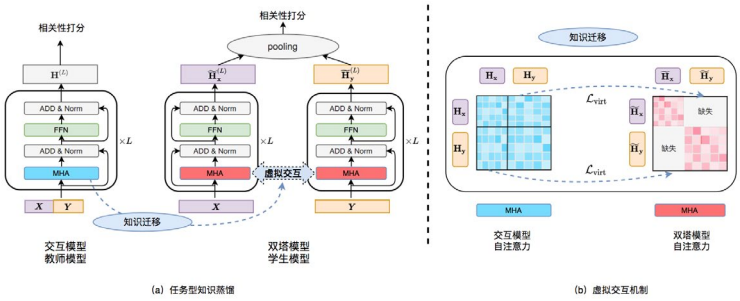

图 5　任务型知识蒸馏 & 虚拟交互

任务型知识蒸馏及虚拟交互的具体过程如上图 5 所示。在任务型知识蒸馏阶段，我们首先基于 MT-BERT-Large 交互模型在业务语料上进行微调得到教师模型。由于学生模型 Siamese-MT-BERT-Medium 缺乏上下文交互，如图 5(b) 所示，注意力矩阵中的灰色部分代表了 2 块缺失的交互信息，我们通过虚拟交互机制对缺失部分进行模拟，计算公式如下为：

$$\widetilde{\mathbf{M}}_{\mathbf{x}\to\mathbf{y}} = \mathrm{softmax}\Big(\mathrm{Attention}(\widetilde{\mathbf{H}}_{\mathbf{x}}\widetilde{\mathbf{W}}_q, \widetilde{\mathbf{H}}_{\mathbf{y}}\widetilde{\mathbf{V}}_k)\Big)$$

$$\widetilde{\mathbf{M}}_{\mathbf{y}\to\mathbf{x}} = \mathrm{softmax}\Big(\mathrm{Attention}(\widetilde{\mathbf{H}}_{\mathbf{y}}\widetilde{\mathbf{V}}_q, \widetilde{\mathbf{H}}_{\mathbf{x}}\widetilde{\mathbf{W}}_k)\Big)$$

其中，$\widetilde{\mathbf{H}}_{\mathbf{x}}$和$\widetilde{\mathbf{H}}_{\mathbf{y}}$分别代表双塔模型中Query和POI表示，$\widetilde{\mathbf{W}}$和$\widetilde{\mathbf{V}}$分别是Query和POI进行编码时的模型参数，$\widetilde{\mathbf{M}}_{\mathbf{x}\to\mathbf{y}}$代表了$\widetilde{\mathbf{H}}_{\mathbf{x}}$到$\widetilde{\mathbf{H}}_{\mathbf{y}}$的注意力（即图5(b)右上角缺失部分），$\widetilde{\mathbf{M}}_{\mathbf{y}\to\mathbf{x}}$代表了$\widetilde{\mathbf{H}}_{\mathbf{y}}$到$\widetilde{\mathbf{H}}_{\mathbf{x}}$的注意力（即图5(b)左下角缺失部分）。而交互模型包含了Query和POI的全交互，计算公式为：

$$\begin{aligned}\mathbf{S} &= \mathrm{Attention}(\mathbf{H}\mathbf{W}_q,\ \mathbf{H}\mathbf{W}_k)\\ &= \mathrm{Attention}((\mathbf{H}_{\mathbf{x}}, \mathbf{H}_{\mathbf{y}})\mathbf{W}_q,\ (\mathbf{H}_{\mathbf{x}}, \mathbf{H}_{\mathbf{y}})\mathbf{W}_k)\\ &= \begin{bmatrix}\mathbf{S}_{\mathbf{x}\to\mathbf{x}} & \mathbf{S}_{\mathbf{x}\to\mathbf{y}}\\ \mathbf{S}_{\mathbf{y}\to\mathbf{x}} & \mathbf{S}_{\mathbf{y}\to\mathbf{y}}\end{bmatrix}\end{aligned}$$

其中，$\mathbf{H}$是交互模型中Query和POI的融合表示，可以分解为$\mathbf{H}_{\mathbf{x}}$和$\mathbf{H}_{\mathbf{y}}$，分别代表Query和POI，$\mathbf{W}$是模型参数。交互模型的自注意力矩阵可以分解为4个部分，其中$\mathbf{S}_{\mathbf{x}\to\mathbf{y}}$和$\mathbf{S}_{\mathbf{y}\to\mathbf{x}}$则是Query和POI之间的交互，也即双塔模型的缺失部分。我们对交互模型的交互矩阵和双塔模型的虚拟交互矩阵之间的L2距离进行最小化，从而将交互模型中的核心交互知识迁移到双塔模型中，计算过程为：

$$\mathbf{M}_{\mathbf{x}\to\mathbf{y}} = \mathrm{softmax}(\mathbf{S}_{\mathbf{x}\to\mathbf{y}})\mathbf{M}_{\mathbf{y}\to\mathbf{x}} = \mathrm{softmax}(\mathbf{S}_{\mathbf{y}\to\mathbf{x}})$$

$$\mathcal{L}_{\mathrm{virt}} = \left\|\widetilde{\mathbf{M}}_{\mathbf{x}\to\mathbf{y}} - \mathbf{M}_{\mathbf{x}\to\mathbf{y}}\right\|_2 + \left\|\widetilde{\mathbf{M}}_{\mathbf{y}\to\mathbf{x}} - \mathbf{M}_{\mathbf{y}\to\mathbf{x}}\right\|_2$$

我们对蒸馏阶段各个模型进行了 Benchmark 上的效果评估以及线上 QPS=50 时的性能测试，结果如表 2 所示。通过虚拟交互进行任务型知识蒸馏得到的任务轻量模型 Siamese-MT-BERT-Medium 相较于直接对通用轻量模型进行微调得到的同结构的 Siamese-MT-BERT-Medium（W/O 任务型知识蒸馏）模型，各项效果指标明显提升，其中 Accuracy 提升 1.18PP，AUC 提升 1.66PP，F1-Score 提升 1.54PP。最终我们对任务轻量模型 Siamese-MT-BERT-Medium 进行上线，相较于最初的 MT-BERT-Large 模型，线上推理速度提升 56 倍，完全满足线上服务的性能要求。

Model	模型规模 / 模型结构	Accuracy	AUC	F1-Score	参数量	耗时
MT-BERT-Large	24 层 1024 维 / 交互	77.87%	85.06%	79.14%	340M	227.5ms
通用轻量模型：MT-BERT-Medium	6 层 384 维 / 交互	77.62%	84.79%	78.63%	21M	16.8ms
Siamese-MT-BERT-Medium（w/o 任务型知识蒸馏）	6 层 384 维 / 双塔	74.23%	81.65%	75.37%	21M	4.0ms
任务轻量模型：Siamese-MT-BERT-Medium	6 层 384 维 / 双塔	75.41%	83.31%	76.91%	21M	4.0ms

表 2　模型效果对比

相关性服务链路优化

相关性计算

为了更好地衡量广告召回结果的相关程度，除了基于模型得出的语义相关性之外，我们还计算了文本相关性、类目相关性等分数，并对所有分数进行融合得到最终的相关性分数。其中，文本相关性的计算借鉴了搜索引擎场景的检索相关性方法，例如 Query 和 POI 的字符串包含关系、短语匹配数和匹配率、以及 BM25 分等。

另外，文本匹配同时考虑了原串匹配、核心词匹配及同义词匹配等多维度指标；类目相关性主要基于 Query 意图分类和商户类目信息进行匹配。分数融合模型可以选择 LR 或者 GBDT 等复杂度比较低的模型，并基于高质量标注数据集训练得到。

相关性应用

通过模型结构和分数融合策略的迭代优化可以得到更加准确合理的相关性分数，但是在实际的相关性应用中，还需要紧密结合广告业务场景，综合考虑平台变现效率、用户体验、广告主供给及转化等多方面因素。基于“减少低质量的不相关广告”和“相关广告排序应该尽量靠前”两个基本要求，我们设计了几种相关性分数的具体应用方式：

- **过滤低质量广告**：完全不相关的广告无疑会严重影响用户体验，需要进行过滤。考虑到不同召回策略和不同业务流量在变现效率及 Badcase 严重程度等方面存在差异，过滤阈值被设计成召回策略 × 类目的二维超参矩阵；
- **重排序参考相关性**：在广告系统的竞价排序模块，在考虑点击率、转化率、交易额和出价等因素的同时，也需要考虑相关性分数；
- **TOP 位次相关性门槛**：首位、首屏等排序靠前的广告结果对于用户体验影响更大，因此针对 TOP 位次设置了相关性门槛，进一步改善用户体验。

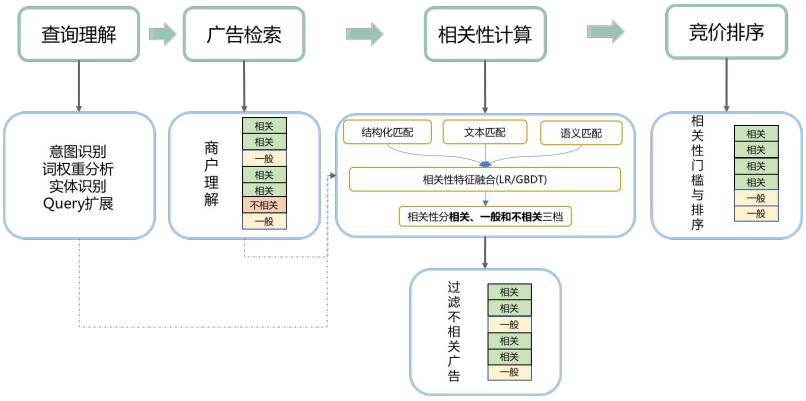

图 6　相关性服务链路示意图

模型部署

为了进一步提升服务性能并且能有效利用计算资源，模型部署阶段我们采用高频流量缓存、长尾流量实时计算的方案。对高频 Query–POI 对进行离线相关性计算并写入缓存，每日对新增或商品信息变化的 Query–POI 对进行增量计算并更新缓存，线上相关性服务优先取缓存数据，如果失效则基于蒸馏后的任务轻量模型进行实时计算。对于输入相关性服务的 Query–POI 对，缓存数据的覆盖率达到 90% 以上，有效缓解了在线计算的性能压力。

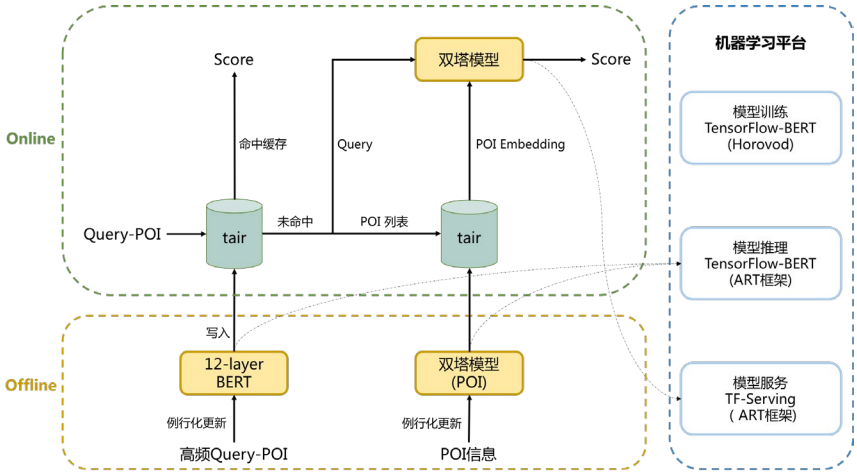

图 7　相关性分数离线 / 在线计算流程图

线上实时计算的任务轻量模型使用 TF-Serving 进行部署，TF-Serving 预测引擎支持使用美团机器学习平台的模型优化工具—ART 框架（基于 Faster-Transformer 改进）进行加速，在将模型转为 FP16 精度后，最终加速比可达到 5.5，数值平均误差仅为 5e-4，在保证精度的同时极大地提高了模型预测的效率。

线上效果

为了更加直接客观地反映线上广告相关性情况，我们建立了美团场景下的搜索广告相关性标准和评估体系，对搜索关键词和广告结果进行相关、一般和不相关的分档标注，采用排序前五位广告的 Badcase 率（即 Badcase@5）作为搜索广告的相关性评估核心指标。

除此之外，由于 CTR 能够通过用户行为间接反映广告的相关程度，并且便于在线上进行 AB 实验评估，而 NDCG 可以反映相关性分数用于广告列表排序的准确性，所以我们选取 CTR 和 NDCG 作为间接指标来辅助验证相关性模型迭代的有效性。我们对本文的优化进行了线上小流量实验，结果显示，实验组 CTR 提升 1.0%，覆盖率降低 1.0%，变现效率基本没有损失。并且经过人工评测，Badcase@5 降低 2.2PP，NDCG 提升 2.0PP，说明优化后的相关性模型能够对召回广告列表进行更加准确的校验，有效提升了广告相关性，从而给用户带来更好的搜索体验。

下面列举了两个 Badcase 解决示例，图 8(a) 和 8(b) 分别包含了搜索“登记照”和“头皮 SPA”时的基线返回结果（左侧截图）和实验组返回结果（右侧截图），截图第一位是广告结果。在这两个示例中，实验组相关性模型将不相关结果“麻朵新生儿摄影”和“莲琪科技美肤抗衰中心”检测出来并过滤掉，让相关广告得以首位展示曝光。

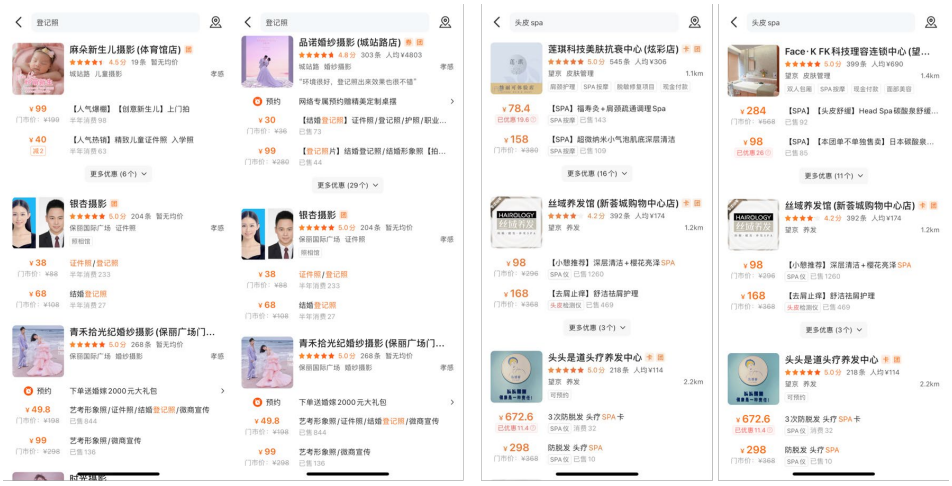

图 8　Badcase 解决示例

总结与展望

本文介绍了预训练技术在美团到店搜索广告相关性上的应用，主要包括样本数据增强、模型结构优化、模型轻量化及线上部署等优化方案。在数据增强方面，为了基于曝光点击数据构造出适合美团广告场景下相关性任务的训练数据，我们构造了多种类型负样本，在采样时考虑正样本置信度、关键词频率平滑、正负样本均衡等因素，另外也对 POI 和团单商品文本进行关键词抽取得到更加简短有效的文本特征。

在模型结构优化方面，我们尝试了对不同业务场景做多任务学习，以及在 BERT 输入中引入品类文本片段这两种方案使模型更好地拟合美团搜索广告业务数据，并利用规模更大的预训练模型进一步提升了模型的表达能力。

在实践应用中，为了同时满足模型效果和线上性能要求，我们对中高频流量进行离线打分和缓存，并且利用 MT-BERT-Large 蒸馏得到的双塔模型进行线上实时预测以覆盖长尾流量。最终，在保证广告平台收入的前提下，有效降低了搜索广告 Badcase 率，提升了用户在平台的搜索体验。

目前，广告相关性打分主要应用于阈值门槛，目的是端到端的过滤掉不相关广告，从

而快速降低广告 Badcase。在此基础上，我们期望相关性模型继续提升区分相关和一般相关广告的能力，从而在重排序中作为排序因子更好的平衡变现效率和用户体验指标，更准确的度量用户体验损失和变现效率提升的兑换关系。此外，在本地搜索类场景下，局部供给经常比较匮乏，实际召回效果对比全局供给的情况更依赖相关性打分的能力，所以我们依然需要在相关性模型上持续深入迭代，并支撑广告召回模型和策略的进一步优化。

在具体技术方向上，相关性门槛阈值设置、广告长文本表达和业务知识融合等方面依然存在优化和提升空间：

- **阈值搜索**：目前的阈值策略需要对每个类目分别调参，缺乏整体性且难以达到全局优化效果。我们正在实验将阈值搜索看作可变现流量上的最优化问题，在限定消耗损失及其他业务约束的条件下，找到一组门槛阈值使得整体 Badcase 解决最大化，并已经取得初步的效果。
- **特征表达**：目前广告 Doc 特征主要采用团单商品标题的关键词抽取结果，但是 Doc 文本仍然较长并且存在一些冗余信息，有必要对 Doc 信息抽取方法继续探索，比如融合外部知识进行信息抽取，或者通过优化 Transformer 注意力机制使模型在相关性打分时更加关注某些重要词项或者行业相关的关键词。
- **联合优化**：Query 和 POI 文本中的蕴含的类目信息、实体成分等对于判断相关性很有帮助，我们计划将相关性任务与搜索广告场景下其他任务联合优化，比如命名实体识别、Query 类目识别等，期望通过引入辅助任务增强模型的学习能力，更全面准确的学习语义相关性。

参考资料

[1] Chen, Qian, et al. “Enhanced lstm for natural language inference.” arXiv preprint arXiv:1609.06038 (2016).
[2] Devlin, Jacob, et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.” arXiv preprint arXiv: 1810.04805 (2018).
[3] Pandu Nayak, “Understanding searches better than ever before.” Google blog (2019).
[4] Wenhao Lu, et al. “TwinBERT: Distilling Knowledge to Twin-Structured BERT Models for Efficient Retrieval.” arXiv preprint arXiv: 2002.06275 (2020).

[5] 李勇 , 佳昊 , 杨扬等 . BERT 在美团搜索核心排序的探索和实践 .
[6] Ma, Xinyu, et al. “PROP: Pre-training with Representative Words Prediction for Ad-hoc Retrieval.” Proceedings of the 14th ACM International Conference on Web Search and Data Mining (2021).
[7] Ma, Xinyu, et al. “B-PROP: Bootstrapped Pre-training with Representative Words Prediction for Ad-hoc Retrieval.” arXiv preprint arXiv: 2104.09791 (2021).
[8] Cao, Qingqing, et al. “DeFormer: Decomposing Pre-trained Transformers for Faster Question Answering.” arXiv preprint arXiv:2005.00697 (2020).
[9] Qu, Yingqi, et al. “RocketQA: An Optimized Training Approach to Dense Passage Retrieval for Open-Domain Question Answering.” arXiv preprint arXiv: 2010.08191 (2021).
[10] Ren, Ruiyang, et al. “RocketQAv2: A Joint Training Method for Dense Passage Retrieval and Passage Re-ranking.” arXiv preprint arXiv: 2110.07367 (2021).
[11] Gao, Tianyu, et al. “SimCSE: Simple Contrastive Learning of Sentence Embeddings.” arXiv preprint arXiv: 2104.08821 (2021).
[12] Hinton, Geoffrey, Oriol Vinyals, and Jeff Dean. “Distilling the knowledge in a neural network.” arXiv preprint arXiv:1503.02531 (2015).
[13] Sanh, Victor, et al. “DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter.” arXiv preprint arXiv:1910.01108 (2019).
[14] Jiao, Xiaoqi, et al. “Tinybert: Distilling bert for natural language understanding.” arXiv preprint arXiv:1909.10351 (2019).
[15] Humeau, Samuel, et al. “Poly-encoders: Transformer architectures and pre-training strategies for fast and accurate multi-sentence scoring.” arXiv preprint arXiv:1905.01969 (2019).
[16] Khattab, Omar, and Matei Zaharia. “Colbert: Efficient and effective passage search via contextualized late interaction over bert.” Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. (2020).

作者简介

邵雯、春喜、晓俊、程佳、雷军等，来自美团广告平台技术部。
杨扬、任磊、金刚、武威等，来自美团平台 / 搜索与 NLP 部。

美团智能客服核心技术与实践

作者：会星

客服是在用户服务体验不完美的情况下，尽可能帮助体验顺畅进行下去的一种解决办法，是问题发生后的一种兜底方案。而智能客服能让大部分简单的问题得以快速自助解决，让复杂问题有机会被人工高效解决。在用户服务的全旅程中，美团平台 / 搜索与 NLP 部提供了问题推荐、问题理解、对话管理、答案供给、话术推荐和会话摘要等六大智能客服核心能力，以期达到低成本、高效率、高质量地与用户进行沟通的目的。本文主要介绍了美团智能客服核心技术以及在美团的实践。

1. 背景

目前，美团的年交易用户量为 6.3 亿，服务了 770 万生活服务类商家。此外，在美团优选业务中还有一个很大的团长群体。美团平台涵盖吃、住、行、游、购、娱等 200 多个生活服务品类，在平台服务的售前、售中、售后各个环节，都有大量信息咨询、订单状态获取以及申诉投诉等沟通诉求。另外，作为一家拥有几万名员工的上市企业，员工之间亦有大量的沟通诉求。面对以上这些需求，如果都是通过人力进行实现，显然不符合公司长远发展的目标，这就需要引入智能客服。

交互立方

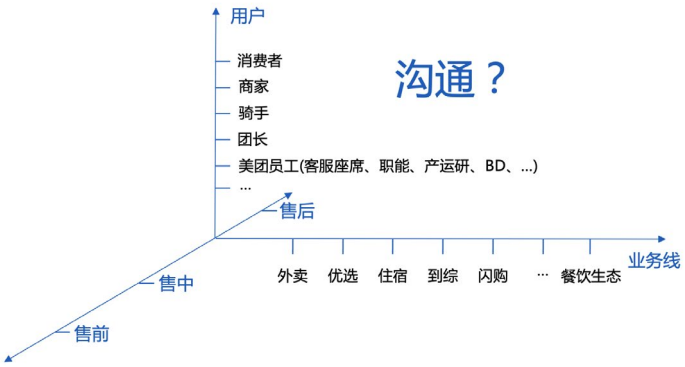

1.1 面对不同场景的智能客服落地

首先，我们看看日常生活中几种最为常见的客服场景。

- **售前场景**：比如消费者在平台选择入住酒店，对房型价格、酒店设施、入退房政策等，下单前都有很强的信息咨询诉求。
- **售中场景**：比如外卖催单还没到，添加备注不要辣、加开发票等咨询等等，售前和售中场景主要发生在消费者和商家或平台之间。
- **售后场景**：比如外卖场景投诉菜品少送、骑手送餐超时、要求退款等，酒店场景投诉酒店到店无法入住等，售后往往涉及到客服座席、消费者、骑手和商家，需要多方协同解决。
- **办公场景**：比如 IT、人力资源、财务、法务等咨询，产运研对提供的接口产品的咨询答疑，产品对销售顾问的答疑，以及销售顾问对商家的答疑等等。

1.2 面对不同人群的智能客服落地

沟通是人类的一项基本需求，在绝大多数场景下，我们对沟通的追求都是以低成本、高效率和高质量为目标，而对话机器人也需要同时满足这三点要求。目前我们按照服务的群体进行划分，智能客服落地场景大体可以分为以下四类：

- **面向用户**：提供智能客服机器人，来帮助他们自助解决大部分的问题。
- **面向座席**：用话术推荐或者会话摘要等能力来提升人工座席的工作效率，改善人工座席的工作体验。
- **面向商家**：打造商家助手来降低商家回复的费力度，改善消费者和商家的沟通体验。
- **面向员工**：通过对话机器人，可以自助给员工进行答疑，从而提升办公效率。

1.3 智能客服是什么

要回答智能客服是什么，可以先看看客服是什么。我们的理解是，客服是在用户服务体验不完美的时候，来帮助体验顺畅进行下去的一种解决办法，是问题发生后的一种兜底方案。而智能客服能让大部分简单的问题得以快速自助解决，让复杂问题有机会被人工高效解决。

上图展示的是用户服务旅程。首先，用户会通过在线打字或者拨打热线电话的方式进线寻求服务，其中在线咨询流量占比在 85% 以上。当用户进入到服务门户后，先是用户表达需求，然后是智能机器人响应需求，过程中机器人先要理解问题，比如是追加备注或是修改地址，还是申请退款等等，继而机器人尝试自助解决。如果解决不了，再及时地流转到人工进行兜底服务。最后，当用户离开服务时，系统会发送调查问卷，期待用户对本次服务进行评价。

2. 智能客服核心技术

2.1 对话交互技术概述

对话交互技术概述

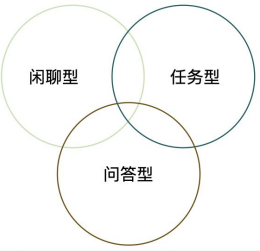

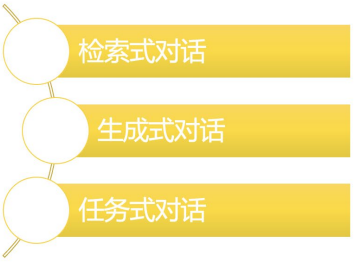

	推荐		QABot(问答)			TaskBot(任务)		ChatBot(闲聊)	
	问题推荐	商品推荐	FAQ	阅读理解	图谱问答	Taskflow	多轮话题引导	检索式话术	生成式话术
售后客服	O		O			O	O	O	O
商家助手	O	O	O	O	O	O	O	O	O
企业办公	O		O	O		O		O	

智能客服背后的技术主要是以对话交互技术为核心。常见的对话任务可分为闲聊型、任务型和问答型：

- **闲聊型**：通常是不关注某项特定任务，它的主要的目标是和人进行开放领域的对话，关注点是生成流畅、合理且自然的回复。
- **任务型**：通常是帮助用户完成某项任务指令，如查找酒店、查询订单状态、解决用户的退款申请等等。用户的需求通常比较复杂，需要通过多轮交互来不断收集任务所需的必要信息，进而根据信息进行决策，执行不同的动作，最终完成用户的指令。
- **问答型**：侧重于一问一答，即直接根据用户的问题给出精准答案。问答型和任务型最本质的区别在于，系统是否需要维护一个用户目标状态的表示和是否需要一个决策过程来完成任务。

在技术实现上，通常又可以划分为检索式、生成式和任务式：

- **检索式**：主要思路是从对话语料库中找出与输入语句最匹配的回复，这些回复通常是预先存储的数据。

- **生成式**：主要思路是基于深度学习的 Encoder-Decoder 架构，从大量语料中习得语言能力，根据问题内容及相关实时状态信息直接生成回答话术。
- **任务式**：就是任务型对话，通常要维护一个对话状态，根据不同的对话状态决策下一步动作，是查询数据库还是回复用户等等。

闲聊、问答、任务型对话本质都是在被动地响应用户需求。在具体业务中还会有问题推荐、商品推荐等来主动引导用户交互。在美团的业务场景里主要是任务型和问答型，中间也会穿插一些闲聊，闲聊主要是打招呼或者简单情绪安抚，起到润滑人机对话的作用。

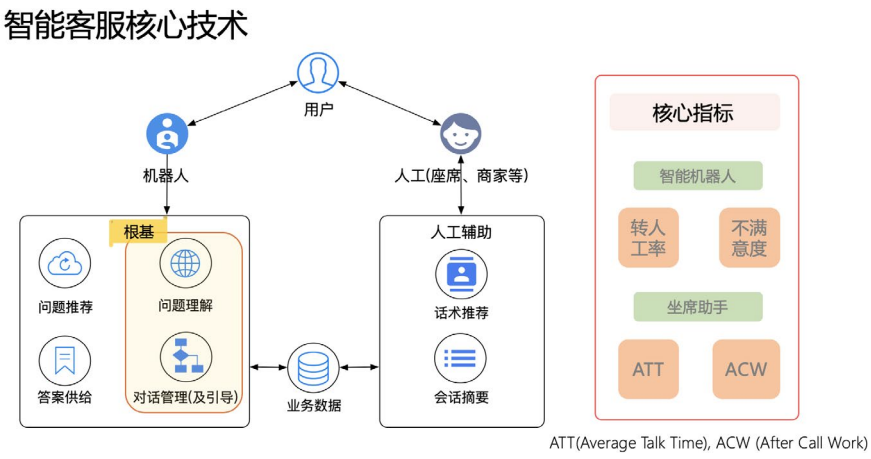

如前面用户服务流程所介绍的那样，用户的沟通对象可能有两个，除了跟机器人沟通外，还可能跟人工沟通。如果是找客服场景人工就是客服座席，如果是找商家场景人工就是商家。机器人的能力主要包括问题推荐、问题理解、对话管理以及答案供给。

目前，衡量机器人能力好坏的核心输出指标是不满意度和转人工率，分别衡量问题解决的好坏，以及能帮人工处理多少问题。而在人工辅助方面，我们提供了话术推荐和会话摘要等能力，核心指标是 ATT 和 ACW 的降低，ATT 是人工和用户的平均沟通时长，ACW 是人工沟通后的其它处理时长。

2.2 智能机器人——多轮对话

这是一个真实的多轮对话的例子。当用户进入到服务门户后，先选择了一个推荐的问题“如何联系骑手”，机器人给出了联系方式致电骑手。同时为了进一步厘清场景，询问用户是否收到了餐品，当用户选择“还没有收到”的时候，结合预计送达时间和当前时间，发现还未超时，给出的方案是“好的，帮用户催一下”，或者是“我再等等吧”，这时候用户选择了“我再等等吧”。

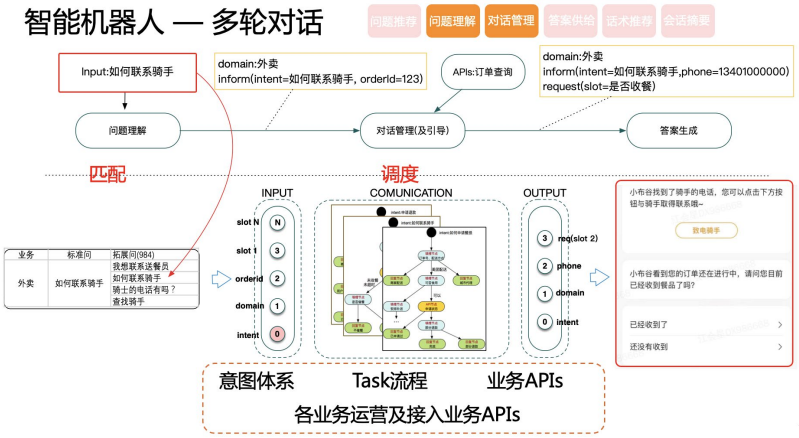

这个例子背后的机器人是怎么工作的呢？首先当用户输入“如何联系骑手”的时候，问题理解模块将它与知识库中的拓展问进行匹配，进而得到对应的标准问即意图“如何联系骑手”。然后对话管理模块根据意图“如何联系骑手”触发相应的任务流程，先查询订单接口，获取骑手电话号码，进而输出对话状态给到答案生成模块，根据模板生成最终结果，如右边的红框内容所示。在这个过程中涉及到要先有意图体系、定义好 Task 流程，以及订单的查询接口，这些都是业务强相关的，主要由各业务的运营团队来维护。那么，对话系统要做的是什么呢？一是将用户的输入与意图体系中的标准问进行匹配，二是完成多轮交互里面的调度。

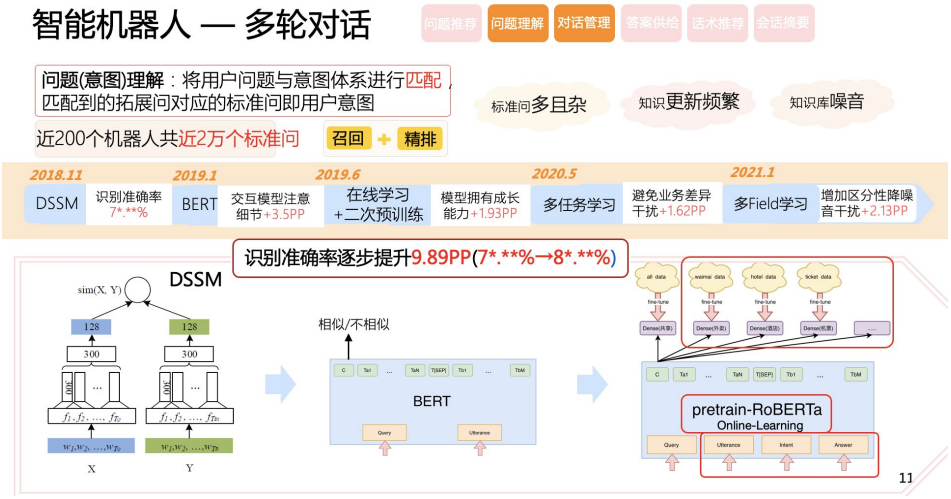

问题理解是将用户问题与意图体系进行匹配，匹配到的拓展问所对应的标准问即用户意图。机器人的工作过程实际是要做召回和精排两件事情。召回更多地是用现有检索引擎实现，技术上更多地关注精排。

美团自研的智能客服系统是从 2018 年开始搭建的，在建设的过程中，我们不断地将业界最先进的技术引入到我们的系统中来，同时根据美团业务的特点，以及问题理解这个任务的特点，对这些技术进行适配。

比如说，当 2018 年底 BERT（参见《美团 BERT 的探索和实践》一文）出现的时候，我们很快全量使用 BERT 替换原来的 DSSM 模型。后面，又根据美团客服对话

的特点，我们将 BERT 进行了二次训练及在线学习改造，同时为了避免业务之间的干扰，以及通过增加知识区分性降低噪音的干扰，我们还做了多任务学习（各业务在上层为独立任务）以及多域学习（Query 与拓展问匹配，改为与拓展问、标准问和答案的整体匹配），最终我们的模型为 Online Learning based Multi-task Multi-Field RoBERTa。经过这样一系列技术迭代，我们的识别准确率也从最初不到 80% 到现在接近 90% 的水平。

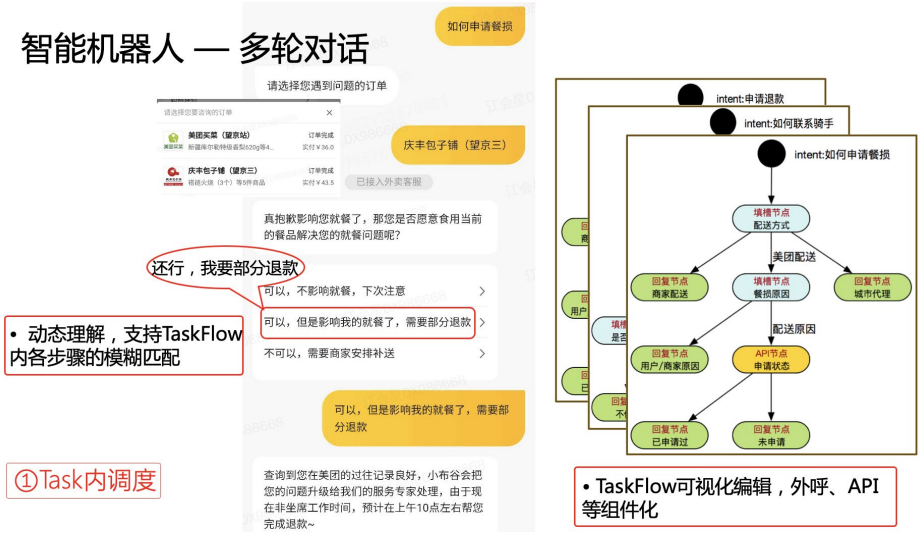

理解了用户意图后，有些问题是可以直接给出答案解决的，而有些问题则需要进一步厘清。比如说“如何申请餐损”这个例子，不是直接告诉申请的方法，而是先厘清是哪一个订单，是否影响食用，进而厘清一些用户的诉求是部分退款还是想安排补送，从而给出不同的解决方案。这样的一个流程是跟业务强相关的，需要由业务的运营团队来进行定义。如右边任务流程树所示，我们首先提供了可视化的 TaskFlow 编辑工具，并且把外呼、地图以及 API 等都组件化，然后业务运营人员可以通过拖拽的方式来完成 Task 流程设计。

对话引擎在与用户的真实交互中，要完成 Task 内各步骤的匹配调度。比如这个例子里用户如果不是点选”可以但影响就餐了…”这条，而是自己输入说“还行，我要部分退款”，怎么办？这个意图也没有提前定义，这就需要对话引擎支持 Task 内各步

骤的模糊匹配。我们基于 Bayes Network 搭建的 TaskFlow Engine 恰好能支持规则和概率的结合，这里的模糊匹配算法复用了问题理解模型的语义匹配能力。

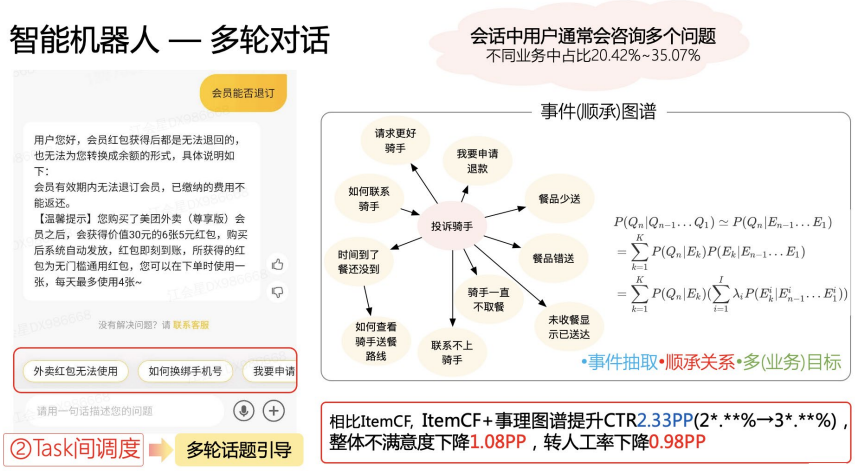

这是另外一个例子，在用户问完“会员能否退订”后，机器人回复的是“无法退回”，虽然回答了这个问题，但这个时候用户很容易不满意，转而去寻找人工服务。如果这个时候我们除了给出答案外，还去厘清问题背后的真实原因，引导询问用户是“外卖红包无法使用”或者是“因换绑手机导致的问题”，基于顺承关系建模，用户大概率是这些情况，用户很有可能会选择，从而会话可以进一步进行，并给出更加精细的解决方案，也减少了用户直接转人工服务的行为。

这个引导任务称为多轮话题引导，具体做法是对会话日志中的事件共现关系以及顺承关系进行建模。如右边图所示，这里原本是要建模句子级之间的引导，考虑到句子稀疏性，我们是将其抽象到事件之间的引导，共现关系我们用的是经典的协同过滤方式建模。另外，考虑到事件之间的方向性，我们对事件之间的顺承关系进行建模，公式如下：

$$P(Q_n|E_{n-1}\dots E_1) = \sum_{k=1}^{K} P(Q_n|E_k)P(E_k|E_{n-1}\dots E_1)$$

并通过多目标学习，同时考虑点击指标和任务指标，如在非转人工客服数据和非不满意数据上分别建模顺承关系，公式如下：

$$P(E_k|E_{n-1}\dots E_1) = \sum_{i=1}^{I} \lambda_i P(E_k^i|E_{n-1}^i\dots E_1^i)$$

最终，我们在点击率、不满意度、转人工率层面，都取得了非常正向的收益。

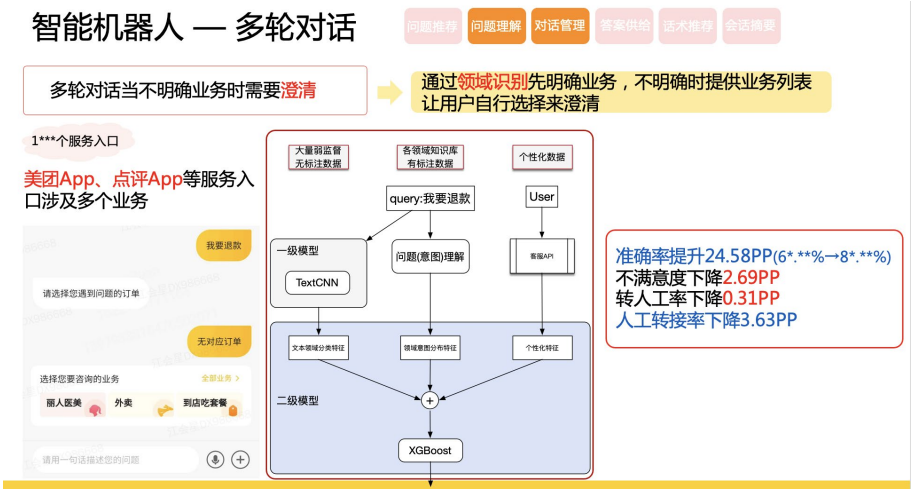

美团平台涵盖吃、住、行、游、购、娱等 200 多个生活服务品类，当用户是从美团 App 或点评 App 等综合服务门户入口进入服务时，需要先行确定用户要咨询的是哪个业务，这里的一个任务是“判断用户 Query 是属于哪个业务”，该任务我们叫做领域识别。若能明确判断领域时，则直接用该领域知识来解答；当不能明确判断时，则还需要多轮对话交互与用户进行澄清。比如用户输入“我要退款”，在多个业务里都存在退款意图，这个时候就需要我们先判断是哪个业务的退款意图，如果判断置信度不高，则给出业务列表让用户自行选择来进行澄清。

领域识别模型主要是对三类数据建模：各领域知识库的有标数据、各领域大量弱监督无标数据和个性化数据。

- 依据从各领域知识库的有标数据中学习得到的问题理解模型信号，可以判断用户输入属于各业务各意图的可能性。
- 我们注意到除了美团 App、点评 App 等综合服务入口涉及多个业务外，还有大量能够明确业务的入口，比如说订单入口，从商品详情页进来的入口，这些入口进来的对话数据是有明确业务标签信息的。因此，我们可以得到大量的弱

监督的各业务领域的数据，基于这些数据我们可以训练一个一级分类模型。

- 同时，有些问题是需要结合用户订单状态等个性化数据才能进一步明确的。比如“我要退款”，多个业务里都会有。因此，又要结合用户状态特征一起来训练一个二级模型，最终来判断用户的输入属于哪个业务。

最终，该二级领域识别模型在满意度、转人工率以及成功转接率指标上都取得了非常不错的收益。

2.3 智能机器人——问题推荐

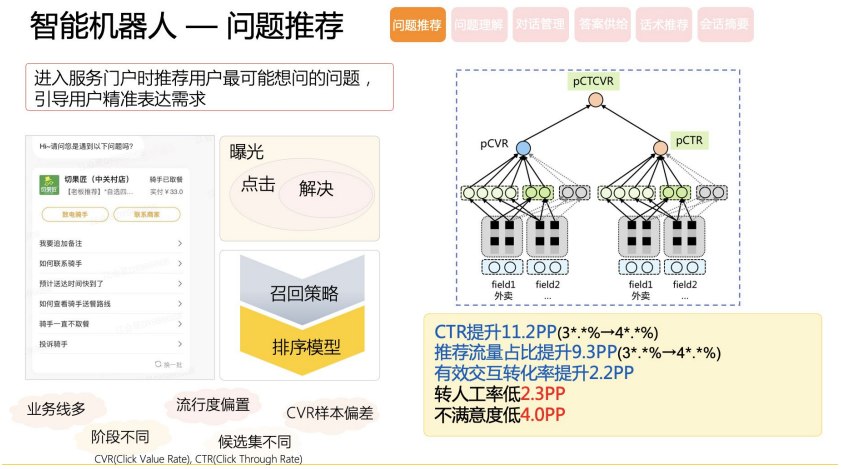

在介绍完多轮对话基础模块问题理解和对话管理后，接下来我们介绍一下智能机器人的另外两个模块：问题推荐和答案供给。如前面多轮对话的例子所示，当用户进入服务门户后，机器人首先是要如何引导用户精准地表达需求，这样即可降低用户迷失或者直接转人工服务，也降低了若机器人不能正确理解时带来的多轮澄清等无效交互。

该问题是一个标准的曝光点击问题，它的本质是推荐问题。我们采用了 CTR 预估任务经典的 FM 模型来作为基础模型，同时结合业务目标，期望用户点击的问题的解决方案能够解决用户问题，该问题最终定义为“曝光、点击、解决”问题，最终的模型是结合多目标学习的 ESSM-FM，对有效交互的转化率、转人工率和不满意度等指标上都带来了提升。

2.4 智能机器人——答案供给

售后客服场景通常问题较集中，且问题的解决多依赖业务内部系统数据及规则，通常是业务部门维护知识库，包括意图体系、Task 流程和答案等。但在售前场景，知识多来自于商户或商品本身、用户体验及评价信息等，具有用户问题开放、知识密度高、人工难以整理答案等特点。比如去哪个城市哪个景点游玩，附近有哪些酒店，酒店是否有浴缸，酒店地址在哪里等，都需要咨询”决策”，针对这些诉求，我们通过智能问答来解决咨询以及答案供给问题。

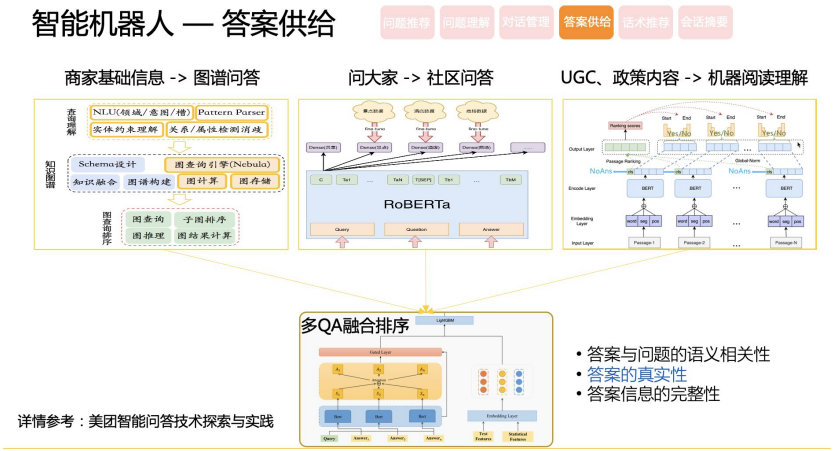

智能问答就是从美团数据中习得答案供给，来快速回答用户的问题，基于不同的数据源，我们建设了不同的问答技术。

- 针对商家基础信息，比如问营业时间、地址、价格等，我们通过图谱问答（KBQA）来解决。利用商家基础信息构建图谱，通过问题理解模型来理解问题，进而查询图谱获取准确的答案。
- 针对社区数据，即商户详情页中“问大家”模块的用户问用户答的社区数据，构建社区问答（Community QA）能力，通过对用户问题与问大家中的”问答对”的相似度建模，选择相似度最高的作为答案，来回答用户的一些开放性问题。
- 针对 UGC 评论数据以及商户政策等无结构化数据，构建文档问答（Document QA）能力，针对用户问题利用机器阅读理解技术从文档中抽取答案，类似我们小时候语文考试中的阅读理解题，进一步回答用户的一些开放性问题。

最后，针对多个问答模块给出的答案，进行多答案来源的答案融合排序，来挑选最终的答案，此外这里还考察了答案真实性，即对“相信多数认为正确的则正确”建模。这部分的详细介绍大家可以参考《美团智能问答技术探索与实践》一文。

3. 人工辅助核心技术

3.1 人工辅助——话术推荐

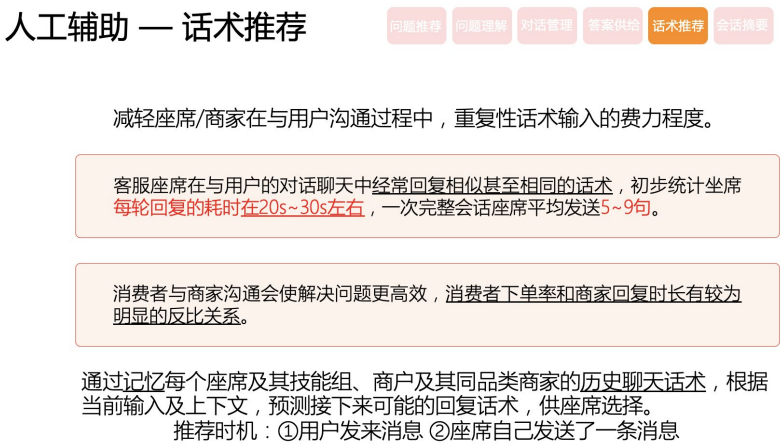

前文介绍的都是智能机器人技术，用户除了跟机器人沟通外，还可能是跟人工沟通。我们在客服座席职场调研过程中发现，座席在与用户的对话聊天中经常回复相似甚至

相同的话术，他们一致期望提供话术推荐的能力来提高效率。此外，除了请求客服座席帮助外，很多情况下用户与商家直接沟通会使得解决问题更高效，而沟通效率不仅影响到消费者的体验，也影响到了商家的经营。比如在外卖业务中，消费者的下单率和商家的回复时长有较为明显的反比关系，无论是客服座席还是商家，都有很强的话术推荐诉求。

那么，话术推荐具体要怎么做呢？常见的做法是先准备好常用通用话术库，部分座席或商家也会准备个人常见话术库，然后系统根据用户的 Query 及上下文来检索最合适的话术来推荐。我们根据调查发现，这部分知识库维护得很不好，既有业务知识变更频繁导致已维护的知识很快不可用因素，也有座席或商家本身意愿不强的因素等。另外，针对新客服座席或者新商家，可用的经验更少。因此我们采用了自动记忆每个座席及其同技能组的历史聊天话术，商家及其同品类商家的历史聊天话术，根据当前输入及上下文，预测接下来可能的回复话术，无需人工进行整理，大大提升了效率。

我们将历史聊天记录构建成“N+1”QA 问答对的形式建模，前 N 句看作问题 Q，后 1 句作为回复话术 A，整个框架就可以转化成检索式的问答模型。在召回阶段，除了文本信息召回外，我们还加入了上文多轮槽位标签，Topic 标签等召回优化，排序为基于 BERT 的模型，加入角色信息建模，角色为用户、商家或者座席。

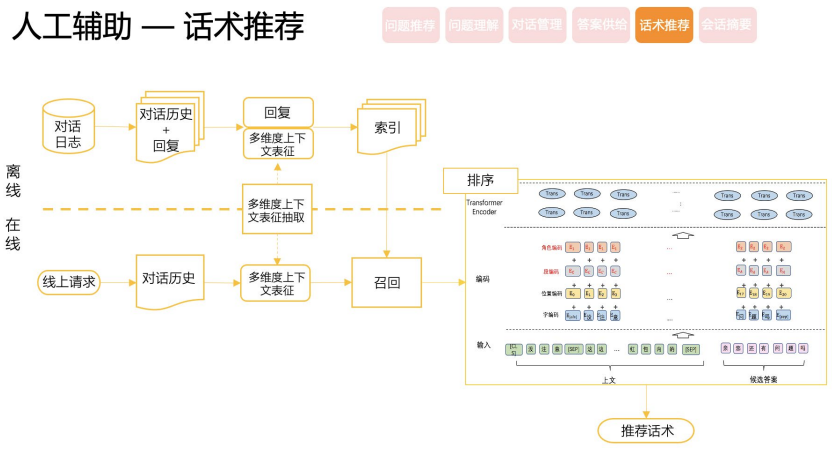

整个架构如上图所示，分为离线和在线两部分。另外上线后我们也加入了一层 CTR

预估模型来提升采纳率。当前多个业务的话术推荐平均采纳率在 24% 左右，覆盖率在 85% 左右。话术推荐特别是对新座席员工价值更大，新员工通常难以组织话术，通过采纳推荐的话术可以来缩减熟练周期，观测发现，3 个月内座席员工的平均采纳率是 3 个月以上座席员工的 3 倍。

3.2 人工辅助——会话摘要

- 提升客服坐席工作效率，改善其办公体验
  - 背景、诉求、处理结果的填写
- 经营分析，产品改善
  - 事件、标签

在客服场景座席跟用户沟通完后，还需要对一些必要信息进行工单纪要，包括是什么事件，事件发生的背景是什么，用户的诉求是什么，最后的处理结果是什么等等。而填写这些内容对座席来说其实是很不友好，通常需进行总结归纳，特别是有些沟通进行的时间还比较长，需要来回翻看对话历史才能正确总结。另外，为了持续对于服务产品进行改善，也需要对会话日志进行相应事件抽取及打上标签，从而方便经营分析。

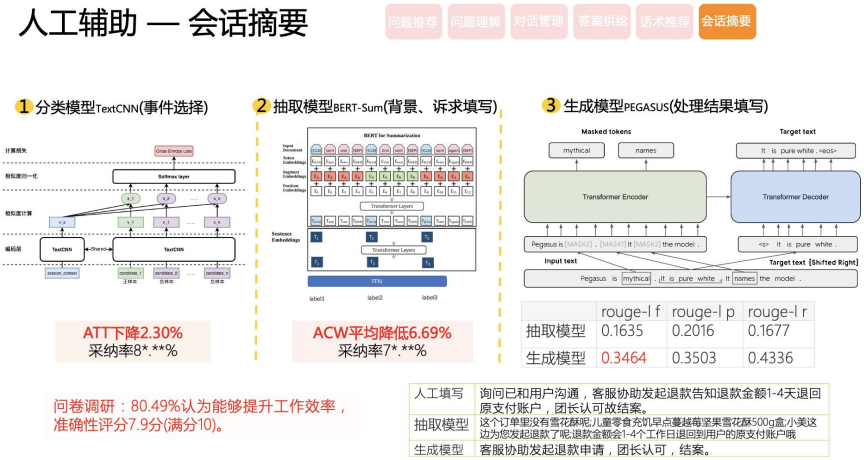

	rouge-l f	rouge-l p	rouge-l r
抽取模型	0.1635	0.2016	0.1677
生成模型	0.3464	0.3503	0.4336

这里有些问题是选择题，有些问题是填空题，比如这通会话具体聊的是哪个事件，我们提前整理有比较完整的事件体系，可以看成是个选择题，可以用分类或者语义相似度计算模型来解决。又比如说事件发生的背景，如外卖退款的背景是因餐撒了、酒店退款的背景是到店没有房间等，是个开放性问题，分析发现可以很好地从对话内容中抽取，可以用摘要抽取模型来解决。而对于处理结果，不仅仅依赖对话内容，还包括是否外呼，外呼了是否商家接通了，后续是否需要回访等等，我们实验发现生成模型更有效。具体使用的模型如上图所示，这里事件选择考虑到经常有新事件的添加，我们转成了双塔的相似度计算任务，背景抽取采用的是 BERT-Sum 模型，处理结果采用的是谷歌的 PEGASUS 模型。

4. 小结与下一步计划

4.1 小结——交互立方

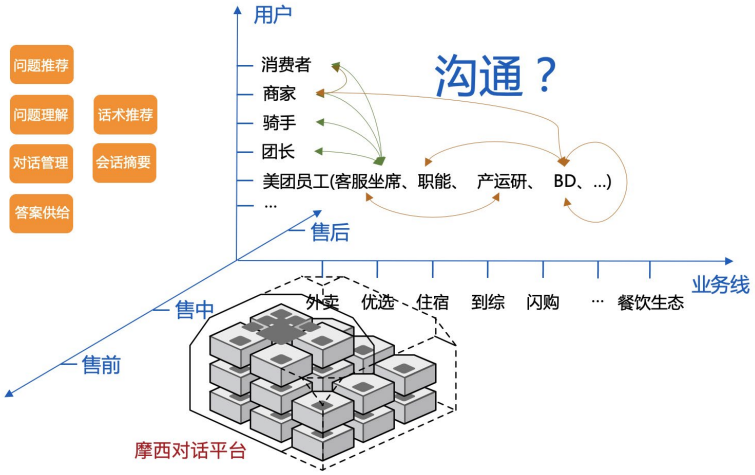

前面介绍了美团智能客服实践中的一些核心技术，过程中也穿插着介绍了客服座席与消费者 / 商家 / 骑手 / 团长等之间的沟通提效，以及消费者与商家之间的沟通提效。除了这两部分之外，在企业办公场景，其实还有员工之间、销售顾问与商家之间的大量沟通。如果一个个去做，成本高且效率低，解决方案是把智能客服中沉淀的能力进行平台化，最好“一揽子”进行解决，以固定成本来支持更多的业务需求。于是我们

搭建了美团的对话平台 – 摩西对话平台，用“一揽子”方案以固定成本来解决各业务的智能客服需求。

4.2 小结——对话平台“摩西”

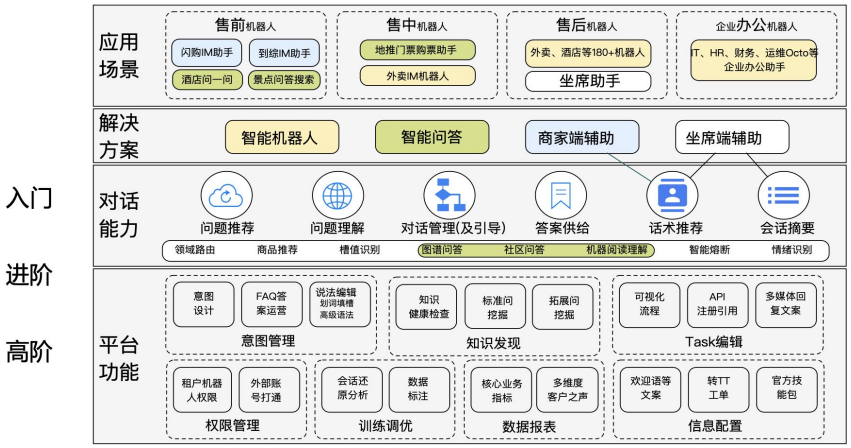

构建一个怎么样的对话平台，才能提供期望的没有 NLP 能力的团队也能拥有很好的对话机器人呢？首先是把对话能力工具化和流程化。如上图所示，系统可分为四层：应用场景层、解决方案层、对话能力层、平台功能层。

- **应用场景层**：在售前应用场景，一类需求是商家助手，如图中所列的美团闪购 IM 助手和到综 IM 助手，需要辅助商家输入和机器人部分接管高频问题能力；还有一类需求是在没有商家 IM 的场景需要智能问答来填补咨询空缺，比如图中所列的酒店问一问和景点问答搜索；另外售中、售后以及企业办公场景，各自需求也不尽相同。
- **解决方案层**：这就要求我们有几套解决方案，大概可以分为智能机器人、智能问答、商家辅助、座席辅助等。每个解决方案的对话能力要求也有所不同，这些解决方案是需要很方便地对基础对话能力进行组装，对使用方是透明的，可以拿来即用。
- **对话能力层**：前面也进行了相应的介绍，六大核心能力包括问题推荐、问题理解、对话管理、答案供给、话术推荐和会话摘要。

- **平台功能层**：此外，我们需要提供配套的运营能力，提供给业务方的运营人员来日常维护知识库、数据分析等等。

其次，提供“一揽子”的解决方案，还需要针对处在不同阶段的业务提供不同阶段的解决方案。

- 有些业务只希望维护好常用的问答，能回答高频的问题就好，那么他们只需要维护一个入门级的机器人，只需要在意图管理模块来维护它的意图，意图的常见说法以及答案就可以了。
- 而对于有运营资源的团队，他们希望不断地去丰富知识库来提升问答能力，这个时候可以使用知识发现模块，可以自动地从每天的日志里面发现新意图及意图的新说法，运营人员只需要每天花一点时间来确认添加及维护答案即可，这是一个进阶的业务方。
- 还有一些高级的业务方希望调用他们业务中的 API 来完成复杂问题的求解。这个时候他们可以使用 TaskFlow 编辑引擎，在平台上直接注册业务的 API，通过可视化拖拽的方式来完成 Task 编辑。

此外，为了进一步方便更多的业务介入，我们也提供了一些闲聊、通用指令、地区查询等官方技能包，业务方可以直接勾选使用。另外，随着我们不断在业务中沉淀，也会有越来越多的官方行业技能包。整体方向上是逐步让业务方使用的门槛变得越来越低。

4.3 下一步计划

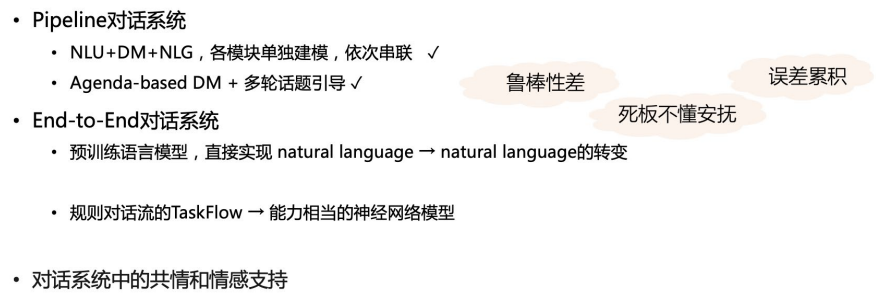

前文所介绍的对话系统是一种 Pipeline 式对话系统，按照功能划分为不同的模块，各个模块单独建模，依次串联。这种方式的好处是可以做到不同团队职责的有效分工，比如研发同学专注于建设好问题推荐模型、问题理解模型和 Task 引擎等；业务运营同学专注于意图体系维护、Task 流程设计以及答案设计等等。它的劣势也很明显，模块耦合，误差累积，很难联合优化，进而各模块负责的同学可能会去修修补补，容易导致动作变形。

另一类建模方式是 End-to-End，将 Pipeline 式对话系统的各个模块联合建模成一个模型，直接实现语言到语言的转变，此类方法最初应用在闲聊式对话系统里面，近期随着大规模预训练模型的快速发展，学术上也逐渐开始研究基于预训练模型的端到端任务型对话系统。它的优点是模型可以充分利用无监督人人会话，用数据驱动可以快速迭代；缺点是模型的可控性差，不易解释且缺乏干预能力。目前主要以学术研究为主，未见成熟的应用案例。

除了使用这种大量无监督的人人会话日志外，还有一种思路是基于 Rule-Based TaskFlow 构建规则的用户模拟器，进行交互以生成大量的对话数据，进而训练对话模型。为了保证对话系统的鲁棒性，也可使用类似对抗攻击的方法优化，可以模拟 Hard User 的行为，不按顺序执行 TaskFlow，随机打断、跳转某个对话节点等等。

此外，通过对比分析人机对话日志和人人对话日志，人机对话比较僵硬死板，无法有效捕捉用户的情绪，而人就很擅长这方面。这在客服场景非常重要，用户往往进来就是带着负面情绪的，机器人需要有共情能力。而端到端数据驱动的对话和对话共情能力建设，也将是接下来一段时间我们尝试的重点方向。

广告深度预估技术在美团到店场景下的突破与畅想

作者：胡可

背景与简介

1. 背景

点击率 / 转化率 / 交易额预估问题，是广告 / 推荐领域的核心，预估值准确性与广告 / 推荐平台的营收和发展直接相关。因此，该方向吸引了学术界与工业界的广泛研究，成为机器学习 / 深度学习技术应用最成功的领域之一。

得益于大规模深度学习框架的推广以及在图像、NLP 等方向的成功应用，深度学习技术被引入广告和推荐领域，尤其在点击率 / 转化率 / 交易额预估问题上，取得了巨大成功，已经成为业界的主流方法。对比传统的机器学习方法 [1][2]，DNN（深度神经网络）[3][4][5] 兼具记忆与泛化性 [6]，在拟合能力上体现出更大优势。然而，经过几年的发展，深度模型的优化变得越来越困难，既往“拿锤子找钉子”——单方面提升模型复杂度的模式已经不再奏效。在这种大背景下，如何打破新的瓶颈呢?

美团到店广告质量预估团队在过去的两年中不断进行实践和研究：通过与美团业务特点深度结合，发挥 DNN 结构设计灵活多变的优势，大量新模型新技术喷涌而出，团队探索出了一条破局之路。

2. 业务特点与挑战

模型整体化方案设计同业务特点紧密相关，团队的业务形态，主要场景覆盖美团 / 大众点评双侧的搜索广告，筛选列表广告，信息流广告三种业务形式（如图 1 所示），意图依次从强到弱。每一个业务也具体包括餐饮、丽人、休闲娱乐、结婚、酒店等不同品类。丰富的业务特点使得算法需要从多个角度进行结合，为团队不断进行新模型的灵活设计提供了广阔的空间。

图 1　美团 / 大众点评双平台各自三种广告形式

进一步理解业务特点，上述的 O2O(Online to Offline) 业务类型，将线下的商业机会与互联网结合，同传统的线上业务的核心差异在两方面，一方面是 Online to Offline 中的“to”，从线上到线下过程中，用户会重点考虑线上线下间的距离因素，因此空间维度的 LBS(Location Based Service) 距离约束是一个重要特点；另一方面是 Online to Offline 中的“Offline”，线下门店消费习惯，行为周期具有明显时间维度特点，例如在月级别固定消费的美甲行为，因此长周期性为另一重要特点。

基于以上 O2O 业务特点，模型整体建模设计有以下空间与时间维度两方面的挑战。

a. LBS 空间距离约束：

- **特点**：线上门店 / 商品需要在有限的距离约束下展示，不同空间位置差异性大。
- **挑战**：带来了候选量差异大，上下文刻画重要等挑战。

b. 长周期性：

- **特点**：门店消费习惯具有周期性强，长期行为影响大等特点。
- **挑战**：用户的长期兴趣建模挑战大，并且因常规模型训练方式较难学习周期性，训练方式存在遗忘历史信息挑战。

3. 深度预估技术

针对 LBS 距离约束与长周期性两方面挑战，下文将简要介绍 CTR(Click-through Rate) 预估技术方案。从机器学习分类的角度理解，CTR 预估是一个有监督机器学习问题：$min_f \ell(f(u,a,c),y)$，最优预测函数$\hat{f}$被用户 (u)、广告 (a)、上下文 (c) 三个维度的函数输入，以及训练过程的函数求解（min_f）所决定，其中上下文包括了请求 Query、请求列表上下文、请求地理位置等实时信息。

如图 2 所示，我们结合 LBS 距离约束和长周期性这两个核心挑战，对 CTR 预估建模函数（用户、广告、上下文和训练过程）进行优化：

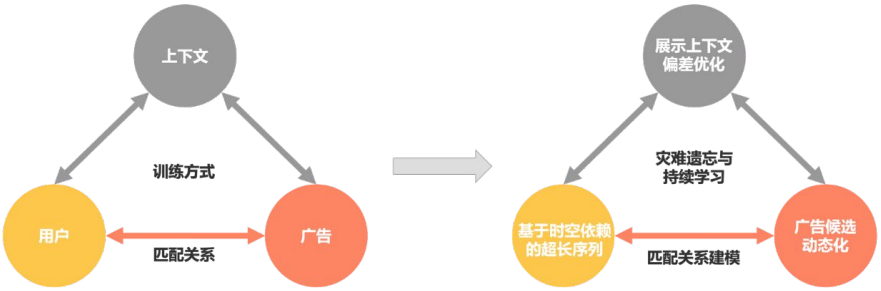

图 2　CTR 预估建模关系图

a. 函数输入：上下文、用户、广告三方面建模

基于位次组合的上下文偏差感知预估（上下文）：由于 LBS 距离约束挑战，空间位置差异引起不同展示上下文影响大，因此利用深度位次交叉网络将广告和位次组合建模，并基于位次信息强化不同请求下的上下文偏差感知。**基于时空依赖的超长序列建模（用户）**：针对长周期性与 LBS 距离约束两方面挑战，一方面基于预训练机制实现了超长序列建模，捕获用户周期性行为；另一方面，实现行为序列的时间与空间联合建模，优化 LBS 距离约束问题。**广告候选动态化（广告）**：由于 LBS 距离约束挑战，空间差异性引起不同位置候选差异大，广告与用户两者表达存在匹配关系（如图 2 所示），只有保障了广告供给的充足性，才能对用户广告关系进行更好的建模。因此进行广告候选量 / 候选类型 / 算力资源三方面动态化，提供用户需求匹配的供给。

b．函数求解：模型训练方式

灾难遗忘与持续学习（训练方式）：针对长周期性挑战，高维稀疏模型在学习最近数据的同时会遗忘历史数据，形成灾难遗忘。通过具备数据回放能力的记忆结构进行持续学习，实现对周而复始的历史数据有效刻画。**整体网络如图 3 所示，结合上述 User/Ad/Context/Training 几方面优化，实现方式通过表示单元（Representation Unit），记忆单元（Memory Unit），组合单元（Combination Unit）三个模块构成高精度高量级的预估系统**。其中表示单元通过加载流式数据，结合超长序列和实时序列，构建时空依赖激活（图中 Representation Unit 的 User 部分）；记忆单元整合历史与当前数据，在数据流控制的基础上，一方面提供历史超长序列的表达学习（图中 Memory Unit 的 User 部分），实现序列长度为 2000~10000 用户全生命周期兴趣建模。另一方面面对灾难遗忘问题 [10]，通过具备数据回放能力的记忆结构进行持续学习（图中 Training 部分），实现高精度的单点预估。组合单元提供组合能力，在广告方面，可以将记忆单元的综合表示与多个泛商品表示进行组合（图中 Ad 部分），在上下文方面，可以与多个位次表示进行组合，将单门店的预估能力扩展到多位次多商品（图中 Context 部分），进而感知展示上下文偏差，从而实现高精度高量级的组合预估系统（**精排在线预估量级 3000+**）。

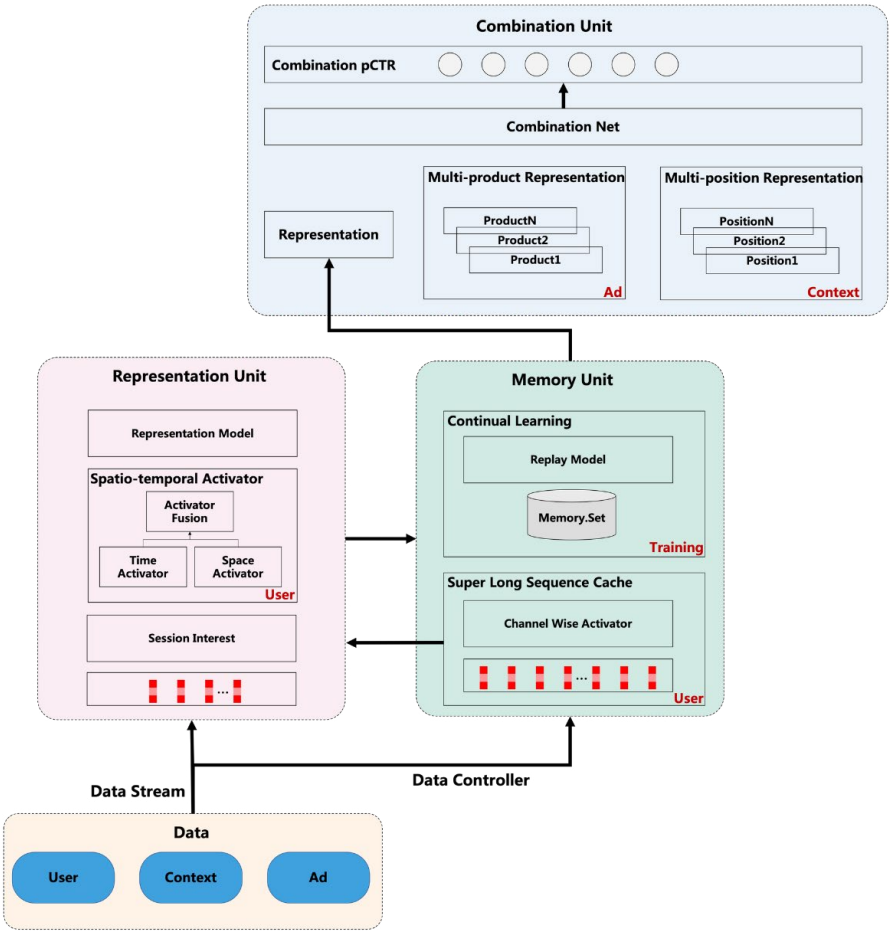

图 3　CTR 预估整体网络图

下文会就 Context、User、Ad、Training 四个方面具体介绍技术突破。

预估技术突破

1. 上下文：基于位次组合的上下文偏差感知预估

由于 CTR 预估模型的训练通常采用曝光点击数据，该数据是一种隐式反馈数据，所以会不可避免地产生各种偏差问题，例如位次偏差、选择性偏差、流行度偏差等。以位次偏差为例（通常也被称为位置偏差，为与本文 LBS 的位置区分开，我们称其为位

次偏差），由于在搜索列表页场景中，用户存在着从上至下的浏览行为习惯，靠前位次的广告通常会受到更多的关注从而容易有更高的 CTR，这种位次倾向会累积到数据中，从而导致数据中存在着偏差问题。此外，受整个列表上下文所产生的点击差异性而导致的偏差也逐渐受到业界关注，在本文该偏差被称之上下文偏差。在 LBS 空间距离约束挑战下，位次偏差和上下文偏差相较于传统电商场景更突出，下文具体介绍该问题。

展示上下文偏差问题：在 O2O 场景的 LBS 距离约束下，不同地理位置相同搜索词所展示的列表差异极大，而传统电商由于不存在 LBS 约束，对于同一搜索词往往更容易根据热度去排序展示，在此比较下，LBS 的展示上下文对于广告有着更大的影响，这就导致了在不同的上下文中数据存在较大不同的偏差。对于位次偏差而言，传统电商的位次偏差更趋向于一个固定偏差，而 LBS 约束下的位次偏差在不同上下文中是有明显差异的，例如一线城市相较于三线城市而言，由于广告的供给更加充足且质量更高，靠前位次广告容易吸引用户点击，更易形成用户点击靠前位次的行为习惯。同时，一线城市商户质量差异小，三线城市商户质量参差不齐，这就导致广告受其上下文自然的影响呈现差异，进一步而言，相同广告在不同自然上下文中点击率也是有差异的，用户容易受到不同上下文的影响从而有不一样的决策，这种差异同样会累积到数据中导致数据存在上下文偏差。为此，本文将位次偏差及广告受不同上下文自然影响所带来的上下文偏差这两类偏差归纳为展示上下文偏差。在美团业务中，搜索广告场景的用户意图较强，其更关注于靠前广告位，位次偏差较大，而在筛选列表广告场景中，意图不明确的用户偏向于去浏览更多的潜在优质商家，因此上下文偏差较大，团队结合这些业务特点在各个场景上推进了基于位次组合的上下文偏差感知预估技术。

位次组合预估技术框架：基于位次偏差问题，我们首先沉淀出一个深度位次交叉网络（Deep Position-wise Interaction Network）（DPIN）模型框架去同时预估多个位次的 CTR。如图 4 所示，DPIN 模型由三个模块组成，分别是处理 J 个（例如 200 个）候选广告的基础模块（Base Module），处理 K 个（例如 10 个）候选广告位次的深度位次交叉模块（Deep Position-wise Interaction Module）以及组合 J X K（例如 2000 个）个交叉候选的位次组合模块（Position-wise Combination Module），不

同模块需预估的样本数量不一样，复杂模块预估的样本数量少，简单模块预估的样本数量多，由此来提高模型性能和保障服务性能。通过这三个模块的组合，DPIN 模型有能力在服务性能的限制下预估每个广告在每个位次上的 CTR，并学习位次信息和其他信息的深度非线性交叉表示 [6]。

上下文偏差感知学习：DPIN 技术框架具备位次信号的深度交叉能力，从而实现多位次的 CTR 预估。在此基础上，由于自然广告分别排序及广告插入自然列表的业务特点，我们在广告预估时可以去考虑已排序好的自然列表，而多位次预估的技术框架赋予了广告可以去感知其局部自然上下文的能力。因此，我们在 DPIN 的基础上考虑每个位次的邻域自然信息，如图 4 所示，深度位次交叉模块在考虑位次、上下文、用户位次历史行为的基础上通过上下文自然聚合（Position-wise Context Aggregation）模块去感知并聚合局部自然上下文信息，从而更好地缓解上下文偏差。进一步地，相同上下文中的自然和广告具有同质性，我们通过基于异质的 Listwise 损失函数加强自然广告间的竞争性建模，通过基于同质的自适应采样加强广告间关系建模。

基于位次组合的上下文偏差感知预估在多个主广告位落地，并都在衡量广告营收的 RPM(Revenue Per Mille) 指标提升 2%~3%。

详情请参考团队的 SIGIR 2021 论文，Deep Position-wise Interaction Network for CTR Prediction[6]。

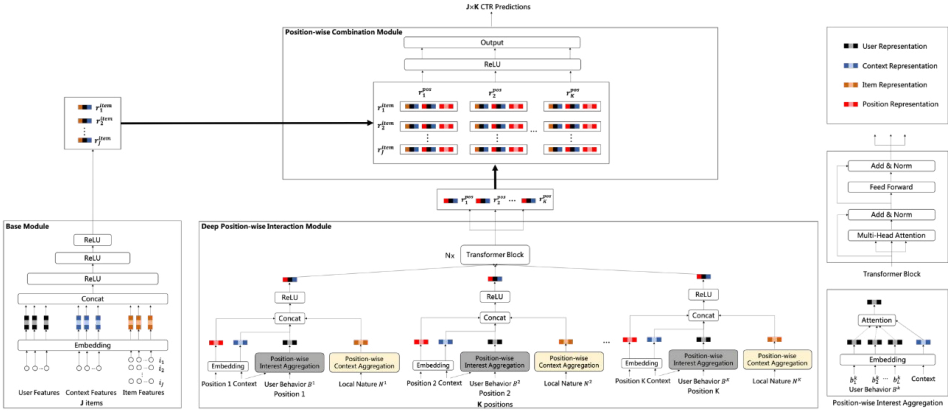

图 4　基于位次组合的上下文偏差感知网络

2. 用户：基于时空依赖的超长序列建模

针对长周期性和 LBS 约束两个挑战，进行用户建模深度优化。一方面针对长周期问题，基于“长短分离”用户行为序列设计原则，通过预训练方式建模长期兴趣；另一方面针对 LBS 约束问题，通过时空建模进行时间与空间的多重依赖关系学习，有效刻画在不同时空条件的用户表达。

用户长期行为复杂性：在美团 O2O 场景下，用户行为习惯存在明显月级周期性（如图 5 所示），并且行为间周期性差异较大，例如脱毛 / 水光针类的周期性大于火锅 / 烧烤类，用户超长序列建模是捕获周期性行为特点的必要条件。在时空依赖方面，用户点击体现出明显的“长分散、短聚合”特点（如图 6 所示），即较短时间内用户的地理位置聚集在单点，但拉长来看，用户将漫游到多个地理位置；超长周期内，大部分用户还会有跨省跨城流动。因此时空联合联合建模存在潜能。

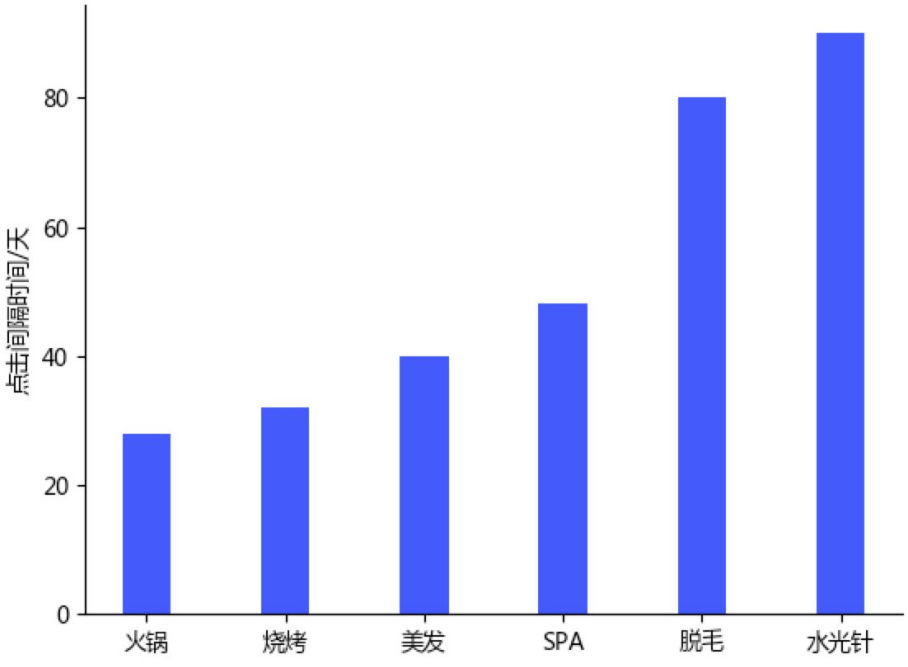

图 5　不同类目行为的平均点击间隔天数

图 6　用户地理位置漫游“长分散，短聚合”特点示例

综上两方面问题，整体建模如下：

$$P(click=1)=f(a,u,c,h(s))\ ,$$

$$\text{where } s=\{(a_i,t_i,g_i)\}_{i\in N}\ ,$$

其中包括 1). 超长序列预训练：$h(s)$ 部分，将其建模为一个仅依赖于历史序列 s 作为输入、用户兴趣向量作为输出的子网络，支撑千级别的超长序列推理性能；2). 时空联合建模：$s=\{(a_i,t_i,g_i)\}_{i\in N}$ 部分的建模。下文具体介绍。

超长序列预训练：针对以上超长序列的性能问题，基于“长短分离”设计，将超长序列单独预训练（如图 7 所示），同短期表达分离，超长序列模块负责将用户全生命周期序列进行激活和降维，提取用户长期兴趣的表达。主模型负责将用户长期表达与短期表达结合。线上推理时，超长序列可以直接读取天级别缓存的表达向量，通过短期表达部分补充因无法实时更新的效果损失，然后再进行长短期兴趣表达结合，最终线上性能增加由原先 30+ms 降至 1ms 以内，实现千级别序列复杂推理。为能捕捉用户周期性行为兴趣，采用 Channel-wise Activator Layer 结构设计（如图 7 所示），利用长期行为兴趣漫游的特点将超长序列切分为能表达不同兴趣的时间子序列（Sub

Seq），并增加行为动态时间间隔表征后，同差异性属性进行多通道表达激活，实现基于类目周期性差异的兴趣表达。对比业界基于相关检索的超长序列方案 [7]，上述超长序列预训练并没有丢弃不相似的表达，充分建模全部行为。例如烧烤与素食、健身房和快餐之间意图负相关，但互相却又强影响，预训练建模以上负相关等更通用的行为影响，在美团数据集中也取得比检索方法 [7] 更显著的效果。

时空联合建模：依赖美团 O2O 的业务特点与挑战，我们充分考量其时间与空间属性，对用户的历史时空信息和当前时空信息进行了充分的建模和交互。我们分辨出用户行为的三重时空信息，即：用户点击发生时的时间、用户请求发出的地理位置、用户所点击的商户的地理位置。基于上述三重时空信息，我们提出 Spatio-temporal Activator Layer（如图 7 所示）：三边时空注意力机制神经网络来对用户历史行为进行建模，通过对请求经纬度信息、商户经纬度信息和请求时间的交互，囊括了同构空间信息深度交叉（用户历史请求位置和用户当前请求位置、用户历史点击商户位置和用户当前目标商户位置等）、异构空间信息深度交叉（用户历史请求位置和用户当前目标 POI 位置、用户历史点击商户位置和用户当前请求位置）、时间信息深度交叉的三边时空信息交互机制。针对空间信息交叉，我们进一步采用地理位置哈希编码和球面距离相结合的方式，以综合表达绝对空间信息和相对位置信息；针对时间信息交叉，我们也采用绝对与相对时间相结合的方式，有效实现用户行为序列在不同时空条件下的三边表达。从业务角度，针对不同的业务特性，我们进行空间信息表达的动态归一。比如在美食业务中，我们刻画用户搜索地和商户的相对距离信息；而在空间变迁属性更强的酒店业务中，当用户搜索词包含地址词时，我们刻画该地址和目标商户的相对距离信息。最后，经上述网络编码后的时空信息经过注意力机制网络融合，得到 LBS 场景下用户超长行为序列对不同请求候选的个性化表达。

基于时空依赖的超长序列建模在各个主广告位落地，RPM 提升 2%~5%。

详情请参考团队的 CIKM 2021 论文，Trilateral Spatiotemporal Attention Network for User Behavior Modeling in Location-based Search[8]。

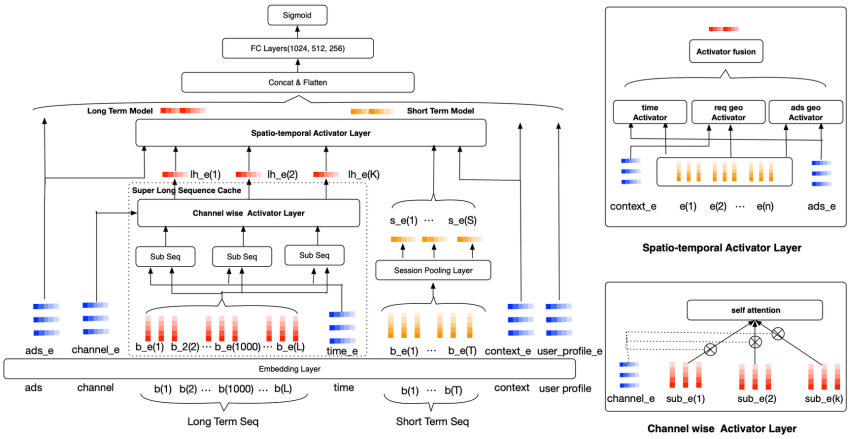

图 7　基于时空依赖的超长序列模型图

3. 广告：广告候选动态化

广告同用户存在着匹配关系，在用户意图精准理解的基础上，充分的广告供给能够进一步释放潜能。而在 LBS 距离约束挑战下，不同请求的广告候选存在很大差异。

因此如图 8 所示，我们从候选量、候选类型、候选算力三个维度构造广告候选动态化系统，实现精细化的供给匹配，具体优化如下：

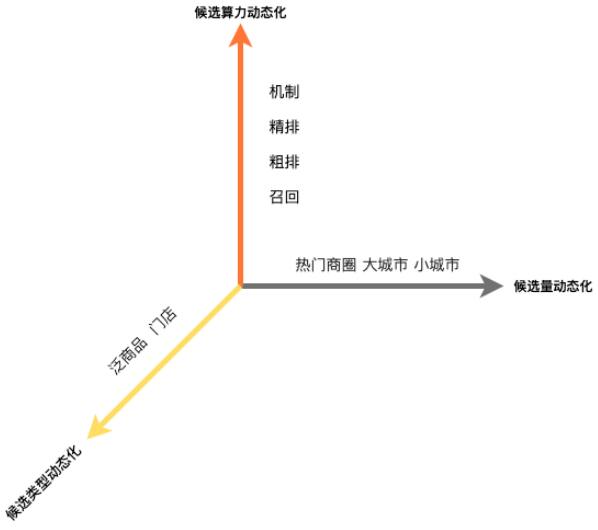

图 8　广告候选动态化三维图

候选量动态化：在广告 / 推荐领域，由于性能和资源限制，召回 –> 粗排 –> 精排 –> 机制，各层之间普遍存在漏斗候选截断，其中的精排候选数一般设置固定值。美团业务的距离约束特点显著，大型城市是小型城市平均候选数的 59 倍。根据城市、商圈等空间粒度进行候选量动态化后，可以在资源固定下最大限度释放热门地区的排序效果，特别是大型城市效果明显，RPM 提升约 20%。

由于候选量大幅度提升，精排模型有更严重的选择性偏差问题——线上面对的扩量候选与此前系统的候选不一致，为扩量前系统候选的超集。将候选扩量对应的流量理解为 Explore 流量，对 CTR 模型训练进行了多阶段优化，进一步取得效果 [13]，整体优化在部分筛选列表广告 RPS 提升 5%~10%。

候选类型动态化：在候选量动态化的基础上，我们进一步进行了候选类型动态化。因不同类型均为广告，我们在此处不采用 Ad 概念，在某些类目上，受 LBS 限制门店数较少，而每个门店下的泛商品（门店下更细粒度候选，同门店差异见上图，例如在结婚品类下的某婚纱照为商品）较多，将候选类型从门店扩展到门店 + 泛商品后，候选供给在部分类目可以扩大约 30 倍。并且在业务中，用户意图逐渐呈现具体化、明确化与多样化特点，例如“写真”等搜索关键词增多，粗粒度的门店候选已经不足以匹配细粒度用户意图。通过深度个性化的异构候选混排，能够匹配细粒度的用户意图，给用户展示最符合其兴趣偏好的候选类型。如图 9 所示，我们通过组合预估实现异构混排系统，主网络的高复杂性门店表征通过共有表达的迁移学习，和商品网络的高数量级商品表征进行维度动态转换对齐，实现数千量级的门店 / 泛商品异构混排系统。在部分筛选列表广告 RPM 提升 10%~15%。

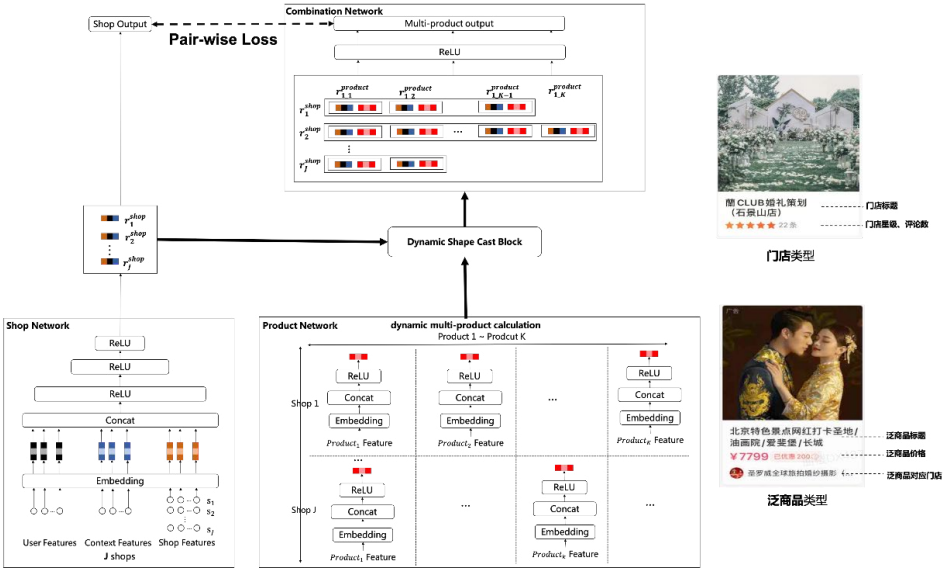

图 9　导构混排网络

候选算力动态化：通过动态的候选供给我们发现更多的候选能够带来效果空间，在此基础上我们进一步进行算力动态化，从性能角度进一步提升候选量级。广告系统收到请求后，会经过召回、粗排、精排、机制模块，最终生成广告展现顺序。其中各模块的超时时间和资源是固定的，导致总体算力缺乏弹性，容易因候选过多出现总体请求超时而不出广告的情况，或是候选过少出现多余算力浪费的现象。因此我们进行候选算力动态化，根据流量价值调整每个模块的耗时，通过全局优化实现在有限算力下收益最大化：首先在工程架构上增加各个服务算力弹性变量，如超时时间、模型复杂度和计算并行度等等，实现了效果和算力的灵活兑换。之后在算法上通过流量价值预估模块预估当前请求价值，确定各阶段打分数。在接下来的各服务阶段，结合当前算力消耗与预估价值情况，即时调整后续阶段算力弹性变量，进一步释放了效果空间。在筛选列表广告 RPM 提升约 2%。

候选动态化效果在各个主广告位落地效果差异较大，RPM 提升范围在 2%~15%。同时广告侧优化我们通过多模态表达学习取得效果，详情后续整理为论文公开。

4. 训练方式：灾难遗忘与持续学习

灾难遗忘 (Catastrophic Forgetting)[10] 是模型学习同人脑学习的一个重要差异，指的是同一个网络模型，在学习新的任务的时候，因分布变化而导致老任务学习的模型权重损坏。在美团广告业务，无论是用户和商户均存在周期性特点，并且高维稀疏网络特性会放大这个特点，现象是在拟合新数据模式过程中，遗忘具备周期性的老数据，形成了灾难遗忘。下面会介绍长周期性挑战，与高维稀疏网络结构问题，以及对应的持续学习解决方案。

周期性数据模式：不同于传统机器学习数据独立同分布假设 (i.i.d.)，CTR 预估模型面临着动态非平稳的外部环境。特别地，在我们的 O2O 业务中，新用户、新商户不停出现，流行元素如小龙虾、烤肉等不时演变，夹杂着周中简餐周末大餐等节日性、季节性、星期级，小时级特征，对 CTR 预估模型的持续学习提出了挑战，要求我们的模型能够快速拟合新出现的数据模式。针对这类时变数据的学习任务，一种常见选择是流式训练。流式训练将数据按照时间顺序依次喂入模型，以 Regret[11] 为目标让模型实时动态地调整模型参数，达到拟合最新数据分布的目的。但是，单纯地流式训练有过分强调新数据模式而遗忘过往学习到的老数据模式的危险。特别地，在我们的 O2O 业务场景下，存在大量周期性数据模式，下面将以星期级周期为例进行介绍。

高维稀疏网络的结构匹配性：不同于 NLP/CV 领域，广告 / 推荐领域的 DNN 模型具有显著的参数不平衡性，即高维度稀疏的 Embedding 层约有亿级 ~ 千亿级别参数量的参数量，而连接 Embedding 到 Output 的 FC 层 (Fully Connected Layers) 却低维稠密，网络中极度稀疏的 Embedding 层占据 99.99%+ 的参数量，该不平衡性易于引发老数据模式的遗忘问题。以天级更新模式的星期几特征为例，线上推理的数据是周六 (t, w(t) = 6) 数据，训练时在未充分纳 t 时刻数据时，会更多的拟合在周五 (t−1) 特征上，而实际上在上一周的周六 (t−7) 与线上推理数据 (t) 具有更强的分布一致性。特别地，如果我们使用星期几这一离散特征，在高维稀疏的 Embedding 层在线上推理的 t 时刻会直接查询到 t−7 天的 Embedding，而低维稠密的 FC 层会查询到 t−1 的 FC 层，会引起严重的结构不匹配问题，形成星期属性模式的灾难性遗忘。

更具一般性地，训练中存在着周中简餐，周末大餐等复杂模式的灾难遗忘，引起效果大幅退化。

面向未来分布的持续学习：为系统性地解决上述问题，我们采用持续学习中的数据回放技术，在流式训练的基础上进一步拟合回放的数据，加强模型在无遗忘约束下的持续学习能力。具体地，为结合流式训练和持续学习的数据回放技术，我们采用 FC 层分多塔的结构来达成预训练模型可流式更新、持续学习模型可依赖最新预训练模型更好地拟合当前数据的效果。如下图 10 所示，通过流式训练我们维护一个预训练模型；而为避免模型过分拟合最新数据而导致历史稀疏 Embedding 层参数和上层 FC 层参数不匹配的问题，通过数据控制器 (Data Controller) 维护一份记忆集 (Memory Set)，其中的数据为根据未来分布预测，在历史数据中采样得到，并将该份记忆集提供给基础模型用于持续学习，从而在加强对未来分布数据的模型预估能力。

持续学习技术在各个主广告位落地，RPM 提升 2%~3%。更多详情已整理为论文投稿中，后续会进行公开。

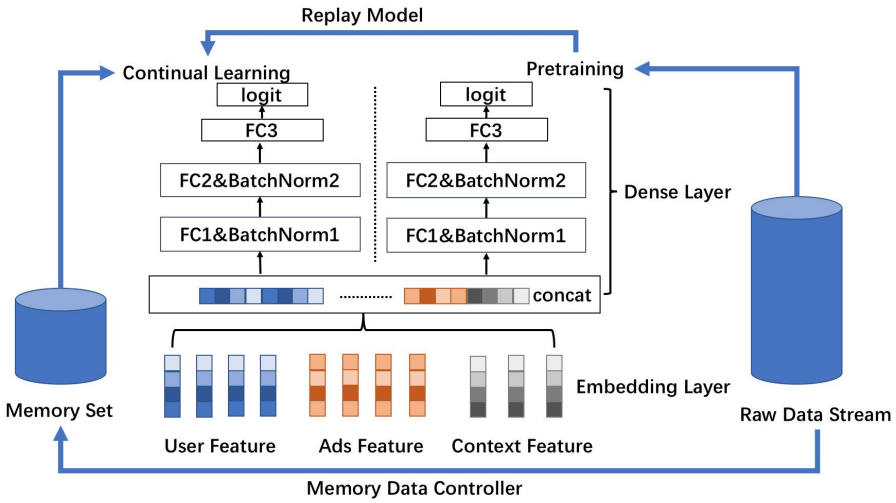

图 10　灾难遗忘与持续学习训练模式

预估技术新趋势

上文介绍了基于 O2O 特点的 CTR 技术突破，我们将优化方法推广在转化率、交易额预估问题，其中 LBS 距离约束在转化率中起到更重要的影响，因方法接近，不再进行赘述。

同一技术的点击率预估优化效果在不同业务类型中也存在一定差异，意图强的搜索广告场景，上下文差异性更大，Context 相关优化有更明显效果。而在意图弱的信息流广告场景，User 建模有更大的空间。

那么预估技术如何持续突破的系统上线？迭代路径从前期通过模型复杂度提升，到现阶段结合问题的模型灵活设计均取得效果，而未来我们认为将越来越剥离模块与目标设置的现状，消除建模中人为的设置假设。

如何抽丝剥茧，回归问题本质？我们认为有如下新趋势。

a. 模型内推理量级动态化

广告系统通常分为召回、粗排、精排（预估）等多个模块，模块漏斗遵循的一个核心设计逻辑是简单模块打分量级大（例如粗排），复杂模块打分量级低（例如精排）。以递归视角进一步理解子模块设计，将设计逻辑泛化到模型内，同样存在简单的网络部分打分量大，复杂的网络部分打分量低，同一个网络打分量差异化的优化方式。例如粗排常用的双塔网络结构 (Two-tower Network) 在 User 端打分一次，Ad 端打分多次。

更具一般性的形式并不局限在表达能力受限的双塔结构，而在于更充分的应用打分量与复杂度的关系进行灵活设计，例如本文阐述的 DPIN(Deep Position-wise Interaction Network)[7] 组合网络部分打分量大，基础网络部分打分量小，同在本文阐述的异构混排网络，超长序列预训练优化同样适用于这一趋势。

未来将在更细化的层面进行推理量级动态化，通过每一个局部精度与性能的平衡达到整体的最优平衡。

b. 问题间评估指标差异化

评测指标是一个比优化方式甚至更重要的问题，点击率预估最经典的评测指标为AUC，而随着模型精度的提升，离线 AUC 提升同线上不一致的情况逐渐增多。回归到预估问题本身，实际排序系统是在固定请求固定位次下的最优排序，等价寻优 User × Context × Time 限定条件的 Ad 最优序。

time 条件在持续变化难建模，为简化问题，以 User/Context 维度分组，近似寻优 Ad 最优序。基于以上假设，User/Context 分组的“组间序”同“组内序”并不具备等价的业务意义。例如个性化优化问题，每一个 User 作为一组进行分组为例，User Group AUC[12] 同线上具有更强的一致性；而在 Context 中的 Position Bias 问题中，我们发现通过 Position Group AUC(PAUC)[7] 评估同线上系统具有更强的一致性。在全局 AUC 增长挑战性变大的背景下，不同问题进行差异性评估指标设计，进而指导模型优化，是取得效果的一个关键趋势。

c. 链路模块间目标多元化

系统整体目标面对排序问题，先是解耦为召回、粗排、精排等多模块独立优化，而后针对整体性排序问题，链路目标一致性优化成为一个明显的演进趋势。在召回 -> 粗排 -> 精排目标一致，取得明显效果的同时，存在着因多模块过于同质化、协同共振引起的马太效应。以召回为例，是否应该由其他路模块，例如探索路召回来解决这个问题?

更具泛化性地，多路召回之间的强互补性，能够提供给下游更优的候选超集，召回各个路之间面向 Diversity Loss 进行优化是未来的探索性方向之一。随着模块间关系动态变化，广告系统目标设计存在着一致性与差异性的辩证关系。

d. 搜索推荐边界模糊化

从广告视角，团队内的搜索广告、推荐广告间做法呈现逐步边界模糊化特点。传统搜索广告围绕意图明确进行 Query 理解，进而内容适配。逐渐 Query 相关的刻画不能完全满足用户意图的细化，搜索问题逐渐转变为在 Query 约束下的个性化匹配问题。

边界模糊化带来的一个技术现象就是全域数据的运用，搜索、推荐间的全方位深度迁移学习是取得效果的一个关键。

e. 模型学习非监督化

如图 11 所示，整个广告系统中，是在用户交互、数据、模型之间不断产生反馈循环，在这个过程中会有偏差循环放大的问题，例如产生偏差的数据会喂入模型影响展示，数据回溯到模型形成进一步归纳偏差。

传统的建模方式是将整个动态的系统简化为监督问题进行预估建模，优化集合仅为线上集合的子集，效果限制随迭代愈发明显。未来针对监督模型无法充分建模的候选超集依然有较大空间。在实际动态演化的广告系统中，无论是新目标定义、模型优化还是 AB Test 评测方式都有较大的探索潜能。

Debiasing 问题优化详情参照团队的 KDD Cup 2020 冠军技术分享，**KDD Cup 2020 Debiasing 比赛冠军技术方案及在美团的实践** [13]。

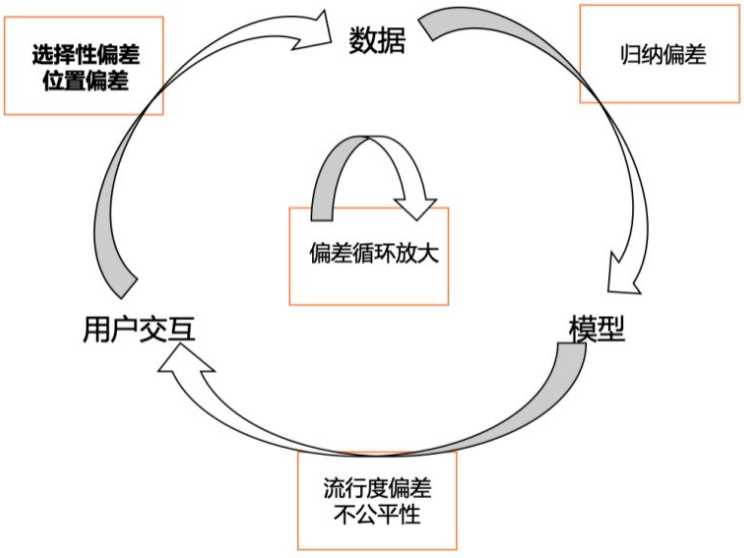

图 11　广告系统中的反馈环路，偏差积累循环

作者简介

胡可、坚强、张博、漆毅、庆涛、曲檀、程佳、雷军等，均来自美团广告平台技术部。

参考文献

[1] Friedman J H . Greedy Function Approximation: A Gradient Boosting Machine[J]. Annals of Statistics, 2001, 29(5):1189-1232.

[2] Rendle S. Factorization machines[C]//2010 IEEE International conference on data mining. IEEE, 2010: 995-1000.

[3] HT Cheng, et al. Wide & Deep Learning for Recommender Systems, 2016

[4] Zhou, Guorui, et al. "Deep interest network for click-through rate prediction." Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018

[5] Modeling Task Relationships in Multi-task Learning with Multi-gate Mixture-of-Experts. ACM, 2018.

[6] Wen, Ling, Chua. A closer look at strategies for memorization.[J]. Clavier Companion, 2014, 6(6):50-52.

[7] Huang J, Hu K, Tang Q, et al. Deep Position-wise Interaction Network for CTR Prediction[J]. arXiv preprint arXiv:2106.05482, 2021.

[8] Search-based User Interest Modeling with Lifelong Sequential Behavior Data for Click-Through Rate Prediction

[9] Qi, Yi, et al. "Trilateral Spatiotemporal Attention Network for User Behavior Modeling in Location-based Search", CIKM 2021.

[10] Overcoming catastrophic forgetting in neural networks[J]. Proceedings of the National Academy of Sciences of the United States of America, 2017.

[11] M. Zinkevich. Online convex programming and generalized infinitesimal gradient ascent. In ICML, 2003.

[12] Optimized Cost per Click in Taobao Display Advertising[C]// the 23rd ACM SIGKDD International Conference. ACM, 2017.

[13] https://tech.meituan.com/2020/08/20/kdd-cup-debiasing-practice.html

招聘信息

美团到店广告平台广告算法团队立足广告场景，探索深度学习、强化学习、人工智能、大数据、知识图谱、NLP 和计算机视觉前沿的技术发展，探索本地生活服务电商的价值。主要工作方向包括：

- 触发策略：用户意图识别、广告商家数据理解，Query 改写，深度匹配，相关性建模。
- 质量预估：广告质量度建模。点击率、转化率、客单价、交易额预估。
- 机制设计：广告排序机制、竞价机制、出价建议、流量预估、预算分配。
- 创意优化：智能创意设计。广告图片、文字、团单、优惠信息等展示创意的优化。

岗位要求

- 有三年以上相关工作经验，对 CTR/CVR 预估、NLP、图像理解，机制设计至少一方面有应用经验。
- 熟悉常用的机器学习、深度学习、强化学习模型。
- 具有优秀的逻辑思维能力，对解决挑战性问题充满热情，对数据敏感，善于分析 / 解决问题。
- 计算机、数学相关专业硕士及以上学历。

具备以下条件优先：

- 有广告 / 搜索 / 推荐等相关业务经验。
- 有大规模机器学习相关经验。

感兴趣的同学可投递简历至：chengxiuying@meituan.com（邮件标题请注明：美团广平算法团队）。

小样本学习及其在美团场景中的应用

作者：骆颖　徐俊　谢睿　武威

1. 背景

美团的各个业务有着丰富的 NLP 场景，而这些场景中模型的构建需要很多的标注资源，成本很高。小样本学习致力于在数据资源稀少的情况下训练出比较好的模型，主要有以下两个评价标准：

- **提升算法效果**：在标注资源一定的情况下，使用小样本学习能够尽可能多地提升相应的指标。
- **节省标注数据**：在算法效果希望达到一定水平的情况下，希望尽可能减少标注数据。

在 NLP 领域少样本的场景下，主要存在以下三种场景，小样本学习针对这些问题采取了不同的措施：

1. 样本空间稀缺（图 1 左）：样本数量较少时，分布稀缺，数据增强旨在更好利用样本 /Embedding 之间的关系，提高模型泛化性能。
2. 样本分布在局部空间（图 1 中）：某个领域往往只有少量标注数据，而有大量的未标注数据。根据对未标注数据的使用方式不同，我们将其划分为两种，第一种是半监督学习，是在模型 Finetune 过程中同时学习标注样本和未标注样本，利用了模型对未标注数据的预测一致性；第二种是集成学习 + 自训练，强调的是融合多个模型对未标注数据的预测结果作为伪标注数据加入训练。
3. 不同领域之间的样本分布差异（图 1 右）：在某个领域充分学习到标注信息之后，因样本空间有差异，无法直接用到其他领域，迁移学习旨在学习到一个领域的充分知识后，能够快速学习到其他领域的知识。

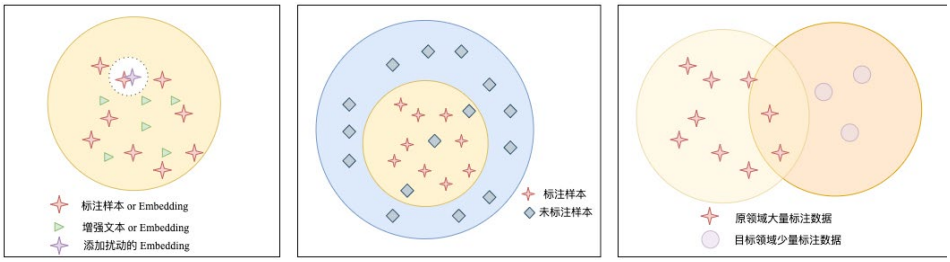

图 1　小样本学习三种应用场景

除了上面提到的三种场景，还有一种是，如何在有限的标注成本中选择更有针对性的样本进行人工标注（主动学习）。因此我们将小样本学习划分为下面几种：

- **数据增强**：数据增强可以分为样本增强和 Embedding 增强。样本增强早先在计算机视觉中对图像进行数据增强，图像的一些简单操作，如将图像旋转或将其转换为灰度，并不会改变其语义，语义不变变换的存在使增强成为计算机视觉研究中的一个重要工具。在 NLP 领域中的样本增强也试图不改变句子主旨来扩充文本数据，主要方法有简单文本替换、预训练语言模型生成相似句子等，对得到的增强数据可以使用课程学习的方式由简到难地进行学习。Embedding 增强在模型的 Embedding 层进行操作，可以通过对 Embedding 加扰动 / 插值等，提升模型的鲁棒性。
- **半监督学习**：监督学习往往需要大量的标注数据，而标注数据的成本比较高，因此如何利用大量的无标注数据来提高监督学习的效果，具有十分重要的意义。近年来，半监督深度学习取得了长足的进展，特别是在计算机视觉领域；相关的研究主要着力于如何针对未标注数据构建无监督信号，与监督学习联合建模，目前的主要方法都是基于无标注数据的一致性正则构建损失函数。
- **集成学习 + 自训练**：机器学习的有监督学习目标是学习出一个稳定的且在各个方面表现都较好的模型，但实际情况中有时只能得到多个有偏好的模型（弱监督模型，在某些方面表现的比较好）。集成学习就是组合这里的多个弱监督模型以期得到一个更好更全面的强监督模型，集成学习潜在的思想是即便某一个弱分类器得到了错误的预测，其他的弱分类器也可以将错误纠正回来。单纯使

用多个模型在预测时做集成会增加线上负担，因此我们利用多个模型对大量无标注数据进行预测，选取组合置信度较高的数据合并到训练集进行训练，最后将多个模型的优势集成到一个统一的模型上。这部分也属于半监督学习的一种，但是与上面提到的半监督学习的主要区别是后者提到的方法都是强调在Finetune 阶段利用模型对未标注数据的预测一致性，而这部分强调融合多个模型的预测结果，故单独将这部分单独列出。

- **Few-shot Learning/ 领域迁移**：人类在具备一定的知识储备后可以快速学习新的知识，研究人员希望机器学习模型也能具备这种能力，一个模型已经从一定类别的大量数据学习许多信息后，对于新的类别可以依据新的少量的标记样本得到新的分类器，该分类器可以在新的类别中识别出该类样本。
- **主动学习**：主动学习是一个机器学习和人工参与迭代的过程，通过机器学习的方法筛选出合适的候选集给人工标注。大致思路是：通过机器学习的方法获取到那些比较“难”分类的样本数据，让人工再次确认和审核，然后再将人工标注得到的数据再次使用有监督学习模型进行训练，逐步提升模型效果。

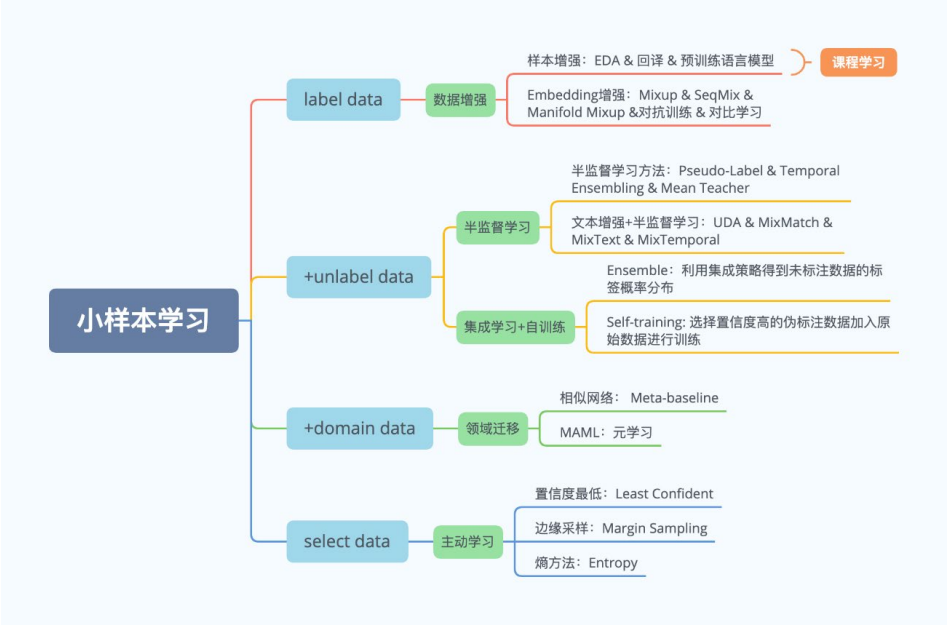

图 2　小样本学习相关工作

2. 方法综述

预训练语言模型 BERT，在 NLP 许多任务中取得非常好的结果。BERT 是基于 Transformer 的深度双向语言表征模型，利用 Transformer 结构构造了一个多层双向的 Encoder 网络。我们采取 BERT 作为 Baseline 模型，对预训练好的模型在特定任务样本上进行 Finetune。

2.1 数据增强

数据增强可以分为数据扩充和 Embedding 增强，数据扩充在保持语义不变的情况下，变换文本的表达形式，如回译、同义词替换、随机删除等等；模型增强主要有 Mixup 和对抗训练，Mixup 在 NLP 领域有一系列的变体，包括 SeqMix、Manifold Mixup 等。数据增强提高了模型的鲁棒性，使得模型更关注文本的语义信息，并对文本的局部噪声不再敏感。在少样本场景，文本增强技术可以有效提高模型的鲁棒性，提高其泛化能力。

2.1.1 样本增强

2.1.1.1 简单数据增强 EDA

EDA[1] 通过知识库来替换句子中的某些词 / 短语，主要包含以下四种操作：

- **同义词替换（Synonym Replacement，SR）**：不考虑停用词，在句子中随机抽取 n 个词，然后从同义词词典中随机抽取同义词，并进行替换。
- **随机插入（Random Insertion，RI）**：随机的找出句中某个不属于停用词集的词，并求出其随机的同义词，将该同义词插入句子的一个随机位置。重复 n 次。
- **随机交换（Random Swap，RS）**：随机的选择句中两个单词并交换它们的位置。重复 n 次。
- **随机删除（Random Deletion，RD）**：以概率 p 随机删除句子中每个单词。

2.1.1.2 回译（Back Translation）

回译是 NLP 在机器翻译中经常使用的一个数据增强的方法，它的本质就是快速产生

一些翻译结果达到增加数据的目的。回译将原有数据翻译为其他语言再翻译回原语言，由于语言逻辑顺序等的不同，回译的方法也往往能够得到和原数据差别较大的新数据。

2.1.1.3 预训练语言模型

- 基于上下文信息的文本增强[2]，利用训练好的语言模型，随机 Mask 文中的一个词或字，再将文本输入语言模型，选择语言模型所预测的 Top k 个词去替换原文中被去掉的词，以形成 k 条新的文本。
- 基于语言生成模型的文本增强 Lambda[3]，Lambda 基于预训练语言模型 GPT，使模型能够捕获语言的结构，从而能产生连贯的句子。在不同任务的少量数据集上对模型进行微调，并使用微调后的模型生成新的句子。

2.1.2 增强样本使用

上面几种方式生成了一批数据增强文本，增强后的文本数量多、带噪音；原始标注数据数据量少、不含噪音。NAACL2021[4] 的一篇工作提出了一种课程学习的方式更好地学习这两种样本。

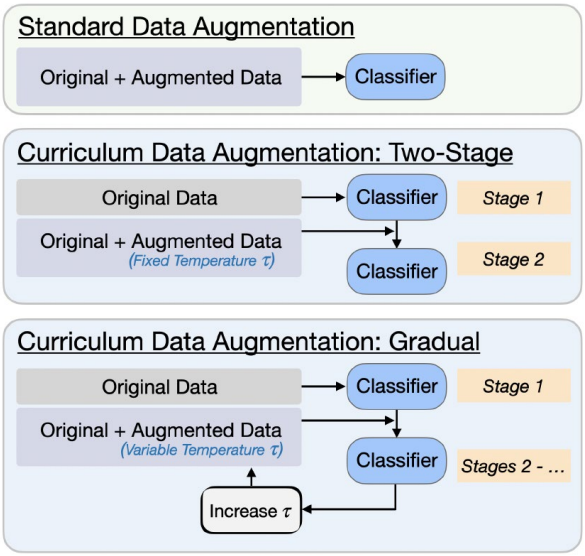

图 3　增强数据三种学习方式

Standard Data Augmentation

直接将原始数据和增强后的数据融合起来进行训练。

Curriculum Data Augmentation

课程学习先学习简单的标注数据，具备一定知识之后再学习带噪音的增强数据，有以下两种使用方式：

1. Two Stage：先在原始数据上进行训练，等到开发集收敛之后再在原始数据和增强数据上一起训练。
2. Gradual：先在原始数据上进行训练，然后逐步以线性方式添加增强数据，通过控制扰动变量 \tau τ，即一开始 \tau=0 τ=0，然后每次线性增加 0.1，直到增加到 0.5。

2.1.3 Embedding 增强

2.1.3.1 Mixup

自然语言具备系统组合性（Systematic Compositionality），能够理解通过适当重组的句子。考虑以下样例，左边两个为原始文本，通过对其中的某些词进行替换 / 重组可以生成右边可理解的样本 [5]。

图 4　自然语言重组变换样例

Mixup[6,7] 提出了一种更通用的，基于向量增强的模型，从训练数据中任抽样两个样本，构造混合样本和混合标签，作为新的增广数据。其中 (x_i, y_i) 和 (x_j, y_j) 为原始样

本，$(\hat{x}, \hat{y})$ 为重组生成的新样本。当 λ 的取值限制在 {0, 1}，就会产生图 4 的组合。

$$\hat{x} = \lambda x_i + (1-\lambda)x_j \ ,$$

$$\hat{y} = \lambda y_i + (1-\lambda)y_j \ ,$$

实验中 λ 的取值满足 Beta 分布。

$$\lambda \sim \mathrm{Beta}(\alpha, \alpha)$$

直观来看，它要求当模型的输入为另外两个输入的线性组合时，输出也是这两个数据单独输入模型后所得输出的线性组合，这其实就是要求模型近似为一个线性系统，防止模型过拟合，Mixup 变换本身可以视为一种正则化技术。 下面介绍几种 Mixup 的变体，SeqMix 和 Manifold Mixup。

a. SeqMix

SeqMix[8] 对 Mixup 生成的句子的困惑度打分，用 Discriminator 判断生成的句子困惑度，只选择困惑度较低的句子，减少噪音句子的影响。同时对于更关注于词的任务（如命名实体识别）替换 Sub-Sequence 而不是整个句子。

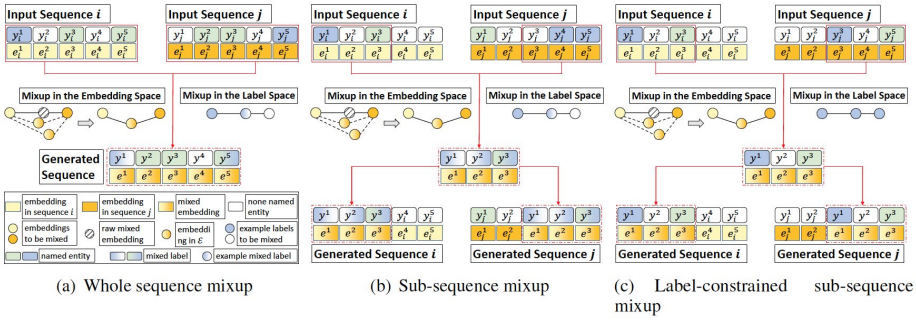

(a) Whole sequence mixup (b) Sub-sequence mixup (c) Label-constrained sub-sequence mixup

图 5 SeqMix 的几种变体

- 图 5（a）最原始的 Mixup，对整个序列做 Mixup，生成新序列。
- 图 5（b）子序列 Mixup，对合法的子序列做 Mixup，并分别代替原来的子序列，生成两个新序列。

- 图 5（c）标签限制的子序列 Mixup，只对同类别标签的子序列做 Mixup，分别代替原来的子序列，生成两个新序列。

b. Manifold Mixup

流形混合算法 Manifold Mixup[9] 将上述的 Mixup 操作泛化到特征上；特征具有更高阶的语义信息，在其维度上插值可能会产生更有意义的样本。在类似于 BERT 的模型中，随机选择层数 k，对该层的特征表示进行 Mixup，具体操作如下：

- 随机选取网络第 k 层（包括输入层）。
- 传两批数据给网络，前向传播直到第 k 层，得到隐藏特征表示 $(g_k(x), y)$ 和 $(g_k(x'), y')$。
- 对其进行 Mixup 生成新样本 $(\tilde{g}_k, \tilde{y}) = (\text{Mixup}_\lambda(g_k(x), g_k(x')), (\text{Mixup}_\lambda(y, y'))$
- 继续前向传播得到输出。
- 计算损失值和梯度。

2.1.3.2 对抗训练

对抗训练 (Adversarial training, AT)[10] 通过在输入样本上增加微小的扰动来显著提高模型 Loss，对抗训练就是训练一个能有效识别原始样本和对抗样本的模型。如果模型在对抗噪声下，依然能够保持光滑，那么整个网络就能够表现出很好的一致性。当将对抗训练应用到分类器时，对抗训练对应的损失函数为（在原有损失函数的基础上又增加了一项）：

$$-\log(p(y \mid x + r_{adv}); \theta); \text{where } r_{adv} = \arg\min_{r, \|r\| \le \epsilon} \log p(y \mid x + r; \tilde{\theta})$$

其中 x 为输入序列，θ 为模型参数，r 为输入上的扰动，$\tilde{\theta}$ 表示将模型的当前参数设置为常数，即表明在构建对抗样本时，反向传播算法不会对当前模型参数进行更新。其中 r_{adv} 的计算为：

$$r_{adv} = \epsilon \frac{g}{\| g \|_2} \text{ where } g = \nabla_x \log p(y \mid x; \tilde{\theta})$$

2.1.3.3 对比学习 R-Drop

Dropout 是深度学习模型常用的正则化手段，Regularized Dropout (R-Drop)[11] 对同一个句子做两次 Dropout，并且强制由 Dropout 生成的不同子模型的输出概率保持一致。具体来说，对于每个训练样本，R-Drop 最小化了由不同 Dropout 生成的子模型的输出概率之间的 KL 散度。

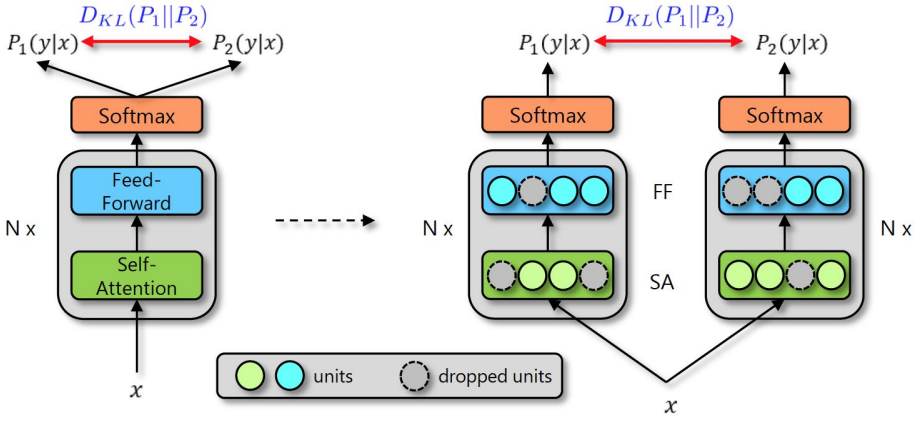

图 6　R-Drop 模型图

图 6 中左边图表示了每个输入样本 (x, y) 都会经过模型两次，得到两个概率分布，右图展示了由于 Dropout 本身的随机性，对同一个样本重复两次就可以得到两个子模型。

给定训练数据 $D = \{(x_i, y_i)\}_{i=1}^{n}$，模型为 $P^w(y \mid x)$，训练数据的交叉熵损失为：

$$L_{CE} = \frac{1}{n}\sum_{i=1}^{n} -\log P^w(y_i \mid x_i)$$

通过不同的 Dropout 可以得到两个子模型 $P_1^w(y \mid x)$ 和 $P_2^w(y \mid x)$，R-Drop 最小化两个子模型输出概率的双向 KL 散度：

$$L_{KL}^i = \frac{1}{2}(D_{KL}(P_1^w(y_i \mid x_i) \,||\, P_2^w(y_i \mid x_i)) + D_{KL}(P_2^w(y_i \mid x_i) \,||\, P_1^w(y_i \mid x_i)))$$

对于训练数据 (x_i, y_i)，最终的损失函数为：

$$L^i = L^i_{CE} + \alpha L^i_{KL} = -\log P_1^w(y_i \mid x_i) - \log P_2^w(y_i \mid x_i) + \frac{\alpha}{2}(D_{KL}(P_1^w(y_i \mid x_i) \| P_2^w(y_i \mid x_i)) + D_{KL}(P_2^w(y_i \mid x_i) \| P_1^w(y_i \mid x_i)))$$

2.2 半监督学习

在实际业务中，有大量的未标注数据，对数据进行标注需要大量的人力。半监督学习的核心目标是，希望通过标注的少量有标签数据，结合大量的无标签数据，训练出具备强泛化能力的模型，从而解决实际中的问题。

- 输入数据：大量的同领域未标注数据和少量的有标注数据。
- 主要基于以下理论基础：

1. 自洽正则化（Consistency Regularization）：对未标记的数据进行增广，产生的增广数据输入模型，它的预测值应该与原数据的预测值一致，即保持自洽。
2. 最小化熵（Entropy Minimization）：基于一个规则，分类器的分类边界不应该穿过边际分布的高密度区域。具体做法为强迫分类器对未标记数据作出低熵预测。
3. 传统正则化（Traditional Regularization）：为了提高模型泛化能力，防止过拟合的方法，如 L2 正则化等。

- 如何构造半监督学习的自洽正则化项是很多半监督模型研究的重点。
  - Temporal Ensemble、Mean Teacher、MixTemporal 这几种方法的思想都是利用了对历史模型的集成，利用历史模型预测结果 / 模型参数构造一致性正则。
  - VAT 则是利用了给 Embedding 加上扰动构造正则项。
  - MixMatch、MixText、UDA 则是利用了样本增强的结果，MixMatch 利用了图像的旋转、缩放等，MixText 和 UDA 依赖于通过回译生成的样本之间的一致性，模型结果很大一部分取决于样本增强的质量。

2.2.1 Temporal Ensembling

Temporal Ensembling[12] 采用时序融合模型，将历史预测结果的指数滑动平均（EMA）作为未标注数据的伪标签，从而和当前的预测结果构造一致性正则项。

- 有标注数据计算交叉熵损失。
- 未标注数据采用历史多次预测结果的指数滑动平均（EMA）作为重构目标计算 MSE 损失，避免采用模型一次的预测作为重构项会产生较大误差，有利于平滑单次预测中的噪声。
- 有标注数据的交叉熵损失和未标注数据的均方误差加权和作为最终损失函数。

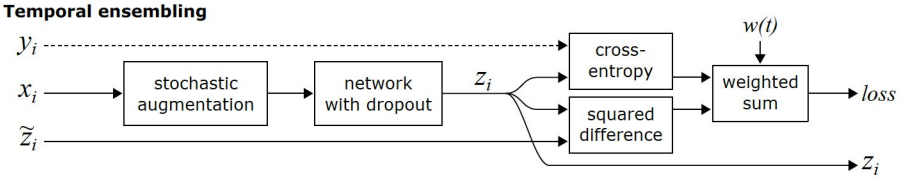

图 7　Temporal Ensembling 模型结构

其中 x_i 中包含有标注数据和未标注数据文本，y_i 表示标注数据标签，z_i 表示当前模型对 x_i 的预测结果，$\tilde{z}_i$ 表示对未标注数据多个 epoch 预测结果的滑动平均值作为其概率分布，$w(t)$ 表示未标注数据 MSE 所占权重，模型刚开始训练时 $w(t) \to 0$，此时模型倾向于学习标注数据标签，随着迭代次数增加，$w(t)$ 慢慢增加，此时模型学习大量未标注数据。

2.2.2 Mean Teacher

Mean Teacher[13] 思想上与 Temporal Ensembling 模型基本一致，Temporal Ensembling 需要矩阵保存历史预测概率，Mean Teacher 模型则是对模型参数做指数滑动平均 EDA 作为 Teacher 模型，原模型作为 Student 模型。用 Teacher 模型和 Student 模型的预测结构构造一致性正则。

- 在 Temporal Ensembling 中，无标签数据的目标标签来自模型前几个 Epoch 预测结果的加权平均。而在 Mean Teacher 中，无标签数据的目标标签来自

Teacher 模型的预测结果。

- 由于是通过模型参数的平均来实现标签预测，因此在每个 Step 都可以把无标签中的信息更新到模型中，而不必像 Temporal Ensembling 模型需要等到一个 Epoch 结束再更新。

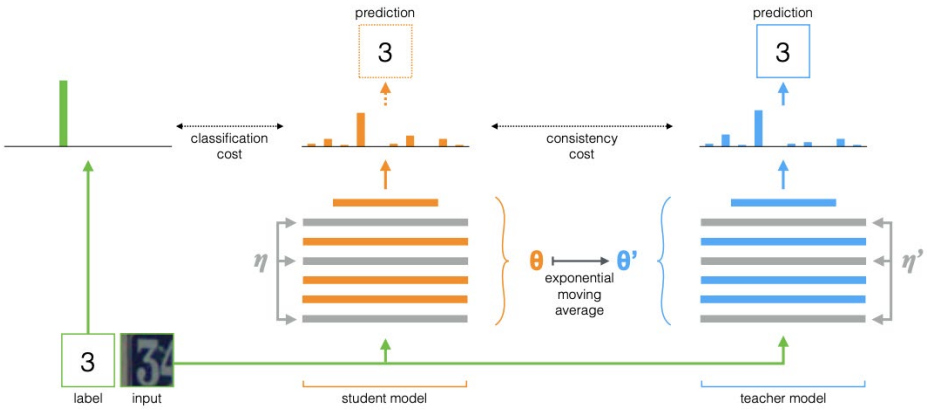

图 8　Mean Teacher 模型结构

2.2.3 VAT

虚拟对抗网络（Virtual adversarial training, VAT）[14] 与 Temporal Ensembling 模型的不同之处在于，后者采用数据增强、Dropout 来对无标签数据施加噪声，而前者施加的则是模型变化最陡峭方向上的噪声，即所谓的对抗噪声。如果模型在对抗噪声下，依然能够保持光滑，那么整个网络就能够表现出很好的一致性。虚拟对抗训练通过对模型添加正则使得一个样本的输出分布与加扰动之后的输出分布相同来将对抗训练扩展到半监督领域。

- 首先对未标注数据抽取随机标准正态扰动 $d \sim \mathcal{N}(0,1)$ 加到 Embedding 上，并用 KL 散度计算梯度。
- 然后用得到的梯度计算对抗扰动，并进行对抗训练。
- 标注数据的交叉熵损失和未标注数据对抗损失作为最终损失函数。

2.2.4 MixMatch

MixMatch[15] 是集大成者，将数据增强、Mixup、Sharpening 等方法融合起来，起重要作用的两个模块就是 Mixup 和 Sharpening。

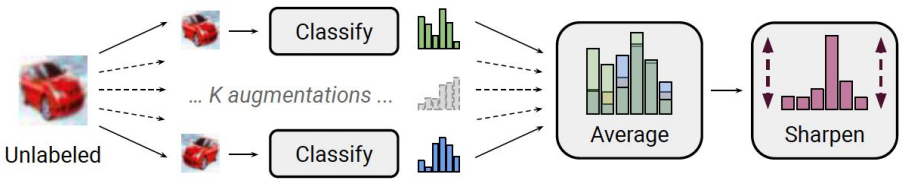

图 9　MixMatch 无标注数据标签构造

- 在图像领域未标注数据的 k 条增强数据来自图像的旋转、缩放等。
- 输入标注数据 $X=(x_b,p_b)$，未标注数据 $U=(u_b)$，利用图 9 生成未标注数据的标签 q_b，q_b 即是模型对未标注数据和它的条增强数据预测结果的平均值。
- 将 $X=(x_b,p_b)$ 和 $U=(u_b,q_b)$ 混合做 Mixup 操作。
- 计算标注数据的交叉熵损失和未标注数据的一致性正则损失项。

2.2.5 MixText

MixText[16] 整个思路和 MixMatch 是一致的。首先利用 Back Translation 对未标注数据做数据增强，利用模型对增强后的数据和原数据的预测结果的加权和作为未标注数据的标签，再对有标注数据和未标注数据同时做 Mixup。

- 无标注数据通过 Back Translation 做数据增强。
- 利用模型对增强后的数据和原数据的预测结果的加权和作为无标注数据的标签。
- 同时对有标注数据和无标注数据做 Mixup。
- 学习有标注数据的交叉熵损失和无标注数据的一致性正则。

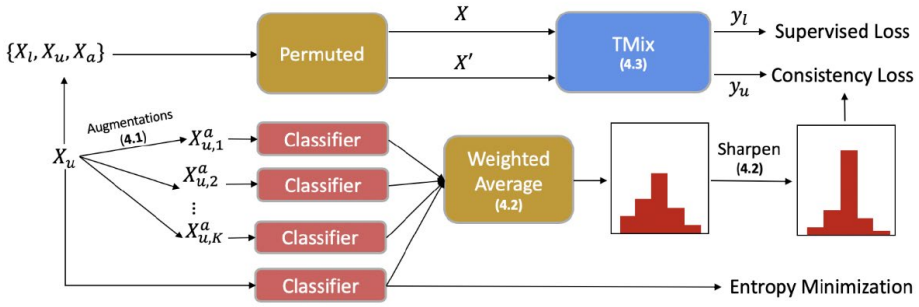

图 10　MixText 模型结构图

其中 x_l 是标注样本，x_u 是未标注样本，x_a 是未标注样本的回译增强样本。与 Manifold Mixup 相似，同样是对模型第 mm 层的隐藏表示做 Mixup，可以挖掘到句子之间的隐式关系。对有标签和无标签数据同时进行插值，可以在学习有标签句子的同时利用无标签句子的信息。

2.2.6 MixTemporal

借鉴 MixMatch 和 MixText 思想，但对无标注数据的预测不是通过 EDA 或者回译这种数据增强，而是利用 Temporal Ensemling 的思想，对多个 Epoch 历史预测结果的指数滑动平均（EMA）作为未标注数据的伪标签，不需要额外的同义词典和翻译工具等，实现较为方便。

最终损失函数计算两部分组成：Mixup 之后的交叉熵 Loss+ 无标注数据一致性正则 Loss。

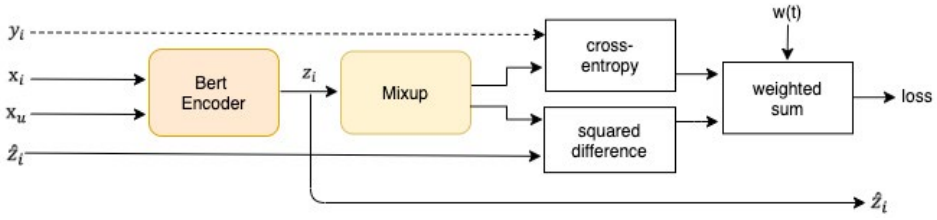

图 11　MixTemporal 模型结构图

其中 x_i 是标注样本，y_i 表示标注样本标签，z_i 表示当前模型对 x_i 的预测结果，$\tilde{z}_i$ 表示对未标注数据多个 Epoch 预测结果的滑动平均值作为其概率分布，$w(t)$ 表示未标注数据 MSE 所占权重。

2.2.7 UDA

UDA[17] 来自 Google，同样也是采用一致性正则。对于图像 UDA 针对图像采取一种高质量的数据增强方法 RandAugment，对于文本 UDA 使用的是回译和非核心词替换，用 TF-IDF 值来衡量一个词对于一段文本的重要性，来判断该词是否要被替换，再联合回译做替换。

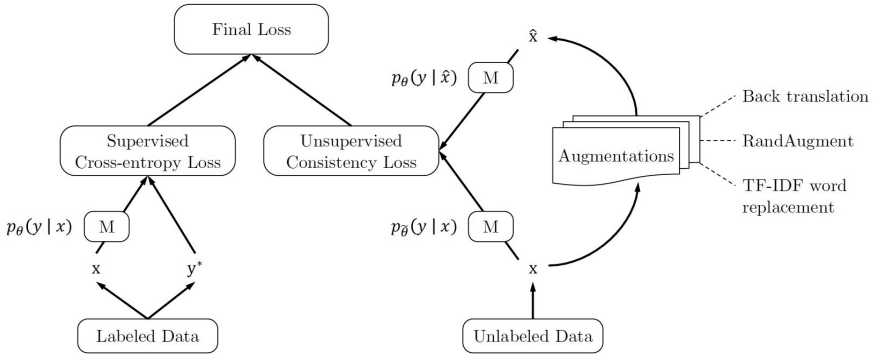

图 12　UDA 模型结构图

训练技巧：

- **Confidence-based masking**：通过阈值筛选一致性正则项。
- **Sharpening Predictions**：让预测的概率分布更加极端化。
- **Domain-relevance Data Filtering**：去掉领域不相关的数据，同样根据置信度来选择。

2.3 集成学习 + 自训练

在有监督学习算法中，目标是学习出一个稳定的且在各个方面表现都较好的模型，但实际情况往往不这么理想，有时只能得到多个有偏好的模型（弱监督模型，在某些方面表现的比较好）。集成学习就是组合这里的多个弱监督模型以期得到一个更好更全

面的强监督模型，集成学习潜在的思想是即便某一个弱分类器得到了错误的预测，其他的弱分类器也可以将错误纠正回来。如果待组合的各个模型之间差异性（Diversity）比较显著，那么 Ensemble 之后通常会有一个较好的结果。

自训练使用少量的标记数据和大量的未标记数据对模型进行联合训练，首先使用经过训练的分类器来预测所有未标记数据的标签，然后选择置信度较高的标签作为伪标注数据，将伪标记数据与人工标记的训练数据联合起来重新训练分类器。

- 集成学习：训练多个不同的模型，如 BERT 模型、Mixup 模型、半监督学习模型。
  - 分别用每个模型预测数据池 U（Unlabeled Data）的标签概率分布。
  - 计算标签概率分布的加权和，得到数据池 U 的概率分布 Soft Prediction。
- 自训练：训练一个模型用于组合其他各个模型。
  - Student 模型学习数据池 U 中高置信度样本的 Soft Prediction。
  - Student 模型作为最后的强学习器。

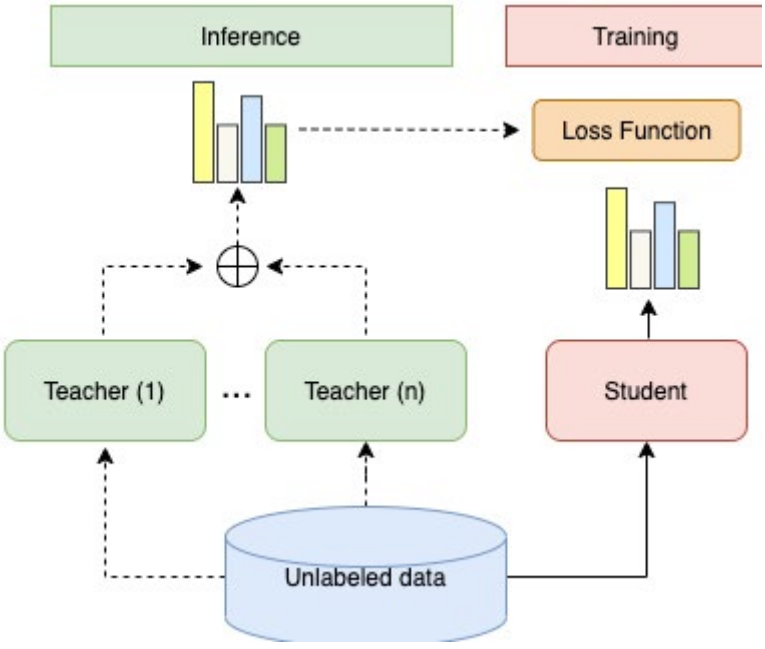

图 13　集成学习 + 自训练结构图

2.4 领域迁移

领域迁移主要解决少样本，多类别的问题。

MAML[18]：2017 年发表被广泛引用的方法，但是训练过程较为复杂，后面被 Meta-Baseline 方法在多个领域超越了。

Meta-Baseline[19]：2020 年发表的新基线方法，大幅超越前者，且方法简单，因此称为 New Baseline。Meta-Baseline 方法，通过在所有 Base Classes 上预先训练分类器，并在基于最近质心的少样本（Few-Shot）分类算法上进行元学习。

- Classifier-Baseline: 在所有的 Base Classes 上使用交叉熵损失预训练分类器，然后移除最后一层 FC，得到 Feature Encoder f_θ。
- Meta-Baseline
  - Pre-Training Stage：训练 Classifier-Baseline 模型。
  - Meta-Learning Stage：给定一个 Few-Shot Task（N-way k-shot），计算每个类别的特征平均值 $w_c = \frac{1}{|S_c|}\sum_{x \in s_c} f_\theta(x)$。
  - 针对于每个 Query-Set 中的样本用余弦相似度计算与每个类别的相似度，减少类内方差。

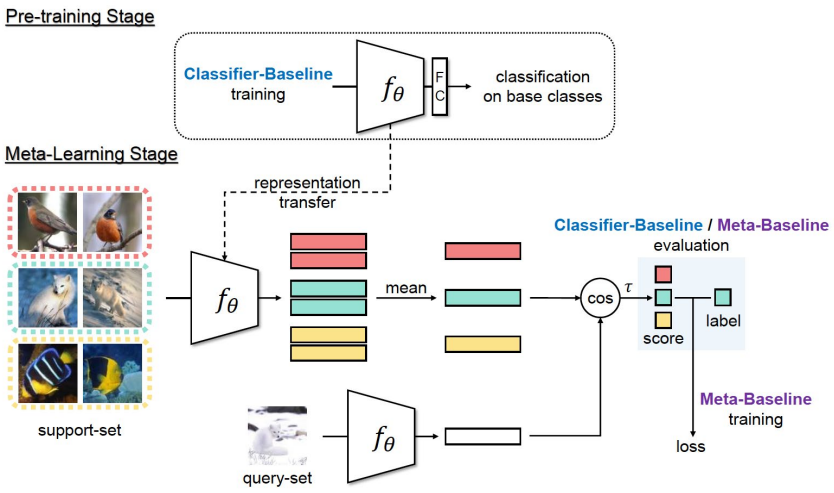

图 14　Meta-Learning Stage 结构图

2.5 主动学习

Active Learning（主动学习）通过一定的算法查询最有用的未标记样本，并交由专家进行标记，然后用查询到的样本训练分类模型来提高模型的精确度。模型抛出的未标注数据为“Hard Sample”，对于“Hard Sample”的不同定义可以衍生出一大堆的方法，如可以是 Ambiguous Sample，即模型最难区分的样本；可以是对模型提升（改变）最大的样本，如梯度提升最大；可以是方差减小等等，相比与有监督学习，主动学习通过让模型更多的关注或学习“Hard Sample”，以期在较少的训练样本下获得较好的模型。

- 查询策略是主动学习的核心之处，不确定性采样的查询是最常用的，不确定性采样的关键是描述样本的不确定性，通常有如下思路：
  - 置信度最低（Least Confident），如对于三分类的情况下，对两个样本预测的概率分别是 (0.8, 0.1, 0.1) 和 (0.51, 0.31, 0.18)，在这种情况下第二个数据更“难”被区分，因此更有标注价值。
  - 边缘采样（Margin Sampling），选择那些更容易被判定成两类的样本数据，即这些数据被判定成两类的概率相差不大，边缘采样选择模型预测最大和第二大的概率差值最小的样本。
  - 熵方法（Entropy），用熵来衡量一个系统的不确定性，熵越大表示系统的不确定性越大，熵越小表示系统的不确定性越小，可以选择那些熵比较大的样本数据作为待标注数据。
- 迭代思路：输入，初始少量标注数据 L_0、未标注数据池 U、深度学习模型 M。
  1. 标注数据集 $L \leftarrow L_0$。
  2. 用 L 训练模型 M，并对未标注数据池 U 进行预测。
  3. 用对应的查询策略选择 U 中需要标注的样本进行标注，并将其加入到标注数据集 L 中。
  4. 重复 2-3 过程，直到达到精度或者或者标注预算。

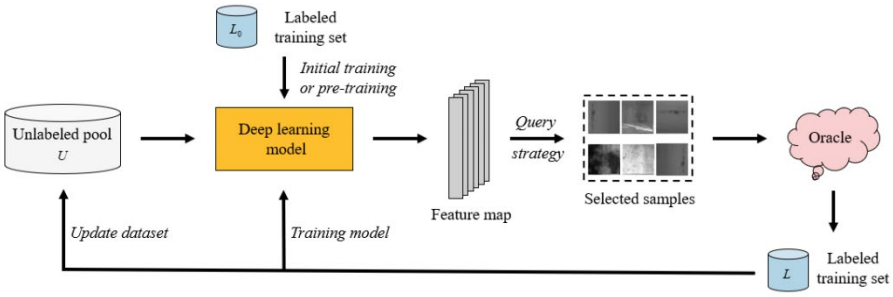

图 15　主动学习迭代过程

3. 应用实践

图 16 展示了基于 BERT[20] 的模型微调，包括句间关系任务和单句分类任务。

1. **单句分类任务**：BERT 模型预训练中的 NSP 任务使得 BERT 中的“[CLS]”位置的输出包含了整个句子对（句子）的信息，我们利用其在有标注的数据上微调模型，给出预测结果。常见单句分类任务如文本分类、情感分类等。
2. **句间关系任务**：对两个句子用“[SEP]”进行拼接，用“[CLS]”位置的输出判断两个句子之间的关系。常见句间关系任务如自然语言推理、语义相似度判断等。

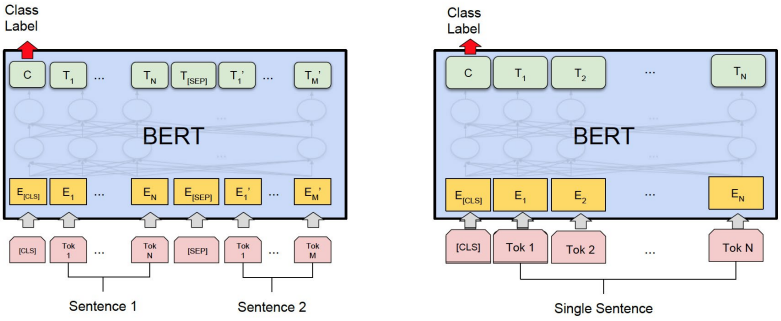

图 16　基于 BERT 的微调模型

3.1 实验结果

在上面我们提到了主要有以下两个评价标准，提升算法效果和节省标注数据，我们分

别在美团业务和通用 Benchmark 数据集上进行了微调实验。

3.1.1 小样本学习，提升算法效果

数据集	数据量	base	数据增强				半监督学习		集成学习+自训练
		base(%)	mixup(%)	AT(%)	R-Drop(%)	manifold-mixup(%)	temporal(%)	mixTemporal(%)	ensemble(%)
医美题材（单句分类）	500	83.73	84.27	83.73	83.87	82.66	**84.67**	**84.40**	84.67
	1000	86.42	**87.23**	86.96	**87.09**	86.29	86.15	85.21	87.09
	3000	88.03	89.11	88.97	**89.78**	88.17	88.57	89.24	**89.24**
POI打标情感分析（句间关系）	500	85.76	85.6	85.8	85.59	86.54	**86.74**	85.46	**86.91**
	1000	85.32	86.44	86.74	86.87	**87.11**	85.66	86.84	**87.28**
	3000	87.88	87.98	88.79	87.95	88.72	88.52	**89.09**	**88.32**

图 17　小样本学习在美团业务 Benchmark 上效果对比（加粗表示了得分最高的两个结果，下划线表示超出 Baseline 结果）

数据集	数据量	base	数据增强				半监督学习		集成学习+自训练
		base(%)	mixup(%)	AT(%)	R-Drop(%)	manifold-mixup(%)	temporal(%)	mixTemporal(%)	ensemble(%)
TNEWS 今日头条中文新闻（单句分类）	500	59.42	59.46	60.36	**60.31**	59.29	60.25	59.14	**60.81**
	1000	60.06	60.08	60.6	60.9	60.67	**61.03**	60.85	**61.63**
	3000	61.48	61.33	62.19	61.72	61.76	**62.69**	61.93	**62.84**
BQ 百度文本相似度（句间关系）	500	74.01	74.51	74.61	73.91	74.62	**75.01**	74.15	**74.93**
	1000	76.49	76.92	77.16	76.96	76.28	**77.71**	77.21	**77.45**
	3000	79.21	79.26	80.04	**80.66**	79.11	79.96	80.44	**81.36**
AFQMC 蚂蚁金融语义相似度（句间关系）	500	62.11	64.29	64.66	62.55	62.23	**67.3**	**67.07**	65.33
	1000	65.01	65.26	65.73	62.53	63.92	**67.4**	**67.44**	65.89
	3000	68.67	68.37	67.65	68.67	68.48	68.35	**70.04**	**69.94**
OCNLI 中文原版自然语言推理（句间关系）	500	53.66	54.41	**56.00**	54.98	48.30	50.71	50.71	**55.35**
	1000	59.22	59.89	60.00	60.4	58.84	58.33	**60.74**	**61.38**
	3000	65.49	66.2	66.4	66.16	**66.61**	66.37	65.89	**67.83**

图 18　小样本学习在中文通用 Benchmark 上效果对比（Dev 集结果，加粗表示了得分最高的两个结果，下划线表示超出 Baseline 结果）

图 17 和图 18 列出了四种 Embedding 增强，两种半监督学习，以及集成学习 + 自训练模型的结果。我们也尝试过上文提到的其他方法，如 UDA/MixText，这些方法依赖于外部翻译软件翻译的结果，效果不稳定。因此我们主要使用了以上模型，几种模型的比较如下：

- **数据增强**：四种 Embedding 增强结果中，对抗训练（AT）表现最为稳定，平均可提升模型 1pp。
- **半监督学习**：数据增强相对于半监督学习结果较为稳定，但半监督学习可以带来的提升较为明显，可提升模型 1.5pp−2pp，其中在 AFQMC 数据集上提升模型 2pp−4pp。
- **集成学习 + 自训练**：集成学习 + 自训练融合了单模型在未标注数据上的预测结果，基本可以达到或这接近最好的结果，平均可提升模型 1.5pp−2pp。

3.1.2 主动学习，减少训练样本

主动学习（Active Learning）选择置信度较低的样本用作下一批标注，可以减少重复 / 相似样本标注，降低标注成本。在新项目标注数据从无到有的时候，可以使用 active learning 选择启动样本。

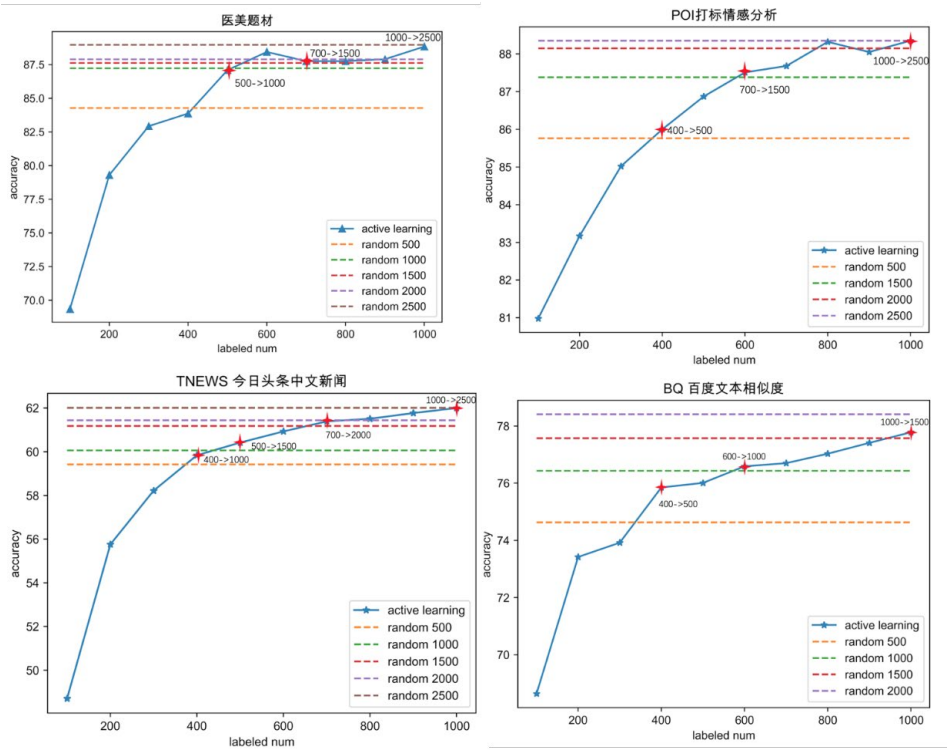

图 19　Active Learning 与随机选择样本在小样本情况下比较

在目前数据集下，平均 500 条 Active Learning 选择数据可以达到 1000 条随机样本结果，900 条数据可以接近 1500 条随机样本结果。在新项目标注数据从无到有的时候，可以使用 Active Learning 选择启动样本。

3.2 在美团业务中的应用

3.2.1 医美题材分类

对美团和点评的笔记内容按题材分为 8 类：猎奇、探店、测评、真人案例、治疗过程、避坑、效果对比、科普。用户点击某一种题材时，返回对应的笔记内容，上线至美团和点评 App 医疗美容频道的百科页、方案页经验分享。该任务是典型的文本分类任务，小样本学习利用 2,989 条训练数据准确率达到了 89.24%。

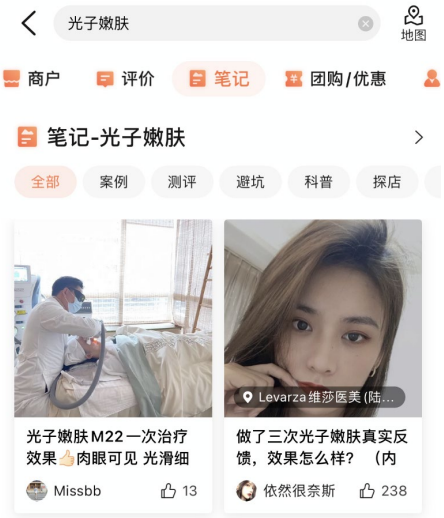

图 20　医美题材分类示例

3.2.2 攻略识别

从 UGC 和笔记中挖掘旅游攻略，提供旅游攻略的内容供给，应用于景点精搜下的攻略模块，召回内容为描述旅游攻略的笔记。该任务为二分类任务，小样本学习利用 384 条训练数据准确率达到了 87%。

图 21　攻略识别示例

3.2.3 医美功效打标

对美团和点评的笔记内容按功效进行召回，功效的类型有：补水、美白、瘦脸、除皱等，上线至医美频道页。该任务是句间关系任务，全量笔记内容为 104 万，有 110 种功效类型需要打标，小样本学习仅用 2909 条训练数据准确率达到了 91.88%。

图 22　医美功效打标示例

3.2.4 医美品牌打标

品牌上游企业有针对旗下产品进行品牌宣传和营销的诉求，而内容营销是当前主流、有效的营销方式之一。品牌打标就是为每种品牌如“伊肤泉”、“术唯可”召回详细介绍该品牌的笔记内容。先用品牌词进行匹配，再判断品牌词和匹配到的笔记内容的相关性，是详细描述该品牌，还是简单提及到品牌名字，上线至医美品牌馆。该任务是句间关系任务，有 103 种品牌，大类品牌 15 种每种标注 64 条数据，其余品牌每种标注 5–8 条数据，小样本学习仅用 1676 条训练数据准确率达到了 88.59%。

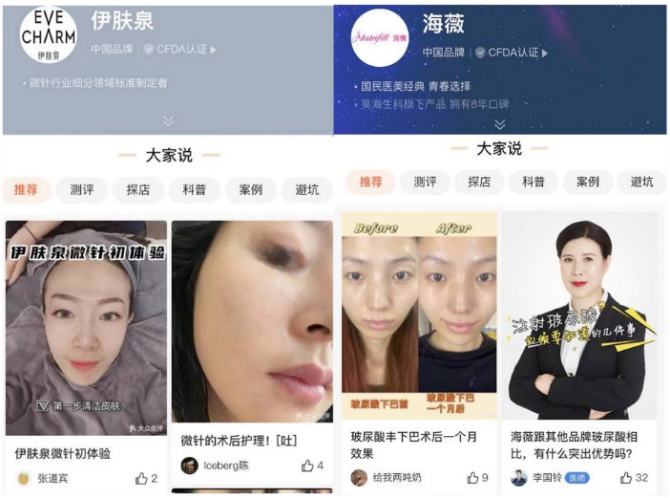

图 23　医美品牌打标示例

3.2.5 其他业务应用

- **医美评价真实性**：点评和美团医美业务如果存在虚假评论，会对体验有比较大的伤害，需要通过模型检测出来。通过 Active Learning 选取标注数据，数据增强、半监督学习和集成学习 + 自训练优化模型，最后业务方仅标注 1757 条数据，模型在检测感知虚假评价的准确率上就能达到 95.88%，超出业务预期。
- **POI 打标情感分析**：该任务为句间关系任务，判断 Query 和内容的情感导向（正面、负面、不确定和不相关）。已有模型在 1 万条数据上训练，通过小样本学习，在已有模型上提升模型精度 0.63pp。

- **学城（美团内部学习工具）文本分类**：该任务为文本分类任务，将文本分为 17 种类别。已有模型在 700 条数据上训练，通过小样本学习，在已有模型上提升模型精度 2.5pp。

4. 未来展望

1. **持续改进现有模型、探索更多模型**。目前的实验结果还有很大的改进空间，需要不断探索，改进模型；同时探索更多的领域迁移模型，并应用到业务中，达成业务方可以用最少的数据训练最好的结果。
2. **在更多任务类型上进行实验**。目前主要是单句分类、句间分类等任务类型上进行实验，需要进一步 MRC 模型、命名实体识别模型。
3. **深入探索领域迁移，训练通用模型**。目前，我们对接的业务较多，因此也积累了不少领域的文本分类和句间关系数据集，希望能够训练一个通用模型用于该领域的各项任务，从而在一个新的业务中使用更少量的数据就能达到很好的业务效果。如可以通过 Facebook 的 EFL[21] 模型，将该领域下的文本分类任务和句间关系任务都重新表述为文本蕴含任务训练一个通用模型，可以直接在新的业务上进行迁移。
4. **建设小样本学习平台**。目前正在将小样本学习能力集成到公司统一的 BERT 平台，开放给公司各业务方灵活使用。后续，在对小样本学习进行了更加深入的探索之后，我们会尝试建立单独的小样本学习平台，提供更多的低资源学习能力。

参考文献

[1] Wei J, Zou K. Eda: Easy data augmentation techniques for boosting performance on text classification tasks[J]. arXiv preprint arXiv:1901.11196, 2019.

[2] Kobayashi S. Contextual augmentation: Data augmentation by words with paradigmatic relations[J]. arXiv preprint arXiv:1805.06201, 2018.

[3] Anaby-Tavor A, Carmeli B, Goldbraich E, et al. Not Enough Data? Deep Learning to the Rescue![J]. arXiv preprint arXiv:1911.03118, 2019.

[4] Wei J, Huang C, Vosoughi S, et al. Few-Shot Text Classification with Triplet Networks, Data Augmentation, and Curriculum Learning[J]. arXiv preprint

arXiv:2103.07552, 2021.
[5] Andreas J. Good-enough compositional data augmentation[J]. arXiv preprint arXiv:1904.09545, 2019.
[6] Zhang H, Cisse M, Dauphin Y N, et al. Mixup: Beyond empirical risk minimization[J]. arXiv preprint arXiv:1710.09412, 2017.
[7] Guo D, Kim Y, Rush A M. Sequence-level mixed sample data augmentation[J]. arXiv preprint arXiv:2011.09039, 2020.
[8] Zhang R, Yu Y, Zhang C. Seqmix: Augmenting active sequence labeling via sequence mixup[J]. arXiv preprint arXiv:2010.02322, 2020.
[9] Verma V, Lamb A, Beckham C, et al. Manifold mixup: Better representations by interpolating hidden states[C]//International Conference on Machine Learning. PMLR, 2019: 6438-6447.
[10] Miyato T, Dai A M, Goodfellow I. Adversarial training methods for semi-supervised text classification[J]. arXiv preprint arXiv:1605.07725, 2016.
[11] Liang X, Wu L, Li J, et al. R-Drop: Regularized Dropout for Neural Networks[J]. arXiv preprint arXiv:2106.14448, 2021.
[12] Laine S, Aila T. Temporal ensembling for semi-supervised learning[J]. arXiv preprint arXiv:1610.02242, 2016.
[13] Tarvainen A, Valpola H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results[J]. arXiv preprint arXiv:1703.01780, 2017.
[14] Miyato T, Maeda S, Koyama M, et al. Virtual adversarial training: a regularization method for supervised and semi-supervised learning[J]. IEEE transactions on pattern analysis and machine intelligence, 2018, 41(8): 1979-1993.
[15] Berthelot D, Carlini N, Goodfellow I, et al. Mixmatch: A holistic approach to semi-supervised learning[J]. arXiv preprint arXiv:1905.02249, 2019.
[16] Chen J, Yang Z, Yang D. Mixtext: Linguistically-informed interpolation of hidden space for semi-supervised text classification[J]. arXiv preprint arXiv:2004.12239, 2020.
[17] Xie Q, Dai Z, Hovy E, et al. Unsupervised data augmentation for consistency training[J]. arXiv preprint arXiv:1904.12848, 2019.
[18] Finn C, Abbeel P, Levine S. Model-agnostic meta-learning for fast adaptation of deep networks[C]//International Conference on Machine Learning. PMLR, 2017: 1126-1135.
[19] Chen Y, Wang X, Liu Z, et al. A new meta-baseline for few-shot learning[J]. arXiv preprint arXiv:2003.04390, 2020.
[20] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. arXiv preprint arXiv:1810.04805, 2018.
[21] Wang S, Fang H, Khabsa M, et al. Entailment as Few-Shot Learner[J]. arXiv preprint arXiv:2104.14690, 2021.

作者简介

骆颖、徐俊、谢睿、武威等，均来自美团搜索与 NLP 部 /NLP 中心。

美团外卖广告智能算力的探索与实践

作者：顺辉　家宏　宋伟　国梁　乾龙　乐彬

1. 业务背景

目前，美团外卖日订单量已突破 4000 万，成为美团最为重要的业务之一。外卖广告服务也从最初的支撑单一业务线发展到现在的十余条业务线，服务整体承受的流量日益增长，所消耗的机器资源也达到了一定的规模。

在外卖场景下，流量呈现明显的双峰结构，即午餐和晚餐两个时段为流量波峰，其余时段流量较小。在这种流量特点下，外卖广告服务在高峰时段面临较大的性能压力，在非高峰时段存在大量算力冗余，从全局来看，机器算力分配效率低，流量价值仍然具有较大的挖掘空间。一方面，流量消耗的算力没有根据流量价值进行动态的分配，造成系统在高价值流量上算力分配不足，价值没有得到充分的挖掘，而在低价值流量上，却存在浪费大量算力的现象；另一方面，在非高峰时段，系统流量较低，导致系统的整体资源利用率偏低，限制了系统获取更高的业务收益。

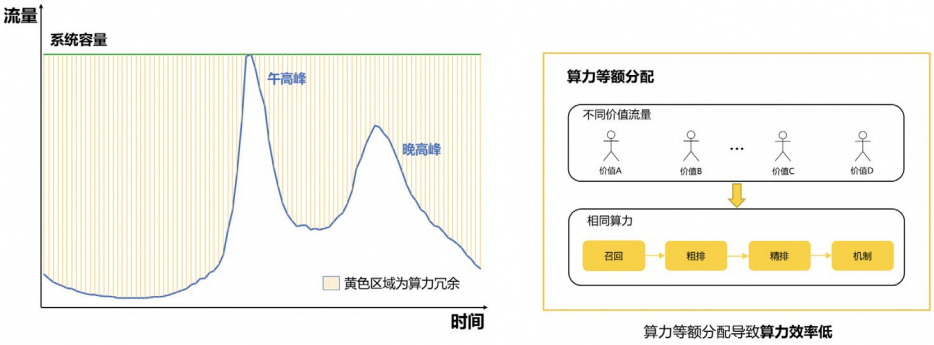

算力等额分配导致**算力效率低**

因此，算力需要进行更合理的分配来得到更加高效的利用。当前业界对于动态算力分配的研究较少，以阿里巴巴定向广告平台的 DCAF[1] 为代表，该方案根据流量价值进行差异化的算力分配，对不同价值的流量分配不同的候选队列长度，实现有限资源约束下的收益最大化。DCAF 提供了一种优秀的解决方案，但该方案在外卖广告场景下

存在一定的局限性。

针对外卖广告场景，外卖广告技术团队在 DCAF 方案的基础上进行了一系列探索和改进，首次进行了队列弹性分配和模型弹性分配相结合的尝试，并取得了不错的收益。一方面，在机器资源持平的情况下，CPM 可以提升 2.3%；另一方面，在业务收益持平的情况下，机器资源可以减少 40%，最后我们在外卖列表广告精排阶段推全了机器资源持平的方案。

2. 整体思路

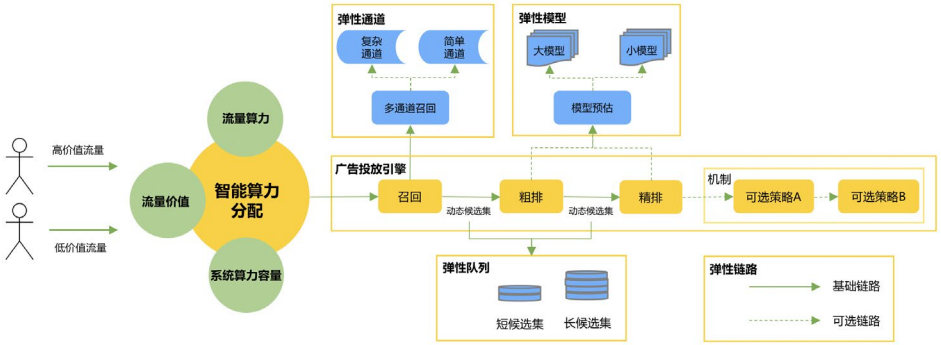

在外卖广告投放引擎中，为应对极大的在线流量压力和庞大的候选集，我们将整个检索过程设计成候选集依次递减的漏斗型级联架构，主要包含召回、粗排、精排、机制等模块。

实现智能算力的整体思路，是在系统算力容量约束下，对不同价值流量进行差异化算力分配，从而提高在广告检索过程中的算力分配效率，实现收益的最大化。智能算力主要包括以下四个要素：

1. 流量价值量化：流量价值指流量为平台、广告商家、用户三方带来的收益，系统需要具备量化流量价值的能力。

2. 流量算力量化：流量算力指流量在系统内消耗的机器资源，在外卖广告场景下，流量消耗的算力和候选集大小、召回通道数量、模型大小、链路复杂度等系统变量紧密相关，同样系统需要具备量化流量算力的能力。

3. 系统算力容量量化：系统算力容量指系统的机器资源总和，和流量算力量化的量纲一致，通常可以通过压测等手段获取系统的算力容量；在系统算力分配过程中，需要保证总体流量算力消耗不超过系统的算力容量。

4. 智能算力分配：基于以上三个要素，在广告投放引擎全链路进行智能算力分配，我们把算力分配的手段定义为“**弹性动作**”，在外卖广告场景下，我们主要归纳了以下四种动作：

- **弹性队列**：线上检索是一个漏斗的过程，不同价值流量可以在级联漏斗的各模块中分配不同候选队列长度。
- **弹性模型**：在模型预估服务中，不同价值流量可以分配不同模型，大模型相对小模型预估效果更好的同时消耗的算力也更多。
- **弹性通道**：在多通道召回中，不同价值流量可以分配不同的召回通道。
- **弹性链路**：在检索链路上，不同价值流量可以分配不同复杂度的检索链路。 这些弹性动作的可选范围，定义为“**弹性档位**”，如队列长度 100 和 200 对应弹性队列的两个不同档位。**在智能算力下，算力的分配过程即弹性动作和弹性档位的智能决策过程**。

挑战分析

为了让智能算力在外卖广告场景下落地，我们主要面临着如下的挑战：

- **问题求解**
  - **挑战点**：智能算力的目标是最优化算力资源分配，这就要求我们对“在系统算力约束下，最大化流量收益”这个问题进行求解。
  - **应对思路**：参考已有方案，将问题拆解为流量价值预估、流量算力预估以及算力分配三个子问题进行求解，并针对外卖广告场景进行探索和改进。
- **系统稳定性保障**
  - **挑战点**：将系统算力分配托管给智能算力框架，从等额算力分配到智能算力分配，不仅需要保证智能算力框架本身的稳定性，更需要保证系统全链路的

平稳运行。

- **应对思路**：除了监控报警、熔断降级等常规保障手段，我们实现了基于系统状态的实时调控功能，保障系统稳定性。

- **通用性 & 扩展性**
  - **挑战点**：兼顾基础能力的复用和个性化能力的扩展，支撑外卖广告推荐和搜索两大方向，多个业务场景的接入。
  - **应对思路**：核心组件以 SDK 形式提供可复用、可扩展能力，同时基于通用的价值评估指标、算力评估指标和智能算力框架，支撑多弹性动作的组合决策和多业务场景的高效接入。

3. 方案设计

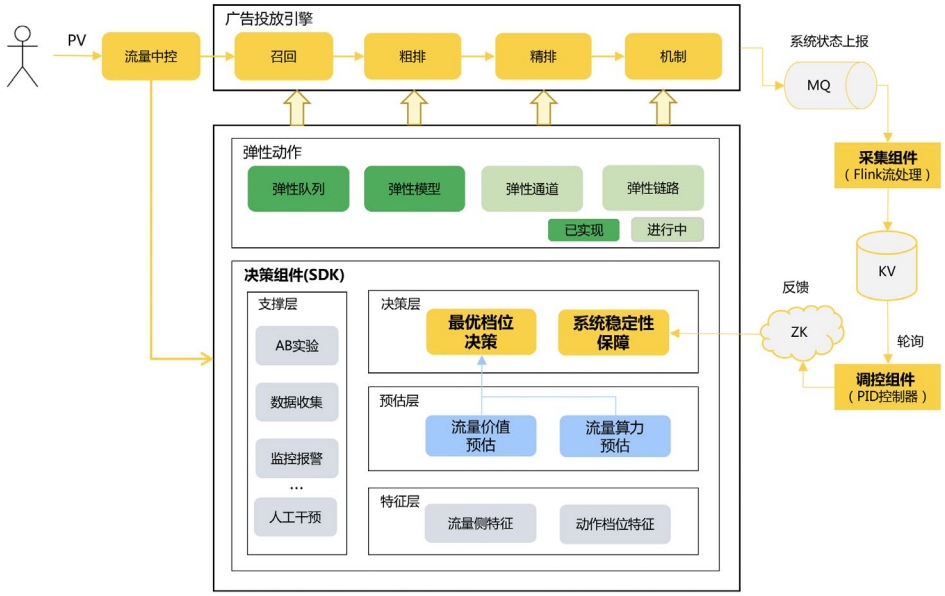

经过工程团队和算法团队深度 Co-Design 后，我们设计了一套多动作组合决策的智能算力框架。整个框架由决策组件、采集组件和调控组件组成，其中决策组件作为智能算力框架的核心，以 SDK 形式嵌入应用服务，提供可复用可扩展的多动作组合**最优档位决策能力**和**系统稳定性保障能力**，为广告投放引擎的各阶段赋能；采集组件和

调控组件为系统稳定性保障提供支撑。下面主要对最优档位决策和系统稳定性保障两个模块进行详细介绍。

3.1 最优档位决策

在业内已有弹性队列求解方案的基础上，我们进行一系列探索和改进：

- 通过选用更加通用的流量算力评估指标，同时增加流量算力预估模块，保证量化指标通用的同时提高精确度，解决**算力量化不通用和不精确**的问题。
- 通过构建特殊档位，首次尝试了**弹性队列和弹性模型的结合**，解决了**部分流量无法建模**的问题。

基于以上策略，我们实现了多弹性动作组合最优化档位决策。

3.1.1 问题建模

现有方案

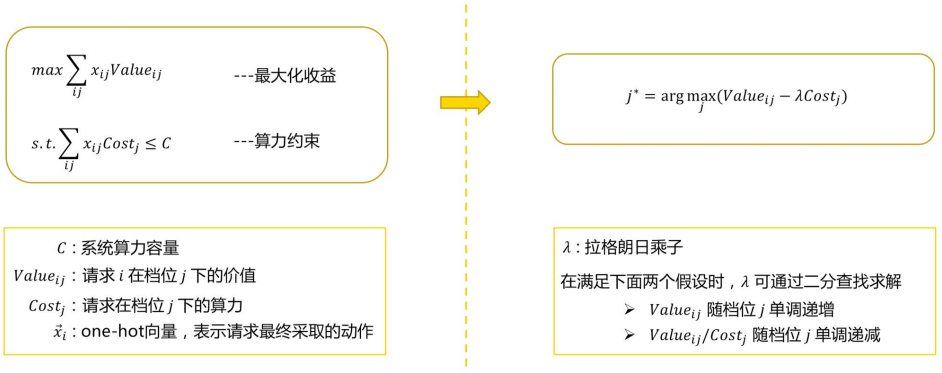

DCAF[1] 将该问题转化为对应的对偶问题进行求解，得到决策公式，实现弹性队列分配。

方案改进

上述建模方案在外卖广告场景中存在以下问题：

- **算力量化问题**
  - **问题描述**：在原论文中，算力仅与队列长度相关。实际上，外卖广告系统中，相同长度的不同流量算力消耗可能不同（比如不同来源的流量会走不同的模型和链路），仅用队列长度无法准确量化算力。
  - **解决方案**：为了建模流量的算力消耗，同时拟合流量侧特征，我们将算力由$Cost_j$拓展为$Cost_{ij}$，并增加流量算力预估模块。
- **低价值流量建模问题**
  - **问题描述**：推导中要求对任意请求满足$max_j(Value_{ij} - \lambda Cost_{ij}) \geq 0$，此时，一些价值低、算力消耗大的流量（$max_j(Value_{ij} - \lambda Cost_{ij}) < 0$）将无法被建模。另外，在外卖广告场景中，由于返回队列必须满足填充率等业务要求，队列长度不能随意选取，档位空间必须满足$Q_{min} \leq j \leq Q_{max}$（$Q_{min}$和$Q_{max}$分别表示当前请求的档位上下界，且$Q_{min}$的值一般为最小填充广告数），这进一步导致了更多的流量不满足约束。
  - **解决方案（弹性模型）**：为了覆盖外卖广告场景中的所有流量，我们增加档位$j = j_0$，在实际落地中该档位对应为将请求分配给简单模型；相对复杂模型，流量分配简单模型后，算力消耗趋近于0（简单模型可以是词表或LR模型等）。

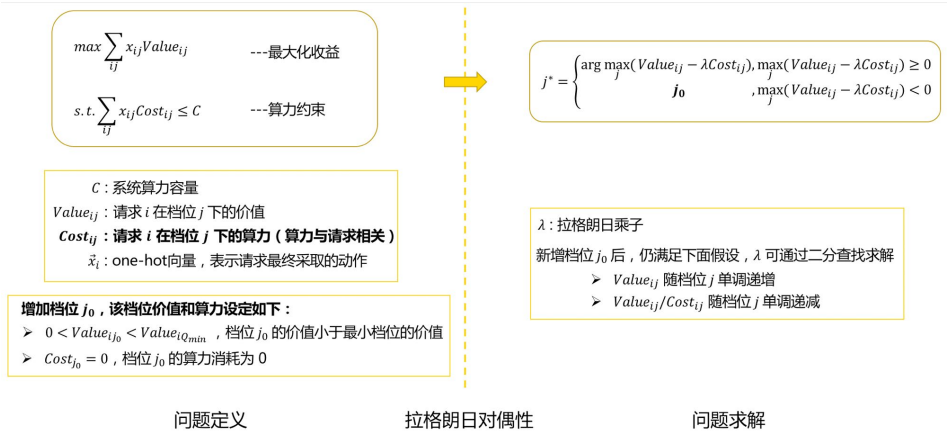

如图所示，由于档位 $j=j0$ 的算力和价值已知，无需对不同模型的价值和算力进行预估，后续的流量价值预估和流量算力预估工作都面向弹性队列即可。

3.1.2 决策框架

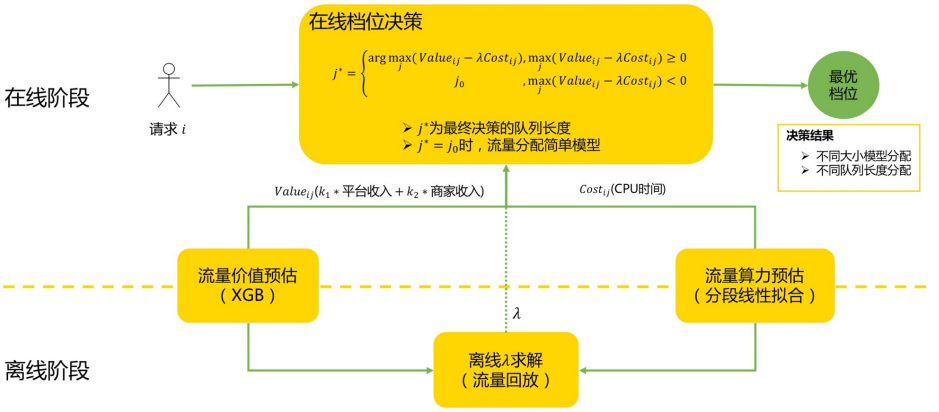

如图所示，最优档位决策模块分为离线和在线两个阶段，包含如下四个子模块：

- **流量价值预估模块**（离线 + 在线）：预估流量在不同档位下的价值。
- **流量算力预估模块**（离线 + 在线）：预估流量在不同档位下的算力。
- **离线 λ 求解模块**（离线）：通过回放历史流量，利用二分查找算法求解最优 λ。
- **在线决策模块**（在线）：对线上流量，基于档位决策公式计算最优档位，并根据计算结果分配不同模型和队列长度。

3.1.3 流量价值预估

流量价值预估是智能算力决策的核心，要求具备一定准确性。而线上进行模型预估会增加检索链路耗时，我们采用离线 XGB 模型预估 + 在线查找词表的方案，既保证了预估的准确性，又足够轻量。

价值评估指标选取：一般来说，流量价值指当前流量为广告平台带来的收入；在外卖广告场景中，我们关注平台收入的同时，也关注商家的收入，因此我们的流量预估的指标选定为 k_1* 平台收入 +k_2* 商家收入。

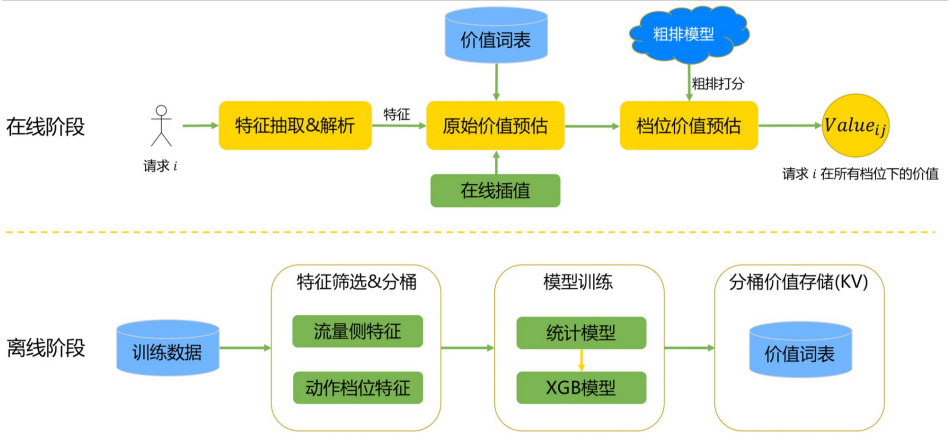

价值评估指标：**平台收入+商家收入**

如图所示，流量价值预估模块包含离线和在线两个阶段。

离线阶段：

- **特征筛选 & 分桶**：基于离线特征重要性分析和分布情况，进行特征筛选和分桶。
- **模型训练**
  - 主要问题：初期我们采用统计方案，在特征分桶较多的情况下，数据稀疏问题严重，且队列长度越大，数据越稀疏。
  - 解决方案：采用 XGB 模型代替统计方案，增强泛化能力。
- 分桶价值存储：不同特征分桶的价值预估结果以 KV 结构写入词表。

在线阶段：

- **特征抽取 & 解析**：进行特征抽取、解析，按照离线分桶规则生成 Key 值。
- **原始价值预估**：根据 Key 值查找对应分桶的价值，然后通过线性插值计算原始队列长度下请求的价值。
- **档位价值预估**：如下图所示，借助粗排打分，通过计算不同档位下价值的衰减情况，实现不同档位的价值预估。

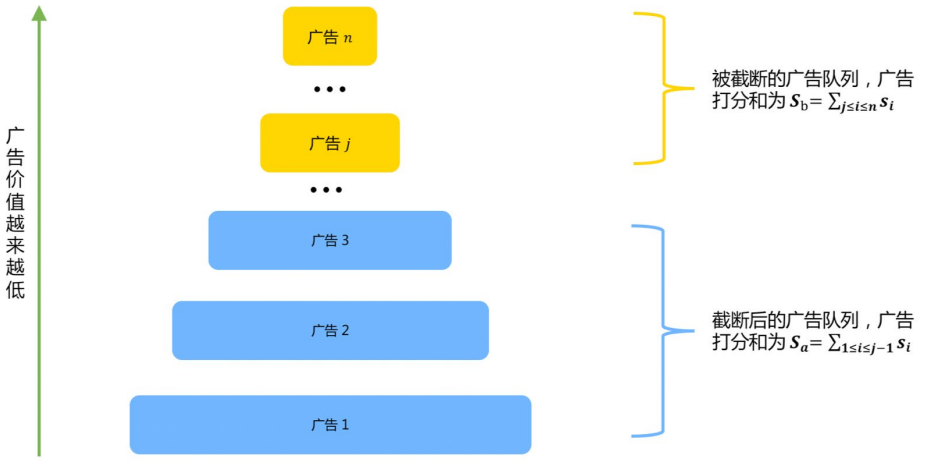

假设广告队列价值为原始流量价值为 V_0 ,则截断后价值为 $V = \frac{S_a}{S_a + S_b} V_0$

3.1.4 流量算力预估

业内智能算力的落地以弹性队列为主，一般采用队列长度作为流量算力评估指标，而队列长度作为流量算力评估指标面临以下两个问题：

- **通用性问题**：在弹性模型、弹性通道和弹性链路中流量算力消耗不由队列长度唯一确定，比如不同来源的流量可能走不同模型（不同模型算力消耗可能不同）。
- **精确度问题**：外卖广告场景下，即使对于弹性队列动作，流量算力消耗和队列长度也不是简单的线性关系。

算力评估指标选取：为了解决以上问题，我们采用流量消耗的 CPU 时间作为流量算力评估指标。

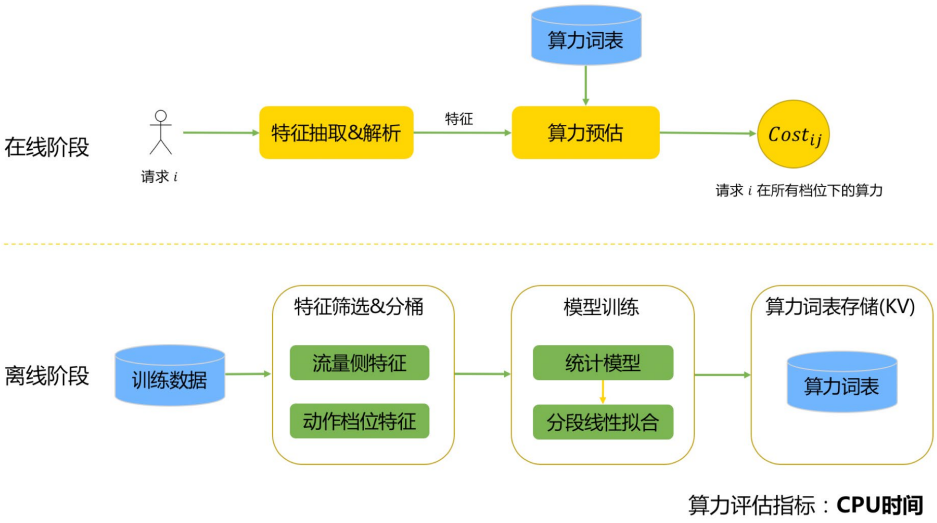

如图所示，流量算力预估包括离线和在线两个阶段。

离线阶段：

- **特征筛选 & 分桶**：基于离线特征重要性分析和分布情况，进行特征筛选和分桶。
- **模型训练**
  - 训练过程：首先将样本划分到不同特征分桶中（同一分桶中队列长度不同，其他特征相同），然后分别对不同分桶拟合算力和队列长度的关系。
  - 主要问题：由于数据分布不平均，队列长度大于一定阈值后，由于数据稀疏，分桶内算力统计值开始出现波动，不利于线上决策。
  - 为了解决数据稀疏的问题，并拟合真实业务中的**拆包现象**，我们使用了**分段线性拟合**方案，将算力和队列长度之间的关系拟合为分段线性函数（下图是某个特征分桶内算力和队列长度关系拟合结果）。

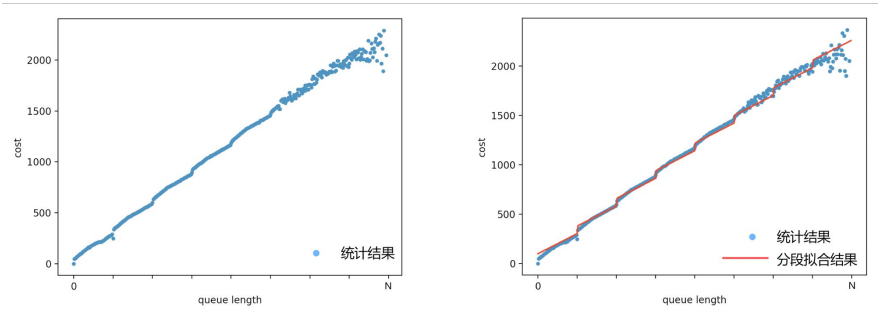

拟合前

➢ 队列越长，数据越稀疏

拟合后

➢ 从短队列泛化到长队列

- **算力词表存储**：不同特征分桶的算力预估结果以 KV 结构写入词表。

在线阶段：

- **特征抽取 & 解析**：进行特征抽取、解析，按照离线分桶规则生成 Key 值。
- **算力预估**：根据 Key 值查找对应分桶的算力。

3.1.5 档位决策

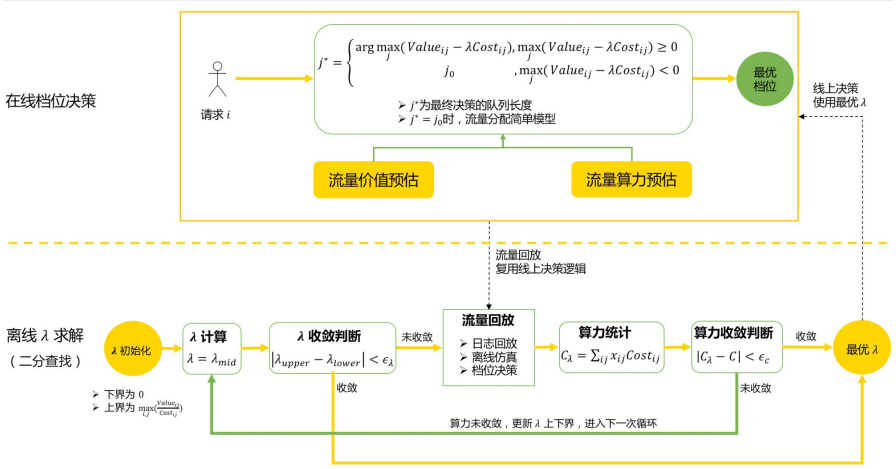

1. 离线 λ 求解

基于价值预估和算力预估模块，通过回放历史流量，利用二分查找算法求解最优 λ。

离线 λ 求解的核心步骤是流量回放：通过重放历史同时段流量，复用线上逻辑，为每个请求模拟决策当前 λ 下的最优档位。

主要问题及解决方案

- 问题描述：离线流量大，将流量划分为多个时间片后，λ 的求解过程需要进行多次流量回放，仿真复杂度高。
- 解决方案：通过流量采样、多个时间片并行化求解等方案，快速求解最优 λ 。

2. 在线档位决策

首先根据业务场景定义候选档位集合（不包括j_0），然后遍历当前请求的候选档位，计算每个档位的收益$Value_{ij} - \lambda Cost_{ij}$，最后按照如下规则进行决策。

最优档位计算：

$$j^* = \begin{cases} arg\,max_j(Value_{ij} - \lambda Cost_{ij}), max_j(Value_{ij} - \lambda Cost_{ij}) \geq 0 \\ j_0, \qquad\qquad\qquad\qquad\qquad\quad max_j(Value_{ij} - \lambda Cost_{ij}) < 0 \end{cases}$$

根据档位执行算力分配动作：

- 当$max_j(Value_{ij} - \lambda Cost_{ij}) \geq 0$，即最大档位对应的收益 ≥ 0时，选择收益最大化档位。
- 当$max_j(Value_{ij} - \lambda Cost_{ij}) < 0$，即最大档位对应的收益 < 0时，流量分配简单模型。

3.2 系统稳定性保障

在智能算力下，系统从等额算力分配转换成动态算力分配，为保障系统服务稳定性，我们提供了熔断降级等常规措施，还实现了基于系统状态的 PID 实时调控功能。

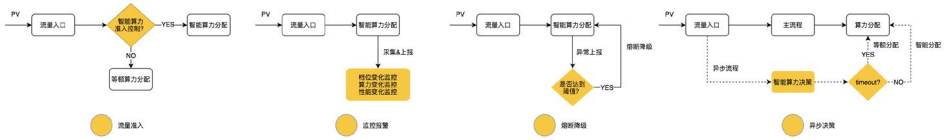

- **流量准入**：提供分广告位、城市、时段等不同流量准入规则，控制智能算力流量。
- **监控报警**：提供 PV 和系统整体两个维度的档位、性能、算力等变化监控和阈值报警。
- **熔断降级**：实时监控智能算力的异常，达到配置的异常阈值后，智能算力会自

动熔断降级，进行等额算力分配。

- **异步决策**：为保障主流程整体链路耗时不增长，智能算力决策是一个异步的过程，超时后进行等额算力分配。

3.2.2 基于系统状态的 PID 实时调控

PID（Proportion Integration Differentiation）是一个通过比例、积分、微分进行控制的主流控制算法，我们通过对系统状态的实时监控和变化感知，基于 PID 算法对系统状态进行实时调控，保证系统状态的稳定。

系统状态通常可以用系统的 CPU/GPU 利用率、QPS、RT（Avg、TP99、TP999 等）、调用失败率（FailRate）等指标衡量。

调控目标

调控目标应该选取最能够快速反映出系统状态变化的指标，基于这个原则，我们选取了 TP999、FailRate、CpuUtils 作为调控目标。

调控策略

基于 PID 调控器，支持多种调控策略：

- **调控动作档位**：对于弹性队列，可以调控队列长度的系数或者上限，从而调节候选队列长度。
- **调控决策公式**：可以通过调控决策公式的 λ 系数，从而调节系统整体的算力消耗。

调控过程

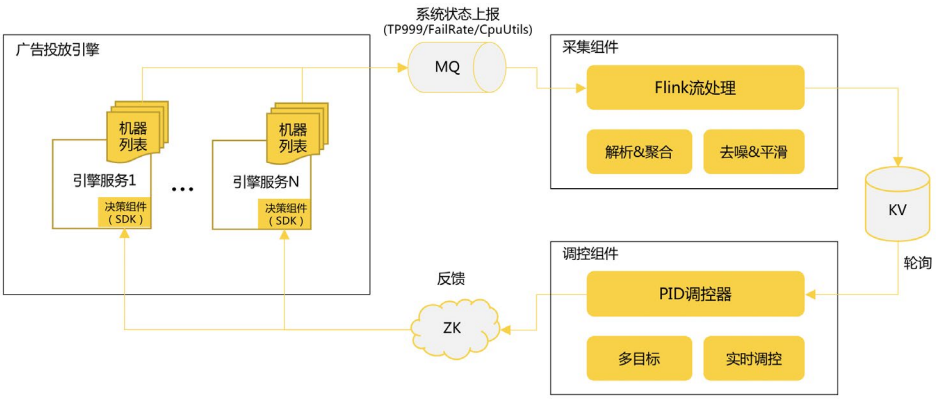

- **系统状态上报**：投放引擎服务通过监控系统，实时反馈系统当前状态，同步到 MQ，其中核心指标具有 10s 的时效性。
- **采集组件**：基于 Flink 流处理框架，实时解析聚合系统状态数据，并进行去噪和平滑处理，处理后的数据写到 KV 存储。
- **调控组件**：基于 PID 算法，通过轮询感知系统状态变化，根据选择的调控目标，实时调控系统算力，将调控结果反馈到投放引擎的决策组件，形成调控闭环。

智能算力接入 PID 实时调控后，在系统负载偏高时，可以快速稳定有效的反馈调节，将系统性能保持在目标水位。

4. 实验

4.1 实验设置

- **系统算力容量的选取**：为了保证线上系统能根据实时流量快速调整，结合外卖的流量特点，我们选择 15min 作为最小的调控单元；实际场景中，我们选取过去多天内流量最大且性能稳定的高峰期时间片，并统计该时间片内消耗的总 CPU 时间作为系统算力容量 C。
- **Baseline 选取**：选取线上无智能算力的流量作为对照组。
- **流量价值预估**：选取最近多天流量作为训练数据，使用 XGB 模型进行预估并将结果写入词表。

- **流量算力预估**：选取最近多天流量作为训练数据，将算力随队列长度的变化拟合为分段线性函数，并将最终预估结果写入词表。
- **离线 λ 求解**：外卖场景中，同环比流量变化趋势基本一致，我们通过重放昨日流量，离线计算当日每个时间片内（15 分钟为一个时间片）最优 λ 并存储为词表。
- **实验思路**：离线仿真时使用的系统算力容量 C 可控制线上算力的消耗，故而可通过调节离线求解使用的系统算力容量 C 实现机器资源持平或业务收益持平的实验。

4.2 实验一：机器资源持平，提高业务收益

	CPM	ROI	CTR	CVR	机器资源
Baseline（系统算力容量 =C）	+0.00%	+0.00%	+0.00%	+0.00%	+0.00%
智能算力（系统算力容量 =C）	**+2.36%**	−1.40%	+0.94%	+0.09%	+0.46%

收益来源分析

- 流量高峰时段，保证系统稳定的同时，通过差异化算力分配提升业务收益。
- 非流量高峰时段，提高系统资源利用率，将空闲机器资源转化为业务收益。

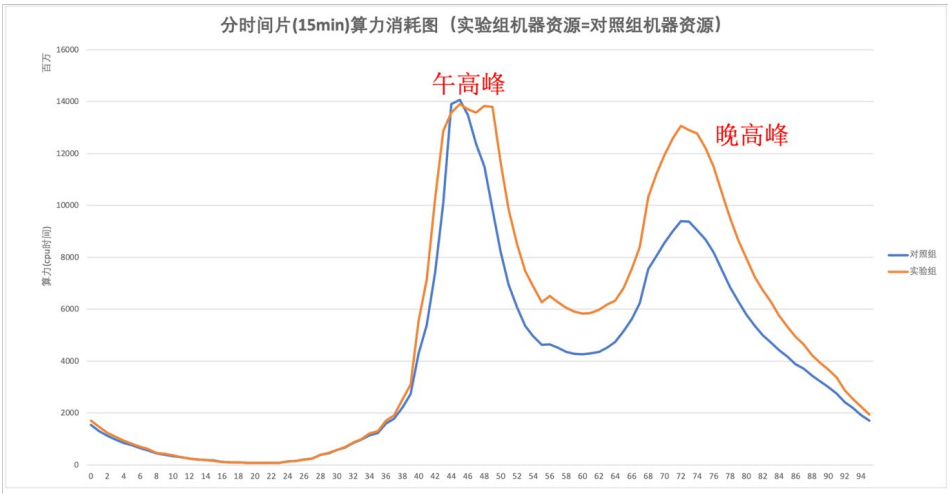

4.3 实验二：业务收益持平，减少机器资源

	CPM	ROI	CTR	CVR	机器资源
Baseline（系统算力容量 =C）	+0.00%	+0.00%	+0.00%	+0.00%	+0.00%
智能算力（系统算力容量 =60% * C）	+0.70%	−1.22%	+0.15%	+0.85%	**−40.8%**

收益来源分析：– 通过压制午高峰和晚高峰算力消耗，达到减少机器资源的目标。从下图可以看出，在高峰时段，实验组的机器资源消耗约占对照组的 60%。 – 同时，在高峰时段进行差异化算力分配，在非高峰时段提高资源利用率，填平整体业务收益。

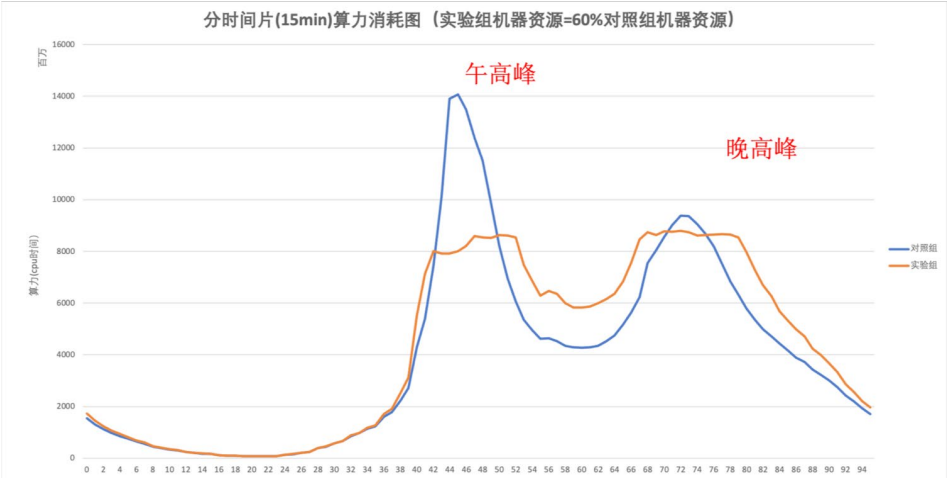

5. 总结与展望

这篇文章主要从最优档位决策和系统稳定性保障两个方面，介绍了智能算力在外卖广告从 0 到 1 建设过程中的思考和优化思路。

未来在算法策略上，我们将尝试基于进化算法和强化学习算法，对系统全链路组合下的算力最优分配问题进行建模和求解；在引擎架构上，对系统仿真能力、在线决策能力和稳定性保障能力进行持续优化，同时尝试和公司弹性伸缩系统相结合，发挥智能算力的更大价值。

6. 参考文献

[1] Jiang, B., Zhang, P., Chen, R., Luo, X., Yang, Y., Wang, G., … & Gai, K. (2020). DCAF: A Dynamic Computation Allocation Framework for Online Serving System. arXiv preprint arXiv:2006.09684.

7. 作者简介

顺辉、家宏、宋伟、国梁、乾龙、乐彬等，均来自美团外卖广告技术团队。

8. 招聘信息

美团外卖广告技术团队大量岗位持续招聘中，诚招广告后台 / 算法开发工程师及专家，坐标北京。欢迎感兴趣的同学加入我们。可投简历至：maoshunhui@meituan.com（邮件主题请注明：美团外卖广告技术团队）

外卖套餐搭配的探索和应用

作者：瑞玉　文斌　杨林　懋地

1. 背景

让用户更方便快捷地选购到满意的外卖商品，是美团外卖一直在努力的方向。本文主要介绍了针对美食类商家的套餐搭配技术以及应用实践。在外卖点餐的选择过程中，用户一般会考虑单品偏好、组合搭配等因素，挑选商家和商品的过程耗时较长。我们通过套餐搭配技术，基于商家的候选商品，自动搭配优质套餐，轻松解决用户“选择困难症”，能够提升用户的决策效率。

2. 业务目标和挑战

2.1 业务目标

目前，美团外卖 App 的套餐搭配应用有很多，有“今日套餐推荐”、“满减神器”、“套餐搭配推荐”等。由于目前外卖商家自行搭配套餐的能力较弱而且意愿不强，导致外卖套餐底层供给对业务场景和商家的覆盖率偏低，不能满足套餐相关推荐排序应用的需求。因此，外卖套餐搭配的业务目标是对于美食类商家搭配出候选的套餐组合，给套餐相关应用方提供更丰富的套餐供给。

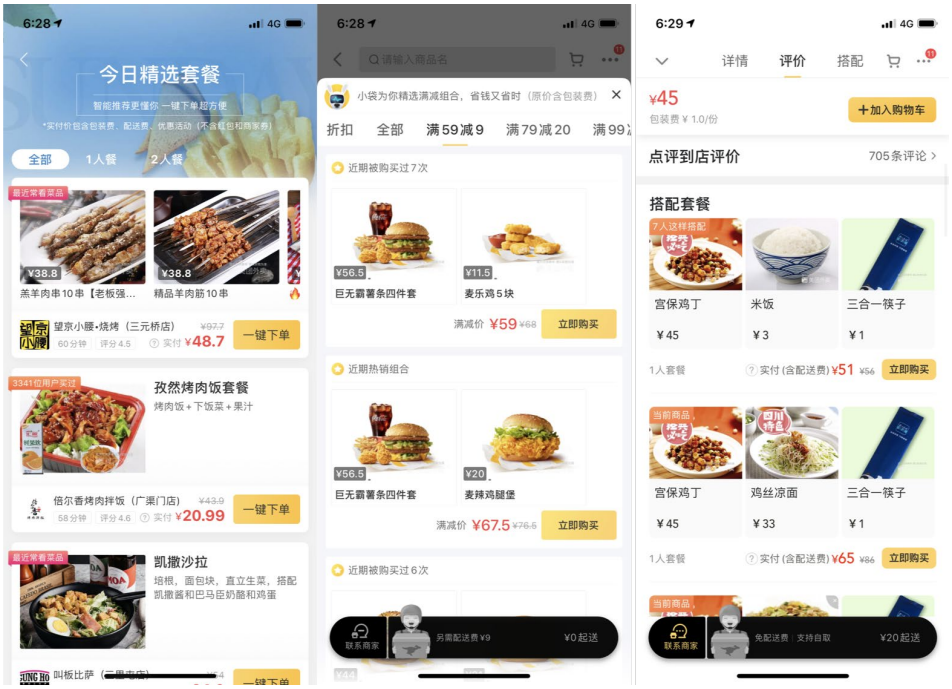

图 1 “套餐推荐”、“满减神器套餐推荐”、“菜品详情页套餐搭配”应用示例

对于套餐相关应用方，我们进行了业务分析：“今日推荐”、“满减神器”等业务的搭配条件相对较弱且可以离线获取搭配条件，归类为推荐型相关业务，此类业务需要保证商家的套餐覆盖率提升，从而保证商家的推荐露出。详情页、满减加购等业务的搭配条件较强，而且偏实时。例如，详情页是用户指定一个菜品后进行搭配，满减加购场景是用户选择一个菜品和特定的价格区间作为条件。这些属于搭配型业务，此类业务需要保证套餐对实时场景的覆盖，从而保证套餐搭配 Tab 的露出。套餐搭配算法的目标有：①提升套餐组合的覆盖度，从而给下游的套餐相关应用提供场景覆盖率高、多样性充足的套餐组合。②保证搭配套餐的质量。

2.2 业务挑战

商品搭配在电商场景下也存在较多的应用，例如淘宝的购物车搭配、服装搭配，化妆品搭配。购物车搭配是基于用户购物车、已购买商品的打包推荐，例如，用户在加购牙刷后，可以给出牙膏的推荐。这类方法主要基于商品的购买行为进行相关性的推

荐，目标不是形成一个完成的搭配组合。但是，外卖美食商品搭配则需要考虑整个组合的合理性，而不单纯基于商品是否相关。比如：大量订单中有“小炒肉 + 番茄鸡蛋汤 + 米饭”、“鱼香肉丝 + 番茄鸡蛋汤 + 米饭”等组合方式，但是“番茄鸡蛋汤 + 米饭”并不构成一个好的套餐搭配。

服装搭配和化妆品搭配为面向组合的搭配推荐，对此类搭配问题的解决方案大体分成两类，一类是：搭配模式用于模型挑选商品过程的剪枝，搭配模式可以是人工或者模型的方式先验给出，参考文献中的论文 4、5 采用此思路，该方法的特点是搭配效果靠剪枝策略 + 质量评估模型共同保证。另一类是通过端到端的网络参数学习搭配模式思路，论文 6 和我们的离线套餐搭配采用此思路，该方案的特点是搭配效果更依赖于端到端模型保证，但同时搭配模型更复杂。

相比电商场景的商品搭配，美食搭配面临独特的业务挑战：

- 套餐搭配的业务场景和搭配条件比较多样，因此套餐搭配方案需要满足各类业务、各种搭配条件下的需求。
- 美食商品属于非标品，且不同商家销售的商品各不相同，导致套餐搭配模式因商家而异。例如，不同商家销售的宫保鸡丁，在份量、口味、食材、价格上都不相同，因此对于宫保鸡丁这道菜也会有不同的套餐搭配方式。
- 算法搭配不可避免会产生低质量的搭配结果，而商品的非标品属性，导致我们更难衡量美食搭配的质量。低质量的搭配可能包括：a. 包含不适宜单独销售、非美食品类的搭配，例如包含赠品、锅具、餐具的搭配。b. 搭配结果不符合常规搭配模式，例如两份饮料，饮料 + 馒头等。

为此，我们的解决方案是：

- 为了解决业务场景和搭配条件多样的问题，我们形成了离线、实时结合的算法搭配框架。对于推荐型相关业务，我们采用离线搭配方法预先搭配出套餐候选，再在业务场景中做个性化排序。离线搭配本着规则到模型的迭代思路，规则搭配依赖知识图谱的商品表示，通过高频聚合 + 规则搭配泛化，产出相对高质量套餐以确保头部商家覆盖。模型搭配可以在保证搭配质量的同时，通过模

型泛化提高套餐的场景覆盖率。对于实时搭配型的业务，算法会依据业务的搭配条件实时搭配套餐，进一步提升各个实时场景下的套餐的覆盖率。

- 为了解决美食商品非标品的问题，我们引入外卖美食图谱对菜品进行了多方位的刻画。我们基于外卖知识图谱提取了菜品丰富的信息表征，例如菜品的标准菜品、菜品品类、口味、食材、做法等，减弱非标品带来的影响。
- 为了保证搭配套餐的质量，我们开发了套餐质量评估的模型。

总体，我们在非标品的商品表示、商家表示、套餐搭配模型、套餐搭配质量评估上都进行了相关的探索和迭代，形成了如下图 2 所示的套餐搭配框架。

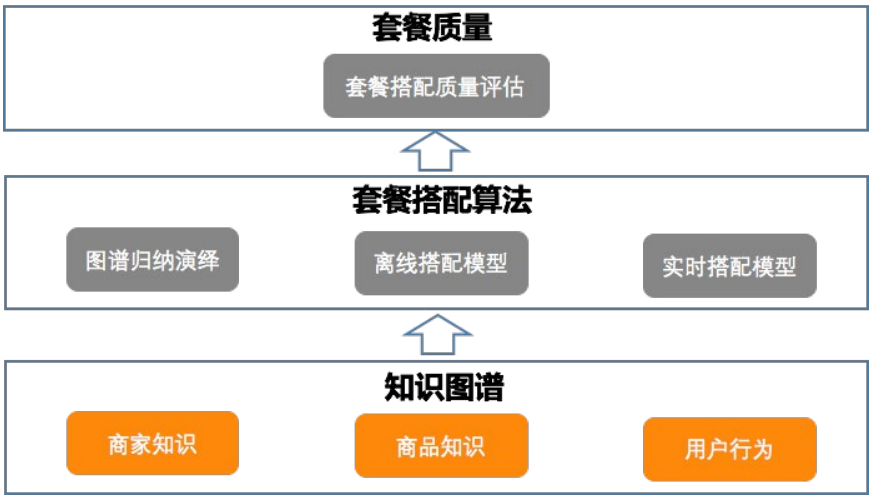

图 2　套餐搭配框架

3. 套餐搭配模型

3.1 基于图谱标签归纳的套餐搭配模型

我们面临的一个问题是外卖商品为非标品，菜品数据质量较差、属性缺失。为此，我们基于商家菜单、菜谱、商品描述等多种信息源，通过信息抽取、关系识别、知识融合等多种方法，构建了以美食为核心的知识图谱，对菜品建立了品类、口味、做法、功效等多个维度的表示。

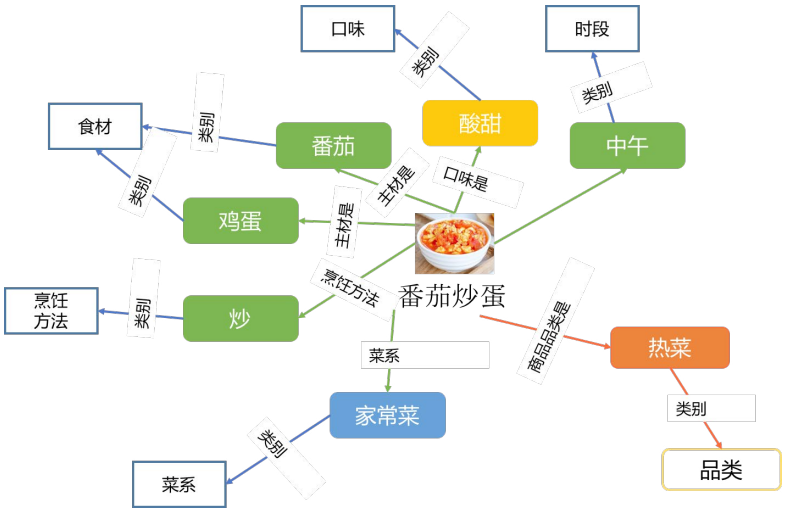

图 3　外卖美食知识图谱

商家的历史高销量套餐一般可认为是优质的套餐，但是，中低销量商家的高销量套餐数量较少，难以支持套餐的个性化推荐等应用。依赖美食图谱对菜品的语义表达，我们首先尝试了基于知识图谱的直接归纳演绎进行套餐搭配的方案。例如，通过高频订单可以归纳得出，{ 热菜 }+{ 米饭 }+{ 汤 } 是一个常见的套餐搭配方式，进而对于商家演绎出“番茄炒鸡蛋 + 番茄鸡蛋汤 + 米饭”的套餐搭配。

图谱归纳演绎的过程是高频聚合和基于搭配模板的泛化过程，我们通过订单聚合、同品牌、同标签、同菜品模板泛化，来产生高质量的套餐搭配，同时套餐的商家覆盖率有了显著的提升。但是搭配模板的问题在于较难对搭配质量和泛化程度取得折中。约束性较强的搭配模板可以确保搭配质量，但泛化能力不足，套餐覆盖度较低。如果用单一或少量标签描述搭配项，会导致模式过度泛化，准确率不能保证。为此，我们引入了基于模型的套餐搭配方法。

3.2 基于 Encoder-Decoder 的套餐搭配模型

用户搭配套餐也是一个信息编码到信息输出的过程：用户浏览商家菜单即是编码过程，得到该商家和商品信息的一个整体概况，再基于这个概况去进行套餐的搭配。贴合该过程的一个思路是采用 Encoder-Decoder 框架进行套餐搭配模型的建设，

Encoder 类比用户浏览菜单的过程，学习菜单的语义信息，Decoder 负责搭配出套餐。Encoder-Decoder 是一种深度学习网络框架，已经被广泛应用于文本摘要、机器翻译、对话生成等应用中，其建模的方式是通过编码（特征提取）和解码（目标拟合），学习从 Encoder 输入数据到 Decoder 输出数据的映射。常见的编码方式有 CNN、RNN、Transformer 等结构，解码方式也类似。

3.2.1 基于 LSTM 的套餐搭配模型

套餐生成问题是要从一个商家的所有候选商品集合中提取出多个商品子集，形成方便用户筛选、可直接下单的套餐。套餐生成的数据源主要是该商家的候选商品信息（如商品的名称、标签、价格、销量等），再结合用餐价格区间、用餐人数等约束条件，以及用户偏好等信息。最初我们采用了 LSTM 作为 Encoder 和 Decoder 的神经网络进行套餐搭配。我们基于图谱语义抽取商品语义表示，并输入 Encoder 的 RNN 模型。Encoder 编码过程类似于用户翻阅商家候选商品的过程，Encoder 端输入菜品名称、菜品标签、菜品的业务属性（价格、销量等），通过 LSTM 对非标品菜品进行特征抽取。如下图 4 所示，每个商品的名称经过 Embedding 层、CNN+Pooling 层提取特征，并同菜品标签、类别的 Embedding 以及价格和销量等连续特征进行拼接，最终作为 Encoder RNN 中每步的输入。

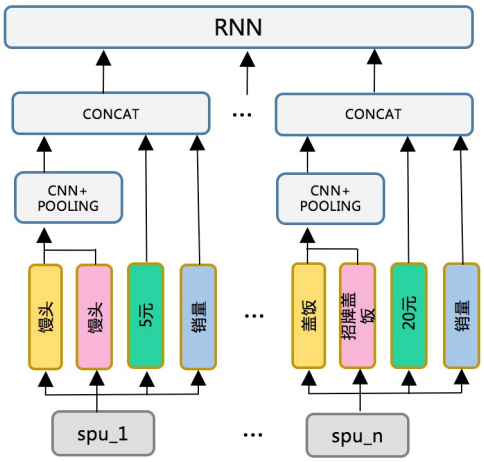

图 4　Encoder 网络结构

Decoder 在解码过程中一般依赖一个固定的字典或词典作为候选集，每一步输出候选集中的字、词被选中的概率分布。对于套餐搭配网络来说，Decoder 解码的候选集来源于 Encoder 输入端商家内的商品列表，而非固定维度的外部菜品词表，Pointer Network 是建模这一问题的有效架构。Pointer Network 是基于 Seq2seq 的扩展，主要解决的是候选集不固定的问题，这一模型架构已被成功应用于抽取式文本摘要，以及旅行商问题、凸包问题等组合优化问题的解决方案中。

套餐搭配解码的具体过程为，Decoder 每一步预估目标菜品来自菜品列表的概率分布。在第 n（n>=1）步时，这个概率分布向量表达了在已经选择了 n−1 个商品的情况下，某个商品或者终止位被选中的概率。若终止位对应的概率较大，则模型倾向以前 n−1 个已选商品形成一个完整的套餐搭配。解码过程中，我们结合 BeamSearch 算法产生 TopN 个结果，保证搭配的多样性。

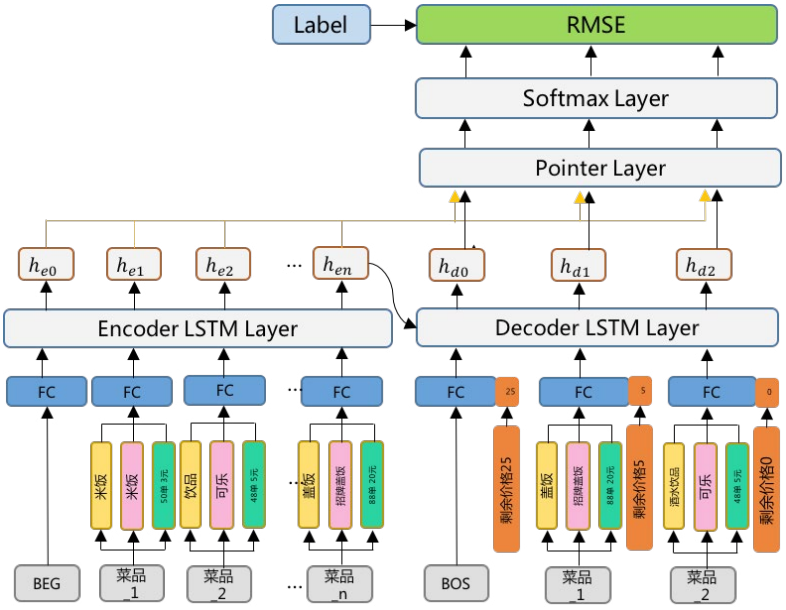

图 5　Encoder−Decoder 网络结构

3.2.2 套餐搭配模型的优化

套餐搭配模型的学习目标

为了解决菜品搭配模式因商家而异的问题，模型通过拟合该商家的历史订单来学习商家的搭配特性。一种较为主流的训练形式是基于商家真实订单，采用 Teacher Forcing 的形式进行训练，使得模型预测的菜品逐位匹配上真实订单内的菜品。Teacher Forcing 式的训练方法使得预测菜品的概率倾向于 0-1 分布，但是现实的菜品搭配通常是个性化、多样性的，例如在 Decoder 已经输出“宫保鸡丁”菜品的基础上，下一步选择的主食为“米饭”或者“炒饭”皆可。

为此，我们对商家历史成单的套餐搭配模式进行统计，计算出商品选择的概率分布，Decoder 以此商品选择的概率分布作为训练目标，同预估的分布计算 MSE Loss，并最小化该值指导模型的训练。Teacher Forcing 的另一个问题是较难引入搭配质量、套餐的点击购买行为等外部知识来指导模型训练，为此我们尝试了采用强化学习的思路进行改进。在解码过程的时刻 T，我们通过蒙特卡洛算法采样（Monte Carlo Sampling）出完整的套餐候选，并计算套餐候选的搭配质量分作为 Reward，结合 MSE Loss 和搭配质量分进行模型训练。

套餐搭配的约束

套餐搭配过程会面临多种业务约束，例如，对于“满减神器”来说，搭配的套餐需要满足给定的满减价格档位。“智能助手”的套餐搭配过程需要考虑用户选定的筛选条件，例如条件可能为“主食为米饭”且“价格为 30 元以下”。我们通过剪枝策略保证搭配过程满足约束，以“满减神器”的价格区间约束为例，Decoder 端在单步产生候选菜品时，会基于剩余的价格过滤掉超出剩余价格范围的菜品。如下图 6 所示，对于商家的 A、B、C、D、E 菜品，Decoder 会利用剩余价格的区间“15 元以内”对后一轮菜品 A、B、C、D、E 进行剪枝，并删除超过价格区间的 C、D 两个菜品。

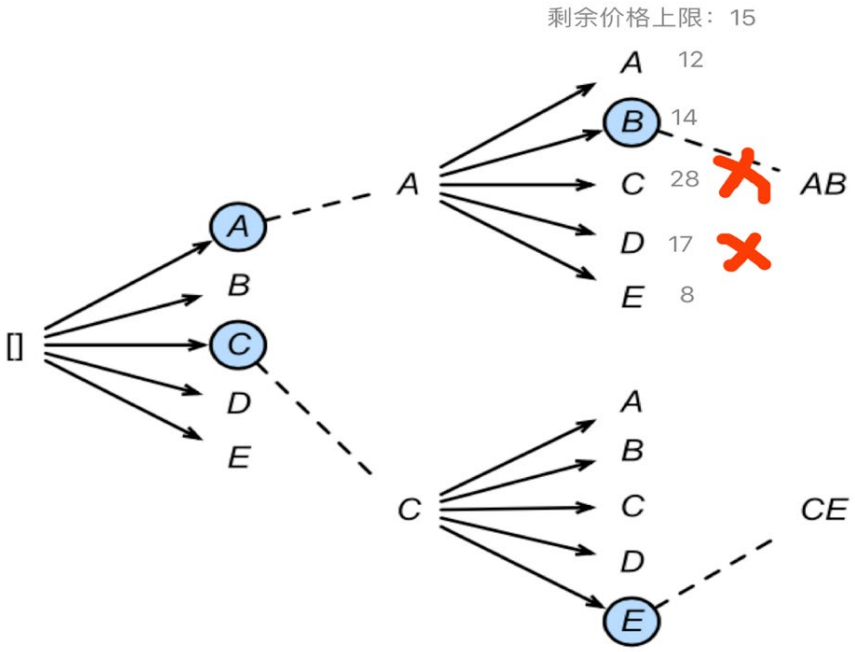

图 6　套餐搭配价格约束

基于 Attention 网络的套餐搭配模型

基于 LSTM 网络的商家内菜品特征提取面临的问题有：第一，商家菜单的菜品本身无序，而 RNN 网络依赖序列进行建模。第二，菜品之间可能存在长距离的语义依赖，例如，菜单内是否有“米饭”、“馒头”等菜品会影响对于“宫保鸡丁”菜品的搭配。

为了更好的对无序菜单和菜品之间依赖信息进行表征，我们尝试了基于 Attention 结构的 Encoder-Decoder 模型。Encoder 部分采用层次化 Attention 结构提取菜品的语义信息，包含底层单菜品级的 Attention 和菜品之间的 Attention 两部分。对于单菜品级的 Attention，我们在字维度采用 Multi-Head Attention 结构得到菜品名称的语义向量，菜品标签同样采用 Multi-Head Attention 得到菜品标签语义向量，对于菜品的交易属性，我们采用多层全连接网络提取交易特征的语义向量。

最后，菜品名称语义向量、菜品标签语义向量、交易特征语义向量拼接后经过全连接层 + 层归一化得到菜品语义向量。对于菜品之间的 Attention 层，我们对该店的菜品

语义向量列表采用多层 Multi-Head Attention 得到该店的菜单级别语义向量。模型 Decoder 部分同样采用 Multi-Head Attention 进行解码，输入信息包括用户偏好信息、历史时刻的解码输入、价格约束等上下文信息，模型在每步输出商家菜单中的菜品被选择的概率分布。Decoder 过程中我们对用户偏好信息同商家菜单级别的语义向量进行 Multi-Head Attention，在套餐搭配过程中考虑用户的用餐偏好。

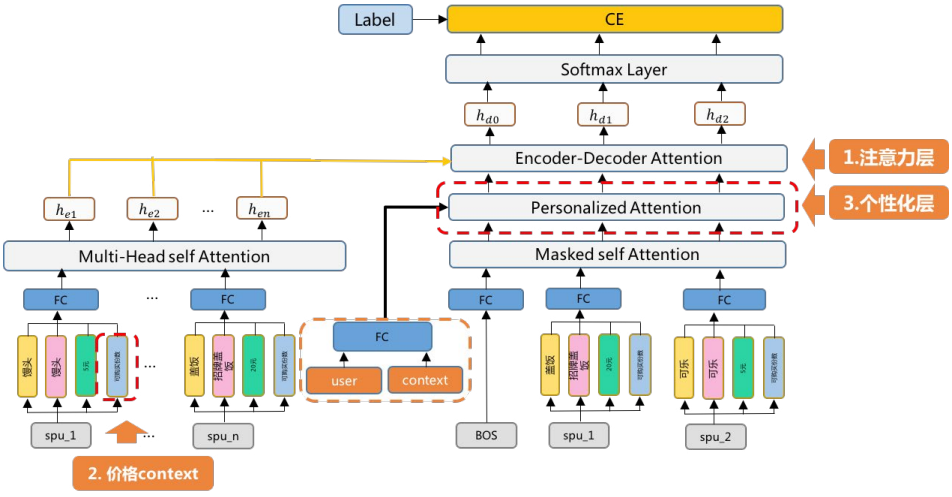

图 7　基于 Attention 的套餐搭配网络

3.2.3 套餐搭配模型分析

我们认为商家高质量的搭配可以从订单的销量体现，一种评估方法即是评估模型输出的套餐对商家真实高销量套餐的覆盖。通过离线和在线评估，我们发现该模型可以拟合出商家高销量套餐。在人工评估部分，我们把算法搭配的套餐和真实成单订单进行混合并让人工进行区分，发现人工无法分辨模型搭配的订单和真实成单订单的差异。同时，该模型具备良好的泛化能力，显著提升了套餐对商家和特定业务场景的覆盖度。

我们对模型输出的菜品表征向量进行了分析，以了解模型的套餐搭配模式。利用 TSNE 对向量进行降维和聚类，通过聚类图观察发现“主食”、“主菜”、“小食”类的菜品各自聚集在一起，可以看出模型识别了菜品的“主食”、“菜品”、”小食”等品类语义属性，并参考此语义进行套餐搭配。

主食类：”馄饨”的TOP N相似菜品	菜品类：”红烧肉”的TOP N相似菜品
鸡汤大馄饨 0.981	黄瓜拌牛肉 0.975
豌杂酸辣粉 0.979	鲜菇牛肉 0.977
猪肉馄饨 0.975	毛家红烧肉 0.980
清汤牛肉面 0.975	白菜肥肠 0.973
皮肚肥肠面 0.974	拌小肠 0.976
海鲜炒乌冬面 0.974	猪头肉 0.981
大葱肉锅贴 0.973	红烧小土豆 0.975
豌杂米粉 0.971	拌牛肉 0.980

3.3 实时套餐搭配模型

利用离线搭配产生套餐候选的方案可以满足推荐型业务的需求，但对于一些搭配型的业务场景仍然覆盖不足，例如，目前离线套餐对菜品的覆盖度较低，即对于菜品详情页等应用只保证部分 PV 的搭配模块露出。

一种解决方案是通过离线搭配提升套餐对美食商品的覆盖，但该方案的存储成本较高，为此我们采用实时套餐搭配方案。实时生成方案的难点在于既要保证套餐质量，又要满足各种搭配条件，最重要的还要保证实时性。最初我们把离线搭配模型应用于线上实时搭配，发现在性能方面存在瓶颈。因此，我们对离线模型进行了精简，精简的思路是将选菜的过程精简为选择菜品类目的过程，将菜品维度的搭配关系精简为菜品类目的搭配关系，实现整个解空间的缩小。如下图 8 所示，具体流程如下：

- **搭配模板挖掘**：通过商家历史订单挖掘出商家高销的类目层面的搭配关系，即搭配模板，例如“热菜 + 主食”。
- **搜索剪枝**：在搭配选菜时，依据搭配模板中的菜品类目，进行菜品的选择。例如上述的例子，首先进行“热菜”的选择，然后进行“主食”的选择。在选择的过程中，根据用户的实时需求，例如指定必选菜、指定价格、指定主食类型等约束条件，对整体的选择过程进行剪枝。
- **筛选评估**：在搭配完成后，对得到的候选搭配结果进行质量评估，这里基于性能考虑，使用树模型进行质量评估，筛选出 Top N 的搭配结果。

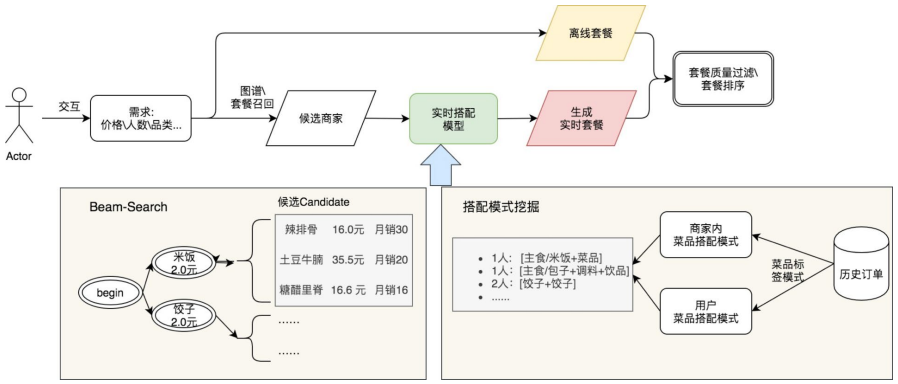

图 8　实时套餐搭配和离线套餐搭配

4. 套餐质量评估

高销量的订单中也存在搭配质量稍低的套餐，加上模型泛化的精度问题，搭配模型很容易生成质量较差的搭配组合。如下图 9 右侧，模型生成的后两个套餐搭配相对不是特别合理。为进一步保证用户体验，我们建立了套餐搭配质量模型，对套餐的质量进行统一评估。套餐质量分类模型将套餐搭配质量转化为一个分类问题。因为套餐组合是有多个菜品组成的，所以我们基于菜品名称、标签等信息构造菜品的表示，然后通过 Global-Attention 来实现菜品间重要程度的考量，同时添加总商品个数、总份数等全局特征来表示整体搭配的信息，模型结构具体见下图 9 所示：

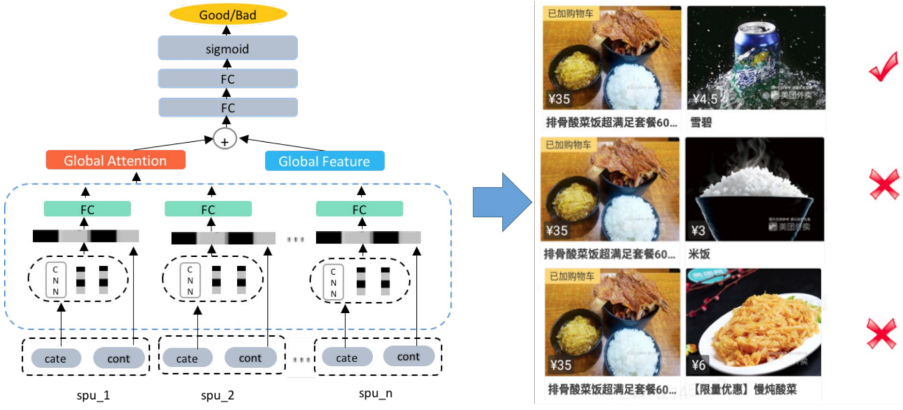

图 9　套餐质量分类

我们对套餐的搭配质量进行了细粒度的分档：极差、差、中、好，且四种类别存在有序关系（极差 < 差 < 中 < 好），对应模型有四个输出值，每一个表示该位为 1 的概率，例如“极差”表示为“1,0,0,0”，“差”表示为“1,1,0,0”，“中”表示为“1,1,1,0”，“好”表示为“1,1,1,1”。模型的损失采用 Pair Hinge Loss 函数，避免前面节点为 0 后面节点为 1 的情况，保证模型的准确度。套餐的搭配质量分值为四个输出节点的求和平均值，使得预测值更加可信。模型结构同一般的分类模型大体一致，目标函数如下：

$$-\frac{1}{m}\sum_{i=1}^{m}\sum_{k=1}^{4}(y_{ik}log\hat{y_{ik}}+(1-y_{ik})log(1-\hat{y_{ik}})+\lambda*\sum_{k=1}^{k'=4}\sum_{k<k'}max(0,-(\hat{y_{ik}}-\hat{y_{ik'}}))$$

图 10　套餐质量分类

套餐质量模型的建设过程中，负例样本主要来自用户反馈的 Bad Case，和通过人工构造不合理搭配模式版筛出的套餐。这种方式存在的问题是：Bad Case 和人工构造的搭配负样本有偏、多样性较差，且负样本同正样本的配比不容易调节。

为此，我们引入一个预训练任务学习历史订单的搭配模式，为套餐搭配质量模型引入更多的搭配先验知识。预训练过程如下图 11 所示，我们随机 Mask 已成单搭配组合中的一个菜品，然后训练 Transformer 模型还原被 Mask 掉的菜品。在这个过程中，考虑一些次优套餐的合理性（例如：”宫保鸡丁 + 米饭 + 可乐”，Mask 掉”宫爆鸡丁”，生成器生成出来的是“鱼香肉丝”，“鱼香肉丝 + 米饭 + 可乐”就可理解为一个次优套餐），我们在最后的损失函数添加预测菜品与目标菜品类别相似性的判别器来解决这类情况。预训练得到的参数最终用来初始化套餐搭配质量分档模型，并基于少量的人工标注语料进行模型的调优。

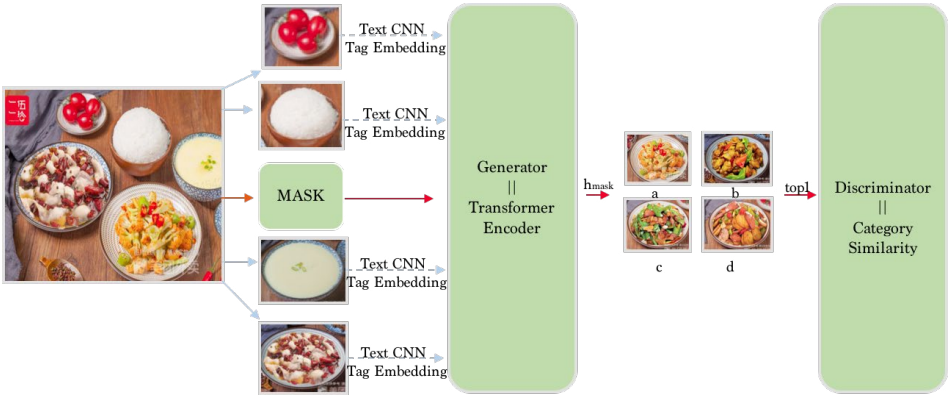

图 11　套餐质量分类

5. 套餐搭配的应用和未来展望

目前，外卖已打造了多款以套餐为核心供给的产品，“今日套餐推荐”帮助用户解决不知道吃什么、选购慢的问题，店铺页内的“满减神器”、“单品搭配推荐”解决用户凑单难、搭配难的问题。为了解决了各业务场景下套餐搭配难题，套餐搭配算法针对覆盖度、搭配质量、搭配多样性进行了持续优化，为业务提供了重要的技术和数据支撑。离线套餐搭配用于”满减神器“、”今日套餐推荐“等业务，显著提高了套餐商家的覆盖率，实时套餐搭配用于“菜品详情页套餐搭配”等业务，并取得较好的业务收益。

后续工作，一方面我们会继续优化菜品知识图谱的构建，完善对非标品菜品的刻画，通过引入图像等多模态数据进一步提升数据准确度和覆盖度，通过构建场景知识图谱更好地刻画用户需求和供给。另一方面我们会探索场景化的套餐搭配：目前我们在场景化套餐搭配方面的工作较少，而且用户在不同场景下会有不同的套餐需求，例如天气寒冷偏爱吃火锅类套餐、腊八节吃粥类套餐，在异地希望吃当地特色类套餐。接下来，我们会在场景化套餐搭配方面进行探索，针对节气、节日、人群等场景搭配套餐，更好的满足用户个性化、场景化的用餐需求。

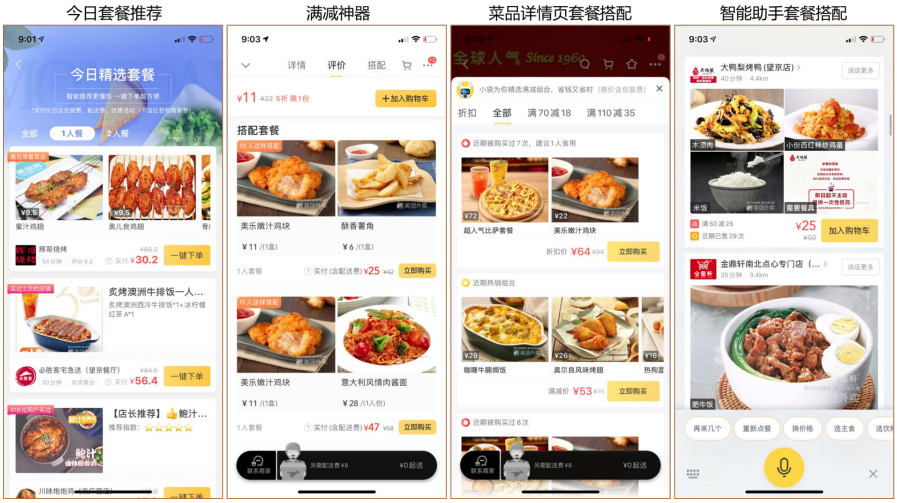

图 12　套餐搭配相关应用

6. 参考文献

[1] Vinyals, Oriol, Meire Fortunato, and Navdeep Jaitly. “Pointer networks.” Advances in neural information processing systems. 2015.

[2] See, Abigail, Peter J. Liu, and Christopher D. Manning. “Get to the point: Summarization with pointer-generator networks.” arXiv preprint arXiv:1704.04368 (2017).

[3] Gong, Jingjing, et al. “End-to-end neural sentence ordering using pointer network.” arXiv preprint arXiv:1611.04953 (2016).

[4] Han, Xintong, et al. “Learning fashion compatibility with bidirectional lstms.” Proceedings of the 25th ACM international conference on Multimedia. 2017.

[5] Alashkar, Taleb, et al. “Examples-Rules Guided Deep Neural Network for Makeup Recommendation.” AAAI. 2017.

[6] Chen, Wen, et al. “Pog: Personalized outfit generation for fashion recommendation at alibaba ifashion.” Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019.

[7] Rush, Alexander M., Sumit Chopra, and Jason Weston. “A neural attention model for abstractive sentence summarization.” arXiv preprint arXiv:1509.00685 (2015).

[8] Paulus, Romain, Caiming Xiong, and Richard Socher. “A deep reinforced model for abstractive summarization.” arXiv preprint arXiv:1705.04304 (2017).

[9] See, Abigail, Peter J. Liu, and Christopher D. Manning. “Get to the point: Summarization with pointer-generator networks.” arXiv preprint arXiv:1704.04368 (2017).

7. 作者简介

瑞玉、文斌、杨林、懋地，均来自美团外卖技术团队。

自动驾驶轨迹预测算法：NeurIPS 挑战赛冠军方案

作者：炎亮　傅壮　德恒　冬淳

01 背景

NeurIPS（Conference on Neural Information Processing Systems）是机器学习和计算神经科学相关的学术会议，也是人工智能方向的顶级会议。INTERPRET 轨迹预测挑战赛（INTERACTION-Dataset-based PREdicTion Challenge）隶属于 NeurIPS 2020 Workshop: Competition Track Saturday。该竞赛由 UC Berkeley MSC Lab 主办，旨在建立一个公共数据集来评估自动驾驶领域各类轨迹预测算法的性能。美团无人车配送中心团队获得 NeurIPS 2020 INTERPRET 轨迹预测挑战赛 Generalizability 赛道冠军，Regular 赛道亚军。

02 赛题简介

INTERPRET 竞赛共包含两条赛道：Generalizability Track 和 Regular Track。Generalizability 赛道中，测试集轨迹与训练集差异较大（采自不同的场景），且不带有高精地图；而 Regular 赛道中测试集轨迹分布与训练集相同（采自相同的场景），同时带有高精地图。数据集采自于美国、中国、德国等多个国家，包含并线 / 变道的高速与城市道路、带停车 / 让车标志的环形路、无保护左转路口等场景。此外，场景中的障碍物包含行人、自行车和机动车 3 种类型。

本次竞赛中，参赛队伍需要根据每个障碍物过去 1 秒（10 帧）的运动轨迹，预测出它在未来 3 秒（30 帧）的轨迹。障碍物的轨迹使用离散采样点集合来表示，采样的频率是 10 赫兹，即每 0.1 秒采样一个轨迹点。竞赛允许参赛队伍对于每个障碍物输出 50 条预测轨迹，但只根据最优轨迹（排序第 1 条）的平均位移误差（Average Displacement Error，ADE）来排名。平均位移误差的计算方式为：

$$ADE = \frac{1}{NT_p}\sum_{i=1}^{N}\sum_{t=1}^{T_p}\| Y_i^t - \hat{Y}_i^t \|_2$$

其中 N 表示障碍物的数量，T_p 表示预测时刻数，Y 表示真实轨迹，$\hat{Y}$ 表示预测轨迹。

03 算法介绍

Part 1 地图数据处理

由于 Generalizability Track 和 Regular Track 数据形式不一致（前者带有高精地图，后者不带高精地图），为保证算法的有效性，我们使用了两种形式来更好地表达场景。如下图 1：

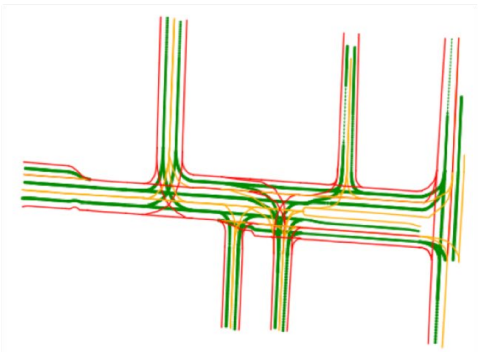

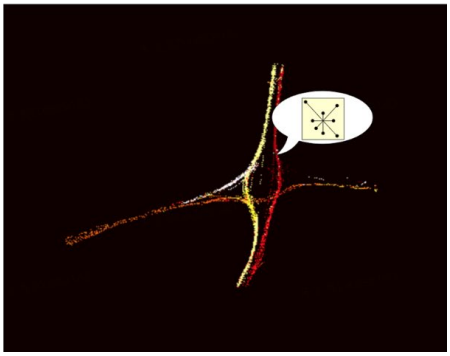

在 Regular Track 中，所有测试集都附带高精地图，我们可以通过查询地图的方式得到任意位置附近的车道线（如图 1- 左所示，场景中道路拓扑非常完整）；而对于 Generalizability Track，测试集没有给出对应的高精地图，无法获取完整的道路结构化信息。对此，我们设计了一种基于地理位置的语义地图来描述非结构化场景下的可行驶区域。基于地理位置的语义地图依赖于场景中障碍物的历史观测轨迹，具体绘制流程主要分为 3 个步骤：

1. 将一定大小（e.g., 50 米 x50 米）的实际场景区域以 d（e.g., 0.2 米）的分辨率划分成 $W \times H$ 个栅格（W=250, H=250）；
2. 根据障碍物的历史轨迹，计算每个轨迹点的方向，放入对应位置的栅格中；
3. 统计所有栅格的运动方向信息，形成方向描述子。具体方法是：将 360 度划分成 8 个区间，45 度一个区间，统计每个区间内的轨迹点个数，然后归一化。

最终，基于地理位置的语义地图的大小为 $H \times W \times 8$ 。

Part 2 预测模型设计

轨迹预测算法设计过程中通常需要考虑一个重要问题：即在预测时如何建模障碍物与周围环境的复杂交互，这里周围环境通常包含多类交通元素，例如其他交通参与者，路网拓扑，交通信号灯等。现有的预测算法中，对障碍物交互的建模方式也不尽相同，例如较早期基于简单位置关系的交互 [1-3]，基于语义地图 +CNN 编码的交互 [4-6]，基于（图）注意力机制的交互 [7-11] 等。随着对障碍物交互认知的加深以及新技术的迭代，

轨迹预测算法的精度也在逐步提高。本次竞赛中，我们提出一种基于混合注意力机制的预测算法，以通用的形式解决两个赛道的预测问题。算法是基于目前主流的图注意力机制，整体设计思路是通过引入混合注意力机制，促使算法更准确地提取障碍物运动特性与车道拓扑特性，同时编码障碍物之间、障碍物与车道间的复杂交互。

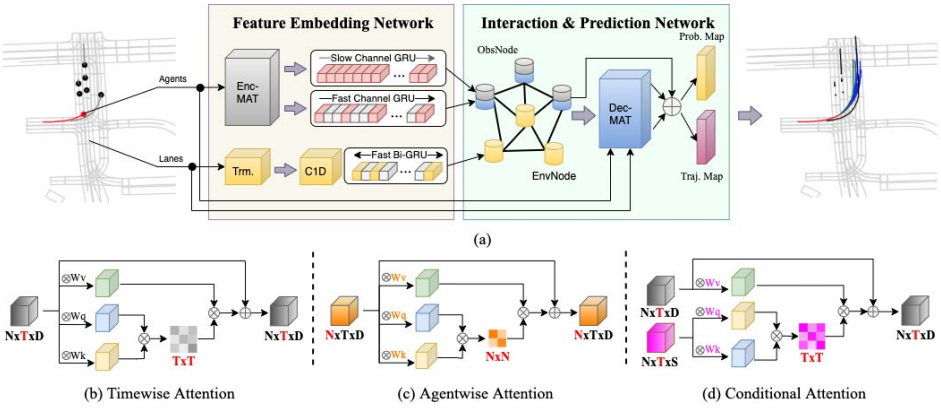

上图 2 是算法的整体结构，整个模型基于主流的 Encoder-Decoder 结构，包含特征编码网络（Feature Embedding Network）和交互 & 预测网络（Interaction & Prediction Network）。特征编码网络使用 Timewise + Agentwise Attention 双注意力机制与双通道 GRU 对障碍物轨迹和地图信息进行高质量特征强化与时序编码；交互预测网络则使用 Agentwise + Conditional Attention 双注意力机制建模智能体间交互行为，并输出多模态预测轨迹及其概率。上述两个网络都是基于混合注意力的图网络，其核心是 Enc-MAT 和 Dec-MAT（Mixture Attention Transformer encoder）模块。Enc-MAT 和 Dec-MAT 是现有 BERT-like 模型（Transformer encoder）的改进结构，下图 3 对比了传统 Transformer encoder、Enc-MAT 和 Dec-MAT 的区别。

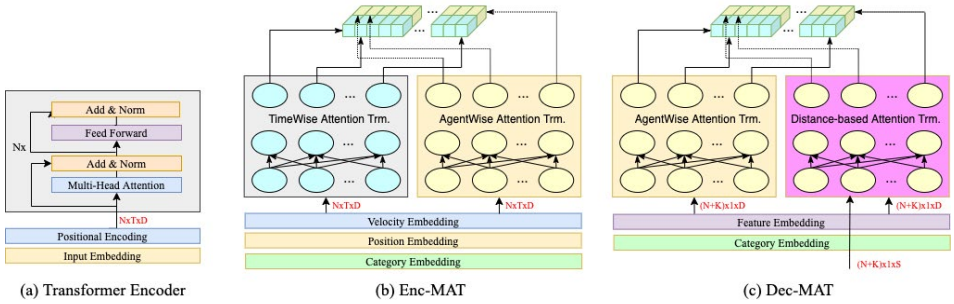

(a) Transformer Encoder (b) Enc-MAT (c) Dec-MAT

从图 3 可以看到，相比于传统 Transformer encoder，Enc-MAT 和 Dec-MAT 改进并额外新增加了一个注意力通道，混合注意力机制也由此而来。Enc-MAT 编码器使用了 Timewise 和 Agentwise 混合注意力机制；Dec-MAT 编码器则是使用了 Agentwise 和 Conditional（同图 3-c 中的 Distance-base Attention）混合注意力机制。算法使用混合注意力代替原有单注意力机制，目的在于结合实际需求来强化障碍物与环境拓扑的特征表达。图 2 下半部分展示了三种 Attention 结构，从计算形式上看，三种注意力方式的计算公式是一致的：

$$Attention(Q,K,V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

区别在于三种注意力方式中，Attention 模块的 QKV 特征的产生方式有区别：

1. 在 Timewise Attention 中，QKV 计算方式为：

$$Q = \phi_{q,ta}(e; w_{q,ta}), K = \phi_{k,ta}(e; w_{k,ta}), V = \phi_{v,ta}(e; w_{v,ta}), e \in \mathbb{R}^{N\times T\times D}$$

2. 在 Agentwise Attention 中，QKV 计算方式为：

$$Q = \phi_{q,aa}(e; w_{q,aa}), K = \phi_{k,aa}(e; w_{k,aa}), V = \phi_{v,aa}(e; w_{v,aa}), e \in \mathbb{R}^{T\times N\times D}$$

3. 在 Conditional Attention 中，QKV 计算方式为：

$$Q = \phi_{q,ca}(c; w_{q,ca}), K = \phi_{k,ca}(e; w_{k,ca}), V = \phi_{v,ca}(e; w_{v,ca}), e \in \mathbb{R}^{N\times T\times D}, c \in \mathbb{R}^{N\times T\times S}$$

上述公式中 e 是输入数据（例如轨迹、车道等）的 Embedding 编码特征，大小为 $N\times T\times D$；c 是额外输入包含人工先验的条件信息，下文会做解释，大小为 $N\times T\times S$；$\phi_*(\cdot)$

是编码函数，例如 Linear 函数，w_* 是对应的编码函数参数。此外，三类 Attention 模块内部也额外增加了 ADD 输入的操作。

Part 3 轨迹预测流程

首先对符号作一些说明：

假设场景中障碍物的数量为 N，历史观测时长为 T，所有障碍物的历史观测轨迹为 P。则 P 大小为 $N \times T \times 6$，6 维特征包含坐标、速度和类别。预测的时长为 T_p，预测轨迹为 $\hat{Y}$，未来真实轨迹为 Y，在输出一条轨迹的情况下，$\hat{Y}$ 和 Y 大小均为 $N \times T_p \times 2$。

此外，当存在高精地图时，假设场景中车道的数量为 K，车道的采样点个数为 L，场景（离散车道）可以被表示为 M。M 大小为 $K \times L \times 2$；当不存在高精地图时，直接使用基于地理位置的语义地图，场景（语义图像）同样可以被表示为 M。M 大小为 $H \times W \times 8$。

编码过程主要包含障碍物历史轨迹编码与场景拓扑编码。以障碍物特征编码为例，流程主要分为两步：

1. **Dec-MAT 编码**。给定障碍物观测轨迹 P，算法首先使用 Enc-MAT 强化每个障碍物的特征。Enc-MAT 中第一个注意力通道在时间维度对数据进行 Timewise Attention 操作，目的是对于每个障碍物，根据其他历史时刻的信息，来强化某个时刻的信息；第二个注意力通道在障碍物维度进行 Agentwise Attention 操作，目的是对于每个时刻，根据其他障碍物的位置信息，来强化某个障碍物的信息。最终两个通道的特征拼接得到障碍物轨迹特征 R_{agent}Ragent；
2. **Slow+Fast Channel GRU 时序编码**。特征 R_{agent} 是经过其它时刻（或者障碍物）强化过的障碍物信息，然后我们通过 Slow Channel GRU 和 Fast Channel GRU 来分别提取障碍物的精细化运动特征和主体运动特征。Slow Channel 是用特征 R_{agent} 的全部时序信息（$N \times T \times 2D$），经过一个 Slow GRU 进行时序编码得到特征 H_1；Fast Channel 则先对特征 R_{agent} 在时序上降采样

（$N \times T_{down} \times 2D$），再经过 Fast GRU 得到特征 H_2。最终障碍物的时序编码结果 H_{agent} 由 H_1 和 H_2 拼接得到，它记录了障碍物的时序运动特性。

对于道路拓扑的编码也采用相似的方式，但与轨迹编码有两个区别：

1. **特征强化区别**。为了简化计算，我们只使用常规的 Transformer Encoder 对场景信息进行 Timewise Attention 单通道注意力特征强化，得到特征 R_{env}。高精地图模式下，R_{env} 为三维特征，大小为 $K \times L \times D$；语义地图模式下，R_{env} 为三维特征，大小为 $1 \times HW \times D$；
2. **时序特征编码区别**。基于上述特征 R_{env}，高精地图模式下，我们使用 Fast Channel Bi-GRU 直接进行双向道路拓扑特征编码；而语义地图模式下，我们使用 Fast X Bi-GRU 和 Fast Y Bi-GRU 对图像横纵两个方向进行时序编码。最终得到特征 H_{env}。

解码过程主要包含高层交互和轨迹预测两个阶段。前者采用混合注意力网络 Dec-MAT，后者使用基础的 MLP 实现轨迹与概率的多任务预测。在介绍流程前，我们先阐述两个相对合理的事实：

- 事实 1：障碍物运动方向和场景中车道走向存在关联（运动趋势关联）。
- 事实 2：障碍物运动更依赖与距离它更近的邻近车道（相对位置关联）。

基于上述两个事实，解码器两个阶段的流程分别可以描述为：

1. 高层交互阶段。障碍物时序特征 H_{agent} 和场景拓扑特征 H_{env} 特征组成一张全局的图，这张图可以表示为一个混合矩阵 H_{mix}（高精地图模式下大小为 $(N+L) \times 1 \times 2D$，语义图模式下为 $(N+1) \times 1 \times 2D$）。基于这张混合图，我们同样使用双通道混合注意力模块 Dec-MAT 进行特征强化与编码。其中，第一个通道对于特征 H_{mix} 的第一维度进行 Agentwise Attention 操作，目的是根据每个障碍物各自的时序运动特征来做全局交互，这基于上述事实 1；第二个通道对于特征 H_{mix}，引入位置信息 c 作为条件进行 Conditional Attention 操作，目的是根据障碍物之间的相对位置关系来做全局交互，这基于上述事实

2。条件特征 c 是障碍物和车道的绝对位置坐标，因此 Conditional Attention 也称为 Distance-based Attention。最终两个通道的编码特征以及输入 H_{mix} 特征相加，过滤掉道路信息后得到障碍物特征 G_{agent}（大小为 $N \times 2D$）；

2. 轨迹预测阶段。G_{agent} 通过 Backbone 以后，经过两个 MLP head 分别输出预测轨迹 $\hat{Y}$ 和轨迹概率 Pr。

最终在 Generalizability 赛道上，我们以 ADE 0.5339 米获得冠军；Regular 赛道上，我们以 ADE 0.1912 米获得亚军。

04 总结

障碍物轨迹预测对无人车安全行驶具有重要的意义，它也是学界与工业界公认有很大挑战性的课题。我们希望通过努力做出更好的解决方案，持续提升自动驾驶系统对障碍物的预测能力，为美团实际业务及出行领域提供更多的技术支持。

05 参考文献

[1] Alahi A, Goel K, Ramanathan V, et al. Social lstm: Human trajectory prediction in crowded spaces[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 961-971.

[2] Gupta A, Johnson J, Fei-Fei L, et al. Social gan: Socially acceptable trajectories with generative adversarial networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 2255-2264.

[3] Zhu Y, Qian D, Ren D, et al. StarNet: Pedestrian trajectory prediction using deep neural network in star topology[C]//Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2019: 8075-8080.

[4] Chai Y, Sapp B, Bansal M, et al. Multipath: Multiple probabilistic anchor trajectory hypotheses for behavior prediction[J]. arXiv preprint arXiv:1910.05449, 2019.

[5] Chang M F, Lambert J, Sangkloy P, et al. Argoverse: 3d tracking and forecasting with rich maps[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 8748-8757.

[6] Liang J, Jiang L, Niebles J C, et al. Peeking into the future: Predicting future person activities and locations in videos[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 5725-5734.

[7] Mohamed A, Qian K, Elhoseiny M, et al. Social-STGCNN: A Social Spatio-

Temporal Graph Convolutional Neural Network for Human Trajectory Prediction[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 14424-14432.

[8] Liang M, Yang B, Hu R, et al. Learning lane graph representations for motion forecasting[C]//European Conference on Computer Vision. Springer, Cham, 2020: 541-556.

[9] Huang Y, Bi H K, Li Z, et al. STGAT: Modeling spatial-temporal interactions for human trajectory prediction[C]//Proceedings of the IEEE International Conference on Computer Vision. 2019: 6272-6281.

[10] Gao J, Sun C, Zhao H, et al. VectorNet: Encoding HD maps and agent dynamics from vectorized representation[J]. arXiv preprint arXiv:2005.04259, 2020.

[11] Zhao H, Gao J, Lan T, et al. Tnt: Target-driven trajectory prediction[J]. arXiv preprint arXiv:2008.08294, 2020.

06 作者简介

炎亮、傅 壮、德恒、冬淳，均为美团无人车配送中心算法工程师。

KDD 2021 | 美团联合多高校提出多任务学习模型，已应用于联名卡获客场景

作者：冬博　陈振

论文下载：《Modeling the Sequential Dependence among Audience Multi-step Conversions with Multi-task Learning in Targeted Display Advertising》

源代码：https://github.com/xidongbo/AITM

Modeling the Sequential Dependence among Audience Multi-step Conversions with Multi-task Learning in Targeted Display Advertising

Dongbo Xi[1,*], Zhen Chen[1,*], Peng Yan[1], Yinger Zhang[1,2],
Yongchun Zhu[3,4], Fuzhen Zhuang[5,6], and Yu Chen[1]
[1]Meituan
[2]Zhejiang University, Hangzhou 310027, China
[3]Key Lab of Intelligent Information Processing of Chinese Academy of Sciences (CAS),
Institute of Computing Technology, CAS, Beijing 100190, China
[4]University of Chinese Academy of Sciences, Beijing 100049, China
[5]Institute of Artificial Intelligence, Beihang University, Beijing 100191, China
[6]SKLSDE, School of Computer Science, Beihang University, Beijing 100191, China
{xidongbo,chenzhen06,yanpeng04,chenyu17}@meituan.com,
zhangyinger@zju.edu.cn, zhuyongchun18s@ict.ac.cn, zhuangfuzhen@buaa.edu.cn

一、摘要

很多应用通常都需要用定向展示广告来获客，比如电子商务平台或者金融应用。随着这类应用的爆炸式增长，如何进行持续有效的获客，已经成为现实世界中这些大规模应用最大的挑战之一。在这些应用中，获客通常是一个用户多步转化的过程。例如在电子商务平台中，用户转化通常表现为一个**曝光 -> 点击 -> 购买**的过程。而在金融广告，比如信用卡业务中，用户转化通常是一个**曝光 -> 点击 -> 申请 -> 核卡 -> 激活**的过程。所以，信用卡广告中获客比传统广告更加具有挑战性：

- 用户多步转化过程中的路径序列依赖更长。
- 在多步转化的长序列依赖中，正反馈（正样本）是逐步稀疏的，类别不平衡越来越严重。

在美团的信用卡业务中，我们通常希望用户能完成最后两个转化阶段（即**曝光 -> 核卡**、**曝光 -> 激活**），这才被认为是有效转化。因此，用前边任务的丰富的正样本信息，来缓解后续任务的类别不平衡问题是很有必要的。而在这个方向上，多任务学习是一个提高端到端获客转化率的典型解决方案。

二、背景介绍

在我们的信用卡业务中：

- **曝光（Impression）**：意味着广告被展示给了特定的用户，这些用户是根据一些排序指标选中的，比如 CTR、CVR 等等。
- **点击（Click）**：用户如果对这个广告内容感兴趣的话，他会点击这个广告，点击后，就会进入申请表格页。
- **申请（Application）**：进入申请表格页后用户可以填写申请表格，并且点击申请按钮来申请一张信用卡。
- **核卡（Approval）**：也称授信，意味着用户信用良好，通过申请并被授予了一定的信用卡额度。在我们的系统中，这在多数情况下也是一个系统实时判断的过程。
- **激活（Activation）**：用户在授信并且收到邮寄的信用卡之后，可以激活信用卡并使用。是否激活的标签通常比较难获得，因为信用卡邮寄需要一定的时间，而且用户主动去激活也需要一定的表现期，所以这里类别不平衡更为严重。在这里，我们通常看用户是否会在核卡后 14 天内激活信用卡。

以上的转化步骤有序列依赖，这意味着只有前一个步骤发生了，后一个步骤才可能发生。基于这个约束，用户只可能有 5 个不同的转化阶段如下图所示：

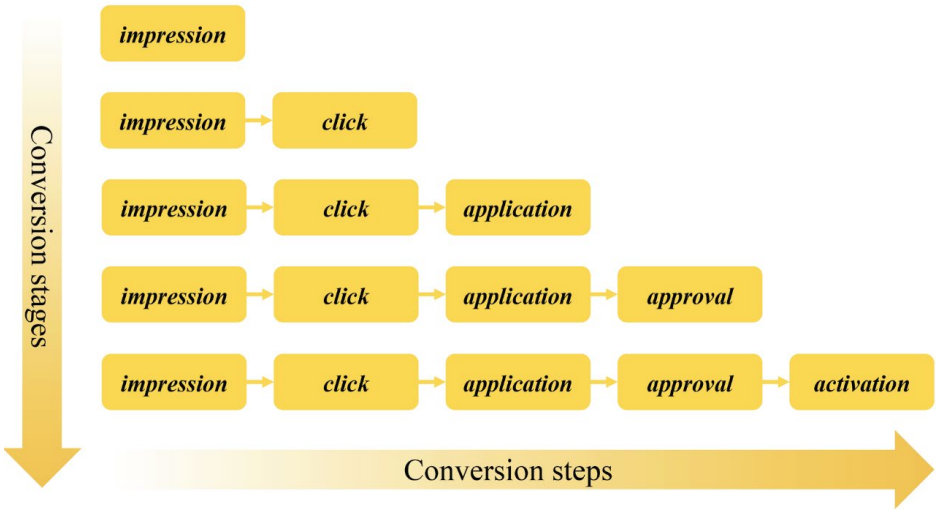

图 1　5 个不同的转化阶段

在工业界和学术界，多任务学习是一个提高端到端获客转化率的典型解决方案。近年来，在多任务学习中建模任务间关系的研究取得了很大的进展。我们将这些主要研究分为两大类：

1）控制多任务模型底部的专家模块如何在任务间参数共享 [1,2,3]，顶部的多塔模块分别处理每个任务，正如图 3（a）所示，我们称这一类为 ** 专家底（Expert-Bottom）** 模式。然而，专家底模式只能在任务间传递浅层表示，但在靠近输出层的网络中往往包含更丰富、更有用的表示 [4,5]，这已被证明能带来更多的增益 [6]。另外，由于专家底模式不是专门为具有序列依赖的任务设计的，因此这些具有专家底模式的模型不能显式地对序列依赖进行建模。

2）在不同任务的输出层中迁移概率 [7,8,9,10]，如图 3（b）所示，我们称之为 ** 概率迁移（Probability-Transfer）** 模式。概率迁移模式只能通过标量乘积传递简单的概率信息，而忽略了向量空间中更丰富、更有用的表示，导致了信息的损失。如果其中任何一个概率没有被准确预测，多个任务将会受到影响。

本文针对序列依赖任务，提出了一种自适应信息迁移多任务（**Adaptive Information Transfer Multi-task，AITM**）框架，该框架通过自适应信息迁移（AIT）模块对用户

多步转化之间的序列依赖进行建模。AIT 模块可以自适应地学习在不同的转化阶段需要迁移什么和迁移多少信息。此外，通过在损失函数中加入行为期望校准器，AITM 框架可以更准确地识别端到端转化。该框架被部署在美团 APP 中，利用它来为对美团联名卡有高转化率的用户实时展示联名卡广告。

三、系统概览

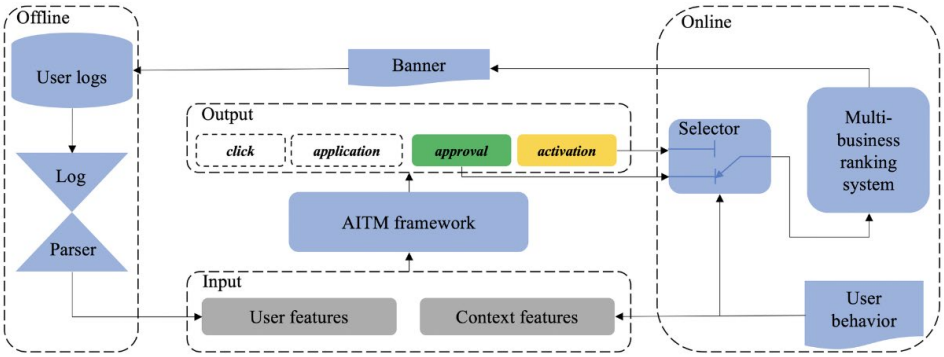

图 2　美团 App 中的多任务排序系统

上图给出了一个多任务排序系统示意图。在我们的信用卡业务中，除了被动的曝光步骤外，我们建模了四个任务。其中核卡、激活是主要任务，点击、申请是辅助任务。这是因为如果用户只完成了点击和申请步骤，而核卡步骤还没有完成，那么就不是一次有效转化，就会造成资源的浪费（例如计算和流量资源）。因此，我们主要关注最后两个端到端的转化任务，即**曝光 –> 核卡**和**曝光 –> 激活**。由于后两个任务的正样本数较少，且激活是延迟反馈的，而前两个辅助任务的正样本数较多，因此可以通过前两个任务来缓解后两个任务的类别不平衡问题。

另外，美团联名信用卡是与不同的银行合作发行的，不同的银行处于不同的业务发展阶段，因此对核卡和激活有不同的要求。信用卡业务刚刚起步的银行往往希望发行更多的信用卡以迅速占领市场，而发展成熟的银行则希望提高激活率以实现快速盈利。因此，我们的系统中有一个选择器，可以为不同的银行输出不同的转化目标，多任务框架可以很好地处理不同的业务需求。

此外，由于美团不同的业务都需要流量来为各自业务获客，而且不同用户对不同业务的兴趣也不同，所以不能简单地将流量划分给不同的业务。我们需要一个多业务排序机制来分配流量从而最大化整体的利益。

四、模型介绍

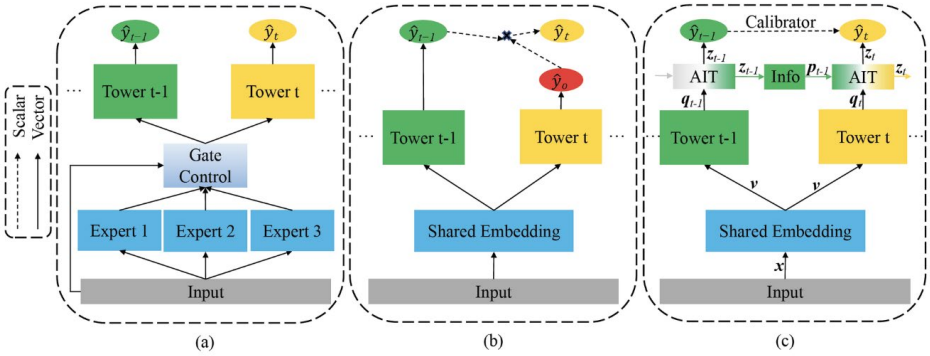

图 3 （a）专家底模式（b）概率迁移模式（c）AITM 框架

上图（c）中展示了我们提出的 AITM 框架。该框架利用 AIT 模块来建模用户多步转化过程中的序列依赖。这个模型图显示了两个相邻的任务：$t-1$ 和 t。

首先，输入特征 $\boldsymbol{x}$ 经过任务共享的 Embedding 分别输出到多个 Tower 网络中。通过共享 Embedding 模块，一方面可以用前边任务的丰富的正样本信息来学习 Embedding 表示，从而缓解后续任务的类别不平衡问题，另一方面可以减少模型参数。Tower 网络可以根据自己需要定制，这里我们只使用了简单的 MLP。然后，AIT 模块利用当前任务 Tower 输出的向量 $\boldsymbol{q}_t$ 以及前一个任务传来的信息 $\boldsymbol{p}_{t-1}$ 来学习任务间如何融合信息。AIT 模块如下定义：

$$\boldsymbol{z}_t = AIT(\boldsymbol{p}_{t-1}, \boldsymbol{q}_t) \ ,$$

$$\boldsymbol{p}_{t-1} = g_{t-1}(\boldsymbol{z}_{t-1}) \ .$$

这里其实利用了特殊设计的注意力机制来自动为迁移信息 $\boldsymbol{p}_{t-1}$ 和原始信息 $\boldsymbol{q}_t$ 来分配权重。而迁移的信息 $\boldsymbol{p}_{t-1}$ 是通过函数 $g_{t-1}(\cdot)$ 来学习的，这里 $g_{t-1}(\cdot)$ 可以是一个简单的全

连接层，用来学习两个相邻的任务间应该迁移什么信息。而该函数的输入 $\boldsymbol{z}_{t-1}$ 是前一个任务的 AIT 模块的输出。

具体地，AIT 模块中的注意力机制如下设计：

$$\boldsymbol{z}_t = \sum_{\boldsymbol{u} \in \{\boldsymbol{p}_{t-1}, \boldsymbol{q}_t\}} w_u h_1(\boldsymbol{u}) \ ,$$

$$w_u = \frac{exp(\hat{w}_u)}{\sum_u exp(\hat{w}_u)}, \hat{w}_u = \frac{< h_2(\boldsymbol{u}), h_3(\boldsymbol{u}) >}{\sqrt{k}} \ .$$

其中，w_u 是自动学习的迁移信息的权重。$h_1(\cdot)$，$h_2(\cdot)$，$h_3(\cdot)$ 利用前馈神经网络将输入投影到新的向量空间。

最后，我们通过在损失函数中施加校准器来约束概率的输出尽量满足序列依赖。损失函数是交叉熵 + 校准器约束，其中 $\alpha \in [0,1]$ 定义了校准器约束强度：

$$L(\theta) = L_{ce}(\theta) + \alpha L_{lc}(\theta) \ .$$

具体地，交叉熵定义如下：

$$L_{ce}(\theta) = -\frac{1}{N} \sum_{t=1}^{T} \sum_{(\boldsymbol{x}, y_t) \in D}^{N} \left(y_t log \hat{y}_t + (1 - y_t) log(1 - \hat{y}_t) \right) \ .$$

校准器约束定义如下：

$$L_{lc}(\theta) = \frac{1}{N} \sum_{t=2}^{T} \sum_{\boldsymbol{x} \in D}^{N} max(\hat{y}_t - \hat{y}_{t-1}, 0) \ .$$

如果 $\hat{y}_t$ 大于 $\hat{y}_{t-1}$，校准器将输出一个正的惩罚项，否则输出 0。

五、实验分析

在本节中，我们将在工业和公开现实数据集上进行实验，对比各种基线模型来评估我们提出的 AITM 框架。接下来，首先会介绍使用的数据集，然后是离线和在线实验结果，最后是进一步的实验分析（包括消融实验、超参数实验和 Case Study）。

5.1 数据集

我们使用两个数据集进行了离线实验。工业数据集是美团联名卡广告曝光的所有样本，我们取了一段时间的样本。该数据集有 4 个任务，分别是点击、申请、核卡、激活。在我们的业务中，我们只关注核卡和激活的转化指标，这两步转化才是有效转化。公开数据集是使用的阿里的点击转化预估数据集 [9,11]，这个数据集有点击、购买两个任务。

Dataset	#Task	#Train	#Validation	#Test	%Positive(%)
Industrial	4	20M	3M	26M	23.29/1.84/1.30/1.00
Public	2	38M	4.2M	43M	3.89/0.02

表 1　数据集统计信息。其中，“%Positive”代表采样后训练集中每个任务的正样本占比

5.2 离线、在线实验

Model	Industrial dataset				Public dataset			
	approval AUC	*activation* AUC	Gain		*click* AUC	*purchase* AUC	Gain	
LightGBM	0.8392±0.0011	0.8536±0.0035	-	-	0.5837±0.0005	0.5870±0.0038	-	-
MLP	0.8410±0.0010	0.8602±0.0014	+0.0018	+0.0066	0.6048±0.0013	0.5806±0.0035	+0.0211	-0.0064
ESMM	0.8443±0.0028	0.8691±0.0025	+0.0051	+0.0155	0.6022±0.0020	0.6291±0.0061	+0.0185	+0.0421
OMoE	0.8438±0.0022	0.8714±0.0009	+0.0046	+0.0178	**0.6049±0.0020**	0.6405±0.0041	**+0.0212**	+0.0535
MMoE	0.8444±0.0026	0.8705±0.0009	+0.0052	+0.0169	0.6047±0.0017	0.6420±0.0031	+0.0210	+0.0550
PLE	0.8518±0.0006	0.8731±0.0016	+0.0126	+0.0195	0.6039±0.0014	0.6417±0.0013	+0.0202	+0.0547
AITM	**0.8534±0.0011****	**0.8770±0.0005***	**+0.0142**	**+0.0234**	0.6043±0.0016	**0.6525±0.0024****	+0.0206	**+0.0655**

表 2　工业和公开数据集上的 AUC（均值 ± 标准差）表现。Gain 表示与 LightGBM 模型相比的 AUC 提升，下划线代表最好的基线模型。“*”表示与最好的基线模型相比，AITM 在配对样本 t 检验上 p-value<0.05。“*”表示与最好的基线模型相比，AITM 在配对样本 t 检验上 p-value<0.01

Model	Gain	
	approval	*activation*
MLP vs LightGBM	+16.95%	+17.55%
AITM vs MLP	+25.00%	+42.11%

表 3　在线 A/B 实验

我们进行了离线和在线实验。随着业务发展，我们先后部署了 LightGBM、MLP 和 AITM 3 个模型到线上。离线和在线实验都证明了 AITM 的显著表现。

5.3 消融实验

我们设计了 AIT 模块来建模用户多步转化过程中的序列依赖，为了证明 AIT 模块的有效性，我们对 AIT 模块进行了消融研究。我们先分别随机取了 500 个激活正、负样本，然后对它们的激活任务预测分进行排序。越 Top 的预测分，表明模型预测这些用户越容易激活联名卡。然后我们利用 t-SNE 在激活任务上画出了原始信息 $\boldsymbol{q}_t$，迁移 + 原始信息 $\boldsymbol{p}_{t-1}+\boldsymbol{q}_t$，以及 AIT 模块学习到的信息 $\boldsymbol{z}_t$ 的二维图。

从下图中，我们可以看到当用户激活比较容易预测时（即激活分 Top0%-Top50%），三个模块都能够较好地区分正负样本。但是，当用户激活比较难预测时（即激活分 Top50%-Top100%），原始信息 $\boldsymbol{q}_t$、迁移 + 原始信息 $\boldsymbol{p}_{t-1}+\boldsymbol{q}_t$ 都不能很好地区分正负样本，而 AIT 模块在 Top50%-Top100% 预测分上显著优于其他两个部分，说明了 AIT 模块的有效性。

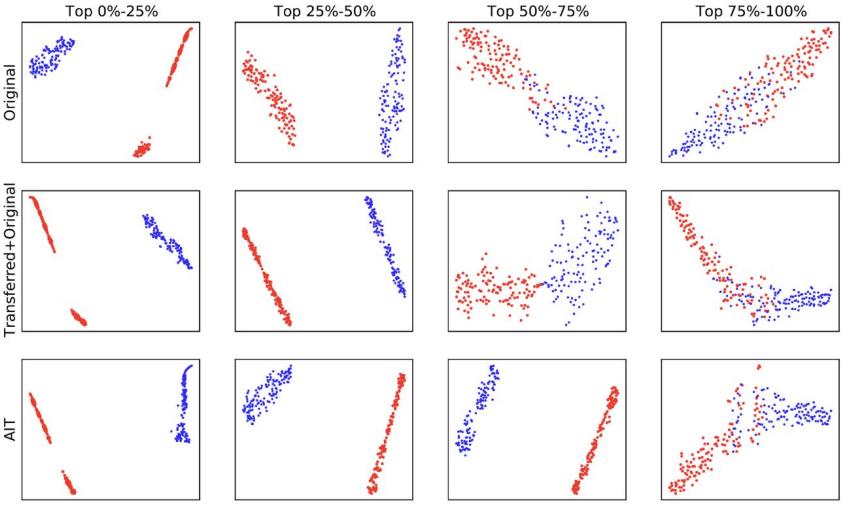

图 4　AIT 中不同模块的 t-SNE 可视化

5.4 超参数实验

另外，为了研究 AITM 框架的稳定性以及对超参数的依赖，我们进行了超参数研究。我们通过对 Embedding 向量维度、校准器强度、正样本比例、任务数量取不同的值进行多次实验，我们有以下发现：

- 前两个超参数实验表明，AITM 模块在 Embedding 向量维度、校准器强度这些超参数下都表现比较稳定。
- 第三个超参数实验表明合适的下采样比例是缓解类别不平衡的一个重要举措。
- 最后一个图显示了更多的任务可以带来更多有用的信息，从而进一步提升端到端转化率。

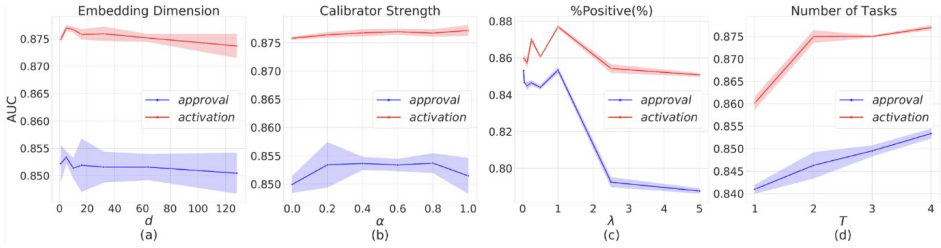

图 5　不同超参数设置下的平均 AUC 表现，阴影代表多次实验的标准差

5.5 Case Study

最后，为了理解 AIT 模块在不同的阶段迁移了什么信息以及多少信息，我们进行了 Case Study。下图中 W_uWu 是迁移信息的权重。我们先随机采样 4 万个测试样本，然后将它们按照相邻两个任务的 Label 分成 3 组：00/10/11（分别对应图中红色、蓝色、绿色的线），并且在每个组中根据 Logloss 对 Top 500 个样本进行排序，越 Top 的样本表示预测越准。

- 首先，看红色的线，由于存在序列依赖，当前一个任务 Label 是 0 时，后一个任务 Label 也只能是 0。所以我们看到前一个任务迁移了很强的信息给后一个任务（权重几乎为 1）。
- 然后，看蓝色和绿色的线，当前一个任务 Label 是 1 时，后一个任务 Label

是不确定的。随着 Logloss 的增加，迁移信息的权重会逐渐增大，这表明后一个任务的预测结果可能会被前一个任务所误导。

- 另外，看绿色的线，当后一个任务 Label 是 1 时，前一个任务迁移了很少的信息（权重很小），这表明后一个任务主要根据自己任务本身来识别正样本。
- 从以上的结果中，我们可以看到 AIT 模块能学习到两个相邻的任务间应该迁移多少信息。

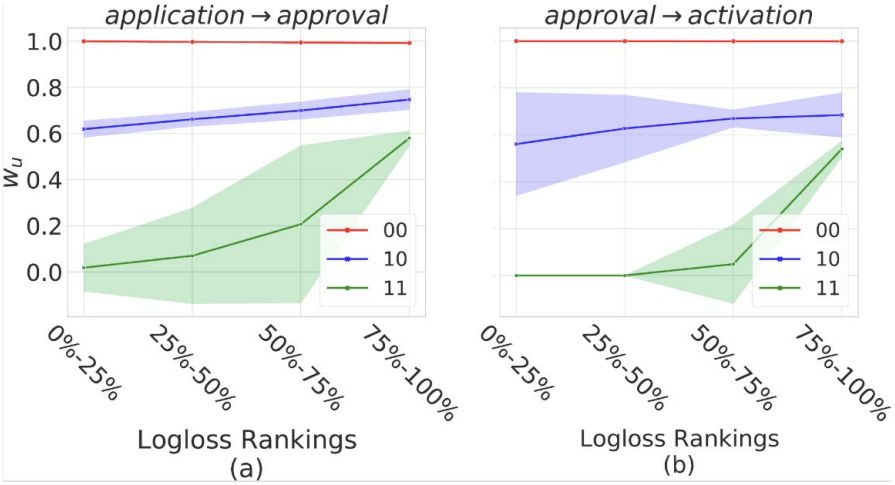

图 6　不同转化阶段的迁移信息平均权重，阴影代表标准差

六、总结

本文提出了一种自适应信息迁移多任务（AITM）框架来建模用户多步转化之间的序列依赖关系。本文提出的自适应信息迁移（AIT）模块配合行为期望校准器，可以学习在不同的转化阶段需要迁移什么和迁移多少信息，以提高序列依赖多任务学习的表现。离线和在线实验结果表明，与最新的基线模型相比该框架有显著的提升。该框架被部署在美团 App 中，利用它来为对美团联名卡有高转化率的用户实时展示联名卡广告。更多的技术细节，欢迎大家参考我们的论文。

七、作者简介

冬博、陈振、燕鹏、陈彧等，来自美团金融智能应用团队。
张颖而：美团实习生、浙江大学本科生
朱勇椿：中科院计算所直博生
庄福振：北京航空航天大学人工智能研究院研究员

招聘信息

美团金融智能应用团队算法岗位持续热招中，诚招优秀算法工程师及专家，坐标北京 / 上海。招聘岗位包括：

营销算法工程师 / 专家

- 服务美团金融各业务场景，负责营销获客、留存促活等场景的算法设计与开发，综合机器学习与优化技术，解决金融营销问题；
- 沉淀算法平台能力，提升算法应用的效率，提供客群挖掘、权益分配、素材匹配、动态创意、运筹规划、精准触达等智能解决方案；
- 结合美团金融业务场景，对深度学习、强化学习、知识图谱等人工智能前沿技术探索创新，实施创新技术沉淀和落地。

风控算法工程师 / 专家

- 通过机器学习模型与策略的开发优化，持续提升对于金融风险行为的识别能力；
- 深入理解业务，应用机器学习技术提高风控工作的自动化程度，全面提升业务效率；
- 跟进人工智能的前沿技术，并在金融风控场景中探索落地。

NLP 算法工程师 / 专家

- 基于美团金融业务场景，结合自然语言处理和机器学习相关技术，落地智能对话机器人到金融营销、风险管理、客服等多个场景；
- 参与研发对话机器人的相关项目，包括但不限于语义理解、多轮对话管理等相关算法的开发和优化；
- 持续跟进学术界和工业界相关技术的发展，并快速应用于项目中。

欢迎感兴趣的同学发送简历至：chenzhen06@meituan.com（邮件标题注明：美团金融智能应用团队）。

参考文献

[1] Jiaqi Ma, Zhe Zhao, Xinyang Yi, Jilin Chen, Lichan Hong, and Ed H Chi. 2018. Modeling task relationships in multi-task learning with multi-gate mixture-of-experts. In KDD. 1930 - 1939.

[2] Zhen Qin, Yicheng Cheng, Zhe Zhao, Zhe Chen, Donald Metzler, and Jingzheng Qin. 2020. Multitask Mixture of Sequential Experts for User Activity Streams. In KDD. 3083 – 3091.

[3] Hongyan Tang, Junning Liu, Ming Zhao, and Xudong Gong. 2020. Progressive Layered Extraction (PLE): A Novel Multi-Task Learning (MTL) Model for Personalized Recommendations. In RecSys. 269 – 278.

[4] Yixuan Li, Jason Yosinski, Jeff Clune, Hod Lipson, and John E Hopcroft. 2016. Convergent Learning: Do different neural networks learn the same representations? In ICLR.

[5] Matthew D Zeiler and Rob Fergus. 2014. Visualizing and understanding convolutional networks. In ECCV. 818 – 833.

[6] Eric Tzeng, Judy Hoffman, Ning Zhang, Kate Saenko, and Trevor Darrell. 2014. Deep domain confusion: Maximizing for domain invariance. arXiv preprint arXiv:1412.3474 (2014).

[7] Chen Gao, Xiangnan He, Dahua Gan, Xiangning Chen, Fuli Feng, Yong Li, Tat-Seng Chua, and Depeng Jin. 2019. Neural multi-task recommendation from multi-behavior data. In ICDE. 1554 – 1557.

[8] Chen Gao, Xiangnan He, Danhua Gan, Xiangning Chen, Fuli Feng, Yong Li, Tat-Seng Chua, Lina Yao, Yang Song, and Depeng Jin. 2019. Learning to Recommend with Multiple Cascading Behaviors. TKDE (2019).

[9] Xiao Ma, Liqin Zhao, Guan Huang, ZhiWang, Zelin Hu, Xiaoqiang Zhu, and Kun Gai. 2018. Entire space multi-task model: An effective approach for estimating post-click conversion rate. In SIGIR. 1137 – 1140.

[10] Hong Wen, Jing Zhang, Yuan Wang, Fuyu Lv, Wentian Bao, Quan Lin, and Keping Yang. 2020. Entire Space Multi-Task Modeling via Post-Click Behavior Decomposition for Conversion Rate Prediction. In SIGIR. 2377 – 2386.

[11] https://tianchi.aliyun.com/datalab/dataSet.html?dataId=408

ACL 2021 | 一文详解美团技术团队 7 篇精选论文

作者：可清　翔宇　恒通　会星等

计算语言学协会年会（ACL 2021）于 2021 年 8 月 1 日至 6 日在泰国曼谷举办（虚拟线上会议）。ACL 是计算语言学和自然语言处理领域最重要的顶级国际会议，该会议由国际计算语言学协会组织，每年举办一次。据谷歌学术计算语言学刊物指标显示，ACL 影响力位列第一，是 CCF-A 类推荐会议。今年 ACL 的主题是“NLP for Social Good”。据官方统计信息，本次会议共收到 3350 篇有效投稿，共计接收 710 篇主会论文（接受率为 21.3%），493 篇 Findings 论文（接受率为 14.9%）。

美团技术团队共有 7 篇论文（其中 6 篇长文，1 篇短文）被 ACL 2021 接收，这些论文是美团在事件抽取、实体识别、意图识别、新槽位发现、无监督句子表示、语义解析、文档检索等自然语言处理任务上的一些技术沉淀和应用。

针对于事件抽取，我们显示地利用周边实体的语义级别的论元角色信息，提出了一个双向实体级解码器（BERD）来逐步对每个实体生成论元角色序列；针对于实体识别，我们首次提出了槽间可迁移度的概念，并为此提出了一种槽间可迁移度的计算方式，通过比较目标槽与源任务槽的可迁移度，为不同的目标槽寻找相应的源任务槽作为其源槽，只基于这些源槽的训练数据来为目标槽构建槽填充模型；针对于意图识别，我们提出了一种基于监督对比学习的意图特征学习方法，通过最大化类间距离和最小化类内方差来提升意图之间的区分度；针对于新槽位发现，我们首次定义了新槽位识别（Novel Slot Detection, NSD）任务，与传统槽位识别任务不同的是，新槽位识别任务试图基于已有的域内槽位标注数据去挖掘发现真实对话数据里存在的新槽位，进而不断地完善和增强对话系统的能力。

此外，为解决 BERT 原生句子表示的“坍缩”现象，我们提出了基于对比学习的句子表示迁移方法—ConSERT，通过在目标领域的无监督语料上 Fine-Tune，使模型生成的句子表示与下游任务的数据分布更加适配。我们还提出了一种新的无监督的

语义解析方法——同步语义解码（SSD），它可以联合运用复述和语法约束解码同时解决语义鸿沟与结构鸿沟的问题。我们还从改进文档的编码入手来提高文档编码的语义表示能力，既提高了效果也提高了检索效率。

接下来，我们将对这 7 篇学术论文做一个更加详细的介绍，希望能对那些从事相关研究的同学有所帮助或启发，也欢迎大家在文末评论区留言，一起交流。

01 Capturing Event Argument Interaction via A Bi-Directional Entity-Level Recurrent Decoder

| 论文下载 | 论文作者：习翔宇，叶蔚（北京大学），张通（北京大学），张世琨（北京大学），王全修（RICHAI），江会星，武威 | 论文类型：Main Conference Long Paper（Oral）

事件抽取是信息抽取领域一个重要且富有挑战性的任务，在自动文摘、自动问答、信息检索、知识图谱构建等领域有着广泛的应用，旨在从非结构化的文本中抽取出结构化的事件信息。事件论元抽取对具体事件的描述信息（称之为论元信息）进行抽取，包括事件参与者、事件属性等信息，是事件抽取中重要且难度极大的任务。绝大部分论元抽取方法通常将论元抽取建模为针对实体和相关事件的论元角色分类任务，并且针对一个句子中实体集合的每个实体进行分离地训练与测试，忽略了候选论元之间潜在的交互关系；而部分利用了论元交互信息的方法，都未充分利用周边实体的语义级别的论元角色信息，同时忽略了在特定事件中的多论元分布模式。

针对目前事件论元检测中存在的问题，本文提出显示地利用周边实体的语义级别的论元角色信息。为此，本文首先将论元检测建模为实体级别的解码问题，给定句子和已知事件，论元检测模型需要生成论元角色序列；同时与传统的词级别的 Seq2Seq 模型不同，本文提出了一个双向实体级解码器（BERD）来逐步对每个实体生成论元角色序列。具体来说，本文设计了实体级别的解码循环单元，能够同时利用当前实例信息和周边论元信息；并同时采用了前向和后向解码器，能够分别从左往右和从右往左地对当前实体进行预测，并在单向解码过程中利用到左侧 / 右侧的论元信息；最终，本文在两个方向解码完成之后，采用了一个分类器结合双向编码器的特征来进行最终

预测，从而能够同时利用左右两侧的论元信息。

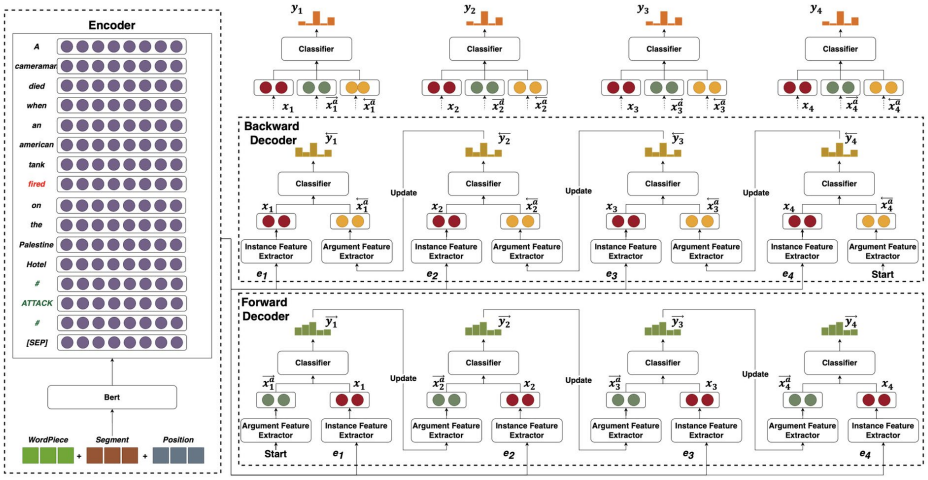

本文在公开数据集 ACE 2005 上进行了实验，并与多种已有模型以及最新的论元交互方法进行对比。实验结果表明该方法性能优于现有的论元交互方法，同时在实体数量较多的事件中提升效果更加显著。

Model	P	R	F1
DMBERT	56.9	57.4	57.2
HMEAE	**62.2**	56.6	59.3
BERT(Inter)	58.4	57.1	57.8
BERT(Intra)	56.4	61.2	58.7
BERD	59.1	**61.5**	**60.3**

Table 2: Overall performance on ACE 2005 (%).

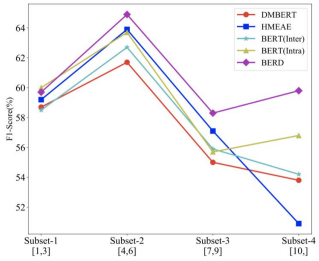

Figure 2: Comparison on four subsets with different range of entity numbers. F1-Score(%) is listed.

02 Slot Transferability for Cross-domain Slot Filling

| 论文下载 | 论文作者：陆恒通（北京邮电大学），韩卓芯（北京邮电大学），袁彩霞（北京邮电大学），王小捷（北京邮电大学），雷书彧，江会星，武威 | 论文类型：Findings of ACL 2021, Long Paper

槽填充旨在识别用户话语中任务相关的槽信息，是任务型对话系统的关键部分。当某

个任务（或称为领域）具有较多训练数据时，已有的槽填充模型可以获得较好的识别性能。但是，对于一个新任务，往往只有很少甚至没有槽标注语料，如何利用一个或多个已有任务（源任务）的标注语料来训练新任务（目标任务）中的槽填充模型，这对于任务型对话系统应用的快速扩展有着重要的意义。

针对该问题的现有研究主要分为两种，第一种通过建立源任务槽信息表示与目标任务槽信息表示之间的隐式语义对齐，来将用源任务数据训练的模型直接用于目标任务，这些方法将槽描述、槽值样本等包含槽信息的内容与词表示以一定方式进行交互得到槽相关的词表示，之后进行基于“BIO”的槽标注。第二种思路采用两阶段策略进行，将所有槽值看作实体，首先用源任务数据训练一个通用实体识别模型识别目标任务所有候选槽值，之后将候选槽值通过与目标任务槽信息的表示进行相似度对比来分类到目标任务的槽上。

现有的工作，大多关注于构建利用源 – 目标任务之间关联信息的跨任务迁移模型，模型构建时一般使用所有源任务的数据。但是，实际上，并不是所有的源任务数据都会对目标任务的槽识别具有可迁移的价值，或者不同源任务数据对于特定目标任务的价值可能是很不相同的。例如：机票预定任务和火车票预定任务相似度高，前者的槽填充训练数据会对后者具有帮助，而机票预定任务和天气查询任务则差异较大，前者的训练数据对后者没有或只具有很小的借鉴价值，甚至起到干扰作用。

再进一步，即使源任务和目标任务很相似，但是并不是每个源任务的槽的训练数据都会对目标任务的所有槽都有帮助，例如，机票预定任务的出发时间槽训练数据可能对火车票预定任务的出发时间槽填充有帮助，但是对火车类型槽就没有帮助，反而起到干扰作用。因此，我们希望可以为目标任务中的每一个槽找到能提供有效迁移信息的一个或多个源任务槽，基于这些槽的训练数据构建跨任务迁移模型，可以更为有效地利用源任务数据。

为此，我们首先提出了槽间可迁移度的概念，并为此提出了一种槽间可迁移度的计算方式，基于可迁移度的计算，我们提出了一种为目标任务选择出源任务中能够提供有效迁移信息的槽的方法。通过比较目标槽与源任务槽的可迁移度，为不同的目标槽寻

找相应的源任务槽作为其源槽，只基于这些源槽的训练数据来为目标槽构建槽填充模型。具体来说，可迁移度融合了目标槽和源槽之间的槽值表示分布相似度，以及槽值上下文表示分布相似度作为两个槽之间的可迁移度，然后对源任务槽依据其与目标槽之间的可迁移度高低进行排序，用可迁移度最高的槽所对应训练语料训练一个槽填充模型，得到其在目标槽验证集上的性能，依据按照可迁移度排序加入新的源任务槽对应训练语料训练模型并得到对应的验证集性能，选取性能最高的点对应的源任务槽及可迁移度高于该槽的源任务槽作为其源槽。利用选择出来的源槽构建目标槽槽填充模型。

槽填充模型依据槽值信息及槽值的上下文信息对槽值进行识别，所以我们在计算槽间可迁移度时，首先对槽值表示分布与上下文表示分布上的相似性进行了度量，然后我们借鉴了 F 值对于准确率及召回率的融合方式，对槽值表示分布相似性及槽值上下文表示分布相似性进行了融合，最后利用 Tanh 将所得到的值归一化到 0–1 之间，再用 1 减去所得到的值，为了符合计算得到的值越大，可迁移度越高的直观认知。下式是我们所提出的槽间可迁移度的计算方式：

$$\mathrm{STM}_{\beta}(s_a, s_b) = 1 - \tanh\left(\frac{(1+\beta^2)sim(p_v(s_a), p_v(s_b))sim(p_c(s_a), p_c(s_b))}{\beta^2 sim(p_v(s_a), p_v(s_b)) + sim(p_c(s_a), p_c(s_b))}\right)$$

$sim(p_v(s_a), p_v(s_b))$ 和 $sim(p_c(s_a), p_c(s_b))$ 分别表示槽 a 与槽 b 在槽值表示分布与上下文表示分布上的相似性，我们采用最大均值差异（MMD）来衡量分布之间的相似度。

我们并没有提出新的模型，但是我们提出的源槽选择方法可以与所有的已知模型进行结合，在多个已有模型及数据集上的实验表明，我们提出的方法能为目标任务槽填充模型带来一致性的性能提升（ALL 所在列表示已有模型原始的性能，STM1 所在列表示用我们的方法选出的数据训练的模型性能。）

Model		CT		RZT		Coach		Coach+TR	
Data/Domain ↓ Training Setting →		ALL	STM_1	ALL	STM_1	ALL	STM_1	ALL	STM_1
MWS	attraction	74.52	**84.99**	74.96	**84.22**	67.26	**73.35**	65.06	**76.16**
	hotel	58.81	47.73	50.63	43.82	59.03	**61.12**	59.00	**60.74**
	restaurant	69.93	63.47	66.29	61.01	78.65	65.36	79.00	71.53
	taxi	51.61	**69.32**	52.82	**66.25**	63.88	**81.17**	70.04	**79.34**
	train	80.78	79.66	80.02	**81.37**	77.68	**82.85**	77.91	**85.23**
	Average F1	67.13	**69.03**	64.94	**67.33**	69.30	**72.77**	70.20	**74.60**
SNIPS	AddToPlaylist	38.82	**41.95**	42.77	**42.92**	45.23	**53.36**	50.90	50.54
	BookRestaurant	27.54	**31.17**	30.68	30.21	33.45	32.60	34.01	32.89
	GetWeather	46.45	**53.03**	50.28	**62.32**	47.93	**60.91**	50.47	**62.38**
	PlayMusic	32.86	23.09	33.12	22.33	28.89	**35.60**	32.01	**34.45**
	RateBook	14.54	**15.39**	16.43	**25.37**	25.67	16.37	22.06	**25.39**
	SearchCreativeWork	39.79	38.72	44.45	42.63	43.91	**49.88**	46.65	**52.21**
	SearchScreeningEvent	13.83	**14.13**	12.25	**15.15**	25.64	23.75	25.63	**26.05**
	Average F1	30.55	**31.07**	32.85	**34.42**	35.82	**38.92**	37.39	**40.56**

03 Modeling Discriminative Representations for Out-of-Domain Detection with Supervised Contrastive Learning

| 论文下载 | 论文作者：曾致远（北京邮电大学），何可清，严渊蒙（北京邮电大学），刘子君（北京邮电大学），吴亚楠（北京邮电大学），徐红（北京邮电大学），江会星，徐蔚然（北京邮电大学）| 论文类型：Main Conference Short Paper (Poster)

在实际的任务型对话系统中，异常意图检测（Out-of-Domain Detection）是一个关键的环节，其负责识别用户输入的异常查询，并给出拒识的回复。与传统的意图识别任务相比，异常意图检测面临着语义空间稀疏、标注数据匮乏的难题。现有的异常意图检测方法可以分为两类：一类是有监督的异常意图检测，是指训练过程中存在有监督的 OOD 意图数据，此类方法的优势是检测效果较好，但缺点是依赖于大量有标注的 OOD 数据，这在实际中并不可行。另一类是无监督的异常意图检测，是指仅仅利用域内的意图数据去识别域外意图样本，由于无法利用有标注 OOD 样本的先验知识，无监督的异常意图检测方法面临着更大的挑战。因此，本文主要是研究无监督的异常意图检测。

无监督异常意图检测的一个核心问题是，如何通过域内意图数据学习有区分度的语义表征，我们希望同一个意图类别下的样本表征互相接近，同时不同意图类别下的样本互相远离。基于此，本文提出了一种基于监督对比学习的意图特征学习方法，通过最

大化类间距离和最小化类内方差来提升特征的区分度。

具体来说，我们使用一个 BiLSTM/BERT 的上下文编码器获取域内意图表示，然后针对意图表示使用了两种不同的目标函数：一种是传统的分类交叉熵损失，另一种是监督对比学习（Supervised Contrastive Learning）损失。监督对比学习是在对比学习的基础上，改进了原始的对比学习仅有一个 Positive Anchor 的缺点，使用同类样本互相作为正样本，不同类样本作为负样本，最大化正样本之间的相关性。同时，为了提高样本表示的多样性，我们使用对抗攻击的方法来进行虚拟数据增强（Adversarial Augmentation），通过给隐空间增加噪声的方式来达到类似字符替换、插入删除、回译等传统数据增强的效果。模型结构如下：

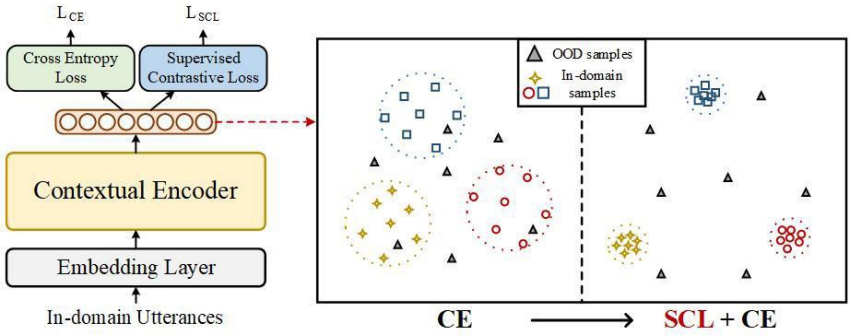

a) The in-domain intent classifier　　b) Using intent representations for OOD detection

我们在两个公开的数据集上验证模型的效果，实验结果表明我们提出的方法可以有效的提升无监督异常意图检测的性能，如下表所示。

Models		CLINC-Full				CLINC-Small			
		IND		OOD		IND		OOD	
		ACC	F1	Recall	F1	ACC	F1	Recall	F1
LSTM	CE	86.34	87.73	63.72	65.23	84.24	84.30	60.40	61.07
	LMCL	86.83	87.90	64.14	65.79	84.46	84.87	60.72	61.89
	SCL+CE(ours)	87.01	88.28	66.80	67.68	85.73	86.61	63.96	64.44
	SCL+LMCL(ours)	**87.37**	**88.60**	**66.92**	**68.04**	**85.93**	**87.02**	**64.16**	**64.70**
BERT	CE	88.13	88.98	64.24	66.17	86.68	86.20	61.64	62.58
	LMCL	88.57	89.12	64.76	66.80	86.76	86.64	62.20	63.11
	SCL+CE(ours)	88.97	89.57	66.84	68.03	87.65	88.07	64.44	64.52
	SCL+LMCL(ours)	**89.20**	**90.03**	**67.28**	**68.21**	**87.87**	**88.30**	**64.64**	**65.01**

04 Novel Slot Detection: A Benchmark for Discovering Unknown Slot Types in the Task-Oriented Dialogue System

| 论文下载 | 论文作者：吴亚楠（北京邮电大学），曾致远（北京邮电大学），何可清，徐红（北京邮电大学），严渊蒙（北京邮电大学），江会星，徐蔚然（北京邮电大学）| 论文类型：Main Conference Long Paper（Oral）

槽填充（Slot Filling）是对话系统中一个重要的模块，负责识别用户输入中的关键信息。现有的槽填充模型只能识别预先定义好的槽类型，但是实际应用里存在大量域外实体类型，这些未识别的实体类型对于对话系统的优化至关重要。

在本文中，我们首次定义了新槽位识别（Novel Slot Detection, NSD）任务，与传统槽位识别任务不同的是，新槽位识别任务试图基于已有的域内槽位标注数据去挖掘发现真实对话数据里存在的新槽位，进而不断地完善和增强对话系统的能力，如下图所示：

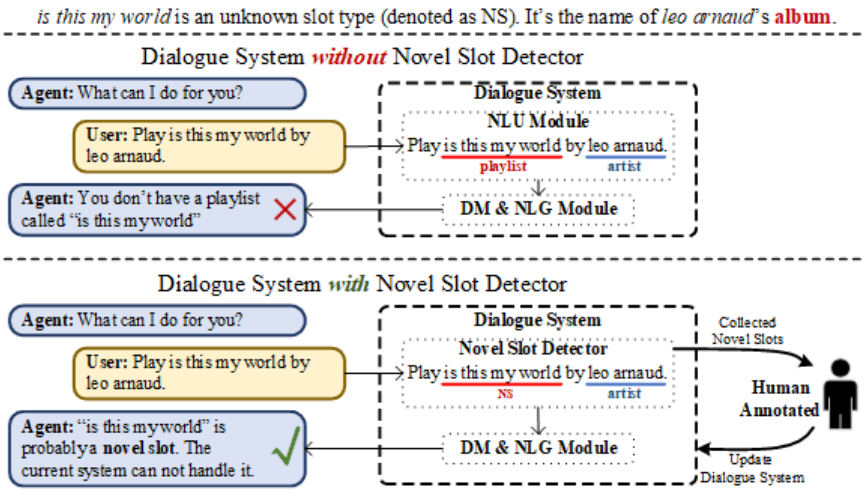

对比现有的 OOV 识别任务和域外意图检测任务，本文提出的 NSD 任务具有显著的差异性：一方面，与 OOV 识别任务相比，OOV 识别的对象是训练集中未出现过的新槽值，但这些槽值所属的实体类型是固定的，而 NSD 任务不仅要处理 OOV 的问

题，更严峻的挑战是缺乏未知实体类型的先验知识，仅仅依赖域内槽位信息来推理域外实体信息；另一方面，和域外意图检测任务相比，域外意图检测仅需识别句子级别的意图信息，而 NSD 任务则面临着域内实体和域外实体之间上下文的影响，以及非实体词对于新槽位的干扰。整体上来看，本文提出的新槽位识别（Novel Slot Detection, NSD）任务与传统的槽填充任务、OOV 识别任务以及域外意图检测任务有很大的差异，并且面临着更多的挑战，同时也给对话系统未来的发展提供了一个值得思考和研究的方向。

基于现有的槽填充公开数据集 ATIS 和 Snips，我们构建了两个新槽位识别数据集 ATIS-NSD 和 Snips-NSD。具体来说，我们随机抽取训练集中部分的槽位类型作为域外类别，保留其余类型作为域内类别，针对于一个句子中同时出现域外类别和域内类别的样例，我们采用了直接删除整个样本的策略，以避免 O 标签引入的 bias，保证域外实体的信息仅仅出现在测试集中，更加的贴近实际场景。同时，我们针对于 NSD 任务提出了一系列的基线模型，整体的框架如下图所示。模型包含两个阶段：

- **训练阶段**：基于域内的槽标注数据，我们训练一个 BERT-based 的序列标注模型（多分类或者是二分类），以获取实体表征。
- **测试阶段**：首先使用训练的序列标注模型进行域内实体类型的预测，同时基于得到的实体表征，使用 MSP 或者 GDA 算法预测一个词是否属于 Novel Slot，也即域外类型，最后将两种输出结果进行合并得到最终的输出。

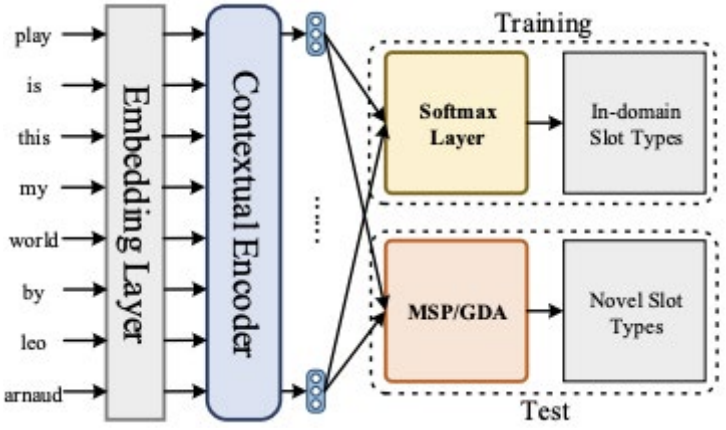

我们使用实体识别的 F1 作为评价指标，包括 Span-F1 和 Token-F1，二者的区别在于是否考虑实体边界，实验结果如下：

Models			5%			15%			30%		
			IND	NSD		IND	NSD		IND	NSD	
detection method	objective	distance strategy	Span F1	Span F1	Token F1	Span F1	Span F1	Token F1	Span F1	Span F1	Token F1
MSP	binary	-	87.21	12.34	25.16	71.44	12.31	39.50	58.88	8.73	40.38
	multiple	-	88.05	14.04	30.50	79.71	20.97	40.02	78.52	25.26	46.91
	binary+multiple	-	89.59	23.58	37.55	83.72	24.70	45.32	79.08	30.66	52.10
GDA	binary	difference	87.95	23.83	35.83	83.65	22.06	43.99	78.72	32.50	44.13
	binary	minimum	61.29	10.36	17.08	49.11	16.91	31.10	48.07	15.56	33.78
	multiple	difference	**93.14**	29.73	45.99	90.07	31.96	53.02	85.56	36.16	54.55
	multiple	minimum	93.10	**31.67***	**46.97***	**90.18**	**32.19**	**53.75***	**86.26***	**38.64***	**55.24***

我们通过大量的实验和分析来探讨新槽位识别面临的挑战：1. 非实体词与新实体之间混淆；2. 不充分的上下文信息；3. 槽位之间的依赖关系；4. 开放槽（Open Vocabulary Slots）。

05 ConSERT: A Contrastive Framework for Self-Supervised Sentence Representation Transfer

| 论文下载 | 论文作者：严渊蒙，李如寐，王思睿，张富峥，武威，徐蔚然（北京邮电大学）| 论文类型：Main Conference Long Paper（Poster）

句向量表示学习在自然语言处理（NLP）领域占据重要地位，许多 NLP 任务的成功离不开训练优质的句子表示向量。特别是在文本语义匹配（Semantic Textual Similarity）、文本向量检索（Dense Text Retrieval）等任务上，模型通过计算两个句子编码后的 embedding 在表示空间的相似度来衡量这两个句子语义上的相关程度，从而决定其匹配分数。尽管基于 BERT 的模型在诸多 NLP 任务上取得了不错的性能（通过有监督的 Fine-Tune），但其自身导出的句向量（不经过 Fine-Tune，对所有词向量求平均）质量较低，甚至比不上 Glove 的结果，因而难以反映出两个句子的语义相似度。

为解决 BERT 原生句子表示这种“坍缩”现象，本文提出了基于对比学习的句子表示迁移方法—ConSERT，通过在目标领域的无监督语料上 fine-tune，使模型生成的句子表示与下游任务的数据分布更加适配。同时，本文针对 NLP 任务提出了

对抗攻击、打乱词序、裁剪、Dropout 四种不同的数据增强方法。在句子语义匹配（STS）任务的实验结果显示，同等设置下 ConSERT 相比此前的 SOTA（BERT-Flow）大幅提升了 8%，并且在少样本场景下仍表现出较强的性能提升。

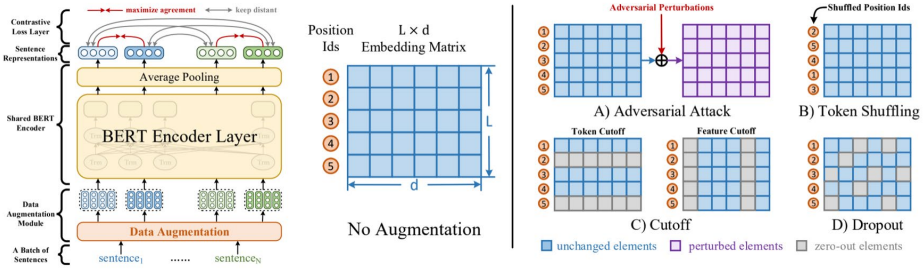

在无监督实验中，我们直接基于预训练的 BERT 在无标注的 STS 数据上进行 Fine-Tune。结果显示，我们的方法在完全一致的设置下大幅度超过之前的 SOTA—BERT-Flow，达到了 8% 的相对性能提升。

Method	STS12	STS13	STS14	STS15	STS16	STSb	SICK-R	Avg.
Unsupervised baselines								
Avg. GloVe embeddings†	55.14	70.66	59.73	68.25	63.66	58.02	53.76	61.32
$BERT_{base}$‡	35.20	59.53	49.37	63.39	62.73	48.18	58.60	53.86
$BERT_{large}$‡	33.06	57.64	47.95	55.83	62.42	49.66	53.87	51.49
$CLEAR_{base}$†	49.0	48.9	57.4	63.6	65.6	75.6	72.5	61.8
IS-$BERT_{base}$-NLI†	56.77	69.24	61.21	75.23	70.16	69.21	64.25	66.58
$BERT_{base}$-CT†	66.86	70.91	72.37	78.55	77.78	-	-	-
$BERT_{large}$-CT†	69.50	75.97	74.22	78.83	78.92	-	-	-
Using STS unlabeled texts								
$BERT_{base}$-flow†	63.48	72.14	68.42	73.77	75.37	70.72	63.11	69.57
$BERT_{large}$-flow†	65.20	73.39	69.42	74.92	**77.63**	72.26	62.50	70.76
$ConSERT_{base}$‡	64.64	78.49	69.07	79.72	75.95	73.97	67.31	72.74
$ConSERT_{large}$‡	**70.69**	**82.96**	**74.13**	**82.78**	76.66	**77.53**	**70.37**	**76.45**

06 From Paraphrasing to Semantic Parsing: Unsupervised Semantic Parsing via Synchronous Semantic Decoding

| 论文下载 | 论文作者：吴杉（中科院软件所），陈波（中科院软件所），辛春蕾（中科院软件所），韩先培（中科院软件所），孙乐（中科院软件所），张伟鹏，陈见耸，杨帆，蔡勋梁 | 论文类型：Main Conference Long Paper

语义解析（Semantic Parsing）是自然语言处理中的核心任务之一，它的目标是把自然语言转换为计算机语言，从而使得计算机真正理解自然语言。目前语义解析面临的一大挑战是标注数据的缺乏。神经网络方法大都十分依赖监督数据，而语义解析的数据标注非常费时费力。因此，如何在无监督的情况下学习语义解析模型成为非常重要的问题，同时也是有挑战性的问题，它的挑战在于，语义解析需要在无标注数据的情况下，同时跨越自然语言和语义表示间的语义鸿沟和结构鸿沟。之前的方法一般使用复述作为重排序或者重写方法以减少语义上的鸿沟。与之前的方法不同，我们提出了一种新的无监督的语义解析方法——同步语义解码（SSD），它可以联合运用复述和语法约束解码同时解决语义鸿沟与结构鸿沟。

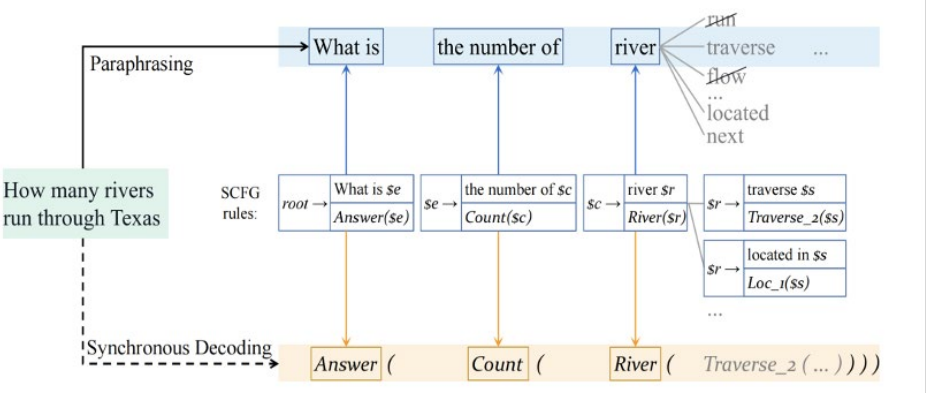

语义同步解码的核心思想是将语义解析转换为复述问题。我们将句子复述成标准句式，同时解析出语义表示。其中，标准句式和逻辑表达式存在一一对应关系。为了保证生成有效的标准句式和语义表示，标准句式和语义表示在同步文法的限制中解码生成。

我们通过复述模型在受限的同步文法上解码，利用文本生成模型对标准句式的打分，找到得分最高的标准句式（如上所述，空间同时受文法限制）。本文给出了两种不同的算法：Rule-Level Inference 以语法规则为搜索单元和 Word-Level Inference 使用词作为搜索单元。

我们使用 GPT2.0 和 T5 在复述数据集上训练序列到序列的复述模型，之后只需要使用同步语义解码算法就可以完成语义解析任务。为了减少风格偏差影响标准句式的生成，我们提出了适应性预训练和句子重排序方法。

Unsupervised									
Cross-domain Zero Shot	-	28.3	53.6	52.4	55.3	60.2	61.7	-	-
GENOVERNIGHT	15.6	27.7	17.3	45.9	46.7	26.3	61.3	9.7	31.3
SYNTH-SEQ2SEQ	16.1	23.6	16.1	30.2	36.6	26.9	43.1	9.2	25.2
SYNTHPARA-SEQ2SEQ	28.4	37.3	33.9	38.1	39.1	41.7	62.7	23.3	38.1
SSD (Word-Level)	68.3	54.9	51.2	55.0	54.7	60.2	65.4	33.6	55.4
SSD (Grammar-Level)	68.8	58.1	56.5	56.1	57.8	59.3	66.9	37.1	**57.6**

我们在三个数据集上进行了实验：Overnight（λ-DCS）、GEO（FunQL）和 GEOGranno。数据覆盖不同的领域和语义表示。实验结果表明，在不使用有监督语义解析数据的情况下，我们的模型在各数据集上均能取得最好的效果。

07 Improving Document Representations by Generating Pseudo Query Embeddings for Dense Retrieval

| 论文下载 | 论文作者：唐弘胤，孙兴武，金蓓弘（中科院软件所），王金刚，张富峥，武威 | 论文类型：Main Conference Long Paper（Oral）

文档检索任务的目标是在海量的文本库中检索出和给定查询语义近似的文本。在实际场景应用中，文档文档库的数量会非常庞大，为了提高检索效率，检索任务一般会分成两个阶段，即初筛和精排阶段。在初筛阶段中，模型通过一些检索效率高的方法筛选出一部分候选文档，作为后续精排阶段的输入。在精排阶段，模型使用高精度排序方法来对候选文档进行排序，得到最终的检索结果。

随着预训练模型的发展和应用，很多工作开始将查询和文档同时送入预训练进行编码，并输出匹配分数。然而，由于预训练模型的计算复杂度较高，对每个查询和文档都进行一次计算耗时较长，这种应用方式通常只能在精排阶段使用。为了加快检索速率，一些工作开始使用预训练模型单独编码文档和查询，在查询前提前将文档库中的文档编码成向量形式，在查询阶段，仅需利用查询编码和文档编码进行相似度计算，减少了时间消耗。由于这种方式会将文档和查询编码为稠密向量形式，因此这种检索也称作“稠密检索”（Dense Retrival）。

一个基本的稠密检索方法会将文档和查询编码成为一个向量。然而由于文档包含的信息较多，容易造成信息丢失。为了改进这一点，有些工作开始对查询和文档的向量表示进行改进，目前已有的改进方法大致可分为三种，如下图所示：

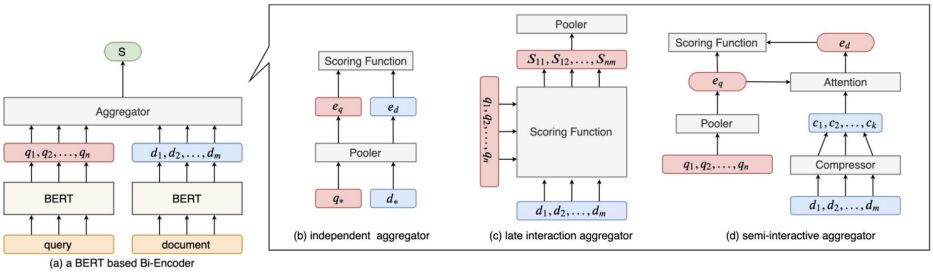

我们的工作从改进文档的编码入手来提高文档编码的语义表示能力。首先，我们认为稠密检索的主要瓶颈在于编码时，文档编码器并不知道文档中的哪部分信息可能会被查询，在编码过程中，很可能造成不同的信息互相影响，造成信息被改变或者丢失。因此，我们在编码文档的过程中，对每个文档构建了多个“伪查询向量”（Pseudo Query Embeddings），每个伪查询向量对应每个文档可能被提问的信息。

具体而言，我们通过聚类算法，将 BERT 编码的 Token 向量进行聚类，对每个文档保留 Top-k 个聚类向量，这些向量包含了多个文档 Token 向量中的显著语义。另外，由于我们对每个文档保留多个伪查询向量，在相似度计算时可能造成效率降低。我们使用 Argmax 操作代替 Softmax，来提高相似度计算的效率。在多个大规模文档检索数据集的实验表明，我们的方法既可以提高效果也提高了检索效率。

Models	MRR@10	Recall@1k
DeepCT	24.3	91.0
docT5Query	27.7	94.7
RepBERT	30.4	94.3
ANCE(First-P)	33.0	95.9
ME-BERT	33.4	-
ME-BERT+BM25	33.8	-
ColBERT	36.0	96.8
Ours	34.5	96.4

Table 1: Results on MS MARCO passage ranking dev set.

Models	MRR@100	NDCG@10
ANCE(First-P)	37.2*	61.5
ME-BERT	33.2	-
ME-BERT+BM25	34.6	-
Ours	39.2	62.8

Table 2: Results on MS MARCO document ranking dev set(MRR@100) and TREC test set(NDCG@10) The value with * is obtained by the public available code and checkpoint in https://github.com/microsoft/ANCE

Operation	offline	online
Per Document BERT Forward	0.9ms	-
Per Document K-means	2.1ms	-
Per Document Encoding	2.3ms	-
Per Query BERT Forward	-	0.5ms
Retrieval	-	180ms
Retrieval(w/o optimization)	-	880ms
Retrieval(independent)	-	100ms
Retrieval(late interaction)	-	940ms

写在后面

以上这些论文是美团技术团队与各高校、科研机构通力合作，在事件抽取、实体识别、意图识别、新槽位发现、无监督句子表示、语义解析、文档检索等领域所做的一些科研工作。论文是我们在实际工作场景中遇到并解决具体问题的一种体现，希望对大家能够有所帮助或启发。

美团科研合作致力于搭建美团各部门与高校、科研机构、智库的合作桥梁和平台，依托美团丰富的业务场景、数据资源和真实的产业问题，开放创新，汇聚向上的力量，围绕人工智能、大数据、物联网、无人驾驶、运筹优化、数字经济、公共事务等领域，共同探索前沿科技和产业焦点宏观问题，促进产学研合作交流和成果转化，推动优秀人才培养。面向未来，我们期待能与更多高校和科研院所的老师和同学们进行合作，欢迎大家跟我们联系（meituan.oi@meituan.com）。

ACL 2021 | 美团提出基于对比学习的文本表示模型，效果相比 BERT-flow 提升 8%

作者：渊蒙　如寐　思睿

尽管基于 BERT 的模型在 NLP 诸多下游任务中取得了成功，直接从 BERT 导出的句向量表示往往被约束在一个很小的区域内，表现出很高的相似度，因而难以直接用于文本语义匹配。为解决 BERT 原生句子表示这种“坍缩”现象，美团 NLP 中心知识图谱团队提出了基于对比学习的句子表示迁移方法——ConSERT，通过在目标领域的无监督语料上 Fine-tune，使模型生成的句子表示与下游任务的数据分布更加适配。在句子语义匹配（STS）任务的实验结果显示，同等设置下 ConSERT 相比此前的 SOTA（BERT-flow）大幅提升了 8%，并且在少样本场景下仍表现出较强的性能提升。

- 论文：《ConSERT: A Contrastive Framework for Self-Supervised Sentence Representation Transfer》
- 会议：ACL 2021
- 下载链接：https://arxiv.org/abs/2105.11741
- 开源代码：https://github.com/yym6472/ConSERT

1. 背景

句向量表示学习在自然语言处理（NLP）领域占据重要地位，许多 NLP 任务的成功离不开训练优质的句子表示向量。特别是在文本语义匹配（Semantic Textual Similarity）、文本向量检索（Dense Text Retrieval）等任务上，模型通过计算两个句子编码后的 Embedding 在表示空间的相似度来衡量这两个句子语义上的相关程度，从而决定其匹配分数。

尽管基于 BERT 的模型在诸多 NLP 任务上取得了不错的性能（通过有监督的 Fine-tune），但其自身导出的句向量（不经过 Fine-tune，对所有词向量求平均）质量较低，甚至比不上 Glove 的结果，因而难以反映出两个句子的语义相似度[1][2][3][4]。我们在研

究的过程中进一步分析了 BERT 导出的句向量所具有的特性，证实了以下两点：

1. BERT 对所有的句子都倾向于编码到一个较小的空间区域内，这使得大多数的句子对都具有较高的相似度分数，即使是那些语义上完全无关的句子对（如图 1a 所示）。我们将此称为 BERT 句子表示的“坍缩（Collapse）”现象。

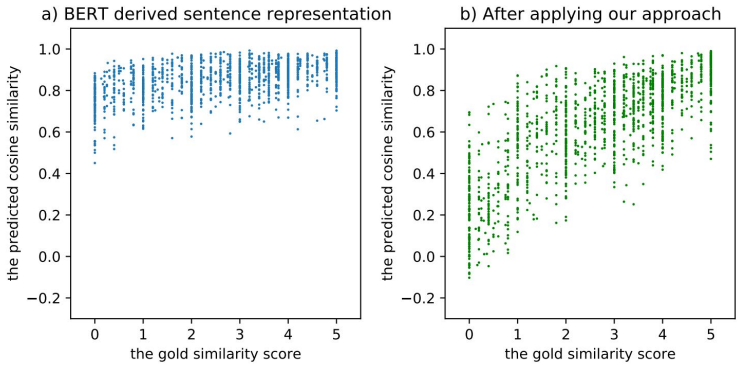

图 1　左：BERT 表示空间的坍缩问题（横坐标是人工标注的相似度分数，纵坐标是模型预测的余弦相似度）；右：经过我们的方法 Fine-tune 之后

2. BERT 句向量表示的坍缩和句子中的高频词有关。具体来说，当通过平均词向量的方式计算句向量时，那些高频词的词向量将会主导句向量，使之难以体现其原本的语义。当计算句向量时去除若干高频词时，坍缩现象可以在一定程度上得到缓解（如图 2 蓝色曲线所示）。

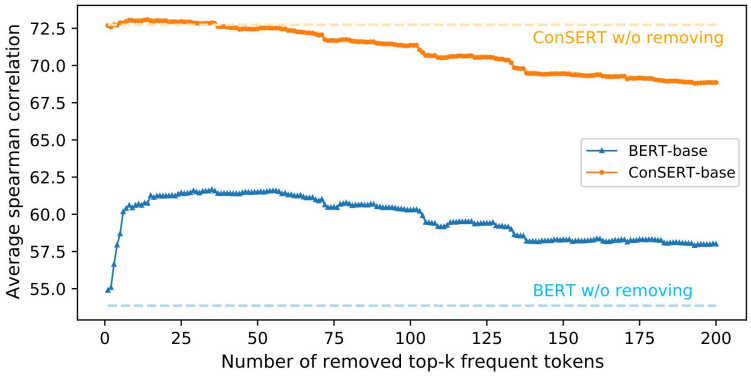

图 2　计算句向量时移除 Top-K 高频词后的性能变化

BERT 导出的句向量难以直接用于下游的语义匹配任务，而用于 Fine-tune 的监督语料又是昂贵的。因此我们希望寻找一种自监督的方法，只需要收集少量来自于下游任务无标注的文本用于 Fine-tune，就能解决 BERT 句向量的“坍缩”问题，同时让其表征更适用于下游任务。

在本文中，我们使用了对比学习（Contrastive Learning）来达到上述目的。对比学习是目前被广泛应用的自监督任务之一，其核心思想为：人类是通过“对比”来辨别对象的，因此相似的事物在编码后的表示空间中应当相近，不同的事物则应当相距尽可能远。通过对同一样本施加不同的数据增强方法，我们能够得到一系列“自相似”的文本对作为正例，同时将同一个 Batch 内的其他文本作为负例，以此为监督信号去规范 BERT 的表示空间。在实验中，我们发现对比学习能够出色地消解高频词对句子语义表示的干扰（如图 2 橙色曲线所示）。在经过对比学习训练之后，模型生成的句子表示将不再由高频词主导（体现在移除前几个高频词后，性能没有出现非常明显的变化）。这是因为对比学习“辨别自身”的学习目标能够天然地识别并抑制这类高频特征，从而避免语义相差较大的句子表示过于相近（即坍缩现象）。

在对比学习中，我们进一步分析了不同的数据增强方法在其中的影响，同时验证了我们的方法在少样本情况下的性能表现。实验结果显示，即使是在非常有限的数据量情况下（如 1000 条无标注样本），我们的方法仍然表现出很强的鲁棒性，能够十分有效地解决 BERT 表示空间的坍缩问题，提升在下游语义匹配任务上的指标。

2. 研究现状和相关工作

2.1 句子表征学习

句子表征学习是一个很经典的任务，分为以下三个阶段：

- 有监督的句子表征学习方法：早期的工作[5]发现自然语言推理（Natural Language Inference，NLI）任务对语义匹配任务有较大的帮助，他们使用 BiLSTM 编码器，融合了两个 NLI 的数据集 SNLI 和 MNLI 进行训练。Universal Sentence Encoder[6]（USE）使用了基于 Transformer 的架构，并使

用 SNLI 对无监督训练进行增强。SBERT[1] 进一步使用了一个共享的预训练的 BERT 编码器对两个句子进行编码，在 NLI 数据集上进行训练（Fine-tune）。

- 自监督的 Sentence-level 预训练：有监督数据标注成本高，研究者们开始寻找无监督的训练方式。BERT 提出了 NSP 的任务，可以算作是一种自监督的句子级预训练目标。尽管之后的工作指出 NSP 相比于 MLM 其实没有太大帮助。Cross-Thought[7]、CMLM[8] 是两种思想类似的预训练目标，他们把一段文章切成多个短句，然后通过相邻句子的编码去恢复当前句子中被 Mask 的 Token。相比于 MLM，额外添加了上下文其他句子的编码对 Token 恢复的帮助，因此更适合句子级别的训练。SLM[9] 通过将原本连贯的若干个短句打乱顺序（通过改变 Position Id 实现），然后通过预测正确的句子顺序进行自监督预训练。
- 无监督的句子表示迁移：预训练模型现已被普遍使用，然而 BERT 的 NSP 任务得到的表示表现更不好，大多数同学也没有资源去进行自监督预训练，因此将预训练模型的表示迁移到任务才是更有效的方式。BERT-flow[2]：CMU&字节 AI Lab 的工作，通过在 BERT 之上学习一个可逆的 Flow 变换，可以将 BERT 表示空间映射到规范化的标准高斯空间，然后在高斯空间进行相似度匹配。BERT-whitening[10]：苏剑林和我们同期的工作。他们提出对 BERT 表征进行白化操作（均值变为 0，协方差变为单位矩阵）就能在 STS 上达到媲美 BERT-flow 的效果。SimCSE[11]：陈丹琦组在 2021 年 4 月份公开的工作。他们同样使用基于对比学习的训练框架，使用 Dropout 的数据增强方法，在维基百科语料上 Fine-tune BERT。

2.2 对比学习

对比学习是 CV 领域从 2019 年末开始兴起的预训练方法，同时最近也被广泛应用到了 NLP 任务中，我们简要介绍两个领域下的进展：

- 计算机视觉（CV）领域的对比学习：2019 年年末 ~ 2020 年年初，Facebook 提出 MoCo[14]，谷歌提出 SimCLR[15]，自此对比学习开始在无监督图像表示

预训练领域大放光彩。SimCLR 提出了一种简单的对比学习框架，通过对同一个图像进行增强，得到两个不同版本，随后通过 ResNet 对图像编码，再使用一个映射层将其映射到对比学习空间，使用 NT-Xent 损失进行预训练。本文的框架也主要受到 SimCLR 的启发。

- NLP 领域的对比学习（用于文本表示学习）：随着对比学习在 CV 无监督图像表示预训练任务上大获成功，许多工作也试图将对比学习引入到 NLP 的语言模型预训练中。下面是一些代表性的工作及其总结：

名称	结构	数据增强方法	作用阶段
BERT-CT[18]	用两个相同结构、不同参数的模型产生两个 View	用两个相同结构、不同参数的模型产生两个 View	微调 BERT
IS-BERT[16]	在 BERT 之上添加额外的 CNN 层	全局 Embedding 作为一个 View；CNN 层局部的 Embedding 作为另一个 View	微调 BERT，最大化全局 Embedding 和局部 Embedding 的互信息，类似 DeepInfoMax（DIM）
CERT[17]	类似 MoCo，用一个动量编码器	回译	先在任务上用对比无监督精调，再迁到有监督任务
CLEAR[20]	类似 SimCLR	Token、Span 的删除（Deletion）、交换位置（Reordering）、替换（Substitution）	预训练阶段，用 MLM 和对比损失联合训练模型
DeCLUTR[19]	类似 SimCLR	从文本中抽取 Span	预训练阶段，用 MLM 和对比损失联合训练模型

3. 模型介绍

3.1 问题定义

给定一个类似 BERT 的预训练语言模型 $\mathbf{M}$，以及从目标领域数据分布中收集的无标签文本语料库 D，我们希望通过构建自监督任务在 D 上对 $\mathbf{M}$ 进行 Fine-tune，使得 Fine-tune 后的模型能够在目标任务（文本语义匹配）上表现最好。

3.2 基于对比学习的句子表示迁移框架

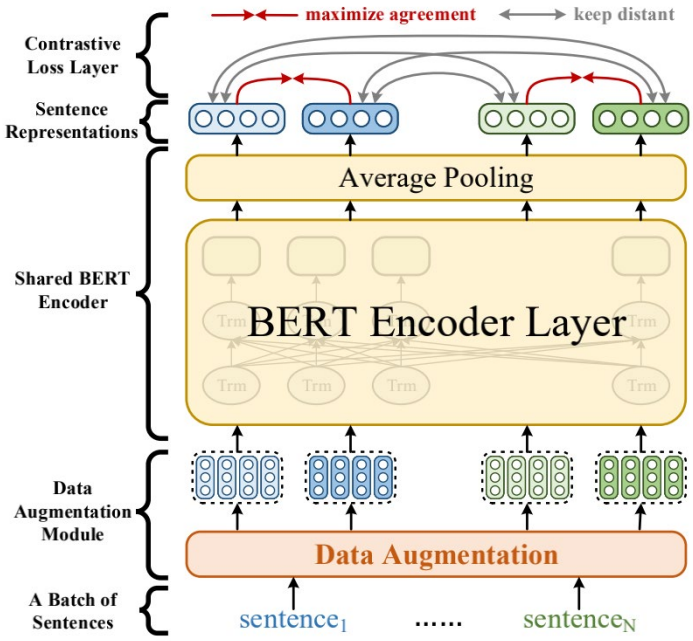

图 3　ConSERT 的基本框架

如图 3 所示，我们受到 SimCLR 的启发对 BERT 编码器进行了改进，提出 ConSERT，主要包含三个部分：

- 一个数据增强模块（详见后文），作用于 Embedding 层，为同一个句子生成两个不同的增强版本（View）。
- 一个共享的 BERT 编码器，为输入的句子生成句向量。
- 一个对比损失层，用于在一个 Batch 的样本中计算对比损失，其思想是最大化同一个样本不同增强版本句向量的相似度，同时使得不同样本的句向量相互远离。

训练时，先从数据集 D 中采样一个 Batch 的文本，设 Batch size 为 N。通过数据增强模块，每一个样本都通过两种预设的数据增强方法生成两个版本，得到总共 $2N$ 条样本。这 $2N$ 条样本均会通过共享的 BERT 编码器进行编码，然后通过一个平均池化层，得到 $2N$ 个句向量。我们采用和 SimCLR 一致的 NT-Xent 损失对模型进行 Fine-tune：

$$\mathcal{L}_{i,j} = -\log \frac{\exp(\text{sim}(r_i, r_j)/\tau)}{\sum_{k=1}^{2N} \mathbf{1}_{[k \neq i]} \exp(\text{sim}(r_i, r_k)/\tau)}$$

这里的 sim() 函数为余弦相似度函数；r 表示对应的句向量；τ 表示 temperature，是一个超参数，实验中取 0.1。该损失从直观上理解，是让 Batch 内的每个样本都找到其对应的另一个增强版本，而 Batch 内的其他 $2N$—2 个样本将充当负样本。优化的结果就是让同一个样本的两个增强版本在表示空间中具有尽可能大的一致性，同时和其他的 Batch 内负样本相距尽可能远。

3.3 用于文本领域的数据增强方法探索

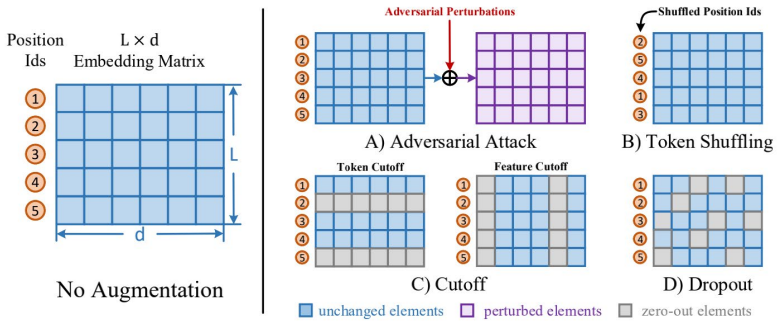

图 4　四种高效的数据增强方法：Adversarial Attack、Token Shuffling、Cutoff、Dropout，均作用于 Embedding 层

图像领域可以方便地对样本进行变换，如旋转、翻转、裁剪、去色、模糊等等，从而得到对应的增强版本。然而，由于语言天然的复杂性，很难找到高效的、同时又保留语义不变的数据增强方法。一些显式生成增强样本的方法包括：

- 回译：利用机器翻译模型，将文本翻译到另一个语言，再翻译回来。
- CBERT[12][13]：将文本的部分词替换成 [MASK]，然后利用 BERT 去恢复对应的词，生成增强句子。
- 意译（Paraphrase）：利用训练好的 Paraphrase 生成模型生成同义句。

然而这些方法一方面不一定能保证语义一致，另一方面每一次数据增强都需要做一次

模型 Inference，开销会很大。鉴于此，我们考虑了在 Embedding 层隐式生成增强样本的方法，如图 4 所示：

- **对抗攻击（Adversarial Attack）**：这一方法通过梯度反传生成对抗扰动，将该扰动加到原本的 Embedding 矩阵上，就能得到增强后的样本。由于生成对抗扰动需要梯度反传，因此这一数据增强方法仅适用于有监督训练的场景。
- **打乱词序（Token Shuffling）**：这一方法扰乱输入样本的词序。由于 Transformer 结构没有“位置”的概念，模型对 Token 位置的感知全靠 Embedding 中的 Position Ids 得到。因此在实现上，我们只需要将 Position Ids 进行 Shuffle 即可。
- **裁剪（Cutoff）**：又可以进一步分为两种：
  - Token Cutoff：随机选取 Token，将对应 Token 的 Embedding 整行置为零。
  - Feature Cutoff：随机选取 Embedding 的 Feature，将选取的 Feature 维度整列置为零。
- **Dropout**：Embedding 中的每一个元素都以一定概率置为零，与 Cutoff 不同的是，该方法并没有按行或者按列的约束。

这四种方法均可以方便地通过对 Embedding 矩阵（或是 BERT 的 Position Encoding）进行修改得到，因此相比显式生成增强文本的方法更为高效。

3.4 进一步融合监督信号

除了无监督训练以外，我们还提出了几种进一步融合监督信号的策略：

- 联合训练（joint）：有监督的损失和无监督的损失通过加权联合训练模型。
- 先有监督再无监督（sup-unsup）：先使用有监督损失训练模型，再使用无监督的方法进行表示迁移。
- 联合训练再无监督（joint-unsup）：先使用联合损失训练模型，再使用无监督的方法进行表示迁移。

4. 实验分析

我们主要在文本语义匹配（Semantic Textual Similarity，STS）任务上进行了实验，包括七个数据集：STS12、STS13、STS14、STS15、STS16、STSb、SICK-R。其中 STS12-16 为 SemEval2012 ~ 2016 评测比赛放出的数据集；STSb 为 STS benchmark，来自于 SemEval2017 评测赛；SICK-R 表示 SICK-Relatedness，是 SICK（Sentences Involving ComPositional Knowledge）数据集中的一个子任务，目标是推断两个句子时间的语义相关性（即 Relatedness）。这些数据集中的样本均包含两个短文本 text1 和 text2，以及人工标注的位于 0 ~ 5 之间的分数，代表 text1 和 text2 语义上的匹配程度（5 表示最匹配，即“两句话表达的是同一个语义”；0 表示最不匹配，即“两句话表达的语义完全不相关”）。下面给出了两条样本作为示例：

text1	text2	人工标注的语义相似度
a man is cutting paper with a sword .	a woman is cutting a tomato .	0.6
a woman is dancing in the rain .	a woman dances in the rain out side .	5.0

在测试时，我们根据此前的工作 [1][2] 选择了斯皮尔曼相关系数（Spearman correlation）作为评测指标，它将用于衡量两组值（模型预测的余弦相似度和人工标注的语义相似度）之间的相关性，结果将位于 [-1, 1] 之间，仅当两组值完全正相关时取到 1。对于每个数据集，我们将其测试样本全部融合计算该指标，并且报告了七个数据集的平均结果。考虑到简洁性，会在表格中报告乘以 100 倍的结果。

4.1 无监督实验

Method	STS12	STS13	STS14	STS15	STS16	STSb	SICK-R	Avg.
Unsupervised baselines								
Avg. GloVe embeddings†	55.14	70.66	59.73	68.25	63.66	58.02	53.76	61.32
$BERT_{base}$‡	35.20	59.53	49.37	63.39	62.73	48.18	58.60	53.86
$BERT_{large}$‡	33.06	57.64	47.95	55.83	62.42	49.66	53.87	51.49
$CLEAR_{base}$†	49.0	48.9	57.4	63.6	65.6	75.6	72.5	61.8
IS-$BERT_{base}$-NLI†	56.77	69.24	61.21	75.23	70.16	69.21	64.25	66.58
$BERT_{base}$-CT†	66.86	70.91	72.37	78.55	77.78	-	-	-
$BERT_{large}$-CT†	69.50	75.97	74.22	78.83	78.92	-	-	-
Using STS unlabeled texts								
$BERT_{base}$-flow†	63.48	72.14	68.42	73.77	75.37	70.72	63.11	69.57
$BERT_{large}$-flow†	65.20	73.39	69.42	74.92	**77.63**	72.26	62.50	70.76
$ConSERT_{base}$‡	64.64	78.49	69.07	79.72	75.95	73.97	67.31	72.74
$ConSERT_{large}$‡	**70.69**	**82.96**	**74.13**	**82.78**	76.66	**77.53**	**70.37**	**76.45**

图 5　无监督设置下的实验结果

在无监督实验中，我们直接基于预训练的 BERT 在无标注的 STS 数据上进行 Fine-tune。结果显示，我们的方法在完全一致的设置下大幅度超过之前的 SOTA—BERT-flow，达到了 8% 的相对性能提升。

4.2 有监督实验

Method	STS12	STS13	STS14	STS15	STS16	STSb	SICK-R	Avg.
Using NLI supervision								
InferSent - GloVe†	52.86	66.75	62.15	72.77	66.87	68.03	65.65	65.01
Universal Sentence Encoder†	64.49	67.80	64.61	76.83	73.18	74.92	76.69	71.22
$SBERT_{base}$-NLI†	70.97	76.53	73.19	79.09	74.30	77.03	72.91	74.89
$SBERT_{large}$-NLI†	72.27	78.46	74.90	80.99	76.25	79.23	73.75	76.55
$SBERT_{base}$-NLI (re-impl.)‡	69.89	75.77	72.36	78.51	73.67	76.75	72.76	74.24
$SBERT_{large}$-NLI (re-impl.)‡	72.69	78.77	75.13	80.95	76.89	79.53	73.25	76.74
$BERT_{base}$-CT†	68.80	74.58	76.62	79.72	77.14	-	-	-
$BERT_{large}$-CT†	69.80	75.45	76.47	81.34	78.11	-	-	-
$ConSERT_{base}$ *joint*‡	70.53	79.96	74.85	81.45	76.72	78.82	77.53	77.12
$ConSERT_{large}$ *joint*‡	**73.26**	**82.36**	**77.73**	**83.84**	**78.75**	**81.54**	**78.64**	**79.44**
Using NLI supervision and STS unlabeled texts								
$BERT_{base}$-flow†	68.95	78.48	77.62	81.95	78.94	81.03	74.97	77.42
$BERT_{large}$-flow†	70.19	80.27	78.85	82.97	**80.57**	81.18	74.52	78.36
$ConSERT_{base}$ *sup-unsup*‡	73.51	84.86	77.44	83.11	77.98	81.80	74.29	79.00
$ConSERT_{large}$ *sup-unsup*‡	75.26	**86.01**	79.00	83.88	79.45	82.95	76.54	80.44
$ConSERT_{base}$ *joint-unsup*‡	74.07	83.93	77.05	83.66	78.76	81.36	76.77	79.37
$ConSERT_{large}$ *joint-unsup*‡	**77.47**	85.45	**79.41**	**85.59**	80.39	**83.42**	**77.26**	**81.28**

图 6　有监督设置下的实验结果

在有监督实验中，我们额外使用了来自 SNLI 和 MNLI 的训练数据，使用上面提到的

融合额外监督信号的三种方法进行了实验。实验结果显示，我们的方法在“仅使用 NLI 有标注数据”和“使用 NLI 有标注数据 + STS 无标注数据”的两种实验设置下均超过了基线。在三种融合监督信号的实验设置中，我们发现 joint-unsup 方法取得了最好的效果。

4.3 不同的数据增强方法分析

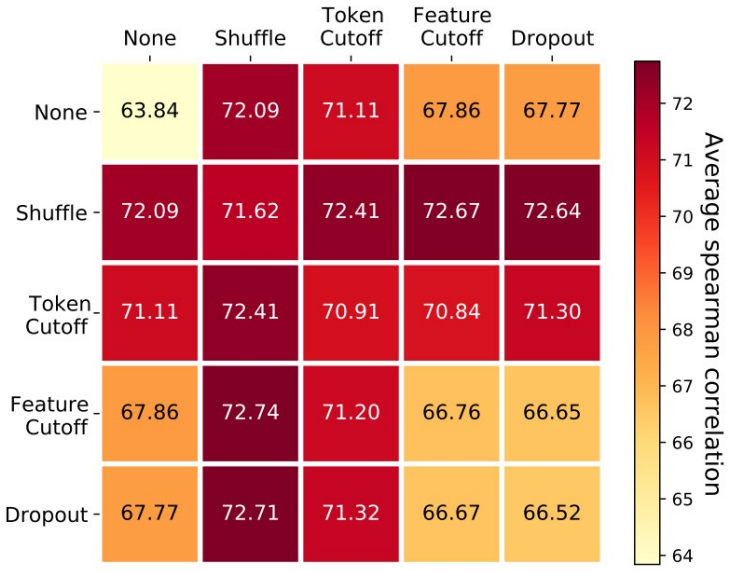

图 7　不同数据增强组合方法的性能

我们对不同的数据增强组合方法进行了消融分析，结果如图 7 所示。我们发现 Token Shuffle 和 Feature Cutoff 的组合取得了最优性能（72.74）。此外，就单种数据增强方法而言，Token Shuffle > Token Cutoff >> Feature Cutoff ≈ Dropout >> None。

4.4 少样本设置下的实验分析

我们进一步分析了数据量（无标注文本的数目）对效果的影响，结果如图 8 所示。结果显示，我们的方法仅需较少的样本就能近似达到全数据量的效果；同时，在样本量很少的情况下（如 100 条文本的情况下）仍相比于 Baseline 表现出不错的性能提升。

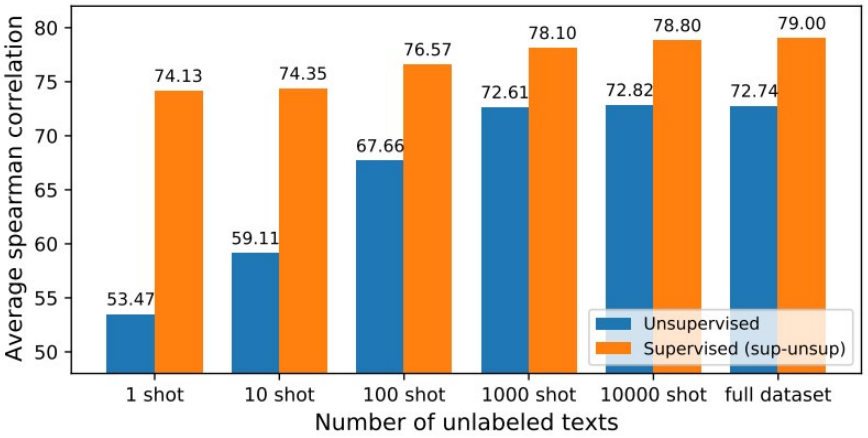

图 8　ConSERT 在小样本情况下的性能

4.5 Temperature 超参的实验分析

在实验中，我们发现对比学习损失函数中的温度超参数（τ）对于结果有很大影响。从图 9 的分析实验中可以看到，当 τ 值在 0.08 到 0.12 之间时会得到最优结果。这个现象再次证明了 BERT 表示的塌缩问题，因为在句子表示都很接近的情况下，τ 过大会使句子间相似度更平滑，编码器很难学到知识。而 τ 如果过小，任务就太过简单，所以需要调整到一个合适的范围内。

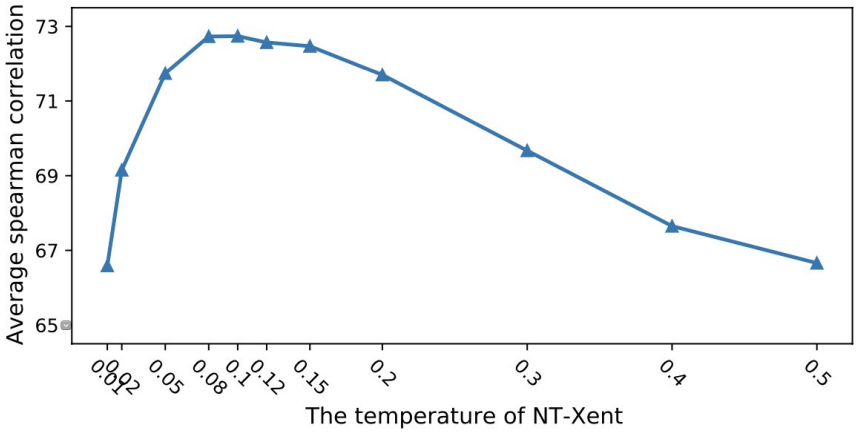

图 9　不同超参数 τ 下的性能

4.6 Batch size 超参的实验分析

在图像领域的对比学习中，Batch size 会对结果有很大影响，因此我们也对比了不同 Batch size 下模型的表现。从图 10 可以看到两者基本是成正比的，但提升很有限。

Batch Size	16	48	96	192	288
Avg. Spearman	72.63	72.60	72.74	72.86	72.98
Number of Steps	6175	2459	1530	930	620

图 10　不同 Batch size 下的性能

5. 总结

在此工作中，我们分析了 BERT 句向量表示空间坍缩的原因，并提出了一种基于对比学习的句子表示迁移框架 ConSERT。ConSERT 在无监督 Fine-tune 和进一步融合监督信号的实验中均表现出了不错的性能；同时当收集到的样本数较少时，仍能有不错的性能提升，表现出较强的鲁棒性。

同时，在美团的业务场景下，有大量不同领域的短文本相关性计算需求，目前 ConSERT 已经在知识图谱构建、KBQA、搜索召回等业务场景使用。未来将会在美团更多业务上进行探索落地。目前，相关代码已经在 GitHub 上开源，欢迎大家使用。

参考文献

[1] Reimers, Nils, and Iryna Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks.” Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2019.

[2] Li, Bohan, et al. “On the Sentence Embeddings from Pre-trained Language Models.” Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020.

[3] Gao, Jun, et al. “Representation Degeneration Problem in Training Natural Language Generation Models.” International Conference on Learning Representations. 2018.

[4] Wang, Lingxiao, et al. “Improving Neural Language Generation with Spectrum Control.” International Conference on Learning Representations. 2019.

[5] Conneau, Alexis, et al. “Supervised Learning of Universal Sentence Representations from Natural Language Inference Data.” Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. 2017.
[6] Cer, Daniel, et al. “Universal Sentence Encoder for English.” Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations. 2018.
[7] Wang, Shuohang, et al. “Cross-Thought for Sentence Encoder Pre-training.” Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020.
[8] Yang, Ziyi, et al. “Universal Sentence Representation Learning with Conditional Masked Language Model.” arXiv preprint arXiv:2012.14388 (2020).
[9] Lee, Haejun, et al. “SLM: Learning a Discourse Language Representation with Sentence Unshuffling.” Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020.
[10] Su, Jianlin, et al. “Whitening sentence representations for better semantics and faster retrieval.” arXiv preprint arXiv:2103.15316 (2021).
[11] Gao, Tianyu, Xingcheng Yao, and Danqi Chen. “SimCSE: Simple Contrastive Learning of Sentence Embeddings.” arXiv preprint arXiv:2104.08821 (2021).
[12] Wu, Xing, et al. “Conditional bert contextual augmentation.” International Conference on Computational Science. Springer, Cham, 2019.
[13] Zhou, Wangchunshu, et al. “BERT-based lexical substitution.” Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. 2019.
[14] He, Kaiming, et al. “Momentum contrast for unsupervised visual representation learning.” Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020.
[15] Chen, Ting, et al. “A simple framework for contrastive learning of visual representations.” International conference on machine learning. PMLR, 2020.
[16] Zhang, Yan, et al. “An Unsupervised Sentence Embedding Method by Mutual Information Maximization.” Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020.
[17] Fang, Hongchao, et al. “Cert: Contrastive self-supervised learning for language understanding.” arXiv preprint arXiv:2005.12766 (2020).
[18] Carlsson, Fredrik, et al. “Semantic re-tuning with contrastive tension.” International Conference on Learning Representations. 2021.
[19] Giorgi, John M., et al. “Declutr: Deep contrastive learning for unsupervised textual representations.” arXiv preprint arXiv:2006.03659 (2020).
[20] Wu, Zhuofeng, et al. “CLEAR: Contrastive Learning for Sentence Representation.” arXiv preprint arXiv:2012.15466(2020).

作者简介

渊蒙、如寐、思睿、富峥、武威等，美团平台 / 搜索与 NLP 部。
徐蔚然，北京邮电大学人工智能学院，模式识别实验室，副教授，博士生导师。

CVPR 2021 | 基于 Transformer 的端到端视频实例分割方法

作者：钰晴　昭良

前言

实例分割是计算机视觉中的基础问题之一。目前，静态图像中的实例分割业界已经进行了很多的研究，但是对视频的实例分割（Video Instance Segmentation，简称 VIS）的研究却相对较少。而真实世界中的摄像头所接收的，无论是自动驾驶背景下车辆实时感知的周围场景，还是网络媒体中的长短视频，大多数都是视频流信息而非纯图像信息。因而研究对视频建模的模型有着十分重要的意义，本文系美团无人配送团队在 CVPR2021 发表的一篇 Oral 论文：《End-to-End Video Instance Segmentation with Transformers》的解读。本届 CVPR 大会共收到 7015 篇有效投稿，最终共 1663 篇论文被接收，论文录用率为 23.7%，Oral 的录用率仅为 4%。

背景

图像的实例分割指的是对静态图像中感兴趣的物体进行检测和分割的任务。视频是包含多帧图像的信息载体，相对于静态图像来说，视频的信息更为丰富，因而建模也更为复杂。不同于静态图像仅含有空间的信息，视频同时含有时间维度的信息，因而更接近对真实世界的刻画。其中，视频的实例分割指的是对视频中感兴趣的物体进行检测、分割和跟踪的任务。如图 1 所示，第一行为给定视频的多帧图像序列，第二行为视频实例分割的结果，其中相同颜色对应同一个实例。视频实例分割不光要对单帧图像中的物体进行检测和分割，而且要在多帧的维度下找到每个物体的对应关系，即对其进行关联和跟踪。

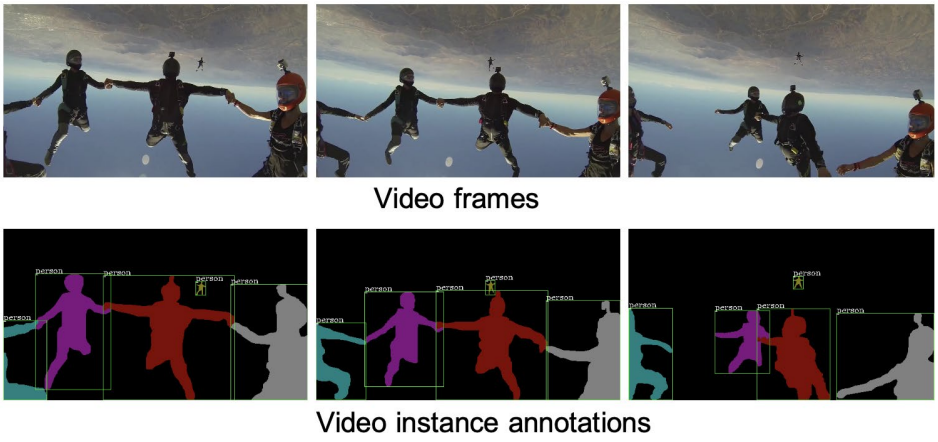

图 1　视频实例分割任务示意

相关工作

现有的视频实例分割算法通常为包含多模块、多阶段的复杂流程。最早的 Mask Track R-CNN[1] 算法同时包含实例分割和跟踪两个模块，通过在图像实例分割算法 Mask R-CNN[2] 的网络之上增加一个跟踪的分支实现，该分支主要用于实例特征的提取。在预测阶段，该方法利用外部 Memory 模块进行多帧实例特征的存储，并将该特征作为实例关联的一个要素进行跟踪。该方法的本质仍然是单帧的分割加传统方法进行跟踪关联。Maskprop[3] 在 Mask Track R-CNN 的基础上增加了 Mask Propagation 的模块以提升分割 Mask 生成和关联的质量，该模块可以实现当前帧提取的 mask 到周围帧的传播，但由于帧的传播依赖于预先计算的单帧的分割 Mask，因此要得到最终的分割 Mask 需要多步的 Refinement。该方法的本质仍然是单帧的提取加帧间的传播，且由于其依赖多个模型的组合，方法较为复杂，速度也更慢。

Stem-seg[4] 将视频实例分割划分为实例的区分和类别的预测两个模块。为了实现实例的区分，模型将视频的多帧 Clip 构建为 3D Volume，通过对像素点的 Embedding 特征进行聚类实现不同物体的分割。由于上述聚类过程不包含实例类别的预测，因此需要额外的语义分割模块提供像素的类别信息。根据以上描述，现有的算法大多沿袭单帧图像实例分割的思想，将视频实例分割任务划分为单帧的提取和多帧的关联

多个模块，针对单个任务进行监督和学习，处理速度较慢且不利于发挥视频时序连续性的优势。本文旨在提出一个端到端的模型，将实例的检测、分割和跟踪统一到一个框架下实现，有助于更好地挖掘视频整体的空间和时序信息，且能够以较快的速度解决视频实例分割的问题。

VisTR 算法介绍

重新定义问题

首先，我们对视频实例分割这一任务进行了重新的思考。相较于单帧图像，视频含有关于每个实例更为完备和丰富的信息，比如不同实例的轨迹和运动模态，这些信息能够帮助克服单帧实例分割任务中一些比较困难的问题，比如外观相似、物体邻近或者存在遮挡的情形等。另一方面，多帧所提供的关于单个实例更好的特征表示也有助于模型对物体进行更好的跟踪。因此，我们的方法旨在实现一个端到端对视频实例目标进行建模的框架。为了实现这一目标，我们第一个思考是：**视频本身是序列级别的数据，能否直接将其建模为序列预测的任务？**比如，借鉴自然语言处理（NLP）任务的思想，将视频实例分割建模为序列到序列（Seq2Seq）的任务，即给定多帧图像作为输入，直接输出多帧的分割 Mask 序列，这时需要一个能够同时对多帧进行建模的模型。

第二个思考是：**视频的实例分割实际同时包含实例分割和目标跟踪两个任务，能否将其统一到一个框架下实现？**针对这个我们的想法是：分割本身是像素特征之间相似度的学习，而跟踪本质是实例特征之间相似度的学习，因此理论上他们可以统一到同一个相似度学习的框架之下。

基于以上的思考，我们选取了一个同时能够进行序列的建模和相似度学习的模型，即自然语言处理中的 Transformer[5] 模型。Transformer 本身可以用于 Seq2Seq 的任务，即给定一个序列，可以输入一个序列。并且该模型十分擅长对长序列进行建模，因此非常适合应用于视频领域对多帧序列的时序信息进行建模。其次，Transformer 的核心机制，自注意力模块（Self-Attention），可以基于两两之间的相似度来进行特征的学习和更新，使得将像素特征之间相似度以及实例特征之间相似度

统一在一个框架内实现成为可能。以上的特性使得 Transformer 成为 VIS 任务的恰当选择。除此之外，Transformer 已经有被应用于计算机视觉中进行目标检测的实践 DETR[6]。因此我们基于 transformer 设计了视频实例分割（VIS）的模型 VisTR。

VisTR 算法流程

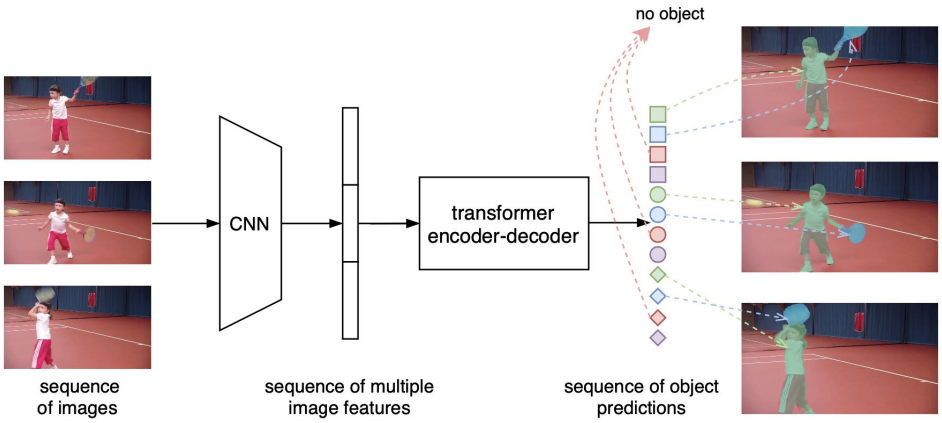

图 2　VisTR 算法框架

遵照上述思想，VisTR 的整体框架如图 2 所示。图中最左边表示输入的多帧原始图像序列（以三帧为例），右边表示输出的实例预测序列，其中相同形状对应同一帧图像的输出，相同颜色对应同一个物体实例的输出。给定多帧图像序列，首先利用卷积神经网络（CNN）进行初始图像特征的提取，然后将多帧的特征结合作为特征序列输入 Transformer 进行建模，实现序列的输入和输出。

不难看出，首先，VisTR 是一个端到端的模型，即同时对多帧数据进行建模。建模的方式即：将其变为一个 Seq2Seq 的任务，输入多帧图像序列，模型可以直接输出预测的实例序列。虽然在时序维度多帧的输入和输出是有序的，但是单帧输入的实例的序列在初始状态下是无序的，这样仍然无法实现实例的跟踪关联，因此我们强制使得每帧图像输出的实例的顺序是一致的（用图中同一形状的符号有着相同的颜色变化顺序表示），这样只要找到对应位置的输出，便可自然而然实现同一实例的关联，无需任何后处理操作。为了实现此目标，需要对属于同一个实例位置处的特征进行序列维

度的建模。针对性地，为了实现序列级别的监督，我们提出了 Instance Sequence Matching 的模块。同时为了实现序列级别的分割，我们提出了 Instance Sequence Segmentation 的模块。端到端的建模将视频的空间和时间特征当做一个整体，可以从全局的角度学习整个视频的信息，同时 Transformer 所建模的密集特征序列又能够较好的保留细节的信息。

VisTR 网络结构

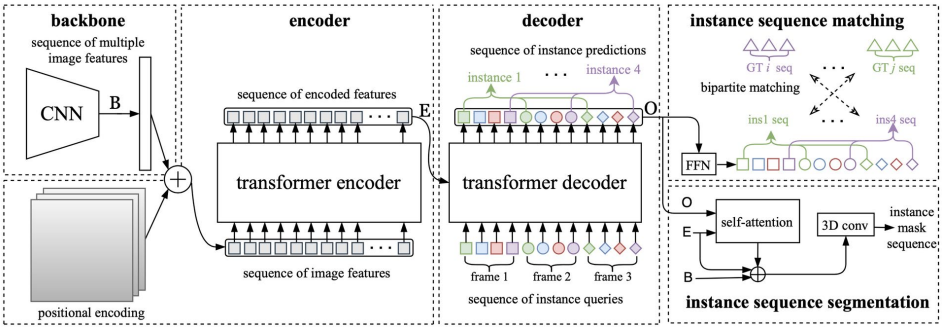

图 3　VisTR 网络结构

VisTR 的详细网络结构如图 3 所示，以下是对网络的各个组成部分的介绍：

- **Backbone**：主要用于初始图像特征的提取。针对序列的每一帧输入图像，首先利用 CNN 的 Backbone 进行初始图像特征的提取，提取的多帧图像特征沿时序和空间维度序列化为多帧特征序列。由于序列化的过程损失了像素原始的空间和时序信息，而检测和分割的任务对于位置信息十分敏感，因此我们将其原始的空间和水平位置进行编码，作为 Positional Encoding 叠加到提取的序列特征上，以保持原有的位置信息。Positional Encoding 的方式遵照 Image Transformer[7] 的方式，只是将二维的原始位置信息变为了三维的位置信息，这部分在论文中有详细的说明。
- **Encoder**：主要用于对多帧特征序列进行整体的建模和更新。输入前面的多帧特征序列，Transformer 的 Encoder 模块利用 Self-Attention 模块，通过点和

点之间相似度的学习，进行序列中所有特征的融合和更新。该模块通过对时序和空间特征的整体建模，能够对属于同一个实例的特征进行更好的学习和增强。

- **Decoder**：主要用于解码输出预测的实例特征序列。由于 Encoder 输入 Decoder 的是密集的像素特征序列，为了解码出稀疏的实例特征，我们参考 DETR 的方式，引入 Instance Query 进行代表性的实例特征的解码。Instance Query 是网络自身学习的 Embedding 参数，用于和密集的输入特征序列进行 Attention 运算选取能够代表每个实例的特征。以处理 3 帧图像，每帧图像预测 4 个物体为例，模型一共需要 12 个 Instance Query，用于解码 12 个实例预测。和前面的表示一致，用同样的形状表示对应同一帧图像的预测，同样的颜色表示同一个物体实例在不同帧的预测。通过这种方式，我们可以构造出每个实例的预测序列，对应为图 3 中的 Instance 1…Instance 4，后续过程中模型都将单个物体实例的序列看作整体进行处理。
- **Instance Sequence Matching**：主要用于对输入的预测结果进行序列级别的匹配和监督。前面已经介绍了从序列的图像输入到序列的实例预测的过程。但是预测序列的顺序其实是基于一个假设的，即在帧的维度保持帧的输入顺序，而在每帧的预测中，不同实例的输出顺序保持一致。帧的顺序比较容易保持，只要控制输入和输出的顺序一致即可，但是不同帧内部实例的顺序其实是没有保证的，因此我们需要设计专门的监督模块来维持这个顺序。在通用目标检测之中，在每个位置点会有它对应的 Anchor，因此对应每个位置点的 Ground Truth 监督是分配好的，而在我们的模型中，实际上是没有 Anchor 和位置的显式信息，因此对于每个输入点我们没有现成的属于哪个实例的监督信息。为了找到这个监督，并且直接在序列维度进行监督，我们提出了 Instance Sequence Matching 的模块，这个模块将每个实例的预测序列和标注数据中每个实例的 Ground Truth 序列进行二分匹配，利用匈牙利匹配的方式找到每个预测最近的标注数据，作为它的 Groud Truth 进行监督，进行后面的 Loss 计算和学习。
- **Instance Sequence Segmentation**：主要用于获取最终的分割结果序列。

前面已经介绍了 Seq2Seq 的序列预测过程，我们的模型已经能够完成序列的预测和跟踪关联。但是到目前为止，我们为每个实例找到的只是一个代表性的特征向量，而最终要解决的是分割的任务，如何将这个特征向量变为最终的 Mask 序列，就是 Instance Sequence Segmentation 模块要解决的问题。前面已经提到，实例分割本质是像素相似度的学习，因此我们初始计算 Mask 的方式就是利用实例的预测和 Encode 之后的特征图计算 Self-Attention 相似度，将得到的相似度图作为这个实例对应帧的初始 Attention Mask 特征。为了更好的利用时序的信息，我们将属于同一个实例的多帧的 Attention Mask 作为 Mask 序列输入 3D 卷积模块进行分割，直接得到最终的分割序列。这种方式通过利用多帧同一实例的特征对单帧的分割结果进行增强，可以最大化的发挥时序的优势。

VisTR 损失函数

根据前面的描述，网络学习中需要计算损失的主要有两个地方，一个是 Instance Sequence Matching 阶段的匹配过程，一个是找到监督之后最终整个网络的损失函数计算过程。

Instance Sequence Matching 过程的计算公式如式 1 所示：由于 Matching 阶段只是用于寻找监督，而计算 Mask 之间的距离运算比较密集，因此在此阶段我们只考虑 Box 和预测的类别 c 两个因素。第一行中的 yi 表示对应第 i 个实例的 Ground Truth 序列，其中 c 表示类别，b 表示 Boundingbox，T 表示帧数，即 T 帧该实例对应的类别和 Bounding Box 序列。第二行和第三行分别表示预测序列的结果，其中 p 表示在 ci 这个类别的预测的概率，b 表示预测的 Bounding Box。序列之间距离的运算是通过两个序列对应位置的值两两之间计算损失函数得到的，图中用 Lmatch 表示，对于每个预测的序列，找到 Lmatch 最低那个 Ground Truth 序列作为它的监督。根据对应的监督信息，就可以计算整个网络的损失函数。

$$y_i = \{(c_i, c_i..., c_i), (b_{i,0}, b_{i,1}..., b_{i,T})\}$$

$$\hat{p}_{(\sigma(i))}(c_i) = \{\hat{p}_{(\sigma(i),0)}(c_i)..., \hat{p}_{(\sigma(i),T)}(c_i)\}$$

$$\hat{b}_{\sigma(i)} = \left\{\hat{b}_{(\sigma(i),0)}, \hat{b}_{(\sigma(i),1)}..., \hat{b}_{(\sigma(i),T)}\right\}$$

$$\mathcal{L}_{\text{match}}\left(y_i, \hat{y}_{\sigma(i)}\right) = -\hat{p}_{\sigma(i)}\left(c_i\right) + \mathcal{L}_{\text{box}}\left(b_i, \hat{b}_{\sigma(i)}\right)$$

$$\hat{\sigma} = \arg\min_{\sigma \in S_n} \sum_{i}^{n} \mathcal{L}_{\text{match}}\left(y_i, \hat{y}_{\sigma(i)}\right)$$

公式 1　Instance Sequence Matching 计算过程

由于我们的方法是将分类、检测、分割和跟踪做到一个端到端网络里，因此最终的损失函数也同时包含类别、Bounding Box 和 Mask 三个方面，跟踪通过直接对序列算损失函数体现。公式 2 表示分割的损失函数，得到了对应的监督结果之后，我们计算对应序列之间的 Dice Loss 和 Focal Loss 作为 Mask 的损失函数。

$$\mathcal{L}_{\text{mask}}\left(m_i, \hat{m}_{\sigma(i)}\right) = \lambda_{\text{mask}} \frac{1}{T} \sum_{t=1}^{T} \Big[\mathcal{L}_{\text{Dice}}(m_{i,t}, \hat{m}_{\sigma(i),t}) + \mathcal{L}_{\text{Focal}}(m_{i,t}, \hat{m}_{\sigma(i),t})\Big].$$

公式 2　分割损失函数

最终的损失函数如公式 3 所示，为同时包含分类（类别概率）、检测（Bounding Box）以及分割（Mask）的序列损失函数之和。

$$\mathcal{L}_{\text{Hung}}(y, \hat{y}) = \sum_{i=1}^{N} \Big[(-\log \hat{p}_{\hat{\sigma}(i)}(c_i)) + \mathcal{L}_{\text{box}}\left(b_i, \hat{b}_{\hat{\sigma}}(i)\right) + \mathcal{L}_{\text{mask}}\left(m_i, \hat{m}_{\hat{\sigma}}(i)\right)\Big].$$

公式 3　VisTR 整体损失函数

实验结果

为了验证方法的效果，我们在广泛使用的视频实例分割数据集 YouTube-VIS 上进行了实验，该数据集包含 2238 个训练视频，302 个验证视频以及 343 个测试视频，以及 40 个物体类别。模型的评估标准包含 AP 和 AR，以视频维度多帧 Mask 之间的 IOU 作为阈值。

时序信息的重要性

相对于现有的方法，VisTR 的最大区别是直接对视频进行建模，而视频和图像的主要区别在于视频包含着丰富的时序信息，如果有效的挖掘和学习时序信息是视频理解的关键，因此我们首先探究了时序信息的重要性。时序包含两个维度：时序的多少（帧数）以及有序和无序的对比。

Length	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
18	29.7	50.4	31.1	29.5	34.4
24	30.5	47.8	33.0	29.5	34.4
30	31.7	53.2	32.8	31.3	36.0
36	33.3	53.4	35.1	33.1	38.5

表 1　不同帧数模型的训练效果对比

表 1 中展示了我们利用不同帧数的 Clip 训练模型最终的测试效果，不难看出，随着帧数从 18 提升至 36，模型的精度 AP 也在不断提升，证明多帧提供的更丰富的时序信息对模型的学习有所帮助。

time order	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
random	32.3	52.1	34.3	33.8	37.3
in order	33.3	53.4	35.1	33.1	38.5

表 2　打乱时序 vs. 按照时序训练的效果对比

表 2 中展示了利用打乱物理时序的 Clip 以及按照物理时序的 Clip 进行模型训练的效果对比，可以看出，按照时间顺序训练的模型有一个点的提升，证明 VisTR 有学到物理时间下物体变化和规律，而按照物理时间顺序对视频建模也有助于视频的理解。

Query 探究

第二个实验是对于 Query 的探究。由于我们的模型直接建模的 36 帧图像，对每帧图像预测 10 个物体，因此需要 360 个 Query，对应表 3 最后一行的结果（Prediction Level）。我们想探究属于同一帧或者同一个实例的 Query 之间是否存在一定的关联，即是否可以共享。针对这个目标，我们分别设计了 Frame Level 的实验：即一帧只使用一个 Query 的特征进行预测，以及 Instance level 的实验：一个实例只使用一个 Query 的特征进行预测。

可以看到，Instance Level 的结果只比 Prediction Level 的结果少一个点，而 Frame Level 的结果要低 20 个点，证明不同帧属于同一个 Instance 的 Query 可以共享，而同一帧不同 Instance 的 Query 信息不可共享。Prediction Level 的 Query 是和输入的图像帧数成正比的，而 Instance Level 的 Query 可以实现不依赖输入帧数的模型。只限制模型要预测的 Instance 个数，不限制输入帧数，这也是未来可以继续研究的方向。除此之外，我们还设计了 Video Level 的实验，即整个视频只用一个 Query 的 Embedding 特征进行预测，这个模型可以实现 8.4 的 AP。

	number	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
video level	1	8.4	13.2	9.5	20.0	20.8
frame level	36	13.7	23.3	14.5	30.4	35.1
ins. level	10	32.0	52.8	34.0	31.6	37.2
pred. level	360	33.3	53.4	35.1	33.1	38.5

表 3　不同类型 Query 的效果对比

其他设计

以下是实验过程中我们发现有效的其他设计。

	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
w/o	28.4	50.1	29.5	29.6	33.3
w	33.3	53.4	35.1	33.1	38.5

表 4　有无 positional encoding 的实验效果对比

由于在特征序列化的过程中会损失原有的空间和时间信息，我们提供了原始的 Positional Encoding 特征以保留原有的位置信息。在表 5 中进行了有无该模块的对比，Positional Encoding 提供的位置信息可以带来约 5 个点的提升。

	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
CNN	32.0	54.5	31.5	31.6	37.7
Transformer	33.3	53.4	35.1	33.1	38.5

表 5　CNN-encoded 的特征 vs.Transformer-Encoded 的特征对分割的效果对比

在分割的过程中，我们通过计算实例的 Prediction 与 Encoded 之后特征的 Self-Attention 来获取初始的 Attention Mask。在表 6 中，我们进行了利用 CNN-Encoded 的特征和利用 Transformer-Encoded 的特征进行分割的效果对比，利用 Transformer 的特征可以提升一个点。证明了 Transformer 进行全局特征更新的有效性。

	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
w/o	33.3	53.4	35.1	33.1	38.5
w	34.4	55.7	36.5	33.5	38.9

表 6　有无 3D 卷积的实验效果对比

表 6 中展示了在分割模块有无 3D 卷积的效果对比，使用 3D 卷积可以带来一个点的提升，证明了利用时序信息直接对多帧 mask 分割的有效性。

可视化结果

图 4　VisTR 可视化效果

VisTR 在 YouTube-VIS 的可视化效果如图 4 所示，其中每行表示同一个视频的序列，相同颜色对应同一个实例的分割结果。可以看出无论是在 (a). 实例存在遮挡 (b). 实例位置存在相对变化 ©. 同类紧邻易混淆的实例 以及 (d). 实例处于不同姿态情形下，模型都能够实现较好的分割个跟踪，证明在有挑战性的情况下，VisTR 仍具有很好的效果。

方法对比

Method	backbone	FPS	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
DeepSORT [28]	ResNet-50	-	26.1	42.9	26.1	27.8	31.3
FEELVOS [24]	ResNet-50	-	26.9	42.0	29.7	29.9	33.4
OSMN [31]	ResNet-50	-	27.5	45.1	29.1	28.6	33.1
MaskTrack R-CNN [30]	ResNet-50	20.0	30.3	51.1	32.6	31.0	35.5
STEm-Seg [1]	ResNet-50	-	30.6	50.7	33.5	31.6	37.1
STEm-Seg [1]	ResNet-101	2.1	34.6	55.8	37.9	34.4	41.6
MaskProp [2]	ResNet-50	-	40.0	-	42.9	-	-
MaskProp [2]	ResNet-101	-	42.5	-	45.6	-	-
VisTR	ResNet-50	30.0/69.9	36.2	59.8	36.9	37.2	42.4
VisTR	ResNet-101	27.7/57.7	40.1	64.0	45.0	38.3	44.9

表 7　VisTR 可视化效果

表 7 是我们的方法和其他方法在 YoutubeVIS 数据集上的对比。我们的方法实现了单一模型的最好效果（其中 MaskProp 包含多个模型的组合），在 57.7FPS 的速度下实现了 40.1 的 AP。其中前面的 27.7 指的是加上顺序的 Data Loading 部分的速度（这部分可以利用并行进行优化），57.7 指的是纯模型 Inference 的速度。由于我们的方法直接对 36 帧图像同时进行建模，因此相对于同样模型的单帧处理，理想情况下能带来大约 36 倍的速度提升，更有助于视频模型的广泛应用。

总结与展望

视频实例分割指的是同时对视频中感兴趣的物体进行分类，分割和跟踪的任务。现有的方法通常设计复杂的流程来解决此问题。本文提出了一种基于 Transformer 的视频实例分割新框架 VisTR，该框架将视频实例分割任务视为直接端到端的并行序列解码和预测的问题。给定一个含有多帧图像的视频作为输入，VisTR 直接按顺序输出视频中每个实例的掩码序列。该方法的核心是一种新的实例序列匹配和分割的策略，能够在整个序列级别上对实例进行监督和分割。 VisTR 将实例分割和跟踪统一到了相似度学习的框架下，从而大大简化了流程。在没有任何 trick 的情况下，VisTR 在所有使用单一模型的方法中获得了最佳效果，并且在 YouTube-VIS 数据集上实现了最快的速度。

据我们所知，这是第一个将 Transformers 应用于视频分割领域的方法。希望我们的方法能够启发更多视频实例分割的研究，同时也希望此框架未来能够应用于更多视频理解的任务。关于论文的更多细节，请参考原文：《End-to-End Video Instance Segmentation with Transformers》，同时代码也已经在 GitHub 上开源：https://github.com/Epiphqny/VisTR，欢迎大家来了解或使用。

作者

美团无人车配送中心：钰晴、昭良、保山、申浩等。
阿德莱德大学：王鑫龙、沈春华。

参考文献

[1] Video Instance Segmentation, https://arxiv.org/abs/1905.04804.
[2] Mask R-CNN, https://arxiv.org/abs/1703.06870.
[3] Classifying, Segmenting, and Tracking Object Instances in Video with Mask Propagation, https://arxiv.org/abs/1912.04573.
[4] STEm-Seg: Spatio-temporal Embeddings for Instance Segmentation in Videos, https://arxiv.org/abs/2003.08429.
[5] Attention Is All You Need, https://arxiv.org/abs/1706.03762.
[6] End-to-End Object Detection with Transformers, https://arxiv.org/abs/2005.12872.
[7] Image Transformer, https://arxiv.org/abs/1802.05751.

招聘信息

美团无人车配送中心大量岗位持续招聘中，诚招算法 / 系统 / 硬件开发工程师及专家。欢迎感兴趣的同学发送简历至：ai.hr@meituan.com（邮件标题注明：美团无人车团队）。

ICLR 2021 | 美团 AutoML 论文：鲁棒的神经网络架构搜索 DARTS-

作者：祥祥　晓星　张勃　晓林

背景

美团日益增长的用户侧和商家侧业务对人工智能（AI）技术有着非常广泛和强烈的诉求。从用户角度出发，美团 AI 在外卖之外，有到店消费、酒店旅游等 200 多个生活服务场景，均需要 AI 来提升用户体验。从商家角度出发，美团 AI 将帮助商家提高效率、分析运营状况，比如能对用户评论进行细粒度分析，来刻画出商家服务现状、商家竞争力分析，以及商圈洞察等等，为商户提供精细化经营建议。

目前，美团 AI 涉及的研发领域，包括自然语言理解、知识图谱、搜索、语音识别、语音生成、人脸识别、文字识别、视频理解、图像编辑、AR、环境预测、行为规划、运动控制等。AI 技术在这些场景中落地的两个关键部分是规模化的数据和先进的深度学习模型，其中高质量模型的设计和更新迭代是当前 AI 生产开发的痛点和难点，亟需自动化技术来辅助并提升生产效率。在此情景下应运而生的技术叫做自动化机器学习（AutoML）。AutoML 被认为是模型设计的未来解决方案，能够将 AI 算法工程师从手动设计的繁复试错中解放出来。

谷歌 2017 年正式提出神经网络架构搜索（Neural Architecture Search，NAS）[1] 用于自动化生成模型架构，这项技术被业界寄予厚望，成为 AutoML 的核心组成部分。凭借日益增强的算力和持续迭代的 NAS 算法，视觉模型在架构层面诞生了像 EfficientNet、MobileNetV3 等影响力深远的系列模型，NAS 也应用到了视觉、NLP、语音等领域的很多方向 [2,3]。NAS 作为生成 AI 模型的 AI，其重要意义不言而喻。美团在 NAS 方向也开展了深入性的研究，对该领域保持着积极的探索。

本文介绍美团和上海交通大学合作的文章 DARTS-[4]，该文即将发表在 ICLR 2021 顶会上。ICLR（International Conference on Learning Representations）全称是

国际学习表征会议，2013 年由两位深度学习大牛、图灵奖得主 Yoshua Bengio 和 Yann LeCun 牵头创办。ICLR 成立至今仅七年，但它已得到学术界的广泛认可，被认为是“深度学习领域的顶级会议”。ICLR 的 h5 指数为 203，在所有科学出版物中排名第 17，超过了 NeurIPS、ICCV 和 ICML。本届 ICLR 共有 2997 篇论文提交，最终接收 860 篇，包括 53 篇 Oral（接收率 6%），114 篇 Spotlight，693 篇 Poster，接收率为 28.7%。

神经网络架构搜索简介

神经网络架构搜索（NAS）的主要任务是如何在有限时间和资源下搜索得到最优的模型。NAS 主要由搜索空间、搜索算法、模型评估三部分组成。NAS 最早在视觉分类任务中验证，在分类任务中常见的搜索空间分为基于子结构单元（Cell）和基于子结构块（Block）两种，前者的特点是具有丰富的图结构，将相同的单元串联再组成最终的网络。后者是直筒型的，搜索的焦点就在于每层子结构块的选取。

按搜索算法分类，NAS 主要包括基于强化学习（Reinforcement Learning，RL）、基于遗传算法（Evolutionary Algorithm，EA）、基于梯度优化（Gradient-Based）的方法。RL 方法通过生成并评估模型来获取反馈，根据反馈来调整生成的策略，从而生成新的模型，循环这一过程直到最优。 EA 方法将模型结构编码为可以交叉和变异的“基因”，通过不同的遗传算法来获取新一代的基因，直到达到最好。EA 方法的优点在于可以处理多种目标，比如一个模型的优劣有参数量、计算延迟、性能指标等多个考察维度，EA 方法便很适合在多个维度进行探索和演进。但 RL 和 EA 均比较耗时，主要受限于模型评估部分，一般采取全量、少量训练的方法。最新的 One-Shot 路线采用训练一个包含所有子结构的超网来评估所有子网的方式，可以从很大程度上提高 NAS 的效率。但同期，基于梯度优化的 DARTS 方法更为高效，成为当下 NAS 方法主流的选择。

DARTS 由卡耐基梅隆大学（CMU）的研究者刘寒骁等人提出，全称为可微分的神经网络架构搜索（Differentiable Architecture Search，DARTS）[5]，大幅提高了

搜索效率，受到了业界的广泛认可。可微分方法（DARTS）基于梯度优化，它首先其定义了一个基于有向无环图（DAG）的子结构（Cell），DAG 有四个中间节点（下图 Figure 1 中灰色方框），每条边有多个可选算子（由不同颜色的边表示），通过 softmax 加和不同边的结果作为到下个节点的输入。堆叠这样的子结构可以形成网络的主干。DARTS 将搜索过程看作对堆叠而成的主干网络（也称为超网，或过参数化网络）的优化过程。这里每条边被赋予了不同的结构权重，并和网络权重一起交叉进行梯度更新。优化完成后结构权重大（由粗线条表示）的作为最终子网的算子，并将该子网作为搜索结果（Figure 1d 展示了最终的 Cell 结构）。这个过程（ Figure 1 从 c 到 d）将连续的结构权重硬性截断为离散值，比如 0.2 变为 1，0.02 变为 0，而这样会产生所谓的离散化偏差（Discretization Gap）。

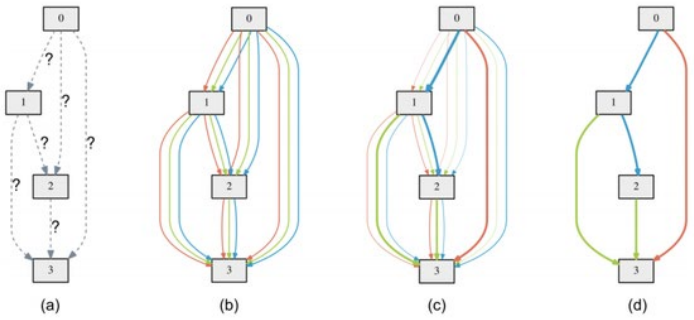

Figure 1: An overview of DARTS: (a) Operations on the edges are initially unknown. (b) Continuous relaxation of the search space by placing a mixture of candidate operations on each edge. (c) Joint optimization of the mixing probabilities and the network weights by solving a bilevel optimization problem. (d) Inducing the final architecture from the learned mixing probabilities.

神经网络架构搜索的难点

简单总结目前神经网络架构搜索主要需要解决的难点在于：

- 搜索过程的**高效性**：搜索算法耗费的计算资源和时间要在可接受的范围，从而可以在实践中得到广泛的应用，直接支撑面向业务数据集的模型结构搜索；
- 搜索结果的**有效性**：搜索得到的模型要在多个数据集上有很好的性能，且又很好的泛化性能和领域迁移能力，比如搜索得到的分类主干网可以很好地迁移到

检测和分割任务，并且有很好的表现；

- 搜索结果的**鲁棒性**：在具有有效性的同时，多次搜索的结果要相对稳定，即提高搜索的可靠性，降低试错成本。

可微分方法的缺点和改进方法

可微分神经网络架构搜索方法的不足之处就是鲁棒性较差，容易产生性能崩塌，即搜索过程中的超网性能表现很好但推断出的子网存在大量的跳跃连接（Skip Connection），严重削弱了最终模型的性能。基于 DARTS 涌现出了非常多的改进工作，比如 Progessive DARTS[6]，Fair DARTS[7]，RobustDARTS[8]，Smooth DARTS[9] 等。其中，ICLR 2020 满分论文 RobustDARTS 提出用 Hessian 特征根作为衡量 DARTS 出现性能崩塌的征兆，但计算特征根又非常耗时。而且在标准的 DARTS 搜索空间下，RobustDARTS 在 CIFAR-10 数据集上的搜索得到的模型性能并不突出。这促使我们思考怎么提高鲁棒性，同时又提高有效性。针对这两个问题，业内有不同的分析和解决方法，代表性的分别是 Fair DARTS（ECCV 2020）、RobustDARTS（ICLR 2020）和 Smooth DARTS（ICML 2020）。

Fair DARTS 观察到大量跳跃连接的存在，并着重分析了其可能的产生原因。文章认为，跳跃连接在可微分的优化过程中，存在竞争环境下的不公平优势（Unfair Advantage），导致跳跃连接容易在竞争中胜出。因此，FairDARTS 提出放宽竞争环境（Softmax 加和）为合作环境（Sigmoid 加和），使得不公平优势带来的影响失效。最终选取算子方式也与 DARTS 不同，通过采取阈值截断，比如选取结构权重高于 0.8 的算子，此时跳跃连接可以和其他算子同时出现，但这样等同于增大了搜索空间：原先的子网中，两个节点之间最终只选取一个。

RobustDARTS（简称 R-DARTS）通过计算 Hessian 特征根来判断优化过程是否出现崩塌，文章认为，损失函数地貌（Loss Landscape）存在尖锐的局部最优点（Sharp Local Minima，Figure 5a 右侧点），离散化过程（α^* 到 α^{disc}）会导致从优化较好的尖锐点偏移到优化较差的地方，从而导致最终模型性能下降。R-DARTS 发现这个过程和 Hessian 特征根关系密切（Figure 5b）。因此可认为，Hessian 特

征根变化幅度过大时优化应该停止，或者通过正则化手段来避免 Hessian 特征根产生大幅变化。

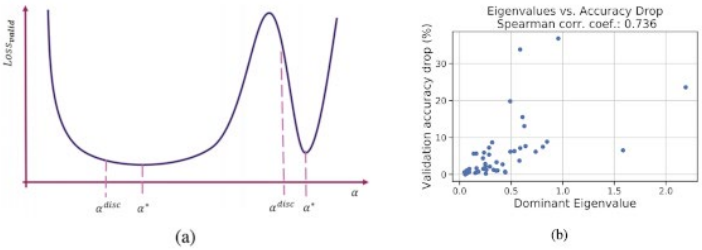

Figure 5: (a) Hypothetical illustration of the loss function change in the case of flat vs. sharp minima. (b) Drop in accuracy after discretizing the search model vs. the sharpness of minima (by means of λ^{α}_{max}).

Smooth DARTS（简作 SDARTS）遵循了 R-DARTS 的判断依据，采取基于扰动的正则化方法，对 Hessian 特征根进行了隐式的约束。具体来讲，SDARTS 对结构权重给予了一定程度的随机扰动，使得超网具有更好的抗干扰性，同时对损失函数地貌有平滑作用。

DARTS- 跳跃连接的工作机制分析

我们首先从跳跃连接的工作机制进行分析性能崩塌现象。ResNet [11] 中引入了跳跃连接，从而使得反向传播时，网络的浅层总包含对深层的梯度，因此可以缓解梯度消失的现象。如下式（i，j，k 表示层数，X 为输入，W 为权重，f 为计算单元）。

$$\frac{\partial \mathcal{L}}{\partial W_i} = \frac{\partial \mathcal{L}}{\partial X_{i+j}} \cdot \prod_{k=1}^{j} \left(\frac{\partial f_{i+k}}{\partial X_{i+k-1}} + \mathbb{1} \right) \cdot \frac{\partial f_i}{\partial W_i} \tag{2}$$

为了理清跳跃连接对残差网络性能的影响，我们在 ResNet 上做了一组验证性试验，即对跳跃连接加上可学习的结构权重参数 β，此时我们的梯度计算则变为下式：

$$\frac{\partial \mathcal{L}}{\partial X_i} = \frac{\partial \mathcal{L}}{\partial X_{i+1}} \cdot \left(\frac{\partial f_{i+1}}{\partial X_i} + \beta \right) \tag{3}$$

三次实验分别初始化 β 为 {0, 0.5, 1.0}，我们发现 β 总能快速增长到 1 附近（Figure 2）来增大深层梯度向浅层的传递，进而缓解梯度消失的现象。

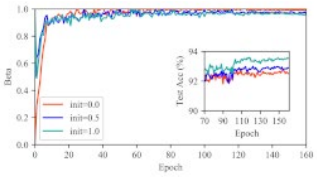

Figure 2: Tendency of trainable coefficient β (initialized with $\{0, 0.5, 1\}$) of the skip connection in ResNet50 and test accuracy (inset figure) vs. epochs. The residual structure is proved to learn a large β to ease training in all three cases. All models are trained and tested on CIFAR-10.

在 DARTS 中，跳跃连接跟 ResNet 类似，当具有可学习参数时，其结构参数也具有这种趋势，从而促进超网的训练。但正如 Fair DARTS [7] 提到的，同时带来的问题就是对其他算子来讲跳跃连接存在不公平优势。

解决崩塌的办法：增加辅助跳跃连接

根据上述的分析，DARTS− 指出跳跃连接（下图 Figure 1 中 Skip）存在双重作用：

- 作为可选算子本身，参与构建子网。
- 与其他算子形成残差结构，从而产生对超网优化产生促进作用。

第一个作用是预期其要发挥的作用，从而与其他算子公平竞争。第二个作用是跳跃连接具有不公平优势的原因，促进了优化，但干扰了我们对最终搜索结果的推断。

为了将第二个作用剥离出来，我们提出额外增加一条跳跃连接（Auxiliary Skip），并使其结构权重 β 从 1 衰减到 0（简便起见，使用线性衰减），这样可以使得超网和子网保持结构上的一致性。Figure 1（b）图示出了一个子结构中两个节点间的连接情况。

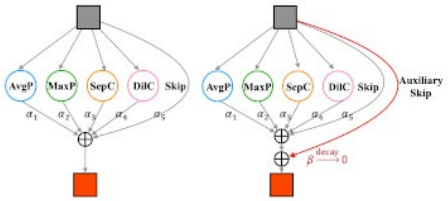

Figure 1: Schematic illustration about (a) DARTS and (b) the proposed DARTS-, featuring an auxiliary skip connection (thick red line) with a decay rate β between every two nodes to remove the potential unfair advantage that leads to performance collapse.

除了增加的辅助跳跃连接，DARTS− 优化过程和 DARTS 大同小异。首先根据 Figure 1（b）构建超网，选取一种 β 衰减策略，然后采取交替迭代优化超网权重 w 和结构权重 α，具体见下面的算法描述（Algorithm 1）。

Algorithm 1 DARTS-

Require:
Network weights w; Architecture parameters α;
Number of search epochs E;
Decay strategy for $\beta_e, e \in \{1, 2, ..., E\}$.

Ensure:
Searched architecture parameters α.

1: Construct a super-network by stacking cells in which there is an auxiliary skip connection between every two nodes of choice
2: **for** each $e \in [1, E]$ **do**
3: Update weights w by $\nabla_w \mathcal{L}_{train}(w, \alpha, \beta_e)$
4: Update parameters α by $\nabla_\alpha \mathcal{L}_{val}(w, \alpha, \beta_e)$
5: **end for**
6: Derive the final architecture based on learned α from the best validation supernet.

在本方法中，我们去掉了用指示信号（Indicator）发现性能崩塌的做法，比如 R-DARTS 中的特征根，从而消除了 DARTS 的性能崩塌，因此命名为 DARTS−。另外根据 PR-DARTS [12] 的收敛理论来分析，辅助跳跃连接具有平衡算子间竞争的作用，且当 β 衰减后，算子间的公平竞争依然保持。

分析和验证

Hessian 特征根变化趋势

在 R-DARTS 以及 DARTS 采用的多个搜索空间下，DARTS- 发现了子网性能增长（Figure 4b）但 Hessian 特征根变化幅度过大（Figure 4a）的情形，这个结果成为了 R-DARTS 所提出原则的反例，即采用 R-DARTS 判定准则，我们会漏掉一些好的模型。这也说明了 DARTS- 可以带来不同于 R-DARTS 的模型结构。

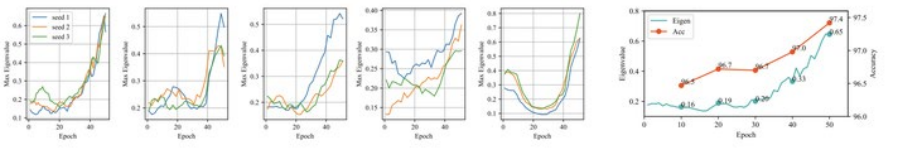

(a) Trajectory of eigenvalues in S0-S4 (left to right) on CIFAR-10 (b) Sampled models' performance

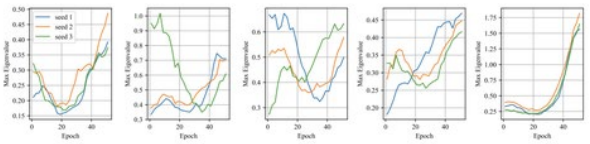

(c) Trajectory of eigenvalues in S0-S4 (left to right) on CIFAR-100

Figure 4: The evolution of maximal eigenvalues of DARTS- when searching in different search spaces S0-S4 on CIFAR-10 (a) and CIFAR-100 (c). We run each experiment 3 times on different seeds. (b) DARTS-'s growing Hessian eigenvalues don't induce poor performance. Among the sampled five models, the one corresponding to the highest eigenvalue has the best performance. This example is done in S0 on CIFAR-10.

验证集准确率地貌

验证集准确率的地貌可以一定程度上说明模型的优化过程难易。DARTS（Figure 3a）在最优解附近范围的地貌相对陡峭，等高线比较疏密不均，而 DARTS- 则表现得舒缓平滑，等高线更为均匀。另外更为光滑的地貌也不容易出现尖锐的局部最优点，一定程度也减少了离散化偏差。

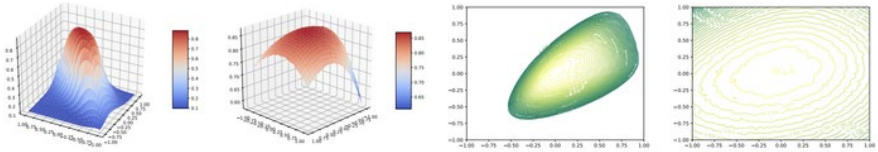

(a) DARTS (b) DARTS- (c) DARTS (d) DARTS-

Figure 3: Comparison of the validation accuracy landscape of (a) DARTS and (b) DARTS- w.r.t. α on CIFAR-10 in S3. Their contour maps are shown respectively in (c) and (d), where we set the step of contour map as 0.1. The accuracy of the derived models are 94.84% (a,c) and 97.58% (b,d), while the maximum Hessian eigenvalues are similarly high (0.52 and 0.42)

实验结果

模型结构

Figure 9 给出了我们在 DARTS 搜索空间 S0 和 Robust DARTS 搜索空间 S1–S4 得到的网络结构。Figure 10 是在 MobileNetV2 的搜索空间下 ImageNet 数据集上进行直接搜索的结果。

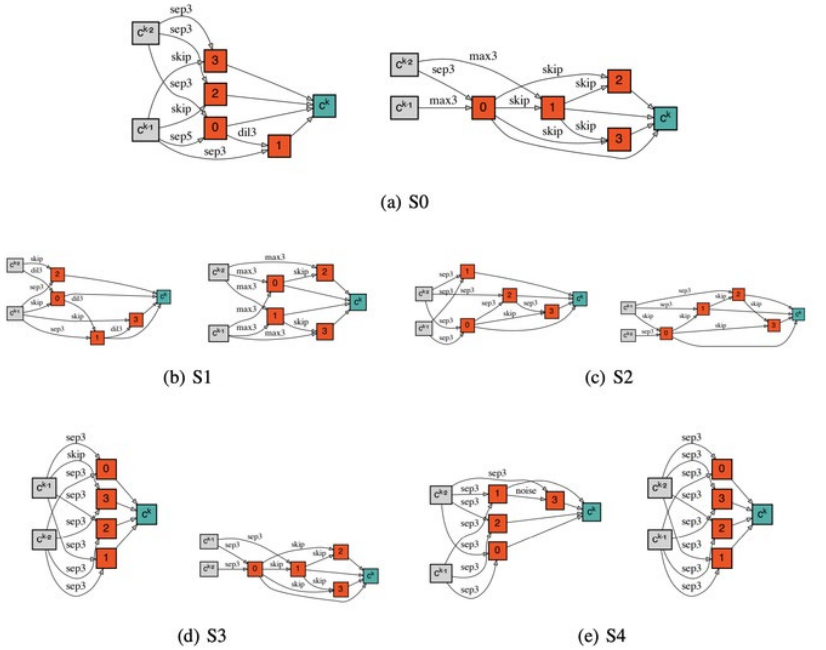

(a) S0

(b) S1 (c) S2

(d) S3 (e) S4

Figure 9: The best found normal cell and reduction cell in search spaces S0-S4 on CIFAR-10 dataset.

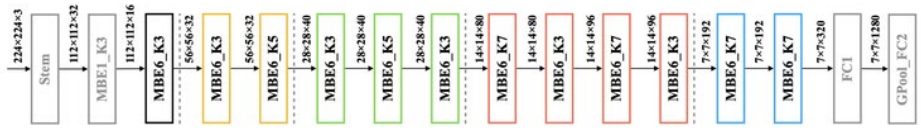

Figure 10: Architecture of DARTS-A searched on ImageNet dataset.

分类任务结果

在标准分类数据集 CIFAR-10 和 ImageNet 上 DARTS- 均取得了业界领先的结果，如下表所示：

Table 2: Comparison of the state-of-the-art models on CIFAR-10 (left) and ImageNet (right). On CIFAR-10 dataset, our average result is obtained on 5 independently searched models to assure the robustness. For ImageNet, networks in the top block are directly searched on ImageNet; the middle indicates that architectures are searched on CIFAR-10 and then transferred to ImageNet; the bottom indicates models have SE and Swish. We search in S0 for CIFAR-10 and S5 for ImageNet.

Models	Params (M)	FLOPs (M)	Acc (%)	Cost GPU Days
NASNet-A (2018)	3.3	608†	97.35	2000
ENAS (2018)	4.6	626†	97.11	0.5
DARTS (2019b)	3.3	528†	97.00±0.14*	0.4
SNAS (2019)	2.8	422†	97.15±0.02*	1.5
GDAS (2019b)	3.4	519†	97.07	0.2
P-DARTS (2019b)	3.4	532†	97.5	0.3
PC-DARTS (2020)	3.6	558†	97.43	0.1
DARTS- (best)	3.5	568	97.5	0.4
P-DARTS (2019b)‡	3.3±0.21	540±34	97.19±0.14	0.3
R-DARTS (2020)	-	-	97.05±0.21	1.6
SDARTS-ADV (2020)	3.3	-	97.39±0.02	1.3
DARTS- (avg.)	3.5±0.13	583±22	97.41±0.08	0.4

† Based on the provided genotypes.
‡ 5 independent searches using their released code.
* Training the best searched model for several times (*whose average doesn't indicate the stability of the method*)

Models	FLOPs (M)	Params (M)	Top-1 (%)	Top-5 (%)	Cost (GPU days)
AmoebaNet-A (2019)	555	5.1	74.5	92.0	3150
MnasNet-92 (2019)	388	3.9	74.79	92.1	3791‡
FBNet-C (2019)	375	5.5	74.9	92.3	9
FairNAS-A (2019b)	388	4.6	75.3	92.4	12
SCARLET-C (2019a)	365	6.7	76.9	93.4	10
FairDARTS-D (2020b)	440	4.3	75.6	92.6	3
PC-DARTS (2020)	597	5.3	75.8	92.7	3.8
DARTS- (ours)	467	4.9	76.2	93.0	4.5
NASNet-A (2018)	564	5.3	74.0	91.6	2000
DARTS (2019b)	574	4.7	73.3	91.3	0.4
SNAS (2019)	522	4.3	72.7	90.8	1.5
PC-DARTS (2020)	586	5.3	74.9	92.2	0.1
FairDARTS-B (2020b)	541	4.8	75.1	92.5	0.4
MobileNetV3 (2019)	219	5.4	75.2	92.2	≈3000
MoGA-A (2020a)	304	5.1	75.9	92.8	12
MixNet-M (2019)	360	5.0	77.0	93.3	≈3000
EfficientNet B0 (2019)	390	5.3	76.3	93.2	≈3000
NoisyDARTS-A◇	449	5.5	77.9	94.0	12
DARTS- (ours)◇	470	5.5	77.8	93.9	4.5

‡ Estimated by Wu et al. (2019).
◇ SE modules and Swish enabled.

在 RobustDARTS 提出的检验鲁棒性的多个搜索空间 S1–S4 中，DARTS- 搜索得到的模型性能优于 R-DARTS 和 SDARTS。

Table 7: Comparison in various search spaces. We report the **lowest error rate** of 3 found architectures. †: under Chen & Hsieh (2020)'s training settings where all models have 20 layers and 36 initial channels (the best is shown in boldface). ‡: under Zela et al. (2020)'s settings where CIFAR-100 models have 8 layers and 16 initial channels (The best is in boldface and underlined).

Benchmark		DARTS‡	R-DARTS‡		DARTS‡		Ours‡	PC-DARTS†	SDARTS†		Ours†
			DP	L2	ES	ADA			RS	ADV	
C10	S1	3.84	3.11	2.78	3.01	3.10	**2.68**	3.11	2.78	2.73	**2.68**
	S2	4.85	3.48	3.31	3.26	3.35	**2.63**	3.02	2.75	2.65	**2.63**
	S3	3.34	2.93	2.51	2.74	2.59	**2.42**	2.51	2.53	2.49	**2.42**
	S4	7.20	3.58	3.56	3.71	4.84	**2.86**	3.02	2.93	2.87	**2.86**
C100	S1	29.46	25.93	24.25	28.37	24.03	**22.41**	18.87	17.02	**16.88**	16.92
	S2	26.05	22.30	22.24	23.25	23.52	**21.61**	18.23	17.56	17.24	**16.14**
	S3	28.90	22.36	23.99	23.73	23.37	**21.13**	18.05	17.73	17.12	**15.86**
	S4	22.85	22.18	21.94	**21.26**	23.20	21.55	17.16	17.17	**15.46**	17.48

NAS 算法评测

NAS-Bench-201[10] 是用于衡量 NAS 算法的评测基准工具之一，DARTS- 也取得了优于其他 NAS 算法的结果，而且最好结果基本逼近了基准中最好的模型。

Table 3: Searching performance on NAS-Bench-201 (Dong & Yang, 2020). Our method robustly obtains new SOTA. Averaged on 4 runs of searching. ^{1st}: first-order, ^{2nd}: second-order

Method	Cost (hours)	CIFAR-10 valid	CIFAR-10 test	CIFAR-100 valid	CIFAR-100 test	ImageNet16-120 valid	ImageNet16-120 test
DARTS^{1st} (2019b)	3.2	39.77±0.00	54.30±0.00	15.03±0.00	15.61±0.00	16.43±0.00	16.32±0.00
DARTS^{2nd} (2019b)	10.2	39.77±0.00	54.30±0.00	15.03±0.00	15.61±0.00	16.43±0.00	16.32±0.00
GDAS (2019b)	8.7	89.89±0.08	93.61±0.09	71.34±0.04	70.70±0.30	41.59±1.33	41.71±0.98
SETN (2019a)	9.5	84.04±0.28	87.64±0.00	58.86±0.06	59.05±0.24	33.06±0.02	32.52±0.21
DARTS-	3.2	**91.03±0.44**	**93.80±0.40**	**71.36±1.51**	**71.53±1.51**	**44.87±1.46**	**45.12±0.82**
DARTS- (best)	3.2	91.55	94.36	73.49	73.51	46.37	46.34
optimal	n/a	91.61	94.37	73.49	73.51	46.77	47.31

迁移能力

DARTS-A 作为主干网在 COCO 数据集目标检测任务上也优于之前 NAS 模型的性能，mAP 达到了 32.5%。

Table 11: Transfer results on COCO datasets of various drop-in backbones.

Backbones	Params (M)	Acc	AP	AP_{50}	AP_{75}	AP_S	AP_M	AP_L
MobileNetV2 (2018)	3.4	72.0	28.3	46.7	29.3	14.8	30.7	38.1
SingPath NAS (2019)	4.3	75.0	30.7	49.8	32.2	15.4	33.9	41.6
MnasNet-A2 (2019)	4.8	75.6	30.5	50.2	32.0	16.6	34.1	41.1
MobileNetV3 (2019)	5.4	75.2	29.9	49.3	30.8	14.9	33.3	41.1
MixNet-M (2019)	5.0	77.0	31.3	51.7	32.4	17.0	35.0	41.9
FairDARTS-C (2020b)	5.3	77.2	31.9	51.9	33.0	17.4	35.3	43.0
DARTS-A (Ours)	5.5	77.8	32.5	52.8	34.1	18.0	36.1	43.4

综合来看，DARTS− 方法继承了 DARTS 的高效率，且在标准数据集、NAS 基准评测、R−DARTS 搜索空间中证明了其鲁棒性和有效性，在检测任务中也证明了其领域迁移的能力，从而印证了搜索方法本身的优越性，解决了当前神经网络架构搜索中的一些难题，将会对 NAS 研究和应用产生积极的推动作用。

总结及展望

本次美团在 ICLR 2021 被收录的文章 DARTS−，重新了梳理 DARTS 搜索结果不够鲁棒的原因，分析了跳跃连接的双重作用，并提出了增加带衰减系数的辅助跳跃连接来对其进行分离的方法，使得内层原生的跳跃连接只表现其作为可选操作的功能。我们同时对 R−DARTS 所依赖的特征根进行深入分析，发现了其作为性能崩塌标志会出现反例的情形。未来 DARTS− 作为高效、鲁棒且通用的搜索方法，期望在其他领域任务和落地中得到更多的拓展和应用。关于文章的更多细节，请参考原文。实验代码已经在 GitHub 上开源。

AutoML 技术可以适用于计算机视觉、语音、NLP、搜索推荐等领域，视觉智能中心 AutoML 算法团队旨在通过 AutoML 技术赋能公司业务、加速算法落地。目前该论文已经申请了专利，本文算法也集成到美团自动化视觉平台系统中，加速自动化模型生产和迭代。除了视觉场景外，我们后续将探索在搜索推荐、无人车、优选、语音等业务场景中的应用。

作者简介

祥祥、晓星、张勃、晓林等，均来自美团视觉智能中心。

参考文献

[1] Learning Transferable Architectures for Scalable Image Recognition, https://arxiv.org/abs/1707.07012.

[2] NAS-FPN: Learning scalable feature pyramid architecture for object detection, https://arxiv.org/abs/1904.07392.

[3] Auto-deeplab: Hierarchical neural architecture search for semantic image segmentation, https://arxiv.org/abs/1901.02985.

[4] DARTS-: Robustly Stepping out of Performance Collapse Without Indicators, https://openreview.net/forum?id=KLH36ELmwIB.

[5] DARTS: Differentiable Architecture Search, https://arxiv.org/pdf/1806.09055.pdf.

[6] Progressive Differentiable Architecture Search: Bridging the Depth Gap between Search and Evaluation, https://arxiv.org/pdf/1904.12760.

[7] Fair DARTS: Eliminating Unfair Advantages in Differentiable Architecture Search, https://arxiv.org/pdf/1911.12126.pdf.

[8] Understanding and Robustifying Differentiable Architecture Search, https://openreview.net/pdf?id=H1gDNyrKDS.

[9] Stabilizing Differentiable Architecture Search via Perturbation-based Regularization, https://arxiv.org/abs/2002.05283.

[10] NAS-Bench-201: Extending the Scope of Reproducible Neural Architecture Search , https://openreview.net/forum?id=HJxyZkBKDr.

[11] Deep Residual Learning for Image Recognition, https://arxiv.org/abs/1512.03385.

[12] Theory-inspired path-regularized differential network architecture search, https://arxiv.org/abs/2006.16537.

SIGIR 2021 | 广告系统位置偏差的 CTR 模型优化方案

作者：坚强、胡可、庆涛、明健、漆毅、程佳、雷军

近些年来，由于人工智能技术的高速发展，所带来的公平性问题也愈发受到关注。同样的，广告技术也存在着许多公平性问题，由于公平性问题造成的偏差对广告系统的生态会产生较大的负面影响。图 1 所示的是广告系统中的反馈环路 [1]，广告系统通过累积的用户交互反馈数据基于一定的假设去训练模型，模型对广告进行预估排序展示给用户，用户基于可看到的广告进行交互进而累积到数据中。在该环路中，位置偏差、流行度偏差等各种不同类型的偏差会在各环节中不断累积，最终导致广告系统的生态不断恶化，形成“强者愈强、弱者愈弱”的马太效应。

由于偏差对广告系统和推荐系统的生态有着极大的影响，针对消除偏差的研究工作也在不断增加。比如国际信息检索会议 SIGIR 在 2018 年和 2020 年组织了一些关注于消除偏差主题的专门会议，同时也给一些基于偏差和公平性的论文颁发了最佳论文奖（Best Paper）[2,3]。KDD Cup 2020 的其中一个赛道也基于电子商务推荐中的流行度偏差进行开展 [1]。

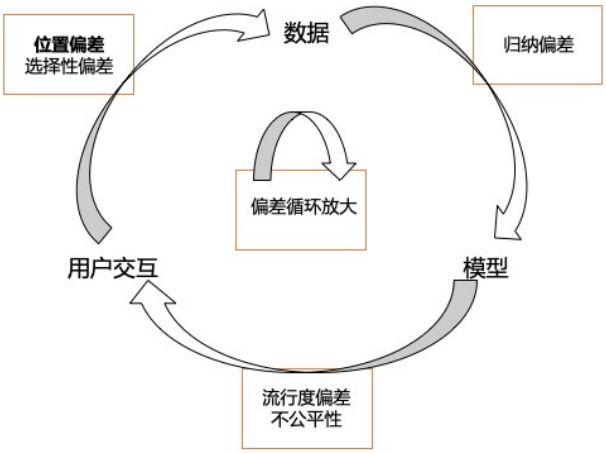

图 1　广告系统中的反馈环路，各种偏差被不断循环累积

美团到店广告平台算法团队基于多年来在广告领域上积累的经验，一直在数据偏差等业界挑战性问题不断进行深入优化与算法创新。在之前分享的《KDD Cup 2020 Debiasing 比赛冠军技术方案与广告业务应用》一文[4]中，团队分享了在 KDD Cup 比赛中取得冠军的选择性偏差以及流行度偏差的解决方案，同时也分享了在广告业务上偏差优化的技术框架。

本文基于这一技术框架进行继续介绍，聚焦于位置偏差问题的最新进展，并详细地介绍团队在美团广告取得显著业务效果的位置偏差 CTR 模型优化方案，以该方案为基础形成的论文《Deep Position-wise Interaction Network for CTR Prediction》也被国际顶级会议 SIGIR 2021 录用。

1. 背景

美团到店广告平台算法团队基于美团和点评双侧的广告业务场景，不断进行广告前沿技术的深入优化与算法创新。在大多数广告业务场景下，广告系统被分为四个模块，分别是触发策略、创意优选、质量预估以及机制设计，这些模块构成一个广告投放漏斗从海量广告中过滤以及精选出优质广告投放给目标用户。其中，触发策略从海量广告中挑选出满足用户意图的候选广告集合，创意优选负责候选广告的图片和文本生成，质量预估结合创意优选的结果对每一个候选广告进行质量预估，包括点击率（CTR）预估、转化率（CVR）预估等，机制排序结合广告质量以及广告出价进行优化排序。在本文中，我们也将广告称之为 item。

CTR 预估，作为质量预估的一个环节，是计算广告中最核心的算法之一。在每次点击付费（CPC）计费模式下，机制设计可以简单地按每千次展示收入（eCPM）来对广告进行排序以取得广告收入最大化。由于 eCPM 正比于 CTR 和广告出价（bid）的乘积。因此，CTR 预估会直接影响到广告的最终收入和用户体验。为了有更高的 CTR 预估精度，CTR 预估从早期的 LR[5]、FM[6]、FFM[7] 等支持大规模稀疏特征的模型，到 XGBoost[8]、LightGBM[9] 等树模型的结合，再到 Wide&Deep[10]、Deep&Cross[11]、DeepFM[12]、xDeepFM[13] 等支持高阶特征交叉的深度学习模型，

进一步演化到 DIN[14]、DIEN[15]、DSIN[16] 等结合用户行为序列的深度学习模型，一直作为工业界以及学术界研究的热点领域之一，被不断探索和不断创新。

由于 CTR 预估模型的训练通常采用曝光点击数据，该数据是一种隐式反馈数据，所以会不可避免地产生各种偏差问题。其中，位置偏差因对 CTR 影响极大而备受关注。如图 2 所示，随机流量上不同位置的 CTR 分布反应了用户通常倾向于点击靠前位置的广告，并且 CTR 会随着曝光位置的增大而迅速下降。因此，直接在曝光点击数据上进行训练，模型不可避免地会偏向于靠前位置的广告集合，造成位置偏差问题。图 2 显示正常流量相比随机流量 CTR 分布更加集中在高位置广告上，通过反馈环路，这一问题将不断地放大，并且进一步损害模型的性能。因此，解决好位置偏差问题不仅能够提升广告系统的效果，而且还能平衡广告系统的生态，促进系统的公平性。

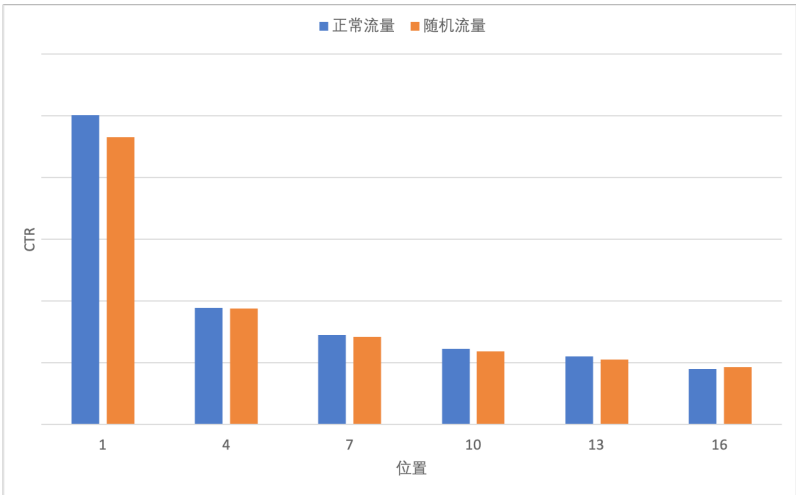

图 2　美团广告正常流量和随机流量在不同位置上的 CTR 分布

广告最终的真实曝光位置信息在线上预估时是未知的，这无疑进一步增大了位置偏差问题的解决难度。现有的解决位置偏差的方法可以大致分为以下两种：

- **神经网络位置特征建模**：该方法将位置建模为神经网络中的特征，由于在预估过程中并不知道真实位置信息，故而有些方法 [17-19] 把位置信息放于网络的 Wide 部分，在线下训练时使用真实位置，在线上预估时使用固定位置，这种

方法由于其简单性和有效性，在工业界被广泛应用。为了在线上预估时无需使用位置信息，如图 3 所示，PAL[20] 将样本的 CTR 建模为 ProbSeen 乘以 pCTR，其中 ProbSeen 仅使用位置特征建模，而 pCTR 使用其他信息建模，在线上只使用 pCTR 作为 CTR 预估值。

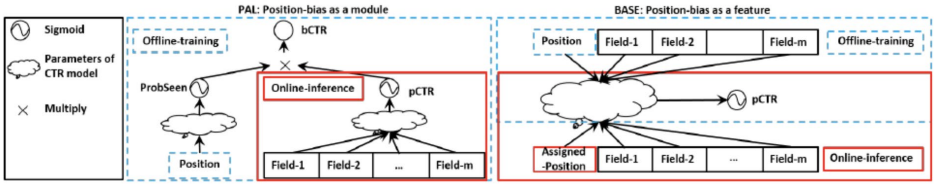

图 3　PAL 框架

- **Inverse Propensity Weighting（IPW）**：该方法被学术界广泛研究 [21–29]，其在模型训练时给不同曝光位置的样本赋予不同的样本权重，直观地看，应该将具有较低接收反馈倾向的广告样本（曝光位置靠后的广告）分配较高的权重。因此，这种方法的难点就在于不同位置的样本权重如何确定，一个简单的方法是使用广告随机展示的流量来准确地计算位置 CTR 偏差，但不可避免地损害用户体验。故而，许多方法致力于在有偏的流量上来准确地预估位置偏差。

上述的方法通常基于一个较强的假设，即点击伯努利变量 C 依赖于两个潜在的伯努利变量 E 和 R，如下式所示：

$$p(C = 1|u, c, i, k) = p(E = 1|k, [s])p(R = 1|u, c, i), \qquad (1)$$

其中，等式左边指的是用户 u 在上下文 c 中点击第 k 个广告 i 的概率，我们定义上下文 c 为实时的请求信息。等式右边第一项指的是位置 k 被查看的概率，其中 $[s]$ 通常为上下文 c 的一个子集，大部分方法假设 $[s]$ 为空集，即位置 k 被查看的概率仅与 k 有关。等式右边第二项指的是相关性概率（例如用户 u 在上下文 c 中对广告 i 的的真实兴趣）。上述方法通常显式或隐式地估计查看概率，然后利用反事实推理（Counterfactual Inference）得出相关性概率，最终在线上将相关性概率作为 CTR 的预估值。训练和预估之间位置信息的不同处理将不可避免地导致线下线上间的不一致问题，进一步导

致次优的模型性能。

此外，已有方法通常假设查看概率仅依赖于位置及部分上下文信息，其假设过于简单。不同的用户通常具有不同的浏览习惯，有些用户可能倾向于浏览更多 item，而有些用户通常能快速做出决定，并且同一个用户在不同的上下文中搜索意图中也会有不同的位置偏好，例如商场等地点词的搜索往往意图不明确导致高低位置的 CTR 差异并不大。故而，位置偏差与用户，上下文有关，甚至可能与广告本身也有关，建模它们间的关系能更好地解决位置偏差问题。

不同于上述的方法，本文提出了一个基于深度位置交叉网络（Deep Position-wise Interaction Network）（DPIN）模型的多位置预估方法去有效地直接建模 $CTR_k^j = p(C=1|u,c,i,k)$ 来提高模型性能，其中 CTR_k^j 是第 j 个广告在第 k 个位置的 CTR 预估值。该模型有效地组合了所有候选广告和位置，以预估每个广告在每个位置的 CTR，实现线下线上的一致性，并在在线服务性能限制的情况下支持位置、用户、上下文和广告之间的深度非线性交叉。广告的最终序可以通过最大化 $\sum CTR_k^j bid^j$ 来确定，其中 bid^j 为广告的出价，本文在线上机制采用一个位置自顶向下的贪婪算法去得到广告的最终序。本文的贡献如下：

- 本文在 DPIN 中使用具有非线性交叉的浅层位置组合模块，该模块可以并行地预估候选广告和位置组合的 CTR，达到线下线上的一致性，并大大改善了模型性能。
- 不同于以往只对候选广告进行用户兴趣建模，本次首次提出对候选位置也进行用户兴趣建模。DPIN 应用一个深度位置交叉模块有效地学习位置，用户兴趣和上下文之间的深度非线性交叉表示。
- 根据对于位置的新处理方式，本文提出了一种新的评估指标 PAUC（Position-wise AUC），用于测量模型在解决位置偏差问题上的模型性能。本文在美团广告的真实数据集上进行了充分的实验，验证了 DPIN 在模型性能和服务性能上都能取得很好的效果。同时本文还在线上部署了 A/B Test，验证了 DPIN 与高度优化的已有基线相比有显著提升。

2. 深度位置交叉网络（Deep Position-wise Interaction Network

本节主要介绍深度位置交叉网络（Deep Position-wise Interaction Network）（DPIN）模型。如图 4 所示，DPIN 模型由三个模块组成，分别是处理 J 个候选广告的基础模块（Base Module），处理 K 个候选位置的深度位置交叉模块（Deep Position-wise Interaction Module）以及组合 J 个广告和 K 个位置的位置组合模块（Position-wise Combination Module），不同模块需预估的样本数量不一样，复杂模块预估的样本数量少，简单模块预估的样本数量多，由此来提高模型性能和保障服务性能。通过这三个模块的组合，DPIN 模型有能力在服务性能的限制下预估每个广告在每个位置上的 CTR，并学习位置信息和其他信息的深度非线性交叉表示。下文将会详细地介绍这三个模块。

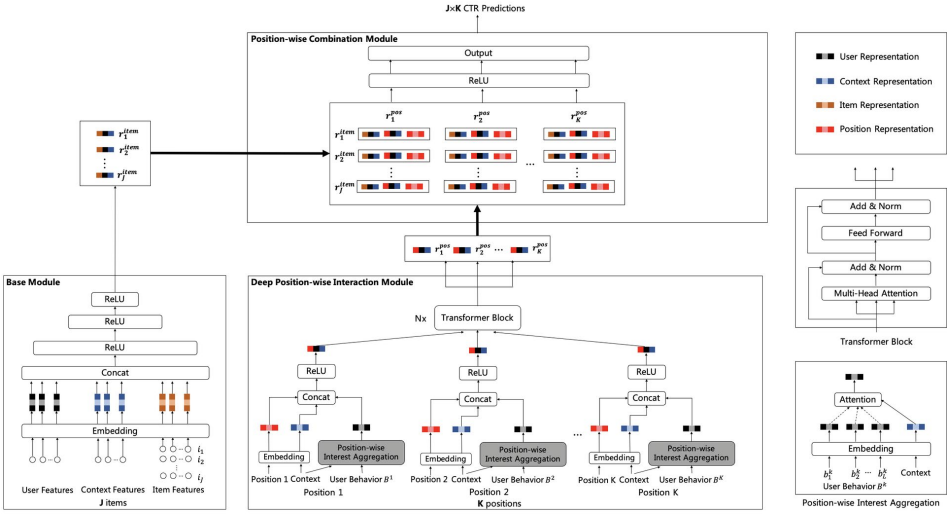

图 4　Deep Position-wise Interaction Network 模型结构

2.1 基础模块（Base Module）

与大多数深度学习 CTR 模型 [10-16] 类似，本文采用 Embedding 和 MLP（多层感知机）的结构作为基础模块。 对于一个特定请求请求，基础模块将用户、上下文和 J 个候选广告作为输入，将每个特征通过 Embedding 进行表示，拼接 Embedding 表示

输入多层 MLP，采用 ReLU 作为激活函数，最终可以得到每个广告在该请求下的表示。第 j 个广告的表示 r_j^{item} 可以通过如下公式得到：

$$\mathbf{u} = Concat(E(u_1), ..., E(u_m)), \quad (2)$$

$$\mathbf{c} = Concat(E(c_1), ..., E(c_n)), \quad (3)$$

$$\mathbf{i_j} = Concat(E(i_1^j), ..., E(i_o^j)), \quad (4)$$

$$\mathbf{r_j^{item}} = MLP(Concat(\mathbf{u}, \mathbf{c}, \mathbf{i_j})), \quad (5)$$

其中 $u_1,\cdots,u_m$， $c_1,\cdots,c_m$， $i_1^j,\cdots,i_o^j$ 分别是当前用户特征集合、当前上下文特征集合以及第 j 个广告的特征集合， $E(\cdot)\in\mathbb{R}$ 是 Embedding 映射。

2.2 深度位置交叉模块（Deep Position-wise Interaction Module）

在大多数业务场景中，基础模块通常已经被高度优化，包含了大量特征甚至用户序列等信息，其目的是捕捉用户在该上下文中对不同广告的兴趣。因此，基础模块的推理时间复杂度通常较大，直接在基础模块中加入位置特征对所有广告在所有位置上进行 CTR 预估是不可接受的。因此，本文提出了一个与基础模块并行的深度位置交叉模块，不同于针对广告进行兴趣建模的基础模块，该模块针对于位置进行兴趣建模，学习每个位置与上下文及用户兴趣的深度非线性交叉表示。

在深度位置交叉模块中，我们提取用户在每个位置的行为序列，将其用于各位置上的用户兴趣聚合，这样可以消除整个用户行为序列上的位置偏差。接着，我们采用一层非线性全连接层来学习位置、上下文与用户兴趣非线性交叉表示。最后，为了聚合用户在不同位置上的序列信息来保证信息不被丢失，我们采用了 Transformer[30] 来使得不同位置上的行为序列表示可以进行交互。

位置兴趣聚合（Position-wise Interest Aggregation）。我们令 $B_k = b_1^k, b_2^k, \cdots, b_L^k$ 为用户在第 k 个位置的历史行为序列，其中 $b_l^k = [v_l^k, c_l^k]$ 为用户在第 k 个位置上的历史第 l 个行为记录， v_l 为点击的 item 特征集合， c_l^k 为发生该行为时的上下文（包括搜索关键词、请求地理位置、一周中的第几天、一天中的第几个小时等），行为记录的 Embedding

表示 $\mathbf{b_l^k}$ 可以通过下式得到：

$$\mathbf{b_l^k} = Concat(E(v_1^{k_l}), ..., E(v_o^{k_l}), E(c_1^{k_l}), ..., E(c_n^{k_l}), E(dif^{k_l})), \quad (6)$$

其中 $v_1^{k_l}, v_o^{k_l}$， $c_1^{k_l}, c_n^{k_l}$ 分别为 v_l^k 和 c_l^k 的特征集合， dif^{kl} 为该行为与当前上下文的时间差。

第 k 个位置行为序列的聚合表示 $\mathbf{b_k}$ 可以通过注意力机制获取，如以下公式所示：

$$a_l^k = Concat(\mathbf{b_l^k}, \mathbf{c})\mathbf{W_a} + b_a, \quad (7)$$

$$\mathbf{b_k} = \sum_{l=1}^{L} \frac{\exp(a_l^k)}{\sum_{i=1}^{L} \exp(a_i^k)} \mathbf{b_l^k}, \quad (8)$$

其引入当前上下文 $\mathbf{c}$ 去计算注意力权重，对于与上下文越相关的行为可以给予越多的权重。

位置非线性交叉（Position-wise Non-linear Interaction）：我们采用一层非线性全连接层来学习位置、上下文与用户兴趣非线性交叉表示，如下式所示：

$$\mathbf{v_k} = ReLU(Concat(E(k), \mathbf{c}, \mathbf{b_k})\mathbf{W_v} + \mathbf{b_v}), \quad (9)$$

其中， $\mathbf{W_v}, \mathbf{bv}$, 将拼接的向量映射到 $dmodel$ 维度。

Transformer Block：如果将 V_k 直接作为第 k 个位置的非线性交叉表示，那么会丢失用户在其他位置上的行为序列信息。因此，我们采用 Transformer 去学习不同位置兴趣的交互。令 $\mathbf{Q} = \mathbf{K} = \mathbf{V} = Concat(\mathbf{v_1}, \mathbf{v_2}, \cdots, \mathbf{v_K})$ 为 Transformer 的输入，Tranformer 的多头自注意力结构可以由以下公式表示：

$$MultiHead(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = Concat(\mathbf{head_1}, ..., \mathbf{head_h})\mathbf{W^O}, \quad (10)$$

$$\mathbf{head_i} = Attention(\mathbf{QW_i^Q}, \mathbf{KW_i^K}, \mathbf{VW_i^V}), \quad (11)$$

$$Attention(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = softmax(\frac{\mathbf{QK^T}}{\sqrt{d_k}})\mathbf{V}, \quad (12)$$

其中， $dk = dmodel / h$ 是每个头的维度。因为 $\mathbf{v_k}$ 中已经包含位置信息，故而我们不需要 Transformer 中的位置编码。同样的，我们也沿用 Transformer 中的前馈网络

（Position-wise Feed-forward Network）、残差连接（Residual Connections）以及层标准化（Layer Normalization）。N 个 Transformer Block 会被使用去加深网络。

最终，深度位置交叉模块会产出每个位置的深度非线性交叉表示，其中第 k 个位置被表示为 r_k^{pos} 。

2.3 位置组合模块（Position-wise Combination Module）

位置组合模块的目的是去组合 J 个广告和 K 个位置来预估每个广告在每个位置上的 CTR，我们采用一层非线性全连接层来学习广告、位置、上下文和用户的非线性表示，第 j 个广告在第 k 个位置上的 CTR 可以由如下公式得出：

$$CTR_k^j = \sigma(ReLU(Concat(\mathbf{r_j^{item}}, \mathbf{r_k^{pos}}, E(k))\mathbf{W_1}+\mathbf{b_1})\mathbf{W_2}+b_2), \quad (13)$$

其中包括了一层非线性连接层和一层输出层，是 $E(k)$ 位置 k 的 embedding 表示，$\sigma(\cdot)$ 是 sigmoid 函数。

整个模型可以使用真实位置通过批量梯度下降法进行训练学习，我们采用交叉熵作为我们的损失函数。

3. 实验

在本节中，我们评估 DPIN 的模型性能和服务性能，我们将详细描述实验设置和实验结果。

3.1 实验设置

数据集：我们使用美团搜索关键词广告数据集训练和评估我们的 CTR 模型。训练数据量达到数亿，测试数据量大约一千万。测试集被划分为两个部分，一部分是线上收集的常规流量日志，另一部分是线上 Top-k 随机的探索流量日志。Top-k 随机的探索流量日志是更适合用来评估位置偏差问题，因为它大大削弱了相关性推荐对位置偏差的影响。

评估指标：我们使用 AUC（Area Under ROC）作为我们的评估指标之一。为了更好的针对位置偏差问题进行评估，我们提出 PAUC（Position-wise AUC）作为我们的另一个评估指标，其由以下公式计算：

$$PAUC = \frac{\sum_{k=1}^{K} \#impression_k PAUC@k}{\sum_{k=1}^{K} \#impression_k}, \tag{14}$$

其中，$\#impression_k$ 是第 k 个位置的曝光数量，$PAUC@k$ 是第 k 个位置曝光数据的 AUC。PAUC 指标衡量每个位置上相关性排序的质量，忽略了位置偏差对排序质量的影响。

对比的方法。为了公平且充分地对比不同模型的效果，我们所有实验中所使用的模型输入使用等量且深度结合美团业务的特征，不同模型中的相同模块都使用一致的参数，并且对比的基线 DIN[14] 模型经过高度优化，以下为我们具体进行对比的实验：

- **DIN**：该模型训练和预估时都没有使用位置信息。
- **DIN+PosInWide**：这个方法在网络的 Wide 部分建模位置特征，在评估时采用第一个位置作为位置特征的默认值去评估。
- **DIN+PAL**：这个方法采用 PAL 框架去建模位置信息。
- **DIN+ActualPosInWide**：这个方法在网络的 Wide 部分建模位置特征，在评估时采用真实位置特征去评估。
- **DIN+Combination**：这个方法在 DIN 的基础上添加了位置组合模块，评估时采用真实位置特征去评估。
- **DPIN-Transformer**：这个方法在我们提出的 DPIN 模型上去除了 Transformer 结构，来验证 Transformer 的作用。
- **DPIN**：这是我们提出的 DPIN 模型。
- **DPIN+ItemAction**：我们在 DPIN 的基础模块 MLP 层前添加深度位置交叉模块，并在位置兴趣聚合和位置非线性交叉中引入候选广告的信息，这个实验是我们方法模型性能的理论上界，然而服务性能是不可接受的。

3.2 离线评估

模型	常规流量		随机流量	
	AUC(%)	PAUC(%)	AUC(%)	PAUC(%)
DIN	0	0	0	0
DIN+PosInWide	-1.22	+0.19	-1.11	+0.16
DIN+PAL	-0.83	+0.38	-0.73	+0.31
DIN+AcutalPosInWide	+1.10	+0.19	+1.02	+0.16
DIN+Combination	+1.52	+0.82	+1.49	+0.71
DPIN-Transformer	+1.43	+0.58	+1.48	+0.60
DPIN	**+1.76**	**+1.26**	**+1.79**	**+1.27**
DPIN+ItemAction	+1.81	+1.33	+1.83	+1.33

表 1　在常规流量和随机流量上的离线实验评估对比结果

表 1 展示了我们所进行的对比方法在常规流量和随机流量上的离线实验评估结果，其中的数值为各个模型相对于 DIN 模型的效果差异，我们首先分析在常规流量上不同方法的差异。与 DIN 相比，DIN+PosInWide 和 DIN+PAL 的模型在 AUC 指标上有所下降，但在 PAUC 上有所提升，这表明了这两种方法都可以有效地缓解位置偏差，但会导致离线和在线之间的不一致。

DIN+AcutalPosInWide 通过在评估过程中引入实际位置来解决不一致问题，这可以通过位置组合模块来实现，但是在 wide 部分建模位置会导致位置特征只是一个偏差，不能提升 PAUC 指标，虽然能更准确地预估各位置上的 CTR，但没有对数据中固有的位置偏差进行更好的学习。

DIN+Combination 通过在 DIN 中引入位置组合模块，我们取得了 1.52% 的 AUC 增益和 0.82% 的 PAUC 增益，达到线下线上一致性的同时也进一步地缓解了位置偏差，这个结果说明了位置偏差与上下文、用户等信息不独立，在不同的用户及上下文中会有不同的位置偏差。更进一步的，DPIN 建模位置、上下文、用户的深度非线性交叉关系，也消除了用户行为序列中存在的位置偏差，对比 DIN+Combination 取得了 0.24% 的 AUC 增益以及 0.44% 的 PAUC 增益。

DPIN-Transformer 的效果说明了丢失其他位置的用户兴趣会影响模型的性能，因为这将损失大部分用户兴趣信息。对比 DPIN 和 DPIN+ItemAction，我们发现 DPIN 的模型性能接近于这个暴力方法，说明 DPIN 模型逼近了我们方法的理论上界。最终，相较于我们的线上基线模型 DIN+PosInWide，DPIN 取得了 2.98% 的 AUC 增益和 1.07% 的 PAUC 增益，这在我们的业务场景中是一次极大的 AUC 和 PAUC 提升。

为了确保我们的方法能够学习位置偏差而不是单纯地过度拟合系统的选择性偏差，我们进一步在随机流量上评估我们的方法。表 1 的结果表明了在常规流量和随机流量上不同方法之间的差异是一致的，这说明了就算系统的推荐结果有了巨大的差异，该模型仍能有效地学习到在不同用户及上下文中的位置偏差，模型学到的位置偏差受系统推荐列表的影响很小，这也说明我们的模型可以不受系统选择性偏差的影响从而泛化到其他推荐方法的流量上。

3.3 服务性能

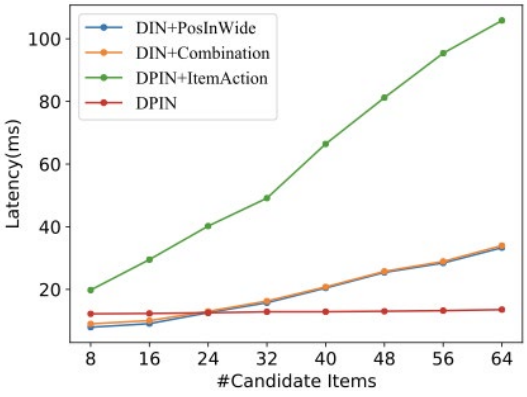

图 5　不同的方法下服务延迟随着不同候选广告数量的变化图

我们从数据集中检索出一些具有不同候选广告数量的请求，以评估不同候选广告数量下的服务性能。如图 5 所示，由于用户序列操作的延迟在服务延迟中占了很大比例，因此与 DIN 模型相比，位置组合模块服务延迟可以忽略不计。DPIN 的服务延迟随着广告数量的增加而缓慢增加，这是因为相比较于 DIN，DPIN 将用户序列从基础模块移动到深度位置交叉模块，而深度位置交叉模块的服务性能与广告数量无关。与

DIPIN+ItemAction 方法相比，DPIN 在服务性能方面有了很大的改进，对模型性能的损害很小，这表明我们提出的方法既高效又有效。

3.4 在线评估

我们在线上部署了 A/B 测试，有稳定的结果表明，与基线相比，DPIN 在 CTR 上提高了 2.25%，在 RPM（每千次展示收入）上提高了 2.15%。如今，DPIN 已在线部署并服务于主要流量，为业务收入的显着增长做出了贡献。

4. 总结与展望

在本文中，我们提出了一种新颖的深度位置交叉网络模型（Deep Position-wise Interaction Network）以缓解位置偏差问题，该模型有效地组合了所有候选广告和位置以估算每个广告在每个位置的点击率，实现了离线和在线之间的一致性。该模型设计了位置、上下文和用户之间的深层非线性交叉，可以学习到不同用户、不同上下文中的位置偏差。为了评估位置偏向问题，我们提出了一种新的评估指标 PAUC，离线实验表明，所提出的 DPIN 的效果和效率均优于已有方法。目前，DPIN 已部署到美团搜索关键词广告系统并服务于主要流量。

值得一提的是，我们的并行组合思想不仅可以用在广告和位置的组合上，也可以用在广告和创意的组合等广告领域常见的组合排序问题。在未来，我们将在这些问题上继续实践我们的方法，并进一步地设计更完善的网络结构来解决类似的组合排序问题。我们也将在偏差领域上进行更多的探索，解决更多的问题，进一步维护广告系统的生态平衡。

作者简介

坚强、胡可、庆涛、明健、漆毅、程佳、雷军等，均来自美团广告平台技术部。

参考文献

[1] Chen, Jiawei, et al. “Bias and Debias in Recommender System: A Survey and

Future Directions." arXiv preprint arXiv:2010.03240 (2020).
[2] Cañamares, Roc í o, and Pablo Castells. "Should I follow the crowd? A probabilistic analysis of the effectiveness of popularity in recommender systems." The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. 2018.
[3] Morik, Marco, et al. "Controlling fairness and bias in dynamic learning-to-rank." Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. 2020.
[4]《KDD Cup 2020 Debiasing 比赛冠军技术方案及在美团的实践》。
[5] Richardson, Matthew, Ewa Dominowska, and Robert Ragno. "Predicting clicks: estimating the click-through rate for new ads." Proceedings of the 16th international conference on World Wide Web. 2007.
[6] Rendle, Steffen. "Factorization machines." 2010 IEEE International Conference on Data Mining. IEEE, 2010.
[7] Juan, Yuchin, et al. "Field-aware factorization machines for CTR prediction." Proceedings of the 10th ACM conference on recommender systems. 2016.
[8] Chen, Tianqi, and Carlos Guestrin. "Xgboost: A scalable tree boosting system." Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining. 2016.
[9] Ke, Guolin, et al. "Lightgbm: A highly efficient gradient boosting decision tree." Advances in neural information processing systems 30 (2017): 3146-3154.
[10] Cheng, Heng-Tze, et al. "Wide & deep learning for recommender systems." Proceedings of the 1st workshop on deep learning for recommender systems. 2016.
[11] Wang, Ruoxi, et al. "Deep & cross network for ad click predictions." Proceedings of the ADKDD'17. 2017. 1-7.
[12] Guo, Huifeng, et al. "DeepFM: a factorization-machine based neural network for CTR prediction." arXiv preprint arXiv:1703.04247 (2017).
[13] Lian, Jianxun, et al. "xdeepfm: Combining explicit and implicit feature interactions for recommender systems." Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018.
[14] Zhou, Guorui, et al. "Deep interest network for click-through rate prediction." Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018.
[15] Zhou, Guorui, et al. "Deep interest evolution network for click-through rate prediction." Proceedings of the AAAI conference on artificial intelligence. Vol. 33. No. 01. 2019.
[16] Feng, Yufei, et al. "Deep session interest network for click-through rate prediction." arXiv preprint arXiv:1905.06482 (2019).
[17] Ling, Xiaoliang, et al. "Model ensemble for click prediction in bing search ads." Proceedings of the 26th International Conference on World Wide Web Companion. 2017.

[18] Zhao, Zhe, et al. “Recommending what video to watch next: a multitask ranking system.” Proceedings of the 13th ACM Conference on Recommender Systems. 2019.
[19] Haldar, Malay, et al. “Improving Deep Learning For Airbnb Search.” Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2020.
[20] Guo, Huifeng, et al. “PAL: a position-bias aware learning framework for CTR prediction in live recommender systems.” Proceedings of the 13th ACM Conference on Recommender Systems. 2019.
[21] Wang, Xuanhui, et al. “Learning to rank with selection bias in personal search.” Proceedings of the 39th International ACM SIGIR conference on Research and Development in Information Retrieval. 2016.
[22] Joachims, Thorsten, Adith Swaminathan, and Tobias Schnabel. “Unbiased learning-to-rank with biased feedback.” Proceedings of the Tenth ACM International Conference on Web Search and Data Mining. 2017.
[23] Ai, Qingyao, et al. “Unbiased learning to rank with unbiased propensity estimation.” The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. 2018.
[24] Wang, Xuanhui, et al. “Position bias estimation for unbiased learning to rank in personal search.” Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining. 2018.
[25] Agarwal, Aman, et al. “Estimating position bias without intrusive interventions.” Proceedings of the Twelfth ACM International Conference on Web Search and Data Mining. 2019.
[26] Hu, Ziniu, et al. “Unbiased lambdamart: an unbiased pairwise learning-to-rank algorithm.” The World Wide Web Conference. 2019.
[27] Ovaisi, Zohreh, et al. “Correcting for selection bias in learning-to-rank systems.” Proceedings of The Web Conference 2020. 2020.
[28] Yuan, Bowen, et al. “Unbiased Ad click prediction for position-aware advertising systems.” Fourteenth ACM Conference on Recommender Systems. 2020.
[29] Qin, Zhen, et al. “Attribute-based propensity for unbiased learning in recommender systems: Algorithm and case studies.” Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2020.
[30] Vaswani, Ashish, et al. “Attention is all you need.” arXiv preprint arXiv:1706.03762 (2017).

让 Flutter 在鸿蒙系统上跑起来

作者：杨超

前言

鸿蒙系统（HarmonyOS）是华为推出的一款面向未来、面向全场景的分布式操作系统。在传统单设备系统能力的基础上，鸿蒙提出了基于同一套系统能力、适配多种终端形态的分布式理念。自 2020 年 9 月 HarmonyOS 2.0 发布以来，华为加快了鸿蒙系统大规模落地的步伐，预计 2021 年底，鸿蒙系统会覆盖包括手机、平板、智能穿戴、智慧屏、车机在内数亿台终端设备。对移动应用而言，**新的系统理念、新的交互形式，也意味着新的机遇**。如果能够利用好鸿蒙的开发生态及其特性能力，可以让应用覆盖更多的交互场景和设备类型，从而带来新的增长点。

与面临的机遇相比，适配鸿蒙系统带来的挑战同样巨大。当前手机端，尽管鸿蒙系统仍然支持安卓 APK 安装及运行，但长期来看，华为势必会抛弃 AOSP，逐步发展出自己的生态，这意味着现有安卓应用在鸿蒙设备上将会逐渐变成“二等公民”。然而，如果在 iOS 及 Android 之外再重新开发和维护一套鸿蒙应用，在如今业界越来越注重开发迭代效率的环境下，所带来的开发成本也是难以估量的。因此，通过打造一套合适的跨端框架，以相对低的成本移植应用到鸿蒙平台，并利用好该系统的特性能力，就成为了一个非常重要的选项。

在现有的众多跨端框架当中，Flutter 以其自渲染能力带来的多端高度一致性，在新系统的适配上有着突出的优势。虽然 Flutter 官方并没有适配鸿蒙的计划，但经过一段时间的探索和实践，美团外卖 MTFlutter 团队成功实现了 Flutter 对于鸿蒙系统的

原生支持。

这里也要提前说明一下，因为鸿蒙系统目前还处于 Beta 版本，所以这套适配方案还没有在实际业务中上线，属于技术层面比较前期的探索。接下来本文会通过原理和部分实现细节的介绍，分享我们在移植和开发过程中的一些经验。希望能对大家有所启发或者帮助。

背景知识和基础概念介绍

在适配开始之前，我们要明确好先做哪些事情。先来回顾一下 Flutter 的三层结构：

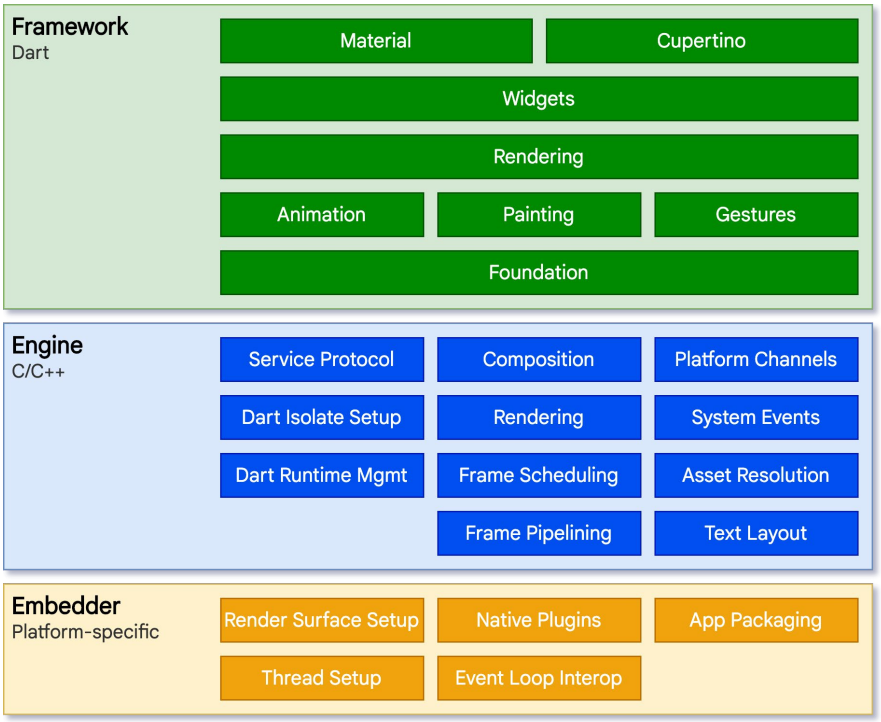

在 Flutter 的架构设计中，最上层为**框架层**，使用 Dart 语言开发，面向 Flutter 业务的开发者；中间层为**引擎层**，使用 C/C++ 开发，实现了 Flutter 的渲染管线和 Dart 运行时等基础能力；最下层为**嵌入层**，负责与平台相关的能力实现。显然我们要做的是将嵌入层移植到鸿蒙上，确切地说，我们要**通过鸿蒙原生提供的平台能力，重新实**

现一遍 Flutter 嵌入层。

对于 Flutter 嵌入层的适配，Flutter 官方有一份不算详细的指南，实际操作起来成本很高。由于鸿蒙的业务开发语言仍然可用 Java，在很多基础概念上与 Android 也有相似之处（如下表所示），我们可以从 Android 的实现入手，完成对鸿蒙的移植。

HarmonyOS	Android	说明
Ability	Activity & Service & ContentProvider	FA（Feature Ability）– Activity PA（Particle Ability）– Service & ContentProvider
AbilitySlice	Fragment	应用的单个页面及其控制逻辑的总和
CommonEventSubscriber	BroadcastReceiver	鸿蒙公共事件服务（CES）的一部分，支持接收公共事件
AbilityPackage	Application	
Intent	Intent	对象之间传递信息的载体
Ability Form	Widget	类似Android的桌面小部件
NotificationHelper	NotificationManager	通知管理器
SystemPasteboard	ClipboardManager	系统剪贴板服务

Flutter 在鸿蒙上的适配

如前文所述，要完成 Flutter 在新系统上的移植，我们需要完整实现 Flutter 嵌入层要求的所有子模块，而从能力支持角度，**渲染**、**交互**以及**其他必要的原生平台能力**是保证 Flutter 应用能够运行起来的最基本的要素，需要优先支持。接下来会依次进行介绍。

1. 渲染流程打通

我们再来回顾一下 Flutter 的图像渲染流程。如图所示，设备发起**垂直同步**（VSync）信号之后，先经过 UI 线程的渲染管线（Animate/Build/Layout/Paint），再经过 Raster 线程的组合和栅格化，最终通过 OpenGL 或 Vulkan 将图像**上屏**。这个流程的大部分工作都由框架层和引擎层完成，对于鸿蒙的适配，我们主要关注的是与设备自身能力相关的问题，即：

(1) 如何监听设备的 VSync 信号并通知 Flutter 引擎? (2) OpenGL/Vulkan 用于上屏的窗口对象从何而来?

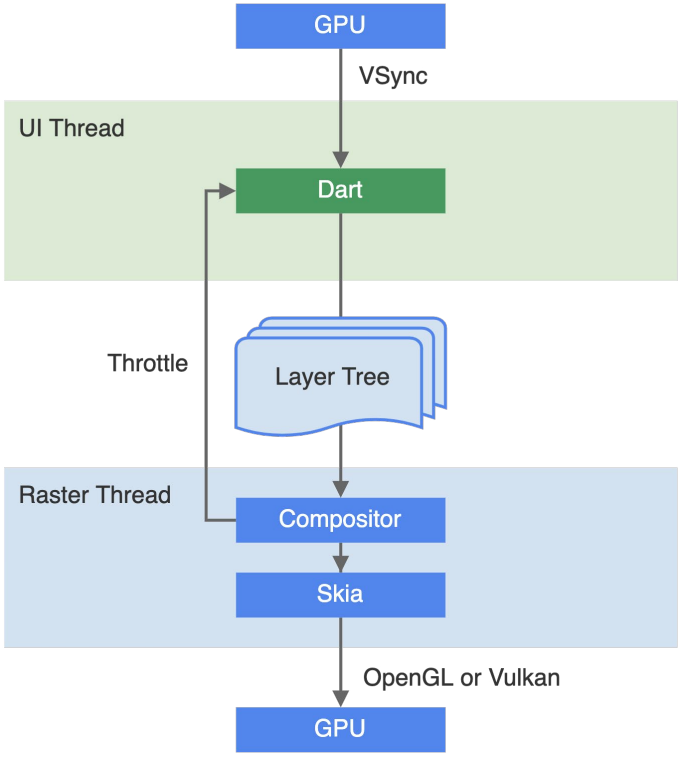

VSync 信号的监听及传递

在 Flutter 引擎的 Android 实现中，设备的 VSync 信号通过 Choreographer 触发，它产生及消费流程如下图所示：

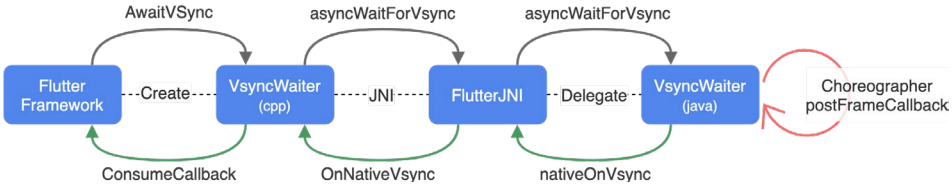

Flutter VSync

Flutter 框架注册 VSync 回调之后，通过 C++ 侧的 VsyncWaiter 类等待 VSync

信号，后者通过 JNI 等一系列调用，最终 Java 侧的 VsyncWaiter 类调用 Android SDK 的 Choreographer.postFrameCallback 方法，再通过 JNI 一层层传回 Flutter 引擎消费掉此回调。Java 侧的 VsyncWaiter 核心代码如下：

```
@Override
public void asyncWaitForVsync(long cookie) {
  Choreographer.getInstance()
      .postFrameCallback(
        new Choreographer.FrameCallback() {
          @Override
          public void doFrame(long frameTimeNanos) {
            float fps = windowManager.getDefaultDisplay().
getRefreshRate();
            long refreshPeriodNanos = (long) (1000000000.0 / fps);
            FlutterJNI.nativeOnVsync(
              frameTimeNanos, frameTimeNanos + refreshPeriodNanos,
cookie);
          }
        });
}
```

在整个流程中，除了来自 Android SDK 的 Choreographer 以外，大多数逻辑几乎都由 C++ 和 Java 的基础 SDK 实现，可以直接在鸿蒙上复用，问题是鸿蒙目前的 API 文档中尚没有开放类似 Choreographer 的能力。所以现阶段我们可以借用鸿蒙提供的类似 iOS Grand Central Dispatch 的线程 API，模拟出 VSync 的信号触发与回调：

```
@Override
public void asyncWaitForVsync(long cookie) {
  // 模拟每秒 60 帧的屏幕刷新间隔：向主线程发送一个异步任务，16ms 后调用
  applicationContext.getUITaskDispatcher().delayDispatch(() -> {
    float fps = 60; // 设备刷新帧率，HarmonyOS 未暴露获取帧率 API，先写死 60 帧
    long refreshPeriodNanos = (long) (1000000000.0 / fps);
    long frameTimeNanos = System.nanoTime();
    FlutterJNI.nativeOnVsync(frameTimeNanos, frameTimeNanos +
refreshPeriodNanos, cookie);
  }, 16);
};
```

渲染窗口的构建及传递

在这一部分，我们需要在鸿蒙系统上构建平台容器，为 Flutter 引擎的图形渲染提供用于上屏的窗口对象。同样，我们参考 Flutter for Android 的实现，看一下 Android 系统是怎么做的：

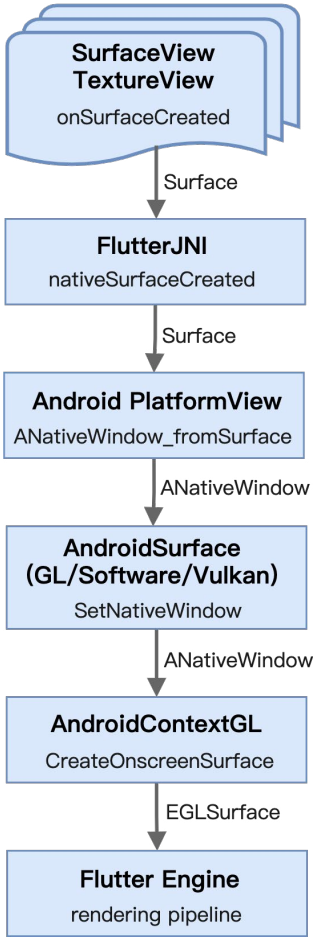

Flutter 在 Android 上支持 Vulkan 和 OpenGL 两种渲染引擎，篇幅原因我们只关注 OpenGL。抛开复杂的注册及调用细节，本质上整个流程主要做了三件事：

- 创建了一个**视图对象**，提供可用于直接绘制的 Surface，将它通过 JNI 传递给原生侧；

- 在原生侧获取 Surface 关联的**本地窗口对象**，并交给 Flutter 的平台容器；
- 将本地窗口对象转换为 OpenGL ES 可识别的**绘图表面（EGLSurface）**，用于 Flutter 引擎的渲染上屏。

接下来我们用鸿蒙提供的平台能力实现这三点。

a. 可用于直接绘制的视图对象

鸿蒙系统的 UI 框架提供了很多常用视图组件（Component），比如按钮、文字、图片、列表等，但我们需要抛开这些上层组件，获得直接绘制的能力。借助官方 媒体播放器开发指导 文档，可以发现鸿蒙提供了 SurfaceProvider 类，它管理的 Surface 对象可以用于视频解码后的展示。而 Flutter 渲染与视频上屏从原理上是类似的，因此我们可以借用 SurfaceProvider 实现 Surface 的管理和创建：

```
// 创建一个用于管理 Surface 的容器组件
SurfaceProvider surfaceProvider = new SurfaceProvider(context);
// 注册视图创建回调
surfaceProvider.getSurfaceOps().get().addCallback(surfaceCallback);

// ... 在 surfaceCallback 中
@Override
public void surfaceCreated(SurfaceOps surfaceOps) {
  Surface surface = surfaceOps.getSurface();
  // ...将 surface 通过 JNI 交给 Native 侧
  FlutterJNI.onSurfaceCreated(surface);
}
```

b. 与 Surface 关联的本地窗口对象

鸿蒙目前开放的 Native API 并不多，在官方文档中我们可以比较容易地找到 Native_layer API。根据文档的说明，Native API 中的 NativeLayer 对象刚好对应了 Java 侧的 Surface 类，借助 GetNativeLayer 方法，我们实现了两者之间的转化：

```
// platform_view_android_jni_impl.cc
static void SurfaceCreated(JNIEnv* env, jobject jcaller, jlong shell_
holder, jobject jsurface) {
  fml::jni::ScopedJavaLocalFrame scoped_local_reference_frame(env);
  // 通过鸿蒙 Native API 获取本地窗口对象 NativeLayer
  auto window = fml::MakeRefCounted<AndroidNativeWindow>(
```

```
      GetNativeLayer(env, jsurface));
  ANDROID_SHELL_HOLDER->GetPlatformView()->NotifyCreated(std::move(wind
ow));
}
```

c. 与本地窗口对象关联的 EGLSurface

在 Android 的 AOSP 实现中，EGLSurface 可通过 EGL 库的 eglCreateWindowSurface 方法从本地窗口对象 **ANativeWindow** 创建而来。对于鸿蒙而言，虽然我们没有从公开文档找到类似的说明，但是 鸿蒙标准库 默认支持了 OpenGL ES，而且鸿蒙 SDK 中也附带了 EGL 相关的库及头文件，我们有理由相信在鸿蒙系统上，EGLSurface 也可以通过此方法从前一步生成的 **NativeLayer** 转化而来，在之后的验证中我们也确认了这一点：

```
// window->handle() 即为之前得到的 NativeLayer
EGLSurface surface = eglCreateWindowSurface(
      display, config_, reinterpret_cast<EGLNativeWindowType>(window-
>handle()),
      attribs);
//... 交给 Flutter 渲染管线
```

2. 交互能力实现

交互能力是支撑 Flutter 应用能够正常运行的另一个基本要求。在 Flutter 中，交互包含了各种触摸事件、鼠标事件、键盘录入事件的传递及消费。以触摸事件为例，Flutter 事件传递的整个流程如下图所示：

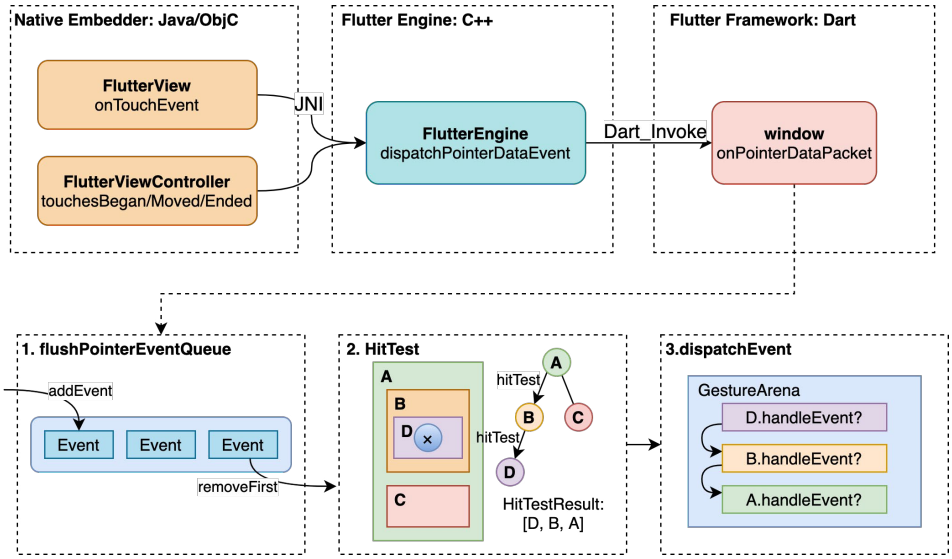

Flutter 事件分发

iOS/Android 的原生容器通过触摸事件的回调 API 接收到事件之后，会将其打包传递至引擎层，后者将事件传发给 Flutter 框架层，并完成事件的消费、分发和逻辑处理。同样，整个流程的大部分工作已经由 Flutter 统一，我们要做的仅仅是在原生容器上**监听**用户的输入，并**封装**成指定格式交给引擎层而已。

在鸿蒙系统上，我们可以借助平台提供的 多模输入 API，实现多种类型事件的监听：

```
flutterComponent.setTouchEventListener(touchEventListener); // 触摸及鼠标事件
flutterComponent.setKeyEventListener(keyEventListener); // 键盘录入事件
flutterComponent.setSpeechEventListener(speechEventListener); // 语音录入事件
```

对于事件的封装处理，可以复用 Android 已有逻辑，只需要关注鸿蒙与 Android 在事件处理上的对应关系即可，比如触摸事件的部分对应关系：

Android MotionEvent	HarmonyOS TouchEvent	说明
getActionMasked()	getAction()	当前触摸行为，点击/按下/移动等
getActionIndex()	getIndex()	按下的是第几个手指
getToolType()	getSourceDevice()	触摸设备类型，是手指还是鼠标
getX、getY	getPointerPosition	坐标偏移信息
ACTION_DOWN ACTION_UP ACTION_POINTER_DOWN ACTION_POINTER_UP	PRIMARY_POINT_DOWN PRIMARY_POINT_UP OTHER_POINT_DOWN OTHER_POINT_UP	触摸行为的具体类型

3. 其他必要的平台能力

为了保证 Flutter 应用能够正常运行，除了最基本的渲染和交互外，我们的嵌入层还要提供资源管理、事件循环、生命周期同步等平台能力。对于这些能力 Flutter 大多都在嵌入层的公共部分有抽象类声明，只需要使用鸿蒙 API 重新实现一遍即可。

比如资源管理，引擎提供了 AssetResolver 声明，我们可以使用鸿蒙 Rawfile API 来实现：

```
class HAPAssetMapping : public fml::Mapping {
 public:
  HAPAssetMapping(RawFile* asset) : asset_(asset) {}
  ~HAPAssetMapping() override { CloseRawFile(asset_); }

  size_t GetSize() const override { return GetRawFileSize(asset_); }

  const uint8_t* GetMapping() const override {
    return reinterpret_cast<const uint8_t*>(GetRawFileBuffer(asset_));
  }

 private:
  RawFile* const asset_;

  FML_DISALLOW_COPY_AND_ASSIGN(HAPAssetMapping);
};
```

对于事件循环，引擎提供了 MessageLoopImpl 抽象类，我们可以使用鸿蒙 Native_EventHandler API 实现：

```
// runner_ 为鸿蒙 EventRunnerNativeImplement 的实例
void MessageLoopHarmony::Run() {
  FML_DCHECK(runner_ == GetEventRunnerNativeObjForThread());
  int result = ::EventRunnerRun(runner_);
  FML_DCHECK(result == 0);
}

void MessageLoopHarmony::Terminate() {
  int result = ::EventRunnerStop(runner_);
  FML_DCHECK(result == 0);
}
```

对于生命周期的同步，鸿蒙的 Page Ability 提供了完整的生命周期回调（如下图所示），我们只需要在对应的时机将状态上报给引擎即可。

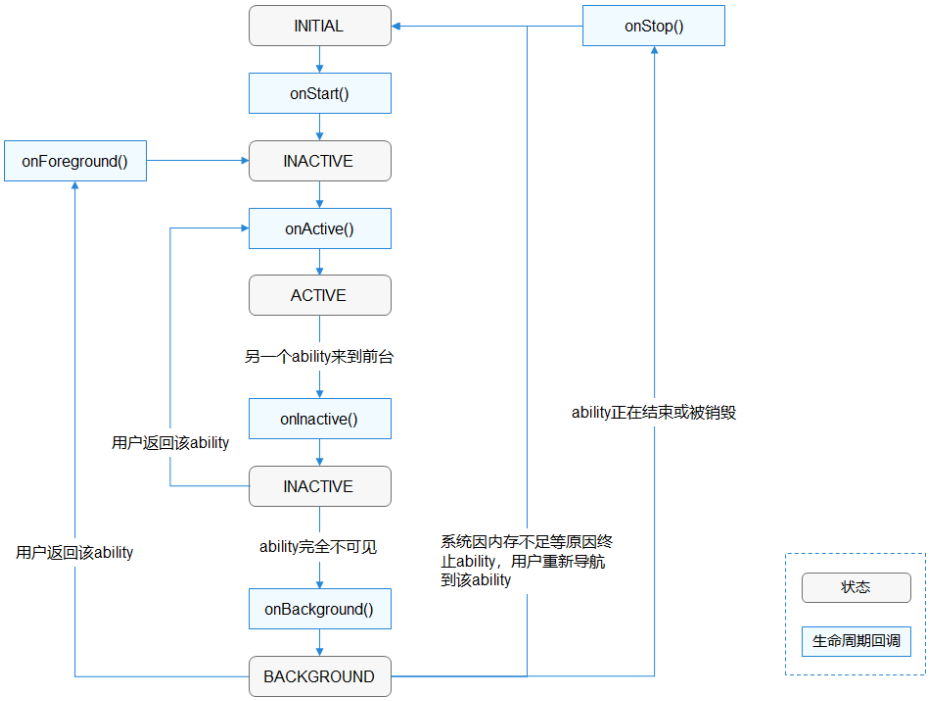

Page Ability Lifecycle

当以上这些能力都准备好之后，我们就可以成功把 Flutter 应用跑起来了。以下是通过 DevEco Studio 运行官方 flutter gallery 应用的截图，截图中 Flutter 引擎已经使用鸿蒙系统的平台能力进行了重写：

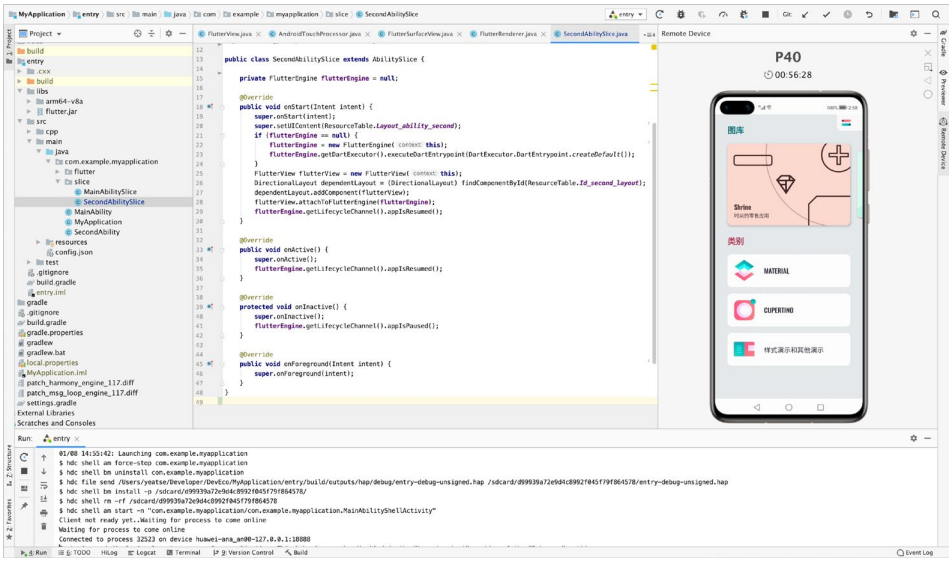

DevEco Running Flutte

借由鸿蒙的多设备支持能力，此应用甚至可在 TV、车机、手表、平板等设备上运行：

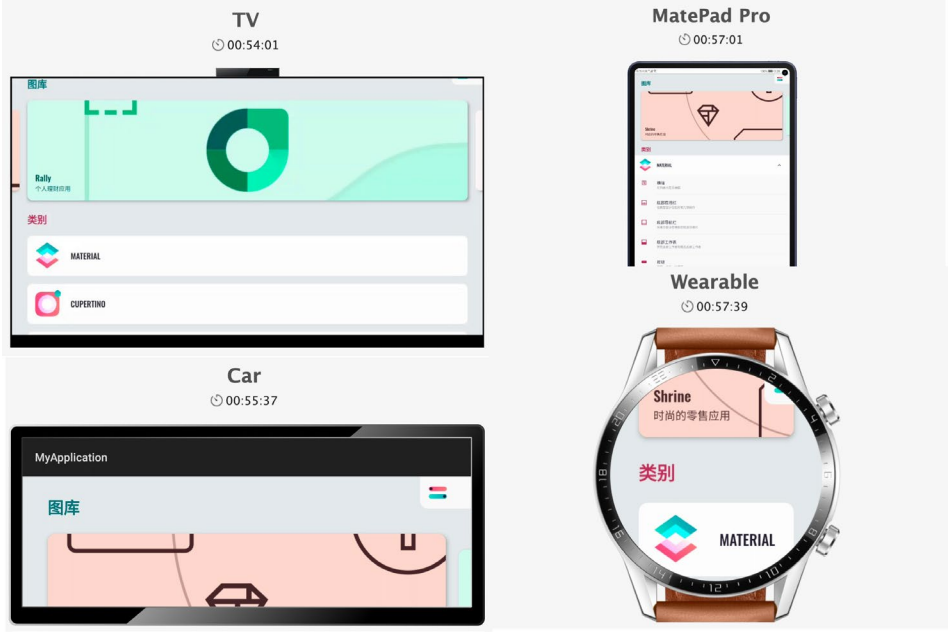

Flutter Multiple Devices

总结和展望

通过上述的构建和适配工作，我们以极小的开发成本实现了 Flutter 在鸿蒙系统上的移植，基于 Flutter 开发的上层业务几乎不做任何修改就可以在鸿蒙系统上原生运行，为迎接鸿蒙系统后续的大规模推广也提前做好了技术储备。

当然，故事到这里并没有结束。在最基本的运行和交互能力之上，我们更需要关注 Flutter 与鸿蒙自身生态的结合：如何优雅地适配鸿蒙的分布式技术？如何用 Flutter 实现设备之间的快速连接、资源共享？现有的众多 Flutter 插件如何应用到鸿蒙系统上？未来 MTFlutter 团队将在这些方面做更深入的探索，因为解决好这些问题，才是真正能让应用覆盖用户生活的全场景的关键。

参考文献

- https://developer.huawei.com/consumer/cn/events/hdc2020/
- https://developer.harmonyos.com/cn/documentation
- https://flutter.dev/docs/resources/architectural-overview
- https://github.com/flutter/flutter/wiki/Custom-Flutter-Engine-Embedders

作者简介

杨超，2016 年加入美团外卖技术团队，目前主要负责 MTFlutter 相关的基础建设工作。

FlutterWeb 在美团外卖的实践

作者：典胜　凌霄　海阔

一、背景

1.1 业务背景

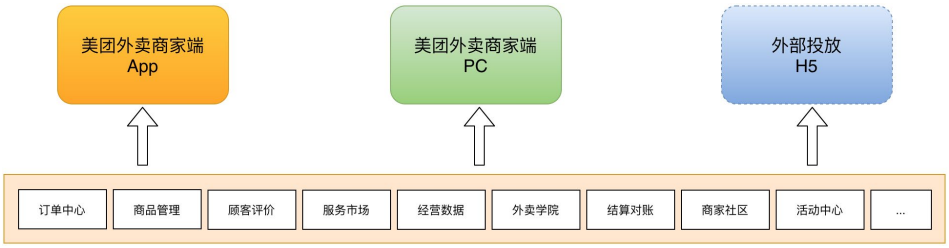

美团外卖商家端业务形态

美团外卖商家端业务围绕数百万商家，在 PC 和 App 上分别提供了交易履约、运营、广告、营销等一系列功能，且经常有外投 H5 的场景（如外卖学院、商家社区、营销活动等）。在这种多形态的业务场景下，如何保障多端体验的一致性，以及如何提升多端迭代的效率，一直是商家端产研关注的重点。

1.1.1 保障多端体验一致性

由于端能力的不同，导致了业务在 App 和 Web 上存在较大的表现差异，例如：App 上自带动画转场，而在 Web 中的实现成本却较高，往往也就降级舍弃了这部分功能。此外，即使我们可利用公司内部的 Roo、MTDUI 等多端 UI 组件库来尽量抹平各端的 UI 差异，但由于组件库在各端的实现不尽相同，很难做到完美的一致性体验。

1.1.2 提升多端迭代效率

由于各端技术体系的不同，涉及多端的需求往往需要不同的开发、测试团队各自完成开发、联调、测试、上线等流程，占用资源巨大，在各团队不可并行支持的情况下，

甚至可能导致整个业务交付周期被拉长。虽然 React Native、Flutter 等跨平台方案解决了一部分复用的问题，但显然在商家端业务场景下是远远不够的，我们的目标是要达到全平台（Android、iOS、PC、H5）复用，最大化地提升多端的迭代效率。

1.2 技术背景

1.2.1 Flutter 在美团外卖商家端的储备

MTFlutter 是美团外卖搭建起的公司级 Flutter 研发生态，它的架构图如下图所示：

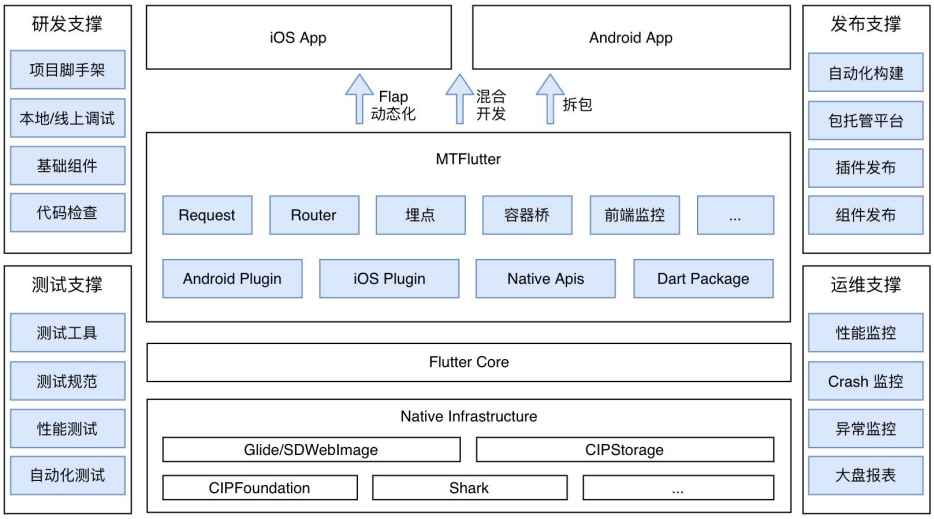

MTFlutter 架构图

如图所示，MTFlutter 已涵盖研发、调试、测试、发布、线上运维及工程管理整套闭环，同时落地了动态化解决方案，支撑了公司多个业务发展。在大前端融合的趋势下，美团外卖商家端持续在探索更优的多端复用方案，通过 MTFlutter 生态的建设，目前 Flutter 技术栈已覆盖商家端 App 中 90% 以上的业务，同时具备 Flutter 开发能力的同学也达到 90% 以上。因此，在有足够技术“储备”的前提下，我们能够基于 Flutter 做全平台（Android、iOS、PC、H5）复用的探索。

1.2.2 Flutter Web 的支持

2018 年 Google 首次公开 Flutter Web Beta 版，旨在进一步实现一份代码、多端运行的愿景。目前，Flutter Web 已被正式合入 Master，期间经过无数工程师的努力，Flutter Web 已能提供与 Flutter Natvie 较统一的交互行为和视觉体验。

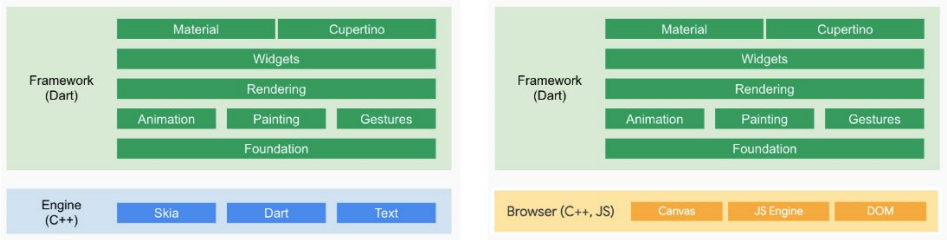

Flutter Native VS Flutter Web

如上图可知，Flutter Web 与 Flutter Native 的整体架构相似，二者共用 Framework 层（绿色部分），提供了包括动画、手势、基础 Widget 类，以及大部分应用所需的 Material/Cupertino 主题 Widget 集合。区别在于：Flutter Web 重写了 dart:ui 层（黄色部分），利用 DOM、Canvas 对齐了 Flutter Native 的 UI 渲染能力，使得 Flutter 编写的 UI 能够在现代浏览器上正常展示。

此外，得益于 dart2js 这个早已成熟的工具，Dart 逻辑能够很容易的转换为 JavaScript，进而在 Web 中被正常运行。

二、面临的挑战

综上所述，我们选择基于 Flutter Web 探索跨端（App\PC\H5）解决方案，真正实现“Write Once & Run AnyWhere”。当然，面临挑战也是巨大的，主要体现在 Flutter 和 MTFlutter 现阶段对 Web 支持还不是很充足。

2.1 Flutter Web 现状

Google 官方目前对 Flutter Web 的工作主要还集中在 dart:ui（Web）的对齐，工程化和性能相关的事项做的还比较少，例如：

- Flutter Web 构建产物较简陋，只是简单的输出 main.dart.js（1.1M，未 Gzip）和 图片等静态资源，缺少 JS 拆包、文件 Hash、资源上传 CDN 等优化工作，极大影响了页面的加载性能。
- 由于 Flutter Web 自身实现了一套页面滚动机制，页面滚动过程中，会频繁计算位置信息，引起滚动区域内容被重新创建，最终导致页面滚动性能较差。

2.2 MTFlutter 现状

虽然 MTFlutter 做了诸多 Flutter Native 层面的定制与优化，但在 Flutter Web 上的建设才刚起步，具体表现在：

- MTFlutter 现有的基础依赖如：Request（请求封装）、Router（路由）、埋点、容器桥、前端监控，尚未支持在 Web 中的实现。
- MTFlutter 已实现了完整的 Flutter Module 的打包发布流程，但并不支持 Web 的构建与部署。

三、整体设计

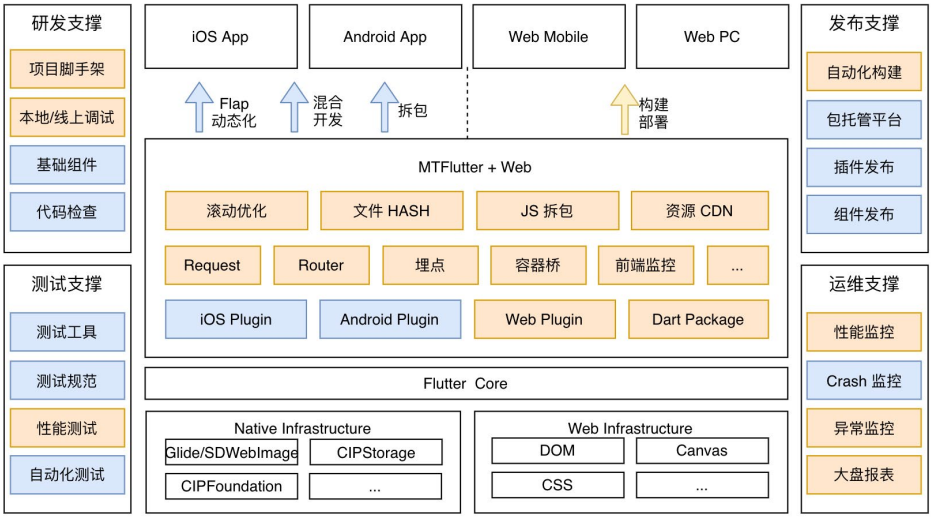

MTFlutter 架构图

上图为 MTFlutter + Web 架构图，由图可知 Flutter Web 页面要满足投产要求，还有大量的工作（上图黄色部分所示），主要包括：

- 扩展基础依赖（如：Request、Router、埋点等）在 Web 侧的支持。
- 完善工程化建设，例如：静态资源优化、构建与部署自动化。
- 深入滚动性能与页面加载性能优化，使得 Flutter Web 能够满足基本的投产要求。

四、详细设计

4.1 基础依赖建设

企业级应用的基础开发依赖（如：请求库、路由库、埋点库等），要重新在 Flutter 中用 Dart 搭建一套，时间成本、兼容性、风险等都是不可控的。而 MTFlutter 是基于原有 Native 基础依赖开发的 Plugin，因此并不支持 Web 端。此章节将展开介绍如何丝滑无感地扩展 MTFlutter 基础依赖在 Web 端的实现。

4.1.1 Flutter Package 分平台编程

在 Flutter 中通过使用 Package 可以创建易于共享的模块化代码。官方强烈推荐使用 Package 形式管理各种工具方法。在官方定义中 Package 包含以下两种类别：

- **Dart Package**：用 Dart 编写的常规 Package，其中一些可能包含依赖于 Flutter 框架的特定功能，其使用范围仅限于 Flutter，例如 path。
- **Plugin Package**：用 Dart 编写 API 多个平台各自实现的特殊 Dart Package。Plugin Package 可以为 Android（使用 Kotlin 或 Java）、iOS（使用 Swift 或 Objective-C）、Web、macOS、Windows 或 Linux 或其任意组合编写插件包。

下面分别对这两种类型 Package 中如何分平台编程进行介绍。

(1) Dart Package

Dart Package 是纯 Dart 编写，因此大部分代码均可由 dart2js 直接编译出 Web 平台可运行的代码，但某些涉及 Native 能力的库（如 dart:io）是无法被转译的，因此

需要有对平台进行兼容的方法，下面介绍两种在 Dart Package 中分平台编程的方案。

代码级别分平台

针对代码级别的分平台，我们可以借助 Flutter SDK 提供的一个常量 kIsWeb。使用方法如下：

> 查看源码可知，kIsWeb 之所以能被用于判断 Web 平台，是利用了 JavaScript 不支持整型的特征，在 Web 环境下，Dart 的 double 和 int 由相同类型的对象支持，浮点数“0.0”等于整数“0”，对于在 AOT 或 VM 上运行的 Dart 代码却并非如此。

```
import 'package:flutter/foundation.dart';
if (kIsWeb) {
  print('Web 端')
} else {
  print('其他端');
}
```

文件级别分平台

针对文件级别分平台，我们利用条件导入导出，其中条件导出具体用法如下：

```
// tool.dart
export 'src/tool_native.dart' // 兜底导出，即没有命中条件时导出的文件
  if (dart.library.html) 'src/tool_web.dart'; // web 端导出的文件，该文件中可以使用 dart:html，也可以通过判断 dart.library.js 导出 Web 端文件。
```

```
// 引入 tool.dart
import 'package:tool/tool.dart';
void main() {
  print('import tool');
}
```

条件导入和条件导出类似，仅需将 export 改为 import 即可。在业务开发中这也是一种非常实用的分平台编程方法。

(2) Plugin Package

Plugin Package (下文简称为 Plugin) 在 Android 和 iOS 平台都是通过 Method-Channel 实现在 UI 层和 Platform 层传递消息从而达到特定平台支持的，官方文档中也全方位介绍了在 Android 和 iOS 平台的具体实现方法及例子，Web 平台的实现却介绍的较少。总结起来，Web 平台和 Native 平台实现方式的不同主要集中在下面两点。

首先，Web Plugin 推荐的方式不是以其平台特有的 JS 语言实现，而是通过 Dart Library 或 Package 实现，对于已有现成可用的 JS SDK 或需要大量使用 JS 实现功能的情况下，官方提供了 package:js 包调用 Javascript，从而实现与 Javascript 的交互。

其次，Web Plugin 不是通过注册 MethodChannel 传递消息的，Flutter 内部可直接调用通过官方指定形式 (Federated Plugin) 编写的 Flutter Web Plugin 类。

下图完整的展示了一个 Plugin 的整体架构：

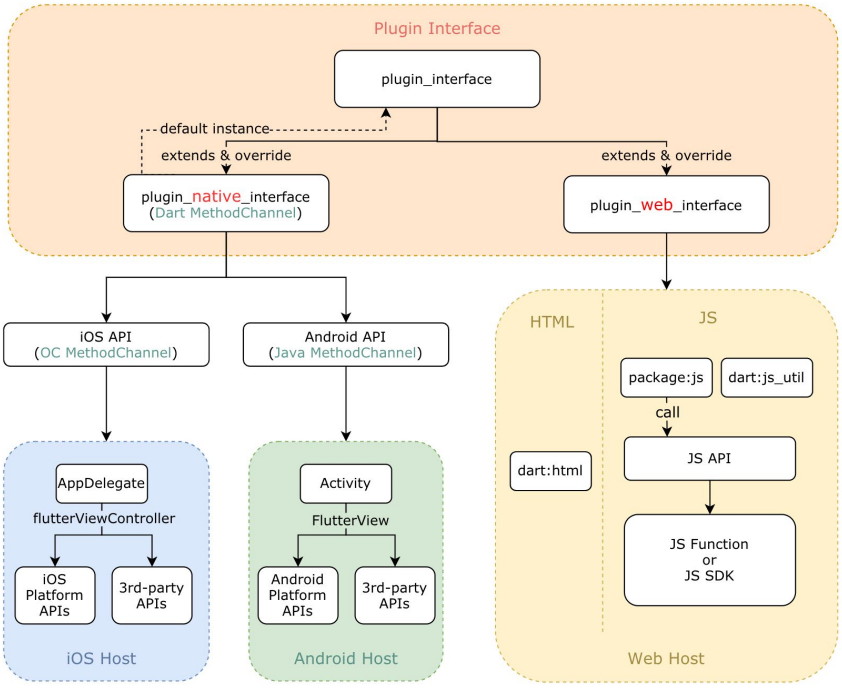

Flutter Plugin 架构图

4.1.2 基础依赖建设

整体来讲，MTFlutter 基础依赖都是使用 Plugin 的形式开发维护的。为处理依赖中的公共逻辑，提高 Plugin 的可扩展性，MTFlutter Plugin 在 Flutter Plugin 架构（各平台原生实现层和 Plugin Interface 层）之上又增加了公共逻辑处理层，最终暴露给用户是 Plugin API 层提供的接口。MTFlutter Plugin 架构图如下：

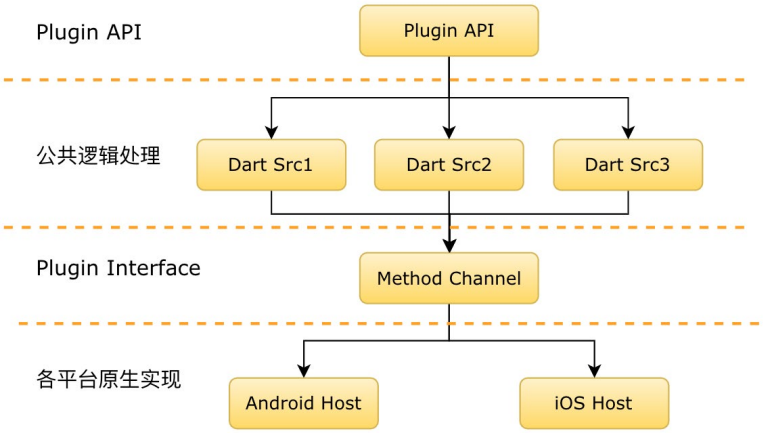

MTFlutter Plugin 架构图

在细节实现上，由于项目中各种依赖的类型之间存在着差异，因此在依赖处理上也略有不同，下面介绍拥有不同特点的依赖所对应解决方案。

(1) 各平台实现能在 Web 侧对齐的场景，如埋点库

埋点库无论在 Native 端还是在 Web 端都是使用公司统一提供的 SDK，在 API 设计上具有天然的一致性，因此我们完全有能力在 Plugin Interface 层对齐所有接口，上层业务逻辑只需按需做些兼容处理即可。埋点库 Web 端扩展的整体设计思路如下：

- 在业务项目的 web/index.html 文件中直接引入 Script 脚本并且进行初始化（注意：引入 Script 的位置，需要放在 main.dart.js 前面）。
- 借助 package:js 库调用埋点 JS SDK，对齐 Flutter 埋点库的 API ，实现 Flutter Plugin 的 Web 端支持，详细架构图如下图所示：

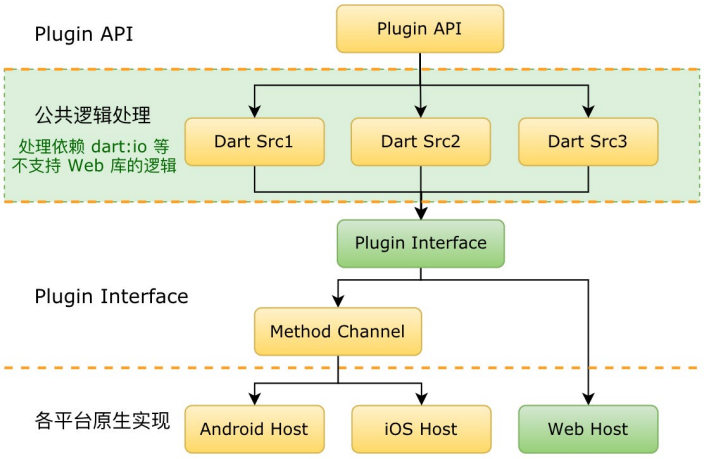

埋点库架构图

（2）各平台实现在 Web 侧无法对齐的场景，如路由库

MTFlutter 路由库是 Native 底层维护的一套全新的路由体系，依靠原生支持提供了强大的定制化功能，而在 Web 端无法这些无法在各平台原生实现层达到 100% 支持。由于 MTFlutter Plugin 最终暴露的是 Plugin API，因此我们选择直接对齐 Plugin API 实现路由库在 Web 端的支持（借助 Flutter Navigator、dart:html 用纯 Dart 语言完成了扩展），详细架构如下图所示：

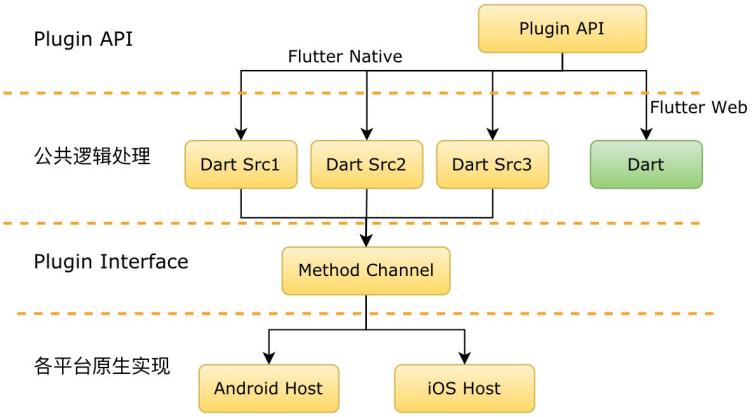

路由库架构图

（3）Web 端需要通过大量 JS 实现功能的依赖库，如请求库

由于在现有的 Web 请求中统一封装着大量的业务处理逻辑（如拦截器、异常上报等），如果用 Dart 重新实现一遍，成本还是较高的。想复用原有基于 Axios（ JS 请求库）封装的请求库就相当于让 Plugin 的 Web 平台实现使用 JS 语言。Dart 和 JS 交互是通过 package:js 进行接口调用，因此我们在公共逻辑处理层用 Dart 对齐了相应的 API，详细架构图如下图所示：

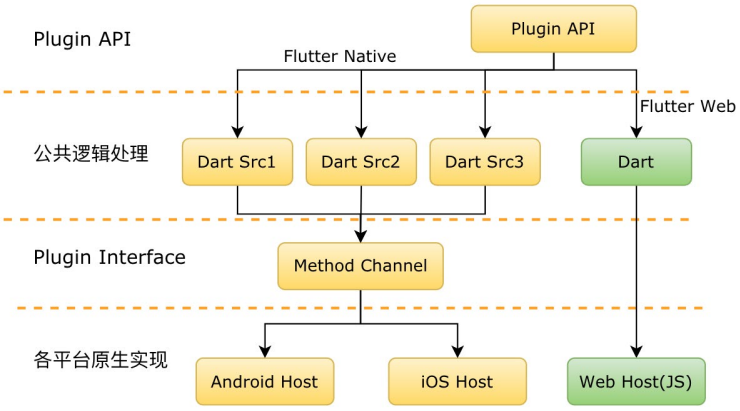

请求库架构图

4.2 性能优化

常规的 Web 项目中，为了保证页面有更好的加载和渲染性能，在静态资源文件的处理方面，我们需要做很多的工作，例如：资源文件 Hash 化、CDN 化、按需加载处理等，这些可以通过 Webpack、Rollup 等构建工具进行预处理。但在 Flutter Web 中，这些预处理的操作目前官方还不支持，原因是 Flutter 暴露给我们的命令只有一个 `flutter build web`，导致我们无法直接进行更细粒度的个性化定制。如果想要让 Flutter Web 达到企业级应用的标准，我们需要更深层次的探索 Flutter SDK 的运行原理。下面我们列出目前遇到的性能问题及其解决方案。

4.2.1 目前存在的性能问题

Google 官方对 Flutter Web 性能优化所做的事项还比较少，编译输出的页面存在较

大的性能问题，主要体现在以下两方面：

- **首屏渲染时间长**。即使使用了 FutureBuilder 把业务代码拆分成 xxx.part.js 之后，main.dart.js 体积依然维持在 1.1M。单一文件加载、解析时间过长，且静态资源缺少 CDN 化的支持，势必会影响首屏的渲染时间。
- **滚动性能较差**。 Flutter Web 自身实现了一套页面滚动机制，在页面滚动过程中，会频繁的创建 Canvas，最终导致滚动性能问题，甚至引起页面 Crash。

通过下图对浏览器网络监控情况的展示，可以清晰的反映出以上问题：

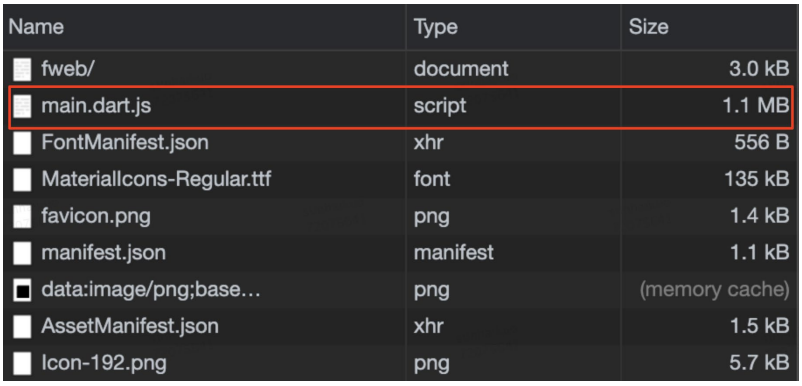

浏览器网络监控

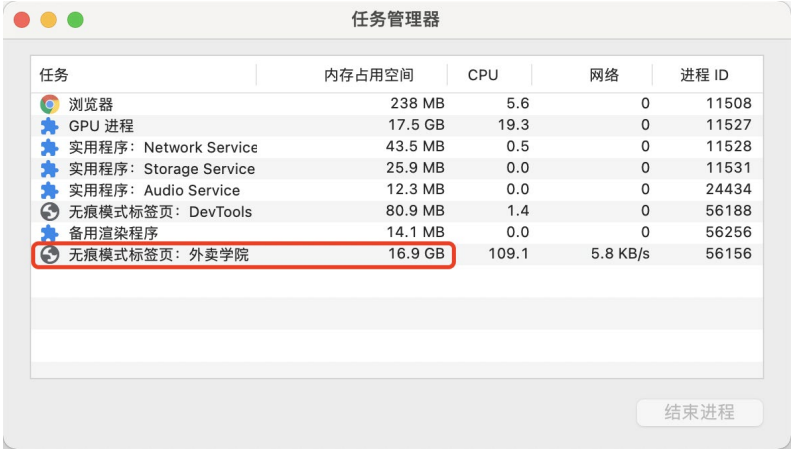

页面滚动过程中，内存的占用情况

为了解决上述的性能问题，我们探索了 Flutter SDK 编译过程，总结出从 Flutter 业务代码到 Web 产物的整体流程，详细流程如下图所示：

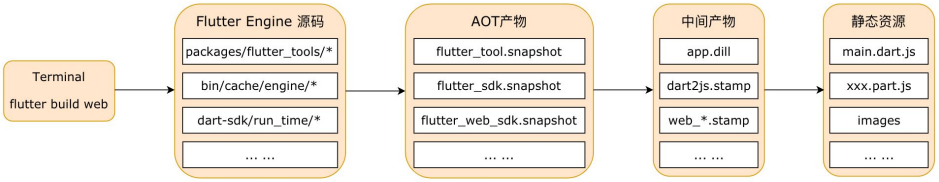

编译流程

从流程中我们可以看到，Flutter 在 Web 端目前只支持 Dart->JS 的转换，以及 UI 层的对齐，在工程化和性能优化方面做的工作并不多。

因此，我们必须解决以上的性能问题，才能保证我们的业务可以正常的交付。通过对编译流程的仔细分析与梳理，我们在 AOT 产物生成之前对 Flutter SDK 进行定制，分别进行**加载性能优化**和**内存性能优化**，下面分别介绍这两部分的内容。

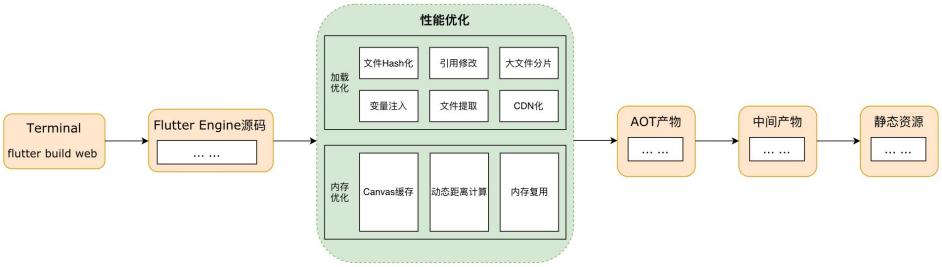

Flutter SDK 进行定制后的流程

4.2.2 加载性能优化

运行 `flutter build web` 命令之后，我们得到的主要静态资源有：主文件 main.dart.js（1.1M），各页面的业务代码 xxx.part.js（使用 FutureBuilder 后）、图片文件。直接应用这些资源到项目中，会遇到以下问题：

- **功能无法及时更新**：浏览器对同名文件的缓存，可能导致程序代码不被及时更新或者出现执行错乱。

- **首屏渲染性能差**：main.dart.js 文件过大，单一文件加载、解析时间过长，势必会影响首屏的渲染时间。
- **无法使用 CDN**：Flutter 仅支持相对路径的加载方式，无法使用当前域名以外的 CDN 域名，导致无法享受 CDN 带来的优势。

为此，在加载部分我们对 Flutter SDK 增加了如下三方面的优化，以达到线上运行的标准，优化步骤如下图所示：

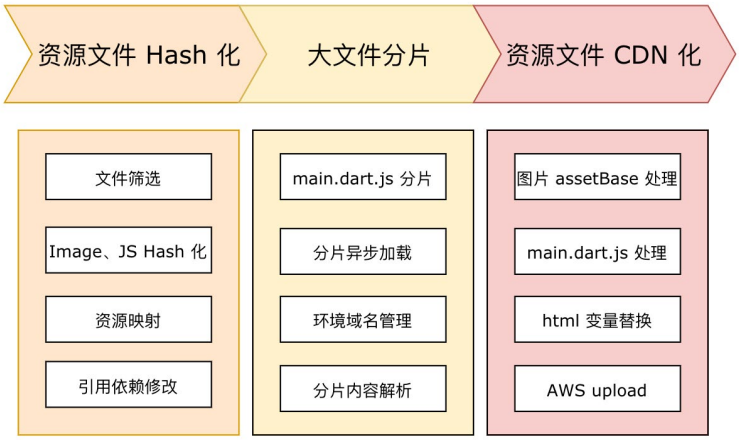

优化步骤

资源文件 Hash 化

除了 web/index.html 文件之外，我们要对所有的引用到文件进行 Hash 化。对 build_system/web.dart 的修改按以下步骤进行：

- 遍历产物目录，并建立 ResourceMap。
- 分别计算每个文件的 Hash 值。
- 为新文件命名为 name-[hash].xxx。
- 修改新文件名在对应文件中的引用关系。

大文件分片

Flutter Web 编译之后会生成 main.dart.js 这一主文件，体积为 1.1M（ Gzip 之后

约 400K ），这给页面的加载性能带来很大的影响。为此，我们对代码进行分片，借助浏览器对多文件并行加载的特性，可以有效提升页面的加载性能。

具体实施步骤是：将 `main.dart.js` 在 Dart 侧拆分成多份纯文本文件，前端通过 XHR 的方式并行加载并按顺序拼接成 Javascript 代码置于 <script> 标签中，从而实现分片文件的并行加载。

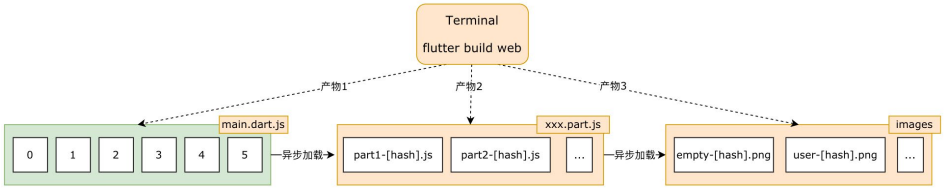

Hash 化以及分片之后，静态资源的引用关系

资源文件 CDN 化

由于 Flutter Web 资源引用机制的不同，即使在资源文件 Hash 化的过程中，把文件的相对路径替换成带 CDN 域名的绝对路径，也无法实现 CDN 资源的加载。同时本地测试发现图片和 Javascript 资源的加载逻辑还不尽相同，为此针对各自的加载逻辑要分别进行优化。

- **图片处理**：经过对源码的大量阅读及梳理，我们发现图片请求的 URL 首先会读取 `meta` 标签中 `assetBase` 值进行 URL 路径拼接，根据拼接好的 URL 来获取资源。目前，在项目 `web/index.html` 模板文件中并没有 `meta` 标签，于是就会根据相对路径进行请求。解决方案是在编译过程中，根据请求环境增加 `meta` 标签并把 `content` 设置为 CDN 路径。
- **JavaScript 处理**：为了解决图片资源文件的加载问题，我们虽然增加了 `assetBase` 的 `meta` 标签，但发现 `xxx.part.js` 文件依然使用当前域名进行加载，可见 Javascript 资源的加载和图片资源加载的逻辑不尽相同。对 `main.dart.js` 源码分析，我们发现请求 `xxx.part.js` 的域名取决于包含 `main.dart.js` 内容的 `Script` 标签的 `src` 属性。通过对 `js_helper.`

dart 的动态编译，我们把读取 src 属性修改为读取 window.assetBase 这一全局变量（meta 标签中 assetBase 值加工后的变量）来实现 xxx.part.js 文件的 CDN 加载。

4.2.3 滚动性能优化

当页面出现可滚动区域时，每次页面滚动会创建大量的 Canvas。使用 Safari 的 Canvas 分析工具，我们发现问题的根本原因是页面滚动的过程中，Flutter 会频繁的创建滚动区域的 Canvas，每次创建的 Canvas 内存都在 10 ~ 70M 不等，滚动的内容越多，内存的占用就会越大，这样滚动几帧之后，内存的占用就会超过浏览器的阈值。

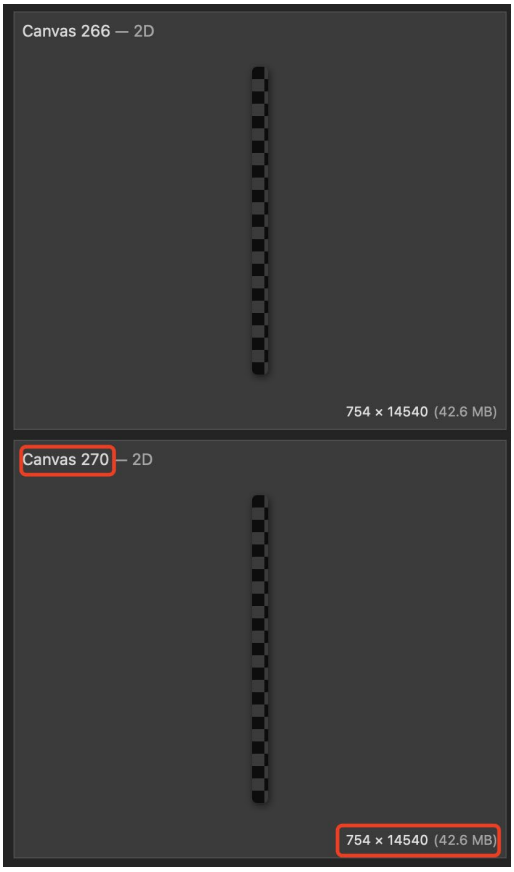

Safari 图形工具中展示 Canvas 的占用

Flutter 对 Canvas 的管理有一个 ReusablePool 的概念，在初始过程中会创建一定的数量的 Canvas，页面交互过程中没有变化的部分，会优先使用 pool 中已经缓存过的 Canvas 以便能够节省内存。由于 Flutter Web 自身实现了一套页面滚动机制，页面滚动过程中，会频繁计算位置信息，引起滚动区域内容被重新创建，这就是为什么每次滚动都会创建 Canvas 的原因。

我们设计的解决方案是：修改 FlutterSDK，在滚动的过程中定义一个阈值，当滚动的高度在阈值范围内，我们就会把当前的 Canvas 缓存起来。这样选择性的创建和销毁 Canvas 可以有效的缓解内存压力，从而提升页面滚动性能。

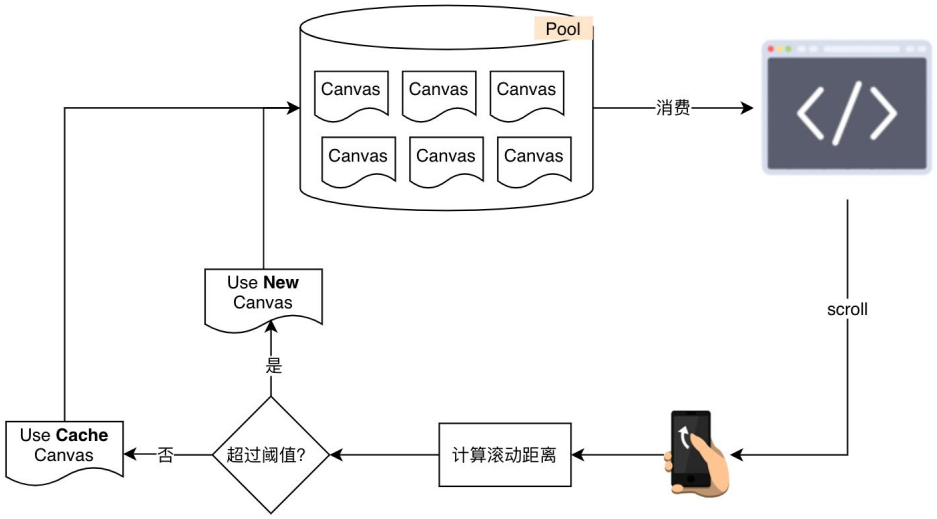

优化之后浏览器创建和销毁 Canvas 的过程

4.3 构建与部署

4.3.1 Docker 镜像定制

由于 MTFlutter Web 环境安装步骤较固定，且整个安装过程耗时较长（> 80s）。因此将其定制为 Docker 镜像并集成至 Talos，Flutter Web 编译阶段便能免去安装流程，有效提升构建效率。Docker 镜像定制和发布的详细流程见官方文档，本文不再赘述。其中用于定制 Flutter Web 镜像的 Dockerfile 文件如下：

```
FROM $BaseImage \# 继承基础镜像
RUN apt-get update
RUN apt-get install rubygems -y
RUN gem install flutter-cli
RUN flutter-cli install
ENV PATH="/$User/.flutter_sdk/bin:${PATH}"
ENV PUB\_HOSTED\_URL="https://xxx.com" \# 私有 pub 服务
ENV FLUTTER\_STORAGE\_BASE_URL="https://storage.flutter-io.cn"
RUN ~/.flutter_sdk/bin/flutter config --enable-web
```

4.3.2 持续交付与部署

为了实现持续交付与部署，我们建立起了 Flutter Web 在 Talos（美团内部前端持续交付解决方案）中的发布流水线：

Talos 发布流水线

可以看到，流水线中已经免去了 MTFlutter Web 环境的安装流程，现有流水线中重要节点介绍如下：

- Flutter-Web-Build 利用 Docker 内置的 MTFlutter 进行 Web 编译。
- Flutter-Web-Publish 负责将编译产物上传美团资源存储服务器。

五、成果展示

5.1 效果展示

我们在美团外卖商家学院（一个以文章、视频等形式帮助商家学习外卖运营知识、了解行业发展和平台策略的平台，它有很强的传播属性，具有外部投放的场景）率先落地了 Flutter Web，现以商家学院视频内容页为例，对比 Flutter Native 和 Flutter Web 的展现效果：

Flutter Native

Flutter Web

可以看出，两者的交互、视觉体验是高度一致的，既保证了业务在 App 内接近 Native 的体验，又极大提高了 Web 与 Flutter Native 的体验一致性。

5.2 页面加载性能

如前文所述，我们实施了一系列针对 Flutter Web 的资源优化手段，使得页面加载性能有较大提升，其中页面完全加载时间大致由 **1300ms（TP50）**降到了 **580ms（TP50）**，更多的性能指标数据见下图：

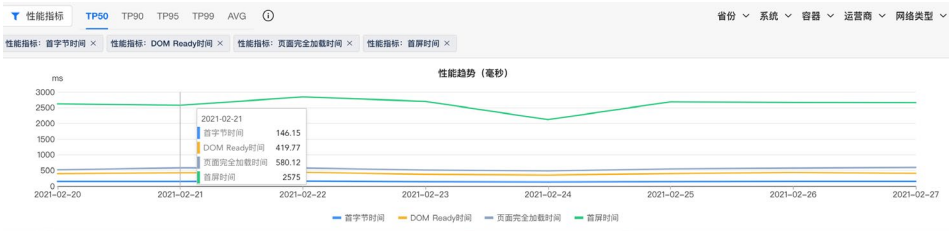

某 7 日性能趋势图

可以看到 Flutter Web 与现有 Web 项目性能指标数据差距已不大，可满足日常业务要求。但加载性能数据仍有较大的优化空间，我们会持续对其进行探索。

5.3 滚动性能

针对滚动优化，我们通过修改 Flutter SDK，使得 Canvas 在页面滚动时无需重复创建，而是被缓存起来。这样大大节省了内存的开销（优化后页面内存占用稳定为 100M 左右，与常规 Web 页面无异），同时在一定程度上提升了滚动性能。以商家学院文章内容页为例，对比优化前后滚动 FPS ：

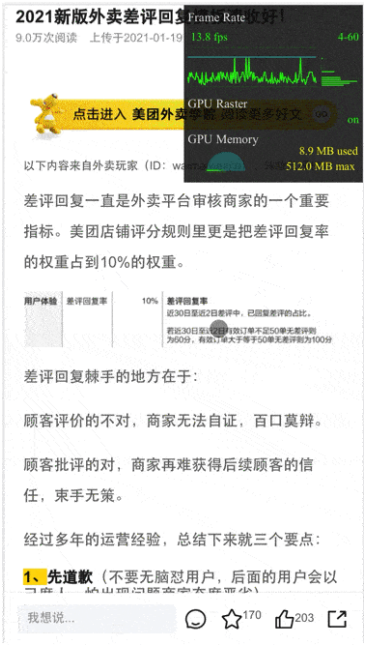

优化前 FPS

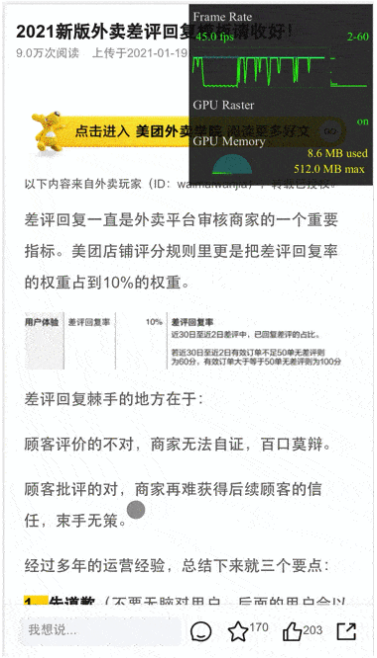

优化后 FPS

可以看到，Flutter Web 页面滚动性能已得到较大提升，足以应对大部分业务场景。但由于 Flutter Web 页面滚动过程中会频繁进行位置信息的计算，在复杂的业务场景（如页面存在大量动画）仍然会暴露出一定的问题。因此对滚动性能的进一步优化也会是我们未来的工作重心。

5.4 业务迭代效率

基于团队对 Flutter Web 工程化能力的建设和 Flutter 良好的跨平台特性，Flutter Web 在美团外卖商家学院改版需求的落地，大大提升了迭代效率，估算人效提升 40% 以上，计算公式为：

$$E = (1 - (1 / Np)) - Ci$$

其中 E 代表人效提升，Ci 指的是兼容和适配所耗费的时间，Np 表示业务跨端数量，目前美团外卖商家学院在 Native 和 H5 两端完成了复用，后续在 PC 侧需求的对齐中，效率提升数值会被放大，预计人效提升达 60% 以上。同时我们将在更多的业务中进行推广与应用，提升整体业务的迭代效率。

六、总结与展望

综上所述，美团外卖商家端多元的业务形态和足够的技术“储备”，使得基于 Flutter 实现多端复用成为了可能。而 Flutter Web 在美团外卖商家学院业务中也取得了阶段性的成果，实现了 App、H5 侧的体验一致性，为后续推动更多业务线实现 App-Web 一体化打下了坚实的基础。

可以预见的是，基于 Flutter Web 实现的多端复用，势必会有效缩短项目交付周期。但由于我们对页面加载性能、滚动性能做的仍不够完美，不足以应对更加复杂的业务场景，因此我们依然还有许多工作：

- **页面滚动性能优化**：由于 Flutter 与 Web 的布局差异，使得 dart:ui（Web）也受 Flutter Native 的布局约束，如何打破这样的约束，是解决滚动性能问题的关键。

- **页面加载性能优化**：当前的页面加载性能仍有较大优化空间，需要对 Flutter 进行编译干预与优化（如按需分离 main.dart.js），减小资源包大小，有效提升页面加载性能。
- **Flutter Web 基建**：完善并优化开发、调试、编译、构建、部署链路，使得新老项目能快速接入 Flutter Web。
- **Flutter Web 在 PC 侧的复用**：与 UED 团队共同制订 PC 与 App 适配规范，同时基于 Dart2js 和 dart:ui（Web）的强大能力，实现逻辑的抽象，完成组件、模块的适配，达到提效最大化；
- **跟进 Flutter 官方动向**：Flutter 2.0 的发布，稳定了对 Web 的支持，同时默认采用 Canvaskit 编译模式，此模式下对页面滚动性能有较大提升。但由于 canvaskit.wasm 文件过于庞大（2.5M），降低了加载性能，因此目前仍不建议在 Web 侧直接使用 Canvaskit。不过官方承诺会在 2021 年对性能进行整体优化，还是值得期待的，我们也将保持跟进和沟通。

我们会持续基于 Flutter Web 做更多的探索和尝试。如果您对 Flutter Web 也感兴趣，欢迎大家在文末评论区留言或者给出建议，非常感谢。

版权声明

本文系美团技术团队出品，著作权归属美团，未经允许，请勿转载或者用于其他商业用途。如用作公益用途，请务必注明：内容转载自美团技术团队。任何商用行为，请发送邮件至 tech@meituan.com 申请授权。

FlutterWeb 性能优化探索与实践

作者：典胜　海阔　徐亮

一、背景

1.1 关于 FlutterWeb

时间回拨到 2018 年，Google 首次公开 FlutterWeb Beta 版，表露出要实现一份代码、多端运行的愿景。经过无数工程师两年多的努力，在今年年初（2021 年 3 月份），Flutter 2.0 正式对外发布，它将 FlutterWeb 功能并入了 Stable Channel，意味着 Google 更加坚定了多端复用的决心。

图 1　FlutterWeb 历史

当然 Google 的“野心”不是没有底气的，主要体现在它强大的跨端能力上，我们看一下 Flutter 的跨端能力在 Web 侧是如何体现的：

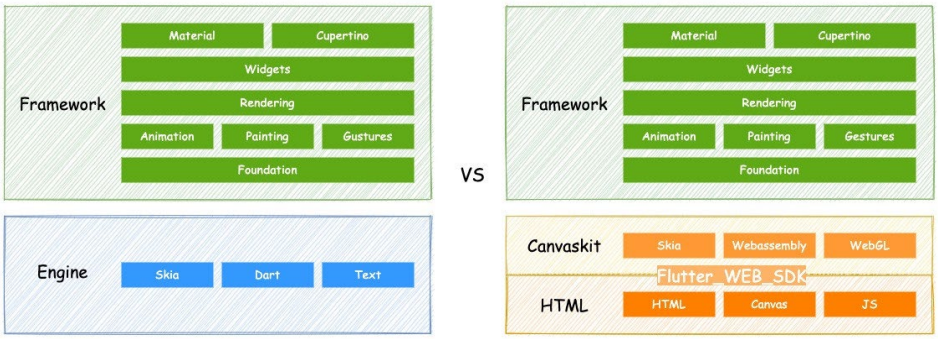

图 2　Flutter 跨端能力

上图分别是 FlutterNative 和 FlutterWeb 的架构图。通过对比可以看出，应用层

Framework 是公用的，意味着在 FlutterWeb 中我们也可以直接使用 Widgets、Gestures 等组件来实现逻辑跨端。而关于渲染跨端，FlutterWeb 提供了两种模式来对齐 Engine 层的渲染能力：Canvaskit Render 和 HTML Render，下方表格对两者的区别进行了对比：

模式	加载性能	滚动性能	兼容性
CanvasKit Render	**加载性能差**，初始包大小约为 2.5M（主要为 wasm 文件），优化空间小	**滚动性能较好**	**兼容性差**，使用 WebAssembly + WebGL 对齐渲染能力
HTML Render	**加载性能一般**，初始包大小约为 1.2M，优化空间大	**滚动性能一般**，在复杂动画、图表场景下稍显吃力	**兼容性优秀**，使用 HTML + Canvas 对齐渲染能力

图 3　模式对比

Canvaskit Render 模式：底层基于 Skia 的 WebAssembly 版本，而上层使用 WebGL 进行渲染，因此能较好地保证一致性和滚动性能，但糟糕的兼容性（WebAssembly 从 Chrome 57 版本才开始支持）是我们需要面对的问题。此外 Skia 的 WebAssembly 文件大小达到了 2.5M，且 Skia 自绘引擎需要字体库支持，这意味着需要依赖超大的中文字体文件，对页面加载性能影响较大，因此目前并不推荐在 Web 中直接使用 Canvaskit Render（官方也建议将 Canvaskit Render 模式用于桌面应用）。

HTML Render 模式：利用 HTML + Canvas 对齐了 Engine 层的渲染能力，因此兼容性表现优秀。另外，MTFlutterWeb 对滚动性能已有过探索和实践，目前能够应对大部分业务场景。而关于加载性能，此模式下的初始包为 1.2M，是 Canvaskit Render 模式产物体积的 1/2，且我们可对编译流程进行干预，控制输出产物，因此优化空间较大。

基于以上原因，美团外卖技术团队选择在 HTML Render 模式下对 FlutterWeb 页面的性能进行优化探索。

1.2 业务现状

美团外卖商家端以 App、PC 等多元化的形态为商家提供了订单管理、商品维护、顾客评价、外卖课堂等一系列服务，且 App、PC 双端业务功能基本对齐。此外，我们还在 PC 上特供了针对连锁商家的多店管理功能。同时，为满足平台运营诉求，部分业务具有外投 H5 场景，例如美团外卖商家课堂，它是一个以文章、视频等形式帮助商家学习外卖运营知识、了解行业发展和跟进经营策略的内容平台，具有较强的传播属性，因此我们提供了站外分享的能力。

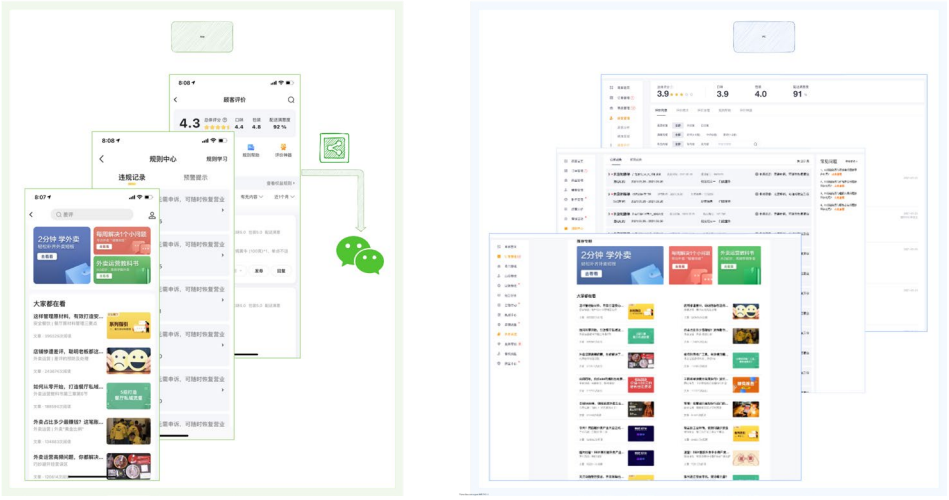

图 4　业务形态

为了实现多端（App、PC、H5）复用，提升研发效率，我们于 2021 年年初开始着手 MTFlutterWeb 研发体系的建设。目前，我们基于 MTFlutterWeb 完成提效的业务超过了 9 个，在 App 中，能够基于 FlutterNative 提供高性能的服务；在 PC 端和 Mobile 浏览器中，利用 FlutterWeb 做到了低成本适配，提升了产研的整体效率。

然而，加载性能问题是 MTFlutterWeb 应用推广的最大障碍。这里依然以美团外卖商家课堂业务为例，在项目之初页面完全加载时间 TP90 线达到了 6s 左右，距离我们的指标基线值（页面完全加载时间 TP90 线不高于 3s，基线值主要依据美团外卖商家端的业务场景、用户画像等来确定）有些差距，用户访问体验有很大的提升空间，

因此 FlutterWeb 页面加载性能优化，是我们亟需解决的问题。

二、挑战

不过，想要突破 FlutterWeb 页面加载的性能瓶颈，我们面临的挑战也是巨大的。这主要体现在 FlutterWeb 缺失静态资源的优化策略，以及复杂的架构设计和编译流程。下图展示了 Flutter 业务代码被转换成 Web 平台产物的流程，我们来具体进行分析：

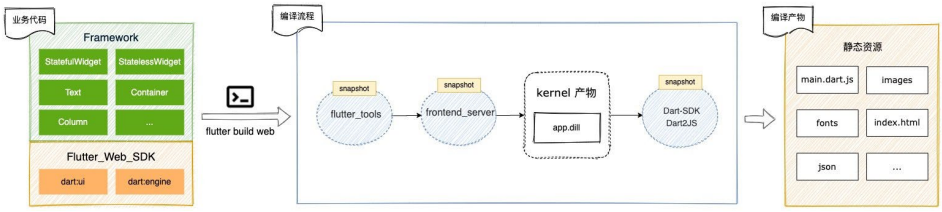

图 5　FlutterWeb 编译流程

- **Framework、Flutter_Web_SDK**（Flutter_Web_SDK 基于 HTML、Canvas，承载 HTML Render 模式的具体实现）等底层 SDK 是可被业务代码直接引入的，帮助我们快速开发出跨端应用；
- **flutter_tools** 是各平台（Android、iOS、Web）的编译入口，它接收 flutter build web 命令和参数并开始编译流程，同时等待处理结果回调，在回调中我们可对编译产物进行二次加工；
- **frontend_server** 负责将 Dart 转换为 AST，生成 kernel 中间产物 app.dill 文件（实际上各平台的编译过程都会生成这样的中间产物），并交由各平台 Compiler 进行转译；
- **Dart2JS Compiler** 是 Dart-SDK 中具体负责转译 JS 的模块，它将上述中间产物 app.dill 进行读取和解析，并注入 Math、List、Map 等 JS 工具方法，最终生产出 Web 平台所能执行的 JS 文件。
- **编译产物**主要为 main.dart.js、index.html、images 等静态资源，Flutter-Web 对这些静态资源缺少常规 Web 项目中的优化手段，例如：文件 Hash 化、文件分片、CDN 支持等。

可以看出，要完成对 FlutterWeb 编译产物的优化，就需要干预 FlutterWeb 的众多编译模块。而为了提升整体的编译效率，大部分模块都被提前编译成了 snapshot 文件（一种 Dart 的编译产物，可被 Dart VM 所运行，用于提升执行效率），例如：flutter_tools.snapshot、frontend_server.snapshot、dart2js.snapshot 等，这又加大了对 FlutterWeb 编译流程进行干预的难度。

三、整体设计

如前文所述，为了实现逻辑、渲染跨平台，Flutter 的架构设计及编译流程都具有一定的复杂性。但由于各平台（Android、iOS、Web）的具体实现是解耦的，因此我们的思路是定位各模块（Dart-SDK、Framework、Flutter_Web_SDK、flutter_tools）的 Web 平台实现并寻求优化，整体设计图如下所示：

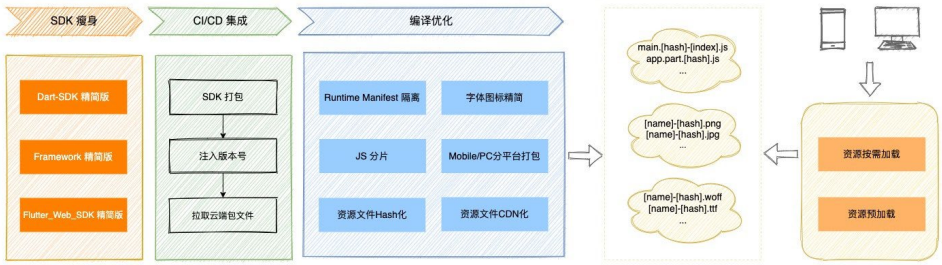

图 6　整体设计

- **SDK 瘦身**：我们分别对 FlutterWeb 所依赖的 Dart-SDK、Framework、Flutter_Web_SDK 进行了瘦身，并将这些精简版 SDK 集成合入 CI/CD（持续集成与部署）系统，为减小产物包体积奠定了基础；
- **编译优化**：此外，我们在 flutter_tools 中的编译流程做了干预，分别进行了 JS 文件分片、静态资源 Hash 化、资源文件上传 CDN 等优化，使得这些在常规 Web 应用中基础的性能优化手段得以在 FlutterWeb 中落地。同时加强了 FlutterWeb 特殊场景下的资源优化，如：字体图标精简、Runtime Manifest 隔离、Mobile/PC 分平台打包等；
- **加载优化**：在编译阶段进行静态资源优化后，我们在前端运行时，支持了资源

预加载与按需加载，通过设定合理的加载时机，从而减小初始代码体积，提升页面首屏的渲染速度。

下面，我们分别对各项优化进行详细的说明。

四、设计与实践

4.1 精简 SDK

4.1.1 包体积分析

工欲善其事，必先利其器，在开始做体积裁剪之前，我们需要一套类似于 web-pack-bundle-analyzer 的包体积分析工具，便于直观地比较各个模块的体积占比，为优化性能提供帮助。

Dart2JS 官方提供了 --dump-info 命令选项来分析 JS 产物，但其表现差强人意，它并不能很好地分析各个模块的体积占比。这里更推荐使用 source-map-explorer，它的原理是通过 sourcemap 文件进行反解，能清晰地反映出每个模块的占用大小，为 SDK 的精简提供了指引。下图展示了 FlutterWeb JS 产物的反解信息（截图仅包含 Framework 和 Flutter_Web_SDK）：

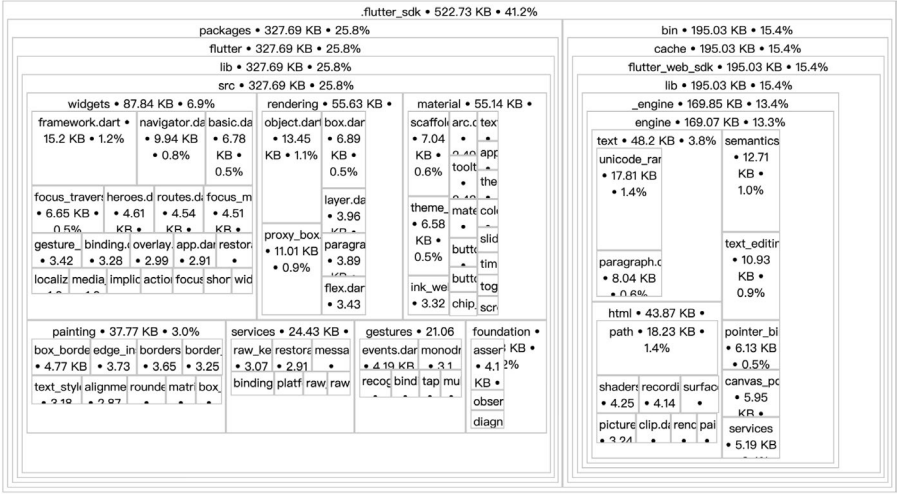

图 7　反解信息

4.1.2 SDK 裁剪

FlutterWeb 依赖的 SDK 主要包括 Dart-SDK、Framework 和 Flutter_Web_SDK，这些 SDK 对包体积的影响是巨大的，几乎贡献了初始化包的所有大小。虽然在 Release 模式下的编译流程中，Dart Compiler 会利用 Tree-Shaking 来剔除那些引入但未使用的 packages、classes、functions 等，很大程度上减少了包体积。但这些 SDK 中仍然存在一些能被进一步优化的代码。

以 Flutter Framework 为例，由于它是全平台公用的模块，因此不可避免地存在各平台的兼容逻辑（通常以 if-else、switch 等条件判断形式出现），而这部分代码是不能被 Tree-Shaking 剔除的，我们观察如下的代码：

```
// FileName: flutter/lib/src/rendering/editable.dart
void _handleKeyEvent(RawKeyEvent keyEvent) {
  if (kIsWeb) {
    // On web platform, we should ignore the key.
    return;
  }
  // Other codes ...
}
```

上述代码选自 Framework 中的 RenderEditable 类，当 kIsWeb 变量为真，表示当前应用运行在 Web 平台。受限于 Tree-Shaking 的机制原理，上述代码中，其它平台的兼容逻辑即注释 Other codes 的部分是无法被剔除的，但这部分代码，对 Web 平台来说却是 Dead Code（永远不可能被执行到的代码），是可以被进一步优化的。

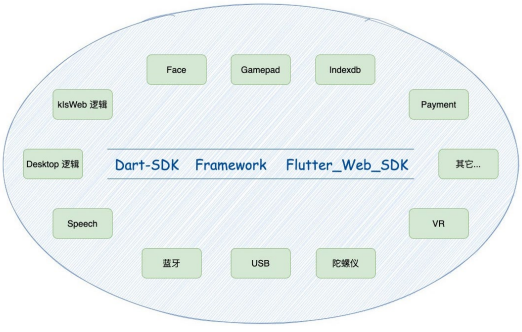

图 8　部分功能构成

上图展示了 SDK 的一部分功能构成，从图中可以看出，FlutterWeb 依赖的这些 SDK 中包含了一些使用频率较低的功能，例如：蓝牙、USB、WebRTC、陀螺仪等功能的支持。为此，我们提供了对这些长尾功能的定制能力（这些功能默认不开启，但业务可配置），将未被启用长尾的功能进行裁剪。

通过上述分析可得，我们的思路就是对 Dead Code 进行二次剔除，以及对这些长尾功能做裁剪。基于这样的思路，我们深入 Dart-SDK、Framework 和 Flutter_Web_SDK 各个击破，最终将 JS Bundle 产物体积由 1.2M 精简至 0.7M，为 FlutterWeb 页面性能优化打下了坚实的基础。

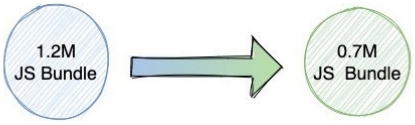

图 9　精简成果

4.1.3 SDK 集成 CI/CD

为了提升构建效率，我们将 FlutterWeb 依赖的环境定制为 Docker 镜像，集成入 CI/CD（持续集成与部署）系统。SDK 裁剪后，我们需要更新 Docker 镜像，整个过程耗时较长且不够灵活。因此，我们将 Dart-SDK、Framework、Flutter_Web_SDK 按版本打包传至云端，在编译开始前读取 CI/CD 环境变量：sdk_version（SDK 版本号），远程拉取相应版本的 SDK 包，并替换当前 Docker 环境中的对应模块，基于以此方案实现 SDK 的灵活发布，具体流程图如下图所示：

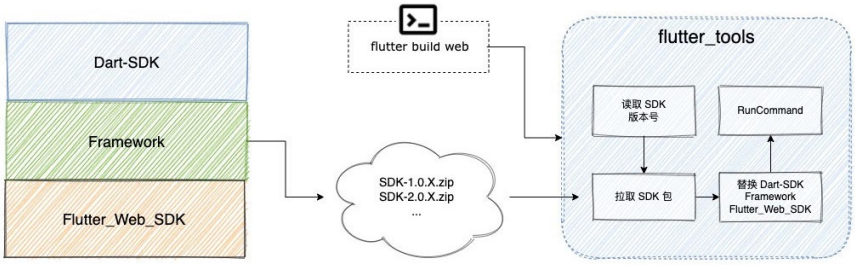

图 10　集成 CI/CD

4.2 JS 分片

FlutterWeb 编译之后默认会生成 main.dart.js 文件，它囊括了 SDK 代码以及业务逻辑，这样会引起以下问题：

- **功能无法及时更新**：为了实现浏览器的缓存优化，我们的项目开启了对静态资源的强缓存，若 main.dart.js 产物不支持 Hash 命名，可能导致程序代码不能被及时更新；
- **无法使用 CDN**：FlutterWeb 默认仅支持相对域名的资源加载方式，无法使用当前域名以外的 CDN 域名，导致无法享受 CDN 带来的优势；
- **首屏渲染性能不佳**：虽然我们进行了 SDK 瘦身，但 main.dart.js 文件依然维持在 0.7M 以上，单一文件加载、解析时间过长，势必会影响首屏的渲染时间。

针对文件 Hash 化和 CDN 加载的支持，我们在 flutter_tools 编译流程中对静态资源进行二次处理：遍历静态资源产物，增加文件 Hash（文件内容 MD5 值），并更新资源的引用；同时通过定制 Dart-SDK，修改了 main.dart.js、字体等静态资源的加载逻辑，使其支持 CDN 资源加载。

更详细的方案设计请参考《Flutter Web 在美团外卖的实践》一文。下面我们重点介绍 main.dart.js 分片相关的一些优化策略。

4.2.1 Lazy Loading

Flutter 官方提供 `deferred as` 关键字来实现 Widget 的懒加载，而 dart2js 在编译过程中可以将懒加载的 Widget 进行按需打包，这样的拆包机制叫做 Lazy Loading。借助 Lazy Loading，我们可以在路由表中使用 deferred 引入各个路由（页面），以此来达到业务代码拆离的目的，具体使用方法和效果如下所示：

```
// 使用方式
import 'pages/index/index.dart' deferred as IndexPageDefer;
{
  '/index': (context) => FutureBuilder(
    future: IndexPageDefer.loadLibrary(),
    builder: (context, snapshot) => IndexPageDefer.Demo(),
  )
  ... ...
}
```

Name	Status
main.dart.js	200
main.dart.js_3.part.js	200
main.dart.js_28.part.js	200
main.dart.js_10.part.js	200
main.dart.js_12.part.js	200
main.dart.js_66.part.js	200
main.dart.js_57.part.js	200
main.dart.js_59.part.js	200

图 11　效果演示

使用 Lazy Loading 后，业务页面的代码会被拆分到了多个 PartJS（对应图中 xxx.part.js 文件）中。这样看似解决了业务代码与 SDK 耦合的问题，但在实际操作过程中，我们发现每次业务代码的变动，仍然会导致编译后的 main.dart.js 随之发生变化（文件 Hash 值变化）。经过定位与跟踪，我们发现这个变化的部分是 PartJS 的加载逻辑和映射关系，我们称之为 Runtime Manifest。因此，需要设计一套方案对 Runtime Manifest 进行抽离，来保证业务代码的修改对 main.dart.js 的影响达到最低。

4.2.2 Runtime Manifest 抽离

通过对业务代码的抽离，此时 main.dart.js 文件的构成主要包含 SDK 和 Runtime Manifest：

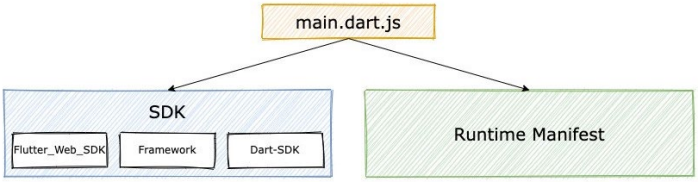

图 12　main.dart.js 构成

那如何能将 Runtime Manifest 进行抽离呢？对比常规 Web 项目，我们的处理方式是把 SDK、Utils、三方包等基础依赖，利用 Webpack、Rollup 等打包工具进行抽离并赋予一个稳定的 Hash 值。同时，将 Runtime Manifest（分片文件的加载

逻辑和映射关系）注入到 HTML 文件中，这样保证了业务代码的变动不会影响到公共包。借助常规 Web 项目的编译思路，我们深入分析了 FlutterWeb 中 Runtime Manifest 的生成逻辑和 PartJS 的加载逻辑，定制出如下的解决方案：

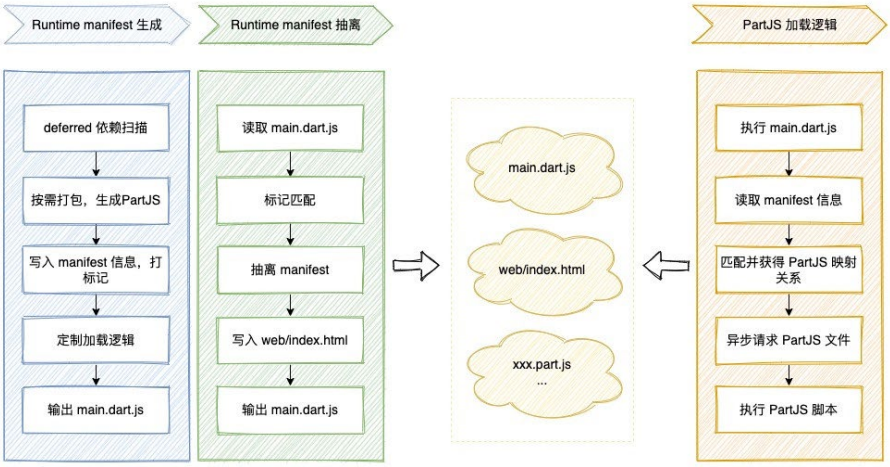

图 13　Runtime Manifest 抽离

在上图中，Runtime Manifest 的生成逻辑位于 Dart2JS Compiler 模块，在该生成逻辑中，我们对 Runtime Manifest 代码块进行了标记，之后在 flutter_tools 中将标记的 Runtime Manifest 代码块抽离并写入 HTML 文件中（以 JS 常量形式存在）。而在 PartJS 的加载流程中，我们将 manifest 信息的读取方式改为了 JS 常量的获取。按照这样的拆分方式，业务代码的变更只会改变 Runtime Manifest 信息，而不会影响到 main.dart.js 公共包。

4.2.3 main.dart.js 切片

经过以上引入 Lazy Loading、Runtime Manifest 抽离，main.dart.js 文件的体积稳定在 0.7M 左右，浏览器对大体积单文件的加载，会有很沉重的网络负担，所以我们设计了切片方案，充分地利用浏览器对多文件并行加载的特性，提升文件的加载效率。

具体实现方案为：将 main.dart.js 在 flutter_tools 编译过程拆分成多份纯文本文件，前端通过 XHR 的方式并行加载并按顺序拼接成 JavaScript 代码置于 < script > 标

签中，从而实现切片文件的并行加载。

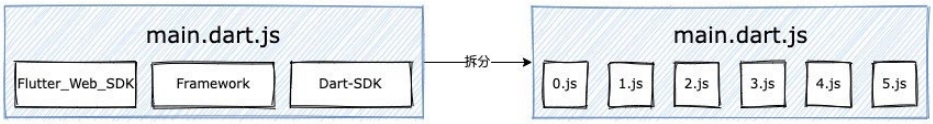

图 14　并行加载

4.3 预加载方案

如上一节所述，虽然我们做了很多工作来稳定 main.dart.js 的内容，但在 Flutter Tree-Shaking 的运行机制下，各个项目引用不同的 Framework Widget，就会导致每个项目生成的 main.dart.js 内容不一致。随着接入 FlutterWeb 的项目越来越多，每个业务的页面互访概率也越来越高，我们的期望是当访问 A 业务时，可以预先缓存 B 业务引用的 main.dart.js，这样当用户真正进入 B 业务时就可以节省加载资源的时间，下面为详细的技术方案。

4.3.1 技术方案

我们把整体的技术方案分为编译、监听、运行三个阶段。

- 编译阶段，在发布流水线上根据前期定制的匹配规则，筛选出符合条件的资源文件路径，生成云端 JSON 并上传；
- 监听阶段，在 DOMContentLoaded 之后，对网络资源、事件、DOM 变动进行监听，并对监听结果根据特定规则进行分析加权，得到一个首屏加载完成的状态标识；
- 运行阶段，在首屏加载完成之后对配置平台下发的云端 JSON 文件进行解析，对符合配置规则的资源进行 HTTP XHR 预加载，从而实现文件的预缓存功能。

下图为预缓存的整体方案设计：

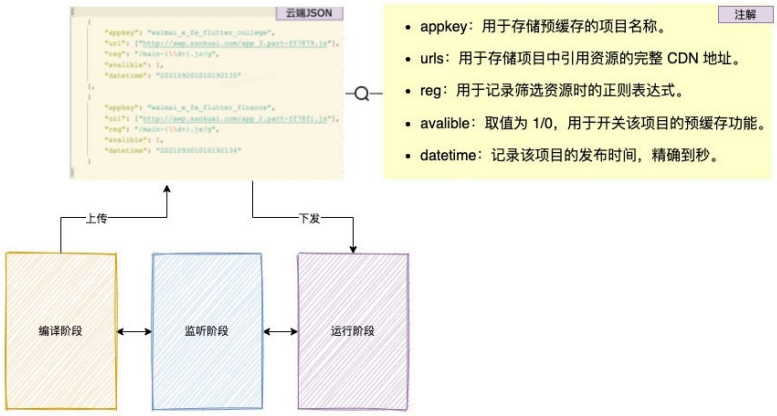

图 15　预缓存方案设计

编译阶段

编译阶段会扩展现有的发布流水线，在 flutter build 之后增加 prefetch build 作业，这样 build 之后就可以对产物目录进行遍历和筛选，得到我们所需资源进而生成云端 JSON，为运行阶段提供数据基础。下面的流程图为编译阶段的详细方案设计：

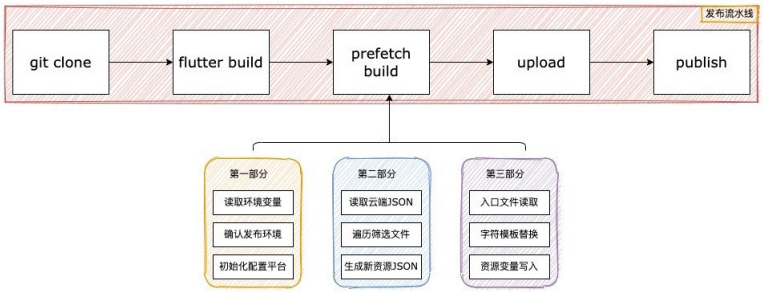

图 16　预缓存编译阶段

编译阶段分为三部分：

- 第一部分：根据不同的发布环境，初始化线上 / 线下的配置平台，为配置文件的读写做好准备；
- 第二部分：下载并解析配置平台下发的资源组 JSON，筛选出符合配置规则的资源路径，更新 JSON 文件并发布到配置平台；

- 第三部分：通过发布流水线提供的 API，把 PROJECT_ID、发布环境注入 HTML 文件中，为运行阶段提供全局变量以便读取。

通过对流水线编译期的整合，我们可以生成新的云端 JSON 并上传到云端，为运行阶段的下发提供数据基础。

监听阶段

我们知道，浏览器对文件请求的并发数量是有限制的，为了保证浏览器对当前页面的渲染处于高优先级，同时还能完成预缓存的功能，我们设计了一套对缓存文件的加载策略，在不影响当前页面加载的情况下，实现对缓存文件的加载操作。以下为详细的技术方案：

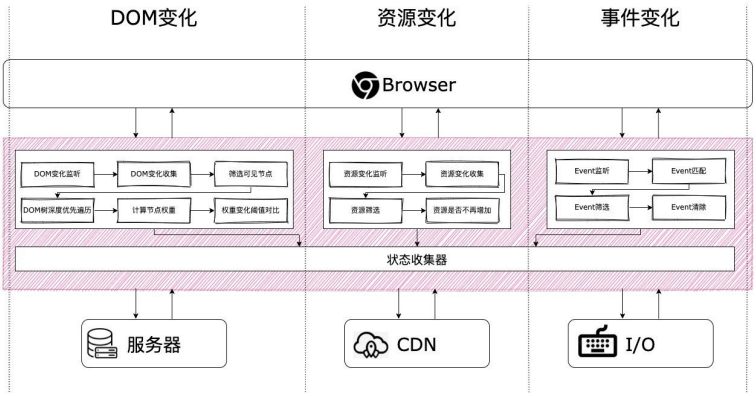

图 17　预缓存监听阶段

在页面 DOMContentLoaded 之后，我们会监听三部分的的变化。

- 第一部分是监听 DOM 的变化。这部分主要是在页面发生 Ajax 请求之后，随着 MV 模式的变动，DOM 也会随之发生变化。我们使用浏览器提供的 MutationObserver API 对 DOM 变化进行收集，并筛选有效节点进行深度优先遍历，计算每个 DOM 的递归权重值，低于阈值我们就认为首屏已加载完成。
- 第二部分是监听资源的变化。我们利用浏览提供的 PerformanceObserver API，筛选出 img/script 类型的资源，在 3 秒内收集的资源没有增加时，我们

认为首屏已加载完成。

- 第三部分是监听 Event 事件。当用户发生 click、wheel、touchmove 等交互行为时，我们就认为当前页面处于一个可交互的状态，即首屏加载已完成，这样会在后续进行资源的预缓存。

通过上述步骤，我们就可以得到一个首屏渲染完成的时机，之后就可以实现预缓存功能了。以下为预缓存功能的实现。

运行阶段

预缓存的整体流程为：下载编译阶段生成的云端 JSON，解析出需要进行预缓存资源的 CDN 路径，最后通过 HTTP XHR 进行缓存资源进行请求，利用浏览器本身的缓存策略，把其他业务的资源文件写入。当用户访问已命中缓存的页面时，资源已被提前加载，这样可以有效地减少首屏的加载时间。下图为运行阶段的详细方案设计：

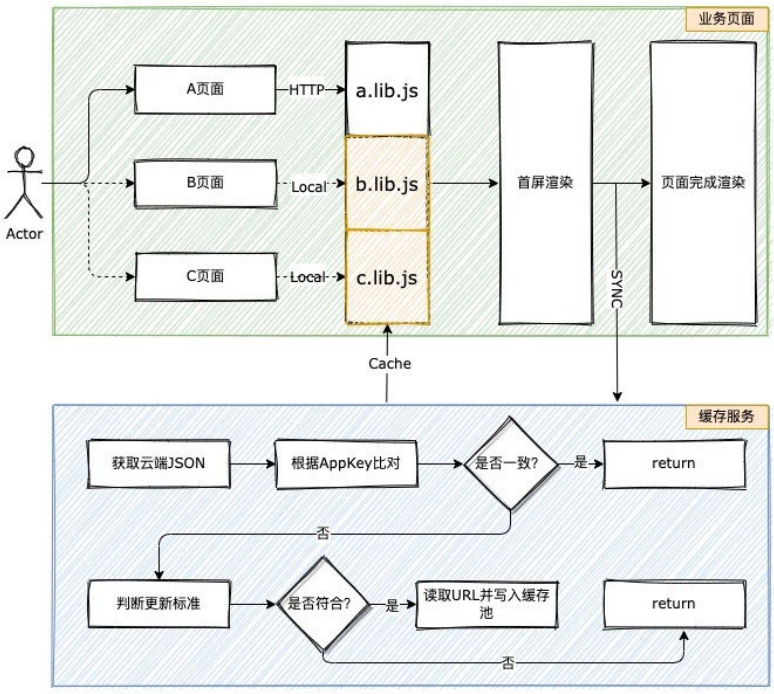

图 18　预缓存运行阶段

在监听阶段，我们可以获取到页面的首屏渲染完成的时机，会获取到云端 JSON，首先判断该项目的缓存是否为启用状态。当该项目可用时，会根据全局变量 PROJECT_ID 进行资源数组的匹配，再以 HTTP XHR 方式进行预访问，把缓存文件写入浏览器缓存池中。至此，资源预缓存已执行完毕。

4.3.2 效果展示与数据对比

当有页面间互访问命中预缓存时，浏览器会以 200（Disk Cache）的方式返回数据，这样就节省了大量资源加载的时间，下图为命中缓存后资源加载情况：

0.js	awp-assets.meituan.net	(disk cache)	7 ms
1.js	awp-assets.meituan.net	(disk cache)	11 ms
2.js	awp-assets.meituan.net	(disk cache)	17 ms
3.js	awp-assets.meituan.net	(disk cache)	16 ms
4.js	awp-assets.meituan.net	(disk cache)	16 ms
5.js	awp-assets.meituan.net	(disk cache)	15 ms

图 19　预缓存效果展示

目前，美团外卖商家端业务已有 10+ 个页面接入了预缓存功能，资源加载 90 线平均值由 400ms 下降到 350ms，降低了 12.5%；50 线平均值由 114ms 下降到 100ms，降低了 12%。随着项目接入接入越来越多，预缓存的效果也会越发的明显。

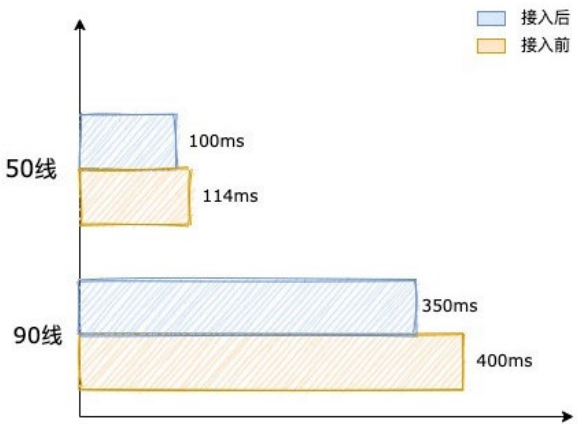

图 20　预缓存数据展示

4.4 分平台打包

如前文所述，美团外卖商家业务大部分都是双端对齐的。为了实现提效的最大化，我们对 FlutterWeb 的多平台适配能力进行加强，实现了 FlutterWeb 在 PC 侧的复用。

在 PC 适配过程中，我们不可避免地需要书写双端的兼容代码，如：为了实现在列表页面中对卡片组件的复用。为此我们开发了一个适配工具 ResponsiveSystem，分别传入 PC 和 App 的各端实现，内部会区分平台完成适配：

```
// ResponsiveSystem 使用举例
Container(
  child: ResponsiveSystem(
    app: AppWidget(),
    pc: PCWidget(),
  ),
)
```

上述代码能较方便的实现 PC 和 App 适配，但 AppWidget 或 PCWidget 在编译过程中都将无法被 Tree-Shaking 去除，因此会影响包体积大小。对此，我们将编译流程进行优化，设计分平台打包方案：

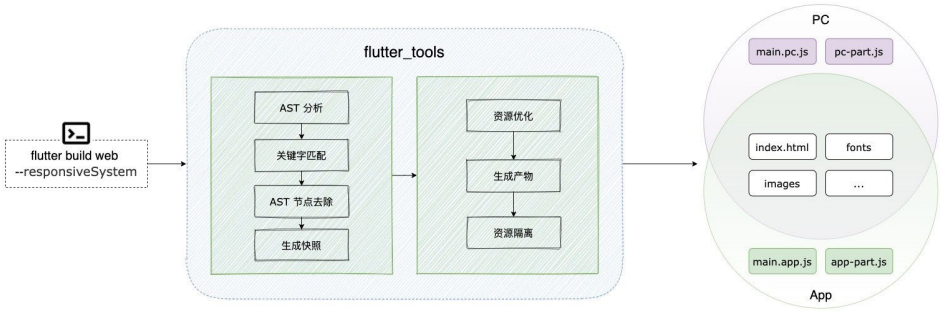

图 21　分平台打包

- 修改 flutter-cli，使其支持 –responsiveSystem 命令行参数；
- 我们在 flutter_tools 中的 AST 分析阶段增加了额外的处理：ResponsiveSystem 关键字的匹配，同时结合编译平台（PC 或 Mobile）来进行 AST 节点的改写；

- 去除无用 AST 节点后，生成各个平台的代码快照（每份快照仅包含单独平台代码）；
- 根据代码快照编译生成 PC 和 App 两套 JS 产物，并进行资源隔离。而对于 images、fonts 等公用资源，我们将其打入 common 目录。

通过这样的方式，我们去除了各自平台的无用代码，避免了 PC 适配过程中引起的包体积问题。依然以美团外卖商家课堂业务（6 个页面）为例，接入分平台打包后，单平台代码体积减小 100KB 左右。

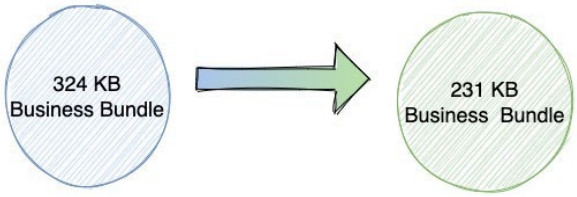

图 22　效果展示

4.5 图标字体精简

当访问 FlutterWeb 页面时，即使在业务代码中并未使用 Icon 图标，也会加载一个 920KB 的图标字体文件：MaterialIcons-Regular.woff。通过探究，我们发现是 Flutter Framework 中一些系统 UI 组件（如：CalendarDatePicker、PaginatedDataTable、PopupMenuButton 等）使用到了 Icon 图标导致，且 Flutter 为了便于开发者使用，提供了全量的 Icon 图标字体文件。

Flutter 官方提供的 `--tree-shake-icons` 命令选项是将业务使用到的 Icon 与 Flutter 内部维护的一个缩小版字体文件（大约 690KB）进行合并，能一定程度上减小字体文件大小。而我们需要的是只打包业务使用的 Icon，所以我们对官方 `tree-shake-icons` 进行了优化，设计了 Icon 的按需打包方案：

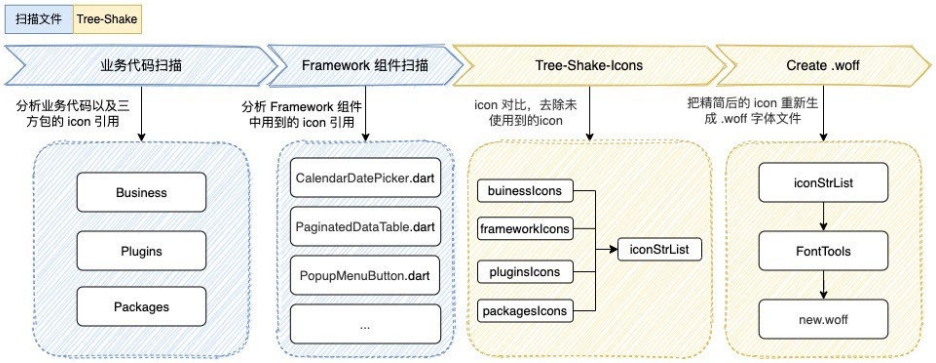

图 23　图标字体精简

- 扫描全部业务代码以及依赖的 Plugins、Packages、Flutter Framework，分析出所有用到的 Icon；
- 把扫描到的所有 Icon 与 material/icons.dart（该文件包含 Flutter Icon 的 unicode 编码集合）进行对比，得到精简后的图标编码列表：iconStrList；
- 使用 FontTools 工具把 iconStrList 生成字体文件 .woff，此时的字体文件仅包含真正使用到的 Icon。

通过以上的方案，我们解决了字体文件过大带来的包体积问题，以美团外卖课堂业务（业务代码中使用了 5 个 Icon）为例，字体文件从 920KB 精简为 11.6kB。

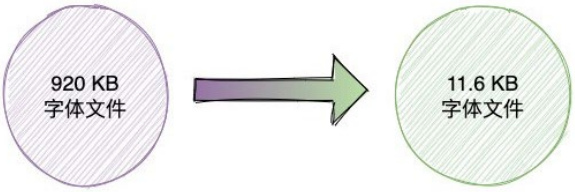

图 24　效果展示

五、总结与展望

综上所述，我们基于 HTML Render 模式对 FlutterWeb 性能优化进行了探索和实践，主要包括 SDK（Dart-SDK、Framework、Flutter_Web_SDK）的精简，静

态资源产物优化（例如：JS 分片、文件 Hash、字体图标文件精简、分平台打包等）和前端资源加载优化（预加载与按需请求）。**最终使得 JS 产物由 1.2M 减少至 0.7M（非业务代码），页面完全加载时间 TP90 线由 6s 降到了 3s**，这样的结果已能满足美团外卖商家端的大部分业务要求。而未来的规划将聚焦于以下 3 个方向：

- **降低 Web 端适配成本**：目前已有 9+ 个业务借助 MTFlutterWeb 实现多端复用，但在 Web 侧（尤其是 PC 侧）的适配效率依然有优化空间，目标是将适配成本降低到 10% 以下（目前大约是 20% ）；
- **构建 FlutterWeb 容灾体系**：Flutter 动态化包有一定的加载失败概率，而 FlutterWeb 作为兜底方案，能提升整体业务的加载成功率。此外 FlutterWeb 可以提供“免安装更新”的能力，降低 FlutterNative 老旧历史版本的维护成本；
- **性能优化的持续推进**：性能优化的阶段性成果为 MTFlutterWeb 的应用推广巩固了基础，但依然是有进一步优化空间的，例如：目前我们仅将业务代码和 Runtime Manifest 进行了拆离，而 Framework 及 三方包在一定程度上也影响到了浏览器缓存的命中率，将这部分代码进行抽离，可进一步提升页面加载性能。

美团外卖技术团队正在基于 FlutterWeb 做更多的探索和尝试。如果你对这方面的技术也比较感兴趣，可以在文末留言，跟我们一起讨论。也欢迎大家给提出一些建议，非常感谢。

设计稿（UI 视图）自动生成代码方案的探索

作者：田贝　少宽　腾飞

1. 背景

设计稿（UI 视图）转代码是前端工程师日常不断重复的工作，这部分工作复杂度较低但工作占比较高，所以提升设计稿转代码的效率一直是前端工程师追求的方向之一。此前，前端工程师尝试过将业务组件模块化构建成通用视图库，并通过拖拽、拼接等形式搭建业务模块，从而实现视图复用，降低设计稿转代码的研发成本。但随着业务的发展和个性化的驱动，通用视图库无法覆盖所有应用场景，本文提出了一种设计稿自动生成代码的方案。

目前，业内主流的代码生成方案有两种，一种是通过训练神经网络，从图片或草图直接生成代码，以微软 sketch2json 为代表；另一种是基于 Sketch 源文件，从中解析出图层信息转化成 DSL 并生成代码，以 imgCook 为代表。经过实践，我们发现第一种方案基于神经网络的代码生成算法虽然简单粗暴，但复杂层布局的准确率较低、可解释程度不高导致后续无法持续优化。方案二中 Sketch 源文件信息量丰富、算法自定义程度高、优化空间大。因此，我们调研了业界基于 Sketch 的代码自动生成方案（已对外公布或者开源），发现了一些不足并尝试解决，下面从算法准确率、代码可读性、研发流程覆盖度等方面做一下对比（**该对比结果仅考察业界方案对我们自己业务的适用性，实际结果可能存在差异**）：

算法准确率			
比较维度	组件识别	布局类型	结论
imgCook	支持进度条、标签等复杂组件识别	支持行/列/包含/悬浮/循环，不支持成组	准确率中
58 Picasso	仅识别基础组件	支持行/列/包含，不支持成组/悬浮/循环	准确率低
我们的方案	仅识别基础组件	支持行/列/包含/成组/悬浮/循环	准确率中

代码可读性		
比较维度	是否使用绝对布局	结论
imgCook	绝对布局使用较多，不符合预期	可读性一般
58 Picasso	绝对布局使用较多，不符合预期	可读性一般
我们的方案	相对布局，符合RD预期	可读性好

研发流程覆盖度				
比较维度	数据绑定	逻辑绑定	埋点绑定	结论
imgCook	智能化/可视化	智能化/可视化	可视化	覆盖度广
58 Picasso	不支持	不支持	不支持	覆盖度窄
我们的方案	可视化	可视化	可视化	覆盖度广

- **算法准确率方面**：淘宝 imgCook 支持基于 AI 的组件识别，不支持成组布局，准确率中等（从官网了解到可以识别循环布局，但不能识别出测试样本中的循环布局），58 Picasso 仅支持原始组件的识别，复杂组件生成错误较多，不支持成组 / 悬浮 / 循环布局，准确率较低。
- **代码可读性方面**：淘宝 imgCook 在生成布局时，测试样本中图层重叠区域使用到了基于根布局的绝对定位方式，不符合 RD 预期，可读性一般，而我们的方案使用相对定位方式，可读性较好。

- **研发流程覆盖度方面**：淘宝 imgCook 从 RD 视角构建了一个 IDE，支持在 IDE 中完成样式调整、逻辑绑定；而我们的方案从产研协作视角出发，支持数据、逻辑、埋点的可视化配置及上线。

2. 方案介绍

如图所示，配置平台主要分成三块包括：设计稿转视图树（UI2DSL）、视图树转代码（DSL2Code）、以及业务信息绑定，下面简单介绍一下每一块的作用。

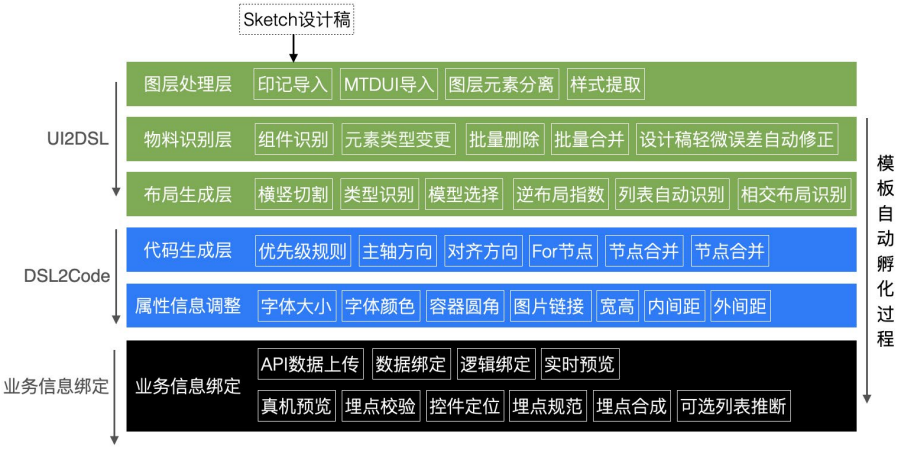

- **设计稿转 DSL 视图树（UI2DSL）**：将设计稿转化成平台无关的 DSL 视图树。
- **视图树转代码（DSL2Code）**：将 DSL 视图树转化成基于 Flex 布局的 MTFlexBox 静态代码。
- **业务信息绑定**：提供可视化配置工具，支持 MTFlexBox 静态代码绑定后台数据、业务逻辑、以及曝光 / 点击等埋点逻辑。

2.1 设计稿转视图树（UI2DSL）

UI2DSL 主要经历以下四个步骤：

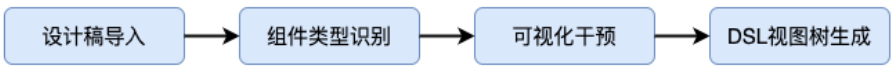

2.1.1 设计稿导入

在日常开发过程中，我们接触比较多的组件有按钮、标题、进度条、评分组件等，但是 Sketch 数据源中并没有这些组件只有图层信息，图层是设计师在设计 UI 视图时用到的视图控件。组件与图层的对应关系是一对多的关系，图层在 Sketch 数据源中的表现形式如下图中的 JSON 数据结构所示，描述了图层的坐标、大小等信息，后续布局生成就是基于对图层的切割来实现的。

```
[
    {
        "class_name":"MSTextLayer",
        "font_face":"PingFangSC-Medium",
        "font_size":13.44,
        "height":36.5,
        "index":8,
        "line_height":18.24,
        "name":" 恒都民生精选猪小排带骨 400g±25g",
        "object_id":"EF55F482-A690-4EC2-8A6E-6E7D2C6A9D91",
        "opacity":0.9000000357627869,
        "text":" 恒都民生精选猪小排带骨 400g±25g",
        "text_align":"left",
        "text_color":"#FF000000",
        "type":"text",
        "width":171.8,
        "x":164.2,
        "y":726.7
    },
    //......
]
```

2.1.2 组件识别

从上面的数据源可以看出，图层有图片、文字、矩形等基本类型，在组件识别这一步图层需要被转化成文字 / 图片 / 进度条 / 评分组件 / 价格组件 / 角标等日常开发使用的组件类型。但是目前我们的进展还停留在只能将图层识别为文字或者图片的阶段，后续我们将接入淘宝开源的 pipcook 框架，基于神经网络算法进行更加丰富的组件类型识别。

2.1.3 可视化干预

设计稿作为输入源是设计稿自动转代码的基础，这对设计稿的设计规范要求较高。但在实践中，我们发现设计师会利用 Sketch 中的基本图形（每个图形最终形成数据源中的一个图层）叠加来描述一个组件的视觉效果，因此设计稿中不可避免会出现冗余图层的问题，干扰 DSL 的生成。虽然我们也尝试了利用自动化的手段删除冗余图层，但对于算法不能识别的部分（例如：图片上有一个文本图层，但是实际情况中文本是显示在图片里的，这个时候无法从算法层面决定是否删除文本），仍然需要靠人工进行图层删除、合并等，否则无法正常生成 DSL。设计稿主要有以下几类问题。

图层未合并

上图是从设计稿解析出来的结果，可以发现在“美团优选”文字上方的图片中有很多红色的矩形框（每个矩形框是一个单独的图层），而算法预期的输入是一个图层，因此需要在算法处理前将多个图层合并成一个图层，右侧的三张图也有类似问题。我们与设计同学进行过沟通，设计同学表示愿意在产出设计稿之前将图层进行合并，但由于目前无法提供检测机制（图层合并是否有遗漏无法自动检测出来），也就无法彻底避免图层未合并的问题。

图层位置交叉

实践中发现当设计稿中不同字体 / 大小 / 颜色的文字排列在一起时，解析出来的图层信息往往会出现重叠的情况，由于 DSL 视图树算法依赖位置来确定不同组件的约束关系，因此位置的交叉会对算法准确度造成较大的影响。

复杂背景图层

上图中红色背景是由 2 个图层（2 个蓝色矩形框）拼接形成的，左图上的蓝色图层是纯色，右图上的蓝色图层是渐变色，在两个图层未合并的情况下，算法生成的代码将会出错。

上面提出的问题，通过约束设计师来达到设计稿的规范化，难度较大，所以我们提供了可视化干预工具。下面对上述问题做一个简单的总结：– 问题一：图层未合并问题肉眼很**容易识别**出来，利用工具将冗余图层进行**快速合并删除**即可。 – 问题二：图层交叉问题肉眼不易识别，因此我们提供了**检测工具**，基于检测工具可以对设计稿中的交叉问题**快速修复**。 – 问题三：复杂背景问题肉眼不易识别，暂时也没有有效的检测工具，用户可以采用**边干预边生成**的方式生成 DSL。

可视化干预是 UI2DSL 重要的一环，**经过可视化干预，将不标准的设计稿转化为标准的图层信息后再输入给算法，可以极大地提升算法的准确率**。这里我们和 imgCook 的处理方式有一个区别：imgCook 在引入了阈值处理等算法后（更智能，出错概率更大），可视化干预能力主要体现在事后，而我们在生成 DSL 之前允许用户对图层进行干预，在干预时用户面对的是直观的图层信息，可以有效降低工具的使用门槛（更稳定，效果更好）。

2.1.4 视图树生成

将扁平的数据源转化为树状结构的 DSL，这个过程如果是人脑来做会怎么思考呢？先确定布局的整体结构是行布局或者列布局，然后再确定局部区域应该是什么布局结构，最后组装起来形成视图树。这个过程与递归算法类似，因此我们采用了递归算法

作为算法的主框架，同时引入了“横竖切割 + 布局结构 + 模型评估”三大利器。

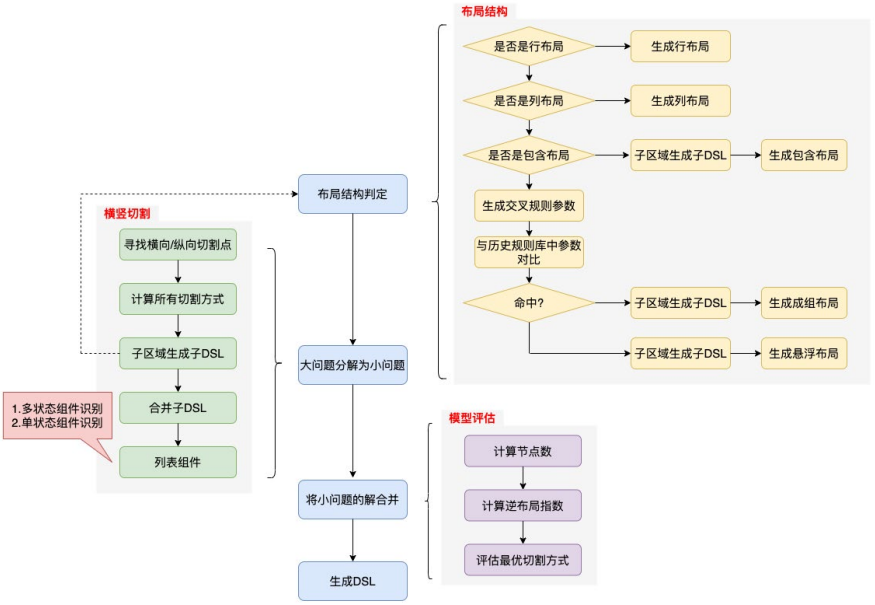

利器一：横竖切割

生成 DSL 时采用了整分的思路，即将大布局不断的切分成小布局，下面以动画的形式看一下简化过的 DSL 生成过程：

将设计稿一部分区域视为一个子区域，最开始的时候子区域和整个模板的面积一样大，基于图层的位置、大小信息，计算每个图层的上 / 下 / 左 / 右边缘坐标与其他图

层的相对关系，就可以寻找到切割点（如上图中红色箭头所指的位置）。接下来依据切割点，将子区域切割成更小的子区域，在切割的过程中如果切割点是横向的，则生成列布局；如果切割点是纵向的，则生成行布局。通过不断的切割子区域得到更小的子区域，直到所有的子区域只剩下图片或者文本等不可切割的图层，这样就可以生成完整的 DSL 视图树了。为了方便读者理解，图例中只演示了行布局、列布局的切分过程，实际情况还包含了其他布局类型，会要复杂许多。

这里还要注意一个问题，当有 3 个切割点时，我们选择了直接将子区域切割成 4 个子区域，实际上我们可以只选择 1 个切割点进行切割，也可以选择 2 个切割点进行切割，当有 N 个切割点时，实际上存在（N 的阶乘 +1）种切割方式，具体选择哪种切割方式，我们会在利器三中讨论。

利器二：布局结构

每个图层都是一个矩形，为了生成布局结构只能依赖矩形的上下左右坐标信息。因此，对布局结构进行分类时，我们根据矩形与矩形之间的位置关系（相交、相离和包含关系）做了以下分类。

注意：从生成 DSL 的结果来看，**包含布局**和**成组布局**的处理方式其实是一样的，都是使用类似于 FrameLayout 的层叠布局包含内部图层元素，但是我们仍然保持分类原则（矩形之间的位置关系）不变。

上图中，相离、包含比较好理解，为什么两个图层相交的时候，会有成组和悬浮两种类型的布局结构呢？我们看下上述成组布局、悬浮布局两个设计稿中分别标出了相交的元素 A、B，它们在位置上的相对关系是一样的，都是 A、B 两个图层对应的矩形框发生了交叉。但是我们希望理想态的 DSL 视图树却有所差异，如下图所示：

- 成组布局中：A、B 逻辑上是一个整体，交叉是必然的，最终 DSL 中 A、B 被层叠布局包含，层叠布局中没有其他元素。
- 悬浮布局中：A、B 逻辑上不是整体，只是碰巧交叉了，最终 DSL 中 A、B 分别在不同的层级中。

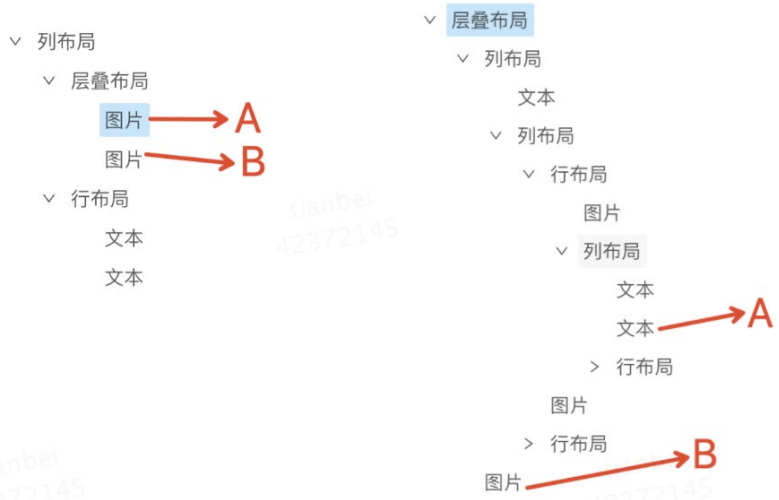

因此，对于图层相交时可能有两种类型的布局结构，分别是成组布局和悬浮布局。从上图可以看出使用成组布局还是悬浮布局是由图层内容决定的，那么就需要算法理解图层内容了，比如基于 AI 构建样本库，记住所有的角标样式（上面表格中 4 描述的），下次遇到角标相交时就生成成组布局。考虑到 AI 模型也是对规则的抽象，我们先搭建一套自定义识别规则。成组布局其位置信息是有规律可循的，例如：角标经常出现

在右上角，标签经常出现在左上角，头像经常横向或者纵向交叉等，因此我们针对图层之间的位置关系构建了交叉模型，如下图所示：

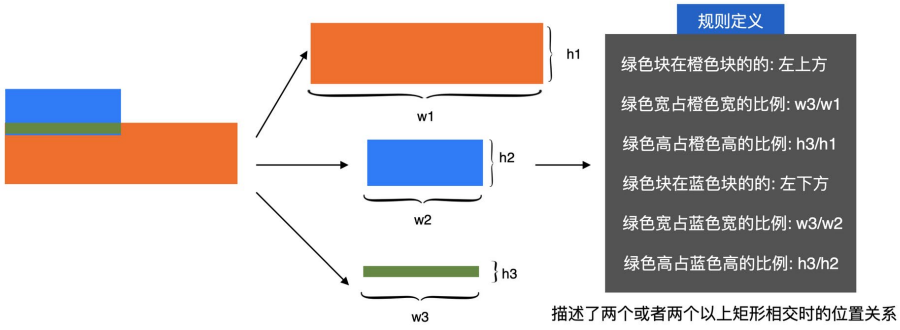

上图的交叉模型可以记住历史模板中成组布局图层之间的位置关系，下次遇到相交布局时判断是否在历史规则库中即可完成识别，如果在就按成组布局处理否则按照悬浮布局处理。下图是通过历史模板构建的成组规则库。

上面介绍了本方案中涉及的 5 种布局类型，目前来看这五种布局类型可以描述所有的模板布局，并且生成代码符合 RD 的预期。下面展示两个设计稿 DSL 实例：

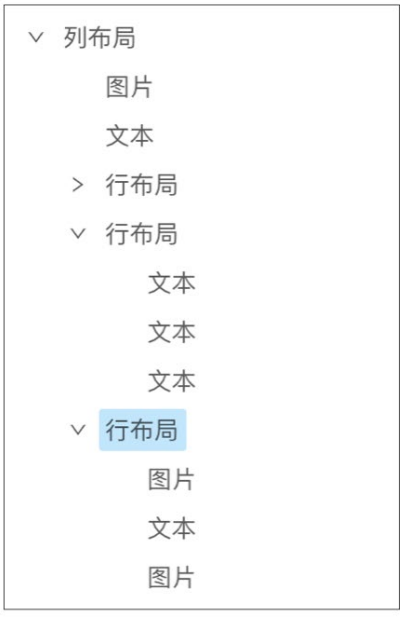

利器三：模型评估

在介绍横竖切割时，可以看到当存在多个切割点时，对所有切割点同时进行了切割，但实际上算法在切割时复杂度会更高，当有三个切割点时，实际上有 5 种切割方式，每种切割方式都会生成一个 DSL。既然有 5 种切割方式，那么到底应该选择哪一种

DSL 呢？模型评估算法就是用来解决这个问题的。

目前模型评估算法有两个指标：布局节点数和逆布局指数。

- DSL 中布局节点数越少，切割方式越好。
- 逆布局指数用来评估 DSL 中的行列布局的合理程度，其中逆布局指数越大越不合理，反之，逆布局指数越小，切割方式越好。

以下图为例，看下视图不同切割方式下对应的模型评估方式：

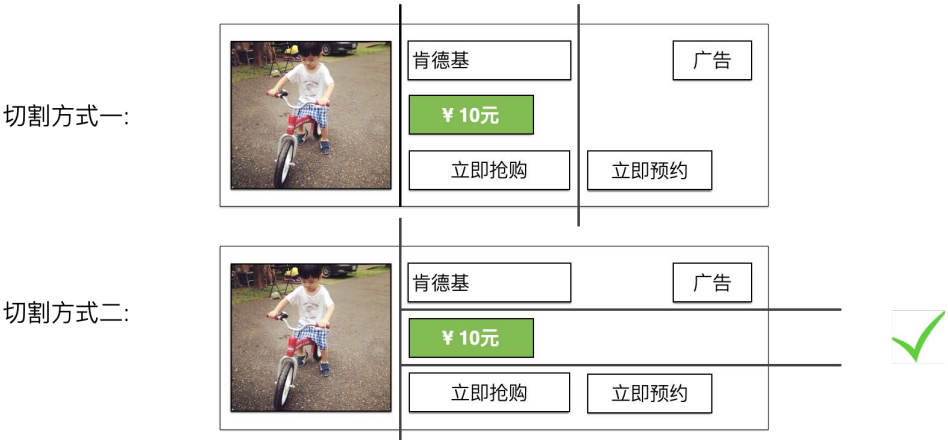

如果模型评估算法只衡量布局节点数的话，那么会选择第一种切割方式生成的 DSL 作为最终的结果。但实际上，第二种切割方式更加合理。在切割方式一中，广告、立即预约处于一个列布局中，但是横向对齐方式（交叉轴）却不一样，“广告”是右对齐，“立即预约”是左对齐，逆布局指数表示交叉轴对齐方式不一致的节点数量，因此通过逆布局指数，我们可以规避掉不合理的切割方式。

2.1.5 列表布局

上一节介绍了基本的布局结构，虽然说这些布局结构已经可以描述所有的 UI 布局，但是与 RD 的编码习惯还是有一些差异。

对于上面的布局，RD 通常不会把相同的 item 写五遍，而是会将 item 放在一个类似于 ListView 的列表组件中，使代码看起来简洁易懂。因此在 DSL 生成阶段，除了识别基本的行 / 列 / 包含 / 成组 / 悬浮布局外，还需要进一步识别行 / 列布局中的元素是否形成列表布局。在试验过程中，我们发现列表布局分为两种：**单状态列表组件**和**多状态列表组件**。上图中每一个 item 的布局结构都是一样的，我们称为单状态列表组件，再来看一下多状态列表组件（如下图所示），每个 item 有多种状态（选中态和非选中态），并且不同状态的布局结构不一致。

对行 / 列布局中单状态列表组件的识别，只需要比较 item 子视图树的结构，子视图树结构一致则判断为单状态列表组件。对多状态列表组件的识别我们采取了自动识别 + 人工干预的方式，自动识别的方式比较粗暴，只要行列布局中子 item 的宽 / 高接近，并且子 item 不是基本组件（基本组件容易形成误判），就判定为多状态列表组件。具体算法是计算子 item 宽高的标准差，小于阈值就判定为多状态列表组件，否则不是。公式如下：

$$(\sqrt{(w_1-\bar{w})^2+(w_2-\bar{w})^2+\ldots+(w_n-\bar{w})^2} < \text{阈值}_w) \quad \wedge \quad (\sqrt{(h_1-\bar{h})^2+(h_2-\bar{h})^2+\ldots+(h_n-\bar{h})^2} < \text{阈值}_h)$$

那为什么还要人工干预呢？因为是否使用列表组件其实与产品逻辑相关，但是目前我们无法将产品文档中的逻辑识别出来，只能尽可能识别出所有的多状态列表组件，并允许用户对生成结果进行变更。比如上述送恋人的设计稿，产品可能约定每一个 item

都有选中态 / 非选中态两种状态，也可能是从业务角度考虑需要着重突出送恋人这个 item，这时每个 item 就只有一种确定的状态，这两种不同的产品逻辑在编写代码时有不同的最优技术方案。

2.2 视图树转代码（DSL2Code）

DSL 视图树只是生成代码的中间产物，还需要对 DSL 进行代码还原，DSL2Code 主要包括两个步骤：属性推断、属性信息调整。

2.2.1 属性推断

属性推断包括两个部分：样式属性和结构属性。样式属性包括字体、背景色、圆角等可以直接通过数据源信息中获取得到的属性；结构属性包括大小、内外边距、主辅轴对齐等结构信息，这些信息无法从数据源中直接获取，所以结构信息的推断是这部分工作的重点。

结构信息推断算法同样使用递归算法作为主框架，通过一次递归对所有元素进行两次遍历来完成结构信息的推断。如下图所示，在对 DSL 所有节点进行递归遍历时，把所有元素依次加入队列中，递归完成后，再把所有节点依次移出队列，这样一进一出便对所有元素完成了两次遍历，我们把这两次遍历称为进队遍历和出队遍历。

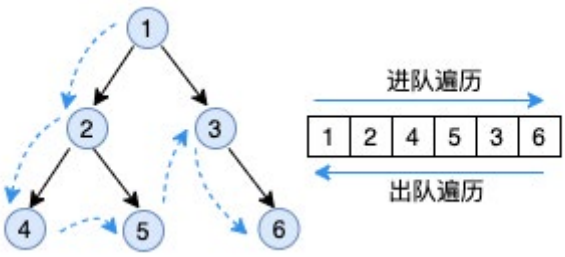

进队遍历时，推断算法根据数据源中信息记录每个节点的大小和位置信息，并根据位置关系计算每个子节点在父节点中期望的主辅轴对齐方式和内外边距。出队遍历时，父节点会根据子节点期望的对齐方式确定父节点最终的主辅轴对齐方式，并根据子节点的拉伸意图修正父节点的大小。拉伸意图即节点的大小不固定，根据显示内容不

同，在水平或垂直方向上可能会变大或变小，例如文本节点根据显示字数的多少长度会发生变化，字数过多时甚至还会换行。

2.2.2 属性信息调整

由于输入源是基于设计稿呈现的静态效果图，设计稿中每个元素缺失了真实的业务含义，同样的展示效果在不同的业务场景中会有不同的属性要求，对于这部分内容，我们无法从输入源中进行准确推断。为此，我们提供了可视化的属性信息调整功能来辅助代码生成，页面效果如下图所示，在这个页面可以对 DSL 中的所有节点属性进行查看和修改调整。

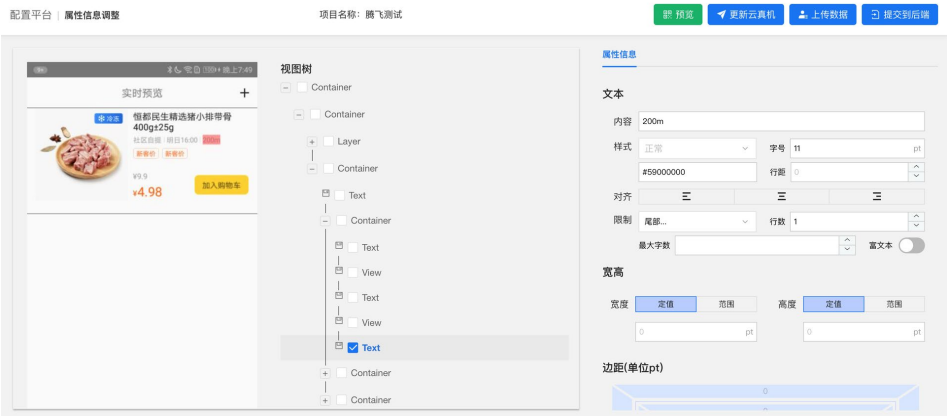

经过业务信息补充后，便可进行最后的自动代码转化，通过语法映射自动把 DSL 转化成 MTFlexbox 模板代码。

3 成果展示

下面是设计稿直接生成代码未经修改展示后的手机屏幕截图，可以看到取得了不错的还原效果：

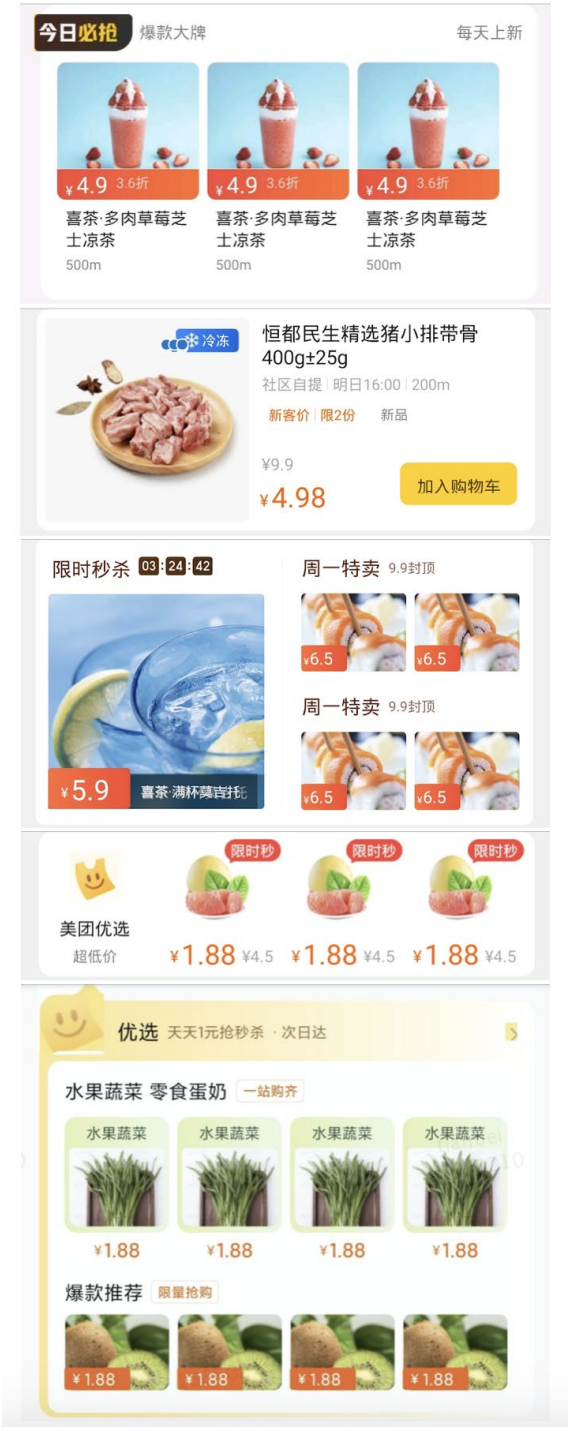
今日必抢
爆款大牌
每天上新
¥4.9 3.6折
喜茶·多肉草莓芝士凉茶
500m
¥4.9 3.6折
喜茶·多肉草莓芝士凉茶
500m
¥4.9 3.6折
喜茶·多肉草莓芝士凉茶
500m
冷冻
恒都民生精选猪小排带骨
400g±25g
社区自提 | 明日16:00 | 200m
新客价 | 限2份
新品
¥9.9
¥4.98
加入购物车
限时秒杀 03:24:42
¥5.9
喜茶·满杯莫吉托
周一特卖 9.9封顶
¥6.5
¥6.5
周一特卖 9.9封顶
¥6.5
¥6.5
美团优选
超低价
限时秒
¥1.88 ¥4.5
限时秒
¥1.88 ¥4.5
限时秒
¥1.88 ¥4.5
优选 天天1元抢秒杀 · 次日达
水果蔬菜 零食蛋奶
一站购齐
水果蔬菜
¥1.88
水果蔬菜
¥1.88
水果蔬菜
¥1.88
水果蔬菜
¥1.88
爆款推荐
限量抢购
¥1.88
¥1.88
¥1.88
¥1.88

以上就是我们近期对代码自动生成的探索及实践，后续我们将引入机器学习及神经网络算法，对过程进行进一步优化。如果您有其他的看法或建议，也欢迎在文末进行评论，或者跟我们联系。

作者简介

田贝、少宽、腾飞等，美团平台终端业务研发团队研发工程师。

团队简介

美团平台终端业务研发团队的职责是保障平台业务高效、稳定迭代的同时，持续优化用户体验和研发效率。团队负责的业务主要包括美团首页等千万级 DAU 高频业务以及分享、账号、音 / 视频等基础业务，支撑和对接外卖、酒店等 30 多个业务方。团队通过动态化能力建设，加快业务上线速度，帮助产品（PM）快速验证业务选型，做出业务决策；架构 / 服务标准化体系建设，提升前后端以及平台与业务线的沟通、合作效率；业务监控和体验优化，有效保障核心业务服务成功率的同时，提升用户使用美团 App 过程中的稳定性和流畅性。团队开发技术栈包括 Android、iOS、React Native、Flexbox 等。

招聘信息

美团平台终端业务研发团队是一个活力四射、对技术充满激情的团队，现诚聘 Android、iOS、FE 工程师，欢迎有兴趣的同学投简历至 tech@meituan.com（备注：美团平台终端业务研发团队）。

美团外卖终端容器无关化研发框架

作者：正浩　宝石　彭震

| 终端容器无关化（Containerless）：与服务无关化（Serverless）的概念类似，即在保持顶层业务研发语言不变更的情况下，在下层可以兼容性地升级、替换终端容器的能力，让用户无需关心终端容器的运维，只要将精力聚焦到业务逻辑上的技术。

一、前言

React2X 是一款面向多终端、跨平台、容器无关化研发框架。在整个美团前端技术栈日益规范的趋势下，React 技术栈在我们技术体系环节中的地位变得越来越重要。在广告、营销这些推广属性的业务上，在各个终端（包括美团 App、美团外卖 App、大众点评 App，以及站外的微信小程序、百度小程序、头条 & 抖音小程序等其他终端）实现“一次开发，同步需求上线”的业务诉求也变得越来越多。在这样的背景下，我们定义了 React2X 应用的核心场景：

- 面对美团内部丰富多样的技术容器体系（Mach、MRN、Titans、MTFlutter、MMP 等），如何保证跨容器开发体验的**一致性**，以及建设跨容器应用开发的**生态能力**，是我们需要解决的问题。
- 公司内丰富的终端容器化技术蓬勃发展，而因业务升级带来的改造成本也比较大，亟待一款**高扩展性**设计的顶层框架作为技术抓手。
- 跨容器动态化能力覆盖，逐步成为各个业务方越来越重视的基础能力，可以大幅缩短需求交付的周期，提高上线发版的效率，并能有效地解决包体积大小的问题，提升业务的**敏捷性**。
- 多场景下的**同构诉求**，例如在各种推广页、模块化、游戏、轻量布局差异的 PC/App 同构场景下，可以节省多端研发的人力。

最终我们的**核心痛点**围绕在了**美团系 · 小程序**和**美团系 · App 矩阵上的**同一个需求的多次开发运维上，为了**解决研发人力瓶颈问题**，我们需要一款“**一次研发，多终端**

容器复用”的研发框架来**提升研发效率**。

调研整个前端领域，我们找到了一些业界的解决方案，像是美团最早的 mpvue、腾讯的 Wepy、滴滴的 Chameleon、京东的 Taro 等等。在经过比较与试用之后，我们最终基于投入产出比的价值判断，选择站在巨人的肩膀上研发定制一款满足美团技术、业务场景的研发框架——**React2X**（后面简称 **R2X**）。从 **R2X** 第一个版本发布到现在，已经接受了来自于公司各个业务两年多的考验。所以我们希望通过本文帮助大家对 **R2X** 有一个大致的了解。

二、目标与场景

2.1 核心目标

为了解决业务需求在多端容器需要重复开发的难题，通过代码复用实现开发提效，我们确定了以下的目标：

- **解决公司内部多终端容器开发痛点**：实现 Webview 容器、小程序容器、MRN 容器、Mach 容器、游戏容器、部分运营推广场景 PC 容器的代码同构复用，统一开发规范，抹平开发差异，并提供对其他容器的扩展能力。
- **建设跨容器动态化能力**：跨容器动态化能力的缺失，导致产品不能够通过快速迭代来验证需求的效果，这个问题严重限制了业务的发展。跨容器动态化能力可以解决美团外卖业务端上发版和包体的问题，帮助业务实现快速发版上线、线上问题热修复、以及容灾的能力。
- **建设容器无关的开发生态体系**：R2X 最终要解决的是容器差异性，进行统一的技术生态能力建设，为多终端容器开发场景提升生产和运维效率。

2.2 应用场景

R2X 开发框架主要期望能最终面向多终端应用的终端容器，用于场景化研发：

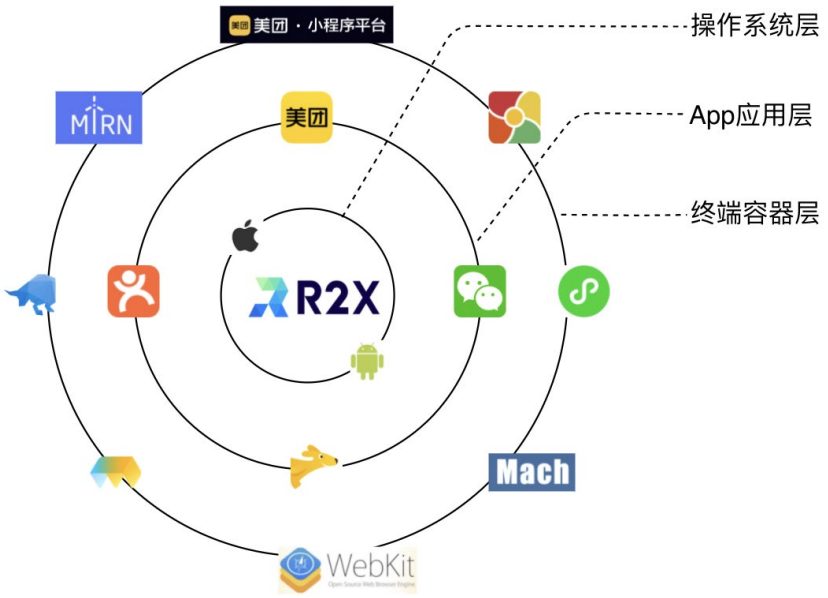

图 1

即：

- 业务项目基于 React 语法为技术框架基础。
- 业务方有在多终端 / 多容器（包括 MRN 容器、Webview 容器、MP 容器、Flutter 容器、Mach 容器、PC 浏览器容器）运行的需求。
- 业务方有特定的场景化诉求，包括推广页、模块化、小游戏、PC/App 同构等等。

三、挑战与优势

3.1 业界调研

针对上述核心目标和应用场景，我们对市面上的跨容器框架进行了调研。由于美团外卖的技术栈统一是 React 为主，所以我们的必备要求是：一款以 React 为 DSL 语言的复用框架，能快速融入美团的技术生态。

根据下表的对比，如果以 React 为 DSL 语言出发，当时就只有 Taro 一家能满足我们的业务诉求，但它的生态环境并不适合在美团体系内使用。基于多方面因素的考

虑，我们决定结合各大主流框架之所长，然后开发出一款属于美团外卖的跨容器复用框架。

对比项	mpvue	Taro 1.3	Chameleon	WePY	UniApp
DSL	Vue	类 React（Nerv）	类 Vue	Vue	Vue
是否支持 React Native	否	是，但支持效果不佳	Weex	否	否
兼容 API	无	有（API 支持程度不一）	自研多态协议	无	是
跨端组件库	无	有	有	无	无
美团生态	有	无	无	无	无
语法校验	无	ESLint	自研	无	有
TypeScript	有	有	无	有	有
定制化扩展	无	可自研 Plugin	无	无	有
编译扩展	无	无	无	无	有
调研结论	不匹配	部分满足	部分满足	不匹配	不匹配

注：前期调研时间截止到 2019 年 05 月，可能与当前数据存在一定的出入。

3.2 技术挑战

当我们决定要打造一款属于美团外卖的跨容器复用框架之后，在实现的过程中主要遇到了以下挑战：

① **各个容器之间差异性适配成本** – 语法语义：MRN/ 小程序 /Webview 在 DSL 上就有着完全不同的语法语义。 – 端能力：同一容器在不同端上表现也存在不少差异，比如外卖 App 中 MRN 容器和美团 App 中 MRN 容器分别有定制的 Native 模块以及各类桥协议等。

② **业务接入的使用成本** – 首次成本：作为一个新定义的框架如何让新业务方快速上手，如何从存量业务线进行迁移。 – 边际成本：如何融合美团的基建生态，让业务方快速复用平台能力。

③ **顶层架构的合理设计** – 高可维护性、高度扩展性：如何快速升级、替换、新增一款底层容器。

注：以上问题我们会在下文“技术全景”章节中给予解答。

3.3 项目优势

3.3.1 功能特点对比

目前，业界以小程序作为跨端目标平台的框架较多，但大多都是使用 Web 前端技术栈作为基础，但同时兼顾 React Native 的技术栈就比较少。下表中列出的是支持以 React、类 React 作为 DSL 的相关框架进行对比。

	R2X	Taro 1.3	Taro 3.0	Rax	Remax
原理	R2X 1.0 重编译时，R2X 2.0 重运行时	重编译时	重运行时	重运行时	重运行时
容器重点	以 MRN，小程序，WebView 为主，同时支持 MTFlutter、Mach、游戏、PC 浏览器	以小程序、Web 为主，React Native 支持不多	以小程序、Web 为主，React Native 交给 58 团队支持	小程序、Web、Flutter	小程序、Web
API	支持 KNB 桥 & 对多平台 API 进行了统一	对多平台 API 进行了统一	对多平台 API 进行了统一	多平台不统一	多平台不统一
跨端组件库	有	有 TaroUI，但不支持 React Native	有 TaroUI，但不支持 React Native	无	无
业务组件扩展	提供扩展方案	参考 TaroUI	参考 TaroUI	提供扩展方案	提供扩展方案
美团内部生态支持	已支持埋点监控等	无	无	无	无
模块化能力	支持	不支持	不支持	不支持	不支持
编译插件扩展	支持	不支持	支持	支持	支持 Webpack 配置

综上所述，从目前的业务形态来看，R2X 在容器的匹配程度以及美团生态支持程度上看，是现阶段的最佳方案。R2X 相较于业界其他框架来说，拥有更加完善的适用于美团外卖团队的本地化实现。

3.3.2 性能数据对比

基于业界跨平台框架和美团内部的跨平台框架，我们针对性能也进行了 Benchmark 测试，最终对比结果如下。

小程序性能对比

框架	创建	更新	添加	交换	删除
R2X-MP	947.6	586.8	1467.2	1355.2	82.2
Remax	2798.2	1872.6	5162.2	4818.2	86.4
Taro-MP	1653.4	976.4	2483.2	2256.6	65.2

结论：可以看到，在小程序 Benchmark 测试结果中，R2X-MP 是领先于 Remax 和 Taro-MP。

与 React Native 性能对比

框架	创建	更新	添加	交换	删除
R2X-MRN	309.875	83.75	384	191.875	82.125
MRN	297.625	105.25	400.125	231.625	65.875
Taro-RN	209.5	77.5	246.25	85.125	17.125

结论：在 React Native 的 Benchmark 测试结果中，R2X-MRN 和 MRN 基本持平，但都低于纯 React Native 的性能表现。

3.3.3 同构场景对比

除了支持了基本的 React Native、小程序和 Webview 容器同构场景之外，R2X 还实现了在 MTFlutter、Mach、小游戏（Webview 游戏、微信小游戏 & 小程序、美团小游戏）、PC 浏览器等容器上的同构能力扩展，相比于业内的其他跨容器开发框架的生态也更加丰富和健全。

	React Native	小程序	Webview	Flutter	模块级容器	小游戏容器	PC浏览器（PC/App同构）
R2X	支持	支持	支持	支持	支持	支持	支持
Taro	支持	支持	支持	不支持	不支持	不支持	不支持
Rax	支持	支持	支持	不支持	不支持	不支持	不支持
Remax	支持	支持	支持	不支持	不支持	不支持	不支持

四、技术全景

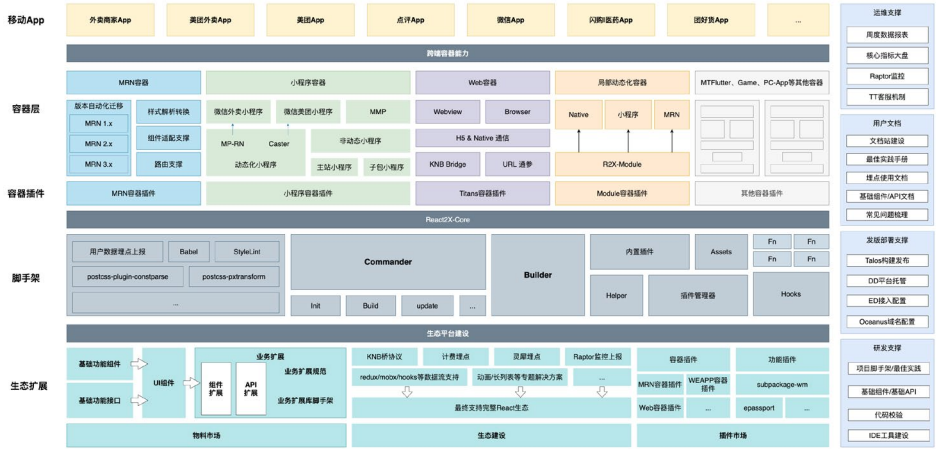

图 2

上图为 R2X 的架构全景图，整体架构可以按照从下到上，从左到右的视角进行解读：

- 最下层是 R2X 的生态环境建设，在 R2X 内部去实现公司生态的常用 SDK 以及业务中的各项专题能力；并通过搭建物料市场 / 插件市场，以业务共建的形式丰富 R2X 生态。
- 再上层是 R2XCore 的根基，通过解析 Command 命令来执行唤起构建器，并实现了类似 Webpack 的插件系统，以插件化的形式组织驱动整个核心构建流程，便于维护以及扩展。
- 再往上是跨端容器层，它是整个跨端能力的核心，通过实现了不同的容器插件来将 R2X 代码编译成各端可执行代码，并通过运行时能力对组件 /API 进行对齐。
- 最上层是承载的 App 端，目前有美团外卖、大众点评、美团等多款移动 App 终端。
- 最右边是 R2X 在研发、发布、运维以及用户文档上做的一些建设。

因为 R2X 覆盖了美团内部大部分的主流容器场景，所以技术体系较为复杂和庞大，大家可以根据自身的业务形态，选择性地去了解对应场景的同构方案。

4.1 底层基础框架

4.1.1 R2X-CLI 的设计

CLI 作为 R2X 项目驱动器，它不仅包含了命令行的启动，更重要的，它是各个编译构建的核心。

在早期，CLI 执行 build 命令时，我们通过 –type 来区分不同的构建容器，从而加载不同的编译逻辑。通过指定构建容器的形式来实现同一套代码能够构建出不同的容器产物。但经过长时间的业务迭代，我们发现了这种结构存在的问题：

- 整体流程冗长且复杂，长时间迭代会变得越来越难以维护。
- 每个容器的构建流程相互独立，且构建逻辑各不一致，有多处重复的逻辑处理。
- 编译流程缺少统一的关键节点，编译时无法进行业务方的定制扩展。

针对以上问题，我们考虑对 CLI 进行了一次全新的重构，引入插件化能力（关于插件化能力的具体实现会在下文详细描述）。CLI 整体结构变成如下图所示：

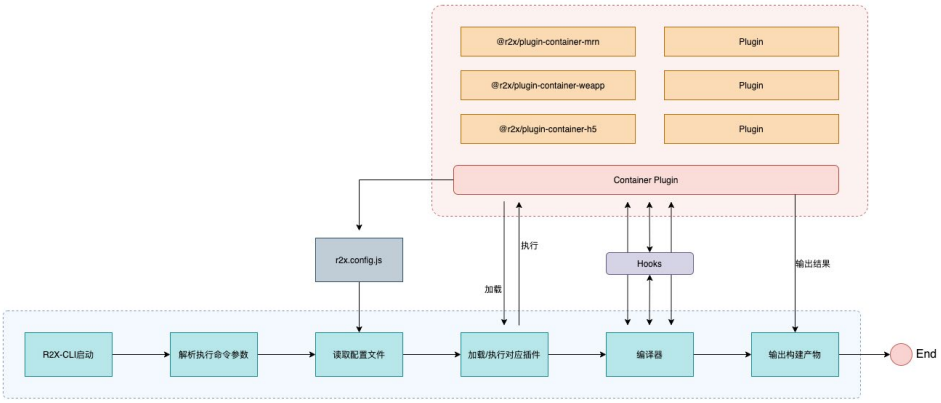

图 3

整个 CLI 模块只需要关心参数的解析以及插件的加载执行，不需要再实现各个容器的具体编译逻辑。通过 Hooks 的形式，将编译的各个时机暴露给插件，插件基于这些 Hook 进行编译能力的实现，最终输出产物给 CLI 模块。这种形式带来了以下几个好处：

- CLI 结构变得清晰，只需要维护配置解析、插件解析等功能。
- 扩展性增强，可通过插件化的形式新增或删减容器 / 编译能力，保证代码独立维护功能的单一性。
- 编译流程可梳理，无论什么容器的编译流程都基于编译器暴露的时机执行并串联，整体流程清晰明了。

4.1.2 组件及 API 的设计

R2X 的目的是希望通过一套代码能够在多端上运行，但是由于多端差异的存在，我们需要设计一套统一的标准规范来进行对齐。在运行时部分，主要分为组件 / 接口的对齐。

多端差异

在开始讲述实现之前，我们先来看看各端之间的差异到底在哪些地方。

组件（标签）差异

- Webview 标签采用的是 XML 写法，所提供的基础标签有 <a/> 等等。
- 小程序采用的是 WXML（WeiXin Markup Language）标签语言，也提供了一套完整的基础标签，但是和 Webview 有着较大的差异。
- React Native 则是采用的 JSX（JS-XML）语法，虽然和 XML 很接近，但是又有着很多的不同点，同时它也有自己的一套基础组件，和 Webview、小程序又截然不同。

API 差异

- **接口差异**：在不同端中都提供了相同或近似的功能，但是其实现方式以及调用参数可能存在着很大的差异，比如数据缓存 Storage，小程序中用 wx.setStorage/wx.setStorageSync，Webview 则 用 localStorage.setItem， 而 MRN 中 AsyncStorage.setItem，几乎每一个功能点都有着多多少少的差异。
- **容器差异**：各个端所提供的 API 都是各自的容器量身打造的，比如小程序的各业务接口类 API，完全是针对小程序所处的微信环境打造的，这类功能与其他

端并不相关。

- **能力差异**：各个端之间的差异我们可以通过定制的手段来适配，然而并不是所有的功能点在各个端上都能够实现。比如在 Webview 中就无法做到像小程序、React Native 中提供很多原生能力，像是文件保存读取等等，这一类差异性在适配过程中都属于不可抗拒、不可抹平的差异。

样式差异

小程序的 WXSS 和 Webview 的 CSS 在参数属性上其实是几乎一致的，但是在层级关系上有着很大的差别，小程序分为全局样式与局部样式，各个组件之间的样式也是不会相互影响（默认配置下）。而对比 React Native 采用的 StyleSheet，是用 Inline Style 的方式，不支持全局样式，不支持标签样式，并且属性有诸多限制，如只能使用 Flex 布局等等。

如何适配

从以上章节我们已经了解到了各个端之间有着非常大的差异点，那我们应该如何克服这些困难呢?

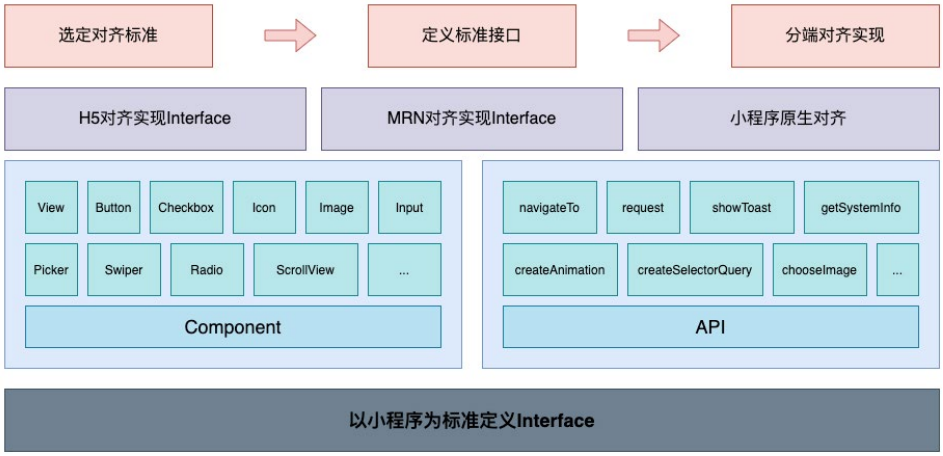

图 4

由于各端对组件和 API 的支持程度不同，我们选定了一端为基础标准，定义好各个组

件的属性以及接口参数，通过 TypeScript 的 Interface 进行实现。然后在各个端分别基于以上的接口进行功能对齐实现，对于端能力限制的功能进行了一定取舍，对高优功能进行了 SDK 底层实现适配。最终，我们基于已有的功能封装实现了一套完整的基础组件 `@r2x/components` 和基础 API`@r2x/r2x`。

4.1.3 开放式插件能力

随着 R2X 的在美团内部的应用越来越多，大家对于 R2X 模式的认可度也在不断提高，我们从业务方中经常听到以下这些问题：“是否可以增加支持某某功能 / 容器”，“我们业务架构比较特殊，能否做出一些调整”。业务方对 R2X 会有更多功能 / 容器的诉求，也会有更多定制化的需求出现。

所以，我们决定实现一套完整的开放式插件能力，提供一种相对比较简单的方式，让大家能够自己来定制这些特殊需求。在最新的版本中，我们将 R2X 的编译时进行了重构，在新的编译时架构中引入了基于 Tapable 的插件系统。开发者可以通过编写插件的方式为 R2X 拓展更多功能，或者为自身业务线定制更多的个性化功能。

在插件类型分为两类：

- **容器插件**，用于封装 R2X 所支持的容器的核心编译能力。
- **功能插件**，基于已有的容器插件，在此基础上进行某种特定功能的自定义实现。

插件能力的整体架构如下：

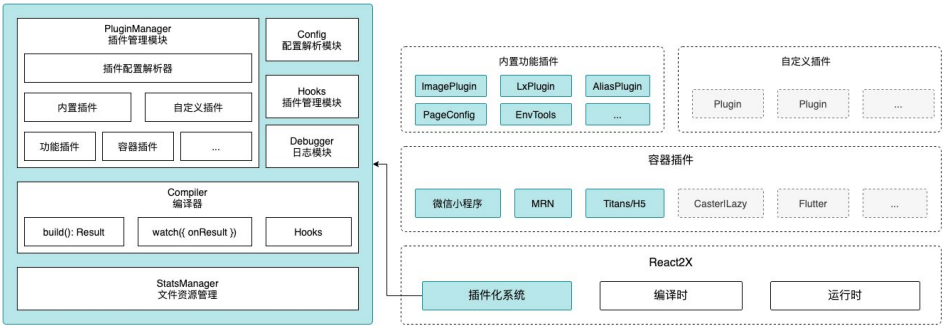

图 5

借助开发式插件能力，我们将之前编写了若干个平台容器插件，开发者安装后即可使用：

- 小程序容器插件：@r2x/plugin-container-wxapp。
- MRN 容器插件：@r2x/plugin-container-mrn。
- Titans 容器插件：@r2x/plugin-container-h5。

除了扩展新的容器平台，我们还可以通过继承现有的容器插件，来编写一些特殊的定制化功能插件。

1. 对代码进行预处理

基于开放式插件能力，我们可以像 Babel 插件一样，通过对 AST 语法的修改对代码源文件进行编译前后的修改。比如：修改文件引用路径、插入代码片段、处理本地图片等等。

2. 对文件产物进行修改

在编译产出生成时，我们可以对编译文件的内容、文件路径、文件结构进行修改。结合自身业务的定制化，CLI 可以将 R2X 项目和现有的原生项目进行结合改造。

除了以上功能，插件化能力为用户在编译时提供了极大的自由度。如果你想体验的话，欢迎加入美团外卖技术团队。

4.1.4 特性能力 - 多态能力

为什么需要多态能力?

多态能力是用于提供跨端时各端组件及 API 的统一解决方案。基于多态能力，开发者可以定制自己的跨端组件。而 R2X 具备了完善的跨端能力，能够覆盖多终端和容器，为什么还需要多态?

业务研发为了满足各自场景的要求需要一定的灵活性。同时，Webview/ 小程序 / React Native 容器存在端上的差异，需要开发者人为进行环境判断。逻辑一复杂、跨端数量一多，代码可读性变低、维护成本起飞，这不是我们的本意。

基于这样的背景，R2X 提供了扩展性良好的多态能力。

R2X 多态能力介绍

对于多态能力的支持，我们分为两类：

- 多态组件 /API，R2X 根据文件后缀区分编译目标端。

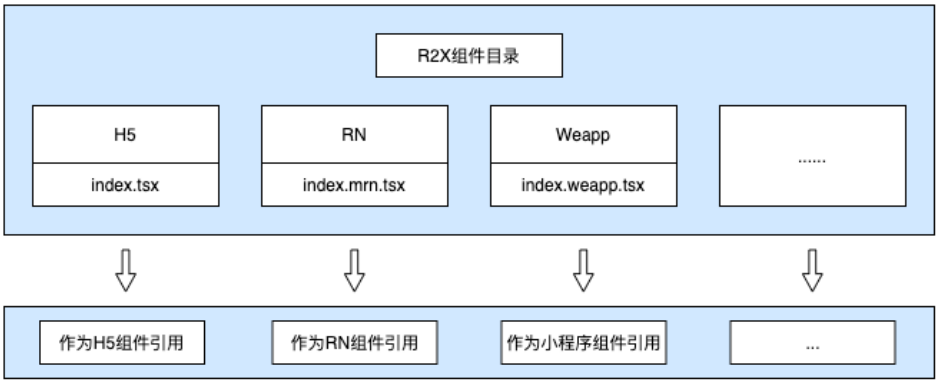

图 6

- 差异化代码，R2X 提供 getEnv 环境方法用于判断当前语句编译目标端类型。

```
<View style={{color: R2X.getEnv() === "WEAPP" ? "green" : "blue" }} />
```

通过差异化代码可轻松满足端差异诉求。

4.2 应用场景同构

4.2.1 页面级容器场景同构

页面级容器场景同构我们借鉴了业内 Taro1.x、Rax 等优秀跨端框架的做法，结合美团内部容器、基建特点做了很多本地化实现和定制，在 Webview、MRN、小程序三种容器上通过不同的编译时方案进行预处理，并且引入了 React 运行时，保证了对 React DSL 支持的完整程度和代码同构率，编译时转化流程方案和运行时结构如下图所示：

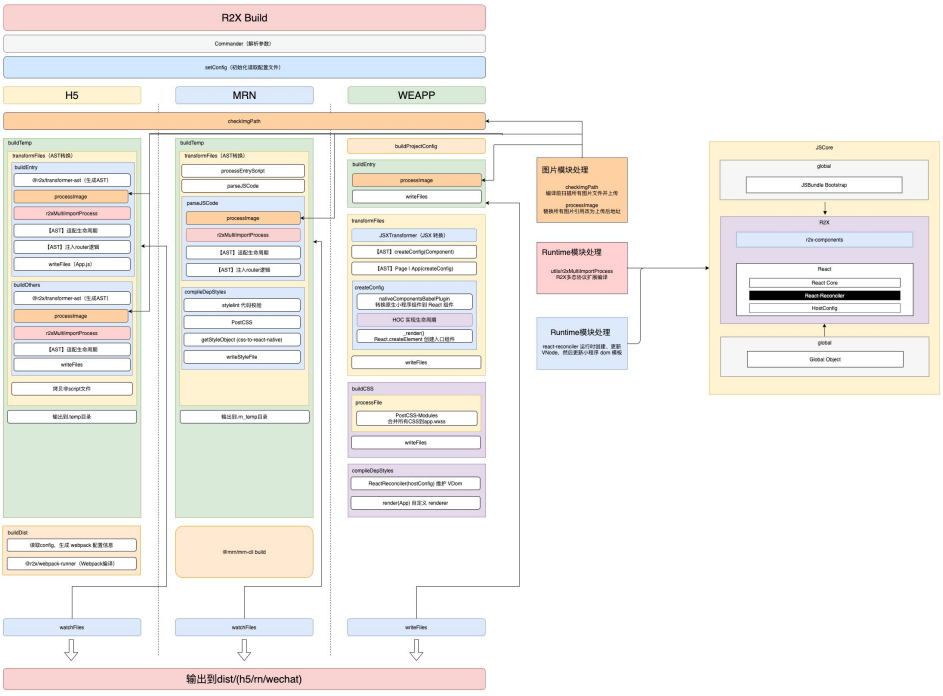

图 7

R2X2.0 相比于 R2X1.0，运行时方案能够解决编译时方案带来的语法限制问题：

- 不能在包含 JSX 元素的 map 循环中使用 if 表达式 ✅
- 不能使用 Array#map 之外的方法操作 JSX 数组 ✅
- 不能在 JSX 参数中使用匿名函数 ✅
- 暂不支持在 render() 之外的方法定义 JSX ✅
- 不允许在 JSX 参数 (props) 中传入 JSX 元素 ✅
- 不能在 JSX 参数中使用对象展开符 ✅

同时也支持大部分 React 第三方生态库，目前已支持使用原生 react-redux。彻底抹平各端的差异，无论是 MRN、Flutter、小程序、Webview 的自定义组件都可以直接当成 React 组件引入，小程序原生自定义组件也无需配置 usingComponents。

4.2.2 模块级容器场景同构

在模块级同构方案上，我们在 App 上依赖 Mach 容器；在小程序容器中，我们克服了 Mach 容器渲染机制的约束（运行时与虚拟 DOM 的使用限制），单独在小程序上设计了 Mach 容器渲染方案，实现了 R2X- 模块化（**R2X-Module**）在客户端和小程序上 99% 以上的代码同构率。

整体方案

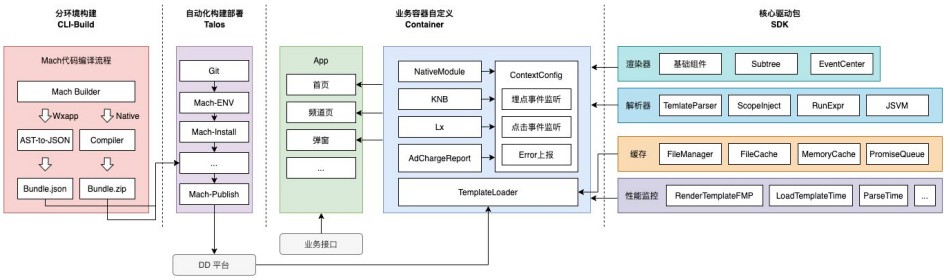

图 8

- **核心驱动包**，容器驱动的核心，针对渲染能力、解析能力、缓存能力、性能监控四个方面进行了实现，达到动态化驱动效果。
- **业务容器自定义**，基于 SDK 提供的驱动能力，针对不同展位特性进行了容器自定义功能扩展配置，让业务方可根据实际业务场景自行扩展。
- **分环境构建**，主要实现了将类 React 语法进行 AST 编译解析，根据构建平台分别编译成对应的 Bundle 产物。
- **自动化构建部署**，将构建能力接入 Talos（美团内部自研的构建部署工具），再结合低代码业务工具实现一键部署，将编译产物根据配置项上传至 DD（美团内部自研移动端动态下发平台）。

模板驱动方案

目前，R2X-Module 在客户端和小程序容器的同构率在 99.3% 以上，在性能方面首次渲染时长和模板渲染时长的 TP50 时间分别是 **185ms** 和 **144ms**，比较优秀但还存在优化空间。同时提供 R2X-Module SDK 供业务方选择。R2X-Module SDK

初始化以及模板加载渲染流程如下图所示：

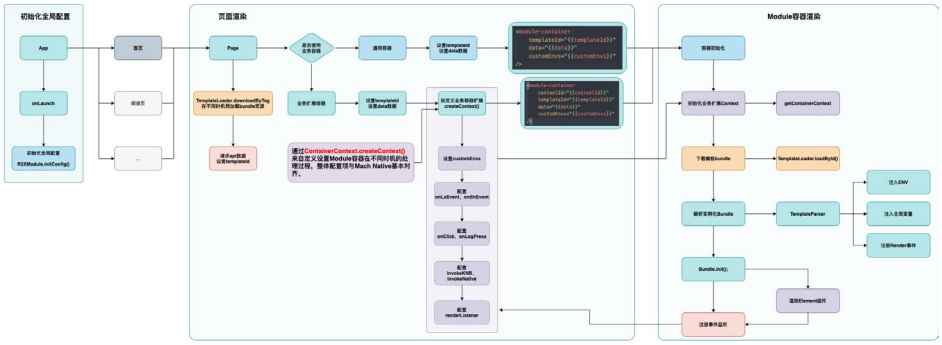

图 9

4.2.3 PC/App 适配同构

在移动互联网发展已经高度成熟的今天，移动端的 PV 流量占比绝大数，以外卖广告商家端为例，PC 端仅仅占有很少比例，其中 PC 流量占比在我们部分业务上已经不及 5%。因此在某些场景下实现 PC/App 的同构方案能够解放一部分人力，对提高开发效率来说是十分必要的。目前，外卖广告商家端的一些轻量布局差异的页面，已经完成了 PC/App 同构的方案设计和落地。

样式同构适配

同构样式库设计：

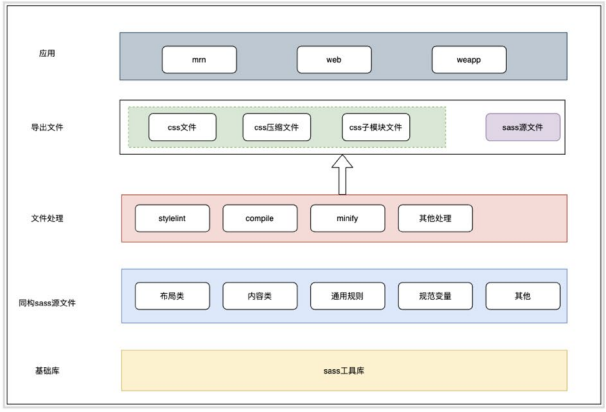

R2X样式转换插件：

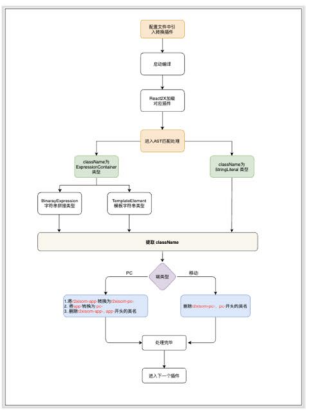

图 10

平台差异样式处理：

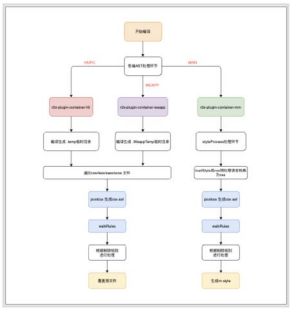

同构组件库：

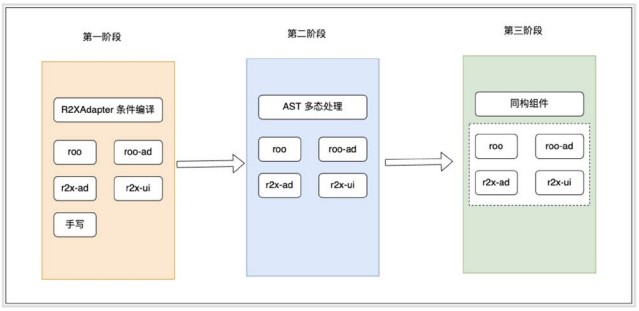

图 11

端能力扩展

R2X 的基础能力支持 Webview/MRN/ 小程序三端，缺少对 PC 微前端子项目的支持。要实现 PC/APP 多端同构需要对 R2X 的端能力进行扩展。PC 端本质上也属于 Web 端，因此 PC 微前端的端能力扩展可以复用大部分的 Webview 的端能力。整体架构图、技术设计要点、扩展流程图如下所示：

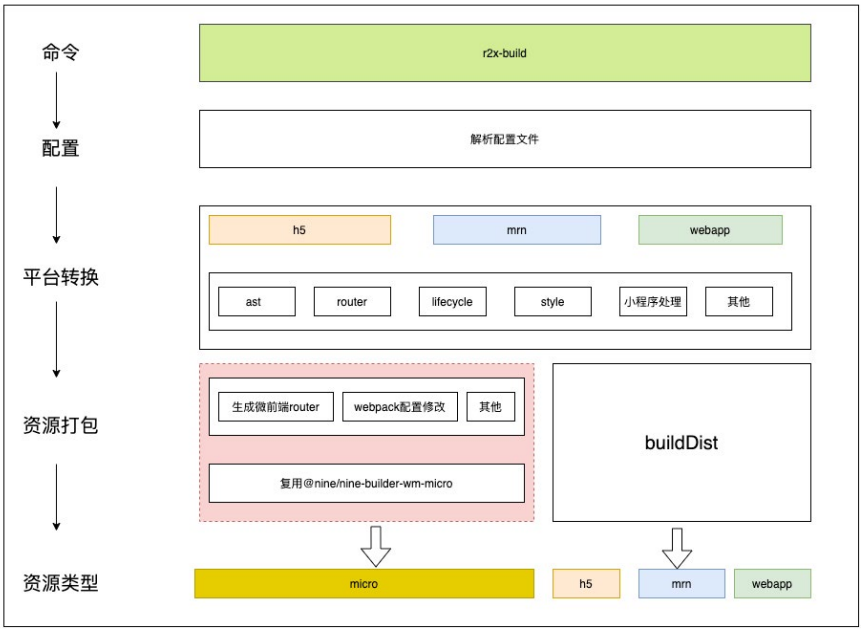

图 12

平台代码处理

在项目同构开发中，不可避免地会出现跟平台强相关的代码或者业务逻辑，比如某些 API 调用的是 App 的底层能力，只能在 React Native 中使用，在 Web 端肯定是不支持的。或者由于产品需求的原因，某些交互或者展示差异较大等等。而项目针对某一端进行编译、打包时，其他不相关的端代码是无用、多余的，如果保留的话，不仅会增加代码体积，甚至会出现编译报错，因此我们需要借助平台代码处理的能力来进行优化。平台代码的处理主要包含三部分：模块导入、组件展示、业务逻辑。

主要思路是使用注释和指定平台的方式，让特定的平台代码只在特定平台生效，注释关键字 `%%platform%%`，比如 `%%RN%%` 表示 React Native 端独有，`%%MICRO%%` 表示 PC 微前端独有，`%%MICRO|Webview%%` 表示 PC 微前端、Webview 两端生效。示例代码如下：

```
import A from '@r2x/r2x-a'; // %%RN%% 只在 React Native 端保留。
import B from '@r2x/r2x-b'; // %%MICRO%% 只在 MICRO 端保留。
import C from '@/utils/c'; // 这是所有端生效的公共模块。
import D from '@r2x/r2x-d'; // %%MICRO|Webview%% 在 MICRO、Webview 多端生效的模块。
```

4.2.4 小游戏容器场景同构

实现 react2x-game 同构方案主要做的两点：渲染层的兼容、业务层的兼容。

- **渲染层的兼容**：实现游戏引擎在多端环境下渲染能力的兼容（Canvas、WebGL）。
- **业务层的兼容**：实现基础 API、项目流程、公共模块的兼容，制定游戏差异的个性化定制规范。

渲染层兼容

在上文，我们提到过“无论是 Webview 游戏、小程序、小游戏、美团小游戏都为我们提供了 Canvas、WebGL 控件”，很大程度地降低了我们兼容渲染层的复杂度。下面表单，是各端对于语法以及 Canvas、WebGL、Document、Window 等基础功能的支持情况：

对象	Webview	微信小游戏	微信小程序	美团小游戏
语法	JavaScript	JavaScript	JavaScript	JavaScript
Canvas	支持	支持	支持	支持
Canvas（离屏）	支持	支持	不支持	支持
WebGL	支持	支持	>2.11.0	支持
Ducument	支持	不支持	不支持	不支持
Window	支持	不支持	不支持	不支持

可以看出，在语法层面各端都支持了 JavaScript 语法，但是在执行环境以及基础功能上的差异比较大，总结来说：

执行环境：小游戏、小程序不具备 DOM、BOM 的能力（渲染引擎中会大量使用）。

基础功能：小程序不支持离屏 Canvas，在 2.11.0 版本以后才开始支持 WebGL。

为了解决这些问题，我们设计开发了 adaptor 层，用来模拟 document、window 的能力。使游戏引擎可以在非 Webview 的环境下正常的执行和调用 BOM、DOM 的基础功能。同时，制定离屏 canvas 的适配方案，用来解决小程序无法支持离屏 canvas 的问题。为了获取到有效离屏 canvas，我们制作了 **“r2x-add-wxml-loader”，在 .wxml 文件的 loader 阶段自动注入额外的 < canvas/> 控件**，并隐藏于手机屏幕之外，用于模拟游戏引擎中的离屏 canvas。

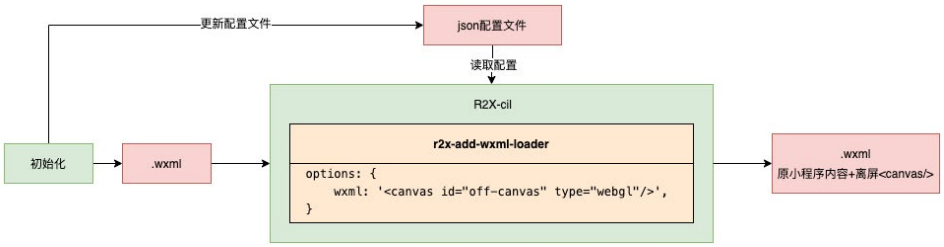

图 13

多端兼容构建

在构建层面，我们通过集成的多种个性化插件工具，对多端代码进行差异处理。如：环境变量注入、各端适配代码的混入、规范检测、代码解析和转化等。针对小游戏、

小程序代码和执行环境的特殊性，制作 wx-build-plugin、lwxapp-build-plugin 等用于处理小游戏和小程序的打包工作。结合上文中提到的各类差异的处理方案，制作 add-wxml-loader、transfrom-loader、wxss-loader 等工具协助完成项目构建。如下图 14 所示，构建之初会注入本次构建的环境变量，读取和分析配置文件，集成和初始化构建工具集合，为项目构建做准备。然后在构建环节，针对各端的差异进行差别处理，分析层针对不同文件进行解析，并在转换层进行转换和构建，最终生成各端需要的最终产物。

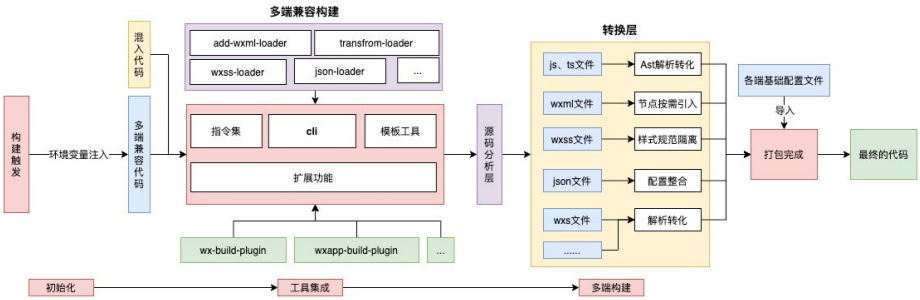

图 14

4.3 落地场景与效果

MRN效果图　　小程序效果图　　H5效果图

R2X- 推广页容器场景同构

R2X- 模块化容器场景同构

R2X- 小游戏容器场景同构

效果收益

R2X 在美团外卖业务中得到了广泛的应用。截止 2021 年 10 月，R2X 累计在美团内部已有二十多个部门在使用或者在调研中，总计落地了上百个工程、页面，框架下

载量达百万次，页面平均代码同构率达 90% 以上。R2X 生态体系在容器代码复用与运维层面，累计为美团节省成本上千人 / 日，并提升动态化页面转化 5%–8% 的成功率。

五、展望与总结

综上所述，在美团外卖多元化业务形态和容器多样性的情况下，跨容器复用成为了发展的必经之路。而 R2X 在经历了两年的迭代下也取得了阶段性的成果，在美团各个业务场景都完成了业务的落地覆盖，针对公司的生态环境接入也做出了不少的基础建设。我们相信跨容器多端代码复用依旧是当前缩减项目交付周期，减少研发成本，提升研发效率的重要一环。但目前我们在很多复杂的业务场景下做的不够完美，因此还有许多工作待完善，例如：

- **开发体验优化**，目前想接入或正在接入的兄弟部门已经越来越多，如何减少接入成本，丰富基础建设，优化开发体验，帮助大家快速迁移接入，将是下一阶段的重要课题。
- **渲染性能优化**，在美团外卖场景下性能优化一直是我们在兼顾高效生产的另一个重要指标。特别在小程序场景下，低端机型的性能体验一直是业界瓶颈，如何突破这一难关将会是同构方案全面推广的“敲门砖”。

最后，感谢各个相关研发团队对 R2X 建设过程中的鼎力支持，R2X 的发展离不开所有参与者日以继夜的投入和贡献，我们会持续基于 R2X 在终端容器领域进行更多探索。如果大家觉得 R2X 还不错，或者对美团的 R2X 框架比较感兴趣，欢迎跟我们一起交流探讨。

作者简介

正浩、宝石、彭震，均为美团外卖终端团队研发工程师。

招聘信息

美团外卖长期招聘 Android、iOS、FE、Java 高级 / 资深工程师和技术专家，欢迎有兴趣的同学投递简历到 lizhenghao@meituan.com。

一款可以让大型 iOS 工程编译速度提升 50% 的工具

作者：思琦　旭陶　霜叶

cocoapods-hmap-prebuilt 是什么?

cocoapods-hmap-prebuilt 是美团平台迭代组自研的一款 cocoapods 插件，以 Header Map 技术 为基础，进一步提升代码的编译速度，完善头文件的搜索机制。

虽然以二进制组件的方式构建 App 是 HPX（美团移动端统一持续集成 / 交付平台）的主流解决方案，但在某些场景下（Profile、Address/Thread/UB/Coverage Sanitizer、App 级别静态检查、ObjC 方法调用兼容性检查等等），我们的构建工作还是需要以全源码编译的方式进行；而且在实际开发过程中，大多是以源码的方式进行开发，所以我们将实验对象设置为基于全源码编译的流程。

废话不多说，我们来看看它的实际使用效果！

总的来说，以美团和大众点评的全源码编译流程为实验对象的前提下，cocoapods-hmap-prebuilt 插件能将总链路提升 45% 以上的速度，在 Xcode 打包环节上能提升 50% 以上的速度，是不是有点动心了?

为了更好的理解这个插件的价值和功能，我们不妨先看一下当前的工程中存在的问题。

为什么现有的项目不够好?

目前，美团内的 App 都是基于 CocoaPods 做包管理方面的工作，所以在实际的开发过程中，CocoaPods 会在 `Pods/Header/` 目录下添加组件名目录和头文件软链，类似于下面的形式：

```
/Users/sketchk/Desktop/MyApp/Pods
└──── Headers
```

```
    ├── Private
    │   └── AFNetworking
    │       ├── AFHTTPRequestOperation.h -> ./XXX/
AFHTTPRequestOperation.h
    │       ├── AFHTTPRequestOperationManager.h -> ./XXX/
AFHTTPRequestOperationManager.h
    │       ├── ...
    │       └── UIRefreshControl+AFNetworking.h -> ./XXX/
UIRefreshControl+AFNetworking.h
    └── Public
        └── AFNetworking
            ├── AFHTTPRequestOperation.h -> ./XXX/
AFHTTPRequestOperation.h
            ├── AFHTTPRequestOperationManager.h -> ./XXX/
AFHTTPRequestOperationManager.h
            ├── ...
            └── UIRefreshControl+AFNetworking.h -> ./XXX/
UIRefreshControl+AFNetworking.h
```

也正是通过这样的目录结构和软链，CocoaPods 得以在 Header Search Path 中添加如下的参数，使得预编译环节顺利进行。

```
$(inherited)
${PODS_ROOT}/Headers/Private
${PODS_ROOT}/Headers/Private/AFNetworking
${PODS_ROOT}/Headers/Public
${PODS_ROOT}/Headers/Public/AFNetworking
```

虽然这种构建 Search Path 的方式解决了预编译的问题，但在某些项目中，例如多达 400+ 组件的巨型项目中，会造成以下几点问题：

- 大量的 Header Search Path 路径，会造成编译参数中的 `-I` 选项极速膨胀，在达到一定长度后，甚至会造成无法编译的情况
- 目前美团的工程中，已经有近 5W 个头文件，这意味着不论是头文件的搜索过程，还是软链的创建过程，都会引起大量的文件 IO 操作，进而会产生一些耗时操作。
- 编译时间会随着组件数量急剧增长，以美团和大众点评有 400+ 个组件的体量为参考，全源码打包耗时均在 1 小时以上。
- 基于路径顺序查找头文件的方式有潜在的风险，例如重名头文件的情况，排在

后面的头文件永远无法参与编译。

- 由于 `${PODS_ROOT}/Headers/Private` 路径的存在，让引用其他组件的私有头文件变为了可能。

想解决上述的问题，好一点的情况下，可能会浪费 1 个小时，而不好的情况，就是让有风险的代码上线了，你说工程师会不会因此而感到头疼?

Header Map 是个啥?

还好 cocoapods-hmap-prebuilt 的出现，让这些问题变成了历史，不过要想理解它为什么能解决这些问题，我们得先理解一下什么是 Header Map。

Header Map 其实是一组头文件信息映射表!

为了更直观的理解 Header Map，我们可以在 Build Setting 中开启 Use Header Map 选项，真实的体验一下它。

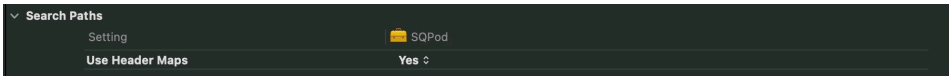

然后在 Build Log 里获取相应组件里对应文件的编译命令，并在最后加上 -v 参数，来查看其运行的秘密：

```
$ clang <list of arguments> -c some-file.m -o some-file.o -v
```

在 console 的输出内容中，我们会发现一段有意思的内容：

```
#include "..." search starts here:
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Intermediates.noindex/PodA.build/Debug-iphonesimulator/PodA_Exampl
e.build/PodA_Example-generated-files.hmap (headermap)
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Intermediates.noindex/PodA.build/Debug-iphonesimulator/PodA_Exampl
e.build/PodA_Example-project-headers.hmap (headermap)
#include <...> search starts here:
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Intermediates.noindex/PodA.build/Debug-iphonesimulator/PodA_Exampl
e.build/PodA_Example-own-target-headers.hmap (headermap)
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Intermediates.noindex/PodA.build/Debug-iphonesimulator/PodA_Exampl
e.build/PodA_Example-all-non-framework-target-headers.hmap (headermap)
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Products/Debug-iphonesimulator/PodA/PodA.framework/Headers
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Intermediates.noindex/PodA.build/Debug-iphonesimulator/PodA_Exampl
e.build/DerivedSources
```

通过上面的图，我们可以看到编译器将寻找头文件的顺序和对应路径展示出来了，而在这些路径中，我们看到了一些陌生的东西，即后缀名为 `.hmap` 的文件，后面还有个括号写着 headermap。

没错！它就是 Header Map 的实体。

此时 Clang 已经在刚才提到的 hmap 文件里塞入了一份头文件名和头文件路径的映射表，不过它是一种二进制格式的文件，为了验证这个的说法，我们可以通过 milend 编写的 hmap 工具来查其内容。

在执行相关命令（即 `hmap print`）后，我们可以发现这些 hmap 里保存的信息结构大致如下，类似于一个 Key-Value 的形式，Key 值是头文件的名称，Value 是头文件的实际物理路径：

```
sketchk ~/Desktop/Host git main
▶ hmap print /Users/sketchk/Library/Developer/Xcode/DerivedData/Host-ewmvmvyzlhizmsau
byxgeyqcnucf/Build/Intermediates.noindex/Pods.build/Debug-iphonesimulator/PodA.build/
PodA-own-target-headers.hmap
ClassA.h -> PodA/ClassA.h
ClassB.h -> PodA/ClassB.h
ClassF.h -> /Users/sketchk/Desktop/PodA/PodA/Classes/C/ClassF.h
PodA-umbrella.h -> PodA/PodA-umbrella.h
PodA/ClassF.h -> /Users/sketchk/Desktop/PodA/PodA/Classes/C/ClassF.h
```

需要注意，映射表的键值内容会随着使用场景产生不同的变化，例如头文件引用是在 `"..."` 的形式下，还是 `<...>` 的形式下，又或是在 Build Phase 里 Header 的配置情况。例如，你将头文件设置为 Public 的时候，在某些 hmap 中，它的 Key 值就为

`PodA/ClassA`，而将其设置为 project 的时候，它的 Key 值可能就是 `ClassA`，而配置这些信息的地方，如下图所示：

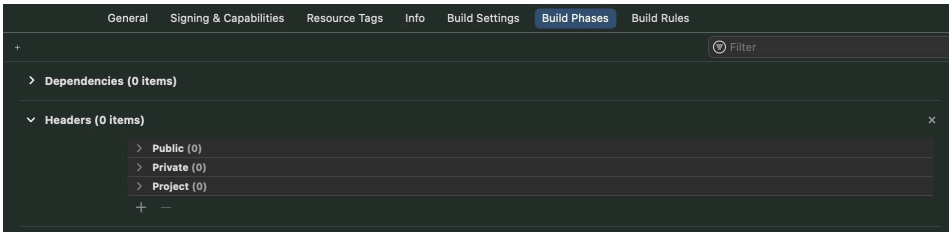

至此我想你应该了解到 Header Map 到底是个什么东西了。

当然这种技术也不是一个什么新鲜事儿，在 Facebook 的 buck 工具中也提供了类似的东西，只不过文件类型变成了 `HeaderMap.java` 的样子。

此时，我估计你可能并不会对 buck 产生太多的兴趣，而是开始思考上一张图中 Headers 的 Public、Private、Project 到底代表着什么意思，好像很多同学从来没怎么关注过，以及为什么它会影响 hmap 里的内容?

Public，Private，Project 是个啥?

在 Apple 官方的 Xcode Help – What are build phases? 文档中，我们可以看到如下的一段解释：

> Associates public, private, or project header files with the target. Public and private headers define API intended for use by other clients, and are copied into a product for installation. For example, public and private headers in a framework target are copied into Headers and Private-Headers subfolders within a product. Project headers define API used and built by a target, but not copied into a product. This phase can be used once per target.

总的来说，我们可以知道一点，就是 Build Phases – Headers 中提到 Public 和

Private 是指可以供外界使用的头文件，而 Project 中的头文件是不对外使用的，也不会放在最终的产物中。

如果你继续翻阅一些资料，例如 StackOverflow – Xcode: Copy Headers: Public vs. Private vs. Project? 和 StackOverflow – Understanding Xcode's Copy Headers phase，你会发现在早期 Xcode Help 的 Project Editor 章节里，有一段名为 Setting the Role of a Header File 的段落，里面详细记载了三个类型的区别。

> **Public:** The interface is finalized and meant to be used by your product's clients. A public header is included in the product as readable source code without restriction. **Private:** The interface isn't intended for your clients or it's in early stages of development. A private header is included in the product, but it's marked "private". Thus the symbols are visible to all clients, but clients should understand that they're not supposed to use them. **Project:** The interface is for use only by implementation files in the current project. A project header is not included in the target, except in object code. The symbols are not visible to clients at all, only to you.

至此，我们应该能够彻底了解了 Public、Private、Project 的区别。简而言之，Public 还是通常意义上的 Public，Private 则代表 In Progress 的含义，至于 Project 才是通常意义上的 Private 含义。

此时，你会不会联想到 CocoaPods 中 Podspec 的 Syntax 里还有 `public_header_files` 和 `private_header_files` 两个字段，它们的真实含义是否和 Xcode 里的概念冲突呢?

这里我们仔细阅读一下官方文档的解释，尤其是 `private_header_files` 字段。

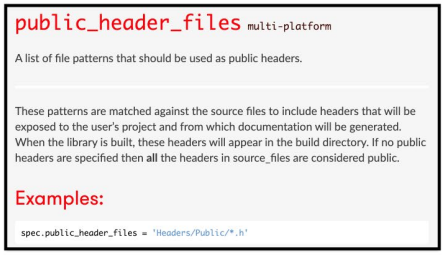

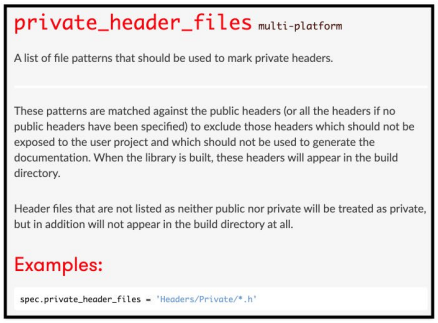

我们可以看到，`private_header_files` 在这里的含义是说，它本身是相对于 Public 而言的，这些头文件本义是不希望暴露给用户使用的，而且也不会产生相关文档，但是在构建的时候，会出现在最终产物中，只有既没有被 Public 和 Private 标注的头文件，才会被认为是真正的私有头文件，且不出现在最终的产物里。

看起来，CocoaPods 对于 Public 和 Private 的官方解释是和 Xcode 中的描述一致的，两处的 Private 并非我们通常理解的 Private，它的本意更应该是开发者准备对外开放，但又没完全 Ready 的头文件，更像一个 In Progress 的含义。

这一块是不是让你有点大跌眼镜？那么，在现实世界中，我们是否正确的使用了它们呢？

为什么用原生的 hmap 不能改善编译速度？

前面我们介绍了 hmap 是什么，以及怎么开启它（启用 Build Setting 中的 Use Header Map 选项），也介绍了一些影响生成 hmap 的因素（Public、Private、Project）。

那是不是我只要开启 Xcode 提供的 Use Header Map 就可以提升编译速度了呢？

很可惜，答案是否定的！

至于原因，我们就从下面的例子开始说起，假设我们有一个基于 CocoaPods 构建的全源码工程项目，它的整体结构如下：

- 首先，Host 和 Pod 是我们的两个 Project，Pods 下的 Target 的产物类型为 Static Library。

- 其次，Host 底下会有一个同名的 Target，而 Pods 目录下会有 n+1 个 Target，其中 n 取决于你依赖的组件数量，而 1 是一个名为 Pods-XXX 的 Target，最后，Pods-XXX 这个 Target 的产物会被 Host 里的 Target 所依赖。

整个结构看起来如下所示：

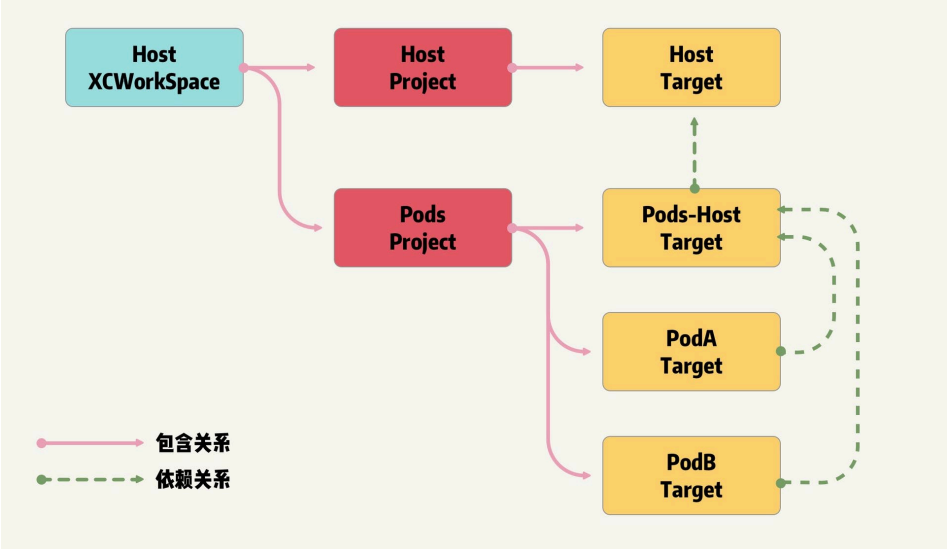

当构建的产物类型为 Static Library 的时候，CocoaPods 在创建头文件产物过程中，它的逻辑大致如下：

- 不论 podspec 里如何设置 `public_header_files` 和 `private_header_files`，相应的头文件都会被设置为 Project 类型。
- 在 `Pods/Headers/Public` 中会保存所有被声明为 `public_header_files` 的头文件。
- 在 `Pods/Headers/Private` 中会保存所有头文件，不论是 `public_header_files` 或者 `private_header_files` 描述到，还是那些未被描述的，这个目录下是当前组件的所有头文件全集。
- 如果 podspec 里未标注 Public 和 Private 的时候，`Pods/Headers/Public` 和 `Pods/Headers/Private` 的内容一样且会包含所有头文件。

正是由于这种机制，会导致一些有意思的问题发生。

- 首先，由于所有头文件都被当做最终产物保留下来，在结合 Header Search Path 里 `Pods/Headers/Private` 路径的存在，我们完全可以引用到其他组件里的私有头文件，例如我只要使用 `#import <SomePod/Private_Header.h>` 的方式，就会命中私有文件的匹配路径。
- 其次，就是在 Static Library 的状况下，一旦我们开启了 Use Header Map，结合组件里所有头文件的类型为 Project 的情况，这个 hmap 里只会包含 `#import "ClassA.h"` 的键值引用，也就是说只有 `#import "ClassA.h"` 的方式才会命中 hmap 的策略，否则都将通过 Header Search Path 寻找其相关路径，例如下图中的 PodB，在其 build 的过程中，Xcode 会为 PodB 生成 5 个 hmap 文件，也就是说这 5 个文件只会在编译 PodB 中使用，其中 PodB 会依赖 PodA 的一些头文件，但由于 PodA 中的头文件都是 Project 类型的，所以其在 hmap 里的 Key 全部为 `ClassA.h`，也就是说我们只能以 `#import "ClassA.h"` 的方式引入。

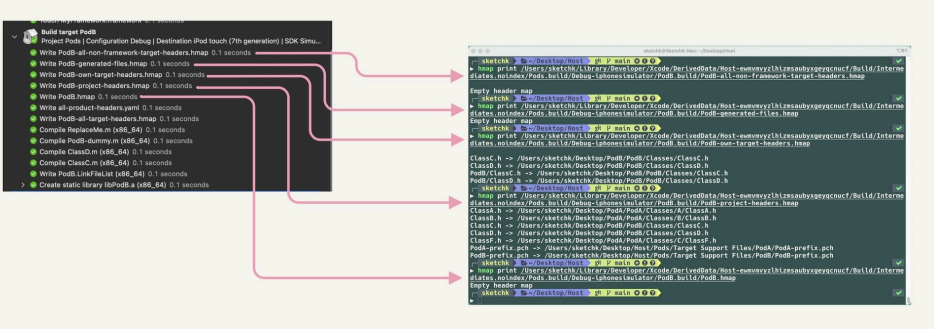

而我们也知道，在引用其他组件的时候，通常都会采用 `#import <A/A.h>` 的方式引入。至于为什么会用这种方式，一方面是这种写法会明确头文件的由来，避免问题，另一方面也是这种方式可以让我们在是否开启 clang module 中随意切换。当然，还有一点就是 Apple 在 WWDC 里曾经不止一次建议开发者使用这种方式来引入头文件。

接着上面的话题来说，所以说在 Static Library 的情况下且以 `#import <A/A.h>` 这

种标准方式引入头文件时，开启 Use Header Map 选项并不会帮我们提升编译速度。

但真的就没有办法使用 Header Map 了么?

cocoapods-hmap-prebuilt 诞生了

当然，总是有办法解决的，我们完全可以自己动手做一个基于 CocoaPods 规则下的 hmap 文件，正是基于这个想法，美团自研的 cocoapods-hmap-prebuilt 插件诞生了。

它的核心功能并不多，大概有以下几点：

- 借助 CocodPods 处理 Header Search Path 和创建头文件 soft link 的时机，构建了头文件索引表并以此生成 n+1 个 hmap 文件（n 是每个组件自己的 Private Header 信息，1 是所有组件公共的 Public Header 信息）。
- 重写 xcconfig 文件里的 Header Search Path 到对应的 hmap 文件上，一条指向组件自己的 private hmap，一条指向所有组件共用的 public hmap。
- 针对 public hmap 里的重名头文件进行了特殊处理，只允许保存组件名 / 头文件名方式的 Key-Value，排查重名头文件带来的异常行为。
- 将组件自身的 Ues Header Map 功能关闭，减少不必要的文件创建和读取。

听起来可能有点绕，内容也有点多，不过这些你都不用关心，你只需要通过以下 2 个步骤就能将其使用起来：

- 在 Gemfile 里声明插件。
- 在 Podfile 里使用插件。

```
// this is part of Gemfile
source 'http://sakgems.sankuai.com/' do
  gem 'cocoapods-hmap-prebuilt'
  gem 'XXX'
  ...
end

// this is part of Podfile
```

```
target 'XXX' do
  plugin 'cocoapods-hmap-prebuilt'
  pod 'XXX'
  ...
end
```

除此之外，为了拓展其实用性，我们还提供了头文件补丁（解决重名头文件的定向选取）和环境变量注入（无侵入的在其他系统中使用）的能力，便于其在不同场景下的使用。

总结

至此，关于 cocoapods-hmap-prebuilt 的介绍就要结束了。

回看整个故事的开始，Header Map 是我在研究 Swift 和 Objective-C 混编过程中发现的一个很小的知识点，而且 Xcode 自身就实现了一套基于 Header Map 的功能，在实际的使用过程中，它的表现并不理想。

但幸运的是，在后续的探索的过程中，我们发现了为什么 Xcode 的 Header Map 没有生效，以及为什么它与 CocoaPods 出现了不兼容的情况，虽然它的原理并不复杂，核心点就是将文件查找和读取等 IO 操作编变成了内存读取操作，但结合实际的业务场景，我们发现它的收益是十分可观的。

或许这是在提醒我们，要永远对技术保持一颗好奇的心！

其实，利用 Clang Module 技术也可以解决本文一开始提到的几个问题，但它并不在这篇文章的讨论范围中，如果你对 Clang Module 或者对 Swift 与 Objective-C 混编感兴趣，欢迎阅读参考文档中的《从预编译的角度理解 Swift 与 Objective-C 及混编机制》一文，以了解更多的详细信息。

参考文档

- Apple - WWDC 2018 Behind the Scenes of the Xcode Build Process
- Apple 的 HeaderMap.cpp 源码

作者

思琦，笔名 SketchK，美团 iOS 工程师，目前负责移动端 CI/CD 方面的工作及平台内 Swift 技术相关的事宜。
旭陶，美团 iOS 工程师，目前负责 iOS 端开发提效相关事宜。
霜叶，2015 年加入美团，先后从事过 Hybrid 容器、iOS 基础组件、iOS 开发工具链和客户端持续集成门户系统等工作。

从预编译的角度理解 Swift 与 Objective-C 及混编机制

作者：思琦　旭陶　霜叶

写在前面

本文涉及面较广，篇幅较长，阅读完需要耗费一定的时间与精力，如果你带有较为明确的阅读目的，可以参考以下建议完成阅读：

- 如果你对预编译的理论知识已经了解，可以直接从【原来它是这样的】的章节开始进行阅读，这会让你对预编译有一个更直观的了解。
- 如果你对 Search Path 的工作机制感兴趣，可以直接从【关于第一个问题】的章节阅读，这会让你更深刻，更全面的了解到它们的运作机制，
- 如果您对 Xcode Phases 里的 Header 的设置感到迷惑，可以直接从【揭开 Public、Private、Project 的真实面目】的章节开始阅读，这会让你理解为什么说 Private 并不是真正的私有头文件
- 如果你想了解如何通过 hmap 技术提升编译速度，可以从【基于 hmap 优化 Search Path 的策略】的章节开始阅读，这会给你提供一种新的编译加速思路。
- 如果你想了解如何通过 VFS 技术进行 Swift 产物的构建，可以从【关于第二个问题】章节开始阅读，这会让你理解如何用另外一种提升构建 Swift 产物的效率。
- 如果你想了解 Swift 和 Objective-C 是如何找寻方法声明的，可以从【Swift 来了】的章节阅读，这会让你从原理上理解混编的核心思路和解决方案。

概述

随着 Swift 的发展，国内技术社区出现了一些关于如何实现 Swift 与 Objective-C 混编的文章，这些文章的主要内容还是围绕着指导开发者进行各种操作来实现混编的效果，例如在 Build Setting 中开启某个选项，在 podspec 中增加某个字段，而鲜有文章对这些操作背后的工作机制做剖析，大部分核心概念也都是一笔带过。

正是因为这种现状，很多开发者在面对与预期不符的行为时，亦或者遇到各种奇怪的报错时，都会无从下手，而这也是由于对其工作原理不够了解所导致的。

笔者在美团平台负责 CI/CD 相关的工作，这其中也包含了 Objective-C 与 Swift 混编的内容，出于让更多开发者能够进一步理解混编工作机制的目的，撰写了这篇技术文章。

废话不多说，我们开始吧！

预编译知识指北

`#import` 的机制和缺点

在我们使用某些系统组件的时候，我们通常会写出如下形式的代码：

```
#import <UIKit/UIKit.h>
```

`#import` 其实是 `#include` 语法的微小创新，它们在本质上还是十分接近的。`#include` 做的事情其实就是简单的复制粘贴，将目标 `.h` 文件中的内容一字不落地拷贝到当前文件中，并替换掉这句 `#include`，而 `#import` 实质上做的事情和 `#include` 是一样的，只不过它还多了一个能够避免头文件重复引用的能力而已。

为了更好的理解后面的内容，我们这里需要展开说一下它到底是如何运行的?

从最直观的角度来看：

假设在 `MyApp.m` 文件中，我们 `#import` 了 `iAd.h` 文件，编译器解析此文件后，开始寻找 iAd 包含的内容（`ADInterstitialAd.h`，`ADBannerView.h`），及这些内容包含的子内容（`UIKit.h`，`UIController.h`，`UIView.h`，`UIResponder.h`），并依次递归下去，最后，你会发现 `#import <iAd/iAd.h>` 这段代码变成了对不同 SDK 的头文件依赖。

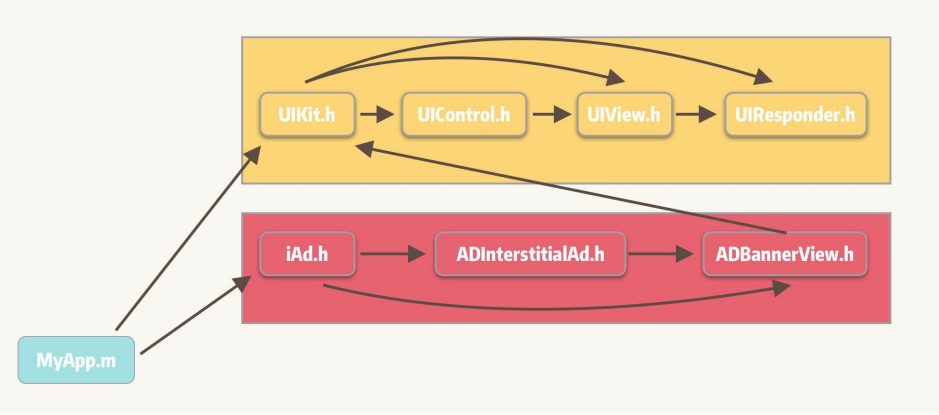

如果你觉得听起来有点费劲，或者似懂非懂，我们这里可以举一个更加详细的例子，不过请记住，对于 C 语言的预处理器而言，`#import` 就是一种特殊的复制粘贴。

结合前面提到的内容，在 AppDelegate 中添加 `iAd.h`：

```
#import <iAd/iAd.h>
@implementation AppDelegate
//...
@end
```

然后编译器会开始查找 `iAd/iAd.h` 到底是哪个文件且包含何种内容，假设它的内容如下：

```
/* iAd/iAd.h */
#import <iAd/ADBannerView.h>
#import <iAd/ADBannerView_Deprecated.h>
#import <iAd/ADInterstitialAd.h>
```

在找到上面的内容后，编译器将其复制粘贴到 AppDelegate 中：

```
#import <iAd/ADBannerView.h>
#import <iAd/ADBannerView_Deprecated.h>
#import <iAd/ADInterstitialAd.h>

@implementation AppDelegate
//...
@end
```

现在，编译器发现文件里有 3 个 `#import` 语句 了，那么就需要继续寻找这些文件及其相应的内容，假设 `ADBannerView.h` 的内容如下：

```
/* iAd/ADBannerView.h */
@interface ADBannerView : UIView
@property (nonatomic, readonly) ADAdType adType;

- (id)initWithAdType:(ADAdType)type

/* ... */
@end
```

那么编译器会继续将其内容复制粘贴到 AppDelegate 中，最终变成如下的样子：

```
@interface ADBannerView : UIView
@property (nonatomic, readonly) ADAdType adType;

- (id)initWithAdType:(ADAdType)type

/* ... */
@end
#import <iAd/ADBannerView_Deprecated.h>
#import <iAd/ADInterstitialAd.h>

@implementation AppDelegate
//...
@end
```

这样的操作会一直持续到整个文件中所有 `#import` 指向的内容被替换掉，这也意味着 `.m` 文件最终将变得极其的冗长。

虽然这种机制看起来是可行的，但它有两个比较明显的问题：健壮性和拓展性。

健壮性

首先这种编译模型会导致代码的健壮性变差！

这里我们继续采用之前的例子，在 AppDelegate 中定义 `readonly` 为 `0x01`，而且这个定义的声明在 `#import` 语句之前，那么此时又会发生什么事情呢?

编译器同样会进行刚才的那些复制粘贴操作，但可怕的是，你会发现那些在属性声明

中的 `readonly` 也变成了 `0x01`，而这会触发编译器报错！

```
@interface ADBannerView : UIView
@property (nonatomic, 0x01) ADAdType adType;

- (id)initWithAdType:(ADAdType)type

/* ... */
@end

@implementation AppDelegate
//...
@end
```

面对这种错误，你可能会说它是开发者自己的问题。

确实，通常我们都会在声明宏的时候带上固定的前缀来进行区分。但生活里总是有一些意外，不是么?

假设某个人没有遵守这种规则，那么在不同的引入顺序下，你可能会得到不同的结果，对于这种错误的排查，还是挺闹心的。不过，这还不是最闹心的，因为还有动态宏的存在，心塞 ing。

所以这种靠遵守约定来规避问题的解决方案，并不能从根本上解决问题，这也从侧面反应了编译模型的健壮性是相对较差的。

拓展性

说完了健壮性的问题，我们来看看拓展性的问题。

Apple 公司对它们的 Mail App 做过一个分析，下图是 Mail 这个项目里所有 `.m` 文件的排序，横轴是文件编号排序，纵轴是文件大小。

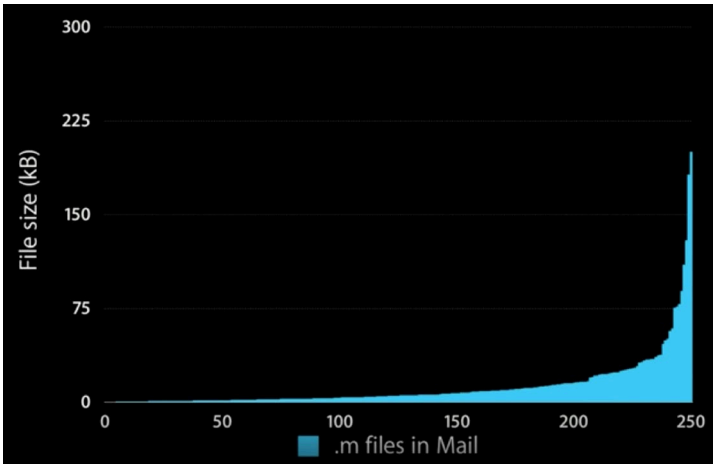

可以看到这些由业务代码构成的文件大小的分布区间很广泛，最小可能有几 kb，最大的能有 200+ kb，但总的来说，可能 90% 的代码都在 50kb 这个数量级之下，甚至更少。

如果我们往该项目的某个核心文件（核心文件是指其他文件可能都需要依赖的文件）里添加了一个对 `iAd.h` 文件的引用，对其他文件意味着什么呢?

> 这里的核心文件是指其他文件可能都需要依赖的文件

这意味着其他文件也会把 `iAd.h` 里包含的东西纳入进来，当然，好消息是，iAd 这个 SDK 自身只有 25KB 左右的大小。

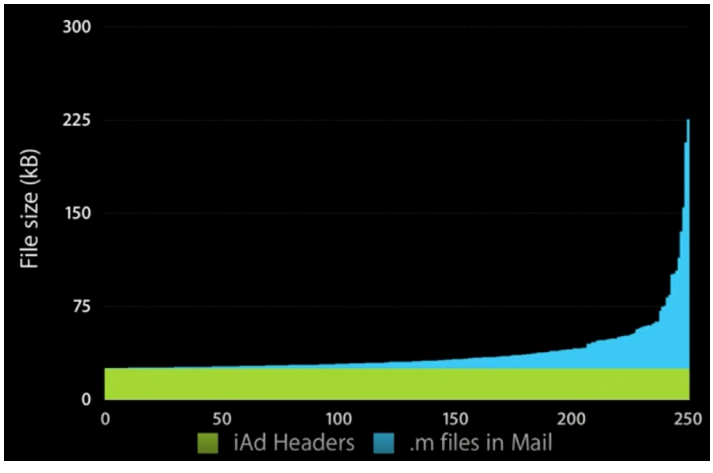

但你得知道 iAd 还会依赖 UIKit 这样的组件，这可是个 400KB+ 的大家伙

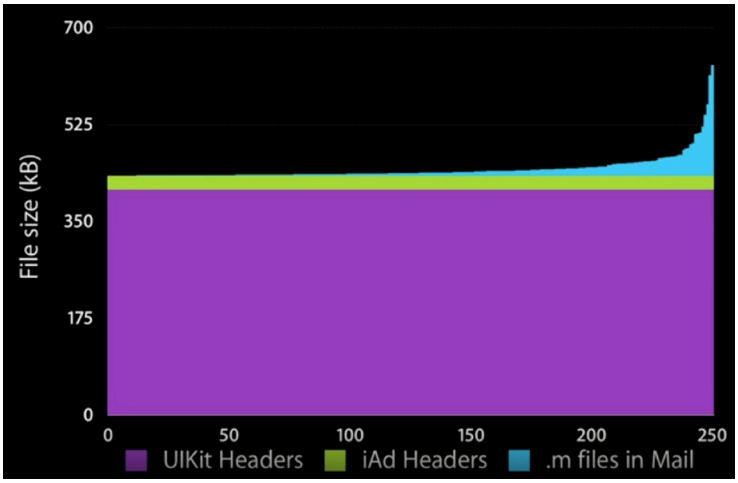

所以，怎么说呢?

在 Mail App 里的所有代码都需要先涵盖这将近 425KB 的头文件内容，即使你的代码只有一行 `Hello World`。

如果你认为这已经让人很沮丧的话，那还有更打击你的消息，因为 UIKit 相比于 macOS 上的 Cocoa 系列大礼包，真的小太多了，Cocoa 系列大礼包可是 UIKit 的 29 倍……

所以如果将这个数据放到上面的图表中，你会发现真正的业务代码在 File Size 轴上的比重真的太微不足道了。

所以这就是拓展性差带来的问题之一!

很明显，我们不可能用这样的方式引入代码，假设你有 M 个源文件且每个文件会引入 N 个头文件，按照刚才的解释，编译它们的时间就会是 M * N，这是非常可怕的!

> 备注：文章里提到的 iAd 组件为 25KB，UIKit 组件约为 400KB，macOS 的 Cocoa 组件是 UIKit 的 29 倍等数据，是 WWDC 2013 Session 404 Advances in Objective-C 里公布的数据，随着功能的不断迭代，以现在的眼光来看，这些数据可能已经偏小，在 WWDC 2018 Session 415 Behind the Scenes of the Xcode Build Process 中提到了 Foundation 组件，它包含的头文件数量大于 800 个，大小已经超过 9MB。

PCH(PreCompiled Header) 是一把双刃剑

为了优化前面提到的问题，一种折中的技术方案诞生了，它就是 PreCompiled Header。

我们经常可以看到某些组件的头文件会频繁的出现，例如 UIKit，而这很容易让人联想到一个优化点，我们是不是可以通过某种手段，避免重复编译相同的内容呢?

而这就是 PCH 为预编译流程带来的改进点!

它的大体原理就是，在我们编译任意 `.m` 文件前，编译器会先对 PCH 里的内容进行预编译，将其变为一种二进制的中间格式缓存起来，便于后续的使用。当开始编译 `.m` 文件时，如果需要 PCH 里已经编译过的内容，直接读取即可，无须再次编译。

虽然这种技术有一定的优势，但实际应用起来，还存在不少的问题。

首先，它的维护是有一定的成本的，对于大部分历史包袱沉重的组件来说，将项目中的引用关系梳理清楚就十分麻烦，而要在此基础上梳理出合理的 PCH 内容就更加麻烦，同时随着版本的不断迭代，哪些头文件需要移出 PCH，哪些头文件需要移进 PCH 将会变得越来越麻烦。

其次，PCH 会引发命名空间被污染的问题，因为 PCH 引入的头文件会出现在你代码中的每一处，而这可能会是多于的操作，比如 iAd 应当出现在一些与广告相关的代码中，它完全没必要出现在帮助相关的代码中（也就是与广告无关的逻辑），可是当你把它放到 PCH 中，就意味组件里的所有地方都会引入 iAd 的代码，包括帮助页面，

这可能并不是我们想要的结果！

> 如果你想更深入的了解 PCH 的黑暗面，建议阅读 4 Ways Precompiled Headers Cripple Your Code ，里面已经说得相当全面和透彻。

所以 PCH 并不是一个完美的解决方案，它能在某些场景下提升编译速度，但也有缺陷！

Clang Module 的来临！

为了解决前面提到的问题，Clang 提出了 Module 的概念，关于它的介绍可以在 Clang 官网 上找到。

简单来说，你可以把它理解为一种对组件的描述，包含了对接口（API）和实现（dylib/a）的描述，同时 Module 的产物是被独立编译出来的，不同的 Module 之间是不会影响的。

在实际编译之时，编译器会创建一个全新的空间，用它来存放已经编译过的 Module 产物。如果在编译的文件中引用到某个 Module 的话，系统将优先在这个列表内查找是否存在对应的中间产物，如果能找到，则说明该文件已经被编译过，则直接使用该中间产物，如果没找到，则把引用到的头文件进行编译，并将产物添加到相应的空间中以备重复使用。

在这种编译模型下，被引用到的 Module 只会被编译一次，且在运行过程中不会相互影响，这从根本上解决了健壮性和拓展性的问题。

Module 的使用并不麻烦，同样是引用 iAd 这个组件，你只需要这样写即可。

```
@import iAd;
```

在使用层面上，这将等价于以前的 `#import <iAd/iAd.h>` 语句，但是会使用 Clang Module 的特性加载整个 iAd 组件。如果只想引入特定文件（比如 `ADBannerView.h`），原先的写法是 `#import <iAd/ADBannerView.h>`，现在可以写成：

```
@import iAd.ADBannerView;
```

通过这种写法会将 iAd 这个组件的 API 导入到我们的应用中，同时这种写法也更符合语义化（semanitc import）。

虽然这种引入方式和之前的写法区别不大，但它们在本质上还是有很大程度的不同，Module 不会“复制粘贴”头文件里的内容，也不会让 `@import` 所暴露的 API 被开发者本地的上下文篡改，例如前面提到的 `#define readonly 0x01`。

此时，如果你觉得前面关于 Clang Module 的描述还是太抽象，我们可以再进一步去探究它工作原理，而这就会引入一个新的概念—— modulemap。

不论怎样，Module 只是一个对组件的抽象描述罢了，而 modulemap 则是这个描述的具体呈现，它对框架内的所有文件进行了结构化的描述，下面是 UIKit 的 modulemap 文件。

```
framework module UIKit {
  umbrella header "UIKit.h"
  module * {export *}
  link framework "UIKit"
}
```

这个 Module 定义了组件的 Umbrella Header 文件（UIKit.h），需要导出的子 Module（所有），以及需要 Link 的框架名称（UIKit），正是通过这个文件，让编译器了解到 Module 的逻辑结构与头文件结构的关联方式。

可能又有人会好奇，为什么我从来没看到过 `@import` 的写法呢？

这是因为 Xcode 的编译器能够将符合某种格式的 `#import` 语句自动转换成 Module 识别的 `@import` 语句，从而避免了开发者的手动修改。

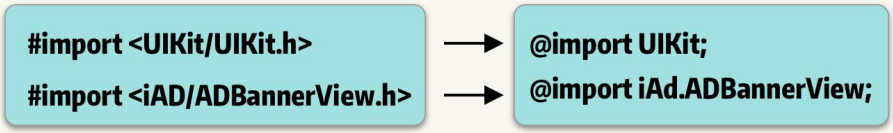

唯一需要开发者完成的就是开启相关的编译选项。

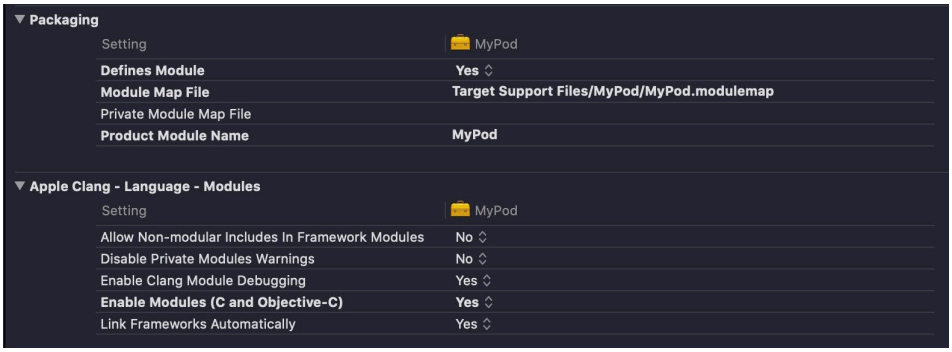

对于上面的编译选项，需要开发者注意的是：

`Apple Clang - Language - Modules` 里 `Enable Module` 选项是指引用系统库的的时候，是否采用 Module 的形式。

而 `Packaging` 里的 `Defines Module` 是指开发者编写的组件是否采用 Module 的形式。

说了这么多，我想你应该对 `#import`，`pch`，`@import` 有了一定的概念。当然，如果我们深究下去，可能还会有如下的疑问：

- 对于未开启 Clang Module 特性的组件，Clang 是通过怎样的机制查找到头文件的呢？在查找系统头文件和非系统头文件的过程中，有什么区别么？
- 对于已开启 Clang Module 特性的组件，Clang 是如何决定编译当下组件的 Module 呢？另外构建的细节又是怎样的，以及如何查找这些 Module 的？还有查找系统的 Module 和非系统的 Module 有什么区别么？

为了解答这些问题，我们不妨先动手实践一下，看看上面的理论知识在现实中的样子。

原来它是这样的

在前面的章节中，我们将重点放在了原理上的介绍，而在这个章节中，我们将动手看看这些预编译环节的实际样子。

`#import` 的样子

假设我们的源码样式如下：

```
#import "SQViewController.h"
#import <SQPod/ClassA.h>

@interface SQViewController ()
@end

@implementation SQViewController
- (void)viewDidLoad {
    [super viewDidLoad];
    ClassA *a = [ClassA new];
    NSLog(@"%@", a);
}

- (void)didReceiveMemoryWarning {
    [super didReceiveMemoryWarning];
}
@end
```

想要查看代码预编译后的样子，我们可以在 `Navigate to Related Items` 按钮中找到 `Preprocess` 选项

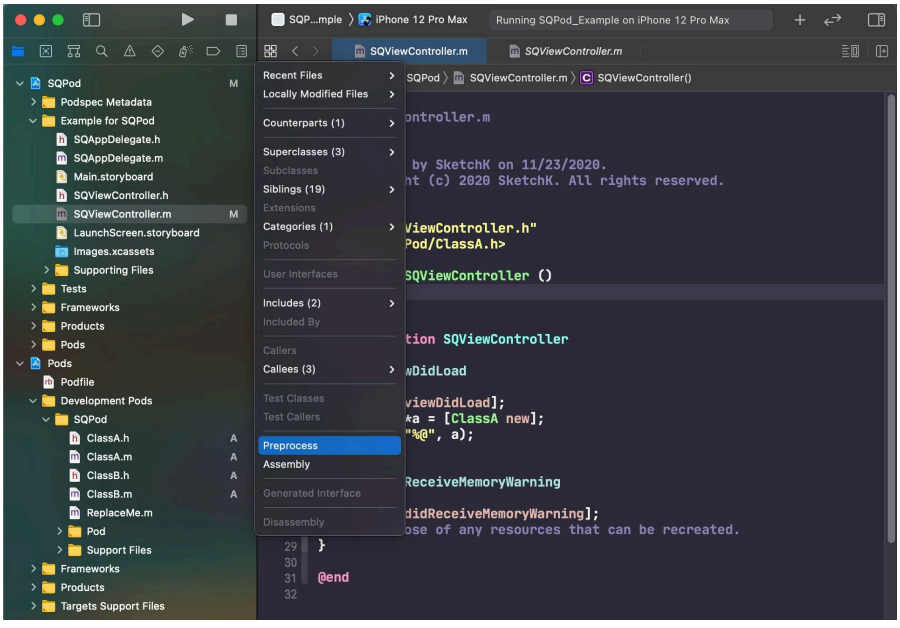

既然知道了如何查看预编译后的样子，我们不妨看看代码在使用 `#import`, PCH 和 `@import` 后，到底会变成什么样子?

这里我们假设被引入的头文件，即 ClassA 中的内如下：

```
@interface ClassA : NSObject
@property (nonatomic, strong) NSString *name;
- (void)sayHello;
@end
```

通过 preprocess 可以看到代码大致如下，这里为了方便展示，将无用代码进行了删除。这里记得要将 Build Setting 中 Packaging 的 `Define Module` 设置为 NO，因为其默认值为 YES，而这会导致我们开启 Clang Module 特性。

```
@import UIKit;
@interface SQViewController : UIViewController
@end

@interface ClassA : NSObject
@property (nonatomic, strong) NSString *name;
- (void)sayHello;
@end

@interface SQViewController ()
@end

@implementation SQViewController
- (void)viewDidLoad {
    [super viewDidLoad];
    ClassA *a = [ClassA new];
    NSLog(@"%@", a);
}

- (void)didReceiveMemoryWarning {
    [super didReceiveMemoryWarning];
}
@end
```

这么一看，`#import` 的作用还就真的是个 Copy & Write。

PCH 的真容

对于 CocoaPods 默认创建的组件，一般都会关闭 PCH 的相关功能，例如笔者创建的 SQPod 组件，它的 `Precompile Prefix Header` 功能默认值为 NO。

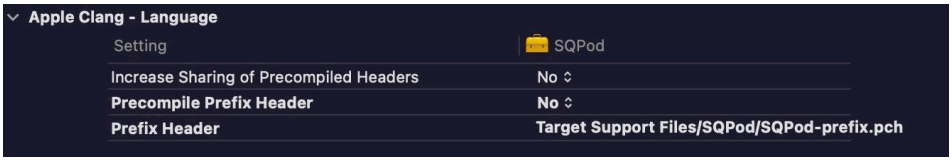

为了查看预编译的效果，我们将 `Precompile Prefix Header` 的值改为 YES，并编译整个项目，通过查看 Build Log，我们可以发现相比于 NO 的状态，在编译的过程中，增加了一个步骤，即 `Precompile SQPod-Prefix.pch` 的步骤。

通过查看这个命令的 `-o` 参数，我们可以知道其产物是名为 `SQPod-Prefix.pch.gch` 的文件。

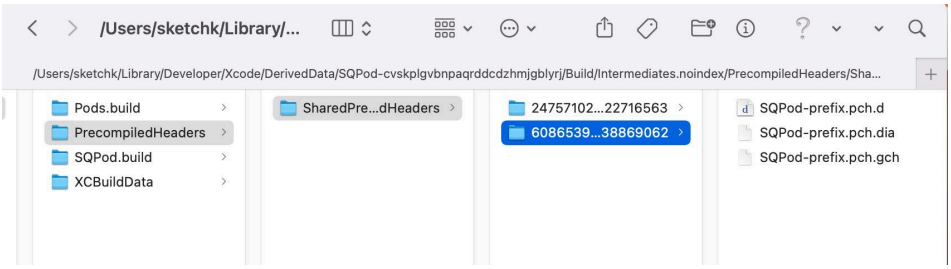

这个文件就是 PCH 预编译后的产物，同时在编译真正的代码时，会通过 `-include` 参数将其引入。

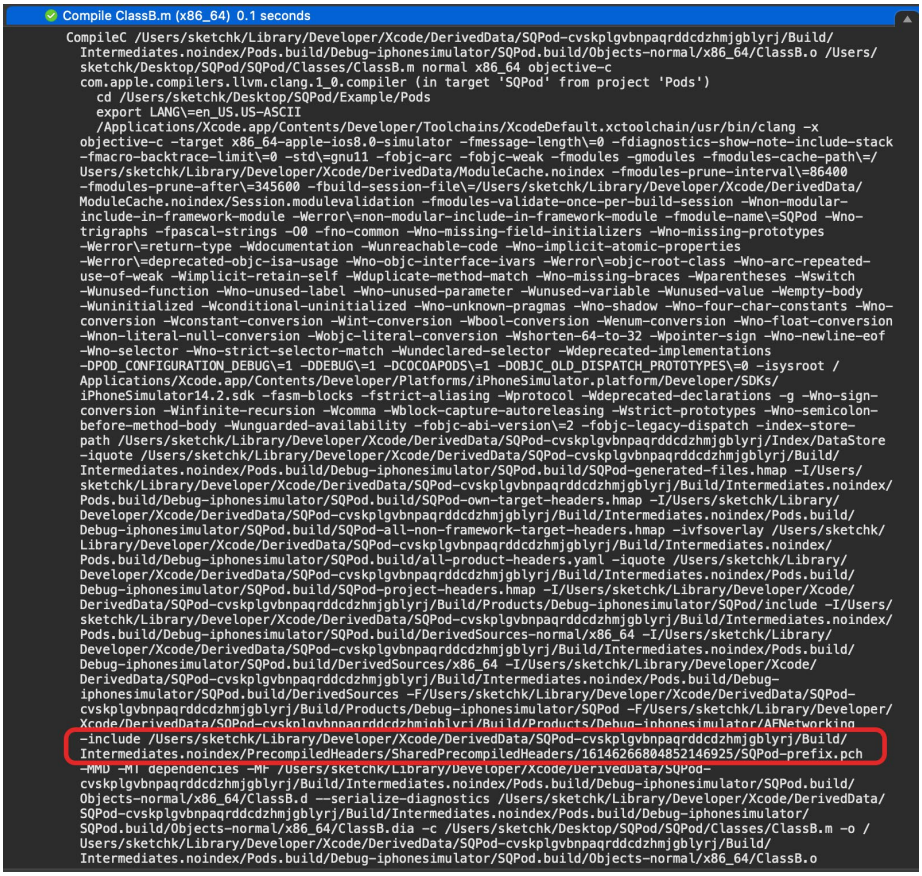

又见 Clang Module

在开启 Define Module 后，系统会为我们自动创建相应的 modulemap 文件，这一点可以在 Build Log 中查找到。

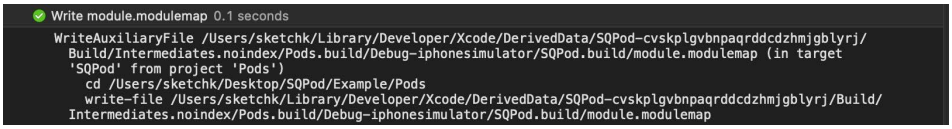

它的内容如下：

```
framework module SQPod {
  umbrella header "SQPod-umbrella.h"

  export *
  module * { export * }
}
```

当然，如果系统自动生成的 modulemap 并不能满足你的诉求，我们也可以使用自己创建的文件，此时只需要在 Build Setting 的 Module Map File 选项中填写好文件路径，相应的 clang 命令参数是 `-fmodule-map-file`。

最后让我们看看 Module 编译后的产物形态。

这里我们构建一个名为 SQPod 的 Module ，将它提供给名为 Example 的工程使用，通过查看 `-fmodule-cache-path` 的参数，我们可以找到 Module 的缓存路径。

```
Compile SQViewController.m (x86_64) 0.2 seconds
CompileC /Users/sketchk/Library/Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/
  Intermediates.noindex/SQPod.build/Debug-iphonesimulator/SQPod_Example.build/Objects-normal/x86_64/
  SQViewController.o /Users/sketchk/Desktop/SQPod/Example/SQPod/SQViewController.m normal x86_64 objective-c
  com.apple.compilers.llvm.clang.1_0.compiler (in target 'SQPod_Example' from project 'SQPod')
    cd /Users/sketchk/Desktop/SQPod/Example
    export LANG\=en_US.US-ASCII
    /Applications/Xcode.app/Contents/Developer/Toolchains/XcodeDefault.xctoolchain/usr/bin/clang -x
  objective-c -target x86_64-apple-ios12.0-simulator -fmessage-length\=0 -fdiagnostics-show-note-include-
  stack -fmacro-backtrace-limit\=0 -std\=gnu99 -fobjc-arc -fmodules -gmodules -fmodules-cache-path\=/Users/
  sketchk/Library/Developer/Xcode/DerivedData/ModuleCache.noindex -fmodules-prune-interval\=86400 -fmodules-
  prune-after\=345600 -fbuild-session-file\=/Users/sketchk/Library/Developer/Xcode/DerivedData/
  ModuleCache.noindex/Session.modulevalidation -fmodules-validate-once-per-build-session -Wnon-modular-
  include-in-framework-module -Werror\=non-modular-include-in-framework-module -Wno-trigraphs -fpascal-
  strings -O0 -fno-common -Wno-missing-field-initializers -Wno-missing-prototypes -Werror\=return-type
  -Wunreachable-code -Wno-implicit-atomic-properties -Werror\=deprecated-objc-isa-usage -Wno-objc-interface-
  ivars -Werror\=objc-root-class -Wno-arc-repeated-use-of-weak -Wimplicit-retain-self -Wduplicate-method-
  match -Wno-missing-braces -Wparentheses -Wswitch -Wunused-function -Wno-unused-label -Wno-unused-parameter
  -Wunused-variable -Wunused-value -Wempty-body -Wuninitialized -Wconditional-uninitialized -Wno-unknown-
  pragmas -Wno-shadow -Wno-four-char-constants -Wno-conversion -Wconstant-conversion -Wint-conversion -Wbool-
  conversion -Wenum-conversion -Wno-float-conversion -Wnon-literal-null-conversion -Wobjc-literal-conversion
  -Wshorten-64-to-32 -Wpointer-sign -Wno-newline-eof -Wno-selector -Wno-strict-selector-match -Wundeclared-
  selector -Wdeprecated-implementations -DDEBUG\=1 -DCOCOAPODS\=1 -DOBJC_OLD_DISPATCH_PROTOTYPES\=0
  -isysroot /Applications/Xcode.app/Contents/Developer/Platforms/iPhoneSimulator.platform/Developer/SDKs/
  iPhoneSimulator14.2.sdk -fasm-blocks -fstrict-aliasing -Wprotocol -Wdeprecated-declarations -g -Wno-sign-
  conversion -Winfinite-recursion -Wcomma -Wblock-capture-autoreleasing -Wstrict-prototypes -Wno-semicolon-
  before-method-body -fobjc-abi-version\=2 -fobjc-legacy-dispatch -index-store-path /Users/sketchk/Library/
  Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Index/DataStore -iquote /Users/sketchk/
  Library/Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/Intermediates.noindex/
  SQPod.build/Debug-iphonesimulator/SQPod_Example.build/SQPod_Example-generated-files.hmap -I/Users/sketchk/
  Library/Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/Intermediates.noindex/
  SQPod.build/Debug-iphonesimulator/SQPod_Example.build/SQPod_Example-own-target-headers.hmap -I/Users/
  sketchk/Library/Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/Intermediates.noindex/
  SQPod.build/Debug-iphonesimulator/SQPod_Example.build/SQPod_Example-all-non-framework-target-headers.hmap
  -ivfsoverlay /Users/sketchk/Library/Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/
  Intermediates.noindex/SQPod.build/Debug-iphonesimulator/SQPod_Example.build/all-product-headers.yaml
  -iquote /Users/sketchk/Library/Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/
  Intermediates.noindex/SQPod.build/Debug-iphonesimulator/SQPod_Example.build/SQPod_Example-project-
  headers.hmap -I/Users/sketchk/Library/Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/
  Products/Debug-iphonesimulator/include -I/Users/sketchk/Library/Developer/Xcode/DerivedData/SQPod-
  cvskplgvbnpaqrddcdzhmjgblyrj/Build/Products/Debug-iphonesimulator/AFNetworking/AFNetworking.framework/
  Headers -I/Users/sketchk/Library/Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/
  Products/Debug-iphonesimulator/SQPod/SQPod.framework/Headers -I/Users/sketchk/Library/Developer/Xcode/
  DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/Intermediates.noindex/SQPod.build/Debug-
  iphonesimulator/SQPod_Example.build/DerivedSources-normal/x86_64 -I/Users/sketchk/Library/Developer/Xcode/
  DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/Intermediates.noindex/SQPod.build/Debug-
  iphonesimulator/SQPod_Example.build/DerivedSources/x86_64 -I/Users/sketchk/Library/Developer/Xcode/
  DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/Intermediates.noindex/SQPod.build/Debug-
  iphonesimulator/SQPod_Example.build/DerivedSources -F/Users/sketchk/Library/Developer/Xcode/DerivedData/
  SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/Products/Debug-iphonesimulator -F/Users/sketchk/Library/Developer/
  Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/Products/Debug-iphonesimulator/AFNetworking -F/
  Users/sketchk/Library/Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/Products/Debug-
  iphonesimulator/SQPod -include /Users/sketchk/Library/Developer/Xcode/DerivedData/SQPod-
  cvskplgvbnpaqrddcdzhmjgblyrj/Build/Intermediates.noindex/PrecompiledHeaders/SharedPrecompiledHeaders/
  247571024832271656 3/SQPod-Prefix.pch -MMD -MT dependencies -MF /Users/sketchk/Library/Developer/Xcode/
  DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/Intermediates.noindex/SQPod.build/Debug-
  iphonesimulator/SQPod_Example.build/Objects-normal/x86_64/SQViewController.d --serialize-diagnostics /
  Users/sketchk/Library/Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/
  Intermediates.noindex/SQPod.build/Debug-iphonesimulator/SQPod_Example.build/Objects-normal/x86_64/
  SQViewController.dia -c /Users/sketchk/Desktop/SQPod/Example/SQPod/SQViewController.m -o /Users/sketchk/
  Library/Developer/Xcode/DerivedData/SQPod-cvskplgvbnpaqrddcdzhmjgblyrj/Build/Intermediates.noindex/
  SQPod.build/Debug-iphonesimulator/SQPod_Example.build/Objects-normal/x86_64/SQViewController.o
```

进入对应的路径后，我们可以看到如下的文件：

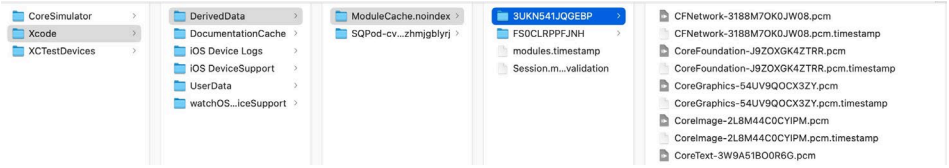

其中后缀名为 `pcm` 的文件就是构建出来的二进制中间产物。

现在，我们不仅知道了预编译的基础理论知识，也动手查看了预编译环节在真实环境下的产物，现在我们要开始解答之前提到的两个问题了！

打破砂锅问到底

关于第一个问题

> 对于未开启 Clang Module 特性的组件，Clang 是通过怎样的机制查找到头文件的呢？在查找系统头文件和非系统头文件的过程中，有什么区别么？

在早期的 Clang 编译过程中，头文件的查找机制还是基于 Header Seach Path 的，这也是大多数人所熟知的工作机制，所以我们不做赘述，只做一个简单的回顾。

Header Search Path 是构建系统提供给编译器的一个重要参数，它的作用是在编译代码的时候，为编译器提供了查找相应头文件路径的信息，通过查阅 Xcode 的 Build System 信息，我们可以知道相关的设置有三处 Header Search Path、System Header Search Path、User Header Search Path。

它们的区别也很简单，System Header Search Path 是针对系统头文件的设置，通常代指 `<>` 方式引入的文件，uUser Header Search Path 则是针对非系统头文件的设置，通常代指 `""` 方式引入的文件，而 Header Search Path 并不会有任何限制，它普适于任何方式的头文件引用。

听起来好像很复杂，但关于引入的方式，无非是以下四种形式：

```
#import <A/A.h>
#import "A/A.h"
#import <A.h>
#import "A.h"
```

我们可以两个维度去理解这个问题，一个是引入的符号形式，另一个是引入的内容形式。

- 引入的符号形式：通常来说，双引号的引入方式（`"A.h"` 或者 `"A/A.h"`）是用于查找本地的头文件，需要指定相对路径，尖括号的引入方式（`<A.h>` 或者 `<A/A.h>`）是全局的引用，其路径由编译器提供，如引用系统的库，但随着 Header Search Path 的加入，让这种区别已经被淡化了。
- 引入的内容形式：对于 `X/X.h` 和 `X.h` 这两种引入的内容形式，前者是说在对应的 Search Path 中，找到目录 A 并在 A 目录下查找 `A.h`，而后者是说在 Search Path 下查找 `A.h` 文件，而不一定局限在 A 目录中，至于是否递归的寻找则取决于对目录的选项是否开启了 `recursive` 模式

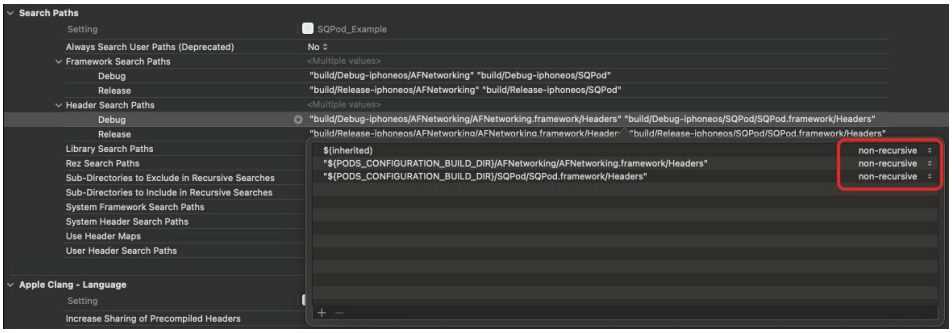

在很多工程中，尤其是基于 CocoaPods 开发的项目，我们已经不会区分 System Header Search Path 和 User Header Search Path，而是一股脑的将所有头文件路径添加到 Header Search Path 中，这就导致我们在引用某个头文件时，不会再局限于前面提到的约定，甚至在某些情况下，前面提到的四种方式都可以做到引入某个指定头文件。

Header Maps

随着项目的迭代和发展，原有的头文件索引机制还是受到了一些挑战，为此，Clang 官方也提出了自己的解决方案。

为了理解这个东西，我们首先要在 Build Setting 中开启 Use Header Map 选项。

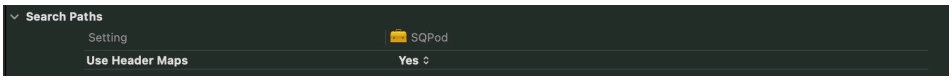

然后在 Build Log 里获取相应组件里对应文件的编译命令，并在最后加上 -v 参数，来查看其运行的秘密：

```
$ clang <list of arguments> -c SQViewController.m -o SQViewcontroller.o -v
```

在 console 的输出内容中，我们会发现一段有意思的内容：

```
#include "..." search starts here:
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Intermediates.noindex/PodA.build/Debug-iphonesimulator/PodA_Exampl
e.build/PodA_Example-generated-files.hmap (headermap)
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Intermediates.noindex/PodA.build/Debug-iphonesimulator/PodA_Exampl
e.build/PodA_Example-project-headers.hmap (headermap)
#include <...> search starts here:
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Intermediates.noindex/PodA.build/Debug-iphonesimulator/PodA_Exampl
e.build/PodA_Example-own-target-headers.hmap (headermap)
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Intermediates.noindex/PodA.build/Debug-iphonesimulator/PodA_Exampl
e.build/PodA_Example-all-non-framework-target-headers.hmap (headermap)
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Products/Debug-iphonesimulator/PodA/PodA.framework/Headers
 /Users/sketchk/Library/Developer/Xcode/DerivedData/PodA-crhgcfyqirwidfdliyxbsp
iprubx/Build/Intermediates.noindex/PodA.build/Debug-iphonesimulator/PodA_Exampl
e.build/DerivedSources
```

通过上面的图，我们可以看到编译器将寻找头文件的顺序和对应路径展示出来了，而在这些路径中，我们看到了一些陌生的东西，即后缀名为 `.hmap` 的文件。

那 hmap 到底这是个什么东西呢?

当我们开启 Build Setting 中的 Use Header Map 选项后，会自动生成的一份头文件名和头文件路径的映射表，而这个映射表就是 hmap 文件，不过它是一种二进制格式的文件，也有人叫它为 Header Map。总之，它的核心功能就是让编译器能够找到相应头文件的位置。

为了更好的理解它，我们可以通过 milend 编写的小工具 hmap 来查其内容。

在执行相关命令（即 `hmap print`）后，我们可以发现这些 hmap 里保存的信息结构大致如下：

```
sketchk ~/Desktop/Host git main
▶ hmap print /Users/sketchk/Library/Developer/Xcode/DerivedData/Host-ewmvmvyzlhizmsau
byxgeyqcnucf/Build/Intermediates.noindex/Pods.build/Debug-iphonesimulator/PodA.build/
PodA-own-target-headers.hmap
ClassA.h -> PodA/ClassA.h
ClassB.h -> PodA/ClassB.h
ClassF.h -> /Users/sketchk/Desktop/PodA/PodA/Classes/C/ClassF.h
PodA-umbrella.h -> PodA/PodA-umbrella.h
PodA/ClassF.h -> /Users/sketchk/Desktop/PodA/PodA/Classes/C/ClassF.h
```

需要注意，映射表的键值并不是简单的文件名和绝对路径，它的内容会随着使用场景产生不同的变化，例如头文件引用是在 `"..."` 的形式，还是 `<...>` 的形式，又或是在 Build Phase 里 Header 的配置情况。

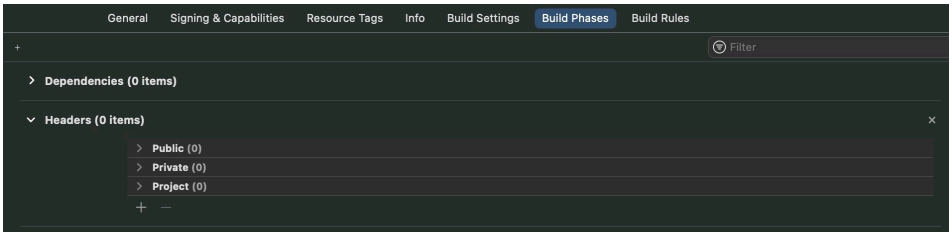

至此，我想你应该明白了，一旦开启 Use Header Map 选项后，Xcode 会优先去 hmap 映射表里寻找头文件的路径，只有在找不到的情况下，才会去 Header Search Path 中提供的路径遍历搜索。

当然这种技术也不是一个什么新鲜事儿，在 Facebook 的 buck 工具中也提供了类似的东西，只不过文件类型变成了 `HeaderMap.java` 的样子。

查找系统库的头文件

上面的过程让我们理解了在 Header Map 技术下，编译器是如何寻找相应的头文件的，那针对系统库的文件又是如何索引的呢？例如 `#import <Foundation/Foundation.h>`

回想一下上一节 console 的输出内容，它的形式大概如下：

```
#include "..." search starts here:
XXX-generated-files.hmap (headermap)
XXX-project-headers.hmap (headermap)

#include <...> search starts here:
XXX-own-target-headers.hmap (headermap)
```

```
XXX-all-target-headers.hmap (headermap)
Header Search Path
DerivedSources
Build/Products/Debug (framework directory)
$(SDKROOT)/usr/include
$(SDKROOT)/System/Library/Frameworks(framework directory)
```

我们会发现，这些路径大部分是用于查找非系统库文件的，也就是开发者自己引入的头文件，而与系统库相关的路径只有以下两个：

```
#include <...> search starts here:
$(SDKROOT)/usr/include
$(SDKROOT)/System/Library/Frameworks.(framework directory)
```

当我们查找 `Foundation/Foundation.h` 这个文件的时候，我们会首先判断是否存在 Foundation 这个 Framework。

```
$SDKROOT/System/Library/Frameworks/Foundation.framework
```

接着，我们会进入 Framework 的 Headers 文件夹里寻找对应的头文件。

```
$SDKROOT/System/Library/Frameworks/Foundation.framework/Headers/
Foundation.h
```

如果没有找到对应的文件，索引过程会在此中断，并结束查找。

以上便是系统库的头文件搜索逻辑。

Framework Search Path

到现在为止，我们已经解释了如何依赖 Header Search Path、hmap 等技术寻找头文件的工作机制，也介绍了寻找系统库（System Framework）头文件的工作机制。

那这是全部头文件的搜索机制么？答案是否定的，其实我们还有一种头文件搜索机制，它是基于 Framework 这种文件结构进行的。

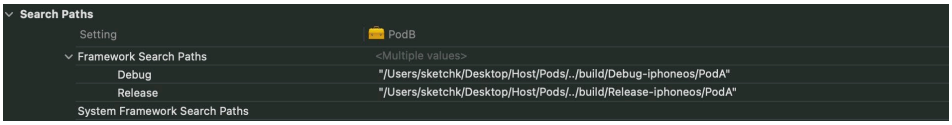

对于开发者自己的 Framework，可能会存在“private”头文件，例如在 podspec 里用 `private_header_files` 的描述文件，这些文件在构建的时候，会被放在 Framework 文件结构中的 PrivateHeaders 目录。

所以针对有 PrivateHeaders 目录的 Framework 而言，Clang 在检查 Headers 目录后，会去 PrivateHeaders 目录中寻找是否存在匹配的头文件，如果这两个目录都没有，才会结束查找。

```
$SDKROOT/System/Library/Frameworks/Foundation.framework/PrivateHeaders/
SecretClass.h
```

不过也正是因为这个工作机制，会产生一个特别有意思的问题，那就是当我们使用 Framework 的方式引入某个带有“Private”头文件的组件时，我们总是可以以下面的方式引入这个头文件！

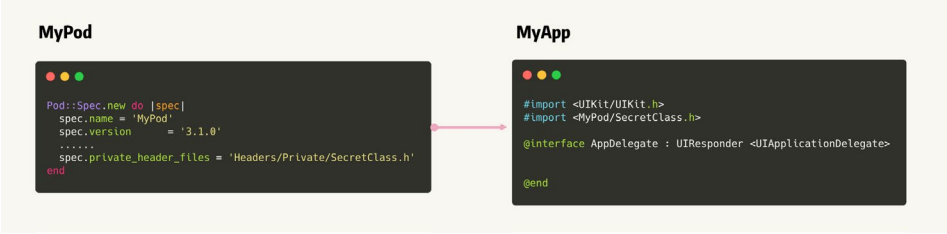

怎么样，是不是很神奇，这个被描述为“Private”的头文件怎么就不私有了?

究其原因，还是由于 Clang 的工作机制，那为什么 Clang 要设计出来这种看似很奇怪的工作机制呢?

揭开 Public、Private、Project 的真实面目

其实你也看到，我在上一段的写作中，将所有 Private 单词标上了双引号，其实就是在暗示，我们曲解了 Private 的含义。

那么这个“Private”到底是什么意思呢?

在 Apple 官方的 Xcode Help – What are build phases? 文档中，我们可以看到如

下的一段解释：

> Associates public, private, or project header files with the target. Public and private headers define API intended for use by other clients, and are copied into a product for installation. For example, public and private headers in a framework target are copied into Headers and Private-Headers subfolders within a product. Project headers define API used and built by a target, but not copied into a product. This phase can be used once per target.

总的来说，我们可以知道一点，就是 Build Phases - Headers 中提到 Public 和 Private 是指可以供外界使用的头文件，且分别放在最终产物的 Headers 和 PrivateHeaders 目录中，而 Project 中的头文件是不对外使用的，也不会放在最终的产物中。

如果你继续翻阅一些资料，例如 StackOverflow - Xcode: Copy Headers: Public vs. Private vs. Project? 和 StackOverflow - Understanding Xcode's Copy Headers phase，你会发现在早期 Xcode Help 的 Project Editor 章节里，有一段名为 Setting the Role of a Header File 的段落，里面详细记载了三个类型的区别。

> **Public:** The interface is finalized and meant to be used by your product's clients. A public header is included in the product as readable source code without restriction. **Private:** The interface isn't intended for your clients or it's in early stages of development. A private header is included in the product, but it's marked "private". Thus the symbols are visible to all clients, but clients should understand that they're not supposed to use them. **Project:** The interface is for use only by implementation files in the current project. A project header is not included in the target, except in object code. The symbols are not visible to clients at all, only to you.

至此，我们应该彻底了解了 Public、Private、Project 的区别。简而言之，Public

还是通常意义上的 Public，Private 则代表 In Progress 的含义，至于 Project 才是通常意义上的 Private 含义。

那么 CocoaPods 中 Podspec 的 Syntax 里还有 `public_header_files` 和 `private_header_files` 两个字段，它们的真实含义是否和 Xcode 里的概念冲突呢?

这里我们仔细阅读一下官方文档的解释，尤其是 `private_header_files` 字段。

private_header_files multi-platform

A list of file patterns that should be used to mark private headers.

These patterns are matched against the public headers (or all the headers if no public headers have been specified) to exclude those headers which should not be exposed to the user project and which should not be used to generate the documentation. When the library is built, these headers will appear in the build directory.

Header files that are not listed as neither public nor private will be treated as private, but in addition will not appear in the build directory at all.

Examples:

```
spec.private_header_files = 'Headers/Private/*.h'
```

我们可以看到，`private_header_files` 在这里的含义是说，它本身是相对于 Public 而言的，这些头文件本义是不希望暴露给用户使用的，而且也不会产生相关文档，但是在构建的时候，会出现在最终产物中，只有既没有被 Public 和 Private 标注的头文件，才会被认为是真正的私有头文件，且不出现在最终的产物里。

其实这么看来，CocoaPods 对于 Public 和 Private 的理解是和 Xcode 中的描述一致的，两处的 Private 并非我们通常理解的 Private，它的本意更应该是开发者准备对外开放，但又没完全 Ready 的头文件，更像一个 In Progress 的含义。

所以，如果你真的不想对外暴露某些头文件，请不要再使用 Headers 里的 Private 或者 podspec 里的 `private_header_files` 了。

至此，我想你应该彻底理解了 Search Path 的搜索机制和略显奇怪的 Public、Private、Project 设定了！

基于 hmap 优化 Search Path 的策略

在查找系统库的头文件的章节中，我们通过 `-v` 参数看到了寻找头文件的搜索顺序：

```
#include "..." search starts here:
XXX-generated-files.hmap (headermap)
XXX-project-headers.hmap (headermap)

#include <...> search starts here:
XXX-own-target-headers.hmap (headermap)
XXX-all-target-headers.hmap (headermap)
Header Search Path
DerivedSources
Build/Products/Debug (framework directory)
$(SDKROOT)/usr/include
$(SDKROOT)/System/Library/Frameworks(framework directory)
```

假设，我们没有开启 hmap 的话，所有的搜索都会依赖 Header Search Path 或者 Framework Search Path，那这就会出现 3 种问题：

- 第一个问题，在一些巨型项目中，假设依赖的组件有 400+，那此时的索引路径就会达到 800+ 个（一份 Public 路径，一份 Private 路径），同时搜索操作可以看做是一种 IO 操作，而我们知道 IO 操作通常也是一种耗时操作，那么，这种大量的耗时操作必然会导致编译耗时增加。
- 第二个问题，在打包的过程中，如果 Header Search Path 过多过长，会触发命令行过长的错误，进而导致命令执行失败的情况。
- 第三个问题，在引入系统库的头文件时，Clang 会将前面提到的目录遍历完才进入搜索系统库的路径，也就是 `$(SDKROOT)/System/Library/Frameworks(framework directory)`，即前面的 Header Search 路径越多，耗时也会越长，这是相当不划算的。

那如果我们开启 hmap 后，是否就能解决掉所有的问题呢?

实际上并不能，而且在基于 CocoaPods 管理项目的状况下，又会带来新的问题。下面是一个基于 CocoaPods 构建的全源码工程项目，它的整体结构如下：

首先，Host 和 Pod 是我们的两个 Project，Pods 下的 Target 的产物类型为 Static Library。

其次，Host 底下会有一个同名的 Target，而 Pods 目录下会有 n+1 个 Target，其中 n 取决于你依赖的组件数量，而 1 是一个名为 Pods-XXX 的 Target，最后，Pods-XXX 这个 Target 的产物会被 Host 里的 Target 所依赖。

整个结构看起来如下所示：

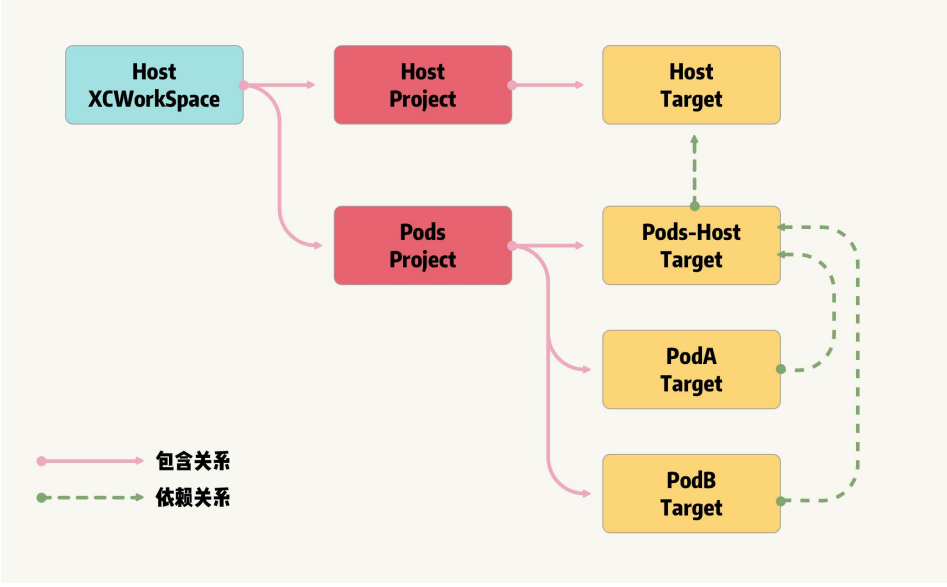

此时我们将 PodA 里的文件全部放在 Header 的 Project 类型中。

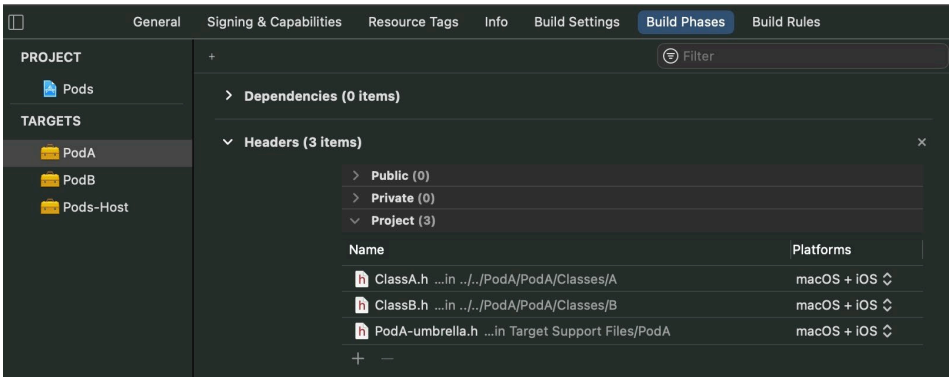

在基于 Framework 的搜索机制下，我们是无法以任何方式引入到 ClassB 的，因为它既不在 Headers 目录，也不在 PrivateHeader 目录中。

可是如果我们开启了 Use Header Map 后，由于 PodA 和 PodB 都在 Pods 这个 Project 下，满足了 Header 的 Project 定义，通过 Xcode 自动生成的 hmap 文件会带上这个路径，所以我们还可以在 PodB 中以 `#import "ClassB.h"` 的方式引入。

而这种行为，我想应该是大多数人并不想要的结果，所以一旦开启了 Use Header Map，再结合 CocoaPods 管理工程项目的模式，我们极有可能会产生一些误用私有头文件的情况，而这个问题的本质是 Xcode 和 CocoaPods 在工程和头文件上的理念冲突造成的。

除此之外，CocoaPods 在处理头文件的问题上还有一些让人迷惑的地方，它在创建头文件产物这块的逻辑大致如下：

- 在构建产物为 Framework 的情况下
  - 根据 podspec 里的 `public_header_files` 字段的内容，将相应头文件设置为 Public 类型，并放在 Headers 中。
  - 根据 podspec 里的 `private_header_files` 字段的内容，将相应文件设置为 Private 类型，并放在 PrivateHeader 中。
  - 将其余未描述的头文件设置为 Project 类型，且不放入最终的产物中。
  - 如果 podspec 里未标注 Public 和 Private 的时候，会将所有文件设置为

Public 类型，并放在 Header 中。

- 在构建产物为 Static Library 的情况下
  - 不论 podspec 里如何设置 `public_header_files` 和 `private_header_files`，相应的头文件都会被设置为 Project 类型。
  - 在 `Pods/Headers/Public` 中会保存所有被声明为 `public_header_files` 的头文件。
  - 在 `Pods/Headers/Private` 中会保存所有头文件，不论是 `public_header_files` 或者 `private_header_files` 描述到，还是那些未被描述的，这个目录下是当前组件的所有头文件全集。
  - 如果 podspec 里未标注 Public 和 Private 的时候，`Pods/Headers/Public` 和 `Pods/Headers/Private` 的内容一样且会包含所有头文件。

正是由于这种机制，还导致了另外一种有意思的问题。

在 Static Library 的状况下，一旦我们开启了 Use Header Map，结合组件里所有头文件的类型为 Project 的情况，这个 hmap 里只会包含 `#import "A.h"` 的键值引用，也就是说只有 `#import "A.h"` 的方式才会命中 hmap 的策略，否则都将通过 Header Search Path 寻找其相关路径。

而我们也知道，在引用其他组件的时候，通常都会采用 `#import <A/A.h>` 的方式引入。至于为什么会用这种方式，一方面是这种写法会明确头文件的由来，避免问题，另一方面也是这种方式可以让我们在是否开启 Clang Module 中随意切换，当然还有一点就是，Apple 在 WWDC 里曾经不止一次建议开发者使用这种方式来引入头文件。

接着上面的话题来说，所以说在 Static Library 的情况下且以 `#import <A/A.h>` 这种标准方式引入头文件时，开启 Use Header Map 并不会提升编译速度，而这同样是 Xcode 和 CocoaPods 在工程和头文件上的理念冲突造成的。

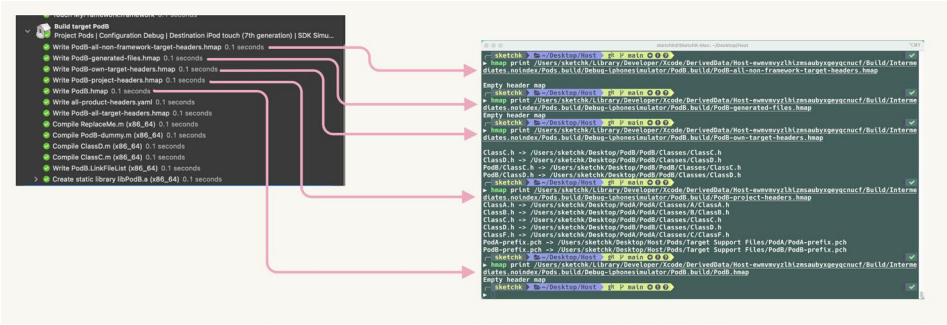

这样来看的话，虽然 hmap 有种种优势，但是在 CocoaPods 的世界里显得格格不入，也无法发挥自身的优势。

那这就真的没有办法解决了么?

当然，问题是有办法解决的，我们完全可以自己动手做一个基于 CocoaPods 规则下的 hmap 文件。

举一个简单的例子，通过遍历 PODS 目录里的内容去构建索引表内容，借助 hmap 工具生成 header map 文件，然后将 Cocoapods 在 Header Search Path 中生成的路径删除，只添加一条指向我们自己生成的 hmap 文件路径，最后关闭 Xcode 的 Ues Header Map 功能，也就是 Xcode 自动生成 hmap 的功能，如此这般，我们就实现了一个简单的，基于 CocoaPods 的 Header Map 功能。

同时在这个基础上，我们还可以借助这个功能实现不少管控手段，例如：

- 从根本上杜绝私有文件被暴露的可能性。
- 统一头文件的引用形式
- ...

目前，我们已经自研了一套基于上述原理的 cocoapods 插件，它的名字叫做 cocoapods-hmap-prebuilt，是由笔者与同事共同开发的。

说了这么多，让我们看看它在实际工程中的使用效果!

经过全源码编译的测试，我们可以看到该技术在提速上的收益较为明显，以美团和点

评 App 为例，全链路时长能够提升 45% 以上，其中 Xcode 打包时间能提升 50%。

关于第二个问题

> 对于已开启 Clang Module 特性的组件，Clang 是如何决定编译当下组件的 Module 呢？另外构建的细节又是怎样的，以及如何查找这些 Module 的？还有查找系统的 Module 和非系统的 Module 有什么区别么？

首先，我们来明确一个问题，Clang 是如何决定编译当下组件的 Module 呢？

以 `#import <Foundation/NSString.h>` 为例，当我们遇到这个头文件的时候：

首先会去 Framework 的 Headers 目录下寻找相应的头文件是否存在，然后就会到 Modules 目录下查找 modulemap 文件。

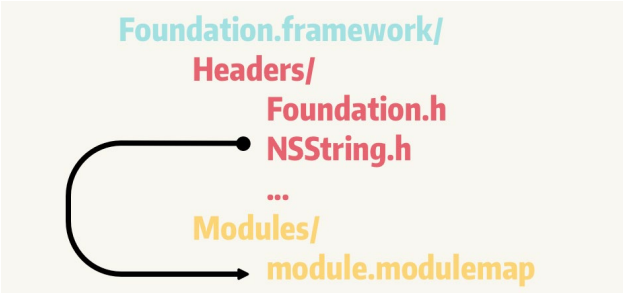

此时，Clang 会去查阅 modulemap 里的内容，看看 NSString 是否为 Foundation 这个 Module 里的一部分。

```
// Module Map - Foundation.framework/Modules/module.modulemap
framework module Foundation [extern_c] [system] {
    umbrella header "Foundation.h"
    export *
    module * {
        export *
    }

    explicit module NSDebug {
        header "NSDebug.h"
        export *
    }
}
```

很显然，这里通过 Umbrella Header，我们是可以在 Foundation.h 中找到 NSString.h 的。

```
// Foundation.h
…
#import <Foundation/NSStream.h>
#import <Foundation/NSString.h>
#import <Foundation/NSTextCheckingResult.h>
…
```

至此，Clang 会判定 `NSString.h` 是 Foundation 这个 Module 的一部分并进行相应的编译工作，此时也就意味着 `#import <Foundation/NSString.h>` 会从之前的 textual import 变为 module import。

Module 的构建细节

上面的内容解决了是否构建 Module，而这一块我们会详细阐述构建 Module 的过程！

在构建开始前，Clang 会创建一个完全独立的空间来构建 Module，在这个空间里会包含 Module 涉及的所有文件，除此之外不会带入其他任何文件的信息，而这也是 Module 健壮性好的关键因素之一。

不过，这并不意味着我们无法影响到 Module 的唯一性，真正能影响到其唯一性的是其构建的参数，也就是 Clang 命令后面的内容，关于这一点后面还会继续展开，这里我们先点到为止。

当我们在构建 Foundation 的时候，我们会发现 Foundation 自身要依赖一些组件，这意味着我们也需要构建被依赖组件的 Module。

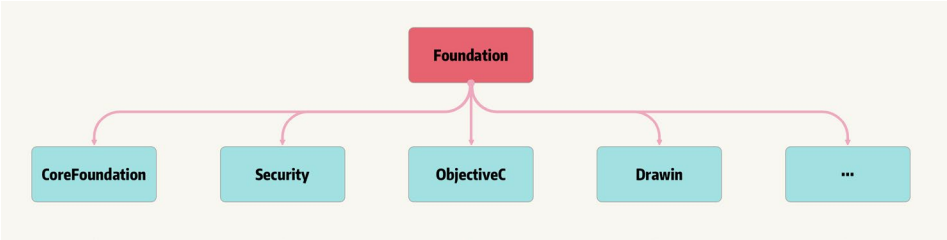

但很明显的是，我们会发现这些被依赖组件也有自己的依赖关系，在它们的这些依赖关系中，极有可能会存在重复的引用。

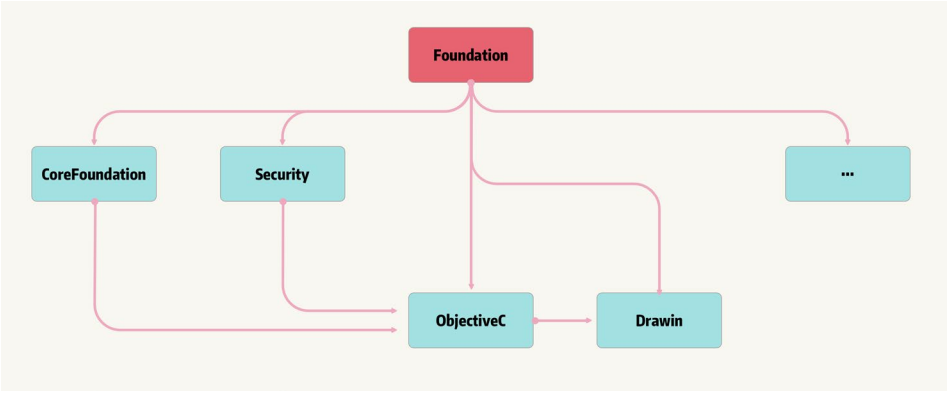

此时，Module 的复用机制就体现出来优势了，我们可以复用先前构建出来的 Module，而不必一次次的创建或者引用，例如 Drawin 组件，而保存这些缓存文件的位置就是前面章节里提到的保存 `pcm` 类型文件的地方。

先前我们提到了 Clang 命令的参数会真正影响到 Module 的唯一性，那具体的原理又是怎样的?

Clang 会将相应的编译参数进行一次 Hash，将获得的 Hash 值作为 Module 缓存文件夹的名称，这里需要注意的是，不同的参数和值会导致文件夹不同，所以想要尽可能的利用 Module 缓存，就必须保证参数不发生变化。

```
$ clang -fmodules —DENABLE_FEATURE=1 ⋯
## 生成的目录如下
98XN8P5QH5OQ/
  CoreFoundation-2A5I5R2968COJ.pcm
  Security-1A229VWPAK67R.pcm
  Foundation-1RDF848B47PF4.pcm

$ clang -fmodules —DENABLE_FEATURE=2 ⋯
## 生成的目录如下
1GYDULU5XJRF/
  CoreFoundation-2A5I5R2968COJ.pcm
  Security-1A229VWPAK67R.pcm
  Foundation-1RDF848B47PF4.pcm
```

这里我们大概了解了系统组件的 module 构建机制，这也是开启 `Enable Modules(C and Objective-C)` 的核心工作原理。

神秘的 Virtual File System（VFS）

对于系统组件，我们可以在 `/Applications/Xcode.app/Contents/Developer/Platforms/iPhoneSimulator.platform/Developer/SDKs/iPhoneSimulator14.2.sdk/System/Library/Frameworks` 目录里找到它的身影，它的目录结构大概是这样的：

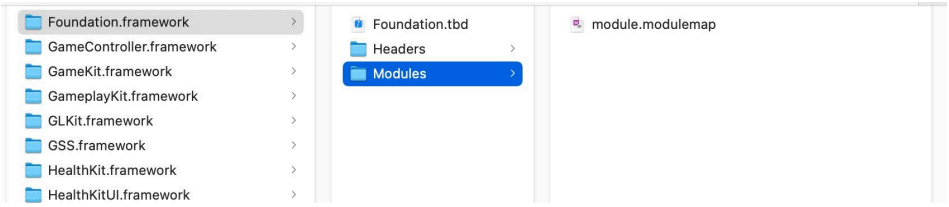

也就是说，对于系统组件而言，构建 Module 的整个过程是建立在这样一个完备的文件结构上，即在 Framework 的 Modules 目录中查找 modulemap，在 Headers 目录中加载头文件。 那对于用户自己创建的组件，Clang 又是如何构建 Module 的呢?

通常我们的开发目录大概是下面的样子，它并没有 Modules 目录，也没有 Headers 目录，更没有 modulemap 文件，看起来和 Framework 的文件结构也有着极大的区别。

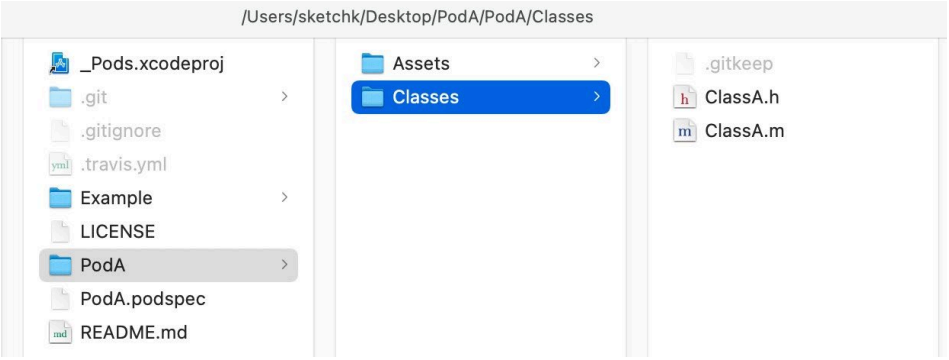

在这种情况下，Clang 是没法按照前面所说的机制去构建 Module 的，因为在这种文件结构中，压根就没有 Modules 和 Headers 目录。

为了解决这个问题，Clang 又提出了一个新的解决方案，叫做 Virtual File System（VFS）。

简单来说，通过这个技术，Clang 可以在现有的文件结构上虚拟出来一个 Framework 文件结构，进而让 Clang 遵守前面提到的构建准则，顺利完成 Module 的编译，同时 VFS 也会记录文件的真实位置，以便在出现问题的时候，将文件的真实信息暴露给用户。

为了进一步了解 VFS，我们还是从 Build Log 中查找一些细节！

在上面的编译参数里，我们可以找到一个 `-ivfsoverlay` 的参数，查看 Help 说明，可以知道其作用就是向编译器传递一个 VFS 描述文件并覆盖掉真实的文件结构信息。

```
-ivfsoverlay <value>    Overlay the virtual filesystem described by file
over the real file system
```

顺着这个线索，我们去看看这个参数指向的文件，它是一个 yaml 格式的文件，在将内容进行了一些裁剪后，它的核心内容如下：

```
{
  "case-sensitive": "false",
  "version": 0,
  "roots": [
    {
      "name": "XXX/Debug-iphonesimulator/PodA/PodA.framework/Headers",
      "type": "directory",
      "contents": [
        { "name": "ClassA.h", "type": "file",
          "external-contents": "XXX/PodA/PodA/Classes/ClassA.h"
        },
        ......
        { "name": "PodA-umbrella.h", "type": "file",
          "external-contents": "XXX/Target Support Files/PodA/PodA-
umbrella.h"
        }
      ]
    },
    {
      "contents": [
        "name": "XXX/Products/Debug-iphonesimulator/PodA/PodA.
framework/Modules",
        "type": "directory"
        { "name": "module.modulemap", "type": "file",
          "external-contents": "XXX/Debug-iphonesimulator/PodA.build/
module.modulemap"
        }
      ]
    }
  ]
}
```

结合前面提到的内容，我们不难看出它在描述这样一个文件结构：

借用一个真实存在的文件夹来模拟 Framework 里的 Headers 文件夹，在这个 Headers 文件夹里有名为 `PodA-umbrella.h` 和 `ClassA.h` 等的文件，不过这几个虚拟文件与 `external-contents` 指向的真实文件相关联，同理还有 Modules 文件夹和它里面的 `module.modulemap` 文件。

通过这样的形式，一个虚拟的 Framework 目录结构诞生了！此时 Clang 终于能按照前面的构建机制为用户创建 Module 了！

Swift 来了

没有头文件的 Swift

前面的章节，我们聊了很多 C 语言系的预编译知识，在这个体系下，文件的编译是分开的，当我们想引用其他文件里的内容时，就必须引入相应的头文件。

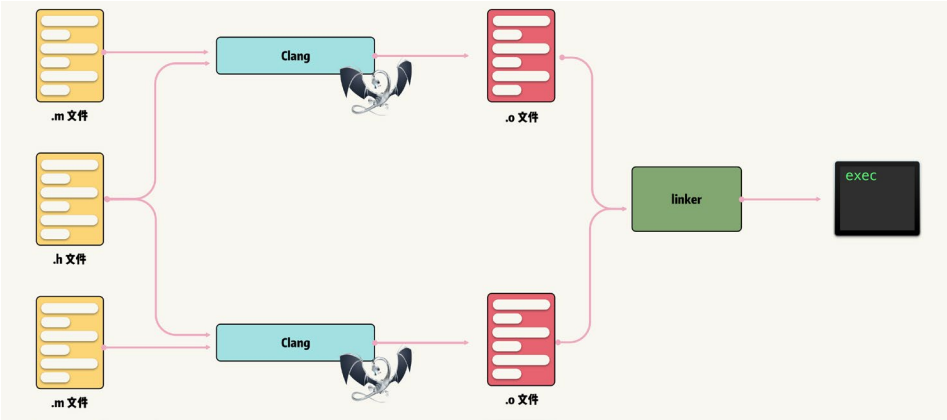

而对于 Swift 这门语言来说，它并没有头文件的概念，对于开发者而言，这确实省去了写头文件的重复工作，但这也意味着，编译器会进行额外的操作来查找接口定义并需要持续关注接口的变化！

为了更好的解释 Swift 和 Objective-C 是如何寻找到彼此的方法声明的，我们这里引入一个例子，在这个例子由三个部分组成：

- 第一部分是一个 ViewController 的代码，它里面包含了一个 View，其中 PetViewController 和 PetView 都是 Swift 代码。
- 第二部分是一个 App 的代理，它是 Objective-C 代码。
- 第三个部分是一段单测代码，用来测试第一个部分中的 ViewController，它是 Swift 代码。

```
import UIKit
class PetViewController: UIViewController {
  var view = PetView(name: "Fido", frame: frame)
  …
}
```

```
#import "PetWall-Swift.h"
@implementation AppDelegate
...
@end
```

```
@testable import PetWall
class TestPetViewController: XCTestCase {
}
```

它们的关系大致如下所示：

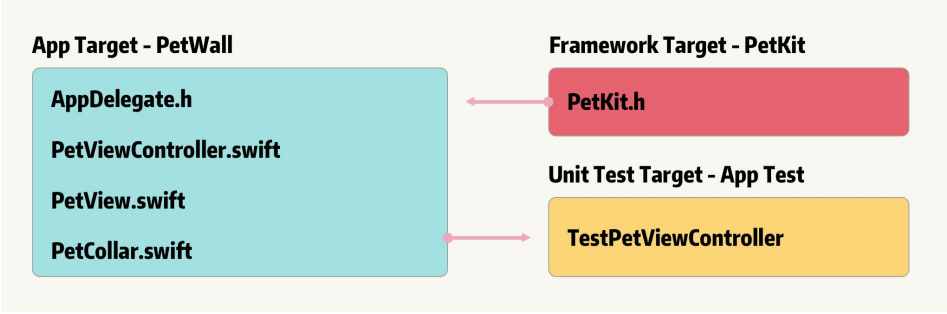

为了能让这些代码编译成功，编译器会面对如下 4 个场景：

首先是寻找声明，这包括寻找当前 Target 内的方法声明（PetView），也包括来自 Objective-C 组件里的声明（UIViewController 或者 PetKit）。

然后是生成接口，这包括被 Objective-C 使用的接口，也包括被其他 Target（Unit Test）使用的 Swift 接口。

第一步 – 如何寻找 Target 内部的 Swift 方法声明

在编译 `PetViewController.swift` 时，编译器需要知道 PetView 的初始化构造器的类型，才能检查调用是否正确。

此时，编译器会加载 `PetView.swift` 文件并解析其中的内容，这么做的目的就是确保初始化构造器真的存在，并拿到相关的类型信息，以便 `PetViewController.swift` 进行验证。

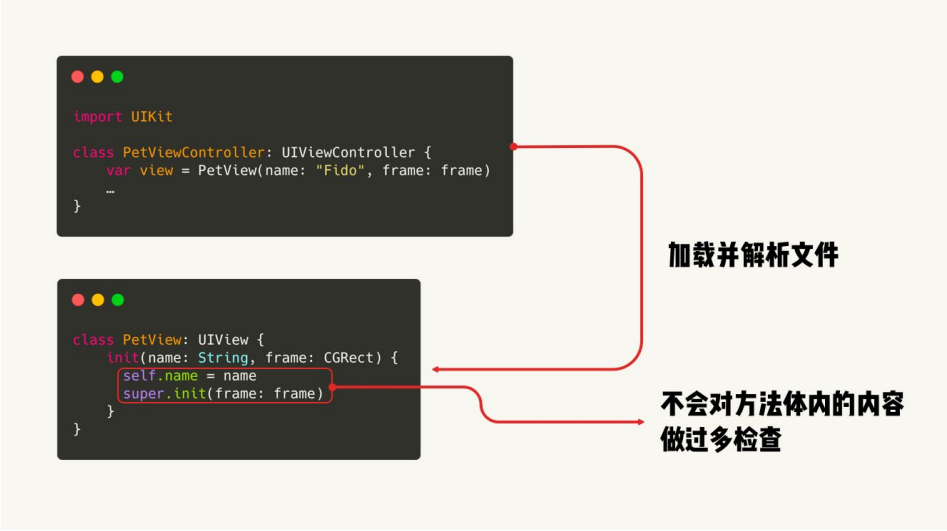

编译器并不会对初始化构造器的内部做检查，但它仍然会进行一些额外的操作，这是什么意思呢?

与 Clang 编译器不同的是，Swiftc 编译的时候，会将相同 Target 里的其他 Swift 文件进行一次解析，用来检查其中与被编译文件关联的接口部分是否符合预期。

同时我们也知道，每个文件的编译是独立的，且不同文件的编译是可以并行开展的，所以这就意味着每编译一个文件，就需要将当前 Target 里的其余文件当做接口，重新编译一次。等于任意一个文件，在整个编译过程中，只有 1 次被作为生产 `.o` 产物的输入，其余时间会被作为接口文件反复解析。

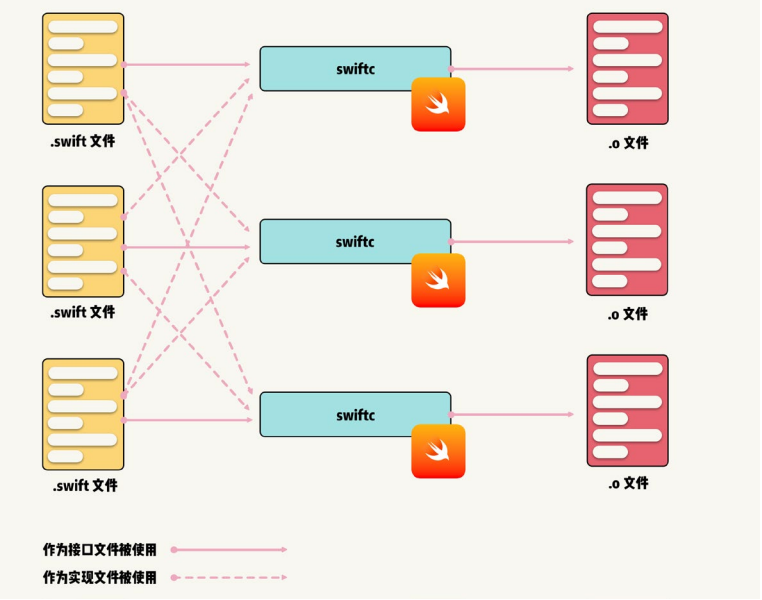

不过在 Xcode 10 以后，Apple 对这种编译流程进行了优化。

在尽可能保证并行的同时，将文件进行了分组编译，这样就避免了 Group 内的文件重复解析，只有不同 Group 之间的文件会有重复解析文件的情况。

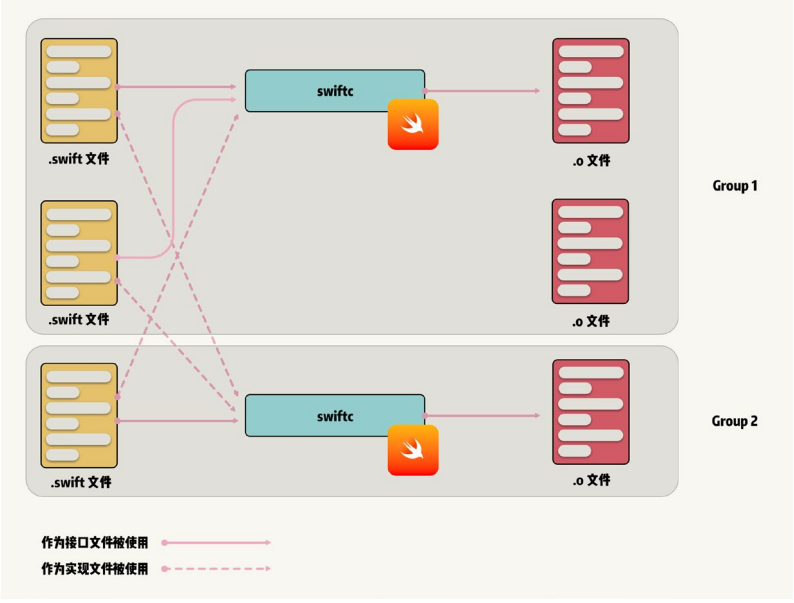

而这个分组操作的逻辑，就是刚才提到的一些额外操作。

至此，我们应该了解了 Target 内部是如何寻找 Swift 方法声明的了。

第二步 – 如何找到 Objective-C 组件里的方法声明

回到第一段代码中，我们可以看到 PetViewController 是继承自 UIViewController，而这也意味着我们的代码会与 Objective-C 代码进行交互，因为大部分系统库，例如 UIKit 等，还是使用 Objective-C 编写的。

在这个问题上，Swift 采用了和其他语言不一样的方案！

通常来说，两种不同的语言在混编时需要提供一个接口映射表，例如 JavaScript 和 TypeScript 混编时候的 `.d.ts` 文件，这样 TypeScript 就能够知道 JavaScript 方法在 TS 世界中的样子。

然而，Swift 不需要提供这样的接口映射表，免去了开发者为每个 Objective-C API 声明其在 Swift 世界里样子，那它是怎么做到的呢？

很简单，Swift 编译器将 Clang 的大部分功能包含在其自身的代码中，这就使得我们能够以 Module 的形式，直接引用 Objective-C 的代码。

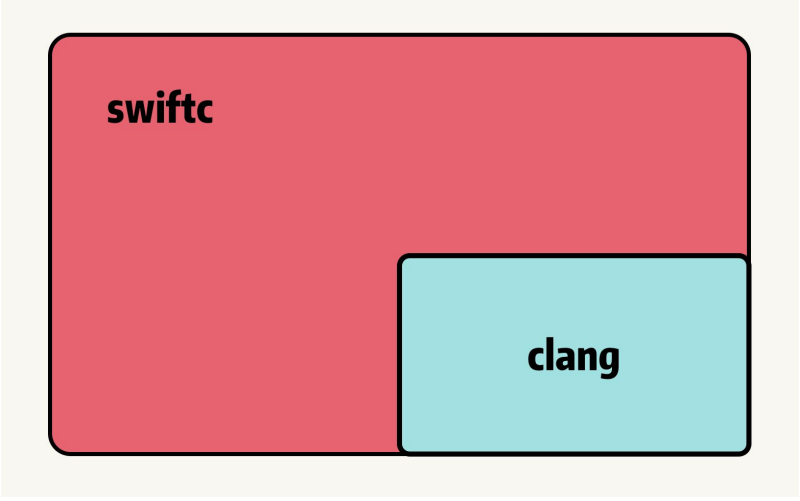

既然是通过 Module 的形式引入 Objective-C，那么 Framework 的文件结构则是最好的选择，此时编译器寻找方法声明的方式就会有下面三种场景：

- 对于大部分的 Target 而言，当导入的是一个 Objective-C 类型的 Framework 时，编译器会通过 modulemap 里的 Header 信息寻找方法声明。
- 对于一个既有 Objective-C，又有 Swift 代码的 Framework 而言，编译器会从当前 Framework 的 Umbrella Header 中寻找方法声明，从而解决自身的编译问题，这是因为通常情况下 modulemap 会将 Umbrella Header 作为自身的 Header 值。
- 对于 App 或者 Unit Test 类型的 Target，开发者可以通过为 Target 创建 Briding Header 来导入需要的 Objective-C 头文件，进而找到需要的方法声明。

不过我们应该知道 Swift 编译器在获取 Objective-C 代码过程中，并不是原原本本的将 Objective-C 的 API 暴露给 Swift，而是会做一些“Swift 化”的改动，例如下面的 Objective-C API 就会被转换成更简约的形式。

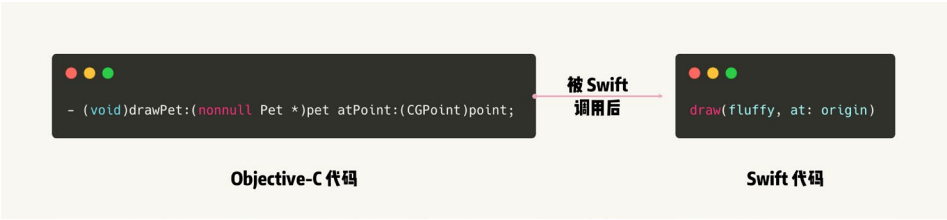

这个转换过程并不是什么高深的技术，它只是在编译器上的硬编码，如果感兴趣，可以在 Swift 的开源库中的找到相应的代码 - PartsOfSpeech.def

当然，编译器也给与了开发者自行定义“API 外貌”的权利，如果你对这一块感兴趣，不妨阅读我的另一篇文章 - WWDC20 10680 - Refine Objective-C frameworks for Swift，那里面包含了很多重塑 Objective-C API 的技巧。

不过这里还是要提一句，如果你对生成的接口有困惑，可以通过下面的方式查看编译器为 Objective-C 生成的 Swift 接口。

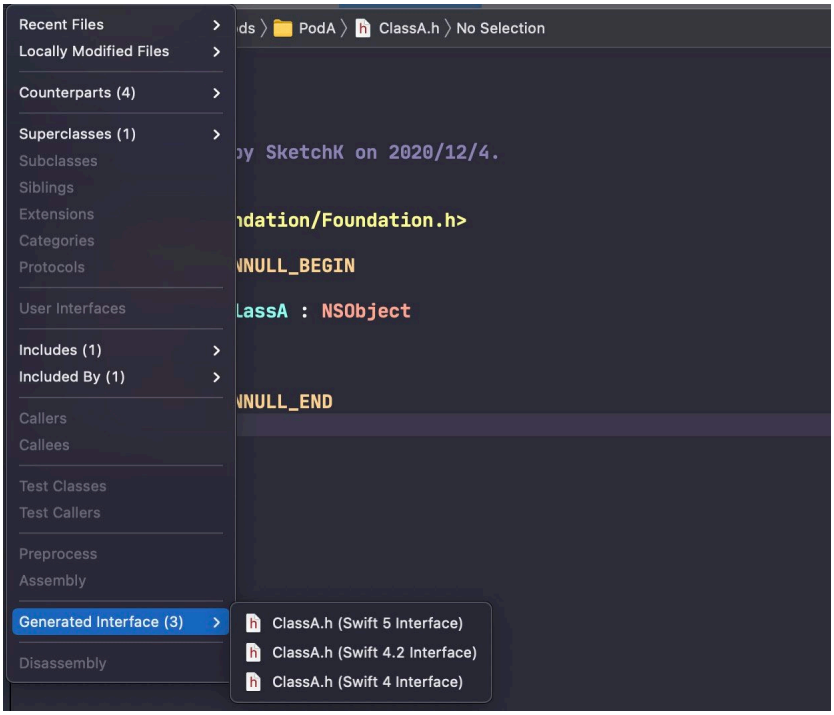

第三步 - Target 内的 Swift 代码是如何为 Objective-C 提供接口的

前面讲了 Swift 代码是如何引用 Objective-C 的 API，那么 Objective-C 又是如何引用 Swift 的 API 呢?

从使用层面来说，我们都知道 Swift 编译器会帮我们自动生成一个头文件，以便 Objective-C 引入相应的代码，就像第二段代码里引入的 `PetWall-Swift.h` 文件，这种头文件通常是编译器自动生成的，名字的构成是 `组件名 -Swift` 的形式。

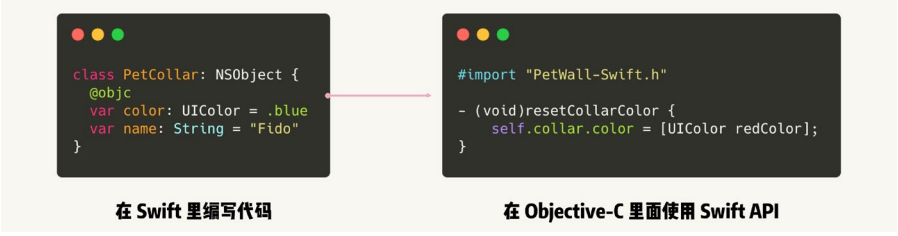

但它到底是怎么产生的呢?

在 Swift 中，如果某个类继承了 NSObject 类且 API 被 `@objc` 关键字标注，就意味着它将暴露给 Objective-C 代码使用。

不过对于 App 和 Unit Test 类型的 target 而言，这个自动生成的 Header 会包含访问级别为 Public 和 internal 的 API，这使得同一 Target 内的 Objective-C 代码也能访问 Swift 里 internal 类型的 API，这也是所有 Swift 代码的默认访问级别。

但对于 Framework 类型的 Target 而言，Swift 自动生成的头文件只会包含 Public 类型的 API，因为这个头文件会被作为构建产物对外使用，所以像 internal 类型的 API 是不会包含在这个文件中。

> 注意，这种机制会导致在 Framework 类型的 Target 中，如果 Swift 想暴露一些 API 给内部的 Objective-C 代码使用，就意味着这些 API 也必须暴露给外界使用，即必须将其访问级别设置为 Public。

那么编译器自动生成的 API 到底是什么样子，有什么特点呢?

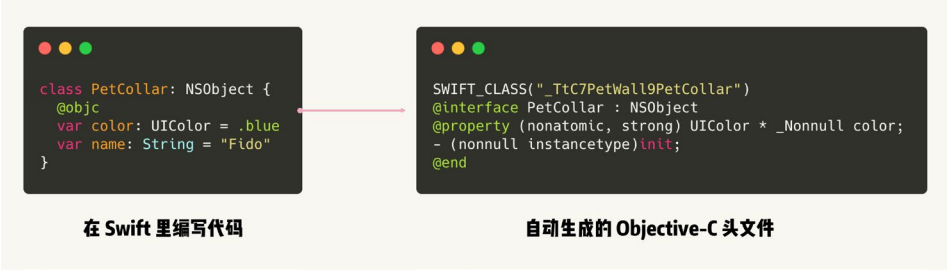

上面是截取了一段自动生成的头文件代码，左侧是原始的 Swift 代码，右侧是自动生成的 Objective-C 代码，我们可以看到在 Objective-C 的类中，有一个名为 `SWIFT_CLASS` 的宏，将 Swift 与 Objective-C 中的两个类进行了关联。

如果你稍加注意，就会发现关联的一段乱码中还绑定了当前的组件名（PetWall），这样做的目的是避免两个组件的同名类在运行时发生冲突。

当然，你也可以通过向 `@objc(Name)` 关键字传递一个标识符，借由这个标识符来控制其在 Objective-C 中的名称，如果这样做的话，需要开发者确保转换后的类名不与其他类名出现冲突。

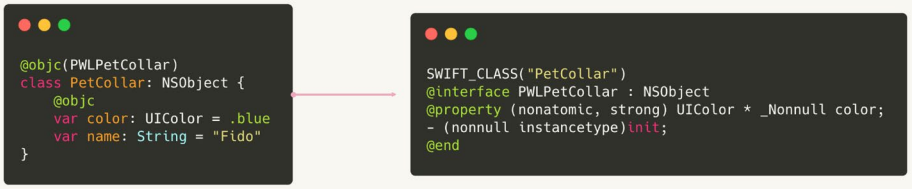

自定义 Swift 在 Objective-C 的类名

这大体上就是 Swift 如何像 Objective-C 暴露接口的机理了，如果你想更深入的了解这个文件的由来，就需要看看第四步。

第四步 - Swift Target 如何生成供外部 Swift 使用的接口

Swift 采用了 Clang module 的理念，并结合自身的语言特性进行了一系列的改进。

在 Swift 中，Module 是方法声明的分发单位，如果你想引用相应的方法，就必须引入对应的 Module，之前我们也提到了 Swift 的编译器包含了 Clang 的大部分内容，所以它也是兼容 Clang Module 的。

所以我们可以引入 Objective-C 的 Module，例如 XCTest，也可以引入 Swift Target 生成的 Module，例如 PetWall。

```
import XCTest
@testable import PetWall
class TestPetViewController: XCTestCase {
  func testInitialPet() {
    let controller = PetViewController()
    XCTAssertEqual(controller.view.name, "Fido")
  }
}
```

在引入 swift 的 Module 后，编译器会反序列化一个后缀名为 `.swiftmodule` 的文件，并通过这种文件里的内容来了解相关接口的信息。

例如，以下图为例，在这个单元测试中，编译器会加载 PetWall 的 Module，并在其中找寻 PetViewController 的方法声明，由此确保其创建行为是符合预期的。

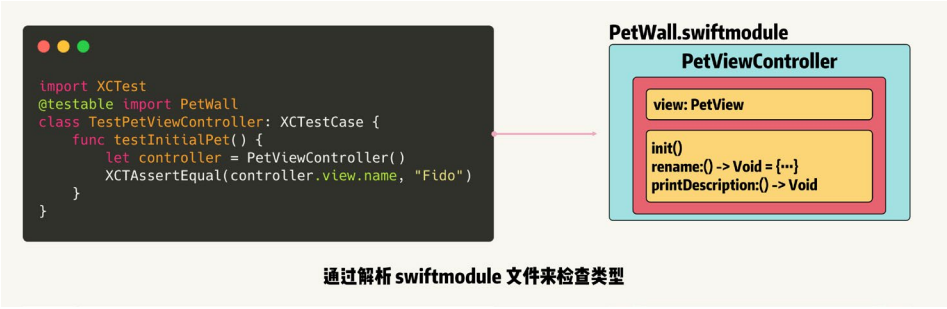

这看起来很像第一步中 Target 寻找内部 Swift 方法声明的样子，只不过这里将解析 Swift 文件的步骤，换成了解析 Swiftmodule 文件而已。

不过需要注意的是，这个 Swfitmodule 文件并不是文本文件，它是一个二进制格式的内容，通常我们可以在构建产物的 Modules 文件夹里寻找到它的身影。

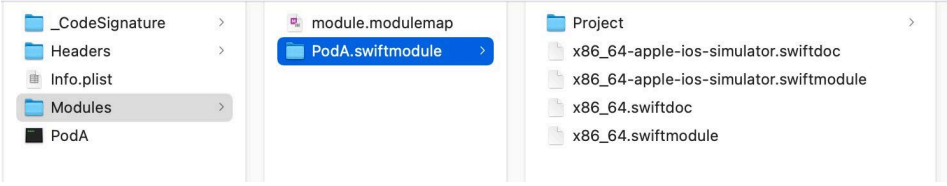

在 Target 的编译的过程中，面向整个 Target 的 Swiftmodule 文件并不是一下产生的，每一个 Swift 文件都会生成一个 Swiftmodule 文件，编译器会将这些文件进行汇总，最后再生成一个完整的，代表整个 Target 的 Swiftmodule，也正是基于这个文件，编译器构造出了用于给外部使用的 Objective-C 头文件，也就是第三步里提到的头文件。

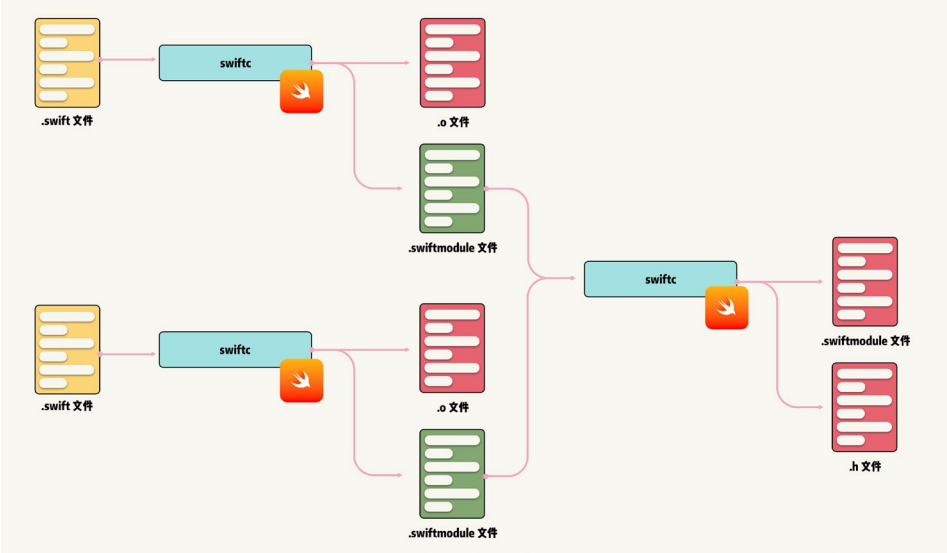

不过随着 Swift 的发展，这一部分的工作机制也发生了些许变化。

我们前面提到的 Swiftmodule 文件是一种二进制格式的文件，而这个文件格式会包含一些编译器内部的数据结构，不同编译器产生的 Swiftmodule 文件是互相不兼容的，这也就导致了不同 Xcode 构建出的产物是无法通用的，如果对这方面的细节感兴趣，可以阅读 Swift 社区里的两篇官方 Blog：Evolving Swift On Apple Platforms After ABI Stability 和 ABI Stability and More，这里就不展开讨论了。

为了解决这一问题，Apple 在 Xcode 11 的 Build Setting 中提供了一个新的编译参数 Build Libraries for Distribution，正如这个编译参数的名称一样，当我们开启它后，构建出来的产物不会再受编译器版本的影响，那它是怎么做到这一点的呢?

为了解决这种对编译器的版本依赖，Xcode 在构建产物上提供了一个新的产物，Swiftinterface 文件。

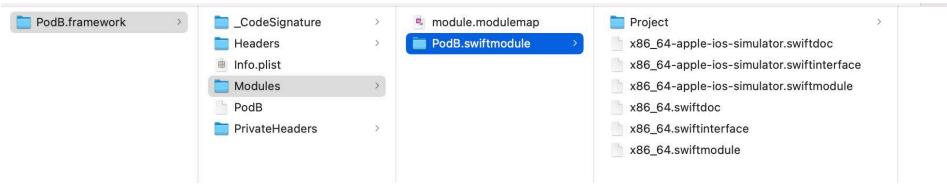

这个文件里的内容和 Swiftmodule 很相似，都是当前 Module 里的 API 信息，不过 Swiftinterface 是以文本的方式记录，而非 Swiftmodule 的二进制方式。

这就使得 Swiftinterface 的行为和源代码一样，后续版本的 Swift 编译器也能导入之前编译器创建的 Swiftinterface 文件，像使用源码的方式一样使用它。

为了更进一步了解它，我们来看看 Swiftinterface 的真实样子，下面是一个 `.swift` 文件和 `.swiftinterface` 文件的比对图。

.swift 文件

```swift
import UIKit

public class Spaceship {
  public let name: String
  private var currentLocation: Location

  public init(name: String) {
    self.name = name
    currentLocation = .launchpad
  }.

  public func fly(
    to destination: Location,
    speed: Speed) {
    currentLocation = destination
  }.
}.

public enum Speed {
  case leisurely
  case fast
}.

public struct Location {
  public var coordinates: Coordinates
}.
```

.swiftinterface文件

```
// swift-interface-format-version: 1.0
// swift-compiler-version: Swift version 5.1
// swift-module-flags:  -target arm64-apple-ios13.0
//                      -enable-library-evolution
//                      -swift-version 5 -O
//                      -module-name FlightKit

import Swift
import UIKit

public class Spaceship {
  public let name: Swift.String

  public init(name: Swift.String)
  public func fly(
    to destination: FlightKit.Location,
    speed: FlightKit.Speed)

  @objc deinit
}.

public enum Speed: Swift.Hashable {
  case leisurely
  case fast

  public static func ==(
    a: FlightKit.Speed,
    b: FlightKit.Speed) -> Swift.Bool
  public func hash(
    into hasher: inout Swift.Hasher)
}

public struct Location {
  public var coordinates: FlightKit.Coordinates
}
```

在 Swiftinterface 文件中，有以下点需要注意

- 文件会包含一些元信息，例如文件格式版本，编译器信息，和 Swift 编译器将其作为模块导入所需的命令行子集。
- 文件只会包含 Public 的接口，而不会包含 Private 的接口，例如 currentLocation。
- 文件只会包含方法声明，而不会包含方法实现，例如 Spacesship 的 init、fly 等方法。

- 文件会包含所有隐式声明的方法，例如 Spacesship 的 deinit 方法，Speed 的 Hashable 协议。

总的来说，Swiftinterface 文件会在编译器的各个版本中保持稳定，主要原因就是这个接口文件会包含接口层面的一切信息，不需要编译器再做任何的推断或者假设。

好了，至此我们应该了解了 Swift Target 是如何生成供外部 Swift 使用的接口了。

这四步意味着什么?

此 Module 非彼 Module

通过上面的例子，我想大家应该能清楚的感受到 Swift Module 和 Clang Module 不完全是一个东西，虽然它们有很多相似的地方。

Clang Module 是面向 C 语言家族的一种技术，通过 modulemap 文件来组织 `.h` 文件中的接口信息，中间产物是二进制格式的 pcm 文件。

Swift Module 是面向 Swift 语言的一种技术，通过 Swiftinterface 文件来组织 `.swift` 文件中的接口信息，中间产物二进制格式的 Swiftmodule 文件。

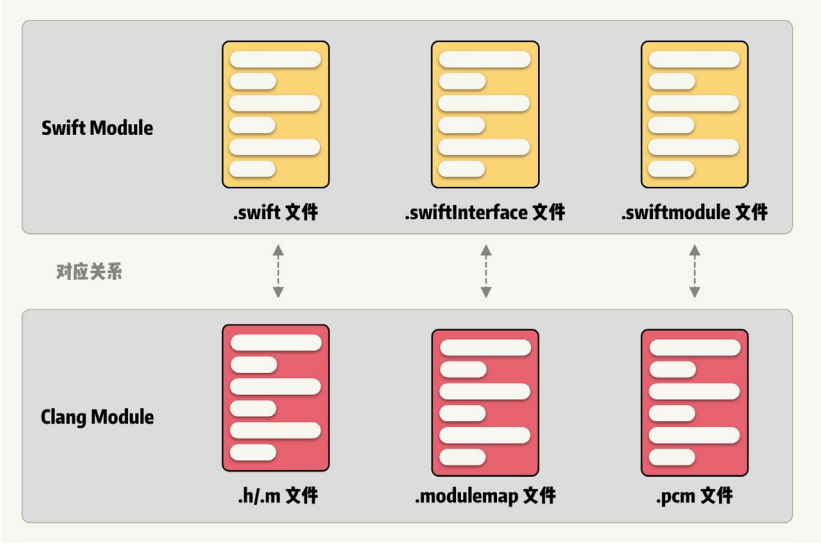

所以说理清楚这些概念和关系后，我们在构建 Swift 组件的产物时，就会知道哪些文件和参数不是必须的了。

例如当你的 Swift 组件不想暴露自身的 API 给外部的 Objective-C 代码使用的话，可以将 Build Setting 中 Swift Compiler - General 里的 Install Objective-C Compatiblity Header 参数设置为 NO，其编译参数为 `SWIFT_INSTALL_OBJC_HEADER`，此时不会生成 `<ProductModuleName>-Swift.h` 类型的文件，也就意味着外部组件无法以 Objective-C 的方式引用组件内 Swift 代码的 API。

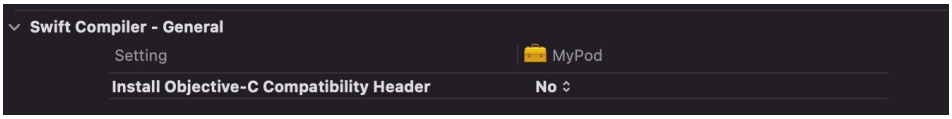

而当你的组件里如果压根就没有 Objective-C 代码的时候，你可以将 Build Setting 中 Packaging 里 Defines Module 参数设置为 NO，它的编译参数为 `DEFINES_MODULE`，此时不会生成 `<ProductModuleName>.modulemap` 类型的文件。

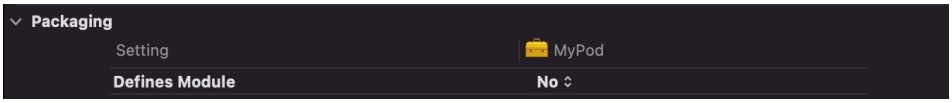

Swift 和 Objective-C 混编的三个“套路”

基于刚才的例子，我们应该理解了 Swift 在编译时是如何找到其他 API 的，以及它又是如何暴露自身 API 的，而这些知识就是解决混编过程中的基础知识，为了加深影响，我们可以将其绘制成 3 个流程图。

当 Swift 和 Objective-C 文件同时在一个 App 或者 Unit Test 类型的 Target 中，不同类型文件的 API 寻找机制如下：

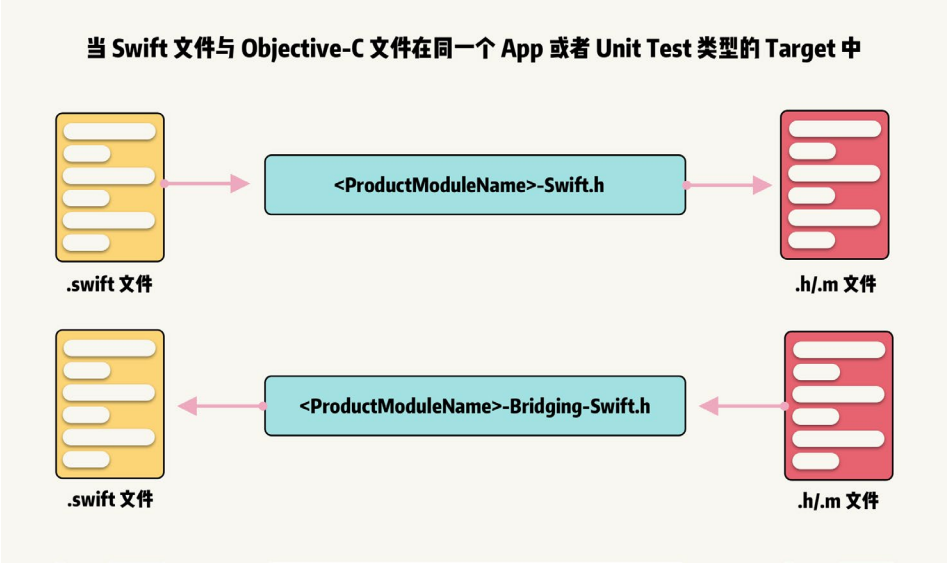

当 Swift 和 Objective-C 文件在不同 Target 中，例如不同 Framework 中，不同类型文件的 API 寻找机制如下：

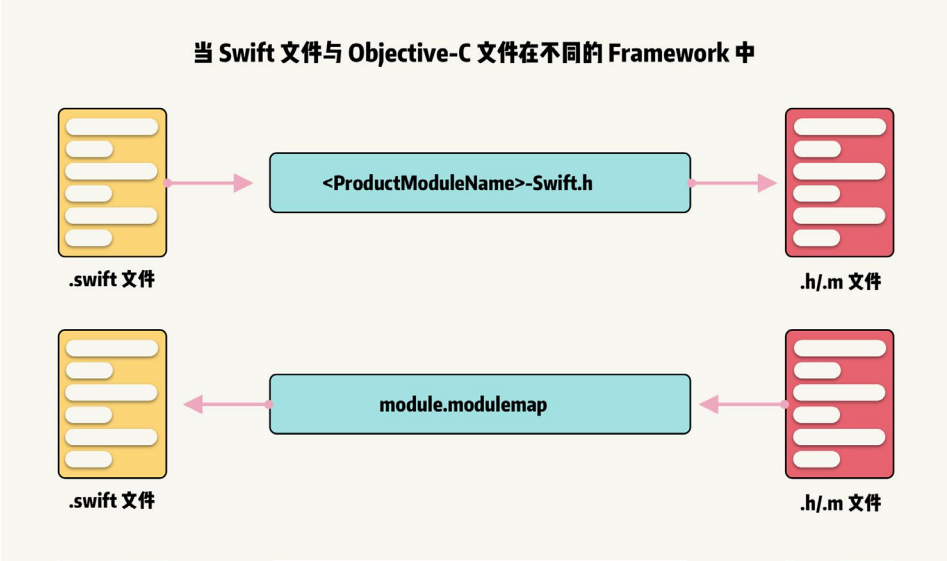

当 Swift 和 Objective-C 文件同时在一个 Target 中，例如同一 Framework 中，不同类型文件的 API 寻找机制如下：

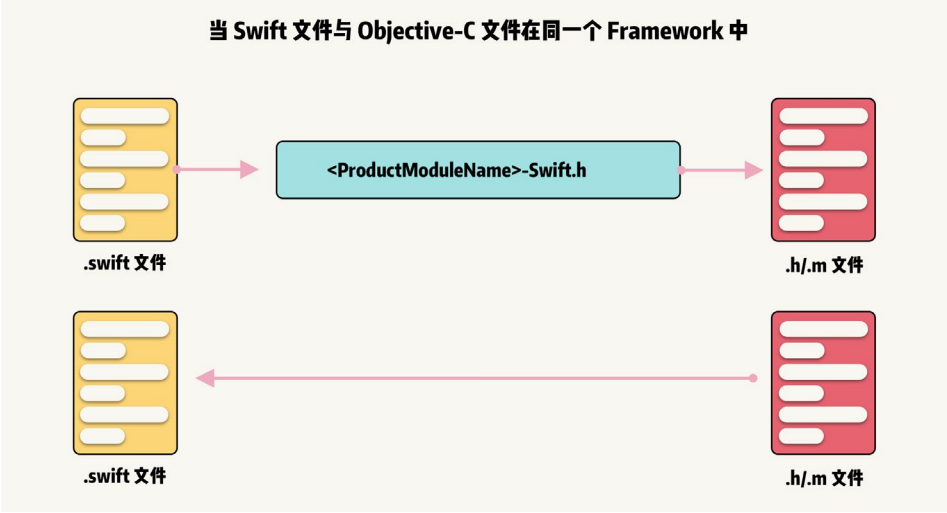

对于第三个流程图，需要做以下补充说明：

- 由于 Swiftc，也就是 Swift 的编译器，包含了大部分的 Clang 功能，其中就包含了 Clang Module，借由组件内已有的 modulemap 文件，Swift 编译器就可以轻松找到相应的 Objective-C 代码。
- 相比于第二个流程而言，第三个流程中的 modulemap 是组件内部的，而第二个流程中，如果想引用其他组件里的 Objective-C 代码，需要引入其他组件里的 modulemap 文件才可以。
- 所以基于这个考虑，并未在流程 3 中标注 modulemap。

构建 Swift 产物的新思路

在前面的章节里，我们提到了 Swift 找寻 Objective-C 的方式，其中提到了，除了 App 或者 Unit Test 类型的 Target 外，其余的情况下都是通过 Framework 的 Module Map 来寻找 Objective-C 的 API，那么如果我们不想使用 Framework 的形式呢?

目前来看，这个在 Xcode 中是无法直接实现的，原因很简单，Build Setting 中 Search Path 选项里并没有 modulemap 的 Search Path 配置参数。

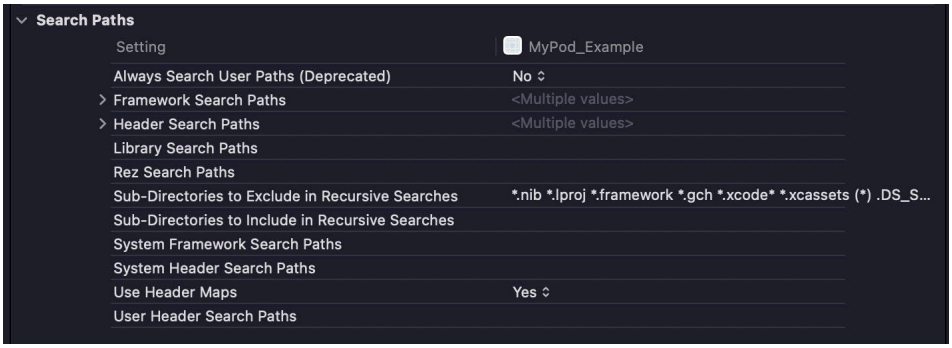

为什么一定需要 modulemap 的 Search Path 呢?

基于前面了解到的内容，Swiftc 包含了 Clang 的大部分逻辑，在预编译方面，Swiftc 只包含了 Clang Module 的模式，而没有其他模式，所以 Objective-C 想要暴露自己的 API 就必须通过 modulemap 来完成。

而对于 Framework 这种标准的文件夹结构，modulemap 文件的相对路径是固定的，它就在 Modules 目录中，所以 Xcode 基于这种标准结构，直接内置了相关的逻辑，而不需要将这些配置再暴露出来。

从组件的开发者角度来看，他只需要关心 modulemap 的内容是否符合预期，以及路径是否符合规范。

从组件的使用者角度来看，他只需要正确的引入相应的 Framework 就可以使用到相应的 API。

这种只需要配置 Framework 的方式，避免了配置 Header Search Path，也避免了配置 Static Library Path，可以说是一种很友好的方式，如果再将 modulemap 的配置开放出来，反而显得多此一举。

那如果我们抛开 Xcode，抛开 Framework 的限制，还有别的办法构建 Swift 产物么?

答案是肯定有的，这就需要借助前面所说的 VFS 技术!

假设我们的文件结构如下所示：

```
├── LaunchPoint.swift
├── README.md
├── build
├── repo
│   └── MyObjcPod
│       └── UsefulClass.h
└── tmp
    ├── module.modulemap
    └── vfs-overlay.yaml
```

其中 `LaunchPoint.swift` 引用了 `UsefulClass.h` 中的一个公开 API，并产生了依赖关系。

另外，`vfs-overlay.yaml` 文件重新映射了现有的文件目录结构，其内容如下：

```
{
  'version': 0,
  'roots': [
    { 'name': '/MyObjcPod', 'type': 'directory',
      'contents': [
        { 'name': 'module.modulemap', 'type': 'file',
          'external-contents': 'tmp/module.modulemap'
        },
        { 'name': 'UsefulClass.h', 'type': 'file',
          'external-contents': 'repo/MyObjcPod/UsefulClass.h'
        }
      ]
    }
  ]
}
```

至此，我们通过如下的命令，便可以获得 LaunchPoint 的 Swiftmodule、Swiftinterface 等文件，具体的示例可以查看我在 Github 上的链接 – manually-expose-objective-c-API-to-swift-example

```
swiftc -c LaunchPoint.swift -emit-module -emit-module-path build/LaunchPoint.
swiftmodule -module-name index -whole-module-optimization -parse-as-library -o
build/LaunchPoint.o -Xcc -ivfsoverlay -Xcc tmp/vfs-overlay.yaml -I /MyObjcPod
```

那这意味着什么呢?

这就意味着，只提供相应的 `.h` 文件和 `.modulemap` 文件就可以完成 Swift 二进制产物的构建，而不再依赖 Framework 的实体。同时，对于 CI 系统来说，在构建产物时，可以避免下载无用的二进制产物（`.a` 文件），这从某种程度上会提升编译效率。

如果你没太理解上面的意思，我们可以展开说说。

例如，对于 PodA 组件而言，它自身依赖 PodB 组件，在使用原先的构建方式时，我们需要拉取 PodB 组件的完整 Framework 产物，这会包含 Headers 目录，Modules 目录里的必要内容，当然还会包含一个二进制文件（PodB），但在实际编译 PodA 组件的过程中，我们并不需要 B 组件里的二进制文件，而这让拉取完整的 Framework 文件显得多余了。

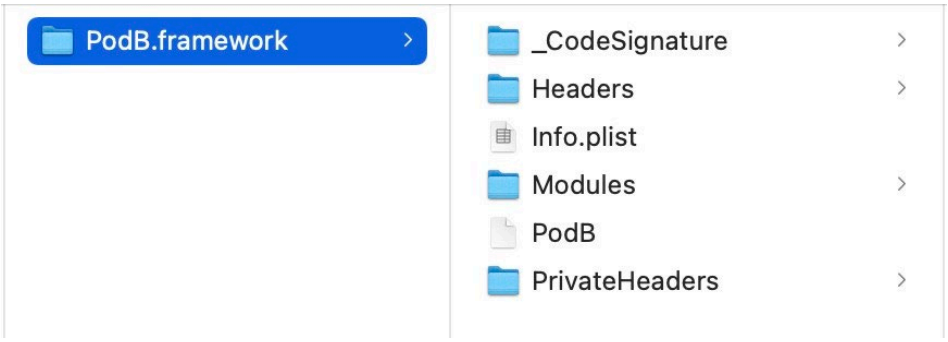

而借助 VFS 技术，我们就能避免拉取多余的二进制文件，进一步提升 CI 系统的编译效率。

总结

感谢你的耐心阅读，至此，整篇文章终于结束了，通过这篇文章，我想你应该：

- 理解 Objective-C 的三种预编译的工作机制，其中 Clang Module 做到了真正意义上的语义引入，提升了编译的健壮性和扩展性。
- 在 Xcode 的 Search Path 的各种技术细节使用到了 hmap 技术，通过加载映射表的方式避免了大量重复的 IO 操作，可以提升编译效率。

- 在处理 Framework 的头文件索引时，总是会先搜索 Headers 目录，再搜索 PrivateHeader 目录。
- 理解 Xcode Phases 构建系统中，Public 代表公开头文件，Private 代表不需要使用者感知，但物理存在的文件，而 Project 代表不应让使用者感知，且物理不存在的文件。
- 不使用 Framework 的情况下且以 `#import <A/A.h>` 这种标准方式引入头文件时，在 CocoaPods 上使用 hmap 并不会提升编译速度。
- 通过 `cocoapods-hmap-built` 插件，可以将大型项目的全链路时长节省 45% 以上，Xcode 打包环节的时长节省 50% 以上。
- Clang Module 的构建机制确保了其不受上下文影响（独立编译空间），复用效率高（依赖决议），唯一性（参数哈希化）。
- 系统组件通过已有的 Framework 文件结构实现了构建 Module 的基本条件，而非系统组件通过 VFS 虚拟出相似的 Framework 文件 结构，进而具备了编译的条件。
- 可以粗浅的将 Clang Module 里的 `.h/m`，`.moduelmap`，`.pch` 的概念对应为 Swift Module 里的 `.swift`，`.swiftinterface`，`.swiftmodule` 的概念
- 理解三种具有普适性的 Swift 与 Objective-C 混编方法
  - 同一 Target 内（App 或者 Unit 类型），基于 `<PorductModuleName>-Swift.h` 和 `<PorductModuleName>-Bridging-Swift.h`。
  - 同一 Target 内，基于 `<PorductModuleName>-Swift.h` 和 Clang 自身的能力。
  - 不同 Target 内，基于 `<PorductModuleName>-Swift.h` 和 `module.modulemap`。
- 利用 VFS 机制构建，可以在构建 Swift 产物的过程中避免下载无用的二进制产物，进一步提升编译效率。

参考文档

- Apple - WWDC 2013 Advances in Objective-C
- Apple - WWDC 2018 Behind the Scenes of the Xcode Build Process

- Apple – WWDC 2019 Binary Frameworks in Swift
- Apple – WWDC 2020 Distribute binary frameworks as Swift packages
- Swift org – Evolving Swift On Apple Platforms After ABI Stability
- Swift org – ABI Stability and More
- StackOverflow – #import using angle brackets < > and quote marks " "
- StackOverflow – Xcode: Copy Headers: Public vs. Private vs. Project?
- StackOverflow – Understanding Xcode's Copy Headers phase
- Xcode Help – What are build phases?
- Xcode Build Settings
- Big Nerd Ranch – Manual Swift: Understanding the Swift/Objective-C Build Pipeline
- Big Nerd Ranch – Build Log Groveling for Fun and Profit: Manual Swift Continued
- Big Nerd Ranch – Build Log Groveling for Fun and Profit, Part 2: Even More Manual Swift
- Quality Coding – 4 Ways Precompiled Headers Cripple Your Code
- try! Swift Tokyo 2018 – Exploring Clang Modules
- milen.me – Swift, Module Maps & VFS Overlays

作者简介

思琦，笔名 SketchK，美团点评 iOS 工程师，目前负责移动端 CI/CD 方面的工作及平台内 Swift 技术相关的事宜。

旭陶，美团 iOS 工程师，目前负责 iOS 端开发提效相关事宜。

霜叶，2015 年加入美团，先后从事过 Hybrid 容器、iOS 基础组件、iOS 开发工具链和客户端持续集成门户系统等工作。

美团民宿跨端复用框架设计与实践

作者：凯林　森伟　熙辰　戈弋　少元

从 PC 时代、移动时代到万物互联的 IoT 时代，伴随终端设备的日趋多样化，跨端复用的种子自此落地，开始生根发芽。从依靠容器能力、各类离线化预装包的 Hybrid 方案，到通过 JSC 连接 JavaScript 生态与原生控件，结合视图框架（React、Vue 等）寻找效率、动态性和性能更均衡的 Native 容器方案（React Native、Weex 等），接着由微信牵头的以多进程 WebView、容器标准化的小程序方案出世，各平台小程序随之春笋萌发，随后带来了国内 Taro、uni-app、Rax、Remax 等多端框架的百家争鸣。

从业务角度出发，跨端技术演进更多是在不同阶段、不同时间段内业务效率上的选择，美团民宿业务就是在大前端融合的浪潮中逐浪前行，不断探索和迭代抉择，为解决业务痛点而孵化出跨端框架技术。本文主要分享美团民宿在跨端复用技术探索层面以及业务实践过程中积累的经验，希望能给大家带来一些帮助或者启发。

1. 背景

1.1 美团民宿业务介绍

美团民宿专注为消费者提供“住得不一样”的旅居体验，提供的服务包括民宿、酒店、公寓、客栈、短租、宾馆、旅行住宿等，同时包括树屋、房车、INS 风等新奇的网红民宿。美团民宿自上线之后，业务发展迅猛，在供给侧，房源类型不断丰富，各类分销、直销、直连、境外陆续推出，房源信息维度不断扩展，筛选、推荐、信息呈现也不断变得复杂。同时伴随着营销方式的丰富、房东管理、经营、服务的不断扩充，民宿的业务也越来越复杂。美团民宿大前端伴随业务的发展不断自我迭代，移动端整体架构也随之不断调整、升级，以寻求匹配业务多样化、复杂化的发展诉求。

1.2 美团民宿移动端现状

业务的发展和跨端复用技术的不断演化，让美团民宿客户端从业务刚起步的单端 Native App，到跨 App（民宿 App、美团 App、点评 App ）的 Native 复用和以 SSR 弥补性能差距的 Hybrid 的结合方案，在这场性能和效率的博弈中，客户端最终落脚以 React Native（以下简称 RN）为核心的复用框架。在此同时，民宿小程序端也随着微信小程序的诞生、生态壮大、多平台化的趋势不断成长，逐渐形成多平台复用的小程序架构。

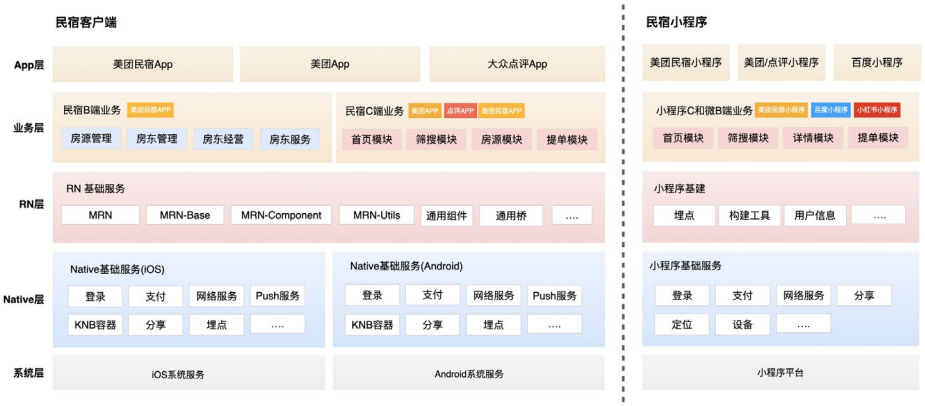

图 1　美团民宿移动端原始架构图

上图是美团民宿移动端原始架构图，左侧是客户端的技术架构，iOS 和 Android 系统层之上是独立的 Native 基建层，再往上通过了 RN 打开双端的复用之门，接着以 RN 容器标准化屏蔽了宿主应用间差异，保障了容器化的一致性，进而实现了业务层的复用和跨 App 的复用。右侧是民宿小程序当前简化的架构图，我们在基建层做了多端适配，通过多平台复用构建工具实现了各平台小程序的复用。当前客户端和小程端相关独立，开发维护也相互独立，团队各司其职。

尽管美团民宿 App 已经通过 RN 实现 iOS 和 Android 的跨端复用，但是由于 App 和小程序仍然需要投入双倍的人力成本进行业务迭代，所以我们思考一个问题：**是否可以更进一步，使用一套代码解决多端，把 iOS App、Android App、小程序进行大一统**。

2. 美团民宿跨端复用框架设计

2.1 行业现状

近几年，在微信小程序产品牵头下，业界也随之诞生出各种小程序应用，各端技术差异使得开发和维护成本都成倍增加。为了抹平原生开发、小程序开发、Web 开发等技术差异，一些优秀多端框架也就此诞生了。比如 Taro、uni-app、Rax、Remax 等，这些框架都是以自身定义 DSL（一般是 React DSL、Vue DSL）转换成各端应用（微信小程序、RN、H5 等），从而实现一套代码，多端运行。

在美团民宿业务中，App 的交易占比较大，从业务角度出发需优先保障 App 的性能体验和需求开发效率，而当前的民宿 App 已迁移至 RN 技术栈。基于这两点，我们希望跨端复用方案的是：RN 转到小程序平台方案，所以上述的多端框架并不能满足我们的 RN- 小程序跨端复用的诉求，为此美团民宿参考了业界多端设计方案，实现了基于 RN 转小程序复用的方案。

RN 采用的是 React 语法，因此如何将 RN 转换为小程序，首先要思考如何将 React 代码转换成小程序可运行的代码（简称小程序代码），其次是 RN 基础组件库的适配。随着这几年的发展，React 代码转换成小程序代码在业界实践也是层出不穷，业界方案分为编译时与运行时两类，以下是这两类方案的简单对比：

框架分类	重编译	重运行
典型代表	Taro2.0 / Rax 编译时	Taro Next / Remax
原理	编译时将 React 代码直接转换成小程序代码	运行是通过 React 自定义渲染器完成页面绘制
优势	性能损耗低	无语法限制
劣势	语法限制大	性能损耗大

对比来看，重编译方案有一个严重的问题：语法限制。因为大部分前端开发者们已经对灵活的语法有一定的依赖性，比如会使用高阶组件、在条件判断的时候写很多 return 等等，这种写法很难在编译过程被准确命中。因此，编译时方案就会制定一些语法规则来限制开发者的写法。重运行方案则没有语法限制问题，可以随意使用各种 React 特性。它的实现原理是通过 react-reconciler 实现小程序平台对应的 React

渲染器（以下简称 MP-Renderer），从而来渲染虚拟 DOM 树。不过小程序没有 DOM API 可以更新界面，所以生成的虚拟 DOM 树数据是通过小程序的 setData 触发渲染层的更新，在渲染层里有一个通用模板可以用来渲染这些数据。

因重编译语法限制的问题，我们决定采用重运行时方案来实现 RN 转小程序。但重运行方案存在性能问题，难以满足业务的要求，我们经不断探索后设计了对应的方案极大提升了性能，下文会详细描述如何解决这个问题的。

2.2 整体方案设计

2.2.1 RN 与小程序复用的技术方案

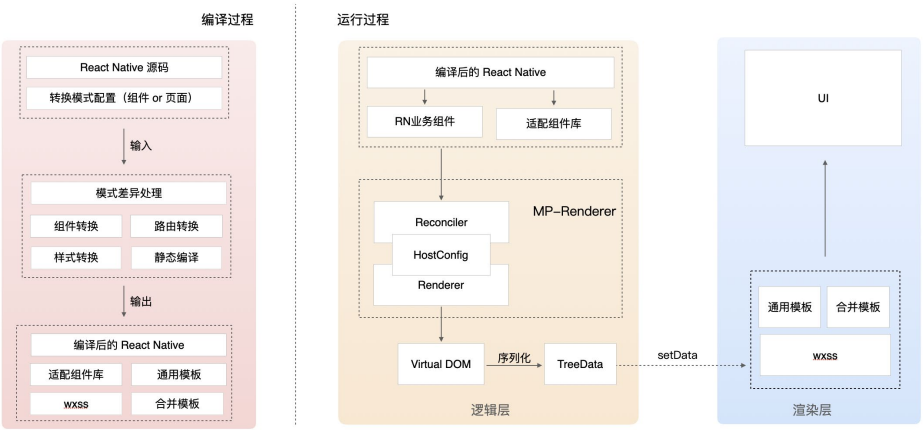

图 2　RN 与小程序复用技术方案图

整体架构分为两个部分：编译过程、运行过程。它的渲染方式与上文描述重运行时方案类似，都是通过 MP-Renderer 来处理 React 代码。下面我们来简要分析这两个过程：

(1) **编译过程**：该阶段对 RN 源码进行一定的转换处理，用于运行过程，编译后主要产生有以下产物：

- **编译后的 RN**：经过编译后产生 RN 代码，本质上还是 React 代码。

- **适配组件库**：RN 基础组件的适配库，是使用小程序自定义组件实现的。
- **通用模板**：由于小程序没有像 Web 有 DOM API 操作节点操作方法，所以这里通过一个通用模板来渲染 React 渲染出来的 TreeData（页面虚拟 DOM 树序列化后的 UI 数据）。
- **合并模板**：主要用于性能优化的，下文会详细分析这个模板的作用。
- **WXSS**：将 RN 代码的 Style 转换为 WXSS，这样可以减少页面的 TreeData 数据量，从而优化性能。

(2) **运行过程**：运行过程分为逻辑层和视图层两部分。

- **逻辑层**：编译后的 RN 源码包含 RN 业务组件和适配组件库，适配组件库是通过小程序自定义组件来进行适配。这样的方式既可以灵活使用小程序原生代码对齐 RN 组件功能，也可以提升转换后小程序的性能，因为小程序原生代码不会产生 TreeData 数据，从而使性能上得到提升。逻辑层有一个 MP-Renderer ，实现方式和上文讲述的是一样的，RN 代码经过渲染后，便产生对应的虚拟 DOM 树，虚拟 DOM 树数据再经过序列化便产生对应的 TreeData（描述页面的 UI 数据）。
- **渲染层**：当页面需要更新的时候，逻辑层通过 setData 将 TreeData 传输到渲染层里，TreeData 与通用模板、合并模板和对应样式结合在一起，便可以渲染出对应的 UI。

综上所述，上述整体设计与业界多端框架有点类似，但是也有不同点，主要体现在适配组件库和合并模板。适配组件库上文有解释比较好理解，而合并模板这里可能大家还是比较有疑惑的。其实这个合并模板内容是由编译过程的“静态编译”转换生成的，这样的处理方式是为提升转换后的小程序性能，接下来，我们会着重来讲述这个性能解决方案。

2.2.2 性能解决方案

重运行时方案性能损耗原因是什么？正如上文所说，重运行时方案会将所有 React 代码对应的 TreeData，再通过小程序 setData 传输到渲染层，当页面初始化或者大

数据更新的话，setData 就需要传递比较大的一个数据，因此也就会造成对应的性能问题。所以要解决这种方案的性能问题，核心就是要减少 TreeData 数据量。

在上述 RN 转小程序方案，有提到适配组件库、样式转换等是可以起到对应性能优化作用的，它的优化原理正是通过减少 TreeData 数据的方式。尽管这些方式可以优化性能，但是在页面比较复杂的时候，TreeData 数据量仍然会保留比较大，因此优化效果并不明显。为此，我们思考一种新的方式来进一步压缩 TreeData 的数据量，也就是前文所提到的结合静态合并树节点方案，在讲述该方案前我们先来看下一个 RN 代码转换为 TreeData 的例子：

图 3　RN 代码转换 TreeData 示例图

如上图所示，RN 代码转换后的 TreeData 是一个描述 UI 树的 JSON 数据，等同于右侧的 UI 树，将这颗树的节点进行分类，可以分为静态数据和动态数据，比如 View、Text 节点就是静态数据，而“Hello”、“World”则是动态数据。所谓静态数据，就是编译过程可预知的，因此这些数据是不是可以转换另一种形式来描述 UI 呢，从而减少 TreeData 的数据量。答案是肯定的，静态编译合并树节点正是通过这样的原理来实现的，如下流程所示：

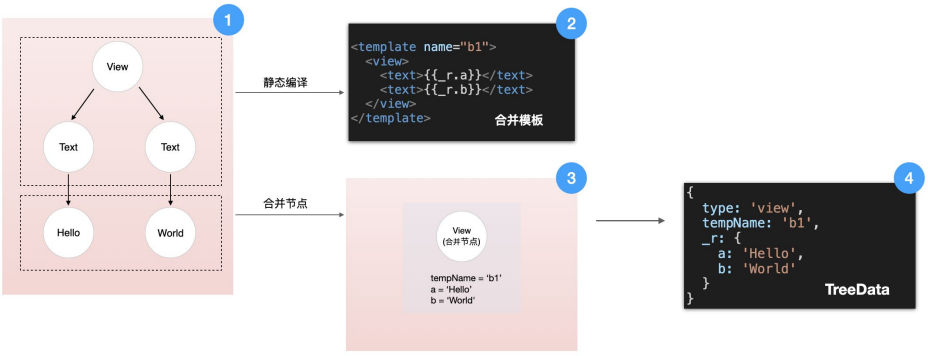

图 4　静态编译合并树节点原理图 -1

这个方案有两个动作，分别是静态编译和合并树节点，静态编译就将 RN 代码的转换成合并模板，如上图序号 2 代码所示，合并模板的名称为“b1”，内容就是一段与 RN JSX 代码对应的 WXML 结构片段。而合并节点是将已经静态编译的节点进行合并，如上图序号 2 至序号 3 流程所示，原本五个节点被合并到顶层的 View 节点，这个 View 节点称为合并节点，合并节点需要记录合并模板的名称和相关的动态数据，目的是为了渲染时让合并节点可以找到对应的合并模板进行渲染，经过这样合并节点后，最终生成的 TreeData，如上图序号 4 所示。可以看到 TreeData 相比之前的数据量就减少了 60% 左右！

看到这里，是不是有同学就有疑问了，上文不是提到静态编译会有语法限制，那这里是否会有语法限制？确实，如果是完全静态编译，是会有语法限制，而这里所说的结合静态编译是有选择性的编译，即在编译过程，首先会通过 AST 分析节点是否静态数据，如果是的话，再转换成对应的合并模板。如果遇到不可预测的动态节点，则按照运行时方案去处理。因此，最终生成的 UI 树节点即会包含合并节点、也会包含原本的组件节点，如下图所示：

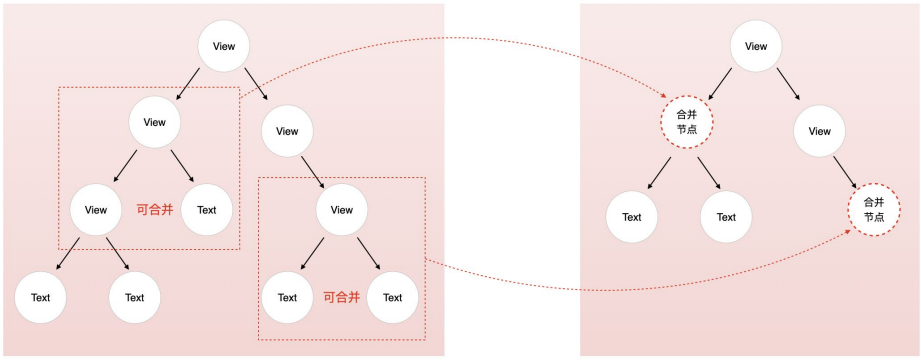

图 5　静态编译合并树节点原理图 -2

通过这样的方式，既可以保证语法无限制，又能通过编译结合的手段最大化优化性能。当然了这种方案也是有缺点，因为这种方案其实是用空间换性能的方式，生成的合并模板会影响会影响包大小，不过对于一些需要追求性能的页面，这点包大小的增加是值得付出的。

为了更好地衡量解决方案对性能的提升程度，我们参考 Taro 官网的实验（实验内容），对优化前后以及原生和 Taro 3.0 运行后的性能指标进行采集与比较。经过实验，统计出各框架在初始化、加载数据、加载大量数据的操作耗时，如下表所示：

操作耗时 \ 框架	优化前	优化后	原生	Taro 3.0.17
初始化（首屏渲染时间）	897ms	423ms	210ms	675ms
加载普通数据（20 条）	1124ms	198ms	110ms	640ms
加载大量数据（400 条）	5330ms	1041ms	470ms	3919ms

从上表中可以看出：性能优化后，得益于更少的渲染数据与更精简的节点树，加载数据的操作耗时比优化前减少 80% ，初始化耗时减少了 52%。与同类型的框架 Taro 3.0 相比，也有更好的性能表现。

与原生相比，优化后性能差距明显减少，但是由于运行时方案相对于原生需要更多的 setData 数据开销和更复杂渲染流程，所以从原理上运行时方案和原生性能差距客观存在。尽管如此，业务实践上两者差距并不会那么明显，因为在测评实验中测试数据

比较纯粹，setData 数据使用率较高，但在业务实践中原生开发 setData 数据难免冗余且难以优化，而运行时方案会默认优化冗余数据使得两者性能差距更接近，从我们历史业务实践数据上看，性能与原生差距在 10% 左右。

3. 美团民宿跨端复用实践

在跨端复用探索中，我们用创新的方案解决了性能和特性限制的难题，设计了 RN-小程序跨端复用框架。虽然跨端复用属于“利器在手”，但是这是一把“双刃剑”，用得其所则事半功倍，处理不当则隐患丛生。那么，如何在业务实践中驾驭好这把利刃呢？我们先介绍在业务实践中遇到的问题，然后介绍解决这些问题的方案。

3.1 跨端复用场景下的问题

- **复用场景下的问题**：小程序产品形态以轻、快、便为旨，用户可快速使用，用完即走，客户端产品相对全、精、稳，可以满足更多的用户需求，以用户留存、用户认知、用户体验为主，两者在产品功能上存在较大的差异，如何恰当地处理产品差异化问题是跨端复用的场景下的一个重要挑战。
- **跨端复用质量隐患**：实现了复用便要考虑两端的各种兼容性问题，这就会产生各种质量上的隐患。如何在复用组件不断迭代中，保障组件接口、输入、输出的兼容性问题？如何保障各个复用组件底层依赖的统一、适配层接口的统一？双端复用场景下，如何更好的做测试和监控？双端同学存在各自技术认知的边界，如何在出现问题时快速排查、及时止损？
- **跨端复用流程规范问题**：新的技术革命，必然打破旧的秩序，在当前跨端复用场景下，各种包括工程管理、代码规范、分支管理、需求同步的问题也会孕育而生，同需解决。

3.2 跨端复用应用架构

为了解决跨端复用在业务实践中遇到的各种问题，我们重新设计了跨端复用应用架构，从架构分层管理、复用方式设计、流程规范、质量保障方面入手，重点解决跨端差异化、质量隐患、流程规范各种问题，并寻求复用的最大化和性能上的均衡。

3.2.1 跨端复用应用架构演进

在这里，先贴出动态的架构演进过程，让大家有一个宏观的认识。我们先简单地描述下演进过程，后续会基于最终的架构图再做详细的介绍。大致演进过程如下：

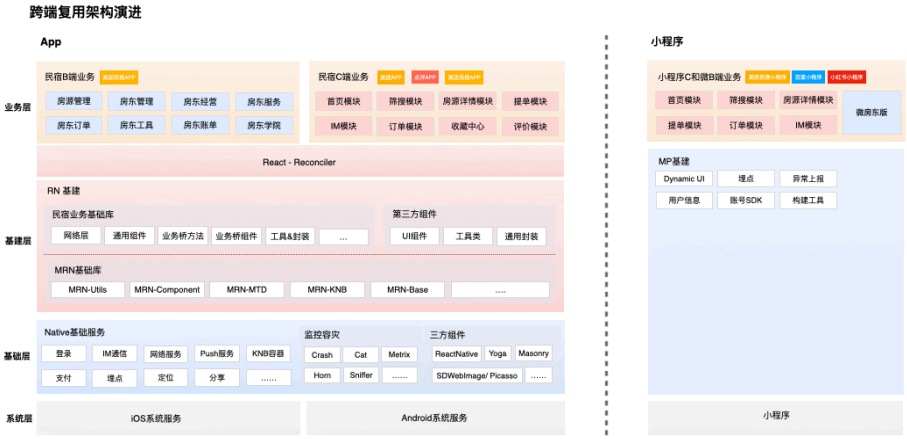

图 6　跨端复用架构演进动画图

- 起初，客户端分 Android App 和 iOS App 单独开发，引入 RN 技术实现了 Android 和 iOS 跨端复用，但是小程序端依然需要单独维护迭代。
- 为了跟进一步实现 RN- 小程序跨端复用，我们接入了自研的 RN- 小程序跨端复用框架，并基于框架的适配规范，以 RN 的基建为基准，打造出一个和 RN 基建统一接口的小程序适配层。
- 完成小程序渲染器接入（MP-Render）和小程序适配层后，React-Reconciler 这一层就可以打通到小程序侧，实现了 React 代码复用到小程序的能力。
- 实现 RN 与小程序间的复用后，就可以对存量的 RN 代码进行抽象、适配、整理，进而抽取出一个组件复用层，这个复用层可直接供上层业务层直接使用。
- 最后，为了解决跨端复用场景下各种流程、协作和质量隐患，我们配套了相应的流程规范和质量保障措施。

3.2.2 跨端复用应用架构整体介绍

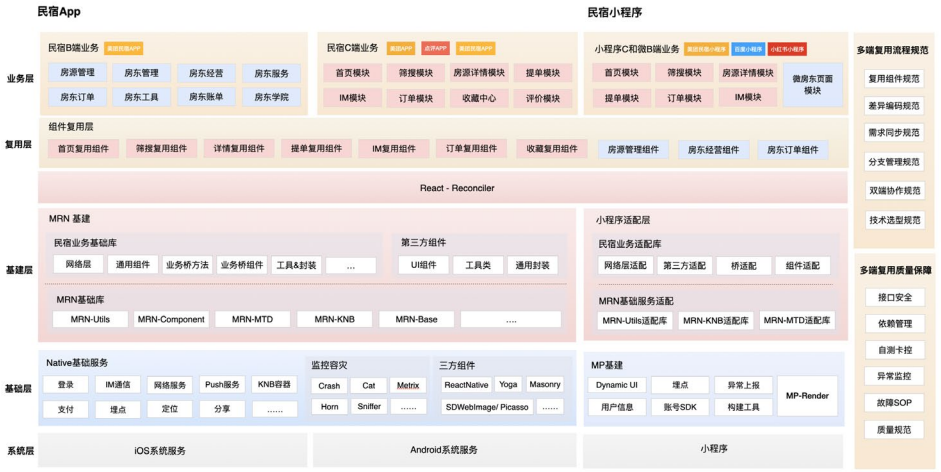

图 7　跨端复用应用架构图

整个民宿的 RN- 小程序跨端复用架构图如上，我们按照从下到上，从左到右的视角进行解读：

- **系统层**：最底层是系统服务，除了 iOS 系统和 Android 系统外，我们把小程序视为一个单独的系统模块。
- **基础服务层**：系统服务之上是基础服务层，这一层主要是集团基于 Native 和小程序建设的基建，全公司通用，覆盖了研发工程中方方面面的基础服务。在此基础上，我们在小程序基建中引入了基于 react-reconciler 实现的小程序运行时渲染器（MP-Render），这个渲染器能在运行时动态更新 vnode 以匹配编译转化的小程序 UI 模板，调用小程序原生 API，最终渲染出小程序组件，有了这个基于 React 的小程序渲染器便使得跨端复用成为可能。
- **基建层**：基础服务层之上是基建层，这块主要包括 MRN 基建和小程序适配层，我们以 MRN 的基建为标准，适配出一个统一标准和统一接口的小程序适配库，通过这一层适配，上层可以无感知、无差异地以同一标准实现复用组件。其中适配层分为 2 块，下半部分主要适配 RN 基础服务，上层是民宿业务独立封装的基础库和第三方库，这块我们单独引入一个名为 Mapping 的适

配库。一个独立的适配库可以让 RN 和小程序在业务迭代和技术变革过程中相互独立，互不干扰，如此就能保障技术的推进完全不会影响业务的迭代。基建层的最上方是 react-reconciler，React 框架本身就是把协调过程和渲染过程分开的，react-reconciler 是实现跨端复用的核心，所以我们把它单独展示出来，它真正打通了客户端和小程序的隔阂，只要有了一个独立的小程序渲染器，就可以全面、无限制的把 React 代码复用到小程序。

- **复用层**：基建层再往上是复用层，复用层主要以组件维度做复用，复用组件是基于存量 RN 组件做抽象和适配，然后抽取独立出来，复用层的组件以统一的标准和接口供上层业务使用。复用层是很重要的一块，好的复用机制能帮助我们解决前面提到的产品差异化问题和复用最大化问题。这块我们单独放到 `3.3 跨端复用方式设计` 来详细讲解。
- **业务层**：复用层之上就是业务层，业务层的各模块主要以页面容器来承接复用组件，基于不同的端和产品差异，可以灵活、动态配置页面的组件来满意业务的差异化需求。

3.3 跨端复用方式设计

差异化问题，一直是跨端复用场景中的一个痛点，双端的产品上、平台上、代码上的差异如何妥善的处理、适配，也是我们一直思考的问题。而好的差异化处理方案可以提升代码的可维护性、降低质量隐患、提升开发效率。我们从复用设计层面出发，探索出页面复用模式、组件复用模式、“组件 + 逻辑复用”模式等三种复用设计方式，并且根据不同的场景下采用不同的复用模式，可以较好地处理跨端差异化问题，同时能兼顾效率提升、性能体验和可维护性。

3.3.1 差异化下的复用方式

我们自研的复用框架提供两种复用模式，如下图所示：

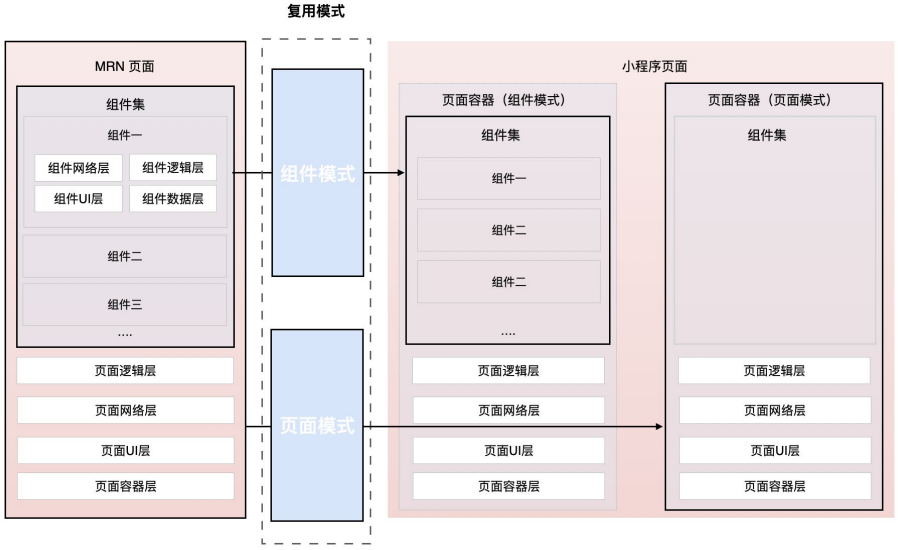

图 8　小程序复用方式原理图

页面复用模式：页面模式基于页面维度的，可以直接把页面的网络层、逻辑层、数据层以及页面内的组件集全部转换复用，这样可以达到复用的最大化，代码复用率能达到 90% 以上，人效提升明显。**组件复用模式**：组件模式是基于组件维度的，复用以页面中的业务组件为目标，把页面的所有组件抽象、解耦、规范化之后抽取为复用组件。组件模式只能复用组件内代码，对于页面容器的逻辑交互、网络层都需要小程序自己实现，代码复用率相对较低，但是组件复用更灵活、可控，可随意插拔、拼接、定制。

以下是两种复用模式的优劣分析。

页面复用模式

优势

1) 提效明显：整个页面包括所有组件、页面逻辑层网络层一并打包转换复用，代码复用率极高，开发效率提升幅度更大。 2) 接入成本低：整个页面直接转化同步复用，无需小程序同学协助接入，减少双端协助、接口沟通带来的出错风险。

劣势

1) 灵活性低：业务差异和小程序特性不易处理，双端差异适配只能在 RN 上做，代码易出错，维护成本高。 2) 性能劣势：整体页面由 RN 转换复用而来，页面一次性渲染，性能上会略差一些，而且做页面级的性能优化困难。 3) 包大小风险大：整页复用情况下包大小较大，且不能动态调配（比如页面内某一模块需求迭代较少，不想复用，但是页面模式做不到动态移除）。

组件复用模式

优势

1) 轻便灵活：组件如插件般可随意插拔、拼接、定制，可较好解决 App 和小程序双端的差异性问题，针对差异点双端可以独立实现，提高项目的可维护性。 2) 性能较好：页面容器依然是小程序原生组件，如滚动、滑动组件采用原生可减少性能损耗，另外组件分布式 setData 渲染有更好的性能，不会像整页一次性渲染导致 setData 数据量较大影响首屏加载性能。 3) 性能优化空间大：不会影响做页面维度的性能优化（如首屏优先、请求前置）。 4) 包大小可控：组件是否复用可以动态调配，比如把页面中迭代较少的组件不复用以减少包大小。

劣势

1) 提效有限：组件模式只能复用组件内的代码，代码复用率较低，页面容器、逻辑层、网络层小程序依然要自己维护一份代码。2) 复用组件维护成本高：组件的接口要考虑组件升级迭代的兼容性、可维护性问题，管理不当，容易产生质量隐患。 3) 接入成本较高：小程序需要实现 RN 的页面逻辑，然后按照组件接口进行接入，有更高的接入成本。

两组复用模式各有利弊，页面模式复用率高，但是灵活性低、性能欠佳；组件模式轻便灵活，性能可控，能较好的处理平台差异化问，但是复用率低、维护成本高。我们在想有没有一种方案能保留组件模式的灵活性，又能降低组件维护成本、提高复用程度。在业务实践中，我们探索出一套“组件 + 逻辑复用”的模式，可以较好地解决上

面提到的问题。

3.3.2 差异化下的逻辑复用

“组件 + 逻辑复用”模式依然保留组件复用的方式，但是在组件复用基础上增加了逻辑层（包括页面逻辑、网络、数据层）的复用，这样保留了组件灵活性，也增加了复用性。具体设计如下图：

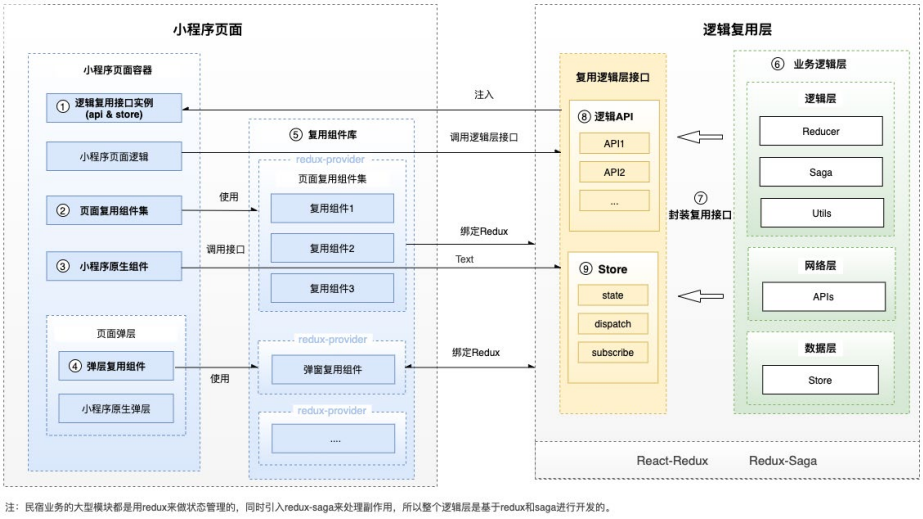

图 9　组件 + 逻辑复用模式原理图

整个组件 + 逻辑复用模式设计图如上，我们按照图片标注的序号进行一一解读：

1) **逻辑复用接口实例**：在小程序的页面容器中，通过注入的方式获取逻辑层复用的接口实例，通过这个实例便可以调用接口实现获取、更改、监听 Redux 的状态，实质上就达到了逻辑复用的效果。 2) **页面复用组件集**：页面可以自由使用复用组件，复用组件可大可小，可以虽然拼装布局，保留了组件模式良好的灵活性。 3) **小程序原生组件**：页面既可以使用复用组件，也可以用小程序原生组件来实现小程序差异化的功能和特性，这样能较好的处理双端差异性。小程序原生组件可以通过 逻辑复用接口实例 来调用逻辑层功能，进而达到逻辑复用的效果。 4) **弹窗复用组件**：弹窗复用组件和页面复用组件同理，这边主要说明可以按照各类维度把复用组件分类，进

而更好的做复用组件管理。 5) **复用组件库**：复用组件库的复用组件可多可少，可大可小，如果页面双端差异性小，一个大组件即可满足。每个复用组件集外层包一层 Reudx-Provider 并设置相同的 Store，便可以和逻辑层自动绑定上。因为 RN 组件本身就是基于 Redux 的，所以复用过程相对容易。 6) **业务逻辑层**：最右侧的业务逻辑层可以简单理解成 3 块，一块是基于 Redux Store 的数据层，这里存放整个页面模块所有的数据和操作、监听数据的接口，一块是包含页面内所有网络请求的网络层，另外就是用来流转状态和处理复用的 Reducer、Redux-Saga，以及配套的各种工具类。业务逻辑层可以根据双端的差异把 Reducer 与 Saga 分拆更小的单元实现差异化的逻辑复用，提升逻辑复用层的代码可维护性。 7) **封装复用接口**：业务逻辑层包含整个页面的业务逻辑，只要针对性开放接口给小程序，让小程序可能获取、更改、监听 Redux 的状态，那实质上就达到了逻辑复用的效果。开放接口给小程序有 2 种方式：逻辑 API 接口 和 Store。 8) **逻辑 API 接口**：基于 Store 给小程序提供小程序真正需要的逻辑 API 接口，通过这些 API 小程序可以来获取数据来渲染 UI（如：渲染没有复用的组件），也可以更新数据，也能监听复用组件内部的数据变化。 9) **Store**：把 Redux Store 暴露出去，小程序便利用 Store 实例可以通过 getState、dispatch、subscribe 来操作、监听状态机了，也就达到逻辑层复用的目的了。

这种方案的优势很明显，它保留组件模式的灵活特性，可以比较方便做差异化处理和性能优化。而逻辑复用层把 Redux 包含进来了，这样不仅转化容易、不易出错，而且逻辑复用接口基于 Redux 的 Store，接口较好设计，容易维护、不易出错。而对于逻辑层，可以根据业务上一些差异做 Reducer 与 Saga 分拆，把不需要复用的代码逻辑排查在外，逻辑层复用也可以做到像组件一样热插拔，按需引入，这样也比较好做差异化代码管理，挺高项目的可维护性，同时也能优先减少包大小风险。

3.4 跨端复用流程规范

为在代码跨端复用过程中尽可能提升开发效率并避免引入质量问题，我们制定了差异化编码规范、需求同步规范、复用组件规范等开发流程规范，以下将通过 RN 到小程

序产品需求同步过程进行简单的介绍。

图 10　跨端复用流程规范图

1. 评估业务需求是否需要同步

针对 PM 提出需要同步的需求，客户端尽量将 RN 业务代码复用至小程序，以提升开发效率。无需同步的需求将通过差异编码规范进行控制，避免同步至小程序后增加潜在风险与测试成本。通常可使用平台判断（如 iOS、Android、WX_Platform ）的方式控制业务代码是否打入复用组件包，也可通过 module.rn.js、module.wx.js 不同后缀文件方式完成相同接口不同逻辑的实现。

2. 评估是否有关联依赖需求

如明确业务需求需要同步，先判断该需求是否有前置需求依赖，再评估技术方案。如无依赖可直接开始复用适配工作；如有依赖，需判断前置需求能否一起同步或做适当降级，以此递推，避免因前置依赖需求未同步出现不符合预期的问题。

3. 制定 RN 组件适配与小程序接入方案

明确需求同步范围评估工作后，需完成以下技术评估工作：（1）明确需求是否需要新建复用组件还是在原有的复用组件上进行迭代。如需新建复用组件 NPM 包，需根据组件复用规范进行技术选型，确定使用“组件 + 逻辑复用模式”、“页面模式”还是“组件模式”，并制定相应的复用组件接口协议；（2）明确该需求是否需要开发 RN- 小程序映射方法、组件，并评估相应的开发量。完成技术评估后需提前与小程序侧沟通接入排期。

4. RN 组件适配开发

客户端完成 RN 侧需求开发后，便可进行复用组件适配小程序开发。完成适配开发工作后需在 RN 页面与小程序 Demo 页面中对复用组件同时进行测试，避免在适配小

程序过程中引入 RN 页面 Bug。复用组件测试完毕后将 NPM 包以及相应的接口文档提供给小程序接入，但在打包前需严格审查当前版本与上个版本间的 diff，避免不符合预期的代码也被同步至小程序。

5. 小程序接入 RN 适配组件

适配完成后将组件打包提供给小程序侧接入，接入后需在美团民宿小程序环境下再次进行自测。原则上客户端同学提供适配好的 RN 组件后，由小程序侧同学接入并测试，但我们也鼓励客户端在完成 RN 组件开发与复用适配后，一并完成小程序侧的组件接入工作，这样需求开发完整度更高，并能有效减少跨端开发下的沟通成本。后续随着大前端融合推进，RN- 小程序代码复用率将逐步提升，客户端（iOS、Android）与 小程序代码将倾向由一名同学完成多端开发。

6. RN 适配代码合入迭代分支

需求在小程序测试完毕后，将 RN 组件适配 Feature 分支代码合入 Release 迭代分支，并在客户端（iOS、Android）打包上线。

3.5 跨端复用质量保障

跨端复用场景下存在包括复用组件接口兼容性问题、组件间的依赖隐患问题、测试和监控的缺失问题，以及故障排查困难等各种质量隐患，我们在业务实践中，也探索出一系列解决这些隐患的质量保障措施，包括组件接口维护、组件依赖管理、双重自测卡控、异常监控融合、双端故障 SOP、跨端复用流程规范 。这些措施能有效保障复用场景下双端的线上质量，民宿业务在跨端复用推进中，因为这些措施的保障护航，没有出现任何的线上故障。

1. 组件接口维护

复用组件随着业务迭代会不断更新升级，组件升级过程中便会带来的组件接口、输入、输出的变动，进而产生兼容性隐患，比如组件输入参数类型变动，而小程序端或 RN 端没有及时兼容或者未知晓，非常容易引发线上质量问题。为此，我们制定了组件接口维护计划，包括复用组件接口规范、组件版本管理规范、组件接口文档建设

等。复用组件接口规范要求复用组件接口、参数必须严格按照规范来，如参数类型使用基础类型、只增少减原则、接口命名清晰、参数个数限制等等，减少双端的接入组件难度，避免参数频繁变动产生质量隐患。组件版本管理规范要求组件版本升级必须遵循語意化 2.0，并且有相应的版本升级文档。组件接口文档建设也是很重要的一环，每个复用组件都有相应的文档维护，记录参数的增删改查，接入方对组件接口变动一目了然，自然减少了接入风险。

2. 组件依赖管理

组件依赖主要存在两个问题，第一，复用框架本身也在不断升级优化、新的复用组件可能用新的编译版本转化而来并且依赖新的运行时渲染器，但是旧的复用组件可能会出现不兼容问题，因此我们开发相关的工具，如果组件依赖的运行时渲染器版本和小程序内置的不一致就会发出警告，提示组件兼容性问题。第二，因为不同的复用组件来自不同的 RN 模块，它们可能依赖不同版本的第三方库，容易产生版本不一致的质量问题。目前的解决方案是把这些依赖库分别打入各自的包里，这样复用组件间依赖相互独立，互不影响。再结合 Tree-Sharking 的优化，打入的依赖的真实包大小并不大，用小量的包大小换取更稳健的质量保证。

3. 双重自测卡控

在跨端复用场景下，一个复用模块的改动要考虑双端兼容和新旧版兼容问题，相比与之前有更高的出错风险，更全面的自测能帮我们尽早暴露问题，减少故障风险。所以我们在 App 侧和小程序侧做了代码自测覆盖率卡控，要求改动代码执行覆盖率超过 90% 才能提测和上线。复用组件既在 RN 侧自测过一遍，在小程序接入后又强制要求再自测一遍，双重自测卡控更能保障组件质量和线上质量。

4. 异常监控融合

RN 和小程序侧都有单独的异常监控机制，包括 JS 异常监控、API 异常监控、自定义异常监控等。但是双端的异常监控机制差别较大，在复用场景下两者交叉混用导致异常监控体系混乱，上报数据格式、策略、日志不统一而造成监控体系误告、漏

告、排查困难、运维混乱等问题。所以我们把双端的异常监控模块打通，适配了底层异常上报逻辑，统一了双端的上报规范，告警策略、日志、处理流程。异常监控体系双端融合后，异常上报、监控、运维都顺畅许多，也帮我们发现不少的线上异常，是 RN- 小程序跨端复用场景线上质量的坚固屏障。

5. 双端故障 SOP

鉴于双端同学存在技术上的隔阂和信息不对称，当出现复用组件的故障或异常时，如何快速排查问题成为一个痛点，小程序的错误日志 RN 同学不熟悉，小程序同学不熟悉 RN 的业务代码实现，框架层面的错误更难排查。为此，我们整体了梳理双端故障 SOP，这里面包括常见日志分析帮助鉴别是复用组件、小程序端、底层复用框架的问题和相应的解决方案，同时开发了 Source Map 错误反解工具协助 RN 同学反解小程序日志帮助快速排错等等。这些 SOP 和工具能够在第一时间帮助双端同学自主或协助排查相关故障，快速止损。

6. 跨端复用流程规范

流程规范包括前面提到的复用组件规范、编码规范、需求同步规范、分支管理规范等等也是质量保障的重要的一环，它让研发流水线每一环都有严格的法律约束，保障整条研发流水线最终能把完整的产品交付到用户手里。

3.6 成果

RN- 小程序跨端复用的设计方案在业务实践中不断完善，探索出效率相对最大化的复用模式。从开发效率角度来看，提升显著。我们总结了代码复用率与人效提升率来评估效率的提升，两个指标具体计算公式如下：

- **代码复用率**：∑ (RN 复用模块代码行数 − 模块中 RN 与小程序平台分支判断代码行数) / ∑ (RN 代码总行数 + 小程序原生代码行数)；其中，RN 复用模块代码行数是根据框架转换生成的组件来确定。
- **人效提升率**：∑ (RN 开发耗时 + 小程序开发耗时 − (RN 开发耗时 + 转换适配耗时)) / ∑ (RN 开发耗时 + 小程序开发耗时)；复用前需要 RN 与小程序侧两

端的开发耗时，复用后只需要 RN 开发与复用组件转换适配的耗时，根据复用前后的耗时可以得出人效提升率公式。

根据转换采用的模式不同，可以得出代码复用率与人效提升率，如下表所示：

转换模式	代码复用率	人效提升率
组件 + 逻辑复用模式	76%	42.36%
页面复用模式	91%	46.71%

从表中可以看出，页面转换模式复用了页面与组件的代码，代码复用率可以达到 90% 以上；组件复用模式复用了组件与部分业务逻辑代码，复用率也可以达到 76%。在人效提升方面，所有模式都能达到较高的人效提升率，代码复用率越高人效提升率也越高，页面转换模式可以复用页面与数据状态处理逻辑人效提升比组件转换模式更高。

4. 总结

民宿大前端团队为解双端研发效率之痛，倾力而寻跨端之技，浅尝百草、深谙其理而后自建之，举偏补弊、终解跨端框架性能之桎梏，青出蓝而胜于蓝。而后践于实业，瑕弊昭然若揭。为此，重设框架以谋其变（复用架构设计），寻之新式以尽其效（复用模式设计），立之新法以固其序（跨端复用流程规范），磨之利器以护其城（跨端复用质量保障），至此成果初成。然朝夕变化不休，路漫远兮，吾当持之求索以适其变、顺其道。跨端复用前行之鉴，故记以文，望有启示，文毕。

作者简介

凯林、森伟、熙辰、戈弋、少元等，均为美团民宿前端团队研发工程师。

招聘信息

美团民宿长期招聘 Android、iOS、FE 前端工程师，坐标在福建厦门。感兴趣的同学可将简历发送至：tech@meituan.com（邮件主题请注明：美团民宿大前端）。

美团跨端一体化富文本管理技术实践

作者：高瞻　宇立等

一、引言

在互联网圈，开发和产品经理之间相爱相杀的故事，相信大家都有所耳闻。归根结底，往往都是从简单的改需求开始，然后你来我往、互不相让，接着吵架斗嘴，最后导致矛盾不断升级，甚至带来比较严重的后果。

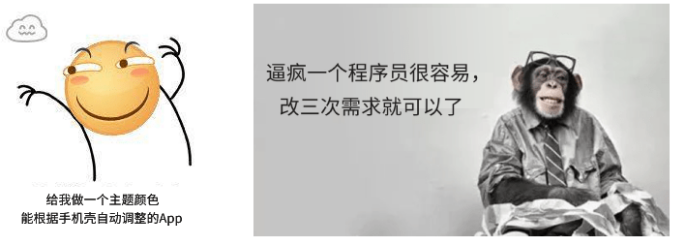

图 1

在这种背景下，如果把一些功能相对简单的、需求变动比较频繁的页面，直接交给产品或者运营自己去通过平台实现，是不是就可以从一定程度上减少产品和开发人员之间的矛盾呢?

二、背景

当然上述的情况，美团也不例外。近些年，美团到家事业群（包括美团外卖、美团配送、闪购、医药、团好货等）的各个业务稳步发展，业务前端对接的运营团队有近几十个，每个运营团队又有不同的运营规则，这些规则还存在一些细微的样式差别，同时规则内容还会随着运营季节、节日、地理位置等进行变化和更新。这些需求具体来说有以下几个特点：

- **需求量大**：业务稳步发展，业务需求不断叠加，甚至部分业务呈指数级增长，

且业务方向涉及到一些业务规则、消息通知、协议文档、规则介绍等需求。

- **变更频繁**：面对市场监管和法务的要求，以及新业务调整等因素的影响，会涉及到需求的频繁变更，像一些业务 FAQ、产品介绍、协议文档、业务规则、系统更新日志等页面，需要做到快速响应和及时上线。
- **复杂度低**：这些页面没有复杂的交互逻辑，如果能把这些简单的页面交给运营 / 产品去实现，开发人员就能有更多的时间去进行复杂功能的研发。
- **时效性高**：临时性业务需求较多，且生命周期较短，具有定期下线和周期性上线等特点。

基于以上特点，为了提高研发效率，美团医药技术部开始构建了一个**跨端一体化富文本管理平台**，希望提供解决这一大类问题的产研方案。不过，部门最初的目标是开发一套提效工具，解决大量诸如帮助文档、协议页、消息通知、规则说明等静态页面的生产与发布问题，让产品和运营同学能够以**所见即所得**的方式**自主**完成静态页面制作与发布，进而缩短沟通成本和研发成本。

但是，随着越来越多业务部门开始咨询并使用这个平台，我们后续不断完善并扩充了很多的功能。经过多次版本的设计和迭代开发后，将该平台命名为 **Page- 佩奇**，并且注册成为美团内部的公共服务，开始为美团内部更多同学提供更好的使用体验。

本文将系统地介绍 Page- 佩奇平台的定位、设计思路、实现原理及取得成效。我们也希望这些实战经验与总结，能给更多同学带来一些启发和思考。

三、跨端一体化富文本管理解决方案

3.1 平台定位

我们希望将 Page- 佩奇打造成一款为产品、运营、开发等用户提供快速一站式发布网页的产研工作台，这是对该平台的一个定位。

- 对产品运营而言，他们能够**可视化**地去创建或修改一些活动说明、协议类、消息类的文章，无需开发排期，省去向开发二次传递消息等繁琐的流程，也无需

等待漫长的发布时间，从而达到灵活快速地进行可视化页面的发布与管理。

- 对开发同学而言，他们能够**在线编写代码**，并实现**秒级**的发布上线，并且支持 ES 6、JavaScript 、Less、CSS 语法，我们还提供了基础的工具、图表库等，能够生成丰富多样的页面。帮助开发同学快速实现数据图表展示，设计特定样式，完成各种交互逻辑等需求。
- 对项目管理方而言，他们能够清晰地看到整个需求流转状态和开发日志信息，为运营管理提供强大的“抓手”。

一般来讲，传统开发流程是这样的：首先产品提出需求，然后召集研发评审，最后研发同学开发并且部署上线；当需求上线之后，如果有问题需要反馈，产品再找研发同学进行沟通并修复，这种开发流程也是目前互联网公司比较常见的开发流程。

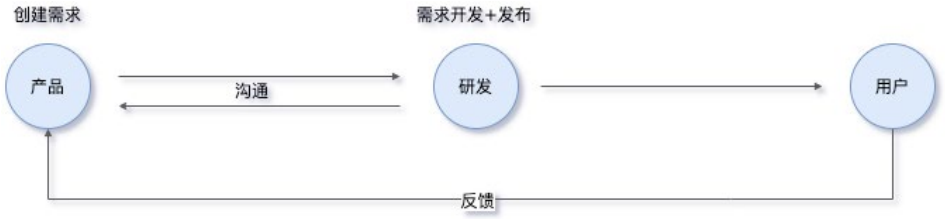

图 2　传统开发流程图

而美团 Page- 佩奇平台的开发流程是：首先产品同学提出需求，然后自己在 Page 平台进行编辑和发布上线，当需求上线之后有问题需要反馈，直接就能触达到产品同学，他们通常可自行进行修复。如果需求需要定制化，或者需要做一些复杂的逻辑处理，那么再让研发人员配合在平台上进行开发并发布上线。

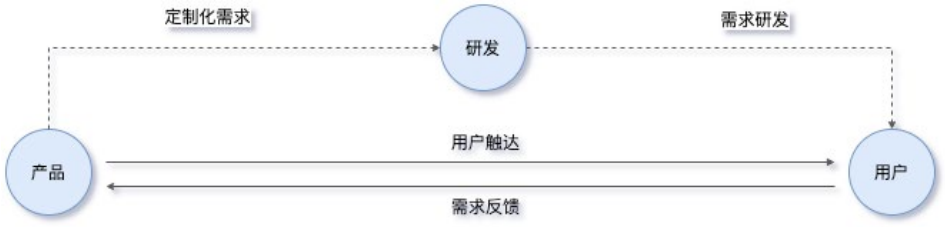

图 3　Page- 佩奇平台开发流程图

简单来说，对那些功能相对简单、需求变动比较频繁的页面，如果用传统的开发流程将会增加产研沟通和研发排期成本，因此传统方案主要适用于功能复杂型的需求。而Page- 佩奇平台开发流程，并不适合功能复杂型的需求，特别适用于功能相对简单、需求变动比较频繁的页面需求。

综上所述，可以看出这两种开发流程其实起到了一个互补的作用，如果一起使用，既可以减少工作量，又可以达到降本提效的目的。

3.2 设计思路

我们最初设计 Page- 佩奇平台的初心其实很简单，为了给产品和运营提供一个通过富文本编辑器快速制作并发布网页的工具。但是，在使用的过程中，很多缺陷也就慢慢地开始暴露，大致有下面这些问题：1. 简单的富文本编辑器满足不了想要的页面效果，怎么办？ 2. 如果能导入想要的模板，是否会更友好？ 3. 怎么查看这个页面的访问数据？如何能监控这个页面的性能问题？ 4. 发布的页面是否有存在安全风险？

于是，我们针对这些问题进行了一些思考和调研：

- 当富文本编辑器满足不了想要实现的效果的时候，可以引入了 WebIDE 编辑器，可以让研发同学再二次编辑进行实现。
- 一个系统想要让用户用得高效便捷，那么就要完善它的周边生态。就需要配备完善的模板素材和物料供用户灵活选择。
- 如果用户想要了解页面的运行情况，那么页面运行的性能数据、访问的数据也是必不可少的。
- 如果发布的内容存在不当言论，就会造成不可控的法律风险，所以内容风险审核也是必不可少的。

实现一个功能很容易，但是想要实现一个相对完善的功能，就必须好好下功夫，多思考和多调研。于是，围绕着这些问题，我们不断挖掘和延伸出了一系列功能：

- **富文本编辑**：强大而简单的可视化编辑器，让一切操作变得简单、直观。产品同学可以通过编辑器自主创建、编辑网页，即使无程序开发经验也可以通过富

文本编辑器随意操作，实现自己想要的效果，最终可以实现一键快速发布上线。

- **WebIDE**：定制化需求，比如，与客户端和后端进行一些通信和请求需求，以及针对产品创建的 HTML 进行二次加工需求，均可以基于 WebIDE 通过 JavaScript 代码实现。具备专业开发经验的同学也可以选择通过前端框架 jQuery、Vue，Echarts 或者工具库 Lodash、Axios 实现在线编辑代码。
- **页面管理**：灵活方便地管理页面。大家可以对有权限的文档进行查看、编辑、授权、下线、版本对比、操作日志、回滚等操作，且提供便捷的文档搜索功能。
- **模板市场**：丰富多样的网页模板，简易而又具备个性。模板市场提供丰富的页面模板，大家可选择使用自己的模板快速创建网页，且发布的每个页面又可以作为自己的模板，再基于这个模板，可随时添加个性化的操作。
- **物料平台**：提供基础 Utils、Echart、Vue、jQuery 等物料，方便开发基于产品的页面进行代码的二次开发。
- **多平台跨端接入**：高效快捷地接入业务系统。通过通信 SDK，其他系统可以快速接入 Page- 佩奇平台。同时支持以 HTTP、Thrift 方式的开放 API 供大家选择，支持客户端、后端调用开放 API。
- **内容风险审核**：严谨高效的审核机制。接入美团内部的风险审核公共服务，针对发布的风险内容将快速审核，防止误操作造成不可控的法律风险。
- **数据大盘**：提供页面的数据监测，帮助大家时刻掌握流量动向。接入美团内部一站式数据分析平台，帮助大家安全、快速、高效地掌握页面的各种监测数据。
- **权限管理**：创建的每个页面都有相对独立的权限，只有经过授权的人才能查看和操作该页面。
- **业务监控**：提供页面级别 JavaScript 错误和资源加载成功率等数据，方便开发排查和解决线上问题。

功能流程图如下所示：

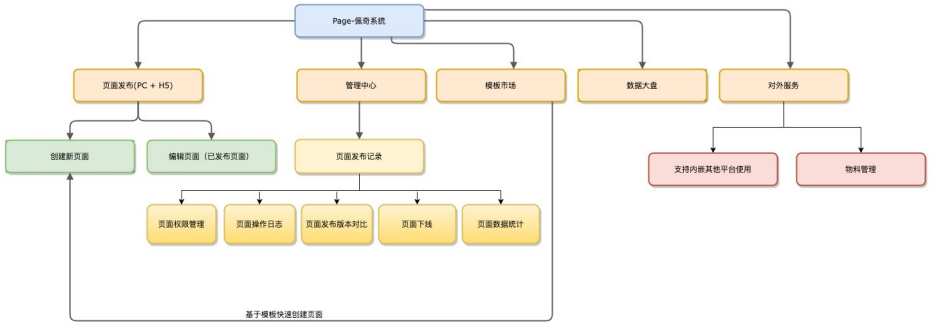

图 4　Page- 佩奇平台功能流程图

3.3 实现原理

3.3.1 基础服务

Page- 佩奇平台的基础服务有四个部分，包括物料服务、编译服务、产品赋能、扩展服务。

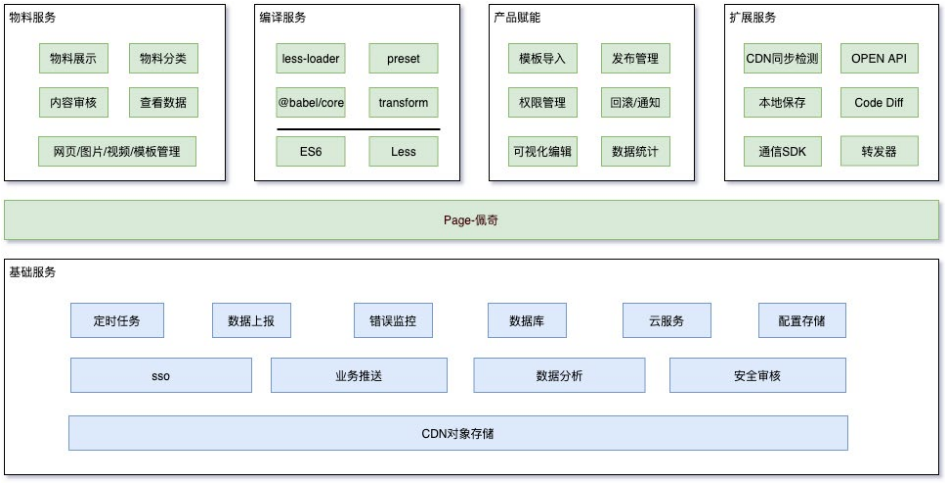

图 5　整体架构图

3.3.2 核心架构

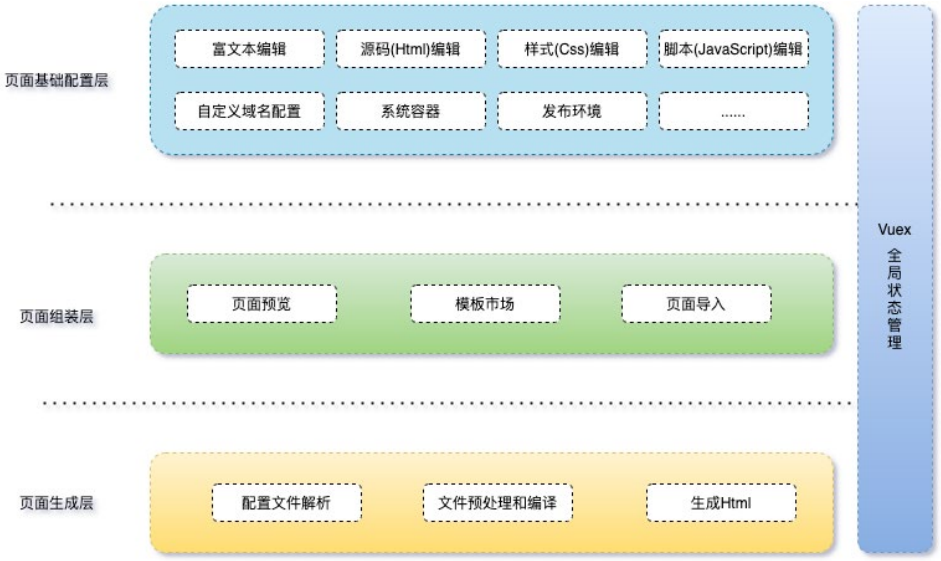

图 6　核心架构图

Page- 佩奇平台核心架构主要包含页面基础配置层、页面组装层以及页面生成层。我们通过 Vuex 全局状态对数据进行维护。

- 页面基础配置层主要提供生成页面的各种能力，包括富文本的各种操作能力、编辑源码（HTML、CSS、JavaScript）的能力、自定义域名配置、适配的容器（PC/H5）、发布环境等。
- 页面组装层则会基于基础配置层所提供的的能力，实现页面的自由编辑，承载大量的交互逻辑，用户的所有操作都在这一层进行。
  - 业务 PV 和 UV 埋点，错误统计，访问成功率上报。
  - 自动适配 PC 和移动端样式。
  - 内网页面显示外网不可访问标签。
- 页面生成层则需要根据组装后的配置进行解析和预处理、编译等操作，最终生成 HTML、CSS、JavaScript 渲染到网页当中。

3.3.3 关键流程

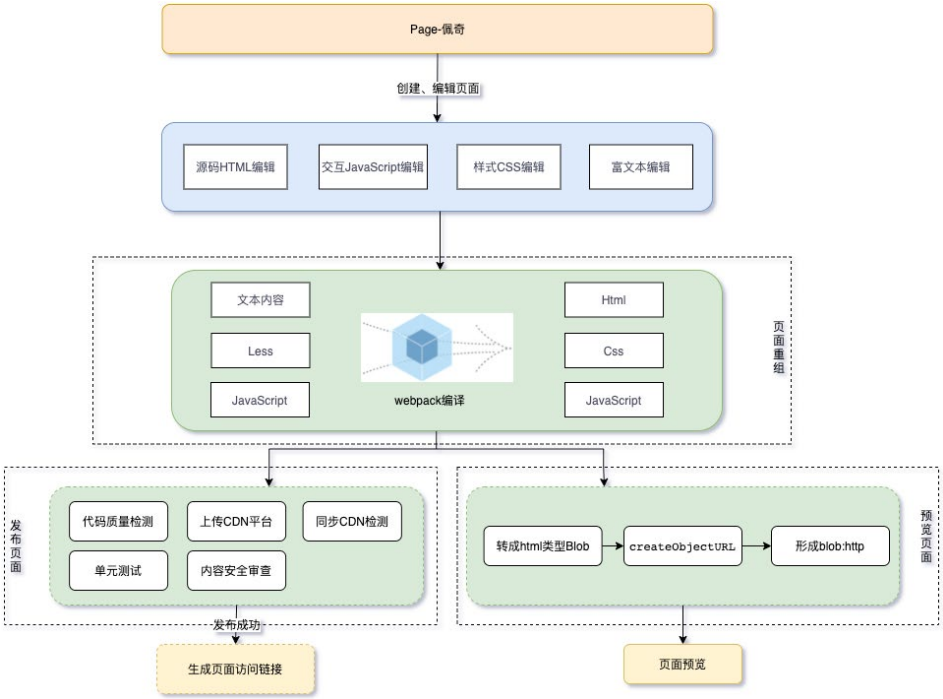

图 7　关键流程图

如上图 7 所示，平台的核心流程主要包含页面创建之后的页面预览、编译服务、生成页面。

- **页面预览**：创建、编辑之后的页面，将会根据内容进行页面重组，对样式和 JavaScript 进行预编译之后，对文本 +JavaScript+CSS 进行组装，生成 HTML 代码块，然后将代码块转换成 Blob URL，最终以 iframe 的方式预览页面。
- **编译服务**：文件树状结构和代码发送请求到后端接口，基于 Webpack 将 Less 编译成 CSS，ES 6 语法编译成 ES 5。通用物料使用 CDN 进行引入，不再进行二次编译。
- **生成页面**：当创建、编辑之后的页面进行发布时，服务端将会进行代码质量检测、内容安全审查、代码质量检测、单元测试、上传对象存储平台、同步 CDN 检测，最终生成页面链接进行访问。

3.3.4 多平台接入

Page- 佩奇平台也可以作为一个完善的富文本编辑器供业务系统使用，支持内嵌到其他系统内。作为消息发布等功能承载，减少重复的开发工作，同时我们配备完善的 SDK 供大家选择使用。通过 Page-SDK 可以直接触发 Page 平台发布、管理等操作，具体的流程如下图所示：

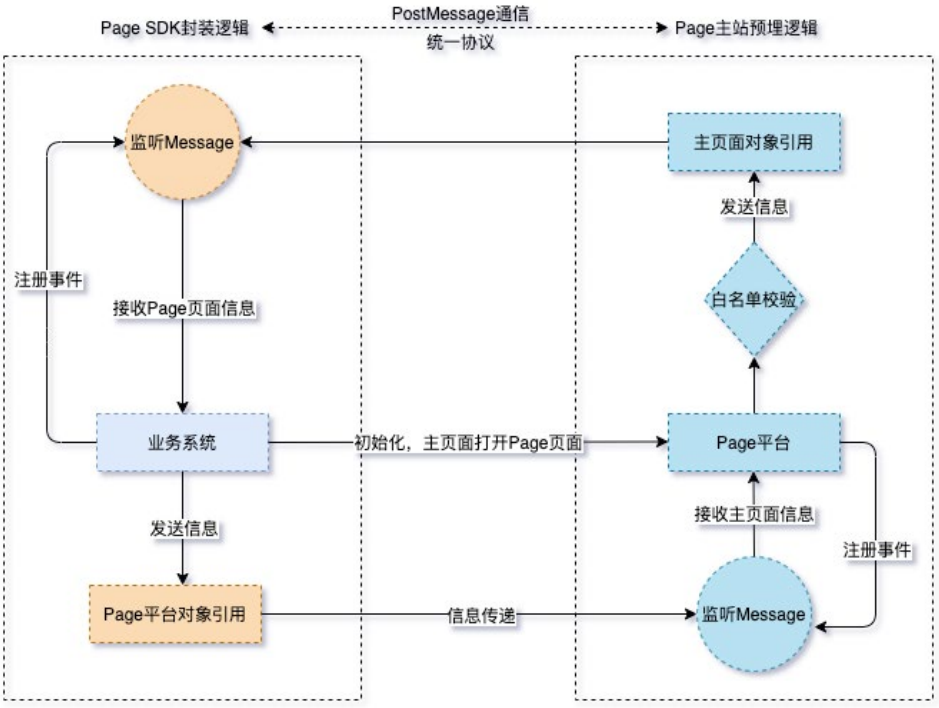

图 8　Page-SDK 流程图

3.3.5 Open API

在使用 Page- 佩奇平台的时候，美团内部一些业务方提出想要通过 Page- 佩奇平台进行页面的发布，同时想要拿到发布的内容做一些自定义的处理。于是，我们提供了 Open API 开放能力，支持以 HTTP 和 Thrift 两种方式进行调用。下面主要讲一下 Thrift API 实现的思路，首先我们先了解下 Thrift 整体流程：

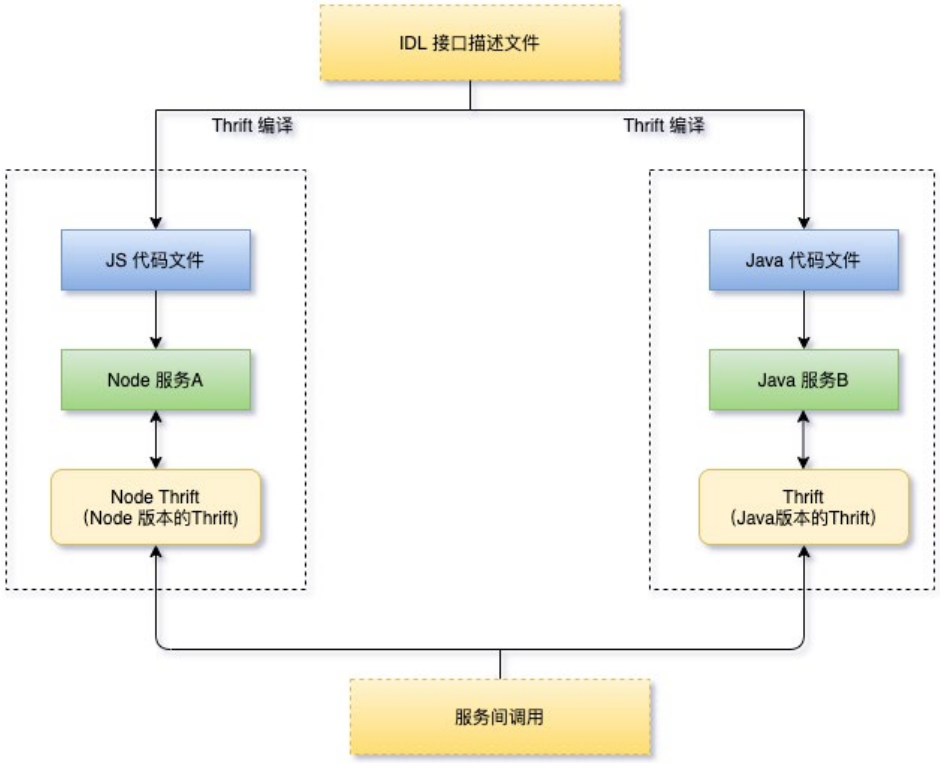

图 9　Thrift 整体流程图

Thrift 的主要使用过程如下：

- 服务端预先编写接口定义语言 IDL（Interface Definition Language）文件定义接口。
- 使用 Thrift 提供的编译器，基于 IDL 编译出服务语言对应的接口文件。
- 被调用服务完成服务注册，调用发起服务完成服务发现。
- 采用统一传输协议进行服务调用与数据传输。

下面具体讲讲，Node 语言是如何实现和其他服务语言实现调用的。由于我们的服务使用的 Node 语言，因此我们的 Node 服务就充当了服务端的角色，而其他语言（Java 等）调用就充当了客户端的角色。

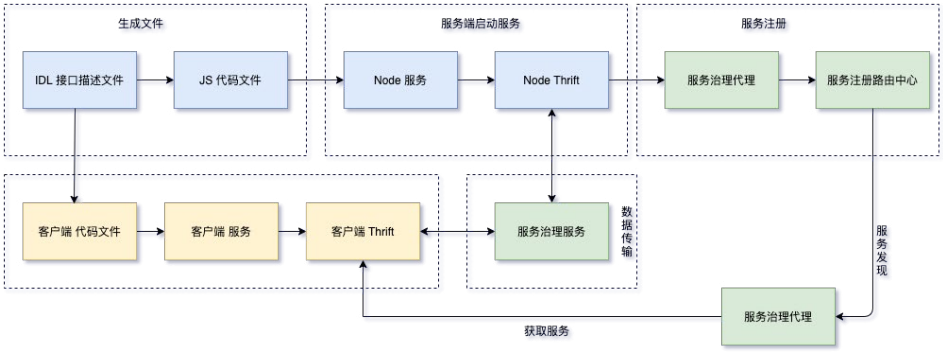

图 10　Thrift 使用详细流程图

- **生成文件**：由服务端定义 IDL 接口描述文件，然后基于 IDL 文件转换为对应语言的代码文件，由于我们用的是 Node 语言，所以转换成 JavaScript 文件。
- **服务端启动服务**：引入生成的 JavaScript 文件，解析接口、处理接口、启动并监听服务。
- **服务注册**：通过服务器内置的“服务治理代理”，将服务注册到美团内部的服务注册路由中心（也就是命名服务），让服务可被调用方发现。
- **数据传输**：被调用时，根据“服务治理服务”协议序列化和反序列化，与其他服务进行数据传输。

目前，美团内部已经有相对成熟的 NPM 包服务，已经帮我们实现了服务注册、数据传输、服务发现和获取流程。客户端如果想调用我们所提供的的 Open API 开放能力，首先申请 AppKey，然后选择使用 Thrift 方式或者 HTTP 的方式，按照所要求的参数进行请求调用即可。

3.4 方案实践

3.4.1 H5 协议

能力：富文本编辑。**描述**：提供富文本可视化编辑，产品和运营无需前端就可以发布和二次编辑页面。**场景**：文本协议，消息通知，产品 FAQ。

具体案例：

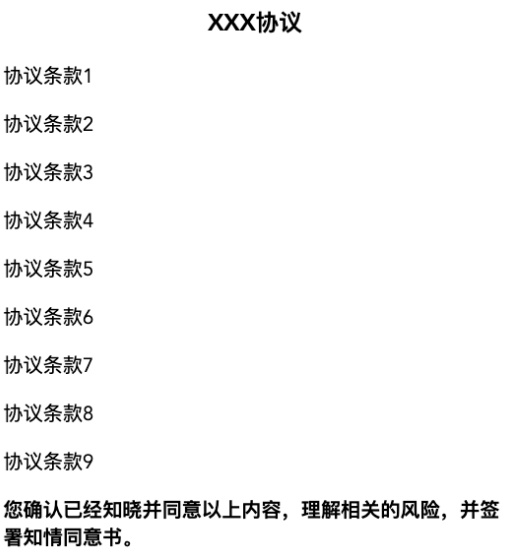

图 11　H5 静态文本协议案例

3.4.2 业务自定义渲染

能力：开放 API（Thirft + HTTP）。**描述**：提供开放 API，支持业务自定义和样式渲染到业务系统，同时解决了 iframe 体验问题。**场景**：客户端、后端、小程序的同学，可根据 API 渲染文案，实现动态化管理富文本信息。

具体案例：

小程序使用组件、Vue 使用 v-html 指令实现动态化渲染商品选择说明。

```
    {
    "code": 0,
    "data": {
      "tag": "苹果，标准",
      "title": "如何挑选苹果",
      "html": "<h1>如何挑选苹果</h1><p>以下标准可供消费者参考</
p><ul><li>酸甜</li><li>硬度</li></ul>",
      "css": "",
      "js": "",
      "file": {}
    },
    "msg": "success"
}
```

3.4.3 投放需求

能力：WebIDE 代码编辑。**描述**：开发基于 WebIDE 代码开发工作，基于渠道和环境修改下载链接，能够做到分钟级支撑。**场景**：根据产品创建静态页面进行逻辑和样式开发。

具体案例：

```
var ua = window.navigator.userAgent
var URL_MAP = {
    ios: 'https://apps.apple.com/cn/app/xxx',
    android: 'xxx.apk',
    ios_dpmerchant: 'itms-apps://itunes.apple.com/cn/app/xxx'
}

if (ua.match(/android/i)) location.href = URL_MAP.android
if (ua.match(/(ipad|iphone|ipod).*os\s([\d_]+)/i)) {
    if (/xx\/com\.xxx\.xx\.mobile/.test(ua)) {
        location.href = URL_MAP.ios_dpmerchant
    } else {
        location.href = URL_MAP.ios
    }
}
```

3.4.4 客户端通信中间页

能力：WebIDE 代码编辑 + 物料平台。**描述**：通过物料平台，引入公司客户端桥 SDK，可以快速完成客户端通信需求。方便前端调试客户端基础桥功能。**场景**：客户端跳转，通信中间页。

具体案例：

```
// 业务伪代码
XXX.ready(() => {
    XXX.sendMessage({
            sign: true,
        params: {
            id: window.URL
        }
    }, () => {
        console.error('通信成功')
    }, () => {
        console.error('通信失败')
    })
})
```

3.4.5 业务系统内嵌 Page

能力：提供胶水层 Page-SDK，连接业务系统和 Page。**描述**：业务系统与 Page-佩奇平台可进行通信，业务系统可调用 Page 发布、预览、编辑等功能，Page 可返回业务系统页面链接、内容、权限等信息。减少重复前后端工作，提升研发效率。**场景**：前端富文本信息渲染，后端富文本信息管理后台。

具体案例：

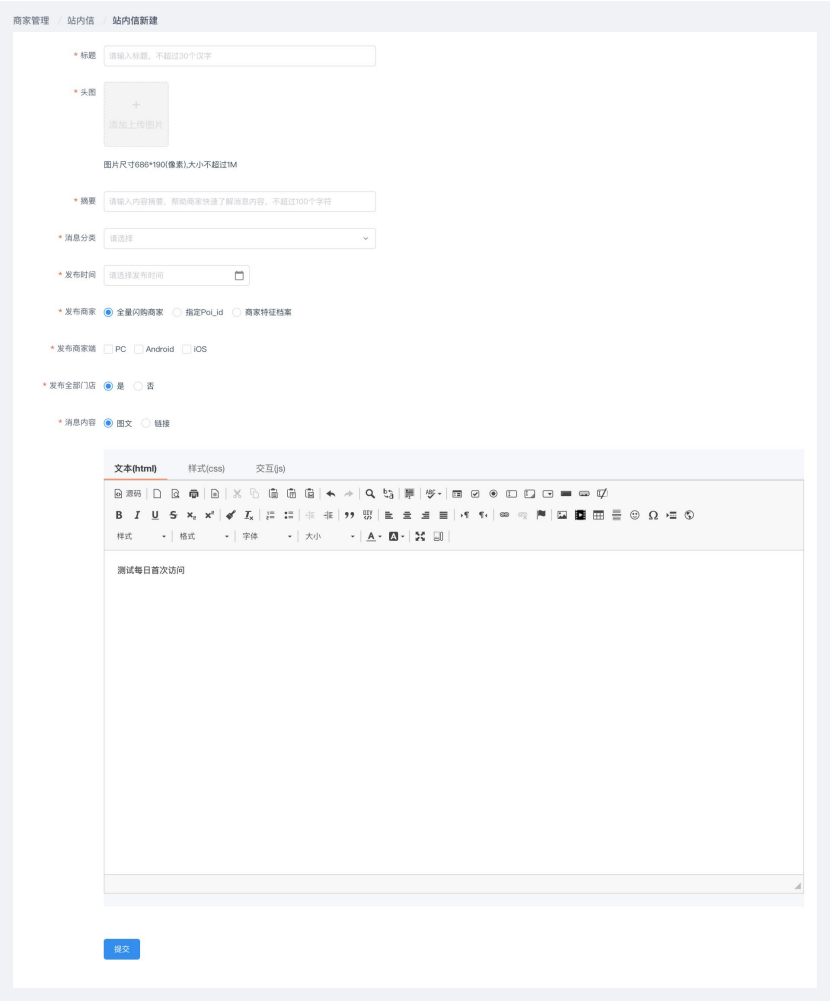

图 12　业务系统内嵌 Page 案例

3.5 业务成绩

截止目前数据统计，Page- 佩奇平台生成网页 5000 多个，编辑页面次数 16000 多次，累计页面访问 PV 超过 8260 万。现在，美团已经有十多个部门和三十多条业务线接入并使用了 Page- 佩奇平台。

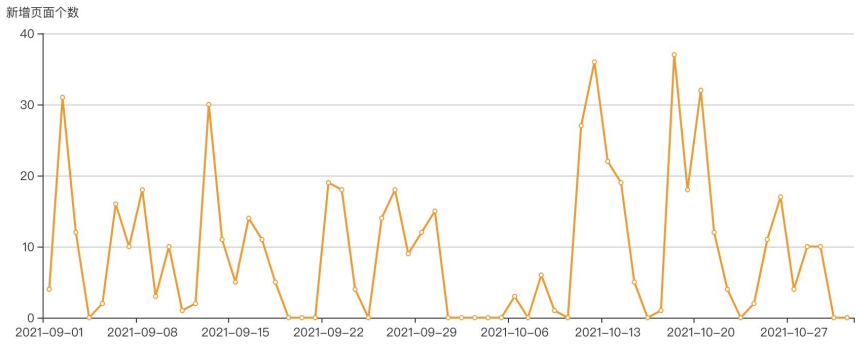

图 13　Page 平台每日生成页面统计

四、总结与展望

富文本编辑器和 WebIDE 不仅是复杂的系统，而且还是比较热门的研究方向。特别是在和美团的基建结合之后，能够解决团队内部很多效率和质量问题。这套系统还提供了语法智能提示、Diff 对比、前置检测、命令行调试等功能，不仅要关注业务发布出去页面的稳定性和质量，更要有内置的一系列研发插件，主动帮助研发提高代码质量，降低不必要的错误。

经过长期的技术和业务演进，Page- 佩奇平台已经能够有效地帮助研发人员大幅提升开发效率，具备初级的 Design To Code 能力，但是仍有许多业务场景值得去我们探索。我们也期待优秀的你参与进来，一起共同建设。

- **WebIDE 融合**：完善基础设施建设和功能需求，更好地支持 Vue、React、ES 6、TS、Less 语法，预览模式采用浏览器编译，能有效地提高预览的速度，发布使用后端编译的模式。

- **研发流程链路**：针对代码进行有效评估，包括 ESlint、代码重复率、智能提示是否可以三方库替代。出具开发代码质量、业务上线的质量报告。
- **综合研发平台**：减少团队同学了解整体基建的时间成本，内置了监控、性能、任务管理等功能，提升业务开发效率。建设自动化日报、周报系统，降低非开发工作量占比。
- **物料开放能力**：接入公共组件平台，沉淀更多的物料，快速满足产品更多样化的需求。

五、作者简介

高瞻、宇立、肖莹、浩畅，来自美团医药终端团队。王咏、陈文，来自美团闪购终端团队。

六、招聘信息

美团医药长期招聘 Android、iOS、FE 前端工程师，坐标在北京和成都。感兴趣的同学可将简历发送至：sunyuli@meituan.com（邮件主题请注明：美团医药终端）。

后端

如何优雅地记录操作日志?

作者：站通

操作日志几乎存在于每个系统中，而这些系统都有记录操作日志的一套 API。操作日志和系统日志不一样，操作日志必须要做到简单易懂。所以如何让操作日志不和业务逻辑耦合，如何让操作日志的内容易于理解，让操作日志的接入更加简单？上面这些都是本文要回答的问题，主要围绕着如何“优雅”地记录操作日志展开描述。

1. 操作日志的使用场景

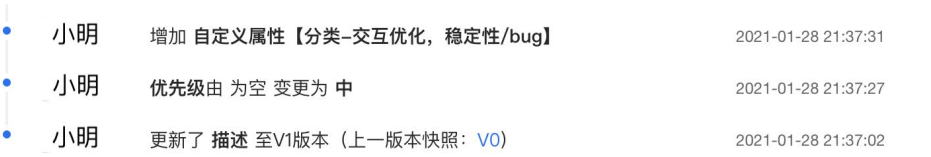

例子

系统日志和操作日志的区别

系统日志：系统日志主要是为开发排查问题提供依据，一般打印在日志文件中；系统日志的可读性要求没那么高，日志中会包含代码的信息，比如在某个类的某一行打印了一个日志。

操作日志：主要是对某个对象进行新增操作或者修改操作后记录下这个新增或者修改，操作日志要求可读性比较强，因为它主要是给用户看的，比如订单的物流信息，用户需要知道在什么时间发生了什么事情。再比如，客服对工单的处理记录信息。

操作日志的记录格式大概分为下面几种：* 单纯的文字记录，比如：2021-09-16 10:00 订单创建。 * 简单的动态的文本记录，比如：2021-09-16 10:00 订单创建，订单号：NO.11089999，其中涉及变量订单号“NO.11089999”。 * 修改类型的文本，包含修改前和修改后的值，比如：2021-09-16 10:00 用户小明修改了订单的配送地址：从“金灿灿小区”修改到“银盏盏小区”，其中涉及变量配送的原地址“金灿灿小区”和新地址“银盏盏小区”。 * 修改表单，一次会修改多个字段。

2. 实现方式

2.1 使用 Canal 监听数据库记录操作日志

Canal 是一款基于 MySQL 数据库增量日志解析，提供增量数据订阅和消费的开源组件，通过采用监听数据库 Binlog 的方式，这样可以从底层知道是哪些数据做了修改，然后根据更改的数据记录操作日志。

这种方式的优点是和业务逻辑完全分离。缺点也很明显，局限性太高，只能针对数据库的更改做操作日志记录，如果修改涉及到其他团队的 RPC 的调用，就没办法监听数据库了，举个例子：给用户发送通知，通知服务一般都是公司内部的公共组件，这时候只能在调用 RPC 的时候手工记录发送通知的操作日志了。

2.2 通过日志文件的方式记录

```
log.info("订单创建")
log.info("订单已经创建，订单编号：{}", orderNo)
log.info("修改了订单的配送地址：从"{}"修改到"{}"，"金灿灿小区"，"银盏盏小区")
```

这种方式的操作记录需要解决三个问题。

问题一：操作人如何记录

借助 SLF4J 中的 MDC 工具类，把操作人放在日志中，然后在日志中统一打印出来。首先在用户的拦截器中把用户的标识 Put 到 MDC 中。

```
@Component
public class UserInterceptor extends HandlerInterceptorAdapter {
  @Override
  public boolean preHandle(HttpServletRequest request,
HttpServletResponse response, Object handler) throws Exception {
    // 获取到用户标识
    String userNo = getUserNo(request);
    // 把用户 ID 放到 MDC 上下文中
    MDC.put("userId", userNo);
    return super.preHandle(request, response, handler);
  }

  private String getUserNo(HttpServletRequest request) {
    // 通过 SSO 或者 Cookie 或者 Auth 信息获取到 当前登陆的用户信息
    return null;
  }
}
```

其次，把 userId 格式化到日志中，使用 %X{userId} 可以取到 MDC 中用户标识。

```
<pattern>"%d{yyyy-MM-dd HH:mm:ss.SSS} %t %-5level %X{userId}
%logger{30}.%method:%L - %msg%n"</pattern>
```

问题二：操作日志如何和系统日志区分开

通过配置 Log 的配置文件，把有关操作日志的 Log 单独放到一日志文件中。

```
// 不同业务日志记录到不同的文件
<appender name="businessLogAppender" class="ch.qos.logback.core.
rolling.RollingFileAppender">
    <File>logs/business.log</File>
    <append>true</append>
    <filter class="ch.qos.logback.classic.filter.LevelFilter">
        <level>INFO</level>
        <onMatch>ACCEPT</onMatch>
        <onMismatch>DENY</onMismatch>
    </filter>
    <rollingPolicy class="ch.qos.logback.core.rolling.
TimeBasedRollingPolicy">
        <fileNamePattern>logs/ 业务 A.%d.%i.log</fileNamePattern>
        <maxHistory>90</maxHistory>
        <timeBasedFileNamingAndTriggeringPolicy class="ch.qos.
logback.core.rolling.SizeAndTimeBasedFNATP">
            <maxFileSize>10MB</maxFileSize>
        </timeBasedFileNamingAndTriggeringPolicy>
    </rollingPolicy>
```

```
    <encoder>
        <pattern>"%d{yyyy-MM-dd HH:mm:ss.SSS} %t %-5level %X{userId}
%logger{30}.%method:%L - %msg%n"</pattern>
        <charset>UTF-8</charset>
    </encoder>
</appender>

<logger name="businessLog" additivity="false" level="INFO">
    <appender-ref ref="businessLogAppender"/>
</logger>
```

然后在 Java 代码中单独的记录业务日志。

```
// 记录特定日志的声明
private final Logger businessLog = LoggerFactory.
getLogger("businessLog");

// 日志存储
businessLog.info(" 修改了配送地址 ");
```

问题三：如何生成可读懂的日志文案

可以采用 LogUtil 的方式，也可以采用切面的方式生成日志模板，后续内容将会进行介绍。这样就可以把日志单独保存在一个文件中，然后通过日志收集可以把日志保存在 Elasticsearch 或者数据库中，接下来看下如何生成可读的操作日志。

2.3 通过 LogUtil 的方式记录日志

```
  LogUtil.log(orderNo, " 订单创建 ", " 小明 ") 模板
  LogUtil.log(orderNo, " 订单创建，订单号 "+"NO.11089999",  " 小明 ")
  String template = " 用户 %s 修改了订单的配送地址：从 "%s" 修改到 "%s""
  LogUtil.log(orderNo, String.format(tempalte, " 小明 ", " 金灿灿小区 ", " 银
盏盏小区 "),  " 小明 ")
```

> 这里解释下为什么记录操作日志的时候都绑定了一个 OrderNo，因为操作日志记录的是：某一个“时间”“谁”对“什么”做了什么“事情”。当查询业务的操作日志的时候，会查询针对这个订单的的所有操作，所以代码中加上了 OrderNo，记录操作日志的时候需要记录下操作人，所以传了操作人“小明”进来。

上面看起来问题并不大，在修改地址的业务逻辑方法中使用一行代码记录了操作日志，接下来再看一个更复杂的例子：

```
private OnesIssueDO updateAddress(updateDeliveryRequest request) {
    DeliveryOrder deliveryOrder = deliveryQueryService.
queryOldAddress(request.getDeliveryOrderNo());
    // 更新派送信息，电话，收件人，地址
    doUpdate(request);
    String logContent = getLogContent(request, deliveryOrder);
    LogUtils.logRecord(request.getOrderNo(), logContent, request.
getOperator);
    return onesIssueDO;
}

private String getLogContent(updateDeliveryRequest request,
DeliveryOrder deliveryOrder) {
    String template = "用户%s修改了订单的配送地址：从"%s"修改到"%s"";
    return String.format(tempalte, request.getUserName(), deliveryOrder.
getAddress(), request.getAddress);
}
```

可以看到上面的例子使用了两个方法代码，外加一个 getLogContent 的函数实现了操作日志的记录。当业务变得复杂后，记录操作日志放在业务代码中会导致业务的逻辑比较繁杂，最后导致 LogUtils.logRecord() 方法的调用存在于很多业务的代码中，而且类似 getLogContent() 这样的方法也散落在各个业务类中，对于代码的可读性和可维护性来说是一个灾难。下面介绍下如何避免这个灾难。

2.4 方法注解实现操作日志

为了解决上面问题，一般采用 AOP 的方式记录日志，让操作日志和业务逻辑解耦，接下来看一个简单的 AOP 日志的例子。

```
@LogRecord(content="修改了配送地址")
public void modifyAddress(updateDeliveryRequest request){
    // 更新派送信息 电话，收件人、地址
    doUpdate(request);
}
```

我们可以在注解的操作日志上记录固定文案，这样业务逻辑和业务代码可以做到解耦，让我们的业务代码变得纯净起来。可能有同学注意到，上面的方式虽然解耦了操

作日志的代码，但是记录的文案并不符合我们的预期，文案是静态的，没有包含动态的文案，因为我们需要记录的操作日志是：用户 %s 修改了订单的配送地址，从“%s”修改到“%s”。接下来，我们介绍一下如何优雅地使用 AOP 生成动态的操作日志。

3. 优雅地支持 AOP 生成动态的操作日志

3.1 动态模板

一提到动态模板，就会涉及到让变量通过占位符的方式解析模板，从而达到通过注解记录操作日志的目的。模板解析的方式有很多种，这里使用了 SpEL（Spring Expression Language，Spring 表达式语言）来实现。我们可以先写下期望的记录日志的方式，然后再看下能否实现这样的功能。

```
@LogRecord(content = "修改了订单的配送地址：从"#oldAddress", 修改到
"#request.address"")
public void modifyAddress(updateDeliveryRequest request, String oldAddress){
    // 更新派送信息 电话，收件人、地址
    doUpdate(request);
}
```

通过 SpEL 表达式引用方法上的参数，可以让变量填充到模板中达到动态的操作日志文本内容。 但是现在还有几个问题需要解决：* 操作日志需要知道是哪个操作人修改的订单配送地址。 * 修改订单配送地址的操作日志需要绑定在配送的订单上，从而可以根据配送订单号查询出对这个配送订单的所有操作。 * 为了在注解上记录之前的配送地址是什么，在方法签名上添加了一个和业务无关的 oldAddress 的变量，这样就不优雅了。

为了解决前两个问题，我们需要把期望的操作日志使用形式改成下面的方式：

```
@LogRecord(
     content = "修改了订单的配送地址：从"#oldAddress", 修改到“#request.address"",
     operator = "#request.userName", bizNo="#request.deliveryOrderNo")
public void modifyAddress(updateDeliveryRequest request, String oldAddress){
    // 更新派送信息 电话，收件人、地址
    doUpdate(request);
}
```

修改后的代码在注解上添加两个参数，一个是操作人，一个是操作日志需要绑定的对象。但是，在普通的 Web 应用中用户信息都是保存在一个线程上下文的静态方法中，所以 operator 一般是这样的写法（假定获取当前登陆用户的方式是 UserContext.getCurrentUser()）。

```
operator = "#{T(com.meituan.user.UserContext).getCurrentUser()}"
```

这样的话，每个 @LogRecord 的注解上的操作人都是这么长一串。为了避免过多的重复代码，我们可以把注解上的 operator 参数设置为非必填，这样用户可以填写操作人。但是，如果用户不填写我们就取 UserContext 的 user（下文会介绍如何取 user ）。最后，最简单的日志变成了下面的形式：

```
@LogRecord(content = "修改了订单的配送地址：从"#oldAddress", 修改到"#request.address"",
           bizNo="#request.deliveryOrderNo")
public void modifyAddress(updateDeliveryRequest request, String oldAddress){
    // 更新派送信息 电话，收件人、地址
    doUpdate(request);
}
```

接下来，我们需要解决第三个问题：为了记录业务操作记录添加了一个 oldAddress 变量，不管怎么样这都不是一个好的实现方式，所以接下来，我们需要把 oldAddress 变量从修改地址的方法签名上去掉。但是操作日志确实需要 oldAddress 变量，怎么办呢?

要么和产品经理 PK 一下，让产品经理把文案从“修改了订单的配送地址：从 xx 修改到 yy”改为“修改了订单的配送地址为：yy”。但是从用户体验上来看，第一种文案更人性化一些，显然我们不会 PK 成功的。那么我们就必须要把这个 oldAddress 查询出来然后供操作日志使用了。还有一种解决办法是：把这个参数放到操作日志的线程上下文中，供注解上的模板使用。我们按照这个思路再改下操作日志的实现代码。

```
@LogRecord(content = "修改了订单的配送地址：从"#oldAddress", 修改到"#request.address"",
        bizNo="#request.deliveryOrderNo")
```

```
public void modifyAddress(updateDeliveryRequest request){
    // 查询出原来的地址是什么
    LogRecordContext.putVariable("oldAddress", DeliveryService.
queryOldAddress(request.getDeliveryOrderNo()));
    // 更新派送信息 电话，收件人、地址
    doUpdate(request);
}
```

这时候可以看到，LogRecordContext 解决了操作日志模板上使用方法参数以外变量的问题，同时避免了为了记录操作日志修改方法签名的设计。虽然已经比之前的代码好了些，但是依然需要在业务代码里面加了一行业务逻辑无关的代码，如果有“强迫症”的同学还可以继续往下看，接下来我们会讲解自定义函数的解决方案。下面再看另一个例子：

```
@LogRecord(content = "修改了订单的配送员：从"#oldDeliveryUserId", 修改到
"#request.userId"",
        bizNo="#request.deliveryOrderNo")
public void modifyAddress(updateDeliveryRequest request){
    // 查询出原来的地址是什么
    LogRecordContext.putVariable("oldDeliveryUserId", DeliveryService.
queryOldDeliveryUserId(request.getDeliveryOrderNo()));
    // 更新派送信息 电话，收件人、地址
    doUpdate(request);
}
```

这个操作日志的模板最后记录的内容是这样的格式：修改了订单的配送员：从“10090”，修改到“10099”，显然用户看到这样的操作日志是不明白的。用户对于用户 ID 是 10090 还是 10099 并不了解，用户期望看到的是：修改了订单的配送员：从“张三（18910008888）”，修改到“小明（13910006666）”。用户关心的是配送员的姓名和电话。但是我们方法中传递的参数只有配送员的 ID，没有配送员的姓名可电话。我们可以通过上面的方法，把用户的姓名和电话查询出来，然后通过 LogRecordContext 实现。

但是，“强迫症”是不期望操作日志的代码嵌入在业务逻辑中的。接下来，我们考虑另一种实现方式：自定义函数。如果我们可以通过自定义函数把用户 ID 转换为用户姓名和电话，那么就能解决这一问题，按照这个思路，我们把模板修改为下面的形式：

```
@LogRecord(content = "修改了订单的配送员：从{deliveryUser{#oldDeliveryUserId}}",
修改到"{deveryUser{#request.userId}}"",
        bizNo="#request.deliveryOrderNo")
public void modifyAddress(updateDeliveryRequest request){
    // 查询出原来的地址是什么
    LogRecordContext.putVariable("oldDeliveryUserId", DeliveryService.
queryOldDeliveryUserId(request.getDeliveryOrderNo()));
    // 更新派送信息 电话，收件人、地址
    doUpdate(request);
}
```

其中 deliveryUser 是自定义函数，使用大括号把 Spring 的 SpEL 表达式包裹起来，这样做的好处：一是把 SpEL（Spring Expression Language，Spring 表达式语言）和自定义函数区分开便于解析；二是如果模板中不需要 SpEL 表达式解析可以容易的识别出来，减少 SpEL 的解析提高性能。这时候我们发现上面代码还可以优化成下面的形式：

```
@LogRecord(content = "修改了订单的配送员：从"{queryOldUser{#request.
deliveryOrderNo()}}", 修改到"{deveryUser{#request.userId}}"",
        bizNo="#request.deliveryOrderNo")
public void modifyAddress(updateDeliveryRequest request){
    // 更新派送信息 电话，收件人、地址
    doUpdate(request);
}
```

这样就不需要在 modifyAddress 方法中通过 LogRecordContext.putVariable() 设置老的快递员了，通过直接新加一个自定义函数 queryOldUser() 参数把派送订单传递进去，就能查到之前的配送人了，只需要让方法的解析在 modifyAddress() 方法执行之前运行。这样的话，我们让业务代码又变得纯净了起来，同时也让“强迫症”不再感到难受了。

4. 代码实现解析

4.1 代码结构

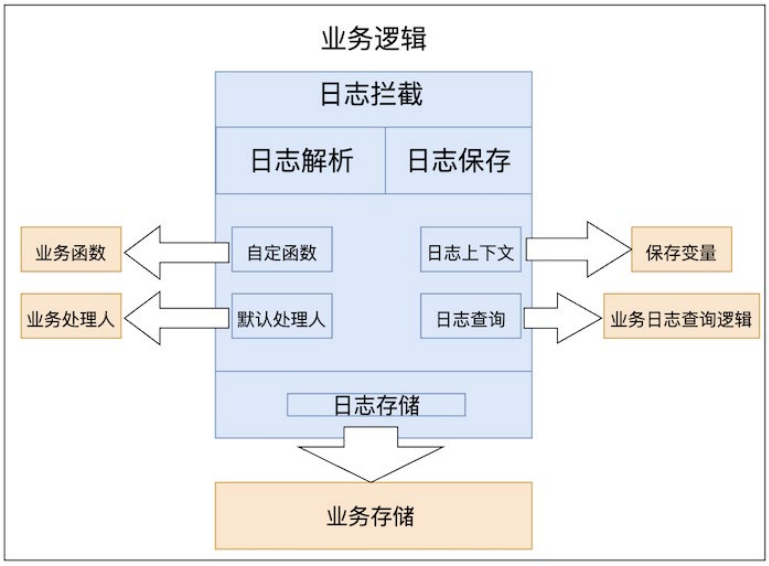

上面的操作日志主要是通过一个 AOP 拦截器实现的，整体主要分为 AOP 模块、日志解析模块、日志保存模块、Starter 模块；组件提供了 4 个扩展点，分别是：自定义函数、默认处理人、业务保存和查询；业务可以根据自己的业务特性定制符合自己业务的逻辑。

4.2 模块介绍

有了上面的分析，已经得出一种我们期望的操作日志记录的方式，那么接下来看看如何实现上面的逻辑。实现主要分为下面几个步骤：* AOP 拦截逻辑 * 解析逻辑 * 模板解析 * LogContext 逻辑 * 默认的 operator 逻辑 * 自定义函数逻辑 * 默认的日志持久化逻辑 * Starter 封装逻辑

4.2.1 AOP 拦截逻辑

这块逻辑主要是一个拦截器，针对 @LogRecord 注解分析出需要记录的操作日志，然后把操作日志持久化，这里把注解命名为 @LogRecordAnnotation。接下来，我

们看下注解的定义：

```
@Target({ElementType.METHOD})
@Retention(RetentionPolicy.RUNTIME)
@Inherited
@Documented
public @interface LogRecordAnnotation {
    String success();

    String fail() default "";

    String operator() default "";

    String bizNo();

    String category() default "";

    String detail() default "";

    String condition() default "";
}
```

注解中除了上面提到参数外，还增加了 fail、category、detail、condition 等参数，这几个参数是为了满足特定的场景，后面还会给出具体的例子。

参数名	描述	是否必填
success	操作日志的文本模板	是
fail	操作日志失败的文本版本	否
operator	操作日志的执行人	否
bizNo	操作日志绑定的业务对象标识	是
category	操作日志的种类	否
detail	扩展参数，记录操作日志的修改详情	否
condition	记录日志的条件	否

为了保持简单，组件的必填参数就两个。业务中的 AOP 逻辑大部分是使用 @Aspect 注解实现的，但是基于注解的 AOP 在 Spring boot 1.5 中兼容性是有问题的，组件为了兼容 Spring boot1.5 的版本我们手工实现 Spring 的 AOP 逻辑。

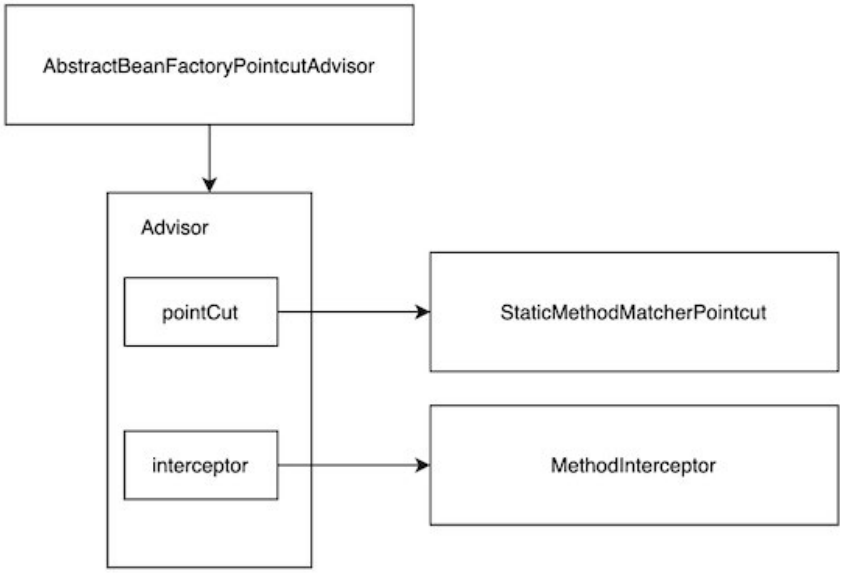

切面选择 `AbstractBeanFactoryPointcutAdvisor` 实现，切点是通过 `StaticMethodMatcherPointcut` 匹配包含 `LogRecordAnnotation` 注解的方法。通过实现 `MethodInterceptor` 接口实现操作日志的增强逻辑。

下面是拦截器的切点逻辑：

```
public class LogRecordPointcut extends StaticMethodMatcherPointcut
implements Serializable {
    // LogRecord 的解析类
    private LogRecordOperationSource logRecordOperationSource;

    @Override
    public boolean matches(@NonNull Method method, @NonNull Class<?>
targetClass) {
        // 解析 这个 method 上有没有 @LogRecordAnnotation 注解，有的话会
解析出来注解上的各个参数
        return !CollectionUtils.isEmpty(logRecordOperationSource.
computeLogRecordOperations(method, targetClass));
    }

    void setLogRecordOperationSource(LogRecordOperationSource
logRecordOperationSource) {
        this.logRecordOperationSource = logRecordOperationSource;
    }
}
```

切面的增强逻辑主要代码如下：

```
@Override
public Object invoke(MethodInvocation invocation) throws Throwable {
    Method method = invocation.getMethod();
    // 记录日志
    return execute(invocation, invocation.getThis(), method, invocation.
getArguments());
}

private Object execute(MethodInvocation invoker, Object target, Method
method, Object[] args) throws Throwable {
    Class<?> targetClass = getTargetClass(target);
    Object ret = null;
    MethodExecuteResult methodExecuteResult = new MethodExecuteResult(true,
null, "");
    LogRecordContext.putEmptySpan();
    Collection<LogRecordOps> operations = new ArrayList<>();
    Map<String, String> functionNameAndReturnMap = new HashMap<>();
    try {
        operations = logRecordOperationSource.
computeLogRecordOperations(method, targetClass);
        List<String> spElTemplates =
getBeforeExecuteFunctionTemplate(operations);
        // 业务逻辑执行前的自定义函数解析
        functionNameAndReturnMap =
processBeforeExecuteFunctionTemplate(spElTemplates, targetClass, method,
args);
    } catch (Exception e) {
        log.error("log record parse before function exception", e);
    }
    try {
        ret = invoker.proceed();
    } catch (Exception e) {
        methodExecuteResult = new MethodExecuteResult(false, e,
e.getMessage());
    }
    try {
        if (!CollectionUtils.isEmpty(operations)) {
            recordExecute(ret, method, args, operations, targetClass,
                    methodExecuteResult.isSuccess(), methodExecuteResult.
getErrorMsg(), functionNameAndReturnMap);
        }
    } catch (Exception t) {
        // 记录日志错误不要影响业务
        log.error("log record parse exception", t);
    } finally {
        LogRecordContext.clear();
    }
```

```
    if (methodExecuteResult.throwable != null) {
        throw methodExecuteResult.throwable;
    }
    return ret;
}
```

拦截逻辑的流程：

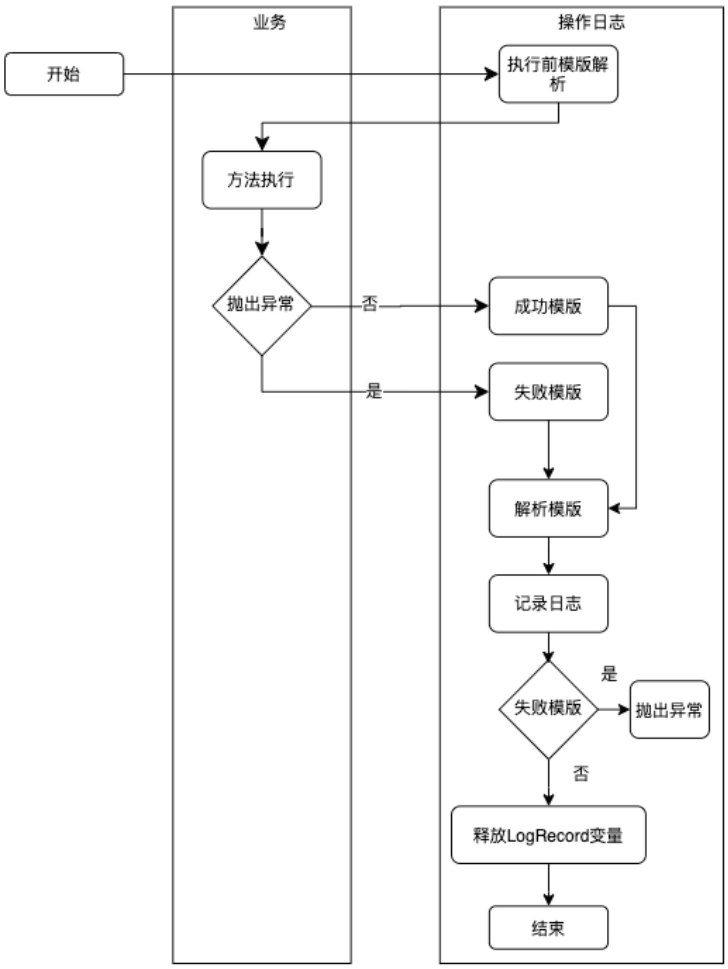

可以看到，操作日志的记录持久化是在方法执行完之后执行的，当方法抛出异常之后会先捕获异常，等操作日志持久化完成后再抛出异常。在业务的方法执行之前，会对提前解析的自定义函数求值，解决了前面提到的需要查询修改之前的内容。

4.2.2 解析逻辑

模板解析

Spring 3 提供了一个非常强大的功能：Spring EL，SpEL 在 Spring 产品中是作为表达式求值的核心基础模块，它本身是可以脱离 Spring 独立使用的。举个例子：

```
public static void main(String[] args) {
        SpelExpressionParser parser = new SpelExpressionParser();
        Expression expression = parser.parseExpression("#root.
purchaseName");
        Order order = new Order();
        order.setPurchaseName("张三");
        System.out.println(expression.getValue(order));
}
```

这个方法将打印“张三”。LogRecord 解析的类图如下：

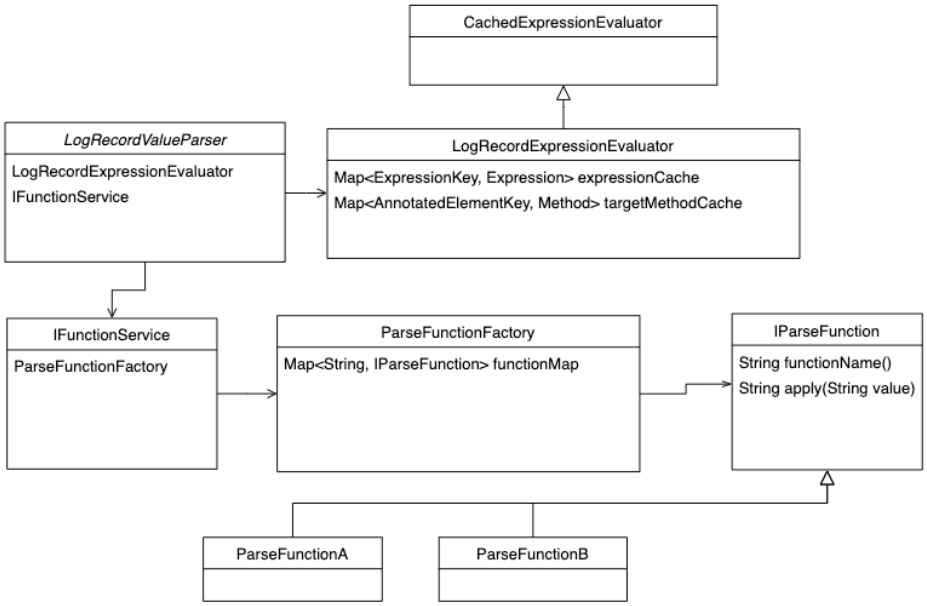

解析核心类：`LogRecordValueParser` 里面封装了自定义函数和 SpEL 解析类 `LogRecordExpressionEvaluator`。

```
public class LogRecordExpressionEvaluator extends
CachedExpressionEvaluator {

    private Map<ExpressionKey, Expression> expressionCache = new
ConcurrentHashMap<>(64);

    private final Map<AnnotatedElementKey, Method> targetMethodCache =
new ConcurrentHashMap<>(64);

    public String parseExpression(String conditionExpression,
AnnotatedElementKey methodKey, EvaluationContext evalContext) {
        return getExpression(this.expressionCache, methodKey,
conditionExpression).getValue(evalContext, String.class);
    }
}
```

`LogRecordExpressionEvaluator` 继承自 `CachedExpressionEvaluator` 类，这个类里面有两个 Map，一个是 expressionCache 一个是 targetMethodCache。在上面的例子中可以看到，SpEL 会解析成一个 Expression 表达式，然后根据传入的 Object 获取到对应的值，所以 expressionCache 是为了缓存方法、表达式和 SpEL 的 Expression 的对应关系，让方法注解上添加的 SpEL 表达式只解析一次。下面的 targetMethodCache 是为了缓存传入到 Expression 表达式的 Object。核心的解析逻辑是上面最后一行代码。

```
getExpression(this.expressionCache, methodKey, conditionExpression).
getValue(evalContext, String.class);
```

`getExpression` 方法会从 expressionCache 中获取到 @LogRecordAnnotation 注解上的表达式的解析 Expression 的实例，然后调用 `getValue` 方法，`getValue` 传入一个 evalContext 就是类似上面例子中的 order 对象。其中 Context 的实现将会在下文介绍。

日志上下文实现

下面的例子把变量放到了 LogRecordContext 中，然后 SpEL 表达式就可以顺利的解析方法上不存在的参数了，通过上面的 SpEL 的例子可以看出，要把方法的参数和 LogRecordContext 中的变量都放到 SpEL 的 `getValue` 方法的 Object 中才可以

顺利的解析表达式的值。下面看下如何实现：

```
@LogRecord(content = "修改了订单的配送员：从"{deveryUser{#oldDeliveryUserId}}",
修改到"{deveryUser{#request.getUserId()}}"",
            bizNo="#request.getDeliveryOrderNo()")
public void modifyAddress(updateDeliveryRequest request){
    // 查询出原来的地址是什么
    LogRecordContext.putVariable("oldDeliveryUserId", DeliveryService.
queryOldDeliveryUserId(request.getDeliveryOrderNo()));
    // 更新派送信息 电话，收件人、地址
    doUpdate(request);
}
```

在 LogRecordValueParser 中创建了一个 EvaluationContext，用来给 SpEL 解析方法参数和 Context 中的变量。相关代码如下：

```
EvaluationContext evaluationContext = expressionEvaluator.
createEvaluationContext(method, args, targetClass, ret, errorMsg,
beanFactory);
```

在解析的时候调用 `getValue` 方法传入的参数 evalContext，就是上面这个 EvaluationContext 对象。下面是 LogRecordEvaluationContext 对象的继承体系：

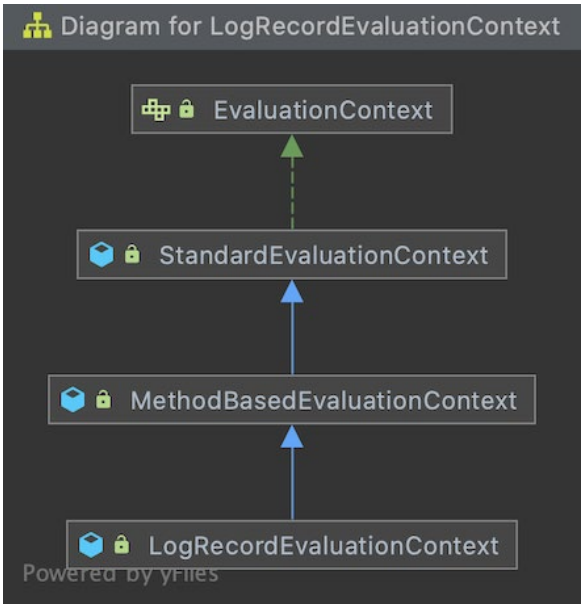

LogRecordEvaluationContext 做了三个事情：* 把方法的参数都放到 SpEL 解析的 RootObject 中。 * 把 LogRecordContext 中的变量都放到 RootObject 中。 * 把方法的返回值和 ErrorMsg 都放到 RootObject 中。

LogRecordEvaluationContext 的代码如下：

```
public class LogRecordEvaluationContext extends
MethodBasedEvaluationContext {

    public LogRecordEvaluationContext(Object rootObject, Method
method, Object[] arguments,
                                      ParameterNameDiscoverer
parameterNameDiscoverer, Object ret, String errorMsg) {
        // 把方法的参数都放到 SpEL 解析的 RootObject 中
        super(rootObject, method, arguments, parameterNameDiscoverer);
        // 把 LogRecordContext 中的变量都放到 RootObject 中
         Map<String, Object> variables = LogRecordContext.getVariables();
         if (variables != null && variables.size() > 0) {
             for (Map.Entry<String, Object> entry : variables.entrySet())
{
                 setVariable(entry.getKey(), entry.getValue());
             }
         }
         // 把方法的返回值和 ErrorMsg 都放到 RootObject 中
         setVariable("_ret", ret);
         setVariable("_errorMsg", errorMsg);
    }
}
```

下面是 LogRecordContext 的实现，这个类里面通过一个 ThreadLocal 变量保持了一个栈，栈里面是个 Map，Map 对应了变量的名称和变量的值。

```
public class LogRecordContext {

    private static final InheritableThreadLocal<Stack<Map<String,
Object>>> variableMapStack = new InheritableThreadLocal<>();
   // 其他省略 ....
}
```

上面使用了 InheritableThreadLocal，所以在线程池的场景下使用 LogRecord-Context 会出现问题，如果支持线程池可以使用阿里巴巴开源的 TTL 框架。那这里为什么不直接设置一个 ThreadLocal<map> 对象，而是要设置一个 Stack 结构呢?

我们看一下这么做的原因是什么。</map

```
@LogRecord(content = "修改了订单的配送员:从"{deveryUser{#oldDeliveryUserId}}",
修改到"{deveryUser{#request.getUserId()}}"",
        bizNo="#request.getDeliveryOrderNo()")
public void modifyAddress(updateDeliveryRequest request){
    // 查询出原来的地址是什么
    LogRecordContext.putVariable("oldDeliveryUserId", DeliveryService.
queryOldDeliveryUserId(request.getDeliveryOrderNo()));
    // 更新派送信息 电话，收件人、地址
    doUpdate(request);
}
```

上面代码的执行流程如下：

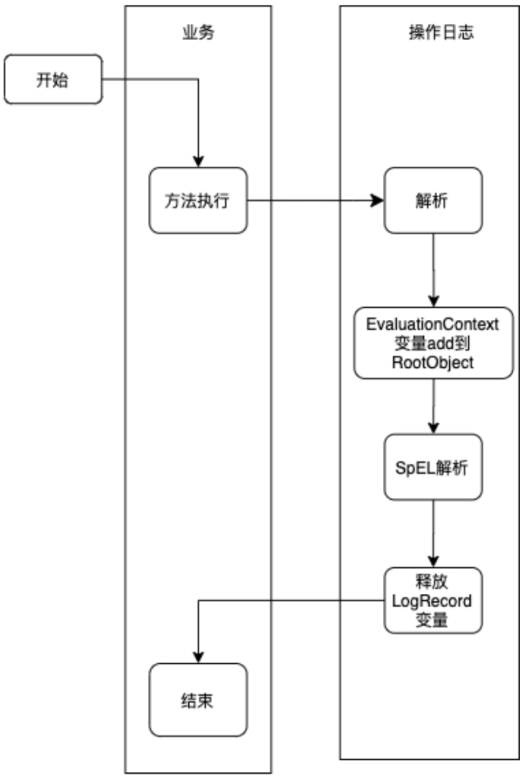

看起来没有什么问题，但是使用 LogRecordAnnotation 的方法里面嵌套了另一个使用 LogRecordAnnotation 方法的时候，流程就变成下面的形式：

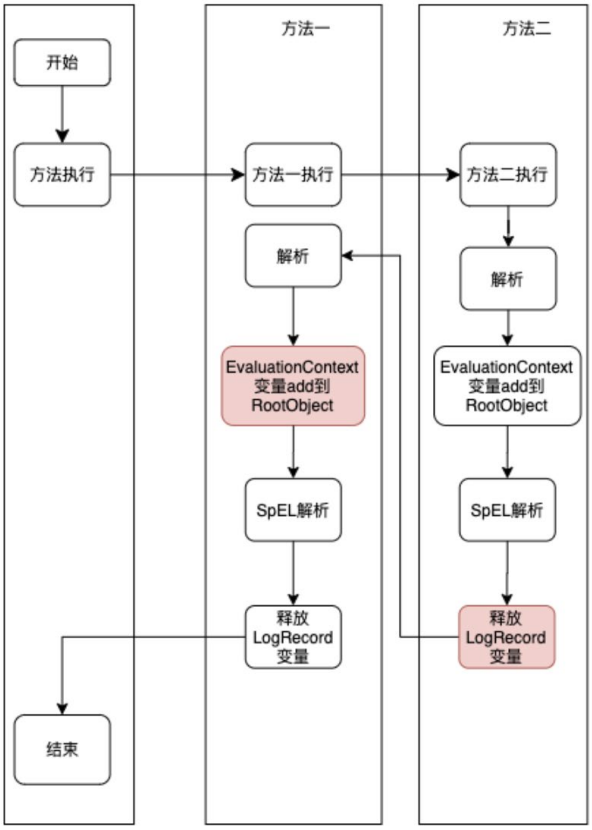

可以看到，当方法二执行了释放变量后，继续执行方法一的 logRecord 逻辑，此时解析的时候 ThreadLocal<map> 的 Map 已经被释放掉，所以方法一就获取不到对应的变量了。方法一和方法二共用一个变量 Map 还有个问题是：如果方法二设置了和方法一相同的变量两个方法的变量就会被相互覆盖。所以最终 LogRecordContext 的变量的生命周期需要是下面的形式：</map

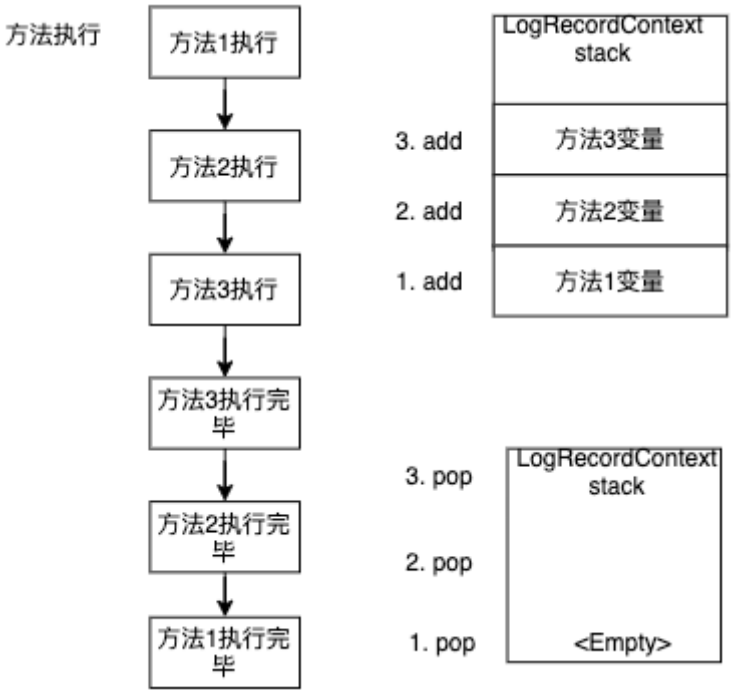

LogRecordContext 每执行一个方法都会压栈一个 Map，方法执行完之后会 Pop 掉这个 Map，从而避免变量共享和覆盖问题。

默认操作人逻辑

在 LogRecordInterceptor 中 IOperatorGetService 接口，这个接口可以获取到当前的用户。下面是接口的定义：

```
public interface IOperatorGetService {

    /**
     * 可以在里面外部的获取当前登陆的用户，比如 UserContext.getCurrentUser()
     *
     * @return 转换成 Operator 返回
     */
    Operator getUser();
}
```

下面给出了从用户上下文中获取用户的例子：

```
public class DefaultOperatorGetServiceImpl implements IOperatorGetService
{

    @Override
    public Operator getUser() {
    //UserUtils 是获取用户上下文的方法
         return Optional.ofNullable(UserUtils.getUser())
                        .map(a -> new Operator(a.getName(), a.getLogin()))
                        .orElseThrow(()->new IllegalArgumentException("user
is null"));

    }
}
```

组件在解析 operator 的时候，就判断注解上的 operator 是否是空，如果注解上没有指定，我们就从 IOperatorGetService 的 getUser 方法获取了。如果都获取不到，就会报错。

```
String realOperatorId = "";
if (StringUtils.isEmpty(operatorId)) {
    if (operatorGetService.getUser() == null || StringUtils.
isEmpty(operatorGetService.getUser().getOperatorId())) {
        throw new IllegalArgumentException("user is null");
    }
    realOperatorId = operatorGetService.getUser().getOperatorId();
} else {
    spElTemplates = Lists.newArrayList(bizKey, bizNo, action, operatorId,
detail);
}
```

自定义函数逻辑

自定义函数的类图如下：

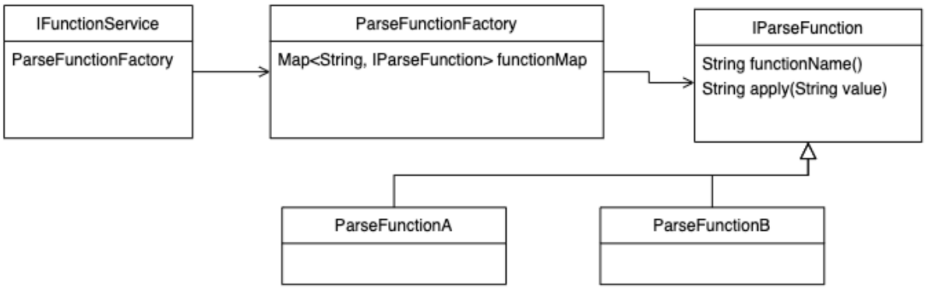

下面是 IParseFunction 的接口定义：`executeBefore` 函数代表了自定义函数是否在业务代码执行之前解析，上面提到的查询修改之前的内容。

```
public interface IParseFunction {

  default boolean executeBefore(){
    return false;
  }

  String functionName();

  String apply(String value);
}
```

ParseFunctionFactory 的代码比较简单，它的功能是把所有的 IParseFunction 注入到函数工厂中。

```
public class ParseFunctionFactory {
  private Map<String, IParseFunction> allFunctionMap;

  public ParseFunctionFactory(List<IParseFunction> parseFunctions) {
    if (CollectionUtils.isEmpty(parseFunctions)) {
      return;
    }
    allFunctionMap = new HashMap<>();
    for (IParseFunction parseFunction : parseFunctions) {
      if (StringUtils.isEmpty(parseFunction.functionName())) {
        continue;
      }
      allFunctionMap.put(parseFunction.functionName(), parseFunction);
    }
  }

  public IParseFunction getFunction(String functionName) {
    return allFunctionMap.get(functionName);
  }

  public boolean isBeforeFunction(String functionName) {
    return allFunctionMap.get(functionName) != null && allFunctionMap.
get(functionName).executeBefore();
  }
}
```

DefaultFunctionServiceImpl 的逻辑就是根据传入的函数名称 functionName 找到

对应的 IParseFunction，然后把参数传入到 IParseFunction 的 apply 方法上最后返回函数的值。

```
public class DefaultFunctionServiceImpl implements IFunctionService {

  private final ParseFunctionFactory parseFunctionFactory;

  public DefaultFunctionServiceImpl(ParseFunctionFactory parseFunctionFactory) {
    this.parseFunctionFactory = parseFunctionFactory;
  }

  @Override
  public String apply(String functionName, String value) {
    IParseFunction function = parseFunctionFactory.
getFunction(functionName);
    if (function == null) {
      return value;
    }
    return function.apply(value);
  }

  @Override
  public boolean beforeFunction(String functionName) {
    return parseFunctionFactory.isBeforeFunction(functionName);
  }
}
```

4.2.3 日志持久化逻辑

同样在 LogRecordInterceptor 的代码中引用了 ILogRecordService，这个 Service 主要包含了日志记录的接口。

```
public interface ILogRecordService {
    /**
     * 保存 log
     *
     * @param logRecord 日志实体
     */
    void record(LogRecord logRecord);

}
```

业务可以实现这个保存接口，然后把日志保存在任何存储介质上。这里给了一个 2.2 节介绍的通过 log.info 保存在日志文件中的例子，业务可以把保存设置成异步或者同

步，可以和业务放在一个事务中保证操作日志和业务的一致性，也可以新开辟一个事务，保证日志的错误不影响业务的事务。业务可以保存在 Elasticsearch、数据库或者文件中，用户可以根据日志结构和日志的存储实现相应的查询逻辑。

```
@Slf4j
public class DefaultLogRecordServiceImpl implements ILogRecordService {

    @Override
//    @Transactional(propagation = Propagation.REQUIRES_NEW)
    public void record(LogRecord logRecord) {
        log.info("【logRecord】log={}", logRecord);
    }
}
```

4.2.4 Starter 逻辑封装

上面逻辑代码已经介绍完毕，那么接下来需要把这些组件组装起来，然后让用户去使用。在使用这个组件的时候只需要在 Springboot 的入口上添加一个注解 @EnableLogRecord(tenant = “com.mzt.test”)。其中 tenant 代表租户，是为了多租户使用的。

```
@SpringBootApplication(exclude = DataSourceAutoConfiguration.class)
@EnableTransactionManagement
@EnableLogRecord(tenant = "com.mzt.test")
public class Main {

    public static void main(String[] args) {
        SpringApplication.run(Main.class, args);
    }
}
```

再看下 EnableLogRecord 的代码，代码中 Import 了 `LogRecordConfigureSelector.class`，在 `LogRecordConfigureSelector` 类中暴露了 `LogRecordProxyAutoConfiguration` 类。

```
@Target(ElementType.TYPE)
@Retention(RetentionPolicy.RUNTIME)
@Documented
@Import(LogRecordConfigureSelector.class)
public @interface EnableLogRecord {
```

```
    String tenant();

    AdviceMode mode() default AdviceMode.PROXY;
}
```

`LogRecordProxyAutoConfiguration` 就是装配上面组件的核心类了，代码如下：

```
@Configuration
@Slf4j
public class LogRecordProxyAutoConfiguration implements ImportAware {

  private AnnotationAttributes enableLogRecord;


  @Bean
  @Role(BeanDefinition.ROLE_INFRASTRUCTURE)
  public LogRecordOperationSource logRecordOperationSource() {
    return new LogRecordOperationSource();
  }

  @Bean
  @ConditionalOnMissingBean(IFunctionService.class)
  public IFunctionService functionService(ParseFunctionFactory
parseFunctionFactory) {
    return new DefaultFunctionServiceImpl(parseFunctionFactory);
  }

  @Bean
  public ParseFunctionFactory parseFunctionFactory(@Autowired
List<IParseFunction> parseFunctions) {
    return new ParseFunctionFactory(parseFunctions);
  }

  @Bean
  @ConditionalOnMissingBean(IParseFunction.class)
  public DefaultParseFunction parseFunction() {
    return new DefaultParseFunction();
  }


  @Bean
  @Role(BeanDefinition.ROLE_INFRASTRUCTURE)
  public BeanFactoryLogRecordAdvisor logRecordAdvisor(IFunctionService
functionService) {
    BeanFactoryLogRecordAdvisor advisor =
            new BeanFactoryLogRecordAdvisor();
    advisor.setLogRecordOperationSource(logRecordOperationSource());
```

```
    advisor.setAdvice(logRecordInterceptor(functionService));
    return advisor;
  }

  @Bean
  @Role(BeanDefinition.ROLE_INFRASTRUCTURE)
  public LogRecordInterceptor logRecordInterceptor(IFunctionService
functionService) {
    LogRecordInterceptor interceptor = new LogRecordInterceptor();
    interceptor.setLogRecordOperationSource(logRecordOperationSource());
    interceptor.setTenant(enableLogRecord.getString("tenant"));
    interceptor.setFunctionService(functionService);
    return interceptor;
  }

  @Bean
  @ConditionalOnMissingBean(IOperatorGetService.class)
  @Role(BeanDefinition.ROLE_APPLICATION)
  public IOperatorGetService operatorGetService() {
    return new DefaultOperatorGetServiceImpl();
  }

  @Bean
  @ConditionalOnMissingBean(ILogRecordService.class)
  @Role(BeanDefinition.ROLE_APPLICATION)
  public ILogRecordService recordService() {
    return new DefaultLogRecordServiceImpl();
  }

  @Override
  public void setImportMetadata(AnnotationMetadata importMetadata) {
    this.enableLogRecord = AnnotationAttributes.fromMap(
            importMetadata.getAnnotationAttributes(EnableLogRecord.class.
getName(), false));
    if (this.enableLogRecord == null) {
      log.info("@EnableCaching is not present on importing class");
    }
  }
}
```

这个类继承 ImportAware 是为了拿到 EnableLogRecord 上的租户属性，这个类使用变量 logRecordAdvisor 和 logRecordInterceptor 装配了 AOP，同时把自定义函数注入到了 logRecordAdvisor 中。

对外扩展类：分别是 `IOperatorGetService`、`ILogRecordService`、`IParseFunction`。业务可以自己实现相应的接口，因为配置了 @ConditionalOnMissing-

Bean，所以用户的实现类会覆盖组件内的默认实现。

5. 总结

这篇文章介绍了操作日志的常见写法，以及如何让操作日志的实现更加简单、易懂；通过组件的四个模块，介绍了组件的具体实现。对于上面的组件介绍，大家如果有疑问，也欢迎在文末留言，我们会进行答疑。

6. 作者简介

站通，2020 年加入美团，基础研发平台 / 研发质量及效率部工程师。

7. 参考资料

- Canal
- spring-framework
- Spring Expression Language (SpEL)
- ThreadLocal、InheritableThreadLocal、TransmittableThreadLocal 三者之间区别

8. 招聘信息

美团研发质量及效率部 ，致力于建设业界一流的持续交付平台，现招聘基础组件方向相关的工程师，坐标北京 / 上海。欢迎感兴趣的同学加入。可投递简历至：chao.yu@meituan.com（邮件主题请注明：美团研发质量及效率部）。

基于 SSD 的 Kafka 应用层缓存架构设计与实现

作者：世吉　仕禄

Kafka 在美团数据平台的现状

Kafka 出色的 I/O 优化以及多处异步化设计，相比其他消息队列系统具有更高的吞吐，同时能够保证不错的延迟，十分适合应用在整个大数据生态中。

目前在美团数据平台中，Kafka 承担着数据缓冲和分发的角色。如下图所示，业务日志、接入层 Nginx 日志或线上 DB 数据通过数据采集层发送到 Kafka，后续数据被用户的实时作业消费、计算，或经过数仓的 ODS 层用作数仓生产，还有一部分则会进入公司统一日志中心，帮助工程师排查线上问题。

目前美团线上 Kafka 规模：

- **集群规模**：节点数达 6000+，集群数 100+。
- **集群承载**：Topic 数 6 万 +，Partition 数 41 万 +。
- **处理的消息规模**：目前每天处理消息总量达 8 万亿，峰值流量为 1.8 亿条 / 秒
- **提供的服务规模**：目前下游实时计算平台运行了 3 万 + 作业，而这其中绝大多数的数据源均来自 Kafka。

Kafka 线上痛点分析 & 核心目标

当前 Kafka 支撑的实时作业数量众多，单机承载的 Topic 和 Partition 数量很大。这种场景下很容易出现的问题是：同一台机器上不同 Partition 间竞争 PageCache 资源，相互影响，导致整个 Broker 的处理延迟上升、吞吐下降。

接下来，我们将结合 Kafka 读写请求的处理流程以及线上统计的数据来分析一下 Kafka 在线上的痛点。

原理分析

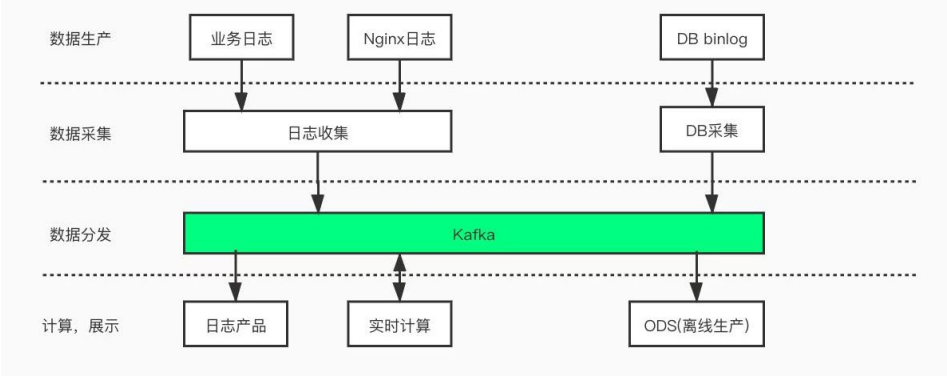

Kafka 处理读写流程的示意图

对于 Produce 请求：Server 端的 I/O 线程统一将请求中的数据写入到操作系统的 PageCache 后立即返回，当消息条数到达一定阈值后，Kafka 应用本身或操作系统内核会触发强制刷盘操作（如左侧流程图所示）。

对于 Consume 请求：主要利用了操作系统的 ZeroCopy 机制，当 Kafka Broker 接收到读数据请求时，会向操作系统发送 sendfile 系统调用，操作系统接收后，首先试图从 PageCache 中获取数据（如中间流程图所示）；如果数据不存在，会触发缺页异常中断将数据从磁盘读入到临时缓冲区中（如右侧流程图所示），随后通过 DMA 操作直接将数据拷贝到网卡缓冲区中等待后续的 TCP 传输。

综上所述，Kafka 对于单一读写请求均拥有很好的吞吐和延迟。处理写请求时，数据写入 PageCache 后立即返回，数据通过异步方式批量刷入磁盘，既保证了多数写请求都能有较低的延迟，同时批量顺序刷盘对磁盘更加友好。处理读请求时，实时消费的作业可以直接从 PageCache 读取到数据，请求延迟较小，同时 ZeroCopy 机制能够减少数据传输过程中用户态与内核态的切换，大幅提升了数据传输的效率。

但当同一个 Broker 上同时存在多个 Consumer 时，就可能会由于多个 Consumer 竞争 PageCache 资源导致它们同时产生延迟。下面我们以两个 Consumer 为例详细说明：

如上图所示，Producer 将数据发送到 Broker，PageCache 会缓存这部分数据。当所有 Consumer 的消费能力充足时，所有的数据都会从 PageCache 读取，全部 Consumer 实例的延迟都较低。此时如果其中一个 Consumer 出现消费延迟（图中的 Consumer Process2），根据读请求处理流程可知，此时会触发磁盘读取，在从磁盘读取数据的同时会预读部分数据到 PageCache 中。当 PageCache 空间不足时，会按照 LRU 策略开始淘汰数据，此时延迟消费的 Consumer 读取到的数据会替换 PageCache 中实时的缓存数据。后续当实时消费请求到达时，由于 PageCache 中的数据已被替换掉，会产生预期外的磁盘读取。这样会导致两个后果：

- 消费能力充足的 Consumer 消费时会失去 PageCache 的性能红利。
- 多个 Consumer 相互影响，预期外的磁盘读增多，HDD 负载升高。

我们针对 HDD 的性能和读写并发的影响做了梯度测试，如下图所示：

可以看到，随着读并发的增加，HDD 的 IOPS 和带宽均会明显下降，这会进一步影响整个 Broker 的吞吐以及处理延迟。

线上数据统计

目前 Kafka 集群 TP99 流量在 170MB/s，TP95 流量在 100MB/s，TP50 流量为 50-60MB/s；单机的 PageCache 平均分配为 80GB，取 TP99 的流量作为参考，在此流量以及 PageCache 分配情况下，PageCache 最大可缓存数据时间跨度为 80*1024/170/60 = 8min，可见当前 Kafka 服务整体对延迟消费作业的容忍性极低。该情况下，一旦部分作业消费延迟，实时消费作业就可能会受到影响。

同时，我们统计了线上实时作业的消费延迟分布情况，延迟范围在 0-8min（实时消费）的作业只占 80%，说明目前存在线上存在 20% 的作业处于延迟消费的状态。

痛点分析总结

总结上述的原理分析以及线上数据统计，目前线上 Kafka 存在如下问题：

- 实时消费与延迟消费的作业在 PageCache 层次产生竞争，导致实时消费产生非预期磁盘读。
- 传统 HDD 随着读并发升高性能急剧下降。
- 线上存在 20% 的延迟消费作业。

按目前的 PageCache 空间分配以及线上集群流量分析，Kafka 无法对实时消费作业提供稳定的服务质量保障，该痛点亟待解决。

预期目标

根据上述痛点分析，我们的预期目标为保证实时消费作业不会由于 PageCache 竞争而被延迟消费作业影响，保证 Kafka 对实时消费作业提供稳定的服务质量保障。

解决方案

为什么选择 SSD

根据上述原因分析可知，解决目前痛点可从以下两个方向来考虑：

- 消除实时消费与延迟消费间的 PageCache 竞争，如：让延迟消费作业读取的数据不回写 PageCache，或增大 PageCache 的分配量等。
- 在 HDD 与内存之间加入新的设备，该设备拥有比 HDD 更好的读写带宽与 IOPS。

对于第一个方向，由于 PageCache 由操作系统管理，若修改其淘汰策略，那么实现难度较为复杂，同时会破坏内核本身对外的语义。另外，内存资源成本较高，无法进行无限制的扩展，因此需要考虑第二个方向。

SSD 目前发展日益成熟，相较于 HDD，SSD 的 IOPS 与带宽拥有数量级级别的提升，很适合在上述场景中当 PageCache 出现竞争后承接部分读流量。我们对 SSD 的性能也进行了测试，结果如下图所示：

从图中可以发现，随着读取并发的增加，SSD 的 IOPS 与带宽并不会显著降低。通过该结论可知，我们可以使用 SSD 作为 PageCache 与 HDD 间的缓存层。

架构决策

在引入 SSD 作为缓存层后，下一步要解决的关键问题包括 PageCache、SSD、HDD 三者间的数据同步以及读写请求的数据路由等问题，同时我们的新缓存架构需要充分匹配 Kafka 引擎读写请求的特征。本小节将介绍新架构如何在选型与设计上解决上述提到的问题。

Kafka 引擎在读写行为上具有如下特性：

- 数据的消费频率随时间变化，越久远的数据消费频率越低。
- 每个分区（Partition）只有 Leader 提供读写服务。
- 对于一个客户端而言，消费行为是线性的，数据并不会重复消费。

下文给出了两种备选方案，下面将对两种方案给出我们的选取依据与架构决策。

备选方案一：基于操作系统内核层实现

目前开源的缓存技术有 FlashCache、BCache、DM-Cache、OpenCAS 等，其中 BCache 和 DM-Cache 已经集成到 Linux 中，但对内核版本有要求，受限于内核版本，我们仅能选用 FlashCache/OpenCAS。

如下图所示，FlashCache 以及 OpenCAS 二者的核心设计思路类似，两种架构的核心理论依据为“数据局部性”原理，将 SSD 与 HDD 按照相同的粒度拆成固定的管理单元，之后将 SSD 上的空间映射到多块 HDD 层的设备上（逻辑映射 or 物理映射）。在访问流程上，与 CPU 访问高速缓存和主存的流程类似，首先尝试访问 Cache 层，如果出现 CacheMiss，则会访问 HDD 层，同时根据数据局部性原理，这部分数据将回写到 Cache 层。如果 Cache 空间已满，会通过 LRU 策略替换部分数据。

FlashCache/OpenCAS 提供了四种缓存策略：WriteThrough、WriteBack、WriteAround、WriteOnly。 由于第四种不做读缓存，这里我们只看前三种。

写入：

- **WriteThrough**：数据写操作在写入 SSD 的同时会写入到后端存储。

- **WriteBack**：数据写操作仅写入 SSD 即返回，由缓存策略 flush 到后台存储。
- **WriteAround**：数据写入操作直接写入后端存储，同时 SSD 对应的缓存会失效。

读取：

- **WriteThrough/WriteBack/WriteAround**：首先读取 SSD，命中不了的将再次读取后端存储，并数据会被刷入到 SSD 缓存中。

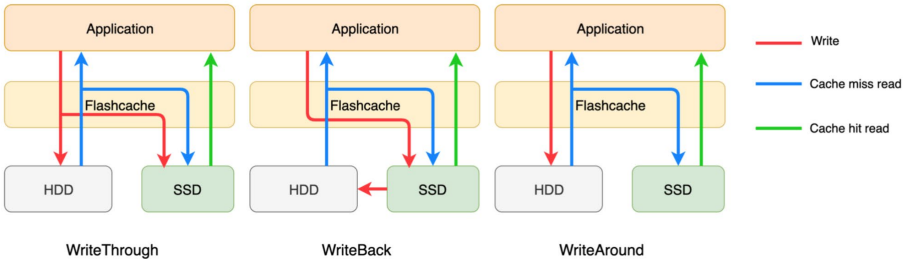

更多详细实现细节，极大可参见这二者的官方文档：

- FlashCache
- OpenCAS

备选方案二：Kafka 应用内部实现

上文提到的第一类备选方案中，核心的理论依据“数据局部性”原理与 Kafka 的读写特性并不能完全吻合，“数据回刷”这一特性依然会引入缓存空间污染问题。同时，上述架构基于 LRU 的淘汰策略也与 Kafka 读写特性存在矛盾，在多 Consumer 并发消费时，LRU 淘汰策略可能会误淘汰掉一些近实时数据，导致实时消费作业出现性能抖动。

可见，备选方案一并不能完全解决当前 Kafka 的痛点，需要从应用内部进行改造。整体设计思路如下，将数据按照时间维度分布在不同的设备中，近实时部分的数据缓存在 SSD 中，这样当出现 PageCache 竞争时，实时消费作业从 SSD 中读取数据，保证实时作业不会受到延迟消费作业影响。下图展示了基于应用层实现的架构处理读请求的流程：

当消费请求到达 Kafka Broker 时，Kafka Broker 直接根据其维护的消息偏移量（Offset）和设备的关系从对应的设备中获取数据并返回，并且在读请求中并不会将 HDD 中读取的数据回刷到 SSD，防止出现缓存污染。同时访问路径明确，不会由于 Cache Miss 而产生的额外访问开销。

下表对不同候选方案进行了更加详细的对比：

决策	优势	不足
基于操作系统内核层实现	1.数据路由对应用层透明，对应用代码改动量小。 2.开源软件自身的健壮性由社区维护，可用性较好（前提：社区比较活跃）。	1.FlashCache/OpenCAS每种模式下都会将数据回刷到SSD缓存中，与PageCache相似，都会发生缓存污染。 2.发生Cache Miss时会多一次对设备的访问，延迟增加。 3.所有的Meta数据都由操作系统维护，内核消耗的内存会增加，在与其他引擎混布的场景下会导致其他服务可申请的内存减少。
Kafka应用内部实现	1.设计缓存策略时充分考虑了Kafka的读写特性，确保近实时的数据消费请求全部落在SSD上，保证这部分请求处理的低延迟，同时从HDD读取的数据不会回刷到SSD防止缓存污染。 2.由于每个日志段都有唯一明确的状态，因此每次请求的查询路径最短，不存在因Cache Miss带来的额外性能开销。	1.需要在Server端代码上进行改进，涉及的开发及测试工作量较大。 2.随社区大版本升级，也需要迭代上这些改进的代码。但可将相关代码贡献社区，解决迭代问题。

最终，结合与 Kafka 读写特性的匹配度，整体工作量等因素综合考虑，我们采用 Kafka 应用层实现这一方案，因为该方案更贴近 Kafka 本身读写特性，能更加彻底地解决 Kafka 的痛点。

新架构设计

概述

根据上文对 Kafka 读写特性的分析，我们给出应用层基于 SSD 的缓存架构的设计目标：

- 数据按时间维度分布在不同的设备上，近实时数据分布在 SSD 上，随时间的推移淘汰到 HDD 上。
- Leader 分区中所有数据均写入 SSD 中。
- 从 HDD 中读取的数据不回刷到 SSD 中。

依据上述目标，我们给出应用层基于 SSD 的 Kafka 缓存架构实现：

Kafka 中一个 Partition 由若干 LogSegment 构成，每个 LogSegment 包含两个索

引文件以及日志消息文件。一个 Partition 的若干 LogSegment 按 Offset（相对时间）维度有序排列。

根据上一小节的设计思路，我们首先将不同的 LogSegment 标记为不同的状态，如图所示（图中上半部分）按照时间维度分为 OnlyCache、Cached 以及 WithoutCache 三种常驻状态。而三种状态的转换以及新架构对读写操作的处理如图中下半部分所示，其中标记为 OnlyCached 状态的 LogSegment 只存储在 SSD 上，后台线程会定期将 Inactive（没有写流量）的 LogSegment 同步到 SSD 上，完成同步的 LogSegment 被标记为 Cached 状态。最后，后台线程将会定期检测 SSD 上的使用空间，当空间达到阈值时，后台线程将会按照时间维度将距离现在最久的 LogSegment 从 SSD 中移除，这部分 LogSegment 会被标记为 WithoutCache 状态。

对于写请求而言，写入请求依然首先将数据写入到 PageCache 中，满足阈值条件后将会刷入 SSD。对于读请求（当 PageCache 未获取到数据时），如果读取的 offset 对应的 LogSegment 的状态为 Cached 或 OnlyCache，则数据从 SSD 返回（图中 LC2-LC1 以及 RC1），如果状态为 WithoutCache，则从 HDD 返回（图中 LC1）。

对于 Follower 副本的数据同步，可根据 Topic 对延迟以及稳定性的要求，通过配置决定写入到 SSD 还是 HDD。

关键优化点

上文介绍了基于 SSD 的 Kafka 应用层缓存架构的设计概要以及核心设计思路，包括读写流程、内部状态管理以及新增后台线程功能等。本小节将介绍该方案的关键优化点，这些优化点均与服务的性能息息相关。主要包括 LogSegment 同步以及 Append 刷盘策略优化，下面将分别进行介绍。

LogSegment 同步

LogSegment 同步是指将 SSD 上的数据同步到 HDD 上的过程，该机制在设计时主要有以下两个关键点：

- **同步的方式**：同步方式决定了 HDD 上对 SSD 数据的可见时效性，从而会影响故障恢复以及 LogSegment 清理的及时性。
- **同步限速**：LogSegment 同步过程中通过限速机制来防止同步过程中对正常读写请求造成影响

同步方式

关于 LogSegment 的同步方式，我们给出了三种备选方案，下表列举了三种方案的介绍以及各自的优缺点：

备选方案	简介	优势	不足
复用Follower同步机制	复用Follower同步Leader的机制，通过内部Fetcher发送网络请求将数据同步到HDD	有可以直接复用的模块	1. 需要与网络处理模块进行交互，同步流程复杂化 2.由于所有网络请求共用同一个请求队列，此类请求出现异常可能会影响其他读写请求
内部线程实时同步数据到HDD	后台线程实时同步数据到HDD	1.数据在HDD上的时效性较高 2.单次请求比较小，对IO较为友好	实时同步的数据均来自active的LogSegment，由于数据处于不断变化中，会带来额外的数据一致性维护的成本
后台线程只同步Inactive数据段到HDD	后台线程只同步Inactive的LogSegment到HDD	对于Inactive的LogSegment，由于已经停止写入，因此通常处于稳态，数据一致性较好维护	由于Inactive状态的LogSegment均为完整的一段，需要对拷贝速率与对设备负载进行Trade Off

最终，我们对一致性维护代价、实现复杂度等因素综合考虑，选择了后台同步 Inactive 的 LogSegment 的方式。

同步限速

LogSegment 同步行为本质上是设备间的数据传输，会同时在两个设备上产生额外的读写流量，占用对应设备的读写带宽。同时，由于我们选择了同步 Inactive 部分的数据，需要进行整段的同步。如果在同步过程中不加以限制会对服务整体延迟造成较大的影响，主要表现在下面两个方面：

- 从单盘性能角度，由于 SSD 的性能远高于 HDD，因此在数据传输时，HDD 写入带宽会被写满，此时其他的读写请求会出现毛刺，如果此时有延迟消费从 HDD 上读取数据或者 Follower 正在同步数据到 HDD 上，会造成服务抖动。
- 从单机部署的角度，单机会部署 2 块 SSD 与 10 块 HDD，因此在同步过程中，1 块 SSD 需要承受 5 块 HDD 的写入量，因此 SSD 同样会在同步过程中出现性能毛刺，影响正常的请求响应延迟。

基于上述两点，我们需要在 LogSegment 同步过程中增加限速机制，总体的限速原则为在不影响正常读写请求延迟的情况下尽可能快速地进行同步。因为同步速度过慢会导致 SSD 数据无法被及时清理而最终被写满。同时为了可以灵活调整，该配置也被设置为单 Broker 粒度的配置参数。

日志追加刷盘策略优化

除了同步问题，数据写入过程中的刷盘机制同样影响服务的读写延迟。该机制的设计不仅会影响新架构的性能，对原生 Kafka 同样会产生影响。

下图展示了单次写入请求的处理流程：

在 Produce 请求处理流程中，首先根据当前 LogSegment 的位置与请求中的数据信息确定是否需要滚动日志段，随后将请求中的数据写入到 PageCache 中，更新 LEO 以及统计信息，最后根据统计信息确定是否需要触发刷盘操作，如果需要则通过 `fileChannel.force` 强制刷盘，否则请求直接返回。

在整个流程中，除日志滚动与刷盘操作外，其他操作均为内存操作，不会带来性能问题。日志滚动涉及文件系统的操作，目前，Kafka 中提供了日志滚动的扰动参数，防止多个 Segment 同时触发滚动操作给文件系统带来压力。针对日志刷盘操作，目前 Kafka 给出的机制是以固定消息条数触发强制刷盘（目前线上为 50000），该机制只能保证在入流量一定时，消息会以相同的频率刷盘，但无法限制每次刷入磁盘的数据量，对磁盘的负载无法提供有效的限制。

如下图所示，为某磁盘在午高峰时间段 write_bytes 的瞬时值，在午高峰时间段，由于写入流量的上升，在刷盘过程中会产生大量的毛刺，而毛刺的值几乎接近磁盘最大的写入带宽，这会使读写请求延迟发生抖动。

针对该问题，我们修改了刷盘的机制，将原本的按条数限制修改为按实际刷盘的速率限制，对于单个 Segment，刷盘速率限制为 2MB/s。该值考虑了线上实际的平均消息大小，如果设置过小，对于单条消息较大的 Topic 会过于频繁的进行刷新，在流量较高时反而会加重平均延迟。目前该机制已在线上小范围灰度，右图展示了灰度后同

时间段对应的 write_bytes 指标，可以看到相比左图，数据刷盘速率较灰度前明显平滑，最高速率仅为 40MB/s 左右。

对于 SSD 新缓存架构，同样存在上述问题，因此在新架构中，在刷盘操作中同样对刷盘速率进行了限制。

方案测试

测试目标

- 验证基于应用层的 SSD 缓存架构能够避免实时作业受到延迟作业的影响。
- 验证相比基于操作系统内核层实现的缓存层架构，基于应用层的 SSD 架构在不同流量下读写延迟更低。

测试场景描述

- 构建 4 个集群：新架构集群、普通 HDD 集群、FlashCache 集群、Open-CAS 集群。
- 每个集群 3 个节点。
- 固定写入流量，比较读、写耗时。
- 延迟消费设置：只消费相对当前时间 10~150 分钟的数据（超过 PageCache 的承载区域，不超过 SSD 的承载区域）。

测试内容及重点关注指标

- Case1: 仅有延迟消费时，观察集群的生产和消费性能。
  - 重点关注的指标：写耗时、读耗时，通过这 2 个指标体现出读写延迟。
  - 命中率指标：HDD 读取量、HDD 读取占比（HDD 读取量 / 读取总量）、SSD 读取命中率，通过这 3 个指标体现出 SSD 缓存的命中率。
- Case2: 存在延迟消费时，观察实时消费的性能。
  - 重点指标：实时作业的 SLA（服务质量）的 5 个不同时间区域的占比情况。

测试结果

从单 Broker 请求延迟角度看：

在刷盘机制优化前，SSD 新缓存架构在所有场景下，较其他方案都具有明显优势。

刷盘机制优化后，其余方案在延迟上服务质量有提升，在较小流量下由于 flush 机制的优化，新架构与其他方案的优势变小。当单节点写入流量较大时（大于 170MB）优势明显。

从延迟作业对实时作业的影响方面看：

新缓存架构在测试所涉及的所有场景中，延迟作业都不会对实时作业产生影响，符合预期。

总结与未来展望

Kafka 在美团数据平台承担统一的数据缓存和分发的角色，针对目前由于 Page-Cache 互相污染、进而引发 PageCache 竞争导致实时作业被延迟作业影响的痛点，我们基于 SSD 自研了 Kafka 的应用层缓存架构。本文主要介绍 Kafka 新架构的设计思路以及与其他开源方案的对比。与普通集群相比，新缓存架构具备非常明显的优势：

- **降低读写耗时**：比起普通集群，新架构集群读写耗时降低 80%。
- **实时消费不受延迟消费的影响**：比起普通集群，新架构集群实时读写性能稳定，不受延时消费的影响。

目前，这套缓存架构优已经验证完成，正在灰度阶段，未来也优先部署到高优集群。其中涉及的代码也将提交给 Kafka 社区，作为对社区的回馈，也欢迎大家跟我们一起交流。

作者简介

世吉，仕禄，均为美团数据平台工程师。

美团图数据库平台建设及业务实践

作者：登昌　梁帅　高辰　杨鑫　尊远　王超

1. 前言

图数据结构，能够很自然地表征现实世界。比如用户、门店、骑手这些实体可以用图中的点来表示，用户到门店的消费行为、骑手给用户的送餐行为可以用图中的边来表示。使用图的方式对场景建模，便于描述复杂关系。在美团，也有比较多的图数据存储及多跳查询需求，概括起来主要包括以下 4 个方面：

- **图谱挖掘**：美团有美食图谱、商品图谱、旅游图谱、用户全景图谱在内的近 10 个领域知识图谱，数据量级大概在千亿级别。在迭代、挖掘数据的过程中，需要一种组件对这些图谱数据进行统一的管理。
- **安全风控**：业务部门有内容风控的需求，希望在商户、用户、评论中通过多跳查询来识别虚假评价；在支付时进行金融风控的验证，实时多跳查询风险点。
- **链路分析**：包括代码分析、服务治理、数据血缘管理，比如公司数据平台上有很多 ETL Job，Job 和 Job 之间存在强弱依赖关系，这些强弱依赖关系形成了一张图，在进行 ETL Job 的优化或者故障处理时，需要对这个图进行实时查询分析。
- **组织架构**：公司组织架构的管理，实线汇报链、虚线汇报链、虚拟组织的管理，以及商家连锁门店的管理。比如，维护一个商家在不同区域都有哪些门店，能够进行多层关系查找或者逆向关系搜索。

总体来说，美团需要一种组件来管理千亿级别的图数据，解决图数据存储以及多跳查询问题。海量图数据的高效存储和查询是图数据库研究的核心课题，如何在大规模分布式场景中进行工程落地是我们面临的痛点问题。传统的关系型数据库、NoSQL 数据库可以用来存储图数据，但是不能很好处理图上多跳查询这一高频的操作。

Neo4j 公司在社交场景（见图 1）里做了传统关系型数据库 MySQL 跟图数据库

Neo4j 的查询性能对比 [1]，在一个包含 100 万人、每人约有 50 个朋友的社交网络里找最大深度为 5 的朋友的朋友，实验结果表明多跳查询中图数据库优势明显（见图 2）。然而选取或者自主研发一款高吞吐、低查询延时、能存储海量数据且易用的图数据库非常困难。下面将介绍美团在图数据库选型及平台建设方面的一些工作。

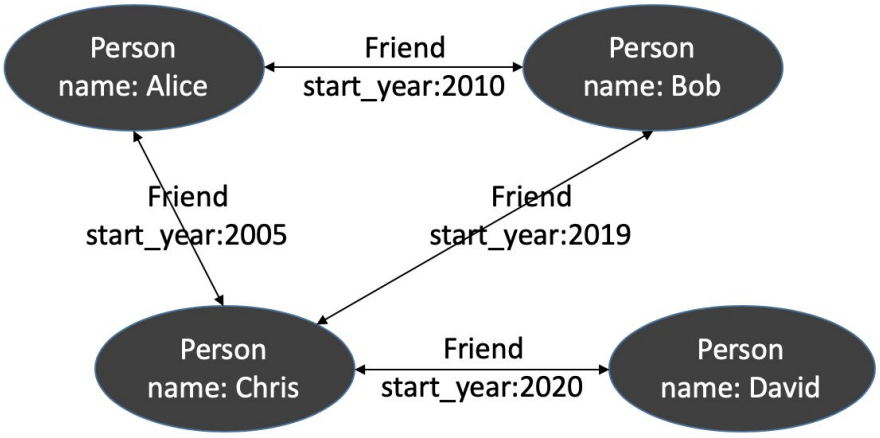

社交场景示例

图 1

深度	关系型数据库的执行时间(s)	Neo4j的执行时间(s)	返回的记录条数
2	0.016	0.01	~2500
3	30.267	0.168	~110000
4	1543.505	1.359	~600000
5	未完成	2.132	~800000

关系数据库 vs 图数据库(多跳查询)

图 2

2. 图数据库选型

在图数据库的选型上我们主要考虑了以下 5 点：(A) 项目开源，暂不考虑需付费的图数据库；(B) 分布式架构设计，具备良好的可扩展性；© 毫秒级的多跳查询延迟；(D)

支持千亿量级点边存储；(E) 具备批量从数仓导入数据的能力。

分析 DB-Engines[2] 上排名前 30 的图数据库，剔除不开源的项目，我们将剩余的图数据库分为三类：

- **第一类：Neo4j[3]、ArangoDB[4]、Virtuoso[5]、TigerGraph[6]、RedisGraph[7]**。此类图数据库只有单机版本开源可用，性能优秀，但不能应对分布式场景中数据的规模增长，即不满足选型要求（B）、（D）。
- **第二类：JanusGraph[8]、HugeGraph[9]**。此类图数据库在现有存储系统之上新增了通用的图语义解释层，图语义层提供了图遍历的能力，但是受到存储层或者架构限制，不支持完整的计算下推，多跳遍历的性能较差，很难满足 OLTP 场景下对低延时的要求，即不满足选型要求（C）。
- **第三类：DGraph[10]、NebulaGraph[11]**。此类图数据库根据图数据的特点对数据存储模型、点边分布、执行引擎进行了全新设计，对图的多跳遍历进行了深度优化，基本满足我们的选型要求。

DGraph 是由前 Google 员工 Manish Rai Jain 离职创业后，在 2016 年推出的图数据库产品，底层数据模型是 RDF[12]，基于 Go 语言编写，存储引擎基于 BadgerDB[13] 改造，使用 RAFT 保证数据读写的强一致性。

NebulaGraph 是由前 Facebook 员工叶小萌离职创业后，在 2019 年 推出的图数据库产品，底层数据模型是属性图，基于 C++ 语言编写，存储引擎基于 RocksDB[14] 改造，使用 RAFT 保证数据读写的强一致性。

这两个项目的创始人都在互联网公司图数据库领域深耕多年，对图数据库的落地痛点有深刻认识，整体的架构设计也有较多相似之处。在图数据库最终的选型上，我们基于 LDBC-SNB 数据集 [15] 对 NebulaGraph、DGraph、HugeGraph 进行了深度性能测评，测试详情见文章：主流开源分布式图数据库 Benchmark，从测试结果看 NebulaGraph 在数据导入、实时写入及多跳查询方面性能均优于竞品。此外，NebulaGraph 社区活跃，问题响应速度快，所以团队最终选择基于 NebulaGraph

来搭建图数据库平台。

3. NebulaGraph 架构

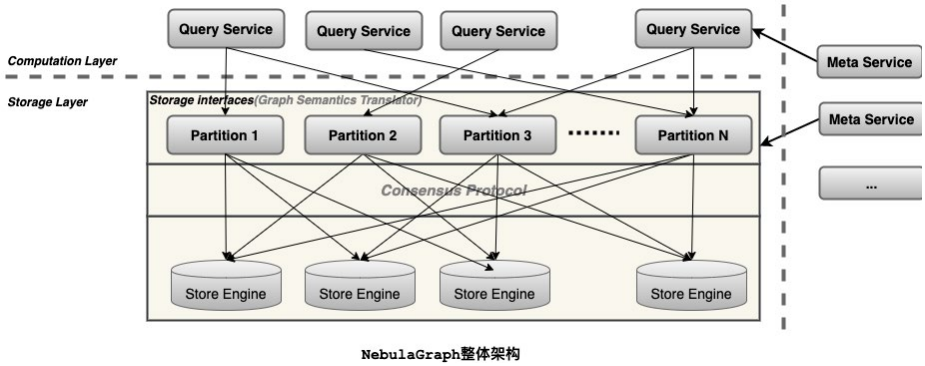

图 3

一个完整的 NebulaGraph 集群包含三类服务，即 Query Service、Storage Service 和 Meta Service。每类服务都有其各自的可执行二进制文件，既可以部署在同一节点上，也可以部署在不同的节点上。下面是 NebulaGraph 架构设计（见图 3）的几个核心点 [16][17]。

- **Meta Service**：架构图中右侧为 Meta Service 集群，它采用 Leader/Follower 架构。Leader 由集群中所有的 Meta Service 节点选出，然后对外提供服务；Followers 处于待命状态，并从 Leader 复制更新的数据。一旦 Leader 节点 Down 掉，会再选举其中一个 Follower 成为新的 Leader。Meta Service 不仅负责存储和提供图数据的 Meta 信息，如 Schema、数据分片信息等；同时还提供 Job Manager 机制管理长耗时任务，负责指挥数据迁移、Leader 变更、数据 compaction、索引重建等运维操作。
- **存储计算分离**：在架构图中 Meta Service 的左侧，为 NebulaGraph 的主要服务，NebulaGraph 采用存储与计算分离的架构，虚线以上为计算，以下为存储。存储计算分离有诸多优势，最直接的优势就是，计算层和存储层可以根据各自的情况弹性扩容、缩容。存储计算分离还带来了另一个优势：使水平扩

展成为可能。此外，存储计算分离使得 Storage Service 可以为多种类型的计算层或者计算引擎提供服务。当前 Query Service 是一个高优先级的 OLTP 计算层，而各种 OLAP 迭代计算框架会是另外一个计算层。

- **无状态计算层**：每个计算节点都运行着一个无状态的查询计算引擎，而节点彼此间无任何通信关系。计算节点仅从 Meta Service 读取 Meta 信息以及和 Storage Service 进行交互。这样设计使得计算层集群更容易使用 K8s 管理或部署在云上。每个查询计算引擎都能接收客户端的请求，解析查询语句，生成抽象语法树（AST）并将 AST 传递给执行计划器和优化器，最后再交由执行器执行。
- **Shared-nothing 分布式存储层**：Storage Service 采用 Shared-nothing 的分布式架构设计，共有三层，最底层是 Store Engine，它是一个单机版 Local Store Engine，提供了对本地数据的 get/put/scan/delete 操作，该层定义了数据操作接口，用户可以根据自己的需求定制开发相关 Local Store Plugin。目前，NebulaGraph 提供了基于 RocksDB 实现的 Store Engine。在 Local Store Engine 之上是 Consensus 层，实现了 Multi Group Raft，每一个 Partition 都对应了一组 Raft Group。在 Consensus 层上面是 Storage interfaces，这一层定义了一系列和图相关的 API。这些 API 请求会在这一层被翻译成一组针对相应 Partition 的 KV 操作。正是这一层的存在，使得存储服务变成了真正的图存储。否则，Storage Service 只是一个 KV 存储罢了。而 NebulaGraph 没把 KV 作为一个服务单独提出，最主要的原因便是图查询过程中会涉及到大量计算，这些计算往往需要使用图的 Schema，而 KV 层没有数据 Schema 概念，这样设计比较容易实现计算下推，是 NebulaGraph 查询性能优越的主要原因。

NebulaGraph 基于 C++ 实现，架构设计支持存储千亿顶点、万亿边，并提供毫秒级别的查询延时。我们在 3 台 48U192G 物理机搭建的集群上灌入 10 亿美食图谱数据对 NebulaGraph 的功能进行了验证。

- 一跳查询 TP99 延时在 5ms 内，两跳查询 TP99 延时在 20ms 内，一般的多

跳查询 TP99 延时在百毫秒内。

- 集群在线写入速率约为 20 万 Records/s。
- 支持通过 Spark 任务离线生成 RocksDB 底层 SST File，直接将数据文件载入到集群中，即类似 HBase BulkLoad 能力。
- 提供了类 SQL 查询语言，对于新增的业务需求，只需构造 NebulaGraph SQL 语句，易于理解且能满足各类复杂查询要求。
- 提供联合索引、GEO 索引，可通过实体属性或者关系属性查询实体、关系，或者查询在某个经纬度附近 N 米内的实体。
- 一个 NebulaGraph 集群中可以创建多个 Space（概念类似 MySQL 的 DataBase），并且不同 Space 中的数据在物理上是隔离的。

4. 图数据库平台建设

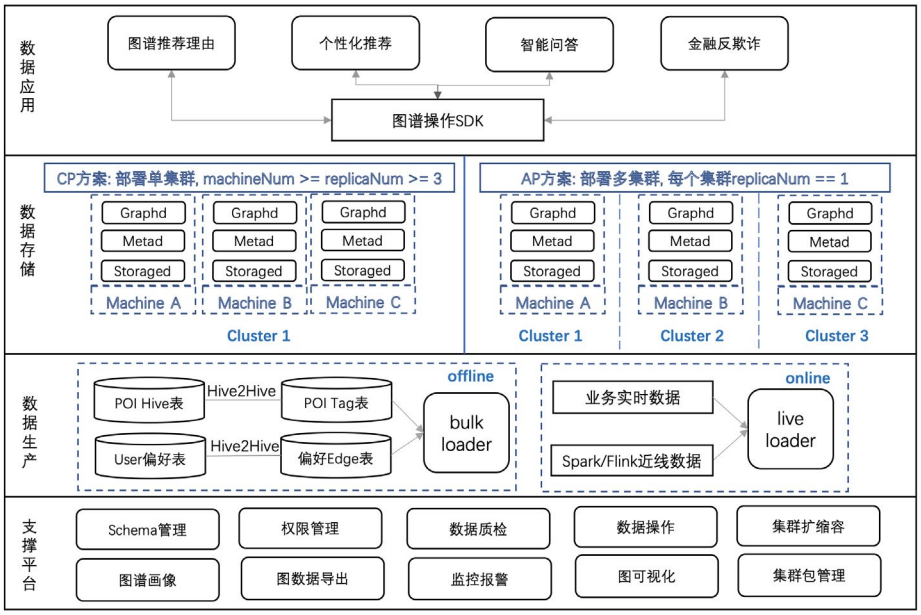

图 4

为了统一管理图数据，减少工程同学在图数据库集群上的运维压力，我们基于开源分布式图数据库 NebulaGraph，搭建了一套一站式图数据库自助管理平台（见图 4），

该平台包含以下 4 层：

- 数据应用层。业务方可以在业务服务中引入图谱 SDK，实时地对图数据进行增删改查。
- 数据存储层。支持两种图数据库集群的部署。
  - 第一种部署方式是 CP 方案，即 Consistency & Partition tolerance。单集群部署，集群中机器数量大于等于副本的数量，副本数量大于等于 3 。只要集群中有大于副本数一半的机器存活，整个集群就可以对外正常提供服务。CP 方案保证了数据读写的强一致性，但这种部署方式下集群可用性不高。
  - 第二种部署方式是 AP 方案，即 Availability & Partition tolerance。在一个应用中部署多个图数据库集群，每个集群数据副本数为 1 ，多集群之间进行互备。这种部署方式的好处在于整个应用对外的可用性高，但数据读写的一致性要差些。
- 数据生产层。图数据主要有两种来源，第一种是业务方把数仓中数据通过 ETL Job 转成点和边的 Hive 表，然后离线导入到图数据库中；第二种是业务线上实时产生的数据、或者通过 Spark/Flink 等流式处理产生的近线数据，调用在线批量写接口实时灌到图数据库中。
- 支撑平台。提供了 Schema 管理、权限管理、数据质检、数据增删改查、集群扩缩容、图谱画像、图数据导出、监控报警、图可视化、集群包管理等功能。

与业界方案相比，团队主导设计的图数据库平台除了支持存储千亿顶点、万亿边，具备毫秒级别查询能力外，还提供了如下四项能力：应用可用性 SLA 达 99.99%；支持每小时百亿量级数据导入；实时写入数据时保证多集群数据最终一致性；易用的图谱可视化能力。下面将介绍具体的设计思路。

4.1 高可用模块设计

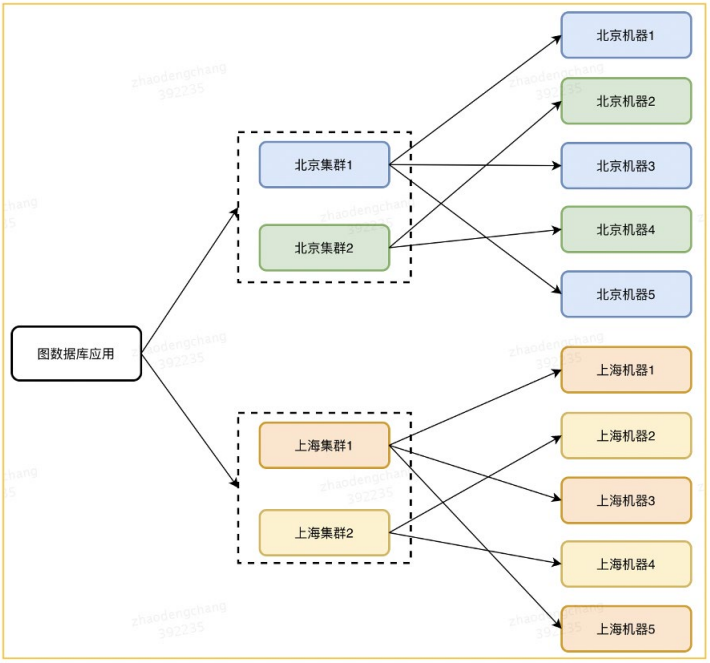

图 5

首先介绍单应用多集群高可用模块的设计（AP 方案）。为什么有 AP 方案的设计呢？因为接入图数据库平台的业务方比较在意的指标是集群可用性。在线服务对集群的可用性要求非常高，最基础的要求是集群可用性能达到 4 个 9，即一年里集群的不可用时间要小于一个小时。对于在线服务来说，服务或者集群的可用性是整个业务的生命线，如果这点保证不了，即使集群提供的能力再多再丰富，那么业务方也不会考虑使用，可用性是业务选型的基础。

另外，公司要求中间件要有跨区域容灾能力，即要具备在多个地域部署多集群的能力。我们分析了平台接入方的业务需求，大约 80% 的场景是 T+1 全量导入数据、线上只读。在这种场景下，对图数据的读写强一致性要求并不高，因此我们设计了单应用多集群这种部署方案。

AP 方案部署方式可以参考图 5，一个业务方在图数据库平台上创建了 1 个应用并部

署了 4 个集群，其中北京 2 个、上海 2 个，平时这 4 个集群同时对外提供服务。假如现在北京集群 1 挂了，那么北京集群 2 可以提供服务。如果说真那么不巧，北京集群都挂了，或者北京侧对外的网络不可用，那么上海的集群也可以提供服务。在这种部署方式下，平台会尽可能地通过一些方式来保证整个应用的可用性。然后每个集群内部尽量部署同机房的机器，因为图数据库集群内部 RPC 非常多，如果有跨机房或者跨区域的频繁调用，整个集群对外的性能会比较低。

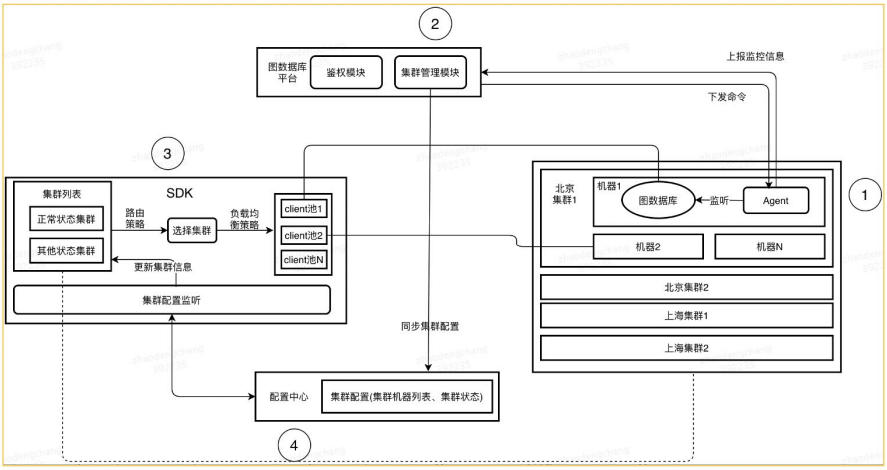

图 6

高可用模块主要包含下面 4 个部分，如上图 6 所示：

第一部分是右侧的图数据库 Agent，它是部署在图数据库集群的一个进程，用来收集机器和图数据库三个核心模块的信息，并上报到图数据库平台。Agent 能够接收图数据库平台的命令并对图数据库进行操作。

第二部分是图数据库平台，它主要是对集群进行管理，并同步图数据库集群的状态到配置中心。

第三部分是图数据库 SDK，主要负责管理连接到图数据库集群的连接。如果业务方发送了某个查询请求，SDK 会进行集群的路由和负载均衡，选择出一条高质量的连接来发送请求。此外，SDK 还会处理图数据库集群中问题机器的自动降级以及恢复，

并且支持平滑切换集群的数据版本。

第四部分是配置中心，类似 ZooKeeper，存储集群的当前状态。

4.2 每小时百亿量级数据导入模块设计

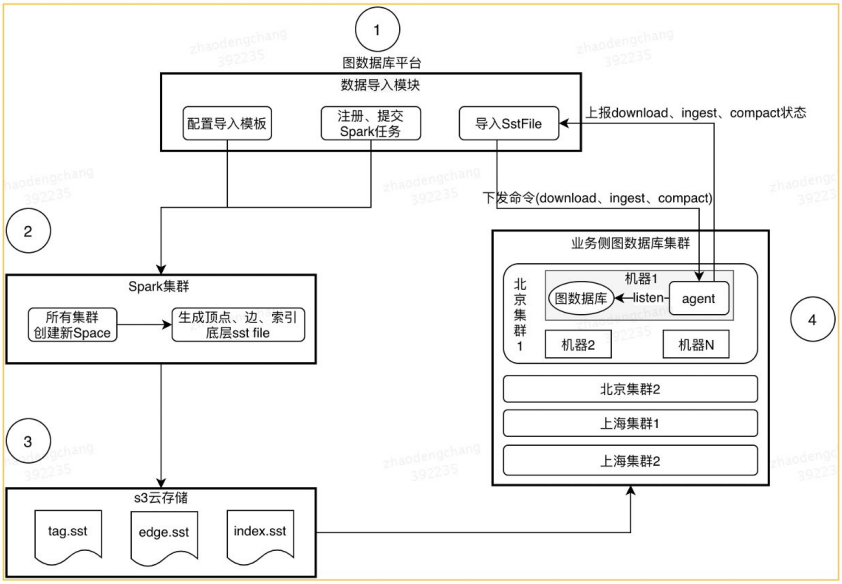

图 7

第二个模块是每小时百亿量级数据导入模块，平台在 2019 年底 – 2020 年初全量导入数据的方式是调用 NebulaGraph 对外提供的批量数据导入接口，这种方式的数据写入速率大概是每小时 10 亿级别，导入百亿数据大概要耗费 10 个小时，耗时较长。此外，在以几十万每秒的速度导数据的过程中，会长期占用机器的 CPU、IO 资源，一方面会对机器造成损耗，另一方面数据导入过程中集群对外提供的读性能会变弱。

为了解决上面两个问题，平台进行了如下优化：在 Spark 集群中直接生成图数据库底层文件 SST File，再借助 RocksDB 的 Bulkload 功能直接 ingest 文件到图数据库。

数据导入的核心流程可以参考图 7，当用户执行导数据操作后，图数据库平台会向公司的 Spark 集群提交一个 Spark 任务，在 Spark 任务中会生成图数据库里相关的点、边以及点索引、边索引相关的 SST 文件，并上传到美团的 S3 云存储上。文件

生成后，图数据库平台会通知应用中多个集群去下载这些存储文件，之后完成 ingest 跟 compact 操作，最后完成数据版本的切换。

为兼顾各个业务方的不同需求，平台统一了应用导入、集群导入、离线导入、在线导入，以及全量导入、增量导入这些场景，然后细分成下面九个阶段，从流程上保证在导数据过程中应用整体的可用性：SST File 生成 、SST File 下载 、ingest、compact、数据校验、增量回溯、数据版本切换、集群重启、数据预热。

4.3 实时写入多集群数据同步模块设计

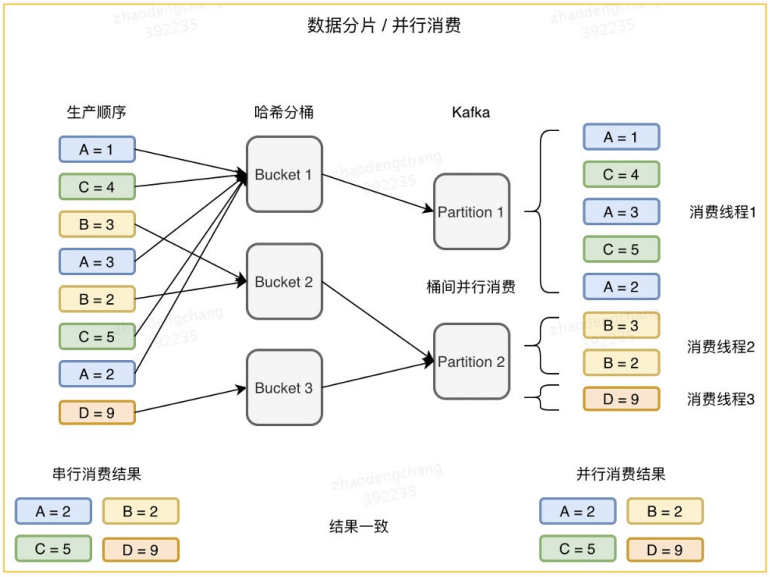

图 8

第三个模块是实时写入多集群数据同步模块，平台约有 15% 的需求场景是在实时读取数据时，还要把新产生的业务数据实时写入集群，并且对数据的读写强一致性要求不高。就是说，业务方写到图数据库里的数据，不需要立马能读到。针对上述场景，业务方在使用单应用多集群这种部署方案时，多集群里的数据需要保证最终一致性。针对这一需求，我们做了以下设计。

第一部分是引入 Kafka 组件，业务方在服务中通过 SDK 对图数据库进行写操作时，

SDK 并不直接写图数据库，而是把写操作写到 Kafka 队列里，之后由该应用下的多个集群异步消费这个 Kafka 队列。

第二部分是集群在应用级别可配置消费并发度，来控制数据写入集群的速度。具体流程如下：

- SDK 对用户写操作语句做语法解析，将其中点边的批量操作拆解成单个点边操作，即对写语句做一次改写。
- Agent 消费 Kafka 时确保每个点及其出边相关操作在单个线程里顺序执行（见图 8），保证这点就能保证各个集群执行完写操作后最终的结果是一致的。
- 并发扩展：通过改变 Kafka 分片数、Agent 中消费 Kafka 线程数来调整 Kafka 中操作的消费速度。如果未来图数据库支持事务的话，上面的配置需要调整成单分片单线程消费，有必要对设计方案再做优化调整。

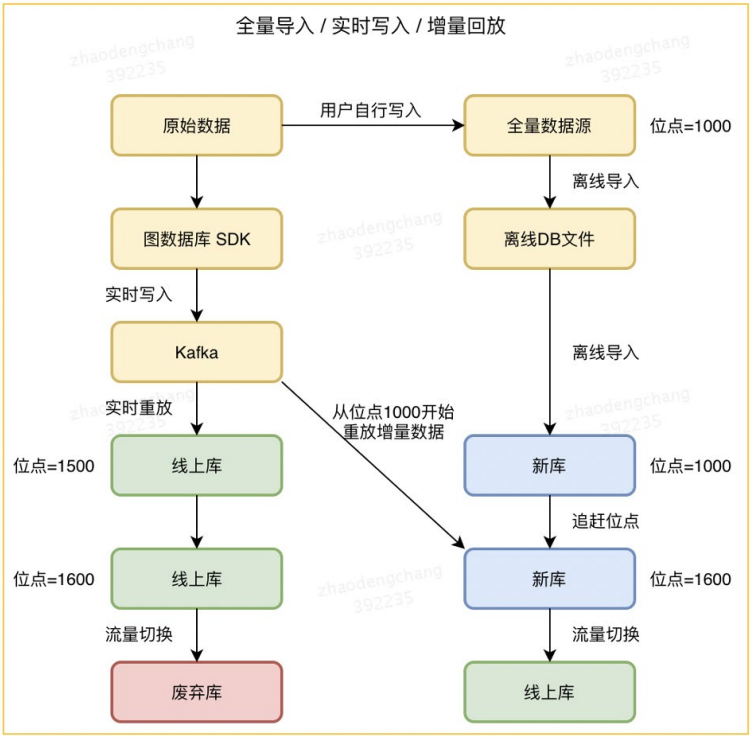

图 9

第三部分是在实时写入数据过程中，平台可以同步生成一个全量数据版本，并做平滑切换（见图 9），确保数据的不重、不漏、不延迟。

4.4 图可视化模块设计

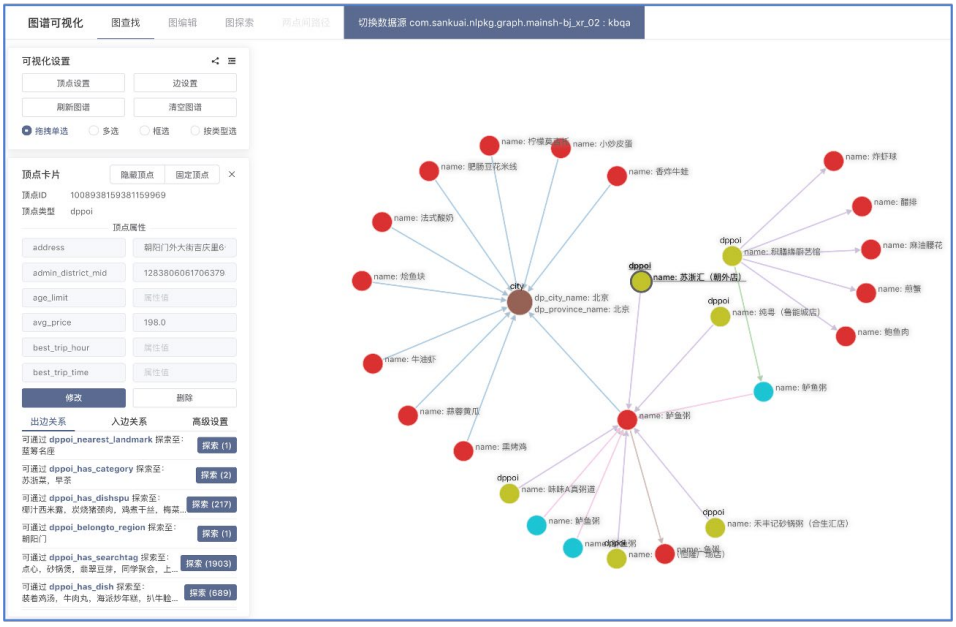

图 10

第四个模块是图可视化模块（见图 10），主要是用于解决子图探索问题。当用户在图数据库平台通过可视化组件查看图数据时，能尽量通过恰当的交互设计来避免因为节点过多而引发爆屏。主要包括以下几个功能：

- 通过 ID 或者索引查找顶点。
- 能查看顶点和边的卡片（卡片中展示点边属性和属性值），可以单选、多选、框选以及按类型选择顶点。
- 图探索，当用户点击某个顶点时，系统会展示它的一跳邻居信息，包括该顶点有哪些出边？通过这个边它能关联到几个点？该顶点的入边又是什么情况？通过这种一跳信息的展示，用户在平台上探索子图的时候，可快速了解到周边的

邻居信息，更快地进行子图探索。在探索过程中，平台也支持通过属性对边进行过滤。

- 图编辑能力，让平台用户在不熟悉 NebulaGraph 语法的情况下也能增删改点边数据，对线上数据进行临时干预。

5. 业务实践

5.1 智能助理

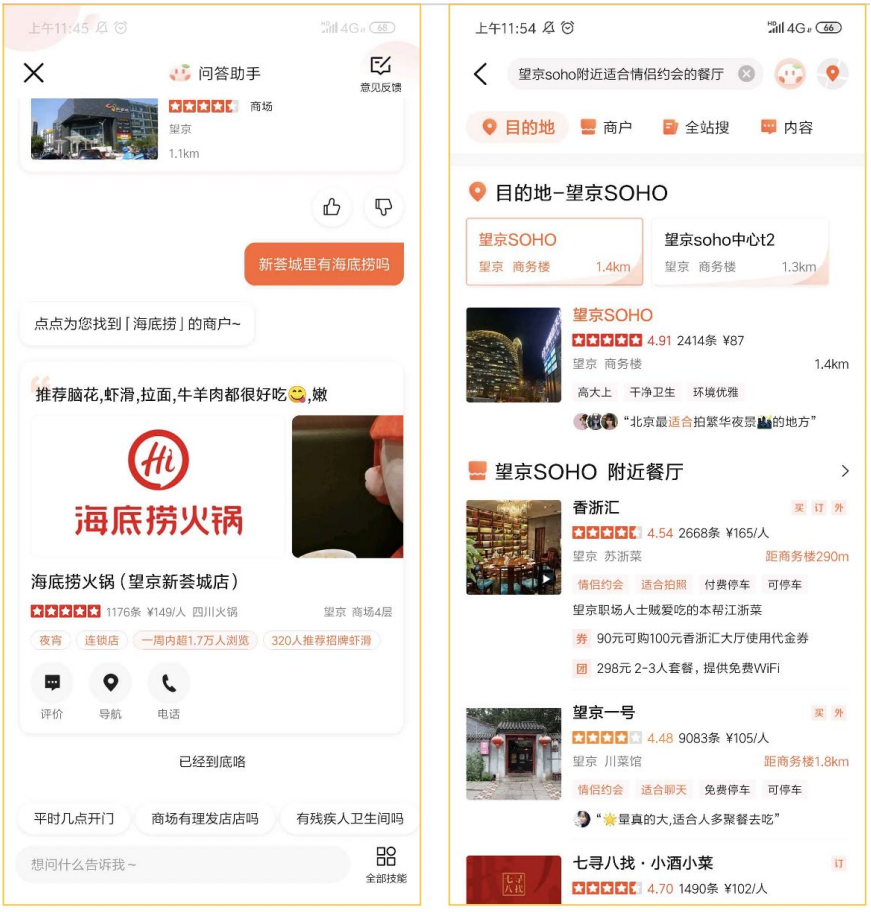

该项目数据是基于美团商户数据、用户评论构建的餐饮娱乐知识图谱，覆盖美食、酒店、旅游等领域，包含 13 类实体和 22 类关系。目前，点边数量大概在百亿级别，

数据 T+1 全量更新，主要用于解决搜索或者智能助理里 KBQA（全称：Knowledge Based Question Answer）类问题。核心处理流程是通过 NLP 算法识别关系和实体后构造出 NebulaGraph SQL 语句，再到图数据库获取数据。

典型的应用场景包括商场找店，比如，某个用户想知道望京新荟城这个商场有没有海底捞，系统可以快速查出结果告诉用户；另一个场景是标签找店，用户想知道望京 SOHO 附近有没有适合情侣约会的餐厅，或者可以多加几个场景标签，系统都可以帮忙查找出来。

5.2 搜索召回

该项目数据是基于医美商家信息构建的医美知识图谱，包含 9 类实体和 13 类关系，点边数量在百万级别，同样也是 T+1 全量更新，主要用于大搜底层实时召回，返回与 Query 相关的商户、产品或医生信息，解决医美类搜索词少结果、无结果问题。比如，某个用户搜“啤酒肚”这种症状、或者“润百颜”这类品牌，系统可以召回相关的医美门店。

5.3 图谱推荐理由

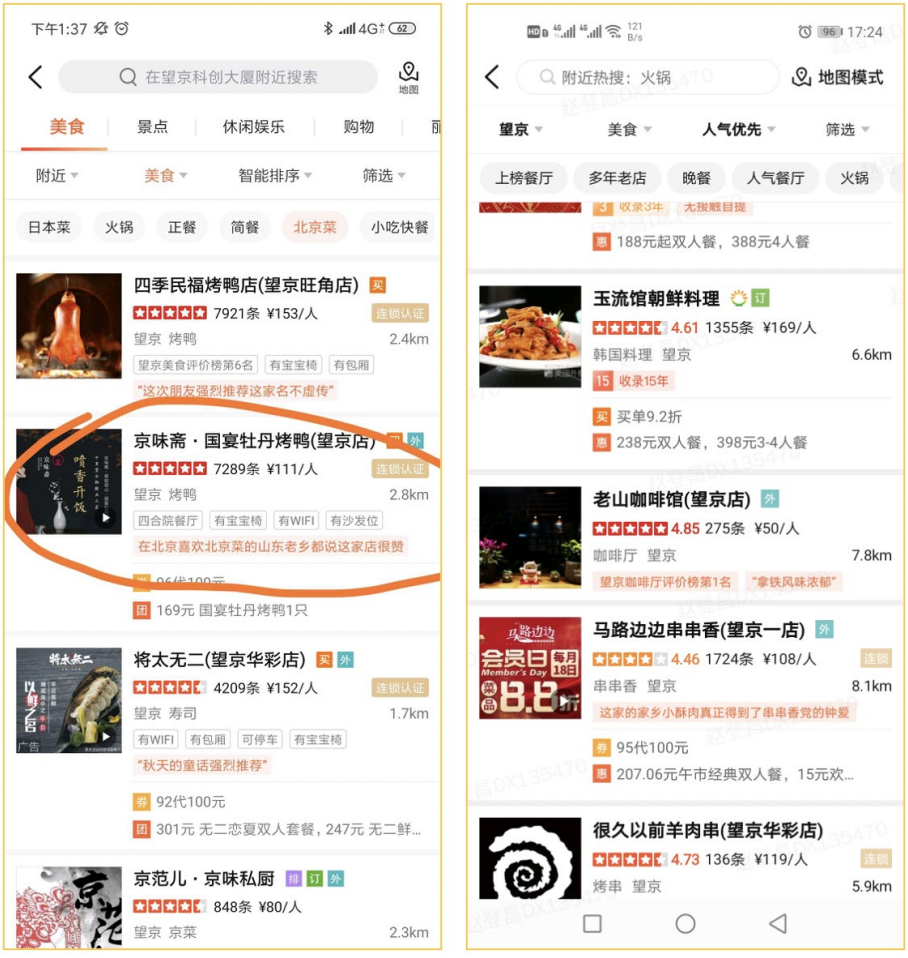

该项目数据来自用户的画像信息、商户的特征信息、用户半年内收藏 / 购买行为，数据量级是 10 亿级别，T+1 全量更新。现在美团 App 和点评 App 上默认的商户推荐列

表是由深度学习模型生成的，但模型并不会给出生成这个列表的理由，缺少可解释性。

而在图谱里用户跟商户之间天然存在多条连通路径，项目考虑选出一条合适路径来生成推荐理由，在 App 界面上展示给用户推荐某家店的原因。该项目基于用户的协同过滤算法来生成推荐理由，在家乡、消费水平、偏好类目、偏好菜系等多个组合维度中找出多条路径，然后给这些路径打分，选出一条分值较高的路径，之后按照特定 Pattern 产出推荐理由。通过上述方式，就可以获得“在北京喜欢北京菜的山东老乡都说这家店很赞”，或者“广州老乡都中意他家的正宗北京炸酱面”这类理由。

5.4 代码依赖分析

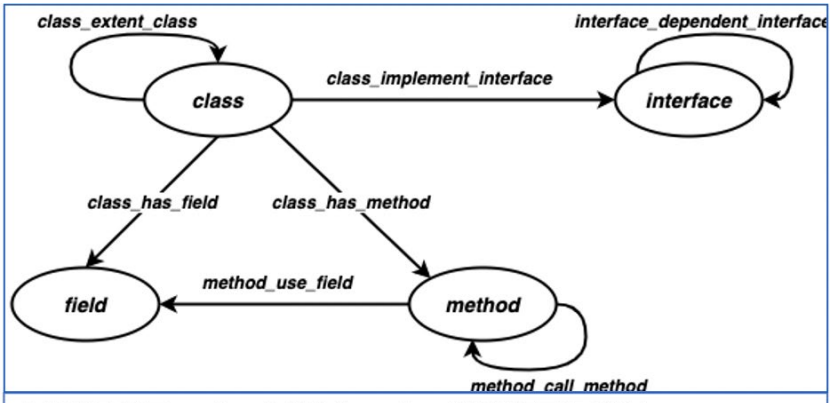

//查找最外层method到某个method的所有无环路径

```
(GO 1 to 30 STEPS FROM 2946345526231222882 OVER
method_call_method REVERSELY YIELD DISTINCT
method_call_method._dst AS id
MINUS
GO 1 to 30 STEPS FROM 2946345526231222882 OVER
method_call_method REVERSELY YIELD DISTINCT
method_call_method._src as id )
| FIND NOLOOP path FROM $-.id TO
2946345526231222882 OVER method_call_method UPTO
30 STEPS
```

//确认两个method间是否有路径

```
FIND SINGLE SHORTEST PATH FROM hash("method1")
TO hash("method2") OVER method_call_method UPTO
30 STEPS
```

该项目把代码库中代码依赖关系写入到图数据库。代码库中存在很多服务代码，这些服务会包括对外提供的接口，这些接口的实现依赖于该服务中某些类的成员函数，这些类的成员函数又依赖了本类的成员变量、成员函数或者其它类的成员函数，那么它们之间的依赖关系就形成了一张图，可以把这个图写到图数据库里做代码依赖分析。

典型应用场景是精准测试：当开发同学完成需求并向公司的代码仓库提交了 PR 后，可以把更改实时地写到图数据库中。这样的话，开发同学就能查到他所写的代码影响了哪些外部接口，并且借助图可视化组件查看调用路径。如果开发同学本来是要改接口 A 的行为，改了很多代码，但是他可能并不知道他改的代码也会影响到对外接口 B、C、D，这时候就可以用代码依赖分析来做个 Check，增加测试的完备性。

6. 总结与展望

目前，图数据库平台基本具备了对图数据的一站式自助管理功能。如果某个业务方要使用这种图数据库能力，那么业务方可以在平台上自助地创建图数据库集群、创建图的 Schema、导入图数据、配置导入数据的执行计划、引入平台提供的 SDK 对数据进行操作等等。平台侧主要负责各业务方图数据库集群的稳定性。目前，美团有三四十个业务已经在平台上落地，基本满足了各个业务方的需求。

未来规划主要有两个方向，第一，根据业务场景优化图数据库内核，提升平台稳定性，开发的通用 Feature 持续反哺 NebulaGraph 社区。第二，挖掘更多的图数据价值。现在平台仅支持图数据存储及多跳查询这种基本能力，后续将基于 NebulaGraph 去探索图学习、图计算的能力，为平台用户提供更多挖掘图数据价值的功能。

7. 作者信息

登昌、梁帅、高辰、杨鑫、尊远、王超等，均为美团搜索与 NLP 部工程师。

8. 招聘信息

如果你对“图存储”、“图学习”、“图计算”感兴趣，欢迎给我们投递简历，投递邮箱：zhaodengchang@meituan.com。

9. 参考资料

[1] Jim Webber, Emil Eifrem, Ian Robinson. Graph Databases(2nd Edition). O'Reilly Media, Inc. 2013: chapter 2.
[2] Neo4j Database, https://github.com/neo4j/neo4j.
[3] ArangoDB, https://github.com/arangodb/arangodb.
[4] Virtuoso, https://github.com/openlink/virtuoso-opensource.
[5] TigerGraph, https://github.com/tigergraph/ecosys.
[6] RedisGraph, https://github.com/RedisGraph/RedisGraph.
[7] JanusGraph, https://github.com/JanusGraph/janusgraph.
[8] HugeGraph, https://github.com/hugegraph/hugegraph.
[9] DGraph, https://github.com/dgraph-io/dgraph.
[10] NebulaGraph, [https://github.com/vesoft-inc/nebula.
[11] RDF, https://www.w3.org/RDF/](https://github.com/vesoft-inc/nebula.
[11] RDF, https://www.w3.org/RDF/).
[12] BadgerDB, https://github.com/dgraph-io/badger.
[13] RocksDB, https://github.com/facebook/rocksdb.
[14] LDBC-SNB 数据集：关联数据基准委员会提供的评测数据集，包含 26 亿顶点、177 亿关系 .
[15] NebulaGraph Architecture — A Bird's View, https://nebula-graph.io/posts/nebula-graph-architecture-overview/.
[16] An Introduction to NebulaGraph's Storage Engine.

OCTO 2.0：美团基于 Service Mesh 的服务治理系统详解

作者：舒超、世朋、来俊

OCTO 是美团内部的服务治理平台，包含服务通信框架、命名服务、服务数据中心和用户管理平台等组件，为公司内全部服务提供了整套的服务治理方案和统一的服务治理体验。我们在之前的几篇文章中分别从不同的角度介绍了 OCTO 平台的建设情况。包括：

- 《美团命名服务的挑战与演进》介绍了美团命名服务（MNS）从 1.0 到 2.0 演进的初衷、实现方案以及落地的效果，并介绍了命名服务作为一个技术中台组件，对业务的重要价值以及推动业务升级的一些成果。
- 《美团 OCTO 万亿级数据中心计算引擎技术解析》介绍了美团自研的 OCTO 数据中心计算引擎的演进历程及架构设计，同时详细地介绍其全面提升计算能力、吞吐能力、降低运维成本所采用的各项技术方案。
- 《团大规模微服务通信框架及治理体系 OCTO 核心组件开源》介绍了 OCTO 的核心组件 OCTO-RPC（JAVA 通信框架）、OCTO-NS（命名服务）和 OCTO-Portal（用户管理平台）的开源情况。
- 《复杂环境下落地 Service Mesh 的挑战与实践》从更高的视角介绍了美团当前的服务治理系统的发展史、所面临的困境和优化思路。对 Service Mesh 在美团大规模复杂服务场景下的落地做了深入的分析。

本文将继续介绍 OCTO 系统在 Service Mesh 化演进方面的工作。主要从数据面的角度，详细介绍各项技术方案的设计思路。

1. 整体架构

我们先看看 OCTO 2.0 的整体架构，如下图所示：

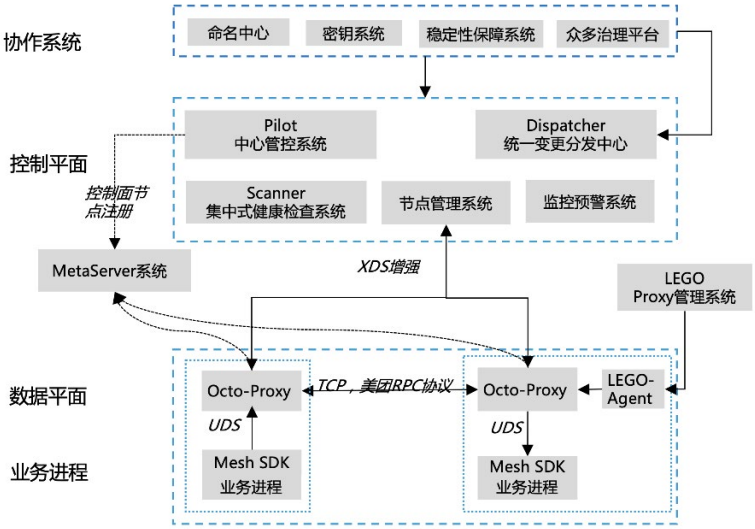

图 1　整体架构四个组成部分：基础设施、控制平面、数据平面和运维系统

基础设施是指美团现有的服务治理系统 OCTO1.0，包括 MNS、KMS（鉴权管理服务）、MCC（配置管理中心）、Rhino（熔断限流服务）等。这些系统接入到 OCTO 2.0 的控制平面，避免过多重构引入的不必要成本。

OCTO 2.0 控制平面摒弃了社区的 Istio，完全自研。数据平面基于开源 Envoy 改造。运维系统负责数据面组件的升级、发布等运维工作。更多的整体选型及原因可参考之前团队的文章：《美团下一代服务治理系统 OCTO2.0 的探索与实践》。

对 OCTO 2.0 中的功能，我们分为 Mesh 和服务治理两个维度。下面我们来重点看下流量劫持、无损重启、服务路由等几个常见的问题，并阐述美团是如何结合现有比较完善的服务治理系统来解决这些问题的。

2. Mesh 功能

2.1 流量劫持

OCTO 2.0 并未采用 Istio 的原生方案，而是使用 iptables 对进出 POD 的流量进行劫持。主要考量了以下两个因素：

- iptables 自身存在性能损失大、管控性差的问题：
  - iptables 在内核对于包的处理过程中定义了五个“hook point”，每个“hook point”各对应到一组规则链，outbond 流量将两次穿越协议栈并且经过这 5 组规则链匹配，在大并发场景下会损失转发性能。
  - iptables 全局生效，不能显式地禁止相关规则的修改，没有相关 ACL 机制，可管控性比较差。
- 在美团现有的环境下，使用 iptables 存在以下几个问题：
  - HULK 容器为富容器形态，业务进程和其他所有基础组件都处于同一容器中，这些组件使用了各种各样的端口，使用 iptables 容易造成误拦截。
  - 美团现在存在物理机、虚拟机、容器等多个业务运行场景，基于 iptables 的流量劫持方案在适配这些场景时复杂度较高。

鉴于上述问题，我们最终采用了 Unix Domain Socket 直连方式来实现业务进程和 OCTO-Proxy 之间的流量转发。

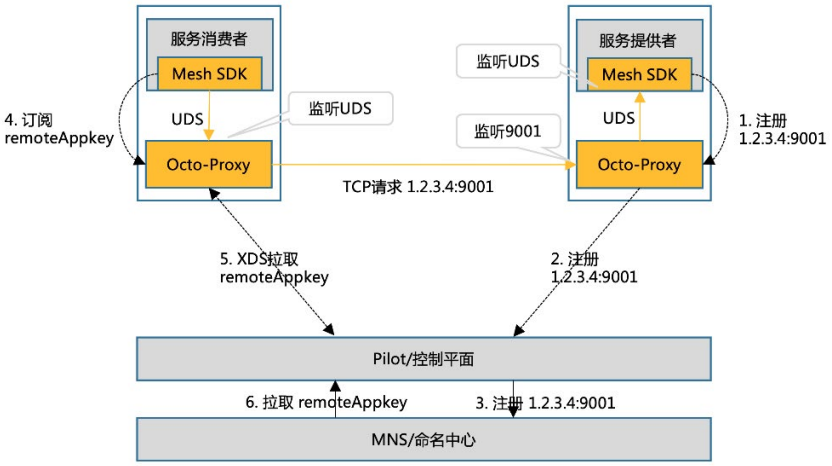

图 2　Unix Domain Socket 直连流量转发

在服务消费者一方，业务进程通过轻量的 Mesh SDK 和 OCTO-Proxy 所监听的 UDS 地址建立连接。在服务提供者一方，OCTO-Proxy 代替业务进程监听在 TCP 端口上，业务进程则监听在指定的 UDS 地址上。

该方案的优点是 Unix Domain Socket 相比于 iptable 劫持拥有更好的性能和更低的运维成本。缺点是需要 Mesh SDK 的支持。

2.2 服务订阅

原生 Envoy 的 CDS/EDS 请求是全量服务发现模式，即将系统中所有的服务列表都请求到数据面中。由于大规模集群中服务数量太多，真正所需的只是少数服务，所以需要改造成按需服务发现模式，仅请求需要访问的后端服务的节点列表。

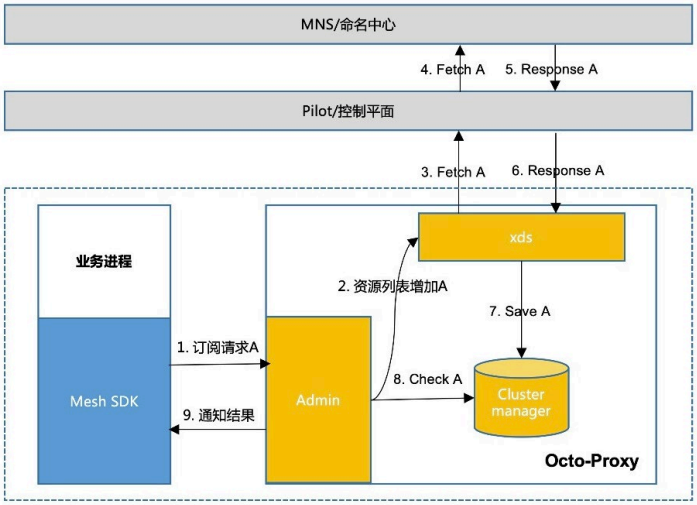

图 3　服务订阅流程

在业务进程启动后，需要通过 HTTP 的方式向 OCTO-Proxy 发起订阅请求。OCTO-Proxy 将所请求的后端服务 Appkey 更新到 XDS 中，XDS 再向控制面请求特定的服务资源。

为了增加整个过程中的健壮性，降低后续运维成本，我们做了部分适配。例如，OCTO-Proxy 的启动速度有可能慢于业务进程，所以在 Mesh SDK 中增加了请求的重试逻辑；将 Mesh SDK 和 OCTO-Proxy 之间的 http 请求改造成了同步请求，防止 Pilot 资源下发延时带来的问题；Mesh SDK 的订阅信息也会保存在本地文件中，以便 OCTO-Proxy 热重启或者故障重启时使用。

2.3 无损热重启

2.3.1 流量损失场景

如何在基础组件升级过程中提供持续、不间断的服务，做到业务流量无损及业务无感知，是所有基础组件面临的一大难题。这个问题对于 OCTO-Proxy 这种处于流量核心链路上的组件更加重要。社区原生的 Envoy 自身已经支持了热重启功能但并不彻底，在某些场景下还是不能做到完全的流量无损。

下图分别在短连接和长连接两种场景下来说明 OCTO-Proxy 热重启时的流量损耗问题。

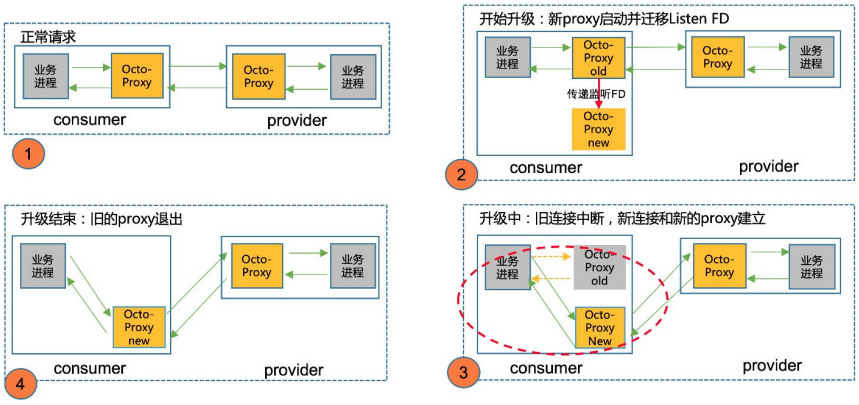

图 4　代理升级过程中流量损耗

对于短连接，所有新的连接会在新的 OCTO-Proxy 上创建，旧 OCTO-Proxy 上已有的连接在响应到来后主动断开。旧 OCTO-Proxy 的所有短连接逐渐断开，这就是“Drain”（排空）的过程。连接排空之后，旧 OCTO-Proxy 主动退出，新的 OCTO-Proxy 继续工作。整个过程中的流量，完全无损。

对于长连接方式，SDK 和旧 OCTO-Proxy 维持一条长连接不断开，并持续使用该连接发送请求。旧 OCTO-Proxy 进程最终退出时，该连接被动断开，此时可能尚有部分响应未返回，导致 Client 端请求超时。因此，Envoy 的热重启对长连接场景的支持并不完美。

为了支持基础组件在升级过程中提供不间断的服务，业界目前主要使用的是滚动发布（Rolling Update）的方式：服务器分批停止服务，执行更新，然后重新将其投入使用，直到集群中所有实例都更新为新版本。在此过程中会主动摘掉业务流量，保证升级过程中业务流量不丢失。

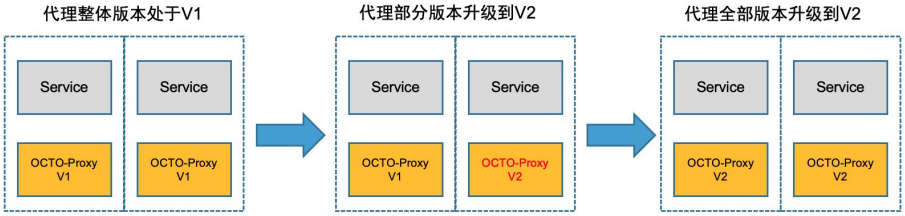

图 5　滚动升级

美团内部因为要兼容物理机、虚拟机、容器，业界云原生使用 K8s 滚动升级的方式不太适用，所以在现有环境下，如何保证服务治理系统的高可用性以及业务的高可靠性是一个非常棘手的事情。

2.3.2 适配方案

当前方案是把业务服务分为两种角色，即对外提供服务的 Server 端角色和对外发起请求的 Client 端角色，针对两种不同的角色采用不同的热更新支持。

Client 端 OCTO-Proxy 热更新：老的 OCTO-Proxy 在进入热重启状态后，对后续“新请求”直接返回含“热重启”标志的响应协议，Client SDK 在收到含“热重启”标志的响应协议时，应主动切换新连接并请求重试（以避免当前 Client SDK 持有的旧连接由于旧 OCTO-Proxy 热重启流程完成后被主动关闭的问题）。这里需要注意，Client SDK 需要“妥善”处理旧连接所在链路上遗留的所有“应答”协议。

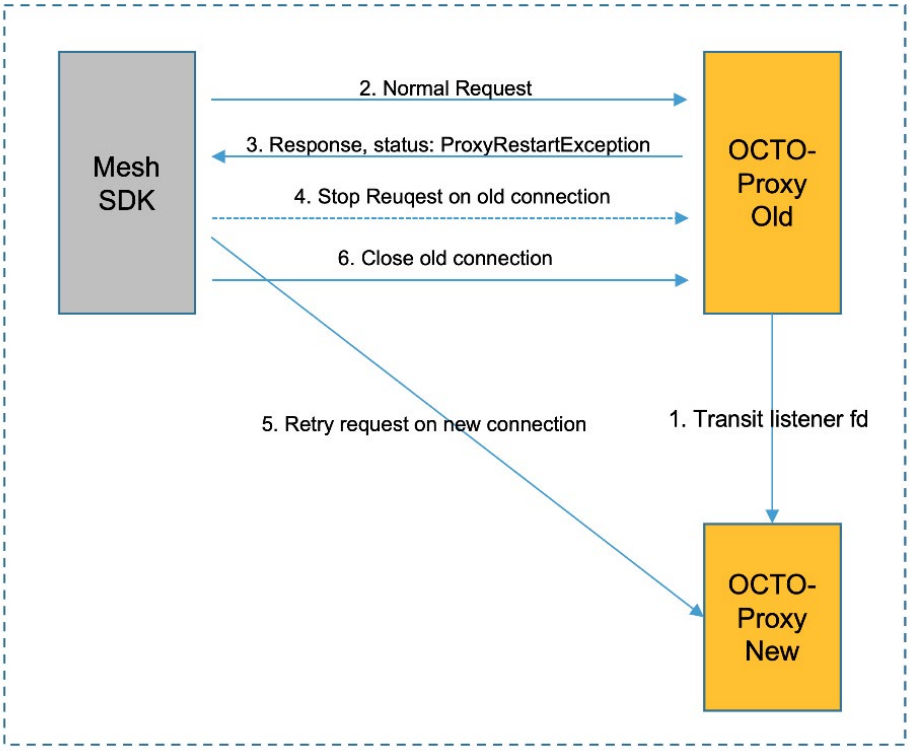

图 6　客户端 SDK/ 代理相互配合进行热升级

通过这种 Client SDK 和 OCTO-Proxy 间的交互配合，可以支持 Client 端在 OCTO-Proxy 升级过程中保证流量的安全性。

Server 端 OCTO-Proxy 热更新：Server 侧 OCTO-Proxy 在热重启开始后，即会主动向 Client 侧 OCTO-Proxy 发送 ProxyRestart 消息，通知 Client 侧 OCTO-Proxy 主动切换新连接，避免当前 Client 侧 OCTO-Proxy 持有的旧连接由于 Server 侧旧 OCTO-Proxy 热重启流程完成后被强制关闭的问题。Client 端 OCTO-Proxy 在收到“主动切换新连接”的请求后，应即时从可用连接池中移除，并“妥善”处理旧连接所在链路上遗留的所有“应答”协议（保守起见可标记连接不可用，并维持一段时间，比如 OCTO-Proxy 默认 drainTime）。

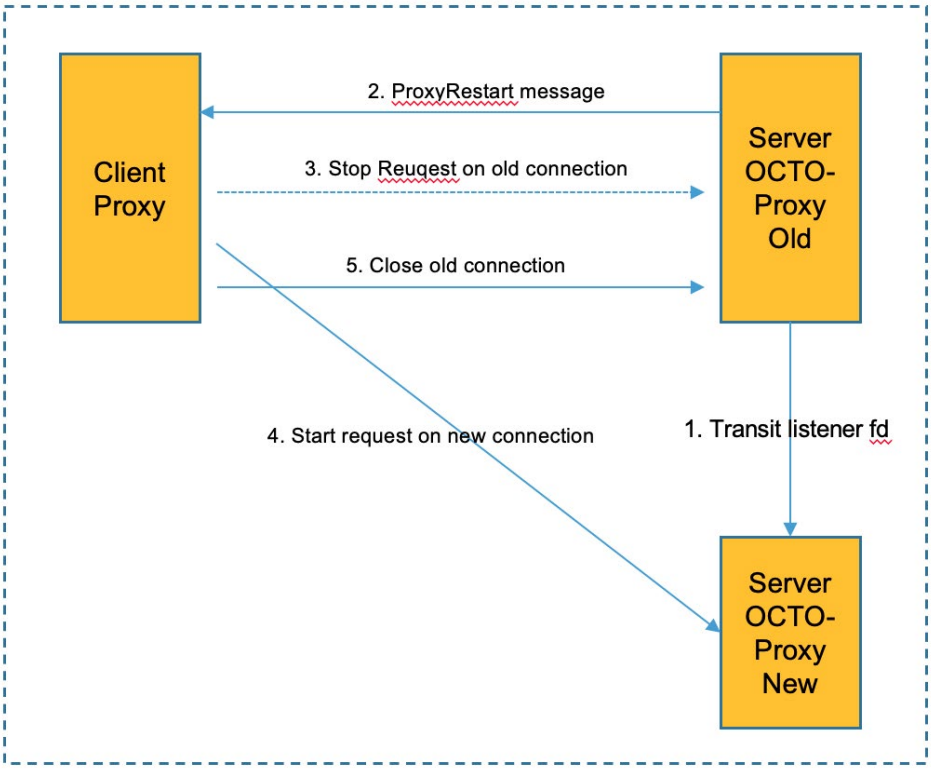

图 7　服务端反向主动通知客户端重连

2.4 数据面运维

2.4.1 LEGO 运维方案

云原生环境中，Envoy 运行在标准的 K8S Pod 中，通常会独立出一个 Sidecar 容器。可以使用 K8s 提供的能力来完成对 Envoy Sidecar 容器的管理，例如容器注入、健康检查、滚动升级、资源限制等。

美团内部所使用的容器运行时模式为“单容器模式”，即一个 Pod 内只包含一个容器（不考虑 Pause 容器）。由于业务进程以及所有的基础组件都运行在一个容器中，所以只能采用进程粒度的管理措施，无法做到容器粒度的管理。我们通过自研的 LEGO 平台解决了 OCTO-Proxy 的运维问题。

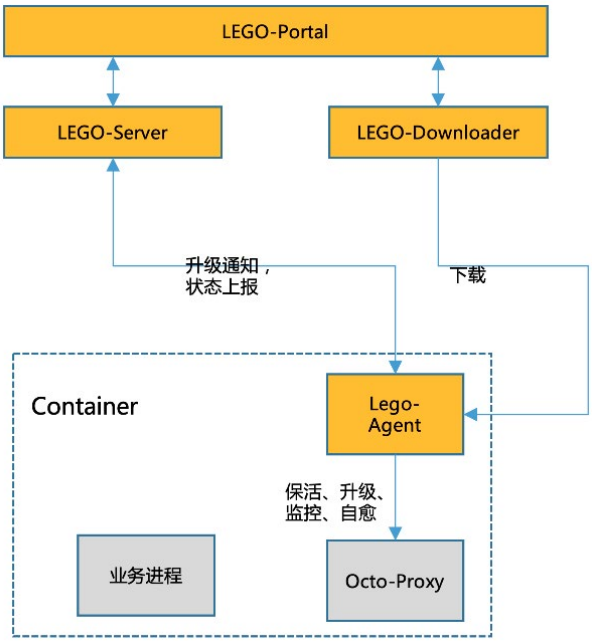

图 8　LEGO 数据面管理系统

我们对 LEGO-Agent 做了定制化改造，增加了对 OCTO-Proxy 的热重启过程的支持。另外，LEGO-Agent 还负责对 OCTO-Proxy 的健康检查、故障状态重启、监控信息上报和版本发布等。相对于原生 K8S 的容器重启方式，进程粒度重启会有更快的速度。

LEGO 系统的另一个优点是，可以同时支持容器、虚拟机和物理机等多种运行时环境。

2.4.2 云原生运维方案

目前，我们也正在探索 OCTO-Proxy 云原生的运维方案，在此场景下最大的区别就是从进程粒度运维转变为了容器粒度运维，与业务应用做到了更好的解耦，同时可享受不可变基础设施等理念带来的红利，但是此场景带来的一个问题就是如何管理容器粒度的热重启。

为此，我们通过自研的 Operator 对 OCTO-Proxy 容器进行全生命周期的运维管

理，并且期望通过 Operator 对 OCTO-Proxy 进行热重启，具体流程如下：

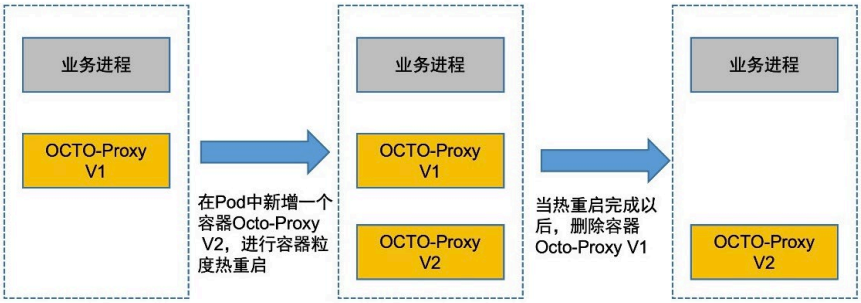

图 9　期望的 OCTO-Proxy 容器热重启流程

但是在实施过程中这个方案是有问题的，原因是 K8s 在底层设计上是不支持对运行中的 Pod 进行容器的增删操作，如果需要实现该方案，将需要对 K8s 底层组件进行定制化修改，这样将带来一定风险以及与社区的不兼容性。为了保证与社区的兼容性，我们对此热重启方案进行改造，最终使用双容器驻留热重启方案：

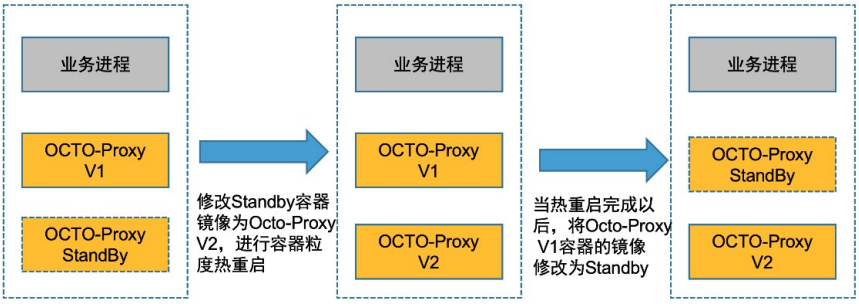

图 10　双容器驻留热重启方案

- 首先，我们在启动 Pod 时，给 OCTO-Proxy 不再只分配一个容器，而是分配两个容器，其中一个容器为正常运行状态，另一个容器为 standby 状态。
- 当需要对 OCTO-Proxy 进行热重启升级时，我们修改 standby 容器的镜像为最新 OCTO-Proxy 的镜像，此时开始热重启流程。
- 当热重启流程结束后，新容器进入正常工作状态，而旧容器进入等待状态，最终，我们将旧容器的镜像修改为 standby 镜像，结束整个热重启流程。

该方案利用一开始就驻留双容器在 Pod 内，避免了 K8s 对运行中 Pod 不能增删容器的限制，实现了在 Pod 中对 OCTO-Proxy 进行容器粒度的热重启。

3. 未来规划

目前接入 OCTO2.0 系统的服务数量数千，天粒度流量数十亿。随着 OCTO2.0 在公司的不断推广，越来越多的服务开始接入，对我们的稳定性和运维能力提出了更高的要求。如何更细致的了解线上 OCTO-Proxy 以及所称在的业务系统的健康状况、如何在出现故障时能更及时的监测到并快速恢复是我们最近 OCTO2.0 系统建设的重点。除此之外，未来 OCTO2.0 的规划重点还包括：

- 运维、发布和稳定性建设朝云原生化方向探索。
- 支持公司内部 Http 服务的 Mesh 化，降低对中心化网关的依赖。
- 全链路 mTLS 支持。

作者简介

舒超、世朋、来俊，均来自美团基础架构部基础开发组，从事 OCTO2.0 的开发工作。

团队简介

美团基础技术部 – 中间件研发中心 – 基础开发组，致力于研发公司级、业界领先的基础架构组件，研发范围涵盖分布式框架、命名服务、Service Mesh 等技术领域。欢迎感兴趣的同学发送简历至：edp.itu.zhaopin@meituan.com。

GraphQL 及元数据驱动架构在后端 BFF 中的实践

作者：陆晨　致远　陈琦

1. BFF 的由来

BFF 一词来自 Sam Newman 的一篇博文《Pattern:Backends For Frontends》，指的是服务于前端的后端。BFF 是解决什么问题的呢？据原文描述，随着移动互联网的兴起，原适应于桌面 Web 的服务端功能希望同时提供给移动 App 使用，而在这个过程中存在这样的问题：

- 移动 App 和桌面 Web 在 UI 部分存在差异。
- 移动 App 涉及不同的端，不仅有 iOS、还有 Android，这些不同端的 UI 之间存在差异。
- 原有后端功能和桌面 Web UI 之间已经存在了较大的耦合。

因为端的差异性存在，服务端的功能要针对端的差异进行适配和裁剪，而服务端的业务功能本身是相对单一的，这就产生了一个矛盾——服务端的单一业务功能和端的差异性诉求之间的矛盾。那么这个问题怎么解决呢？这也是文章的副标题所描述的”Single-purpose Edge Services for UIs and external parties”，引入 BFF，由 BFF 来针对多端差异做适配，这也是目前业界广泛使用的一种模式。

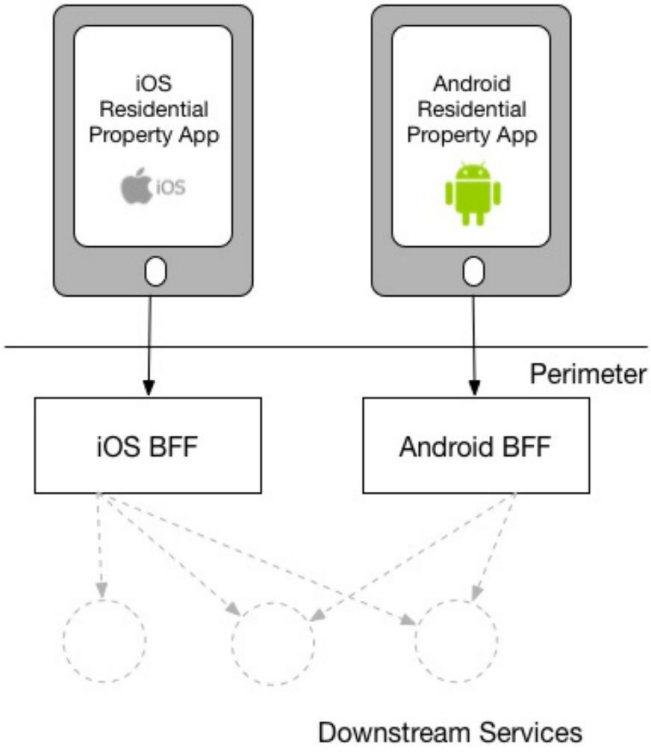

图 1　BFF 示意图

在实际业务的实践中，导致这种端差异性的原因有很多，有技术的原因，也有业务的原因。比如，用户的客户端是 Android 还是 iOS，是大屏还是小屏，是什么版本。再比如，业务属于哪个行业，产品形态是什么，功能投放在什么场景，面向的用户群体是谁等等。这些因素都会带来面向端的功能逻辑的差异性。

在这个问题上，笔者所在团队负责的商品展示业务有一定的发言权，同样的商品业务，在 C 端的展示功能逻辑，深刻受到商品类型、所在行业、交易形态、投放场所、面向群体等因素的影响。同时，面向消费者端的功能频繁迭代的属性，更是加剧并深化了这种矛盾，使其演化成了一种服务端单一稳定与端的差异灵活之间的矛盾，这也是商品展示（商品展示 BFF）业务系统存在的必然性原因。本文主要在美团到店商品展示场景的背景下，介绍面临的一些问题及解决思路。

2. BFF 背景下的核心矛盾

BFF 这层的引入是解决服务端单一稳定与端的差异灵活诉求之间的矛盾，这个矛盾并不是不存在，而是转移了。由原来后端和前端之间的矛盾转移成了 BFF 和前端之间的矛盾。笔者所在团队的主要工作，就是和这种矛盾作斗争。下面以具体的业务场景为例，结合当前的业务特点，说明在 BFF 的生产模式下，我们所面临的具体问题。下图是两个不同行业的团购货架展示模块，这两个模块我们认为是两个商品的展示场景，它们是两套独立定义的产品逻辑，并且会各自迭代。

图 2　展示场景

在业务发展初期，这样的场景不多。BFF 层系统“烟囱式”建设，功能快速开发上线满足业务的诉求，在这样的情况下，这种矛盾表现的不明显。而随着业务发展，行业的开拓，形成了许许多多这样的商品展示功能，矛盾逐渐加剧，主要表现在以下两个方面：

- 业务支撑效率：随着商品展示场景变得越来越多，API 呈爆炸趋势，业务支撑效率和人力成线性关系，系统能力难以支撑业务场景的规模化拓展。
- 系统复杂度高：核心功能持续迭代，内部逻辑充斥着 `if…else…`，代码过程式编写，系统复杂度较高，难以修改和维护。

那么这些问题是怎么产生的呢？这要结合“烟囱式”系统建设的背景和商品展示场景所面临的业务，以及系统特点来进行理解。

特点一：外部依赖多、场景间取数存在差异、用户体验要求高

图例展示了两个不同行业的团购货架模块，这样一个看似不大的模块，后端在 BFF 层要调用 20 个以上的下游服务才能把数据拿全，这是其一。在上面两个不同的场景中，需要的数据源集合存在差异，而且这种差异普遍存在，这是其二，比如足疗团购货架需要的某个数据源，在丽人团购货架上不需要，丽人团购货架需要的某个数据源，足疗团购货架不需要。尽管依赖下游服务多，同时还要保证 C 端的用户体验，这是其三。

这几个特点给技术带来了不小的难题：1）聚合大小难控制，聚合功能是分场景建设？还是统一建设？如果分场景建设，必然存在不同场景重复编写类似聚合逻辑的问题。如果统一建设，那么一个大而全的数据聚合中必然会存在无效的调用。2）聚合逻辑的复杂性控制问题，在这么多的数据源的情况下，不仅要考虑业务逻辑怎么写，还要考虑异步调用的编排，在代码复杂度未能良好控制的情况下，后续聚合的变更修改将会是一个难题。

特点二：展示逻辑多、场景之间存在差异，共性个性逻辑耦合

我们可以明显地识别某一类场景的逻辑是存在共性的，比如团单相关的展示场景。直观可以看出基本上都是展示团单维度的信息，但这只是表象。实际上在模块的生成过程中存在诸多的差异，比如以下两种差异：

- 字段拼接逻辑差异：比如以上图中两个团购货架的团购标题为例，同样是标题，在丽人团购货架中的展示规则是：**[类型] + 团购标题**，而在足疗团购货架的展示规则是：**团购标题**。
- 排序过滤逻辑差异：比如同样是团单列表，A 场景按照销量倒排序，B 场景按照价格排序，不同场景的排序逻辑不同。

诸如此类的**展示逻辑**的差异性还有很多。类似的场景实际上在内部存在很多差异的逻辑，后端如何应对这种差异性是一个难题，下面是最常见的一种写法，通过读取具体的条件字段来做判断实现逻辑路由，如下所示：

```
if(category == "丽人") {
  title = "[" + category + "]" + productTitle;
} else if (category == "足疗") {
  title = productTitle;
}
```

这种方案在功能实现方面没有问题，也能够复用共同的逻辑。但是实际上在场景非常多的情况下，将会有非常多的差异性判断逻辑叠加在一起，功能一直会被持续迭代的情况下，可以想象，系统将会变得越来越复杂，越来越难以修改和维护。

总结：在 BFF 这层，不同商品展示场景存在差异。在业务发展初期，系统通过独立建设的方式支持业务快速试错，在这种情况下，业务差异性带来的问题不明显。而随着业务的不断发展，需要搭建及运营的场景越来越多，呈规模化趋势。此时，业务对技术效率提出了更高的要求。**在这种场景多、场景间存在差异的背景下，如何满足场景拓展效率同时能够控制系统的复杂性，就是我们业务场景中面临的核心问题**。

3. BFF 应用模式分析

目前业界针对此类的解决方案主要有两种模式，一种是后端 BFF 模式，另一种是前端 BFF 模式。

3.1 后端 BFF 模式

后端 BFF 模式指的是 BFF 由后端同学负责，这种模式目前最广泛的实践是基于 GraphQL 搭建的后端 BFF 方案，具体是：后端将展示字段封装成展示服务，通过 GraphQL 编排之后暴露给前端使用。如下图所示：

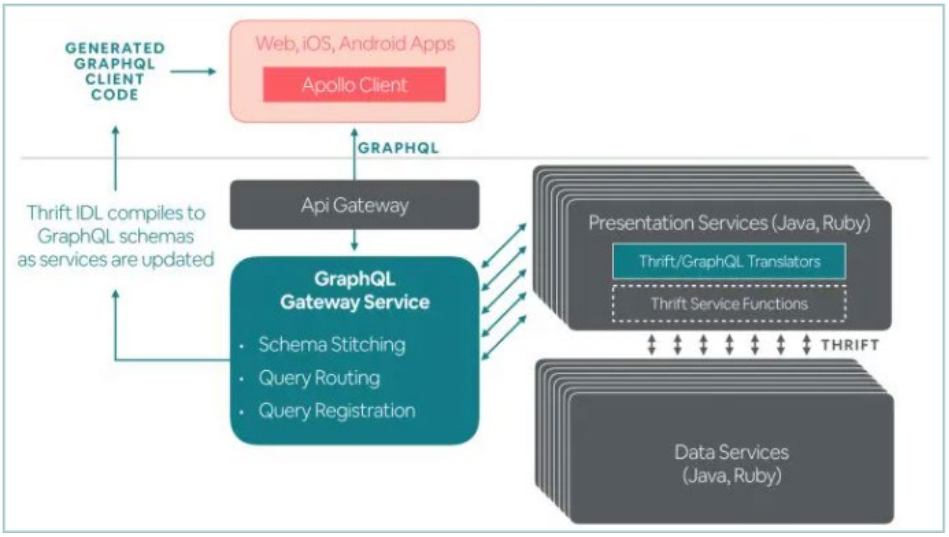

图 3　后端 BFF 模式

这种模式最大的特性和优势是，当展示字段已经存在的情况下，后端不需要关心前端差异性需求，按需查询的能力由 GraphQL 支持。这个特性可以很好地应对不同场景存在展示字段差异性这个问题，前端直接基于 GraphQL 按需查询数据即可，后端不需要变更。同时，借助 GraphQL 的编排和聚合查询能力，后端可以将逻辑分解在不同的展示服务中，因此在一定程度上能够化解 BFF 这层的复杂性。

但是基于这种模式，仍然存在几个问题：展示服务颗粒度问题、数据图划分问题以及字段扩散问题，下图是基于当前模式的具体案例：

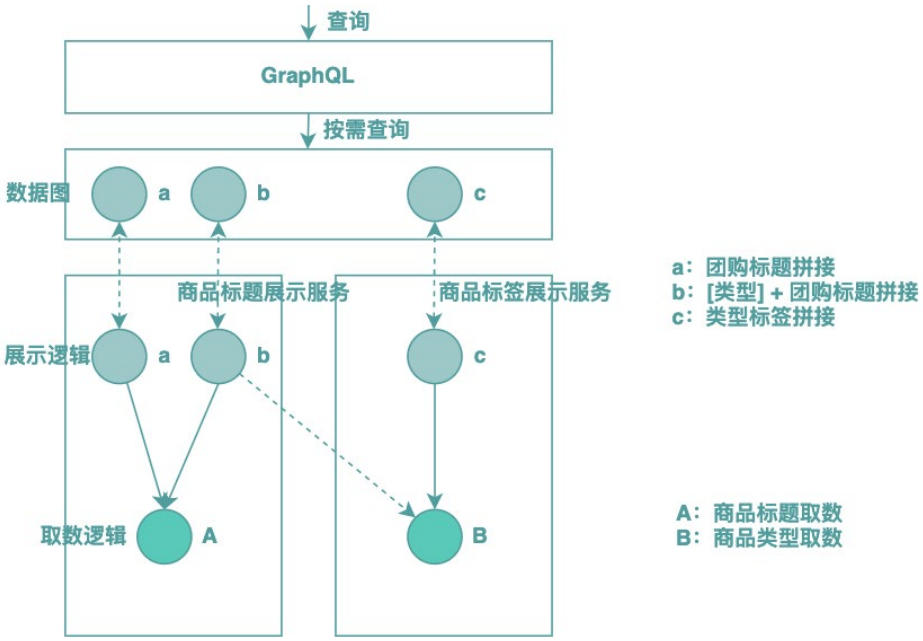

图 4　后端 BFF 模式（案例）

1）展示服务颗粒度设计问题

这种方案要求展示逻辑和取数逻辑封装在一个模块中，形成一个展示服务（Presentation Service），如上图所示。而实际上展示逻辑和取数逻辑是多对多的关系，还是以前文提到的例子说明：

> **背景**：有两个展示服务，分别封装了商品标题和商品标签的查询能力。**情景**：此时 PM 提了一个需求，希望商品在某个场景的标题以“[类型]+ 商品标题”的形式展示，此时商品标题的拼接依赖类型数据，而此时类型数据商品标签展示服务中已经调用了。**问题**：商品标题展示服务自己调用类型数据还是将两个展示服务合并到一起?

以上描述的问题的是展示服务颗粒度把控的问题，我们可以怀疑上述的示例是不是因为展示服务的颗粒度过小? 那么反过来看一看，如果将两个服务合并到一起，那么势必又会存在冗余。这是展示服务设计的难点，**核心原因在于，展示逻辑和取数逻辑本**

身是多对多的关系，结果却被设计放在了一起。

2）数据图划分问题

通过 GraphQL 将多个展示服务的数据聚合到一张图（GraphQL Schema）中，形成一个数据视图，需要数据的时候只要数据在图中，就可以基于 Query 按需查询。那么问题来了，这个图应该怎么组织？是一张图还是多张图？图过大的话，势必带来复杂的数据关系维护问题，图过小则将会降低方案本身的价值。

3）展示服务内部复杂性 + 模型扩散问题

上文提到过一个商品标题的展示存在不同拼接逻辑的情况，在商品展示场景，这种逻辑特别普遍。比如同样是价格，A 行业展示优惠后价格，B 行业展示优惠前价格；同样是标签位置，C 行业展示服务时长，而 D 行业展示商品特性等。那么问题来了，展示模型如何设计？以标题字段为例，是在展示模型上放个 `title` 字段就可以，还是分别放个 `title` 和 `titleWithCategory`？如果是前者那么服务内部必然会存在 `if…else…` 这种逻辑，用于区分 `title` 的拼接方式，这同样会导致展示服务内部的复杂性。如果是多个字段，那么可以想象，展示服务的模型字段也将会不断扩散。

总结：后端 BFF 模式能够在一定程度上化解后端逻辑的复杂性，同时提供一个展示字段的复用机制。但是仍然存在未决问题，如展示服务的颗粒度设计问题，数据图的划分问题，以及展示服务内部的复杂性和字段扩散问题。目前这种模式实践的代表有 Facebook、爱彼迎、eBay、爱奇艺、携程、去哪儿等等。

3.2 前端 BFF 模式

前端 BFF 模式在 Sam Newman 的文章中的”And Autonomy”部分有特别的介绍，指的是 BFF 本身由前端团队自己负责，如下示意图所示：

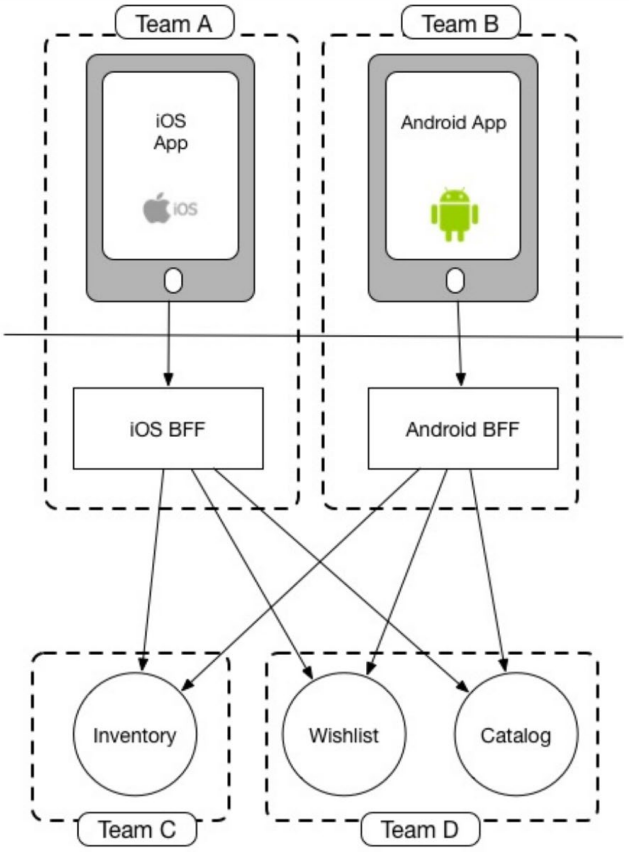

图 5　前端 BFF 模式

这种模式的理念是，本来能一个团队交付的需求，没必要拆成两个团队，两个团队本身带来较大的沟通协作成本。本质上，也是一种将“敌我矛盾”转化为“人民内部矛盾”的思路。前端完全接手 BFF 的开发工作，实现数据查询的自给自足，大大减少了前后端的协作成本。但是这种模式没有提到我们关心的一些核心问题，如：复杂性如何应对、差异性如何应对、展示模型如何设计等等问题。除此之外，这种模式也存在一些前提条件及弊端，比如较为完备的前端基础设施；前端不仅仅需要关心渲染、还需要了解业务逻辑等。

总结：前端 BFF 模式通过前端自主查询和使用数据，从而达到降低跨团队协作的成本，提升 BFF 研发效率的效果。目前这种模式的实践代表是阿里巴巴。

4. 基于 GraphQL 及元数据的信息聚合架构设计

4.1 整体思路

通过对后端 BFF 和前端 BFF 两种模式的分析，我们最终选择后端 BFF 模式，前端 BFF 这个方案对目前的研发模式影响较大，不仅需要大量的前端资源，而且需要建设完善的前端基础设施，方案实施成本比较高昂。

前文提到的后端 GraphQL BFF 模式代入我们的具体场景虽然存在一些问题，但是总体有非常大的参考价值，比如展示字段的复用思路、数据的按需查询思路等等。在商品展示场景中，**有 80% 的工作集中在数据的聚合和集成部分**，并且这部分具有很强的复用价值，因此信息的查询和聚合是我们面临的主要矛盾。因此，我们的思路是：**基于 GraphQL+ 后端 BFF 方案改进，实现取数逻辑和展示逻辑的可沉淀、可组合、可复用**，整体架构如下示意图所示：

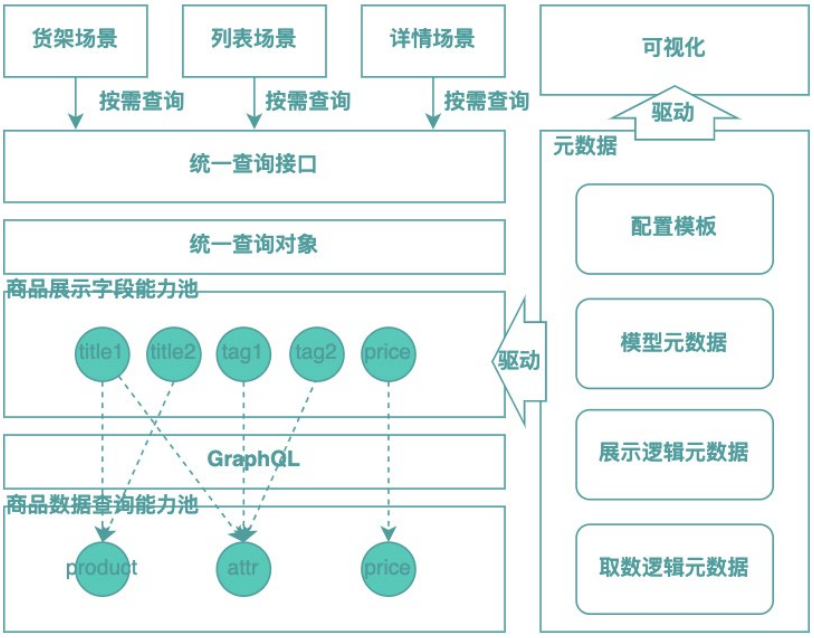

图 6　基于 GraphQL BFF 的改进思路

从上图可看出，与传统 GraphQL BFF 方案最大的差别在于我们将 GraphQL 下放

至数据聚合部分，由于数据来源于商品领域，领域是相对稳定的，因此数据图规模可控且相对稳定。除此之外，整体架构的核心设计还包括以下三个方面：1）取数展示分离；2）查询模型归一；3）元数据驱动架构。

我们通过取数展示分离解决展示服务颗粒度问题，同时使得展示逻辑和取数逻辑可沉淀、可复用；通过查询模型归一化设计解决展示字段扩散的问题；通过元数据驱动架构实现能力的可视化，业务组件编排执行的自动化，这能够让业务开发同学聚焦于业务逻辑的本身。下面将针对这三个部分逐一展开介绍。

4.2 核心设计

4.2.1 取数展示分离

上文提到，在商品展示场景中，展示逻辑和取数逻辑是多对多的关系，而传统的基于 GraphQL 的后端 BFF 实践方案把它们封装在一起，这是导致展示服务颗粒度难以设计的根本原因。思考一下取数逻辑和展示逻辑的关注点是什么？取数逻辑关注怎么查询和聚合数据，而展示逻辑关注怎么加工生成需要的展示字段，它们的关注点不一样，放在一起也会增加展示服务的复杂性。因此，我们的思路是将取数逻辑和展示逻辑分离开来，单独封装成逻辑单元，分别叫取数单元和展示单元。在取数展示分离之后，GraphQL 也随之下沉，用于实现数据的按需聚合，如下图所示：

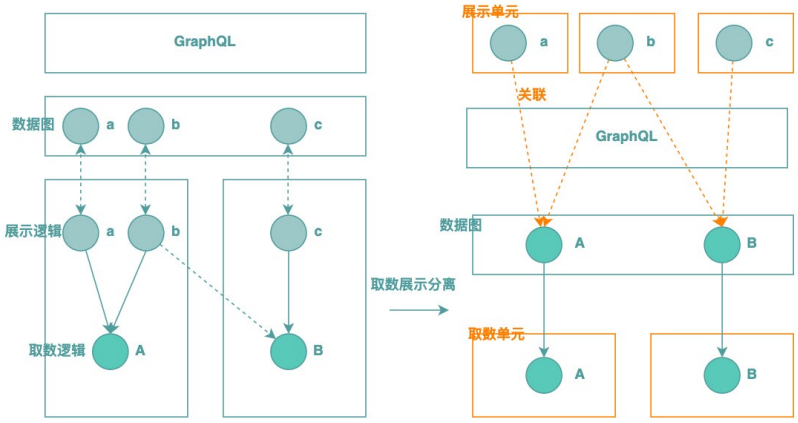

图 7　取数展示分离 + 元数据描述

那么取数和展示逻辑的封装颗粒度是怎么样的呢？不能太小也不能太大，在颗粒度的设计上，我们有两个核心考量：1）**复用**，展示逻辑和取数逻辑在商品展示场景中，都是可以被复用的资产，我们希望它们能沉淀下来，被单独按需使用；2）**简单**，保持简单，这样容易修改和维护。基于这两点考虑，颗粒度的定义如下：

- **取数单元**：尽量只封装 1 个外部数据源，同时负责对外部数据源返回的模型进行简化，这部分生成的模型我们称之为取数模型。
- **展示单元**：尽量只封装 1 个展示字段的加工逻辑。

分开的好处是简单且可被组合使用，那么具体如何实现组合使用呢？我们的思路是通过元数据来描述它们之间的关系，基于元数据由统一的执行框架来关联运行，具体设计下文会展开介绍。通过取数和展示的分离，元数据的关联和运行时的组合调用，可以保持逻辑单元的简单，同时又满足复用诉求，这也很好地解决了传统方案中存在的**展示服务的颗粒度问题**。

4.2.2 查询模型归一

展示单元的加工结果通过什么样的接口透出呢？接下来，我们介绍一下查询接口设计的问题。

1）查询接口设计的难点

常见查询接口的设计模式有以下两种：

- **强类型模式**：强类型模式指的是查询接口返回的是 POJO 对象，每一个查询结果对应 POJO 中的一个明确的具有特定业务含义的字段。
- **弱类型模式**：弱类型模式指的是查询结果以 K-V 或 JSON 模式返回，没有明确的静态字段。

以上两种模式在业界都有广泛应用，且它们都有明确的优缺点。强类型模式对开发者友好，但是业务是不断迭代的，与此同时，系统沉淀的展示单元会不断丰富，在这样的情况下，接口返回的 DTO 中的字段将会愈来愈多，每次新功能的支持，都要伴随着接口查询模型的修改，JAR 版本的升级。而 JAR 的升级涉及数据提供方和数据消

费两方，存在明显效率问题。另外，可以想象，查询模型的不断迭代，最终将会包括成百上千个字段，难以维护。

而弱类型模式恰好可以弥补这一缺点，但是弱类型模式对于开发者来说非常不友好，接口查询模型中有哪些查询结果对于开发者来说在开发的过程中完全没有感觉，但是程序员的天性就是喜欢通过代码去理解逻辑，而非配置和文档。其实，这两种接口设计模式都存在着一个共性问题——缺少抽象，下面两节，我们将介绍在接口返回的查询模型设计方面的抽象思路及框架能力支持。

2）查询模型归一化设计

回到商品展示场景中，一个展示字段有多种不同的实现，如商品标题的两种不同实现方式：1）商品标题；2）[类目]+ 商品标题。商品标题和这两种展示逻辑的关系本质上是一种抽象 – 具体的关系。识别这个关键点，思路就明了了，我们的思路是对查询模型做抽象。查询模型上都是抽象的展示字段，一个展示字段对应多个展示单元，如下图所示：

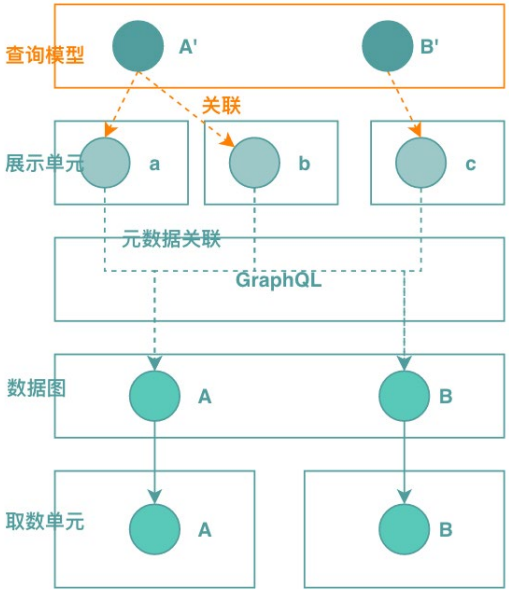

图 8　查询模型归一化 + 元数据描述

在实现层面同样基于元数据描述展示字段和展示单元之间的关系，基于以上的设计思路，可以在一定程度上减缓模型的扩散，但是还不能避免扩展。比如除了价格、库存、销量等每个商品都有的标准属性之外，不同的商品类型一般还会有这个商品特有的属性。比如密室主题拼场商品才有“几人拼”这样的描述属性，这种字段本身抽象的意义不大，且放在商品查询模型中作为一个单独的字段会导致模型扩张，针对这类问题，我们的解决思路是引入扩展属性，扩展属性专门承载这类非标准的字段。通过标准字段 + 扩展属性的方式建立查询模型，能够较好地解决**字段扩散**的问题。

4.2.3 元数据驱动架构

到目前为止，我们定义了如何分解**业务逻辑单元**以及如何设计**查询模型**，并提到用元数据描述它们之间的关系。基于以上定义实现的业务逻辑及模型，都具备很强的复用价值，可以作为业务资产沉淀下来。那么，为什么用元数据描述业务功能及模型之间的关系呢?

我们引入元数据描述主要有两个目的：1）代码逻辑的自动编排，通过元数据描述业务逻辑之间的关联关系，运行时可以自动基于元数据实现逻辑之间的关联执行，从而可以消除大量的人工逻辑编排代码；2）业务功能的可视化，元数据本身描述了业务逻辑所提供的功能，如下面两个示例：

> 团单基础售价字符串展示，例：30 元。 团单市场价展示字段，例：100 元。

这些元数据上报到系统中，可以用于展示当前系统所提供的功能。通过元数据描述组件及组件之间关联关系，通过框架解析元数据自动进行业务组件的调用执行，形成了如下的元数据架构：

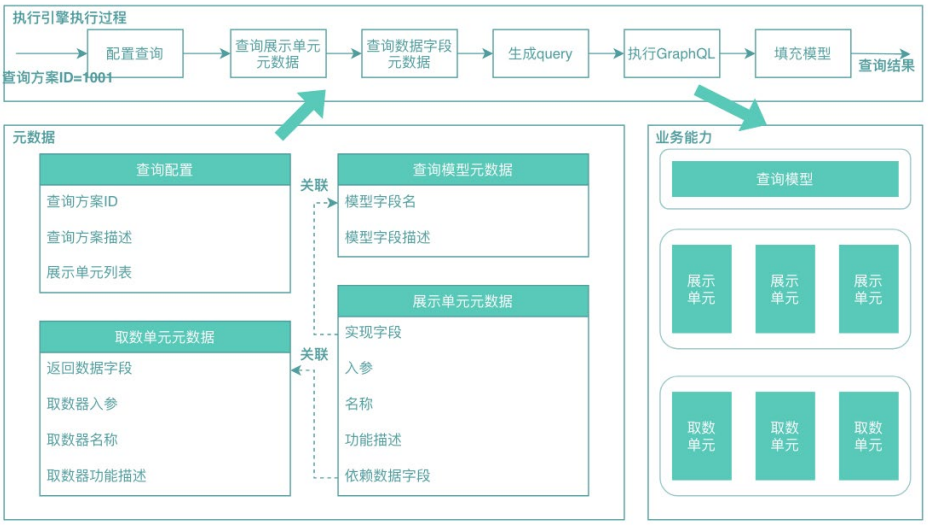

图 9　元数据驱动架构

整体架构由三个核心部分组成：

- 业务能力：标准的业务逻辑单元，包括取数单元、展示单元和查询模型，这些都是关键的可复用资产。
- 元数据：描述业务功能（如：展示单元、取数单元）以及业务功能之间的关联关系，比如展示单元依赖的数据，展示单元映射的展示字段等。
- 执行引擎：负责消费元数据，并基于元数据对业务逻辑进行调度和执行。

通过以上三个部分有机的组合在一起，形成了一个元数据驱动风格的架构。

5. 针对 GraphQL 的优化实践

5.1 使用简化

1）GraphQL 直接使用问题

引入 GraphQL，会引入一些额外的复杂性，比如会涉及到 GraphQL 带来的一些概念如：Schema、RuntimeWiring，下面是基于 GraphQL 原生 Java 框架的开发过程：

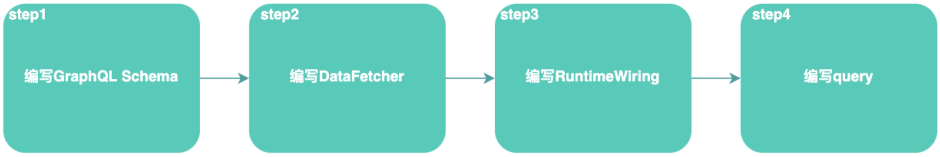

图 10　原生 GraphQL 使用流程

这些概念对于未接触过 GraphQL 的同学来说，增加了学习和理解的成本，而这些概念和业务领域通常没有什么关系。而我们仅仅希望使用 GraphQL 的按需查询特性，却被 GraphQL 本身拖累了，业务开发同学的关注点应该聚焦在业务逻辑本身才对，这个问题如何解决呢?

著名计算机科学家 David Wheeler 说了一句名言，”All problems in computer science can be solved by another level of indirection”。没有加一层解决不了的问题，本质上是需要有人来对这事负责，因此我们在原生 GraphQL 之上增加了一层执行引擎层来解决这些问题，目标是屏蔽 GraphQL 的复杂性，让开发人员只需要关注业务逻辑。

2）取数接口标准化

首先要简化数据的接入，原生的 `DataFetcher` 和 `DataLoader` 都是处在一个比较高的抽象层次，缺少业务语义，而在查询场景，我们能够归纳出，所有的查询都属于以下三种模式：

- **1 查 1**：根据一个条件查询一个结果。
- **1 查 N**：根据一个条件查询多个结果。
- **N 查 N**：一查一或一查多的批量版本。

由此，我们对查询接口进行了标准化，业务开发同学基于场景判断是那种，按需选择使用即可，取数接口标准化设计如下：

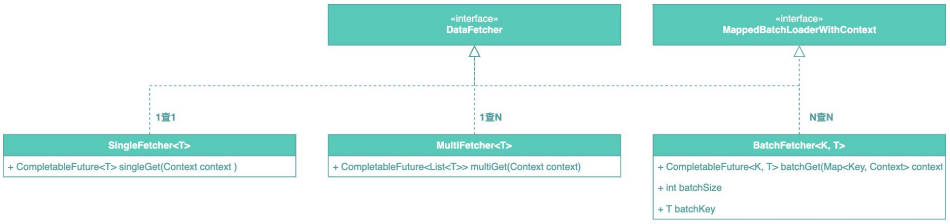

图 11　查询接口标准化

业务开发同学按需选择所需要使用的取数器，通过泛型指定结果类型，1 查 1 和 1 查 N 比较简单，N 查 N 我们对其定义为批量查询接口，用于满足”N+1”的场景，其中 `batchSize` 字段用于指定分片大小，`batchKey` 用于指定查询 Key，业务开发只需要指定参数，其他的框架会自动处理。除此之外，我们还约束了返回结果必须是 `CompleteFuture`，用于满足聚合查询的全链路异步化。

3）聚合编排自动化

取数接口标准化使得数据源的语义更清晰，开发过程按需选择即可，简化了业务的开发。但是此时业务开发同学写好 `Fetcher` 之后，还需要去另一个地方去写 `Schema`，而且写完 `Schema` 还要再写 `Schema` 和 `Fetcher` 的映射关系，业务开发更享受写代码的过程，不太愿意写完代码还要去另外一个地方取配置，并且同时维护代码和对应配置也提高了出错的可能性，能否将这些冗杂的步骤移除掉?

`Schema` 和 `RuntimeWiring` 本质上是想描述某些信息，如果这些信息换一种方式描述是不是也可以，我们的优化思路是：在业务开发过程中标记注解，通过注解标注的元数据描述这些信息，其他的事情交给框架来做。解决思路示意图如下：

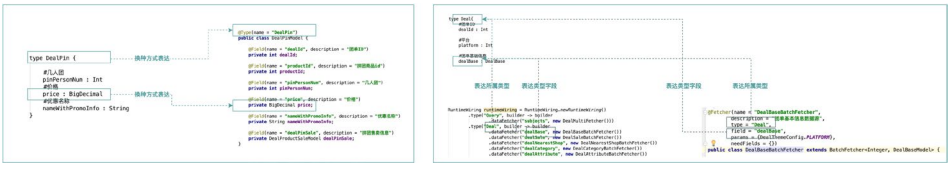

图 12　注解元数据描述 Schema 和 RuntimeWiring

5.2 性能优化

5.2.1 GraphQL 性能问题

虽然 GraphQL 已经开源了，但是 Facebook 只开源了相关标准，并没有给出解决方案。GraphQL-Java 框架是由社区贡献的，基于开源的 GraphQL-Java 作为按需查询引擎的方案，我们发现了 GraphQL 应用方面的一些问题，这些问题有部分是由于使用姿势不当所导致的，也有部分是 GraphQL 本身实现的问题，比如我们遇到的几个典型的问题：

- 耗 CPU 的查询解析，包括 `Schema` 的解析和 `Query` 的解析。
- 当查询模型比较复杂特别是存在大列表时候的延时问题。
- 基于反射的模型转换 CPU 消耗问题。
- `DataLoader` 的层级调度问题。

于是，我们对使用方式和框架做了一些优化与改造，以解决上面列举的问题。本章着重介绍我们在 GraphQL-Java 方面的优化和改造思路。

5.2.2 GraphQL 编译优化

1）GraphQL 语言原理概述

GraphQL 是一种查询语言，目的是基于直观和灵活的语法构建客户端应用程序，用于描述其数据需求和交互。GraphQL 属于一种领域特定语言（DSL），而我们所使用的 GraphQL-Java 客户端在语言编译层面是基于 ANTLR 4 实现的，ANTLR 4 是一种基于 Java 编写的语言定义和识别工具，ANTLR 是一种元语言（Meta-Language），它们的关系如下：

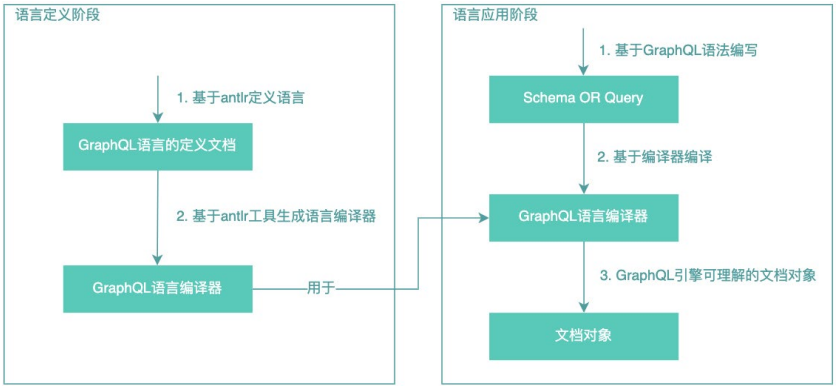

图 13　GraphQL 语言基本原理示意图

GraphQL 执行引擎所接受的 `Schema` 及 `Query` 都是基于 GraphQL 定义的语言所表达的内容，GraphQL 执行引擎不能直接理解 GraphQL，在执行之前必须由 GraphQL 编译器翻译成 GraphQL 执行引擎可理解的文档对象。而 GraphQL 编译器是基于 Java 的，经验表明在大流量场景实时解释的情况下，这部分代码将会成为 CPU 热点，而且还占用响应延迟，`Schema` 或 `Query` 越复杂，性能损耗越明显。

2）Schema 及 Query 编译缓存

`Schema` 表达的是数据视图和取数模型同构，相对稳定，个数也不多，在我们的业务场景一个服务也就一个。因此，我们的做法是在启动的时候就将基于 `Schema` 构造的 GraphQL 执行引擎构造好，作为单例缓存下来，对于 `Query` 来说，每个场景的 `Query` 有些差异，因此 `Query` 的解析结果不能作为单例，我们的做法是实现 `PreparsedDocumentProvider` 接口，基于 `Query` 作为 Key 将 `Query` 编译结果缓存下来。如下图所示：

```
private ConcurrentMap<String, PreparsedDocumentEntry> queryCacheEntry = Maps.newConcurrentMap();

@Override
public PreparsedDocumentEntry getDocument(ExecutionInput executionInput, Function<ExecutionInput, PreparsedDocumentEntry> computeFunction) {
    if (queryCacheEntry.get(executionInput.getQuery()) == null) {
        queryCacheEntry.putIfAbsent(executionInput.getQuery(), computeFunction.apply(executionInput));
    }
    return queryCacheEntry.get(executionInput.getQuery());
}
```

图 14　Query 缓存实现示意图

5.2.3 GraphQL 执行引擎优化

1) GraphQL 执行机制及问题

我们先一起了解一下 GraphQL-Java 执行引擎的运行机制是怎么样的。假设在执行策略上我们选取的是 `AsyncExecutionStrategy`，来看看 GraphQL 执行引擎的执行过程：

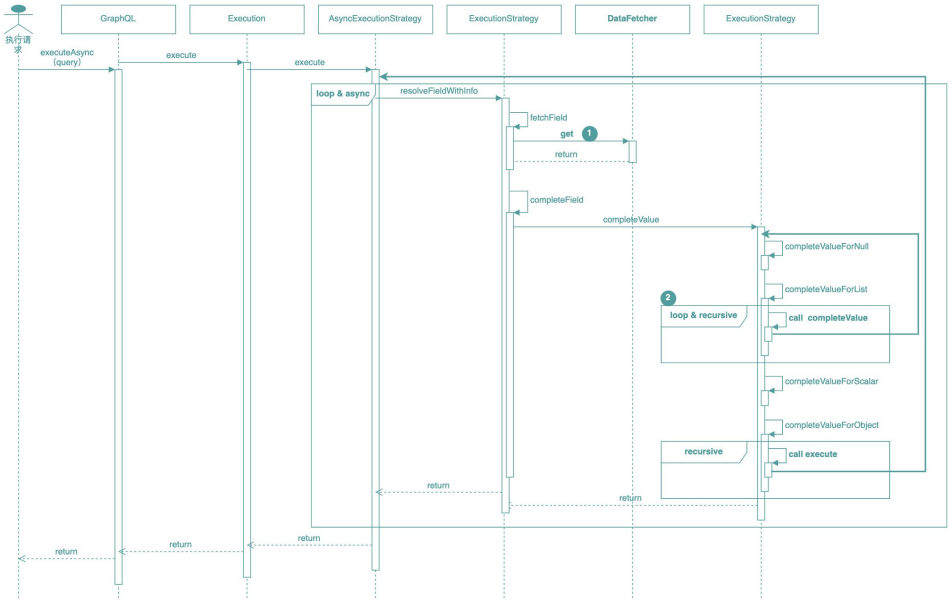

图 15　GraphQL 执行引擎执行过程

以上时序图做了些简化，去除了一些与重点无关的信息，`AsyncExecutionStrategy` 的 `execute` 方法是对象执行策略的异步化模式实现，是查询执行的起点，也是根节点查询的入口，`AsyncExecutionStrategy` 对对象的多个字段的查询逻辑，采取的是循环 + 异步化的实现方式，我们从 `AsyncExecutionStrategy` 的 `execute` 方法触发，理解 GraphQL 查询过程如下：

- 调用当前字段所绑定的 `DataFetcher` 的 `get` 方法，如果字段没有绑定 `DataFetcher`，则通过默认的 `PropertyDataFetcher` 查询字段，`PropertyDataFetcher` 的实现是基于反射从源对象中读取查询字段。

- 将从 `DataFetcher` 查询得到结果包装成 `CompletableFuture`，如果结果本身是 `CompletableFuture`，那么不会包装。
- 结果 `CompletableFuture` 完成之后，调用 `completeValue`，基于结果类型分别处理。
  - 如果查询结果是列表类型，那么会对列表类型进行遍历，针对每个元素在递归执行 `completeValue`。
  - 如果结果类型是对象类型，那么会对对象执行 `execute`，又回到了起点，也就是 `AsyncExecutionStrategy` 的 `execute`。

以上是 GraphQL 的执行过程，这个过程有什么问题呢？下面基于图上的标记顺序一起看看 GraphQL 在我们的业务场景中应用和实践所遇到的问题，这些问题不代表在其他场景也是问题，仅供参考：

问题 1：`PropertyDataFetcher` CPU 热点问题，`PropertyDataFetcher` 在整个查询过程中属于热点代码，而其本身的实现也有一些优化空间，在运行时 `PropertyDataFetcher` 的执行会成为 CPU 热点。（具体问题可参考 GitHub 上的 commit 和 Conversion：https://github.com/graphql-java/graphql-java/pull/1815）

图 16　PropertyDataFetcher 成为 CPU 热点

问题 2：列表的计算耗时问题，列表计算是循环的，对于查询结果中存在大列表的场景，此时循环会造成整体查询明显的延迟。我们举个具体的例子，假设查询结果中存在一个列表大小是 1000，每个元素的处理是 0.01ms，那么总体耗时就是 10ms，基于 GraphQL 的查机制，这个 10ms 会阻塞整个链路。

2）类型转换优化

通过 GraphQL 查询引擎拿到的 GraphQL 模型，和业务实现的 `DataFetcher` 返回的取数模型是同构，但是所有字段的类型都会被转换成 GraphQL 内部类型。`ProperyDataFetcher` 之所以会成为 CPU 热点，问题就在于这个模型转换过程，业务定义的模型到 GraphQL 类型模型转换过程示意图如下图所示：

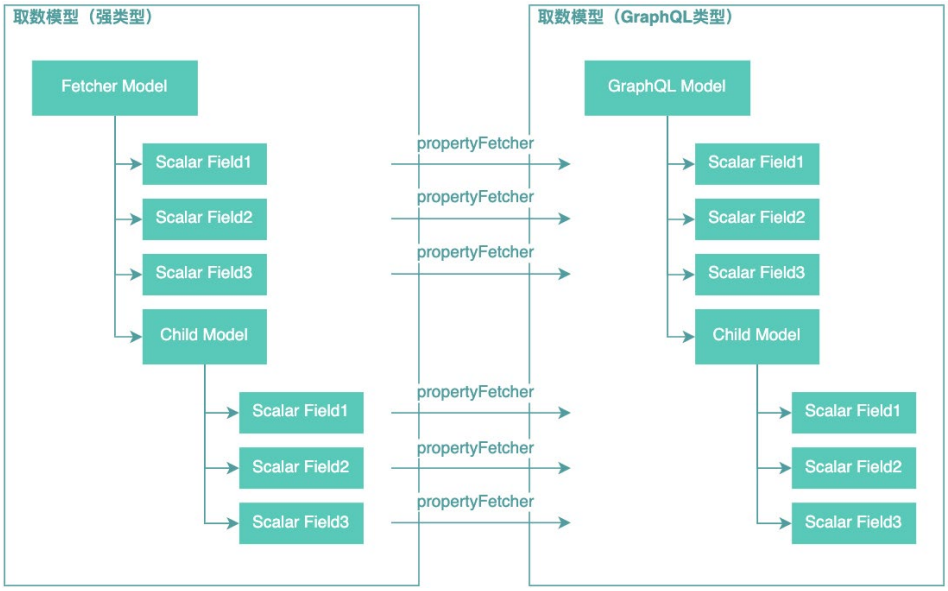

图 17　业务模型到 GraphQL 模型转换示意图

当查询结果模型中的字段非常多的时候，比如上万个，意味着每次查询有上万次的 `PropertyDataFetcher` 操作，实际就反映到了 CPU 热点问题上，这个问题我们的解决思路是保持原有业务模型不变，将非 `PropertyDataFetcher` 查询的结果反过来填充到业务模型上。如下示意图所示：

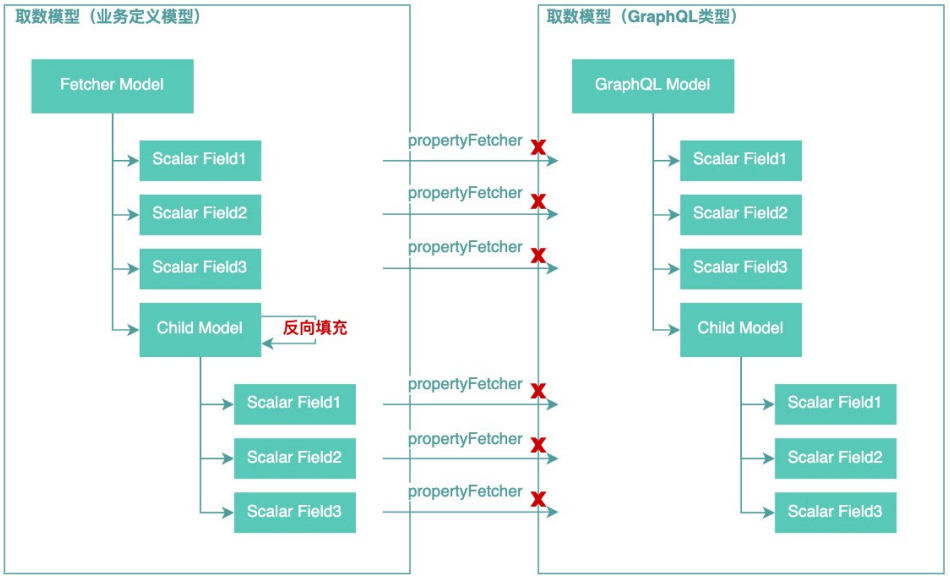

图 18　查询结果模型反向填充示意图

基于这个思路，我们通过 GraphQL 执行引擎拿到的结果就是业务 `Fetcher` 返回的对象模型，这样不仅仅解决了因字段反射转换带来的 CPU 热点问题，同时对于业务开发来说增加了友好性。因为 GraphQL 模型类似 JSON 模型，这种模型是缺少业务类型的，业务开发直接使用起来非常麻烦。以上优化在一个场景上试点测试，结果显示该场景的平均响应时间缩短 1.457ms，平均 99 线缩短 5.82ms，平均 CPU 利用率降低约 12%。

3）列表计算优化

当列表元素比较多的时候，默认的单线程遍历列表元素计算的方式所带来的延迟消耗非常明显，对于响应时间比较敏感的场景这个延迟优化很有必要。针对这个问题我们的解决思路是充分利用 CPU 多核心计算的能力，将列表拆分成任务，通过多线程并行执行，实现机制如下：

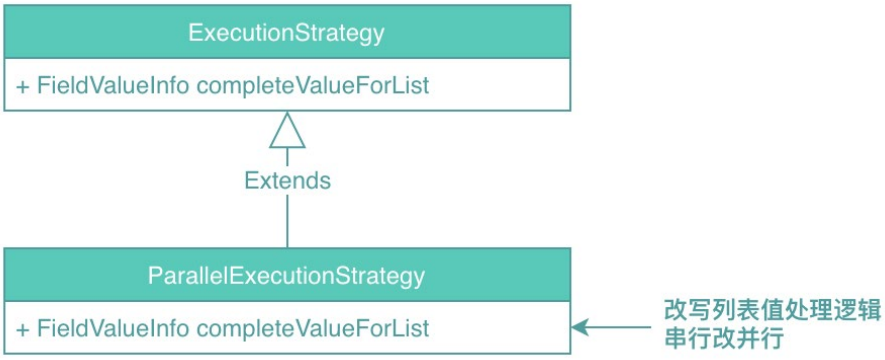

图 19　列表遍历多核计算思路

5.2.4 GraphQL-DataLoader 调度优化

1) DataLoader 基本原理

先简单介绍一下 DataLoader 的基本原理，DataLoader 有两个方法，一个是 `load`，一个是 `dispatch`，在解决 N+1 问题的场景中，DataLoader 是这么用的：

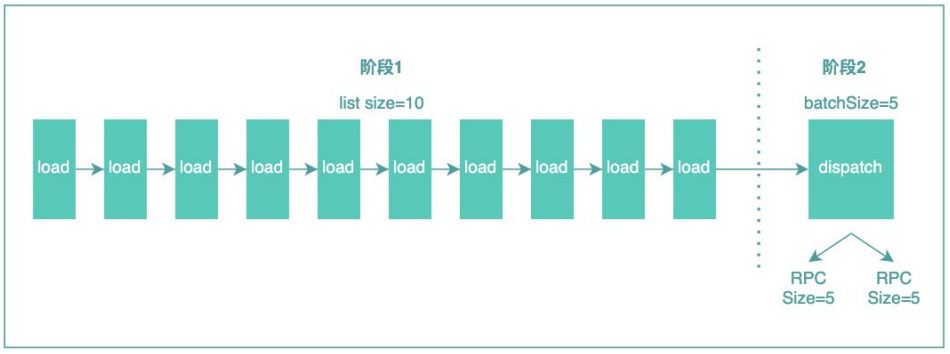

图 20　DataLoader 基本原理

整体分为 2 个阶段，第一个阶段调用 `load`，调用 N 次，第二个阶段调用 `dispatch`，调用 `dispatch` 的时候会真正的执行数据查询，从而达到批量查询 + 分片的效果。

2）DataLoader 调度问题

GraphQL-Java 对 DataLoader 的集成支持的实现在 `FieldLevelTrackingApproach` 中，`FieldLevelTrackingApproach` 的实现会存在怎样的问题呢？下面基于一张图表达原生 DataLoader 调度机制所产生的问题：

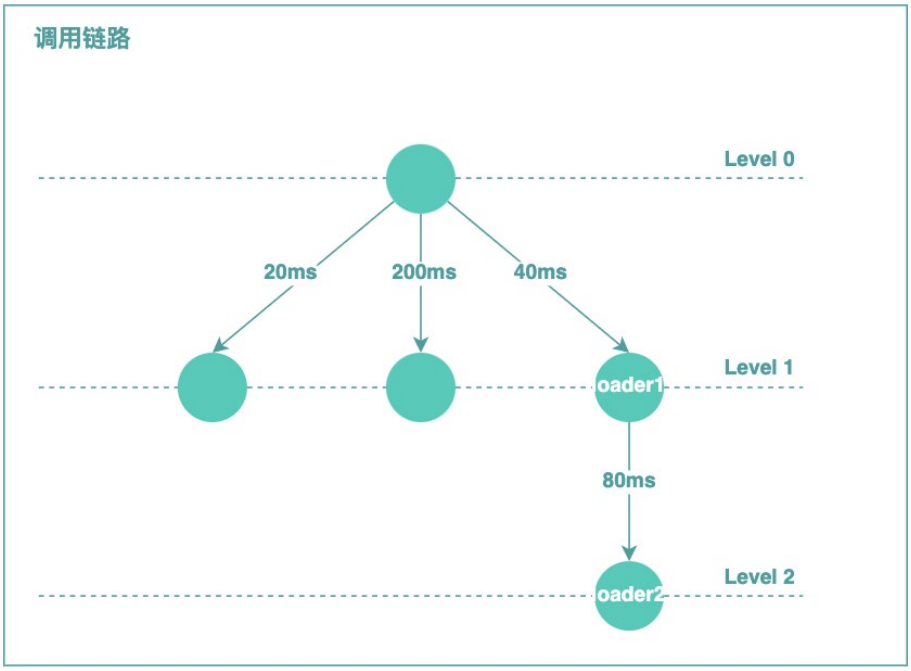

图 21　GraphQL-Java 对 DataLoader 调度存在的问题

问题很明显，基于 `FieldLevelTrackingApproach` 的实现，下一层级的 `DataLoader` 的 `dispatch` 是需要等到本层级的结果都回来之后才发出。基于这样的实现，查询总耗时的计算公式等于：TOTAL = MAX（Level 1 Latency）+ MAX（Level 2 Latency）+ MAX（Level 3 Latency）+ …，**总查询耗时等于每层耗时最大的值加起来，而实际上如果链路编排由业务开发同学自己来写的话，理论上的效果是总耗时等于所有链路最长的那个链路所耗的时间**，这个才是合理的。而 `FieldLevelTrackingApproach` 的实现所表现出来的结果是反常识的，至于为什么这么实现，目前我

们理解可能是设计者基于简单和通用方面的考虑。

问题在于以上的实现在有些业务场景下是不能接受的，比如我们的列表场景的响应时间约束一共也就不到 100ms，其中几十 ms 是因为这个原因搭进去的。针对这个问题的解决思路，一种方式是对于响应时间要求特别高的场景独立编排，不采用 GraphQL；另一种方式是在 GraphQL 层面解决这个问题，保持架构的统一性。接下来，介绍一下我们是如何扩展 GraphQL-Java 执行引擎来解决这个问题的。

3）DataLoader 调度优化

针对 DataLoader 调度的性能问题，**我们的解决思路是在最后一次调用某个 `DataLoader` 的 `load` 之后，立即调用 `dispatch` 方法发出查询请求**，问题是我们怎么知道哪一次的 load 是最后一次 load 呢？这个问题也是解决 DataLoader 调度问题的难点，以下举个例子来解释我们的解决思路：

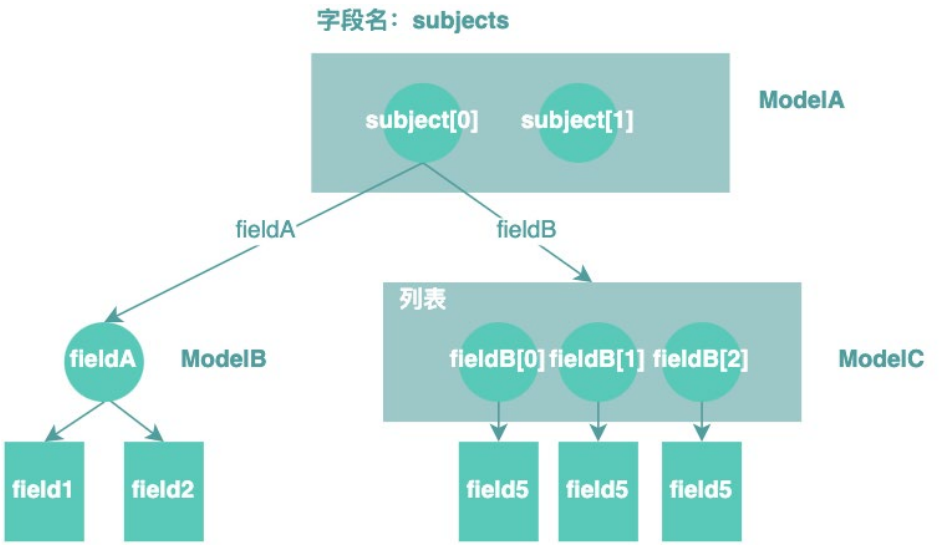

图 22　查询对象结果示意图

假设我们查询到的模型结构如下：根节点是 `Query` 下的字段，字段名叫 `subjects`，`subject` 引用的是个列表，`subject` 下有两个元素，都是 `ModelA` 的对象实例，`ModelA` 有两个字段，`fieldA` 和 `fieldB`，`subjects[0]` 的 `fieldA` 关联是

`ModelB` 的一个实例，`subjects[0]` 的 `fieldB` 关联多个 `ModelC` 实例。

为了方便理解，我们定义一些概念，字段、字段实例、字段实例执行完、字段实例值大小、字段实例值对象执行大小、字段实例值对象执行完等等：

- **字段**：具有唯一路径，是静态的，和运行时对象大小没有关系，如：`subjects` 和 `subjects/fieldA`。
- **字段实例**：字段的实例，具有唯一路径，是动态的，跟运行时对象大小有关系，如：`subjects[0]/fieldA` 和 `subjects[1]/fieldA` 是字段 `subjects/fieldA` 的实例。
- **字段实例执行完**：字段实例关联的对象实例都被 GraphQL 执行完了。
- **字段实例值大小**：字段实例引用对象实例的个数，如以上示例，`subjects[0]/fieldA` 字段实例值大小是 1，`subjects[0]/fieldB` 字段实例值大小是 3。

除了以上定义之外，我们的业务场景还满足以下条件：

- 只有 1 个根节点，且根节点是列表。
- `DataLoader` 一定属于某个字段，某个字段下的 `DataLoader` 应该被执行次数等于其下的对象实例个数。

基于以上信息，我们可以得出以下问题分析：

- 在执行字段实例的时候，我们可以知道当前字段实例的大小，字段实例的大小等于字段关联 `DataLoader` 在当前实例下需要执行 `load` 的次数，因此在执行 `load` 之后，我们可以知道当前对象实例是否是其所在字段实例的最后一个对象。
- 一个对象的实例可能会挂在不同的字段实例下，所以仅当当前对象实例是其所在字段实例的最后一个对象实例的时候，不代表当前对象实例是所有对象实例中的最后一个，当且仅当对象实例所在节点实例是节点的最后一个实例的时候才成立。
- 我们可从字段实例大小推算字段实例的个数，比如我们知道 `subjects` 的

大小是2，那么就知道`subjects`字段有两个字段实例`subjects[0]`和`subjects[1]`，也就知道字段subjects/fieldA有两个实例，`subjects[0]/fieldA`和`subjects[1]/fieldA`，因此我们从根节点可以往下推断出某个字段实例是否执行完。

通过以上分析，我们可以得出，一个对象执行完的条件是其所在的字段实例以及其所在的字段所有的父亲字段实例都执行完，且当前执行的对象实例是其所在字段实例的最后一个对象实例的时候。基于这个判断逻辑，我们的实现方案是在每次调用完`DataFetcher`的时候，判断是否需要发起`dispatch`，如果是则发起。另外，以上时机和条件存在漏发`dispatch`的问题，有个特殊情况，当当前对象实例不是最后一个，但是剩下的对象大小都为0的时候，那么就永远不会触发当前对象关联的`DataLoader`的`load`了，所以在对象大小为0的时候，需要额外再判断一次。

根据以上逻辑分析，我们实现了`DataLoader`调用链路的最优化，达到理论最优的效果。

6. 新架构对研发模式的影响

生产力决定生产关系，元数据驱动信息聚合架构是展示场景搭建的核心生产力，而业务开发模式和过程是生产关系，因此也会随之改变。下面我们将会从开发模式和流程两个角度来介绍新架构对研发带来的影响。

6.1 聚焦业务的开发模式

新架构提供了一套基于业务抽象出的标准化代码分解约束。以前开发同学对系统的理解很可能就是“查一查服务，把数据粘在一起”，而现在，研发同学对于业务的理解及代码分解思路将会是一致的。比如展示单元代表的是展示逻辑，取数单元代表的是取数逻辑。同时，很多冗杂且容易出错的逻辑已经被框架屏蔽掉了，研发同学能够有更多的精力聚焦于业务逻辑本身，比如：业务数据的理解和封装，展示逻辑的理解和编写，以及查询模型的抽象和建设。如下示意图所示：

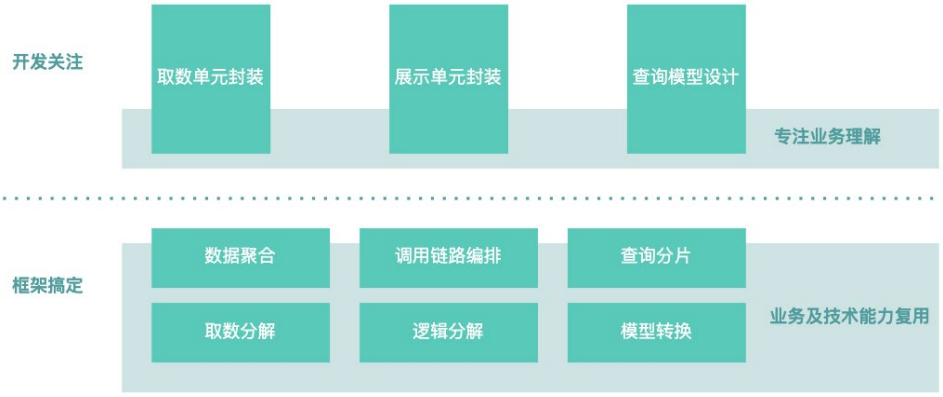

图 23　业务开发聚焦业务本身

6.2 研发流程升级

新架构不仅仅影响了研发的代码编写，同时也影响着研发流程的改进，基于元数据架构实现的可视化及配置化能力，现有研发流程和之前研发流程相比有了明显的区别，如下图所示：

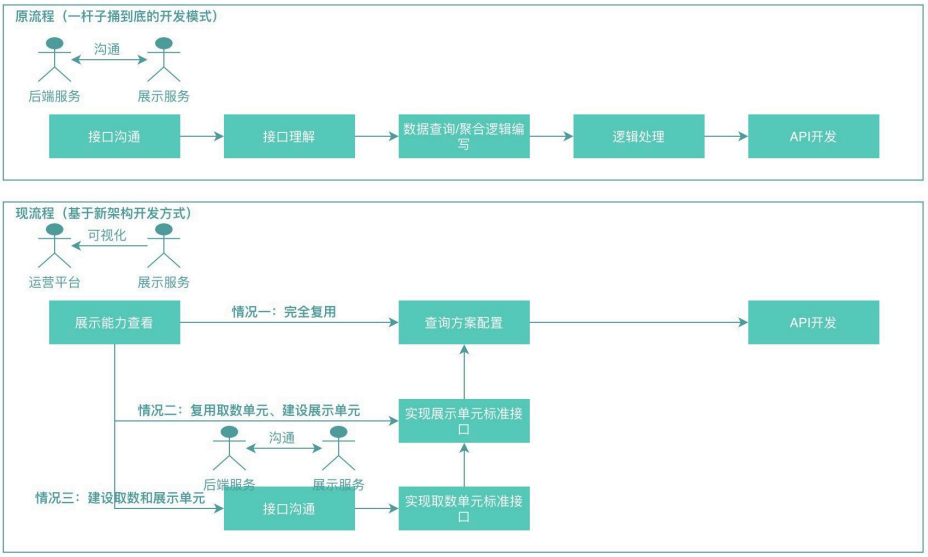

图 24　基于开发框架搭建展示场景前后研发流程对比

以前是“一杆子捅到底”的开发模式，每个展示场景的搭建需要经历过从接口的沟通到 API 的开发整个过程，基于新架构之后，系统自动具备多层复用及可视化、配置化能力。

情况一：这是最好的情况，此时取数功能和展示功能都已经被沉淀下来，研发同学需要做的只是创建查询方案，基于运营平台按需选择需要的展示单元，拿着查询方案 ID 基于查询接口就可以查到需要的展示信息了，可视化、配置化界面如下示意图所示：

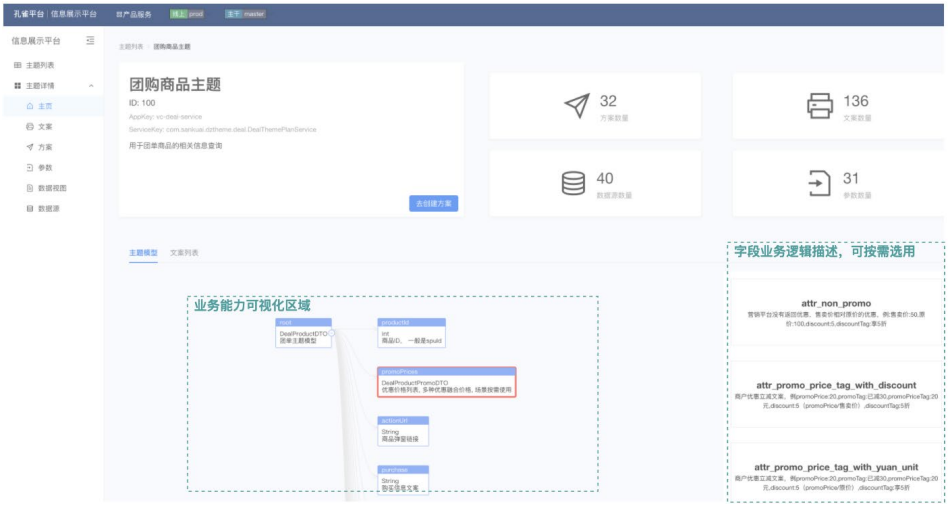

图 25　可视化及文案按需选用

情况二：此时可能没有展示功能，但是通过运营平台查看到，数据源已经接入过，那么也不难，只需要基于现有的数据源编写一段加工逻辑即可，这段加工逻辑是非常爽的一段纯逻辑的编写，数据源列表如下示意图所示：

图 26　数据源列表可视化

情况三：最坏的情况是此时系统不能满足当前的查询能力，这种情况比较少见，因为后端服务是比较稳定的，那么也无需惊慌，只需要按照标准规范将数据源接入进来，然后编写加工逻辑片段即可，之后这些能力是可以被持续复用的。

7. 总结

商品展示场景的复杂性体现在：场景多、依赖多、逻辑多，以及不同场景之间存在差异。在这样的背景下，如果是业务初期，怎么快怎么来，采用“烟囱式”个性化建设的方式不必有过多的质疑。但是随着业务的不断发展，功能的不断迭代，以及场景的规模化趋势，“烟囱式”个性化建设的弊端会慢慢凸显出来，包括代码复杂度高、缺少能力沉淀等问题。

本文以基于对美团到店商品展示场景所面临的核心矛盾分析，介绍了：

- 业界不同的 BFF 应用模式，以及不同模式的优势和缺点。
- 基于 GraphQL BFF 模式改进的元数据驱动的架构方案设计。
- 我们在 GraphQL 实践过程中遇到的问题及解决思路。
- 新架构对研发模式产生的影响呈现。

目前，笔者所在团队负责的核心商品展示场景都已迁入新架构，基于新的研发模式，我们实现了 50% 以上的展示逻辑复用以及 1 倍以上的效率提升，希望本文对大家能够有所帮助。

8. 参考文献

[1]https://samnewman.io/patterns/architectural/bff/
[2] https://www.thoughtworks.com/cn/radar/techniques/graphql-for-server-side-resource-aggregation
[3] 了解电商后台系统，看这篇就够了
[4] 框架定义 - 百度百科
[5] 高效研发 - 闲鱼在数据聚合上的探索与实践
[6]《系统架构 - 复杂系统的产品设计与开发》

9. 招聘信息

美团到店综合研发中心长期招聘前端、后端、数据仓库、机器学习 / 数据挖掘算法工程师，坐标上海，欢迎感兴趣的同学发送简历至：tech@meituan.com（邮件标题注明：美团到店综合研发中心—上海）。

速度与压缩比如何兼得？压缩算法在构建部署中的优化

作者：宏达

背景

通常而言，服务发布平台的构建部署的流程（镜像部署除外）会经过**构建**（同步代码 -> 编译 -> 打包 -> 上传）、**部署**（下载包 -> 解压到目标机器 -> 重启服务）等步骤。以美团内部的发布平台 Plus 为例，最近我们发现一些发布项在构建产物打包压缩的过程中耗时比较久。如下图所示的 pack 步骤，一共消耗了 1 分 23 秒。

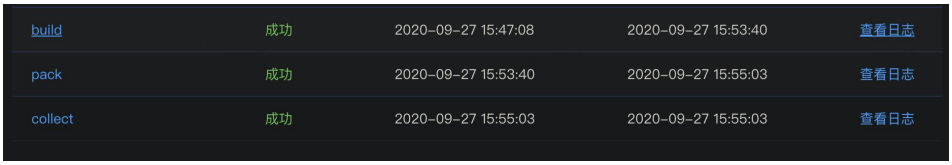

而在平常为用户解答运维问题的时候我们也发现，很多用户会习惯将一些较大的机器学习或者 NLP 相关的数据放入到仓库中，这部分数据往往占据几百兆，甚至占据几个 GB 的磁盘空间，十分影响打包的速度。 Java 项目也是如此，由于 Java 服务框架繁多，依赖也多，通常这些服务打包后也要占据百兆级别的空间，耗时也会达到十多秒。下图是我们的 pack 步骤的中位数，基本上大部分的 Java 服务和 Node.js 服务都至少要消耗 13s 左右的时间来做压缩打包 。

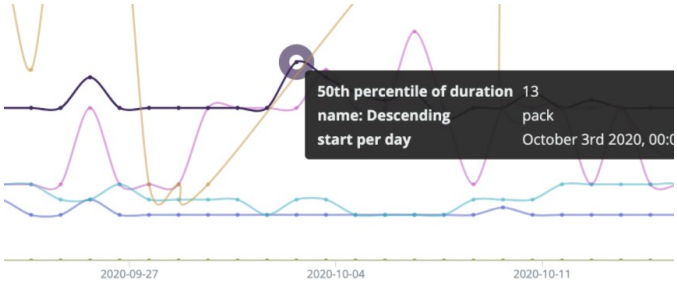

pack 作为几乎所有需要部署的服务必需步骤，它目前的耗时基本上仅低于编译和构

建镜像，因此，为了提高整体构建的效率，我们准备对 pack 打包压缩的步骤进行一轮优化工作。

方案对比

准备场景数据

发布项的包大小分析

为了尽可能地模拟构建部署中的应用场景，我们将 2020 年的部分**构建包数据**进行了整理分析，其中压缩后的包大小如下图所示，钟形曲线说明了整体的包体积呈正态分布，并且有着较明显的长尾效应。压缩后体积主要在 200M 以内，压缩前的大小大致在 516.0MB 以内。

而 99% 的服务压缩包大小会在 1GB 以内，而对于压缩步骤而言，其实越大的项目耗时越明显，优化的空间越大。因此，我们在针对性的方案对比测试中选择了 1GB 左右的构建包进行压缩测试，既能覆盖 99% 的场景，也可以看出压缩算法之间比较明显的提升。

这样选择的主要原因如下：

- 数据大的情况下计算结果会比小数据误差小很多。
- 能够覆盖绝大多数应用场景。
- 效果对比明显，可以看到是否有明显的提升。

备注：由于在相同压缩库相同压缩比等配置的情况下，Compression Speed 并没有明显变化，因此没有做其它包体积的批量测试和数据汇总。

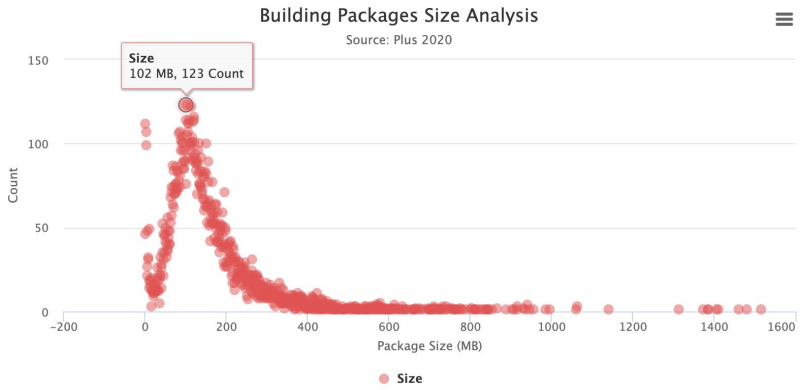

本文中我们使用的测试项目为美团内部的较大型的 C++ 项目，其中文件类型除去 C++、Python、Shell 代码文件，还有 NLP、工具等二进制数据（不包括 .git 中存储的提交数据），数据类型比较全面。

目录大小为 1.2G，也可以比较清晰地对比出不同方案之间的差距。

gzip

gzip 是基于 DEFLATE 的算法，它是 LZ77 和 Huffman 编码 的结合。DEFLATE 的目的是为了取代 LZW 和其他受专利保护的数据压缩算法，因为这些算法在当时限制了压缩和其他流行的存档器的可用性（Wikipedia）。

我们通常使用 `tar -czf` 命令来进行打包并且压缩的操作，z 参数正是使用 gzip 的方式来进行压缩。DEFLATE 标准（RFC1951）是一个被广泛使用的无损数据压缩标准。它的压缩数据格式由一系列块构成，对应输入数据的块，每一块通过 LZ77（基于字典压缩，就是将最高概率出现的字母以最短的编码表示）算法和 Huffman 编码进行压缩，LZ77 算法通过查找并替换重复的字符串来减小数据体积。

文件格式

- 一个 10 字节的报头，包含一个魔数 (1f 8b)，压缩方法（比如 08 用于 DEFLATE），1 字节的 header flags，4 字节的时间戳，compression flags 和操作系统 ID。

- 可选的额外 headers，包括原始文件名、注释字段、“extra”字段和 header 的 CRC-32 校验码 lower half 。
- DEFLATE 压缩主体。
- 8 字节的 footer，包含 CRC-32 校验以及原始未压缩的数据。

我们可以看到 gzip 是主要基于 CRC 和 Huffman LZ77 的 DEFLATE 算法，这也是后面 ISA-L 库的优化目标。

Brotli

Alakuijala 和 Szabadka 在 2013-2016 年完成了 Brotli 规范，该数据格式旨在进一步提高压缩比，它在优化网站速度上有大量应用。Brotli 规范的正式验证是由 Mark Adler 独立实现的。Brotli 是一个用于数据流压缩的数据格式规范，它使用了通用的 LZ77 无损压缩算法、Huffman 编码和二阶上下文建模（2nd order context modelling）的特定组合。大家可以参考这篇论文查看其实现原理。

因为语言本身的特性，基于上下文的建模方法（Context Modeling）可以得到更好的压缩比，但由于它的性能问题很难普及。当前比较流行的突破算法有两种：

- ANS：Zstd, lzfse
- Context Modeling：Brotli, bz2

具体测试数据见下文。

Zstd

Zstd 全称叫 Zstandard，是一个提供高压缩比的快速压缩算法，主要实现的编程语言为 C，是 Facebook 的 Yann Collet 于 2016 年发布的，Zstd 采用了有限状态熵（Finite State Entropy，缩写为 FSE）编码器。该编码器是由 Jarek Duda 基于 ANS 理论开发的一种新型熵编码器，提供了非常强大的压缩速度 / 压缩率的折中方案（事实上也的确做到了“鱼”和“熊掌”兼得）。Zstd 在其最大压缩级别上提供的压缩比接近 lzma、lzham 和 ppmx，并且性能优于 lza 或 bzip2。Zstandard 达到了

Pareto frontier（资源分配最佳的理想状态），因为它解压缩速度快于任何其他当前可用的算法，但压缩比类似或更好。

对于小数据，它还特别提供一个载入预置词典的方法优化速度，词典可以通过对目标数据进行训练从而生成。

官方 Benchmark 数据对比

zstd 与 gzip lzma lz4 对比	Compressor name	Ratio	Compression	Decompress
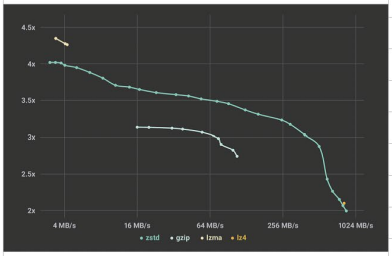	Zstd 1.4.5 -1	2.884	500 MB/s	1660 MB/s
	zlib 1.2.11 -1	2.743	90 MB/s	400 MB/s
	brotli 1.0.7 -0	2.703	400 MB/s	450 MB/s
	Zstd 1.4.5 --fast=1	2.434	570 MB/s	2200 MB/s
	Zstd 1.4.5 --fast=3	2.312	640 MB/s	2300 MB/s
	Zstd 1.4.5 --fast=5	2.178	700 MB/s	2420 MB/s
	lzo1x 2.10 -1	2.106	690 MB/s	820 MB/s
	lz4 1.9.2	2.101	740 MB/s	4530 MB/s
	snappy 1.1.8	2.073	560 MB/s	1790 MB/s

压缩级别可以通过 -fast 指定，提供更快的压缩和解压缩速度，相比级别 1 会导致压缩比率的一些损失，如上表所示。Zstd 可以用压缩速度换取更强的压缩比。它是可配置的小增量，在所有设置下，解压缩速度都保持不变，这是大多数 LZ 压缩算法（如 zlib 或 lzma）共享的特性。

- 我们采用 Zstd 默认的参数进行了测试，压缩时间 8.471s 仅为原来的 11.266%，提升了 88.733%。
- 解压时间 3.211 仅为原来的 29.83%，提升约为 70.169%。
- 同时压缩率也从 2.548 提升到了 2.621。

LZ4

LZ4 是一种无损压缩算法，每核提供大于 500 MB/s 的压缩速度（大于 0.15 Bytes/cycle）。它的特点是解码速度极快，每核速度为多 GB/s（ 约 1 Bytes/cycle ）。

从上面的 Zstd 的 Benchmark 对比中，我们看到了 LZ4 算法效果十分出众，因此我们也对 LZ4 进行了对比，LZ4 更加侧重压缩解压速度，尤其是解压缩的速度，压缩

比并不是它的强项，它默认支持 1-9 的压缩参数，我们分别进行了测试。

LZ4 使用默认参数压缩速度十分优秀，比 Zstd 快很多，但是压缩比并不高，比 Zstd 压缩后多了 206 MB，足足多了 46%，这就意味着更多的数据传输时间和磁盘空间占用。即使是最大的压缩比也并不高，仅仅从 1.79 提升到了 2.11，但是耗时却从 5s 提升到了 51s。通过对比，LZ4 的确在压缩率上并不是最优秀的方案，在 2.x 级别压缩率上基本上时间优势荡然无存，而且还有一点，就是 LZ4 目前官方并没有对多核 CPU 并行压缩的支持，所以在后续的对比中，LZ4 丧失了压缩解压缩速度的优势。

Pigz

Pigz 的作者 Mark Adler，同时也是 Info-ZIP 的 zip 和 unzip、GNU 的 gzip 和 zlib 压缩库的共同作者，并且是 PNG 图像格式开发工作的参与者。

Pigz 是 gzip 的并行实现的缩写，它主要思想就是利用多个处理器和核。它将输入分成 128 KB 的块，每个块都被并行压缩。每个块的单个校验值也是并行计算的。它的实现直接使用了 zlib 和 pthread 库，比较易读，而且重要的是兼容 gzip 的格式。Pigz 使用一个线程（主线程）进行解压缩，但可以创建另外三个线程进行读、写和检查计算，所以在某些情况下可以加速解压缩。

一些博客在 i7 4790K 这样的家用 PC 平台中测试 Pigz 的压缩性能时，并没有十分高的速度，但在我们真机验证的数据中提升要明显很多。通过测试，它的压缩时间执行速度只用了 1.768s，充分发挥了我们平台物理机的性能，User 时间（CPU 时间之和）一共使用了 1m30.569s，这和前面的使用 gzip 单线程的方式速度几乎是一个级别。压缩率 2.5488 和正常使用 `tar -czf` 几乎相差不多。

ISA-L Acceleration Version

ISA-L 是一套在 IA 架构上加速算法执行的开源函数库，目的在于解决存储系统的计算需求。ISA-L 使用的是 BSD-3-Clause License，因此在商业上同样可以使用。

使用过 SPDK（Storage Performance Development Kit）或者 DPDK（Data

Plane Development Kit）应该也听说过 ISA-L ，前者使用了 ISA-L 的 CRC 部分，后者使用了它的压缩优化。ISA-L 通过使用高效的 SIMD（Single Instruction, Multiple Data）指令和专用指令，最大化的利用 CPU 的微架构来加速存储算法的计算过程。ISA-L 底层函数都是使用手工汇编代码编写，并在很多细节上做了调优（现在经常要考虑 ARM 平台，本文中所提及的部分指令在该平台支持度不高甚至是不支持）。

ISA-L 对压缩算法主要做了 CRC、DEFLATE 和 Huffman 编码的优化实现，官方的数据指出 ISA-L 相比 zlib-1 有 5 倍的速度提升。

举例来说，不少底层的存储开源软件实现的 CRC 都使用了查表法，代码中存储或者生成了一个 CRC value 的表格，然后计算过程中查询值，ISA-L 的汇编代码中包含了无进位乘法指令 PCLMULQDQ 对两个 64 位数做无进位乘法，最大化 intel PCLMULQDQ 指令的吞吐量来优化 CRC 的性能。更好的情况是 CPU 支持 AVX-512，就可以使用 VPCLMULQDQ（PCLMULQDQ 在 EVEX 编码的 512 bit 版本实现）等其它优化指令集（查看是否支持的方式见“附录”）。

```
244     .16B_reduction_loop:
245         vpclmulqdq  xmm8, xmm7, xmm10, 0x11
246         vpclmulqdq  xmm7, xmm7, xmm10, 0x00
247         vpxor       xmm7, xmm8
248         vmovdqu     xmm0, [arg2]
249         vpshufb     xmm0, xmm0, xmm18
250         vpxor       xmm7, xmm0
251         add     arg2, 16
252         sub     arg3, 16
```

备注：截图来自 crc32_ieee_by16_10.asm

使用

ISA-L 实现的压缩优化级别支持 [0,3]，3 为压缩比最大的版本，综合考虑我们采用了最大的压缩比，虽然压缩比 2.346 略低于 gzip 不过影响不大。在 2019 年 6 月发

布的 v2.27 版本里，ISA-L 加了多线程的 Feature，因此在后续的测试中，我们采用了多线程并发的参数，效果提升比较显著。

由于我们构建机器的系统为 Centos7 需要自行编译 ISA-L 的依赖，比如 nasm 等库，所以在安装配置上会比较复杂，ISA-L 支持多种优化参数比如，IGZIP_HIST_SIZE（压缩过程中加大滑动窗口），LONGER_HUFFTABLES，更大的 Huffman 编码表，这些编译参数也会对库有很大提升。

压缩时间

```
real  0m1.372s
user  0m5.512s
sys 0m1.791s
```

测试后的效果相当惊人，是目前对比方案中最为快速的，时间上节省了 98.09%。

由于和 gzip 格式兼容，因此同样可以使用 `tar -xf` 命令进行解压，后续的解压缩测试过程中，我们使用的仍然是 ISA-L 提供的解压方式。

Pzstd

通过 Pigz 的测试，我们就在想，是否 Zstd 这样优秀的算法也可以支持并行呢，在官方的 Repo 中，我们十分惊喜地发现了一个“宝藏”。

Pzstd 是 C++11 实现的并行版本的 Zstandard（Zstd 也在这之后加入了多线程的支持），类似于 Pigz 的工具。 它提供了与 Zstandard 格式兼容的压缩和解压缩功能，可以利用多个 CPU 核心。 它将输入分成相等大小的块，并将每个块独立压缩为 Zstandard 帧。 然后将这些帧连接在一起以产生最终的压缩输出。 Pzstd 同样支持文件的并行解压缩。 解压缩使用 Zstandard 压缩的文件时，PZstandard 在一个线程中执行 IO，而在另一个线程中进行解压缩。

下图是和 Pigz 的压缩和解压缩速度对比，来自官方 Github 仓库（机器配置为：Intel Core i7 @ 3.1 GHz, 4 threads），效果比 Pigz 还要出色，具体对比数据见下文：

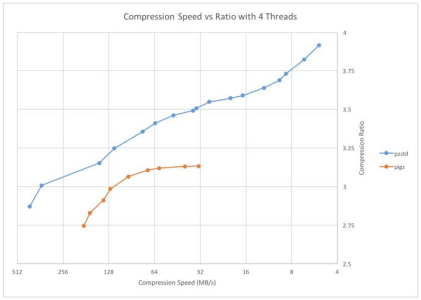

压缩速度

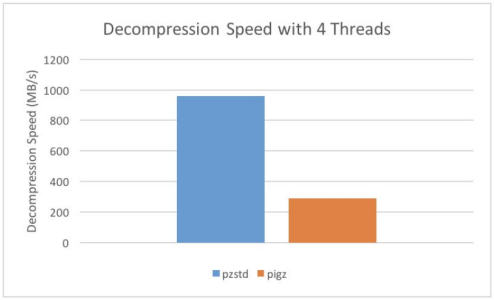

解压缩速度

Pied Piper (Middle-out compression)

Middle-out Compression 最初是在美剧中提到的一个概念，不过现在已经有了一个真正的实现 middle-out，该算法目前小范围应用在压缩时序数据中，由于缺乏成熟地理论支撑以及数据对比，没有正式进入方案的对标。

备注：Pied Piper 是美剧《硅谷》中虚拟出来的公司和算法。

兼容性

本文中调研所提及的对比方案，都是统一在构建集群中的机器中进行测试，由于构建系统 在线上的机器集群配置高度统一（包括硬件平台和系统版本），所以兼容性表现和测试数据也高度吻合。

选型

实际上，部分官方的测试机器的配置和美团构建平台的物理机配置并不一致，场景可能也有区别，上面引用的测试结果中所使用的 CPU 以及平台架构和编译环境和我们所用的也有些出入，而且大多数还是家用的硬件比如 i7-4790K 或者 i9-9900K，这也是需要使用构建平台的物理机和具体的构建包压缩场景来进行测试的原因，因为这样才能得出最接近我们使用场景的数据。

对比数据

几个方案的数据对比如下表格（在本文中的时间数据选择是通过多次运行后，选择结果的中位数）：

	Gzip	Brotli	Zstd	LZ4	Pigz	ISA-L	Pzstd
Data Compression Ratio	2.5482	2.3068	2.621	1.791	2.5488	2.346	2.616
Compression Time	71.636	7.398	8.471	5.141	1.768	1.372	1.065
Compression Speed	16.272 MB/s	157.57 MB/s	137.613 MB/s	226.75 MB/s	659.345 MB/s	849.652 MB/s	1094.5752 MB/s
Decompression Time	10.764	7.643	3.211	2.731	6.097	4.094	1.481

压缩时间对比

从整个构建后的压缩构建包的时间可视化图中可以看出，最初版本的 gzip 压缩相当耗时，而采取 Pzstd 是最快速的方案，ISA-L 稍慢，Pigz 略微慢一点，这**三者都可以达到从 1m11s 到 1s 左右的优化，最快可以节省 98.51% 的压缩时间**。

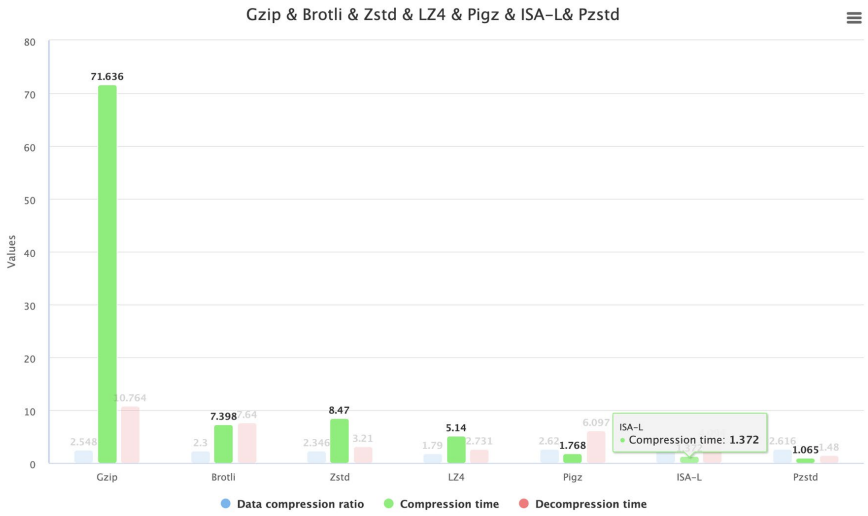

解压缩时间对比

解压缩的时间上并没有像压缩效率相差很多，在 GB 级别的项目中压缩比 2.5-2.6 范围内时，时间都在 11s 以内。而且为了最大兼容已有的实现和保持稳定性，解压方案优先考虑兼容 gzip 格式的策略，这样对部署目标机器的侵入性最小，即可以使用 `tar -xf` 解压的方案优先。

而在后面的方案实施中，由于部署需要稳定可靠的环境，所以我们暂时没有对部署机器做环境改造。

下面的时间对比是分别使用各自的解压方案的对比：

- Pzstd 解压速度最快，相比 Gzip 节省了 86.241% 的时间。
- Zstd 算法的解压缩效率其次，大约可以节省 70.169% 的解压时间。
- ISA-L 可节省 61.9658% 的时间。
- Pigz 可节省 43.357% 的解压时间。
- Brotli 解压可以节省 29.02% 的时间。

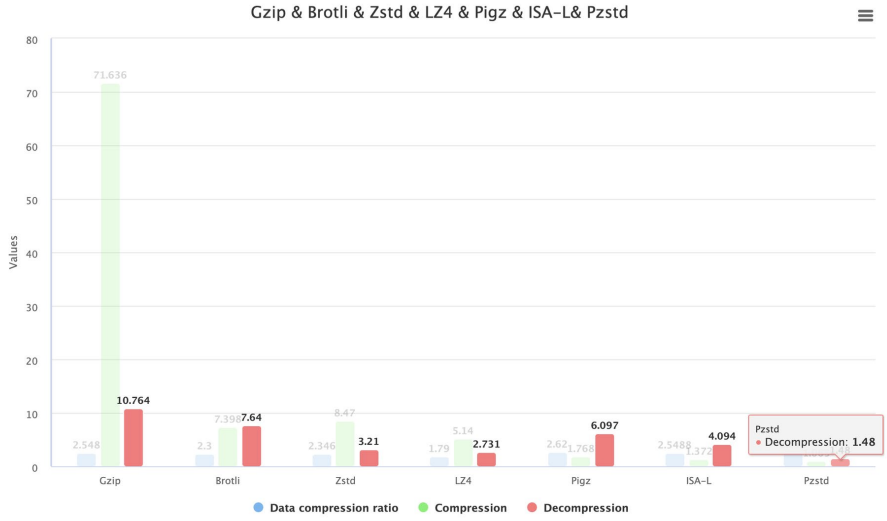

压缩比的对比

压缩比的对比中 Zstd 和 Pzstd 有一些优势，其中 Brotli 和 LZ4 由于支持的参数限制，比较难测试同级别压缩比下的速度，因此选择了压缩比稍低的参数，但是效率仍然距离 Pigz 和 Pzstd 存在一些差距。

而 ISA-L 的实现在压缩比上有一些牺牲，不过并没有差距很大。

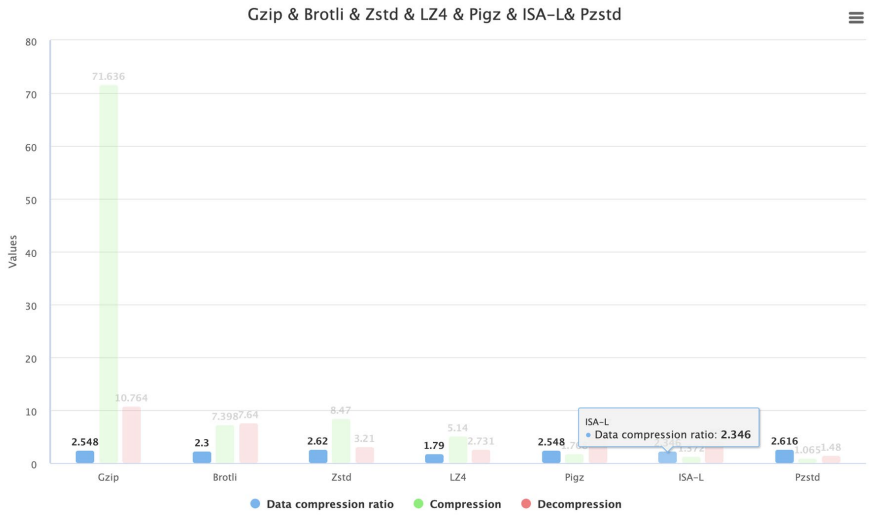

优劣分析总结

	理念	优势	劣势
Brotli	1. **优秀的新算法**	• 对于小文件的速度可能会稍微明显一些 • 压缩解压缩的速度比较不错，但是并不突出。	• **不兼容之前的 gzip 格式**，由于中间生成的压缩文件格式需要严格使用 Brotli 来进行处理，对于其它有可能已经使用 Plus 平台构建包的平台来说，兼容性是一个挑战。 • 大型文件尤其是在构建场景中，它的压缩速度并不是十分突出。 • 解压必需 Brotli 库的安装（也就是说部署的目标机器需要安装 Brotli 库）
Zstd	1. **优秀的新算法**	• **压缩解压速度十分优秀。** • 安装依赖单一，避免遇到麻烦的依赖冲突问题。 • **压缩比十分优秀。**	• **不兼容之前的 gzip 格式**，由于中间生成的压缩文件格式需要严格使用 zstd 来进行处理，对于其它有可能使用 Plus 平台构建包的平台来说，兼容性是一个挑战。 • 解压必需 zstd 库的安装（也就是说部署的目标机器需要安装 zstd 库）
LZ4	1. **优秀的新算法**	• **压缩解压速度十分优秀。** • 安装依赖单一，避免遇到麻烦的依赖冲突问题。	• **不兼容之前的 gzip 格式**，由于中间生成的压缩文件格式需要严格使用 LZ4 来进行处理，对于其它有可能使用 Plus 平台构建包的平台来说，兼容性是一个挑战。 • 解压必需 LZ4 库的安装（也就是说部署的目标机器需要安装 LZ4 库） • 压缩率并不理想
Pigz	1. 并行策略	• **压缩结果完全兼容 gzip 格式**，即便解压不做改动也可以完全兼容，这对于使用了构建压缩包的其它服务可能是十分完美的结果。同时对于部署目标机器的侵入性最小。 • **压缩解压速度极其优秀，仅次于 Pzstd 和 ISA-L。** • 对 tar 支持比较友好，可以方便地使用外接压缩插件。 • 安装依赖单一，避免遇到麻烦的依赖冲突问题。	无
ISA-L	1. gzip 算法以及底层指令优化 2. 并行策略	• **压缩结果完全兼容 gzip 格式**，即使解压不做改动也可以完全兼容，这对于使用了构建压缩包的其它服务可能是十分完美的结果。同时对于部署目标机器没有侵入性。 • **压缩解压速度极其优秀，仅次于 Pzstd。** • 对 tar 支持比较友好。	• 压缩比 稍微低一点点，且压缩比的参数范围有限。 • 实现接入成本略微复杂（不过好在我们的机器集群配置环境十分统一）。
Pzstd	1. **优秀的新算法** 2. 并行策略	• **压缩和解压的速度都极其优秀。** • 对 tar 支持比较友好，只需要在机器上安装 zstd 并且修改 tar 参数即可，改动较小。 • 安装依赖单一，避免遇到麻烦的依赖冲突问题。 • **压缩比十分优秀。**	• **不兼容之前的 gzip 格式**，由于中间生成的压缩文件格式需要严格使用 zstd 来进行处理，对于其它有可能使用 Plus 平台构建包的平台来说，兼容性是一个挑战。 • 解压必需 zstd 库的安装（也就是说部署的目标机器需要安装 zstd 库）

在本文开始阶段，我们介绍了构建部署流程，因此我们此次优化的目标时间大致计算公式如下：

$$TotalCost = Time_{compression} + \frac{PackageSize}{UploadSpeed} + \frac{PackageSize}{DownloadSpeed} + Time_{decompression}$$

在测试案例对比中，时间耗时的顺序为 Pzstd < ISA-L < Pigz < LZ4 < Zstd < Brotli < Gzip（排名越靠前越好），其中压缩和解压缩的时间在整体的耗时上占比较大，因此备选策略为 Pzstd、ISA-L、Pigz。

当然，这其中还存在磁盘空间的成本优化问题，即压缩比可能对磁盘空间产生优化，

但是对构建的耗时会产生负优化，不过由于目前时间维度是我们优化的主要目标，比磁盘成本和上传带宽成本要重要，因此压缩比采用了较为普遍或者默认最优的压缩比方案，即在 2.3 – 2.6 范围内。不过在一些内存型数据库等存储介质成本较为高的场景中，也许要综合多个方面需要更多考量，请大家知悉。

评分策略

比较于 gzip，新算法都具有想当不错的速度，但是由于压缩格式的向前不兼容，加上需要客户端（部署目标机器）的支持，可能方案实施周期会较长。

而对于部署来说，可能收益并不是十分明显，反而加重了一些维护和运维成本，所以我们暂时没有把 Pzstd 的方案放到较高的优先级。

选型的策略主要有基于如下原则：

- 整体耗时优化提升最大，这也是整体优化方案的出发点。
- 保证最大兼容性，为了让接入构建平台的业务和平台减少改动成本，需要保持方案的兼容性（优先考虑最大兼容的策略，即兼容 gzip 的方案优先）。
- 保证部署目标机器环境的稳定和可靠，选择对部署机器侵入最小的方案，这样无需安装客户端或者库。
- 压缩场景在真机模拟测试中完全契合美团构建平台的场景，即在我们现有的物理机平台和目标压缩场景中对比数据效果良好。
- 其实本问题更全面的评分角度有很多维度，比如对象存储的磁盘成本、带宽成本、任务耗时，甚至是机器成本，不过为了简化整体方案的选型，我们省略了一些计算，同时压缩比的对比选择上也选择了各自官方推荐的范围。

综合以上几点，决定一期采取 ISA-L 的方式加速，可以最稳定并且较高速地提升构建平台的效率，未来可能会实现 Pzstd 的方案，下面的数据为一期的结果。

优化效果

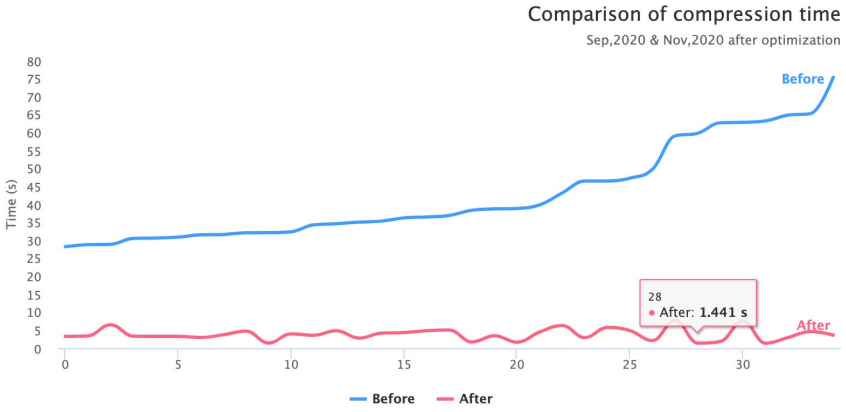

为了方便结果的展示，我们过滤出了部分打包时间较长的发布项展示出来（这些耗时很久的项目往往十分影响用户的使用体验，而且总体的占比在 10% 左右），这部分任务优化的时间从 27s 到 72s 不等，过去越是项目大的项目压缩时间越长，如今压缩时间都可以稳定在 10s 以内，而且是在我们的机器同时执行多个任务的情况下。

而后我们将优化前的 Pack 步骤（压缩 + 上传）部分打点数据，以及优化后的部分打点数据做了汇总，得出了平均的优化效果对比，数据如下：

- 在我们之前的一个构建包的统计中，多数的构建包压缩后在 100MB 左右，压缩前大概是在 250MB，按照 gzip 算法的压缩速度的确会在 10s 左右的级别。
- 由于构建的物理机可能同时运行多个任务，所以实际压缩效果会比测试中稍微耗时多一点。

	Pack 耗时之和	任务数	平均时间	压缩时间（去除复制文件和上传的时间）
优化前	908202	65613	13.8417996433634	10.2
优化后	215298	46853	4.59518067146181	1.035

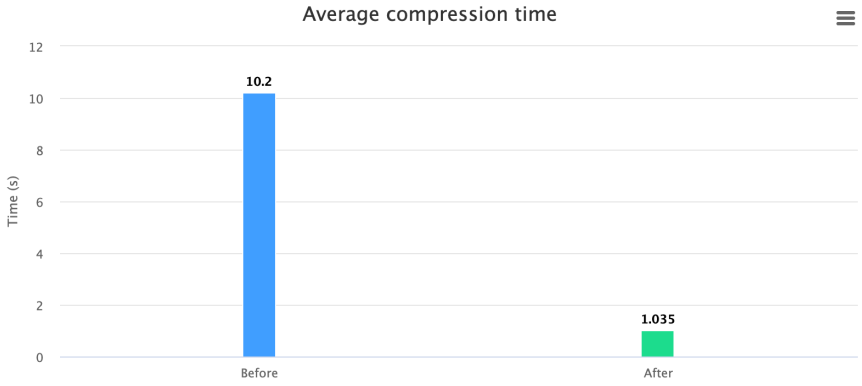

压缩平均节省了 90% 的时间。

写在后面

- 由于文中提到的一些方案涉及到具体平台环境的 CPU 指令集，甚至库的编译环境，编译参数也会影响具体的效果，所以推荐在方案实施的时候对集群环境保持统一，也可为集群环境做特殊的定制优化。
- 为 Centos 打包 RPM 文件的时候尤其需要注意下编译环境的配置，否则可能效果和测试会有出入。
- Java 的 Jar 包 和 War 包也可能进行压缩，针对这种场景，压缩率的确提升不大，但是速度依旧有提升。

作者简介

宏达，美团基础技术部研发工程师。

团队简介

基础技术部 – 研发质量及效率部 – 代码仓库和构建组，团队旨在建设代码仓库管理、协作及代码构建能力，完善多维度的工作流执行引擎及构建工具链，与公司其他研发工具打通，提高业务整体的开发、交付效率。

附录

机器环境

文中的测试统一在如下物理机中进行，测试中使用相同的目标文件。测试 机使用的是非 PCIE SSD 磁盘。

```
inxi -Fx 省略部分数据输出如下，其中一些并行指令集在优化中可能会使用到。其中 flags 中可以看到支持 avx avx2 指令集，并不支持 avx-512 ，不过仍然有很大性能提升。
System:    Host: ****** Kernel: ****** bits: 64 compiler: gcc v: 4.8.5
Console: tty 7 Distro: CentOS Linux release 7.1.1503 (Core)

CPU:       Info: 2x 16-Core model: Intel Xeon Gold 5218 bits: 64
type: MT MCP SMP arch: Cascade Lake rev: 7 L2 cache: 44.0 MiB

           flags: avx avx2 lm nx pae sse sse2 sse3 sse4_1 sse4_2
ssse3 vmx bogomips: 293978 Speed: 2300 MHz min/max: N/A

Info:        Processes: 764  Memory: 187.19 GiB used: 15.05 GiB
(8.0%) Init: systemd runlevel: 3 Compilers: gcc: 4.8.5


/proc/cpuinfo 文件中也可以查看 CPU 支持的指令集
```

```
flags         : fpu vme de pse tsc msr pae mce cx8 apic sep mtrr pge mca cmov
at pse36 clflush dts acpi mmx fxsr sse sse2 ss ht tm pbe syscall nx pdpe1gb
rdtscp lm constant_tsc art arch_perfmon pebs bts rep_good nopl xtopology
nonstop_tsc aperfmperf eagerfpu pni pclmulqdq dtes64 monitor ds_cpl vmx
smx est tm2 ssse3 sdbg fma cx16 xtpr pdcm pcid dca sse4_1 sse4_2 x2apic movbe
popcnt aes xsave avx f16c rdrand lahf_lm abm 3dnowprefetch epb cat_l3 cdp_l3
intel_ppin intel_pt ssbd mba ibrs ibpb stibp tpr_shadow vnmi flexpriority
ept vpid fsgsbase tsc_adjust bmi1 hle avx2 smep bmi2 erms invpcid rtm cqm
mpx rdt_a avx512f avx512dq rdseed adx smap clflushopt clwb avx512cd avx512bw
avx512vl xsaveopt xsavec xgetbv1 cqm_llc cqm_occup_llc cqm_mbm_total cqm_mbm
_local dtherm ida arat pln pts pku ospke spec_ctrl intel_stibp flush_l1d
arch_capabilities
```

参考文献

- https://engineering.fb.com/core-data/smaller-and-faster-data-compression-with-zstandard/
- https://engineering.fb.com/core-data/zstandard/
- https://peazip.github.io/fast-compression-benchmark-brotli-zstandard.html
- https://news.ycombinator.com/item?id=16227526
- https://github.com/facebook/zstd

- http://fastcompression.blogspot.com/2013/12/finite-state-entropy-new-breed-of.html
- https://zlib.net/pigz/
- https://cran.r-project.org/web/packages/brotli/vignettes/brotli-2015-09-22.pdf
- https://bugs.python.org/issue41566
- https://01.org/sites/default/files/documentation/isa-l_api_2.28.0.pdf
- https://www.intel.com/content/dam/www/public/us/en/documents/white-papers/fast-crc-computation-generic-polynomials-pclmulqdq-paper.pdf

招聘信息

美团研发质量及效率部 – 研发平台团队，致力于建设业界一流的持续交付平台，现招聘构建与制品库、代码仓库、服务发布、流水线等多个方向的工程师，坐标北京 / 上海。欢迎感兴趣的同学加入。可投递简历至：dongjing04@meituan.com（邮件主题请注明：美团研发质量及效率部 – 研发平台）

百亿规模 API 网关服务 Shepherd 的设计与实现

作者：充泽　志洋　李敏

一、背景介绍

1.1 API 网关是什么?

API 网关是随着微服务（Microservice）概念兴起的一种架构模式。原本一个庞大的单体应用（All in one）业务系统被拆分成许多微服务（Microservice）系统进行独立的维护和部署，服务拆分带来的变化是 API 的规模成倍增长，API 的管理难度也在日益增加，使用 API 网关发布和管理 API 逐渐成为一种趋势。一般来说，API 网关是运行于外部请求与内部服务之间的一个流量入口，实现对外部请求的协议转换、鉴权、流控、参数校验、监控等通用功能。

1.2 为什么要做 Shepherd API 网关?

在没有 Shepherd API 网关之前，美团业务研发人员如果要将内部服务输出为对外的 HTTP API 接口。通常要搭建一个 Web 应用，用于完成基础的鉴权、限流、监控日志、参数校验、协议转换等工作，同时需要维护代码逻辑、基础组件的升级，研发效率相对比较低。此外，每个 Web 应用都需要维护机器、配置、数据库等，资源利用率也非常差。

美团内部一些业务线苦于没有现成的解决方案，根据自身业务特点，研发了业务相关的 API 网关。放眼业界，亚马逊、阿里巴巴、腾讯等公司也都有成熟的 API 网关解决方案。

因此，Shepherd API 网关项目正式立项，我们的目标是为美团提供高性能、高可用、可扩展的统一 API 网关解决方案，让业务研发人员通过配置的方式即可对外开放功能和数据。

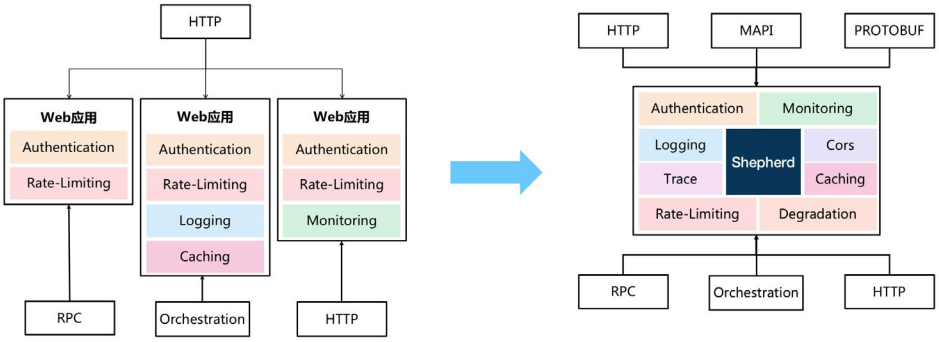

图 1

1.3 使用 Shepherd 带来的收益是什么?

从业务研发人员的角度来看，接入 Shepherd API 网关，能带来哪些收益呢？简而言之包括三个方面。

- **提升研发效率**
  - 业务研发人员只需要通过配置的方式即可快速开放服务接口。
  - Shepherd 统一提供鉴权、限流、熔断等非业务基础能力。
  - Shepherd 支持业务研发人员通过开发自定义组件的方式扩展 API 网关能力。
- **降低沟通成本**
  - 业务研发人员配置好 API，可以自动生成 API 的前后端交互文档和客户端 SDK，方便前后端开发人员进行交互、联调。
- **提升资源利用率**
  - 基于 Serverless 的架构思想，实现 API 全托管，业务研发人员无需关心机器资源问题。

二、技术设计与实现

2.1 整体架构

我们先来看看 Shepherd API 网关的整体架构，如下图所示：

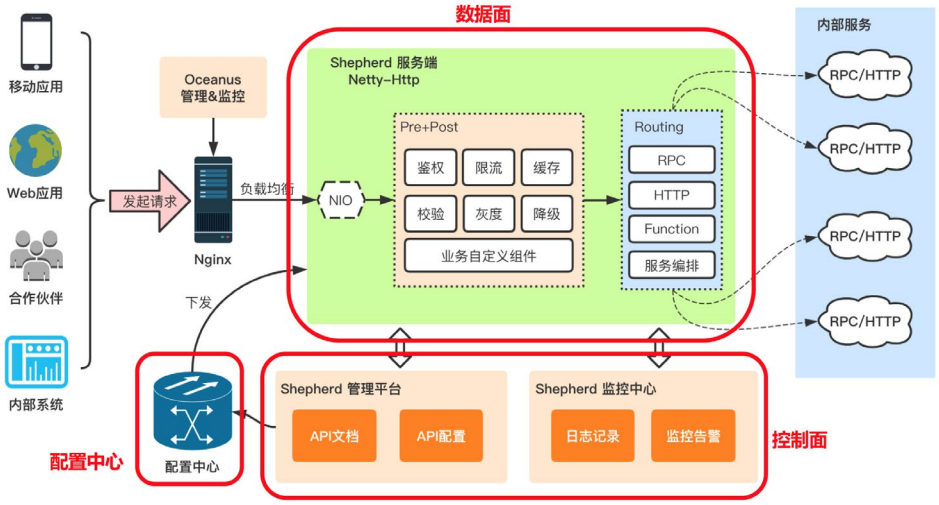

图 2

Shepherd API 网关的**控制面**由 Shepherd 管理平台和 Shepherd 监控中心组成。管理平台主要完成 API 的全生命周期管理以及配置下发的工作，监控中心完成 API 请求监控数据的收集和业务告警功能。

Shepherd API 网关的**配置中心**主要完成控制面与数据面的信息交互，通过美团统一配置服务 Lion 来实现。

Shepherd API 网关的**数据面**也就是 Shepherd 服务端。一次完整的 API 请求，可能是从移动应用、Web 应用，合作伙伴或内部系统发起，经过 Nginx 负载均衡系统后，到达服务端。服务端集成了一系列的基础功能组件和业务自定义组件，通过泛化调用请求后端 RPC 服务、HTTP 服务、函数服务或服务编排服务，最后返回响应结果。

下面我们将针对这三个主要模块做详细的介绍。

2.1.1 控制面

使用 API 网关的控制面，业务研发人员可以轻松的完成 API 的全生命周期管理，如下图所示：

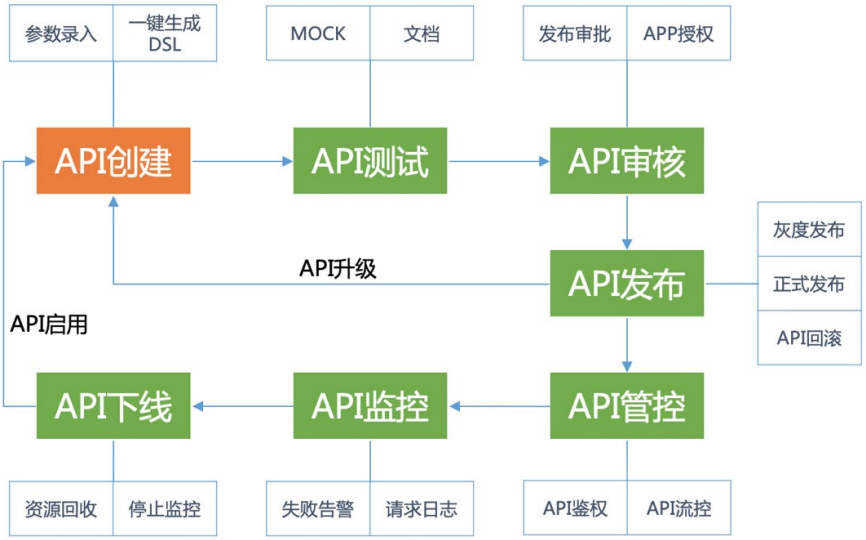

图 3

业务研发人员从创建 API 开始，完成参数录入、DSL 脚本生成；接着可以通过文档和 MOCK 功能进行 API 测试；API 测试完成后，为了保证上线稳定性，Shepherd 管理平台提供了发布审批、灰度上线、版本回滚等一系列安全保证措施；API 运行期间会监控 API 的调用失败情况、记录请求日志，一旦发现异常及时发出告警；最后，对于不再使用的 API 进行下线操作后，会回收 API 所占用的各类资源并等待重新启用。

整个生命周期，全部通过配置化、流程化的方式，由业务研发人员全自助管理，上手时间基本在 10 分钟以内，极大地提升了研发效率。

2.1.2 配置中心

API 网关的配置中心存放 API 的相关配置信息——使用自定义的 DSL（Domain-Specific Language，领域专用语言）来描述，用于向 API 网关的数据面下发 API 的路由、规则、组件等配置变更。

配置中心的设计上使用统一配置管理服务 Lion 和本地缓存结合的方式，实现动态配

置，不停机发布。API 的配置如下图所示：

图 4

API 配置的详细说明：

- **Name、Group**：名字、所属分组。
- **Request**：请求的域名、路径、参数等信息。
- **Response**：响应的结果组装、异常处理、Header、Cookies 信息。
- **Filters、FilterConfigs**：API 使用到的功能组件和配置信息。
- **Invokers**：后端服务 (RPC/HTTP/Function) 的请求规则和编排信息。

2.1.3 数据面

API 路由

API 网关的数据面在感知到 API 配置后，会在内存中建立请求路径与 API 配置的路由信息。通常 HTTP 请求路径上，会包含一些路径变量，考虑到性能问题，Shepherd 没有采用正则匹配的方式，而是设计了两种数据结构来存储。如下图所示：

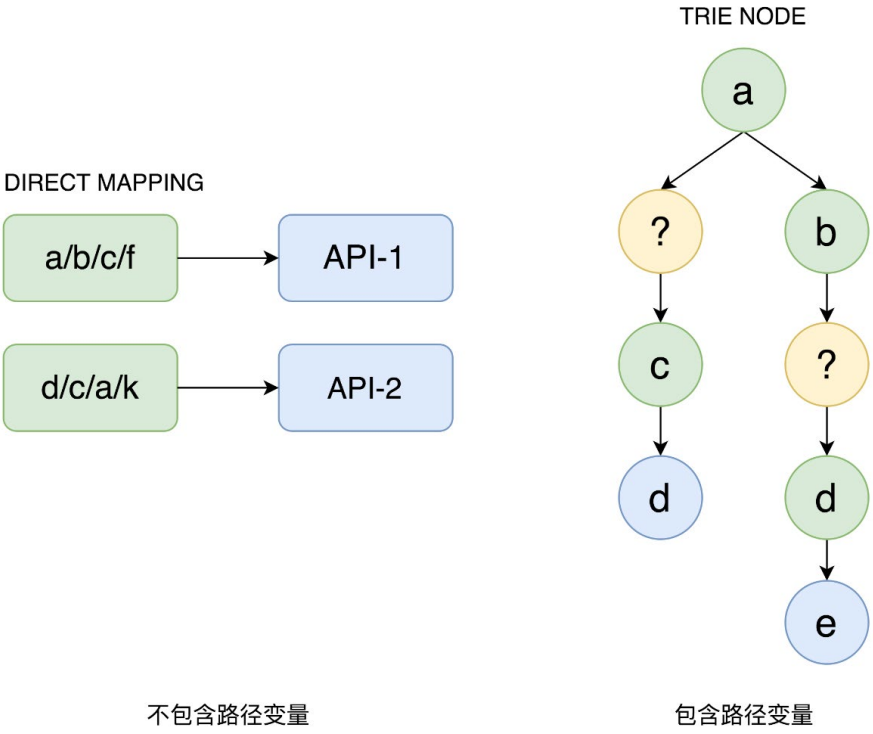

图 5

一种是不包含路径变量的直接映射的 MAP 结构。其中，Key 就是完整的域名和路径信息，Value 是具体的 API 配置。

另外一种是包含路径变量的前缀树数据结构。通过前缀匹配的方式，先进行叶子节点精确查找，并将查找节点入栈处理，如果匹配不上，则将栈顶节点出栈，再将同级的变量节点入栈，如果仍然找不到，则继续回溯，直到找到（或没找到）路径节点并退出。

功能组件

当请求流量命中 API 请求路径进入服务端，具体处理逻辑由 DSL 中配置的一系列功能组件完成。网关提供了丰富的功能组件集成，包括链路追踪、实时监控、访问日志、参数校验、鉴权、限流、熔断降级、灰度分流等，如下图所示：

图 6

协议转换 & 服务调用

API 调用的最后一步，就是协议转换以及服务调用了。网关需要完成的工作包括：获取 HTTP 请求参数、Context 本地参数，拼装后端服务参数，完成 HTTP 协议到后端服务的协议转换，调用后端服务获取响应结果并转换为 HTTP 响应结果。

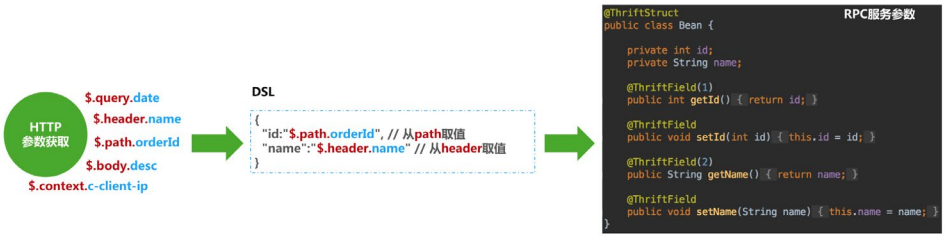

图 7

上图以调用后端 RPC 服务为例，通过 JsonPath 表达式获取 HTTP 请求不同部位的参数值，替换 RPC 请求参数相应部位的 Value，生成服务参数 DSL，最后借助 RPC 泛化调用完成本次服务调用。

2.2 高可用设计

Shepherd API 网关作为接入层的基础组件，高可用性一直是业务研发人员非常关心的部分。接下来。我们就来探索一下 Shepherd 在高可用设计方面的实践。

2.2.1 排除性能隐患

一个高可用的系统，预防故障的发生，首先要排除性能隐患，保证高性能。

Shepherd 对 API 请求做了全异步化处理，请求通过 Jetty IO 线程异步提交到业务处理线程池，调用后端服务使用 RPC 或 HTTP 框架的异步方式，释放了由于网络等待引起的线程占用，使线程数不再成为网关的瓶颈。下图是使用 Jetty 容器时，服务端的请求线程处理逻辑：

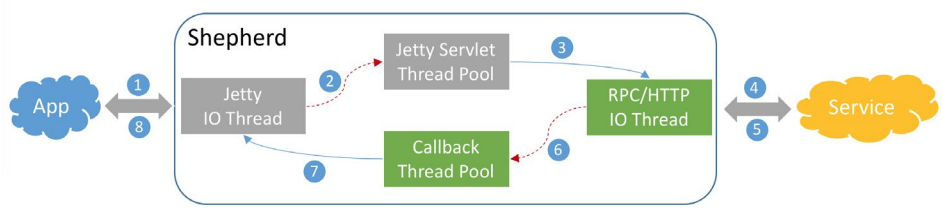

图 8

我们通过域名压测网关单机的端到端 QPS，发现 QPS 在超过 2000 时，会出现很多超时错误，而网关的服务端负载与性能却非常富余。调研发现，公司内其他的 Web 应用都存在这个问题，与 Oceanus 团队进行联合排查后，发现是 Nginx 与 Web 应用之间的长连接功能没有打开，且无法配置。Oceanus 团队经过紧急排期，研发并上线长连接功能后，Shepherd 端到端的 QPS 成功提升到了 10000 以上。

另外，我们对 Shepherd 服务端进行了 API 请求预热的优化，使得网关启动时能立刻达到最佳性能，减少毛刺的发生。然后，通过压测时的 CPU 热点排查，将性能瓶颈找出，减少主链路上的本地日志打印，对请求日志进行异步化、远程化改造。Shepherd 端到端的 QPS 再次提升 30% 以上。

在 Shepherd 服务上线稳定运行一年以后，我们再次对性能进行优化，并且做了一次网络框架升级，将 Jetty 容器全面替换为 Netty 网络框架，性能提升 10% 以上，Shepherd 端到端的 QPS 成功提升到 15000 以上。下图是使用 Netty 框架时，服务端的请求线程处理逻辑：

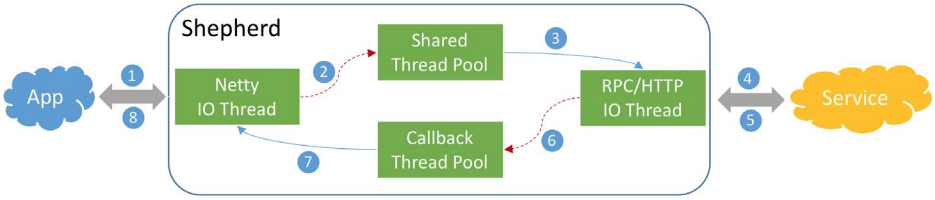

图 9

2.2.2 服务隔离

集群隔离

借鉴公司缓存、任务调度等成熟组件的经验，Shepherd 在设计之初，就考虑了按业务线维度进行集群隔离，也支持重要业务独立部署。如下图所示：

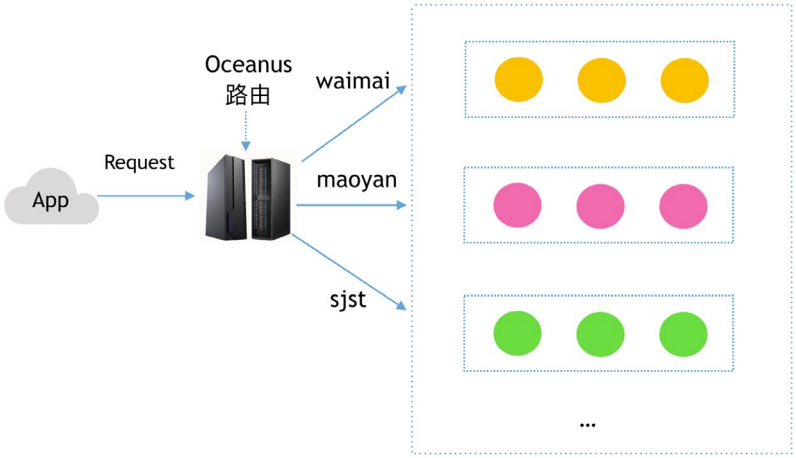

图 10

请求隔离

服务节点维度，Shepherd 支持请求的快慢线程池隔离。快慢线程池隔离主要用于一些使用了同步阻塞组件的 API，例如 SSO 鉴权、自定义鉴权等，可能导致长时间阻塞共享业务线程池。

快慢隔离的原理是统计 API 请求的处理时间，将请求处理耗时较长，超过容忍阈值的

API 请求隔离到慢线程池，避免影响其他正常 API 的调用。

除此之外，Shepherd 也支持业务研发人员配置自定义线程池进行隔离。具体的线程隔离模型如下图所示：

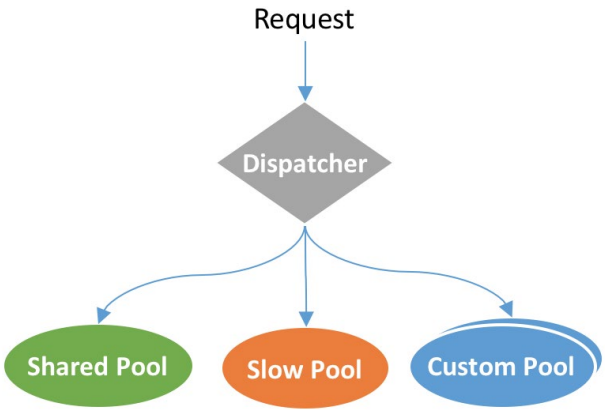

图 11

2.2.3 稳定性保障

Shepherd 提供了一些常规的稳定性保障手段，来保证自身和后端服务的可用性。如下图所示：

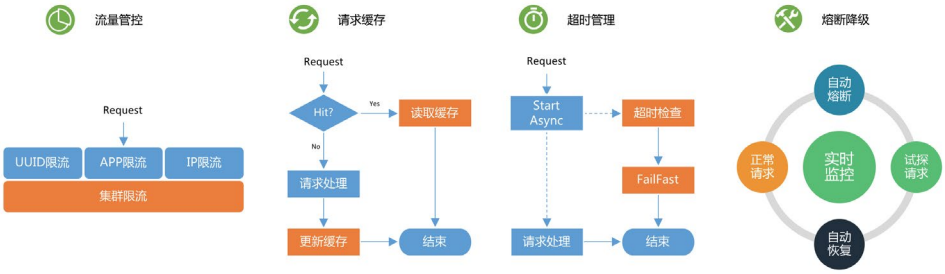

图 12

- **流量管控**：从用户自定义 UUID 限流、App 限流、IP 限流、集群限流等多个维度提供流量保护。
- **请求缓存**：对于一些幂等的、查询频繁的、数据及时性不敏感的请求，业务研

发人员可开启请求缓存功能。

- **超时管理**：每个 API 都设置了处理超时时间，对于超时的请求，进行快速失败的处理，避免资源占用。
- **熔断降级**：支持熔断降级功能，实时监控请求的统计信息，达到配置的失败阈值后，自动熔断，返回默认值。

2.2.4 请求安全

请求安全是 API 网关非常重要的能力，Shepherd 集成了丰富的安全相关的系统组件，包括有基础的请求签名、SSO 单点登录、基于 SSO 鉴权的 UAC/UPM 访问控制、用户鉴权 Passport、商家鉴权 EPassport、商家权益鉴权、反爬等等。业务研发人员只需要简单配置，即可使用。

2.2.5 可灰度

API 网关作为请求入口，往往肩负着请求流量灰度验证的重任。

灰度场景

Shepherd 在灰度能力上，支持灰度 API 自身逻辑，也支持灰度下游服务，也可以同时灰度 API 自身逻辑和下游服务。如下图所示：

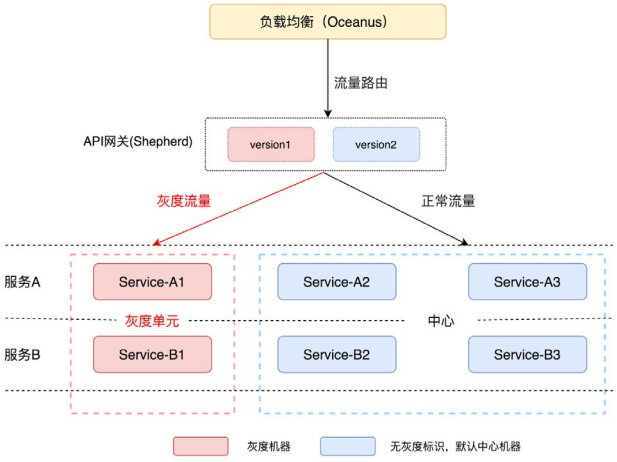

图 13

灰度 API 自身逻辑时，通过将流量分流到不同的 API 版本实现灰度能力；灰度下游服务时，通过给流量打标，分流到指定的下游灰度单元中。

灰度策略

Shepherd 支持丰富的灰度策略，可以按照比例数灰度，也可以按照特定条件灰度。

2.2.6 监控告警

立体化监控

Shepherd 提供 360 度的立体化监控，从业务指标、机器指标、JVM 指标提供 7x24 小时的专业守护，如下表：

	监控模块	主要功能
1	统一监控 Raptor	实时上报请求调用信息、系统指标，负责应用层（JVM）监控、系统层（CPU、IO、网络）监控
2	链路追踪 Mtrace	负责全链路参数透传、全链路追踪监控
3	日志监控 Logscan	监控本地日志异常关键字：如 5xx 状态码、空指针异常等
4	远程日志中心	API 请求日志、Debug 日志、组件日志等可上报远程日志中心
5	健康检查 Scanner	对网关节点进行心跳检测和 API 状态检测，及时发现异常节点和异常 API

多维度告警

有了全面的监控体系，自然少不了配套的告警机制，主要的告警能力包括：

	告警类型	触发时机
1	限流告警	API 请求达到限流规则阈值触发限流告警
2	请求失败告警	鉴权失败、请求超时、后端服务异常等触发请求失败告警
3	组件异常告警	自定义组件处理耗时长、失败率高告警
4	API 异常告警	API 发布失败、API 检查异常时触发 API 异常告警
5	健康检查失败告警	API 心跳检查失败、网关节点不通时触发健康检查失败告警

2.2.7 故障自愈

Shepherd 服务端接入了弹性伸缩模块，可根据 CPU 等指标进行快速扩容、缩容。除此之外，还支持快速摘除问题节点，以及更细粒度的问题组件摘除。

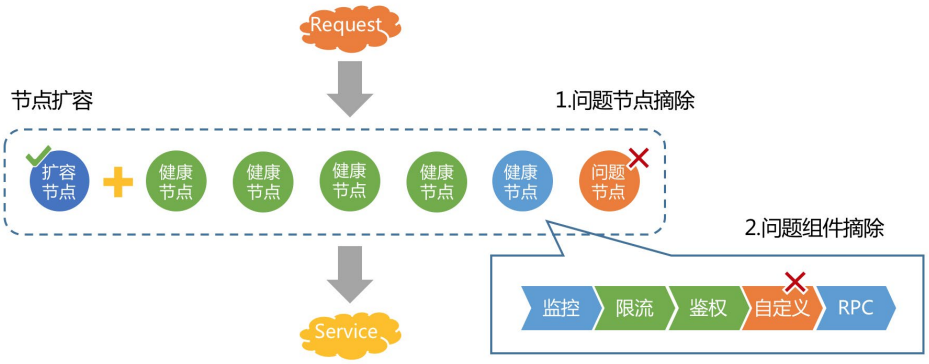

图 14

2.2.8 可迁移

对于一些已经在对外提供 API 的 Web 服务，业务研发人员为了减少运维成本和后续的研发提效，考虑将其迁移到 Shepherd API 网关。

对于一些非核心 API，可以考虑使用 Oceanus 的灰度发布功能直接迁移。但是对于一些核心 API，上面的灰度发布功能是机器级别的，粒度较大，不够灵活，不能很好的支持灰度验证过程。

解决方案

Shepherd 为业务研发人员提供了一个灰度 SDK，接入 SDK 的 Web 服务，可在识别灰度流量后转发到 Shepherd API 网关进行验证。

灰度哪些 API、灰度百分比可以在 Shepherd 管理端动态调节，实时生效，业务研发人员还可以通过 SPI 的方式自定义灰度策略。灰度验证通过后，再把 API 迁移到 Shepherd API 网关，保障迁移过程的稳定性。

灰度过程

灰度前：在 Shepherd 管理平台创建 API 分组，域名配置为目前使用的域名。在 Oceanus 上，原域名规则不变。

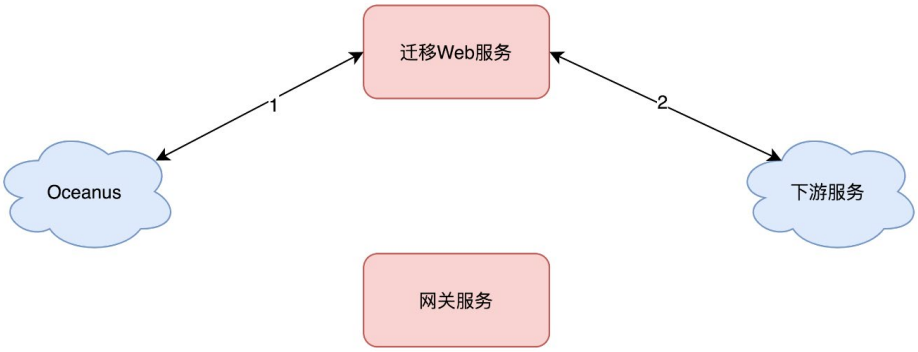

图 15

灰度中：在 Shepherd 管理平台开启灰度功能，灰度 SDK 将灰度流量转发到网关服务，进行验证。

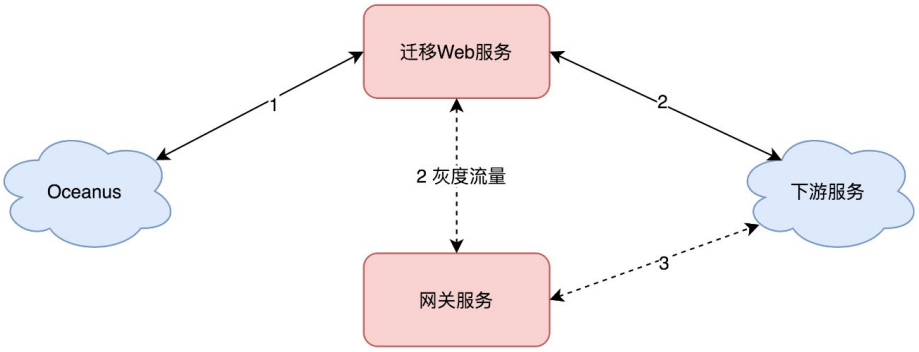

图 16

灰度后：通过灰度流量验证 Shepherd 上的 API 配置符合预期后再迁移。

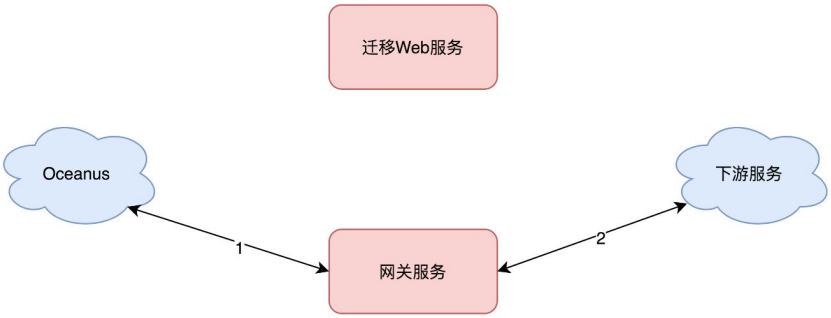

图 17

2.3 易用性设计

Shepherd API 网关的功能强大且复杂，易用性对业务研发人员来说至关重要，我们着重来看下自动生成 DSL、API 操作提效的解决方案。

2.3.1 自动生成 DSL

业务研发人员在实际使用网关管理平台时，我们尽量通过图形化的页面配置来减轻 DSL 的编写负担。但服务参数转换的 DSL 配置，仍然需要业务研发人员手工编写。一般来说，生成服务参数 DSL 的流程是：

- 引入服务的接口包依赖。
- 拿到服务参数类定义。
- 编写 Testcase 生成 JSON 模板。
- 填写参数映射规则。
- 最后手工录入管理平台，发布 API。

整个过程非常繁琐，且容易出错。如果需要录入的 API 多达几十上百个，全部由业务研发人员手工录入的效率是非常低下的。

解决方案

那么能不能将服务参数 DSL 的生成过程给自动化呢？ 答案是可以的，业务 RD 只需在网关录入 API 文档信息，然后录入服务的 Appkey、服务名、方法名信息，Shep-

herd 管理端会从最新发布的服务框架控制台获取到服务参数的 JSON Schema 信息，JSON Schema 定义了服务参数的类型和结构信息，管理端可根据这些信息，自动生成服务参数的 JSON Mock 数据。结合 API 文档的信息，自动替换参数名相同的 Value 值。 这套 DSL 自动生成方案，使用过程中对业务透明、标准化，业务方只需升级最新版本服务框架即可使用，极大提升研发效率，目前受到业务研发人员的广泛好评。

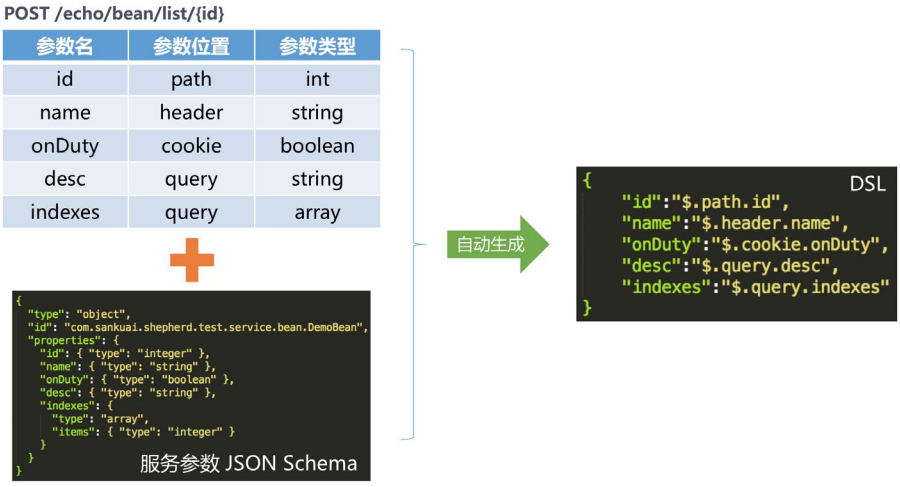

图 18

2.3.2 API 操作提效

快速创建 API

API 网关的核心能力是建立在 API 配置的基础上的，但提供强大功能的同时带来了较高的复杂性，不少业务研发人员吐槽 API 配置太繁琐，学习成本高。快速创建 API 的功能应运而生，业务研发人员只需要提供少量的信息就可以创建 API。快速创建 API 的功能当前分为 4 种类型（后端 RPC 服务 API、后端 HTTP 服务 API、SSO CallBack API、Nest API），未来会根据业务应用场景的不同，提供更多的快速创建 API 类型。

批量操作

业务研发人员在 API 网关上，需要管理非常多的业务分组，每个业务分组，最多可以有 200 个 API 配置，多个 API 可能有很多相同的配置，如组件配置，错误码配置和跨域配置的。每个 API 对于相同的配置都要配置一遍，操作重复度很高。因此 Shepherd 支持批量操作多个 API：勾选多个 API 后，通过【批量操作】功能可一次性完成多个 API 配置更新，降低业务重复配置的操作成本。

API 导入导出

Shepherd 提供在不同研发环境相互导入导出 API 的能力，业务研发人员在线下测试完成后，只需要使用 API 导入导出功能，即可将配置导出到线上生产环境，避免重复配置。

2.4 可扩展性设计

一个设计良好的基础组件，除了能提供强大的基础能力，还需要有良好的扩展能力。Shepherd 的可扩展性主要体现在：支持自定义组件、服务编排的能力。

2.4.1 自定义组件

Shepherd 提供了丰富的系统组件完成鉴权、限流、监控能力，能够满足大部分的业务需求。但仍有一些特殊的业务需求，如自定义验签、自定义结果处理等。Shepherd 通过提供加载自定义组件能力，支持业务完成一些自定义逻辑的扩展。

下图是自定义组件实现的一个实例。getName 中填写自定义组件申请时的名称，invoke 方法中实现自定义组件的业务逻辑，如继续执行、进行页面跳转、直接返回结果、抛出异常等。

```
public class TestFilter implements InvocationFilter<BaseProcessContext> {
    @Override
    public String getName() { return "test_filter"; }

    @Override
    public InvocationResponse invoke(InvocationHandler handler,
                                     BaseProcessContext processContext)
            throws Throwable {
        String opType = processContext.getRequest().getQueries().get("opType");

        if ("继续执行".equalsIgnoreCase(opType)) {
            return handler.handle(processContext);

        } else if ("页面跳转".equalsIgnoreCase(opType)) {
            return APIUtils.redirect( redirectUrl: "http://www.meituan.com", processContext);

        } else if ("直接返回结果".equalsIgnoreCase(opType)) {
            Response httpRes = new Response<>().success("默认结果");
            return APIUtils.writeSuccessResponse(httpRes, processContext);

        } else {
            throw new ParamCheckException("错误的操作类型");
        }
    }
}
```

图 19

目前 Shepherd 通过自定义组件已经成功支持了美团优选、外卖、餐饮、打车等重要业务，接入的自定义组件数量有 200 多个。

2.4.2 服务编排

一般情况下，网关上配置的一个 API 对应后端一个 RPC 或者 HTTP 服务。如果调用端有聚合和编排后端服务的需求，那么有多少后端服务，就必须发起多少次 HTTP 的请求调用。由此就会带来一些问题，调用端的 HTTP 请求次数过多，效率低，在调用端聚合服务的逻辑过重。

服务编排的需求应运而生，服务编排是对既有服务进行编排调用，同时对获取的数据进行处理。主要应用在数据聚合场景：一次 HTTP 请求返回的数据需要调用多个或多次服务（RPC 或 HTTP）才能获取到完整的结果。

经过前期调研，公司已经有一套成熟的服务编排框架，由客服团队开发的海盗组件（参见《海盗中间件：美团服务体验平台对接业务数据的最佳实践》一文），也是美团

内部的公共服务。

因此我们与海盗团队合作，设计了 Shepherd 的服务编排支持方案。海盗通过独立部署的方式提供服务编排能力，Shepherd 与海盗之间通过 RPC 进行调用。这样可以解耦 Shepherd 与海盗，避免因服务编排能力影响集群上的其他服务，同时多一次 RPC 调用并不会有明显耗时增加。使用上对业务研发人员也是透明的，非常方便，业务研发人员在管理端配置好服务编排的 API，通过配置中心同时下发到 Shepherd 服务端和海盗服务上，即可开始使用服务编排能力。整体的交互架构图如下：

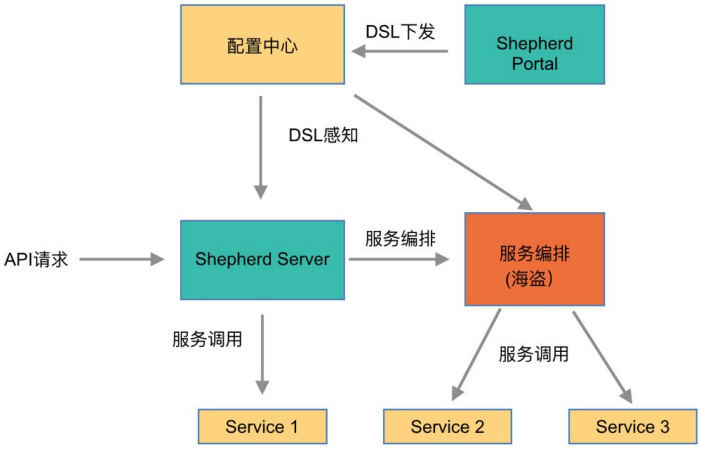

图 20

三、未来规划

目前接入 Shepherd API 网关的 API 数量超过 18000 多个，线上运行的集群数量 90 多个，日均总调用次数在百亿以上。随着 Shepherd API 网关业务规模的不断增长，对我们的可用性、易用性、可扩展性必将提出更高的要求。未来一年，Shepherd 的规划重点包括有云原生架构演进、静态网站托管、组件市场等。

3.1 云原生架构演进

Shepherd API 网关的云原生架构演进有三个目标：简化接入网关步骤，提升业

务研发人员的研发效率；减小服务端 War 包大小，提升安全性和稳定性；接入 Serverless 弹性，降低成本，提高资源利用率。

为了实现这个三个目标，我们计划整体迁移网关服务到公司的 Serverless 服务 Nest（参见《美团 Serverless 平台 Nest 的探索与实践》一文）上，同时通过抽取 Shepherd 核心功能到 SDK 的方式集成到业务的网关集群，业务研发人员可以只选择自己需要使用的自定义组件，从而大幅减小服务端的 War 包大小。

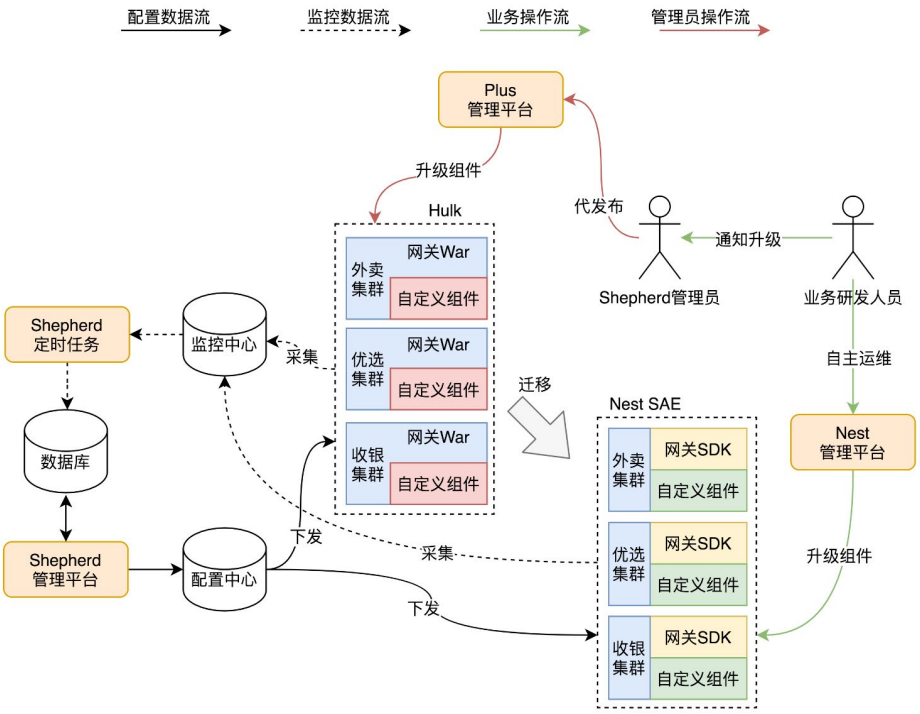

图 21

3.2 静态网站托管

依托 Shepherd API 网关实现静态网站托管的目标是：**建设通用的静态网站托管解决方案，为开发者提供便捷、稳定、高扩展性的静态网站托管服务**。

静态网站托管解决方案能为业务研发人员提供的主要功能包括：托管静态网站资源，

包括存储及访问；管理应用生命周期，包括自定义域配置以及身份验证和授权；CI/CD 集成等。

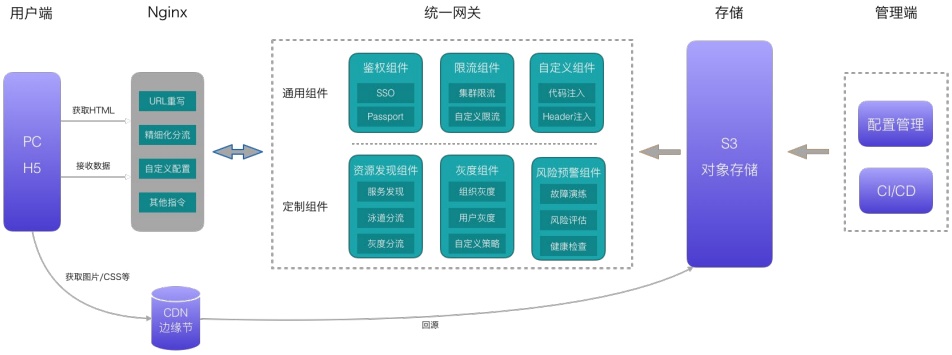

图 22

3.3 组件市场

Shepherd API 网关组件市场的目标是：**合作共赢，形成开发生态，业务研发人员可将开发的自定义组件提供给其他有需要的业务研发团队使用**。

我们希望让业务研发人员参与到自定义组件的开发，完善使用文档后设置为公共组件，开放给所有使用 Shepherd 的业务研发人员使用，避免重复造轮子。

作者简介

充泽、志洋、李敏等，均来自美团基础技术部 – 基础架构团队。

招聘信息

美团基础技术部 – 基础架构团队诚招高级、资深技术专家，Base 北京、上海。我们致力于建设美团全公司统一的高并发高性能分布式基础架构平台，涵盖数据库、分布式监控、服务治理、高性能通信、消息中间件、基础存储、容器化、集群调度等基础架构主要的技术领域。欢迎有兴趣的同学投送简历至：edp.itu.zhaopin@meituan.com。

TensorFlow 在推荐系统中的分布式训练优化实践

作者：逸帆 家恒 峥少 鹏鹏 永宇 正阳 黄军

1. 背景

TensorFlow（下文简称 TF）是谷歌推出的一个开源深度学习框架，在美团推荐系统场景中得到了广泛的使用。但 TensorFlow 官方版本对工业级场景的支持，目前做得并不是特别的完善。美团在大规模生产落地的过程中，遇到了以下几方面的挑战：

- 所有参数都是用 Variable 表达，对于百亿以上的稀疏参数开辟了大量的内存，造成了资源的浪费；
- 只支持百级别 Worker 的分布式扩展，对上千 Worker 的扩展性较差；
- 由于不支持大规模稀疏参数动态添加、删除，增量导出，导致无法支持 Online Learning；
- 大规模集群运行时，会遇到慢机和宕机；由于框架层不能处理，导会致任务运行异常。

以上这些问题，并不是 TensorFlow 设计的问题，更多是底层实现的问题。考虑到美团大量业务的使用习惯以及社区的兼容性，我们基于原生 TensorFlow 1.x 架构与接口，从大规模稀疏参数的支持、训练模式、分布式通信优化、流水线优化、算子优化融合等多维度进行了深度定制，从而解决了该场景的核心痛点问题。

首先新系统在支持能力层面，目前可以做到千亿参数模型，上千 Worker 分布式训练的近线性加速，全年样本数据能够 1 天内完成训练，并支持 Online Learning 的能力。同时，新系统的各种架构和接口更加友好，美团内部包括美团外卖、美团优选、美团搜索、广告平台、大众点评 Feeds 等业务部门都在使用。**本文将重点介绍大规模分布式训练优化的工作**，希望对大家能够有所帮助或启发。

2. 大规模训练优化挑战

2.1 业务迭代带来的挑战

随着美团业务的发展，推荐系统模型的规模和复杂度也在快速增长，具体表现如下：

- **训练数据**：训练样本从到百亿增长到千亿，增长了近 10 倍。
- **稀疏参数**：个数从几百到几千，也增长了近 10 倍；总参数量从几亿增长到百亿，增长了 10~20 倍。
- **模型复杂度**：越来越复杂，模型单步计算时间增长 10 倍以上。

对于大流量业务，一次训练实验，从几个小时增长到了几天，而此场景一次实验保持在 1 天之内是基本的需求。

2.2 系统负载分析

2.2.1 问题分析工具链

TensorFlow 是一个非常庞大的开源项目，代码有几百万行之多，原生系统的监控指标太粗，且不支持全局的监控，如果要定位一些复杂的性能瓶颈点，就比较困难。我们基于美团已经开源的监控系统 CAT[2]，构建了 TensorFlow 的细粒度监控链路（如下图 1 所示），可以精准定位到性能的瓶颈问题。

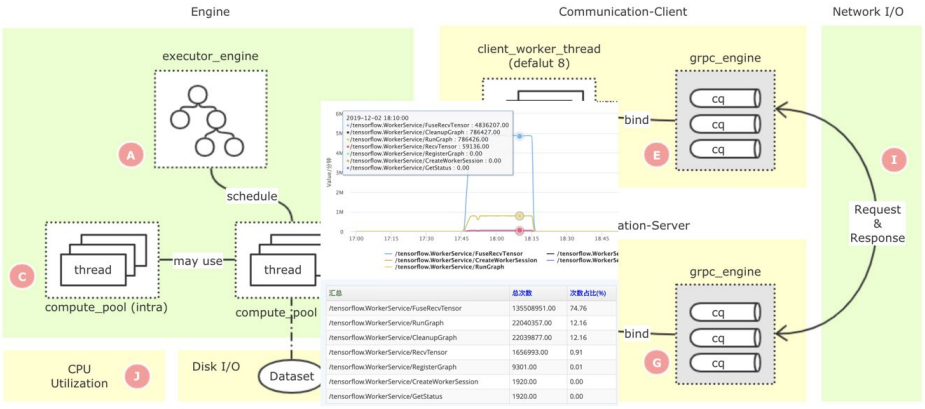

图 1　TensorFlow PS 架构全链路监控

同时，在性能优化的过程中，会涉及到大量的性能测试和结果分析，这也是一个非常耗费人力的工作。我们抽象了一套自动化的实验框架（如下图 2 所示），可以自动化、多轮次地进行实验，并自动采集各类监控指标，然后生成报告。

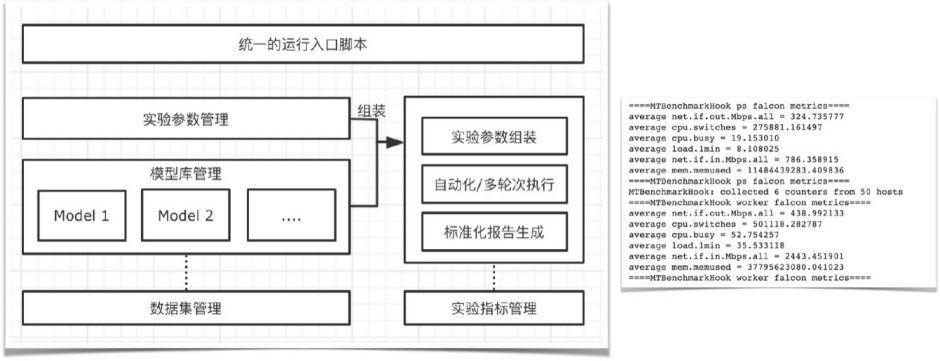

图 2　自动化实验框架

2.2.2 业务视角的负载分析

在推荐系统场景中，我们使用了 TensorFlow Parameter Server[3]（简称 PS）异步训练模式来支持业务分布式训练需求。对于这套架构，上述的业务变化会带来什么样的负载变化？如下图 3 所示：

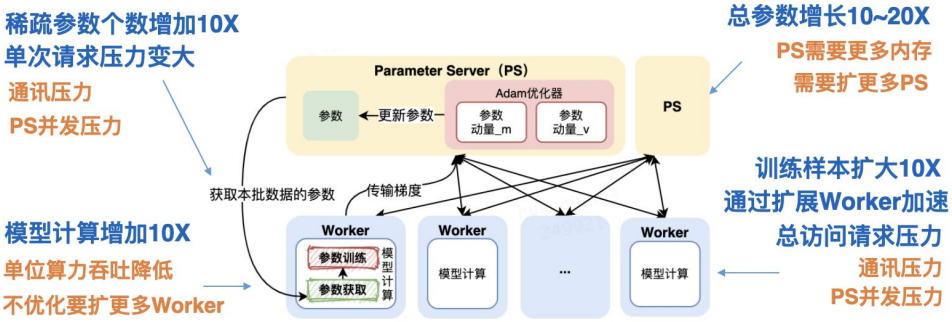

图 3　TensorFlow PS 架构大规模训练负载分析

总结来看，主要包括通信压力、PS 并发压力、Worker 计算压力。对于分布式系统来说，通常是通过横向扩展来解决负载问题。虽然看来起可以解决问题，但从实验结

果来看，当 PS 扩展到一定数量后，单步训练时间反而会增加，如下图 4 所示：

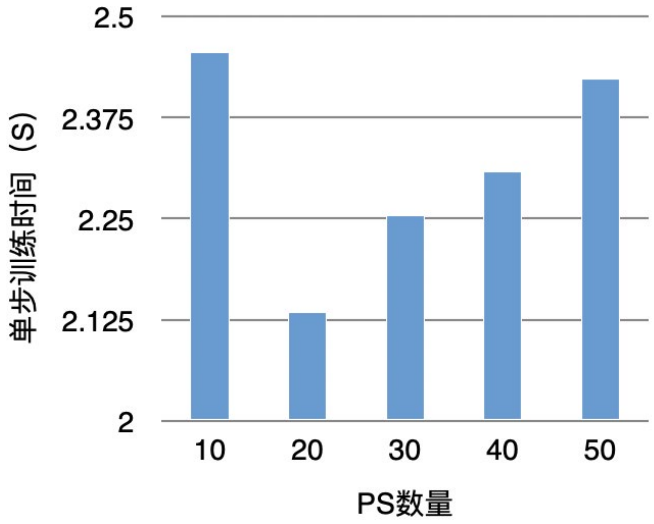

图 4　扩展 PS 提升训练性能实验

导致这种结果的核心原因是：Worker 单步训练需要和所有的 PS 通信同步完成，每增加 1 个 PS 要增加 N 条通信链路，这大大增加了链路延迟（如下图 5 所示）。而一次训练要执行上百万、上千万步训练。最终导致**链路延迟超过了加 PS 算力并发的收益**。

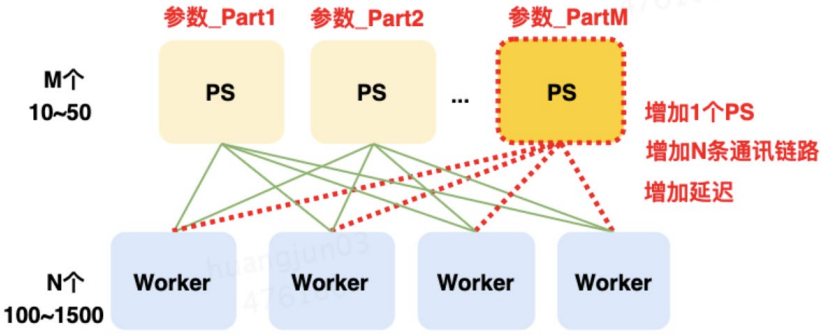

图 5　增加 PS 带来的链路开销

而对于这个系统，优化的核心难点在于：**如何在有限的 PS 实例下，进行分布式计算的优化**。

3. 优化实践

3.1 大规模稀疏参数介绍

对于推荐系统模型，绝大多数参数都是稀疏参数，而对稀疏参数来说有一个非常重要的操作是 Embedding，这个操作通常也是负载最重的，也是后续优化的重点。由于我们对稀疏参数进行了重新定义，后续的优化也基于此之上，所以我们先介绍一下这部分的工作。

在原生的 TensorFlow 中构建 Embedding 模块，用户需要首先创建一个足够装得下所有稀疏参数的 Variable，然后在这个 Variable 上进行 Embedding 的学习。然而，使用 Variable 来进行 Embedding 训练存在很多弊端：

- Variable 的大小必须提前设定好，对于百亿千亿的场景，该设定会带来巨大的空间浪费；
- 训练速度慢，无法针对稀疏模型进行定制优化。

我们首先解决了有无的问题，使用 HashTable 来替代 Variable，将稀疏特征 ID 作为 Key，Embedding 向量作为 Value。相比原生使用 Variable 进行 Embedding 的方式，具备以下的优势：

- HashTable 的大小可以在训练过程中自动伸缩，避免了开辟冗余的存储空间，同时用户无需关注申请大小，从而降低了使用成本。
- 针对 HashTable 方案实施了一系列定制优化，训练速度相比 Variable 有了很大的提高，可以进行千亿规模模型的训练，扩展性较好。
- 得益于稀疏参数的动态伸缩，我们在此基础上支持了 Online Learning。
- API 设计上保持与社区版本兼容，在使用上几乎与原生 Variable 一致，对接成本极低。

简化版的基于 PS 架构的实现示意如下图 6 所示：

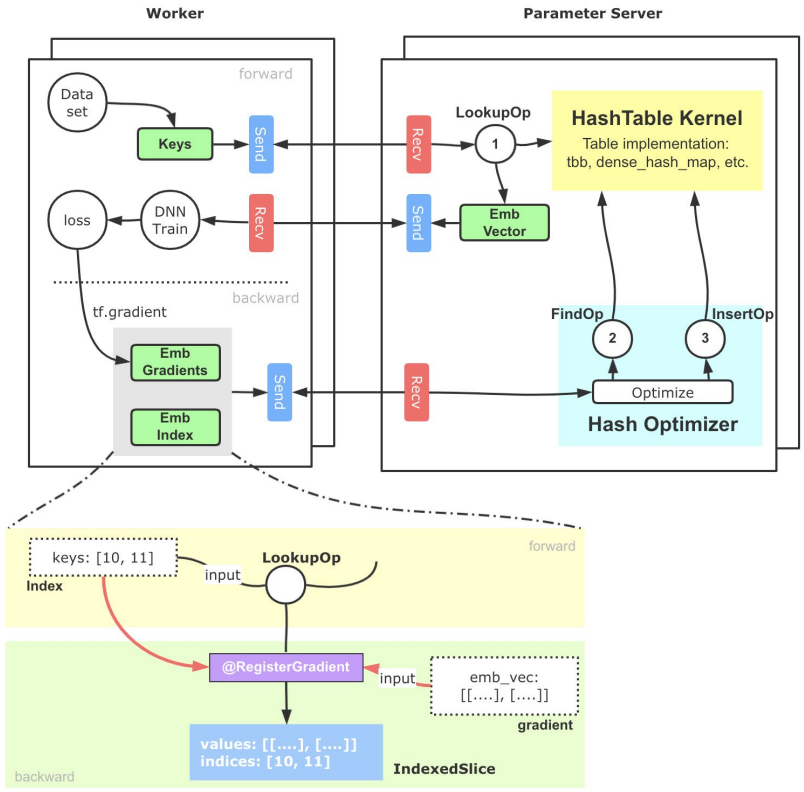

图 6　支撑大规模稀疏参数的 HashTable 方案

核心流程大致可以分为以下几步：

- 稀疏特征 ID（通常我们会提前完成统一编码的工作）进入 Embedding 模块，借助 TensorFlow 搭建的 Send-Recv 机制，这些稀疏特征 ID 被拉取到 PS 端，PS 端上的 Lookup 等算子会实际从底层 HashTable 中查询并组装 Embedding 向量。
- 上述 Embedding 向量被 Worker 拉回进行后续训练，并通过反向传播计算出这部分参数的梯度，这些梯度进一步被位于 PS 端的优化器拉回。
- PS 端的优化器首先调用 Find 算子，从 HashTable 获取到梯度对应的原始稀疏参数向量和相应的优化器参数，最终通过优化算法，完成对 Embedding 向量和优化器参数的更新计算，再通过 Insert 算子插入 HashTable 中。

3.2 分布式负载均衡优化

这部分优化，是分布式计算的经典优化方向。PS 架构是一个典型的“水桶模型”，为了完成一步训练，Worker 端需要和所有 PS 完成交互，因此 PS 之间的平衡就显得非常重要。但是在实践中，我们发现多个 PS 的耗时并不均衡，其中的原因，既包括 TensorFlow PS 架构简单的切图逻辑（Round-Robin）带来的负载不均衡，也有异构机器导致的不均衡。

对于推荐模型来说，我们的主要优化策略是，把所有稀疏参数和大的稠密参数自动、均匀的切分到每个 PS 上，可以解决大多数这类问题。而在实践过程中，我们也发现一个比较难排查的问题：原生 Adam 优化器，实现导致 PS 负载不均衡。下面会详细介绍一下。

在 Adam 优化器中，它的参数优化过程需要两个 β 参与计算，在原生 TensorFlow 的实现中，这两个 β 是所有需要此优化器进行优化的 Variabl（或 HashTable）所共享的，并且会与第一个 Variable（名字字典序）落在同一个 PS 上面，这会带来一个问题：每个优化器只拥有一个 β_1 和一个 β_2，且仅位于某个 PS 上。因此，在参数优化的过程中，该 PS 会承受远高于其他 PS 的请求，从而导致该 PS 成为性能瓶颈。

$$
\begin{aligned}
&t = t + 1 \\
&\alpha_t := \alpha * \sqrt{1 - \beta_2^t} / (1 - \beta_1^t) \\
&m_t := \beta_1 * m_{t-1} + (1 - \beta_1) * g_t \\
&v_t := \beta_2 * v_{t-1} + (1 - \beta_2) * g_t * g_t \\
&variable = variable - \frac{\alpha_t}{(\sqrt{v_t} + \epsilon)} * m_t
\end{aligned}
$$

图 7　Adam 优化算法

但是通过观察 Adam 的优化算法，我们可以看到 β_1 和 β_2 都是常量，且蓝色高亮的部分都是相对独立的计算过程，各个 PS 之间可以独立完成。基于这样的发现，优化

的方法也就非常直观了，我们为每一个 PS 上的 Adam 优化器冗余创建了 β 参数，并在本地计算 t 和 alpha 值，去除了因此负载不均导致的 PS 热点问题。

该优化所带来的提升具备普适性且效果明显，在美团内部某业务模型上，通过 β 热点去除可以带来 9% 左右的性能提升。此外，由于摆脱了对 β 的全局依赖，该优化还能提高 PS 架构的可扩展性，在扩增 Worker 数量的时候相比之前会带来更好的加速比。

3.3 通信优化

通过 2.2 章节的分析可知，系统的通信压力也非常大，我们主要基于 RDMA 做了通信优化的工作。首先简单介绍一下 RDMA，相比较于传统基于套接字 TCP/IP 协议栈的通信过程，RDMA 具有零拷贝、内核旁路的优势，不仅降低了网络的延迟，同时也降低了 CPU 的占用率，RDMA 更适合深度学习模型的相关通信过程。

RDMA 主要包括三种协议 Infiniband、RoCE(V1, V2)、iWARP。在美团内部的深度学习场景中，RDMA 通信协议使用的是 RoCE V2 协议。目前在深度学习训练领域，尤其是在稠密模型训练场景（NLP、CV 等），RDMA 已经是大规模分布式训练的标配。然而，在大规模稀疏模型的训练中，开源系统对于 RDMA 的支持非常有限，TensorFlow Verbs[4] 通信模块已经很长时间没有更新了，通信效果也并不理想，我们基于此之上进行了很多的改进工作。

经过优化后的版本，在 1TB Click Logs[5] 公开数据集、DLRM[6] 模型、100 个 Worker 以上的训练，性能提升了 20%~40%。在美团的多个业务模型上，对比 TensorFlow Seastar[7] 改造的通信层实现也有 10%~60% 的速度提升。同时也把我们的工作回馈给了社区。

3.3.1 Memory Registration 优化

RDMA 有三种数据传输的方式 SEND/RECV、WRITE、READ，其中 WRITE、READ 类似于数据发送方直接在远程 Memory 进行读写，Receiver 无法感知，WRITE 和 READ 适用于批量数据传输。在 TensorFlow 内部，基于 RDMA 的数据传输方式使用的是 WRITE 单边通信模式。

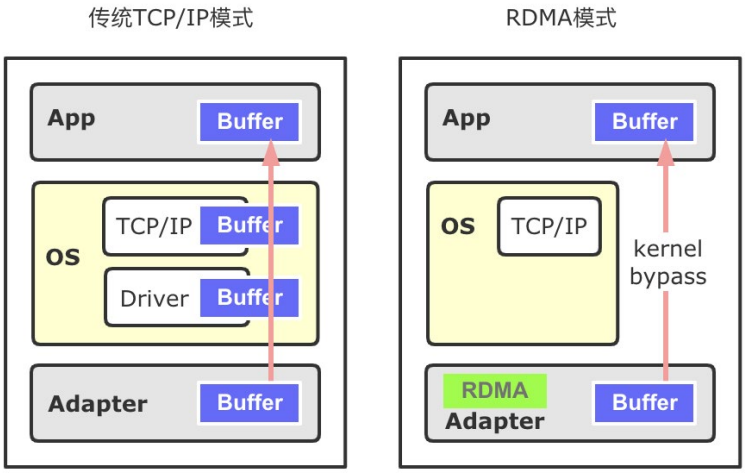

图 8　RDMA 传输方式

在 RDMA 传输数据时，需要提前开辟内存空间并将其注册到网卡设备上（Memory Registration 过程，下称 MR），使得这片空间可以被网卡直接操作。开辟新的内存并注册到设备上，整个过程是比较耗时的。下图 9 展示了不同大小的内存绑定到网卡设备上的耗时，可以看到随着注册内存的增大，绑定 MR 的耗时迅速增加。

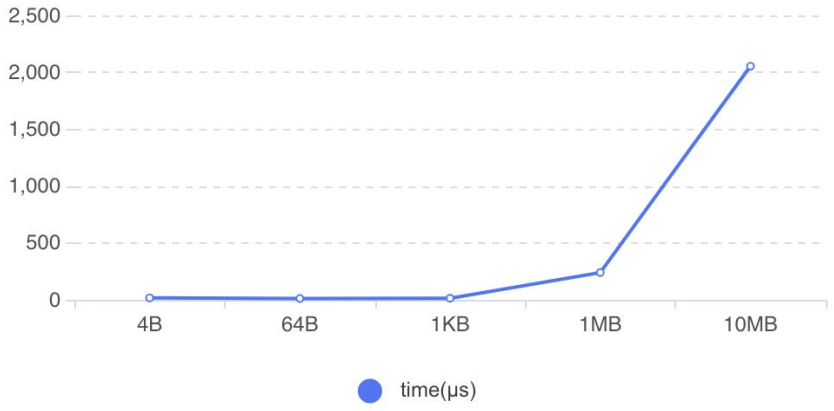

图 9　MR 过程开销

社区版 Tensorflow RDMA 实现，Tensor 创建依旧沿用了统一的 BFC Allocator，并将所有创建的 Tensor 都注册到 MR 上。正如上面所提到的，MR 的注册绑定具

有性能开销，高频、大空间的 MR 注册会带来显著的性能下降。而训练过程中的 Tensor，只有那些涉及到跨节点通信的 Tensor 有必要进行 MR，其余 Tensor 并不需要注册到 MR。因此，优化的方法也就比较直接了，我们识别并管理那些通信 Tensor，仅对这些跨节点通信的 Tensor 进行 MR 注册就好了。

3.3.2 RDMA 静态分配器

RDMA 静态分配器是上一个 MR 注册优化的延伸。通过 Memory Registration 优化，去除非传输 Tensor 的 MR 注册，我们降低了 MR 注册数量。但是在稀疏场景大规模的训练下，并行训练的 Worker 常有几百上千个，这会带来新的问题：

- PS 架构中的 PS 和 Worker 互为 Client-Server，这里以 PS 端为例，当 Worker 数目增加到上千个时，Worker 数目的增多，造成 PS 端 MR 注册频次还是非常高，增加了内存分配注册的耗时。
- 由于稀疏场景不同 Step 之间同一个算子输出 Tensor 的形状可能发生变化，导致了创建的 MR 可复用性较差，带来了较高的内存碎片和重复注册 MR 开销。

针对上面的问题，我们引入了 MR 静态分配器的策略。

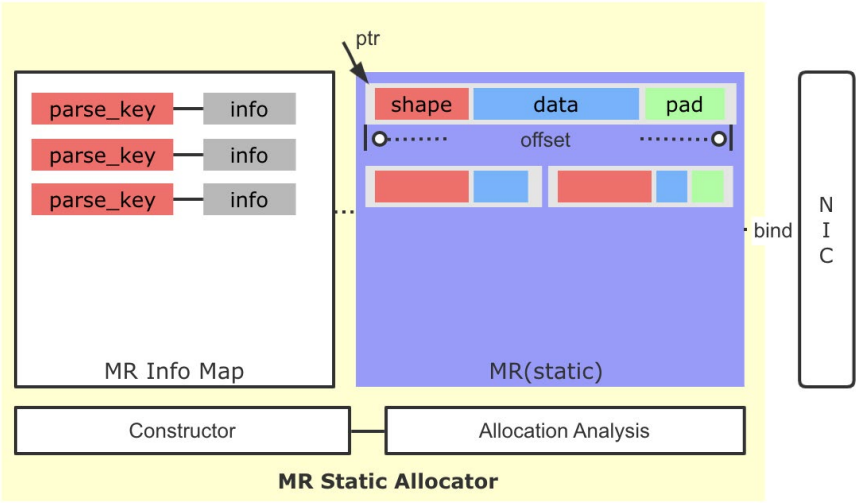

图 10　MR 静态分配器

这里核心的设计思路为：

- 虽然稀疏场景同一个算子输出 Tensor 的 Shape 存在变化的可能，但是整体变化幅度可控，通过监控与分析，是可以找到一个较为稳定的内存大小，满足多 Step 间 Tensor 的存储需求。
- 基于上面的信息，我们修改了原有逐 Tensor(Request) 的 MR 申请策略，通过一次性预申请一块较大的空间并注册到网卡端，后续通过自己维护的分配策略进行空间的分配，大大降低了 MR 申请的频率，绝大多数情况下，训练全过程中只需要一次 MR 注册申请即可。
- 我们引入了一种简单的交换协议，将传输 Tensor 的 Shape，Data 打包到一起，写到 Client 端。Client 端根据协议，解析出 Tensor 大小，并最终读取 Data，避免了原生实现中因 Tensor 的 Shape 变化而产生的多次协商过程。

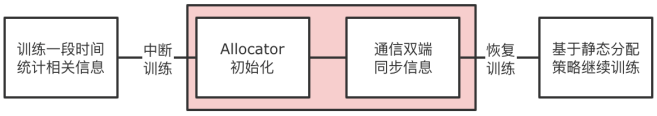

图 11　MR 静态分配器构造流程

具体到实现中，我们引入了 Allocation Analysis 模块，在训练开始的一段时间，我们会对分配的历史数据进行分析，以得到一个实际预开辟 MR 大小以及各个 Tensor 的预留空间大小。然后我们会暂停训练的进程，启动 Allocator 的构造过程，包括 MR 的创建以及通信双端的信息同步。利用相关信息构造 MR Info Map，这个 Map 的 Key 是传输 Tensor 的唯一标记（ParsedKey，计算图切图时确定），Info 结构体中包含了本地地址指针、offset 大小、ibv_send_wr 相关信息等。然后恢复训练，后续 Tensor 的传输就可以使用静态开辟好的 MR 进行收发，也免去了因 Shape 变化而产生的多次协商过程。

3.3.3 Multi RequestBuffer 与 CQ 负载均衡

TensorFlow 社区版的 RDMA 通信过程，不仅仅包含上面 Tensor 数据的发送和接收过程，还包括传输相关的控制消息的发送和接收过程，控制消息的发送和接收过程

同样是使用了 ibv_post_send 和 ibv_post_recv 原语。原生的控制流实现存在一些瓶颈，在大规模训练时会限制控制流的吞吐，进而影响数据收发的效率。具体体现在：

- 请求的发送通过同一片 RequestBuffer 内存进行写出，多个 Client 的请求均依赖这一片 Buffer，也就导致到控制流信息实际是串行发送的，只有等到对端的 Ack 信息后，才可以下一个 Request 的写出，限制了请求的发送吞吐。
- 在 Client 端需要轮询 RDMA Completion Queue 来获得请求的到达，以及相关状态的变更。原生实现仅有一个 Completion Queue，单线程进行轮询处理，在大规模分布式训练中，限制了应答的效率。

针对上面的问题，我们采用了 Multi RequestBuffer 与 CQ 负载均衡优化，破除了在请求发送和请求应答环节可能存在的吞吐瓶颈。

3.3.4 Send-Driven & Rendezvous-Bypass

对于 Tensorflow PS 架构熟悉的同学会了解，一整张计算图被切割为 Worker 端和 PS 端后，为了使两张计算图能够彼此交换数据，建立了基于 Rendezvous（汇合点）机制的异步数据交换模式。如下图 12 所示：

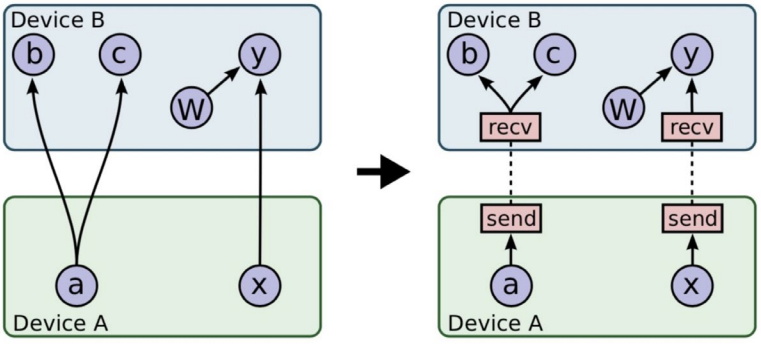

图 12　TensoFlow 切图之 Send-Recv 对添加

基于上图的切图逻辑，Recv 算子代表着这一侧计算图有 Tensor 的需求，而 Tensor 的生产者则位于与之配对的另一设备上的 Send 算子背后。

在具体实现上，Tensorflow 实现了 Recv-Driven 的数据交换模式，如上图所

示，位于 DeviceA 和 DeviceB 的两张计算图会异步并发的执行，位于 DeviceB 的 Recv 执行时会发起一条 RPC 请求发往 DeviceA，DeviceA 收到请求后，会将请求路由到 Rendezvous 中，如果在当中发现所需要的数据已经生产好，并被 Send 算子注册了进来，那么就地获取数据，返回给 DeviceB；如果此时数据还没有生产好，则将来自于 DeviceB 的 Recv 请求注册在 Rendezvous 中，等待后续 DeviceA 生产好后，由 Send 算子发送过来，找到注册的 Recv，触发回调，返回数据给 DeviceB。

我们看到，汇合点机制优雅地解决了生产者消费者节奏不同情况下数据交换的问题。不过 Recv-Driven 的模式也引入了两个潜在的问题：

- 据我们的观察，在实际业务模型中，在 Rendezvous 中 Recv 算子等待 Send 算子的比例和 Send 算子等待 Recv 算子的比例相当，也就是说对于 Send 等到 Recv 的数据，在 Send 准备好的那一刹那就可以发给对端，但是由于机制实现问题，还是等待 Recv 算子过来，才将数据拉取回去，通信过程耗时较长。
- Rendezvous 作为一个数据交换的热点，它内部的逻辑开销并不低。

针对上面提到的问题，我们在 RDMA 上实现了另外一种数据交换的模式，叫做 Send-Driven 模式。与 Recv-Driven 模式相对，顾名思义就是有 Send 算子直接将数据写到 Recv 端，Recv 端接收数据并注册到本地 Rendezvous 中，Recv 算子直接从本地的 Rendezvous 中获取数据。具体流程如下图 13 所示：

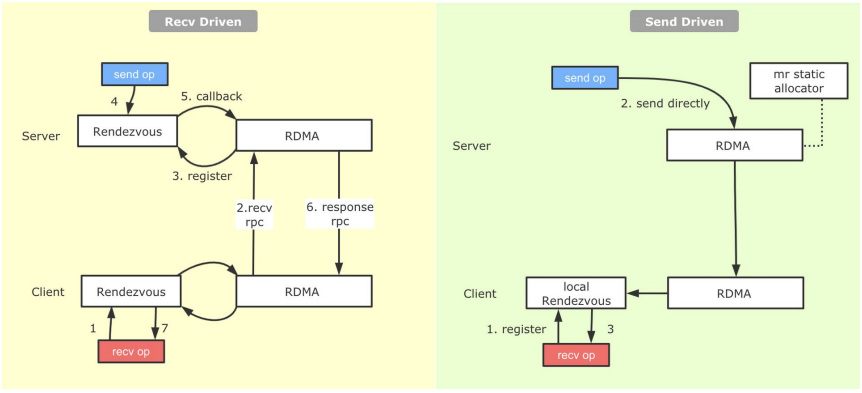

图 13　原生的 Recv-Driven 与补充的 Send-Driven 机制

从图中可以看到，相较于 Recv-Driven 模式，Send-Driven 模式的通信流程得到了比较大的简化，另外在数据 ready 后立即发送的特性，跳过了一侧的 Rendezvous，并且对于生产者先于消费者的情况，可以加快消费端数据获取的速度。

3.4 延迟优化

这部分优化，也是分布式计算的经典优化方向。整个流程链路上那些可以精简、合并、重叠需要不断去挖掘。对于机器学习系统来说，相比其它的系统，还可以用一些近似的算法来做这部分工作，从而获得较大的性能提升。下面介绍我们在两个这方面做的一些优化实践。

3.4.1 稀疏域参数聚合

在启用 HashTable 存储稀疏参数后，对应的，一些配套参数也需要替换为 HashTable 实现，这样整个计算图中会出现多张 HashTable 以及大量的相关算子。在实践中，我们发现需要尽量降低 Lookup/Insert 等算子的个数，一方面降低 PS 的负载，一方面降低 RPC QPS。因此，针对稀疏模型的常见用法，我们进行了相关的聚合工作。

以 Adam 优化器为例，需要创建 m、v 两个 slot，以保存优化中的动量信息，它的 Shape 与 Embedding 相同。在原生优化器中，这两个 Variable 是单独创建的，并在反向梯度更新的时候会去读写。同理，使用 HashTable 方案时，我们需要同时创建两张单独的 HashTable 用来训练 m、v 参数。那么在前向，反向中需要分别对 Embedding、m、v 进行一次 Lookup 和一次 Insert，总共需要三次 Lookup 和三次 Insert。

这里一个优化点就是将 Embedding、m、v，以及低频过滤的计数器（见下图 14 的 Counting HashTable）聚合到一起，作为 HashTable 的 Value，这样对稀疏参数的相关操作就可以聚合执行，大大减少了稀疏参数操作频次，降低了 PS 的压力。

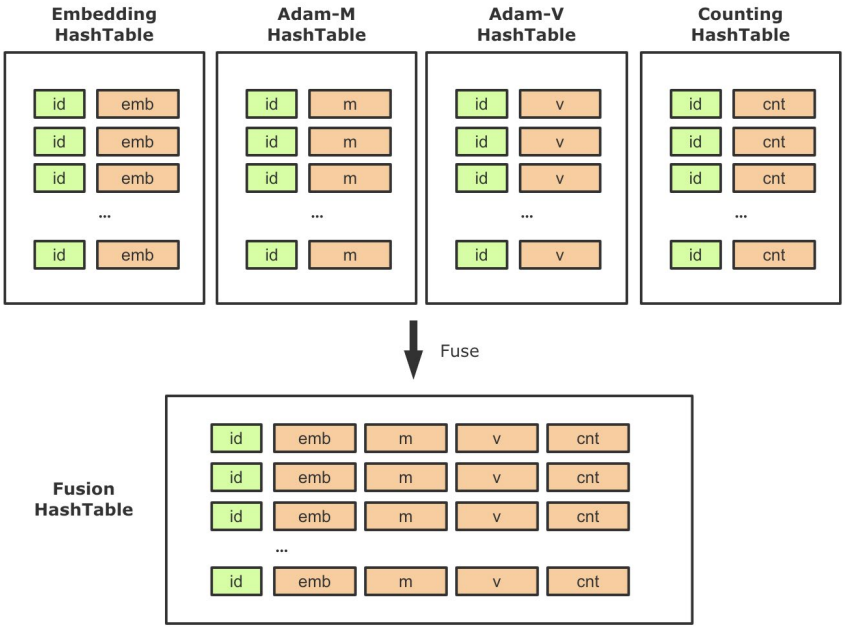

图 14　基于 HashTable 的参数融合策略

该特性属于一个普适型优化，开启聚合功能后，训练速度有了显著的提高，性能提升幅度随着模型和 Worker 规模的变化，效果总是正向的。在美团内部真实业务模型上，聚合之后性能相比非聚合方式能提升了 45% 左右。

3.4.2 Embedding 流水线优化

流水线，在工业生产中，指每一个生产单位只专注处理某个片段的工作，以提高工作效率及产量的一种生产方式。在计算机领域内，更为大家熟知的是，流水线代表一种多任务之间 Overlap 执行的并行化技术。例如在典型的 RISC 处理器中，用户的程序由大量指令构成，而一条指令的执行又可以大致分为：取指、译码、执行、访存、写回等环节。这些环节会利用到指令 Cache、数据 Cache、寄存器、ALU 等多种不同的硬件单元，在每一个指令周期内，这 5 个环节的硬件单元会并行执行，得以更加充分的利用硬件能力，以此提高整个处理器的指令吞吐性能。处理器的指令流水线是一套复杂而系统的底层技术，但其中的思想在分布式深度学习框架中也被大量的使用，例如：

- 如果将分布式训练简单的抽象为计算和通信两个过程，绝大多数主流的深度学习框架都支持在执行计算图 DAG 时，通信和计算的 Overlap。
- 如果将深度模型训练简单的分为前向和反向，在单步内，由于两者的强依赖性，无法做到有效并行，字节 BytePS[8] 中引入的通信调度打破了 step iteration 间的屏障，上一轮的部分参数更新完毕后，即可提前开始下轮的前向计算，增强了整体视角下前反向的 Overlap。
- 百度 AIBox[9] 为了解决 CTR 场景 GPU 训练时，参数位于主存，但计算位于 GPU 的问题，巧妙调度不同硬件设备，搭建起了主要利用 CPU/ 主存 / 网卡的参数预准备阶段和主要利用 GPU/NVLink 的网络计算阶段，通过两个阶段的 Overlap 达到更高的训练吞吐。

我们看到，在深度学习框架设计上，通过分析场景，可以从不同的视角发掘可并行的阶段，来提高整体的训练吞吐。

对于大规模稀疏模型训练时，核心模型流程是：先执行稀疏参数的 Embedding，然后执行稠密部分子网络。其中稀疏参数 Embedding 在远端 PS 上执行，主要耗费网络资源，而稠密部分子网络在本地 Worker 执行，主要耗费计算资源。这两部分占了整个流程的大部分时间，在美团某实际业务模型上分别耗时占比：40+%、50+%。

那我们是否可以提前执行稀疏参数的 Embedding，来做到通信和计算的 Overlap，隐藏掉这部分时间呢？从系统实现上肯定是可行的，但从算法上讲，这样做会引入参数 Staleness 的问题，可能会导致模型精度受到影响。但在实际的生产场景中，大规模异步训练时本身就会带来几十到几百个步的滞后性问题。经过我们测试，提前获取一两步的稀疏参数，模型精度并未受到影响。

在具体实现上，我们把整个计算图拆分为 Embedding Graph（EG）和 Main Graph（MG）两张子图，两者异步独立执行，做到拆分流程的 Overlap（整个拆分过程，可以做到对用户透明）。EG 主要覆盖从样本中抽取 Embedding Key，查询组装 Embedding 向量，Embedding 向量更新等环节。MG 主要包含稠密部分子网络计算、梯度计算、稠密参数部分更新等环节。

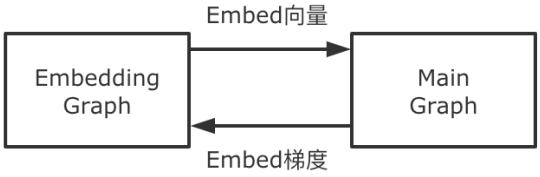

图 15　Embedding 流水线模块交互关系

两张子图的交互关系为：EG 向 MG 传递 Embeding 向量（从 MG 的视角看，是从一个稠密 Variable 读取数值）；MG 向 EG 传递 Embedding 参数对应的梯度。上述两个过程的表达都是 TensorFlow 的计算图，我们利用两个线程，两个 Session 并发的执行两张计算图，使得两个阶段 Overlap 起来，以此到达了更大的训练吞吐。

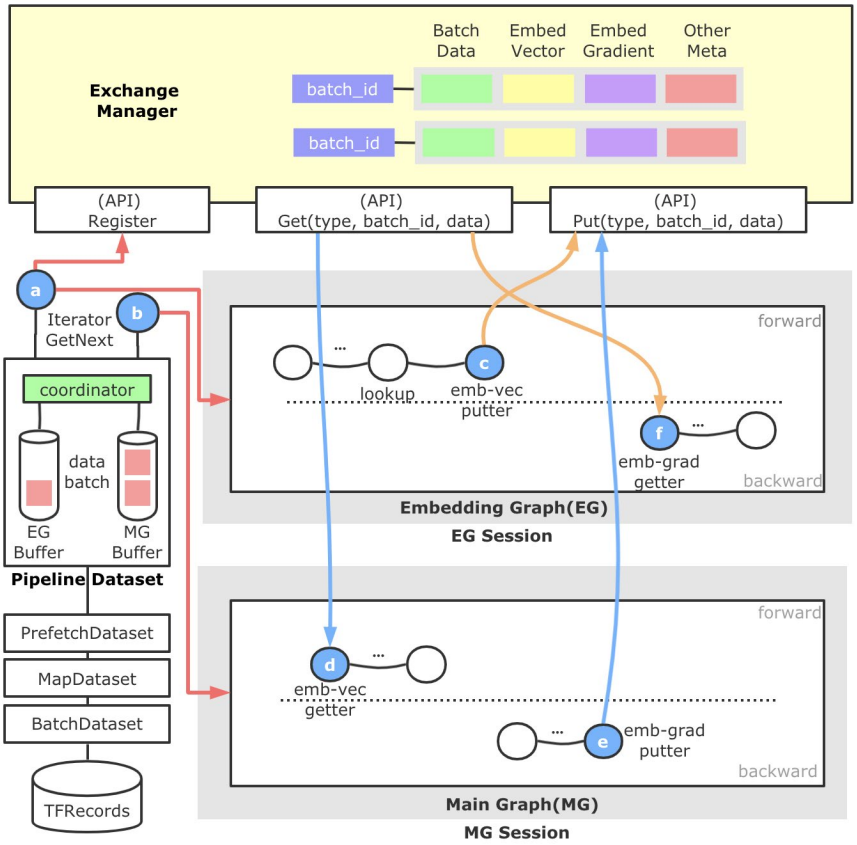

图 16　Embedding 流水线架构流程图

上图是 Embedding 流水线的架构流程图。直观来看分为左侧的样本分发模块，顶部的跨 Session 数据交换模块，以及自动图切分得到的 Embedding Graph 和 Main Graph，蓝色的圆圈代表新增算子，橙色箭头代表 EG 重点流程，蓝色箭头代表 MG 重点流程，红色箭头代表样本数据重点流程。

- 以对用户透明的形式引入了一层名为 Pipeline Dataset 的抽象层，这一层的产生是为了满足 EG/MG 两张计算图以不同节奏运行的需求，支持自定义配置。另外，为了使得整个流水线中的数据做到彼此的配套，这里还会负责进行一个全局 Batch ID 的生成及注册工作。Pipeline Dataset 对外暴露两种 Iterator，一个供 EG 使用，一个供 MG 使用。Pipeline Dataset 底部共享 TensorFlow 原生的各层 Dataset。
- 顶部的 ExchangeManager 是一个静态的，跨 Session 的数据交换媒介，对外暴露数据注册和数据拉取的能力。抽象这个模块的原因是，EG 和 MG 原本归属于一张计算图，因为流水线的原因拆解为拆为两张图，这样我们需要建立一种跨 Session 的数据交换机制，并准确进行配套。它内部以全局 Batch ID 做 Key，后面管理了样本数据、Embeding 向量、Embedding 梯度、Unique 后的 Index 等数据，并负责这些数据的生命周期管理。
- 中间的 Embedding Graph 由独立的 TF Session 运行于一个独立的线程中，通过 a 算子获得样本数据后，进行特征 ID 的抽取等动作，并进行基于 HashTable 方法的稀疏参数查询，查询结果通过 c 算子放置到 ExchangeManager 中。EG 中还包含用于反向更新的 f 算子，它会从 ExchangeManager 中获取 Embedding 梯度和与其配套的前向参数，然后执行梯度更新参数逻辑。
- 下面的 Main Graph 负责实际稠密子网络的计算，我们继承并实现一种可训练的 EmbeddingVariable，它的构建过程（d 算子）会从 ExchangeManager 查找与自己配套的 Embedding 向量封装成 EmbeddingVariable，给稠密子网络。此外，在 EmbeddingVariable 注册的反向方法中，我们添加了 e 算子使得 Embedding 梯度得以添加到 ExchangeManager 中，供 EG 中的 f 算子消费。

通过上面的设计，我们就搭建起了一套可控的 EG/MG 并发流水线训练模式。总体来看，Embedding 流水线训练模式的收益来源有：

- 经过我们对多个业务模型的 Profiling 分析发现，EG 和 MG 在时间的比例上在 3:7 或 4:6 的左右，通过将这两个阶段并行起来，可以有效的隐藏 Embedding 阶段，使得 MG 网络计算部分几乎总是可以立即开始，大大加速了整体模型的训练吞吐。
- TensorFlow 引擎中当使用多个优化器（稀疏与非稀疏）的时候，会出现重复构建反向计算图的问题，一定程度增加了额外计算，通过两张子图的拆分，恰好避免了这个问题。
- 在实施过程中的 ExchangeManager 不仅负责了 Embedding 参数和梯度的交换，还承担了元数据复用管理的职责。例如 Unique 等算子的结果保存，进一步降低了重复计算。

另外，在 API 设计上，我们做到了对用户透明，仅需一行代码即可开启 Embedding 流水线功能，对用户隐藏了 EG/MG 的切割过程。目前，在美团某业务训练中，Embedding 流水线功能在 CPU PS 架构下可以带来 20%~60% 的性能提升（而且 Worker 并发规模越大，性能越好）。

3.5 单实例 PS 并发优化

经过 2.2 章节的分析可知，我们不能通过持续扩 PS 来提升分布式任务的吞吐，单实例 PS 的并发优化，也是非常重要的优化方向。我们主要的优化工作如下。

3.5.1 高性能的 HashTable

PS 架构下，大规模稀疏模型训练对于 HashTable 的并发读写要求很高，因为每个 PS 都要承担成百乃至上千个 Worker 的 Embedding 压力，这里我们综合速度和稳定性考虑，选用了 tbb::concurrent_hash_map[10] 作为底层 HashTable 表实现，并将其包装成一个新的 TBBConcurrentHashTable 算子。经过测试，在千亿规模下 TBBConcurrentHashTable 比原生 MutableDenseHashTable 训练速度上快了 3 倍。

3.5.2 HashTable BucketPool

对于大规模稀疏模型训练来说，Embedding HashTable 会面对大量的并发操作，通过 Profiling 我们发现，频繁动态的内存申请会带来了较大性能开销（即使 TensorFlow 的 Tensor 有专门的内存分配器）。我们基于内存池化的思路优化了 HashTable 的内存管理。

我们在 HashTable 初始化时，会先为 Key 和 Value 分别创造两个 BucketPool，每个池子都会先 Malloc 较大一块内存备用，考虑到可能会有对 HashTable 进行中的 Key 和 Value 进行 Remove 的场景（如 Online Learning 训练时），需要对从 HashTable 中删除的 Key 和 Value 所使用的内存进行回收，因此每个 BucketPool 还有一个 ReuseQueue 来负责维护回收的内存。每次向内部的哈希表数据结构中 Insert Key 和 Value 的时候，Key 和 Value 内存和释放分配都进行池化管理。用这种方式降低了大规模稀疏训练中遇到稀疏内存分配开销，整体端到端训练性能提升了 5% 左右。

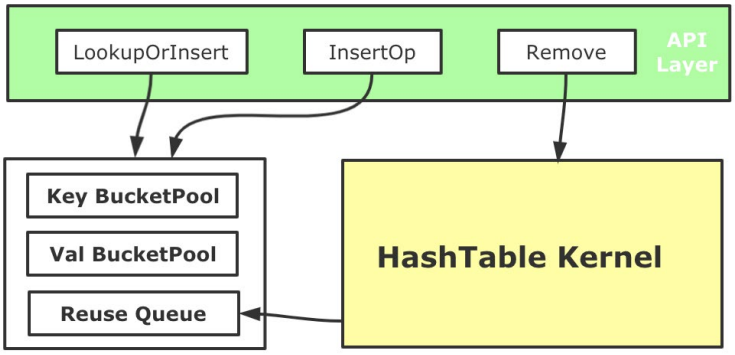

图 17 HashTable 内存优化

3.6 单位算力吞吐优化

经过 2.2 章节的分析，Worker 的计算压力也非常大，如果不优化 Worker，同时要保持吞吐，需要横向扩展更多的 Worker，给 PS 带来更大的压力。而对于用户来说，如果能在有限的计算资源下带来性能提升，对业务价值更高。我们通过 CAT 统计出了一些高频算子，并进行了专项优化。这里选取 Unique&DynamicPartition 算子融

合案例进行分享。

在 TensorFlow PS 架构中，包括 Embedding 向量在内的共享参数都存储在 PS 上，并通过网络与 Worker 交互，在进行 Embedding 查询过程中，往往会涉及如下两个环节：

- 由于稀疏参数的性质，从样本中抽取得到的待查询 Embedding ID，它的重复率往往高达 70%~90%，如果不进行去重查询，不论是对 HashTable 的查询还是网络的传输，都会带来不小的压力。因此，通常会在查询前进行 Unique 操作。
- 在大规模稀疏场景中，为了存储千亿规模的参数，会有多个 PS 机器共同承载。而 Worker 端会负责对查询请求按照设定的路由规则进行切分，这里通常会在查询前进行 DynamicPartition 动作。

通常这两个过程会利用 TensorFlow 既有的算子进行搭建，但在实际使用中，我们发现它并不是很高效，主要问题在于：

- Unique 算子原生实现，它内部使用的内存分配策略较为低效。使用了两倍输入参数（Embedding ID）的大小进行内存分配，但由于输入参数较大，而且重复率高，导致 HashTable 创建过大且非常稀疏。几乎每次插入都会产生一次 minor_page_fault，导致 HashTable 性能下降。我们使用 Intel Vtune 验证了这一点（参见图 18）。
- Unique 和 Dynamic Partition 算子存在冗余数据遍历，这些操作其实可以在一次数据遍历中全部做完，节省掉算子切换、冗余数据遍历的耗时。

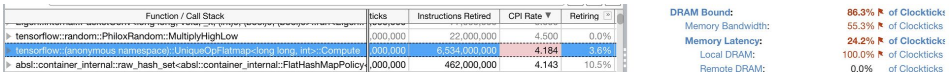

图 18　Unique 算子内部出现 DRAM Bound 问题

总结来说，HashTable 开辟过大会导致大量的 minor_page_fault，导致访存的时间增加，HashTable 过小又可能会导致扩容。我们采用了基于启发式算法的内存自适应 Unique 算子实现，通过对训练历史重复率的统计，我们可以得到一个相对合理的

HashTable 大小，来提高访存的性能；另外 Unique 算子内 HashTable 的具体选择上，经过我们的多种测试，选择了 Robin HashTable 替换了原生 TF 中的实现。

进一步，我们对围绕 Embedding ID 的 Unique 和 Partition 环节进行了算子合并，简化了逻辑实现。经过上述的优化，Unique 单算子可以取得 51% 的加速，在真实模型端到端上可以获得 10% 左右的性能提升，算子总数量降低了 4%。

在整个关键算子优化的过程中，Intel 公司的林立凡、张向泽、高明进行大量的技术支持，我们也复用了他们的部分优化工作，在此深表感谢！

4. 大规模稀疏算法建模

大规模稀疏能力在业务落地的过程中，算法层面还需要从特征和模型结构上进行对应升级，才能拿到非常好的效果。其中外卖广告从业务特点出发，引入大规模稀疏特征完成外卖场景下特征体系的升级，提供了更高维的特征空间和参数空间，增强了模型的拟合能力。重新设计了面向高维稀疏场景的特征编码方案，解决了特征编码过程中的特征冲突问题，同时编码过程去掉了部分冗余的特征哈希操作，一定程度上简化了特征处理逻辑，并降低了特征计算的耗时。

在系统层面，面对百亿参数、百亿样本以上量级的大规模稀疏模型的训练，会带来训练迭代效率的大大降低，单次实验从一天以内，增长到一周左右。美团机器学习平台训练引擎团队，除了上述 TensorFlow 框架层面的优化、还针对业务模型进行了专项优化，整体吞吐优化了 8 到 10 倍（如果投入更多计算资源，可以进一步加速），大大提升业务的迭代效率，助力外卖广告业务取得了较为明显的提升。

5. 总结与展望

TensorFlow 在大规模推荐系统中被广泛使用，但由于缺乏大规模稀疏的大规模分布式训练能力，阻碍了业务的发展。美团基于 TensorFlow 原生架构，支持了大规模稀疏能力，并从多个角度进行了深度优化，做到千亿参数、千亿样本高效的分布式训练，并在美团内部进行了大规模的使用。对于这类关键能力的缺失，TensorFlow 社

区也引起了共鸣，社区官方在 2020 年创建了 SIG Recommenders[11]，通过社区共建的方式来解决此类问题，美团后续也会积极的参与到社区的贡献当中去。

美团推荐系统场景的模型训练，目前主要运行在 CPU 上，但随着业务的发展，有些模型变得越来越复杂，CPU 上已经很难有优化空间（优化后的 Worker CPU 使用率在 90% 以上）。而近几年，GPU 的计算能力突飞猛进，新一代的 NVIDIA A100 GPU，算力达到了 156TFLOPS（TF32 Tensor Cores）、80G 显存、卡间带宽 600GB/s。对于这类复杂模型的 Workload，我们基于 A100 GPU 架构，设计了下一代的分布式训练架构，经过初步优化，在美团某大流量业务推荐模型上也拿到了较好的效果，目前还在进一步优化当中，后续我们会进行分享，敬请期待。

6. 作者简介

逸帆、家恒、峥少、鹏鹏、永宇、正阳、黄军等，来自美团基础研发平台，机器学习平台训练引擎组，主要负责美团分布式机器学习训练系统的性能优化与能力建设。
海涛，来自美团外卖广告策略团队，主要负责美团外卖广告业务的算法探索和策略落地工作。

7. 招聘信息

美团机器学习平台大量岗位持续招聘中，社招 / 校招均可（欢迎投递我们的校招北斗岗位：美团机器学习平台基础架构），坐标北京 / 上海，构建多领域的公司级机器学习平台，帮大家吃得更好，生活更好。简历可投递至：huangjun03@meituan.com。

8. 参考信息

[1] https://www.usenix.org/system/files/conference/osdi16/osdi16-abadi.pdf
[2] https://github.com/dianping/cat
[3] https://www.usenix.org/system/files/conference/osdi14/osdi14-paper-li_mu.pdf
[4] https://github.com/tensorflow/networking/tree/master/tensorflow_networking/verbs
[5] https://labs.criteo.com/2013/12/download-terabyte-click-logs/
[6] https://arxiv.org/abs/1906.00091
[7] https://github.com/tensorflow/networking/tree/master/tensorflow_networking/seastar
[8] https://github.com/bytedance/byteps
[9] http://research.baidu.com/Public/uploads/5e18a1017a7a0.pdf
[10] https://github.com/oneapi-src/oneTBB
[11] https://github.com/tensorflow/recommenders-addons

美团 Serverless 平台 Nest 的探索与实践

作者：殷琦　华珅　飞飞　志洋　奕锟　佳文　凯鑫　亚辉

1. 背景

Serverless 一词于 2012 年被提出，2014 年由于亚马逊的 AWS Lambda 无服务器计算服务的兴起，而被大家广泛认知。Serverless 通常被直译成“无服务器”，无服务器计算是可以让用户在不考虑服务器的情况下构建并运行应用程序。使用无服务器计算，应用程序仍在服务器上运行，但所有服务器管理工作均由 Serverless 平台负责。如机器申请、代码发布、机器宕机、实例扩缩容、机房容灾等都由平台帮助自动完成，业务开发只需考虑业务逻辑的实现即可。

回顾计算行业的发展历程，基础设施从物理机到虚拟机，再从虚拟机到容器；服务架构从传统单体应用架构到 SOA 架构，再从 SOA 架构到微服务架构。从基础设施和服务架构两条主线来看整体技术发展趋势，大家可能会发现，不论是基础设施还是服务架构，都是从大往小或者由巨到微的方向上演进，这种演变的本质原则无非是解决资源成本或者研发效率的问题。当然，Serverless 也不例外，它也是用来解决这两个方面的问题：

- **资源利用率**：Serverless 产品支持快速弹性伸缩能力，能够帮助业务提升资源利用率，在业务流量高峰时，业务的计算能力、容量自动扩容，承载更多的用户请求，而在业务流量下降时，所使用的资源也会同时收缩，避免资源浪费。
- **研发运维效率**：在 Serverless 上开发人员一般只需要填写代码路径或者上传代码包，平台能够帮助完成构建、部署的工作。开发人员不直接面对机器，对于机器的管理，机器是否正常以及流量高低峰的是否需要扩缩容等问题，这些统统不需要去考虑，由 Serverless 产品帮助研发人员去完成。这样就能使他们从繁琐的运维工作中解放出来，从 DevOps 转向 NoOps，更加专注于业务逻辑的实现。

虽然 AWS 在 2014 年就推出了第一个 Serverless 产品 Lambda，但 Serverless 技术在国内的应用一直不温不火。不过近两三年，在容器、Kubernetes 以及云原生等技术的推动下，Serverless 技术迅速发展，国内各大互联网公司都在积极建设 Serverless 相关产品，探索 Serverless 技术的落地。在这种背景下，美团也于 2019 年初开始了 Serverless 平台的建设，**内部项目名称为 Nest**。

截止到目前，Nest 平台已经过两年的建设，回顾整体的建设过程，主要经历了以下三个阶段：

- **快速验证，落地 MVP 版本**：我们通过技术选型、产品与架构设计、开发迭代，快速落地了 Serverless 产品的基本的能力，如构建、发布、弹性伸缩、对接触发源、执行函数等。上线后，我们推进了一些业务的试点接入，帮助验证打磨产品。
- **优化核心技术，保障业务稳定性**：有了前期的试点业务验证，我们很快发现产品的存在的一些稳定性相关的问题，主要有弹性伸缩的稳定性、冷启动的速度、系统与业务的可用性、容器的稳定性。针对这些问题我们对各个问题涉及的技术点做了专项的优化改进。
- **完善技术生态，落实收益**：优化了核心技术点后，产品逐渐成熟稳定，但依然面临生态性问题，如研发工具欠缺，上下游产品没有打通、平台开放能力不足等问题，影响或阻碍了产品的推广使用。因此，我们继续完善产品的技术生态，扫清业务接入使用障碍，落实产品的业务收益。

2. 快速验证，落地 MVP 版本

2.1 技术选型

建设 Nest 平台，首要解决的就是技术选型问题，Nest 主要涉及三个关键点的选型：演进路线、基础设施、开发语言。

2.1.1 演进路线

起初 Serverless 服务主要包含 FaaS（Function as a Service）和 BaaS（Back-end as a Service），近几年 Serverless 的产品领域有所扩张，它还包含面向应用的 Serverless 服务。

- **FaaS**：是运行在一个无状态的计算容器中的函数服务，函数通常是事件驱动、生命周期很短（甚至只有一次调用）、完全由第三方管理的。业界相关 FaaS 产品有 AWS 的 Lambda、阿里云的函数计算等。
- **BaaS**：是建立在云服务生态之上的后端服务。业界相关 BaaS 产品包括 AWS 的 S3、DynamoDB 等。

面向应用的 Serverless 服务：如 Knative，它提供了从代码包到镜像的构建、部署，以及弹性伸缩等全面的服务托管能力，公有云产品有 Google Cloud Run（基于 Knative）、阿里云的 SAE（Serverless Application Engine）。

在美团内部，BaaS 产品其实就是内部的中间件以及底层服务等，它们经过多年的发展，已经非常丰富且成熟了。因此，在美团的 Serverless 产品演进主要在函数计算服务和面向应用的 Serverless 服务两个方向上。那究竟该如何演进呢？当时主要考虑到在业界 FaaS 函数计算服务相对于面向应用的 Serverless 服务来说，更加成熟且确定。因此，我们决定“**先建设 FaaS 函数计算服务，再建设面向应用的 Serverless 服务**”这样一条演进路线。

2.1.2 基础设施

由于弹性伸缩是 Serverless 平台必备的能力，因此 Serverless 必然涉及到底层资源的调度和管理。这也是为什么当前业界有很多开源的 Serverless 产品（如 OpenFaaS、Fission、Nuclio、Knative 等）是基于 Kubernetes 来实现的，因为这种选型能够充分利用 Kubernetes 的基础设施的管理能力。在美团内部基础设施产品是 Hulk，虽然 Hulk 是基于 Kubernetes 封装后的产品，但 Hulk 在落地之初考虑到落地难度以及各种原因，最终未按照原生的方式来使用 Kubernetes，并且在容器层采用的也是富容器模式。

在这种历史背景下，我们在做基础设施选型时就面临两种选项：一是使用公司的 Hulk 来作为 Nest 的基础设施（非原生 Kubernetes），二是采用原生 Kubernetes 基础设施。我们考虑到当前业界使用原生 Kubernetes 是主流趋势并且使用原生 Kubernetes 还能充分利用 Kubernetes 原生能力，可以减少重复开发。因此，最终考量的结果是我们采用了**原生 Kubernetes 作为我们的基础设施**。

2.1.3 开发语言

由于在云原生领域的主流语言是 Golang，并且 Kubernetes 的生态中，Golang 是绝对的主导语言。但在美团，Java 才是使用最广泛的语言，相比 Golang，Java 在公司内部生态比较好。因此，在语言的选型上我们**选择了 Java 语言**。在 Nest 产品开发之初，Kubernetes 社区的 Java 客户端还不够完善，但随着项目的推进，社区的 Java 客户端也逐渐丰富了起来，目前已经完全够用了。另外，我们也在使用过程中，也贡献了一些 Pull Request，反哺了社区。

2.2 架构设计

基于以上的演进路线、基础设施、开发语言的选型，我们进行了 Nest 产品的架构设计。

在整体的架构上，流量由 EventTrigger（事件触发源，如 Nginx、应用网关、定时任务、消息队列、RPC 调用等）触发到 Nest 平台，Nest 平台内会根据流量的特征路由到具体函数实例，触发函数执行，而函数内部代码逻辑可以调用公司内的各个 BaaS 服务，最终完成函数的执行，返回结果。

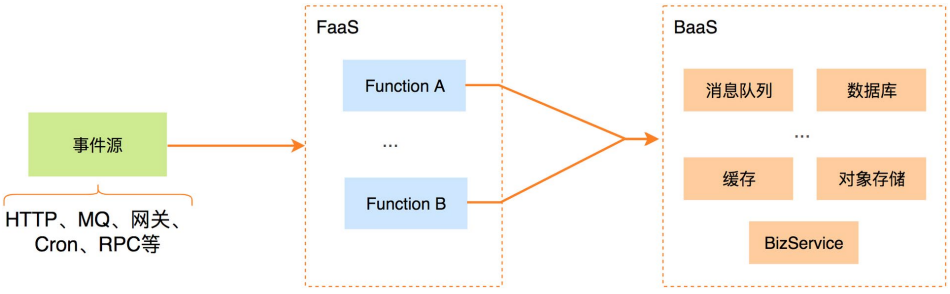

图 1　FaaS 架构图

在技术实现上，Nest 平台使用 Kubernetes 作为基础底座并适当参考了一些 Knative 的优秀设计，在其架构内部主要由以下几个核心部分组成：

- **事件网关**：核心能力是负责对接外部事件源的流量，然后路由到函数实例上；另外，网关还负责统计各个函数的进出流量信息，为弹性伸缩模块提供伸缩决策的数据支撑。
- **弹性伸缩**：核心能力是负责函数实例的弹性伸缩，伸缩主要根据函数运行的流量数据以及实例阈值配置计算函数目标实例个数，然后借助 Kubernetes 的资源控制能力，调整函数实例的个数。
- **控制器**：核心能力是负责 Kubernetes CRD（Custom Resource Definition）的控制逻辑实现。
- **函数实例**：函数的运行实例。当事件网关流量触发过来，会在函数实例内执行相应的函数代码逻辑。
- **治理平台**：面向用户使用的平台，负责函数的构建、版本、发布以及一些函数元信息的管理等。

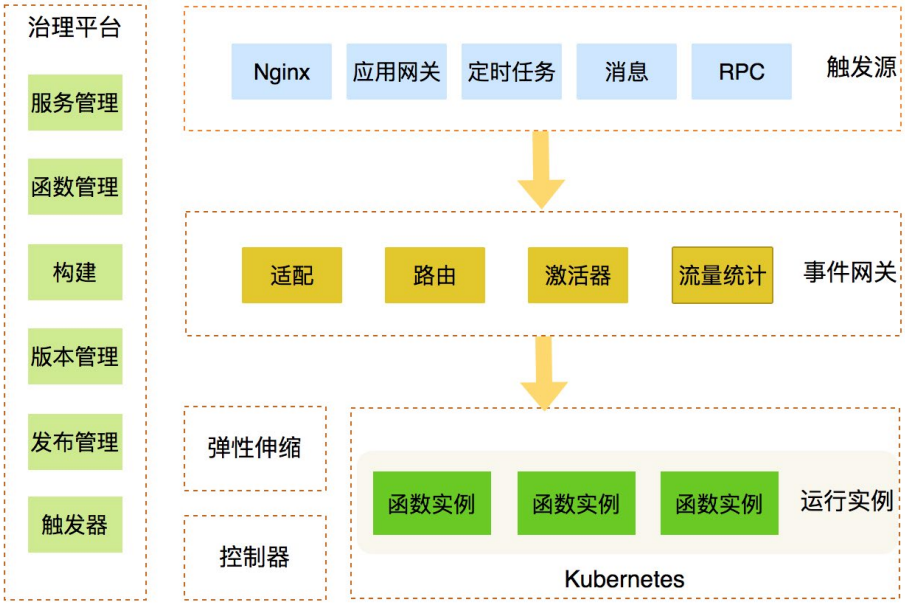

图 2　Nest 架构图

2.3 流程设计

在具体的 CI/CD 流程上，Nest 又与传统的模式有何区别呢？为了说明这个问题，我们先来看一看在 Nest 平台上函数的整体生命周期怎样的？具体有以下四个阶段：构建、版本、部署、伸缩。

- **构建**：开发的代码和配置通过构建生成镜像或可执行文件。
- **版本**：构建生成的镜像或可执行文件加上发布配置形成一个不可变的版本。
- **部署**：将版本发布，即完成部署。
- **伸缩**：根据函数实例的流量以及负载等信息，来进行实例的弹性扩缩容。

就这四个阶段来看，Nest 与传统的 CI/CD 流程本质区别在于部署和伸缩：传统的部署是感知机器的，一般是将代码包发布到确定的机器上，但 Serverless 是要向用户屏蔽机器的（在部署时，可能函数的实例数还是 0）；另外，传统的模式一般是不具备动态扩缩容的，而 Serverless 则不同，Serverless 平台会根据业务的自身流量需要，进行动态扩缩容。后续章节会详细讲解弹性伸缩，因此这里我们只探讨部署的设计。

部署的核心点在于如何向用户屏蔽机器？对于这个问题，我们**抽象了机器，提出了分组**的概念，分组是由 SET（单元化架构的标识，机器上会带有该标识）、泳道（测试环境隔离标识，机器上会带有该标识）、区域（上海、北京等）三个信息组成。用户部署只需在相应的分组上进行操作，而不用涉及到具体机器。能够做到这些的背后，是由 Nest 平台帮助用户管理了机器资源，每次部署会根据分组信息来实时初始化相应的机器实例。

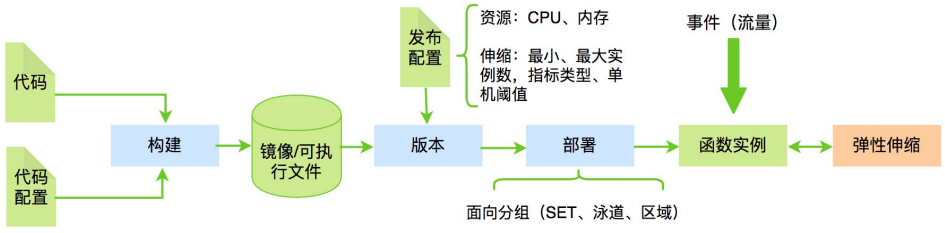

图 3　函数生命周期

2.4 函数触发

函数的执行是由事件触发的。完成函数的触发，需要实现以下四个流程：

- **流量引入**：向事件源注册事件网关的信息，将流量引入到事件网关。如针对 MQ 事件源，通过注册 MQ 的消费组，引入 MQ 的流量到事件网关。
- **流量适配**：事件网关对事件源进入的流量进行适配对接。
- **函数发现**：对函数元数据（函数实例信息、配置信息等）的获取过程，类似微服务的服务发现过程。事件网关接受的事件流量需要发送到具体的函数实例，这就需要对函数进行发现。这里发现实质是获取 Kubernetes 中的内置资源或者 CRD 资源中存储的信息。
- **函数路由**：事件流量的路由过程，路由到特定的函数实例上。这里为了支持传统路由逻辑（如 SET、泳道、区域路由等）以及版本路由能力，我们采用了多层路由，第一层路由到分组（SET、泳道、区域路由），第二层路由到具体版本。同版本内的实例，通过负载均衡器选择出具体实例。另外，通过该版本路由，我们很轻松的支持了金丝雀、蓝绿发布。

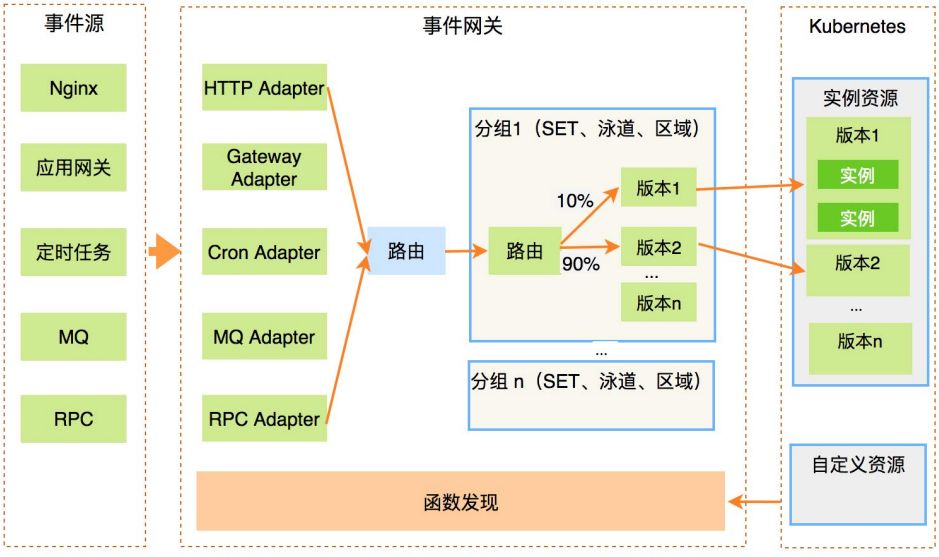

图 4　函数触发

2.5 函数执行

函数不同于传统的服务，传统的服务是个可执行的程序，但函数不同，函数是代码片段，自身是不能单独执行的。那流量触发到函数实例后，函数是如何执行的呢?

函数的执行的首要问题是函数的运行环境：由于 Nest 平台是基于 Kubernetes 实现的，因此函数一定是运行在 Kubernetes 的 Pod（实例）内，Pod 内部是容器，容器的内部是运行时，运行时是函数流量接收的入口，最终也是由运行时来触发函数的执行。一切看起来是那么的顺利成章，但我们在落地时是还是遇到了一些困难，最主要的困难是**让开发同学可以在函数内无缝的使用公司内的组件**，如 OCTO（服务框架）、Celler（缓存系统）、DB 等。

在美团的技术体系中，由于多年的技术沉淀，很难在一个纯粹的容器（没有任何其他依赖）中运行公司的业务逻辑。因为公司的容器中沉淀了很多环境或服务治理等能力，如服务治理的 Agent 服务以及实例环境配置、网络配置等。

因此，为了业务在函数内无缝的使用公司内的组件，我们复用公司的容器体系来降低业务编写函数的成本。但复用公司的容器体系也没那么简单，因为在公司内没有人试过这条路，Nest 是公司第一个基于原生 Kubernetes 建设的平台，“第一个吃螃蟹的人”总会遇到一些坑。对于这些坑，我们只能在推进过程中“逢山开路，遇水搭桥”，遇到一个解决一个。总结下来，其中最核心的是在容器的启动环节打通的 CMDB 等技术体系，让运行函数的容器与开发同学平时申请的机器用起来没有任何区别。

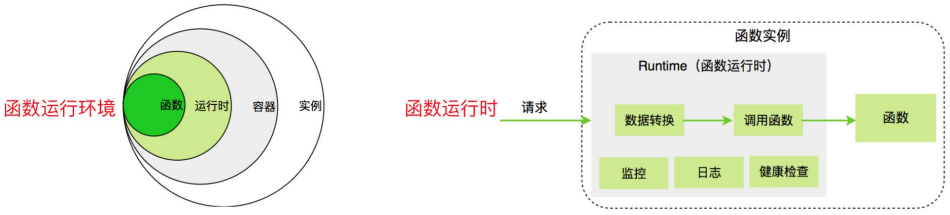

图 5　函数执行

2.6 弹性伸缩

弹性伸缩的核心问题主要有三个：什么时候伸缩，伸缩多少，伸缩的速度快不快？也就是伸缩时机、伸缩算法、伸缩速度的问题。

- **伸缩时机**：根据流量 Metrics 实时计算函数期望实例数，进行扩缩。流量的 Metrics 数据来自于事件网关，这里主要统计函数的并发度指标，弹性伸缩组件每秒中会主动从事件网关获取一次 Metrics 数据。
- **伸缩算法**：并发度 / 单实例阈值 = 期望实例数。根据收集的 Metrics 数据以及业务配置的阈值，通过算法计算出期望的实例数，然后通过 Kubernetes 接口设置具体实例数。整个算法看起来虽然简单，但非常稳定、鲁棒性好。
- **伸缩速度**：主要取决于冷启动时间，在下个章节会详细讲解这块内容。

除了基本的扩缩容能力，我们还支持了伸缩到 0，支持配置最大、最小实例数（最小实例即预留实例）。伸缩到 0 的具体实现是，我们在事件网关内部增加了激活器模块，当函数无实例时，会将函数的请求流量缓存在激活器内部，然后立即通过流量的 Metrics 去驱动弹性伸缩组件进行扩容，等扩容的实例启动完成后，激活器再将缓存的请求重试到扩容的实例上触发函数执行。

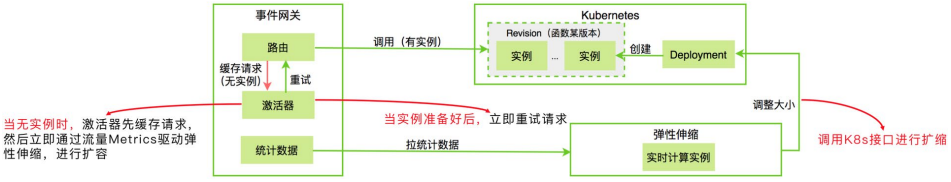

图 6　弹性伸缩

3. 优化核心技术，保障业务稳定性

3.1 弹性伸缩优化

上面提到的伸缩时机、伸缩算法、伸缩速度这三要素都是理想情况下的模型，尤其是伸缩速度，当前技术根本做不到毫秒级别的扩缩容。因此，在线上实际场景中，弹性

伸缩会存在一些不符合预期的情况，比如实例伸缩比较频繁或者扩容来不及，导致服务不太稳定的问题。

- **针对实例伸缩比较频繁问题**，我们在弹性伸缩组件内维护了统计数据的滑动窗口，通过计算均值来平滑指标，还通过延时缩容，实时扩容来缓解频繁扩缩问题。另外，我们增加了基于 QPS 指标的伸缩策略，因为 QPS 指标相对并发度指标会更加稳定。
- **针对扩容来不及问题**，我们采取提前扩容的手段，当达到实例阈值的 70% 就扩容，能够比较好的缓解这个问题。除此之外，我们还支持了多指标混合伸缩（并发度、QPS、CPU、Memory），定时伸缩等策略，满足各种业务需求。

下图展示的是线上弹性伸缩的真实案例（其配置的最小实例数为 4，单实例阈值 100，阈值使用率 0.7），其中上半部分是业务每秒的请求数，下半部分是扩缩实例的决策图，可以看到在成功率 100% 的情况下，业务完美应对流量高峰。

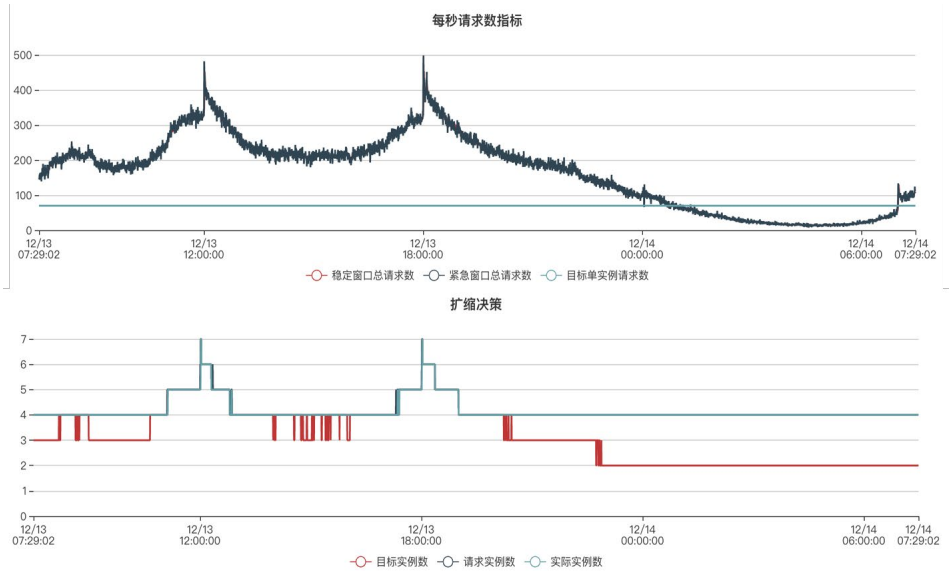

图 7　弹性伸缩案例

3.2 冷启动优化

冷启动是指在函数调用链路中包含了资源调度、镜像 / 代码下载、启动容器、运行时初始化、用户代码初始化等环节。当冷启动完成后，函数实例就绪，后续请求就能直接被函数执行。冷启动在 Serverless 领域至关重要，它的耗时决定了弹性伸缩的速度。

所谓“天下武功，无坚不破，唯快不破”，这句话在 Serverless 领域也同样受用。试想如果拉起一个实例足够快，快到毫秒级别，那几乎所有的函数实例都可以缩容到 0，等有流量时，再扩容实例处理请求，这对于存在高低峰流量的业务将极大的节省机器资源成本。当然，理想很丰满，现实很骨感。做到毫秒级别几乎不可能。但只要冷启动时间越来越短，成本自然就会越来越低，另外，极短的冷启动时间对伸缩时函数的可用性以及稳定性都有莫大的好处。

图 8　冷启动的各个阶段

冷启动优化是个循序渐进的过程，我们对冷启动优化主要经历了三个阶段：镜像启动优化、资源池优化、核心路径优化。

- **镜像启动优化**：我们对镜像启动过程中的耗时环节（启动容器和运行时初始化）进行了针对性优化，主要对容器 IO 限速、一些特殊 Agent 启动耗时、启动盘与数据盘数据拷贝等关键点的优化，最终将启动过程中的系统耗时从 42s 优化到 12s 左右。

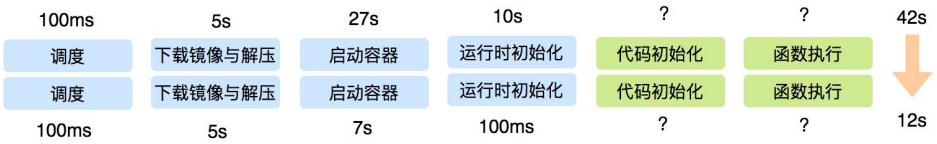

图 9　镜像启动优化成果

- **资源池优化**：镜像启动耗时优化到 12s，基本已经快达到瓶颈点，再继续优化空间不大。因此，我们想能否绕开镜像启动的耗时环节？最终，我们采用了一个比较简单思路“空间换时间”，用资源池方案：缓存一些已启动的实例，当需要扩容时，直接从资源池获取实例，绕开镜像启动容器的环节，最终效果很明显，将启动的系统耗时从 12s 优化到 3s。这里需要说明的是资源池自身也是通过 Kubernetes 的 Depolyment 进行管理，池中实例被取走会立即自动补充。

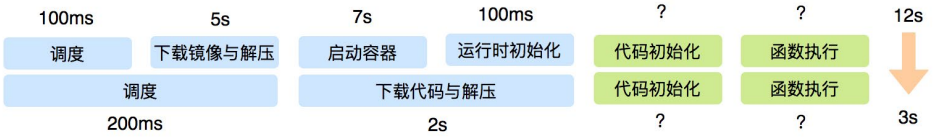

图 10　资源池优化成果

- **核心路径优化**：在资源池优化的基础上，我们再次精益求精，针对启动流程中的下载与解压代码两个耗时环节进行优化，过程中我们采用了高性能的压缩解压算法（LZ4 与 Zstd）以及并行下载和解压技术，效果非常好。另外，我们还支持了通用逻辑（中间件、依赖包等）下沉，通过预加载的方式，最终将函数端到端的启动耗时优化到 2s，这就意味着扩容一个函数实例只需要 2s（包含函数启动）。如果排除掉函数自身的初始化启动耗时，平台侧的耗时已在毫秒级别。

3.3 高可用保障

说到高可用，对于一般的平台，指的就是平台自身的高可用，但 Nest 平台有所不同，Nest 的高可用还包含托管在 Nest 平台上的函数。因此，Nest 的高可用保障需要从平台和业务函数两个方面着手。

3.3.1 平台高可用

对平台的高可用，Nest 主要从架构层、服务层、监控运营层、业务视角层面都做了全面的保障。

- **架构层**：我们针对有状态服务，如弹性伸缩模块，采用了主从架构，当主节点异常时从节点会立即替换。另外，我们还实现了架构上的多层隔离。 横向地域隔离：Kubernetes 两地两集群强隔离、服务（事件网关、弹性伸缩）集群内两地弱隔离（上海的弹性伸缩只负责上海 Kubernetes 集群内的业务伸缩，事件网关存在两地调用需求，需访问两地 Kubernetes）。纵向业务线隔离：服务业务线强隔离，不同业务线使用不同集群服务；在 Kubernetes 层的资源用 namespace 实现业务线弱隔离。

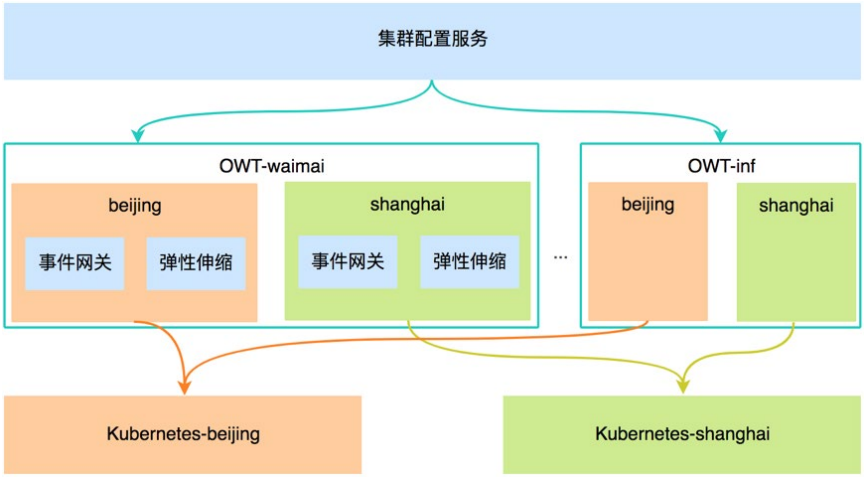

图 11　部署架构

- **服务层**：主要指的是事件网关服务，由于所有的函数流量都经过事件网关，因此事件网关的可用性尤为重要，这层我们支持了限流和异步化，保障服务的稳定性。
- **监控运营层**：主要通过完善系统监控告警、梳理核心链路并推动相关依赖方进行治理。另外，我们会定期梳理 SOP 并通过故障演练平台实施故障注入演练，发现系统隐患问题。

- **业务视角层**：我们开发了在线不间断实时巡检服务，通过模拟用户函数的请求流量，实时检测系统的核心链路是否正常。

3.3.2 业务高可用

对于业务高可用，Nest 主要从服务层、平台层两个层面做了相关的保障。

- **服务层**：支持了业务降级、限流能力：当后端函数故障时，可通过降级配置，返回降级结果。针对异常的函数流量，平台支持限制其流量，防止后端函数实例的被异常流量打垮。
- **平台层**：支持了实例保活、多层级容灾以及丰富的监控告警能力：当函数实例异常时，平台会自动隔离该实例并立即扩容新实例。平台支持业务多地区部署，在同地区将函数实例尽可能打散不同机房。当宿主机、机房、地区故障时，会立即在可用宿主机、可用机房或可用区重建新实例。另外，平台自动帮业务提供了函数在时延、成功率、实例伸缩、请求数等多种指标的监控，当在这些指标不符合预期时，自动触发告警，通知业务开发和管理员。

图 12　业务监控

3.4 容器稳定性优化

前文已提到，Serverless 与传统模式在 CI/CD 流程上是不同的，传统模式都是事先准备好机器然后部署程序，而 Serverless 则是根据流量的高低峰实时弹性扩缩容实例。当新实例扩容出来后，会立即处理业务流量。这听起来貌似没什么毛病，但在富容器生态下是存在一些问题的：我们发现刚扩容的机器负载非常高，导致一些业务请求执行失败，影响业务可用性。

分析后发现主要是因为容器启动后，运维工具会进行 Agent 升级、配置修改等操作，这些操作非常耗 CPU。同在一个富容器中，自然就抢占了函数进程的资源，导致用户进程不稳定。另外，函数实例的资源配置一般比传统服务的机器要小很多，这也加剧了该问题的严重性。基于此，我们参考业界，联合容器设施团队，落地了轻量级容器，将运维的所有 Agent 放到 Sidecar 容器中，而业务的进程单独放到 App 容器中。采用这种容器的隔离机制，保障业务的稳定性。同时，我们也推动了容器裁剪计划，去掉一些不必要的 Agent。

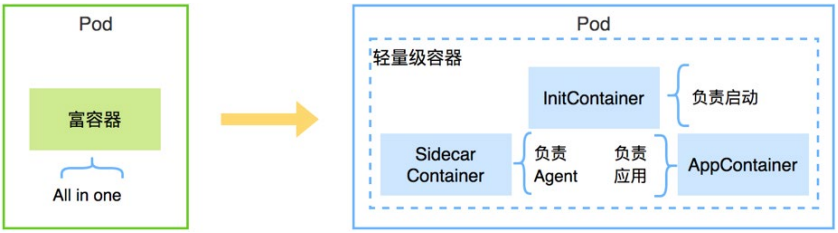

图 13 轻量级容器

4. 完善生态，落实收益

Serverless 是个系统工程，在技术上涉及到 Kubernetes、容器、操作系统、JVM、运行时等各种技术，在平台能力上涉及到 CI/CD 各个流程的方方面面。

为了给用户提供极致的开发体验，我们为用户提供了开发工具的支持，如 CLI（Command Line Interface）、WebIDE 等。为了解决现有上下游技术产品的交互的问题，我们与公司现有的技术生态做了融合打通，方便开发同学使用。为了方便下游

的集成平台对接，我们开放了平台的 API，实现 Nest 赋能各下游平台。针对容器过重，系统开销大，导致低频业务函数自身资源利用率不高的问题，我们支持了函数合并部署，成倍提升资源利用率。

4.1 提供研发工具

开发工具能够降低平台的使用成本，帮助开发同学快速的进行 CI/CD 流程。目前 Nest 提供了 CLI 工具，帮助开发同学快速完成创建应用、本地构建、本地测试、Debug、远程发布等操作。Nest 还提供了 WebIDE，支持在线一站式完成代码的修改、构建、发布、测试。

4.2 融合技术生态

仅支持这些研发工具还是不够的，项目推广使用后，我们很快就发现开发同学对平台有了新的需求，如无法在 Pipeline 流水线、线下服务实例编排平台上完成对函数的操作，这对我们项目的推广也形成了一些阻碍。因此，我们融合这些公司的成熟技术生态，打通了 Pipeline 流水线等平台，融入到现有的上下游技术体系内，解决用户的后顾之忧。

4.3 开放平台能力

有很多 Nest 的下游解决方案平台，如 SSR（Server Side Render）、服务编排平台等，通过对接 Nest 的 OpenAPI，实现了生产力的进一步解放。例如，不用让开发同学自己去申请、管理和运维机器资源，就能够让用户非常快速的实现一个 SSR 项目或者编排程序从 0 到 1 的创建、发布与托管。

Nest 除了开放了平台的 API，还对用户提供了自定义资源池的能力，拥有了该项能力，开发同学可以定制自己的资源池，定制自己的机器环境，甚至可以下沉一些通用的逻辑，实现冷启动的进一步优化。

4.4 支持合并部署

合并部署指的是将多个函数部署在一个机器实例内。合并部署的背景主要有两个：

- 当前的容器较重，容器自身的系统开销较大，导致业务进程资源利用率不高（尤其是低频业务）。
- 在冷启动耗时不能满足业务对时延的要求的情况下，我们通过预留实例来解决业务的需求。

基于这两个背景，我们考虑支持合并部署，将一些低频的函数部署到同一个机器实例内，来提升预留实例中业务进程的资源利用率。

在具体实现上，我们参考 Kubernetes 的设计方案，设计了一套基于 Sandbox 的函数合并部署体系（每个 Sandbox 就是一个函数资源），将 Pod 类比成 Kubernetes 的 Node 资源，Sandbox 类比成 Kubernetes 的 Pod 资源，Nest Sidecar 类比成 Kubelet。为了实现 Sandbox 特有的部署、调度等能力，我们还自定义了一些 Kubernetes 资源（如 SandboxDeployment、SandboxReplicaSet、Sandbox-Endpoints 等）来支持函数动态插拔到具体的 Pod 实例上。

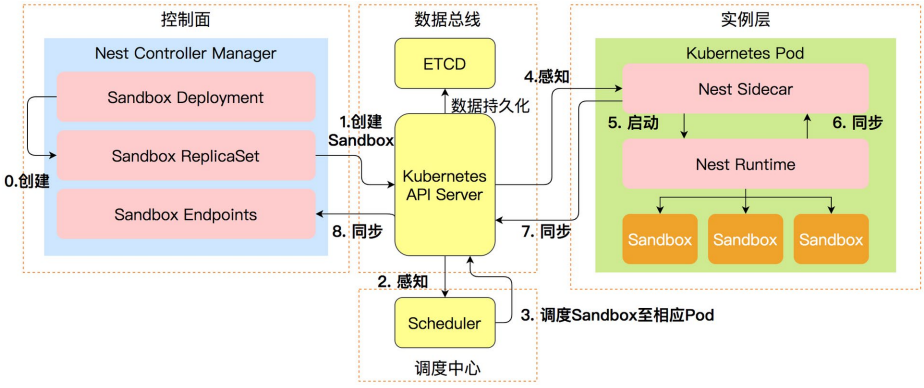

图 14　合并部署架构

除此之外，在合并部署的形态下，**函数之间的隔离性**也是不可回避的问题。为了尽可能的解决函数（合并在同一个实例中）之间的互相干扰问题，在 Runtime 的实现上，我们针对 Node.js 和 Java 语言的特点采取了不同的策略：Node.js 语言的函数使用不同的进程来实现隔离，而 Java 语言的函数，我们采用类加载隔离。采用这种策略的主要原因是由于 Java 进程占用内存空间相较于 Node.js 进程会大很多。

5. 落地场景、收益

目前 Nest 产品在美团前端 Node.js 领域非常受欢迎，也是落地最广泛的技术栈。当前 Nest 产品在美团前端已实现了规模化落地，几乎涵盖了所有业务线，接入了大量的 B/C 端的核心流量。

5.1 落地场景

具体的落地前端场景有：BFF（Backend For Frontend）、CSR（Client Side Render）/SSR（Server Side Render）、后台管理平台场景、定时任务、数据处理等。

- **BFF 场景**：BFF 层主要为前端页面提供数据，采用 Serverless 模式，前端同学不需要考虑不擅长的运维环节，轻松实现了 BFF 向 SFF（Serverless For Frontend）模式的转变。
- **CSR/SSR 场景**：CSR/SSR 指的是客户端渲染和服务端渲染，有了 Serverless 平台，不用考虑运维环节，更多的前端业务来尝试使用 SSR 来实现前端首屏的快速展现。
- **后台管理平台场景**：公司有很多的后台管理平台的 Web 服务，它们虽然相较于函数是比较重的，但完全可以直接托管 Serverless 平台，充分享受 Serverless 平台极致的发布和运维效率。
- **定时任务场景**：公司存在很多周期性任务，如每隔几秒拉取数据，每天 0 点清理日志，每小时收集全量数据并生成报表等，Serverless 平台直接与任务调度系统打通，只需写好任务的处理逻辑并在平台上配置定时触发器，即完成定时任务的接入，完全不用管理机器资源。
- **数据处理场景**：将 MQ Topic 作为事件源接入 Serverless 平台，平台会自动订阅 Topic 的消息，当有消息消费时，触发函数执行，类似定时任务场景，作为用户也只需写好数据处理的逻辑并在平台上配置好 MQ 触发器，即完成 MQ 消费端的接入，完全不用管理机器资源。

5.2 落地收益

Serverless 的收益是非常明显的，尤其在前端领域，大量的业务接入已是最好的说明。具体收益，从以下两个方面分别来看：

- **降成本**：通过 Serverless 的弹性伸缩能力，高频业务资源利用率能提升到 40% ~ 50%；低频业务函数通过合并部署，也能极大降低函数运行成本。
- **提效率**：整体研发研发效率提升约 40%。
  - 从代码开发来看，提供完备的 CLI、WebIDE 等研发工具，能够帮助开发同学生成代码脚手架，聚焦编写业务逻辑，快速完成本地测试；另外，让业务服务零成本具备在线查看日志与监控的能力。
  - 从发布来看，通过云原生的模式，业务无需申请机器，发布、回滚都是秒级别的体验。另外，还能利用平台天然能力，配合事件网关，实现切流、完成金丝雀测试等。
  - 从日常运维来看，业务无需关注机器故障、资源不足、机房容灾等传统模式该考虑的问题，另外，当业务进程异常时，Nest 能够自动完成异常实例的隔离，迅速拉起新实例实现替换，降低业务影响。

6. 未来规划

- **场景化解决方案**：接入 Serverless 的场景众多，如 SSR、后台管理端、BFF 等，不同的场景有不同的项目模板、场景配置，如伸缩配置、触发器配置等，另外，不同的语言，配置也有所不同。这无形中增加了业务的使用成本，给新业务的接入带来了阻碍。因此，我们考虑场景化的思路来建设平台，将平台的能力与场景强关联起来，平台深度沉淀各场景的基本配置和资源，这样不同的场景，业务只需要简单的配置就可以将 Serverless 玩转起来。
- **传统微服务 Serverless 化**：传统微服务的 Serverless 化即是路线选型中提到的面向应用的 Serverless 服务。在美团使用最广的开发语言是 Java，公司内部存在大量的传统的微服务项目，这些项目如果都迁移到函数模式，显然是不现实的。试想如果这些传统的微服务项目不用改造，也能直接

享受 Serverless 的技术红利，其业务价值不言而喻。因此，传统微服务的 Serverless 化是我们未来拓展业务的一个重要方向。在实施路径上，我们会考虑将服务治理体系（如 ServiceMesh）与 Serverless 做技术融合，服务治理组件为 Serverless 提供伸缩指标支持并在伸缩过程中实现精准的流量调配。

- **冷启动优化**：当前虽然函数的冷启动优化已经取得了较好的成绩，尤其是平台侧的系统启动耗时，提升空间已经非常有限，但业务代码自身的启动耗时还是非常突出，尤其是传统 Java 微服务，基本是分钟级别的启动耗时。因此，后续我们的冷启动优化会重点关注业务自身的启动耗时，争取极大降低业务自身的启动时间。在具体优化方法上，我们会考虑采用 AppCDS、GraalVM 等技术，降低业务自身启动耗时。
- **其他规划**
  - **丰富完善研发工具**，提升研发效率，如 IDE 插件等。
  - **打通上下游技术生态**，深度融入公司现有技术体系，减少因上下游平台带来使用障碍。
  - **容器轻量化**，轻量化的容器能够带来更优的启动耗时以及更佳的资源利用率，因此，容器轻量化一直是 Serverless 的不懈追求。在具体落地上，准备联合容器设施团队一起推进容器中的一些 Agent 采用 DaemonSet 方式部署，下沉到宿主机，提升容器的有效载荷。

作者简介

殷琦、华珅、飞飞、志洋、奕锟等，来自基础架构部应用中间件团队。
佳文、凯鑫，亚辉等，来自金融技术平台大前端团队。

招聘信息

美团基础架构团队诚招高级、资深技术专家，Base 北京、上海。我们致力于建设美团全公司统一的高并发高性能分布式基础架构平台，涵盖数据库、分布式监控、服务治理、高性能通信、消息中间件、基础存储、容器化、集群调度等基础架构主要的技术领域。欢迎有兴趣的同学投送简历到：tech@meituan.com。

算法平台在线服务体系的演进与实践

作者：永波　季尚　艳伟　非凡

0. 写在前面

AI 可以说是目前互联网行业炙手可热的“明星”。无论是老牌巨头，还是流量新贵，都在大力研发 AI 技术，为自家的业务赋能。美团很早就开始探索不同的机器学习模型在各种业务场景的应用，从最开始的线性模型、树模型，再到近几年的深度神经网络、BERT、DQN 等，并成功应用于搜索、推荐、广告、配送等业务，也取得了较好的效果与产出。

美团配送技术部建设的算法平台——Turing（下称图灵平台），旨在提供一站式的服务，覆盖数据预处理、特征生成、模型训练、模型评估、模型部署、在线预测、AB 实验、算法效果评估的全流程，降低了算法工程师的使用门槛，帮助他们脱离繁琐的工程化开发，把有限的精力聚焦于业务和算法逻辑的迭代优化。具体的实践，大家可参考美团技术团队此前推送的一篇技术博客《一站式机器学习平台建设实践》。

随着机器学习平台、特征平台、AB 平台等陆续完成，配送技术团队发现在线预测部分逐渐成为算法开发和迭代的瓶颈，为此，我们开始启动图灵在线服务框架的整体研发。本文将与大家详细探讨图灵平台中的在线服务框架——图灵 OS（Online Serving）的设计和实践，希望对大家能够有所帮助或者启发。

随着图灵平台逐渐成熟，包括美团配送在内，已经有超过 18 个业务方接入了图灵平台，整体概况大致如下：共接入 10+ 个 BU（业务单元），100% 覆盖美团配送核心业务场景，支持 500+ 个在线模型、2500+ 个特征、180+ 个算法策略，每天支持百亿次的在线预测。通过图灵平台赋能，算法迭代周期由天级别降至小时级别，大幅提升了配送算法的迭代效率。

1. 图灵平台介绍

图灵平台是一站式算法平台，总体架构如下图 1 所示，底层依托于 Kubernetes 和 Docker，实现了对 CPU/GPU 等资源的统一调度和管理，集成了 Spark ML、XGBoost、TensorFlow 等机器学习 / 深度学习框架，包含特征生产、模型训练、模型部署、在线推理、AB 实验等一站式平台功能，支撑了美团配送及闪购、骑行、买菜、地图等事业部的调度、时间预估、配送范围、搜索、推荐等各类 AI 应用。图灵平台主要包括机器学习平台、特征平台、图灵在线服务（Online Serving）、AB 实验平台四大功能。

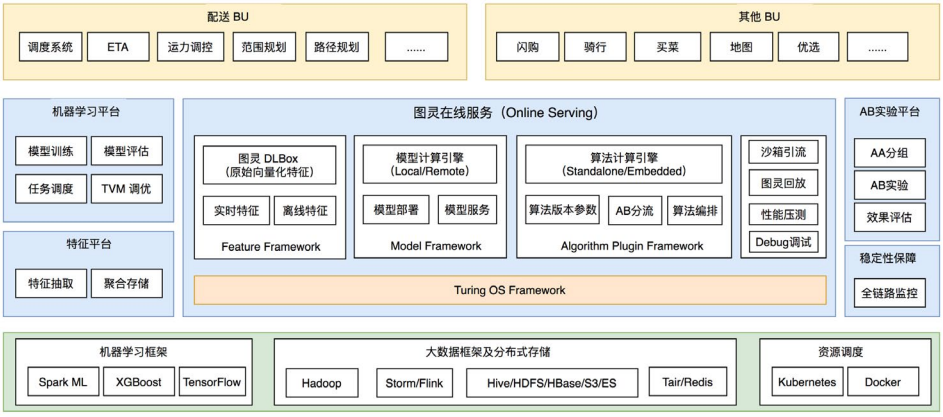

图 1　图灵平台总体架构

- **机器学习平台**：提供模型训练、任务调度、模型评估和模型调优等功能，基于 DAG 实现拖拽式的可视化模型训练。
- **特征平台**：提供在线和离线特征生产、特征抽取和特征聚合等功能，并推送到在线的特征库，提供高性能的特征获取服务。
- **图灵在线服务**：Online Serving，以下简称图灵 OS，为特征获取、数据预处理、模型和算法策略的线上部署及高性能计算提供统一的平台化解决方案。
- **AB 实验平台**：提供事前的 AA 分组，事中的 AB 分流和事后的效果评估等功能，覆盖 AB 实验的完整生命周期。

图灵 OS 主要指图灵平台的在线服务模块，聚焦于机器学习 / 深度学习在线服务，目标是让离线训练好的模型能够快速上线，有效提升各业务部门的算法迭代效率，快速拿到结果，对业务产生价值。以下将重点介绍图灵在线服务（Turing Online Serving）。

2. 图灵 OS 的建设背景

在美团配送业务发展初期，为了支撑业务的快速发展，快速支持算法上线、快速试错，各个业务线的工程方独自开发在线预测的一系列功能，也就是我们所熟知的“烟囱模式”。此种模式各自为战，非常灵活，能够快速支持业务的个性化需求。但随着业务规模的逐渐扩大，这种“烟囱模式”的缺点就凸显了出来，主要表现在以下三个方面：

- **重复造轮子**：特征获取和预处理、特征版本切换、模型加载和切换、在线预测和 AB 实验等都是各自研发，从零做起。
- **平台化能力缺失**：缺乏对特征、模型迭代上线的完整生命周期的平台化运维、管理、监控和追踪能力，研发效率低下。
- **算法与工程耦合严重**：算法与工程边界模糊，耦合严重，相互制约，算法迭代效率低下。

“烟囱模式”在业务发展早期做出了不可磨灭的贡献，但随着业务体量的增长，这种方式的边际收益逐渐降低到了不可忍受的程度，亟需一个统一的在线服务框架来进行改变。

目前，市面上大部分主流开源的机器学习在线服务框架仅提供了模型预测功能，不包含预处理和后处理模块，如下图 2 所示。

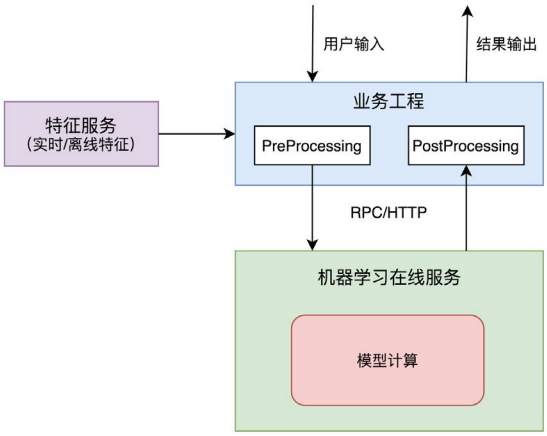

图 2　机器学习在线服务示意图

比如谷歌 TensorFlow Serving 是一个用于机器学习模型 Serving 的高性能开源在线服务框架，提供 gRPC/HTTP 接口供外部调用，支持模型热更新与自动模型版本管理，同时解决了资源调度、服务发现等痛点，对外提供稳定可靠的服务。但是 TensorFlow Serving 不包含预处理和后处理模块，需要将业务工程方将输入预处理成张量传递给 TensorFlow Serving 进行模型计算，然后再对模型计算结果进行后处理。预处理和后处理的逻辑对于算法策略非常重要，迭代也比较频繁，这部分跟模型结合比较密切，更适合由算法同学负责，如果由工程方实现，则工程同学只是单纯的实现算法同学设计的逻辑，耦合过于严重，迭代效率低，而且还容易导致设计和具体实现不一致，引发线上事故。

为了解决上述问题，为用户提供更方便易用的算法平台，图灵平台建设了统一的在线服务框架，通过整合模型计算和预处理 / 后处理等模块，以算法版本的形式进行呈现，并进行迭代，免去了与算法与工程之间复杂的交互。

这里我们对算法定义进行了扩展，本文中的算法（也称算法策略）可以理解成一个组合函数：y=f1(x)+fi(x)+…+fn(x)，其中 fi(x) 可以是规则计算、模型计算（机器学习和深度学习）或者非模型算法计算（比如遗传算法、运筹优化等）。该组合函数中任何组合因子的调整（比如模型输入输出变更、模型类型变更或者规则调整）都可看作是

一次算法版本的迭代。算法迭代是算法开发 – 上线 – 效果评估 – 改进的循环过程。Turing OS 的目标就是优化算法的迭代效率。

3. 图灵 OS 1.0

3.1 图灵 OS 1.0 介绍

为了解决“烟囱模式”开发过程中的重复造轮子和平台化能力缺失的问题，我们着手搭建了图灵 OS 1.0 框架。该框架整合了模型计算和预处理、后处理模块，把繁杂的特征获取和预处理、模型计算、后处理等逻辑都封装在图灵在线服务框架中以 SDK 的形式对外提供。算法工程师基于图灵在线服务 SDK 开发个性化的预处理和后处理逻辑；业务工程集成图灵在线服务 SDK 和算法包，调用 SDK 提供的接口进行模型计算和算法计算。

通过图灵 OS 1.0，我们解决了各业务方独自开发、独自迭代以及重复造轮子的问题，大大简化了算法工程师和工程研发人员的开发工作，而且工程是通过图灵在线服务框架间接调用算法预处理和模型计算，不直接跟算法进行交互，一定程度上也减轻了工程和算法的耦合问题。

如图 3 所示，该阶段的图灵在线服务框架集成了以下功能：

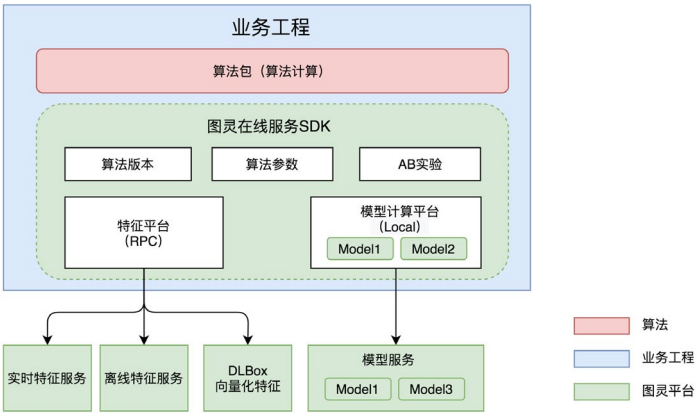

图 3　图灵 OS 1.0

3.1.1 特征获取

- 通过特征聚合、动态分组、本地缓存以及业务线级别物理资源隔离等手段，提供高可用、高性能的特征在线获取计算能力。
- 通过自定义 MLDL（Machine Learning Definition Language）将特征获取流程配置化，并统一特征获取流程，提升在线服务特征的易用性。
- DLBox（Deep Learning Box）支持将原始向量化特征和模型放在同一节点进行本地计算，解决深度学习场景下需要召回大规模数据的性能问题，支撑配送各个业务高并发及算法快速迭代。

3.1.2 模型计算

- 支持本地（Local）和远程（Remote）两种模型部署模式，分别对应将模型部署在业务服务本地和专用的模型在线服务集群中；通过多机异步并行计算，支持 CPU/GPU 资源异构等手段，解决大规模模型计算的性能问题；通过模型 Sharding 解决超大规模模型单机无法装载的问题。
- 在深度学习模型计算方面，利用高性能计算加速库 MKL-DNN 以及 TVM 等编译优化技术进一步提升深度学习模型的推理性能。
- 通过 MLDL 封装的模型特征关联关系以及预处理逻辑等配置，实现了特征获取、特征处理以及组装的自动化，提升了模型的开发迭代效率。

3.1.3 算法计算

- 支持算法版本管理、AB 路由，支持动态获取算法版本所关联的模型、特征和参数等，支持模型和参数的热更新。
- 支持 AB 实验以及灵活的灰度发布放量，并通过统一埋点日志实现 AB 实验效果评估。

3.2 图灵 OS 1.0 遗留问题

图灵 OS 1.0 解决了各业务线重复造轮子、特征混乱和平台能力缺失等问题，通过提供一站式平台化服务，支撑了美团配送各业务线大规模算法在线预测的场景和高性能计算的需求；使算法同学更加关注算法策略本身的迭代优化，提高了算法迭代的效率。但是对于前述的工程、算法、平台三方耦合问题，还没有很好的解决，主要体现在：

- 业务工程静态依赖算法包，算法包部署在业务工程中，算法包更新迭代上线需要业务工程发版。
- 算法包与业务工程运行在同一个 JVM 中，虽然减少一次 RPC 消耗，但是算法包的计算性能会影响业务工程的性能，业务工程稳定性不可控，比如 TensorFlow 模型计算时对 CPU 的消耗过大、大模型的加载和切换对内存的消耗等问题。
- 随着图灵平台提供的功能越来越丰富，图灵在线服务 SDK 变得越来越臃肿，业务工程必须升级图灵在线服务 SDK 才能使用图灵平台新功能，但是业务工程升级 SDK 风险较高，而且会拖慢业务工程部署的速度。

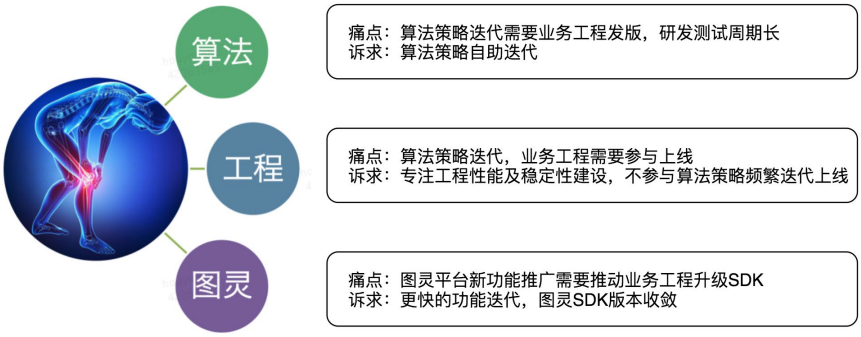

图 4　三方高耦合示意图

基于上述几点可知，算法、工程和图灵平台三方高耦合，导致各自都存在很多痛点，如图 4 所示。这些问题严重影响了算法迭代效率，算法迭代上线测试工期长，效率低：

- **算法痛点**：算法包迭代强依赖业务工程上线，每次工程发版都需要走一个完整的研发测试周期，流程长，效率低。
- **工程痛点**：算法包与业务工程在同一个 JVM 中，算法计算的性能将影响业务工程服务的性能；同时业务工程需要跟随算法包的迭代频繁发版，改动可能只涉及升级算法包的版本。
- **图灵平台痛点**：图灵在线服务 SDK 部署在业务工程中，版本收敛难度大，兼容难度大；同时图灵新功能推广难度大，需要业务工程升级图灵在线服务 SDK。

因此，必须将算法、工程和图灵平台更好的解耦，既满足算法快速迭代的需求，又能满足业务工程端稳定性的诉求，合作共赢。

4. 图灵 OS 2.0

针对图灵 OS 1.0 框架中算法、工程和图灵平台三方高耦合的痛点，我们研发了图灵 OS 2.0 框架，目标是解决算法、工程、图灵平台三者耦合的问题，让算法迭代无需依赖工程发版，图灵平台新功能上线无需业务工程升级 SDK，进一步提升算法迭代效率和工程开发效率。

围绕解耦算法、工程和图灵平台的目标，在图灵 OS 2.0 框架中，我们设计研发了算法包插件化热部署框架、算法数据通道和算法编排框架等功能，支持算法自助迭代上线。同时设计研发了以沙箱引流、实时回放、性能压测和 Debug 测试等功能为一体的算法验证平台，保证了算法策略的高性能、正确性及稳定性。图灵 OS 2.0 框架解耦了算法、工程和图灵平台，实现了算法与工程迭代的各自闭环。大部分算法迭代的整个流程无需工程研发人员、测试工程师的参与，算法工程师在小时级即可完成算法策略的迭代上线；通过图灵 OS 2.0 的赋能，算法的研发迭代效率得到了大幅提升。

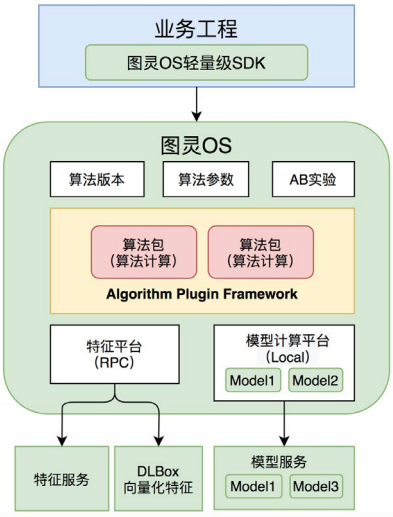

图 5　图灵 OS 框架 V2.0

图灵 OS 2.0 具体功能特性如下：

- **标准化轻量级 SDK**：业务工程只需依赖一个轻量级的图灵 OS SDK，无需频繁升级，降低工程端接入难度，解耦业务工程与图灵平台。
- **算法插件化**：自研图灵算法插件框架，支持算法包作为一个插件在图灵 OS 服务中热部署，解耦算法与工程；图灵 OS 服务中可部署多个算法包的多个版本，每个算法包拥有独立的线程池资源。
- **数据通道**：在一些复杂的算法场景下，算法策略还需依赖业务工程完成：1）算法内部获取数据，只能通过业务工程调用接口获取结果之后传递给算法；2）算法内部调用算法，只能通过业务工程中转同时调用算法 A 和算法 B。为了解决上述两点，我们提出了数据通道（Data Channel）的概念，使得算法本身具备自主获取数据的能力，而不是所有数据都需要业务工程获取然后再透传给算法。
- **算法编排**：多个算法按照串行或者并行的方式组合为有向无环图图（DAG），可以看作是一个算法编排；业务算法的抽象与沉淀，对应到新架构就是算法的组合与编排，算法编排为业务上线和算法迭代进一步赋能，进一步提升了业务算法迭代效率，进一步解耦算法和工程。
- **沙箱引流**：图灵沙箱是一个与图灵 OS 物理隔离，但运行环境完全一致的服务，流量经过沙箱不会对线上业务造成任何影响；沙箱可验证算法逻辑的正确性，同时评估算法计算的性能，提升研发测试流程的效率。
- **图灵回放及统一埋点**：在算法计算及模型计算的过程中会产生很多重要数据（算法策略、模型、特征、参数和数据通道等相关数据），这些数据不仅有助于快速排查定位系统问题，也为 AB 实验报告、沙箱引流和性能压测等模块提供了重要的数据基础，为了更好地自动记录、存储和使用这些数据，我们设计了实时回放平台和统一埋点。
- **性能压测**：图灵 OS 通过整合美团全链路压测系统 Quake 的能力，复用统一回放平台采集的流量数据来构造请求，对部署了新版本算法包的沙箱进行压力测试，保证算法策略迭代的性能及稳定性。

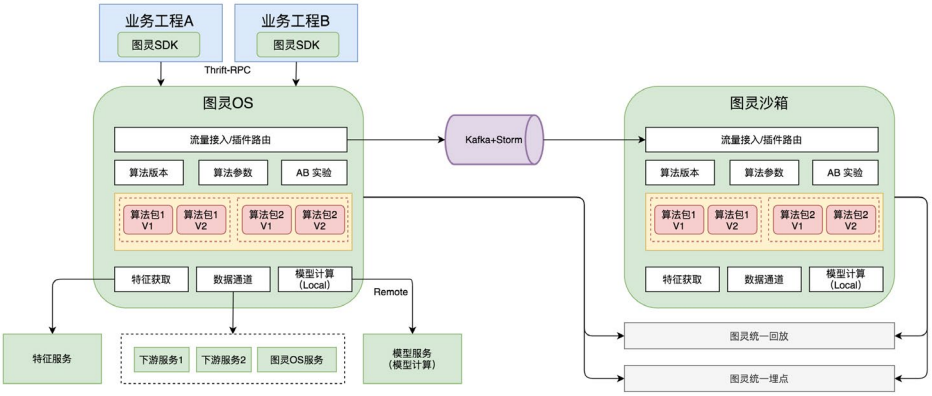

图 6　图灵 OS 2.0 总体架构

以下将对上述几个功能特性进行展开介绍，看看图灵 OS 2.0 是如何解决算法、工程和图灵平台三方耦合痛点的。

4.1 标准化轻量级 SDK

为了解决业务工程和图灵平台的耦合痛点，即图灵在线服务 SDK 部署在业务工程中，SDK 版本收敛难度大的问题，我们主要从 SDK 轻量化、简单易接入、稳定可扩展、安全可靠等几个方面考虑对图灵在线服务 SDK 进行了拆分和改造：

- **SDK 轻量化**：将原有图灵 OS SDK 逻辑下沉到图灵 OS 服务中，只提供简单通用的批量预测接口；该 SDK 无需过多暴露算法相关的细节，算法版本路由、实时 / 离线特征获取、模型计算等都隐藏到图灵 OS 内部。轻量级的 SDK 内部集成了图灵 OS 的自定义路由，业务方无需关注算法包部署在哪个图灵 OS 集群，对使用方完全透明。
- **简单易接入**：提供统一且通用的 Thrift 接口进行算法计算，使用 Protobuf/Thrift 来定义算法输入输出，相对于目前 Java 类定义接口的优势是兼容性有保障；Protobuf 接口定义完成后，算法和工程可以各自独立进行代码开发。
- **可扩展**：轻量级 SDK 版本稳定，无需工程端反复升级；Protobuf 天然支持序列化，后续流量拷贝、回放埋点等都可以基于此进行。
- **高性能**：针对大批量算法计算且要求高可用的场景，例如面向 C 端用户的批量

预测，我们设计了异步分批高度并行等手段提升算法计算性能；针对单任务计算耗时长、CPU 消耗高且要求高可用的场景，例如分城市区域的调度路径规划，我们设计了客户端快速失败最优重试机制保证高可用，也均衡了图灵 OS 的计算资源。

- **安全可靠**：针对单个图灵 OS 部署多个算法包的场景，提供线程池级别的资源隔离，针对各业务线不同的算法包，按业务场景垂直拆分，提供物理级别集群资源隔离，同时增加熔断降级机制，保证计算流程稳定可靠。

4.2 算法插件化

通过对图灵 OS SDK 进行标准化轻量化改造，我们解决了业务工程和图灵平台之间耦合的痛点。通过对图灵 OS 进行服务化改造，解决了算法和业务工程之间耦合的痛点。但是算法和图灵平台之间耦合的痛点依然存在且痛点增加：算法迭代上线依赖图灵 OS 服务发版，并未能达到三方解耦的目标。

为了解决算法与图灵平台之间的耦合痛点，进一步提升算法策略的迭代效率，我们下一步的设计思路是算法插件化，图灵 OS 容器化：将算法包作为一个插件，部署到图灵 OS 中，算法包发版不要求图灵 OS 发版，甚至不需要重启图灵 OS，如图 7 所示。

- **算法插件化**：我们自研了图灵 OS 算法插件框架，支持算法包以插件的形式部署到图灵 OS 服务中；具体实现方案是自定义算法类加载器 ClassLoader，不同的 ClassLoader 加载不同的算法包版本，通过加载多版本算法包以及指针替换，实现算法包热部署。
- **图灵 OS 容器化**：图灵 OS 充当一个插件容器，装载算法包不同的算法版本，执行算法版本路由以及算法策略计算，图灵 OS 经过容器化改造之后的流程：1）如果算法版本不需要新增参数，则工程端和图灵 OS 都不需要发版；2）业务工程主要工作是传递参数给算法，逻辑简单，如输入参数无变化则不需要发版，算法包发版节奏自己掌控。

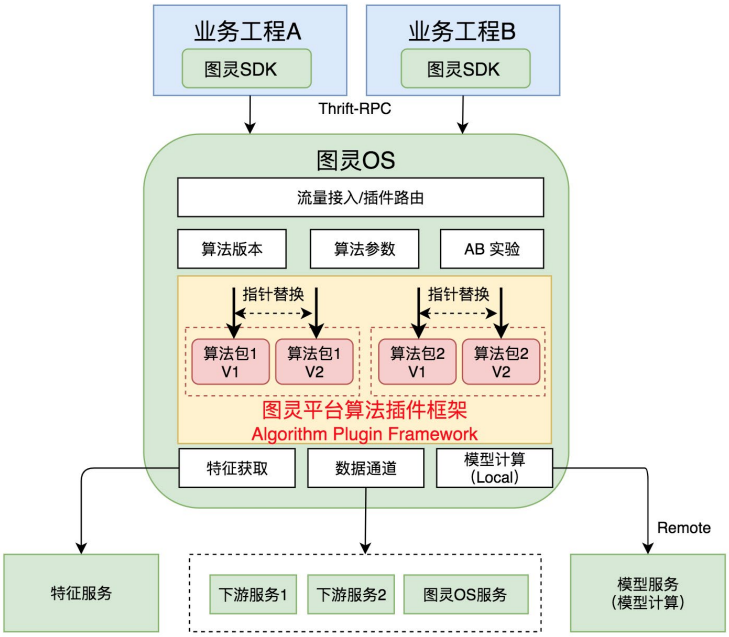

图 7　图灵 OS 容器化 – 算法插件化示意图

4.3 数据通道

通过上述手段，我们解决了算法、工程和图灵平台三者在发版迭代时的耦合问题。但是除了上述的耦合之外，还有一些复杂算法场景，算法与业务工程依然存在耦合，主要体现在算法依赖业务工程的以下两点数据：

- **算法内部获取数据**：目前是通过业务工程调用接口获取结果之后传递给算法，例如一些服务化接口数据、分布式 KV 缓存数据等，算法和业务工程都需要进行开发迭代上线。
- **算法内部调用算法**：目前通过业务工程同时调用算法 A 和算法 B 并编写中转逻辑来实现，例如算法 A 的输入需要用到算法 B 的结果，或者需要综合算法 A 和算法 B 的结果得到最终输出，这些操作一般都交由业务工程来处理。一种可选方案是将算法 A 和算法 B 合并成一个庞大的算法，但该方案的劣势是增加了算法 A 和算法 B 独立进行 AB 实验及灰度的研发成本。

为了解决上述两点，我们提出了数据通道（Data Channel）的概念，使算法本身具备自主获取数据的能力。在算法内部算法可通过图灵 OS 提供注解的方式支持数据通道，算法与业务工程的交互接口仅需传递一些关键参数及上下文数据即可，算法内部自行组装该数据通道所需参数。经过数据通道化的改造，算法接口进一步简化，算法与工程耦合度进一步降低，算法内部调用算法的问题，我们可通过下面介绍的算法编排来进行解决。

4.4 算法编排

一个完整的算法计算流程包括算法计算部分，以及针对输入的预处理逻辑和计算结果的后处理逻辑等，算法计算可以是 N 次规则计算，N 次模型计算（机器学习和深度学习等），或者非模型的算法计算（比如遗传算法、运筹优化等），或者多种类型算法组合。我们把这种具有独立输入输出的计算逻辑单元抽象为一个算子，算子可编排、可复用，通用的两类算子如下：

- **模型计算算子**：即模型计算引擎执行模型计算，我们支持 Local 和 Remote 两种模型计算模式，在 Remote 计算模式中，模型可能部署在不同的模型集群中，算子是对模型计算的进一步封装，将 Local 和 Remote 选择及模型集群路由等功能对用户透明，算法工程师无需感知，我们会根据整体计算性能进行动态调整。
- **算法计算算子**：即图灵 OS 中的算法计算引擎执行算法策略计算，不同的算法插件可能部署在不同的图灵 OS 中，同时也将图灵 OS 集群的路由功能进行了封装，对用户透明。

多个算子之间通过串行或者并行的方式组合为一个有向无环图（DAG），形成了算子编排，当前我们有两种方式实现算子编排：

- **算法数据通道**：不同图灵 OS 中的算法计算引擎互相调用或者算法计算引擎调用模型计算引擎，算法数据通道是实现算子编排的一种具体手段。
- **算法总控逻辑**：我们在算法调用的上层抽离出一层算法总控逻辑层，满足复杂

算法场景及多个算法关联依赖的情况，该算法总控逻辑由算法工程师在算法包中实现；通过算法总控逻辑功能，算法工程师可以任意编排算法之间的关系，进一步解耦算法和工程。

从算法工程师的视角来看，图灵 OS 以搭积木的方式提供服务，通过组合一个个独立的子功能及算子，以标准的方式串并联，从而形成满足各式各样需求的在线系统。

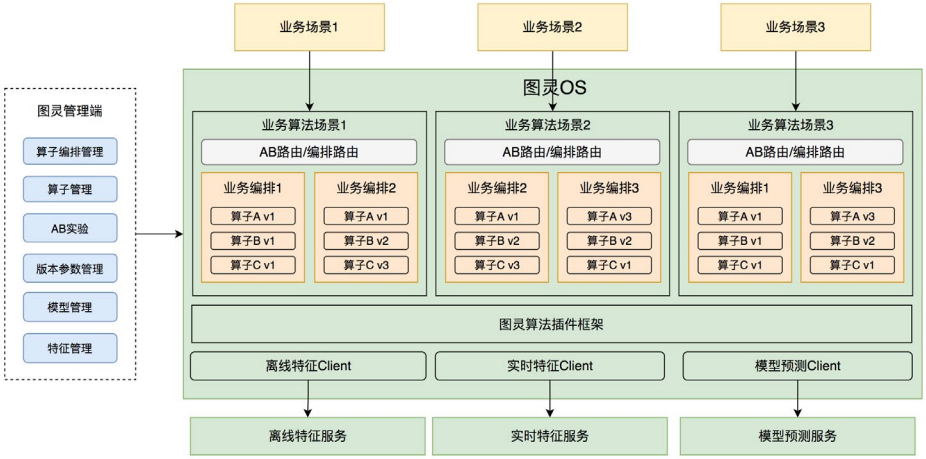

图 8　基于算子编排的算法在线服务架构

在该架构下，算法的工作主要有如下三部分：1）算法工程师进行业务流程的抽象与建模；2）算法工程师进行独立的算子开发与测试；3）算法工程师基于业务流程抽象进行算子的编排与组合。算子编排为业务功能上线和算法迭代进一步赋能，业务算法迭代效率进一步提升。

4.5 多模式集成

上文介绍了图灵 OS 作为一个容器可部署多个算法包的多个版本，并支持算法包热部署。图灵 OS 通过插件化热部署以及编排等功能，解耦了业务工程、算法以及图灵的三方耦合，极大地提升了算法的迭代效率。为了进一步满足业务的要求，我们提供了两种图灵 OS 部署集成模式：Standalone 模式和 Embedded 模式。

Standalone（独立模式）

Standalone 模式下，图灵 OS 是独立于业务服务单独部署的，业务服务通过轻量级 SDK 调用算法，图灵轻量级 SDK 内部封装了图灵 OS 的自定义路由，以及 Thrift-RPC 调用图灵 OS 服务的逻辑。

Embedded（内嵌模式）

在某些高并发及高性能要求的复杂场景中，对我们图灵 OS 的集成模式及性能提出了更高的要求。在独立部署模式下，业务工程每一次算法计算都有 RPC 的消耗，因此我们实现了图灵 OS 新的集成模式——Embedded。在 Embedded 模式下，我们对外提供图灵 OS 框架代码包，业务方在自己的工程服务中集成图灵 OS 框架包，业务服务同时也作为一个图灵 OS 容器，还是通过轻量级 SDK 调用算法，在业务服务本地进行算法计算。内嵌图灵 OS 的特点如下：

- 业务工程因集成了图灵 OS 框架代码，而继承了算法包插件化和热部署的功能，具备了业务功能和图灵 OS 容器的双重属性。
- 业务工程并不直接依赖算法包，而是由图灵 OS 框架进行动态管理，算法包进行插件化热部署，达到了算法和工程解耦的目的。
- 业务工程直接进行本地算法计算，减少了算法调用的 RPC 及序列化消耗，同时复用了业务工程服务器资源，进一步减少集群资源消耗，提升了资源利用率。

在算法包插件部署时，以内嵌模式集成的业务工程将作为容器装载相应的算法包，路由到本地进行算法计算，如下图 9 所示。

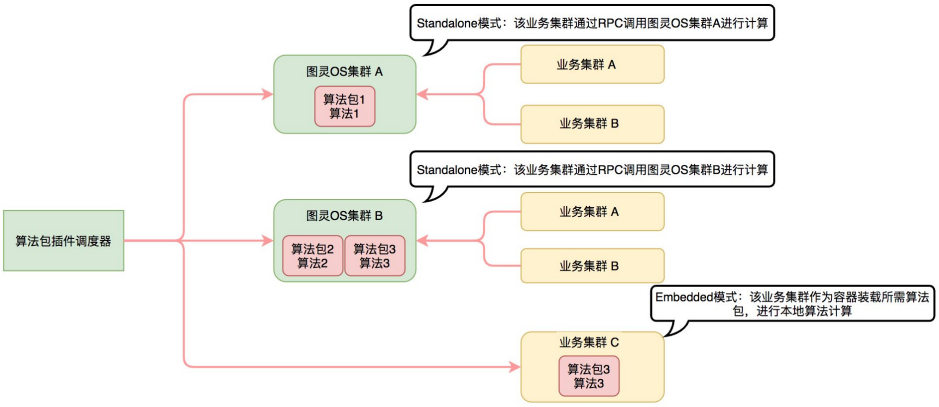

图 9　图灵 OS 集成模式 Embed/RPC 示意图

Standalone 和 Embedded 模式各有利弊，谁都没有绝对的优势，使用时需要根据具体的业务场景进行选择。两种模式的对比如下：

部署模式	优点	缺点	适用场景
Stand-alone	耦合度更低，业务方只依赖图灵轻量级 SDK	需要搭建图灵 OS 集群，占用机器资源；有 RPC 调用开销	适合大批量调用，需要分布式多机异步并行计算的业务场景
Embed-ded	复用业务方机器，资源利用率高；少了 RPC 调用，性能高	无法充分发挥多机异步分布式并行，只能单机并行	适合小批量调用，对单次调用 RT 性能要求较高的业务场景

4.6 图灵沙箱

在图灵 OS 支持算法插件热部署之后，算法迭代效率相比之前大幅提升，算法工程师的上线自由度也得到大幅增加，无需经过业务工程和测试的排期开发和测试；但是也引入了新的问题：

- 算法迭代上线前，无法引线上流量进行预计算，提前对算法效果进行上线前评测，上线前校验难，算法工程师测试效率较低。
- 当前线上实时评估和校验困难，算法策略的线上性能和效果评估缺少流程化自动化工具。
- 频繁的迭代上线对图灵 OS 服务以及业务的稳定性来说也是很大的挑战。

当时的可选方案是算法策略先部署上线，灰度切小流量，然后再分析统一埋点日志评测算法效果。该方案的缺陷是无法在上线前对算法效果进行评测，问题发现时间过晚。如果灰度的功能有问题，会对线上的业务造成影响，产生 Bad Case。针对上述上线前校验环节的各个问题，我们研发了图灵沙箱，在不干扰线上业务稳定的前提下，实现了算法的全链路仿真实验。

图灵沙箱是一个与图灵 OS 服务物理隔离但运行环境完全一致的服务，流量经过沙箱不会对线上业务造成任何影响。如下图 10 所示，线上流量引流到线上环境沙箱，图灵 OS 和图灵沙箱的各环境配置及数据都一致（版本、参数、特征、模型等）。算法新版本（如下图 10 中算法包 1 的版本 V3）先部署沙箱，引流验证算法正确性，同时还可以在沙箱内引流进行算法性能压测。图灵沙箱作为算法验证流程的自动化工具，提升了算法测试效率，进一步提升了算法版本的迭代效率。

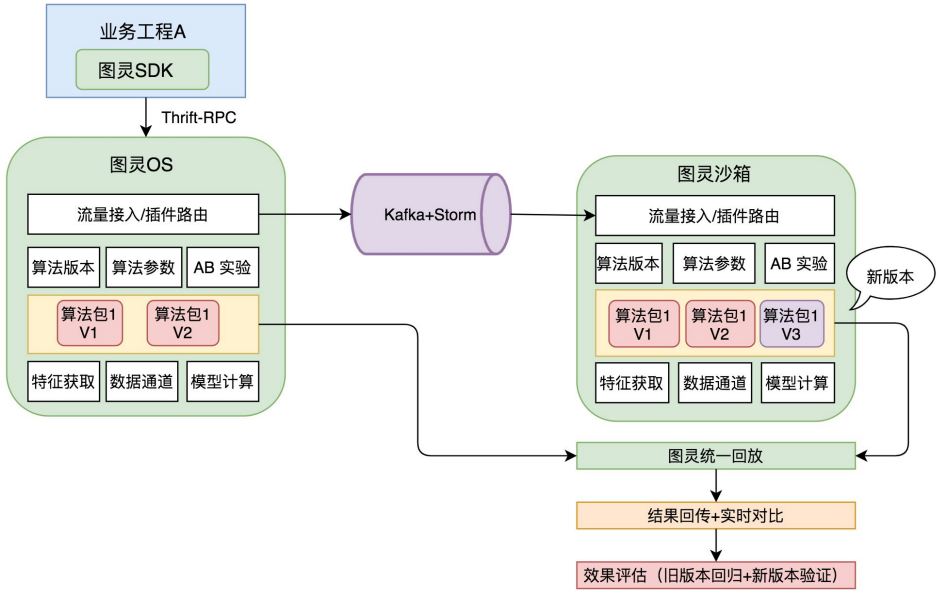

图 10　图灵沙箱引流验证示意图

4.7 统一回放平台

为了方便分析算法效果及异常时排查问题，我们需要把算法计算过程中的输入、输出、所用的特征以及模型等数据都记录下来，以便还原现场。但是算法计算过程中会产生大量的数据，对存储和记录带来了挑战：

- **数据量大**：一次请求可能对应多次算法模型计算，并且往往会用到丰富的特征值，导致中间计算数据数倍于请求量。
- **并发量高**：集中收集存储各图灵 OS 服务产生的数据，需要具备承载这些服务高峰期 QPS 流量之和的能力。
- **定制性强**：图灵 OS 部署了数十种不同的算法，他们的请求和响应格式千差万别，特征和数据源等数据更是难以统一。

为了更好地记录和存储这些重要数据，图灵 OS 设计研发了统一回放平台，针对上述问题给出了解决方案，如下图 11 所示：

- 采取 ES 和 HBase 结合存储回放数据，其中 ES 存储关键索引字段，HBase 存储完整数据记录，充分发挥二者的优势，同时满足了快速查询搜索和海量数据存储的要求。
- 利用 Google Protobuf 的 DynamicMessage 功能，对原始 Google Protobuf 格式进行扩展，动态支持回放数据格式的定义及数据组装，并支持与 ES 索引的同步，既保证序列化和存储的高性能，也保证各算法数据的高效接入。
- 考虑到对这些数据查询的时效性要求不高，使用消息队列将发送和存储进行解耦，达到对流量削峰填谷的效果，图灵 OS 平台中的各算法通过回放 Client 自动接入回放。

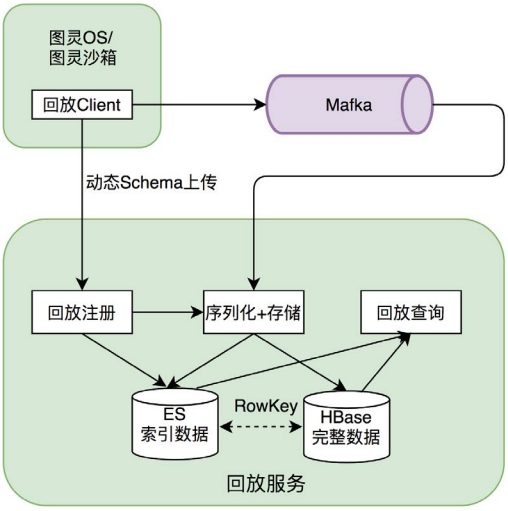

图 11　图灵回放平台示意图

4.8 性能压测及调优

通过图灵沙箱和统一回放，图灵 OS 具备了快速验证算法数据正确性的能力，但是在算法计算性能分析方面缺少自动化工具。图灵 OS 通过整合公司全链路压测系统 Quake（Quake 介绍详见《全链路压测平台（Quake）在美团中的实践》）的能力，复用统一回放平台采集的流量数据来构造请求，对部署了新版算法包的图灵 OS 或图灵沙箱进行压力测试。

压测过程中记录算法在不同 QPS 场景下的性能表现，主要包括 CPU 和内存等应用指标，TP 时延和超时率等响应耗时数据，并与线上真实性能、历史压测数据和服务承诺的 SLA 进行对比分析给出压测报告及优化指南，存在明显性能问题时将阻断算法包的上线流程。图灵 OS 也接入了美团内部性能诊断优化平台 Scalpel，可以生成压测过程中线程堆栈和性能热点的分析报告，辅助用户快速定位性能瓶颈点，为具体优化方向提供参考。

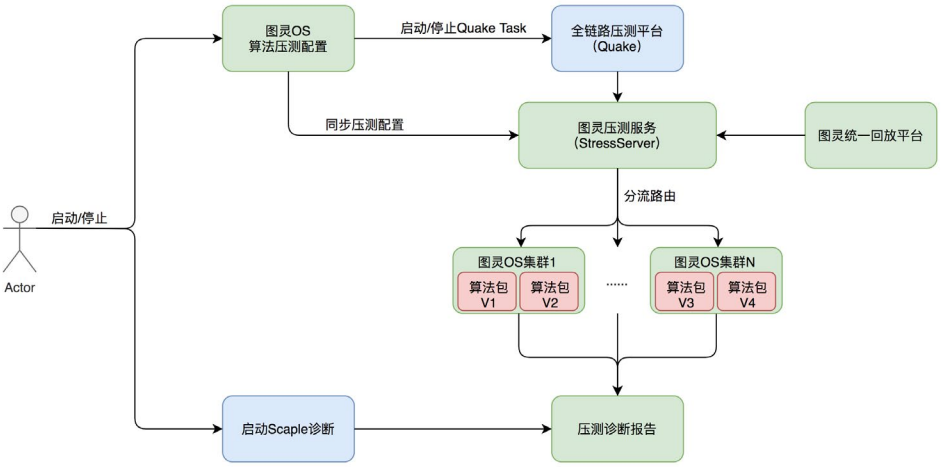

图 12　图灵全链路压测及性能诊断示意图

5. 图灵 OS 2.0 建设成果

5.1 算法研发流程

通过图灵 OS 的算法插件化改造和动态热部署的能力，我们解耦了算法、工程和图灵平台，实现了算法与工程迭代的各自闭环，提升了研发效率，算法迭代上线周期大幅缩短：

- 当模型迭代、特征变更及算法策略迭代时，算法工程师可以自主完成全链路的开发测试，无需工程研发人员和测试工程师的介入；同时算法包可独立部署，无需任何服务上线，上线后周知到工程侧及产品方关注相关指标变化即可。
- 当新业务场景和新算法策略接入时，还需要算法和工程共同开发，定义好 Protobuf 接口之后，算法工程师和工程研发人员可以各自独立开发代码，各自上线。

通过使用图灵 OS 提供的沙箱引流验证和性能压测诊断等自动化工具，算法策略迭代的效率进一步提升，算法迭代上线周期大幅缩短，由天级别提升至小时级别。算法工程师自主开发，然后部署图灵 OS 进行自测调试，部署沙箱进行引流测试，通过压测平台评估效果性能，最后自主部署上线，整个流程无需工程研发人员及图灵工程师的

参与，达到自动运维的目标；同时通过各种手段保证算法策略的执行性能及图灵 OS 的运行稳定性。

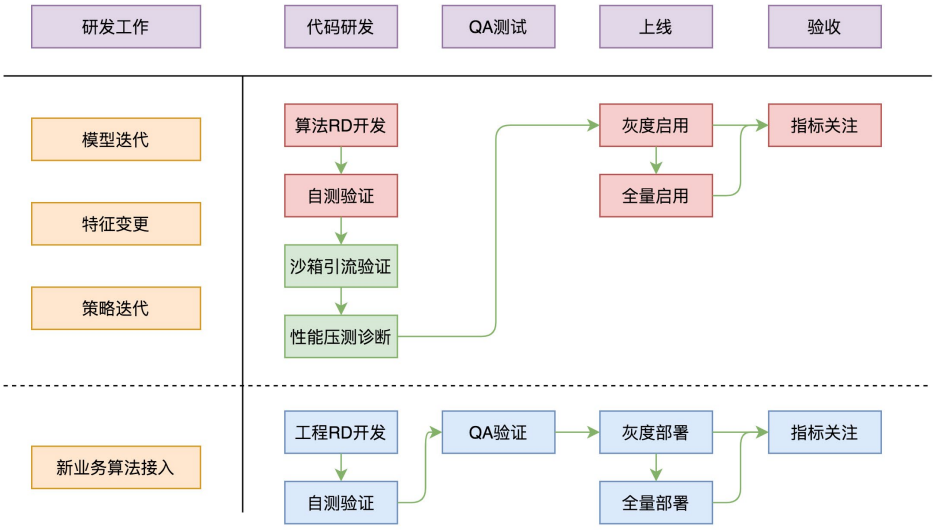

图 13　图灵算法研发流程

5.2 图灵 OS 2.0 使用汇总

图灵 OS（即图灵在线服务框架 2.0）建设已有大半年的时间，整体概况大致如下：当前已搭建 20+ 个图灵 OS 集群，已接入 25+ 个算法包、50+ 个算法，每月算法包部署上线次数 200+ 次；每天支持百亿次算法策略计算。通过图灵 OS 赋能，大部分算法迭代整个流程无需工程研发人员、测试工程师的参与，算法工程师在小时级即可完成算法策略的迭代上线。

当前，一个图灵 OS 集群可承载单业务线的多个算法包或单个部门的多个子业务线算法包，算法包和图灵 OS 集群可动态关联及动态部署，图灵 OS 同时支持业务线级别和算法包级别的物理资源隔离。为了方便业务方的使用，我们提供了完善的接入文档和视频课程。除了图灵平台方搭建图灵 OS 集群之外，任何一个业务方基本上可以在 1 小时内构建出自己的图灵 OS 服务。我们同时提供了最佳实践文档与性能调优配置等，使得业务方在没有指导的情况下可以自行解决大部分问题。目前我们正在建设自

动化运维工具，进一步降低了图灵 OS 的接入门槛和运维成本。

6. 总结及未来展望

当然，肯定没有完美的算法平台及算法在线服务框架，图灵 OS 还有很大的进步空间。随着我们对机器学习和深度学习线上服务的持续探索，会有越来越多的应用场景需要图灵 OS 支持，未来我们会在以下方面持续进行建设：

- 建设图灵 OS 自动化运维工具和自动化测试工具，支持算法半自动化开发，进一步降低平台接入成本和运维成本。
- 进一步完善图灵 OS 框架，完善算法支撑能力，支持在 Spark 环境运行，当算法迭代时，基于海量的数据验证算法新功能的正确性、性能及效果。
- 推进图灵 OS 全图化引擎的建设，通过抽象算法业务的通用组件，提供图形化流程编排工具和图执行引擎，为业务上线和算法迭代进一步赋能，进一步提升迭代效率。

7. 作者简介

永波、季尚、艳伟、非凡等，均来自美团配送技术部算法平台组，负责图灵平台建设等相关工作。

8. 招聘信息

如果你想近距离感受一下图灵平台及图灵 OS 的魅力，欢迎加入我们。美团配送技术团队诚招机器学习平台、算法工程方向等的技术专家和架构师，共同面对复杂业务和高并发流量的挑战，共建全行业最大的即时配送网络和平台，迎接美团配送业务全面智能化的时代。感兴趣同学可投递简历至：houyongbo@meituan.com（邮件标题注明：美团配送技术团队）。

美团终端消息投递服务 Pike 的演进之路

作者：健午　佳猛　陆凯　冯江

1. Pike 的前世今生

1.1 Pike 1.0 的诞生背景

2015 年，美团诞生了 Shark 终端网络通道，为公司移动端提供长连代理加速服务。Shark 通过网络接入点的全球多地部署和保持长连来提升网络请求的端到端成功率，降低端到端延时，从而提升用户体验。

Pike 1.0 是基于 Shark 长连通道实现的应用内推送服务。由于底层传输基于 Shark 长连通道，使得 Pike 1.0 天生便具有了低延时、高可靠、防 DNS 劫持等优秀基因。目前 Pike 1.0 在美团内部的实时互动、营销推送、状态下发、配置同步等业务场景都有广泛使用。

1.2 Pike 1.0 的工作流程

移动端 SDK 会在每次长连接创建成功后，使用 APPID、设备唯一标识 UnionID（美团唯一标识、点评唯一标识等）向服务器发起注册，在注册成功之后业务服务端就可以通过 Pike 1.0 服务端 SDK 提供的接口，主动向设备的 App 推送消息。服务端推送的消息通过长连接通道抵达客户端，最后通过注册的回调接口投递给业务方。整体工作流程参见下图：

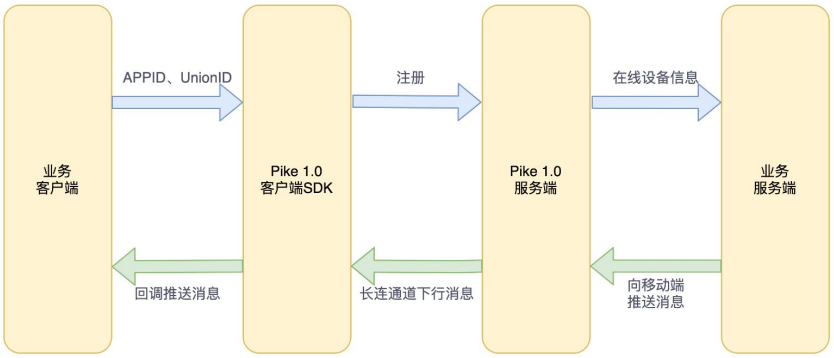

图 1　Pike 1.0 工作流程图

1.3 Pike 1.0 的优势

Pike 1.0 底层传输基于 Shark 长连通道，所以 Pike 1.0 在以下几个方面有不错的表现：

- **防 DNS 劫持**：底层通道直接使用 IP 直连，省去 DNS 解析耗时的同时也避免了被 DNS 劫持的风险。
- **低延时**：Shark 长连接采用就近接入点长连接的方式，省去了传统 HTTP 传输需要多次建连、握手的消耗，端到端数据传输延时相比 HTTP 大幅缩短。
- **安全性好**：Shark 采用自定义二进制协议进行数据传输，进行了通道级别的 TLS 加密，防篡改，更安全。
- **更好的境外体验**：Pike 1.0 与 Shark 共享服务集群，Shark 长连通道在海外多地都部署了接入点，代理加速接入，网络延时及成功率表现要优于常规请求。

1.4 Pike 1.0 的痛点

Pike 1.0 作为 Shark 的衍生产品固然有其闪光的地方，但是对 Shark 的强依赖所带来的痛点更是让开发人员叫苦不迭，主要痛点如下。

1.4.1 代码结构耦合

在客户端 SDK 方面，Pike 1.0 代码与 Shark 代码结构耦合，共用底层通道建连、数据加解密、二进制协议等逻辑。如图展示了 Pike 1.0 与 Shark 在代码结构上的关系。

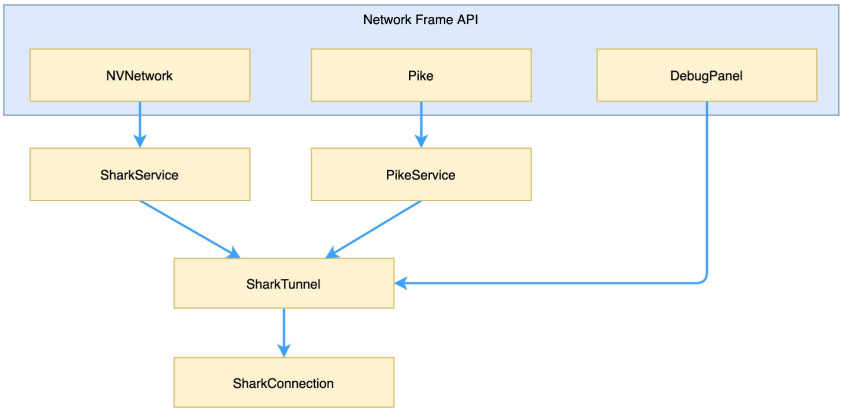

图 2　Pike 1.0 与 Shark 代码结构示意图

耦合带来的弊端一：代码优化升级困难。针对一个 SDK 的变更经常需要更多地考虑对另一个 SDK 是否有负面影响，是否影响面可控，这就无端地增加了开发成本。

耦合带来的弊端二：Shark 与 Pike 1.0 的网络配置环境共用，如图所示，通过 DebugPanel 对 SharkTunnel 进行网络环境配置都会同时对 Shark 和 Pike 1.0 生效，但是业务方在使用的时候往往只关注其中的一个 SDK，不同 SDK 之间的相互影响引入了很多客服问题，也给客服问题的排查带来了较多干扰因素。

1.4.2 账号体系混乱

Pike 1.0 在同一个 App 上只支持一种设备唯一标识 UnionID，不同 App 上注册使用的 UnionID 会有不同，例如美团使用美团唯一标识，点评则使用点评唯一标识。假如一个业务只在一个 App 上使用的话 Pike 1.0 自然可以很好地工作，但是同一个业务有可能需要在多个 App 上同时使用（如图所示），如果业务方不对账号体系进行兼容的话，美团 App 上使用点评唯一标识作为推送标识的业务将无法工作，点评 App 上使用美团唯一标识作为推送标识的的业务也会无法工作。这就导致同一个业务在不同 App 上的推送标识 ID 逻辑会非常复杂，后端要同时维护多套账号体系之间的映射，才能解决账号体系混乱的问题。

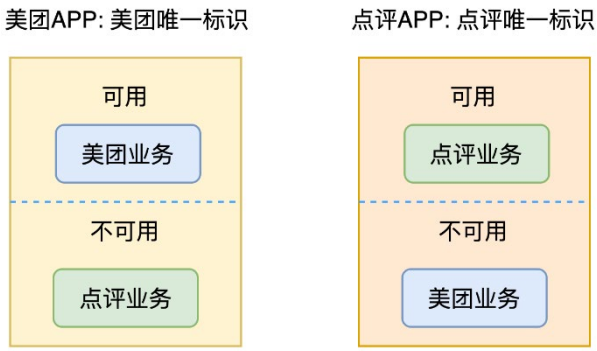

图 3　Pike 1.0 账号体系不兼容示意图

1.4.3 推送连接不稳定

Pike 1.0 由于共用 Shark 的通道逻辑而缺乏推送场景专项优化，在检测通道异常、断连恢复等方面表现不够优秀。在通道可用性上，Shark 与 Pike 1.0 关注的 SLA 也有着很大的不同。

例如，Shark 在长连接通道不可用的情况下，可以通过降级短连接来规避业务网络请求持续失败所带来的成功率下降问题。但是对于 Pike 1.0 此时如果通道不能快速恢复的话就会造成业务消息投送失败，将直接影响消息投递成功率。所以 Shark 通道针对连接保活的公共逻辑并不能完美地应用在 Pike 1.0 业务场景上。

虽然 Pike 1.0 在 Shark 通道的基础上进一步在协议层强化了心跳探测机制以提高通道可用性，但通道不能及时检测异常还是时有发生。此外，Pike 1.0 内部使用的事件分发技术的可靠性还暂时没能达到 100%，零星地会上报一些异常断连而导致推送不成功的客服问题。综上，针对推送连接不稳定专项优化的诉求也就不断被提上日程。

1.5 Pike 2.0 的诞生

Pike 1.0 现有的痛点在业务场景日益丰富的现状下遭遇了诸多挑战。力求解决 Pike 1.0 现有在 Android 和 iOS 平台运营上遇到的问题，一方面我们重新梳理产品架构与代码实现，另一方面我们决定与基础技术部另一个服务于 H5 的消息投递服务 Pike Web 进行产品融合，进而推出全新的升级产品——Pike 2.0。

下图展示了 Pike 2.0 的产品全景，针对 Pike 1.0 的现状，Pike 2.0 前后端都做了诸多优化，包括技术架构升级、集群独立、协议扩展等。其中在客户端方面 Pike 2.0 提供了基于多语言实现服务于多平台的 SDK，在服务端方面 Pike 使用部署 Java 应用的分布式集群来提供服务。

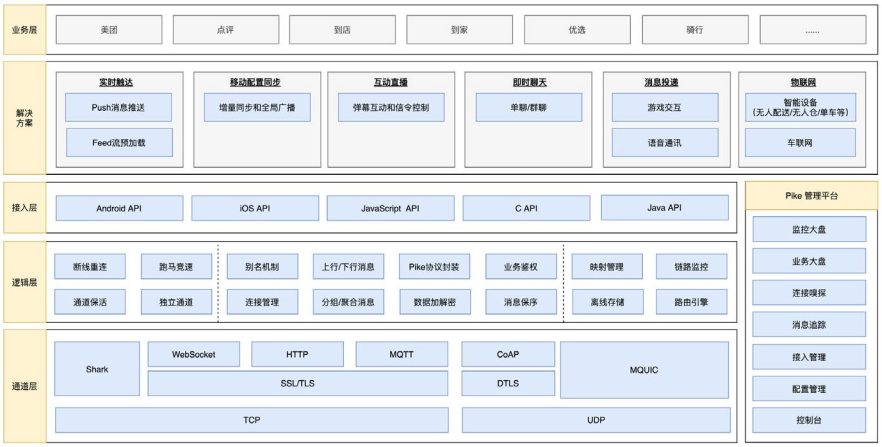

图 4　Pike 2.0 产品全景图

本文主要从客户端视角，详细阐述 Pike 2.0 客户端 SDK 的技术方案设计，从原理上说明 Pike 2.0 带来的技术优势。

2. Pike 2.0 架构设计

针对上文提及的 Pike 1.0 代码结构耦合的痛点，Pike 2.0 进行了全新的架构升级，在代码结构、环境配置、服务集群等方面上都与 Shark 保持产品隔离。

2.1 设计思想

经过接近一年的技术积累与沉淀，从 Shark 提炼的 TunnelKit 长连内核组件和 TNTunnel 通用通道组件已经趋于稳定，所以 Pike 2.0 选择基于 TunnelKit 与 TNTunnel 来构建双向消息通道服务。具体优势有：

- Pike 2.0 基于 TunnelKit 长连内核构建，能有效地复用现有长连接控制相关的

功能，减少不必要的开发工作。

- Pike 2.0 能够共享 TNTunnel 的相关通用特性，如 Shark 协议封装、数据加解密等，后期维护成本较小。
- Pike 2.0 协议作为 Shark 协议的 Payload 传输，可以灵活定制自己特性相关的协议。

2.2 整体架构

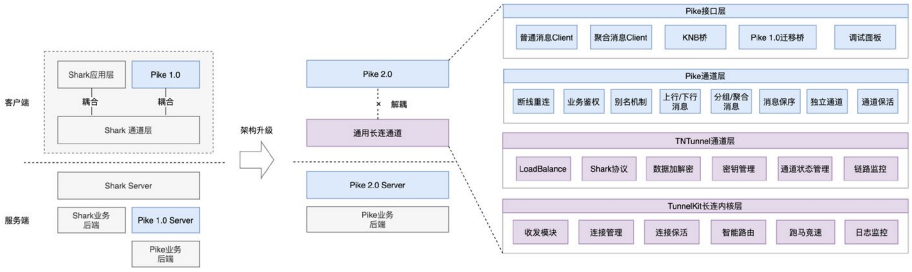

图 5　客户端架构演进图

整体架构如图所示，包括 Pike 接口层，Pike 通道层，TNTunnel 通道层和 Tunnel-Kit 长连内核层。

2.2.1 Pike 接口层

Pike 接口层旨在为主流前端技术栈中所有需要应用内消息服务的业务提供简洁可靠的接口：

- Pike 2.0 提供了 Android、iOS、MRN 等公司主流技术栈的接入 SDK，业务可以根据自己的需求灵活选择。
- Pike 2.0 针对不同的消息 QPS，设计了两种不同 Client。对于消息量超过 50 条每秒的业务，例如直播弹幕推送，我们推荐接入聚合消息 Client；对于消息量较小的其他业务，普通消息 Client 则可以满足需求。
- Pike 2.0 针对线上 Pike 1.0 系统提供了业务无感的迁移方案，业务方无需任何人力投入便可以从之前的 Pike 1.0 系统迁移至 Pike 2.0 系统来进行消息的收发。

2.2.2 Pike 通道层

Pike 通道层是特性的实现层，所有 Pike 接口层的 API 调用都会通过线程调度转变成封装的 Task 在 Pike 通道层完成具体的操作，Pike 通道层是单线程模型，最大程度规避掉了线程安全问题。

Pike 特性如下：

- **断线重连**：鉴于长连接的不稳定特征，Pike 2.0 通道通过断线重连机制来使的业务方可以认为在网络没有发生故障的情况下是持续可用的。
- **业务鉴权**：业务后端可以通过 Pike 2.0 通道对连接的监控来感知连接变更，同时对接入网络的客户端设备进行可用性判别。
- **别名机制**：针对不同业务方对业务标识做了隔离，每个业务可以自定义标识 ID，解决了 Pike 1.0 同一个 App 平台不同业务必须强制使用相同标识 ID 的痛点。
- **上行 / 下行消息**：Pike 2.0 是双向通道服务，不仅支持 Pike 1.0 原有的消息推送能力，即服务端向客户端发送下行消息；同时也支持客户端主动发送消息，即客户端向服务端发送上行消息。业务只要通过 Pike 2.0 系统便可以形成消息的闭环。
- **分组 / 聚合消息**：Pike 2.0 支持消息分组和消息聚合来满足高 QPS 业务场景的使用。其中消息分组表示业务可以通过自定义标签来对一组用户进行消息广播；消息聚合表示将短时间内井喷式的消息进行聚合下发以提高系统的吞吐量。
- **消息保序**：Pike 2.0 支持同一客户端发送的上行消息有序投递到固定的业务服务器。
- **独立通道**：Pike 2.0 默认所有业务是使用一条共享的通道，针对业务量大或者对吞吐量有要求的业务可以自动切换独享的通道来保证消息的投递成功率和时延。
- **通道保活**：Pike 2.0 在连接保活的基础上增加了通道巡检，能够在检测到异常的情况下自动重启通道，确保在要求长稳的环境下进一步提升通道可用性。

2.2.3 TNTunnel 通道层

TNTunnel 通道层是封装通用通道逻辑的功能层。主要涉及通道状态管理、协议封装、数据加解密等通用核心模块，是将通用通道逻辑从原先 Shark 通道中提炼而成的独立分层。Pike 协议虽然是构建在现有 Shark 协议之上的应用层协议，但是 Pike 通道已经和原先的 Shark 通道在逻辑上完全解耦。一方面，Pike 2.0 会最大限度地复用 Shark 协议已成熟的技术，但是又不依赖于原有的 Shark 逻辑；另一方面，后续涉及二进制协议、安全协议等协议方面的升级优化都可以同时服务于 Pike 2.0。

2.2.4 TunnelKit 长连内核层

TunnelKit 长连内核层主要功能是对接 Socket 来处理 TCP 或者 UDP 数据的发送与接收，管理各个连接的可用性等。每条 Pike 2.0 通道在 TunnelKit 中都是维护一条连接的，通过心跳保活机制和连接管理来保证在网络环境正常的情况下永远有一条连接来承载 Pike 数据。TunnelKit 作为所有通道层的基础，是决定上层长连接通道稳定性最重要的一层。

3. Pike 2.0 工作机制

在进行了全新架构升级的基础上，Pike 针对上文提及的 Pike 1.0 账号体系混乱、推送连接不稳定的痛点重新设计并完善了工作机制。

其中，PikeClient 作为 Pike 系统对接业务方的门户，在整个 Pike 2.0 系统中起着至关重要的作用，本文将以 PikeClient 为切入点介绍 Pike 的工作机制。

3.1 PikeClient 生命周期

为了更好地维护 Pike 2.0 内部状态，PikeClient 使用状态机来负责生命周期管理。

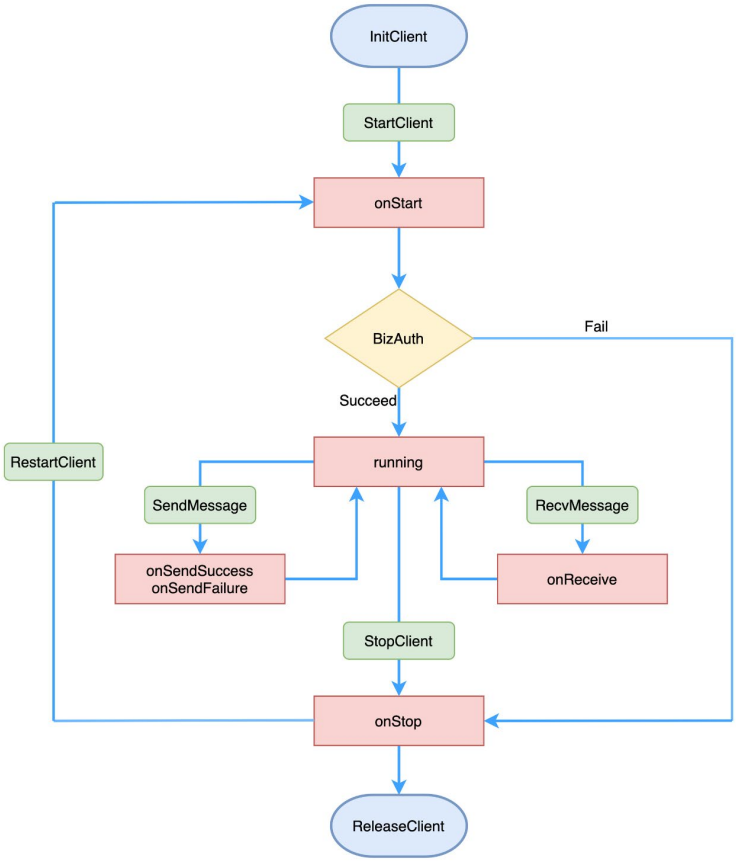

图 6　PikeClient 生命周期图

如图所示，PikeClient 生命周期主要包括如下几个部分：

- onStart：该状态是业务方调用 StartClient 或者 RestartClient 之后进入的状态，此时 PikeClient 已经正常启动，之后 Pike 2.0 内部会发起业务鉴权并根据鉴权结果流转到其他的状态，如图所示如果业务鉴权失败则进入 onStop 状态，如果业务鉴权成功则进入 running 状态。
- onStop：该状态是业务方调用 StopClient 或者业务鉴权失败之后进入的状态，此时 PikeClient 已经停止工作，客户端进入该状态之后需要 Restart 才能重新使用。
- running：该状态是 PikeClient 长稳工作的状态，此时 Pike 2.0 等待响应服务

推送的下行消息或者随时准备发送上行消息。作为双向消息通道，Pike 2.0 处理上下行消息的能力是完全并行的。

- onReceive: 该状态是 PikeClient 成功接收到下行消息之后进入的状态，Pike 2.0 将接收到的消息投递给业务方之后重新进入 running 状态等待下一次操作。
- onSendSuccess/onSendFailure：该状态是 PikeClient 发送上行消息之后进入的状态，业务方可以通过监听该状态来获取本次消息发送的结果。

通过基于状态机的生命周期管理，既严格定义了 PikeClient 的工作流程，也可以准确监控其内部状态，提高了 PikeClient 的可维护性。

3.2 PikeClient 工作模式

针对 Pike 1.0 混乱的账号体系痛点，Pike 2.0 设计了全新的工作模式。如下图所示，Pike 通过通道代理模块提供共享通道和独立通道两种模式来满足不通业务场景的需求。

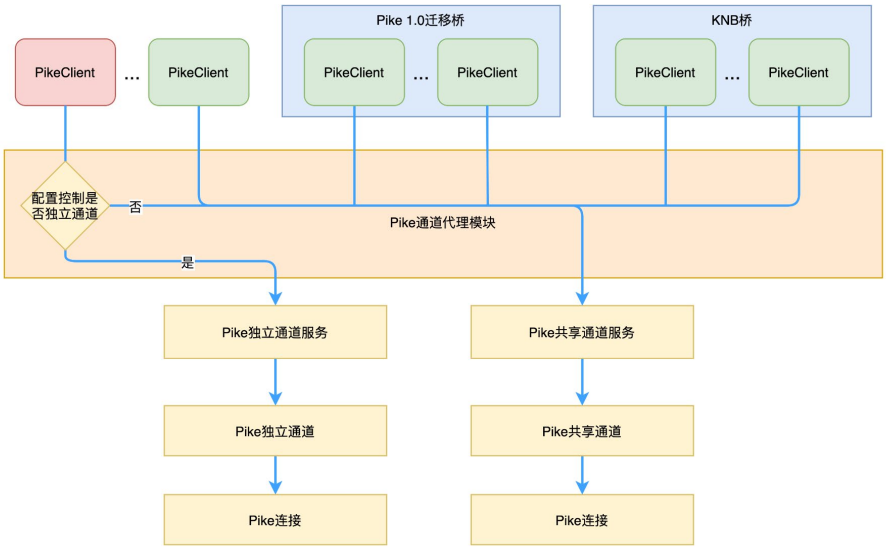

图 7　PikeClient 工作模式示意图

3.2.1 共享通道模式

共享通道模式是 Pike 2.0 基本的工作模式，新增的业务方在默认情况下都会使用该模式接入 Pike 2.0。

在 Pike 2.0 中 PikeClient 与 Pike 通道服务是多对一的共享关系，每个业务方都会有自己的 PikeClient，每个 PikeClient 都可以自定义消息推送标识 ID 而避免使用全局标识 ID。业务后端可以精简推送标识逻辑，避免同时维护多套账号体系。

不同业务的 PikeClient 仅在接入层面做了业务隔离，在 Pike 2.0 通道中会由 Pike 通道服务完成统一的管理。这种多对一的共享关系使得所有 Pike 业务共享 Pike 2.0 通道特性，同时又可以针对每个业务的使用场景设置其特定的消息处理能力，每个接入 Pike 2.0 的业务方都只需要关注其自己的 PikeClient 即可。

3.2.2 独立通道模式

独立通道模式是共享通道模式的拓展能力，Pike 2.0 通过配置控制来决策是否切换至该模式。

Pike 2.0 默认情况下所有业务方都是共享同一个 Pike 通道服务，然而鉴于业务场景的不同，每个业务对于消息吞吐量，消息时延等 SLA 指标的诉求也有差异，例如游戏业务对于消息时延过长的容忍性就比较差。针对特殊业务 Pike 2.0 提供了独立通道切换的能力支持。

所有 PikeClient 都通过 Pike 通道代理模块来对接 Pike 通道服务，Pike 通道代理模块可以通过开关配置来控制 PikeClient 与特定的 Pike 通道服务协同工作。通过运用代理模式，既保证了原有结构的完整性，在不需要调整 Pike 通道代码逻辑的基础上就能够完成独立通道能力支持；又可以扩展通道切换能力，有效地管理通道切换的流程，让 Pike 2.0 通道最大化提供业务能力的同时避免资源浪费。

3.3 PikeClient 保活机制

PikeClient 的保活完全依赖 Pike 2.0 通道的保活，针对 Pike 1.0 推送连接不稳定的痛点，Pike 2.0 通道在吸收 Pike 1.0 在保活机制方面沉淀的技术的基础上继续优化，

最后设计出基于心跳探测、重连机制和通道巡检的三重保活机制。保活机制如下图：

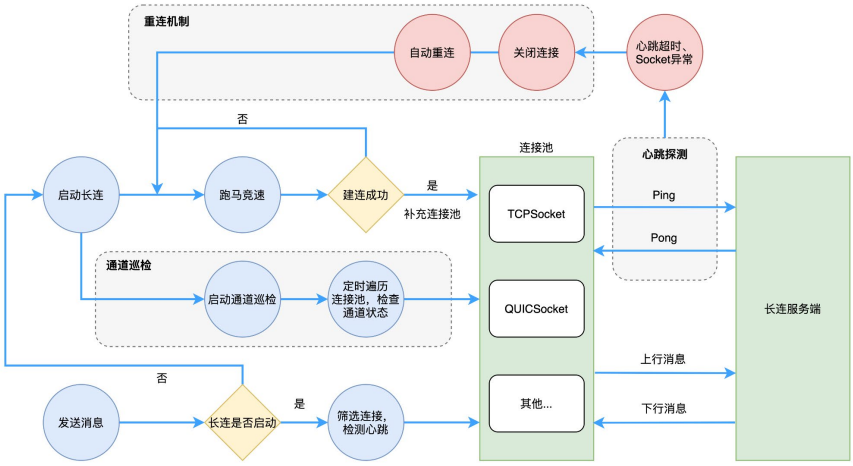

图 8　长连通道保活机制示意图

3.3.1 心跳探测

心跳探测是一种检查网络连接状态的常见手段，Pike 长连接是 TCP 连接，TCP 是虚拟连接，如果实际物理链路中出现诸如异常网络节点等因素导致连接出现异常，客户端和服务端并不能及时感应到连接异常，这时就会出现连接的状态处于 ESTABLISHED 状态，但连接可能已死的现象，心跳探测就是为了解决这种网络异常的技术方案。

客户端在心跳巡检计时器设置的心跳周期到达时判断是否存在上次心跳超时的异常，如果心跳超时则认为该连接已经不可用了，则会从连接池移除该连接并触发下文的重连机制。为了更快地发现通道异常，Pike 2.0 对于心跳周期与心跳超时都是可配置的，针对不同 App 使用的场景可以灵活地设置；而且在每次发送上行数据的时候都会及时检测上次心跳是否超时，使得心跳探测结果不必等到下次心跳周期到达的时刻才知悉。

Pike 2.0 并不是采用固定心跳频率来发送心跳包，Pike 2.0 会利用通道的上下行数据包来动态减少心跳包的发送次数。此外，智能心跳也是 Pike 2.0 持续关注的话题。

3.3.2 重连机制

重连机制是 Pike 2.0 作为长连接通道最核心的特性，也是 Pike 2.0 连接稳定性建设最重要的一环。

客户端会在发送消息、接收消息和心跳探测三个环节来决策是否需要触发重，一方面，如果主动发现连接池中可用连接不足则自动启动重连机制；另一方面，当现有可用连接关闭时也会自动触发重连机制。

Pike 2.0 在重连的过程中会采用斐波那契数列退避算法来发起建连请求直至建连成功，一方面，Pike 2.0 保证只要在网络可用的情况下总能够维持可用的长连接来服务于业务消息；另一方面，Pike 2.0 在网络持续不可用的情况下避免连续建连使得系统满载。

3.3.3 通道巡检

通道巡检是在心跳探测和重连机制的基础上进一步提升 Pike 2.0 稳定性的有效机制。

客户端会根据心跳周期设置一个全局的巡检定时器，在每次定时器设置的时刻到达时，客户端会触发通道异常检测逻辑，一旦发现异常都会尝试重启通道。

Pike 2.0 首先会在触发通道异常检测的时候获取当前通道状态，如果通道当前没有主动关闭但是通道处于不可用的状态，Pike 2.0 会强制执行一次自启动；此外，在通道巡检的过程中，巡检管理器会不断收集消息收发过程中出现的超时异常，当超时异常次数连续累计超过配置的最大阈值时，Pike 2.0 会认为当前通道可用性较低，需要强制关闭并执行一次自启动。

4. Pike 2.0 新增特性

Pike 2.0 作为 Pike 1.0 的升级产品，不只是为了解决 Pike 1.0 的痛点，通过新增特性以开拓新的应用场景也是 Pike 2.0 时刻关注的点。

4.1 聚合消息

随着公司内直播业务的兴起，公司内部也有很多业务方使用 Pike 1.0 作为弹幕、评论、直播间控制信令等下行实时消息的传输通道。但 Pike 1.0 基于早先的设计架构为弹幕、评论这种短时间需要处理海量消息的场景提供可靠服务的能力渐渐力不从心，主要表现在 QPS 大幅增长时，消息投递成功率降低、延时增加和系统性能开销增长等方面。Pike 通过引入聚合消息为直播场景中消息的投递提出更加通用的解决方案。

4.1.1 设计思想

直播场景中涉及的消息主要具备以下特点：

- 弹幕作为一种实时互动的载体，短时间内需处理大量的图片、文本等信息，如果不做聚合会浪费大量的带宽。
- 直播间相比普通推送场景，由于用户已经进入直播间，用户行为也相对统一可控，所以更需要一种群组消息来统一处理。
- 直播间对于不同类型的消息处理逻辑可以区分优先级，比如抽奖、控制信令是要求可靠性不能丢弃，而对于弹幕则可根据直播间热度、服务承受能力适当丢弃。

聚合消息在设计上主要采用下述思想：

- 从时间维度对消息进行聚合，减少不必要的带宽消耗。
- 采用消息分级策略，根据消息的类型设定不同的优先级，保证重要消息的可靠性。
- 抽象出类似直播间的聚合单元，统一管理加入聚合单元的用户行为。
- 采用客户端主动拉取的策略。相比传统的服务端推送策略，主动拉取是利用客户端天然分布式的特点将用户状态保存在客户端，服务端通过减少状态维护进而可以留出更多的资源用于业务处理。
- 提供上行消息能力，提供更完整的消息流通路径。

4.1.2 方案流程

Pike 2.0 针对每个聚合单元都使用环形队列来维护消息列表，发送到该聚合单元的

消息在经过优先级过滤之后都会插入队列 tail 指针标示的位置，随着该聚合单元内消息不断增加最后达到最大队列长度时，head 指针会不断移动来给 tail 指针腾出位置。聚合单元通过控制最大长度的环形队列来避免消息短时间井喷式增长带来的服务性能问题。

客户端在主动拉取的时候都会携带上一次获取到的消息处在环形队列中的偏移量，这样服务就会将偏移量标示的位置到 tail 指针标示的位置之间的消息进行聚合作为本次拉取的结果一次性返回给客户端。不同客户端各自维护自己的偏移量，以此来避免服务端对于客户端的状态维护。

客户端与服务端的具体交互如图所示，客户端在加入聚合单元之后主动拉取，如果本次拉取携带的偏移量能够从服务的环形队列中获取到聚合消息，那么就将消息回调给业务之后马上进行下一次拉取操作。如果本次携带的偏移量已经位于环形队列 tail 指针的位置，那么服务端将不做任何响应，客户端等待本次拉取超时之后开始下一次拉取操作，重复该流程直至客户端离开该聚合单元。与此同时，业务服务端如果有消息需要推送，则通过 RPC 的方式发送给 Pike 服务端，消息处理模块将执行消息分级策略过滤之后的有效消息插入环形队列。

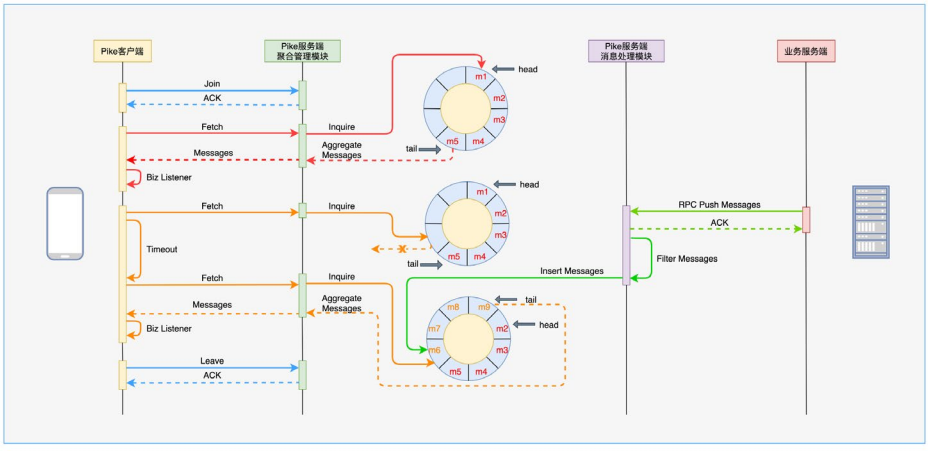

图 9　聚合消息交互流程图

4.2 消息保序

Pike 1.0 在设计之初就只适用于消息推送的场景，而 Pike 2.0 在其基础上演进为双向消息投递服务，即不仅支持下行的消息推送，还支持上行的消息投递。Pike 2.0 在上行的消息投递方面进一步拓展了消息保序的功能，这里的消息保序主要包含两个层面的含义，首先每一个业务客户端发送的消息都最大程度地到达同一个业务服务器，其次这些消息是按照客户端发送的时序一致地到达该业务服务器。

4.2.1 粘性会话

为了使每一个业务客户端发送的消息都最大程度地到达同一个业务服务器，Pike 2.0 引入了粘性会话的概念。粘性会话指的是同一客户端连接上的消息固定转发至某一特定的业务方机器处理，客户端断连重连后，保持新连接上的消息仍转发至该业务机器。

粘性会话可以归纳为如下的流程。首次业务登录的时候 Pike 2.0 服务器会利用负载均衡算法选择一台业务服务器，并将该业务服务器的路由标识通过业务登录结果通知客户端并保存，之后如果通道状态稳定的话所有的上行消息就都会投递到该业务服务器。如果期间通道状态波动出现断连的情况，Pike 2.0 在发起重连之后会重新进行业务登录，这一次业务登录会将之前保存的路由标识重新上报给 Pike 2.0 服务器，这样 Pike 2.0 服务器就会通过路由标识重新绑定该业务服务器。当然，如果路由标识指示的业务服务器已经停止提供服务，那么 Pike 2.0 服务器会重新通过负载均衡算法选择新的一台业务服务器，同时客户端会获取到新的路由标识，之后的逻辑重复该过程直至 Pike 2.0 客户端退出。

4.2.2 时序一致性

我们都知道 TCP 是有序的，那么在同一个 TCP 连接的前提下什么情况会出现客户端发送的消息乱序到达业务服务器呢？原因就是 Pike 2.0 服务器从 TCP 中读出消息之后将其投递给业务服务器是通过 RPC 异步调用的。

为了解决这种问题，最简单的方案当然是客户端将消息队列的发送窗口限定为 1，每

一条发送消息都在 Pike 2.0 服务器投递给业务服务器之后才能收到 ACK，这时再发送下一条消息。但是考虑到网络传输在链路上的时延远远大于端上处理的时延，所以该方案的 QPS 被网络传输设了瓶颈，假设一个 RTT 是 200ms，那么该方案理论也只能达到 5 的 QPS。

Pike 2.0 为了提高上行消息保序投递的 QPS，采用服务端设置消息队列缓存的方案。如图所示，客户端可以在发送窗口允许的范围内一次性将多条消息发送出去，服务端把收到的消息都按顺序缓存在消息队列中，然后串行的通过 RPC 调用将这些缓存的消息依序投递给业务服务器。这种保序方案将 QPS 性能的瓶颈点从之前网络传输在链路上的时延转移到了 RPC 调用的时延上，而实际场景中一次 RPC 调用往往在几个毫秒之间，远远小于网络传输在链路上的时延，继而显著地提升了 QPS。

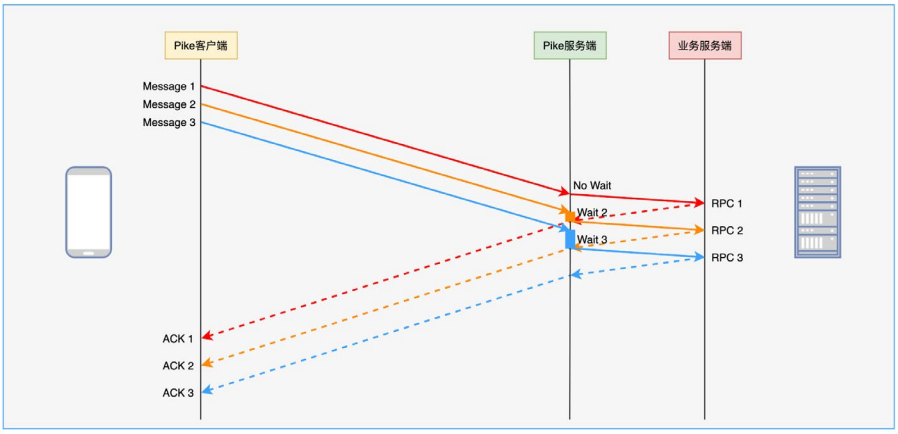

图 10　时序一致性示意图

5. Pike 2.0 稳定性保障

5.1 Pike 2.0 监控体系

Pike 2.0 依赖美团监控平台 Raptor 完成监控体系建设，服务端和客户端都建设了各自完善的指标监控。Pike 2.0 客户端通过利用 Raptor 的端到端指标能力和自定义指标能力输出了超过 10+ 个监控指标来实时监控 Pike 系统，这些指标覆盖通道建立、

消息投递、业务登录、系统异常等多维度。在实时指标监控的基础上 Pike 2.0 针对不同指标配置了报警阈值，以推送消息为例，如果特定 App 的大盘数据在每分钟的上下波动幅度超过 10%，那么 Raptor 系统就会向 Pike 项目组成员推送告警信息。

基于所有 Raptor 监控指标，Pike 2.0 提炼核心 SLA 指标如下：

指标名称	指标定义	指标意义
上行消息投递成功率	上行消息从发送到收到 ACK 的成功率	代表 Pike 2.0 业务上行消息投递能力
上行消息投递延时	上行消息投递 RTT	同上
下行消息投递成功率	下行消息从发送到收到 ACK 的成功率	代表 Pike 2.0 业务下行消息投递能力
下行消息投递延时	下行消息投递 RTT	同上
通道可用耗时	通道从建立到可以传递消息的时间	代表 Pike 2.0 通道建连能力
日均消息量	日均投递的上下行消息总量	代表 Pike 2.0 产品服务能力

Pike 2.0 会定期输出基于核心 SLA 指标的大盘数据报表，同时可以基于 App、业务类型、网络类型等多维度对数据进行筛选以满足不同用户对于指标数据的需求。

5.2 Pike 2.0 个案用户追踪

监控体系能从全局的角度反映 Pike 2.0 系统稳定性，针对个案用户，Pike 管理平台提供完整的链路追踪信息。

每个 Pike 2.0 连接都由唯一标识 Token 来区分，通过该唯一标识 Token 在 Pike 管理平台的“连接嗅探”模块主动探测便能获得对应连接上所有信令的交互流程。如图所示，流程中明确标注了客户端建立连接、发起鉴权、绑定别名等信令，点击对应信令可以跳转信令详情进一步查看该信令所携带的信息，再结合 SDK 埋点在美团日志服务 Logan 的离线日志就可以快速发现并定位问题。

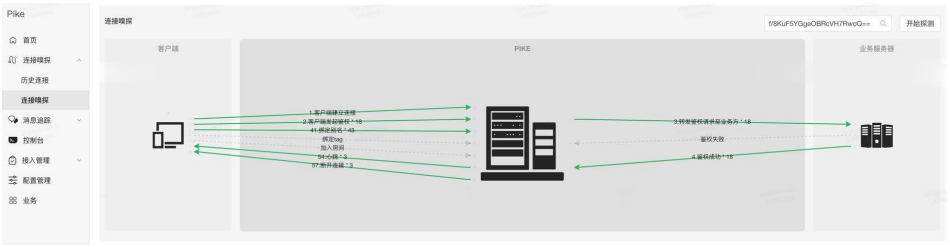

图 11　个案用户追踪信令交互图

6. Pike 2.0 建设成果

截至 2021 年 6 月，Pike 共接入业务 200+ 个，日均消息总量约 50 亿 +，Pike 2.0 消息到达率 >99.5%（相比 Pike 1.0 提升 0.4% ），Pike 2.0 平均端到端延时 <220ms（相比 Pike 1.0 减少约 37%）。

部分应用案例：

- 直播场景消息服务方案。支持直播业务的直播互动功能，具备了支持同时在线百万级别大型直播的能力。
- 消息推送、Feed 流预加载等实时触达方案。支持营销类、控制类等业务消息实时推送，业务消息到达率最高提升 10%，长连通道建联耗时减少 5%。
- IoT 设备接入方案。支持取餐柜业务 IoT 接入能力，帮助业务消息到达率从 98.4% 提升到 99.6%。
- 小游戏场景消息投递方案。支持美团小游戏场景通信能力，消息到达率达到 99.8% 以上，上行延时低至 195ms。

7. 总结与未来展望

Pike 在美团应用广泛，目前主要集中在实时触达、互动直播、移动同步等业务场景，随着公司业务的快速发展，Pike 对可用性、易用性、可扩展性提出了更高要求，希望提升各种业务场景下的网络体验，因此 Pike 未来的规划重点主要是：提供多端、多场景下的网络通信方案，不断完善协议生态，在各种应用场景下对抗复杂网络。

- **拓展 Pike 通用基础能力，提升通道性能**。通过优化保序方案，提供专用通道，

优化传输协议等方式，进一步提升吞吐量和稳定性，降低推送时延。

- **建设 Pike IoT，提供 IoT 接入层方案**。为公司内物联网应用场景（单车、充电宝、取餐柜、智能头盔、仓库、门店设备等）提供统一的 IoT 接入层解决方案，支持多种接入协议（HTTP、MQTT、CoAP 等），为业务提供安全可靠的设备连接通信能力。
- **优化弱网环境通信体验**。在移动端和 IoT 端基于美团自研 MQUIC 网络协议库，探索 Pike over QUIC，在桌面端探索 WebTransport 技术，通过全面支持 QUIC 协议，提升弱网大包场景下的网络性能，降低长尾分布的请求耗时。

作者简介

健午、佳猛、陆凯、冯江等，均来自美团基础技术部 – 前端技术中心。

招聘信息

美团基础技术部 – 前端技术中心诚招高级、资深技术专家，Base 上海、北京。我们致力于为美团海量业务建设高性能、高可用、高体验的前端基础技术服务，涵盖网络通信、资源托管、设计体系、研发协同、低代码、性能监控、运维保障、Node 基建、IoT 基础设施等技术领域，欢迎有兴趣的同学投送简历至：edp.itu.zhaopin@meituan.com。

新一代 CTR 预测服务的 GPU 优化实践

作者：伟龙　小卓　文魁　駃飞　小新

1. 背景

CTR（Click-Through-Rate）即点击通过率，是指网络广告的点击到达率，即该广告的实际点击次数除以广告的展现量。为 CTR 指标服务的打分模型，一般称为 CTR 模型。我们可以将此概念进一步扩展到互联网应用中各种预估转化率的模型。CTR 模型在推荐、搜索、广告等场景被广泛应用。相对于 CV（计算机视觉）、NLP（自然语音处理）场景的模型，CTR 模型的历史结构比较简单，计算量较小。美团的 CTR 模型一直沿用 CPU 推理的方式。随着近几年深度神经网络的引入，CTR 模型结构逐渐趋于复杂，计算量也越来越大，CPU 开始不能满足模型对于算力的需求。

而 GPU 拥有几千个计算核心，可以在单机内提供密集的并行计算能力，在 CV、NLP 等领域展示了强大的能力。通过 CUDA[1] 及相关 API，英伟达建立了完整的 GPU 生态。基于此，美团基础研发平台通过一套方案将 CTR 模型部署到 GPU 上。单从模型预测阶段看，我们提供的基于英伟达 T4 的 GPU 深度优化方案，在相同成本约束下，对比 CPU，提升了 10 倍的吞吐能力。同时，在典型的搜索精排场景中，从端到端的维度来看，整体吞吐能力提升了一倍以上。

除了提高吞吐、降低成本外，GPU 方案还为 CTR 模型的应用带来了额外的可能。例如，在某搜索框自动补全的场景，由于天然的交互属性，时延要求非常苛刻，一般来说无法使用复杂的模型。而在 GPU 能力的加持下，某复杂模型的平均响应时间从 15 毫秒降低至 6~7 毫秒，已经达到了上线要求。

接下来，本文将与大家探讨美团机器学习平台提供的新一代 CTR 预测服务的 GPU 优化思路、效果、优势与不足，希望对从事相关工作的同学有所帮助或者启发。

2. CTR 模型 GPU 推理的挑战

2.1 应用层的挑战

- CTR 模型结构多变，包含大量业务相关的结构，同时新的 SOTA 模型也层出不穷，硬件供应商由于人力受限，会重点优化常用的经典结构，如 ResNet。对于没有收敛的结构，官方没有端到端的优化工具可以支持。
- CTR 模型中通常包含较大的 Embedding 表结构，要考虑到 Embedding 表存在显存放不下的情况。
- 在典型的推荐场景中，为了达到更快的 POI 曝光的目的，模型的时效性要求很高，在线模型服务需要提供增量更新模型的能力。

2.2 框架层的挑战

- **算子层面**：目前主流的深度学习框架，如 TensorFlow 和 PyTorch，可以说是深度学习第二代框架，它们首先要解决第一代框架 Caffe 的问题，Caffe 有一个明显问题就是 Layer 的粒度过粗，导致那个时代的算法开发者都必须有“自己写自定义层”的能力。TensorFlow 和 PyTorch 都把模型表达能力放在较高的优先级，导致算子粒度比较小，无论是对 CPU 还是 GPU 架构，都会带来很大的额外开销。
- **框架层面**：TensorFlow 和 PyTorch 本质都是训练框架，对算法开发者比较友好，但非部署友好。其中隐含了很多为了方便分布式训练做的设计，比如 TensorFlow 为了方便将 Variable 拆到不同的 PS 上，内置了 Partitioned_Variable 的设计。在基于 GPU 单机预测的场景下，这些结构也会带来额外的开销。

2.3 硬件层的挑战

第一，TensorFlow 的算子粒度划分较细，导致一个模型通常由几千个算子构成，这些算子在 GPU 上的执行转变为对应的 GPU kernel 的执行。kernel 是 GPU 上并行执行的函数。

GPU kernel 大体上可以划分为传输数据、kernel 启动、kernel 计算等几个阶段，其中每个 kernel 的启动需要约 10μs 左右。大量的小算子导致每个 kernel 的执行时间很短，kernel 启动的耗时占了大部分。相邻的 kernel 之间需要通过读写显存进行数据的传输，产生大量的访存开销。而 GPU 的访存吞吐远远低于计算吞吐，导致性能低下，GPU 利用率并不高。

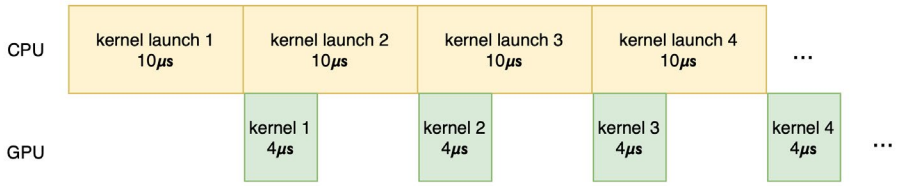

第二，GPU 卡上包含多个计算单元，理论上，不同计算单元是可以跑不同 kernel 的，但实际上为了编程简单，CUDA 默认假设在同一时刻一个 Stream 里跑同一个 kernel。虽然可以通过多 Stream 的方式跑，但是多 Steam 之间又缺少细粒度的协同机制。

在经过充分调研与讨论后，我们决定第一期重点关注 TensorFlow 框架下如何解决常见 CTR 模型结构在英伟达 GPU 上执行效率不高的问题，我们先将问题收敛为以下两个子问题：1. 算子粒度过细，GPU 执行效率低下。 2. 模型结构多变，手工优化投入大，通用性差。

3. 优化手段

为了解决上面的问题，我们对业界深度学习加速器进行了一些调研。业界比较成熟的推理优化方案主要是 TensorRT/XLA/TVM。TensorRT 采用手工优化，对一些定制的模型结构进行算子融合，并对计算密集型算子（如卷积）进行了高效调优。XLA 是 TensorFlow 内置的编译优化工具，主要针对访存密集型结构，通过编译手段，实现算子的融合。TVM[2] 具备较全面的优化能力，使用编译手段进行算子的融合，同时可以通过机器学习的方式实现计算密集型算子的自动调优。

经过广泛的调研和对比，我们最终选择了 TVM 作为优化工具。TVM 通过编译手段，

可以较好地应对多变的模型结构，解决了手工优化通用性差的问题。但 TVM 应用在业务模型也存在一系列问题：支持的算子数较少，而且目前对动态 Shape 的支持还不够好。针对这两个问题，我们将 TVM 和 TensorFlow 结合起来，结合 CTR 模型的结构特点与 GPU 的硬件特性，开发一系列流程，实现了对 CTR 模型的优化。

3.1 算子融合

通过将多个小算子融合为一个语义等价的大算子，可以有效减少 GPU 上的 kernel 数量。一方面，kernel 数量减少直接降低了 kernel 发射的开销；另一方面，融合后的大 kernel 执行的计算量增加，避免了多个 kernel 间数据传输导致的频繁访存，提高了计算的访存比。

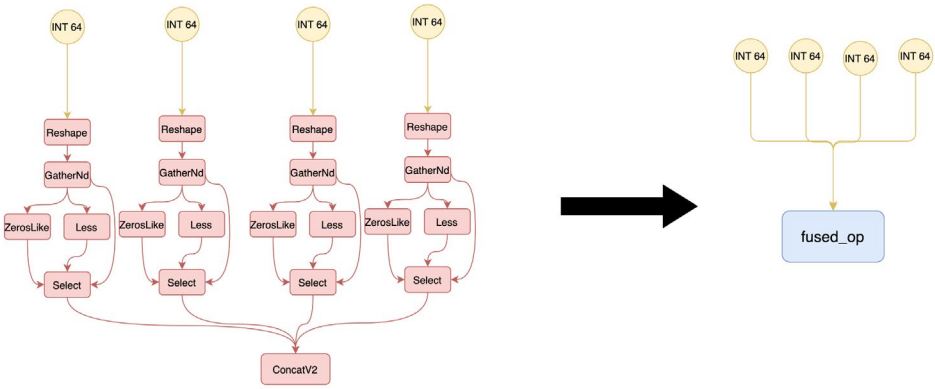

可以看到，上图中的左右等价结构，左侧的 21 个算子执行的运算，可以在 1 个等价算子中完成。反映到 GPU 的活动上，左侧至少有 21 个 GPU kernel 以及 21 次显存的读写，而右侧只需要执行 1 个 kernel 以及 1 次显存读写。对于每个融合后的算子，需要有对应的 kernel 实现。然而，模型的算子组合是无穷的，对每种融合后算子手工实现 kernel 是不现实的。TVM 通过编译手段，可以自动进行算子的融合以及设备代码生成，避免了逐一手写 kernel 的负担。

3.1.1 TF-TVM 自动切图优化

TensorFlow 模型中，如果包含 TVM 不支持的算子，会导致无法执行 TVM 转换。

我们的思路是将可以用 TVM 优化的部分切出来，转为 TVM 的 engine，其他部分依然使用 TensorFlow 的算子。在 XLA 和 TRT 转换的时候也有类似问题，我们分析了 TF-XLA 和 TF-TRT 二者的实现：

- TF-XLA 的实现方案，在 Grappler[4] 优化图之后，有一个 POST_REWRITE_FOR_EXEC（通过这个关键字可以在源码中搜索到）阶段，在这个阶段，会执行三个针对 Graph 的 Pass，分别是用来标记算子，封装子图，改写子图并构建 LaunchOp。
- TF-TRT 的实现方案，TF-TRT 在 Grappler 中注册了一个优化器，在这个优化器中，找到连通子图，并将其替换为 TRT Engine。

在最终方案实现上，我们参考了 TF-TRT 的设计。这个设计对比 XLA 的优势在于 XLA 切图方案与 TensorFlow 源码紧耦合，直接将 XLA 的三个 Pass 嵌入到了启动 Session 的主流程中。而切图策略，优化策略后续会有非常频繁的迭代，我们不希望与 TensorFlow 的源码太过耦合。我们扩展了 TF-TVM 的方案，在实际使用中我们把这个切图过程为一个独立流程。在模型部署或更新时，自动触发。

在推理阶段，优化过的子图使用 TVM 执行，其余的计算图使用 TensorFlow 原生实现执行，将两者结合共同完成模型的推理。由于 TVM 和 TensorFlow 的 Runtime 各自使用独立的内存管理，数据在不同框架间传输会导致额外的性能开销。为了降低这部分开销，我们打通了两个框架的底层数据结构，尽可能避免额外的数据拷贝。

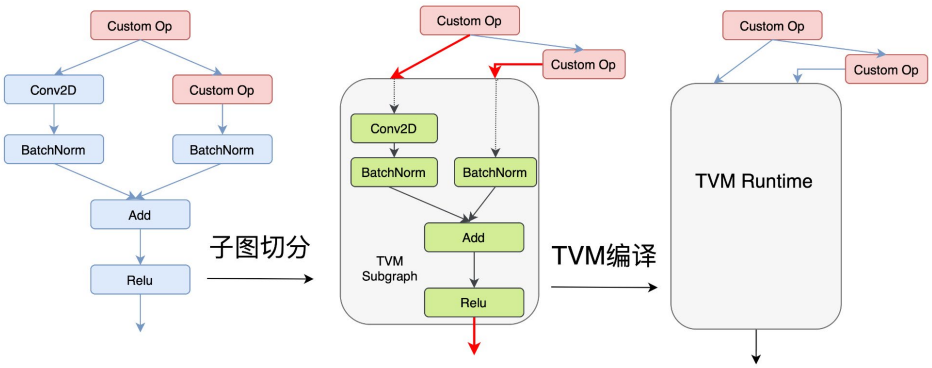

3.1.2 计算图等价替换

TensorFlow 模型中过多的不被 TVM 支持的算子会导致 TF-TVM 切图零碎，影响最终的优化效果。为了让 TF-TVM 切图尽量大且完整，以及让 TVM 优化过程中的融合力度更大，我们对模型中的一些复杂结构进行检测，替换为执行更高效或更易于融合的等价结构。

例如，TensorFlow 原生 EmbeddingLookup 结构，为了支持分布式训练，会对 Embedding 表进行切分，产生 DynamicPartition 和 ParallelDynamicStitch 等动态算子。这些动态算子不被 TVM 支持，导致 TF-TVM 图切分过于细碎。为了让 TF-TVM 切图更完整，我们通过图替换，对这种结构进行修改，通过将 Embedding 分表提前合并，得到简化的 EmbeddingLookup 结构。

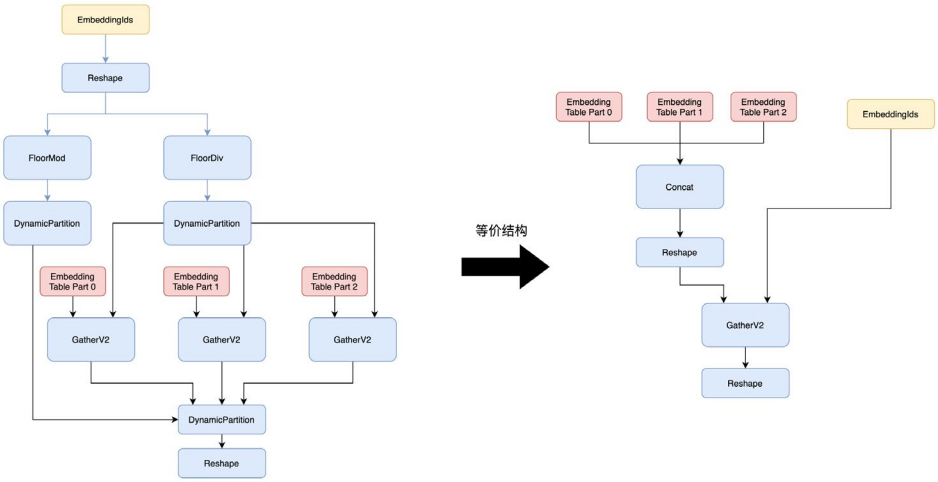

3.2 CPU-GPU 数据传输优化

TVM 优化后的子图被替换为一个节点，该节点在 GPU 上执行，通常有几十甚至几百个输入，该节点的前置输入（如 Placeholder）通常是在 CPU 上执行，会涉及多次的 CPU-GPU 传输。频繁的小数据量传输，无法充分利用带宽。为了解决这个问题，我们对模型结构进行修改，在计算图中添加合并与拆分节点，控制切图的位置，减少数据传输的次数。

一种可能的合并方式是，对这些输入按相同的 Shape 和 Dtype 进行合并，后续进行拆分，将拆分节点切入 TVM 的子图一起优化。这种方式会导致一些问题，如部分子图的算子融合效果不佳；另一方面，GPU kernel 函数的参数传递内存限制在 4KB，对于 TVM 节点输入非常多的情况（如超过 512 个），会遇到生成代码不合法的情况。

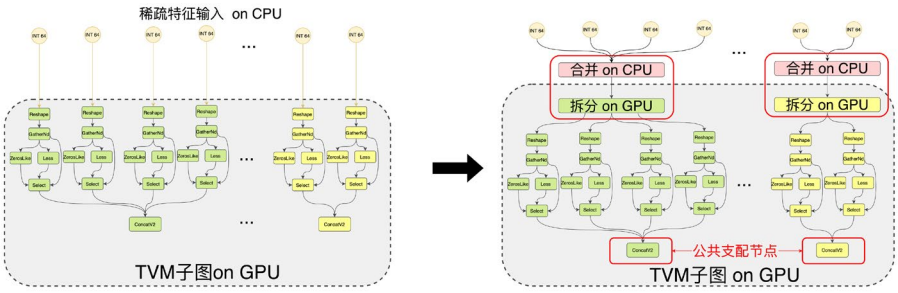

3.3 高频子图手工优化

对于 TVM 无法支持的子图，我们对业务中高频使用的结构进行抽象，采用手写自定义算子的方式，进行了高效 GPU 实现。

例如，模型中有部分时序特征使用 String 类型输入，将输入的字符串转为补齐的数字 Tensor，将 int 类型的 Tensor 作为下标进行 Embedding 操作。这部分子图的语义如图，以下简称 SE 结构（StringEmbedding）：

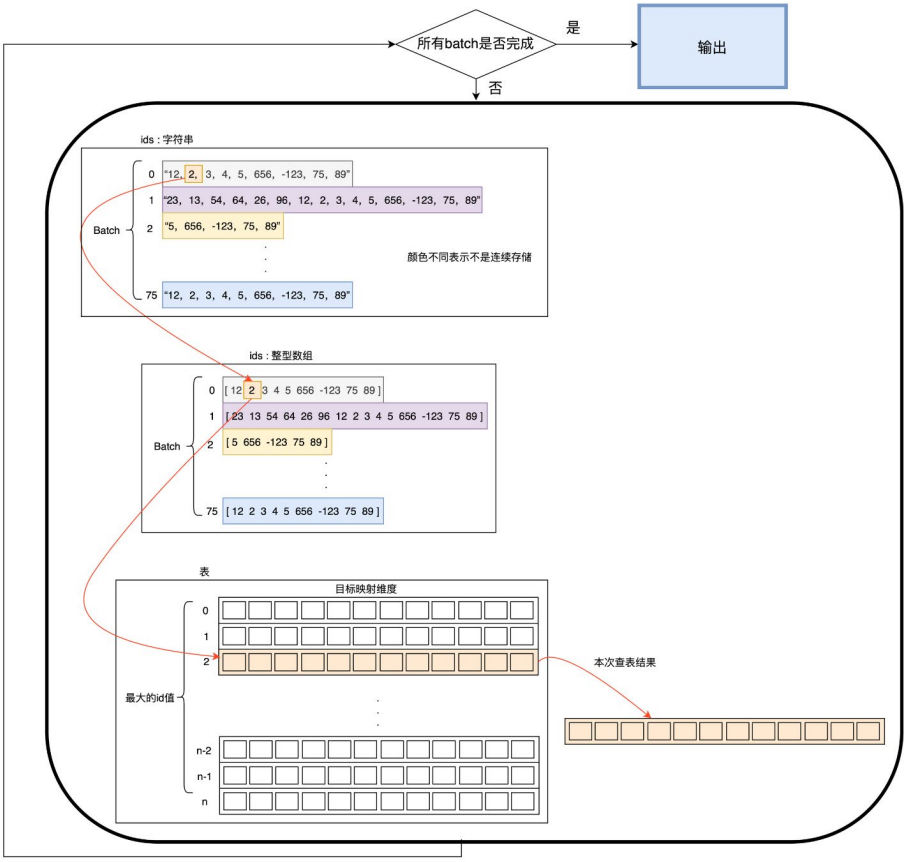

这一部分结构，TensorFlow 的原生实现只有基于 CPU 的版本，在数据量较大且并行度较高的情景下，性能下降严重，成为整个模型的瓶颈。为了优化这部分结构的性能，我们在 GPU 上实现了高效的等价操作。

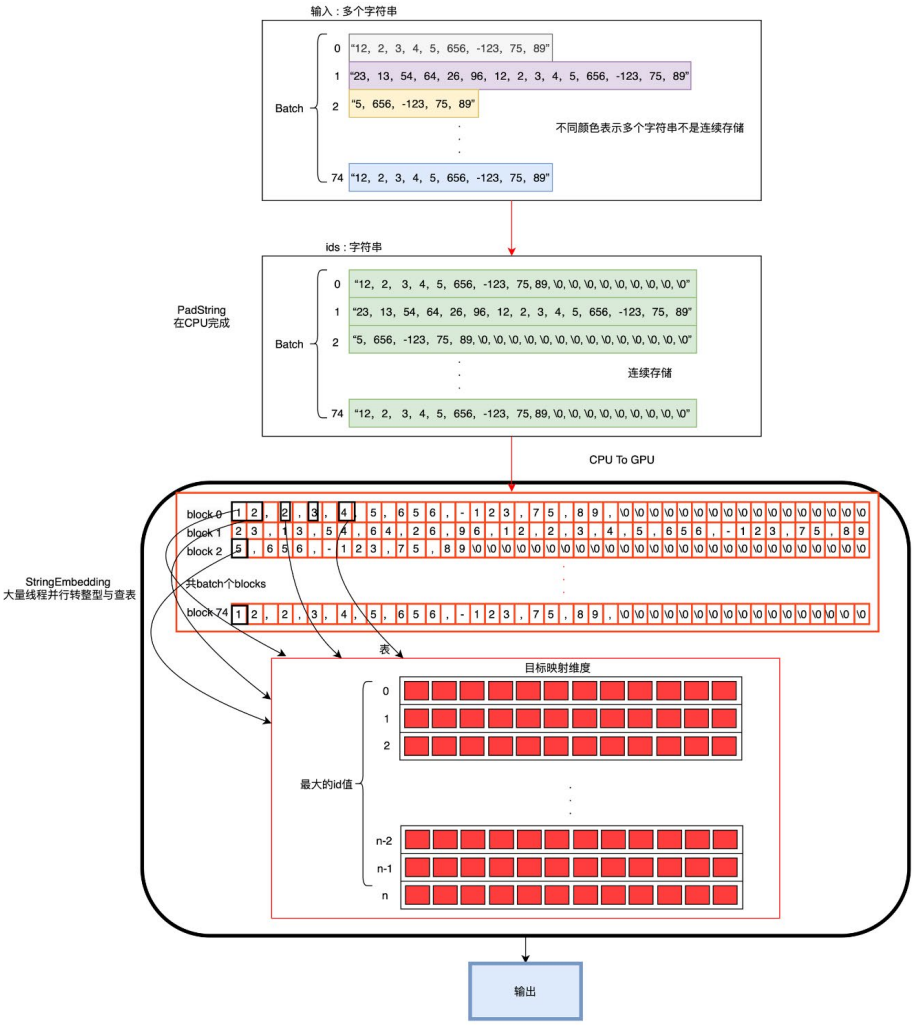

如图所示，PadString 算子在 CPU 端将多个字符串按最大长度进行补齐，拼接成一个内存连续的 uint8 类型 Tensor，以便一次性传输到 GPU。StringEmbedding 接收到补齐后的字符串后，利用 GPU 并行计算的特性，协同大量线程完成字符串的切分与查表操作。在涉及规约求和、求前缀和等关键过程中，使用了 GPU 上的 Reduce/Scan 算法，编码过程使用 `warp_shuffle` 指令，不同线程通过寄存器交换数据，避免了频繁访存的开销，获得了很好的性能。

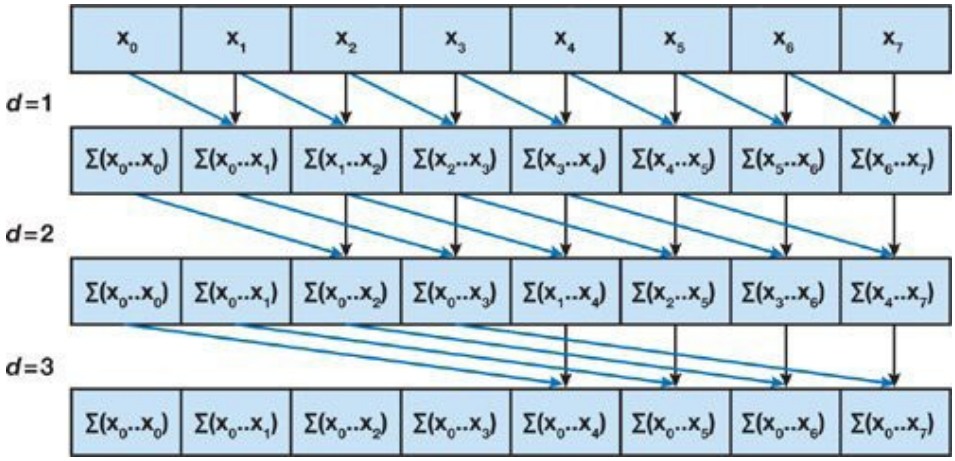

GPU Scan 算法示意，一个 8 个元素的前缀和操作，只需要 3 个迭代周期。在一个有几十路类似操作的模型中，手工优化前后的 GPU timeline 对比如下图，可以看到 H2D + StringEmbedding 这部分结构的耗时有很大的缩减，从 42 毫秒缩减到 1.83 毫秒。

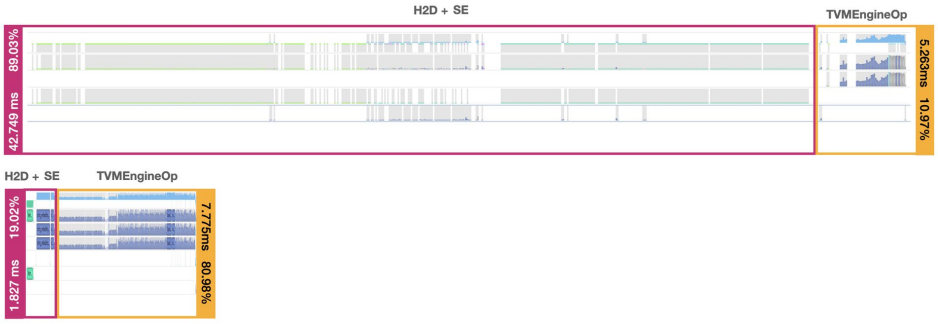

除了 StringEmbedding 结构，我们对 StringSplit + ToNumber + SparseSegmentSqrt、多路并行 StringEmbedding 等结构都进行了高效融合实现，在优化流程中通过结构匹配进行相应的替换。

3.4 CPU-GPU 分流

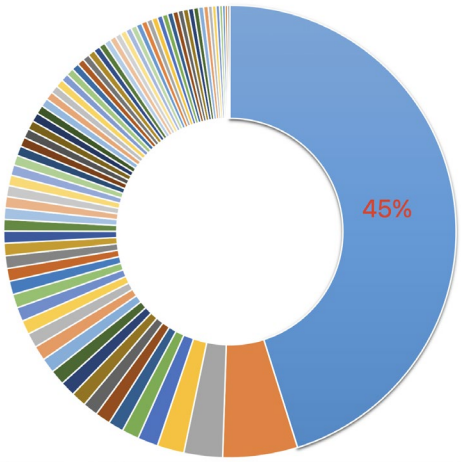

实际线上的 RPC 请求，每个请求内的样本数（下文称 Batch）是在 [1,MaxValue] 范围内变化的，MaxValue 受上游业务系统，其他基础系统能力等多方面因素制约，相对固定。如上图所示，以某个搜索服务为例，我们统计了线上的 Batch 数值分布，Batch=MaxValue 的请求占比约 45%，Batch=45 占比 7.4%，Batch=1 占比 2.3%。其余的 Batch 占比从 0.5% 到 1% 不等。对于 GPU 来说，提高单个请求的 Batch 能更好地利用硬件资源，发挥 GPU 的并行计算能力，表现出相对 CPU 更优的延迟和吞吐；当 Batch 较小时，GPU 相对 CPU 的优势就不明显了（下图是我们测试同样的模型在固定压力下，CPU/GPU 上延迟的变化）。

大部分请求都由 GPU 在做了，CPU 资源有较多空余，我们将一些小 Batch 的碎请求放在 CPU 运行，这样可以让整个 Worker 的资源利用更加均衡，提高系统整体的性能。我们根据测试设定了一个 Batch 阈值，以及计算图在异构硬件上区别执行的判断逻辑：对于小 Batch 的情况，直接在 CPU 上执行计算图，只有 Batch 超过阈值的请求才会在 GPU 上推理。从线上的统计数据来看，整体流量的 77% 跑在 GPU 上，23% 跑在 CPU 上。

在 GPU 的一系列优化策略和动作中，Batch 大小是很重要的信息，不同 Batch 下优化出的 kernel 实现可能是不同的，以达到对应 workload 下最优的计算性能；由于线

上的流量特点，发送到 GPU 的请求 Batch 分布比较细碎，如果我们针对每个 Batch 都优化一个模型的 kernel 实现显然是不够经济和通用的。因此，我们设计了一个 Batch 分桶策略，生成 N 个固定 Batch 的优化模型，在实际请求到来时找到 Batch 距离最近的一个 Bucket，将请求向上 Padding 到对应的 Batch 计算，从而提高了 GPU 的利用效率。

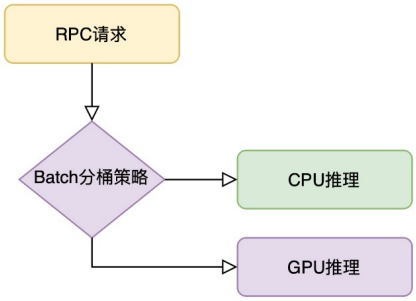

4. 压测性能分析

我们选取一个模型进行线上性能压测分析。

- CPU 模型测试环境为 16 核 Intel® Xeon® Gold 5218 CPU @ 2.30GHz，16G 内存。
- GPU 模型测试环境为 8 核 Intel® Xeon® Gold 5218 CPU @ 2.30GHz，Tesla T4 GPU，16G 内存。

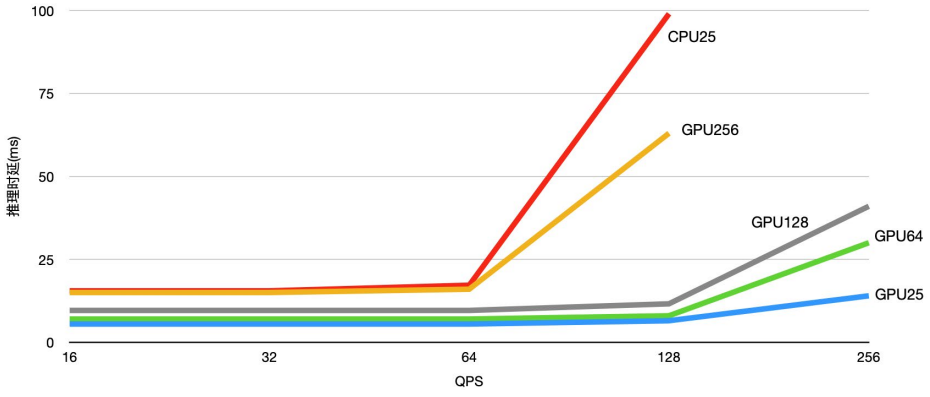

下图对比了在不同的 QPS 下（x 轴），GPU 模型在各 BatchSize 下的推理时延（y 轴）。GPU 模型在 BatchSize=128 以下，推理耗时差异不明显，较大的 BatchSize 更有利于吞吐；对比 BatchSize=256 的 GPU 模型与 BatchSize 为 25 的 CPU 模型，在 QPS 低于 64 的情况下，二者推理耗时基本持平；QPS 超过 64 的情况下，GPU 的推理时延低于 CPU。GPU 的吞吐相比 CPU 提升了 10 倍。

同时，我们可以看到不同曲线的陡峭程度，CPU 在 QPS 高出 64 后，时延会迅速上升，GPU 则依然保持平稳，直到 QPS 超过 128 才会有明显上升，但仍旧比 CPU 更平稳。

5. 整体架构

针对 CTR 模型的结构特点，我们抽象出了一套平台化的通用优化流程。通过对模型结构的分析，自动应用合适的优化策略，通过性能评估和一致性校验，保证模型的优化效果。

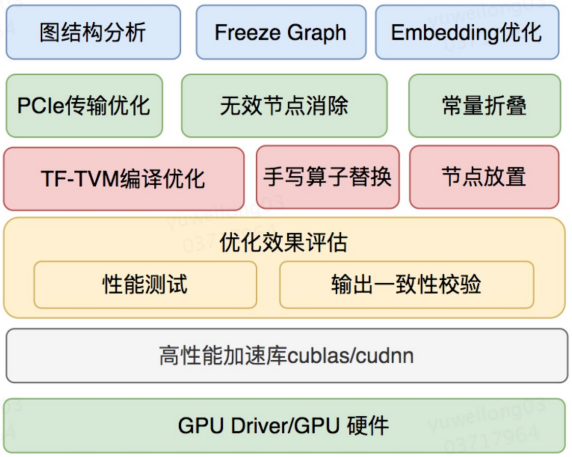

6. 不足之处与未来规划

在易用性层面，目前的方案形式是提供了一套在线优化脚本，用户提交模型后，自动优化部署。由于涉及对计算图结构的分析、编辑以及 TVM 的编译等过程，目前的模

型优化耗时较长，大部分模型优化耗时在 20 分钟左右。后续需要考虑加速 TVM 编译的效率。

在通用性层面，从我们的实际应用情况来看，TVM 编译优化和高性能手写算子是最主要的收益来源。手工优化很考验开发同学对业务模型的理解和 GPU 编程的能力。编写一个高性能的融合算子已经不太容易，要做到有一定的迁移能力和扩展性则更有难度。

总的来说，CTR 模型推理在 GPU 上未来需要考虑的问题还有很多。除了要基于业务理解提供更好的性能外，还要考虑模型规模巨大后无法完整放入显存的问题以及支持在线模型更新的问题。

作者简介

伟龙、小卓、文魁、驶飞、小新等，均来自美团基础研发平台 – 机器学习预测引擎组。

参考资料

[1] CUDA C++ Programming Guide
[2] TVM Documentation
[3] Accelerating Inference In TF-TRT User Guide
[4] TensorFlow graph optimization with Grappler

招聘信息

美团机器学习平台大量岗位持续招聘中，实习、社招均可，坐标北京 / 上海，欢迎感兴趣的同学加入我们，构建多领域公司级机器学习平台，帮大家吃得更好，生活更好。简历可投递至：wangxin66@meituan.com。

美团弹性伸缩系统的技术演进与落地实践

作者：tuyang

弹性伸缩具有应突发、省成本、自动化的业务价值。平台侧将各业务零散、闲置资源进行整合，形成一个大规模资源池，通过弹性调度、库存管控技术在公司运营成本和业务体感中寻求较好的平衡。

本文将介绍美团弹性伸缩系统落地过程中面临的技术挑战、推广以及在运营层面的一些思考。在美团这种多样化的业务场景中落地弹性伸缩，与业界公有云、自建私有云的公司相比，既有共性又有自己的特点，希望能为大家提供新的思路或者启发。

前言

稳定、高效、可靠的基础设施是互联网企业应对业务高峰流量的底层基石。作为美团统一的基础技术平台，基础技术部一直致力于通过业内前沿技术的落地，保障公司内部所有业务在线生产系统所依赖的基础技术平台能稳定、安全、低成本、可持续地运行与发展。

弹性伸缩系统是基于 Docker 开发的自动弹性伸缩平台，在美团经历了多年的发展。

早在 2016 年，美团就在线上环境中尝试使用容器环境，推出了基于 OpenStack 的**容器集群平台 Hulk 1.0**。随着容器的落地，弹性伸缩 1.0 版本应运而生，它解决了扩容实例慢、扩容上线慢、资源回收慢、计算资源冗余等问题。

结合前两年的探索和实践以及业界相关领域技术的成熟度，2018 年至今，我们对容器集群平台进行了一次自底向上的的整体升级，也就是现在的 **Hulk 2.0 平台**。在底层，Hulk 2.0 建设了自研的操作系统、容器引擎，并将 OpenStack 替换成了容器编排的事实标准 Kubernetes；在上层弹性伸缩系统 PaaS 层面，推出了弹性伸缩系统 2.0，解决了弹性伸缩 1.0 实践过程中面临的很多业务痛点，包括：

- **扩出的业务代码版本不一致**：导致业务逻辑异常，造成资损。
- **部分服务高峰期资源不足**：导致业务无法有效承载流量，引起资损，
- **平台维护成本高**：北京、上海的业务各自一套弹性伸缩用户端管理平台、弹性逻辑（因为美团、大众点评合并前期，服务治理框架、CMDB 系统、发布系统尚未标准化）。
- **配置使用灵活性低**：业务集群每增 / 减一个 IDC 均需在平台做相匹配的配置操作，在资源的调控上无法和公司的流量调度体系包括单元化架构、同地域、同中心调用有效地进行匹配。

一、弹性伸缩系统演进

弹性伸缩 1.0 架构

我们首先看一下，产品演进路线和弹性伸缩 1.0 架构图。

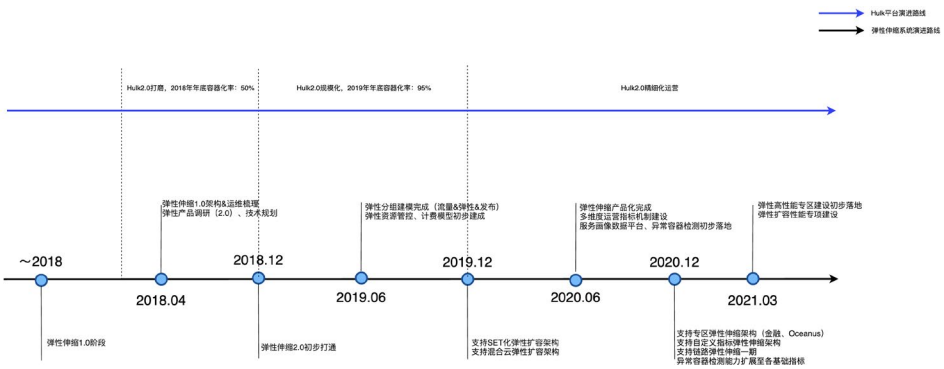

产品演进路线

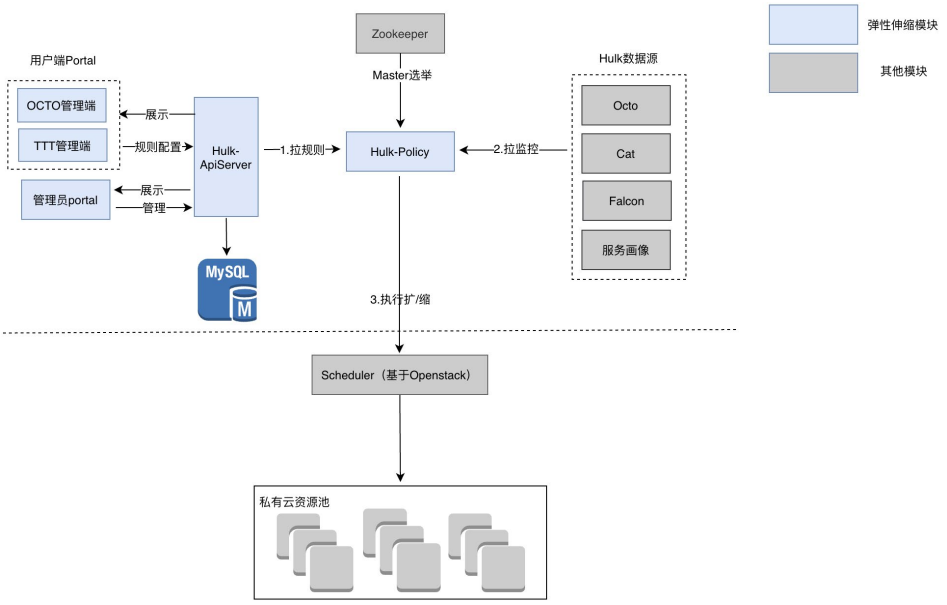

弹性伸缩 1.0 架构

自左向右、自上而下进行模块介绍：

- **用户端 Portal**：OCTO 管理端，OCTO 是美团服务治理平台，出于北京业务操作服务节点习惯的考虑，在其上开发了对应的弹性伸缩管理页面；TTT 管理端，TTT 是上海侧（原大众点评侧）的 CMDB 管理平台，出于上海侧业务操作服务节点习惯的考虑，在其上开发了对应的弹性伸缩管理页面。
- **Hulk-ApiServer**：Hulk 1.0 容器平台的网关服务。
- **Hulk-Policy**：弹性伸缩系统 1.0 的业务逻辑模块，其中涵盖了具体的指标聚合、扩缩容逻辑、策略等，主从架构模式，使用 Zookeeper 进行 Master 选举，从是冷备。
- **Hulk 数据源**：OCTO，美团服务治理平台；CAT，美团服务端、移动端监控平台，主要负责应用层面；Falcon，基于开源 Falcon 定制化的系统监控平台，主要负责机器层面。
- **Scheduler**：Hulk 1.0 容器平台的调度系统，基于 OpenStack 做了二次开发。

弹性伸缩 2.0 架构

弹性伸缩系统 2.0 主要在以下四个方面进行了架构演进：

1）调度系统 – 替换：将 OpenStack 替换成了容器编排的事实标准 Kubernetes，并且在常驻资源池的基础上，新托管了专区资源池以及应急资源池。 2）**单体服务 – 微服务化**。 a. API-Server：弹性伸缩 – 网关服务。 b. Engine：弹性伸缩 – 引擎，负责各服务实例扩缩的发起、终止，主从架构模式，使用 Zookeeper 进行 Master 选举，从是热备。 c. Metrics-Server、Metrics-Data：【新增】弹性伸缩指标服务，负责 Raptor、OCTO 等数据源的采集 & 聚合。 d. Resource-Server：【新增】弹性伸缩 – 库存管控服务，为各服务自动扩缩的资源需求保驾护航。 3）**服务画像 – 数据平台化**：Portrait-Server、Portrait-Data，弹性伸缩系统内部自建的服务画像数据体系。 4）**可观测性**：【新增】Alarm、Scanner，负责弹性伸缩的监控告警、运营治理等工作。

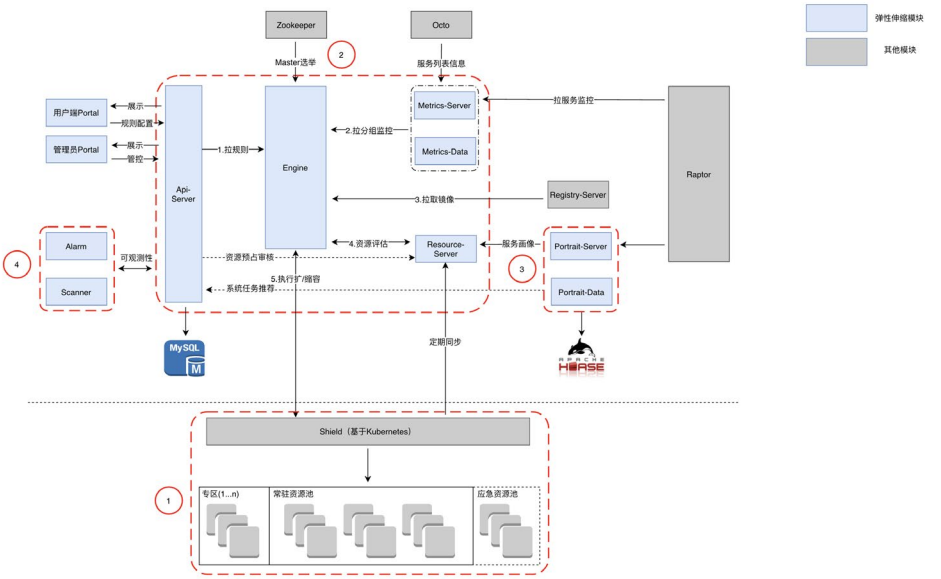

弹性伸缩 2.0 架构

二、挑战与应对之策

在介绍前，有必要重点说明下 2018 年这个时间节点。如前言中所述，2018 年以前弹性伸缩 1.0 这个 PaaS 平台存在的一些问题，以及整体 Hulk 1.0 容器平台落地过程中遇到的一些问题，在产品战略上我们提出了 Hulk 2.0 的计划，它涵盖调度系统、容器引擎、内核隔离增强、弹性伸缩增强等领域；在战术上，遵循自顶向下的设计原则、自底向上的实施原则。

在 2018 年 4 月前比较长的一段时间内，Hulk 容器平台的研发主要聚焦在底层系统的升级上（优先打通 Hulk 2.0 容器编排 Kubernetes、容器创建 / 销毁的流程），在弹性伸缩 PaaS 平台的投入约为 0.5 个人力，增量业务停止接入，存量业务继续维护。在 Hulk 2.0 底层系统基本成型后，容器平台团队一方面开始着手将未接入弹性伸缩平台的 Hulk 1.0 容器平滑迁移至 Hulk 2.0 容器。另外一方面，开始着手组建人力建设可对接 Hulk 2.0 容器平台编排能力的弹性伸缩 2.0 系统，为已接入弹性伸缩平台的 Hulk 1.0 容器平滑迁移过来做技术储备。

在弹性伸缩 2.0 系统的演进过程中遵循“技术”、“推广”、“运营”的演进策略。我们可以先来看下在搭建平台的过程中面临的一些挑战以及解法。

2.1 技术挑战

结合当下弹性伸缩系统面临的处境，并对业界弹性伸缩产品做过一番调研后，在平台搭建上确定了如下三期目标：

- **一期目标**：弹性伸缩 2.0 系统 MVP 版本，简单来说是把底层 OpenStack 相关生态更换成 Kubernetes 周边生态，上层功能先维持不变。
- **二期目标**：业务上，找同部门业务先行试点，基于反馈，小步快跑，快速迭代；技术上，对北京、上海服务治理平台，CMDB 系统等相关业务逻辑进行融合。
- **三期目标**：1.0 系统的用户端融合为一套，减少业务侧的理解成本、研发侧的开发 / 维护成本。

在上述三期目标基本落地后，弹性伸缩 2.0 系统基本可以跑起来，处于一个不比弹性

伸缩 1.0 系统差的阶段，接下来基于过往运维问题汇总以及业务访谈诉求，在后端架构上做了几个比较大的升级。

2.1.1 弹性调度

正如前言所述，和大部分弹性伸缩产品类似，早期启用弹性伸缩的过程如下：

- **创建弹性分组**：弹性分组是弹性伸缩管理的基本单元，弹性分组用来管理同质化的业务实例，在美团的实践中，主要是同一个 IDC 中的实例。
- **创建弹性伸缩配置**：用于确定扩容出来的弹性伸缩实例的机型配置，比如：CPU、内存、硬盘大小等。
- **创建弹性伸缩规则**：具体来讲就是扩容几台、缩容几台。
- **创建弹性伸缩任务**：监控任务、定时任务。

在美团的落地场景中，我们遇到如下问题：

- **该扩未扩**，业务集群新部署一个 IDC 的实例时，不容易联想到需要给这个 IDC 实例创建弹性分组，导致的问题是高峰期其他 IDC 可正常扩容，这个 IDC 无法正常扩容。
- **不该扩却扩**，业务集群不再使用某个 IDC 后，未联想到需要关停这个弹性分组，导致的问题是一些定时任务依旧扩容出这个 IDC 的实例，部分情况下会引发业务异常。
- IDC 视角的扩缩局限性，未站在“上帝视角”做扩缩容决策，会导致部分 IDC 资源紧缺时，比较难以 Fail-Fast。
- 业务在不同 IDC 的业务逻辑不一致，部分业务把具体的策略耦合在业务逻辑中，一个业务集群使用一套镜像弹性扩容，会引发业务异常。

基于以上种种原因，我们拉通了各 PaaS 方，梳理了流量分组、弹性分组、发布分组之间的关系，以保证弹性伸缩在美团私有云中的扩容准确性。

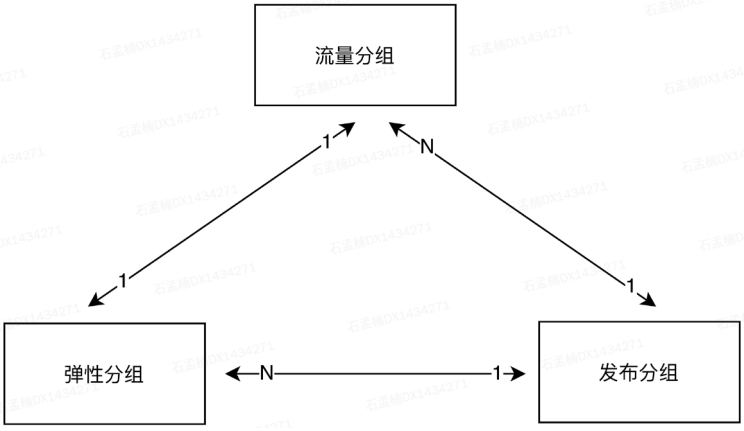

分组关系图

- **流量分组**：划分来源于美团服务治理平台 -OCTO、SET 化平台 - 大禹，比如这个服务走的是 SET 化方式（类业界单元化架构），那么每一个 SET 就是一个流量分组；依次类推，设置的是无差别调用方式，那么全局就是一个流量分组；设置的是同地域（Region）调用方式，那么每个 Region 就是一个流量分组；设置的是同中心调用方式，那么每个中心就是一个流量分组；设置的是同 IDC 优先调用方式，那么每个 IDC 就是一个流量分组。
- **弹性分组**：无需手动划分，一个流量分组就对应一个弹性分组，直接 Mapping 创建即可。
- **发布分组**：划分来源于美团发布平台 -Plus，对于未采用 SET 化架构的业务集群，则仅有一个 Default- 发布分组；针对采用 SET 化架构的集群，每个 SET 对应一个 SET- 发布分组，它们的代码 / 镜像可以不一样；基于同一个 SET 下又可能有多个地域、多个中心、多个 IDC（目前美团的 SET 化架构以同 IDC 调用为主），所以和流量分组之间是 1 对 N 的关系。

同地域访问的方式比较有代表性，这里对同地域调用 & 未 SET 化、同地域调用 &SET 化的业务集群自动扩容方式进行展开说明，其他组合可依次类推。

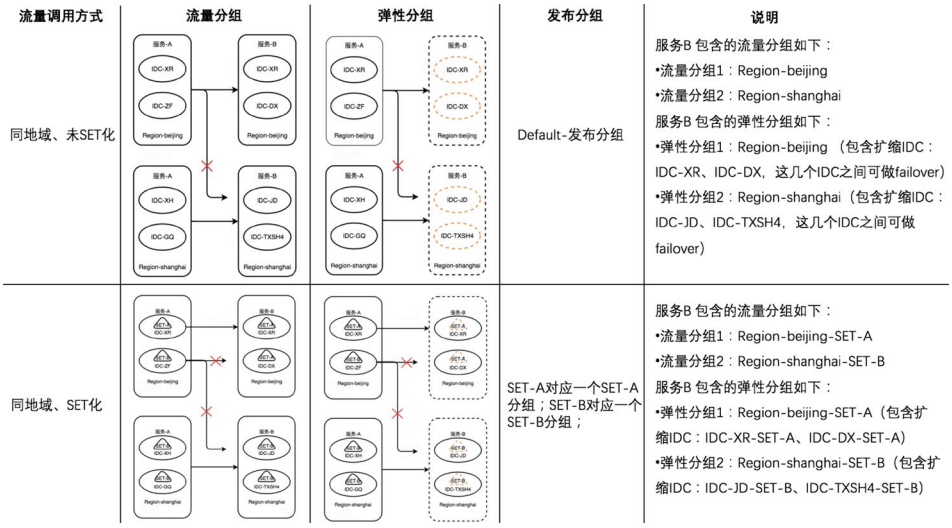

分组明细图

2.1.2 库存管控

弹性伸缩系统如果只是单纯地提供一个 IaaS 资源的自动供给能力，这件事情并不难。然而实际情况下，弹性伸缩系统在落地过程中需要解决资源上面临的问题。

- **业务关注点**：资源如何保障？过往在弹性伸缩系统 1.0 遇到过多次扩不出资源的情况。
- **组织关注点**：弹性资源池该划分为多大合适？如果储备大量的资源，却无法较好的进行分时复用，作为 PaaS 平台本身会造成资源闲置。

针对业务的这个关注点，目前业界公有云厂商的做法基本是不做 SLA 承诺或者说很难做到 SLA 承诺，因此也自然不会面临到组织的关注点问题。具体来说，在美团主要是通过以下几个措施来解决。

2.1.2.1 多租户管理

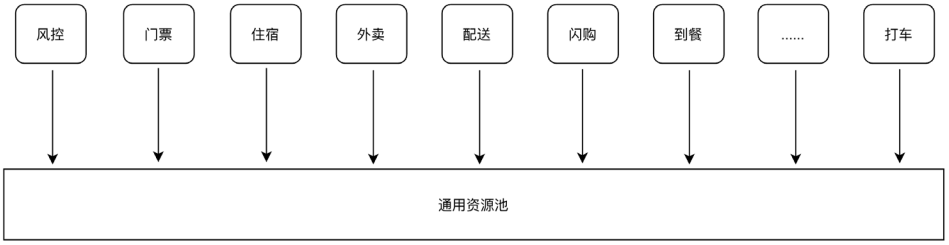

资源多租户图

平台给到每个业务线的资源并非无限，会给每个业务集群的弹性分组，设置一个默认的资源 Quota。如果业务觉得默认 Quota 不够，可通过工单的方式进行一轮评估调整（从实践来看，绝大部分情况无需调整）。针对这个资源 Quota，平台侧承诺的 SLA：99.9% 的扩容成功率。

这里会有个问题：是不是给业务 Quota 后，这部分资源就直接划分给这个业务独占了？答案：不是的。这只是一个逻辑上的划分，资源本身是各业务混用的，平台需控制资源闲置率，本身会做些“超售”，但过程中需解决好“超售”可能面临的问题，这就是水位线监管机制。

2.1.2.2 常态 – 资源保障

常规 – 资源保障，指的是平日、小节假日下的资源供给机制，这部分的资源来源于常驻资源池（架构图所示），平台会对已接入平台的所有服务，进行小时粒度的资源重预估。具体示意图如下：

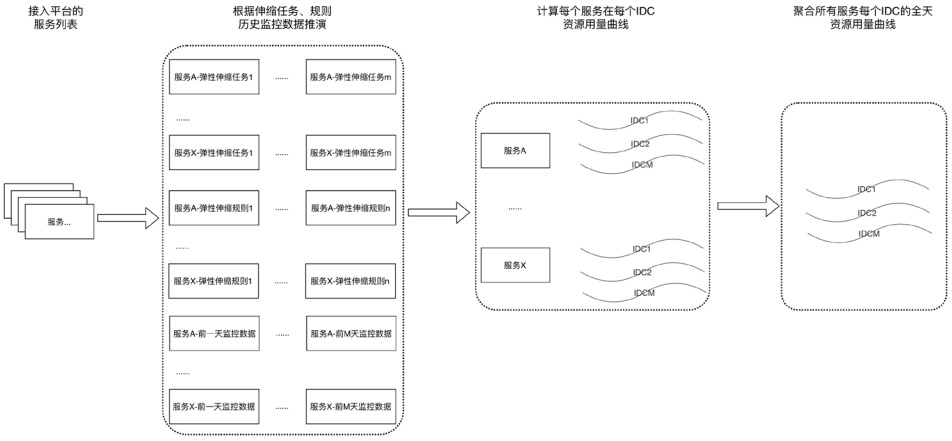

资源保障图

新增 / 更新服务的伸缩任务、伸缩规则时，会对当前变更对整体资源池水位的影响进行预估，如果在叠加时间点将超过整体资源池的水位，平台会拒绝执行变更操作，并给到用户和平台管理员消息推送，用户可通过工单方式进行资源请求说明（需保障存量服务的资源可靠性）。

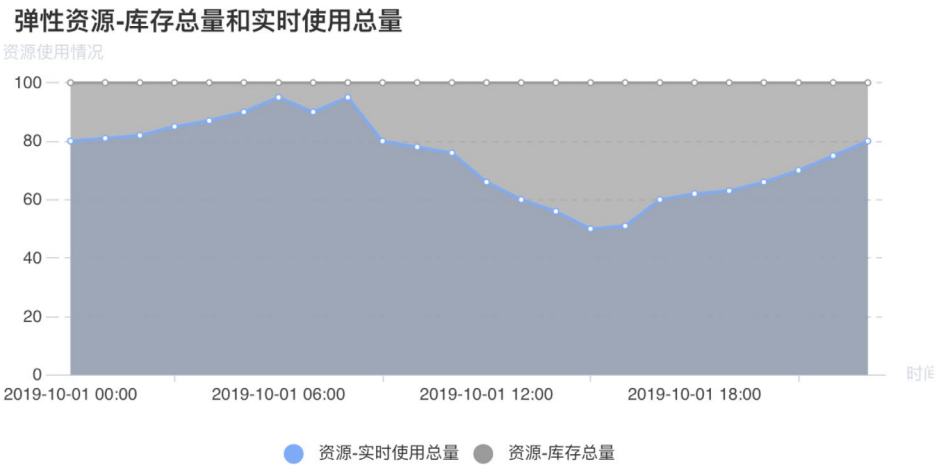

库存 & 实时用量

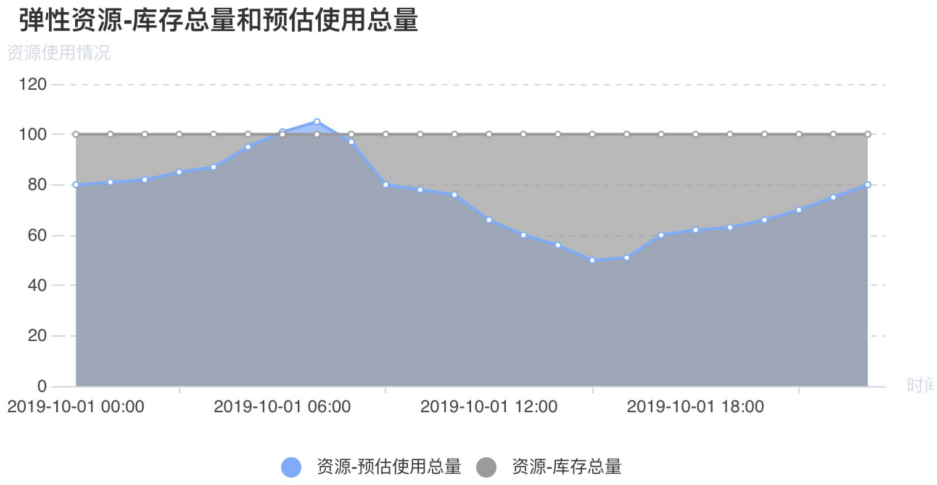

库存 & 预估用量

2.1.2.3 应急 – 资源保障

常驻资源池的大小是有限的，应急 – 资源保障指的是业务拉新、大促、大节假日等非常态的资源供给机制，这部分的资源来源于常驻资源池 + 应急资源池（如架构图所示）。应急资源池简单来说就是，我们按用量计费模式购买的公有云资源，这是一种更灵活的资源池模式（具备一定的租约）。在此基础上，我们构建了更省成本的混合云弹性调度能力（在此之前仅在私有云的常驻资源池调度）。

- **弹性扩容**：常驻资源池实例优先占用，应急资源池实例次之。
- **弹性缩容**：应急资源池实例先缩容，常驻资源池实例次之。

以下示意图展示的是一个服务在大促期间（维持 T 天）需要 208 台容器实例，其中 8 台为常态下的资源诉求，200 台为应急资源诉求。

大促前：

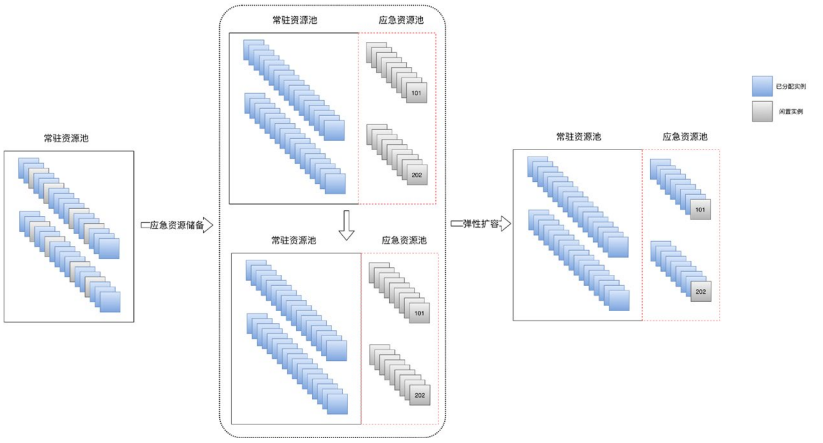

大促后（T+1）：

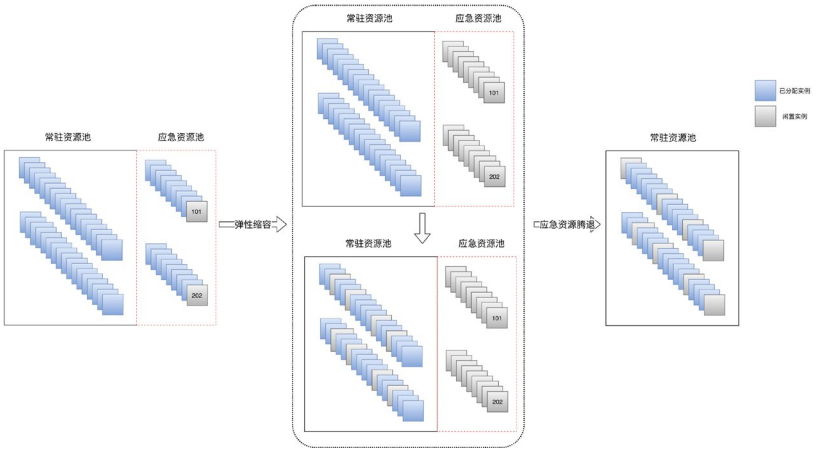

T+1 天后，这些应急资源池将被腾退回公有云厂商，公司无需为后续继续付费。多业务都应急的场景其实会偏复杂些；特殊情况下，需要采用重调度、治理。

2.2 推广思路

在 2020 年之前，是弹性伸缩 2.0 系统的练内功阶段，并未大规模向业务推广 Hulk 2.0 弹性伸缩系统，主要原因归结为两方面：

- 公司还处在从虚拟机、Hulk 1.0 容器迁移至 Hulk 2.0 容器阶段，Hulk 2.0 容器实例还处于打磨以及逐步赢得业务信任的过程中，推广弹性弹性伸缩 2.0 系

统，容器化是第一步。

- Hulk 2.0 系统在基础功能上不足以满足相对复杂的业务场景，比如 SET 化架构的业务。

截止 2020 年年底，共接入了约 500 个服务。这里主要以弹性伸缩 1.0 系统中平滑迁移过来的服务，同部门的服务（Eat Your Own Dog Food）为主。

在 2020 年 -2021 年，是弹性伸缩 2.0 系统的规模化阶段。

- **数据驱动**：从数万个服务中，通过自建的服务画像数据体系挖掘出数千个美团适合接入弹性伸缩的服务，主要是参考高低峰、是否有状态、实例配置、业务集群规模等因素，并将其下钻到各业务部门，共建设 30+ 运营大盘，锁定了平台侧希望去赋能的业务群体。
- **价值量化**：这里面经历了一些认知迭代的过程，最后提炼出来主要是三方面：“应突发”、“省成本”、“自动化”。
- **深入业务**：在前面 500 多个服务相对比较稳定之后，大概花了两三个月，和美团的各个业务线负责人去聊，主要围绕业务介绍（只有了解它，才有可能为它赋能），弹性伸缩价值介绍（横向拉通其他业务的最佳实践），业务今年的 OKR 是哪几块（评估弹性伸缩三方面的价值是否可以帮助业务更好的达成业绩、合作共赢），一起讨论当前业务接入后可能看到的收益。
- **技术培训**：根据前期深入业务，获得的反馈。业务比较关注技术原理、接入成本、系统健壮性、最佳实践、有哪些潜在的坑。团队同学把这些进行了提炼总结，输出了弹性伸缩白皮书（技术原理、FAQ 手册、最佳实践等）、避坑指南，并在有需要的业务部门进行 VIP 式的技术分享，一次不够、可以来两次，大大小小的业务团队、公司级的分享，我们做了十几二十次。
- **渠道闭环**：公司层面上要做一些大促活动，如“安心复苏计划”、“517 吃货节”、“1001 夜直播”，这些活动只要我们知道了，我们就主动加入进去看看能帮助哪些，从结果来看，效果还是挺好的。我们还在公司的 COE 系统（故障复盘分析工具）去搜“负载”、“秒杀”、“暴涨”、“扩容”之类的关键字，学习

问题的处理过程以及待办事项，评估后发现能帮上的，我们就主动联系业务去沟通。

- **业务回访**：虽然我们会在技术支持群内会做答疑，且每周会进行值班问题的汇总 Review，但相对来说会偏零散些。我们开始是采用问卷调查的方式去获取反馈，但是践行下来效果比较一般。因此，我们还是采用比较原始的方式——“促膝长谈”，我们主动从业务侧去拉取接入后遇到的问题，在评估优先级后快速迭代系统本身。

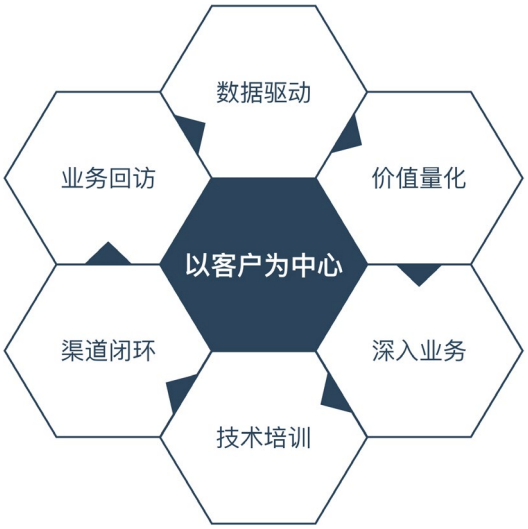

经过以上这些工作，我们 80%+ 的服务接入了弹性，覆盖了公司 90%+ 的业务线。回到那句话，如果弹性伸缩系统只是单纯地提供一个 IaaS 资源的自动供给能力，这件事情并不难，而我们的定位是 PaaS 平台。

2.3 运营难题

这部分主要介绍向业务交付弹性容器实例后，碰到的三类典型问题：**配置、启动、性能**。这些问题大部分不是弹性伸缩 2.0 这个 PaaS 平台本身领域内可直接闭环解决的事项，这往往取决于各 PaaS 平台是否已全量标准化、业务自身逻辑、以及基础设施层性能等因素，催化我们多去做这一步的原因只有一个：**弹性扩容出的实例只有很好的帮助业务分担负载，才可真正帮助业务解决问题**。

2.3.1 配置问题

配置问题	现象	解法
非标准化的发布模式	从上述弹性扩容架构的介绍中可知，弹性伸缩系统是和发布系统紧密相连的，只有开启了标准化发布模式（内部称之为"灰度发布"，因为历史原因/特殊场景也会有非标准化发布模式）的业务才能接入平台，这块是弹性伸缩系统的准入门槛，但是在实际运行的过程中业务在代码回滚、强制发布的时候可能会退化到非标准化发布模式，在高峰时候触发了弹性扩容，在镜像决策逻辑上会存在二义性问题；	启动"safe mode"模式，可以不work，但是不能work出错。平台会自动把这块的信息通过告警的形式发送给业务。（当然在实践过程中也会有定期巡检来提前发现这个问题）
任务配置不合理	过往存在部分业务接入了弹性伸缩平台，在真正高峰期时候并未触发扩容承载流量的现象；复盘去看，存在一些现象：部分业务新人对自己参与的业务不够熟悉，配置上无法准确把握；部分同学对阈值的理解在集群维度/单机维度等出现了偏差，导致配置错误。这些都是偏惨痛的代价；	针对存量业务，结合业务的监控数据、扩缩容记录、配置情况综合评估出目前业务配置合理程度，针对不合理的配置，给到业务侧分级推送风险（高、中、低）；针对增量业务，提供基础的弹性任务推荐能力，在业务进行任务配置、规则配置的过程中给到推荐值作为引导。

2.3.2 启动问题

启动问题，大部分解决的是容器的这种开箱即用方式所面临的问题，而非过往的采用先申请机器、再在这上面发布代码包的方式。而且这里面会经常要面临着业务的质疑，为什么我手动发布的时候不存在这个问题，采用弹性扩容就出现了?

启动问题	现象	解法
端口冲突	业务端口使用不规范导致（公司统一配置10240-65000段端口，用于系统随机分配的临时端口。当业务注册服务的端口也在该区间，应用启动，Listen端口时，可能出现对应端口，被系统其它进程临时占用，导致冲突，应用小概率启动失败）	方案一，推动业务改造，存量不规范服务修改端口，但会涉及上下游一并改造，成本高/收益小，难度较大； 方案二，推动RPC框架升级，增加端口注册重试逻辑，发现冲突时，休眠一定时间再次注册，但该问题无法根治，因成本较小已落地； 方案三，修改内核参数，容器启动时，设置ip_local_reserved_ports参数（容器粒度，不影响宿主机），将用户使用的端口排除，避免随机端口使用；经过试验该方案只在3.10内核版本的服务器上才生效，而生产环境上也有一定量的低于这个版本的服务器，该问题无法根治，且成本高/收益小，未推该方案； 兜底方案，弹性伸缩系统提供了运营治理工具：自动优雅重启容器，使其自愈；
数据库连接配置	批量扩容机器时，多个客户端实例创建大量的连接，导致服务端超时	将风险系统化告知业务，并推荐业务做一些数据库客户端连接池的配置修改
慢启动	部分服务启动时长过程超过10分钟，平台会将其归类为慢启动实例	将风险推系统化告知业务（比如：未来如果存在突发流量，即使毫秒级扩容出实例，业务也无法承载流量），将是否改造的决定权交给业务。
未挂载负载均衡系统	未内嵌自动挂载负载均衡系统SDK的业务，在手动发布的过程中会借助于发布平台上提供的Hook机制；	将风险推系统化告知业务，将改造方法以及是否改造的决定权交给业务。
启动瞬间-响应超时比较严重	业务镜像初始化过程中，会涉及到通用环境初始化、Agent版本更新等现象，导致CPU被非业务进程抢占；	1.基础镜像层面，推动建设agent发版规范； 2.通过nice方式降低Agent更新对CPU的抢占； 3.将通用环境初始化左移到基础镜像侧；
访问外网超时	基于安全的考虑，美团的业务访问外网需要预先申请白名单，在机器创建的过程中会进行机器粒度网络白名单的初始化以及验证逻辑，但这块和业务的代码是解耦的。过往采用手工发布的方式，在申请机器和部署代码之间有一个人工操作的时间空挡，这部分时间对于网络白名单初始化这个逻辑而言足够了，但采用镜像扩容这种开箱即用的方式，会面临业务启动了，白名单还没生效的问题；	协同调度系统层、容器层、网络层做全链路的改造升级，只有网络白名单初始化完成后，才将容器实例进行交付（无需业务关注的逻辑尽可能下沉）；

2.3.3 性能问题

生产环境中，业务容器的性能问题其实是比较复杂的，可能涉及到重 IO 容器影响、宿主机 Load 过高、多个容器突发占用 CPU 过高导致影响某个业务容器问题。相对于不使用弹性时囤积算力的稳定场景，弹性扩缩容场景中，因对资源的频繁调配会更容易遇到资源性能的问题。为了保障使用效果，Hulk 项目组主要从三个角度对性能问题完整解决：

- **事前**：服务粒度配置个性化调度策略。
- **事中**：基于服务画像数据平台提供服务时序特征、宿主机时序特征，建设多维度资源打散能力的调度算法。
- **事后**：针对存量 Node 上的重 IO、重 CPU 等容器进行重调度。

三、业务赋能场景

3.1 节假日扩缩容

业务场景：有着明显的“七节二月”特性，就流量而言周末是工作日的 1.5 倍左右，节假日流量是周末的 3~5 倍左右。服务机器基本上是按照节假日的流量部署，平时机器使用率很低。

如何使用弹性伸缩：

- 接入弹性伸缩定时任务，节假日期间弹性扩容，应对节假日流量高峰；非节假日高峰，弹性缩容，减少服务器资源开销。
- 任务配置示例：节前配置定时任务扩容；节后配置定时任务缩容；监控扩容任务作为托底。

接入效果：业务侧平均节约成本 20.4%。

3.2 日常高峰期扩容

业务场景：配送是外卖服务的下游，具有明显的午高峰特性。

如何使用弹性伸缩：

- 设置定时任务：在午高峰来临前扩容出足量的机器，在午高峰结束后缩掉富余的机器，如示例，分组【global – banner-east – 无 swimlane】绑定了 2 个定时任务，每天 09:55 扩容 125 台机器；每天 14:00 缩容 125 台机器。

接入效果：接入弹性之前，为应对午高峰流量，该服务需要常驻机器 2420 台；接入弹性之后常驻机器释放了 365 台，高峰期弹性机器占总机器数的 15%。

3.3 应急资源保障

业务场景：风控反爬服务，是公司业务的服务安全盾和数据安全盾。目前，已有上百个业务方接入反爬服务，每天处理百亿级重点流量，为各大业务方防控恶意流量，保障业务稳定、数据安全及统计数据的正确性。风控反爬相关服务，活动节假日期间，服务负载会受业务影响增长明显，需要活动节假日期间补充大量资源。

如何使用弹性策略：活动节假日期间，风控反爬业务，申请弹性应急资源（采购公有云宿主机），提升活动期间弹性扩容总量，提升服务稳定性。活动节假日过后，缩容应急资源，腾退公有云宿主机，节约资源。

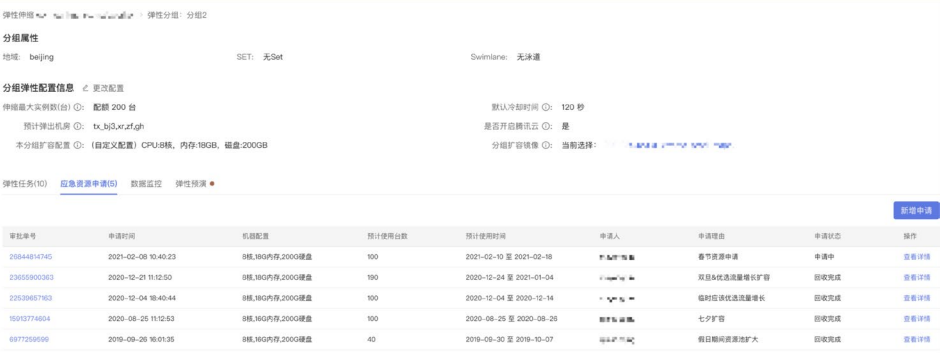

服务 A

服务 B

接入效果：为风控业务支持了 5 次大规模线上活动，基于弹性伸缩的应急 – 资源保障机制，累计提供公有云资源 700+ 台高配容器，约 7000+CPU 资源。

3.4 服务链路扩缩容

业务场景：餐饮 SaaS 采取“火车模型发布的模式”交付功能，需要为 70+ 服务申请专用的灰度链路机器，用于云端功能的灰度验证。但机器每月仅需使用 2~3 个工作日，一直持有机器，造成机器资源浪费；最初团队是通过每月定时手动申请、释放机器来解决，耗费较大人力，一定程度上影响到了研发的效率。

如何使用弹性策略：

- 配置链路拓扑。
- 每月活动开始前，配置链路任务，设置：扩缩容时间、机器 SET/LiteSet 标识、链路服务扩容机器数量。
- 到达设定时间，自动扩容、缩容机器。

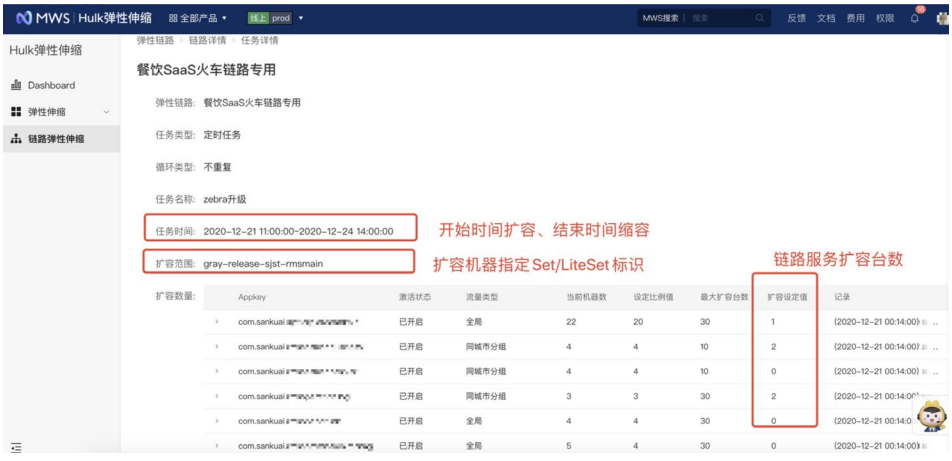

接入效果

- 使用前：火车发版涉及 70+ 服务，每月需要 70+ 服务负责人各自在发版前扩容机器，验证完成后缩容机器。
- 使用后：首次配置链路拓扑后，此后每月仅需一名 RD 同学，统一配置一个链

路任务，达到预设时间，自动扩、缩容，大大提高效率。

四、弹性伸缩未来规划

随着弹性伸缩系统 2.0 在美团的规模化落地，我们未来会从稳定性、易用性、业务解决方案、新技术探索四个方面去做深、做广：

（1）**稳定性**：基础服务的稳定性是一切的基石，而这往往是不少研发同学容易忽视的一点，研发同学需“在晴天时修屋顶”。

- **系统自身的健壮性**：集群全链路拆分（缩爆炸半径）、池化、资源 QoS 保障能力建设。
- **弹性实例的稳定性**：加固发现能力，持续完善异常检测工具（区别于常规的健康检测，会从异构算力的宿主机、不同内核参数、各系统指标层面进行综合决策），自动进行异常实例的替换；加强数据运营，提升反馈能力，持续协同调度算法进行演进。

（2）**易用性**

- **强化预演模式**：可以预测当前的弹性伸缩规则，服务接下来 24 小时的扩缩是怎么样的。这块我们目前做了个 MVP 版本，接下来除了会进一步提升用户触达率，另外也计划在用户端为接入的用户呈现使用后收益数据。
- **自动任务配置**：基于阈值的配置方式不小程度上取决于工程师经验，可能会因为工程师过于“年轻”而没有做正确的配置，导致一些异常；目前在接入侧已经对部分业务放开了任务推荐的功能；计划基于运营数据进一步打磨工具后，会周期性的自动帮助业务调整配置。

（3）**业务解决方案**

- **链路伸缩**：目前已经实现了基于链路拓扑批量配置、对各服务伸缩规则进行拆分的能力；接下来会将服务与服务之间，服务与中间件、存储之间的背压反馈作用于弹性决策中。

- **专区弹性伸缩**：目前已在金融业务线、美团七层负载均衡服务网关 Oceanus 中发挥弹性伸缩系统的“应突发”价值，未来计划为更多有专区场景的业务提供弹性伸缩支持。

（4）**新技术探索**：借鉴 Knative、Keda 的设计理念，为云原生业务场景的弹性伸缩做技术储备。

作者简介

涂扬，现任基础架构部弹性策略团队负责人。

招聘信息

美团基础架构团队诚招高级、资深技术专家，Base 北京、上海。我们致力于建设美团全公司统一的高并发高性能分布式基础架构平台，涵盖数据库、分布式监控、服务治理、高性能通信、消息中间件、基础存储、容器化、集群调度等基础架构主要的技术领域。欢迎有兴趣的同学投送简历至：edp.itu.zhaopin@meituan.com。

美团外卖实时数仓建设实践

作者：朱良　玉良　文博　山林

实时数仓以端到端低延迟、SQL 标准化、快速响应变化、数据统一为目标。美团外卖数据智能组总结的最佳实践是：一个通用的实时生产平台跟一个通用交互式实时分析引擎相互配合，同时满足实时和准实时业务场景。两者合理分工，互相补充，形成易开发、易维护且效率高的流水线，兼顾开发效率与生产成本，以较好的投入产出比满足业务的多样性需求。

01 实时场景

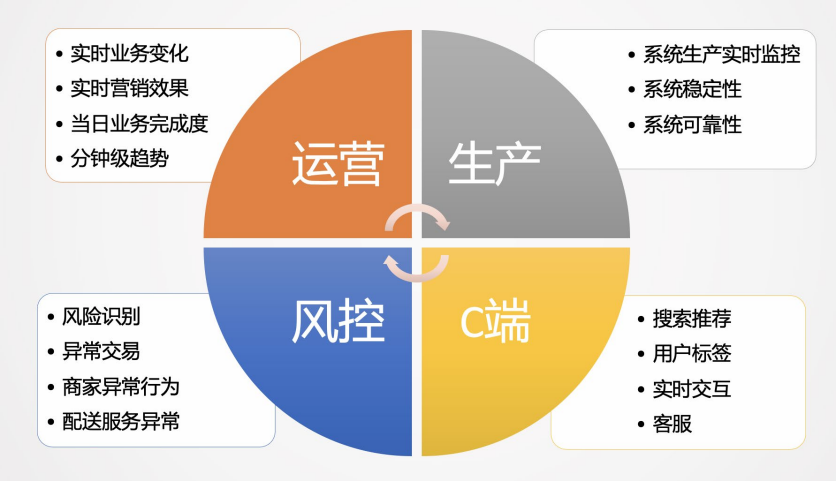

实时数据在美团外卖的场景是非常多的，主要有以下几个方面：

- **运营层面**：比如实时业务变化，实时营销效果，当日营业情况以及当日分时业

务趋势分析等。

- **生产层面**：比如实时系统是否可靠，系统是否稳定，实时监控系统的健康状况等。
- **C 端用户**：比如搜索推荐排序，需要实时行为、特点等特征变量的生产，给用户推荐更加合理的内容。
- **风控侧**：实时风险识别、反欺诈、异常交易等，都是大量应用实时数据的场景。

02 实时技术及架构

1. 实时计算技术选型

目前，市面上已经开源的实时技术还是很多的，比较通用的有 Storm、Spark Streaming 以及 Flink，技术同学在做选型时要根据公司的具体业务来进行部署。

美团外卖依托于美团整体的基础数据体系建设，从技术成熟度来讲，公司前几年主要用的是 Storm。当时的 Storm，在性能稳定性、可靠性以及扩展性上也是无可替代的。但随着 Flink 越来越成熟，从技术性能上以及框架设计优势上已经超越了 Storm，从趋势来讲就像 Spark 替代 MR 一样，Storm 也会慢慢被 Flink 替代。当然，从 Storm 迁移到 Flink 会有一个过程，我们目前有一些老的任务仍然运行在 Storm 上，也在不断推进任务迁移。

	Storm	Flink
状态管理	无状态，需用户自行进行状态管理	有状态
窗口支持	对事件窗口支持较弱，缓存整个窗口的所有数据，窗口结束时一起计算	窗口支持较为完善，自带一些窗口聚合方法，并且会自动管理窗口状态。
消息投递	At Most Once At Least Once	At Most Once At Least Once Exactly Once
容错方式	ACK机制 ：对每个消息进行全链路跟踪，失败或超时进行重发。	检查点机制 ：通过分布式一致性快照机制，对数据流和算子状态进行保存。在发生错误时，使系统能够进行回滚。
性能	稳定，可靠。性能上整体不如Flink	吞吐量是storm 3倍+， 时延明显低于storm
应用现状	公司内应用成熟，老业务大多运行在storm平台上	平台在完善升级，推动业务迁移到Flink平台。大厂应用成熟

具体 Storm 和 Flink 的对比可以参考上图表格。

2. 实时架构

① Lambda 架构

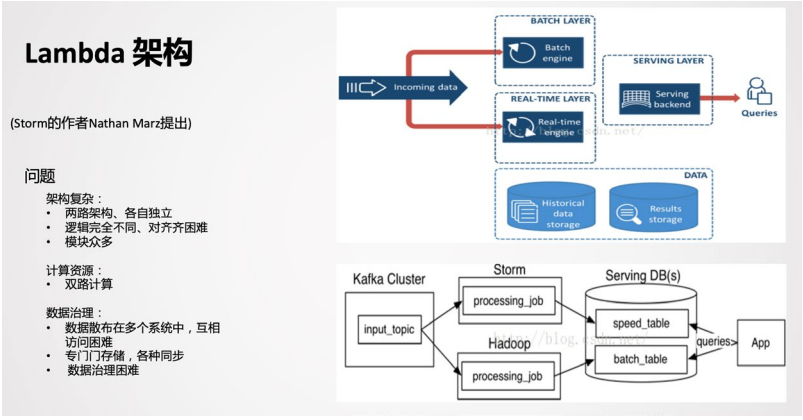

Lambda 是比较经典的一款架构，以前实时的场景不是很多，以离线为主，当附加了实时场景后，由于离线和实时的时效性不同，导致技术生态是不一样的。而 Lambda 架构相当于附加了一条实时生产链路，在应用层面进行一个整合，双路生产，各自独立。在业务应用中，顺理成章成为了一种被采用的方式。

双路生产会存在一些问题，比如加工逻辑 Double，开发运维也会 Double，资源同样会变成两个资源链路。因为存在以上问题，所以又演进了一个 Kappa 架构。

② Kappa 架构

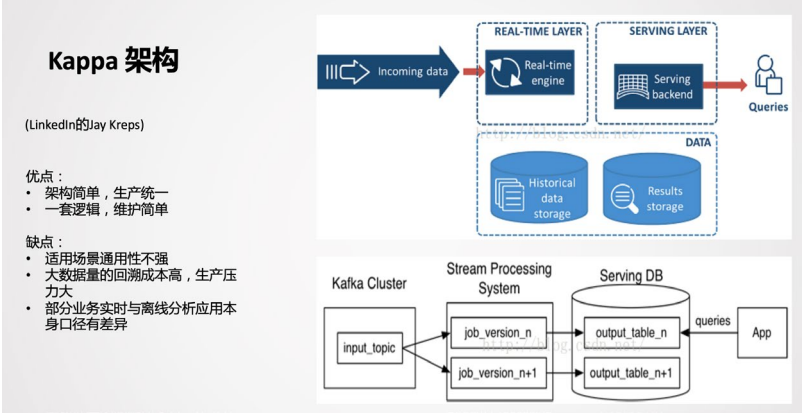

Kappa 从架构设计来讲，比较简单，生产统一，一套逻辑同时生产离线和实时。但是在实际应用场景有比较大的局限性，在业内直接用 Kappa 架构生产落地的案例不多见，且场景比较单一。这些问题在美团外卖这边同样会遇到，我们也会有自己的一些思考，将会在后面的章节进行阐述。

03 业务痛点

首先，在外卖业务上，我们遇到了一些问题和挑战。在业务早期，为了满足业务需要，一般是 Case By Case 地先把需求完成。业务对于实时性要求是比较高的，从时效性的维度来说，没有进行中间层沉淀的机会。在这种场景下，一般是拿到业务逻辑直接嵌入，这是能想到的简单有效的方法，在业务发展初期这种开发模式也比较常见。

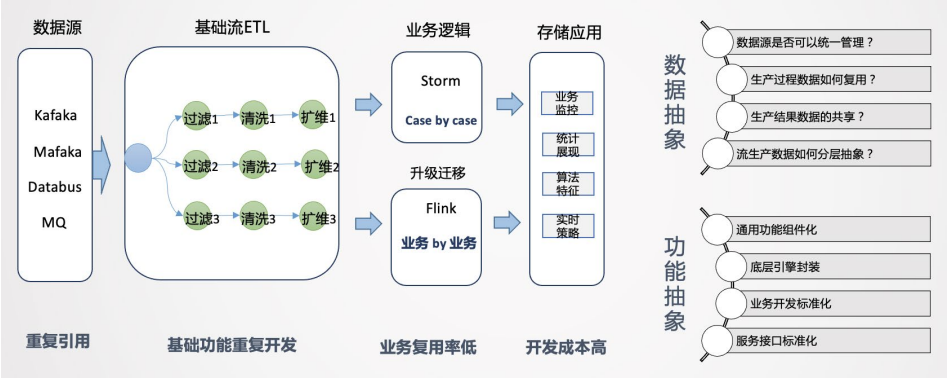

如上图所示，拿到数据源后，我们会经过数据清洗、扩维，通过 Storm 或 Flink 进行业务逻辑处理，最后直接进行业务输出。把这个环节拆开来看，数据源端会重复引用相同的数据源，后面进行清洗、过滤、扩维等操作，都要重复做一遍。唯一不同的是业务的代码逻辑是不一样的，如果业务较少，这种模式还可以接受，但当后续业务量上去后，会出现谁开发谁运维的情况，维护工作量会越来越大，作业无法形成统一管理。而且所有人都在申请资源，导致资源成本急速膨胀，资源不能集约有效利用，因此要思考如何从整体来进行实时数据的建设。

04 数据特点与应用场景

那么如何来构建实时数仓呢？首先要进行拆解，有哪些数据，有哪些场景，这些场景有哪些共同特点，对于外卖场景来说一共有两大类，日志类和业务类。

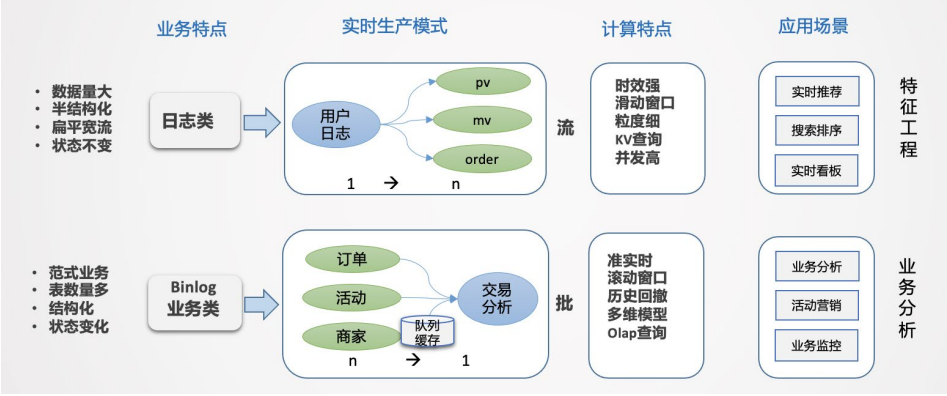

- **日志类**：数据量特别大，半结构化，嵌套比较深。日志类的数据有个很大的特点，日志流一旦形成是不会变的，通过埋点的方式收集平台所有的日志，统一进行采集分发，就像一颗树，树根非常大，推到前端应用的时候，相当于从树根到树枝分叉的过程（从 1 到 n 的分解过程）。如果所有的业务都从根上找数据，看起来路径最短，但包袱太重，数据检索效率低。日志类数据一般用于生产监控和用户行为分析，时效性要求比较高，时间窗口一般是 5min 或 10min，或截止到当前的一个状态，主要的应用是实时大屏和实时特征，例如用户每一次点击行为都能够立刻感知到等需求。
- **业务类**：主要是业务交易数据，业务系统一般是自成体系的，以 Binlog 日志的形式往下分发，业务系统都是事务型的，主要采用范式建模方式。特点是结构化，主体非常清晰，但数据表较多，需要多表关联才能表达完整业务，因此是一个 n 到 1 的集成加工过程。

而业务类实时处理，主要面临的以下几个难点：

- **业务的多状态性**：业务过程从开始到结束是不断变化的，比如从下单 -> 支付 -> 配送，业务库是在原始基础上进行变更的，Binlog 会产生很多变化的日

志。而业务分析更加关注最终状态，由此产生数据回撤计算的问题，例如 10 点下单，13 点取消，但希望在 10 点减掉取消单。

- **业务集成**：业务分析数据一般无法通过单一主体表达，往往是很多表进行关联，才能得到想要的信息，在实时流中进行数据的合流对齐，往往需要较大的缓存处理且复杂。
- **分析是批量的，处理过程是流式的**：对单一数据，无法形成分析，因此分析对象一定是批量的，而数据加工是逐条的。

日志类和业务类的场景一般是同时存在的，交织在一起，无论是 Lambda 架构还是 Kappa 架构，单一的应用都会有一些问题。因此针对场景来选择架构与实践才更有意义。

05 实时数仓架构设计

1. 实时架构：流批结合的探索

基于以上问题，我们有自己的思考。通过流批结合的方式来应对不同的业务场景。

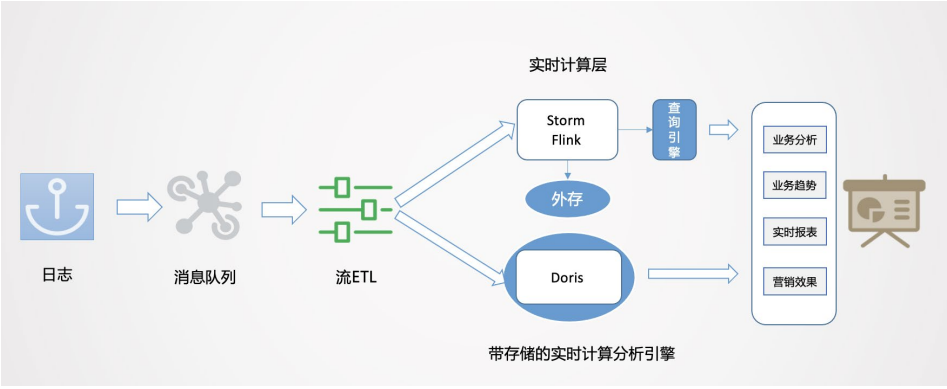

如上图所示，数据从日志统一采集到消息队列，再到数据流的 ETL 过程，作为基础数据流的建设是统一的。之后对于日志类实时特征，实时大屏类应用走实时流计算。对于 Binlog 类业务分析走实时 OLAP 批处理。

流式处理分析业务的痛点是什么？对于范式业务，Storm 和 Flink 都需要很大的外存，来实现数据流之间的业务对齐，需要大量的计算资源。且由于外存的限制，必须

进行窗口的限定策略，最终可能放弃一些数据。计算之后，一般是存到 Redis 里做查询支撑，且 KV 存储在应对分析类查询场景中也有较多局限。

实时 OLAP 怎么实现？有没有一种自带存储的实时计算引擎，当实时数据来了之后，可以灵活的在一定范围内自由计算，并且有一定的数据承载能力，同时支持分析查询响应呢？随着技术的发展，目前 MPP 引擎发展非常迅速，性能也在飞快提升，所以在这种场景下就有了一种新的可能。这里我们使用的是 Doris 引擎。

这种想法在业内也已经有实践，且成为一个重要探索方向。阿里基于 ADB 的实时 OLAP 方案等。

2. 实时数仓架构设计

从整个实时数仓架构来看，首先考虑的是如何管理所有的实时数据，资源如何有效整合，数据如何进行建设。

从方法论来讲，实时和离线是非常相似的。离线数仓早期的时候也是 Case By Case，当数据规模涨到一定量的时候才会考虑如何治理。分层是一种非常有效的数据治理方式，所以在实时数仓如何进行管理的问题上，首先考虑的也是分层的处理逻辑，具体内容如下：

- **数据源**：在数据源的层面，离线和实时在数据源是一致的，主要分为日志类和业务类，日志类又包括用户日志、DB 日志以及服务器日志等。
- **实时明细层**：在明细层，为了解决重复建设的问题，要进行统一构建，利用离线数仓的模式，建设统一的基础明细数据层，按照主题进行管理，明细层的目的是给下游提供直接可用的数据，因此要对基础层进行统一的加工，比如清洗、过滤、扩维等。
- **汇总层**：汇总层通过 Flink 或 Storm 的简洁算子直接可以算出结果，并且形成汇总指标池，所有的指标都统一在汇总层加工，所有人按照统一的规范管理建设，形成可复用的汇总结果。

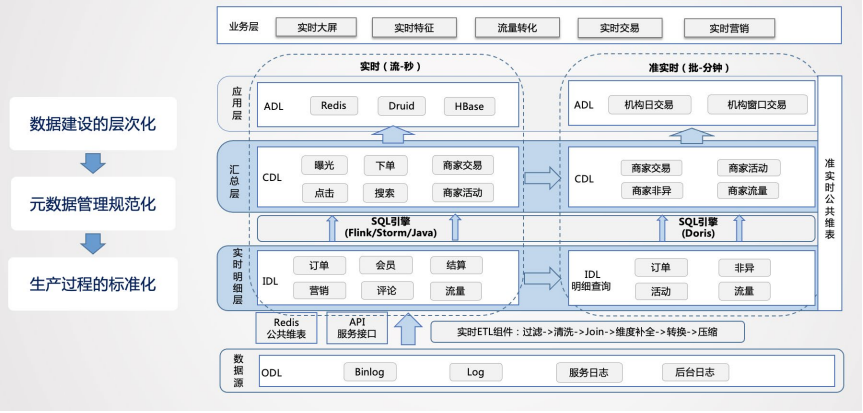

总结起来，从整个实时数仓的建设角度来讲，首先数据建设的层次化要先建出来，先搭框架，然后定规范，每一层加工到什么程度，每一层用什么样的方式，当规范定义出来后，便于在生产上进行标准化的加工。由于要保证时效性，设计的时候，层次不能太多，对于实时性要求比较高的场景，基本可以走上图左侧的数据流，对于批量处理的需求，可以从实时明细层导入到实时 OLAP 引擎里，基于 OLAP 引擎自身的计算和查询能力进行快速的回撤计算，如上图右侧的数据流。

06 实时平台化建设

架构确定之后，我们后面考虑的是如何进行平台化的建设，实时平台化建设是完全附加于实时数仓管理之上进行的。

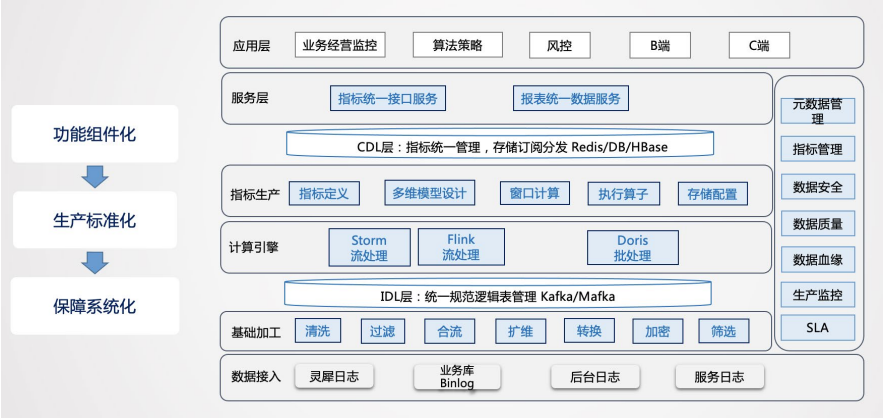

首先进行功能的抽象，把功能抽象成组件，这样就可以达到标准化的生产，系统化的保障就可以更深入的建设，对于基础加工层的清洗、过滤、合流、扩维、转换、加密、筛选等功能都可以抽象出来，基础层通过这种组件化的方式构建直接可用的数据结果流。这会产生一个问题，用户的需求多样，为了满足了这个用户，如何兼容其他的用户，因此可能会出现冗余加工的情况。从存储的维度来讲，实时数据不存历史，不会消耗过多的存储，这种冗余是可以接受的，通过冗余的方式可以提高生产效率，是一种**以空间换时间**思想的应用。

通过基础层的加工，数据全部沉淀到 IDL 层，同时写到 OLAP 引擎的基础层，再往上是实时汇总层计算，基于 Storm、Flink 或 Doris，生产多维度的汇总指标，形成统一的汇总层，进行统一的存储分发。

当这些功能都有了以后，元数据管理，指标管理，数据安全性、SLA、数据质量等系统能力也会逐渐构建起来。

1. 实时基础层功能

实时基础层的建设要解决一些问题。首先是一条流重复读的问题，一条 Binlog 打过来，是以 DB 包的形式存在的，用户可能只用其中一张表，如果大家都要用，可能存在所有人都要接这个流的问题。解决方案是可以按照不同的业务解构出来，还原到基础数据流层，根据业务的需要做成范式结构，按照数仓的建模方式进行集成化的主题建设。

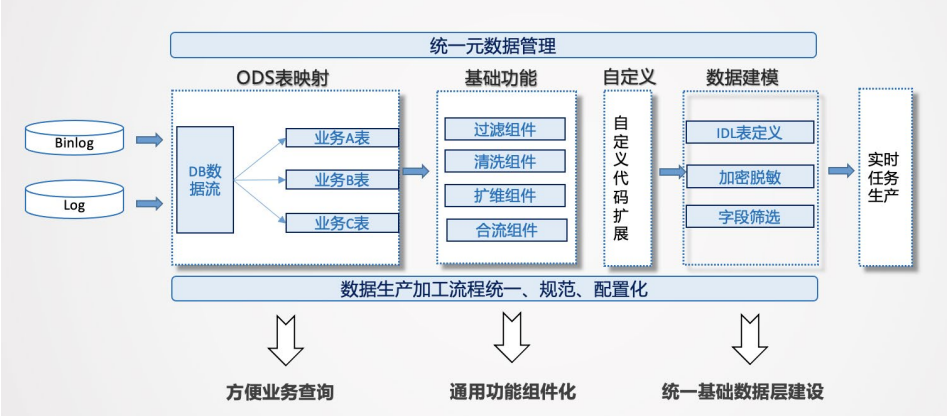

其次要进行组件的封装，比如基础层的清洗、过滤、扩维等功能，通过一个很简单的表达入口，让用户将逻辑写出来。数据转换环节是比较灵活的，比如从一个值转换成另外一个值，对于这种自定义逻辑表达，我们也开放了自定义组件，可以通过 Java 或 Python 开发自定义脚本，进行数据加工。

2. 实时特征生产功能

特征生产可以通过 SQL 语法进行逻辑表达，底层进行逻辑的适配，透传到计算引擎，屏蔽用户对计算引擎的依赖。就像对于离线场景，目前大公司很少通过代码的方式开发，除非一些特别的 Case，所以基本上可以通过 SQL 化的方式表达。

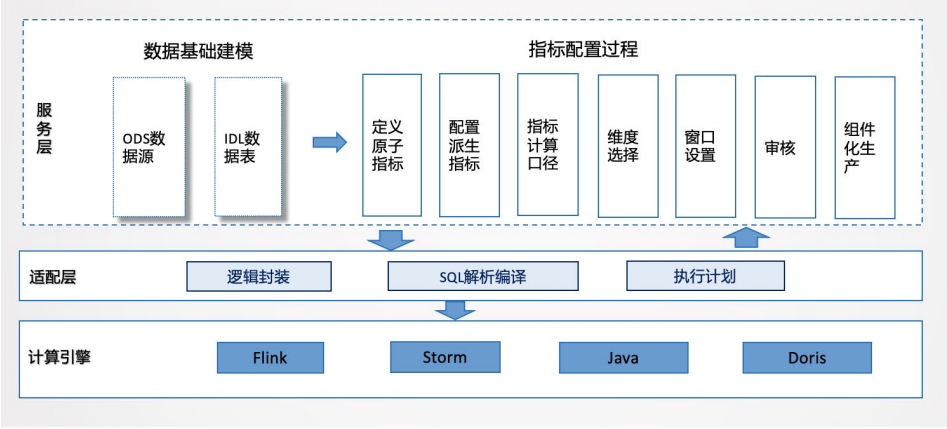

在功能层面，把指标管理的思想融合进去，原子指标、派生指标，标准计算口径，维度选择，窗口设置等操作都可以通过配置化的方式，这样可以统一解析生产逻辑，进行统一封装。

还有一个问题，同一个源，写了很多 SQL，每一次提交都会起一个数据流，比较浪费资源，我们的解决方案是，通过同一条流实现动态指标的生产，在不停服务的情况下可以动态添加指标。

所以在实时平台建设过程中，更多考虑的是如何更有效的利用资源，在哪些环节更能节约化的使用资源，这是在工程方面更多考虑的事情。

3. SLA 建设

SLA 主要解决两个问题，一个是端到端的 SLA，一个是作业生产效率的 SLA，我们采用埋点 + 上报的方式，由于实时流比较大，埋点要尽量简单，不能埋太多的东西，能表达业务即可，每个作业的输出统一上报到 SLA 监控平台，通过统一接口的形式，在每一个作业点上报所需要的信息，最后能够统计到端到端的 SLA。

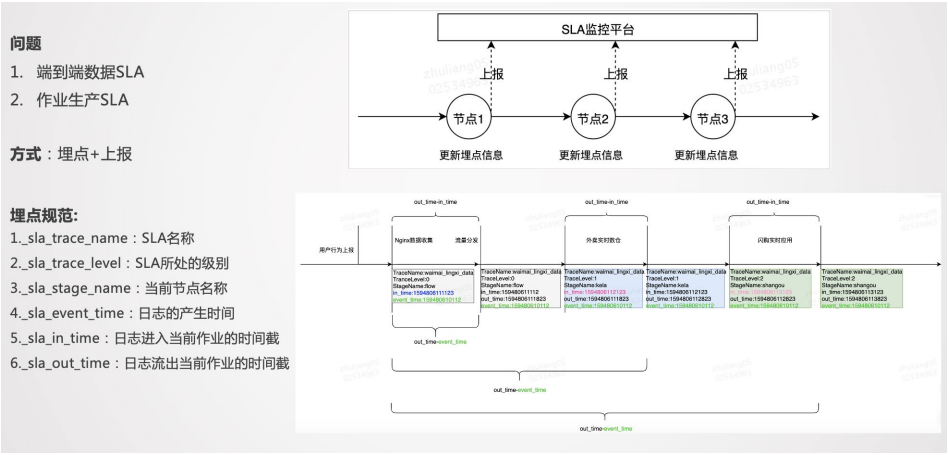

在实时生产中，由于链路非常长，无法控制所有链路，但是可以控制自己作业的效率，所以作业 SLA 也是必不可少的。

4. 实时 OLAP 方案

问题

- **Binlog 业务还原复杂**：业务变化很多，需要某个时间点的变化，因此需要进行排序，并且数据要存起来，这对于内存和 CPU 的资源消耗都是非常大的。
- **Binlog 业务关联复杂**：流式计算里，流和流之间的关联，对于业务逻辑的表达是非常困难的。

解决方案

通过带计算能力的 OLAP 引擎来解决，不需要把一个流进行逻辑化映射，只需要解决数据实时稳定的入库问题。

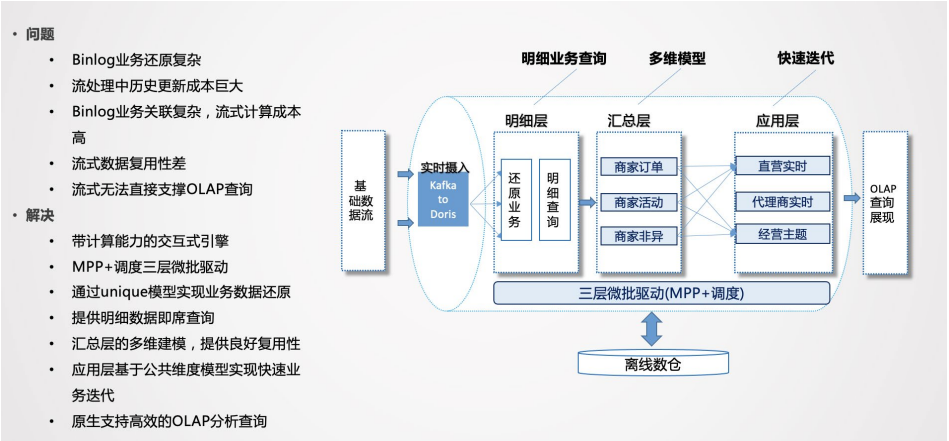

我们这边采用的是 Doris 作为高性能的 OLAP 引擎，由于业务数据产生的结果和结果之间还需要进行衍生计算，Doris 可以利用 Unique 模型或聚合模型快速还原业务，还原业务的同时还可以进行汇总层的聚合，也是为了复用而设计。应用层可以是物理的，也可以是逻辑化视图。

这种模式重在解决业务回撤计算，比如业务状态改变，需要在历史的某个点将值变更，这种场景用流计算的成本非常大，OLAP 模式可以很好的解决这个问题。

07 实时应用案例

最后通过一个案例说明，比如商家要根据用户历史下单数给用户优惠，商家需要看到历史下了多少单，历史 T+1 的数据要有，今天实时的数据也要有，这种场景是典型的 Lambda 架构。我们可以在 Doris 里设计一个分区表，一个是历史分区，一个是今日分区，历史分区可以通过离线的方式生产，今日指标可以通过实时的方式计算，写到今日分区里，查询的时候进行一个简单的汇总。

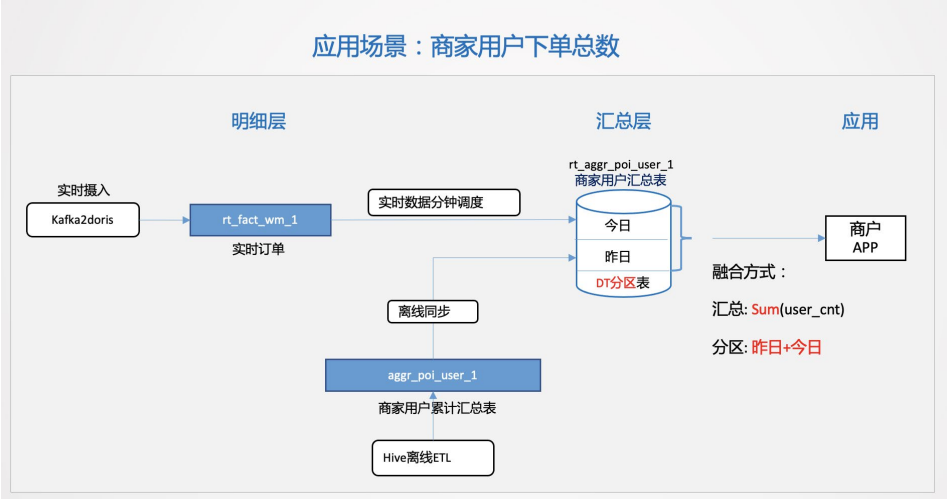

这种场景看起来比较简单，难点在于商家的量上来之后，很多简单的问题都会变得复杂。后续，我们也会通过更多的业务输入，沉淀出更多的业务场景，抽象出来形成统一的生产方案和功能，以最小化的实时计算资源支撑多样化的业务需求，这也是未来我们需要达到的目的。

美团酒旅数据治理实践

作者：建舒　王磊　罗茜

一、背景

1. 为什么要做数据治理

随着移动互联网的兴起，线下商业活动逐渐开始向线上化发展，数据的产生速度有了极大的提升。越来越多的公司开始认识到数据的重要性，并将其打造成为公司的核心资产，从而驱动业务的发展。在数据相关的领域中，“数据治理”这个话题近两年尤为火热，很多公司特别是大型互联网公司都在做一些数据治理的规划和动作。

为什么要做数据治理？因为在数据产生、采集、加工、存储、应用到销毁的全过程中，每个环节都可能会引入各种质量、效率或安全相关的问题。在公司早期的发展阶段，这些数据问题对公司发展的影响并不是很大，公司对问题的容忍度相对也比较高。但是，随着业务的发展，公司在利用数据资产创造价值的同时，对数据质量和稳定性要求也有所提升。此外，当数据积累得越来越多，公司对数据精细化运营程度的要求也随之提高，会逐渐发现有很多问题需要治理。

同时，在数据开发的过程中也会不断引入一些问题，而数据治理就是要不断消除引入的这些问题，保障数据准确、全面和完整，为业务创造价值，同时严格管理数据的权限，避免数据泄露带来的业务风险。因此，数据治理是数字时代很多公司一项非常重要的核心能力。

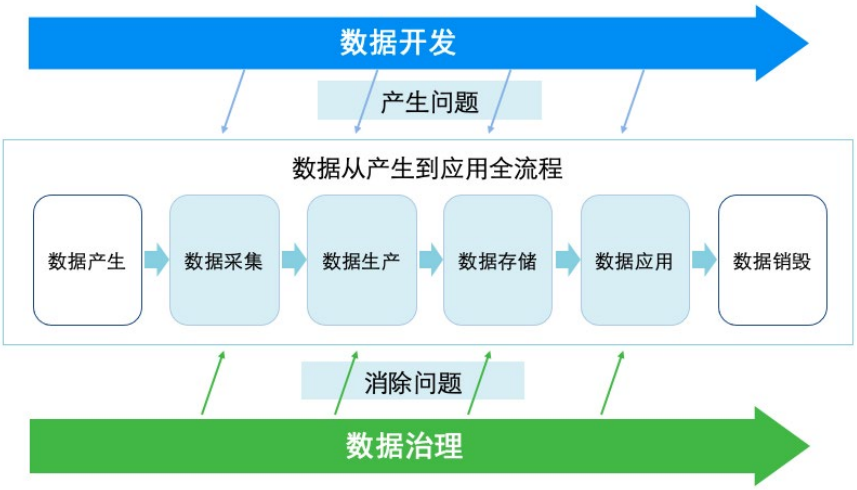

2. 需要治理哪些问题

数据治理是一项需要长期被关注的复杂工程，这项工程通过建立一个满足企业需求的数据决策体系，在数据资产管理过程中行使权力、管控和决策等活动，并涉及到组织、流程、管理制度和技术体系等多个方面。一般而言，数据治理的治理内容主要包括下面几个部分：

- **质量问题**：这是最重要的问题，很多公司的数据部门启动数据治理的大背景就是数据质量存在问题，比如数仓的及时性、准确性、规范性，以及数据应用指标的逻辑一致性问题等。
- **成本问题**：互联网行业数据膨胀速度非常快，大型互联网公司在大数据基础设施上的成本投入占比非常高，而且随着数据量的增加，成本也将继续攀升。
- **效率问题**：在数据开发和数据管理过程中都会遇到一些影响效率的问题，很多时候是靠“盲目”地堆人力在做。
- **安全问题**：业务部门特别关注用户数据，一旦泄露，对业务的影响非常之大，甚至能左右整个业务的生死。
- **标准问题**：当公司业务部门比较多的时候，各业务部门、开发团队的数据标准不一致，数据打通和整合过程中都会出现很多问题。

数据常见问题

- 数据质量
- 成本控制
- 研发效率
- 数据安全
- 标准规范

3. 美团酒旅数据现状

2014 年，美团酒旅业务成为独立的业务部门，到 2018 年，酒旅平台已经成为国内酒旅业务重要的在线预订平台之一。业务发展速度较快，数据增长速度也很快。在 2017 到 2018 两年里，生产任务数以每年超过一倍的速度在增长，数据量以每年两倍多的速度在增长。如果不做治理的话，根据这种接近指数级的数据增长趋势来预测，未来数据生产任务的复杂性及成本负担都会变得非常之高。在 2019 年初，我们面临着下面五种问题：

- **数据质量问题严重**：一是数据冗余严重，从数据任务增长的速度来看，新上线任务多，下线任务少，对数据表生命周期的控制较少；二是在数据建设过程中，很多应用层数据都属于“烟囱式”建设，很多指标口径没有统一的管理规范，数据一致性无法进行保证，同名不同义、同义不同名的现象频发。
- **数据成本增长过快**：某些业务线大数据存储和计算资源的机器费用占比已经超过了 35%，如果不加以控制，大数据成本费用只会变得越来越高。
- **数据运营效率低下**：数据使用和咨询多，数据开发工程师需要花费大量时间一对一解答业务用户的各种问题。但是这种方式对于用户来说，并没有提升数据的易用性，无法有效地积累和沉淀数据知识，还降低了研发人员的工作效率。
- **数据安全缺乏控制**：各业务线之间可以共用的数据比较多，而且每个业务线没有统一的数据权限管控标准。

- **开发标准规范缺失**：早期为快速响应业务需求，研发人员通常采用“烟囱式”的开发模式，由于缺乏相应的开发规范约束，且数据工程师的工作思路和方式差异性都非常大，导致数据仓库内的重复数据多，规范性较差。当发生数据问题时，问题的排查难度也非常大，且耗时较长。

4. 治理目标

2019 年，美团酒旅数据团队开始主动启动数据治理工作，对数据生命周期全链路进行体系化数据治理，期望保障数据的长期向好，解决数据各个链路的问题，并保持数据体系的长期稳定。具体的目标包含以下几个方面：

- 建立数据开发全链路的标准规范，提高数据质量，通过系统化手段管理指标口径，保障数据一致性。
- 控制大数据成本，避免大数据机器成本膨胀对业务营收带来的影响，合理控制数据的生命周期，避免数据重复建设，减少数据冗余，及时归档和清理冷数据。
- 管理数据的使用安全，建立完善的数据安全审批流程和使用规范，确保数据被合理地使用，避免因用户数据泄露带来的安全风险和商业损失。
- 提高数据工程师的开发和运维效率，减少他们数据运营时间的投入，提高数据运营的自动化和系统化程度。

二、数据治理实践

其实早在 2018 年以前，酒旅数据组就做过数据治理，当时只是从数仓建模、指标管理和应用上单点做了优化和流程规范。之后，基于上面提到的五个问题，我们又做了一个体系化的数据治理工作。下面将介绍一下美团酒旅数据团队在数据治理各个方向上的具体实践。

1. 数据治理策略

数据治理方案需要覆盖数据生命周期的全链路，我们把数据治理的内容划分为几大部分：组织、标准规范、技术、衡量指标。整体数据治理的实现路径是以标准化的规范

和组织保障为前提，通过做技术体系整体保证数据治理策略的实现。同时，搭建数据治理的衡量体系，随时观测和监控数据治理的效果，保障数据治理长期向好的方向发展。

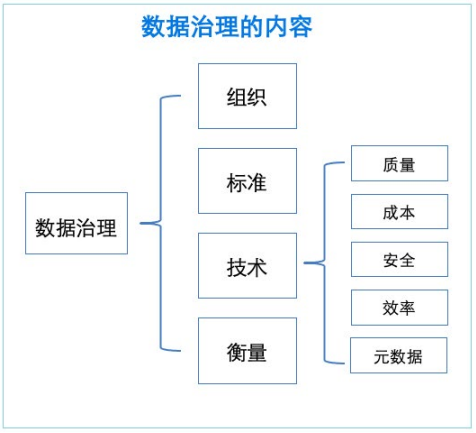

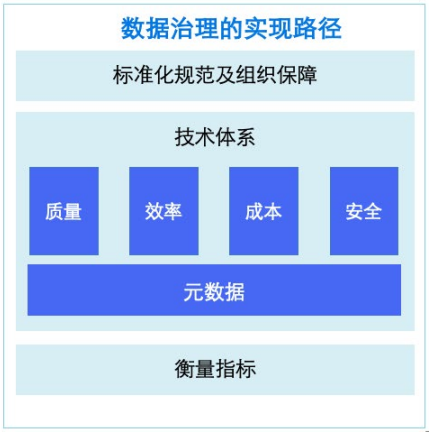

2. 标准化和组织保障

我们制定了一个全链路的数据标准，从数据采集、数仓开发、指标管理到数据生命周期管理，全链路建立标准，在标准化建立过程中联合组建了业务部门的数据管理委员会。

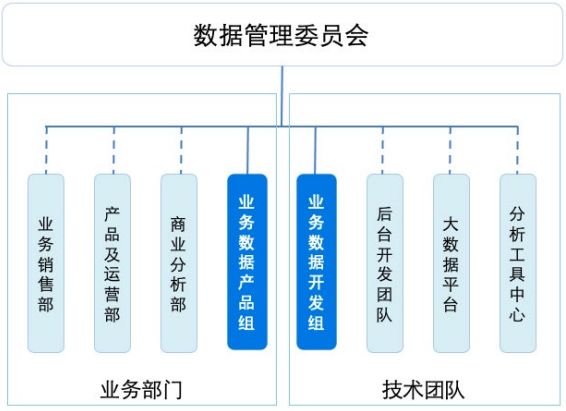

2.1 标准化

数据标准化包括三个方面：一是标准制定；二是标准执行；三是在标准制定和执行过程中的组织保障，比如怎么让标准能在数据技术部门、业务部门和相关商业分析部门达成统一。

从标准制定上，我们制定了一套覆盖数据生产到使用全链路的数据标准方法，从数据采集、数仓开发、指标管理到数据生命周期管理都建立了相应环节的标准化的研发规范，数据从接入到消亡整个生命周期全部实现了标准化。

2.2 组织保障

根据美团数据管理分散的现状，专门建立一个职能全面的治理组织去监督执行数据治理工作的成本有点太高，在推动和执行上，阻力也会比较大。所以，在组织保障上，我们建立了委员会机制，通过联合业务部门和技术部门中与数据最相关的团队成立了数据管理委员会，再通过委员会去推动相关各方去协同数据治理的相关工作。

业务部门的数据接口团队是数据产品组，数据技术体系是由数据开发组负责建设，所以我们以这两个团队作为核心建立了业务数据管理委员会，并由这两个团队负责联合业务部门和技术部门的相关团队，一起完成数据治理各个环节工作和流程的保障。组织中各个团队的职责分工如下：

数据管理委员会：负责数据治理策略、目标、流程和标准的制定，并推动所有相关团队达成认知一致。**业务数据产品组**：负责数据标准、需求对接流程、指标统一管理、数据安全控制以及业务方各部门的协调推动工作。**技术数据开发组**：负责数据仓库、数据产品、数据质量、数据安全和数据工具的技术实现，以及技术团队各个部门的协调推动工作。

3. 技术系统

数据治理涉及的范围非常广，需要协作的团队也很多，除了需要通过组织和流程来保障治理行动正常开展，我们也考虑通过技术系统化和自动化的方式进一步提效，让系

统代替人工。下面我们将从数据质量、数据成本、数据安全和运营效率等几个方向，来逐一介绍技术实现方案。

3.1 数据质量

数据质量是影响数据价值最重要的因素，高质量的数据给带来准确的数据分析，错误的数据会把业务引导到错误的方向。数据质量涉及范围较广，在数据链路的每一个环节都有可能出现数据质量问题，酒旅业务现阶段的主要质量问题包括：

- 数仓规范性差，数仓架构无统一的强制规范执行约束，数仓历史冗余数据严重。
- 应用层数据属于“烟囱式”建设，指标在多个任务中生产，无法保证数据的一致性。
- 数据下游应用的数据使用无法把控，数据准确较差，接口稳定性无法得到保障。
- 业务方对多个数据产品的指标逻辑无统一的定义，各个产品中数据不能直接对标。

数据组的治理数据质量方案覆盖了数据生命周期的各个环节，下面将介绍一下整体的技术架构。

- **统一数仓规范建模（One Model）**：通过统一数仓规范建模系统化保障数仓规范执行，做到业务数仓规范标准化，并及时监控和删除重复和过期的数据。
- **统一指标逻辑管理（One Logic）**：通过业务内统一的指标定义和使用，并系统化管理指标逻辑，数据应用层的数据指标逻辑都从指标管理系统中获取，保障所有产品中的指标逻辑一致。
- **统一数据服务（One Service）**：通过建设统一的数据服务接口层，解耦数据逻辑和接口服务，当数据逻辑发生变化后不影响接口数据准确性，同时监控接口的调用，掌握数据的使用情况。
- **统一用户产品入口（One Portal）**：分用户整合数据产品入口，使同一场景下数据逻辑和使用方式相同，用户没有数据不一致的困惑。

3.1.1 统一数仓规范建模（One Model）

在业务发展初期，数据团队集中精力在快速建设数仓来支持业务，数仓建模规范疏于管理。随着业务的发展，数仓中的数据急剧增多，数据产品和下游应用快速增加，数据工程师和数据使用方也变得越来越多，数仓的问题日益突显。业务数据仓库从初期发展到现在主要暴露了 3 方面的问题：

- 数据规范性较差，不同时间的数仓规范不同，数仓规范的执行审核需要较多的人力。
- 数据不一致问题多，同一指标在多个 ETL 中生产，数据更新同步也不及时。
- 历史数据冗余严重，数据存储方式较多，业务方查询不知道该用哪个数据。

数据团队主要通过数仓规范化制定、数仓分层架构和数仓规范化系统来解决上述问题，下面是我们的具体解决方案。

制定标准 – 数仓规范

做好数仓规范化最基本的前提是要制定一系列标准化的规范，并推动组内同学执行。标准化的适用性、全面性和可执行性直接影响到规范的执行效果。数仓规范主要从 3 个方面制定数据标准化：

- 数仓建模规范，数仓建设最基础的规范，包括分层、命名、码值、指标定义、分层依赖等维度。
- 主数据管理规范，数仓各个主题的数据只有一份，团队共建复用，不能重复开发。
- 数据使用规范，在查询数据时优先查询主题层，不再提供明细层和 ODS 层的查询访问入口。

工具保障 – 数仓规范化开发系统 –Dataman

在执行数据规范化的过程中，我们发现团队中每个人对规范的理解不一致，很可能造成数据规范不统一，审核人在审核上线任务时需要考虑规范的全部规则，审批需要投入的人力较多。在这样的流程下，数据规范性无法从根源上进行控制，因此需要建设数据规范化的工具，通过系统保障规范的一致性。数据组使用的数据层规范化工具 –Dataman，主要包括 3 个功能模块：标准化规范、配置化开发和规则化验证。

- **标准化规范**：制定业务数据仓库的标准规范并配置在系统中，包括架构分层、字段管理、词根管理、公共维度和码值管理等，在 ETL 开发时通过统一的数仓规范开发，通过配置化实现数仓的命名、分层和码值，保障数仓长期的规范性。

- **配置化开发**：系统化保障工程师在开发 ETL 过程中遵守数仓规范，Dataman 可以用配置化的方式生成 XT 任务模板，模板中包含数据模型的基础信息，研发同学只需要在任务模板中开发数据生产逻辑。

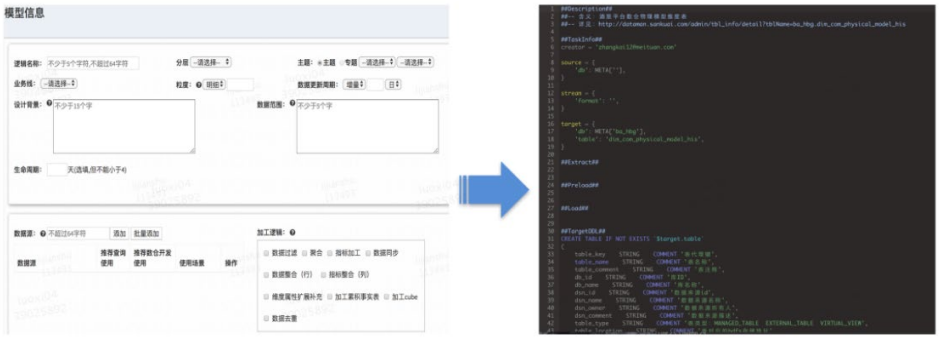

- **规则化验证**：跟进数据仓库底层元数据和标准化配置信息，定期扫描数仓的规范性情况，判断出不符合数仓规范的任务和高相似度的数据表。

3.1.2 统一指标逻辑管理（One Logic）

业务使用数据的第一步是搭建业务指标体系，业务的目标和策略的执行情况需要通过指标来分析，指标体系的合理性和指标数据的质量直接影响到业务决策，指标的重要性不言而喻。我们通过系统化地管理数据指标，从根源上解决指标口径一致性问题，主要从以下 3 个方向入手：

- **指标定义规范化**
- **指标管理系统化**
- **数据查询智能化**

指标定义规范化

此处主要从指标的生成和管理上做好规范，确保业务同学和研发人员对指标体系管理的认知一致，确保指标的新建、更改和使用都按照规范执行。我们通过下面 2 个方向来实现指标定义的规范统一。

- **业务指标体系的规范化**：我们在业务线内统一了指标体系规范，指标分为原子指标、计算指标和复合指标，通过使用这 3 类指标支持业务的数据分析需求，业务未来新增指标也要按照这个标准分类。
- **指标的管理规范化**：我们与商业分析团队一起梳理业务指标逻辑标准和录入流程，通过制定指标的新增和变更规范 SOP，解决由指标管理流程引起的质量问题，使得指标定义、系统录入、指标认证和使用各个环节都有严格的流程管控，经由业务侧数据产品经理、业务侧数据治数据管理员和数据工程师共同审批，确保标准规范的落地执行。

指标管理系统化

物理数据表管理：数据表管理的信息主要包括表的基础元数据信息、表类型（维表或事实表）、表的推荐度、描述信息和样例数据等。数据表管理主要是面向数据开发同学，通过维护数据表信息，为数据模型和指标管理提供数据基础支持。

数据模型管理：是对物理数据表的模型构建，通过一个物理模型可以查询到指标和相关的维度数据。数据模型可以是星型模型或宽表，星型模型中维护多个数据表的关联方式、关联字段、维度表包含字段和模型的 ER 图等信息。

指标管理：主要包括 2 部分的内容，指标的业务信息和技术信息。

- **业务信息**：为了保障业务的指标信息准确且统一，指标的业务信息需要数据产品经理与商业分析团队讨论确定后录入，录入后需要指标所属数据主题的负责人审批后才能上线。
- **技术信息**：技术信息主要包括指标对应的物理模型以及指标的计算逻辑，技术信息的填写需要数据工程师配置。技术信息配置后会在系统里生成技术元数据，指标管理系统通过技术元数据生成数据查询语句，提供给下游应用。

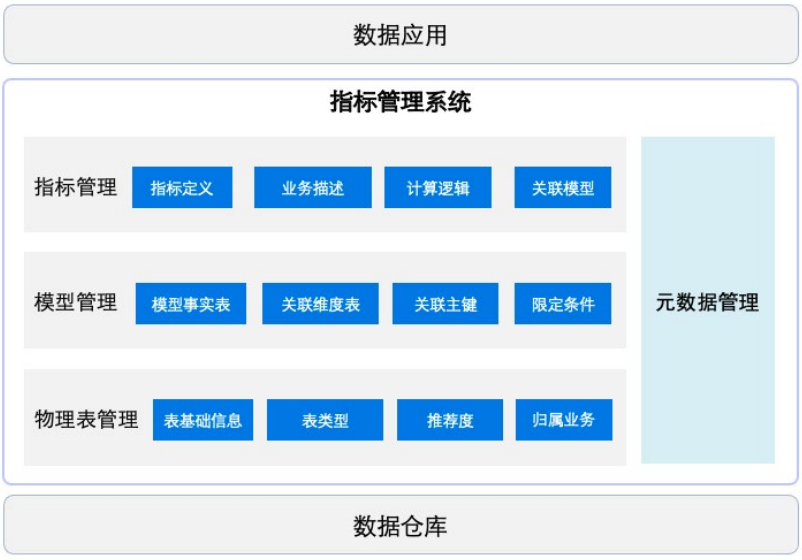

指标查询智能化

在指标管理系统中创建指标时，我们系统化管理了指标与数仓物理模型的关联关系和取数逻辑，通过数据物理模型获得指标对应的字段和可以关联的维度，以此把指标解析为数据查询 SQL 语句，通过数据查询引擎执行生产的 SQL，智能化获得指标数据。

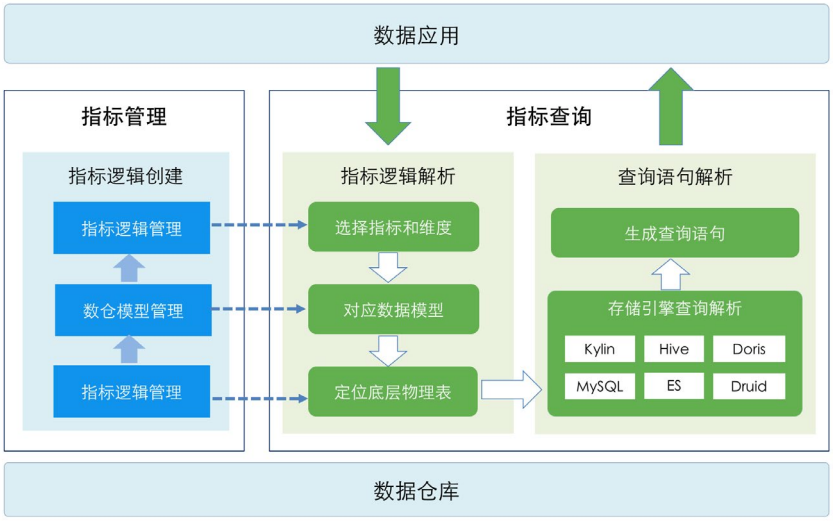

在查询解析过程中，经常出现指标绑定了多个底层数据表的情况，此时需要我们手动

的选一个物理模型作为指标生产的底层数据。但问题是，如果一个指标对应的模型太多，每次解析都需要手动指定，研发人员不确定选择哪个模型的性能最好。另外，随着物理模型的增多，大量旧的指标配置的关联模型不是最优解，就需要手动优化更改。为了解决这个问题，指标管理系统增加了智能解析模块，在选择智能模式查询时，系统会根据指标管理模型的数据量、存储性能和查询次数等信息自动选取最优的物理模型。

3.1.3 统一数据服务（One Service）

数据仓库对外提供数据的需求越来越多，除了管理层、分析师和产品运营同学使用数据产品和报表外，数据还需要提供到各个业务系统中使用。常用的提供数据的方式主要包括同步数据表、提供 SQL 和为下游服务开发定制化 API 接口等方式，但存在以下几个方面的问题：

- 数据一致性无法保障，当数据指标逻辑更改时，业务系统不能及时调整，导致不同业务系统的数据不一致。
- 数据同步到业务系统后，我们就无法管控数据的使用方式，也不能监控到数据是否被其他下游使用的情况。
- 数据开发效率比较低，数据服务稳定性比较差，数据工程师开发一个定制化 API 接口需要几天时间，各个接口服务单独维护，服务稳定性也比较差。

从 2018 年开始，数据 BP 中心与分析系统中心合作建设了统一数据 API 服务平台（Buffalo），通过开发可配置的数据接口服务平台实现数据对外的灵活提供，并实现对数据服务的下游使用及性能的可监控。统一的数据服务平台解决了几个比较关键的问题：

- **数据逻辑统一收口**：数据服务接口和数据逻辑解耦，当数仓更改和数据指标逻辑变更后下游无感知。
- **数据服务的更好管控**：研发同学能够了解到数据被哪些下游使用、调用了多少次和数据服务是否稳定等信息。
- **开发效率大幅提升，服务稳定性大幅提高**：通过统一服务平台可以在 1 小时内

完成一个接口的配置化开发，与此同时，接口稳定性统一运维，服务稳定性有了很好的保障。

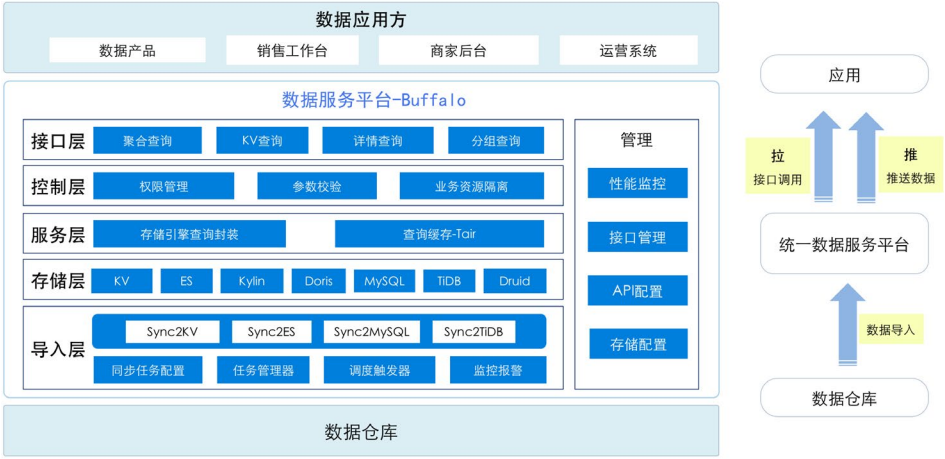

3.1.4 统一用户产品入口（One Portal）

如果不加控制，数据产品就会建设得越来越多。酒旅业务在 2018 年有超过 10 个数据相关产品的入口，用户很难快速地找到自己想要查的数据产品和报表。不同产品面对的用户不一样，数据的使用场景和展示方式也各不相同，业务方在使用数据时不知道从哪里能看到最全面的数据产品。

此外，也存在因为适用场景不一样，导致面向不同用户的数据逻辑不同的情况，比如某些业务同学查看的 GMV 不包含民宿数据，但是商业分析团队要看的 GMV 是包含民宿数据的。为了能够让业务方能够在一个数据产品门户中找到更全面的数据，且这个产品门户中多个产品的数据逻辑是一致的，我们将数据门户按照使用用户和应用场景划分为 3 类：

- 决策分析使用“大圣”（美团内部的数据平台），面向管理者和商业分析团队，所有业务管理者和商业分析团队成员需要的数据都可以从大圣数据产品里查看。
- 业务数据查询使用“天狼”（美团内部的数据平台），用户主要是销售，在天狼里能查看销售所需的各种数据。
- 数据资产信息查询使用“大禹”（美团内部的数据平台），用户是研发人员和检

索数据信息的业务方，在大禹数据门户里可以找到数据资产的信息，能更快地找到想要的数据，更全面地了解相关的元数据。

3.1.5 整体系统架构

整体的技术架构分为三层，从统一数据建模到统一指标逻辑、统一数据服务和统一产品入口，整体保障了数据的质量，同时配合数据管理的组织保障体系和流程规范，将整体数据质量相关的架构搭建起来。

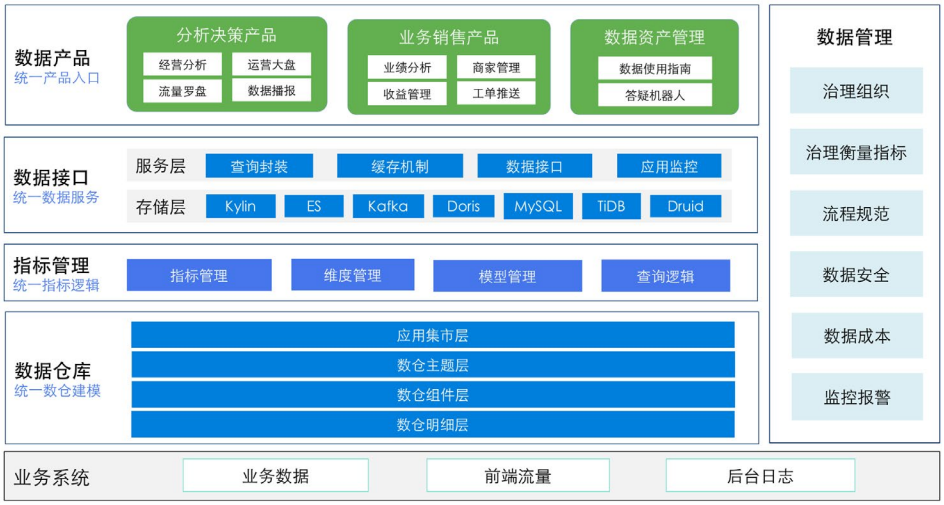

3.2 数据运营效率

数据工程师在日常工作中的主要工作包括两大部分：数据开发和数据运营。我们在前面介绍了通过数据开发和指标管理相关的工具系统建设，开发效率得到了大幅提升。

而数据运营是另一大类工作，他们的主要时间投入在数据使用咨询和数据问题答疑，大概占数据工程师日常工作 5% ~ 10% 的时间。

数据工程师日常投入到运营的人力多的主要原因是信息不对称和信息检索能力弱，数据团队建设了很多数据模型和数据产品，但是用户不知道怎么快速地找到和使用这些数据，问题主要体现在下面 3 个方面：

- **找数难**：所需要的数据有没有？在哪里能找到？
- **看不懂**：数据仓库是以数据表和报表等方式提供，数据的逻辑和含义不够清晰易懂。
- **不会用**：数据指标的查询逻辑是什么？多个表怎么关联使用？

3.2.1 方案思路

数据团队通过数据资产信息的系统化的方式建设易用的数据检索产品，帮助用户更快捷、更方便地找到数据，并指导用户正确地使用数据，提高数据信息的易用性，以此减少数据工程师的数据答疑和运维时间。实现策略是通过用户的问题分类，通过数据信息系统化的方式分类解答 80% 的问题，最后少量的问题透传到研发人员再进行人工答疑。系统化方式主要分两层，数据使用智能和数据答疑机器人。

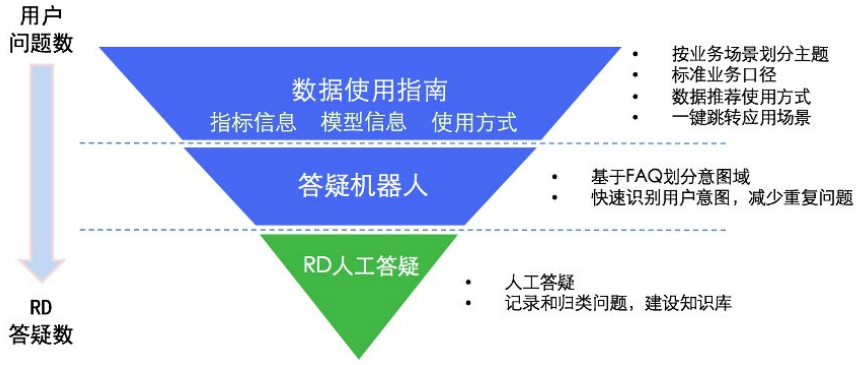

3.2.2 数据使用指南系统

数据使用指南的定位是业务数据信息的知识白皮书，提供最新、最全、最准确的指标口径、项目指标体系、数据表用法等信息，以简洁、流畅的操作支持数据指南中的内

容及时更新，降低业务方的数据答疑和数据使用成本。

数据使用指南通过把业务场景和数据使用场景打通，从业务场景分析到使用到的数据表、指标和数据产品打通，在系统中能够快速找到数据表、指标定义、数据查询SQL、指标所在数据产品等信息，一站式解决数据查找、使用和分析的全部场景。主要功能包括指标信息和数据表信息及使用。

- **指标信息**：包括业务分类指标和指标的详细信息，在指标详细信息页面可以查看指标定义、指标使用场景、指标统计维度、指标对应数据表、指标所在数据产品和指标的 SQL 查询示例等信息，把指标信息与数据表和数据产品关联，方便用户快速根据指标信息查找到数据。
- **数据表信息及使用方式**：包括数据表的基础信息、表的使用推荐度、SQL 查询样例、数据更新时间和数据就绪时间等信息，帮助使用者快速定位需要的数据表和数据 SQL 的查询使用。

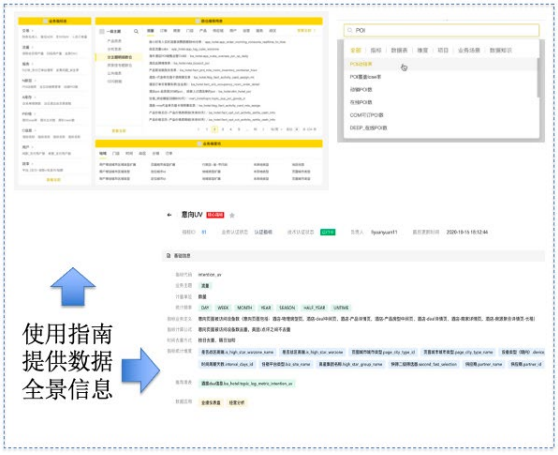

3.2.3 数据答疑机器人

用户在使用数据时，经常咨询数据工程师一些问题，比如想找的数据在哪个表？指标怎么取？业务系统的一个字段怎么在数仓里面取到？很多问题会被重复问到，每次解答都需要研发人员花费一定的时间，而通过 Wiki 的方式维护效果较差，于是我们考虑用自动化答疑的方式，把数据工程师在日常答疑过程中积累问题和答案，通过一定

的规则匹配，当再次被问到时系统可以自动地给出解答。

使用日常答疑中积累的咨询问题和答案作为基础答疑知识库，数据答疑机器人使用美团 AI 平台的摩西机器人搭建，配合问题答疑的策略，实现对历史已有问题和答案通过搜索匹配后发送给用户，具体实现方式如下：

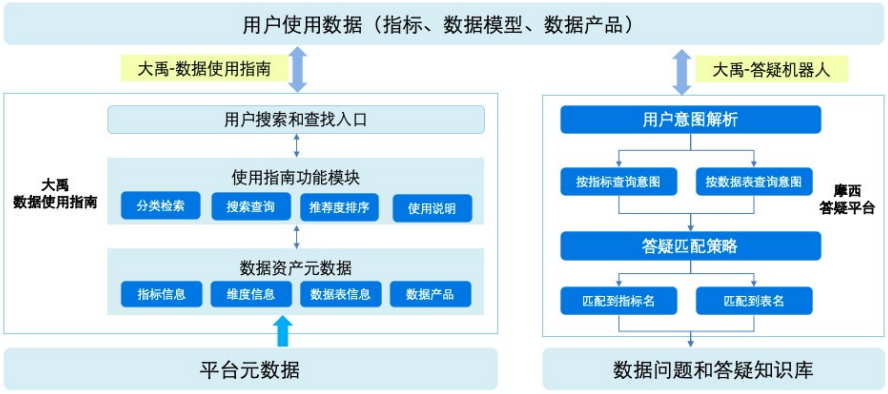

3.3 数据成本

大数据的主要成本构成有 3 大部分，计算资源、存储资源和日志采集资源，其中计算资源和存储占总成本超过 90%，我们的数据成本治理主要是针对大数据计算和存储这两个部分。

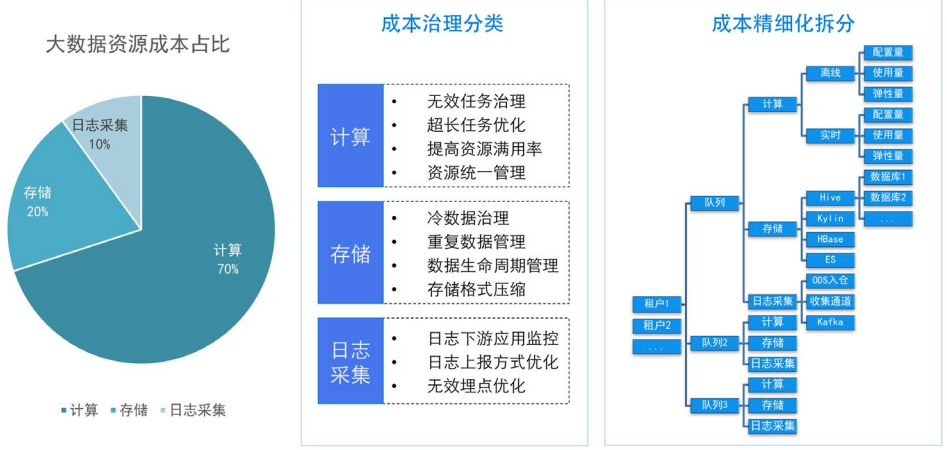

大数据成本优化方案

- 计算资源
  - 无效任务清理，通过任务生产出来数据的使用情况判断是否为无效任务，通过下线无效任务，减少任务执行使用的计算资源。
  - 超长任务优化，经过任务的计算资源使用数据可以发现，某几个大任务在执行时会占用大部分的计算资源，导致其他任务执行时间变长，或者占用配置外的弹性计算资源，导致计算成本增加。数据组会统计和监控每天任务的执行情况，发现执行时间长（超过 2 个小时）或者占用资源多的任务会及时进行优化。
  - 分散利用计算资源，数仓的夜间批处理任务使用计算资源的实际一般都集中在早晨 2 点到上午 10 点前，这就导致在一天中只有三分之一的资源被充分利用，而且这段时间内通常资源都是不够用的，需要使用平台提供的配置外弹性资源。而其他时间段的计算资源闲置，对资源有较大的浪费。为了把全天的资源都有效地利用起来，我们会把一些对就绪时间不敏感的任务（比如算法挖掘、用户标签、数据回刷等）放到 10 点之后，把配置的计算资源充分利用起来。
  - 租户拆分和整合统一管理，提高资源池总量和资源总体的使用率。
- 存储资源
  - 数仓架构优化和重构：通过统一数仓建模规范，把相似或相同模型进行整合和去重，确保每个主题数据只保留一份。
  - 数据存储压缩：在数据仓库建设初期，很多 Hive 表的存储格式是 txt，通过压缩为 ORC 格式可以减少大量的存储空间。
  - 冷数据处理：把数据分为冷、热两大类数据，通过每天对全部数仓表扫描识别出冷数据，发给数据负责人及时处理。
  - 数据生命周期控制：按照数仓分层的应用场景配置数据的生命周期，明细数仓层保留的全部历史数据，主题层保留 5 年数据，应用层保留 1 ~ 3 年数据。通过数据生命周期控制，极大地减少了数据存储成本。

- 日志采集资源
  - 下线冷数据的上游日志数据收集任务，数据收集费用主要来自两类数据，业务系统数据库的 Log 同步和后台日志数据收集，通过对收集数据的使用情况监控，及时下线下游无应用的数据收集任务。

3.4 数据安全

数据资产对业务来说既是价值，也是风险。数据安全作为业务部门“事关生死”的核心工作，在技术架构上会从数据产生到数据应用各个环节进行控制，保障数据应用事前有控制、事中有监控和事后有审计。数据安全控制从业务系统开始对用户高敏感数据加密，在数仓进行分级和脱敏，在应用层做密文数据权限和密钥权限的双重保障，管控用户相关的高敏感数据，按照三层系统控制加五个使用原则实现如下：

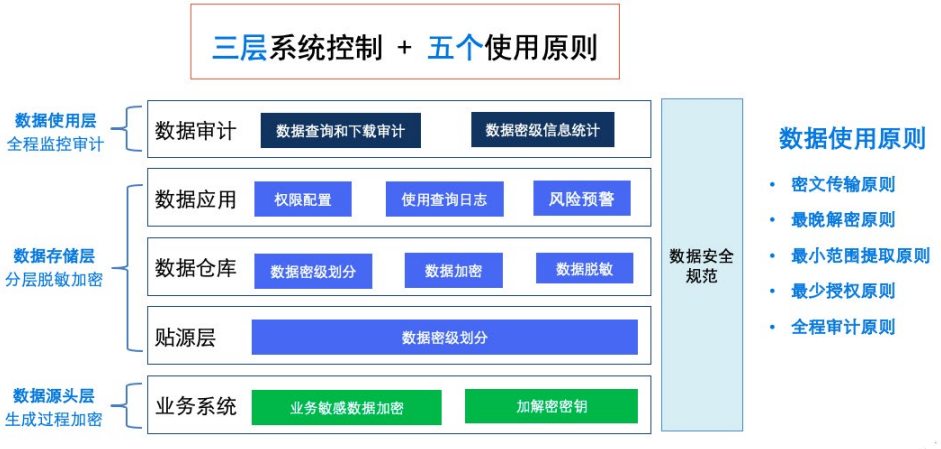

4. 衡量指标

业务部门在业务发展初级就会建立指标体系，并使用数据指标对各个业务过程做精细化的分析，衡量业务目标的达成情况和行动的执行程度。数据治理也需要一套成熟稳定的衡量指标体系，对数据体系做到长期、稳定和可量化的衡量。我们通过制定体系化的数据衡量指标体系，来及时监测数据治理过程中哪些部分做的好，哪些部分还有问题。

4.1 衡量指标建设

为了能够不重不漏地把指标都建立起来，我们从 2 个方面进行考虑：

- 技术分类，按照数据团队关注的问题和目标，把数据治理的指标体系分成质量、成本、安全、易用性和效率这 5 大类。
- 数据流环节，分别从数据的采集、生产、存储、指标管理、应用和销毁等环节监控关注的指标。

4.2 衡量指标保障数据治理

根据 PDCA 原则，将数据治理作为日常的运营项目做起来，底层依赖数据指标体系进行监控，之上从发现问题到提出优化方案，然后跟进处理，再到日常监控，构成一个完整的循环。

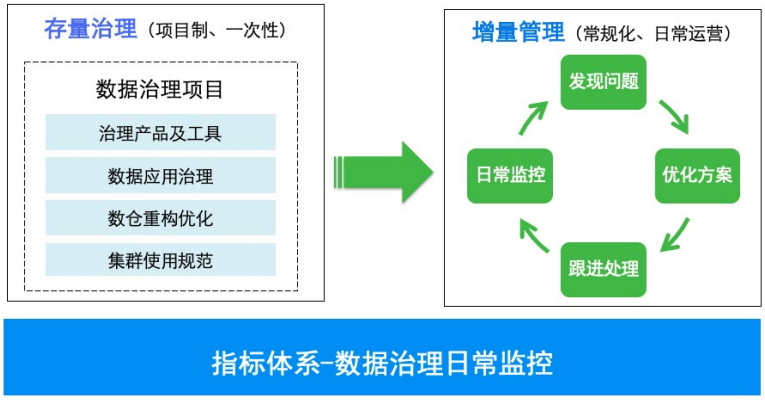

5. 治理效果总结

数据治理覆盖了数据生命周期全链路，通过围绕数据从产生到价值消亡全部生命周期，建立数据治理组织、制定治理衡量体系和建设治理技术系统来达到数据治理目标。经过体系化的数据治理，数据系统的治理、成本、安全和运营效率都有了比较大的改善。

- **数据质量**：技术架构优化后，通过标准化规范和系统保障数据的准确性，并在治理过程中清除和整合了历史冗余数据，数据质量问题有很大的改善。2019 年数据生产任务的增长率比 2018 年减少了 60% 左右。
- **数据成本**：经过数据成本优化后，在支持 2019 年酒旅业务高速增长的同时，大数据的单均成本费用降低了 40% 左右。
- **数据安全**：通过业务系统数据加密和数据仓库数据脱敏，双重保障高敏感数据安全，避免数据泄露。通过数据安全规范和数据敏感性的宣导，加强业务同学的数据安全意识，业务没有严重数据安全问题的发生。
- **运营效率**：运营工具化减少了研发同学超过 60% 的日常答疑时间，极大地减少了研发同学工作被打扰的次数，提高了开发效率。

三、未来规划

数据治理分为三个大阶段：被动治理、主动治理、自动治理。

- 第一阶段我们做的是**被动治理**，也就是阶段性治理，缺少统筹考虑，主要是基于单个问题的治理，而且治理之后过一段时间可能还要做重复治理。这个阶段更多是人治，一个项目成立，协调几个人按照项目制完成，没有体系规划，也没有组织保障。
- 第二阶段是**主动治理**，有长期的统筹规划，能覆盖到数据生命周期的各个链路，在治理过程中把一些手段和经验流程化、标准化、系统化，长期解决一些数据问题，让数据治理长期可控。
- 第三阶段是**自动治理**，也是智能治理，在长期规划和数据生命周期各环节链路确定好之后，把已经有的经验、流程和标准做成策略。一旦出现问题，自动监控，通过一些系统化的方式解决。自动治理的第一步还是治理方案的落地和策略化，这非常依赖于元数据，把数据治理各个过程中的一些经验技术都沉淀起来。做完策略沉淀之后做自动化，把策略用工具的方式实现，当系统发现数据有问题时，自动就去处理。

目前，美团酒旅业务数据治理处在第二阶段和第三阶段之间，虽然有整体治理计划、技术架构和组织保障，但仍需要投入一定的人力去做。未来，数据治理会继续朝着智能化的方向进行探索，真正把自动化治理工作做得更好。

四、作者简介

建舒，2015 年加入美团，数据科学与平台部数据工程师。
王磊，2017 年加入美团，数据科学与平台部数据工程师。
罗茜，2017 年加入美团，数据科学与平台部数据产品经理。

实践之后，我们来谈谈如何做好威胁建模

作者：李瑞

1. 写在前面

1.1 什么是威胁建模

> 孙子兵法：知彼知己，百战不殆；不知彼知己，一胜一负；不知彼不知己，每战必殆。
>
> 微软：威胁建模实践使开发团队可以在计划的运行环境的背景下，以结构化的方式思考、记录并讨论系统设计的安全影响。威胁建模是帮助保护系统、应用程序、网络和服务的有效方法。这是一种工程技术，用于识别潜在的威胁和建议，以帮助降低风险并在开发生命周期的早期实现安全目标。
>
> OWASP: identifying, communicating, and understanding threats and mitigations within the context of protecting something of value.

计算机发明后不久，人们就发现需要为这些信息系统处理威胁。早在 1994 年，NSA 和 DARPA 就提出了攻击树、威胁树等概念。1999 年微软内部发表了题为《The threats to our products》的文章，为定义 Windows 全系产品面临的安全威胁正式提出了 STRIDE 助记符。随着 2002 年比尔 · 盖茨著名的《可信任计算备忘录》宣言发布，微软承诺改善软件产品的安全性，随即正式在 SDL（安全开发生命周期）中采用了威胁建模。

威胁建模数十年来不断取得大家的认可，在业内也有 STRIDE、Trike、OCTAVE 等多种方法论实践。安全行业的从业人员普遍认识到，在研发团队的安全例行活动中，对于一些拥有重要数据资产、安全事件影响力大的系统除了要进行常规的渗透测试、黑白盒代码扫描之外，更应该系统地定期开展威胁建模活动并对业务赋能。

对美团安全团队来说，引入领先的安全技术设计能力，构建全方位、多维度智能防御

体系，是我们不懈追求的目标。美团有众多基础设施，核心业务系统也需要以成熟的方法论进行威胁评审。本文将着重分享威胁建模是如何帮助美团安全团队评估、发现大量安全设计的风险，以及在互联网企业，应该如何大范围地实施威胁建模并完整地进行落地。

1.2 威胁建模的价值

- **识别体系化的结构缺陷**：大多数安全问题是设计缺陷问题，而不是安全性错误。威胁建模能帮助识别这些设计缺陷，从而减少风险敞口，指导安全测试，并降低因安全漏洞而造成的品牌损害或财务损失等可能性。
- **节约组织安全成本**：通过对威胁进行建模，并在设计阶段建立安全性需求，降低安全设计缺陷导致的修复成本。在需求管理和威胁分析阶段，与业务开发团队高效互动，释放安全团队的专业能力，专注于高性价比的安全建设。
- **落地 DevSecOps 文化**：通过威胁建模跑通开发和安全工具的流程集成，把风险管理嵌入产品的完整生命周期，从而推动形成完整的 DevSecOps 工具链。
- **满足合规要求**：威胁建模是国际安全行业通用的方法论，通过向管理层和监管机构提供产品的风险管理活动的完整记录，帮助团队遵守全球法律法规要求，包括 PCI DSS、GDPR、HIPAA、CSA STAR 等。

1.3 遇到的挑战

普及威胁建模流程和技术可以有效提升企业的安全建设水平，作为互联网企业，要实施敏捷的软件开发流程，威胁建模活动也应尽量便捷，但实际工作起来并不简单，落地过程中也会遇到不少挑战。按优先级排序，挑战包括以下几个方面：

- 缺乏优秀的自动化建模工具；
- 安全团队没有时间和精力对每个应用都实施建模；
- 缺乏对威胁建模足够的了解，知识库涉及不同领域、专家经验难以共享；
- 建模活动、输出结果没有融入业务的敏捷研发流程；
- 简易的建模活动基于问卷或者表格记录分析，并没有实际的更新、积累和进一步分析。

2. 准备威胁建模

2.1 能力要求

在进行复杂的威胁分析时，并不是 SDL 一个团队就可以独立完成的，还需要数据安全、IT 安全、风控合规等安全团队协作，评审活动也涉及到内容、网络、隐私保护、法务、运维各个领域。各参与者最好提前建立对公司基础设施、安全分工的认知，相对清楚各个产品的作用、特点、接入办法、适用场景。**建议实施威胁建模的参与人员都了解有关产品的设计、接入文档材料，看不懂不用担心，多浏览几遍，逐步熟悉即可**。

对于实施威胁建模的负责人有四个层面的基本技术能力要求，包括：

- 懂常用的安全技术、安全机制、攻击方法、危害、加密算法；
- 懂业务、流程、内部技术服务、产品与产品之间、组件和组件之间的关系；
- 组织人员策略资源来推动项目实施；
- 将安全规划、安全流程、治理模型组合来符合纵深防御原则。

威胁评审，重点是评和审，对参与威胁评审的人员软实力要求，包括：

- 一定程度了解业务；
- 合格的文档编写能力；
- 有意识地优化企业体系结构中的研发安全流程；
- 有意愿传播安全能力，以支持增强安全团队话语能力。

2.2 评估流程

准备

实施威胁评估时，首先要取得业务团队负责人的认同：不管有没有事件驱动，安全团队的参与都将为业务系统提供产品竞争力。哪怕现阶段安全并不能完全赋能给业务，但长期来看，威胁建模应该在业务技术迭代的每个环节都去自助实施。随着技术的积累，业务团队独立完成威胁技术安全分析是有可能的。

团队

参与团队以“Two-Pizza Teams”团队为最佳，建立工作团队后，按需引入相关人，以后这个工作组聚焦为业务提供安全能力。**保持沟通是构建产品安全的诀窍，实施威胁建模的效果深受团队如何组织和交流的影响**。

分工	角色	负责人	职责
谁负责（R = Responsible）		安全负责人	负责执行任务的角色，具体负责批准威胁模型，审视评估范围
谁批准（A = Accountable）		业务负责人	对任务负全责的角色，只有同意或签署之后，项目才能得以进行
谁支持（S = Support）	PMO	项目管理角色	负责安全项目进度进展和推进节奏
	业务团队	业务主要项目成员	主要负责与团队了解业务和设计原理，采取措施缓解威胁
	安全团队	各组件负责人+安全团队	推动业务方识别、解决相关风险
咨询谁（C = Consulted）		其他团队	在任务实施前或中提供指导性意见的人员，如蓝军、防御团队
告知谁（I = Informed）		项目开发、测试人员	及时被通知结果的人员，实施威胁的改善

周期

实施这项活动的整个周期除了解决风险的阶段稍长，从问卷调查到给出威胁评估报告，建议持续时间为 1 到 2 周；如时间太短，团队成员之间不能建立足够的信任，不能充分给出安全评估的结果；如时间太长，会忘记之前讨论的结果，耗费双方团队精力。威胁评估迭代的周期保持灵活，在人力充足的情况下以重大变更、功能模块迭代的数月、半年一轮为佳，人力不足的时候应尽量把评审过程由人力到工具化、自动化、服务化。

流程

安全架构评审的核心是威胁建模，详细参考可以参考《安全架构评审实战》一文。当然，传统的建模流程太重了，虽然尊重业务的设计过程很复杂，威胁分析也没有理由取巧走捷径，是改善安全必须付出的成本，但应尽量在复用现有流程的同时针对敏捷

开发做出适当精简——通过问卷简化核心安全要素的分析、通过组织流程优化沟通方式、通过融入研发流程快速闭环。总结出比较适合互联网企业的评估工作流程如下：

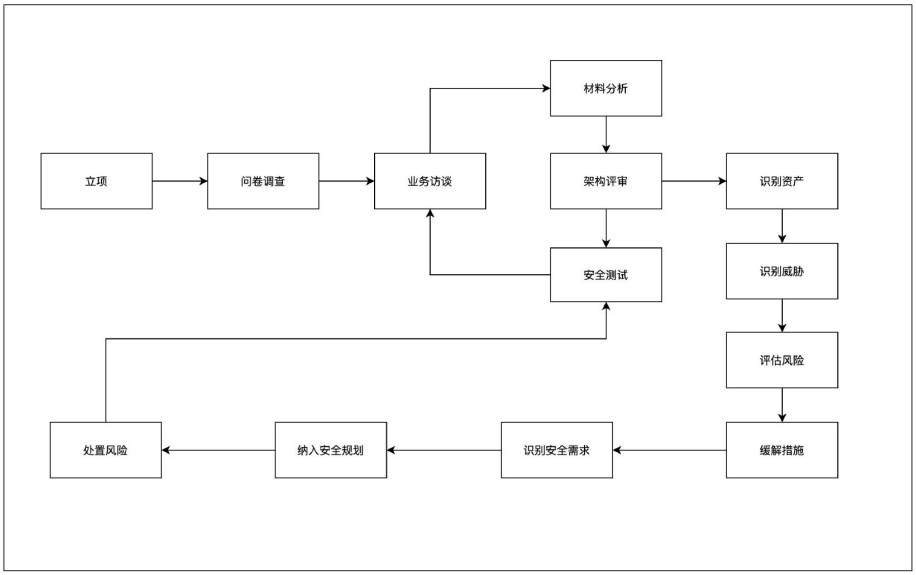

- **首先是立项，增量尽量都覆盖**。存量根据攻防优先级选择合适的重要系统开始评估，建议由业务方和安全一致的选择目标范围，一般建议从基础设施系统自下而上，从 IaaS/PaaS 层开始比较合理。因为基础设施的安全状况改进了，整个业务线都可以覆盖接入受益。评审不仅仅需要安全方面投入资源，也需要业务团队有人力参与问卷填写、项目介绍、多轮访谈、核对威胁、解决风险，需双方共同意识到：达成安全目标需要业务人员共同参与进来，安全和业务都很专业。双方建立的关系不应该是例行安全审计那样的“你问我答”，氛围可以尽量轻松。对齐发现的安全风险并不是哪个团队做得不好，而是认清事实，及时止损，发现风险、解决技术债务，交付和设计安全的代码也是开发的长期挑战，双方应着眼于改善产品未来的安全状况。
- **第二步问卷调查或文档填写的目的是收集必要的业务信息**。文档 / 问卷应精心设计，不要采用过于专业的术语，目的是扫除业务方知识盲点，建立对产品初步的安全现状认知。不清楚的问卷选项可以不填，填就尽量保证准确。**建立工**

作群后发出问卷调查要求，问卷是启动威胁建模项目的起点，业务方认真填写问卷是项目良好开展的前提。

- 同业务的访谈要反复进行多次，安全团队的风格要么过于强硬，要么容易脸皮薄，觉得和业务打交道要对方多次配合，不好意思打扰业务，这是错的，需要纠正。
  - 访谈由安全评审人主持，时间尽量控制在 40 分钟以内，人数最小是 4 人左右。第一次访谈可以从问卷的内容开始，就每一个问卷选项进行交流，确保业务正确理解问卷中提到的问题，确保问卷的填写结果是业务想要表达的意思，确保业务不清楚的、有分歧的可以通过讨论给出一致结论。问卷访谈时不用过于讨论技术细节、系统不足和实际修复方案，主要是了解业务的基本安全情况。访谈的第二个议题是邀请业务方对软件设计文档、架构图进行讲解。最后的总结 5 分钟左右，会后遗留三项 To Do：①填写应用信息收集表，包括技术文档地址、代码仓库地址、域名、CI\CD 发布项、技术栈、测试环境账户；②下一次沟通时间；③安全对接专人。
  - 第二次访谈之前，安全人员应多阅读业务方的文档、代码，进行适度的安全测试。这次访谈希望有业务方架构师、代码开发负责人参与，对于安全前期整理的所不理解的调用关系问题、现有的安全控制措施问题、流程细节、组件、认证方式等其他技术细节进行讨论，分歧点和讨论结果通过文档记录方便查阅。
  - 日常发现的疑问可以多次随时沟通，评审是一项“开卷考试”，很多黑白盒发现的安全风险无需花大精力执行安全测试，通过向业务方咨询就能得到确认。
  - 访谈的对象通过产品、架构设计、开发人员类型的不同视角可以发现业务自身的讹误，业务如有不清楚的地方或历史遗留问题，不用在这里卡壳，先弄懂能弄清楚的来逐步拼接“拼图”。
  - 最简单的威胁建模，就是关于威胁的“头脑风暴”而已。访谈的原则要把自己作为业务的 CISO，从产品安全负责人的角度考虑：这个产品卖出去，可

以提供什么安全能力？出现安全事故事前该怎么做？

- 开展架构评审中威胁建模的几个子过程，包括定义资产、识别威胁、评估风险、给出缓解措施等，将在下面的“实施威胁建模”章节详细展开说。
- 威胁建模的阶段性成果交付物会是不同形式，如安全白皮书、安全设计指导、威胁评估报告。业务团队可以从安全给出的长期修复方案和安全规划中获益。最终报告最好有安全团队内部双人复核机制，不同安全专家视角里对威胁的理解是不一样的，双人复核的另一个好处是可以减少工作量，比如分工区分 A- 管理端、B-Agent、A- 代码、B- 设计实现或者 A- 评审、B- 复查分工。给出威胁建模结果前一定要同业务团队再次沟通，确认哪些风险是安全视角被错误理解的，哪些是已经在业务视野中，哪些是业务团队认知不到位的。修复方案要区分接受、缓解、转移、处理风险四种情况。沟通时对应报告每个威胁项要求业务方给出明确的排期。短期可以走安全工单，长期纳入业务的规划排期中，识别出的共性安全问题作为安全专项制定孵化相应的安全工具和项目，补全安全建设的蓝图。
- **发现风险总是容易，解决风险才是这项工作的价值**。减缓发现的威胁可能需要业务重新设计，需要排除万难达成目标，不然评审过的系统带来的虚假安全感，还不如没有安全感。一个有趣的现状是解决威胁时对于安全团队是业务在修复漏洞，对于业务是在满足安全团队提出安全需求。安全团队以往的视角总是急迫希望业务立即去修复，其实大可不必着急，不妨就按照安全需求去沟通。评审发现的问题不少是架构和设计方面的问题，比如认证、鉴权、数据安全方面，需要业务方进行大的设计变更，要建设对应的公共基础服务，要理解业务（反正风险已经存在很长时间了，敬畏业务的修复成本，尊重技术客观规律），只要能解决问题即可。好的修复方案一定是考虑性价比的，而且可行性大于必要性，每个团队的资源都不是无限的，按照处理的优先级进行排序工作。对识别出暂时不能解决的问题可以做出对应的监控、审计手段，如果要介入培训此时也是好的阶段，优秀的工程师总是想掌握到不同的知识，培训不是被动地聚在一起讲 PPT，而是互动交流，建立安全文化的积极性。

- 在业务方确定处置风险完毕后，安全团队复查修复是否完成，修复是否引入新的问题，业务方是否对方案理解到位。这个过程要和业务团队保持互动，安全评审并不是单纯安全测试，而是指导安全能力的提升，结束时可以给业务积极的反馈，保持健康的安全文化。
- 威胁评估的活动最好定期重复进行。安全防护为什么要与时俱进？第一，随着制度法规的完善，对业务的安全性提出更高的要求；第二，企业安全基础设施能力不断提升，可为业务提供的公共安全能力不断增强；第三，业务系统可能随着时间的变化，安全现状有质的改变，随着信息系统所承载的业务完善或稳定，业务有取消合并的迭代。

3. 实施威胁建模

绘制数据流图，识别定义威胁、处置威胁、验证风险得到正确处理是威胁建模的四个常用步骤。

3.1 数据流关系图都不准确，尽量有用而已

为什么我们需要建模？因为实施威胁建模时往往系统并未完整构建，模型会帮助思考系统的设计，以攻击者和防守方的方式思考对应的安全威胁。

经过初步问卷和访谈后，安全团队也收集到大量业务反馈的信息，产品和应用安全团队聚在一起讨论软件架构和潜在的安全问题。使用威胁建模工具、审查数据流图、威胁模型的目标都是为了达成更充分讨论的目的而服务。建议安全团队基于业务的流程图、调用关系同业务一起绘制 DFD 数据流图。一般常见的数据流形式有：①白板上作为会议随堂讨论的示意图，辅助提高沟通效率，一般用于说明系统层级架构；②业务现有文档中的时序图、UML 图辅助理解复杂问题和技术细节。

画系统架构的目标是解决利益相关者的关注点，业务实现安全功能，安全实现安全设计。大家普遍反映实施威胁建模时都在画架构图时遇到最大的困难，纠结于用什么工具。在绘制 DFD 图的工具选择上：

- 微软的 Microsoft Threat Modeling Tool 工具的优点是，适合初学者接触熟

悉了解外部实体、数据流、过程、存储、信任边界的基本概念，缺点是除了 Windows 应用程序和 Azure 示例之外没有合适的威胁模板。

- OWASP Threat Dragon 的优点是表达方式更丰富，但是不能支持动态拖拽和自动导出威胁列表。大家没有必要将整理数据流图视为困难，实战中威胁建模能力只能通过多练习、反复挑战的方法熟悉技能。

回过头看早期的一些对威胁模型的判断往往不准确的，没有关系，毕竟你曾经“实施”过威胁建模了。绘制数据流的过程可以理解业务、确保安全视角没有遗漏。威胁建模完全自动化基本是伪需求，没有足够多的业务产品需要持续进行建模评审、大量的原始信息来自于文档、架构师的经验、场景和知识极其复杂。建议尽快上手可以使用系统自带的流程图，使用 Visio 和 Draw.io 最方便。

元素	表示	含义	示例	注意事项
外部实体	方块	外部的引入	Web请求、用户、字符输入	通过标签写清系统名称、简介；从左往右，从下到上
进程	圆形	处理的进行	软件进程、SSO系统、一个微服务、客户端、供应商、可执行文件	为了简化可以用双环圈合并表示多个进程；同一层级进程所表示的维度一致
数据存储	两条平行线	存储相关	对象存储、kv数据库、块存储、注册表	本地配置文件往往是容易忽略的存储元素；存储背后的管理系统不能忽略；Kafka、HBase、p2p等系统难以归类可灵活使用；通过不同的颜色区分要保护的级别
数据流	带有箭头的曲线	数据流向交互	gRPC请求、网络连接、JDBC、人脸识别动作、函数调用	数据流可单向表示，并不一定要求要双向箭头；数据流要表明使用的技术和交互的内容；通过编号表示数据流向顺序
信任边界	虚线	信任边界	网络划分、进程隔离、VPN连接	数据流经过信任边界；可以存在多个层级的信任边界

数据流的细粒度也难以抉择，谨慎地选择信息的层级和粒度并不是一件容易的事情，初学者刚开始的时候总是觉得每个功能都得拆分，每个功能都要求加密，灵活程度取舍于所使用的架构模型、架构师的经验和系统的复杂度。根据笔者的经验，一种 C4 Model 结合微软威胁模型图例的方法容易取得合作方业务架构师的认同，以下给大家

做个简单的示例。

系统上下文图（System Context Diagram）

> 在这一层级中细节并不重要，只显示系统概况。 重点应该放在人员（角色）和软件系统上，而不是技术，协议和其他低层级细节上，从而使非技术人员也能够看得懂。这个图也是明确需求的重要图示。这表示一个应用和其他系统的下辖有调用关系。不需要完整表示数据的流向，只要大致描述清楚系统的周边关系，不遗漏关键步骤。

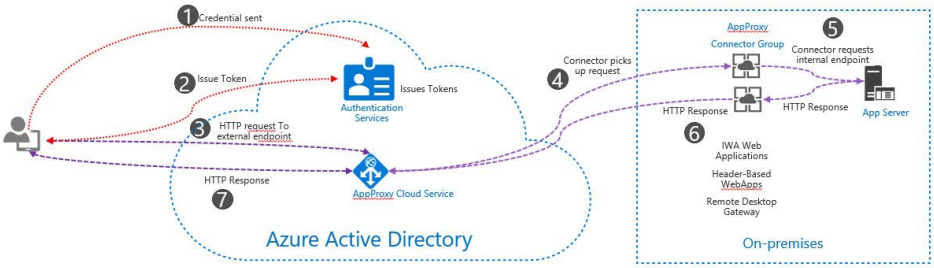

上述这个层级的示范是微软 Azure 的威胁建模的数据流图，优点是通过数字表示了流程顺序。

应用图（Application Diagram）

> 应用是可单独运行 / 可部署的单元（例如，单独的进程空间）执行代码或存储数据。应用图显示了软件体系结构的高层结构以及如何分配职责。它还显示了主要的技术选择以及容器之间的通信方式。

一个应用包含多个服务，如果一个系统有多个子系统，应该对每个子系统都进行分析。通过威胁建模应该尝试了解整体情况，包含应用本身、数据库、交互、部署场景、云服务、接入的基础服务。下图是模拟一个支付应用的示例。

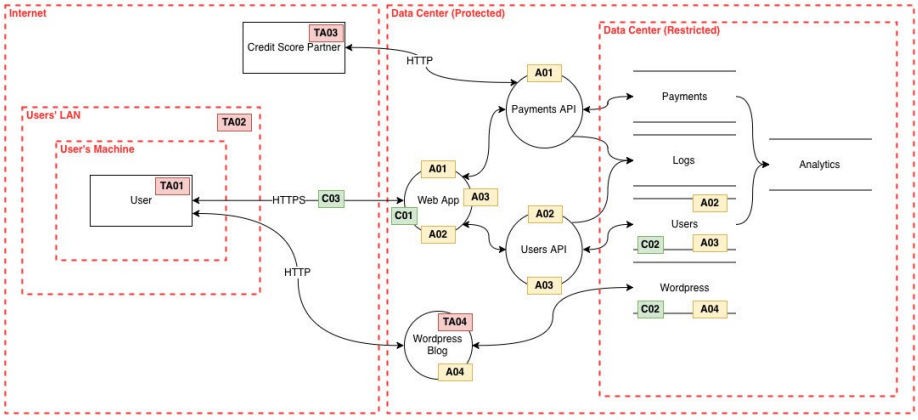

Assets	
ID	Description
A01	Credit card data
A02	User PII
A03	User credentials
A04	Blog administrator credentials

Security Controls	
ID	Description
C01	Authentication
C02	Password hashing
C03	TLS

Threat Actors	
ID	Description
TA01	Malicious user
TA02	LAN Man-In-The-Middle
TA03	Malicious/compromised credit score partner
TA04	Compromised Wordpress blog

服务图（Service Component diagram）

服务图显示了服务如何由多个“组件”组成，每个组件是什么，它们的职责以及技术 / 实现接口（API）或者细节。这个细粒度的分解是建模最大的工作量，为分解的各个通用组件创建的威胁模型结果可以复用在其他应用上。比如 Kubernetes 被分为 Kube-Proxy、ETCD、Kubelet、Kube-APIServer、Scheduler、Container、Pods 等。

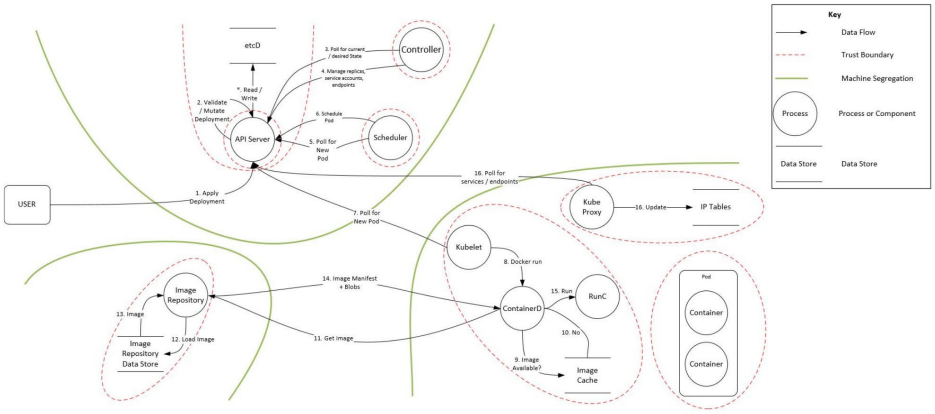

代码层级

这一层是可选的，可以使用 UML 类图、实体关系图、函数调用关系或类似的图。对于分析特定代码层级的漏洞很方便。推荐使用白盒扫描工具、IntelliJ IDEA 的依赖矩阵、Diagrams、Flow 插件进行分析。

数据流图这项技术本身存在的不足是：关注组件的交付是还是相对偏数据流动视角，不少人的交互场景如钓鱼、敏感功能误操作不能表示出来；不能完全遍历出程序的全部功能（除非图足够复杂）；基于程序设计图之上绘制却又丢失了设计细节，无法自动化；数据流会额外显示出基础设施引起的风险，并不仅仅是业务自身的安全。

3.2 识别威胁是互动过程

威胁建模是一种协作行为，一类结构化的思维方式，一项实践的科学。以软件程序为中心的威胁建模、枚举威胁、解决威胁、验证来解决四个问题：具体业务是什么？哪些地方可能出现风险？如何规避解决？是否覆盖完整。

所以识别威胁的第一步是灵活定义攻击者的目标，组织要保护的资产和信任级别，如：S3 存储、源代码、主机、数据库、凭据、行级数据，知识产权等。公有云、私有云不同的责任共担模型就清晰给出了不同的业务需要关注哪些资产的示例，云上资产的建模更关注安全的信任边界。

第二步给出明确的攻击路径，定义攻击者：比如恶意内部员工、外部攻击者，竞争对手、好奇者等，攻击路径的抉择直接影响攻击面和信任边界的划定。

第三步即威胁评估的过程不能缺少架构分类思维。一般使用 ASTRIDE（隐私、欺骗、篡改、信息泄露、否认性、拒绝服务和特权提升）和攻击树模型作为常用的威胁建模技术指导原则。

| ASTRIDE（Advanced STRIDE ）

微软已经不再维护 STRIDE，采用 ASTRIDE 更符合面向消费者的网络安全行业的发展。

威胁	安全属性	定义	举例
隐私（Privacy）	隐私保护	用户信息防护	用户隐私被查阅
仿冒（Spooling）	认证	冒充人或物	冒充其他用户、服务账号
篡改（Tampering）	完整性	修改数据或代码	修改存储的信息
抵赖（Repudiation）	审计	不承认做过某行为	日志、审计
信息泄露（Information Disclosure）	保密性	信息被泄露或窃取	数据库信息被泄露
拒绝服务（Dos）	可用性	消耗资源、服务可不用	高危操作导致不可用
权限提升（Elevation of privilege）	授权	未经授权获取、提升权限	普通用户提升到管理员

将系统分解为相关的组件，分析每个组件对应的威胁。有个技巧是从外部实体逐次开始，关注有交互的进程，没有交互的进程一般没有威胁。

元素	P(rivacy)	S	T	R	I	D	E
外部实体		✔		✔			
进程	✔	✔	✔	✔	✔	✔	✔
数据存储	✔		✔	✔	✔	✔	
数据流	✔		✔		✔	✔	

上图中，数据存储仅是保存日志信息时才有抵赖的威胁。

分析威胁模型和业务互动时，按照上面的两张表考虑每个元素对应的威胁，实施时要对照进行思考当做 Checklist 来分类。ASTRIDE 是帮助认识归类威胁的工具，而不是分类定义，某些威胁比如没有启用 HTTPS，从中间人攻击的角度分析实际的风险既是数据泄露，也属于篡改、隐私分类，有的威胁如 IoT 设备的爆炸、丢失不属于以上任一分类，没有必要强行去分类，反正已经发现记录威胁了。另外，信任边界很重要，安全本质是信任问题，攻击面的定义直接影响威胁的划分。

几个安全概念的区别

- 威胁是应用潜在存在的安全弱点。

- 漏洞是对威胁的利用，产品实现了预期之前的功能，影响了安全性。
- Bug 是未实现的功能。
- 风险是发生的，对资产有危害的可能性。
- 风险 = (威胁 + 漏洞) * 可能性。

举个例子：存在新冠肺炎病毒是“威胁”，没带口罩是“漏洞”，存在感染病毒可能是“风险”，人体不能解决病毒是“Bug”，主动免疫是安全需求。

对于威胁的判断来源，可以参考：

- 业界同类产品的安全白皮书，如各家公有云的材料相对比较全，要思考这些同类产品都有哪些安全功能，有没有安全需求，能不能实现。
- 通过内部工单系统搜索该部门名下的历史漏洞：经常一个产品历史出现过越权漏洞，是因为整个产品都没有鉴权；一个接口不符合编码规范，同一份代码的另一个接口出现安全问题的风险高。
- 开源产品的安全设计方案，历史漏洞。
- 专利、论文、行业知识库，对于新的技术的如人脸识别、机器学习、大数据业务这方面的材料很宝贵。

以上举个简单的例子，场景是租户通过第三方开放平台登录后通过微服务处理业务。

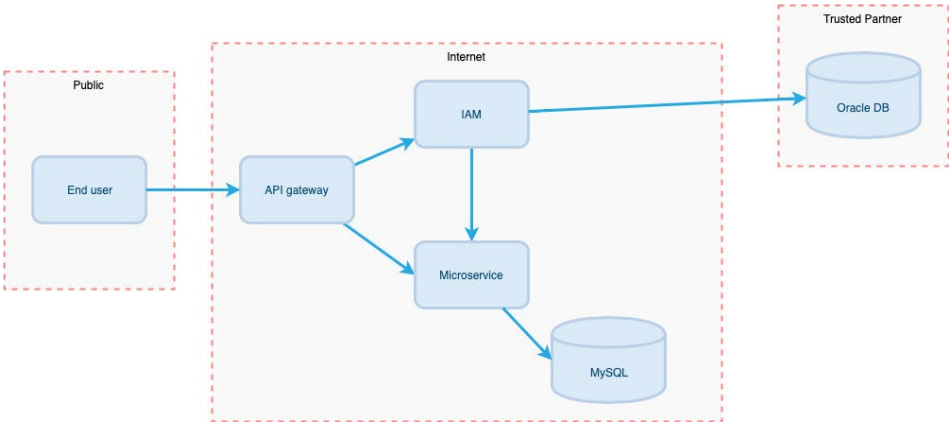

对于 API 网关，存在的威胁包括：

- 认证和授权
  - 未强制 HTTPS
  - 缺失二次认证措施
- 日志和监控
  - 缺失日志记录和审计模块
  - 日志本地留存

对于 IAM 服务服务器，存在的威胁包括：

- 信息泄露：用户身份信息泄露
- 认证
  - 暴力破解对外发送的管理平台 Token
  - 授权策略绕过
- 可用性
  - 单机实例，误操作可导致宕机风险

对于 MySQL 服务，部分存在的威胁包括：

- 认证：攻击者获取凭据后可以直接访问、修改、删除业务数据
- 权限提升：攻击者可以从普通用户提升至 Root，获取数据库完全控制权限
- 信息泄露：SQL 注入导致所保存的业务数据泄露

评估风险结果没有列出来有些是自动认可忽略的，有些是放在基线等安全控制措施，大多数的威胁发现都是基于参与者的经验，可以从安全最佳实践、加固指导、历史案例形成知识库积累下来。具体实施的过程目前没有完全的自动化工具，但是检测项一般有共识：比如从域名系统查看是否启用强制 HTTPS、S3 对象存储查看是否启用服务器端加密、硬编码问题、是否加入 FIDO 等。

虽然威胁建模的一个要点是避免关注漏洞而不是威胁，但基本没有一个系统是从零搭建的。新的项目也会大量引入框架、组件、第三方服务，适当的安全测试是必要，原

则是聚焦发现设计方面高层次的风险，但如果参与人员具备一些实际攻防能力，可以将其他安全工具发现的问题纳入一起解决，百利而无一害，本身建模的一个目标就是指导安全测试的方向。测试时要注意常见的攻防案例是影响机密性，也要考虑攻击者破坏应用的可用性和完整性。

| 攻击树模型

安全专家大都熟悉实战中通过哪些攻击手段可以损害资产。很多网络上的渗透测试报告就是以攻击链路形成的思维导图为例，可以据此细化出一个产品的攻击树。攻击树模型有两种方法：自下而上和 Use Case 型。前者是全部覆盖到实现目标的入口，后者基于前者的细节，在确定攻击的前提下展示出实际的攻击，涉及大量用例的、业务逻辑复杂的、有交互过程的、系统已经设计完成的，通过攻击树很容易发现安全威胁。攻击树模型一般遵循以下的定义图例：

元素	表示	含义	示例	注意事项
且	圆角梯形	条件“且”	自然人身份、手机号、macOS、AppleScript、账户	一般“且”的最下层是信息探测
或	三角形	条件“或”	恶意配置文件、网络请求、密钥、特权用户	目标可能是或的一个节点
节点	圆角方块	条件因素	执行RCE操作、查找未授权漏洞	节点存在是为了匹配“或”的逻辑
目标	上述图案的蓝色	目标	持久化、命令执行、领红包优惠、获取密码、拒绝服务	子节点是必须满足的条件才能使父节点为真，根节点是攻击的总体目标

通过下面举个例子，攻击者尝试持久化在 Kubernetes 集群内部执行命令，可以通过部署恶意镜像、容器内执行命令、提权控制宿主机多种方法。在部署恶意镜像这一步，自下而上浏览首先要具备访问 Kubernetes API 权限的认证信息或 Kubelet 工具的凭据，然后必须有镜像仓库操作写的权限，然后部署恶意镜像。

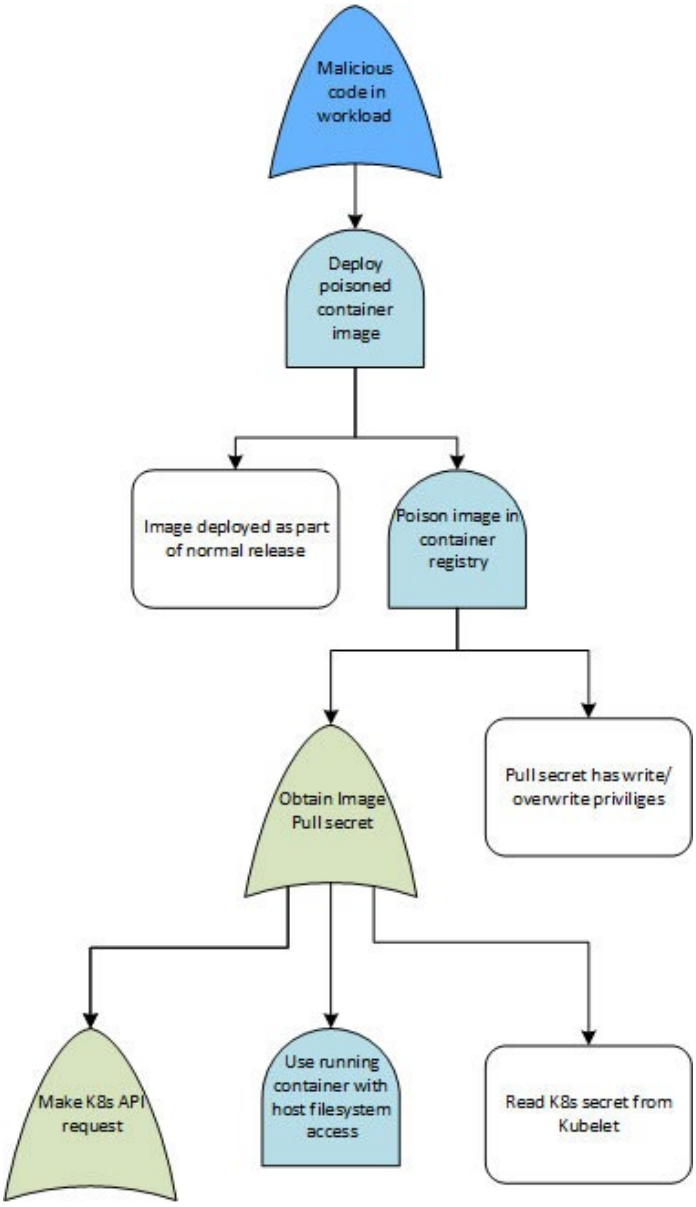

识别到威胁后对威胁进行几个处理步骤：

- 标记详情，附加参考材料、变更记录；
- 威胁影响级别：从机密性、完整性、可用性，利用难度四个角度进行评估。衡量风险没有必要强制按照 DREAD、CVSS 评分模型，很大程度依赖于参与的

安全专家对攻击者的视角、安全建设的成熟度、业务的可接受能力进行定级，一般给出高中低即可。

3.3 处理威胁是重中之重

经过上述的活动，我们获取了一个大的威胁列表，下一步就是处置评估出来的每个风险，这方面的材料可以参考 ISO27001 和 ISO31000 的系列指导。分为四个应对措施。

缓解

采取措施加大攻击者的利用时间。就像 Google Project Zero 的原则“Make 0-Day Hard”。比如发现密码猜解的威胁，采用二次认证、风控验证码的技术，缓解和解决风险的界限往往并不清晰。仔细想想大部分的日常安全工作都是缓解威胁，比如部署 WAF、制定安全规章制度、监控和响应。

解决

完全解决该威胁。解决是最乐观的情况，常见的安全方案是基于现有的代码实现，比如防 SQL 注入组件，使用加密套件解决硬编码问题。如果威胁建模是发生在编码之前，可以使用现有的安全方案如 Security SDK、密钥管理服务、身份认证方案，当然也可以引用新的安全技术去建设。

转移

转移是将威胁承担交由其他系统去处理，比如用户协议和隐私条款、免责声明，变更管理的二次认证、外包、购买网络安全保险。但是安全也不能对业务给个方案说你得买一份保险，这需要找到安全和业务的平衡感。

接受

接受风险也是面对安全成本的一个合理处理方式，不同层级的业务负责人对待安全的视角是有不同考虑的。比如在物理安全领域，我们往往做得适度投入，背后的原因是接受了战争、核武器等不可抗拒因素。

依据上述的威胁定义补充是等级、优先级、修复成本、负责人、排期、安全测试结果、解决方案记录结果，报告文字要规范，避免使用安全特定术语、缩略语如 PoC、RCE、SSRF、HIDS 字样。给出前瞻性的安全方案是区分安全测试和威胁建模的主要区别。对于共性问题建立孵化安全解决方案，有安全专项的也进行标记，后续可以比对安全项目的效果。

解决威胁的抽象原则要区分出安全建设的原则纵深防御、最小权限原则、默认（强制）安全并不一定适用于业务系统，业务更熟悉安全架构设计的 5A 原则：

- 身份认证（Authentication）：用户主体是谁?
- 授权（Authorization）：授予某些用户主体允许或拒绝访问客体的权限。
- 访问控制（Acccess Control）：控制措施以及是否放行的执行者。
- 可审计（Auditable）：形成可供追溯的操作日志。
- 资产保护（Asset Protection）：资产的保密性、完整性、可用性保障。

5A 的划分容易让业务理解到开发架构、逻辑架构、数据架构、技术架构、业务架构中，从而避免因为安全缓解措施的影响导致原本的业务需求不能实现，或者性能、编码、成本变更得太多。

完成威胁建模的标志是双方团队对图表没有异议，可以依据数据流图，复述清楚数据流向、攻击面如何、已经做了什么、存在哪些风险、应该做到什么。让业务没有安全知识的提升的建模是失败的，业务方应当是下一个产品迭代中安全提升的主动贡献者。

以下是威胁列表的结果示例模板：

威胁ID	风险等级	威胁描述	威胁分类	影响的资产	策略	修复方案	状态	负责人	排期
1	高	服务器同客户端通信使用采用http模式，可被中间人攻击窃取难以通信层面数据交互的保密性、完整性和抗重放攻击性。	信息泄露	客户端活动内容日志上报系统信息及访问ip	解决	对外网开放时使用全站HTTPS功能	TODO		20211231
2	中	使用Token方案，存在生成随机性不足，攻击者可推算出有效序列值，伪造用户进行登录的威胁	欺骗	用户数据	缓解	使用非对称加密算法随机生成key值	DONE		
3	低	服务器和客户端采用webservice，服务器宕机会导致服务离线	拒绝服务	服务	解决	通过统一容灾方式，多机方式部署。			
4	高	系统年久无人维护，源代码开源被逆向渗透	信息泄露、拒绝服务	应用本身	接受	NA			

3.4 验证威胁达到闭环

修复问题就是安全团队复查威胁得到合理的处置，高标准就是合理。跟踪威胁的解决不要拘泥于使用的安全内部的工单系统，在业务的研发管理系统记录也是一个明智的选择。同业务方制定单双周的沟通会，确保每个风险在跟进按时解决。威胁建模并不是一次性活动，每次双周沟通都简短沟通，花 5–10 分钟再一次实施建模：沟通下遇到什么困难，有什么安全需求，积累建模的习惯，通过反复执行这个活动可以从设计层面识别大量的安全风险。

我们总是提安全要 Shift Left（左移），建模给了产品团队良好的“右移”机会。团队之间的知识共享帮助大家理解安全的本质，知道安全这件事该如何做，从而逐步改善公司的安全状况。Security by Design 要求安全前置介入到需求和设计阶段，真正让介入需求阶段，安全又总是无从下手，其实需求阶段的安全活动包括用例验证、资产识别、安全基线，将权限、日志、操作安全、加密需求、编码规范、基础服务纳入安全相关基线，设计阶段主要有方案评审、安全特性设计，最重要的更是威胁建模。团队互动的过程要以文档的形式完整记录，这种材料是给其他团队下一次威胁建模的有效输入。

4. 如何评价这件事做得好坏

威胁建模不能立竿见影，建模没有什么特别的，对于业务方来说应该是同编码、测试、交付一样很普通的工作，安全也仅仅是日常工作的一部分。事情的主要目标是建立产品的安全属性，可以通过最终的安全缺陷改进情况、评审覆盖度、修复解决率作为过程指标，安全成熟度、安全事故数作为结果指标。实施投入威胁建模本身已经是一件技能很复杂的事情了，对参与人员引导做正确的事，不需要设置发现威胁数等硬性指标。

威胁建模在于对评估可能的风险、分析潜在攻击者的手法、攻击路径，提升产品的抗攻击韧性方面有独特的优势。这项方法论根本没有什么最佳实践，没有单一的“最好”或执行威胁建模的“正确”方法，而是为了满足解决这些威胁而实施的一系列复杂和多维度的权衡，唯有不断修正迭代才能完善。但如果没有威胁建模过程参与，组织不会清楚现有系统的安全现状。不管怎样，一旦你取得阶段性的成果，组织内部就认识到这样的协作可以对改善总体安全状况产生较大的作用，是高性价的投入，就可以克服关于威胁建模耗费人力、周期长、难点大这些阻力的声音，从而真正从事预防性的安全建设。

5. 经验教训

美团内部实施威胁建模时，首先就设立了如下的目标：

- 覆盖基础设施相对重要的公共组件服务和重要管理平台；
- 形成一套可复用的安全评审流程，知识库和工具；
- 及时发现公司管理平台的运营安全类风险，排期止损加固。

通过制定的威胁建模计划同业务部门深入开展合作，团队完成了数十个项目的评估，发现了数百个高危设计缺陷，从而试图解决两类核心问题：①人为操作导致的安全风险；②安全融入基础架构。识别提炼出孵化出特权账户管理平台、服务鉴权、执行沙箱、全程票据、安全知识库等安全子项目。当然建模的效果有好有坏，我们仍需学习、调整、迭代。我们总结了如下的经验教训：

- 关注真实的威胁，从技术威胁入手延伸到业务威胁；
- 安全没有“银弹”，使用其他应用安全措施补充威胁建模；
- 见木不见林，致力于高效的建模，而不纠结于细节；
- 关注安全的沟通协作，改善研发解决安全问题的思维方式，胜于投入精力在安全测试。

业界关于威胁建模的实施方法论在物联网、机器学习、Serverless 场景依旧很有生命力，说明在软件工程领域这会是识别威胁真正有效的办法。相信 Threat Modeling Application Security Testing（威胁模型驱动的应用安全测试）将成为应用安全的又一主流安全测试方法。

参考资料

- https://michenriksen.com/blog/drawio-for-threat-modeling/
- https://github.com/cncf/financial-user-group/tree/master/projects/k8s-threat-model
- http://ceur-ws.org/Vol-413/paper12.pdf
- https://community.iriusrisk.com/
- https://aws.amazon.com/marketplace/pp/ThreatModeler-ThreatModeler/B07S65ZLPQ
- https://threatdragon.org/login
- http://mozilla.github.io/seasponge/#/
- https://insights.sei.cmu.edu/sei_blog/2018/12/threat-modeling-12-available-methods.html
- http://www.owasp.org.cn/owasp-project/OWASP_Top_10_Proactive_Controls_V3v1.1.pdf
- http://www.woshipm.com/it/1663882.html
- https://developer.ibm.com/zh/components/redhat-openshift-ibm-cloud/articles/threat-modeling-microservices-openshift-4/
- https://docs.microsoft.com/en-us/archive/msdn-magazine/2006/november/uncover-security-design-flaws-using-the-stride-approach
- https://cheatsheetseries.owasp.org/cheatsheets/Threat_Modeling_Cheat_Sheet.html
- https://csrc.nist.gov/publications/detail/sp/800-154/draft
- https://github.com/google/end-to-end/wiki/Threat-model

Fairplay DRM 与混淆实现的研究

作者：吴聊　落落　朱米

什么是 DRM？

DRM 全称 Digital Rights Management，即数字版权保护。苹果为了保护 App Store 分发的音乐 / 视频 / 书籍 /App 免于盗版，开发了 Fairplay DRM 技术，并申请了很多相关的专利，比较有代表性的如：– US8934624B2: Decoupling rights in a digital content unit from download – US8165286B2: Combination white box/black box cryptographic processes and apparatus – ES2373131T3: Safe distribution of content using descifrado keys

长久以来，关于 App DRM 的研究很少，而 DRM 的关键是授权和加密。破解 Fairplay DRM 加密的方式俗称“砸壳”，这是进行 iOS App 安全研究的必要前提。自从 2013 年苹果引入 App DRM 机制以后，诞生了如 Cluth、Bagbak、Flexdecrypt 这样的经典“砸壳工具”，而此类“砸壳工具”通常需要越狱设备的支持，因此具有一定的局限性。

2020 年发布的 M1 Mac 将 Fairplay DRM 机制引入了 MacOS，由于 Mac 设备的权限没有 iOS 严格，因此我们得以在 MacOS 上探索更多 Fairplay DRM 的原理，最终目标是使解密流程不受 Apple 平台的限制。下面，我们先来聊聊 Apple 中是如何实现的?

Apple 上 DRM 的实现：Fairplay DRM

LC_ENCRYPTION_INFO 中的标记

加密的 MachO 含有 LC_ENCRYPTION_INFO 字段，其中 cryptoff 标识了加密部分在文件中的起始偏移，cryptsize 标识了加密部分的尺寸，cryptid 则表明了加密的方法。Fairplay DRM 保护下的 App，其加密尺寸为 4096 的倍数，加密方式标识为 1。

```
[➜  COVID-19.app otool -l COVID-19 | grep -i crypt
          cmd LC_ENCRYPTION_INFO_64
     cryptoff 16384
    cryptsize 3588096
      cryptid 1
```

图 1

而负责解密 Mach-O 的组件主要包括：**内核态的 FairplayIOKit 和用户态的 fairplayd**。

Fairplay 的 Open

MacOS 的 XNU Kernel 中有 text_crypter_create_hook 这个导出符号，IOTextEncryptionFamily 驱动则注册了这个 Hook，并作为桥梁，将调用转发给了 FairplayIOKit 内核驱动。

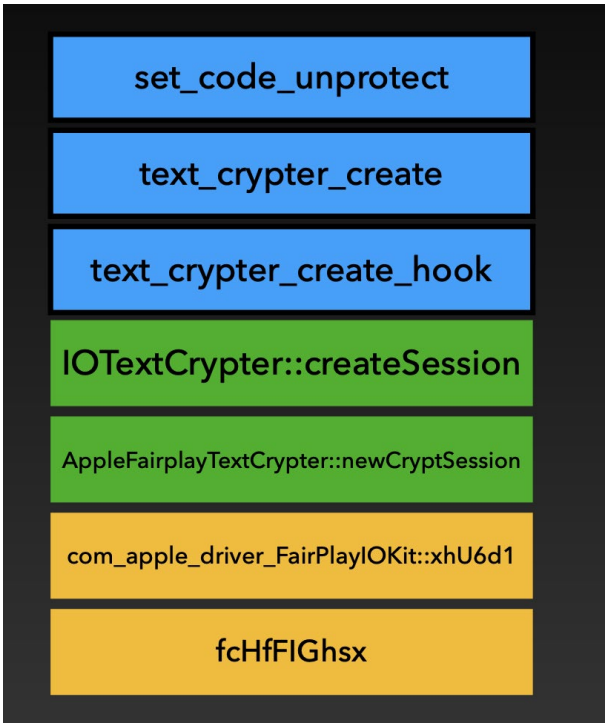

图 2

最终负责处理的函数是：

```
com_apple_driver_FairPlayIOKit::xhU6d1(
  char const* executable_path,
  long long cpu_type,
  long long cpu_subtype,
  rp6S0jzg** out_handle
)
```

此后，内核中的 FairplayIOKit 开始初始化，通过 host_get_special_port 中的 unfreed port 发送 MIG 调用到用户态的 fairplayd，fairplayd 开始处理 SC_Info 目录下的 sinf 和 supp 文件，并将处理的数据返回给内核中的 FairplayIOKit。

注：用户态的 fairplayd 具体工作流程不在本文讨论范围内。

其中 MIG 调用的结构如下：

```
struct FPRequest{
    mach_msg_header_t header;
    mach_msg_body_t body;
    mach_msg_ool_descriptor_t ool;
    NDR_record_t ndr;
    uint32_t size;
    uint64_t cpu_type;
    uint64_t cpu_subtype;
};

struct FPResponse{
    mach_msg_header_t header;
    mach_msg_body_t body;
    mach_msg_ool_descriptor_t ool1; //supf 文件映射
    mach_msg_ool_descriptor_t ool2; //unk，正比与加密内容的尺寸
    uint64_t unk1;
    uint8_t unk2[136];
    uint8_t unk3[84];
    uint32_t size1;
    uint32_t size2;
    uint64_t unk5;
};
```

完成所有调用后，返回的结构 rp6S0jzg* 实际是一个 uint32_t 类型的 handle，接下来则可以用这个 handle 来完成解密操作。

Fairplay 的 Decrypt Page

前面提到的 Fairplay Open 操作最终返回了一个 pager_crypt_info 的结构体，其中 page_decrypt 的 Hook 由 IOTextEncryptionFamily 驱动接管，并最终转发给 FairplayIOKit。

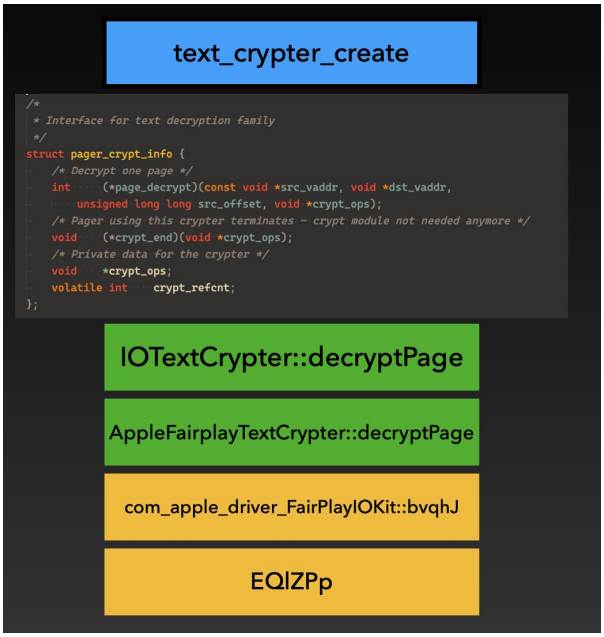

图 3

最后，FairplayIOKit 中负责解密的函数定义如下：

```
com_apple_driver_FairPlayIOKit::bvqhJ(
  rp6S0jzg *hanlde,
  unsigned long long offset,
  unsigned char const* src,
  unsigned char * dst
)
```

至此，Fairplay 的解密逻辑完成调用。值得注意的是，在 Fairplay DRM 中，page 的概念为 4096bytes。

那么，用户态 fairplayd 处理的 sinf 和 supp 文件又是什么样子的呢?

SINF 和 SUPF 文件

结构

用户态的 fairplayd 会读取随 IPA 携带的两个重要文件：SINF 和 SUPF，存储在 App 的 SC_Info 目录下。

```
[➜  COVID-19.app ls -alh SC_Info
total 152
drwxr-xr-x   7 root  wheel   224B  3  3 16:54 .
drwxr-xr-x  54 root  wheel   1.7K 10 23 07:14 ..
-rw-r--r--   1 root  wheel   1.0K  3  3 16:24 COVID-19.sinf
-rw-r--r--   1 root  wheel    28K 10 22 16:14 COVID-19.supf
-rw-r--r--   1 root  wheel    28K 10 22 16:14 COVID-19.supp
-rw-r--r--   1 root  wheel    80B 10 22 16:14 COVID-19.supx
-rw-r--r--   1 root  wheel   440B 10 22 16:14 Manifest.plist
```

图 4

其中 SUPF 文件和 IPA 一起分发，每个用户的 IPA 和 SUPF 文件都是一致的，其中 SUPF 文件中保存了加密 Mach-O 的密钥，但是密钥本身被另外的机制加密。而 SINF 文件则作为每个用户的 DRM 许可，记录了购买用户的标识符和姓名，以及解密 SUPF 需要的信息，**因此在 Sandbox 策略下，App 无法读取自身的 SINF 文件，以防止其被作为唯一 ID 追踪用户**。

SINF

SINF 文件是一个 LTV+KV 结构的文件，它的字段如下所示：

```
sinf.frma: game
sinf.schm: itun
sinf.schi.user: 0xdeadbeef
sinf.schi.key : 0x00000005
sinf.schi.iviv: 0x12345678901234567890123456789012
sinf.schi.righ.veID: 0x000007d3
sinf.schi.righ.plat: 0x00000000
sinf.schi.righ.aver: 0x01010100
sinf.schi.righ.tran: 0xdc64f80c
sinf.schi.righ.sing: 0x00000000
sinf.schi.righ.song: 0x59a73c58
```

```
sinf.schi.righ.tool: P550
sinf.schi.righ.medi: 0x00000080
sinf.schi.righ.mode: 0x00002000
sinf.schi.righ.hi32: 0x00000004
sinf.schi.name: User Name
sinf.schi.priv: (432 Bytes Private Key)
sinf.sign: (128 Bytes Private)
```

SUPF

SUPF 文件主要分为三个部分，我们将其命名为 Key Segments、Fairplay Certificate、RSA Signature，其中 Key Segments 可以含有多个子 Segment，用来保存多个架构的解密信息。

```
KeyPair Segments:
      Segment 0x0: arm64, Keys: 0x36c/4k, sha1sum =
e369546960d805dd1188d42e3350430c7e3a0025

Fairplay Certificate:
    Data:
        Version: 3 (0x2)
        Serial Number:
            33:33:af:08:07:08:af:00:01:af:00:00:10
        Signature Algorithm: sha1WithRSAEncryption
        Issuer: C=US, O=Apple Inc., OU=Apple Certification Authority,
CN=Apple FairPlay Certification Authority
        Validity
            Not Before: Jul  8 00:48:29 2008 GMT
            Not After : Jul  7 00:48:29 2013 GMT
        Subject: C=US, O=Apple Inc., OU=Apple FairPlay,
CN=AP.3333AF080708AF0001AF000010
        Subject Public Key Info:
            Public Key Algorithm: rsaEncryption
                RSA Public-Key: (1024 bit)
                Modulus:
                    00:b0:01:16:4b:62:b2:37:8d:60:12:4f:02:15:15:
                    a0:32:1b:e8:ed:44:ed:e9:17:5b:ec:9e:5d:11:24:
                    5a:66:2f:dc:a3:25:aa:52:70:e1:09:22:09:4b:65:
                    0f:67:f5:82:dc:af:78:9b:4c:45:f3:b4:f4:77:aa:
                    fc:a3:b2:84:c3:8b:09:c6:2e:55:f5:14:85:07:ac:
                    ae:0d:ff:ff:ca:41:3b:44:cb:52:b6:28:60:55:23:
                    35:8d:26:71:c6:12:a5:e0:72:58:09:3c:4a:9e:b6:
                    63:df:2a:91:94:27:eb:65:0a:b2:36:45:11:c1:91:
                    43:58:12:d9:e5:18:a1:ad:db
                Exponent: 65537 (0x10001)
        X509v3 extensions:
```

```
            X509v3 Key Usage: critical
                Digital Signature, Key Encipherment, Data Encipherment,
Key Agreement
            X509v3 Basic Constraints: critical
                CA:FALSE
            X509v3 Subject Key Identifier:
                7B:07:34:81:A5:75:D0:F6:11:BB:D2:36:3F:79:93:4B:A1:70:EB:CF
            X509v3 Authority Key Identifier:
              keyid:FA:0D:D4:11:91:1B:E6:B2:4E:1E:06:49:94:11:DD:63:62:07:59:64

    Signature Algorithm: sha1WithRSAEncryption
         06:11:4e:87:ed:b1:08:70:c2:0d:e4:d2:94:bb:7f:ee:50:18:
         c0:2a:21:34:0e:99:1f:bf:60:a2:58:d0:0c:28:3d:03:5b:ab:
         4e:72:69:ba:41:52:45:b2:29:27:4a:c8:ba:7f:b5:9b:63:78:
         b1:68:41:40:59:3f:05:8a:57:74:c5:63:30:cc:f3:20:41:c0:
         3c:65:d4:0d:22:47:f3:97:76:e6:d6:3c:eb:e7:20:78:10:59:
         fd:96:09:82:c3:41:f0:5f:d0:3e:91:44:6d:77:3f:a5:d9:da:
         f0:f7:53:ad:94:61:28:1c:4c:40:3b:17:2b:dd:e3:00:df:77:
         71:22

RSA Signature: 6aeb00124d62f75f5761f7c26ec866a061f0776be7e84bfad4b6a1941d
bddfdb3bd1afdcc5ef305877fa5bee41caa37b1a9d4ce763cf7d2cb89efa60660a49dd5dd
ff0f46eee7cd916d382f727d912e82b6e0a62e8110c195e298481aa8c8162faac066ef017
c6c2c508700d7adb57e0c988af437621e698946da1b09adf89e9
```

下面，我们来聊聊 Fairplay DRM 的混淆原理和实现。

混淆原理和一些实现

LLVM Pass

LLVM 是一个优良的编译器框架，其中，我们可以将其大略的分为前端、中端、后端：

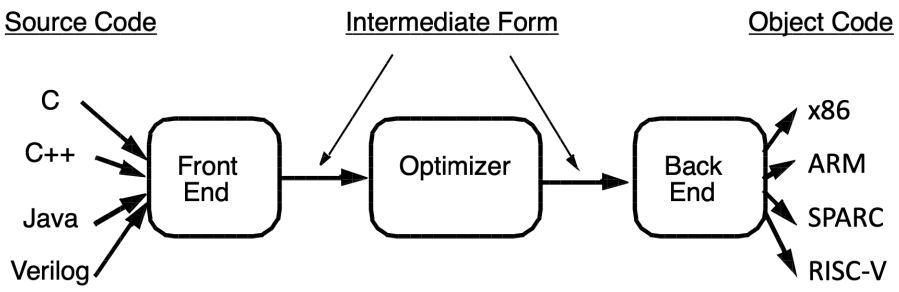

图 5

配图节选自 CMU 的 CS 15-745 课程：https://www.cs.cmu.edu/~15745。

前端负责将高级语言转化为 LLVM IR；中端处理 LLVM IR，完成一系列的分析、优化任务，我们称之为 Pass，再次输出 LLVM IR；后端则负责将 LLVM IR 转化为机器码。其中，中端的玩法特别丰富，基本的优化任务：如死代码消除、常量折叠都在这一部分完成；Address Sanitizer、PC Sanitizer 等编译器插桩也是在这里进行的；其他的混淆框架如讨论的较多的 ollvm 以及 Hikari，甚至包括苹果的混淆机制，也都是基于此完成。

这一混淆方式可以基本的分为控制流混淆和数据流混淆，除此之外的一些混淆方式，比如 VMP 等，不在本文讨论范围内。

makeOpaque

在编译器中，**为了防止一些具体的表达式被优化，我们会将表达式进行等价变化，我们暂时将这样的操作定义为 makeOpaque**（如 Safari 的 JavascriptCore，其 JIT 组件 B3 就提供这样的机制），C++ 伪代码如下：

```
Expression* makeOpaque(Expression *in);
```

不透明谓词（Opaque Predicate）

谓词（Predicate）在计算机中，指的是执行后为 True 或 False 的表达式。数论里面的一些结论可以作为我们生成**不透明谓词**的基础，这些不透明谓词的结果恒为 True 或恒为 False。比如下列表达式中，y 执行的结果就恒为 True：

```
uint32_t x = 0;
bool y = ((x * x % 4) == 0 || (x * x % 4) == 1);
```

不透明谓词应用到混淆中的一个例子就是 bogus CFG。 如源语句如下：

```
foo1();
foo2();
```

经过变换，我们添加了一个虚假的分支（即 bogus CFG）：

```
foo1();
if ( false )
  junk_code();
else
  foo2();
```

但是如果没有经过特别处理，编译器、反编译器的死代码消除就会将虚假分支去除掉，因此我们需要 makeOpaque 的引入，假设我们引入了前面示例中的表达式：

```
foo1();
uint32_t x = rand();
bool y = ((x * x % 4) == 0 || (x * x % 4) == 1);
if ( !y )
  junk_code();
else
  foo2();
```

那么如果编译器、反编译器没有相应的识别机制的话，这一部分的死代码就保留了下来，**通过在死代码里面插入大量干扰指令，可以为逆向的人员带来极大的困扰**。经测试在 -O2 优化下，Clang 11 已经可以识别这个规则，但是 GCC 5.4 无法识别。

可逆变换

这里我们介绍一下目前混淆技术中常用的等价变换方式。

异或

异或规则是最常见的变换，这里不再赘述。

```
x ^ c ^ c = x;
```

仿射变换（Affine transformation）

我们先来看一下仿射函数。

- 它的一般表达式为：

$$f(x) = Ax + b$$

- 这里A是一个$m \times k$的矩阵，x是一个k维向量，b是一个m维向量。所以它也可以表示为：

$$f(x_0, \ldots, x_k) = A_0x_0 + \ldots + A_kx_k + b$$

- 当$b = 0$时，仿射函数就是线性函数。
- 那么，在MBA混淆中，仿射函数f在有限域上即可表示为：

$$f(x) = (ax + b) \mod 2^n$$

- 其中$a, b \in GF(2^n)$且互质，则f的逆函数f^{-1}为：

$$f^{-1}(x) = (a^{-1}(x - b)) \mod 2^n$$

- 其中a^{-1}是a在有限域上的乘法逆元，满足$(a \times a^{-1}) \equiv 1 \mod 2^n$。

下面我们来看一下实际应用。

由于计算机中的运算属于隐式的模运算，因此会具有一些有意思的性质。如对于一个 uint32 上的运算，模运算逆元定义如下：

```
// 对于
uint32_t a, r_a;

// 如果满足
(a * r_a) % UINT32_MAX == 1;

// 那么 a 和 r_a 互为模反元素
```

对于互为模反元素的 a 和 r_a（可通过扩展欧几里得算法求得），有这样的特性：

```
uint32_t x = rand();
uint32_t y1 = a * x + c;
// 那么满足
x == ra * y1 +  (- ra * c)
```

最后举个例子来说明：

```
// 对于互为模反元素的 4872655123 * 3980501275，取
uint32_t x = 0xdeadbeef;
uint32_t c = 0xbeefbeef;
// 则 -ra * c = 0x57f38dcb，且
((x * 4872655123) + 0xbeefbeef) * 3980501275 + 0x57f38dcb == x
/*
可在 lldb 中验证如下
(lldb) p/x uint32_t x=0xdeadbeef; (uint32_t)(((x * 4872655123) +
0xbeefbeef) * 3980501275 + 0x57f38dcb)
(uint32_t) $8 = 0xdeadbeef
*/
```

MBA 表达式（Mixed Boolean-Arithmetic Expression）

MBA 表达式是把算术运算（+，-，*，/）和位运算（&，|，~）混合在一起用以隐藏原本表达式的混淆方法。它基于不同的数学原理存在多种形式，这里主要介绍多项式 MBA，这是目前混淆技术中最常遇到的形式。

多项式MBA表达式的一般定义为：当一个表达式E形如：

$$E = \sum_{i \in I} a_i (\prod_{j \in J_i} e_{i,j}(x_0, \ldots, x_{t-1}))$$

其中，我们将多项式表达式定义在伽罗瓦域（Galois field）$GF(2^n)$中（这是计算机科学中常使用的有限域），a_i是域中的常量，$e_{i,j}$是域中变量$x_0, \ldots, x_{t-1} \in \{0,1\}^n$的位运算表达式，$I \subset Z$（这里$Z$表示整数集），并且$\forall i \in I$，$J_i \subset Z$是有限索引集。这个表达式就是多项式MBA表达式。

那么，线性MBA表达式是多项式MBA表达式的一种特殊形式：

$$\sum_{i \in I} a_i e_i(x_0, \ldots, x_{t-1})$$

比如，与$E = x + y$等价的线性表达式为：

$$E = (x \oplus y) + 2 \times (x \wedge y)$$

类似的，在 Fairplay 混淆中用到的 MBA 表达式为：

```
//OperationSet(+, -, *, &, |, ~)
x - c = (x ^ ~c) + ((2 * x) & ~(2 * c + 1)) + 1;
```

而使用 MBA 进行混淆操作主要依靠以下两个步骤：

- MBA改写（MBA rewrites）：将一个运算改写为MBA表达式（比如上文中改写$x + y$）。
- 插入一致性（Insertions of identities）：假设e是使用MBA混淆过的表达式的某一部分，f是$GF(2^n)$中的可逆函数，则有$e = f(f^{-1}(e))$成立，f是仿射函数。

不透明常量（Opaque Constant）

不透明常量是基于 MBA 混淆的方法，用于隐藏数据流中的常量。它使用了置换多项式，是一种在有限域上的可逆多项式。

根据参考文献中提供的一个在有限域$GF(2^n)$中m维可逆多项式的子集P_m，和一个用于寻找这种可逆多项式的公式，不透明常量可以按照以下方式构造：

- $P \in P_m$，Q是P的逆：$P(Q(X)) = X$，$\forall X \in GF(2^n)$。
- $K \in GF(2^n)$是要隐藏的常量。
- E是变量$x_1, \ldots, x_t \in GF(2^n)$组成的值为0的MBA表达式（类似$E = x + y - (x \oplus y) - 2 \times (x \wedge y)$）。

然后，K可以被替换为：

$$P(Q(K)) = P(E + Q(K)) = K$$

因此，在程序中，我们可以选择任意变量来计算K的值，这就是不透明常量的生成原理。

控制流平坦化

这一部分是逆向工程中讨论的最热门的话题，即将正常的控制流转换等价替换为一个状态机，从而干扰静态的控制流分析，业界也有较多的解决方案。同时因为 Fairplay DRM 中没有明显用到这种类型的混淆，不再多讨论。

非直接跳转（Indirect Branch）

将一些基本块的起始地址保存在全局变量中，通过不透明常量的生成，使得反汇编工具和肉眼无法直接获取到基本块跳转的目标，模型如下：

```
// 记录基本块地址到全局查找表 LUT
LUT[i] = PC;

// 执行跳转
jmp/call LUT[makeOpaque(i)]
```

具体的实例：

```
v8 = 1431655766LL * (((a4 - 95) << 7) | 0x41);
v9 = ((((a4 - 95) << 7) | 0x41) - 3 * (BYTE4(v8) + (v8 < 0))) & 0xF1;
v10 = ((a4 - 95) & 0x3D ^ 0xFFFFFFC1) % 102;
v11 = (v10 >> 1) & 0x3C;
v12 = -29
    * v10
    * (v11 & (a4 - 95) & (((((1431655765 * v11) >> 32) - v11) >> 1) + ((((1431655765 * v11) >> 32) - v11) >> 31) + 61));
v13 = -29
    * v10
    * (v11 & (a4 - 95) & (((((1431655765 * v11) >> 32) - v11) >> 1) + ((((1431655765 * v11) >> 32) - v11) < 0) + 61));
v14 = (fp_dh_04861724ecb347e32e20b160688591c9[(((((((v9 * v9) & (a4 - 95)) >> 3) & 0xFE) + 27) >> 1) - 75) - 136])(
        0x4000LL,
        64LL);
```

图 6

这样，逆向人员就无法直接获取跳转的目标函数、基本块了。同理，通过将判断语句的条件映射到跳转表，也可以实现对条件跳转的混淆。

所以，在逆向被混淆的 Fairplay 代码时，**IDA Pro 大多数时刻，只能识别出来函数的第一个基本块，无法分析出函数的边界**。

跨函数混淆 + 调用约定混淆

正常情况下，编程语言如 C 语言的参数传递遵循特定的调用约定，但是部分混淆工具会对一些内部函数的调用约定进行修改，以 Fairplay DRM 为例：

```
int64_t __cdecl fcHfFIGhsx(char *exec_path, __int64 cpu_type, __int64 cpu_subtype, _QWORD *outHandle)
{
  ObfsArgs *buff; // x23
  unsigned int e; // w9
  unsigned int v7; // w8
  int64_t v8; // x19

  buff = (ObfsArgs *)IOMallocAligned(0x4000uLL, 0x40uLL);
  buff->arg1 = (__int64)exec_path;
  buff->arg3 = cpu_type;
  buff->arg4 = cpu_subtype;
  e = 0x71744B67 * ((unsigned int)buff ^ 0x6FF60040);
  buff->args_ptr = (__int64)&buff->arg1;
  buff->buff_end = (__int64)&buff->end_of_buff;
  buff->context = 0xCFC02DEB - e;
  buff->constant = e + 0x41320139;
  buff->red_zone = (__int64)&buff->char80;
  fp_dh_5e7bd3a952e988b6c0416d5dac36ca7b_dispatch(buff);
  v7 = buff->retval;
  *outHandle = LODWORD(buff->arg2);
  if ( v7 >> 1 == 577715707 )
    v8 = 4294925292LL;
  else
    v8 = v7 - 1155474011;
  _IOFreeAligned(buff, 0x4000uLL);
  return v8;
}
```

图 7

我们可以看到常规的以寄存器和栈传递参数的方式被替换成了以堆传递参数的方式了，在构造好了结构体的情况下，这个参数传递的特征可以被清晰的看出来。同时，这里面对一些传递的参数进行了异或混淆，在子函数里面再恢复出来，使得我们难以直接得到原始数据，而静态分析的工具比如 IDA Pro 也不支持跨函数的数据流分析。

更严重的是，一些影响子函数运行的重要依赖数据，被提升到了父函数内，导致**在没有恢复调用关系前，我们根本无法推测子函数的运行流程**。

那么，Fairplay DRM 的破解之道就是要找到它的弱点。

Fairplay 混淆的弱点

通过前边的工作，我们已经能 Fairplay 正常的完成打开和解密工作了，通过一系列的静态分析和追踪调试，我们发现了这一套混淆系统的一些对抗方案。

这些问题的本质原因是：**混淆系统在 IR 层面设计，对机器相关的部分操作没有混淆，因此在生成的机器码里面，我们可以推断得到混淆前的一些特征信息**。

函数边界识别

前面提到，由于 Fairplay 用到了非直接跳转的混淆技术，IDA Pro 无法直接分析函数的边界。通过跟踪，我们发现在 arm64e 设备下，该内核驱动中，同一个函数的所有基本块在运行到跳转指令时，均使用了同一个 PAC Context，或者称之为 PAC Modifier。

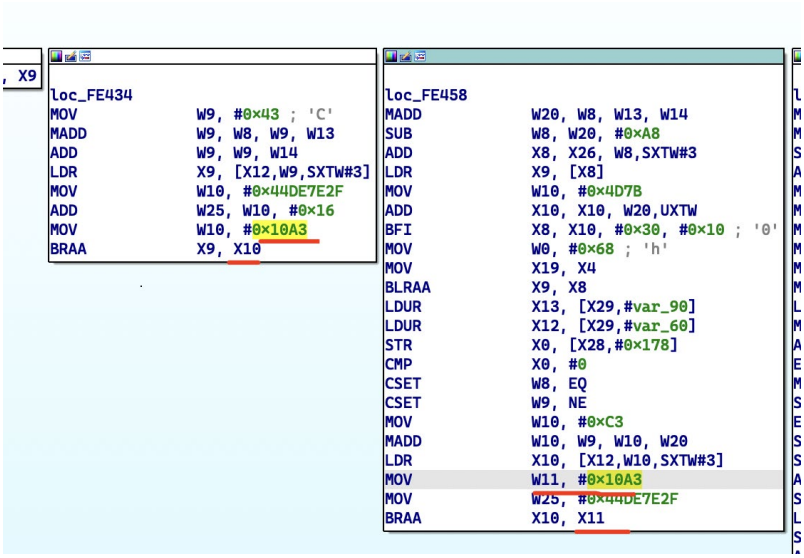

图 8

借由这个特性，我们可以将函数的边界和基本块分组，尽管目前为止这些基本块之间

并不是连通的。

非直接跳转

对于**无条件跳转**，我们通过设置断点跟踪执行流，就可以解决了。

```
* thread #1, queue = 'com.apple.main-thread', stop reason = breakpoint 2.1
    frame #0: 0x000000010066a224 FairPlayIOKit`EQlZPp
FairPlayIOKit`EQlZPp:
->  0x10066a224 <+0>:  pacibsp
    0x10066a228 <+4>:  stp    x28, x27, [sp, #-0x60]!
    0x10066a22c <+8>:  stp    x26, x25, [sp, #0x10]
    0x10066a230 <+12>: stp    x24, x23, [sp, #0x20]
Target 0: (uloader) stopped.
(lldb) sb
Process 60585 stopped
* thread #1, queue = 'com.apple.main-thread', stop reason = instruction step into
    frame #0: 0x000000010066a2f0 FairPlayIOKit`EQlZPp + 204
FairPlayIOKit`EQlZPp:
->  0x10066a2f0 <+204>: blraa  x10, x9
    0x10066a2f4 <+208>: mov    x19, x0
    0x10066a2f8 <+212>: add    x24, x0, #0x80             ; =0x80
    0x10066a2fc <+216>: add    x25, x0, #0x4, lsl #12     ; =0x4000
[*] hit branch instruction
        source: FairPlayIOKit[0x10e2f0]: blraa  x10, x9
        target: uloader[0x100009bec]: sub    sp, sp, #0x40              ; =0x40
        symbol: IOMallocAligned
```

图 9

再通过 KeyPatch 这样的工具，我们可以将一些简单的函数恢复到比较易于理解的地步。

```
1  __int64 __fastcall EQlZPp(uint32_t handle, uint64_t offset, const char *from, char *to)
2  {
3    ObfsArgs *buff; // x19
4    unsigned int v9; // w9
5    __int64 v10; // x20
6
7    buff = (ObfsArgs *)IOMallocAligned(0x4000uLL, 0x40uLL);
8    LODWORD(buff->arg1) = handle;
9    buff->arg2 = offset;
10   buff->arg3 = (__int64)from;
11   buff->arg4 = (__int64)to;
12   v9 = 1903446887 * ((unsigned int)buff ^ 0x6FF60040);
13   buff->context = 0x33E2E940 - v9;
14   buff->constant = v9 + 0x41320139;
15   buff->args_ptr = (__int64)&buff->arg1;
16   buff->buff_end = (__int64)&buff->end_of_buff;
17   buff->red_zone = (__int64)&buff->char80;
18   fp_dh_5e7bd3a952e988b6c0416d5dac36ca7b_dispatch(buff);
19   v10 = (unsigned int)(buff->retval - 1155474011);
20   IOFreeAligned(buff, 0x4000uLL);
21   return v10;
22 }
```

图 10

但是这里的难点在于恢复混淆里面的**非直接跳转指令**，如下图所示：

```
)FEA2C ; ---------------------------------------------------------------------------
)FEA2C
)FEA2C loc_FEA2C                                ; DATA XREF: __const:0000000000131D98↓o
)FEA2C                  SUB             W9, W13, #0×B
)FEA30                  MADD            W19, W8, W9, W14
)FEA34                  SUB             W8, W19, #0×9D
)FEA38                  ADD             X8, X26, W8,SXTW#3
)FEA3C                  LDR             X9, [X8]
)FEA40                  MOV             W10, #0×4D86
)FEA44                  ADD             X10, X10, W19,UXTW
)FEA48                  BFI             X8, X10, #0×30, #0×10 ; '0'
)FEA4C                  MOV             W0, #0×68 ; 'h'
)FEA50                  STUR            X15, [X29,#var_E8]
)FEA54                  STUR            X17, [X29,#var_C0]
)FEA58                  MOV             X20, X4
)FEA5C                  BLRAA           X9, X8
)FEA60                  LDUR            X13, [X29,#var_90]
)FEA64                  LDUR            X12, [X29,#var_60]
)FEA68                  STR             X0, [X28,#0×178]
)FEA6C                  CMP             X0, #0
)FEA70                  CSET            W8, NE
)FEA74                  CSET            W9, EQ
)FEA78                  MOV             W10, #0×B
)FEA7C                  MADD            W10, W9, W10, W19
)FEA80                  LDR             X10, [X12,W10,SXTW#3]
)FEA84                  MOV             W11, #0×10A3
)FEA88                  MOV             W25, #0×44DE7E2F
)FEA90                  BRAA            X10, X11
)FEA94 ; ---------------------------------------------------------------------------
)FEA94                  STLUR           X4, [X9,#0×A2]
)FEA98
)FEA98 loc_FEA98                                ; DATA XREF: __const:00000000001315A0↓o
)FEA98                  MOV             X15, X20
)FEA9C                  MOV             X14, X0
)FEAA0                  STR             X24, [SP,#0×230+var_128]
```

图 11

对于这个跳转指令，我们可以生成如下的表达式：

```
//cmp x0, #0
w10 = qword[x12 + (EQ * 0xB + w19) << 3]
//0xB 代表两个基本块的在 LUT 中的下标差
```

通过 CSET 指令的形式，我们已经可以推断跳转指令应该是 J.NE 或者 J.EQ 了，通过我们的调试器插件，我们可以得到其中一个分支的跳转地址和原本的跳转指令，再通过表达式的信息，我们可以很快推断出另外一个分支的地址。

```
)FEA30                  MADD            W19, W8, W9, W14
)FEA34                  SUB             W8, W19, #0x9D
)FEA38                  ADD             X8, X26, W8,SXTW#3
)FEA3C                  LDR             X9, [X8]
)FEA40                  MOV             W10, #0x4D86
)FEA44                  ADD             X10, X10, W19,UXTW
)FEA48                  BFI             X8, X10, #0x30, #0x10 ; '0'
)FEA4C                  MOV             W0, #0x68 ; 'h' ; size
)FEA50                  STUR            X15, [X29,#var_E8]
)FEA54                  STUR            X17, [X29,#var_C0]
)FEA58                  MOV             X20, X4
)FEA5C                  BL              _kernel_alloc ; allocate AES Key Context
)FEA60                  LDUR            X13, [X29,#var_90]
)FEA64                  LDUR            X12, [X29,#var_60]
)FEA68                  STR             X0, [X28,#0x178]
)FEA6C                  CMP             X0, #0
)FEA70                  CSET            W8, NE
)FEA74
)FEA74 loc_FEA74
)FEA74                  CSET            W9, EQ
)FEA78
)FEA78 loc_FEA78
)FEA78                  MOV             W10, #0xB
)FEA7C                  MADD            W10, W9, W10, W19
)FEA80                  LDR             X10, [X12,W10,SXTW#3] ; qword(X12 +  ((EQ * 0xb) + w19) << 3)
)FEA84                  MOV             W11, #0x10A3
)FEA88                  MOV             W25, #0x44DE7E2F
)FEA90                  B.EQ            b_fail  ; Keypatch modified this from:
)FEA90                                  ;   BRAA X10, X11
)FEA90                                  ; Keypatch modified this from:
)FEA90                                  ;   B loc_FEA98
)FEA94
)FEA94 loc_FEA94                        ; Keypatch modified this from:
)FEA94                  NOP             ;   STLUR X4, [X9,#0xA2]
)FEA98
)FEA98 loc_FEA98                        ; DATA XREF: __const:00000000001315A0↓o
)FEA98                  MOV             X15, X20
)FEA9C                  MOV             X14, X0
)FEAA0                  STR             X24, [SP,#0x230+var_128]
)FEAA4                  STUR            X21, [X29,#var_F8]
```

图 12

再通过 Keypatch，我们可以得到混淆前的分支语句结构：

```
v36 = 0x41320139 - 1093795995 * v28;    // fairplay decrypt page
v37 = v5;
aes_key_info = (char *)kernel_alloc(0x68uLL);
*(_QWORD *)(v1 + 376) = aes_key_info;
LODWORD(v10) = 1155431983;
if ( aes_key_info )
{
  v39 = v37;
  v40 = aes_key_info;
  v41 = v36 - 109 * (aes_key_info != 0LL) + 1093795995 * (aes_key_info == 0LL);
  v42 = 238749221 * (v1 ^ 0x919C4051754C40F9LL);
  *(_QWORD *)(v1 + 8) = (char *)*(&fp_dh_4396ae8ed4349da05f55800960ab32a2 + v41) + v42;
  *(_QWORD *)(v1 + 16) = v736;
  *(_QWORD *)(v1 + 24) = v2;
  v728 = (v41 - 2001003789) ^ v42;
  *(_DWORD *)v1 = v728;
  vs = (ObfsArgs_02a1db *)v1;
  v43 = v1;
  v737 = v40;
  v44 = v39;
  fp_dh_854ff69355f49d2621e587d7db58812d(v43);// call IOLockLock
```

图 13

至此，我们已经可以完整地恢复 Fairplay 的大多数控制流了。

数据流混淆

这一部分在前面已经提及到了一些，目前我们已经找到了 MBA 表达式的模式，但还没能找到 Fairplay 中生成不透明常量的完整规则。其中 MBA 表达式的重写规则目前看起来仅有一个，即：

```
x - c = (x ^ ~c) + ((2 * x) & ~(2 * c + 1)) + 1;
```

一些基于模式匹配的工具，比如 D810 已经可以比较好的处理这样的情况了。

结束语

目前，我们已经可以获取到解密每一段 Mach-O 的 AES 密钥了，通过大量的调试和反混淆，我们已经得出了这些密钥生成的初步结论。我们希望最终的目的是不依赖 Apple 设备的前提下，完成 Fairplay DRM 加解密的研究。

```
>>> calling fairplay decrypt page : EQlZPp(handle=0x70a231b3,off=0x36b000,src=0x102ddf0
00,dst=0x134811800)
0x10e2f0 ⟹ IOMallocAligned(0x4000,0x40) ⇒ 0x135809200
0xfea5c ⟹ IOMalloc(0x68) ⇒ 0x13470eb00
0xfa7a4 ⟹ IOLockLock(0x13463e2f0)
0xfb91c ⟹ IOUnlock(0x13463e2f0)
0xfa7a4 ⟹ IOLockLock(0x13463e2d0)
0x40924 ⟹ aes_decrypt_key(key=0x13470eb02,len=0x10,ctx=0x16d84b3a0)
0x4093c ⟹ aes_decrypt_cbc(in=0x102ddf000,iv=0x13470eb12,n_blk=0x100,out=0x134811800,c
tx=0x16d84b3a0)
        aes-128-cbc key: 6978[redacted]04f6, iv: b591[redacted]
[redacted]2497
0xfb91c ⟹ IOUnlock(0x13463e2d0)
0x10c094 ⟹ IOFree(0x13470eb00,0x68)
0x10e608 ⟹ IOFreeAligned(0x135809200,0x4000)
>>> calling fairplay decrypt page : EQlZPp(handle=0x70a231b3,off=0x36c000,src=0x102de00
00,dst=0x134811800)
0x10e2f0 ⟹ IOMallocAligned(0x4000,0x40) ⇒ 0x135809200
0xfea5c ⟹ IOMalloc(0x68) ⇒ 0x13470eb00
0xfa7a4 ⟹ IOLockLock(0x13463e2f0)
0xfb91c ⟹ IOUnlock(0x13463e2f0)
0xfa7a4 ⟹ IOLockLock(0x13463e2d0)
0x40924 ⟹ aes_decrypt_key(key=0x13470eb02,len=0x10,ctx=0x16d84b3a0)
0x4093c ⟹ aes_decrypt_cbc(in=0x102de0000,iv=0x13470eb12,n_blk=0x100,out=0x134811800,c
tx=0x16d84b3a0)
        aes-128-cbc key: 842d[redacted]238e, iv: 49ef[redacted]
[redacted]48c2
0xfb91c ⟹ IOUnlock(0x13463e2d0)
0x10c094 ⟹ IOFree(0x13470eb00,0x68)
0x10e608 ⟹ IOFreeAligned(0x135809200,0x4000)
```

图 14

最后，附上源码，欢迎大家进行参考和研究。

参考文献

- Eyrolles, N. (2017). Obfuscation with Mixed Boolean-Arithmetic Expressions: reconstruction, analysis and simplification tools (Doctoral dissertation, Universit é Paris-Saclay)
- https://github.com/obfuscator-llvm/obfuscator
- https://github.com/HikariObfuscator/Hikari
- https://github.com/keystone-engine/keypatch
- https://eshard.com/posts/d810_blog_post_1

作者简介

吴聊、落落、朱米，均来自美团信息安全部。

Spock 单元测试框架介绍以及在美团优选的实践

作者：建华

1. 背景

XML 之父 Tim Bray 最近在博客里有个好玩的说法：“代码不写测试就像上了厕所不洗手……单元测试是对软件未来的一项必不可少的投资。”具体来说，单元测试有哪些收益呢?

- 它是最容易保证代码覆盖率达到 100% 的测试。
- 可以大幅降低上线时的紧张指数。
- 单元测试能更快地发现问题（见下图左）。
- 单元测试的性价比最高，因为错误发现的越晚，修复它的成本就越高，而且难度呈指数式增长，所以我们要尽早地进行测试（见下图右）。
- 编码人员，一般也是单元测试的主要执行者，是唯一能够做到生产出无缺陷程序的人，其他任何人都无法做到这一点。
- 有助于源码的优化，使之更加规范，快速反馈，可以放心进行重构。

<table>
<tr>
<td> 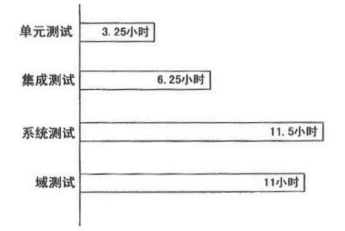

Microsoft applications, 10-20 defects/KLOC during unit testing, 0.5 defects/KLOC after release.
图 7-1 微软公司测试的数据统计结果</td>
<td> 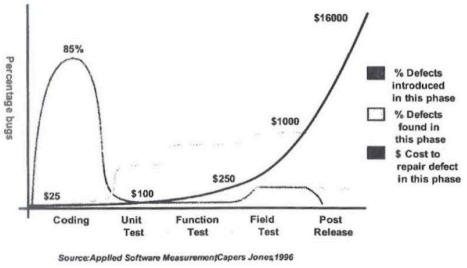

Source:Applied Software Measurement(Capers Jones,1996
图 7-2 测试中最容易出现缺陷的图示
pic2</td>
</tr>
<tr>
<td>这张图来自微软的统计数据：Bug 在单元测试阶段被发现，平均耗时 3.25 小时，如果漏到系统测试阶段，要花费 11.5 小时。</td>
<td>这张图，旨在说明两个问题：85% 的缺陷都在代码设计阶段产生，而发现 Bug 的阶段越靠后，耗费成本就越高，指数级别的增高。</td>
</tr>
</table>

尽管单元测试有如此的收益，但在我们日常的工作中，仍然存在不少项目它们的单元测试要么是不完整要么是缺失的。常见的原因总结如下：代码逻辑过于复杂；写单元测试时耗费的时间较长；任务重、工期紧，或者干脆就不写了。

基于以上问题，相较于传统的 JUnit 单元测试，今天为大家推荐一款名为 Spock 的测试框架。目前，美团优选物流技术团队绝大部分后端服务已经采用了 Spock 作为测试框架，在开发效率、可读性和维护性方面取得了不错的收益。

不过网上 Spock 资料比较简单，甚至包括官网的 Demo，无法解决我们项目中复杂业务场景面临的问题，通过深入学习和实践之后，本文会将一些经验分享出来，希望能够帮助大家提高开发测试的效率。

2. Spock 是什么？和 JUnit、jMock 有什么区别？

Spock 是一款国外优秀的测试框架，基于 BDD（行为驱动开发）思想实现，功能非常强大。Spock 结合 Groovy 动态语言的特点，提供了各种标签，并采用简单、通用、结构化的描述语言，让编写测试代码更加简洁、高效。官方的介绍如下：

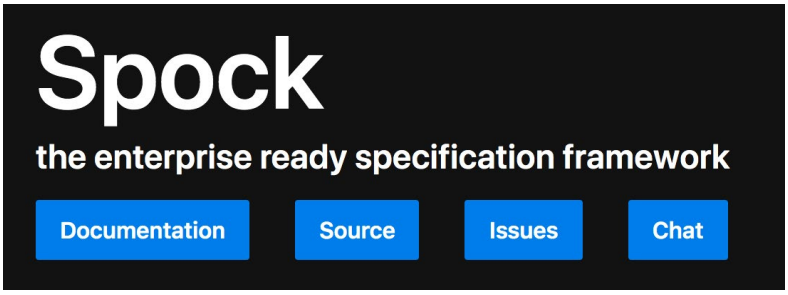

> What is it? Spock is a testing and specification framework for Java and Groovy applications. What makes it stand out from the crowd is its beautiful and highly expressive specification language. Thanks to its JUnit runner, Spock is compatible with most IDEs, build tools, and continuous integration servers. Spock is inspired from JUnit, RSpec, jMock, Mockito, Groovy, Scala, Vulcans, and other fascinating life forms.

Spock 是一个 Java 和 Groovy` 应用的测试和规范框架。之所以能够在众多测试框架中脱颖而出，是因为它优美而富有表现力的规范语言。Spock 的灵感来自 JUnit、RSpec、jMock、Mockito、Groovy、Scala、Vulcans。

简单来讲，Spock 主要特点如下：

- 让测试代码更规范，内置多种标签来规范单元测试代码的语义，测试代码结构清晰，更具可读性，降低后期维护难度。
- 提供多种标签，比如：`given`、`when`、`then`、`expect`、`where`、`with`、`thrown`……帮助我们应对复杂的测试场景。
- 使用 Groovy 这种动态语言来编写测试代码，可以让我们编写的测试代码更简洁，适合敏捷开发，提高编写单元测试代码的效率。
- 遵从 BDD（行为驱动开发）模式，有助于提升代码的质量。
- IDE 兼容性好，自带 Mock 功能。

为什么使用 Spock？ Spock 和 JUnit、jMock、Mockito 的区别在哪里?

总的来说，JUnit、jMock、Mockito 都是相对独立的工具，只是针对不同的业务场景提供特定的解决方案。其中 JUnit 单纯用于测试，并不提供 Mock 功能。

我们的服务大部分是分布式微服务架构。服务与服务之间通常都是通过接口的方式进行交互。即使在同一个服务内也会分为多个模块，业务功能需要依赖下游接口的返回数据，才能继续后面的处理流程。这里的下游不限于接口，还包括中间件数据存储比如 Squirrel、DB、MCC 配置中心等等，所以如果想要测试自己的代码逻辑，就必须把这些依赖项 Mock 掉。因为如果下游接口不稳定可能会影响我们代码的测试结果，让下游接口返回指定的结果集（事先准备好的数据），这样才能验证我们的代码是否正确，是否符合逻辑结果的预期。

尽管 jMock、Mockito 提供了 Mock 功能，可以把接口等依赖屏蔽掉，但不能对静态方法 Mock。虽然 PowerMock、jMockit 能够提供静态方法的 Mock，但它们之间也

需要配合（JUnit + Mockito PowerMock）使用，并且语法上比较繁琐。工具多了就会导致不同的人写出的单元测试代码“五花八门”，风格相差较大。

Spock 通过提供规范性的描述，定义多种标签（`given`、`when`、`then`、`where` 等），去描述代码“应该做什么”，“输入条件是什么”，“输出是否符合预期”，从语义层面规范了代码的编写。

Spock 自带 Mock 功能，使用简单方便（也支持扩展其他 Mock 框架，比如 PowerMock），再加上 Groovy 动态语言的强大语法，能写出简洁高效的测试代码，同时能方便直观地验证业务代码的行为流转，增强工程师对代码执行逻辑的可控性。

3. 使用 Spock 解决单元测试开发中的痛点

如果在（`if/else`）分支很多的复杂场景下，编写单元测试代码的成本会变得非常高，正常的业务代码可能只有几十行，但为了测试这个功能覆盖大部分的分支场景，编写的测试代码可能远不止几十行。

之前有遇到过某个功能上线很久一直都很正常，没有出现过问题，但后来有个调用请求的数据不一样，走到了代码中一个不常用的逻辑分支时，出现了 Bug。当时写这段代码的同学也认为只有很小几率才能走到这个分支，尽管当时写了单元测试，但因为时间比较紧张，分支又多，就漏掉了这个分支的测试。

尽管使用 JUnit 的 @Parametered 参数化注解或者 DataProvider 方式可以解决多数据分支问题，但不够直观，而且如果其中某一次分支测试 Case 出错了，它的报错信息也不够详尽。

这就需要一种编写测试用例高效、可读性强、占用工时少、维护成本低的测试框架。首先不能让业务人员排斥编写单元测试，更不能让工程师觉得写单元测试是在浪费时间。而且使用 JUnit 做测试工作量不算小。据初步统计，采用 JUnit 的话，它的测试代码行和业务代码行能到 3:1。如果采用 Spock 作为测试框架的话，它的比例可缩减到 1:1，能够大大提高编写测试用例的效率。

下面借用《编程珠玑》中一个计算税金的例子。

```
public double calc(double income) {
        BigDecimal tax;
        BigDecimal salary = BigDecimal.valueOf(income);
        if (income <= 0) {
            return 0;
        }
        if (income > 0 && income <= 3000) {
            BigDecimal taxLevel = BigDecimal.valueOf(0.03);
            tax = salary.multiply(taxLevel);
        } else if (income > 3000 && income <= 12000) {
            BigDecimal taxLevel = BigDecimal.valueOf(0.1);
            BigDecimal base = BigDecimal.valueOf(210);
            tax = salary.multiply(taxLevel).subtract(base);
        } else if (income > 12000 && income <= 25000) {
            BigDecimal taxLevel = BigDecimal.valueOf(0.2);
            BigDecimal base = BigDecimal.valueOf(1410);
            tax = salary.multiply(taxLevel).subtract(base);
        } else if (income > 25000 && income <= 35000) {
            BigDecimal taxLevel = BigDecimal.valueOf(0.25);
            BigDecimal base = BigDecimal.valueOf(2660);
            tax = salary.multiply(taxLevel).subtract(base);
        } else if (income > 35000 && income <= 55000) {
            BigDecimal taxLevel = BigDecimal.valueOf(0.3);
            BigDecimal base = BigDecimal.valueOf(4410);
            tax = salary.multiply(taxLevel).subtract(base);
        } else if (income > 55000 && income <= 80000) {
            BigDecimal taxLevel = BigDecimal.valueOf(0.35);
            BigDecimal base = BigDecimal.valueOf(7160);
            tax = salary.multiply(taxLevel).subtract(base);
        } else {
            BigDecimal taxLevel = BigDecimal.valueOf(0.45);
            BigDecimal base = BigDecimal.valueOf(15160);
            tax = salary.multiply(taxLevel).subtract(base);
        }
        return tax.setScale(2, BigDecimal.ROUND_HALF_UP).doubleValue();
    }
```

能够看到上面的代码中有大量的 `if-else` 语句，Spock 提供了 where 标签，可以让我们通过表格的方式来测试多种分支。

```
@Unroll
def "个税计算，收入:#income, 个税:#result"() {
  expect: "when + then 的组合"
  CalculateTaxUtils.calc(income) == result
```

```
    where: "表格方式测试不同的分支逻辑"
    income || result
    -1     || 0
    0      || 0
    2999   || 89.97
    3000   || 90.0
    3001   || 90.1
    11999  || 989.9
    12000  || 990.0
    12001  || 990.2
    24999  || 3589.8
    25000  || 3590.0
    25001  || 3590.25
    34999  || 6089.75
    35000  || 6090.0
    35001  || 6090.3
    54999  || 12089.7
    55000  || 12090
    55001  || 12090.35
    79999  || 20839.65
    80000  || 20840.0
    80001  || 20840.45
}
```

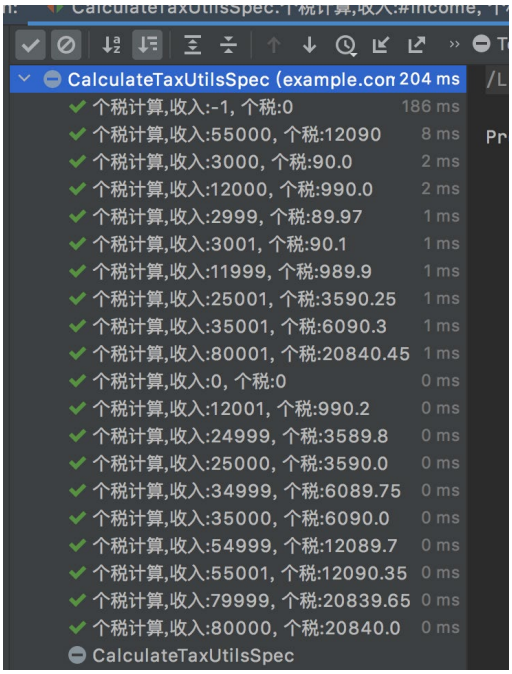

上图中左边使用 Spock 写的单元测试代码，语法简洁，表格方式测试覆盖分支场景更加直观，开发效率高，更适合敏捷开发。

单元测试代码的可读性和后期维护

我们微服务场景很多时候需要依赖其他接口返回的结果，才能验证自己的代码逻辑。Mock 工具是必不可少的。但 jMock、Mockito 的语法比较繁琐，再加上单元测试代码不像业务代码那么直观，又不能完全按照业务流程的思路写单元测试，这就让不少同学对单元测试代码可读性不够重视，最终导致测试代码难以阅读，维护起来更是难上加难。甚至很多同学自己写的单元测试，过几天再看也一样觉得“云里雾里”的。也有改了原来的代码逻辑导致单元测试执行失败的；或者新增了分支逻辑，单元测试没有覆盖到的；最终随着业务的快速迭代单元测试代码越来越难以维护。

Spock 提供多种语义标签，如：`given`、`when`、`then`、`expect`、`where`、`with`、`and` 等，从行为上规范了单元测试代码，每一种标签对应一种语义，让单元测试代码结构具有层次感，功能模块划分更加清晰，也便于后期的维护。

Spock 自带 Mock 功能，使用上简单方便（Spock 也支持扩展第三方 Mock 框架，比如 PowerMock）。我们可以再看一个样例，对于如下的代码逻辑进行单元测试：

```
public StudentVO getStudentById(int id) {
        List<StudentDTO> students = studentDao.getStudentInfo();
        StudentDTO studentDTO = students.stream().filter(u -> u.getId()
== id).findFirst().orElse(null);
        StudentVO studentVO = new StudentVO();
        if (studentDTO == null) {
            return studentVO;
        }
        studentVO.setId(studentDTO.getId());
        studentVO.setName(studentDTO.getName());
        studentVO.setSex(studentDTO.getSex());
        studentVO.setAge(studentDTO.getAge());
        // 邮编
        if ("上海".equals(studentDTO.getProvince())) {
            studentVO.setAbbreviation("沪");
            studentVO.setPostCode("200000");
        }
        if ("北京".equals(studentDTO.getProvince())) {
```

```
            studentVO.setAbbreviation("京");
            studentVO.setPostCode("100000");
        }
        return studentVO;
    }
```

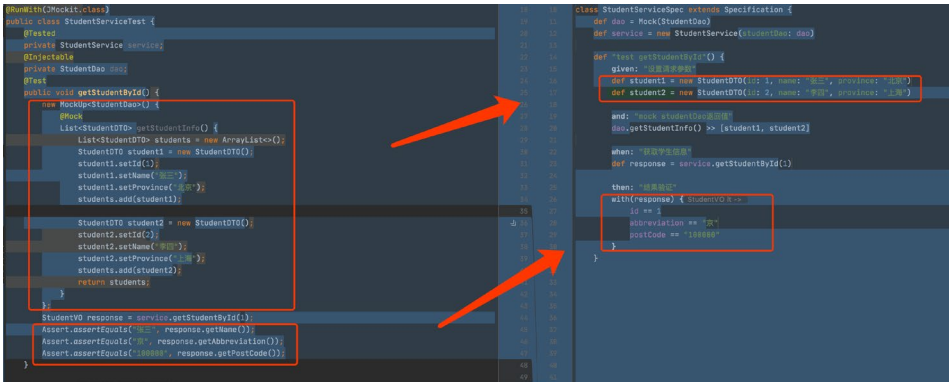

比较明显，左边的 JUnit 单元测试代码冗余，缺少结构层次，可读性差，随着后续的迭代，势必会导致代码的堆积，维护成本会变得越来越高。右边的单元测试代码 Spock 会强制要求使用 `given`、`when`、`then` 这样的语义标签（至少一个），否则编译不通过，这样就能保证代码更加规范，结构模块化，边界范围清晰，可读性强，便于扩展和维护。而且使用了自然语言描述测试步骤，让非技术人员也能看懂测试代码（`given` 表示输入条件，`when` 触发动作，`then` 验证输出结果）。

Spock 自带的 Mock 语法也非常简单：`dao.getStudentInfo() >> [student1, student2]`。

两个右箭头 `>>` 表示模拟 `getStudentInfo` 接口的返回结果，再加上使用的 Groovy 语言，可以直接使用 `[]` 中括号表示返回的是 `List` 类型。

单元测试不仅仅是为了统计代码覆盖率，更重要的是验证业务代码的健壮性、业务逻辑的严谨性以及设计的合理性

在项目初期阶段，可能为了追赶进度而没有时间写单元测试，或者这个时期写的单元测试只是为了达到覆盖率的要求（比如为了满足新增代码行或者分支覆盖率统计要求）。

很多工程师写的单元测试基本都是采用 Java 这种强类型语言编写，各种底层接口的 Mock 写起来不仅繁琐而且耗时。这时的单元测试代码可能就写得比较粗糙，有粒度过大的，也有缺少单元测试结果验证的。这样的单元测试对代码的质量帮助不大，更多是为了测试而测试。最后时间没少花，可效果却没有达到。

针对有效测试用例方面，我们测试基础组件组开发了一些检测工具（作为抓手），比如去扫描大家写的单元测试，检测单元测试的断言有效性等。另外在结果校验方面，Spock 表现也是十分优异的。我们可以来看接下来的场景：`void` 方法，没有返回结果，如何写测试这段代码的逻辑是否正确?

如何确保单元测试代码是否执行到了 `for` 循环里面的语句，循环里面的打折计算又是否正确呢?

```
    public void calculatePrice(OrderVO order){
        BigDecimal amount = BigDecimal.ZERO;
        for (SkuVO sku : order.getSkus()) {
            Integer skuId = sku.getSkuId();
            BigDecimal skuPrice = sku.getSkuPrice();
            BigDecimal discount = BigDecimal.valueOf(discountDao.
getDiscount(skuId));
            BigDecimal price = skuPrice * discount;
            amount = amount.add(price);
        }
        order.setAmount(amount.setScale(2, BigDecimal.ROUND_HALF_DOWN));
    }
```

如果用 Spock 写的话，就会方便很多，如下图所示：

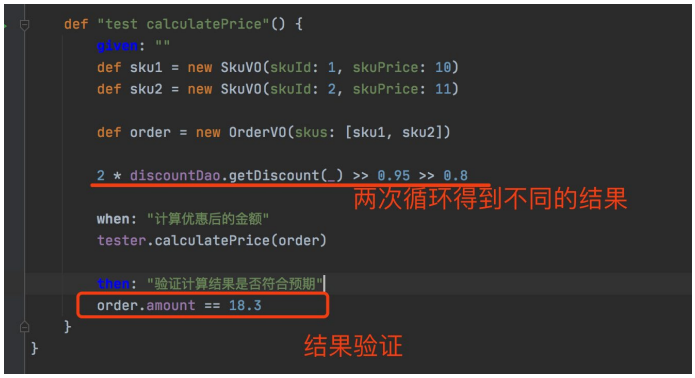

这里，`2 * discountDao.getDiscount(_) >> 0.95 >> 0.8` 在 `for` 循环中一共调用了 2 次，第一次返回结果 0.95，第二次返回结果 0.8，最后再进行验证，类似于 JUnit 中的 Assert 断言。

这样的收益还是比较明显的，不仅提高了单元测试的可控性，而且方便验证业务代码的逻辑正确性和合理性，这也是 BDD 思想的一种体现。

4. Mock 模拟

考虑如下场景，代码如下：

```
@Service
public class StudentService {
    @Autowired
    private StudentDao studentDao;
    public StudentVO getStudentById(int id) {
        List<StudentDTO> students = studentDao.getStudentInfo();
        StudentDTO studentDTO = students.stream().filter(u -> u.getId()
== id).findFirst().orElse(null);
        StudentVO studentVO = new StudentVO();
        if (studentDTO == null) {
            return studentVO;
        }
        studentVO.setId(studentDTO.getId());
        studentVO.setName(studentDTO.getName());
        studentVO.setSex(studentDTO.getSex());
        studentVO.setAge(studentDTO.getAge());
        // 邮编
        if ("上海".equals(studentDTO.getProvince())) {
            studentVO.setAbbreviation("沪");
            studentVO.setPostCode("200000");
        }
        if ("北京".equals(studentDTO.getProvince())) {
            studentVO.setAbbreviation("京");
            studentVO.setPostCode("100000");
        }
        return studentVO;
    }
}
```

其中 `studentDao` 是使用 Spring 注入的实例对象，我们只有拿到了返回的 `students`，才能继续下面的逻辑（根据 `id` 筛选学生，`DTO` 和 `VO` 转换，邮编等）。所以正常的做法是把 `studentDao` 的 `getStudentInfo()` 方法 Mock 掉，模拟一个指定的值，因为我们真正关心的是拿到 `students` 后自己代码的逻辑，这是需要重点验证

的地方。按照上面的思路使用 Spock 编写的测试代码如下：

```
class StudentServiceSpec extends Specification {
    def studentDao = Mock(StudentDao)
    def tester = new StudentService(studentDao: studentDao)

    def "test getStudentById"() {
        given: "设置请求参数"
        def student1 = new StudentDTO(id: 1, name: "张三", province: "北京")
        def student2 = new StudentDTO(id: 2, name: "李四", province: "上海")

        and: "mock studentDao 返回值"
        studentDao.getStudentInfo() >> [student1, student2]

        when: "获取学生信息"
        def response = tester.getStudentById(1)

        then: "结果验证"
        with(response) {
            id == 1
            abbreviation == "京"
            postCode == "100000"
        }
    }
}
```

这里主要讲解 Spock 的代码（从上往下）。

`def studentDao = Mock(StudentDao)` 这一行代码使用 Spock 自带的 Mock 方法，构造一个 `studentDao` 的 Mock 对象，如果要模拟 `studentDao` 方法的返回，只需 `studentDao.方法名() >> "模拟值"` 的方式，两个右箭头的方式即可。`test getStudentById` 方法是单元测试的主要方法，可以看到分为 4 个模块：`given`、`and`、`when`、`then`，用来区分不同单元测试代码的作用：

- `given`：输入条件（前置参数）。
- `when`：执行行为（`Mock` 接口、真实调用）。
- `then`：输出条件（验证结果）。
- `and`：衔接上个标签，补充的作用。

每个标签后面的双引号里可以添加描述，说明这块代码的作用（非强制），如 `when："获取信息"`。因为 Spock 使用 Groovy 作为单元测试开发语言，所以代码量上比使

用 Java 写的会少很多，比如 `given` 模块里通过构造函数的方式创建请求对象。

```
given: "设置请求参数"
def student1 = new StudentDTO(id: 1, name: "张三", province: "北京")
def student2 = new StudentDTO(id: 2, name: "李四", province: "上海")
```

实际上 `StudentDTO.java` 这个类并没有 3 个参数的构造方法，是 Groovy 帮我们实现的。Groovy 默认会提供一个包含所有对象属性的构造方法。而且调用方式上可以指定属性名，类似于 `key:value` 的语法，非常人性化，方便在属性多的情况下构造对象，如果使用 Java 写，可能就要调用很多的 `setXxx()` 方法，才能完成对象初始化的工作。

```
and: "mock studentDao返回值"
studentDao.getStudentInfo() >> [student1, student2]
```

这个就是 Spock 的 Mock 用法，当调用 `studentDao.getStudentInfo()` 方法时返回一个 `List`。`List` 的创建也很简单，中括号 `[]` 即表示 `List`，Groovy 会根据方法的返回类型，自动匹配是数组还是 `List`，而 `List` 里的对象就是之前 `given` 块里构造的 `user` 对象，其中 `>>` 就是指定返回结果，类似 `Mockito` 的 `when().thenReturn()` 语法，但更简洁一些。

如果要指定返回多个值的话，可以使用 `3` 个右箭头 `>>>`，比如：`studentDao.getStudentInfo() >>> [[student1,student2],[student3,student4],[student5,student6]]`。

也可以写成这样：`studentDao.getStudentInfo() >> [student1,student2] >> [student3,student4] >> [student5,student6]`。

每次调用 `studentDao.getStudentInfo()` 方法返回不同的值。

```
public List<StudentDTO> getStudentInfo(String id){
    List<StudentDTO> students = new ArrayList<>();
    return students;
}
```

这个 `getStudentInfo(String id)` 方法，有个参数 `id`，这种情况下如果使用 Spock 的 Mock 模拟调用的话，可以使用下划线 `_` 匹配参数，表示任何类型的参数，多个逗号隔开，类似于 `Mockito` 的 `any()` 方法。如果类中存在多个同名方法，可以通过 `_ as 参数类型` 的方式区别调用，如下面的语法：

```
// _ 表示匹配任意类型参数
List<StudentDTO> students = studentDao.getStudentInfo(_);

// 如果有同名的方法，使用 as 指定参数类型区分
List<StudentDTO> students = studentDao.getStudentInfo(_ as String);
```

`when` 模块里是真正调用要测试方法的入口 `tester.getStudentById()`。`then` 模块作用是验证被测方法的结果是否正确，符合预期值，所以这个模块里的语句必须是 `boolean` 表达式，类似于 JUnit 的 `assert` 断言机制，但不必显示地写 `assert`，这也是一种约定优于配置的思想。`then` 块中使用了 Spock 的 `with` 功能，可以验证返回结果 `response` 对象内部的多个属性是否符合预期值，这个相对于 JUnit 的 `assertNotNull` 或 `assertEquals` 的方式更简单一些。

强大的 Where

上面的业务代码有 2 个 `if` 判断，是对邮编处理逻辑：

```
    // 邮编
    if ("上海".equals(studentDTO.getProvince())) {
         studentVO.setAbbreviation("沪");
         studentVO.setPostCode("200000");
     }
     if ("北京".equals(studentDTO.getProvince())) {
         studentVO.setAbbreviation("京");
         studentVO.setPostCode("100000");
     }
```

如果要完全覆盖这 2 个分支就需要构造不同的请求参数，多次调用被测试方法才能走到不同的分支。在前面，我们介绍了 Spock 的 `where` 标签可以很方便的实现这种功能，代码如下所示：

```
    @Unroll
    def "input 学生 id:#id, 返回的邮编 :#postCodeResult, 返回的省份简称
:#abbreviationResult"() {
        given: "Mock 返回的学生信息"
        studentDao.getStudentInfo() >> students

        when: "获取学生信息"
        def response = tester.getStudentById(id)

        then: "验证返回结果"
        with(response) {
            postCode == postCodeResult
            abbreviation == abbreviationResult
        }
        where: "经典之处：表格方式验证学生信息的分支场景"
        id | students                    || postCodeResult |
abbreviationResult
        1  | getStudent(1, "张三", "北京") || "100000"       | "京"
        2  | getStudent(2, "李四", "上海") || "200000"       | "沪"
    }

    def getStudent(def id, def name, def province) {
        return [new StudentDTO(id: id, name: name, province: province)]
    }
```

where 模块第一行代码是表格的列名，多个列使用 | 单竖线隔开，|| 双竖线区分输入和输出变量，即左边是输入值，右边是输出值。格式如下：

输入参数 1 | 输入参数 2 || 输出结果 1 | 输出结果 2

而且 IntelliJ IDEA 支持 format 格式化快捷键，因为表格列的长度不一样，手动对齐比较麻烦。表格的每一行代表一个测试用例，即被测方法执行了 2 次，每次的输入和输出都不一样，刚好可以覆盖全部分支情况。比如 id、students 都是输入条件，其中 students 对象的构造调用了 getStudent 方法，每次测试业务代码传入不同的 student 值，postCodeResult、abbreviationResult 表示对返回的 response 对象的属性判断是否正确。第一行数据的作用是验证返回的邮编是否是 100000，第二行是验证邮编是否是 200000。这个就是 where+with 的用法，更符合我们实际测试的场景，既能覆盖多种分支，又可以对复杂对象的属性进行验证，其中在定义的测试方法名，使用了 Groovy 的字面值特性：

```
@Unroll
def "input 学生id:#id, 返回的邮编:#postCodeResult, 返回的省份简称:#abbreviationResult"() {
```

即把请求参数值和返回结果值的字符串动态替换掉，`#id`、`#postCodeResult`、`#abbreviationResult`# 号后面的变量是在方法内部定义的，实现占位符的功能。

`@Unroll` 注解，可以把每一次调用作为一个单独的测试用例运行，这样运行后的单元测试结果更加直观：

而且如果其中某行测试结果不对，Spock 的错误提示信息也很详细，方便进行排查（比如我们把第 1 条测试用例返回的邮编改成 `100001`）：

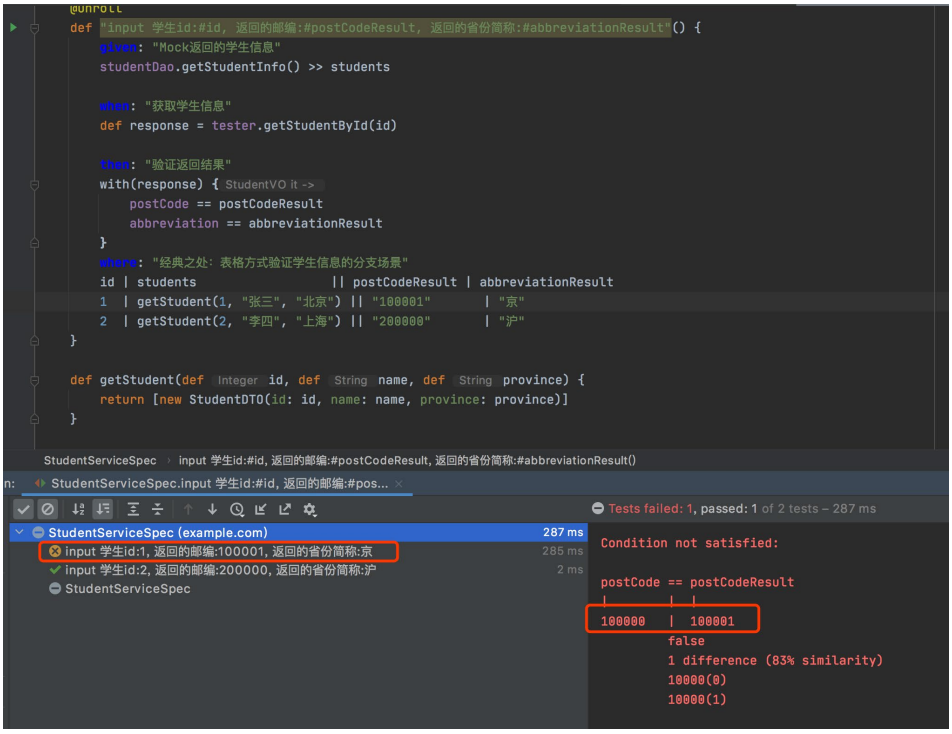

可以看出，第 1 条测试用例失败，错误信息是 `postCodeResult` 的预期结果和实际结果不符，业务代码逻辑返回的邮编是 `100000`，而我们预期的邮编是 `100001`，这样就可以排查是业务代码逻辑有问题，还是我们的断言不对。

5. 异常测试

我们再看下异常方面的测试，例如下面的代码：

```
 public void validateStudent(StudentVO student) throws BusinessException {
        if(student == null){
            throw new BusinessException("10001", "student is null");
        }
        if(StringUtils.isBlank(student.getName())){
           throw new BusinessException("10002", "student name is null");
        }
        if(student.getAge() == null){
            throw new BusinessException("10003", "student age is null");
        }
        if(StringUtils.isBlank(student.getTelephone())){
            throw new BusinessException("10004", "student telephone is
null");
        }
        if(StringUtils.isBlank(student.getSex())){
            throw new BusinessException("10005", "student sex is null");
        }
    }
```

`BusinessException` 是封装的业务异常，主要包含 `code`、`message` 属性：

```
/**
 * 自定义业务异常
 */
public class BusinessException extends RuntimeException {
    private String code;
    private String message;

    setXxx...
    getXxx...
}
```

这个大家应该都很熟悉，针对这种抛出多个不同错误码和错误信息的异常。如果使用 JUnit 的方式测试，会比较麻烦。如果是单个异常还好，如果是多个的话，测试代码

就不太好写。

```
@Test
public void testException() {
    StudentVO student = null;
    try {
        service.validateStudent(student);
    } catch (BusinessException e) {
        Assert.assertEquals(e.getCode(), "10001");
        Assert.assertEquals(e.getMessage(), "student is null");
    }

    student = new StudentVO();
    try {
        service.validateStudent(student);
    } catch (BusinessException e) {
        Assert.assertEquals(e.getCode(), "10002");
        Assert.assertEquals(e.getMessage(), "student name is null");
    }
}
```

当然可以使用 JUnit 的 `ExpectedException` 方式：

```
@Rule
public ExpectedException exception = ExpectedException.none();
exception.expect(BusinessException.class); // 验证异常类型
exception.expectMessage("xxxxxx"); // 验证异常信息
```

或者使用 `@Test(expected = BusinessException.class)` 注解，但这两种方式都有缺陷。

`@Test` 方式不能指定断言的异常属性，比如 `code`、`message`。`ExpectedException` 的方式也只提供了 `expectMessage` 的 API，对自定义的 `code` 不支持，尤其像上面的有很多分支抛出多种不同异常码的情况。接下来我们看下 Spock 是如何解决的。Spock 内置 `thrown()` 方法，可以捕获调用业务代码抛出的预期异常并验证，再结合 `where` 表格的功能，可以很方便地覆盖多种自定义业务异常，代码如下：

```
@Unroll
def "validate student info: #expectedMessage"() {
    when: "校验"
    tester.validateStudent(student)
```

```
        then: "验证"
        def exception = thrown(expectedException)
        exception.code == expectedCode
        exception.message == expectedMessage

        where: "测试数据"
        student            || expectedException | expectedCode |
expectedMessage
        getStudent(10001) || BusinessException | "10001"      | "student
is null"
        getStudent(10002) || BusinessException | "10002"      | "student
name is null"
        getStudent(10003) || BusinessException | "10003"      | "student
age is null"
        getStudent(10004) || BusinessException | "10004""     | "student
telephone is null"
        getStudent(10005) || BusinessException | "10005"      | "student
sex is null"
    }

    def getStudent(code) {
        def student = new StudentVO()
        def condition1 = {
            student.name = "张三"
        }
        def condition2 = {
            student.age = 20
        }
        def condition3 = {
            student.telephone = "12345678901"
        }
        def condition4 = {
            student.sex = "男"
        }

        switch (code) {
            case 10001:
                student = null
                break
            case 10002:
                student = new StudentVO()
                break
            case 10003:
                condition1()
                break
            case 10004:
                condition1()
                condition2()
```

```
                break
            case 10005:
                condition1()
                condition2()
                condition3()
                break
        }
        return student
    }
```

在 `then` 标签里用到了 Spock 的 `thrown()` 方法，这个方法可以捕获我们要测试的业务代码里抛出的异常。`thrown()` 方法的入参 `expectedException`，是我们自己定义的异常变量，这个变量放在 `where` 标签里就可以实现验证多种异常情况的功能（`Intellij Idea` 格式化快捷键，可以自动对齐表格）。`expectedException` 类型调用 `validateUser` 方法里定义的 `BusinessException` 异常，可以验证它所有的属性，`code`、`message` 是否符合预期值。

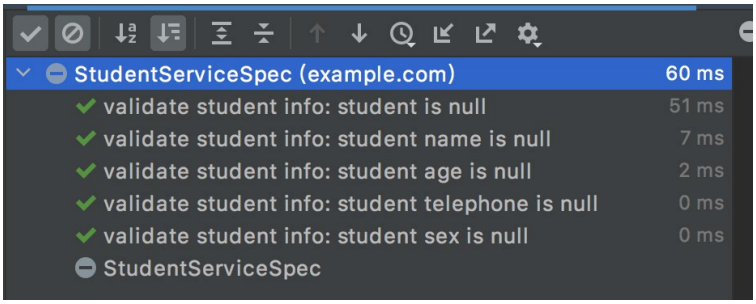

6. Spock 静态方法测试

接下来，我们一起看下 Spock 如何扩展第三方 PowerMock 对静态方法进行测试。

Spock 的单元测试代码继承自 `Specification` 基类，而 `Specification` 又是基于 JUnit 的注解 `@RunWith()` 实现的，代码如下：

```
@RunWith(Sputnik.class)
@SuppressWarnings("UnusedDeclaration")
public abstract class Specification extends MockingApi {
```

PowerMock 的 `PowerMockRunner` 也是继承自 JUnit，所以使用 PowerMock 的 `@PowerMockRunnerDelegate()` 注解，可以指定 Spock 的父类 `Sputnik` 去代理运行 PowerMock，这样就可以在 Spock 里使用 `PowerMock` 去模拟静态方法、`final` 方法、私有方法等。其实 Spock 自带的 GroovyMock 可以对 Groovy 文件的静态方法 Mock，但对 Java 代码支持不完整，只能 Mock 当前 Java 类的静态方法，官方给出的解释如下：

> Mocking Static Methods
>
> (Think twice before using this feature. It might be better to change the design of the code under specification.)
>
> Global mocks support mocking and stubbing of static methods:

```
RealSubscriber anySubscriber = GroovySpy(global: true)

1 * RealSubscriber.someStaticMethod("hello") >> 42
```

如下代码：

```
 public StudentVO getStudentByIdStatic(int id) {
        List<StudentDTO> students = studentDao.getStudentInfo();

        StudentDTO studentDTO = students.stream().filter(u -> u.getId()
== id).findFirst().orElse(null);
        StudentVO studentVO = new StudentVO();
        if (studentDTO == null) {
            return studentVO;
        }
        studentVO.setId(studentDTO.getId());
        studentVO.setName(studentDTO.getName());
        studentVO.setSex(studentDTO.getSex());
        studentVO.setAge(studentDTO.getAge());

        // 静态方法调用
        String abbreviation = AbbreviationProvinceUtil.
convert2Abbreviation(studentDTO.getProvince());
        studentVO.setAbbreviation(abbreviation);
        studentVO.setPostCode(studentDTO.getPostCode());

        return studentVO;
    }
```

上面使用了 `AbbreviationProvinceUtil.convert2Abbreviation()` 静态方

法，对应的测试用例代码如下：

```
@RunWith(PowerMockRunner.class)
@PowerMockRunnerDelegate(Sputnik.class)
@PrepareForTest([AbbreviationProvinceUtil.class])
@SuppressStaticInitializationFor(["example.com.
AbbreviationProvinceUtil"])
class StudentServiceStaticSpec extends Specification {
    def studentDao = Mock(StudentDao)
    def tester = new StudentService(studentDao: studentDao)

    void setup() {
        // mock 静态类
        PowerMockito.mockStatic(AbbreviationProvinceUtil.class)
    }

    def "test getStudentByIdStatic"() {
        given: "创建对象"
        def student1 = new StudentDTO(id: 1, name: "张三", province: "北京")
        def student2 = new StudentDTO(id: 2, name: "李四", province: "上海")

        and: "Mock 掉接口返回的学生信息"
        studentDao.getStudentInfo() >> [student1, student2]

        and: "Mock 静态方法返回值"
        PowerMockito.when(AbbreviationProvinceUtil.
convert2Abbreviation(Mockito.any())).thenReturn(abbreviationResult)

        when: "调用获取学生信息方法"
        def response = tester.getStudentByIdStatic(id)

        then: "验证返回结果是否符合预期值"
        with(response) {
            abbreviation == abbreviationResult
        }
        where:
        id || abbreviationResult
        1  || "京"
        2  || "沪"
    }
}
```

在 `StudentServiceStaticSpec` 类的头部使用 `@PowerMockRunnerDelegate(Sputnik.class)` 注解，交给 Spock 代理执行，这样既可以使用 Spock +Groovy 的各种功能，又可以使用 PowerMock 的对静态，`final` 等方法的 Mock。

`@SuppressStaticInitializationFor(["example.com.AbbreviationProvinceUtil"])`，这行代码的作用是限制 `AbbreviationProvinceUtil` 类里的静态代码块初始化，因为 `AbbreviationProvinceUtil` 类在第一次调用时可能会加载一些本地资源配置，所以可以使用 PowerMock 禁止初始化。然后在 `setup()` 方法里对静态类进行 Mock 设置，`PowerMockito.mockStatic(AbbreviationProvinceUtil.class)`。最后在 `test getStudentByIdStatic` 测试方法里对 `convert2Abbreviation()` 方法指定返回默认值：`PowerMockito.when(AbbreviationProvinceUtil.convert2Abbreviation(Mockito.any())).thenReturn(abbreviationResult)`。

运行时在控制台会输出：

Notifications are not supported for behaviour ALL_TESTINSTANCES_ARE_CREATED_FIRST

这是 Powermock 的警告信息，不影响运行结果。

如果单元测试代码不需要对静态方法、`final` 方法 Mock，就没必要使用 PowerMock，使用 Spock 自带的 `Mock()` 就足够了。因为 PowerMock 的原理是在编译期通过 ASM 字节码修改工具修改代码，然后使用自己的 `ClassLoader` 加载，而加载的静态方法越多，测试耗时就会越长。

7. 动态 Mock 静态方法

考虑场景，让静态方法每次调用返回不同的值。

以下代码：

```
public List<OrderVO> getOrdersBySource(){
        List<OrderVO> orderList = new ArrayList<>();
        OrderVO order = new OrderVO();
        if ("APP".equals(HttpContextUtils.getCurrentSource())) {
            if("CNY".equals(HttpContextUtils.getCurrentCurrency())){
                System.out.println("source -> APP, currency -> CNY");
            } else {
                System.out.println("source -> APP, currency -> !CNY");
            }
            order.setType(1);
        } else if ("WAP".equals(HttpContextUtils.getCurrentSource())) {
            System.out.println("source -> WAP");
            order.setType(2);
        } else if ("ONLINE".equals(HttpContextUtils.getCurrentSource()))
{
            System.out.println("source -> ONLINE");
            order.setType(3);
        }
        orderList.add(order);
        return orderList;
}
```

这段代码的 `if else` 分支逻辑，主要是依据 `HttpContextUtils` 这个工具类的静态方法 `getCurrentSource()` 和 `getCurrentCurrency()` 的返回值来决定流程。这样的业务代码也是我们平时写单元测试时经常遇到的场景，如果能让 `HttpContextUtils.getCurrentSource()` 静态方法每次 Mock 出不同的值，就可以很方便地覆盖 `if else` 的全部分支逻辑。Spock 的 `where` 标签可以方便地和 PowerMock 结合使用，让 PowerMock 模拟的静态方法每次返回不同的值，代码如下：

```
    /**
     * PowerMock
     */
    @Unroll
    def "when source=#source, order type=#type" () {
        given: "mock来源"
        PowerMockito.when(HttpContextUtils.getCurrentSource()).thenReturn(source)

        and: "mock币种"
        PowerMockito.when(HttpContextUtils.getCurrentCurrency()).thenReturn(currency)

        when: "执行"
        def orderList = orderService.getUserOrdersBySource()

        then: "验证结果"
        with(orderList) { List<OrderVO> it ->
            it[0].type == type
        }

        where: "表格方式验证订单信息的分支场景"
        source   | currency || type
        "APP"    | "CNY"    || 1
        "APP"    | "USD"    || 1
        "WAP"    | ""       || 2
        "ONLINE" | ""       || 3
    }
}
```

PowerMock 的 `thenReturn` 方法返回的值是 `source` 和 `currency` 等 2 个变量，不是具体的数据，这 2 个变量对应 `where` 标签里的前两列 `source|currency`。这样的写法，就可以在每次测试业务方法时，让 `HttpContextUtils.getCurrentSource()` 和 `HttpContextUtils.getCurrentCurrency()` 返回不同的来源和币种，就能轻松的覆盖 `if` 和 `else` 的分支代码。即 Spock 使用 `where` 表格的方式让 PowerMock 具有了动态 Mock 的功能。接下来，我们再看一下如何对于 `final` 变量进行 Mock。

```
public List<OrderVO> convertOrders(List<OrderDTO> orders){
        List<OrderVO> orderList = new ArrayList<>();
        for (OrderDTO orderDTO : orders) {
            OrderVO orderVO = OrderMapper.INSTANCE.convert(orderDTO);
            if (1 == orderVO.getType()) {
                orderVO.setOrderDesc("App 端订单 ");
            } else if(2 == orderVO.getType()) {
                orderVO.setOrderDesc("H5 端订单 ");
            } else if(3 == orderVO.getType()) {
                orderVO.setOrderDesc("PC 端订单 ");
            }
```

```
            orderList.add(orderVO);
        }
        return orderList;
}
```

这段代码里的 `for` 循环第一行调用了 `OrderMapper.INSTANCE.convert()` 转换方法，将 `orderDTO` 转换为 `orderVO`，然后根据 `type` 值走不同的分支，而 `OrderMapper` 是一个接口，代码如下：

```
@Mapper
public interface OrderMapper {
    // 即使不用 static final 修饰，接口里的变量默认也是静态、final 的
    static final OrderMapper INSTANCE = Mappers.getMapper(OrderMapper.
class);

    @Mappings({})
    OrderVO convert(OrderDTO requestDTO);
}
```

`INSTANCE` 是接口 `OrderMapper` 里定义的变量，接口里的变量默认都是 `static final` 的，所以我们要先把这个 `INSTANCE` 静态 `final` 变量 Mock 掉，这样才能调用它的方法 `convert()` 返回我们想要的值。`OrderMapper` 这个接口是 `mapstruct` 工具的用法，`mapstruct` 是做对象属性映射的一个工具，它会自动生成 `OrderMapper` 接口的实现类，生成对应的 `set`、`get` 方法，把 `orderDTO` 的属性值赋给 `orderVO` 属性，通常情况下会比使用反射的方式好不少。看下 Spock 如何写这个单元测试：

```
@Unroll
def "test convertOrders"() {
  given: "Mock 掉 OrderMapper 的静态 final 变量 INSTANCE，并结合 Spock 设置动态返
回值"
  def orderMapper = Mock(OrderMapper.class)
  Whitebox.setInternalState(OrderMapper.class, "INSTANCE", orderMapper)
  orderMapper.convert(_) >> order

  when:
  def orders = service.convertOrders([new OrderDTO()])

  then: "验证结果"
  with(orders) {
```

```
        it[0].orderDesc == desc
    }

    where: "测试数据"
    order                  || desc
    new OrderVO(type: 1)   || "App 端订单"
    new OrderVO(type: 2)   || "H5 端订单"
    new OrderVO(type: 3)   || "PC 端订单"
}
```

- 首先使用 Spock 自带的 `Mock()` 方法，将 `OrderMapper` 类 Mock 为一个模拟对象 `orderMapper`，`def orderMapper = Mock(OrderMapper.class)`。
- 然后使用 PowerMock 的 `Whitebox.setInternalState()`，对 `OrderMapper` 接口的 `static final` 常量 `INSTANCE` 赋值（`Spock` 不支持静态常量的 `Mock`），赋的值正是使用 SpockMock 的对象 `orderMapper`。
- 使用 Spock 的 Mock 模拟 `convert()` 方法调用，`orderMapper.convert(_) >> order`，再结合 `where` 表格，实现动态 Mock 接口的功能。

主要是这 3 行代码：

```
def orderMapper = Mock(OrderMapper.class) // 先使用 Spock 的 Mock
Whitebox.setInternalState(OrderMapper.class, "INSTANCE", orderMapper) //
通过 PowerMock 把 Mock 对象 orderMapper 赋值给静态常量 INSTANCE
orderMapper.convert(_) >> order // 结合 where 模拟不同的返回值
```

这样就可以使用 Spock 结合 PowerMock 测试静态常量，达到覆盖 if else 不同分支逻辑的功能。

8. 覆盖率

Jacoco 是统计单元测试覆盖率的一种工具，当然 Spock 也自带了覆盖率统计的功能，这里使用第三方 Jacoco 的原因主要是国内公司使用的比较多一些，包括美团很多技术团队现在使用的也是 Jacoco，所以为了兼容就以 Jacoco 来查看单元测试覆盖率。这里说下如何通过 Jacoco 确认分支是否完全覆盖到。

在 pom 文件里引用 Jacoco 的插件：`jacoco-maven-plugin`，然后执行 `mvn`

`package` 命令，成功后会在 target 目录下生成单元测试覆盖率的报告，点开报告找到对应的被测试类查看覆盖情况。

```
20.     */
21.    public static Map<String, String> getBirAgeSex(String certificateNo) {
22.        String birthday = "";
23.        String age = "";
24.        String sex = "";
25.
26.        int year = Calendar.getInstance().get(Calendar.YEAR);
27.        char[] number = certificateNo.toCharArray();
28.        boolean flag = true;
29.        if (number.length == 15) {
30.            for (int x = 0; x < number.length; x++) {
31.                if (!flag) return new HashMap<>();
32.                flag = Character.isDigit(number[x]);
33.            }
34.        } else if (number.length == 18) {
35.            for (int x = 0; x < number.length - 1; x++) {
36.                if (!flag) return new HashMap<>();
37.                flag = Character.isDigit(number[x]);
38.            }
39.        }
40.        if (flag && certificateNo.length() == 15) {
41.            birthday = "19" + certificateNo.substring(6, 8) + "-"
42.                    + certificateNo.substring(8, 10) + "-"
43.                    + certificateNo.substring(10, 12);
44.            sex = Integer.parseInt(certificateNo.substring(certificateNo.length() - 3,
45.                    certificateNo.length())) % 2 == 0 ? "女" : "男";
46.            age = (year - Integer.parseInt("19" + certificateNo.substring(6, 8))) + "";
47.        } else if (flag && certificateNo.length() == 18) {
48.            birthday = certificateNo.substring(6, 10) + "-"
49.                    + certificateNo.substring(10, 12) + "-"
50.                    + certificateNo.substring(12, 14);
51.            sex = Integer.parseInt(certificateNo.substring(certificateNo.length() - 4,
52.                    certificateNo.length() - 1)) % 2 == 0 ? "女" : "男";
53.            age = (year - Integer.parseInt(certificateNo.substring(6, 10))) + "";
54.        }
55.        Map<String, String> map = new HashMap<>();
56.        map.put("birthday", birthday);
57.        map.put("age", age);
58.        map.put("sex", sex);
59.        return map;
```

绿色背景表示完全覆盖，黄色是部分覆盖，红色没有覆盖到。比如第 `34` 行黄色背景的 `else if()` 判断，提示有二分之一的分支缺失，虽然它下面的代码也被覆盖了（显示为绿色），这种情况跟具体使用哪种单元测试框架没关系，因为这只是分支覆盖率统计的规则，只不过使用 Spock 的话，解决起来会更简单，只需在 `where` 下增加一行针对的测试数据即可。

9. DAO 层测试

DAO 层的测试有些不太一样，不能再使用 Mock，否则无法验证 SQL 是否正确。对于 DAO 测试有一般最简的方式是直接使用 `@SpringBootTest` 注解启动测试环境，通过 Spring 创建 Mybatis、Mapper 实例，但这种方式并不属于单元测试，而是集

成测试范畴了，因为当启用 `@SpringBootTest` 时，会把整个应用的上下文加载进来。不仅耗时时间长，而且一旦依赖环境上有任何问题，可能会影响启动，进而影响 DAO 层的测试。最后，需要到数据库尽可能隔离，因为如果大家都使用同一个 Test 环境的数据的话，一旦测试用例编写有问题，就可能会污染 Test 环境的数据。

针对以上场景，可采用以下方案：1. 通过 MyBatis 的 SqlSession 启动 mapper 实例（避免通过 Spring 启动加载上下文信息）。 2. 通过内存数据库（如 H2）隔离大家的数据库连接（完全隔离不会存在互相干扰的现象）。 3. 通过 DBUnit 工具，用作对于数据库层的操作访问工具。 4. 通过扩展 Spock 的注解，提供对于数据库 Schema 创建和数据 Data 加载的方式。如 csv、xml 或直接 `Closure` 编写等。

在 pom 文件增加相应的依赖。

```
<dependency>
     <groupId>com.h2database</groupId>
     <artifactId>h2</artifactId>
     <version>1.4.200</version>
     <scope>test</scope>
 </dependency>
 <dependency>
     <groupId>org.dbunit</groupId>
     <artifactId>dbunit</artifactId>
     <version>2.5.1</version>
     <scope>test</scope>
 </dependency>
```

增加 Groovy 的 maven 插件、资源文件拷贝以及测试覆盖率统计插件。

```
<!-- 测试插件 -->
<plugin>
  <groupId>org.codehaus.gmavenplus</groupId>
  <artifactId>gmavenplus-plugin</artifactId>
  <version>1.8.1</version>
  <executions>
    <execution>
      <goals>
        <goal>addSources</goal>
        <goal>addTestSources</goal>
        <goal>generateStubs</goal>
        <goal>compile</goal>
```

```
            <goal>generateTestStubs</goal>
            <goal>compileTests</goal>
            <goal>removeStubs</goal>
            <goal>removeTestStubs</goal>
          </goals>
        </execution>
      </executions>
    </plugin>
    <plugin>
      <groupId>org.apache.maven.plugins</groupId>
      <artifactId>maven-surefire-plugin</artifactId>
      <version>3.0.0-M3</version>
      <configuration>
        <useFile>false</useFile>
        <includes>
          <include>**/*Spec.java</include>
        </includes>
        <parallel>methods</parallel>
        <threadCount>10</threadCount>
        <testFailureIgnore>true</testFailureIgnore>
      </configuration>
    </plugin>
    <plugin>
      <groupId>org.apache.maven.plugins</groupId>
      <artifactId>maven-resources-plugin</artifactId>
      <version>2.6</version>
      <executions>
        <execution>
          <id>copy-resources</id>
          <phase>compile</phase>
          <goals>
            <goal>copy-resources</goal>
          </goals>
          <configuration>
            <outputDirectory>${basedir}/target/resources</outputDirectory>
            <resources>
              <resource>
                <directory>${basedir}/src/main/resources</directory>
                <filtering>true</filtering>
              </resource>
            </resources>
          </configuration>
        </execution>
      </executions>
    </plugin>
    <plugin>
      <groupId>org.jacoco</groupId>
      <artifactId>jacoco-maven-plugin</artifactId>
      <version>0.8.2</version>
```

```
    <executions>
      <execution>
        <id>prepare-agent</id>
        <goals>
          <goal>prepare-agent</goal>
        </goals>
      </execution>
      <execution>
        <id>report</id>
        <phase>prepare-package</phase>
        <goals>
          <goal>report</goal>
        </goals>
      </execution>
      <execution>
        <id>post-unit-test</id>
        <phase>test</phase>
        <goals>
          <goal>report</goal>
        </goals>
        <configuration>
          <dataFile>target/jacoco.exec</dataFile>
          <outputDirectory>target/jacoco-ut</outputDirectory>
        </configuration>
      </execution>
    </executions>
  </plugin>
```

加入对于 Spock 扩展的自动处理框架（用于数据 `Schema` 和 `Data` 初始化操作）。

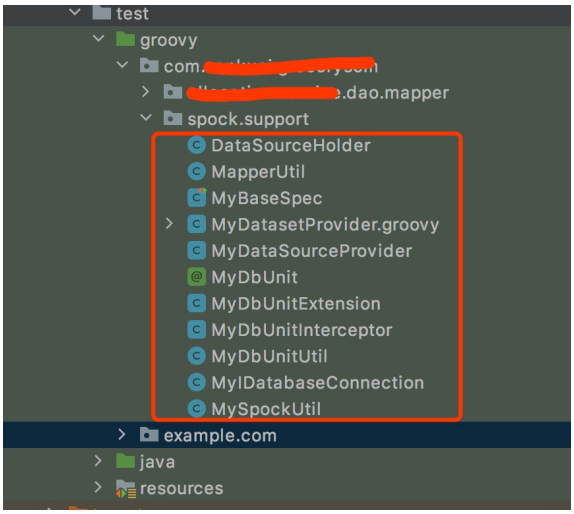

这里介绍一下主要内容，注解 `@MyDbUnit`：

```
@Retention(RetentionPolicy.RUNTIME)
@Target(ElementType.METHOD)
@ExtensionAnnotation(MyDbUnitExtension.class)
@interface MyDbUnit {
    /**
     * <pre>
     * content = {
     *     your_table_name(id: 1, name: 'xxx', age: 21)
     *     your_table_name(id: 2, name: 'xxx', age: 22)
     * })
     </pre>
     * @return
     */
    Class<? extends Closure> content() default Closure.class;
    /**
     * xml 存放路径（相对于测试类）
     * @return
     */
    String xmlLocation() default "";
    /**
     * csv 存放路径（相对于测试类）
     * @return
     */
    String csvLocation() default "";
}
```

考虑以下代码的测试：

```
@Repository("personInfoMapper")
public interface PersonInfoMapper {
    @Delete("delete from person_info where id=#{id}")
    int deleteById(Long id);

    @Select("select count(*) from person_info")
    int count();

    @Select("select * from user_info")
    List<PersonInfoDO> selectAll();
}
```

`Demo1`（使用 `@MyDbUnit`，`content` 指定导入数据内容，格式 `Closure`）。

```
class Demo1Spec extends MyBaseSpec {
```

```
    /**
     * 直接获取待测试的 mapper
     */
    def personInfoMapper = MapperUtil.getMapper(PersonInfoMapper.class)

    /**
     * 测试数据准备，通常为 sql 表结构创建用的 ddl，支持多个文件以逗号分隔。
     */
    def setup() {
        executeSqlScriptFile("com/xxx/xxx/xxx/........./schema.sql")
    }
    /**
     * 数据表清除，通常待 drop 的数据表
     */
    def cleanup() {
        dropTables("person_info")
    }

    /**
     * 直接构造数据库中的数据表，此方法适用于数据量较小的 mapper sql 测试
     */
    @MyDbUnit(
            content = {
                person_info(id: 1, name: "abc", age: 21)
                person_info(id: 2, name: "bcd", age: 22)
                person_info(id: 3, name: "cde", age: 23)
            }
    )
    def "demo1_01"() {
        when:
        int beforeCount = personInfoMapper.count()
        // groovy sql 用于快速执行 sql，不仅能验证数据结果，也可向数据中添加数据。
        def result = new Sql(dataSource).firstRow("select * from
'person_info'")
        int deleteCount = personInfoMapper.deleteById(1L)
        int afterCount = personInfoMapper.count()

        then:
        beforeCount == 3
        result.name == "abc"
        deleteCount == 1
        afterCount == 2
    }

    /**
     * 直接构造数据库中的数据表，此方法适用于数据量较小的 mapper sql 测试
     */
    @MyDbUnit(content = {
        person_info(id: 1, name: 'a', age: 21)
```

```
    })
    def "demo1_02"() {
        when:
        int beforeCount = personInfoMapper.count()
        def result = new Sql(dataSource).firstRow("select * from
'person_info'")
        int deleteCount = personInfoMapper.deleteById(1L)
        int afterCount = personInfoMapper.count()

        then:
        beforeCount == 1
        result.name == "a"
        deleteCount == 1
        afterCount == 0
    }
}
```

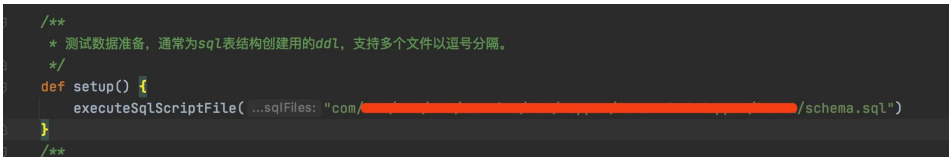

在 `setup()` 阶段，把数据库表中的 `Schema` 创建好，然后通过下面的 `@MyDbUnit` 注解的 `content` 属性，把数据导入到数据库中。`person_info` 是表名，`id`、`name`、`age` 是数据。

```
/**
 * 直接构造数据库中的数据表,此方法适用于数据量较小的mapper sql测试
 */
@MyDbUnit(
        content = {
            person_info(id: 1, name: "abc", age: 21)
            person_info(id: 2, name: "bcd", age: 22)
            person_info(id: 3, name: "cde", age: 23)
        }
)
```

通过 `MapperUtil.getMapper()` 方法获取 `mapper` 实例。

```
/**
 * 直接获取待测试的mapper
 */
def personInfoMapper = MapperUtil.getMapper(PersonInfoMapper.class)
```

当测试数据量较大时，可以编写相应的数据文件，通过 `@MyDbUnit` 的 `xmlLocation` 或 `csvLocation` 加载文件（分别支持 csv 和 xml 格式）。

```
@Retention(RetentionPolicy.RUNTIME)
          @Target(ElementType.METHOD)
          @ExtensionAnnotation(MyDbUnitExtension.class)
@interface MyDbUnit {
    /**
     * <pre>
     * content = {
     *    your_table_name(id: 1, name: 'xxx', age: 21)
     *    your_table_name(id: 2, name: 'xxx', age: 22)
     * })
     </pre>
     * @return
     */
    Class<? extends Closure> content() default Closure.class;
    /**
     * xml存放路径(相对于测试类)
     * @return
     */
    String xmlLocation() default "";
    /**
     * csv存放路径(相对于测试类)
     * @return
     */
    String csvLocation() default "";
}
```

如通过 csv 加载文件，`csvLocation` 指向 csv 文件所在文件夹。

```
@MyDbUnit(csvLocation = "com/xxx/........./data01")
    def "demo2_01"() {
        when:
        int beforeCount = personInfoMapper.count()
```

```
        def result = new Sql(dataSource).firstRow("select * from
'person_info'")
        int deleteCount = personInfoMapper.deleteById(1L)
        int afterCount = personInfoMapper.count()

        then:
        beforeCount == 3
        result.name == "abc"
        deleteCount == 1
        afterCount == 2
    }
```

通过 xml 加载文件，`xmlLocation` 指向 xml 文件所在路径。

```
@MyDbUnit(xmlLocation = "com/xxxx/........./demo3_02.xml")
    def "demo3_02"() {
        when:
        int beforeCount = personInfoMapper.count()
        def result = new Sql(dataSource).firstRow("select * from
'person_info'")
        int deleteCount = personInfoMapper.deleteById(1L)
        int afterCount = personInfoMapper.count()

        then:
        beforeCount == 1
        result.name == "a"
        deleteCount == 1
        afterCount == 0
    }
```

还可以不通过 `@MyDbUnit` 而使用 API 直接加载测试数据文件。

```
class Demo4Spec extends MyBaseSpec {
    def personInfoMapper = MapperUtil.getMapper(PersonInfoMapper.class)

    /**
     * 数据表清除，通常待 drop 的数据表
     */
    def cleanup() {
        dropTables("person_info")
    }
    def "demo4_01"() {
        given:
        executeSqlScriptFile("com/xxxx/.........../schema.sql")
        IDataSet dataSet = MyDbUnitUtil.loadCsv("com/xxxx/.........../
data01");
        DatabaseOperation.CLEAN_INSERT.execute(MyIDatabaseConnection.
```

```
getInstance().getConnection(), dataSet);

        when:
        int beforeCount = personInfoMapper.count()
        def result = new Sql(dataSource).firstRow("select * from
'person_info'")
        int deleteCount = personInfoMapper.deleteById(1L)
        int afterCount = personInfoMapper.count()

        then:
        beforeCount == 3
        result.name == "abc"
        deleteCount == 1
        afterCount == 2
    }

    def "demo4_02"() {
        given:
        executeSqlScriptFile("com/xxxx/...../schema.sq")
        IDataSet dataSet = MyDbUnitUtil.loadXml("com/xxxx/...../
demo3_02.xml");
        DatabaseOperation.CLEAN_INSERT.execute(MyIDatabaseConnection.
getInstance().getConnection(), dataSet);

        when:
        int beforeCount = personInfoMapper.count()
        def result = new Sql(dataSource).firstRow("select * from
'person_info'")
        int deleteCount = personInfoMapper.deleteById(1L)
        int afterCount = personInfoMapper.count()

        then:
        beforeCount == 1
        result.name == "a"
        deleteCount == 1
        afterCount == 0
    }
}
```

最后为大家梳理了一些文档，供大家参考。

Spock Framework Reference Documentation
老 K 的 Java 博客

作者简介

建华，美团优选事业部工程师。

美团 App 页面视图可测性改造实践

作者：张杰

美团 App 的页面特点

对于不同的用户，美团 App 页面的呈现方式其实多种多样，这就是所谓的“千人千面”。以美团首页的“猜你喜欢”模块为例，针对与不同的用户有单列、Tab、双列等多种不同形式。这么多不同的页面样式需求，如果要在 1 天内时间内完成开发、测试、上线流程，研发团队也面临着很大的挑战。所以测试工程师就需要重度依赖自动化测试来形成快速的验收机制。

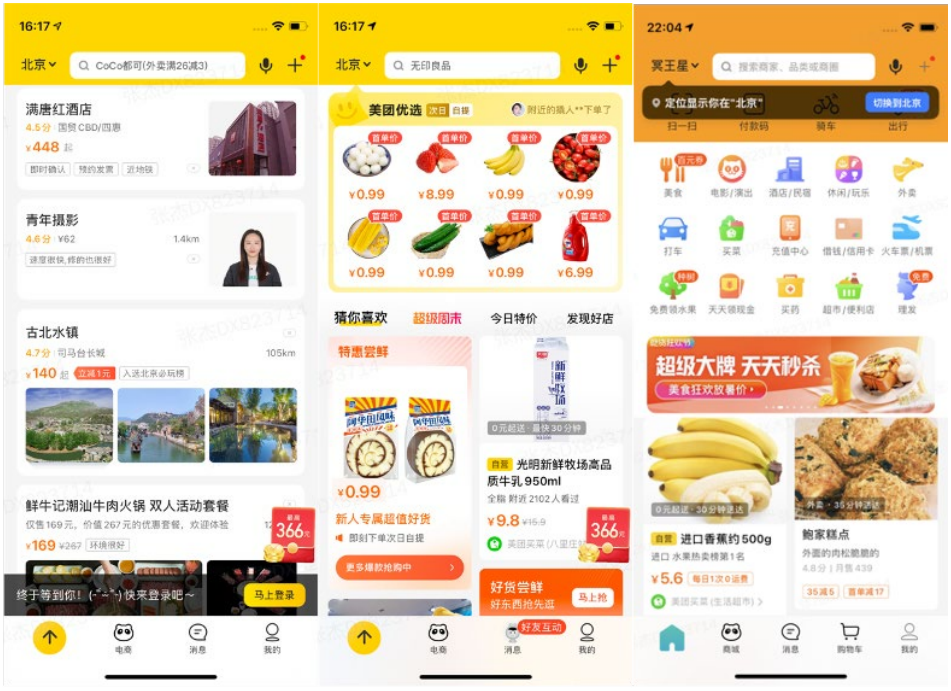

图 1　美团 App 首页多种页面布局样式

自动化测试实施中的技术挑战

接下来，本文将会从页面元素无法定位、Appium 元素定位的原理、AccessibilityNodeInfo 和 Drawable 等三个维度进行阐述。

页面元素无法定位

图 2　页面元素审查情况

目前，美团 App 客户端自动化主要依托于 Appium（一个开源、跨平台的测试框架，可以用来测试原生及混合的移动端应用）来实现页面元素的定位和操作，当我们通过 Appium Inspector 进行页面元素审查时，能通过元素审查找到的信息只有外面的边框和下方的两个按钮，其他信息均无法识别（如上图 2 所示）。中央位置的图片、左上角的文本信息都无法通过现有的 UI 自动化方案进行定位和解析。不能定位元素，也就无法进行页面的操作和断言，这就严重影响了自动化的实施工作。

经过进一步的调研，我们发现这些页面卡片中大量使用 Drawable 对象来绘制页面的信息，从而导致元素无法进行定位。为什么 Drawable 对象无法定位呢？下面我们一起研究一下 UI 自动化元素定位的原理。

Appium 元素定位的原理

目前的 UI 自动化测试，使用 Appium 进行页面元素的定位和操作。如下图所示，AppiumServer 和 UiAutomator2 的手机端进行通信后完成元素的操作。

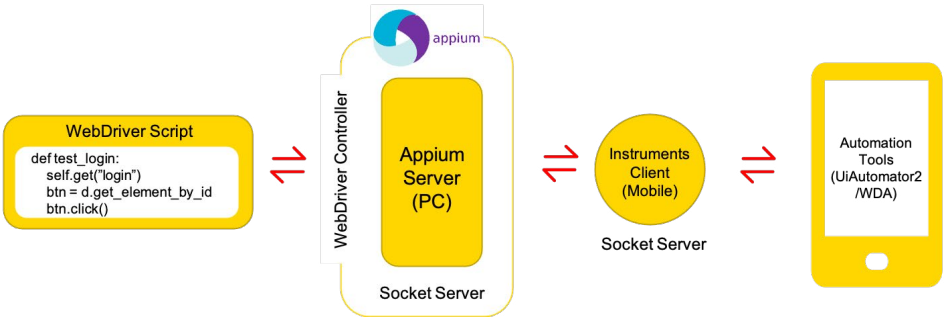

图 3　Appium 的通信原理

通过阅读 Appium 源码发现完成一次定位的流程如下图所示：

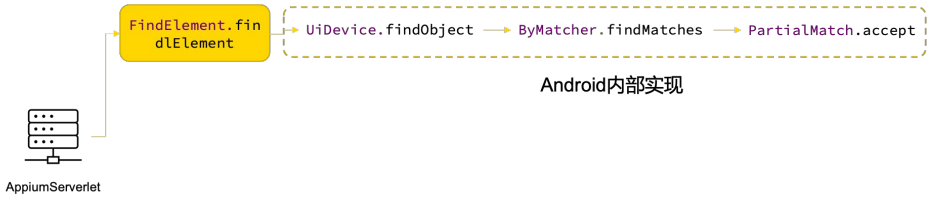

图 4　Appium 定位元素的实现流程

- 首先，Appium 通过调用 `findElement` 的方式进行元素定位。
- 然后，调用 Android 提供 `UIDevice` 对象的 `findObject` 方法。
- 最终，通过 `PartialMatch.accept` 完成元素的查找。

接下来我们看一下，这个 `PartialMatch.accept` 到底是如何完成元素定位的。通过对于源码的研究，我们发现元素的信息都是存储在一个叫做 `AccessibilityNodeInfo` 的对象里面。源码中使用大量 `node.getXXX` 方法中的信息，大家是否眼熟呢？这些信息其实就是我们日常自动化测试中可以获取 UI 元素的属性。

Attribute	Value
elementId	d52e7234-3392-411d-b93e-debc70e6a52a
index	0
package	com.sankuai.meituan
class	android.view.View
text	
content-desc	外卖
checkable	false
checked	false
clickable	true
enabled	true

图 5　AppiumInspector 审查元素获取信息示意

`Drawable` 无法获取元素信息，是否和 `AccessibilityNodeInfo` 相关？我们进一步探究 `Drawable` 和 `AccessibilityNodeInfo` 的关系。

AccessibilityNodeInfo 和 Drawable

通过对于源码的研究，我们绘制了如下类图来解释 `AccessibilityNodeInfo` 和 `Drawable` 之间的关系。

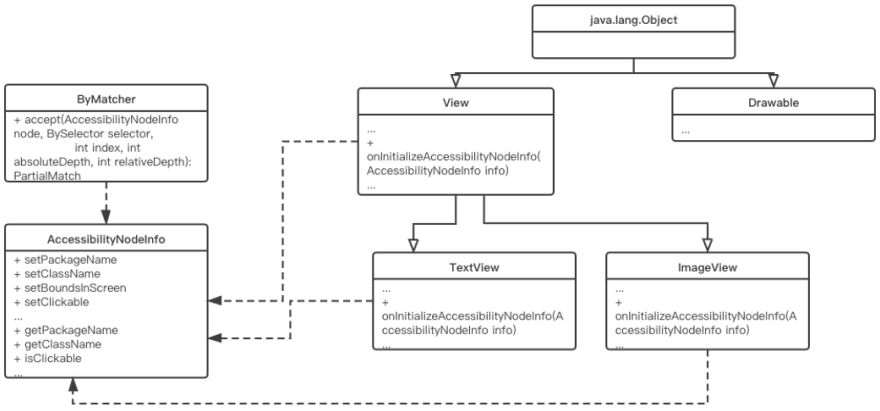

图 6　类关系示意图

View 实现了 AccessibilityEventSource 接口并实现了一个叫做 onInitial-izeAccessibilityNodeInfo 的方法来填充信息。我们也在 Android 官方文档中找到了对于此信息的说明：

> onInitializeAccessibilityNodeInfo() ：此方法为无障碍服务提供有关视图状态的信息。默认的 View 实现具有一组标准的视图属性，但如果您的自定义视图提供除了简单的 TextView 或 Button 之外的其他互动控件，则您应替换此方法并将有关视图的其他信息设置到由此方法处理的 AccessibilityNodeInfo 对象中。

而 Drawable 并没有实现对应的方法，所以也就无法被自动化测试找到。探究了元素查找原理之后，我们就要开始着手解决问题了。

页面视图可测性改造 -XraySDK

定位方案对比

既然知道了 Drawable 没有填充 AccessibilityNodeInfo，也就说明我无法接入目前的自动化测试方案来完成页面内容的获取。那我们可以想到如下三种方案来解决问题：

实现方案	影响范围
改造 Appium 定位方式，让 Drawable 可以被识别	需要改动底层的 AccessibilityNodeInfo obtain(View,int) 方法和为 Drawable 添加 AccessibilityNodeInfo 这样就需要对于所有的 Android 系统做兼容，影响范围过大
使用 View 替代 Drawable	动态布局卡片使用 Drawable 进行绘制就是因为 Drawable 比 View 使用资源更少，绘制性能更好，放弃使用 Drawable 就等于放弃了性能的改进
使用图像识别进行定位	动态卡片中有很多图像中包含文字，还有多行文本都会对图像识别的准确性带来很大的影响

上面的三种方案，目前看来都无法有效地解决动态卡片元素定位的问题。如何在影响范围较小的前提下，达成获取视图信息的目标呢？接下来，我们将进一步研究动态布局的实现方案。

视图信息的获取和存储 -XrayDumper

我们的应用场景非常明确，自动化测试通过集成 Client 来获得和客户端交互能力，通过 Client 向 App 发送指令来页面信息的获取。那我们可以考虑内嵌一个 SDK（XraySDK）来完成视图的获取，然后再向自动化提供一个客户端（XrayClient）来完成这部分功能。

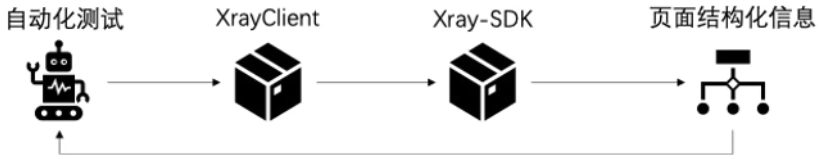

图 7　XraySDK 的工作流程示意图

对于 XraySDK 的功能划分，如下表所示：

模块名	功能划分	运行环境	产品形态
Xray-Client	1. 和 Xray-Server 进行交互进行指令发送和数据的接收 2. 暴露对外的 Api 给自动化或者其他系统	自动化内部或者三方系统内部	JAR 包或基于其他语言的依赖包
Xray-SDK	1. 进行页面信息的获取以及结构化(Xray-Dumper) 2. 接收用户指令来进行结构化数据输出(Xray-Server)	App 内部	客户端 SDK（AAR 和 Pod-Library）

XraySDK 如何才能获取到我们需要的 Drawable 信息呢？我们先来研究一下动态布局的实现方案。

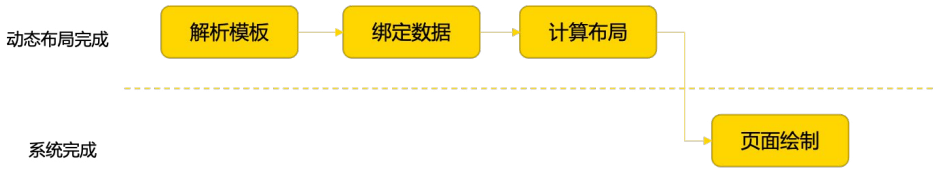

图 8　动态卡片的页面绘制流程

动态布局的视图呈现过程分为：解析模板 -> 绑定数据 -> 计算布局 -> 页面绘制，计算布局结束后，元素在页面上的位置就已经确定了，那么只要拦截这个阶段信息就可

以实现视图信息的获取。

通过对于代码的研究，我们发现在 `com.sankuai.litho.recycler.AdapterCompat` 这个类中控制着视图布局行为，在 `bindViewHolder` 中完成视图的最终的布局和计算。首先，我们通过在此处插入一个自定义的监听器来拦截布局信息。

```
public final void bindViewHolder(BaseViewHolder<Data> viewHolder, int
position) {
        if (viewHolder != null) {
            viewHolder.bindView(context, getData(position), position);

            // 自动化测试回调
            if (componentTreeCreateListeners != null) {
                if (viewHolder instanceof LithoViewHolder) {
                    DataHolder holder = getData(position);
                    // 获取视图布局信息
                    LithoView view = ((LithoViewHolder<Data>)
viewHolder).lithoView;
                    LayoutController layoutController =
((LithoDynamicDataHolder) holder).getLayoutController(null);
                    VirtualNodeBase node = layoutController.viewNodeRoot;
                    // 通过监听器将视图信息向外传递给可测性 SDK
                    componentTreeCreateListeners.
onComponentTreeCreated(node, view.getRootView(), view.
getComponentTree());
                }
            }
        }
    }
```

然后，通过暴露一个静态方法给可测性 SDK，完成监听器的初始化。

```
public static void
setComponentTreeCreateListener(ComponentTreeCreateListener l) {
        AdapterCompat.componentTreeCreateListeners = l;
        try {
            // 兼容 mbc 的动态布局自动化测试，为避免循环依赖，采用反射调用
            Class<?> mbcDynamicClass = Class.forName("com.sankuai.
meituan.mbc.business.item.dynamic.DynamicLithoItem");
            Method setComponentTreeCreateListener =
mbcDynamicClass.getMethod("setComponentTreeCreateListener",
ComponentTreeCreateListener.class);
            setComponentTreeCreateListener.invoke(null, l);

        } catch (Exception e) {
```

```
            e.printStackTrace();
        }

        try {
            // 搜索新框架动态布局自动化测试
            Class<?> searchDynamicClass = Class.forName("com.sankuai.
meituan.search.result2.model.DynamicItem");
            Method setSearchComponentTreeCreateListener =
searchDynamicClass.getMethod("setComponentTreeCreateListener",
ComponentTreeCreateListener.class);
            setSearchComponentTreeCreateListener.invoke(null, l);
        } catch (Exception e) {
            e.printStackTrace();
        }
    }
```

最后，自动化通过设置自定义的监听器来完成视图信息的获取和存储。

```
// 通过静态方法设置一个 ComponentTreeCreateListener 来监听布局事件
AdapterCompat.setComponentTreeCreateListener(new AdapterCompat.
ComponentTreeCreateListener() {
            @Override
            public void onComponentTreeCreated(VirtualNodeBase node,
View rootView, ComponentTree tree) {
                // 将信息存储到一个自定义的 ViewInfoObserver 对象中
                ViewInfoObserver vif = new ViewInfoObserver();
                vif.update(node, rootView, tree);
            }
        });
```

我们将视图信息存储在 ViewInfoObserver 这样一个对象中。

```
public class ViewInfoObserver implements AutoTestObserver{
    public static HashMap<String, View> VIEW_MAP = new HashMap<>();
    public static HashMap<VirtualNodeBase, View> VIEW = new HashMap<>();
    public static HashMap<String, ComponentTree> COMPTREE_MAP = new
HashMap<>();
    public static String uri = "http://dashboard.ep.dev.sankuai.com/
outter/dynamicTemplateKeyFromJson";

    @Override
    public void update(VirtualNodeBase vn, View view,ComponentTree tree)
{
        if (null != vn && null != vn.jsonObject) {
            try {
                String string = vn.jsonObject.toString();
```

```
                Gson g = new GsonBuilder().setPrettyPrinting().create();
                JsonParser p = new JsonParser();
                JsonElement e = p.parse(string);

                String templateName = null;
                String name1 = getObject(e,"templateName");
                String name2 = getObject(e,"template_name");
                String name3 = getObject(e,"template");
                templateName = null != name1 ? name1 : (null != name2 ?
name2 : (null != name3 ? name3 : null));

                if (null != templateName) {
                // 如果已经存储则更新视图信息
                    if (VIEW_MAP.containsKey(templateName)) {
                        VIEW_MAP.remove(templateName);
                    }
                    // 存储视图编号
                    VIEW_MAP.put(templateName, view);
                    if (VIEW.containsKey(templateName)) {
                        VIEW.remove(templateName);
                    }
                    // 存储视图信息
                    VIEW.put(vn, view);
                    if (COMPTREE_MAP.containsKey(templateName)) {
                        COMPTREE_MAP.remove(templateName);
                    }
                    COMPTREE_MAP.put(templateName, tree);
                    System.out.println("autotestDyn: update success");

                }

            } catch (Exception e) {
                System.out.println(e.toString());
                System.out.println("autotestDyn: templateName not exist!");
            }
        }
    }
```

当需要查询这些信息的时候，就可以通过 XrayDumper 来完成信息的输出。

```
public class SubViewInfo {
    public JSONObject getOutData(String template) throws JSONException {
        JSONObject outData = new JSONObject();
        JSONObject componentTouchables = new JSONObject();

        if (!COMPTREE_MAP.isEmpty() && COMPTREE_MAP.containsKey(template)
&& null != COMPTREE_MAP.get(template)) {
            ComponentTree cpt = COMPTREE_MAP.get(template);
```

```
            JSONArray componentArray = new JSONArray();

            ArrayList<View> touchables = cpt.getLithoView().
getTouchables();
            LithoView lithoView = cpt.getLithoView();
            int[] ls = new int[2];
            lithoView.getLocationOnScreen(ls);
            int pointX = ls[0];
            int pointY = ls[1];

            for (int i = 0; i < touchables.size(); i++) {
                JSONObject temp = new JSONObject();
                int height = touchables.get(i).getHeight();
                int width = touchables.get(i).getWidth();
                int[] tl = new int[2];
                touchables.get(i).getLocationOnScreen(tl);
                temp.put("height",height);
                temp.put("width",width);
                temp.put("pointX",tl[0]);
                temp.put("pointY",tl[1]);

                String url = "";
                try {
                    EventHandler eh = (EventHandler)
getValue(getValue(touchables.get(i), "mOnClickListener"),
"mEventHandler");
                    DynamicClickListener listener =
(DynamicClickListener) getValue(getValue(eh, "mHasEventDispatcher"),
"listener");
                    Uri clickUri = (Uri) getValue(listener, "uri");
                    if (null != clickUri) {
                        url = clickUri.toString();
                    }
                } catch (Exception e) {
                    Log.d("autotest", "get click url error!");
                }

                temp.put("url",url);
                componentArray.put(temp);
            }
            componentTouchables.
put("componentTouchables",componentArray);
            componentTouchables.put("componentTouchablesCount", cpt.
getLithoView().getTouchables().size());

            View[] root = (View[])getValue(cpt.
getLithoView(),"mChildren");
            JSONArray allComponentArray = new JSONArray();
            if (root.length > 0) {
```

```
                for (int i = 0; i < root.length; i++) {
                    try {
                        if (null != root[i]) {
                            Object items[] = (Object[])
getValue(getValue(root[i], "mMountItems"), "mValues");
                            componentTouchables.put("componentCount",
items.length);
                            for (int itemIndex = 0; itemIndex < items.
length; itemIndex++) {
                                getMountItems(allComponentArray,
items[itemIndex], pointX, pointY);
                            }
                        }
                    } catch (Exception e) {

                    }
                }
            }
            componentTouchables.
put("componentUntouchables",allComponentArray);
        } else {
            Log.d("autotest","COMPTREE_MAP is null!");
        }
        outData.put(template,componentTouchables);
        System.out.println(outData);
        return outData;
    }
    }
}
```

视图信息的输出 -XrayServer

我们获取到了信息，接下来就要考虑如何将视图信息传递给自动化测试脚本，我们参考了 Appium 的设计。

Appium 通过在手机上安装的 InstrumentsClient 启动了一个 SocketServer 通过 HTTP 协议来完成自动化和底层测试框架的数据通信。我们也可以借鉴上述思路，在美团 App 中启动一个 WebServer 来完成信息的输出。

第一步，我们实现了一个继承了 Service 组件，这样就可以方便的通过命令行的方式的启动和停止可测性的功能。

```
public class AutoTestServer extends Service  {
    @Override
    public IBinder onBind(Intent intent) {
        return null;
    }

    @Override
    public int onStartCommand(Intent intent, int flags, int startId) {
    ....
        return super.onStartCommand(intent, flags, startId);
    }
}
```

第二步，通过 HttpServer 的方式对外暴露通信的接口。

```
public class AutoTestServer extends Service  {
    @Override
    public IBinder onBind(Intent intent) {
        return null;
    }

    @Override
    public int onStartCommand(Intent intent, int flags, int startId) {
        // 创建对象，端口通过参数传入
        if (intent != null) {
            int randNum = intent.getIntExtra("autoTestPort",8999);
            HttpServer myServer = new HttpServer(randNum);
            try {
                // 开启 HTTP 服务
                myServer.start();
                System.out.println("AutoTestPort:" + randNum);
            } catch (IOException e) {
                System.err.println("AutoTestPort:" + e.getMessage());
                myServer = new HttpServer(8999);
                try {
                    myServer.start();
                    System.out.println("AutoTestPort:8999");
                } catch (IOException e1) {
                    System.err.println("Default:" + e.getMessage());
                }
            }
        }
        return super.onStartCommand(intent, flags, startId);
    }
}
```

第三步，将之前设置好的监听器进行注册。

```
public class AutoTestServer extends Service  {
    @Override
    public IBinder onBind(Intent intent) {
        return null;
    }

    @Override
    public int onStartCommand(Intent intent, int flags, int startId) {
    // 注册监听器
        AdapterCompat.setComponentTreeCreateListener(new AdapterCompat.
ComponentTreeCreateListener() {
            @Override
            public void onComponentTreeCreated(VirtualNodeBase node,
View rootView, ComponentTree tree) {
                ViewInfoObserver vif = new ViewInfoObserver();
                vif.update(node, rootView, tree);
            }
        });

        // 创建对象，端口通过参数传入
        .....
        return super.onStartCommand(intent, flags, startId);
    }
}
```

最后，在 HttpServer 中通过不同的路径来实现接收不同的指令。

```
private JSONObject getResponseByUri(@Nonnull IHTTPSession session) throws
JSONException {
        String uri = session.getUri();
        if (isFindCommand(uri)) {
            return getResponseByFindUri(uri);
        }
}

@Nonnull
private JSONObject getResponseByFindUri(@Nonnull String uri) throws
JSONException {
    String template = uri.split("/")[2];
    String protocol = uri.split("/")[3];
    switch (protocol) {
        case "frame":
            TemplateLayoutFrame tlf = new TemplateLayoutFrame();
            return tlf.getOutData(template);
        case "subview":
            SubViewInfo svi = new SubViewInfo();
            return svi.getOutData(template);
        // 省略了部分的代码处理逻辑
```

```
            ....
            default:
                JSONObject errorJson = new JSONObject();
                errorJson.put("success", false);
                errorJson.put("message", " 输入 find 链接地址有误 ");
                return errorJson;
        }
    }
```

SDK 整体功能结构

自动化脚本通过访问设备的特定端口（例如：http://localhost:8899/find/subview），经由 XrayServer，通过访问路径将请求转发至 XrayDumper 进行信息的提取和输出。然后布局解析器将布局信息序列化成 JSON 数据，再经由 XrayServer，通过网络以 HTTP 响应的方式传到给自动化测试脚本。

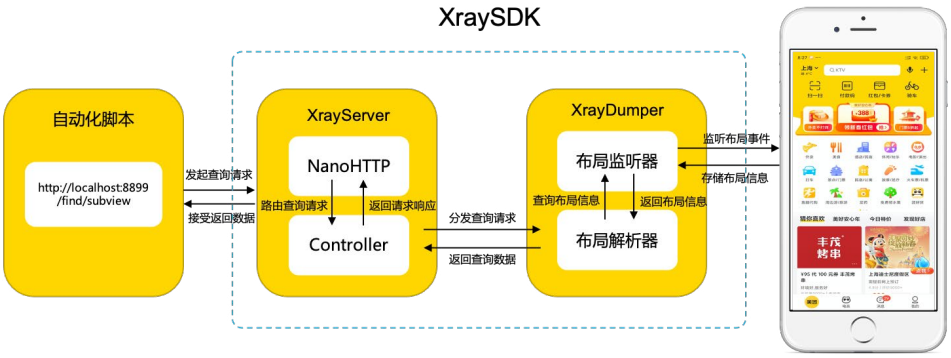

图 9 –XraySDK 功能结构示意图

视图信息的增强

除了常规的位置、内容、类型等信息，我们还通过检查时间监听器的方式，进一步判断视图元素是否可以进行交互，进一步增强了页面视图结构的有效信息。

```
// setGestures
ArrayList<String> gestures = new ArrayList<>();
if (view.isClickable()){
   gestures.add("isClickable");
```

```
}
if (view.isLongClickable()){
   gestures.add("isLongClickable");
}
// 省略部分代码
.....
```

动态布局自动化的收益

基于视图可测性的提升，美团动态化卡片的自动化测试覆盖度有了大幅的提升，从原来无法做自动化测试，到目前 80% 以上的动态化卡片都实现了自动化测试，而且效率也得到了明显的提升。

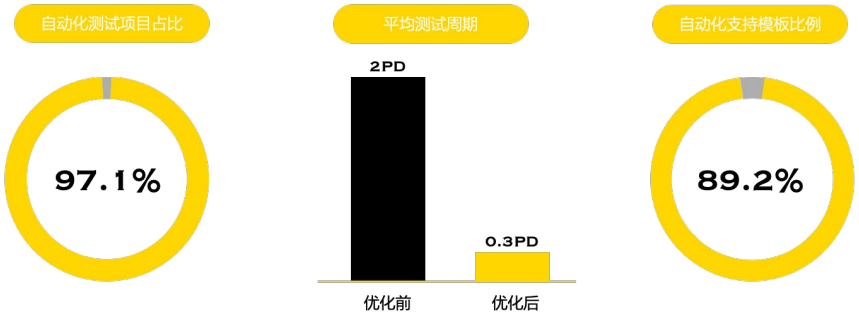

图 10　自动化效率提升收益

未来展望

页面视图信息作为客户端测试最基础且重要的属性之一，是对用户视觉信息的一种代码级的表示。它对于机器识别页面元素信息有着非常重要的作用，对于它的可测性改造将会给技术团队带来很大的收益。我们会列举了几个视图可测性改造的探索方向，仅供大家参考。

使用视图解析原理解决 WebView 元素定位

应用同样的思想，我们还可以用来解决 WebView 元素定位的问题。

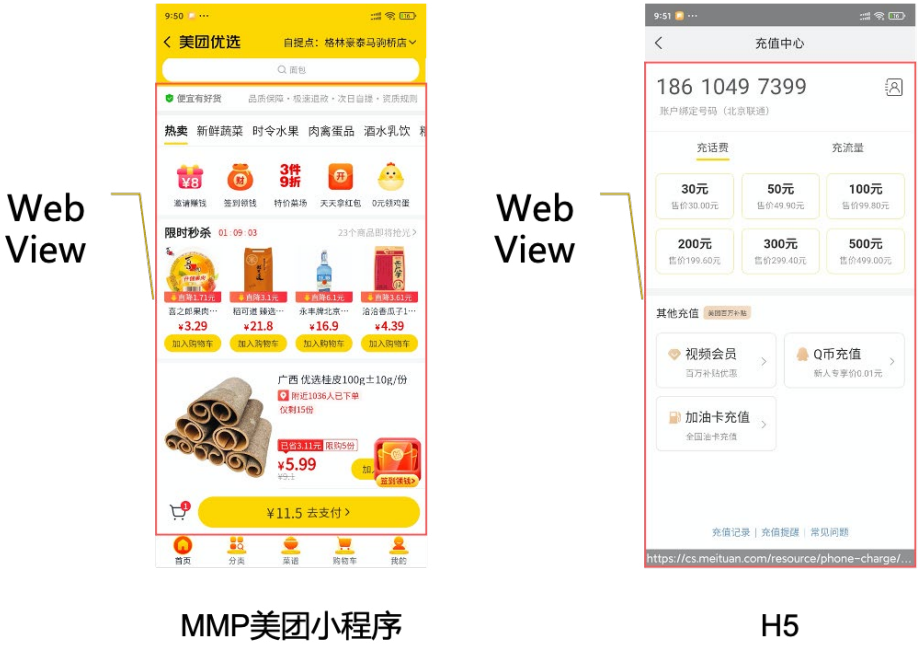

图 11 WebView 页面示例

通过运行在 App 内部的 SDK，可以获取到对应的 WebView 实例。通过获取到根节点，从根节点开始进行循环遍历，同时把每个节点的信息存储下来就可以得到所有的视图信息了。

在 WebView 是否也有同样合适的根节点呢？基于对于 HTML 的理解我们可以想到 HTML 中所有的标签都是挂在 BODY 标签下面的，BODY 标签就是我们需要选取的根节点。我们可以通过 WebElement[“attrName”] 的方式来进行属性的获取。

```
function traverse(node) {\
    var domObj = getBoundingClientRect(node);\
    domObj['name'] = node.tagName;\
    var gestures = [];\
    if (node._vnode && node._vnode.events) {\
            for (var i = 0; i < node._vnode.events.length; i++) {\
                    gestures.push(node._vnode.events[i].name);\
            }\
    }\
    domObj['gestures'] = gestures;\
    var children = [];\
    for (var j = 0; j < node.children.length; j++) {\
        var subDom = traverse(node.children[j]);\
        children.push(subDom);\
    }\
    domObj['children'] = children;\
    return domObj;\
}\

function getResult() {\
    return JSON.stringify(rootObj);\
}\
rootObj = traverse(root);\
getResult();\
```

图 12　遍历 WebView 节点的代码示例

视图可测性改造的更多应用场景

- **提升功能测试可靠性**：在功能测试自动化中，通过内部更加稳定和迅速的视图信息输出，可以有效提升自动化测试的稳定性。避免由于元素无法获取或者元素获取缓慢导致的自动化测试失败。
- **提升可靠性测试效率**：对于依靠随机或者按照视图信息进行页面随机操作的可靠性测试，依赖对于视图信息的过滤，也可以只操作可以交互的元素（通过过滤元素事件监听器是否为空）。这样就可以有效提升可靠性测试的效率，在单位时间内可以完成更多页面的检测。
- **增加兼容性测试检测手段**：在页面兼容性方面，通过对页面组件位置信息和属性来扫描页面内是否存在不合理的堆叠、空白区域、形状异常等 UI 呈现异常。也可以获取内容信息，例如图片、文本，来检查是否存在不适宜内容呈现。可以作为图像对比方案的有效补充。

招聘信息

美团平台质量技术中心，负责美团 App 业务和大前端（移动客户端和 Web 前端）基础技术质量工作，沉淀流程规范和配套工具、提升研发效率。团队技术一流、氛围良好，感兴趣的同学简历可以发送至 : zhangjie63@meituan.com

论文

ConSERT: A Contrastive Framework for Self-Supervised Sentence Representation Transfer

Yuanmeng Yan[1*], **Rumei Li**[2*], **Sirui Wang**[2], **Fuzheng Zhang**[2], **Wei Wu**[2], **Weiran Xu**[1]
[1]Beijing University of Posts and Telecommunications, Beijing, China
[2]Meituan Inc., Beijing, China
{yanyuanmeng,xuweiran}@bupt.edu.cn
{lirumei,wangsirui,zhangfuzheng,wuwei30}@meituan.com

Abstract

Learning high-quality sentence representations benefits a wide range of natural language processing tasks. Though BERT-based pre-trained language models achieve high performance on many downstream tasks, the native derived sentence representations are proved to be collapsed and thus produce a poor performance on the semantic textual similarity (STS) tasks. In this paper, we present ConSERT, a **Con**trastive Framework for Self-Supervised **SE**ntence **R**epresentation **T**ransfer, that adopts contrastive learning to fine-tune BERT in an unsupervised and effective way. By making use of unlabeled texts, ConSERT solves the collapse issue of BERT-derived sentence representations and make them more applicable for downstream tasks. Experiments on STS datasets demonstrate that ConSERT achieves an 8% relative improvement over the previous state-of-the-art, even comparable to the supervised SBERT-NLI. And when further incorporating NLI supervision, we achieve new state-of-the-art performance on STS tasks. Moreover, ConSERT obtains comparable results with only 1000 samples available, showing its robustness in data scarcity scenarios.

1 Introduction

Sentence representation learning plays a vital role in natural language processing tasks (Kiros et al., 2015; Hill et al., 2016; Conneau et al., 2017; Cer et al., 2018). Good sentence representations benefit a wide range of downstream tasks, especially for computationally expensive ones, including large-scale semantic similarity comparison and information retrieval.

Recently, BERT-based pre-trained language models have achieved high performance on many downstream tasks with additional supervision. However, the native sentence representations derived from BERT[1] are proved to be of low-quality (Reimers and Gurevych, 2019; Li et al., 2020). As shown in Figure 1a, when directly adopt BERT-based sentence representations to semantic textual similarity (STS) tasks, almost all pairs of sentences achieved a similarity score between 0.6 to 1.0 , even if some pairs are regarded as completely unrelated by the human annotators. In other words, the BERT-derived native sentence representations are somehow collapsed (Chen and He, 2020), which means almost all sentences are mapped into a small area and therefore produce high similarity.

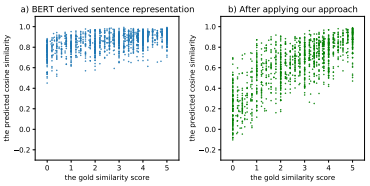

Figure 1: The correlation diagram between the gold similarity score (x-axis) and the model predicted cosine similarity score (y-axis) on the STS benchmark dataset.

Such phenomenon is also observed in several previous works (Gao et al., 2019; Wang et al., 2019; Li et al., 2020). They find the word representation space of BERT is anisotropic, the high-frequency words are clustered and close to the origin, while low-frequency words disperse sparsely. When averaging token embeddings, those high-frequency words dominate the sentence representations, inducing biases against their real semantics [2]. As a

*Work done during internship at Meituan Inc. The first two authors contribute equally. Weiran Xu is the corresponding author.

[1]Typically, we take the output of the [CLS] token or average token embeddings at the last few layers as the sentence representations.

[2]We also empirically prove this hypothesis, please refer to Section 5.1 for more details.

result, it is inappropriate to directly apply BERT's native sentence representations for semantic matching or text retrieval. Traditional methods usually fine-tune BERT with additional supervision. However, human annotation is costly and often unavailable in real-world scenarios.

To alleviate the collapse issue of BERT as well as reduce the requirement for labeled data, we propose a novel sentence-level training objective based on contrastive learning (He et al., 2020; Chen et al., 2020a,b). By encouraging two augmented views from the same sentence to be closer while keeping views from other sentences away, we reshape the BERT-derived sentence representation space and successfully solve the collapse issue (shown in Figure 1b). Moreover, we propose multiple data augmentation strategies for contrastive learning, including adversarial attack (Goodfellow et al., 2014; Kurakin et al., 2016), token shuffling, cutoff (Shen et al., 2020) and dropout (Hinton et al., 2012), that effectively transfer the sentence representations to downstream tasks. We name our approach ConSERT, a **Con**trastive Framework for **SE**ntence **R**epresentation **T**ransfer.

ConSERT has several advantages over previous approaches. Firstly, it introduces no extra structure or specialized implementation during inference. The parameter size of ConSERT keeps the same as BERT, making it easy to use. Secondly, compared with pre-training approaches, ConSERT is more efficient. With only 1,000 unlabeled texts drawn from the target distribution (which is easy to collect in real-world applications), we achieve 35% relative performance gain over BERT, and the training stage takes only a few minutes (1-2k steps) on a single V100 GPU. Finally, it includes several effective and convenient data augmentation methods with minimal semantic impact. Their effects are validated and analyzed in the ablation studies.

Our contributions can be summarized as follows: 1) We propose a simple but effective sentence-level training objective based on contrastive learning. It mitigates the collapse of BERT-derived representations and transfers them to downstream tasks. 2) We explore various effective text augmentation strategies to generate views for contrastive learning and analyze their effects on unsupervised sentence representation transfer. 3) With only fine-tuning on unsupervised target datasets, our approach achieves significant improvement on STS tasks. When further incorporating with NLI supervision, our approach achieves new state-of-the-art performance. We also show the robustness of our approach in data scarcity scenarios and intuitive analysis of the transferred representations.[3]

2 Related Work

2.1 Sentence Representation Learning

Supervised Approaches Several works use supervised datasets for sentence representation learning. Conneau et al. (2017) finds the supervised Natural Language Inference (NLI) task is useful to train good sentence representations. They use a BiLSTM-based encoder and train it on two NLI datasets, Stanford NLI (SNLI) (Bowman et al., 2015) and Multi-Genre NLI (MNLI) (Williams et al., 2018). Universal Sentence Encoder (Cer et al., 2018) adopts a Transformer-based architecture and uses the SNLI dataset to augment the unsupervised training. SBERT (Reimers and Gurevych, 2019) proposes a siamese architecture with a shared BERT encoder and is also trained on SNLI and MNLI datasets.

Self-supervised Objectives for Pre-training BERT (Devlin et al., 2019) proposes a bi-directional Transformer encoder for language model pre-training. It includes a sentence-level training objective, namely next sentence prediction (NSP), which predicts whether two sentences are adjacent or not. However, NSP is proved to be weak and has little contribution to the final performance (Liu et al., 2019). After that, various self-supervised objectives are proposed for pre-training BERT-like sentence encoders. Cross-Thought (Wang et al., 2020) and CMLM (Yang et al., 2020) are two similar objectives that recover masked tokens in one sentence conditioned on the representations of its contextual sentences. SLM (Lee et al., 2020) proposes an objective that reconstructs the correct sentence ordering given the shuffled sentences as the input. However, all these objectives need document-level corpus and are thus not applicable to downstream tasks with only short texts.

Unsupervised Approaches BERT-flow (Li et al., 2020) proposes a flow-based approach that maps BERT embeddings to a standard Gaussian latent space, where embeddings are more suitable for comparison. However, this approach introduces

[3]Our code is available at https://github.com/yym6472/ConSERT.

extra model structures and need specialized implementation, which may limit its application.

2.2 Contrastive Learning

Contrastive Learning for Visual Representation Learning Recently, contrastive learning has become a very popular technique in unsupervised visual representation learning with solid performance (Chen et al., 2020a; He et al., 2020; Chen et al., 2020b). They believe that good representation should be able to identify the same object while distinguishing itself from other objects. Based on this intuition, they apply image transformations (e.g. cropping, rotation, cutout, etc.) to randomly generate two augmented versions for each image and make them close in the representation space. Such approaches can be regarded as the invariance modeling to the input samples. Chen et al. (2020a) proposes SimCLR, a simple framework for contrastive learning. They use the normalized temperature-scaled cross-entropy loss (NT-Xent) as the training loss, which is also called InfoNCE in the previous literature (Hjelm et al., 2018).

Contrastive Learning for Textual Representation Learning Recently, contrastive learning has been widely applied in NLP tasks. Many works use it for language model pre-training. IS-BERT (Zhang et al., 2020) proposes to add 1-D convolutional neural network (CNN) layers on top of BERT and train the CNNs by maximizing the mutual information (MI) between the global sentence embedding and its corresponding local contexts embeddings. CERT (Fang and Xie, 2020) adopts a similar structure as MoCo (He et al., 2020) and uses back-translation for data augmentation. However, the momentum encoder needs extra memory and back-translation may produce false positives. BERT-CT (Carlsson et al., 2021) uses two individual encoders for contrastive learning, which also needs extra memory. Besides, they only sample 7 negatives, resulting in low training efficiency. DeCLUTR (Giorgi et al., 2020) adopts the architecture of SimCLR and jointly trains the model with contrastive objective and masked language model objective. However, they only use spans for contrastive learning, which is fragmented in semantics. CLEAR (Wu et al., 2020) uses the same architecture and objectives as DeCLUTR. Both of them are used to pre-train the language model, which needs a large corpus and takes a lot of resources.

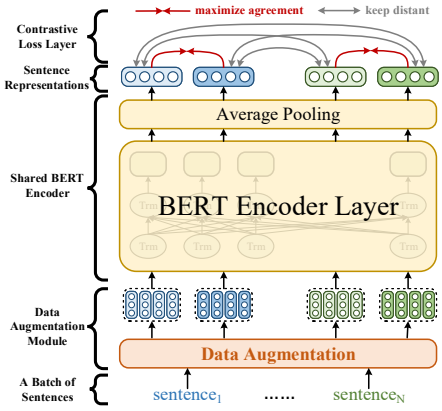

Figure 2: The general framework of our proposed approach.

3 Approach

In this section, we present ConSERT for sentence representation transfer. Given a BERT-like pre-trained language model $\mathbf{M}$ and an unsupervised dataset $\mathcal{D}$ drawn from the target distribution, we aim at fine-tuning $\mathbf{M}$ on $\mathcal{D}$ to make the sentence representation more task-relevant and applicable to downstream tasks. We first present the general framework of our approach, then we introduce several data augmentation strategies for contrastive learning. Finally, we talk about three ways to further incorporate supervision signals.

3.1 General Framework

Our approach is mainly inspired by SimCLR (Chen et al., 2020a). As shown in Figure 2, there are three major components in our framework:

- A data augmentation module that generates different views for input samples at the token embedding layer.
- A shared BERT encoder that computes sentence representations for each input text. During training, we use the average pooling of the token embeddings at the last layer to obtain sentence representations.
- A contrastive loss layer on top of the BERT encoder. It maximizes the agreement between one representation and its corresponding version that is augmented from the same sentence while keeping it distant from other sentence representations in the same batch.

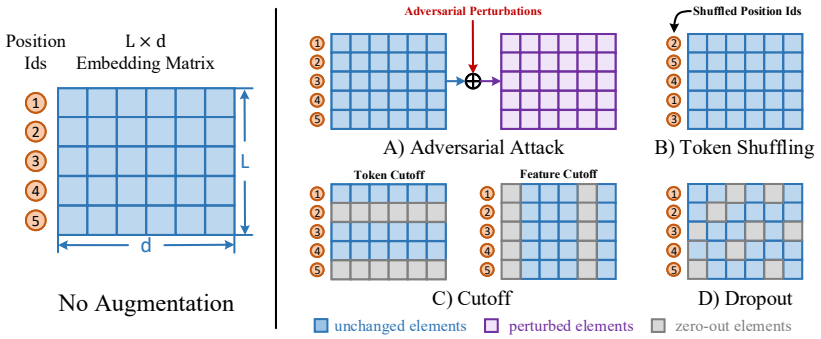

Figure 3: The four data augmentation strategies used in our experiments.

For each input text x, we first pass it to the data augmentation module, in which two transformations T_1 and T_2 are applied to generate two versions of token embeddings: $\boldsymbol{e}_i = T_1(x), \boldsymbol{e}_j = T_2(x)$, where $\boldsymbol{e}_i, \boldsymbol{e}_j \in \mathbb{R}^{L \times d}$, L is the sequence length and d is the hidden dimension. After that, both $\boldsymbol{e}_i$ and $\boldsymbol{e}_j$ will be encoded by multi-layer transformer blocks in BERT and produce the sentence representations r_i and r_j through average pooling.

Following Chen et al. (2020a), we adopt the normalized temperature-scaled cross-entropy loss (NT-Xent) as the contrastive objective. During each training step, we randomly sample N texts from $\mathcal{D}$ to construct a mini-batch, resulting in $2N$ representations after augmentation. Each data point is trained to find out its counterpart among $2(N-1)$ in-batch negative samples:

$$\mathcal{L}_{i,j} = -\log \frac{\exp(\text{sim}(r_i, r_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{1}_{[k \neq i]} \exp(\text{sim}(r_i, r_k)/\tau)} \quad (1)$$

, where $\text{sim}(\cdot)$ indicates the cosine similarity function, τ controls the temperature and $\mathbb{1}$ is the indicator. Finally, we average all $2N$ in-batch classification losses to obtain the final contrastive loss $\mathcal{L}_{\text{con}}$.

3.2 Data Augmentation Strategies

We explore four different data augmentation strategies to generate views for contrastive learning, including adversarial attack (Goodfellow et al., 2014; Kurakin et al., 2016), token shuffling, cutoff (Shen et al., 2020) and dropout (Hinton et al., 2012), as illustrated in Figure 3.

Adversarial Attack Adversarial training is generally used to improve the model's robustness. They generate adversarial samples by adding a worst-case perturbation to the input sample. We implement this strategy with Fast Gradient Value (FGV) (Rozsa et al., 2016), which directly uses the gradient to compute the perturbation and thus is faster than two-step alternative methods. Note that this strategy is only applicable when jointly training with supervision since it relies on supervised loss to compute adversarial perturbations.

Token Shuffling In this strategy, we aim to randomly shuffle the order of the tokens in the input sequences. Since the bag-of-words nature in the transformer architecture, the position encoding is the only factor about the sequential information. Thus, similar to Lee et al. (2020), we implement this strategy by passing the shuffled position ids to the embedding layer while keeping the order of the token ids unchanged.

Cutoff Shen et al. (2020) proposes a simple and efficient data augmentation strategy called cutoff. They randomly erase some tokens (for token cutoff), feature dimensions (for feature cutoff), or token spans (for span cutoff) in the $L \times d$ feature matrix. In our experiments, we only use token cutoff and feature cutoff and apply them to the token embeddings for view generation.

Dropout Dropout is a widely used regularization method that avoids overfitting. However, in our experiments, we also show its effectiveness as an augmentation strategy for contrastive learning. For this setting, we randomly drop elements in the token embedding layer by a specific probability and set their values to zero. Note that this strategy is different from Cutoff since each element is considered individually.

	STS12	STS13	STS14	STS15	STS16	STSb	SICK-R	Total
Number of train samples	0	0	0	0	0	5749	4500	-
Number of valid samples	0	0	0	0	0	1500	500	-
Number of test samples	3108	1500	3750	3000	1186	1379	4927	-
Number of Unlabeled Texts	6216	3000	7500	17000	18366	17256	19854	89192

Table 1: The statistics of STS datasets.

3.3 Incorporating Supervision Signals

Besides unsupervised transfer, our approach can also be incorporated with supervised learning. We take the NLI supervision as an example. It is a sentence pair classification task, where the model are trained to distinguish the relation between two sentences among *contradiction*, *entailment* and *neutral*. The classification objective can be expressed as following:

$$\begin{aligned} f &= \text{Concat}(r_1, r_2, |r_1 - r_2|) \\ \mathcal{L}_{\text{ce}} &= \text{CrossEntropy}(Wf + b, y) \end{aligned} \tag{2}$$

, where r_1 and r_2 denote two sentence representations.

We propose three ways for incorporating additional supervised signals:

- **Joint training (joint)** We jointly train the model with the supervised and unsupervised objectives $\mathcal{L}_{\text{joint}} = \mathcal{L}_{\text{ce}} + \alpha\mathcal{L}_{\text{con}}$ on NLI dataset. α is a hyper-parameter to balance two objectives.

- **Supervised training then unsupervised transfer (sup-unsup)** We first train the model with $\mathcal{L}_{\text{ce}}$ on NLI dataset, then use $\mathcal{L}_{\text{con}}$ to fine-tune it on the target dataset.

- **Joint training then unsupervised transfer (joint-unsup)** We first train the model with the $\mathcal{L}_{\text{joint}}$ on NLI dataset, then use $\mathcal{L}_{\text{con}}$ to fine-tune it on the target dataset.

4 Experiments

To verify the effectiveness of our proposed approach, we conduct experiments on Semantic Textual Similarity (STS) tasks under the unsupervised and supervised settings.

4.1 Setups

Dataset Following previous works(Reimers and Gurevych, 2019; Li et al., 2020; Zhang et al., 2020), we evaluate our approach on multiple STS datasets, including STS tasks 2012 - 2016 (STS12 - STS16) (Agirre et al., 2012, 2013, 2014, 2015, 2016), STS benchmark (STSb) (Cer et al., 2017) and SICK-Relatedness (SICK-R) (Marelli et al.). Each sample in these datasets contains a pair of sentences as well as a gold score between 0 and 5 to indicate their semantic similarity. For our unsupervised experiments, we mix the unlabeled texts from these datasets to fine-tune our model. We obtain all 7 datasets through the SentEval toolkit (Conneau and Kiela, 2018). The statistics is shown in Table 1.

For supervised experiments, we use the combination of SNLI (570k samples) (Bowman et al., 2015) and MNLI (430k samples) (Williams et al., 2018) to train our model. In the *joint training* setting, the NLI texts are also used for contrastive objectives.

Baselines To show our effectiveness on unsupervised sentence representation transfer, we mainly select BERT-flow (Li et al., 2020) for comparison, since it shares the same setting as our approach. For unsupervised comparison, we use the average of GloVe embeddings, the BERT-derived native embeddings, CLEAR (Wu et al., 2020) (trained on BookCorpus and English Wikipedia corpus), IS-BERT (Zhang et al., 2020) (trained on unlabeled texts from NLI datasets), BERT-CT (Carlsson et al., 2021) (trained on English Wikipedia corpus). For comparison with supervised methods, we select InferSent (Conneau et al., 2017), Universal Sentence Encoder (Cer et al., 2018), SBERT (Reimers and Gurevych, 2019) and BERT-CT (Carlsson et al., 2021) as baselines. They are all trained with NLI supervision.

Evaluation When evaluating the trained model, we first obtain the representation of sentences by averaging the token embeddings at the last two layers[4], then we report the spearman correlation between the cosine similarity scores of sentence representations and the human-annotated gold scores. When calculating spearman correlation, we merge all sentences together (even if some STS datasets have multiple splits) and calculate spearman correlation for only once[5].

[4] As shown in Li et al. (2020), averaging the last two layers of BERT achieves slightly better results than averaging the last one layer.

[5] Note that such evaluation procedure is different from

Method	STS12	STS13	STS14	STS15	STS16	STSb	SICK-R	Avg.
Unsupervised baselines								
Avg. GloVe embeddings†	55.14	70.66	59.73	68.25	63.66	58.02	53.76	61.32
$\text{BERT}_{\text{base}}$‡	35.20	59.53	49.37	63.39	62.73	48.18	58.60	53.86
$\text{BERT}_{\text{large}}$‡	33.06	57.64	47.95	55.83	62.42	49.66	53.87	51.49
$\text{CLEAR}_{\text{base}}$†	49.0	48.9	57.4	63.6	65.6	75.6	72.5	61.8
IS-$\text{BERT}_{\text{base}}$-NLI†	56.77	69.24	61.21	75.23	70.16	69.21	64.25	66.58
$\text{BERT}_{\text{base}}$-CT†	66.86	70.91	72.37	78.55	77.78	-	-	-
$\text{BERT}_{\text{large}}$-CT†	69.50	75.97	74.22	78.83	78.92	-	-	-
Using STS unlabeled texts								
$\text{BERT}_{\text{base}}$-flow†	63.48	72.14	68.42	73.77	75.37	70.72	63.11	69.57
$\text{BERT}_{\text{large}}$-flow†	65.20	73.39	69.42	74.92	**77.63**	72.26	62.50	70.76
$\text{ConSERT}_{\text{base}}$‡	64.64	78.49	69.07	79.72	75.95	73.97	67.31	72.74
$\text{ConSERT}_{\text{large}}$‡	**70.69**	**82.96**	**74.13**	**82.78**	76.66	**77.53**	**70.37**	**76.45**

Table 2: The performance comparison of ConSERT with other methods in an *unsupervised* setting. We report the spearman correlation $\rho \times 100$ on 7 STS datasets. Methods with † indicate that we directly report the scores from the corresponding paper, while methods with ‡ indicate our implementation.

Implementation Details Our implementation is based on the Sentence-BERT[6] (Reimers and Gurevych, 2019). We use both the BERT-base and BERT-large for our experiments. The max sequence length is set to 64 and we remove the default dropout layer in BERT architecture considering the *cutoff* and *dropout* data augmentation strategies used in our framework. The ratio of token cutoff and feature cutoff is set to 0.15 and 0.2 respectively, as suggested in Shen et al. (2020). The ratio of dropout is set to 0.2. The temperature τ of NT-Xent loss is set to 0.1, and the α is set to 0.15 for the joint training setting. We adopt Adam optimizer and set the learning rate to 5e-7. We use a linear learning rate warm-up over 10% of the training steps. The batch size is set to 96 in most of our experiments. We use the dev set of STSb to tune the hyperparameters (including the augmentation strategies) and evaluate the model every 200 steps during training. The best checkpoint on the dev set of STSb is saved for test. We further discuss the influence of the batch size and the temperature in the subsequent section.

4.2 Unsupervised Results

For unsupervised evaluation, we load the pre-trained BERT to initialize the BERT encoder in our framework. Then we randomly mix the unlabeled texts from 7 STS datasets and use them to fine-tune our model.

The results are shown in Table 2. We can observe that both BERT-flow and ConSERT can improve the representation space and outperform the GloVe and BERT baselines with unlabeled texts from target datasets. However, $\text{ConSERT}_{\text{large}}$ achieves the best performance among 6 STS datasets, significantly outperforming $\text{BERT}_{\text{large}}$-flow with an 8% relative performance gain on average (from 70.76 to 76.45). Moreover, it is worth noting that $\text{ConSERT}_{\text{large}}$ even outperforms several supervised baselines (see Figure 3) like InferSent (65.01) and Universal Sentence Encoder (71.72), and keeps comparable to the strong supervised method $\text{SBERT}_{\text{large}}$-NLI (76.55). For the $\text{BERT}_{\text{base}}$ architecture, our approach $\text{ConSERT}_{\text{base}}$ also outperforms $\text{BERT}_{\text{base}}$-flow with an improvement of 3.17 (from 69.57 to 72.74).

4.3 Supervised Results

For supervised evaluation, we consider the three settings described in Section 3.3. Note that in the *joint* setting, only NLI texts are used for contrastive learning, making it comparable to SBERT-NLI. We use the model trained under the *joint* setting as the initial checkpoint in the *joint-unsup* setting. We also re-implement the SBERT-NLI baselines and use them as the initial checkpoint in the *sup-unsup* setting.

The results are illustrated in Table 3. For the models trained with NLI supervision, we find that ConSERT *joint* consistently performs better than SBERT, revealing the effectiveness of our proposed contrastive objective as well as the data augmentation strategies. On average, $\text{ConSERT}_{\text{base}}$ *joint*

SentEval toolkit, which calculates spearman correlation for each split and reports the mean or weighted mean scores.

[6] https://github.com/UKPLab/sentence-transformers

Method	STS12	STS13	STS14	STS15	STS16	STSb	SICK-R	Avg.
Using NLI supervision								
InferSent - GloVe†	52.86	66.75	62.15	72.77	66.87	68.03	65.65	65.01
Universal Sentence Encoder†	64.49	67.80	64.61	76.83	73.18	74.92	76.69	71.22
$\text{SBERT}_{\text{base}}$-NLI†	70.97	76.53	73.19	79.09	74.30	77.03	72.91	74.89
$\text{SBERT}_{\text{large}}$-NLI†	72.27	78.46	74.90	80.99	76.25	79.23	73.75	76.55
$\text{SBERT}_{\text{base}}$-NLI (re-impl.)‡	69.89	75.77	72.36	78.51	73.67	76.75	72.76	74.24
$\text{SBERT}_{\text{large}}$-NLI (re-impl.)‡	72.69	78.77	75.13	80.95	76.89	79.53	73.25	76.74
$\text{BERT}_{\text{base}}$-CT†	68.80	74.58	76.62	79.72	77.14	-	-	-
$\text{BERT}_{\text{large}}$-CT†	69.80	75.45	76.47	81.34	78.11	-	-	-
$\text{ConSERT}_{\text{base}}$ *joint*‡	70.53	79.96	74.85	81.45	76.72	78.82	77.53	77.12
$\text{ConSERT}_{\text{large}}$ *joint*‡	**73.26**	**82.36**	**77.73**	**83.84**	**78.75**	**81.54**	**78.64**	**79.44**
Using NLI supervision and STS unlabeled texts								
$\text{BERT}_{\text{base}}$-flow†	68.95	78.48	77.62	81.95	78.94	81.03	74.97	77.42
$\text{BERT}_{\text{large}}$-flow†	70.19	80.27	78.85	82.97	**80.57**	81.18	74.52	78.36
$\text{ConSERT}_{\text{base}}$ *sup-unsup*‡	73.51	84.86	77.44	83.11	77.98	81.80	74.29	79.00
$\text{ConSERT}_{\text{large}}$ *sup-unsup*‡	75.26	**86.01**	79.00	83.88	79.45	82.95	76.54	80.44
$\text{ConSERT}_{\text{base}}$ *joint-unsup*‡	74.07	83.93	77.05	83.66	78.76	81.36	76.77	79.37
$\text{ConSERT}_{\text{large}}$ *joint-unsup*‡	**77.47**	85.45	**79.41**	**85.59**	80.39	**83.42**	**77.26**	**81.28**

Table 3: The performance comparison of ConSERT with other methods in a *supervised* setting. We report the spearman correlation $\rho \times 100$ on 7 STS datasets. Methods with † indicate that we directly report the scores from the corresponding paper, while methods with ‡ indicate our implementation.

achieves a performance gain of 2.88 over the re-implemented $\text{SBERT}_{\text{base}}$-NLI, and $\text{ConSERT}_{\text{large}}$ *joint* achieves a performance gain of 2.70.

When further performing representation transfer with STS unlabeled texts, our approach achieves even better performance. On average, $\text{ConSERT}_{\text{large}}$ *joint-unsup* outperforms the initial checkpoint $\text{ConSERT}_{\text{large}}$ *joint* with 1.84 performance gain, and outperforms the previous state-of-the-art $\text{BERT}_{\text{large}}$-flow with 2.92 performance gain. The results demonstrate that even for the models trained under supervision, there is still a huge potential of unsupervised representation transfer for improvement.

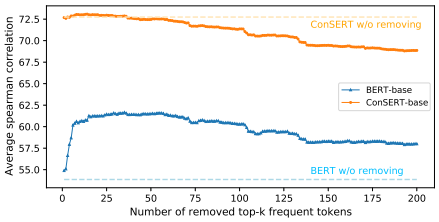

Figure 4: The average spearman correlation on STS tasks w.r.t. the number of removed top-k frequent tokens. Note that we also considered the [CLS] and [SEP] tokens and they are the 2 most frequent tokens. The frequency of each token is calculated through the test split of the STS Benchmark dataset.

5 Qualitative Analysis

5.1 Analysis of BERT Embedding Space

To prove the hypothesis that the collapse issue is mainly due to the anisotropic space that is sensitive to the token frequency, we conduct experiments that mask the embeddings of several most frequent tokens when applying average pooling to calculate the sentence representations. The relation between the number of removed top-k frequent tokens and the average spearman correlation is shown in Figure 4.

We can observe that when removing a few top frequent tokens, the performance of BERT improves sharply on STS tasks. When removing 34 most frequent tokens, the best performance is achieved (61.66), and there is an improvement of 7.8 from the original performance (53.86). For ConSERT, we find that removing a few most frequent tokens only results in a small improvement of less than 0.3. The results show that our approach reshapes the BERT's original embedding space, reducing the influence of common tokens on sentence representations.

5.2 Effect of Data Augmentation Strategy

In this section, we study the effect of data augmentation strategies for contrastive learning. We consider 5 options for each transformation, including None (i.e. doing nothing), Shuffle, Token Cutoff,

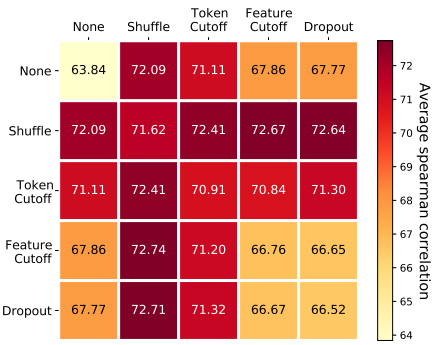

Figure 5: The performance visualization with different combinations of data augmentation strategies. The row indicates the 1st data augmentation strategy while the column indicates the 2nd data augmentation strategy.

Feature Cutoff, and Dropout, resulting in 5×5 combinations. Note that the Adversarial Attack strategy is not considered here, since it needs additional supervision to generate adversarial samples. All these experiments follow the unsupervised setting and use the $\text{BERT}_{\text{base}}$ architecture.

The results can be found in Figure 5. We can make the following observations. First, Shuffle and Token Cutoff are the two most effective strategies (where Shuffle is slightly better than Token Cutoff), significantly outperforming Feature Cutoff and Dropout. This is probably because Shuffle and Token Cutoff are more related to the downstream STS tasks since they are directly operated on the token level and change the structure of the sentence to produce hard examples.

Secondly, Feature Cutoff and Dropout also improve performance by roughly 4 points when compared with the None-None baseline. Moreover, we find they work well as a complementary strategy. Combining with another strategy like Shuffle may further improve the performance. When combined Shuffle with Feature Cutoff, we achieve the best result. We argue that Feature Cutoff and Dropout are useful in modeling the invariance of the internal noise for the sentence encoder, and thus improve the model's robustness.

Finally, we also observe that even without any data augmentation (the None-None combination), our contrastive framework can improve BERT's performance on STS tasks (from 53.86 to 63.84). This None-None combination has no effect on maximizing agreement between views since the representations of augmented views are exactly the same. On the contrary, it tunes the representation space by pushing each representation away from others. We believe that the improvement is mainly due to the collapse phenomenon of BERT's native representation space. To some extent, it also explains why our method works.

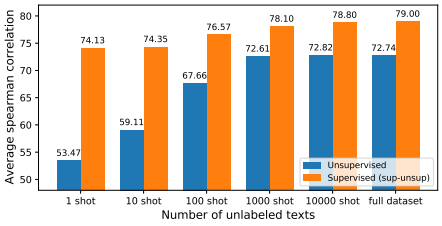

Figure 6: The few-shot experiments under the unsupervised and supervised settings. We report the average spearman correlation on STS datasets with 1, 10, 100, 1,000, and 10,000 unlabeled texts available, respectively. The full dataset indicates all 89192 unlabeled texts from 7 STS datasets.

5.3 Performance under Few-shot Settings

To validate the reliability and the robustness of ConSERT under the data scarcity scenarios, we conduct the few-shot experiments. We limit the number of unlabeled texts to 1, 10, 100, 1000, and 10000 respectively, and compare their performance with the full dataset.

Figure 6 presents the results. For both the unsupervised and the supervised settings, our approach can make a huge improvement over the baseline with only 100 samples available. When the training samples increase to 1000, our approach can basically achieve comparable results with the models trained on the full dataset. The results reveal the robustness and effectiveness of our approach under the data scarcity scenarios, which is common in reality. With only a small amount of unlabeled texts drawn from the target data distribution, our approach can also tune the representation space and benefit the downstream tasks.

5.4 Influence of Temperature

The temperature τ in NT-Xent loss (Equation 1) is used to control the smoothness of the distribution normalized by softmax operation and thus influences the gradients when backpropagation. A large temperature smooths the distribution while a small temperature sharpens the distribution. In our experiments, we explore the influence of temperature

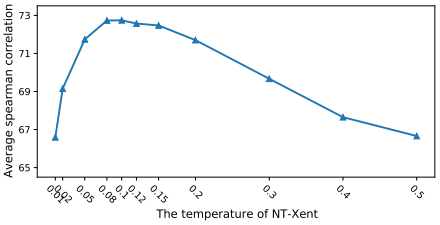

Figure 7: The influence of different temperatures in NT-Xent. The best performance is achieved when the temperature is set to 0.1.

Batch Size	16	48	96	192	288
Avg. Spearman	72.63	72.60	72.74	72.86	72.98
Number of Steps	6175	2459	1530	930	620

Table 4: The average spearman correlation as well as the training steps of our unsupervised approach with different batch sizes.

and present the result in Figure 7.

As shown in the figure, we find the performance is extremely sensitive to the temperature. Either too small or too large temperature will make our model perform badly. And the optimal temperature is obtained within a small range (from about 0.08 to 0.12). This phenomenon again demonstrates the collapse issue of BERT embeddings, as most sentences are close to each other, a large temperature may make this task too hard to learn. We select 0.1 as the temperature in most of our experiments.

5.5 Influence of Batch Size

In some previous works of contrastive learning, it is reported that a large batch size benefits the final performance and accelerates the convergence of the model since it provides more in-batch negative samples for contrastive learning (Chen et al., 2020a). Those in-batch negative samples improve the training efficiency. We also analyze the influence of the batch size for unsupervised sentence representation transfer.

The results are illustrated in Table 4. We show both the spearman correlation and the corresponding training steps. We find that a larger batch size does achieve better performance. However, the improvement is not so significant. Meanwhile, a larger batch size does speed up the training process, but it also needs more GPU memories at the same time.

6 Conclusion

In this paper, we propose ConSERT, a self-supervised contrastive learning framework for transferring sentence representations to downstream tasks. The framework does not need extra structure and is easy to implement for any encoder. We demonstrate the effectiveness of our framework on various STS datasets, both our unsupervised and supervised methods achieve new state-of-the-art performance. Furthermore, few-shot experiments suggest that our framework is robust in the data scarcity scenarios. We also compare multiple combinations of data augmentation strategies and provide fine-grained analysis for interpreting how our approach works. We hope our work will provide a new perspective for future researches on sentence representation transfer.

Acknowledgements

We thank Keqing He, Hongzhi Zhang and all anonymous reviewers for their helpful comments and suggestions. This work was partially supported by National Key R&D Program of China No. 2019YFF0303300 and Subject II No. 2019YFF0303302, DOCOMO Beijing Communications Laboratories Co., Ltd, MoE-CMCC "Artifical Intelligence" Project No. MCM20190701.

Broader Impact

Sentence representation learning is a basic task in natural language processing and benefits many downstream tasks. This work proposes a contrastive learning based framework to solve the collapse issue of BERT and transfer BERT sentence representations to target data distribution. Our approach not only provides a new perspective about BERT's representation space, but is also useful in practical applications, especially for data scarcity scenarios. When applying our approach, the user should collect a few unlabeled texts from target data distribution and use our framework to fine-tune BERT encoder in a self-supervised manner. Since our approach is self-supervised, no bias will be introduced from human annotations. Moreover, our data augmentation strategies also have little probability to introduce extra biases since they are all based on random sampling. However, it is still possible to introduce data biases from the unlabeled texts. Therefore, users should pay special attention to ensure that the training data is ethical, unbiased, and closely related to downstream tasks.

References

Eneko Agirre, Carmen Banea, Claire Cardie, Daniel Cer, Mona Diab, Aitor Gonzalez-Agirre, Weiwei Guo, Inigo Lopez-Gazpio, Montse Maritxalar, Rada Mihalcea, et al. 2015. Semeval-2015 task 2: Semantic textual similarity, english, spanish and pilot on interpretability. In *Proceedings of the 9th international workshop on semantic evaluation (SemEval 2015)*, pages 252–263.

Eneko Agirre, Carmen Banea, Claire Cardie, Daniel Cer, Mona Diab, Aitor Gonzalez-Agirre, Weiwei Guo, Rada Mihalcea, German Rigau, and Janyce Wiebe. 2014. Semeval-2014 task 10: Multilingual semantic textual similarity. In *Proceedings of the 8th international workshop on semantic evaluation (SemEval 2014)*, pages 81–91.

Eneko Agirre, Carmen Banea, Daniel Cer, Mona Diab, Aitor Gonzalez Agirre, Rada Mihalcea, German Rigau Claramunt, and Janyce Wiebe. 2016. Semeval-2016 task 1: Semantic textual similarity, monolingual and cross-lingual evaluation. In *SemEval-2016. 10th International Workshop on Semantic Evaluation; 2016 Jun 16-17; San Diego, CA. Stroudsburg (PA): ACL; 2016. p. 497-511.* ACL (Association for Computational Linguistics).

Eneko Agirre, Daniel Cer, Mona Diab, and Aitor Gonzalez-Agirre. 2012. Semeval-2012 task 6: A pilot on semantic textual similarity. In ** SEM 2012: The First Joint Conference on Lexical and Computational Semantics–Volume 1: Proceedings of the main conference and the shared task, and Volume 2: Proceedings of the Sixth International Workshop on Semantic Evaluation (SemEval 2012)*, pages 385–393.

Eneko Agirre, Daniel Cer, Mona Diab, Aitor Gonzalez-Agirre, and Weiwei Guo. 2013. * sem 2013 shared task: Semantic textual similarity. In *Second joint conference on lexical and computational semantics (* SEM), volume 1: proceedings of the Main conference and the shared task: semantic textual similarity*, pages 32–43.

Samuel Bowman, Gabor Angeli, Christopher Potts, and Christopher D Manning. 2015. A large annotated corpus for learning natural language inference. In *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*, pages 632–642.

Fredrik Carlsson, Magnus Sahlgren, Evangelia Gogoulou, Amaru Cuba Gyllensten, and Erik Ylipää Hellqvist. 2021. Semantic re-tuning with contrastive tension. In *International Conference on Learning Representations*.

Daniel Cer, Mona Diab, Eneko Agirre, Iñigo Lopez-Gazpio, and Lucia Specia. 2017. Semeval-2017 task 1: Semantic textual similarity multilingual and crosslingual focused evaluation. In *Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2017)*, pages 1–14.

Daniel Cer, Yinfei Yang, Sheng-yi Kong, Nan Hua, Nicole Limtiaco, Rhomni St John, Noah Constant, Mario Guajardo-Cespedes, Steve Yuan, Chris Tar, et al. 2018. Universal sentence encoder for english. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 169–174.

Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. 2020a. A simple framework for contrastive learning of visual representations. *arXiv preprint arXiv:2002.05709*.

Ting Chen, Simon Kornblith, Kevin Swersky, Mohammad Norouzi, and Geoffrey Hinton. 2020b. Big self-supervised models are strong semi-supervised learners.

Xinlei Chen and Kaiming He. 2020. Exploring simple siamese representation learning. *arXiv preprint arXiv:2011.10566*.

Alexis Conneau and Douwe Kiela. 2018. Senteval: An evaluation toolkit for universal sentence representations. In *Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)*.

Alexis Conneau, Douwe Kiela, Holger Schwenk, Loïc Barrault, and Antoine Bordes. 2017. Supervised learning of universal sentence representations from natural language inference data. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 670–680.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186.

Hongchao Fang and Pengtao Xie. 2020. Cert: Contrastive self-supervised learning for language understanding. *arXiv preprint arXiv:2005.12766*.

Jun Gao, Di He, Xu Tan, Tao Qin, Liwei Wang, and Tie-Yan Liu. 2019. Representation degeneration problem in training natural language generation models. *arXiv preprint arXiv:1907.12009*.

John M Giorgi, Osvald Nitski, Gary D. Bader, and Bo Wang. 2020. Declutr: Deep contrastive learning for unsupervised textual representations. *ArXiv*, abs/2006.03659.

Ian J Goodfellow, Jonathon Shlens, and Christian Szegedy. 2014. Explaining and harnessing adversarial examples. *arXiv preprint arXiv:1412.6572*.

Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. 2020. Momentum contrast for unsupervised visual representation learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9729–9738.

Felix Hill, Kyunghyun Cho, and Anna Korhonen. 2016. Learning distributed representations of sentences from unlabelled data. In *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 1367–1377.

Geoffrey E Hinton, Nitish Srivastava, Alex Krizhevsky, Ilya Sutskever, and Ruslan R Salakhutdinov. 2012. Improving neural networks by preventing co-adaptation of feature detectors. *arXiv preprint arXiv:1207.0580*.

R Devon Hjelm, Alex Fedorov, Samuel Lavoie-Marchildon, Karan Grewal, Phil Bachman, Adam Trischler, and Yoshua Bengio. 2018. Learning deep representations by mutual information estimation and maximization. *arXiv preprint arXiv:1808.06670*.

Ryan Kiros, Yukun Zhu, Russ R Salakhutdinov, Richard Zemel, Raquel Urtasun, Antonio Torralba, and Sanja Fidler. 2015. Skip-thought vectors. *Advances in neural information processing systems*, 28:3294–3302.

Alexey Kurakin, Ian Goodfellow, and Samy Bengio. 2016. Adversarial examples in the physical world. *arXiv preprint arXiv:1607.02533*.

Haejun Lee, Drew A Hudson, Kangwook Lee, and Christopher D Manning. 2020. Slm: Learning a discourse language representation with sentence unshuffling. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1551–1562.

Bohan Li, Hao Zhou, Junxian He, Mingxuan Wang, Yiming Yang, and Lei Li. 2020. On the sentence embeddings from pre-trained language models. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 9119–9130, Online. Association for Computational Linguistics.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. 2019. Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*.

Marco Marelli, Stefano Menini, Marco Baroni, Luisa Bentivogli, Raffaella Bernardi, Roberto Zamparelli, et al. A sick cure for the evaluation of compositional distributional semantic models.

Nils Reimers and Iryna Gurevych. 2019. Sentence-bert: Sentence embeddings using siamese bert-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3973–3983.

Andras Rozsa, Ethan M Rudd, and Terrance E Boult. 2016. Adversarial diversity and hard positive generation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops*, pages 25–32.

Dinghan Shen, Mingzhi Zheng, Yelong Shen, Yanru Qu, and Weizhu Chen. 2020. A simple but tough-to-beat data augmentation approach for natural language understanding and generation. *arXiv preprint arXiv:2009.13818*.

Lingxiao Wang, Jing Huang, Kevin Huang, Ziniu Hu, Guangtao Wang, and Quanquan Gu. 2019. Improving neural language generation with spectrum control. In *International Conference on Learning Representations*.

Shuohang Wang, Yuwei Fang, Siqi Sun, Zhe Gan, Yu Cheng, Jingjing Liu, and Jing Jiang. 2020. Cross-thought for sentence encoder pre-training. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 412–421.

Adina Williams, Nikita Nangia, and Samuel Bowman. 2018. A broad-coverage challenge corpus for sentence understanding through inference. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 1112–1122.

Zhuofeng Wu, Sinong Wang, Jiatao Gu, Madian Khabsa, Fei Sun, and Hao Ma. 2020. Clear: Contrastive learning for sentence representation. *arXiv preprint arXiv:2012.15466*.

Ziyi Yang, Yinfei Yang, Daniel Cer, Jax Law, and Eric Darve. 2020. Universal sentence representation learning with conditional masked language model. *arXiv preprint arXiv:2012.14388*.

Yan Zhang, Ruidan He, Zuozhu Liu, Kwan Hui Lim, and Lidong Bing. 2020. An unsupervised sentence embedding method by mutual information maximization. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1601–1610.

DisenKGAT: Knowledge Graph Embedding with Disentangled Graph Attention Network

Junkang Wu[1†], Wentao Shi[1], Xuezhi Cao[2], Jiawei Chen[1*]
Wenqiang Lei[3], Fuzheng Zhang[2], Wei Wu[2], Xiangnan He[1]
[1]University of Science and Technology of China, [2]Meituan, [3]National University of Singapore.
{jkwu0909@mail.,shiwnetao123@mail.,cjwustc@,hexn@}ustc.edu.cn
{caoxuezhi@,zhangfuzheng@,wuwei30@}meituan.com,wenqianglei@gmail.com

ABSTRACT

Knowledge graph completion (KGC) has become a focus of attention across deep learning community owing to its excellent contribution to numerous downstream tasks. Although recently have witnessed a surge of work on KGC, they are still insufficient to accurately capture complex relations, since they adopt the single and static representations. In this work, we propose a novel Disentangled Knowledge Graph Attention Network (DisenKGAT) for KGC, which leverages both *micro-disentanglement* and *macro-disentanglement* to exploit representations behind Knowledge graphs (KGs). To achieve micro-disentanglement, we put forward a novel relation-aware aggregation to learn diverse component representation. For macro-disentanglement, we leverage mutual information as a regularization to enhance independence. With the assistance of disentanglement, our model is able to generate adaptive representations in terms of the given scenario. Besides, our work has strong robustness and flexibility to adapt to various score functions. Extensive experiments on public benchmark datasets have been conducted to validate the superiority of DisenKGAT over existing methods in terms of both accuracy and explainability.The code is available at https://github.com/Wjk666/DisenKGAT.

CCS CONCEPTS

• **Computing methodologies** → **Knowledge representation and reasoning**;

KEYWORDS

Knowledge Graph, graph neural network, disentangled representation, mutual information

ACM Reference Format:
Junkang Wu, Wentao Shi, Xuezhi Cao, Jiawei Chen, Wenqiang Lei, Fuzheng Zhang, Wei Wu, Xiangnan He. 2021. DisenKGAT: Knowledge Graph Embedding with Disentangled Graph Attention Network. In *Proceedings of the 30th ACM International Conference on Information and Knowledge Management (CIKM '21), November 1–5, 2021, Virtual Event, QLD, Australia.* ACM, New York, NY, USA, 10 pages. https://doi.org/10.1145/3459637.3482424

∗ Corresponding author.
† Work done at Meituan.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
CIKM '21, November 1–5, 2021, Virtual Event, QLD, Australia
© 2021 Association for Computing Machinery.
ACM ISBN 978-1-4503-8446-9/21/11…$15.00
https://doi.org/10.1145/3459637.3482424

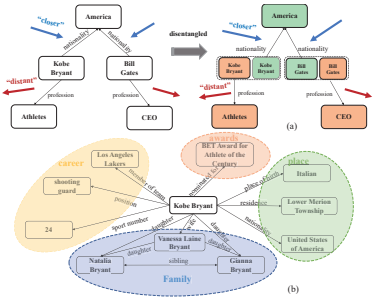

Figure 1: An example of the "Kobe Bryant" and "Bill Gates" neighboring distribution, where different color depicts a "topic" or "cluster". It is clear to figure that an entity always plays multiple roles in different scenarios.

1 INTRODUCTION

In recent years, knowledge graphs (KG) aroused considerable research interest since they changed the paradigm for numerous state-of-the-art natural language processing solutions and enhanced the AI-related applications. Representative applications include *e.g.,* dialogue generation [9], question answering [20], recommender systems [44], etc. Although modern KGs such as FreeBase [4], WordNet [22], Nell [23] have already contained millions of entities and triplets, they are still far away from complete due to the constantly emerging new knowledge. Therefore, knowledge graph completion (KGC), which predicts whether a new given triple is valid or not, still attracts much research attention.

In literature, most state-of-the-art KGC models are based on knowledge graph embedding, which focuses on learning low-dimensional embedding for entities and relations. These models could be classified into three types, translational models [5, 16, 41], bilinear transformation models [25, 33, 43] and convolutional network based models [8, 12, 24]. Although these models have achieved excellent performance, they still ignored the meaningful graph context such as vast structural information. In this way, Graph

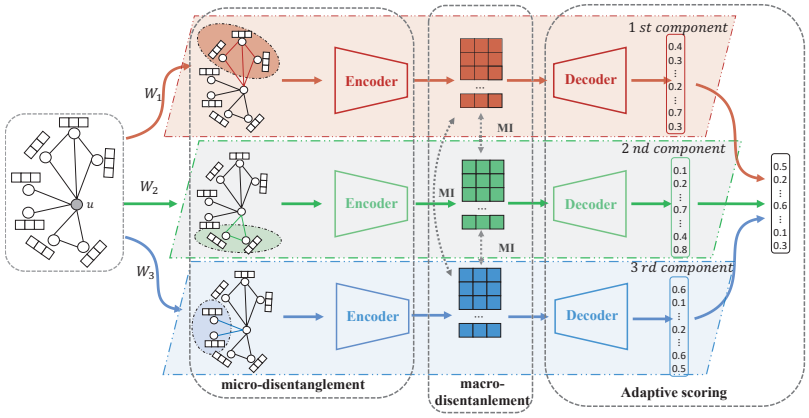

Figure 2: An architecture overview of our DisenKGAT. The whole model contains three key modules: (1) relation-aware aggregation, (2) independence constraint, and (3) adaptive scoring. Each channel (color) represents a specific component and different components keep individuals with each other by the correlation restriction. The final prediction result depends on all components of the entities and is adaptive to the given scenario (relation). Best viewed in color.

neural network based models [21, 28, 29, 35] become an active research focus for knowledge graph completion. Inspired by the various graph aggregation mechanisms [14, 37], they make use of layer-wise propagation to collect neighboring entity embedding incorporating the relation representation. In addition, CompGCN [35] proposes a novel framework for combining the aggregation ability of the GCN and the representative score function to construct the encoder-decoder paradigm in knowledge graph completion.

Although significant progress has been made by the combination of the graph structural information and semantic prediction, static representation still limits the flexibility and expressiveness of the embedding in particular in complex one-to-many (1-to-N), many-to-one (N-to-1), and many-to-many (N-to-N) relations. Typically, as shown in Figure 1 (a), "nationality" is a many-to-one relation — everyone has a unique nationality and numerous people have an identical nationality. Take the query *(Kobe, profession, ?)* and query *(Bill Gates, profession, ?)* as an example, owning to the common nationalities ("America") of "Bill Gates" and "Kobe", existing methods will naturally pull the representations of *Kobe* and *Bill Gates* closer to capture such identity. However, in terms of the relation "profession", where the two people indeed exhibit quite a difference, such static and similar representations will obviously affect the link prediction performance. In other words, existing methods can not generate a different representation while the scenario changes dynamically.

According to the issue mentioned above, we summarize that (i) simply aggregating neighborhood entities fails to effectively model the critical relationship that is significant in characterizing the local information in a specific scenario. We argue that entities and relations when engaged in different graph contexts, might exhibit extremely distinct meanings. (ii) They ignore the entanglement of the latent factors behind the entities embeddings while an entity may have multiple aspects and various relations focus on distinct aspects of entities. As the example in Figure 1 (b), the entity "Kobe Brant" is associated with different task components such as "Family", "Career", "Place" and "awards". Assume that in the prediction task of "Kobe's son", it's supposed to pay more attention to the component family such as wife and daughters rather than the irrelevant component about career or awards. (iii) In the light of the above two points, these methods result in low interpretability and non-robustness, i.e., they are prone to overreact to an irrelevant neighbor which does not fit the current scenario and wipe out the rich structural and context information for KGs itself.

In this work, we provide a novel Disentangled Knowledge Graph Attention network (DisenKGAT) that is able to learn the disentangled representation of the entities in terms of the property of the knowledge graph and has strong robustness in several kinds of representative score functions. To tackle the issue of entanglement of latent factors, we propose a mechanism that incorporates the micro-and macro-disentanglement. More specifically, As for the micro-disentanglement, that is, each entity contains multiple diverse components, our model leverages a dynamic assignment mechanism to collect neighboring entities' representation similar to the current scenario. Furthermore, as for the consideration of macro-disentanglement, that is, different components should separate clearly, we utilize mutual information regularization to ensure each component be independent of each other. Besides, the learned disentangled representation can be along with different kinds of score functions which is also proof of strong robustness.

we summarize the main contributions of our work as follows:

- We propose a novel Disentangled knowledge graph convolutional network to learn the disentangled embedding for knowledge graphs. And the proposed encoder model can be potentially generalized to other score functions in the task of knowledge graph completion. To the best of our knowledge, this is the first attempt to leverage the disentangled representation in knowledge graph completion.
- To achieve micro-disentanglement of entities, we propose a special relation-aware aggregation mechanism, which aggregating the neighborhood information at a semantic level while ensuring the consistency of the adaptive scoring part of the model.
- To achieve macro-disentanglement of the component distribution level, we propose a mutual information-based regularization to reduce intra-component correlation.
- We conduct extensive experiments on real-world benchmark datasets to validate the effectiveness of our proposal. Our DisenKGAT not only outperforms state-of-the-arts but also has strong robustness and interpretability.

2 RELATED WORK

2.1 Knowledge Graph Embedding

The fundamental point of knowledge graph representation learning is to learn how low-dimensional distributed embedding of entities and relations. These models could be roughly divided into three categories: Distance-based model [5, 16, 41] , semantic models [25, 33, 43], and neural network based models [8, 12, 24]. Most of these KG embedding methods build a paradigm that defining a score function at first to measure the plausibility of the given triplets and then making sure positive samples have higher scores than negative samples. Despite the success of these approaches, there still exists lacking consideration for knowledge graph structural information. Meanwhile, graph neural network based KG [21, 28, 29, 35] models try to use more graph structure information and gradually develop it into a mature and more flexible aggregation pattern adapted to the characteristics of the complex knowledge graph. However, they are still learning a static representation for each entity and relation which can not deal with the 1-to-N, N-to-1, and N-to-N relations.

Motivated by the aforementioned observations, the problem has received scant attention in the research literature, but from distinct views. [11, 16, 41] provide the relation-specific projections to project an entity into a different latent space related to the given relation. Coke [38] utilizes the transformer to exploit the contextualized and dynamic representations for entities and relations. FAAN [30] proposes an adaptive attention network and a transformer encoder which could help to adaptively match references with queries. It seems that the mainstream method of tackling the issue of static representation borrows the capability of Transformer in capturing the dynamic KG embeddings. It has even shown that the aggregation mechanism in Transformers [36] is similar to dealing with a complete graph by GNNs which could benefit entity representation learning and graph structural mining collaboratively. Although similar phenomena have been touched upon in previous work, there is a little formal discussion about knowledge graph embedding with disentangled representation to investigate latent factors behind the entities.

2.2 Disentangled Representation Learning

Disentangled representation learning, which aims to learn embedding including various separate components behind the data, has get significant progress in numerous fields, such as texts [13], images [6] user behaviors [19] and recommendation [39]. In the field of the graph, DisenGCN [18] is the first work that tends to achieve the micro-disentanglement at the sample level but lacks the consideration of macro-separability. IPGDN [17] and ADGCN [46], which utilize the Hilbert-Schmidt Independence Criterion (HSIC) and adversarial learning respectively, further extend to achieve micro-and macro- disentanglement to ensure independence properties. And [46] is the pioneer work which put forward the concept of micro- and macro- disentanglement explicitly. The above models develop the disentanglement idea in homogeneous networks, while DisenHAN [40] focus on Heterogeneous networks. Despite the success of disentangled learning attempts in graphs, how to apply it in complex knowledge graph still remain challenging. Here, our work focus on learning disentangled representation in KG, which generates adaptive embedding in the light of the scenario.

3 PRELIMINARY

In this section, we first present some important concepts related to knowledge graph and mutual information. Then we give the formal definition of our task.

Knowledge Graph. Knowledge graphs (KGs) is defined as a directed graph that stores structured information of real-world entities and facts. Let $\mathcal{G} = \{\mathcal{V}, \mathcal{R}, \mathcal{L}\}$ be an instance of a KG, where $\mathcal{V}$, $\mathcal{R}$ and $\mathcal{L}$ denote the entity (node), relation and edge (fact) sets respectively. Each edge $e \in \mathcal{L}$ is presented as a triple $(h, r, t) \in \mathcal{V}\times\mathcal{R}\times\mathcal{V}$, describing there is a relationship $r \in \mathcal{R}$ from head entity h to tail entity t. For example, the triple *(Kobe Byrant, daughter, Natalia Bryant)* describes that *Kobe Byrant* has a daughter named *Natalia Byrant.*

Mutual information. Mutual information (MI) is a fundamental quantity for measuring the dependence of two random variables. The mutual information between the random variables X and Z is defined as follow:

$$\mathcal{I}(x, z) = \mathbb{E}_{(p(x,z))}[log\frac{p(x, z)}{p(x)p(z)}] \tag{1}$$

where $p(x, z)$ is the joint probability distribution of X and Z, while $p(x)$ and $p(z)$ are the corresponding marginal distribution. In contrast to correlation, mutual information is able to capture non-linear dependencies between variables and thus acts as a standard measure of true dependence [3].

Task Formulation. The task of knowledge graph completion involving inferring the missing edges in the knowledge graph $\mathcal{G}$, *i.e.,* predicting the target entity of a given query of head entity and relation $(h, r, ?)$ [1]. Specifically, the task is usually formulated as a ranking problem, which aims at learning a score function $\psi(h, r, t) : \mathcal{V} \times \mathcal{R} \times \mathcal{V} \rightarrow \mathbb{R}$ that assigns a higher score for valid triplets than the invalid ones.

[1]Some of the related work formulate the problem as inferring the missing head entity given a tail entity and a a relation $(?, r, t)$. In fact, the two problems are reducible to the same problem — learning a proper score function $\psi(h, r, t)$.

4 DISENTANGLED KNOWLEDGE GRAPH ATTENTION NETWORK

In this section, we present our disentangled knowledge graph attention network (DisenKGAT), an end-to-end deep model that is able to learn disentangled entities representation. Overall, the architecture of DisenKGAT is illustrated in Figure 2, consisting of four modules: (1) Disentangled Transformation (Section 4.1): we first project original features of each entity into K different latent spaces, which encode distinct semantic of the entity; (2) Relation-aware Aggregation (Section 4.2): we leverage relation-aware attention mechanism to identify relevant neighbors for each factor and then correspondingly guide the neighbor information aggregation; (3) Independence constraint (Section 4.3): mutual information regularization is introduced to enhance the independence between each disentangled components; (4) Adaptive Scoring (Section 4.4): we generate the final prediction by adaptively combining the results from each component according to the given scenario (*i.e.,* relation).

4.1 Disentangled Transformation

Our model aims to learn disentangled representation where each component contains distinct semantic. Specifically, for each entity u, we would like its representation to be composed of K independent components, *i.e.,* , $e_u = [h_{u,1}, h_{u,2}, ..., h_{u,K}]$, where $h_{u,k} \in \mathbb{R}^{\frac{d_{embed}}{K}}$ depicting the k-th aspect of the entity u. To achieve this goal, we first project the feature vector x_u into different latent spaces in order to make each component extract distinct semantic from the node feature:

$$h^0_{u,k} = \sigma(W_k \cdot x_u) \tag{2}$$

where the initial embeddings $\{h^0_{u,k}\}_{k=1}^K$ are obtained from x_i through K distinct projection matrix $W = \{W_1, W_2, \cdots, W_K\}$, σ is the activation function and x_u is the feature of the entity u. Note that here we do not use any normalization such as BatchNorm [10] or LayerNorm [1], as we empirically find it ineffective in our task.

4.2 Relation-aware Aggregation for Micro-disentanglement

The feature vector is typically incomplete in real-world and is insufficient to generate a satisfactory embedding. As such, to comprehensively characterize each component of entities, neighborhood aggregation is required so that the learning of each entity can benefit from the rich information from the neighborhoods. However, in a disentangled knowledge graph learning task, we should not use all the neighbors when re-constructing node component $h_{u,K}$ as only a subset of neighbors carry the useful information for the aspect k. Take the entity "Kobe Bryant" (as shown in Figure 1) as an example, when we would like to learn the component of "Family", we must highlight those neighbors with relation "daughters" and "wife" while down weight the contribution of others. In order to more accurately describe the k-th aspect of an entity, we must answer the following important question: How to identify the subset of relevant neighbors that are actually connected by the entity u due to the fact k? Although recent years have seen a neighborhood routing strategy for homogeneous disentangled graph learning [18], it is no longer suitable for knowledge graph as it would neglect crucial information — the edge relation, which provides explicit evidence of why two entities are connected and naturally plays a key role in aggregation.

For this purpose, in this paper, we propose a novel relation-aware aggregation strategy. We first conduct component-level interaction and then leverage relation-aware attention mechanism to adaptively combine useful information from relevant neighbors for each component. For each entity u and each component k, we conduct the following interaction to generate message from the specific neighbor v with the relation r:

$$m_{(v,k,r)} = \phi(h_{v,k}, h_r, \theta_r) \tag{3}$$

$$\theta_r = W_r = diag(w_r) \tag{4}$$

Here, $\phi : \mathbb{R}^d \times \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ is a composition operator; $m_{(v,r)}$ denotes the message aggregated from neighbor v with relation r; and $\theta_r \in \mathbb{R}^d$ denotes the relation-specific projection matrix. Borrowed the idea from [43] , here θ_r is restricted to be a diagonal matrix for efficiency. Note that the implementation of ϕ can refer to the recent work on vanilla knowledge graph embedding. In this paper, we implement the composition operator ϕ in a variant way, with four kinds of approaches including subtraction, multiplication, cross interaction and circular-correlation (detailed formula refer to Section 5.5). This result validates the generalization of our method, which can enjoy the merits of existing methods.

In order to better capture the relevance between u and v in each component space, we leverage a relation-aware attention mechanism to infer the importance of each neighbor in aggregation. Here we simply adopt the dot-product(DP) attention based on the hypothesis that the more similar the entity u and the neighbor v are in the k-th component in terms of their relation r, the more likely the factor k is to be the reason for the connection.

$$\begin{aligned}\alpha^k_{(u,v,r)} &= softmax((e^k_{u,r})^T \cdot e^k_{v,r}) \\ &= \frac{exp((e^k_{u,r})^T \cdot e^k_{v,r})}{\sum_{(v',r)\in\hat{N}(u)} exp((e^k_{(u,r)})^T \cdot e^k_{(v',r)})}\end{aligned} \tag{5}$$

where $e^k_{u,r} = c_{u,k} \circ \theta_r$, represents the k-th relation-aware component representation of entity u in a specific relation-aware subspace. θ_r is shared with the θ in Formula (4) in order to ensure the consistency of the semantic subspace. $\hat{N}(u)$ denotes the neighboring entities $N(u)$ including u itself.

Obtained the attention score, we could aggregate the representation from neighbors in each component respectively. Let $h^{l+1}_{u,k}$ denotes the k-th component representation of the entity u obtained after l layers which is defined as:

$$h^{l+1}_{u,k} = \sigma(\sum_{(v,r)\in\hat{N}(u)} \alpha^k_{(u,v,r)} \phi(h^l_{v,k}, h^l_r, \theta_r)) \tag{6}$$

Similarly, here h^l_r denotes the representation of a relation r in the k-th layer. We also update h^l_r with layer-wise linear transformation with parameters W^l_{rel} as:

$$h^{l+1}_r = W^l_{rel} \cdot h^l_r \tag{7}$$

In summary, the relation-aware aggregation strategy guarantees that $h^{l+1}_{u,k}$ is prone to be aggregated into a tight area in each component subspace. **We refer to [46]** and would like to name such disentangled mechanism as *micro-disentanglement*.

4.3 Independence Constraint for Macro-disentanglement

In the complex multi-relational graph such as knowledge graph, we expect that there should be a weak dependence among the different component representations. Similar objectives have been proposed in different views such as distance correlation and Hilbert-Schmidt Independence Criterion (HSIC) [17], but we argue that controlling the linear correlation is insufficient, as the nonlinear dependence commonly exists especially in complex knowledge graphs. Mutual information, which is a fundamental quantity for measuring nonlinear dependence of two random variables, sheds a light on achieving comprehensive disentanglement, *i.e.,* directly controlling the mutual information between the disentangled components would be more a promising solution for disentangled graph representation learning.

Although the idea is straightforward, the solution is challenging. Directly optimizing mutual information is infeasible. Although there is some work on developing surrogate objective functions, most of them delving into the lower bound of mutual information. But these objective functions are not suitable for the minimization, with which the training procedure is easily inclined to divergence. To deal with this problem, we propose to utilize the contrastive log-ratio upper-bound MI estimator [7] for achieving disentanglement which estimates the differences of conditional probabilities between positive and negative samples. However, this estimator can not be directly applied as a conditional probability between different components are unavailable such as $p(h_{u,i}|h_{u,j})$, where $i \neq j$. To push this idea forward, we propose to leverage a variational distribution $q_\theta(h_{u,i}|h_{u,j})$ with variational parameter θ a simple neural network Q to approximate the real conditional one. We define the final object function as:

$$\begin{aligned}\mathcal{L}_{mi} = \sum_i \sum_j \mathbb{E}_{(h_{u,i},h_{u,j})\sim p(h_{u,i},h_{u,j})}[\log q(z_{u,i}|z_{u,j})] \\ - \mathbb{E}_{(h_{u,i},h_{u',j})\sim p(h_{u,i})p(h_{u,j})}[\log q(z_{u,i}|z_{u',j})]\end{aligned} \tag{8}$$

Notice that, $i \neq j$ and Q is trained to minimize the KL-divergence between the true conditional probabilities distribution $p(h_{u,i}|h_{u,j})$ and variational one $q_\theta(h_{u,i}|h_{u,j})$ at the same time.

$$\mathcal{L}_{(h_{u,i},h_{u,j})} = \mathbb{D}_{KL}[p(h_{u,i}|h_{u,j})||q_\theta(h_{u,i}|h_{u,j})] \tag{9}$$

Here, we assume the conditional distribution $p(h_{u,i}|h_{u,j})$ is a Gaussian distribution, and optimize it with final object function alternately.

In summary, explicitly controlling mutual information estimation between components would weak their dependence such that they can capture distinct semantic. **We refer to [46]** and would like to name such disentanglement mechanism as *macro-disentanglement.*

4.4 Adaptive Scoring

Merit of disentangled knowledge graph representation is its adaption that the importance of each aspect on final prediction can adaptively adjust according to the given scenario (*i.e.,* relation in knowledge graph completion). To achieve this goal, in this module (*aka.* decoder), we first conduct component-level prediction and then leverage an attentive scoring mechanism to guide the fusion of the results from different components.

Component-level prediction. Here we take the tail prediction as an example. Once obtained the disentangled head entity and relation representation after the L times neighborhood aggregation, we compute the score for each candidate triplets (u, r, v) in each component. In fact, our method is flexible and can enjoy the merit of recent advances in knowledge graph completion — we can choose any score function that recent work delving into, such as transE [5], DistMult [43] and ConvE [8]. Here we take ConvE as an example for description:

$$\psi^k_{(u,r,v)} = f(vec(f(\overline{h^L_{u,k}}; \overline{h^L_r} \star \omega))W)h^L_{v,k} \tag{10}$$

Where, $\overline{h^L_{u,k}} \in \mathbb{R}^{d_w \times d_h}, \overline{h^L_r} \in \mathbb{R}^{d_w \times d_h}$ denote 2D reshaping of $h^L_{v,k} \in \mathbb{R}^{d_w d_h \times 1}, h^L_r \in \mathbb{R}^{d_w d_h \times 1}$, and $(\star)$ denotes the convolution operation. The whole formula represents the plausibility of the given triplet (u, r, v) in the k-th component.

Relation-aware attentive fusion. To make our model is adaptive to the given relation, we add the attention scoring $\beta^k_{(u,r)}$ after the decoder module. We assume that, in the relation-aware subspace, the best-matched component representation should be closer to the given relation embedding. In other words, As for query *(Kobe Byrant, member of the sports team, ?)*, our model should pay more attention to the component which aggregates more neighboring information from the topic "career". And the "career" component contains multi triplets such as *(Kobe, sports number, 24), (Kobe, position, shooting guard)* will be "closer" to the relation *member of sports team* against other components. Hence, by sharing the mapping matrix θ_r with the relation-aware aggregation module, it can facilitate disentangling components thoroughly and distinguish the correct triplet.

$$\begin{aligned}\beta^k_{(u,r)} &= softmax((h^L_{u,k} \circ \theta_r)^T \cdot h^L_r) \\ &= \frac{exp((h^L_{u,k} \circ \theta_r)^T \cdot h^L_r)}{\sum_{k'} exp(h_{u,k'} \circ \theta_r)^T \cdot h^L_r)}\end{aligned} \tag{11}$$

where $h^L_{u,k}$ and h^L_r denotes the final representation of k-th component of entity u and relation r respectively.

$$\psi^{final}_{(u,r,v)} = \sum_k \beta^k_{(u,r)} \psi^k_{(u,r,v)} \tag{12}$$

4.5 Full Objective

In the training procedure, we leverage a standard cross entropy loss with label smoothing, defined as:

$$\begin{aligned}\mathcal{L} = -\frac{1}{B}\frac{1}{N} \sum_{(u,r)\in batch} \sum_i (t_i \cdot \log(\psi^{final}_{(u,r,v_i)}) \\ + (1 - t_i) \cdot \log(1 - \psi^{final}_{(u,r,v_i)})) + \lambda \cdot \mathcal{L}_{mi}\end{aligned} \tag{13}$$

Where B is the batch size, N is the number of entities in KG, t_i is the label of the given query (u,r), and $\mathcal{L}_{mi}$ and λ are the mutual information regularization loss and its corresponding hyperparameter. Note that, Q in Formula (9) is optimized in an alternative way during the training procedure.

Table 1: KG completion results for embeddings on FB15k-237 and WN18RR. The best results are in bold and the second best results are underlined.

Model	FB15k-237					WN18RR				
	MRR	MR	Hits@1	Hit@3	Hit@10	MRR	MR	Hits@1	Hit@3	Hit@10
TransE [5]	0.294	357	-	-	0.465	0.226	3384	-	-	0.501
Distmult [43]	0.241	254	0.155	0.263	0.419	0.43	5110	0.39	0.44	0.49
ConvE [8]	0.325	244	0.237	0.356	0.501	0.43	4187	0.40	0.44	0.52
RotatE [31]	0.338	177	0.241	0.375	0.533	0.476	3340	0.428	0.492	0.571
SACN [29]	0.35	-	0.261	0.39	0.54	0.47	-	0.43	0.48	0.54
InteractE [34]	0.354	**172**	0.263	-	0.535	0.463	5202	0.43	-	0.528
MuRE [2]	0.336	-	0.245	0.370	0.521	0.465	-	0.436	0.487	0.554
COMPGCN [35]	0.355	197	0.264	0.39	0.535	0.479	3533	**0.443**	0.494	0.546
AcrE [27]	0.358	-	0.266	0.393	0.545	0.459	-	0.422	0.473	0.532
ReInceptionE [42]	0.349	173	-	-	0.528	0.483	1894	-	-	0.582
DisenKGAT	**0.368**	179	**0.275**	**0.407**	**0.553**	**0.486**	**1504**	0.441	**0.502**	**0.578**

Table 2: Dataset statistics

Data sets	$\|\varepsilon\|$	$\|\mathcal{R}\|$	Triplets		
			Train	Valid	Test
FB15k-237	14,541	237	272,114	17,535	20,466
WN18RR	40,943	11	86,835	3,034	3,134

5 EXPERIMENTS

In this section, we present experiments to demonstrate the effectiveness of DisenKGAT. We design numerous experiments aim to answer the following research questions:

- **RQ1:** How does DisenKGAT perform compared to existing aproaches, *w.r.t.* distance-based and semantic matching models?
- **RQ2:** How do the critical components (e.g., relation-aware aggregation) contirbute to DisenKGAT and how do different hyperparameters (e.g., factor number) affect DisenKGAT?
- **RQ3:** Does DisenKGAT work roubstly with other decoder modules?
- **RQ4:** Can DisenKGAT give explanations of the benefits brought by the disentangled factors?

5.1 Experimental Settings

5.1.1 ***Data Sets***. To verify the performance of DisenKGAT, we select two most commonly used public datasets: FB15k-237 [32] and WN18RR[8]. The summary statistics of the above dataset is listed in Table. FB15k-237 is an improved version of the FB15k [5] dataset where all trivial inverse relations are moved. It contains large-scale general knowledge facts such as awards, places, and actors. WN18RR is a subset of WN18[5] that stores structured knowledge of English lexicons including hypernym, hyponym, and synonym, etc. It also deletes inverse relations similar to FB15k-237.

5.1.2 ***Baselines***. We compare our DisenKGAT with several state-of-the-art methods, including distanced-based models (TransE [5], RotatE [31]), semantic matching models (Distmult [43], RESCAL), and neural network based models (ConvE [8], InteractE [34], SACN [29], ArcE [27], ReinceptionE [42], COMPGCN [35]).

- **TransE** [5] is the first translation based work in knowledge graph embedding by assuming that the superposition of head and relation embedding h+r should be close to the tail embedding of t.
- **RESCAL** [26] is the three-way rank-r factorization methods which treats each relation as a full rank matrix.
- **DistMult** [43] puts forward a simplified bilinear formulation which deals with each relation as a diagonal matrix.
- **InteractE** [34] is an extensive version of ConvE. It increases the rich interactions between entities and relations by the usage of feature permutation and circular convolution.
- **RotatE** [31] is built upon TransE, which regards relation as a kind of rotation from head entiy to tail entity.
- **ConvE** [8] is a representative neural network based models, which leverage 2D convolution and multiple layers of nonlinear transformation to model the complex interaction between entities and relations.
- **SACN** [29] proposes an end-to-end structure aware convolutional Network that takes the benefit of GCN and ConvE together.
- **MuRE** [2] is translational distance hyperbolic embedding with a diagonal relational matrix.
- **ArcE** [27] utilizes a simple but effective atrous convolution on knowledge graph embedding.
- **ReinceptionE** [42] proposes an inception network with joint local-global structural information.
- **COMPGCN** [35] is a general framework which incorporates graph neural network with knowledge graph embedding.

5.1.3 ***Evaluation protocol***. We perform the link prediction task following the settings in [5], given the test triplet to be predicted, we rank it against all candidate triplets which filter out all the valid triplets appearing in the training, validation, and test datasets. And inverse relation is also added to predict the head entity [15] during the training procedure. Meanwhile, the performance of our model is reported on the standard link prediction metrics: Mean Reciprocal Rank (MRR), Mean Rank (MR), and Hits@1, Hits@3, Hits@10.

5.1.4 ***Paramter Settings***. We implement our DisenKGAT model in PyTorch and have released our implementation (codes, parameter

Table 3: Results on link prediction by relation category on FB15k-237 dataset. Following the [41], the relations are divided into four categories: one-to-one (1-1), one-to-many (1-N), many- to-one (N-1), and many-to-many (N-N).

		RotatE		WGCN		COMPGCN		DisenKGAT	
		MRR	H@10	MRR	H@10	MRR	H@10	MRR	H@10
Head Pred	1-1	0.498	0.593	0.422	0.547	0.457	0.604	**0.501**	**0.625**
	1-N	0.092	0.174	0.093	0.187	0.112	0.190	**0.128**	**0.248**
	N-1	0.471	0.674	0.454	0.647	0.471	0.656	**0.486**	**0.659**
	N-N	0.261	0.476	0.261	0.459	0.275	0.474	**0.291**	**0.496**
Tail Pred	1-1	0.484	0.578	0.406	0.531	0.453	0.589	**0.499**	**0.641**
	1-N	0.749	0.674	0.771	0.875	0.779	0.885	**0.789**	**0.889**
	N-1	0.074	0.138	0.068	0.139	0.076	0.151	**0.086**	**0.180**
	N-N	0.364	0.608	0.385	0.607	0.395	0.616	**0.402**	**0.629**

setting, and training log) to enhance the reproducibility. In our method, each component embedding size is fixed to 200 for a fair comparison. And we fix the optimizer as Adam. A grid search is conducted to confirm the optimal parameter setting for each model. To be more specific, the number of layer is tuned amongst {1, 2, 3}, dropout is tuned in {0.0, 0.1, ...0.5} to prevent over-fitting, batch size is varying in {128, 256, 512, 1024, 2048}, and the coefficients of Mutual information regularization are search in {0.1, 0.01, 0.001, 0.0001}. We initialize the model parameter with Xavier for a fair comparison with GNN-based models, especially for COMPGCN.

5.2 Performance Comparsion (RQ1)

We begin to summarize the results by analyzing the performance of all models reported in table and have the following observations:

- From the results in Table 1, we can see our proposed DisenKGAT obtains competitive results compared with state-of-the-art models. In particular, DisenKGAT achieve a considerable improvement on the FB15k-237 dataset w.r.t MRR, Hits@1, and Hits@3, it is also superior to other models using MR on the WN18RR dataset. We attribute these results to the disentanglement module on a complex knowledge graph. Since the FB15k-237 dataset includes 237 relation types, it is suitable for our motivation to deal with multi-relation entanglement issues. Meanwhile, WN18RR only contains 11 relation types, and each entity embodies an extremely single meaning. For example, the entity "pass on" has three diverse meanings (transmit, transfer possession of, cause be distributed), and each meaning belongs to an individual entity. Hence, our latter experiments will pay more attention to FB15k-237.
- Focus on the complex multi-relations scenario especially for the issue of 1-N, N-1, and N-N relations (shown in Table 3), We present the experimental results on different relation types following the [41]. We choose the FB15k-237 as our object owing to its abundant multi-relations and denser graph structure and compare our model with ROTATE [31], W-GCN [29], COMPGCN [35]. We find that DisenKGAT outperforms baselines in all relation types. More specifically, GNN-based models (W-GCN, COMPGCN) are superior to RotatE on complex relation types (1-N, N-1, N-N) which indicates that full utilization of graph structure facilitates handling complex relations. Meanwhile, we observe that RoatatE outperforms W-GCN and COMPGCN on simple relation (1-1), which can be attributed to its strong capability in capturing various relation structures, including symmetry/antisymmetry, composition, and inversion. Just as our motivation, we tend to capture rich latent factors in complex scenarios and generate adaptive embeddings in terms of the given scenario. Therefore, our model will aggregate those neighbors which are in similar "topics" potentially, thus outperforms other models by a large margin in both simple and complex relations.

Table 4: Result of ablation study

model	MRR	MR	Hits@1	Hits@3	Hits@10
w/o micro	0.355	197	0.265	0.392	0.534
w/o macro	0.356	303	0.263	0.392	0.542
w/o HSIC	0.352	259	0.263	0.387	0.527
DisenKGAT	0.368	179	0.275	0.407	0.553

5.3 Ablation Study (RQ2)

As the disentangled propagation mode consistently outperforms all kinds of baseline along with various score functions, we investigate the impact of each module of the model to analyze it deeply and comprehensively. To be more specific, we conduct ablation studies on the presence of aggregation mechanism, independence modeling, attention scoring, and several hyper-parameters.

5.3.1 Impact of micro-disentanglement. To achieve the micro-disen tanglement, we utilize a relation-aware aggregation module which facilitates the distinction of different components of each entity. So is it crucial to consider neighboring information and utilize such propagation layers? Toward this end, multi variants are constructed by removing the whole micro aggregation module termed as DisenKGAT$_{\text{w/o micro}}$.The detailed results are listed in Table 4. In contrast to the complete model, DisenKGAT$_{\text{w/o micro}}$ obtains dramatically worse results, which can be attributed to the following reasons. (1) Owing to the operator of relation-aware mapping, each component is projected into different latent subspace and contains individual semantic information.(2) With the assistance of relation-aware aggregation, our model explores the deeply fine-grained level of "topics" and collect specific neighbors in different scenario. However, lacking the micro-disentanglement, our model degrade into COMPGCN, which leaving entanglement unexplored.

Table 5: Performance on link prediction task evaluated on FB15k-237 dataset. Similar to COMPGCN, X + M (Y) denotes that method M is used for obtaining entity (and relation) embeddings with X as the scoring function. Y denote the composition operator ϕ. And detailed analysis refer to section

Scoring Function(=X)→	TransE			DistMult			ConvE		
Methods↓	MRR	MR	H@10	MRR	MR	H@10	MRR	MR	H@10
X	0.294	357	0.465	0.241	354	0.419	0.325	244	0.501
X+D-GCN	0.299	351	0.469	0.321	225	0.497	0.344	200	0.524
X+W-GCN	0.264	1520	0.444	0.324	229	0.504	0.244	201	0.525
X+COMPGCN(sub)	0.335	194	0.514	0.336	231	0.513	0.352	199	0.530
X+COMPGCN(Mult)	0.337	233	0.515	0.338	200	0.518	0.353	216	0.532
X+COMPGCN(Corr)	0.336	214	0.518	0.335	227	0.514	0.355	197	0.535
X+DisenKGAT(sub)	0.334	183	0.51	0.346	196	0.531	0.358	181	0.543
X+DisenKGAT(Mult)	0.342	**170**	0.524	0.353	**184**	0.536	0.364	**171**	0.550
X+DisenKGAT(Corr)	0.338	203	0.520	0.341	200	0.528	0.359	189	0.541
X+DisenKGAT(Cross)	**0.343**	187	**0.526**	**0.354**	204	**0.540**	**0.368**	179	**0.553**

5.3.2 Impact of macro-disentanglement. To achieve the macro-disentanglement, we leverage mutual information minimization to ensure each component be separate. Intuitively, without the separability regularization, it is prone to cause the aggregated information to be unrepresentative in terms of the given scenario. In particular, we conduct experiments to verify our intuition. (1) On the one hand, removing the mutual information regularization, denoted as ($\text{DisenKGAT}_{\text{w/o macro}}$), helps to validate the importance of macro-separability. (2) On the other hand, we replace the MI regularization with Hilbert-Schmidt Independence Criterion (HSIC), denoted as $\text{DisenKGAT}_{\text{w/o HSIC}}$, which is also common metrics measuring two-variable correlation.

Obviously, the non-regularization mode is inferior to the complete model. We suspect that mutual information helps to generate diverse component representation to some extent and avoids producing the representation of repeated semantics. Furthermore, the choice of macro-disentanglement regularization is also critical in the training procedure. HSIC is also a common measurement of correlation which was utilized in some tiny homogeneous graphs [17]. However, the empirical result shows that it is not suitable for more complex heterogeneous graphs such as our knowledge graph.

5.3.3 Impact of component number. In this section, we consider varying the number of disentangled factors. The suitable disentangled factors are related to the facts in the real datasets. Here we search the component numbers in the range of {1, 2, 3, 4, 5}. Figure 3 summarizes the experimental results *w.r.t.* the FB15k-237 and WN18RR data set. We observe that:

When the choice of the number of disentangled components is 1 in FB15k-237, our model intuitively degrades into a normal GNN-based model which coupling with attention aggregation and relation-aware mapping. Although it outperforms the COMPGCN attributed to the flexible aggregation mechanism, it still leads to suboptimal results. We suspect that lacking exploiting the latent factors will be difficult to deal with complex semantic meanings and degenerate to static representation learning.

In FB15k-237, increasing the number of disentangled components can substantially provide a considerable improvement in terms of all measures. The best choice is around 4, which is related to the "topics number" of most entities. When $k > 4$, the performance dramatically degrades since it makes some topics too fine-grained to carry crucial information. The difference is that in the WN18RR dataset, because of its simple and fine-grained meaning, the best selection of K is about 2, and with the increase of K value, the performance collapses significantly.

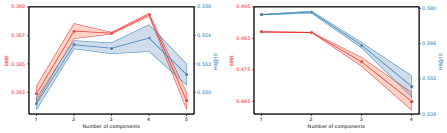

(a) FB1515k-237 **(b) WN18RR**

Figure 3: Impact of component number (K).

5.4 Robustness (RQ3)

As mentioned in contribution, our model has strong robustness in knowledge graph embedding since it could work along with multi-categories score function and has a considerable improvement. Borrowed from COMPGCN, we evaluate the effect of using different representative score function (shown in Table 5) : TransE (translational), DistMult (semantic matching), and ConvE (neural-based model). Inspired from [5, 28, 45], we define four kinds of operators:

- **Subtraction(Sub)** : $\phi(e_s, e_r, \theta) = (\theta_r \cdot e_s) - e_r$
- **Multiplication(Mult)** : $\phi(e_s, e_r, \theta) = (\theta_r \cdot e_s) \circ r_r$
- **circular correlation(Corr)** : $\phi(e_s, e_r, \theta) = (\theta_r e_s) \star e_r$
- **Crossover Interaction(Cross)** : $\phi(e_s, e_r, \theta) = \theta_r e_s + \theta_r (e_s \circ e_r)$

The empirical results are shown in Table 5. We observe that:

- By the utilization of the Graph Convolution Network, it can further explore the graph structural information. Hence it could

provides a substantial improvement. And we suspect that owing to the lacking consideration of incorporating relation embedding into the propagation layer at the aggregation stage, W-GCN and D-GCN do not perform well with the various score functions. On the contrary, COMPGCN and our proposed DisenKGAT outperform across the three score functions in terms of all measures.

- On average, our DisenKGAT obtains around 2%, 5%, 3% relative increase in MRR with TransE, DistMult, and ConvE respectively compare to the COMPGCN. To be more specific, as the design of relation-aware aggregation and mutual information regularization empowers the model with rich structural information and disentangled latent factors, we can surpass the baseline models by a large margin in all metrics. However, unlike other combinations, our model with TransE score function in "sub" composition operator leads to slight improvement. We attribute these results to the shallowness of the intrinsic structure used in TransE, which is difficult to capture the deeply complex interactions between entities and relations.

5.5 Explainability of DisenKGAT (RQ4)

In this section, we exploit the disentangled component of each entity in the test set to investigate how the disentangled factors facilitate the embedding. We provide two examples from FB15k-237 to show an intuitive impression of our disentangled performance. The detailed results are displayed in Figure 4, we then have the following observations:

- In the module of relation-aware aggregation, we leverage a similarity score to measure the correlation between neighbors in each component. We assume that, the similarity between the entity u and v in the k-th component subspace represents the importance of factor k in this scenario. In other words, factor k may be associated with a "topic" or a "cluster" which influences the reason why u and v are linked. For example in the upper part of Figure 4, the top two neighbors of entity "United States of American" in component c_1 are *(Olympics, 1924 Summer Olympics)*[2] and *(Olympics, 1900 Summer Olympics)*, while *(location/contains, Washington metropolitan area)* and *(location/contains, LaGuardia Airport)* are ranked top two in component c_2. It is clear to figure out that, each component of the entity "United States of American" plays a diverse role and constructs distinguishable clusters potentially.
- In the module on attention scoring, we utilize a similarity score β to match the given query to the semantic representation in each component. As shown in the right part of Figure 4, given the query of *(United States of the America, /tv/country_of_origin_reverse,?)*, the component c_4 rank first in the whole semantic space. In terms of the analysis in the last point, we could guess component c_1, c_2, c_3, c_4 are related to the topic "Sports", "place", "City" and "film and TV" respectively. Obviously, c_4 is closer to the given query, and its weight reflects the important influence in the task of link prediction.
- As the whole computation is element-wise, link prediction is under the scoring of the triplets in each component independently. So the topic or cluster in each component of various entities should be shared all the time. We find that given the query *(Danny DeVito, /film/produced_by_inverse)*, the most crucial component is also c_4. Similar to the analysis in point 2 above, the component c_4 about the entity "Danny DeVito" is about "film" which is similar to the entity "The United States of the America". This empirically shows that the entity "Danny DeVito" may be linked with "United States of the America" in some scenarios such as "nationality". Then the model induces a similar topic c_4 in both entities which intuitively helps to deal with the embedding in the complex knowledge graph.

[2]Note that the complete triplet is *(United States of American, Olympics, 1924 Summer Olympics)*. We discuss the neighbors here in the format of (relation, tail) as above.

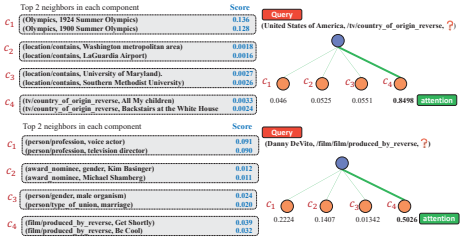

Figure 4: Explanations of disentangled performance. Best viewed in color.

6 CONCLUSION AND FUTURE WORK

In this work, we focus on the disentangled representation behind entities in the knowledge graph for link prediction. We propose a novel Disentangled Knowledge attention network, DisenKGAT, which exploits the disentangled factors from two views: (1) leveraging a novel relation-aware aggregation mechanism to achieve the micro-disentanglement while ensuring the structural information; and (2) taking the macro-separability into consideration, which utilizes mutual information minimization as a regularization. Furthermore, we provide various experiments to verify the effectiveness and explainability of our model.

For future work, we will explore a more general disentangled framework that could adapt to more complex scenarios. For example, how to disentangle knowledge graph in a fine-grained level, where the number of components per entity can be different and flexible. Besides, we also have a plan to explore the potential of mutual information in more various scenarios rather than just as a regularization in our work.

ACKNOWLEDGMENTS

This work is supported by the National Key Research and Development Program of China (2020AAA0106000), USTC Research Funds of the Double First-Class Initiative (WK2100000019), and the Meituan.

REFERENCES

[1] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. 2016. Layer normalization. *arXiv preprint arXiv:1607.06450* (2016).

[2] Ivana Balazevic, Carl Allen, and Timothy Hospedales. 2019. Multi-relational poincaré graph embeddings. *Advances in Neural Information Processing Systems* 32 (2019), 4463–4473.

[3] Mohamed Ishmael Belghazi, Aristide Baratin, Sai Rajeshwar, Sherjil Ozair, Yoshua Bengio, Aaron Courville, and Devon Hjelm. 2018. Mutual information neural estimation. In *International Conference on Machine Learning*. PMLR, 531–540.

[4] Kurt Bollacker, Colin Evans, Praveen Paritosh, Tim Sturge, and Jamie Taylor. 2008. Freebase: a collaboratively created graph database for structuring human knowledge. In *Proceedings of the 2008 ACM SIGMOD international conference on Management of data*. 1247–1250.

[5] Antoine Bordes, Nicolas Usunier, Alberto Garcia-Duran, Jason Weston, and Oksana Yakhnenko. 2013. Translating embeddings for modeling multi-relational data. In *Neural Information Processing Systems (NIPS)*. 1–9.

[6] Xi Chen, Yan Duan, Rein Houthooft, John Schulman, Ilya Sutskever, and Pieter Abbeel. 2016. InfoGAN: Interpretable Representation Learning by Information Maximizing Generative Adversarial Nets. In *Advances in Neural Information Processing Systems*, D. Lee, M. Sugiyama, U. Luxburg, I. Guyon, and R. Garnett (Eds.), Vol. 29. Curran Associates, Inc.

[7] Pengyu Cheng, Weituo Hao, Shuyang Dai, Jiachang Liu, Zhe Gan, and Lawrence Carin. 2020. CLUB: A Contrastive Log-ratio Upper Bound of Mutual Information. In *Proceedings of the 37th International Conference on Machine Learning*. 1779–1788.

[8] Tim Dettmers, Pasquale Minervini, Pontus Stenetorp, and Sebastian Riedel. 2018. Convolutional 2d knowledge graph embeddings. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 32.

[9] He He, Anusha Balakrishnan, Mihail Eric, and Percy Liang. 2017. Learning symmetric collaborative dialogue agents with dynamic knowledge graph embeddings. *arXiv preprint arXiv:1704.07130* (2017).

[10] Sergey Ioffe and Christian Szegedy. 2015. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International conference on machine learning*. PMLR, 448–456.

[11] Guoliang Ji, Shizhu He, Liheng Xu, Kang Liu, and Jun Zhao. 2015. Knowledge graph embedding via dynamic mapping matrix. In *Proceedings of the 53rd annual meeting of the association for computational linguistics and the 7th international joint conference on natural language processing (volume 1: Long papers)*. 687–696.

[12] Xiaotian Jiang, Quan Wang, and Bin Wang. 2019. Adaptive convolution for multi-relational learning. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. 978–987.

[13] Vineet John, Lili Mou, Hareesh Bahuleyan, and Olga Vechtomova. 2019. Disentangled Representation Learning for Non-Parallel Text Style Transfer. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, Florence, Italy, 424–434. https://doi.org/10.18653/v1/P19-1041

[14] Thomas N. Kipf and Max Welling. 2017. Semi-Supervised Classification with Graph Convolutional Networks. In *International Conference on Learning Representations (ICLR)*.

[15] Timothee Lacroix, Nicolas Usunier, and Guillaume Obozinski. 2018. Canonical Tensor Decomposition for Knowledge Base Completion. In *Proceedings of the 35th International Conference on Machine Learning (Proceedings of Machine Learning Research, Vol. 80)*, Jennifer Dy and Andreas Krause (Eds.). PMLR, 2863–2872.

[16] Yankai Lin, Zhiyuan Liu, Maosong Sun, Yang Liu, and Xuan Zhu. 2015. Learning entity and relation embeddings for knowledge graph completion. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 29.

[17] Yanbei Liu, Xiao Wang, Shu Wu, and Zhitao Xiao. 2020. Independence promoted graph disentangled networks. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 34. 4916–4923.

[18] Jianxin Ma, Peng Cui, Kun Kuang, Xin Wang, and Wenwu Zhu. 2019. Disentangled graph convolutional networks. In *International Conference on Machine Learning*. PMLR, 4212–4221.

[19] Jianxin Ma, Chang Zhou, Peng Cui, Hongxia Yang, and Wenwu Zhu. 2019. Learning Disentangled Representations for Recommendation. In *Advances in Neural Information Processing Systems*, H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett (Eds.), Vol. 32. Curran Associates, Inc.

[20] Andrea Madotto, Chien-Sheng Wu, and Pascale Fung. 2018. Mem2seq: Effectively incorporating knowledge bases into end-to-end task-oriented dialog systems. *arXiv preprint arXiv:1804.08217* (2018).

[21] Diego Marcheggiani and Ivan Titov. 2017. Encoding sentences with graph convolutional networks for semantic role labeling. *arXiv preprint arXiv:1703.04826* (2017).

[22] George A Miller. 1995. WordNet: a lexical database for English. *Commun. ACM* 38, 11 (1995), 39–41.

[23] Tom Mitchell, William Cohen, Estevam Hruschka, Partha Talukdar, Bishan Yang, Justin Betteridge, Andrew Carlson, Bhanava Dalvi, Matt Gardner, Bryan Kisiel, et al. 2018. Never-ending learning. *Commun. ACM* 61, 5 (2018), 103–115.

[24] Dai Quoc Nguyen, Tu Dinh Nguyen, Dat Quoc Nguyen, and Dinh Phung. 2017. A novel embedding model for knowledge base completion based on convolutional neural network. *arXiv preprint arXiv:1712.02121* (2017).

[25] Maximilian Nickel, Lorenzo Rosasco, and Tomaso Poggio. 2016. Holographic embeddings of knowledge graphs. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 30.

[26] Maximilian Nickel, Volker Tresp, and Hans-Peter Kriegel. 2011. A three-way model for collective learning on multi-relational data. In *Icml*.

[27] Feiliang Ren, Juchen Li, Huihui Zhang, Shilei Liu, Bochao Li, Ruicheng Ming, and Yujia Bai. 2020. Knowledge Graph Embedding with Atrous Convolution and Residual Learning. In *Proceedings of the 28th International Conference on Computational Linguistics*. International Committee on Computational Linguistics, Barcelona, Spain (Online), 1532–1543.

[28] Michael Schlichtkrull, Thomas N Kipf, Peter Bloem, Rianne Van Den Berg, Ivan Titov, and Max Welling. 2018. Modeling relational data with graph convolutional networks. In *European semantic web conference*. Springer, 593–607.

[29] Chao Shang, Yun Tang, Jing Huang, Jinbo Bi, Xiaodong He, and Bowen Zhou. 2019. End-to-end structure-aware convolutional networks for knowledge base completion. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 33. 3060–3067.

[30] Jiawei Sheng, Shu Guo, Zhenyu Chen, Juwei Yue, Lihong Wang, Tingwen Liu, and Hongbo Xu. 2020. Adaptive Attentional Network for Few-Shot Knowledge Graph Completion. *arXiv preprint arXiv:2010.09638* (2020).

[31] Zhiqing Sun, Zhi-Hong Deng, Jian-Yun Nie, and Jian Tang. 2019. Rotate: Knowledge graph embedding by relational rotation in complex space. *arXiv preprint arXiv:1902.10197* (2019).

[32] Kristina Toutanova and Danqi Chen. 2015. Observed versus latent features for knowledge base and text inference. In *Proceedings of the 3rd workshop on continuous vector space models and their compositionality*. 57–66.

[33] Théo Trouillon, Johannes Welbl, Sebastian Riedel, Éric Gaussier, and Guillaume Bouchard. 2016. Complex embeddings for simple link prediction. In *International Conference on Machine Learning*. PMLR, 2071–2080.

[34] Shikhar Vashishth, Soumya Sanyal, Vikram Nitin, Nilesh Agrawal, and Partha Talukdar. 2020. Interacte: Improving convolution-based knowledge graph embeddings by increasing feature interactions. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 34. 3009–3016.

[35] Shikhar Vashishth, Soumya Sanyal, Vikram Nitin, and Partha Talukdar. 2019. Composition-based multi-relational graph convolutional networks. *arXiv preprint arXiv:1911.03082* (2019).

[36] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Ł ukasz Kaiser, and Illia Polosukhin. 2017. Attention is All you Need. In *Advances in Neural Information Processing Systems*, Vol. 30. Curran Associates, Inc.

[37] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò, and Yoshua Bengio. 2018. Graph Attention Networks. *International Conference on Learning Representations* (2018).

[38] Quan Wang, Pingping Huang, Haifeng Wang, Songtai Dai, Wenbin Jiang, Jing Liu, Yajuan Lyu, Yong Zhu, and Hua Wu. 2019. Coke: Contextualized knowledge graph embedding. *arXiv preprint arXiv:1911.02168* (2019).

[39] Xiang Wang, Hongye Jin, An Zhang, Xiangnan He, Tong Xu, and Tat-Seng Chua. 2020. Disentangled Graph Collaborative Filtering. In *Proceedings of the 43nd International ACM SIGIR Conference on Research and Development in Information Retrieval, SIGIR 2020, Xi'an, China, July 25-30, 2020*.

[40] Yifan Wang, Suyao Tang, Yuntong Lei, Weiping Song, Sheng Wang, and Ming Zhang. 2020. DisenHAN: Disentangled Heterogeneous Graph Attention Network for Recommendation. In *Proceedings of the 29th ACM International Conference on Information & Knowledge Management*. 1605–1614.

[41] Zhen Wang, Jianwen Zhang, Jianlin Feng, and Zheng Chen. 2014. Knowledge graph embedding by translating on hyperplanes. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 28.

[42] Zhiwen Xie, Guangyou Zhou, Jin Liu, and Jimmy Xiangji Huang. 2020. ReInceptionE: Relation-Aware Inception Network with Joint Local-Global Structural Information for Knowledge Graph Embedding. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, Online, 5929–5939. https://doi.org/10.18653/v1/2020.acl-main.526

[43] Bishan Yang, Wen-tau Yih, Xiaodong He, Jianfeng Gao, and Li Deng. 2014. Embedding entities and relations for learning and inference in knowledge bases. *arXiv preprint arXiv:1412.6575* (2014).

[44] Fuzheng Zhang, Nicholas Jing Yuan, Defu Lian, Xing Xie, and Wei-Ying Ma. 2016. Collaborative knowledge base embedding for recommender systems. In *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining*. 353–362.

[45] Wen Zhang, Bibek Paudel, Wei Zhang, Abraham Bernstein, and Huajun Chen. 2019. Interaction embeddings for prediction and explanation in knowledge graphs. In *Proceedings of the Twelfth ACM International Conference on Web Search and Data Mining*. 96–104.

[46] Shuai Zheng, Zhenfeng Zhu, Zhizhe Liu, Shuiwang Ji, and Yao Zhao. 2021. Adversarial Graph Disentanglement. *arXiv preprint arXiv:2103.07295* (2021).

Task-Oriented Clustering for Dialogues

[1,2]Chenxu Lv, [1]Hengtong Lu, [2]Shuyu Lei, [2]Huixing Jiang,
[2]Wei wu, [1]Caixia Yuan, [1]Xiaojie Wang
[1]Beijing University of Posts and Telecommunications, Beijing, China
[2]Meituan Group, Beijing, China
{chenxulv, luhengtong, yuancx, xjwang}@bupt.edu.cn
{leishuyu, jianghuixing, wuwei30}@meituan.com

Abstract

A reliable clustering algorithm for task-oriented dialogues can help developer analysis and define dialogue tasks efficiently. It is challenging to directly apply prior normal text clustering algorithms for task-oriented dialogues, due to the inherent differences between them, such as coreference, omission and diversity expression. In this paper, we propose a Dialogue Task Clustering Network (DTCN) model for task-oriented clustering. The proposed model combines context-aware utterance representations and cross-dialogue utterance cluster representations for task-oriented dialogues clustering. An iterative end-to-end training strategy is utilized for dialogue clustering and representation learning jointly. Experiments on three public datasets show that our model significantly outperformed strong baselines in all metrics[1].

1 Introduction

Task-Oriented Dialogue Clustering (TODC) aims to group task-oriented dialogues into different clusters according to their underlying tasks. Since each cluster includes dialogues for one specific task, it therefore brings convenience for task induction and definition. Especially for large unlabeled human-human dialogues, TODC can be employed to help to induce and define new tasks rapidly which is important for designing of task-oriented dialogue system.

Most prior studies focus on normal text clustering, and have made significant progress via keywords extracting (Bafna et al., 2016; Neto et al., 2000), topic model (Blei et al., 2001; Onan et al., 2017), deep clustering (Xie et al., 2016; Guo et al., 2017; Jiang et al., 2017; Yang et al., 2017). However, inherent differences between task-oriented dialogues and normal texts make above methods difficult to be applied in clustering of task-oriented dialogues directly. The first difficulty is that coreference and information omission occur frequently in dialogues (Su et al., 2019), which makes it harder to build a good representation for utterances in dialogue than in normal text. The second difficulty is that the task-related slot names and intents are scattered in each utterance implicitly and expressed diversely. In most cases, only slots values are given in dialogues without explicit slot names. Only by comparing utterances in different dialogues, we can find task-related implicit information, as shown in Fig.1. Considering these special characteristics in task-oriented dialogues, we emphasize that TODC should utilize in-dialogue relations between different utterance to build context-aware representations for each utterance and utilize cross-dialogue similarity between utterances in different dialogues to induce implicit task-related concepts information.

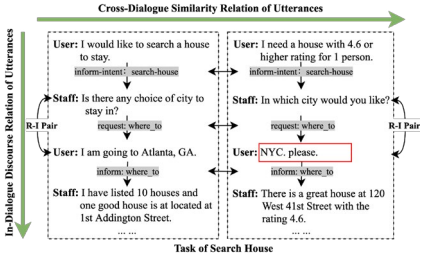

Figure 1: From top to down, the figure shows an example of in-dialogue discourse relation of utterances. From left to right, the figure shows an example of cross-dialogue similarity relation of utterances, the implicit task-related concepts information like "inform-intent:search-house" can be concluded from different dialogues by grouping the utterances with similar semantic.

To address above problems, we proposed a Dialogue Task Clustering Network (DTCN) for TODC. The key points of DTCN are two folds. First, we construct in-dialogue utterance adjacency graph for each dialogue, and encode the graph with graph

[1]https://github.com/Ryan-Lv/DTCN

attention networks (GAT) to build context-aware representations. Second, we cluster all utterances to induce implicit task-related concepts, and then learn utterance cluster representations to utilize this information. Further integrating both kinds of representations into dialogue representations. Finally, training the model with two stages training strategy, which includes pre-training and joint-training stages, the former pretrains a Transformer-based auto-encoder with the proposed Gate-based Transformer decoder for initial clustering assignments, the latter trains jointly the whole model with a self-training strategy for optimizing dialogue representations and dialogue cluster assignments iteratively.

Experimental results on three constructed public dialogue datasets (SGD-S, SGD-M and MultiwozT) show that our model significantly outperforms the existing strong text clustering algorithms in all metrics on TODC. Especially, we achieve 19.76% improvement of accuracy on SGD-S dataset compared with the best baseline, which indicates that the proposed dialogue representation method can capture more task-related information.

In summary, the contributions of our paper are as follows:

- We propose an unsupervised Dialogue Task Clustering Network (DTCN). As far as we know, this is the first work on task-oriented clustering for dialogues. Our model learns dialogue representations and clusters dialogues simultaneously by fusing both representations of utterances and utterance clusters.
- We propose a context-aware utterance representation learning model, which uses Graph Attention Network to efficiently capture in-dialogue structural information between utterances and learns the representations with the proposed Gate-based Transformer decoder.
- Experiments on three public datasets show that the proposed model significantly outperforms the existing strong baselines in all metrics on TODC.

2 Related work

Clustering Data representation and clustering algorithm are the two keys to address clustering problems. Previous works (Hartigan, 1979; McLachlan and Basford, 1988; Blei et al., 2001) mainly focused on feature transformation or clustering independently. Data are usually mapped into a feature space and then directly fed into a clustering algorithm to cluster. In the recent years, owing to the development of deep learning, more and more deep clustering methods (Caron et al., 2018; Xie et al., 2016; Guo et al., 2017; Yang et al., 2017; Jiang et al., 2017) were proposed, which can obtain feature representations and cluster assignments simultaneously.

Graph Neural Network Recently, there has been a surge of interest in Graph Neural Networks (GNNs) (Wu et al., 2020b) approaches for graph representation learning. Some GNN variants (Velickovic et al., 2018; Kipf and Welling, 2017) are proposed and also applied in dialogue related tasks. Chen et al. (2020) proposed Graph Attention Matching Network and Recurrent Graph Attention Network based on Graph Attention Network to encode utterances, schema graphs and previous dialogue states. Ghosal et al. (2019) proposed Dialogue Graph Convolutional Network based on Graph Convolutional Network (Kipf and Welling, 2017) to model inter and self-party dependency to improve context understanding.

3 Task formulation

Given an unlabeled dialogue dataset $D = \{d_j\}_{j=1}^{N_{dia}}$, where N_{dia} denotes the total number of dialogues in dataset and $d_j = \{u_i\}_{i=1}^{I}$ denotes one dialogue with I utterances. Task-Oriented Dialogue Clustering (TODC) aims to group D into K_{dia} clusters according to the underlying tasks.

4 The Proposed Model

The proposed Dialogue Task Clustering Network (DTCN) is composed of five modules as shown in Fig.2, and trained with two stages training strategy. In the first stage, we used an autoencoder to learn context-aware utterance representations for initial clustering assignments, in which the Utterance Encoder (UE) and the Structural Context Encoder (SCE) are used as encoder, the Utterance Decoder (UD) module is used as decoder. In the second stage, introducing two new modules based on the pretrained autoencoder, including the Utterance Cluster Representation Learning (UCRL) module for learning utterance cluster representations and the Dialogue Representation Learning (DRL) module for learning dialogue representations, and adopting an iterative training strategy for optimizing jointly dialogue clustering assignments and dialogue representations.

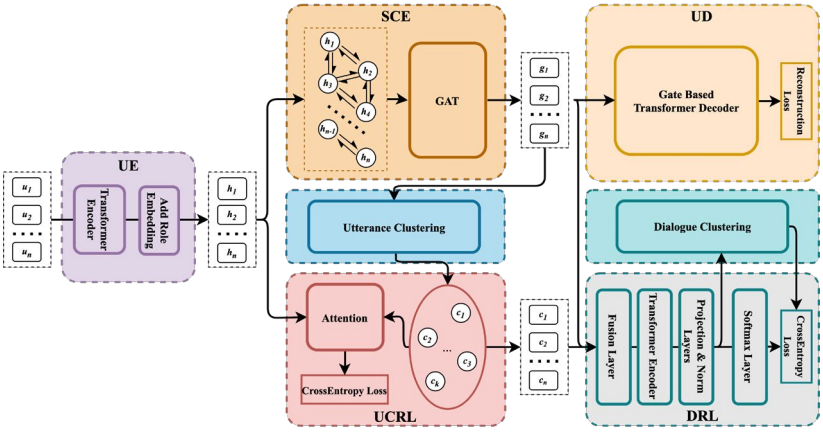

Figure 2: The Frame of Dialogue Task Clustering Network (DTCN).

4.1 Utterance Encoder

UE module aims to encode each utterance to an embedding initially. Specifically, for the i-th utterance $u_i = \{w_t\}_{t=1}^{m_i}$, calculating the word encoding $\epsilon_t \in \mathbb{R}^{d_{mod}}$ for each word w_t firstly as shown in Eq.1,

$$\epsilon_t = emb_t + pos_t \tag{1}$$

where d_{mod} is the embedding size, emb_t is the word embedding and pos_t is the position encoding calculated by the sinusoidal encoding method(Vaswani et al., 2017).

Then, feeding $\{\epsilon_t\}_{t=1}^{m_i}$ into Transformer encoder and adding role embedding $r_i \in \mathbb{R}^{d_{mod}}$ to obtain the initial representation $h_i \in \mathbb{R}^{d_{mod}}$ of the utterance u_i as shown in Eq.2,

$$h_i = Transformer(\epsilon_1, \ldots, \epsilon_{m_i}) + r_i \tag{2}$$

where the mean values of all words of each utterance are used as the outputs of Transformer encoder.

4.2 Structural Context Encoder

SCE module aims to learn context-aware utterance representation, including utterance adjacency graph construction and graph encoding.

Specifically, an adjacency graph $G = (V, E)$ is built for each dialogue $d_j = \{u_i\}_{i=1}^{n_j}$ firstly. $V = \{v_i\}_{i=1}^{n_j}$ is the node set, in which v_i is corresponding to the utterance u_i and its initial representation is h_i. The edges set E between the nodes is defined by N-adjacency relationship as shown in Eq.3,

$$e_{ij} = \begin{cases} 1, & |j-i| \leq N \\ 0, & others \end{cases} \tag{3}$$

where N represents the window size, we suppose that the utterances in the window have discourse relation.

Then, feeding the graph G into Graph Attention Network to obtain the context-aware utterance representation with structural context information as shown in Eq.4,

$$g = GAT(G, h_1, \ldots, h_{n_j}) \tag{4}$$

where $g = \{g_i\}_{i=1}^{n_j}$, $g_i \in \mathbb{R}^{d_{mod}}$ is the improved utterance representation of u_i.

4.3 Utterance Decoder

To better learn context-aware utterance representations, the Gate-based Transformer decoder is proposed as shown in Fig.3. Compared with the standard Transformer decoder, the Gate-based Transformer decoder has an additional Gate-based Extractor sublayer which captures more related information for decoding different words. Specifically, to decode word w_{t+1} in u_i, the Gate-based Extractor sublayer extracts the hidden state g_i^t from g_i through the gate mechanism (Gers, 2001) as shown in Eq.5,

$$g_i^t = g_i \odot sigmoid([a_i^t \| g_i] W^T) \tag{5}$$

where $\cdot\|\cdot$ refers to concatenation, $W^T \in \mathbb{R}^{2d_{mod} \times d_{mod}}$ is a trainable weight matrix, a_i^t is the

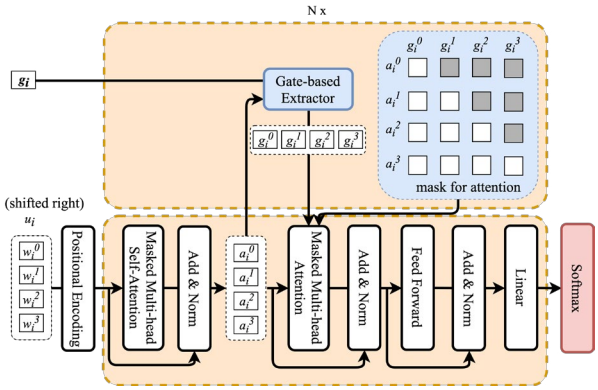

Figure 3: The Gate-based Transformer Decoder.

hidden state corresponding to word w_t through the Masked Multi-head Self-Attention sublayer.

Similar to the Transformer decoder, we use the linear projection and softmax function to convert the outputs to the probability distribution of next word $p_i^{t+1} \in \mathbb{R}^{N_{voc}}$, where N_{voc} is the vocabulary size. The cross-entropy loss $\mathcal{L}_{ud}$ between p_i^{t+1} and the ground-truth word id y_i^{t+1} is employed as shown in Eq.6,

$$\mathcal{L}_{ud} = -\sum_{i=1}^{n_j}\sum_{t=1}^{m_i-1} y_i^{t+1} ln(p_i^{t+1}) \quad (6)$$

where m_i is the number of words in u_i.

4.4 Utterance Cluster Representation Learning

UCRL module first induces implicit task-related concepts by clustering utterances, and then represent this information by leaning representations for each utterance cluster.

Specifically, first grouping all utterances into K_{utt} clusters with the context-aware representations by Gaussian Mixture Model (GMM) (McLachlan and Basford, 1988).

Then, an utterance cluster representation learning method based on the transfer relationship is proposed. It makes use of historical utterance cluster representations and initial representation of the current utterance to update the utterance cluster representation corresponding to the current utterance. Specifically, given a dialogue history $\{u_1, ..., u_{i-1}\}$, let the corresponding utterance cluster representations be $\widetilde{C^{i-1}} = \{c_1, ..., c_{i-1}\}$ and the current utterance representation from UE module be h_i, the utterance cluster representation $c_i^{'}$ corresponding to current utterance u_i is calculated as shown in Eq.7,

$$c_i^{'} = softmax(\frac{h_i \widetilde{C^{i-1}}^T}{\sqrt{d_{mod}}})\widetilde{C^{i-1}} \quad (7)$$

Furthermore, a loss function for cluster representation learning is adopted as shown in Eq.8,

$$\mathcal{L}_{ucrl} = -\sum_{i=1}^{n_j} y_{u_i} ln(softmax(c_i^{'} C^T)) \quad (8)$$

where $C \in \mathbb{R}^{K_{utt} \times d_{mod}}$ is the representation matrix of all utterance clusters, softmax function is used to get the cluster probability distribution, finally cross-entropy between the distribution and the utterance cluster label y_{u_i}corresponding to u_i is calculated.

4.5 Dialogue Representation Learning

DRL module aims to learn dialogue representations by fusing the context-aware utterance representations and the corresponding utterance cluster representations, the former contains the in-dialogue discourse relation information, the latter contains the cross-dialogue task-related concepts information.

Specifically, given a dialogue $d_j = \{u_i\}_{i=1}^{n_j}$, let the corresponding class label be y_{d_j}, the context-aware representation of utterances in the dialogue be $g = \{g_i\}_{i=1}^{n_j}$, the utterance cluster representations be $\widetilde{C} = \{c_i\}_{i=1}^{n_j}$, and the utterance position embeddings be $pos_u = \{pos_{u_i}\}_{i=1}^{n_j}$. The first step

is fusing the g, $\widetilde{C}$, and pos_u into an embedding as shown in Eq.9,

$$\zeta_i = [g_i \| c_i] W^T + pos_{u_i} \tag{9}$$

where $W^T \in \mathbb{R}^{2d_{mod} \times d_{mod}}$, $pos_{u_i} \in \mathbb{R}^{d_{mod}}$ are all trainable.

Then, the Transformer encoder is leveraged to encode $\{\zeta_i\}_{i=1}^{n_j}$, the output o_j is the [CLS] position embedding as shown in Eq.10,

$$o_j = TransformerEncoder(\zeta_1, ..., \zeta_{n_j}) \tag{10}$$

Finally, a Linear layer and a LayerNorm layer project the output o_j into the dialogue representation $z_j \in \mathbb{R}^{K_{dia}}$ as shown in Eq.11,

$$z_j = layernorm(o_j \cdot W^T) \tag{11}$$

A cross-entropy loss as shown in Eq.12, is used to supervise the learning of dialogue representation by maximizing the distance among the dialogue representations in the different classes, which is helpful to cluster dialogues.

$$\mathcal{L}_{cls} = -\sum_{j=1}^{N_{dia}} y_{d_j} ln(softmax(z_j)) \tag{12}$$

4.6 Dialogue Clustering

After obtaining the dialogue representation, we group them into K_{dia} clusters with Gaussian Mixture Model (GMM). And assigning a label for each dialogue, which will be used as pseudo label for training DRL module. Further, a trained DRL module will generates better dialogue representation, and then better dialogue representations help to obtain better clustering assignments. It should be noted that dialogue representations used for the initial clustering is the mean value of utterance representations g from the pretrained autoencoder, and for the subsequent clustering is the learned dialogue representation z.

Due to the instability of the GMM, the initial clustering assignment is obtained by voting after clustering for continuous N_{clu} times as shown in Algo.1.

4.7 Model Training Process

A two-stage training strategy including pre-training and joint-training is employed for model training. In the pre-training stage, learning the context-aware utterance representation g_i for each utterance with the autoencoder based on encoder-decoder architecture for initial clustering assignments, where UE, SCE modules as the encoder and UD as the decoder. The pre-training loss is defined by Eq.13,

Algorithm 1: Initial labels assignment algorithm

Input : Initial count matrix $\theta = \mathbf{0}$; Initial labels assignment vector $A = \mathbf{0}$; Clustering assignments sequence $\{A_n\}_{n=1}^{N_{clu}}$.

for $i \in \{1, 2, 3, ..., N_{clu}\}$ **do**
  if $i == 1$ **then**
    $A = A_1$
  end
  Best map: mapping assignment A_i to assignment A using Hungarian algorithm.
  Update θ: $\theta_{ij} = \theta_{ij} + 1$ if s_i is assigned to cluster j in mapped assignment A_i.
  Update A: $A_i = argmax(\theta_i)$ where θ_i is i-th row of θ.
end
Return final labels assignment vector A;

$$\mathcal{L}_{Pre} = \mathcal{L}_{ud} \tag{13}$$

In the joint-training stage, an iterative training strategy is adopted. In each iteration, the label reassignment strategy is employed to improve the confidence of clustering assignments. Specifically, clustering all utterances and dialogues after each training epoch, and updating the old clustering assignment by best mapping the clusters between new and old clustering assignment using the Hungarian algorithm (Kuhn, 1955). However, the pseudo labels used by UCRL and DRL modules are not assigned immediately, but reassigning every $interval$ epochs. Finally, stopping training when the change between two consecutive dialogue clustering assignment is less than $tol\%$ or reaching the maximum training epochs max_{ep}. The last dialogue clustering assignment is used as the final clustering results. The loss is defined by Eq.14,

$$\mathcal{L}_{Joint} = \mathcal{L}_{ud} + \beta \cdot \mathcal{L}_{ucrl} + \mathcal{L}_{cls} \tag{14}$$

where β is loss coefficient.

5 Experiments

5.1 Datasets

In order to better evaluate the performance of different algorithms on TODC, we constructed three public task-divided dialogue datasets based on Schema-Guided Dialogue (SGD) (Rastogi et al., 2020) and Multiwoz dataset (Zang et al., 2020). In both SGD and Multiwoz datasets, we determine whether two

Datasets	SGD-S	SGD-M	Multiwoz-T
Tasks Number	29	59	35
Dialogues Number	3925	4722	9695
Dialogues Length(avg)	15.57	21.68	13.94

Table 1: The statistics of the datasets.

dialogues belong to the same dialogue task by judging whether the two dialogues contain the same set of active-intents. Finally, three datasets labeled by dialogue task are constructed: SGD-S includes-single domain dialogues of SGD dataset, SGD-M includes multiple-domains dialogues of SGD dataset, Multiwoz-T includes all dialogues of Multiwoz dataset. Detailed division instructions and datasets will be released. Tab.1 shows the statistics of them.

5.2 Implement Details

In our experiments, the hidden size is set to 256. Using 3-layers Transformer encoder for both UE and DRL module, 2-layers GAT for SCE module, and 3-layers Gated-based Transformer decoder for UD module. The window size is set to 2, 2, 1 for SGD-S, SGD-M and Multiwoz-T respectively.

In the pre-training stage, we train 100 epochs with batch size 16 on each dataset with the same optimizer settings as the Transformer (Vaswani et al., 2017). In the joint-training stage, estimating K_{utt} by BIC score (Schwarz et al., 1978) to 50, 50, 60, and setting $interval$ to 2, 2, 1 for SGD-S, SGD-M and Multiwoz-T datasets respectively. Besides, setting the coefficient of $\mathcal{L}_{ucrl}$ to 10 for stabilizing the utterance cluster representations quickly. And the learning rate at each step is calculated as shown in Eq.15,

$$lr = lr_{max} \cdot wm_{stp}^{0.5} \cdot min(N_{stp}^{-0.5}, N_{stp} \cdot wm_{stp}^{-1.5}) \tag{15}$$

where the maximum learning rate lr_{max} is set to 1e-3, 1e-3 and 5e-4 for SGD-S, SGD-M and Multiwoz-T respectively, the warmup steps $wm_{stp} = interval \cdot N_{dia_bth}$, N_{dia_bth} is the batch number of the corresponding dataset. Such warmup strategy increases learning rate linearly between the first and second dialogue labels reassignment until lr_{max}, then decreases proportionally.

5.3 Baselines and Metrics

Three types of baselines are adopted to be compared with the proposed model on TODC performance.

Raw feature based models. Using bag of words model (BOW) and TF-IDF feature to represent dialogues, and clustering with *LDA* (Blei et al., 2001), *K-means* and *GMM* algorithms respectively.

Pretrained feature based models. Representing dialogues with the mean values of all utterance representations extracted from official pretrained *SkipThought* (Kiros et al., 2015), *TODBert* (Wu et al., 2020a) and *SentenceBert* (Reimers and Gurevych, 2019) models, then cluster with *GMM*.

Deep clustering models. Four popular deep clustering models are adopted as strong baselines. *DCN* (Yang et al., 2017) used k-means clustering loss to learn clustering friendly representations. *VaDE* (Jiang et al., 2017) is a generative deep clustering model based on variational autoencoder. *DEC* (Xie et al., 2016) designed a clustering objective to guide the learning of the data representations. *IDEC* (Guo et al., 2017) is a modified version of *DEC* with a reconstruction loss to preserve local structure.

We run 5 times continuously for all baselines, and then report the mean value and standard deviation. For *DCN*, *VaDE*, *DEC* and *IDEC*, using the same settings as the previous works, and searching the update interval in {2, 5, 10, 20}. In addition, searching the γ in {1.0, 0.1, 0.01, 0.001} for *IDEC*, and λ in {0.001, 0.005, 0.01, 0.05, 0.1, 0.5} for *DCN*.

Metrics Four popular metrics are adopted to evaluate TODC performance, including Accuracy (ACC), Purity, Normalized Mutual Information (NMI) (Strehl and Ghosh, 2002), and Adjusted Rand Index (ARI) (Hubert and Arabie, 1985). For each metric, a larger value implies a better clustering performance.

5.4 Main Results

Tab.2 shows the clustering performance of different methods. We can see that the proposed model outperforms all three types baselines significantly. Compared with the best baseline, our model improves ACC by 19.76%, 16.67% and 4.87%, Purity by 12.83%, 14.80% and 7.26%, NMI by 9.45%, 8.65% and 3.45%, ARI by 22.59%, 20.49% and 7.10% on SGD-S, SGD-M and Multiwoz-T datasets respectively. The results show that the obtained dialogue representations can capture more task-related information.

Model	SGD-S				SGD-M				Multiwoz-T			
	ACC	Purity	NMI	ARI	ACC	Purity	NMI	ARI	ACC	Purity	NMI	ARI
Raw Feature Models												
K-means	59.04±1.41	70.32±1.50	80.69±0.58	55.60±2.12	50.76±3.52	55.53±3.26	73.25±1.83	45.55±3.29	29.44±1.79	37.38±1.28	45.65±1.05	24.07±1.90
GMM	59.96±3.05	71.18±1.59	81.18±1.09	57.39±3.81	50.06±3.50	55.12±2.85	73.20±1.45	45.82±3.07	34.90±1.88	42.51±1.53	50.19±1.68	28.88±2.61
LDA	55.78±2.64	68.0±1.31	75.13±0.72	50.06±2.08	39.35±2.03	40.34±1.64	67.94±0.98	33.12±1.81	39.58±1.14	49.32±0.67	54.66±0.42	33.36±0.40
PreTrained Feature Models												
SkipThought+GMM	36.16±2.16	44.56±0.94	50.41±2.14	30.43±2.83	15.59±0.95	17.98±0.72	31.37±0.95	7.50±0.55	14.35±0.51	22.99±0.30	23.84±0.37	6.85±0.31
TODBert+GMM	54.93±2.79	71.23±1.44	77.87±1.00	52.32±3.69	53.78±0.79	69.00±1.46	77.11±0.98	53.76±2.24	32.56±1.64	43.50±1.84	53.93±2.91	30.44±1.40
SentenceBert+GMM	57.18±3.64	69.88±1.63	78.62±0.89	55.37±3.72	55.85±1.88	63.18±1.44	76.69±0.98	50.36±2.34	37.97±2.41	49.86±2.27	59.45±2.32	30.62±2.58
Deep Clustering Models												
DCN	55.32±2.73	64.29±1.37	79.09±1.62	53.28±3.09	42.08±2.33	49.99±3.39	73.57±1.39	34.93±2.29	47.08±0.32	60.04±0.31	68.39±0.39	41.71±0.52
VaDE	60.66±1.55	70.97±1.67	79.24±0.67	54.67±1.22	51.55±3.49	54.14±3.65	74.62±0.96	45.71±2.54	50.51±0.14	56.36±0.15	66.55±0.07	44.45±0.19
DEC	64.10±1.53	73.69±0.90	82.95±0.48	59.28±1.27	68.89±2.20	70.44±2.31	87.89±0.99	65.24±2.73	56.16±1.66	65.12±0.85	78.43±0.52	51.58±1.61
IDEC	64.61±1.37	75.15±0.51	82.92±0.22	59.17±1.35	70.32±1.10	77.03±0.74	88.03±0.45	67.77±1.08	58.64±3.19	66.03±1.21	78.39±1.34	54.06±2.35
Our Model												
PreTrained	66.67±3.11	79.02±1.55	85.46±1.13	63.65±2.68	49.84±1.59	53.09±1.94	69.39±2.04	45.33±2.63	45.71±2.16	57.68±1.21	67.27±1.00	39.44±2.12
Full model	**84.37±2.33**	**87.98±2.31**	**92.37±0.93**	**82.76±2.84**	**86.99±2.14**	**91.83±1.19**	**96.68±0.51**	**88.26±1.97**	**63.51±3.03**	**73.29±2.60**	**81.84±1.49**	**61.16±2.41**

Table 2: Comparison of clustering performance on three datasets.

5.5 Ablation Studies

Ablation Studies of Major Modules We conduct ablation studies to evaluate the compact of different components in our model.

Model	SGD-S			
	ACC	Purity	NMI	ARI
Full	**84.37±2.33**	**87.98±2.31**	**92.37±0.93**	**82.76±2.84**
-w/o SCE	64.67±2.84	72.63±3.12	80.41±30.3	62.76±2.64
-w/o UCRL	75.18±1.01	84.34±0.17	89.64±0.36	74.39±1.07

Table 3: Ablation studies for major modules.

As shown in Tab.3, both SCE and UCRL contribute to the proposed model, and compared to UCRL module, the SCE module has a greater impact on performance. On the one hand, it shows that the integration of the structural context of utterance can improve the quality of utterance representation and further affect the dialogue representation. On the other hand, the utterance clustering assignment based on the utterance representation from SCE module has a direct impact on UCRL module, and the utterance cluster representations from UCRL module will directly affect dialogue representation.

Ablation Studies of Losses We also conduct ablation studies to evaluate the compact of different losses in our model.

Model	SGD-S			
	ACC	Purity	NMI	ARI
Full	**84.37±2.33**	**87.98±2.31**	**92.37±0.93**	**82.76±2.84**
PreTrained	66.67±3.11	79.02±1.55	85.46±1.13	63.65±2.68
-w/o $\mathcal{L}_{ud}$	79.86±3.21	86.02±1.60	89.64±1.14	77.03±3.00
-w/o $\mathcal{L}_{ucrl}$	75.16±2.12	85.03±0.50	89.70±0.34	75.38±3.52

Table 4: Ablation studies for losses. "-w/o $\mathcal{L}_{ucrl}$" refers to the performance using the utterance cluster embedding simply without learning by the $\mathcal{L}_{ucrl}$.

As shown in Tab.4, the ACC is reduces by 9.21% after removing $\mathcal{L}_{ucrl}$ loss, which indicates that the structure information learned through the logical transfer relationship between utterance clusters is helpful to distinguish different tasks. And the ACC is reduced by 4.51% after removing $\mathcal{L}_{ud}$ loss, which indicates that stabilizing the utterance representations helps stabilize model training. Meanwhile, we can see that all performance have been significantly improved after joint training, which indicates that introducing the induced implicit concepts information by clustering utterances and adopting an iterative training strategy are beneficial for TODC.

5.6 Window Size N Analysis

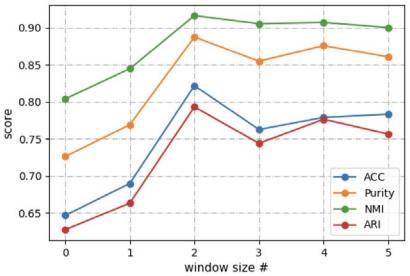

Figure 4: The performance with different window size.

We analyze the impact of the window size N on all performance on SGD-S dataset. As shown in Fig.4, as the window size increases, the performance is significantly improved. When the window size is 2, all performance reaches the maximum, then decreases slightly and stabilizes. This indicates that the optimal window size is 2. If the size of window is too small, the context information in-

troduced is insufficient, and if it is too large, it will introduce too much noise and affect performance.

5.7 Clustering Number K_{dia} Analysis

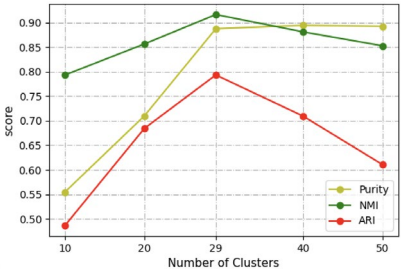

Figure 5: The performance of Purity, NMI and ARI with different dialogue clustering number.

We also analyze the impact of the clustering number on performance of NMI, ARI and Purity on SGD-S dataset. As shown in Fig.5, as the clustering number increases, all performance is significantly improved. When the clustering number is 29, which is the ground-truth number of tasks in SGD-S dataset, all performance reaches the maximum. Then the performance of Purity stabilizes, while NMI and ARI decrease.

The Purity measures the degree to which the samples in the cluster belong to the same true category. As the number of clusters increases, the purity will gradually increase as shown in the Fig.5, and then stabilize. NMI and ARI measure the degree of overlap between clustering and true category distributions. When the clusters number differs greatly from the true categories number, the performance will significantly decrease as shown in the Fig.5.

6 Case Studies

We selected some typical utterance clusters to evaluate the quality of learned context-aware utterance representation, and analysis whether some interpretable task-related concepts can be induced by obtained utterance clusters.

One case is shown in the Fig.6, obviously, these utterances are all about the concept of "user wants to search one-way flight". Besides, we also found some special utterance clusters. Another case is shown in Fig.7, there are two segments from two dialogues, to our surprise, all of these utterances are grouped into one cluster. This phenomenon can be explained from two aspects. First, from

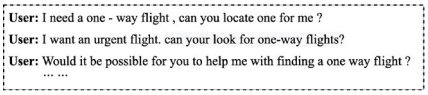

Figure 6: An example of utterance cluster, these utterances are about the concept of "SearchOneWayFilght"

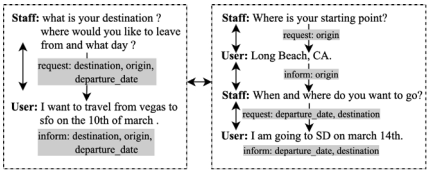

Figure 7: An example of special utterance cluster, these utterances are all related to slots of "destination, origin and departure_date".

top to down, discourse relation information and the involved slots information make the representations of related utterances similar. For example, the both utterances of left segment are involved the same three slots, and associated by request-inform pair relationship, the both representations tend to be similar after incorporating this information. Further, from left to right, the cross-dialogue utterances with the similar context information are grouped automatically.

These indicate that our model can fully integrate contextual information by constructing adjacency graphs, and can also induce interpretable concepts through clustering utterances.

7 Conclusion and Future Work

This paper proposes a Dialogue Task Clustering Network for dialogue task clustering. The model makes use of both in-dialogue discourse relation information and cross-dialogue utterance similarity relation information to build dialogue representations. And an end-to-end iterative strategy of jointly dialogue representation learning and clustering is used to train the model. Experiments on three public datasets show that the proposed model significantly outperforms the existing strong clustering algorithms on dialogue task clustering. In the future, we will further induce more detailed task-related concepts information and explore the inner structure in each dialogue cluster for task induction and definition.

Acknowledgments

We would like to thank anonymous reviewers for their suggestions and comments. The work was supported by the National Natural Science Foundation of China (NSFC62076032)

References

Prafulla Bafna, Dhanya Pramod, and Anagha Vaidya. 2016. Document clustering: Tf-idf approach. In *2016 International Conference on Electrical, Electronics, and Optimization Techniques (ICEEOT)*, pages 61–66. IEEE.

David M. Blei, Andrew Y. Ng, and Michael I. Jordan. 2001. Latent dirichlet allocation. In *Advances in Neural Information Processing Systems 14 [Neural Information Processing Systems: Natural and Synthetic, NIPS 2001, December 3-8, 2001, Vancouver, British Columbia, Canada]*, pages 601–608. MIT Press.

Mathilde Caron, Piotr Bojanowski, Armand Joulin, and Matthijs Douze. 2018. Deep clustering for unsupervised learning of visual features. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 132–149.

Lu Chen, Boer Lv, Chi Wang, Su Zhu, Bowen Tan, and Kai Yu. 2020. Schema-guided multi-domain dialogue state tracking with graph attention neural networks. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, pages 7521–7528.

Felix Gers. 2001. *Long short-term memory in recurrent neural networks*. Ph.D. thesis, Verlag nicht ermittelbar.

Deepanway Ghosal, Navonil Majumder, Soujanya Poria, Niyati Chhaya, and Alexander Gelbukh. 2019. DialogueGCN: A graph convolutional neural network for emotion recognition in conversation. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 154–164, Hong Kong, China. Association for Computational Linguistics.

Xifeng Guo, Long Gao, Xinwang Liu, and Jianping Yin. 2017. Improved deep embedded clustering with local structure preservation. In *Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence, IJCAI 2017, Melbourne, Australia, August 19-25, 2017*, pages 1753–1759. ijcai.org.

John A Hartigan. 1979. A k-means clustering algorithm: Algorithm as 136. *Appl. Stat.*, 28:126–130.

Lawrence Hubert and Phipps Arabie. 1985. Comparing partitions. *Journal of classification*, 2(1):193–218.

Zhuxi Jiang, Yin Zheng, Huachun Tan, Bangsheng Tang, and Hanning Zhou. 2017. Variational deep embedding: An unsupervised and generative approach to clustering. In *Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence, IJCAI 2017, Melbourne, Australia, August 19-25, 2017*, pages 1965–1972. ijcai.org.

Thomas N. Kipf and Max Welling. 2017. Semi-supervised classification with graph convolutional networks. In *5th International Conference on Learning Representations, ICLR 2017, Toulon, France, April 24-26, 2017, Conference Track Proceedings*. OpenReview.net.

Ryan Kiros, Yukun Zhu, Ruslan Salakhutdinov, Richard S. Zemel, Raquel Urtasun, Antonio Torralba, and Sanja Fidler. 2015. Skip-thought vectors. In *Advances in Neural Information Processing Systems 28: Annual Conference on Neural Information Processing Systems 2015, December 7-12, 2015, Montreal, Quebec, Canada*, pages 3294–3302.

Harold W Kuhn. 1955. The hungarian method for the assignment problem. *Naval research logistics quarterly*, 2(1-2):83–97.

GJ McLachlan and KE Basford. 1988. Mixture models marcel dekker. *New York*.

Joel Larocca Neto, Alexandre D Santos, Celso AA Kaestner, Neto Alexandre, D Santos, et al. 2000. Document clustering and text summarization.

Aytug Onan, Hasan Bulut, and Serdar Korukoglu. 2017. An improved ant algorithm with lda-based representation for text document clustering. *Journal of Information Science*, 43(2):275–292.

Abhinav Rastogi, Xiaoxue Zang, Srinivas Sunkara, Raghav Gupta, and Pranav Khaitan. 2020. Towards scalable multi-domain conversational agents: The schema-guided dialogue dataset. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, pages 8689–8696.

Nils Reimers and Iryna Gurevych. 2019. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, China. Association for Computational Linguistics.

Gideon Schwarz et al. 1978. Estimating the dimension of a model. *Annals of statistics*, 6(2):461–464.

Alexander Strehl and Joydeep Ghosh. 2002. Cluster ensembles—a knowledge reuse framework for combining multiple partitions. *Journal of machine learning research*, 3(Dec):583–617.

Hui Su, Xiaoyu Shen, Rongzhi Zhang, Fei Sun, Pengwei Hu, Cheng Niu, and Jie Zhou. 2019. Improving multi-turn dialogue modelling with utterance rewriter. *arXiv preprint arXiv:1906.07004*.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4-9, 2017, Long Beach, CA, USA*, pages 5998–6008.

Petar Velickovic, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò, and Yoshua Bengio. 2018. Graph attention networks. In *6th International Conference on Learning Representations, ICLR 2018, Vancouver, BC, Canada, April 30 - May 3, 2018, Conference Track Proceedings*. OpenReview.net.

Chien-Sheng Wu, Steven CH Hoi, Richard Socher, and Caiming Xiong. 2020a. Tod-bert: Pre-trained natural language understanding for task-oriented dialogue. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 917–929.

Zonghan Wu, Shirui Pan, Fengwen Chen, Guodong Long, Chengqi Zhang, and S Yu Philip. 2020b. A comprehensive survey on graph neural networks. *IEEE transactions on neural networks and learning systems*.

Junyuan Xie, Ross B. Girshick, and Ali Farhadi. 2016. Unsupervised deep embedding for clustering analysis. In *Proceedings of the 33nd International Conference on Machine Learning, ICML 2016, New York City, NY, USA, June 19-24, 2016*, volume 48 of *JMLR Workshop and Conference Proceedings*, pages 478–487. JMLR.org.

Bo Yang, Xiao Fu, Nicholas D. Sidiropoulos, and Mingyi Hong. 2017. Towards k-means-friendly spaces: Simultaneous deep learning and clustering. In *Proceedings of the 34th International Conference on Machine Learning, ICML 2017, Sydney, NSW, Australia, 6-11 August 2017*, volume 70 of *Proceedings of Machine Learning Research*, pages 3861–3870. PMLR.

Xiaoxue Zang, Abhinav Rastogi, Srinivas Sunkara, Raghav Gupta, Jianguo Zhang, and Jindong Chen. 2020. Multiwoz 2.2: A dialogue dataset with additional annotation corrections and state tracking baselines. *arXiv preprint arXiv:2007.12720*.

ASAP: A Chinese Review Dataset Towards Aspect Category Sentiment Analysis and Rating Prediction

Jiahao Bu[1]*, Lei Ren[1]*, Shuang Zheng[1,2]*, Yang Yang[1], Jingang Wang[1]†, Fuzheng Zhang[1], Wei Wu[1]
[1]Meituan, Beijing, China
[2]School of Economics and Management, Dalian University of Technology, Dalian, China
{bujiahao,renlei04,zhengshuang04,yangyang113}@meituan.com
{wangjingang02,zhangfuzheng,wuwei30}@meituan.com

Abstract

Sentiment analysis has attracted increasing attention in e-commerce. The sentiment polarities underlying user reviews are of great value for business intelligence. Aspect category sentiment analysis (ACSA) and review rating prediction (RP) are two essential tasks to detect the fine-to-coarse sentiment polarities. ACSA and RP are highly correlated and usually employed jointly in real-world e-commerce scenarios. While most public datasets are constructed for ACSA and RP separately, which may limit the further exploitations of both tasks. To address the problem and advance related researches, we present a large-scale Chinese restaurant review dataset **ASAP** including $46,730$ genuine reviews from a leading online-to-offline (O2O) e-commerce platform in China. Besides a 5-star scale rating, each review is manually annotated according to its sentiment polarities towards 18 pre-defined aspect categories. We hope the release of the dataset could shed some light on the field of sentiment analysis. Moreover, we propose an intuitive yet effective joint model for ACSA and RP. Experimental results demonstrate that the joint model outperforms state-of-the-art baselines on both tasks.

1 Introduction

With the rapid development of e-commerce, massive user reviews available on e-commerce platforms are becoming valuable resources for both customers and merchants. Aspect-based sentiment analysis(ABSA) on user reviews is a fundamental and challenging task which attracts interests from both academia and industries (Hu and Liu, 2004; Ganu et al., 2009; Jo and Oh, 2011; Kiritchenko et al., 2014). According to whether the aspect terms are explicitly mentioned in texts, ABSA can be further classified into aspect term sentiment analysis (ATSA) and aspect category sentiment analysis (ACSA), we focus on the latter which is more widely used in industries. Specifically, given a review "Although the fish is delicious, the waiter is horrible!", the ACSA task aims to infer the sentiment polarity over aspect category *food* is positive while the opinion over the aspect category *service* is negative.

The user interfaces of e-commerce platforms are more intelligent than ever before with the help of ACSA techniques. For example, Figure 1 presents the detail page of a coffee shop on a popular e-commerce platform in China. The upper aspect-based sentiment text-boxes display the aspect categories (e.g., *food*, *sanitation*) mentioned frequently in user reviews and the aggregated sentiment polarities on these aspect categories (the orange ones represent positive and the blue ones represent negative). Customers can focus on corresponding reviews effectively by clicking the aspect-based sentiment text-boxes they care about (e.g., the orange filled text-box "卫生条件好" (*good sanitation*)). Our user survey based on $7,824$ valid questionnaires demonstrates that 80.08% customers agree that the aspect-based sentiment text-boxes are helpful to their decision-making on restaurant choices. Besides, the merchants can keep track of their cuisines and service qualities with the help of the aspect-based sentiment text-boxes. Most Chinese e-commerce platforms such as Taobao[1], Dianping[2], and Koubei[3] deploy the similar user interfaces to improve user experience.

Users also publish their overall 5-star scale ratings together with reviews. Figure 1 displays a sample of 5-star rating to the coffee shop. In comparison to fine-grained aspect sentiment, the overall review rating is usually a coarse-grained synthesis of the opinions on multiple aspects. Rating pre-

*Equal contribution.
†Corresponding author.

[1]https://www.taobao.com/
[2]https://www.dianping.com/
[3]https://www.koubei.com/

diction(RP) (Jin et al., 2016; Li et al., 2018; Wu et al., 2019a) which aims to predict the "seeing stars" of reviews also has wide applications. For example, to promise the aspect-based sentiment text-boxes accurate, unreliable reviews should be removed before ACSA algorithms are performed. Given a piece of user review, we can predict a rating for it based on the overall sentiment polarity underlying the text. We assume the predicted rating of the review should be consistent with its ground-truth rating as long as the review is reliable. If the predicted rating and the user rating of a review disagree with each other explicitly, the reliability of the review is doubtful. Figure 2 demonstrates an example review of low-reliability. In summary, RP can help merchants to detect unreliable reviews.

Therefore, both ACSA and RP are of great importance for business intelligence in e-commerce, and they are highly correlated and complementary. ACSA focuses on predicting its underlying sentiment polarities on different aspect categories, while RP focuses on predicting the user's overall feelings from the review content. We reckon these two tasks are highly correlated and better performance could be achieved by considering them jointly.

As far as we know, current public datasets are constructed for ACSA and RP separately, which limits further joint explorations of ACSA and RP. To address the problem and advance the related researches, this paper presents a large-scale Chinese restaurant review dataset for **A**spect category **S**entiment **A**nalysis and rating **P**rediction, denotes as **ASAP** for short. All the reviews in ASAP are collected from the aforementioned e-commerce platform. There are 46,730 restaurant reviews attached with 5-star scale ratings. Each review is manually annotated according to its sentiment polarities towards 18 fine-grained aspect categories. To the best of our knowledge, ASAP is the largest Chinese large-scale review dataset towards both ACSA and RP tasks.

We implement several state-of-the-art (SOTA) baselines for ACSA and RP and evaluate their performance on ASAP. To make a fair comparison, we also perform ACSA experiments on a widely used SemEval-2014 restaurant review dataset (Pontiki et al., 2014). Since BERT (Devlin et al., 2018) has achieved great success in several natural language understanding tasks including sentiment analysis (Xu et al., 2019; Sun et al., 2019; Jiang et al., 2019), we propose a joint model that employs the fine-to-coarse semantic capability of BERT. Our joint model outperforms the competing baselines on both tasks.

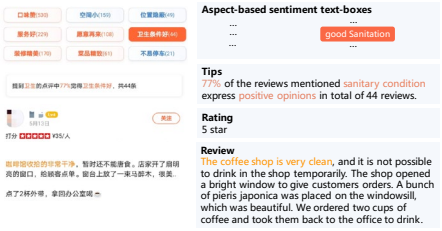

Figure 1: The user interface of a coffee shop on a popular e-commerce App. The top aspect-based sentiment text-boxes display aspect categories and sentiment polarities. The orange text-boxes are positive, while the blue ones are negative. The reviews mentioning the clicked aspect category (e.g., *good sanitation*) with ratings are shown below. The text spans mentioning the aspect categories are also highlighted.

Figure 2: A content-rating disagreement case. The review holds a 2-star rating while all the mentioned aspects are super positive.

Our main contributions can be summarized as follows. (1) We present a large-scale Chinese review dataset towards aspect category sentiment analysis and rating prediction, named as ASAP, including as many as 46,730 real-world restaurant reviews annotated from 18 pre-defined aspect categories. Our dataset has been released at https://github.com/Meituan-Dianping/asap. (2) We explore the performance of widely used models for ACSA and RP on ASAP. (3) We propose a joint learning model for ACSA and RP tasks. Our model achieves the best results both on ASAP and SemEval RESTAURANT datasets.

2 Related Work and Datasets

Aspect Category Sentiment Analysis. ACSA (Zhou et al., 2015; Movahedi et al., 2019; Ruder et al., 2016; Hu et al., 2018) aims to predict sentiment polarities on all aspect categories mentioned in the text. The series of SemEval datasets consisting of user reviews from e-commerce websites have been widely used and

pushed forward related research (Wang et al., 2016; Ma et al., 2017; Xu et al., 2019; Sun et al., 2019; Jiang et al., 2019). The SemEval-2014 task-4 dataset (SE-ABSA14) (Pontiki et al., 2014) is composed of laptop and restaurant reviews. The restaurant subset includes 5 aspect categories (i.e., *Food*, *Service*, *Price*, *Ambience* and *Anecdotes/Miscellaneous*) and 4 polarity labels (i.e., *Positive*, *Negative*, *Conflict* and *Neutral*). The laptop subset is not suitable for ACSA. The SemEval-2015 task-12 dataset (SE-ABSA15) (Pontiki et al., 2015) builds upon SE-ABSA14 and defines its aspect category as a combination of an entity type and an attribute type(e.g., *Food#Style_Options*). The SemEval-2016 task-5 dataset (SE-ABSA16) (Pontiki et al., 2016) extends SE-ABSA15 to new domains and new languages other than English. MAMS (Jiang et al., 2019) tailors SE-ABSA14 to make it more challenging, in which each sentence contains at least two aspects with different sentiment polarities.

Compared with the prosperity of English resources, high-quality Chinese datasets are not rich enough. "ChnSentiCorp" (Tan and Zhang, 2008), "IT168TEST" (Zagibalov and Carroll, 2008), "Weibo"[4], "CTB" (Li et al., 2014) are 4 popular Chinese datasets for general sentiment analysis. However, aspect category information is not annotated in these datasets. Zhao et al. (2014) presents two Chinese ABSA datasets for consumer electronics (mobile phones and cameras). Nevertheless, the two datasets only contain 400 documents ($\sim$ 4000 sentences), in which each sentence only mentions one aspect category at most. BDCI[5] automobile opinion mining and sentiment analysis dataset (Dai et al., 2019) contains 8,290 user reviews in automobile industry with 10 predefined categories. Peng et al. (2017) summarizes available Chinese ABSA datasets. While most of them are constructed through rule-based or machine learning-based approaches, which inevitably introduce additional noise into the datasets. Our ASAP excels above Chinese datasets both on quantity and quality.

Rating Prediction. Rating prediction (RP) aims to predict the "seeing stars" of reviews, which represent the overall ratings of reviews. In comparison to fine-grained aspect sentiment, the overall review rating is usually a coarse-grained synthesis of the opinions on multiple aspects. Ganu et al. (2009); Li et al. (2011); Chen et al. (2018) form this task as a text classification or regression problem. Considering the importance of opinions on multiple aspects in reviews, recent years have seen numerous work (Jin et al., 2016; Cheng et al., 2018; Li et al., 2018; Wu et al., 2019a) utilizing the information of the aspects to improve the rating prediction performance. This trending also inspires the motivation of ASAP.

Most RP datasets are crawled from real-world review websites and created for RP specifically. Amazon Product Review English dataset (McAuley and Leskovec, 2013) containing product reviews and metadata from Amazon has been widely used for RP (Cheng et al., 2018; McAuley and Leskovec, 2013). Another popular English dataset comes from Yelp Dataset Challenge 2017[6], which includes reviews of local businesses in 12 metropolitan areas across 4 countries. Openrice[7] is a Chinese RP dataset composed of 168,142 reviews. Both the English and Chinese datasets don't annotate fine-grained aspect category sentiment polarities.

3 Dataset Collection and Analysis

3.1 Data Construction & Curation

We collect reviews from one of the most popular O2O e-commerce platforms in China, which allows users to publish coarse-grained star ratings and writing fine-grained reviews to restaurants (or places of interest) they have visited. In the reviews, users comment on multiple aspects either explicitly or implicitly, including *ambience*,*price*, *food*, *service*, and so on.

First, we retrieve a large volume of user reviews from popular restaurants holding more than 50 user reviews randomly. Then, 4 pre-processing steps are performed to promise the ethics, quality, and reliability of the reviews. (1) User information (e.g., user-ids, usernames, avatars, and post-times) are removed due to privacy considerations. (2) Short reviews with less than 50 Chinese characters, as well as lengthy reviews with more than 1000 Chinese characters are filtered out. (3) If the ratio of non-Chinese characters within a review is over 70%, the review is discarded. (4) To detect the low-

[4] http://tcci.ccf.org.cn/conference/2014/pages/page04_dg.html

[5] https://www.datafountain.cn/competitions/310

[6] http://www.yelp.com/dataset_challenge/

[7] https://www.openrice.com

quality reviews (e.g., advertising texts), we build a BERT-based classifier with an accuracy of 97% in a leave-out test-set. The reviews detected as low-quality by the classifier are discarded too.

3.2 Aspect Categories

Since the reviews already hold users' star ratings, this section mainly introduces our annotation details for ACSA. In SE-ABSA14 restaurant dataset (denoted as RESTAURANT for simplicity), there are 5 coarse-grained aspect categories, including *food*, *service*, *price*, *ambience* and *miscellaneous*. After an in-depth analysis of the collected reviews, we find the aspect categories mentioned by users are rather diverse and fine-grained. Take the text "...The restaurant holds a high-end decoration but is quite noisy since a wedding ceremony was being held in the main hall... (...环境看起来很高大上的样子，但是因为主厅在举办婚礼非常混乱，感觉特别吵...)" in Table 3 for example, the reviewer actually expresses opposite sentiment polarities on two fine-grained aspect categories related to *ambience*. The restaurant's decoration is very high-end (*Positive*), while it's very noisy due to an ongoing ceremony (*Negative*). Therefore, we summarize the frequently mentioned aspects and refine the 5 coarse-grained categories into 18 fine-grained categories. We replace *miscellaneous* with *location* since we find users usually review the restaurants' location (e.g., whether the restaurant is easy to reach by public transportation.). We denote the aspect category as the form of "*Coarse-grained Category#Fine-grained Categoty*", such as "*Food#Taste*" and "*Ambience#Decoration*". The full list of aspect categories and definitions are listed in Table 1.

3.3 Annotation Guidelines & Process

Bearing in mind the pre-defined 18 aspects, assessors are asked to annotate sentiment polarities towards the mentioned aspect categories of each review. Given a review, when an aspect category is mentioned within the review either explicitly and implicitly, the sentiment polarity over the aspect category is labeled as 1 (*Positive*), 0 (*Neutral*) or -1 (*Negative*) as shown in Table 3.

We hire 20 vendor assessors, 2 project managers, and 1 expert reviewer to perform annotations. Each assessor needs to attend a training to ensure their intact understanding of the annotation guidelines. Three rounds of annotation are conducted sequentially. First, we randomly split the whole dataset into 10 groups, and every group is assigned to 2 assessors to annotate independently. Second, each group is split into 2 subsets according to the annotation results, denoted as **Sub-Agree** and **Sub-Disagree**. **Sub-Agree** comprises the data examples with agreement annotation, and **Sub-Disagree** comprises the data examples with disagreement annotation. **Sub-Agree** will be reviewed by assessors from other groups. The controversial examples during the review are considered as difficult cases. **Sub-Disagree** will be reviewed by the 2 project managers independently and then discuss to reach an agreement annotation. The examples that could not be addressed after discussions are also considered as difficult cases. Third, for each group, the difficult examples from two subsets are delivered to the expert reviewer to make a final decision. More details of difficult cases and annotation guidelines during annotation are demonstrated in Table 2.

Finally, ASAP corpus consists of 46,730 pieces of real-world user reviews, and we split it into a training set (36,850), a validation set (4,940) and a test set (4,940) randomly. Table 3 presents an example review of ASAP and corresponding annotations on the 18 aspect categories.

3.4 Dataset Analysis

Figure 3 presents the distribution of 18 aspect categories in ASAP. Because ASAP concentrates on the domain of restaurant, 94.7% reviews mention *Food#Taste* as expected. Users also pay great attention to aspect categories such as *Service#Hospitality*, *Price#Level* and *Ambience#Decoration*. The distribution proves the advantages of ASAP, as users' fine-grained preferences could reflect the pros and cons of restaurants more precisely.

The statistics of ASAP are presented in Table 4. We also include a tailored SE-ABSA14 RESTAURANT dataset for reference. Please note that we remove the reviews holding aspect categories with sentiment polarity of "conflict" from the original RESTAURANT dataset.

Compared with RESTAURANT, ASAP excels in the quantities of training instances, which supports the exploration of recent data-intensive deep neural models. ASAP is a review-level dataset, while RESTAURANT is a sentence-level dataset. The average length of reviews in ASAP is much longer, thus the reviews tend to contain richer aspect information. In ASAP, the reviews contain

Table 1: The full list of 18 aspect categories and definitions.

Aspect category	Definition	Aspect category	Definition
Food#Taste (口味)	Food taste	*Location#Easy_to_find* (是否容易寻找)	Whether the restaurant is easy to find
Food#Appearance (外观)	Food appearance	*Service#Queue* (排队时间)	Whether the queue time is acceptable
Food#Portion (分量)	Food portion	*Service#Hospitality* (服务人员态度)	Waiters/waitresses' attitude/hospitality
Food#Recommend (推荐程度)	Whether the food is worth being recommended	*Service#Parking* (停车方便)	Parking convenience
Price#Level (价格水平)	Price level	*Service#Timely* (点菜/上菜速度)	Order/Serving time
Price#Cost_effective (性价比)	Whether the restaurant is cost-effective	*Ambience#Decoration* (装修)	Decoration level
Price#Discount (折扣力度)	Discount strength	*Ambience#Noise* (嘈杂情况)	Whether the restaurant is noisy
Location#Downtown (位于商圈附近)	Whether the restaurant is located near downtown	*Ambience#Space* (就餐空间)	Dining Space and Seat Size
Location#Transportation (交通方便)	Convenient public transportation to the restaurant	*Ambience#Sanitary* (卫生情况)	Sanitary condition

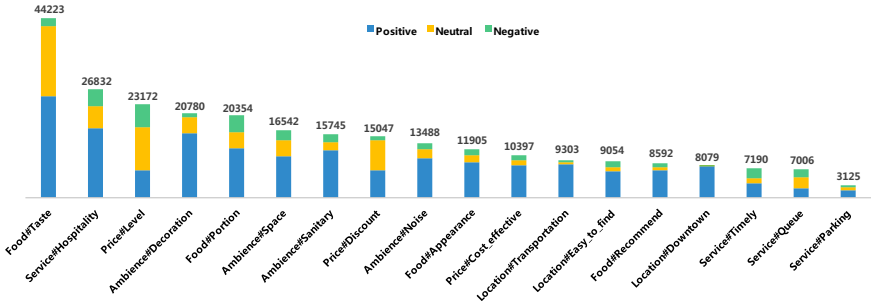

Figure 3: The distribution of 18 fine-grained aspect categories in ASAP.

5.8 aspect categories in average, which is 4.7 times of RESTAURANT. Both review-level ACSA and RP are more challenging than their sentence-level counterparts. Take the review in Table 3 for example, the review contains several sentiment polarities towards multiple aspect categories. In addition to aspect category sentiment annotations, ASAP also includes overall user ratings for reviews. With the help of ASAP, ACSA and RP can be further optimized either separately or jointly.

4 Methodology

4.1 Problem Formulation

We use D to denote the collection of user review corpus in the training data. Given a review R which consists of a series of words: $\{w_1, w_2, ..., w_Z\}$, ACSA aims to predict the sentiment polarity $y_i \in \{Positive, Neutral, Negative\}$ of review R with respect to the mentioned aspect category a_i, $i \in \{1, 2, ..., N\}$. Z denotes the length of review R. N is the number of pre-defined aspect categories (i.e., 18 in this paper). Suppose there are K mentioned aspect categories in R. We define a mask vector $[p_1, p_2, ..., p_N]$ to indicate the occurrence of aspect categories. When the aspect category a_i is mentioned in R, $p_i = 1$, otherwise $p_i = 0$. So we have $\sum_{i=1}^{N} p_i = K$. In terms of RP, it aims to predict the 5-star rating score of g, which represents the overall rating of the given review R.

4.2 Joint Model

Given a user review, ACSA focuses on predicting its underlying sentiment polarities on different aspect categories, while RP focuses on predicting the user's overall feelings from the review content. We reckon these two tasks are highly correlated and better performance could be achieved by considering them jointly.

The advent of BERT has established the success

Table 2: Difficult cases and annotation guidelines.

Category	Example	Example (Translation)	Guideline	Annotation
Change of sentiment over time	我之前挺喜欢这家餐厅的饭菜，不过今天的饭菜可不怎么样.	I used to like the food of this restaurant, but the taste is not as expected today.	When there existed a sentiment drifting over time in the review, the most recent sentiment polarity is adopted.	(*Food#Taste*, −1)
Implicit sentiment polarity	比五星级酒店的餐厅差远了，而且在五星级酒店中餐厅里两个人吃一顿也就500左右就够了	The restaurant was far worse than the dinning hall of any five-star hotel, considering that the meal for two people only cost 500 CNY in a five-star hotel.	Some reviewers express their polarities in an implicit manner instead of expressing their feelings directly. The implicit sentiment polarity is adopted to complete the annotation.	(*Price#Level*, −1)
Conflict opinions	这道菜有点咸，但是味道很赞。	This dish was a bit salty, but it tasted great.	When there existed multiple sentiment polarities toward the same aspect-category, the dominant sentiment is chosen.	(*Food#Taste*, 1)
Mild sentiment	饭菜还可以，不过也算不上特别好吃。	The food was okay, but nothing great.	The “neutral” label applies to mildly positive or mildly negative sentiment	(*Food#Taste*, 0)
Irrelevant restaurant	上次去的一家店很难吃，今天来了这家新的，感觉很好吃。	The food of the shop which I went to last time was very bad. Today I came to this new one. I felt very good.	The review mentions restaurant that the user has visited in the past. We only focus on the restaurant being reviewed	(*Food#Taste*, 1)

of the “pre-training and then fine-tuning” paradigm for NLP tasks. BERT-based models have achieved impressive results in ACSA (Xu et al., 2019; Sun et al., 2019; Jiang et al., 2019). Review rating prediction can be deemed as a single-sentence classification (regression) task, which could also be addressed with BERT. Therefore, we propose a joint learning model to address ACSA and RP in a multi-task learning manner. Our joint model employs the fine-to-coarse semantic representation capability of the BERT encoder. Figure 4 illustrates the framework of our joint model.

ACSA As shown in Figure 4, the token embeddings of the input review are generated through a shared BERT encoder. Briefly, let $H \in \mathbb{R}^{d*Z}$ be the matrix consisting of token embedding vectors $\{h_1, ..., h_Z\}$ that BERT produces, where d is the size of hidden layers and Z is the length of the given review. Since different aspect category information is dispersed across the content of R, we add an attention-pooling layer (Wang et al., 2016) to aggregate the related token embeddings dynamically for every aspect category. The attention-pooling layer helps the model focus on the tokens most related to the target aspect categories.

$$M_i^a = \tanh(W_i^a * H) \quad (1)$$

$$\alpha_i = softmax(\omega_i^T * M_i^a) \quad (2)$$

$$r_i = \tanh(W_i^p * H * \alpha_i^T) \quad (3)$$

Where $W_i^a \in \mathbb{R}^{d*d}$, $M_i^a \in \mathbb{R}^{d*Z}$, $\omega_i \in \mathbb{R}^d$, $\alpha_i \in \mathbb{R}^Z$, $W_i^p \in \mathbb{R}^{d*d}$, and $r_i \in \mathbb{R}^d$. α_i is a vector consisting of attention weights of all tokens which can selectively attend the regions of the aspect category related tokens, and r_i is the attentive representation of review with respect to the i_{th} aspect category a_i, $i \in \{1, 2, ..., N\}$. Then we have

$$\hat{y}_i = softmax(W_i^q * r_i + b_i^q) \quad (4)$$

Where $W_i^q \in \mathbb{R}^{C*d}$ and $b_i^q \in \mathbb{R}^C$ are trainable parameters of the softmax layer. C is the number of labels (i.e, 3 in our task). Hence, the ACSA loss for a given review R is defined as follows,

$$loss_{ACSA} = \frac{1}{K} \sum_{i=1}^{N} p_i \sum_{C} y_i * \log \hat{y}_i \quad (5)$$

If the aspect category a_i is not mentioned in S, y_i is set as a random value. The p_i serves as a gate function, which filters out the random y_i and ensures only the mentioned aspect categories can participate in the calculation of the loss function.

Table 3: A review example in ASAP, with overall star rating and aspect category sentiment polarity annotations.

Review	Rating	Aspect Category	Label	Aspect Category	Label
With convenient traffic, the restaurant holds a high-end decoration, but quite noisy because a wedding ceremony was being held in the main hall. Impressed by its delicate decoration and grand appearance though, we had to wait for a while at the weekend time. However, considering its high price level, the taste is unexpected. We ordered the Kung Pao Prawn, the taste was acceptable and the serving size is enough, but the shrimp is not fresh. In terms of service, you could not expect too much due to the massive customers there. By the way, the free-served fruit cup was nice. Generally speaking, it was a typical wedding banquet restaurant rather than a comfortable place to date with friends. 交通还挺方便的，环境看起来很高大上的样子，但是因为主厅在举办婚礼非常混乱，特别吵感觉，但是装修的还不错，感觉很精致的装修，门面很气派，周末去的时候还需要等位。味道的话我觉得还可以但是跟价格比起来就很一般了，性价比挺低的，为了去吃宫保虾球的，但是我觉得也就那样吧虾不是特别新鲜，不过虾球很大，味道还行。服务的话由于人很多所以也顾不过来上菜的速度不快，但是有送水果杯还挺好吃的。总之就是典型的婚宴餐厅不是适合普通朋友吃饭的地方了。	3-Star	*Location#Transportation* (交通方便)	1	*Price#Discount* (折扣力度)	-
		Location#Downtown (位于商圈附近)	-	*Ambience#Decoration* (装修)	1
		Location#Easy_to_find (是否容易寻找)	-	*Ambience#Noise* (嘈杂情况)	−1
		Service#Queue (排队时间)	-	*Ambience#Space* (就餐空间)	1
		Service#Hospitality (服务人员态度)	-	*Ambience#Sanitary* (卫生情况)	-
		Service#Parking (停车方便)	-	*Food#Portion* (分量)	1
		Service#Timely (点菜/上菜速度)	−1	*Food#Taste* (口味)	1
		Price#Level (价格水平)	0	*Food#Appearance* (外观)	-
		Price#Cost_effective (性价比)	−1	*Food#Recommend* (推荐程度)	-

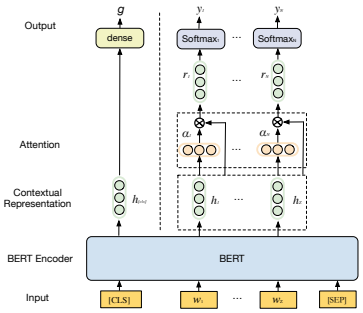

Figure 4: The framework of the proposed joint learning model. The right part of the dotted vertical line is used to predict multiple aspect category sentiment polarities, while the left part is used to predict the review rating.

Rating Prediction Since the objective of RP is to predict the review rating based on the review content, we adopt the [CLS] embedding $h_{[cls]} \in \mathbb{R}^d$ BERT produces as the representation of the input review, where d is the size of hidden layers in the BERT encoder.

$$\hat{g} = \beta^T * \tanh(W^r * h_{[cls]} + b^r) \quad (6)$$

Hence the RP loss for a given review R is defined as follows,

$$loss_{RP} = |g - \hat{g}| \quad (7)$$

Where $W^r \in \mathbb{R}^{d*d}$,$b^r \in \mathbb{R}^d$, $\beta \in \mathbb{R}^d$ are trainable parameters.

The final loss of our joint model becomes as follows.

$$loss = loss_{ACSA} + loss_{RP} \quad (8)$$

5 Experiments

We perform an extensive set of experiments to evaluate the performance of our joint model on ASAP

Table 4: The statistics and label/rating distribution of ASAP and RESTAURANT. The review length are counted by Chinese characters and English words respectively. The sentences are segmented with periods in ASAP, while RESTAURANT is a sentence-level dataset.

Dataset	Split	Reviews	Average sentences per review	Average aspects per review	Average length	Positive	Negative	Neutral	1-star	2-star	3-star	4-star	5-star
ASAP	Train	36,850	8.6	5.8	319.7	133,721	27,425	52,225	1,219	1,258	5,241	13,362	15,770
	Dev	4,940	8.7	5.9	319.9	18,176	3,733	7,192	151	166	784	1,734	2,105
	Test	4,940	8.3	5.7	317.1	17,523	3,813	7,026	165	173	717	1,867	2,018
RESTAURANT	Train	2,855	1	1.2	15.2	2150	822	498	-	-	-	-	-
	Test	749	1	1.3	15.6	645	215	94	-	-	-	-	-

and RESTAURANT (Pontiki et al., 2014). Ablation studies are also conducted to probe the interactive influence between ACSA and RP.

5.1 ACSA

Baseline Models We implement several ACSA baselines for comparison. According to the different structures of their encoders, these models are classified into Non-BERT based models or BERT-based models. Non-BERT based models include TextCNN (Kim, 2014), BiLSTM+Attn (Zhou et al., 2016), ATAE-LSTM (Wang et al., 2016) and CapsNet (Sabour et al., 2017). BERT-based models include vanilla BERT (Devlin et al., 2018), QA-BERT (Sun et al., 2019) and CapsNet-BERT (Jiang et al., 2019).

Implementation Details of Experimental Models In terms of non-BERT-based models, we initialize their inputs with pre-trained embeddings. For Chinese ASAP, we utilize Jieba[8] to segment Chinese texts and adopt Tencent Chinese word embeddings (Song et al., 2018) composed of $8,000,000$ words. For English RESTAURANT, we adopt 300-dimensional word embeddings pre-trained by Glove (Pennington et al., 2014).

In terms of BERT-based models, we adopt the 12-layer Google BERT Base[9] to encode the inputs.

The batch sizes are set as 32 and 16 for non-BERT-based models and BERT-based models respectively. Adam optimizer (Kingma and Ba, 2014) is employed with $\beta_1 = 0.9$ and $\beta_2 = 0.999$. The maximum sequence length is set as 512. The number of epochs is set as 3. The learning rates are set as 0.001 and 0.00005 for non-BERT-based models and BERT-based models respectively. All the models are trained on a single NVIDIA Tesla 32G V100 Volta GPU.

Evaluation Metrics Following the settings of RESTAURANT, we adopt Macro-F1 and Accuracy (Acc) as evaluation metrics.

Experimental Results & Analysis We report the performance of aforementioned models on ASAP and RESTAURANT in Table 5. Generally, BERT-based models outperform Non-BERT based models on both datasets. The two variants of our joint model perform better than vanilla-BERT, QA-BERT, and CapsNet-BERT, which proves the advantages of our joint learning model. Given a user review, vanilla-BERT, QA-BERT, and CapsNet-BERT treat the pre-defined aspect categories independently, while our joint model combines them together with a multi-task learning framework. On one hand, the encoder-sharing setting enables knowledge transferring among different aspect categories. On the other hand, our joint model is more efficient than other competitors, especially when the number of aspect categories is large. The ablation of RP (i.e., joint model(w/o RP)) still outperforms all other baselines. The introduction of RP to ACSA brings marginal improvement. This is reasonable considering that the essential objective of RP is to estimate the overall sentiment polarity instead of fine-grained sentiment polarities.

We visualize the attention weights produced by our joint model on the example of Table 3 in Figure 5. Since different aspect category information is dispersed across the review of R, we add an attention-pooling layer (Wang et al., 2016) to aggregate the related token embeddings dynamically for every aspect category. The attention-pooling layer helps the model focus on the tokens most related to the target aspect categories. Figure 5 visualizes attention weights of 3 given aspect categories. The intensity of the color represents the magnitude of attention weight, which means the relatedness of tokens to the given aspect category. It's obvious that our joint model focus on the tokens most related to the aspect categories across the review of R.

[8] https://github.com/fxsjy/jieba

[9] https://github.com/google-research/bert

Table 5: The experimental results of ACSA models on ASAP and RESTAURANT. Best scores are boldfaced.

Category	Model	ASAP		RESTAURANT	
		Macro-F1	Acc.	Macro-F1	Acc.
Non-BERT-based models	TextCNN (Kim, 2014)	60.41%	71.10%	70.56%	82.29%
	BiLSTM+Attn (Zhou et al., 2016)	70.53%	77.78%	70.85%	81.97%
	ATAE_LSTM (Wang et al., 2016)	76.60%	81.94%	70.15%	82.12%
	CapsNet (Sabour et al., 2017)	75.54%	81.66%	71.84%	82.63%
BERT-based models	Vanilla-BERT (Devlin et al., 2018)	79.18%	84.09%	79.22%	87.63%
	QA-BERT (Sun et al., 2019)	79.44%	83.92%	80.89%	88.89%
	CapsNet-BERT (Jiang et al., 2019)	78.92%	83.74%	80.94%	89.00%
	Joint Model (w/o RP)	80.75%	85.15%	**82.01%**	**89.62%**
	Joint Model	**80.78%**	**85.19%**	-	-

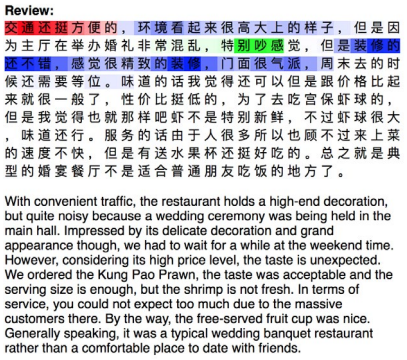

Figure 5: Attention visualization example. We only show attention weights of 3 aspect categories for beauty. The red text span "..With convenient traffic..(..交通还挺方便的..)" is related to *Location#Transportation*. The blue text span "..the restaurant holds a high-end decoration..Impressed by its delicate decoration and grand appearance though..(..环境看起来高大上的样子..装修还不错，很精致的装修..)" is related to *Ambience#Decoration*. The green text span "..but quite noisy..(..特别吵感觉..)" is related to *Ambience#Noise*. The intensity of the color represents the magnitude of attention weight.

5.2 Rating Prediction

We compare several RP models on ASAP, including TextCNN (Kim, 2014), BiLSTM+Attn (Zhou et al., 2016) and ARP (Wu et al., 2019b). The data pre-processing and implementation details are identical with ACSA experiments.

Evaluation Metrics. We adopt Mean Absolute Error (MAE) and Accuracy (by mapping the predicted rating score to the nearest category) as evaluation metrics.

Experimental Results & Analysis The experimental results of comparative RP models are illustrated in Table 6.

Table 6: Experimental results of RP models on ASAP. Best scores are boldfaced.

Model	MAE	Acc.
TextCNN (Kim, 2014)	.5814	52.99%
BiLSTM+Attn (Zhou et al., 2016)	.5737	54.38%
ARP (Wu et al., 2019b)	.5620	54.76%
Joint Model (w/o ACSA)	.4421	60.08%
Joint Model	**.4266**	**61.26%**

Our joint model which combines ACSA and RP outperforms other models considerably. On one hand, the performance improvement is expected since our joint model is built upon BERT. On the other hand, the ablation of ACSA (i.e., joint model(w/o ACSA)) brings performance degradation of RP on both metrics. We can conclude that the fine-grained aspect category sentiment prediction of the review indeed helps the model predict its overall rating more accurately.

This section conducts preliminary experiments to evaluate classical ACSA and RP models on our proposed ASAP dataset. We believe there still exists much room for improvements to both tasks, and we will leave them for future work.

6 Conclusion

This paper presents **ASAP**, a large-scale Chinese restaurant review dataset towards aspect category sentiment analysis (ACSA) and rating prediction (RP). ASAP consists of 46,730 restaurant user reviews with star ratings from a leading e-commerce platform in China. Each review is manually annotated according to its sentiment polarities on 18 fine-grained aspect categories. Besides evaluations of ACSA and RP models on ASAP separately, we also propose a joint model to address ACSA and RP synthetically, which outperforms other state-of-the-art baselines considerably. we hope the release of ASAP could push forward related researches and applications.

References

Chong Chen, Min Zhang, Yiqun Liu, and Shaoping Ma. 2018. Neural attentional rating regression with review-level explanations. In *Proceedings of the 2018 World Wide Web Conference*, pages 1583–1592.

Zhiyong Cheng, Ying Ding, Lei Zhu, and Mohan Kankanhalli. 2018. Aspect-aware latent factor model: Rating prediction with ratings and reviews. In *Proceedings of the 2018 world wide web conference*, pages 639–648.

Zehui Dai, Wei Dai, Zhenhua Liu, Fengyun Rao, Huajie Chen, Guangpeng Zhang, Yadong Ding, and Jiyang Liu. 2019. Multi-task multi-head attention memory network for fine-grained sentiment analysis. In *CCF International Conference on Natural Language Processing and Chinese Computing*, pages 609–620. Springer.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2018. Bert: Pre-training of deep bidirectional transformers for language understanding. *CoRR*, abs/1810.04805.

Gayatree Ganu, Noemie Elhadad, and Amélie Marian. 2009. Beyond the stars: improving rating predictions using review text content. In *WebDB*, volume 9, pages 1–6. Citeseer.

Mengting Hu, Shiwan Zhao, Li Zhang, Keke Cai, Zhong Su, Renhong Cheng, and Xiaowei Shen. 2018. CAN: constrained attention networks for multi-aspect sentiment analysis. *CoRR*, abs/1812.10735.

Minqing Hu and Bing Liu. 2004. Mining and summarizing customer reviews. In *Proceedings of the tenth ACM SIGKDD international conference on Knowledge discovery and data mining*, pages 168–177.

Qingnan Jiang, Lei Chen, Ruifeng Xu, Xiang Ao, and Min Yang. 2019. A challenge dataset and effective models for aspect-based sentiment analysis. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 6281–6286.

Zhipeng Jin, Qiudan Li, Daniel D Zeng, YongCheng Zhan, Ruoran Liu, Lei Wang, and Hongyuan Ma. 2016. Jointly modeling review content and aspect ratings for review rating prediction. In *Proceedings of the 39th International ACM SIGIR conference on Research and Development in Information Retrieval*, pages 893–896.

Yohan Jo and Alice H Oh. 2011. Aspect and sentiment unification model for online review analysis. In *Proceedings of the fourth ACM international conference on Web search and data mining*, pages 815–824. ACM.

Yoon Kim. 2014. Convolutional neural networks for sentence classification. *arXiv preprint arXiv:1408.5882*.

Diederik P Kingma and Jimmy Ba. 2014. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.

Svetlana Kiritchenko, Xiaodan Zhu, Colin Cherry, and Saif Mohammad. 2014. Nrc-canada-2014: Detecting aspects and sentiment in customer reviews. In *Proceedings of the 8th International Workshop on Semantic Evaluation (SemEval 2014)*, pages 437–442.

Changliang Li, Bo Xu, Gaowei Wu, Saike He, Guanhua Tian, and Hongwei Hao. 2014. Recursive deep learning for sentiment analysis over social data. In *2014 IEEE/WIC/ACM International Joint Conferences on Web Intelligence (WI) and Intelligent Agent Technologies (IAT)*, volume 2, pages 180–185. IEEE.

Fangtao Li, Nathan Nan Liu, Hongwei Jin, Kai Zhao, Qiang Yang, and Xiaoyan Zhu. 2011. Incorporating reviewer and product information for review rating prediction. In *Twenty-second international joint conference on artificial intelligence*.

Junjie Li, Haitong Yang, and Chengqing Zong. 2018. Document-level multi-aspect sentiment classification by jointly modeling users, aspects, and overall ratings. In *Proceedings of the 27th International Conference on Computational Linguistics*, pages 925–936, Santa Fe, New Mexico, USA. Association for Computational Linguistics.

Dehong Ma, Sujian Li, Xiaodong Zhang, and Houfeng Wang. 2017. Interactive attention networks for aspect-level sentiment classification. In *International Joint Conference on Artificial Intelligence*, pages 4068–4074.

Julian McAuley and Jure Leskovec. 2013. Hidden factors and hidden topics: understanding rating dimensions with review text. In *Proceedings of the 7th ACM conference on Recommender systems*, pages 165–172.

Sajad Movahedi, Erfan Ghadery, Heshaam Faili, and Azadeh Shakery. 2019. Aspect category detection via topic-attention network.

Haiyun Peng, Erik Cambria, and Amir Hussain. 2017. A review of sentiment analysis research in chinese language. *Cognitive Computation*, 9(4):423–435.

Jeffrey Pennington, Richard Socher, and Christopher Manning. 2014. Glove: Global vectors for word representation. In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pages 1532–1543.

Maria Pontiki, Dimitrios Galanis, Haris Papageorgiou, Suresh Manandhar, and Ion Androutsopoulos. 2015. Semeval-2015 task 12: Aspect based sentiment

analys. In *International Workshop on Semantic Evaluation (SemEval 2015)*.

Maria Pontiki, Dimitrios Galanis, John Pavlopoulos, Haris Papageorgiou, Ion Androutsopoulos, and Suresh Manandhar. 2014. Semeval-2014 task 4: Aspect based sentiment analysis. In *International Workshop on Semantic Evaluation (SemEval 2015)*.

Maria Pontiki, Dimitris Galanis, Haris Papageorgiou, Ion Androutsopoulos, Suresh Manandhar, AL-Smadi Mohammad, Mahmoud Al-Ayyoub, Yanyan Zhao, Bing Qin, Orphée De Clercq, et al. 2016. Semeval-2016 task 5: Aspect based sentiment analysis. In *Proceedings of the 10th international workshop on semantic evaluation (SemEval-2016)*, pages 19–30.

Sebastian Ruder, Parsa Ghaffari, and John G. Breslin. 2016. A hierarchical model of reviews for aspect-based sentiment analysis.

Sara Sabour, Nicholas Frosst, and Geoffrey E Hinton. 2017. Dynamic routing between capsules. In *Advances in neural information processing systems*, pages 3856–3866.

Yan Song, Shuming Shi, Jing Li, and Haisong Zhang. 2018. Directional skip-gram: Explicitly distinguishing left and right context for word embeddings. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers)*, pages 175–180.

Chi Sun, Luyao Huang, and Xipeng Qiu. 2019. Utilizing bert for aspect-based sentiment analysis via constructing auxiliary sentence. *arXiv preprint arXiv:1903.09588*.

Songbo Tan and Jin Zhang. 2008. An empirical study of sentiment analysis for chinese documents. *Expert Systems with applications*, 34(4):2622–2629.

Yequan Wang, Minlie Huang, and Li Zhao. 2016. Attention-based lstm for aspect-level sentiment classification. In *Empirical Methods in Natural Language Processing*, pages 606–615.

Chuhan Wu, Fangzhao Wu, Junxin Liu, Yongfeng Huang, and Xing Xie. 2019a. Arp: Aspect-aware neural review rating prediction. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management*, pages 2169–2172.

Chuhan Wu, Fangzhao Wu, Junxin Liu, Yongfeng Huang, and Xing Xie. 2019b. Arp: Aspect-aware neural review rating prediction. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management*, pages 2169–2172.

Hu Xu, Bing Liu, Lei Shu, and Philip S Yu. 2019. Bert post-training for review reading comprehension and aspect-based sentiment analysis. *arXiv preprint arXiv:1904.02232*.

Taras Zagibalov and John A Carroll. 2008. Unsupervised classification of sentiment and objectivity in chinese text. In *Proceedings of the Third International Joint Conference on Natural Language Processing: Volume-I*.

Yanyan Zhao, Bing Qin, and Ting Liu. 2014. Creating a fine-grained corpus for chinese sentiment analysis. *IEEE Intelligent Systems*, 30(1):36–43.

Peng Zhou, Wei Shi, Jun Tian, Zhenyu Qi, Bingchen Li, Hongwei Hao, and Bo Xu. 2016. Attention-based bidirectional long short-term memory networks for relation classification. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 207–212.

Xinjie Zhou, Xiaojun Wan, and Jianguo Xiao. 2015. Representation learning for aspect category detection in online reviews. In *Twenty-ninth Aaai Conference on Artificial Intelligence*.

From Paraphrasing to Semantic Parsing: Unsupervised Semantic Parsing via Synchronous Semantic Decoding

Shan Wu[1,3], **Bo Chen**[1], **Chunlei Xin**[1,3], **Xianpei Han**[1,2,*], **Le Sun**[1,2,*],
Weipeng Zhang[4], **Jiansong Chen**[4], **Fan Yang**[4], **Xunliang Cai**[4]
[1]Chinese Information Processing Laboratory [2]State Key Laboratory of Computer Science
Institute of Software, Chinese Academy of Sciences, Beijing, China
[3]University of Chinese Academy of Sciences, Beijing, China [4]Meituan
{wushan2018,chenbo,xianpei,sunle}@iscas.ac.cn,
xinchunlei20@mails.ucas.ac.cn,
{zhangweipeng02,chenjiansong,yangfan79,caixunliang}@meituan.com

Abstract

Semantic parsing is challenging due to the structure gap and the semantic gap between utterances and logical forms. In this paper, we propose an unsupervised semantic parsing method – Synchronous Semantic Decoding (SSD), which can simultaneously resolve the semantic gap and the structure gap by jointly leveraging paraphrasing and grammar-constrained decoding. Specifically, we reformulate semantic parsing as a constrained paraphrasing problem: given an utterance, our model synchronously generates its canonical utterance[1] and meaning representation. During synchronous decoding: the utterance paraphrasing is constrained by the structure of the logical form, therefore the canonical utterance can be paraphrased controlledly; the semantic decoding is guided by the semantics of the canonical utterance, therefore its logical form can be generated unsupervisedly. Experimental results show that SSD is a promising approach and can achieve competitive unsupervised semantic parsing performance on multiple datasets.

1 Introduction

Semantic parsing aims to translate natural language utterances to their formal meaning representations, such as lambda calculus (Zettlemoyer and Collins, 2005; Wong and Mooney, 2007), FunQL (Kate et al., 2005; Lu et al., 2008), and SQL queries. Currently, most neural semantic parsers (Dong and Lapata, 2016; Chen et al., 2018b; Zhao et al., 2020; Shao et al., 2020) model semantic parsing as a sequence to sequence translation task via encoder-decoder framework.

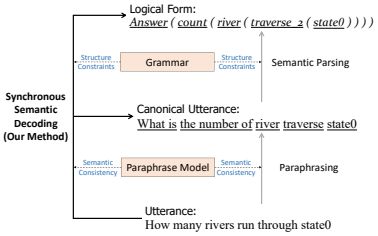

Figure 1: Different from previous staged methods (indicated by gray lines), our method generates canonical utterance and logical form synchronously. The semantic gap and the structure gap are simultaneously resolved by jointly leveraging paraphrasing and grammar-constrained decoding. Thus, our synchronous decoding employs both the semantic and the structure constraints to solve unsupervised semantic parsing.

Semantic parsing is a challenging task due to the structure gap and the semantic gap between natural language utterances and logical forms. For structure gap, because utterances are usually word sequences and logical forms are usually trees/graphs constrained by specific grammars, a semantic parser needs to learn the complex structure transformation rules between them. For semantic gap, because the flexibility of natural languages, the same meaning can be expressed using very different utterances, a semantic parser needs be able to map various expressions to their semantic form. To address the structure gap and the semantic gap, current semantic parsers usually rely on a large amount of labeled data, often resulting in data bottleneck problem.

Previous studies have found that the structure gap and the semantic gap can be alleviated by leveraging external resources, therefore the reliance on data can be reduced. For structure gap, previous studies found that constrained decoding can effectively constrain the output structure by injecting grammars of logical forms and facts in

*Corresponding Author

[1]Canonical utterances are pseudo-language representations of logical forms, which have the synchronous structure of logical forms.(Berant and Liang, 2014; Xiao et al., 2016; Su and Yan, 2017; Cao et al., 2020)

knowledge bases during inference. For example, the grammar-based neural semantic parsers (Xiao et al., 2016; Yin and Neubig, 2017) and the constrained decoding algorithm (Krishnamurthy et al., 2017). For semantic gap, previous studies have found that paraphrasing is an effective technique for resolving the diversity of natural expressions. Using paraphrasing, semantic parsers can handle the different expressions of the same meaning, therefore can reduce the requirement of labeled data. For example, supervised methods (Berant and Liang, 2014; Su and Yan, 2017) use the paraphrasing scores between canonical utterances and sentences to re-rank logical forms; Two-stage (Cao et al., 2020) rewrites utterances to canonical utterances which can be easily parsed. The main drawback of these studies is that they use constrained decoding and paraphrasing independently and separately, therefore they can only alleviate either semantic gap or structure gap.

In this paper, we propose an unsupervised semantic parsing method – *Synchronous Semantic Decoding (SSD)*, which can simultaneously resolve the structure gap and the semantic gap by jointly leveraging paraphrasing and grammar-constrained decoding. Specifically, we model semantic parsing as a constrained paraphrasing task: given an utterance, we synchronously decode its canonical utterance and its logical form using a general paraphrase model, where the canonical utterance and the logical form share the same underlying structure. Based on the synchronous decoding, the canonical utterance generation can be constrained by the structure of logical form, and the logical form generation can be guided by the semantics of canonical form. By modeling the interdependency between canonical utterance and logical form, and exploiting them through synchronous decoding, our method can perform effective unsupervised semantic parsing using only pretrained general paraphrasing model – no annotated data for semantic parsing is needed.

We conduct experiments on GEO and OVERNIGHT. Experimental results show that our method is promising, which can achieve competitive unsupervised semantic parsing performance, and can be further improved with external resources. The main contributions of this paper are:

- We propose an unsupervised semantic parsing method – Synchronous Semantic Decoding , which can simultaneously resolve the semantic gap and the structure gap by jointly leveraging paraphrasing and grammar-constrained semantic decoding.
- We design two effective synchronous semantic decoding algorithms – rule-level inference and word-level inference, which can generate paraphrases under the grammar constraints and synchronously decode meaning representations.
- Our model achieves competitive unsupervised semantic parsing performance on GEO and OVERNIGHT datasets.

2 Model Overview

We now present overview of our synchronous semantic decoding algorithm, which can jointly leverage paraphrasing and grammar-constrained decoding for unsupervised semantic parsing. Given an utterance, SSD reformulates semantic parsing as a constrained paraphrasing problem, and synchronously generates its canonical utterance and logical form. For example in Fig. 2, given "How many rivers run through Texas", SSD generates "What is the number of river traverse State0" as its canonical form and `Answer(Count(River(Traverse_2(State0))))` as its logical form. During synchronous decoding: the utterance paraphrase generation is constrained by the grammar of logical forms, therefore the canonical utterance can be generated controlledly; the logical form is generated synchronously with the canonical utterance via synchronous grammar. Logical form generation is controlled by the semantic constraints from paraphrasing and structure constraints from grammars and database schemas. Therefore the logical form can be generated unsupervisedly.

To this end, SSD needs to address two challenges. Firstly, we need to design paraphrasing-based decoding algorithms which can effectively impose grammar constraints on inference. Secondly, current paraphrasing models are trained on natural language sentences, which are different from the unnatural canonical utterances. Therefore SSD needs to resolve this style bias for effective canonical utterance generation.

Specifically, we first propose two inference algorithms for constrained paraphrasing based syn-

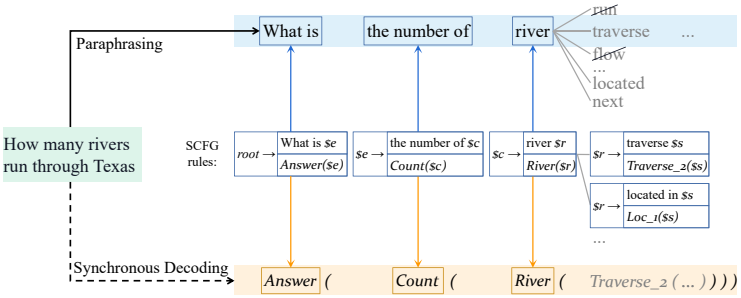

Figure 2: Overview of our approach. The sentence is paraphrased to canonical utterance and parsed to logical form synchronously. When decoding "traverse", the paraphrase model tends to generate the words such as "run", "flow", "traverse" to preserve semantics. And synchronous grammar limits the next words of the canonical utterance to follow the candidate production rules. Then it is easy to discard "run" and "flow", and select the most likely word "traverse" with its production rule from the candidates. In this parper, we propose rule-level and word-level inference methods to decode words and production rules synchronously.

chronous semantic decoding: rule-level inference and word-level inference. Then we resolve the style bias of paraphrase model via adaptive fine-tuning and utterance reranking, where adaptive fine-tuning can adjust the paraphrase model to generate canonical utterances, and utterance reranking resolves the style bias by focusing more on semantic coherence. In Sections 3-5, we provide the details of our implementation.

3 Synchronous Semantic Decoding

Given an utterance x, we turn semantic parsing into a constrained paraphrasing task. Concretely, we use synchronous context-free grammar as our synchronous grammar, which provides a one-to-one mapping from a logical form y to its canonical utterance c^y. The parsing task $\hat{y} = \arg\max_{y \in \mathcal{Y}} p_{\text{parse}}(y|x)$ is then transferred to $\hat{y} = \arg\max_{y \in \mathcal{Y}} p_{\text{paraphrase}}(c^y|x)$. Instead of directly parsing utterance into its logical form, SSD generates its canonical utterance and obtains its logical form based on the one-to-one mapping relation. In following we first introduce the grammar constraints in decoding, and then present two inference algorithms for generating paraphrases under the grammar constraints.

3.1 Grammar Constraints in Decoding

Synchronous context-free grammar(SCFG) is employed as our synchronous grammar, which is widely used to convert a meaning representation into an unique canonical utterance (Wang et al., 2015; Jia and Liang, 2016). An SCFG consists of a set of production rules: $N \rightarrow \langle \alpha, \beta \rangle$, where N is a non-terminal, and α and β are sequence of terminal and non-terminal symbols. Each non-terminal symbol in α is aligned to the same non-terminal symbol in β, and vice versa. Therefore, an SCFG defines a set of joint derivations of aligned pairs of utterances and logical forms.

SCFGs can provide useful constraints for semantic decoding by restricting the decoding space and exploiting the semantic knowledge:

Grammar Constraints The grammars ensure the generated utterances/logical forms are grammar-legal. In this way the search space can be greatly reduced. For example, when expanding the non-terminal `$r` in Fig 2 we don't need to consider the words "run" and "flow", because they are not in the candidate grammar rules.

Semantic Constraints Like the type checking in Wang et al. (2015), the constraints of knowledge base schema can be integrated to further refine the grammar. The semantic constraints ensure the generated utterances/logical forms will be semantically valid.

3.2 Decoding

3.2.1 Rule-Level Inference

One strategy to generate paraphrase under the grammar constraint is taking the grammar rule as the decoding unit. Grammar-based decoders have been proposed to output sequences of grammar rules instead of words(Yin and Neubig, 2017). Like them, our rule-level inference method takes the grammar rule as the decoding unit. Figure 3 (a) shows an example of our rule level inference method.

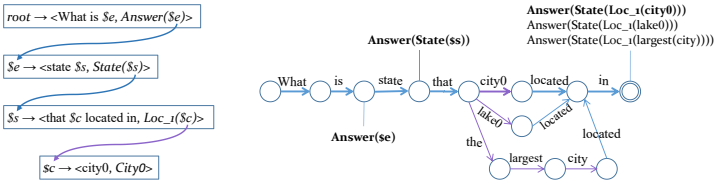

(a) Rule-Level Inference (b) Word-Level Inference

Figure 3: From the utterance "*which state is city0 in*", two inference methods generate its canonical utterance "*what is state that city0 located in*" and its logical form `Answer(State(Loc_1(City0)))`. The ways they handle non-terminal `$c` which is not at the end of utterance-side production rule are represented by purple lines.

Algorithm 1: Rule-level inference

Input : input utterance x, paraphrasing model $Para$, beam size B, maximum output length L, SCFG rules R, maximum search depth K;

$beam_0 \leftarrow \{\langle s \rangle\}$
$outputs \leftarrow \{\}$
for $t = 1$ **to** L **do**
  for hypothesis c **in** $beam_{t-1}$ **do**
    for r **in** expand rules for c **do**
      if all non-terminals in r_β are on the right **then**
        $c' \leftarrow \text{Expand}(c, r)$
        $beam_t \leftarrow beam_t \cup \{c'\}$
      else
        $c' \leftarrow \text{expand}(c, r)$
        $beam_t^{c'} \leftarrow \{c'\}$
        for $k = 1$ **to** K **do**
          for hypothesis h **in** $beam_{t+k-1}^{c'}$ **do**
            $r_h \leftarrow$ expand rules for h's first non-terminal
            $beam_{t+k}^{c'} \leftarrow beam_{t+k}^{c'} \cup \text{Expand}(h, r_h)$
          $beam_{t+k}^{c'} \leftarrow \text{NBest}(beam_{t+k}^{c'}, B)$
          Move utterances from $beam_{t+k}^{c'}$ to $beam_{t+k}$, if non-terminals are on the right of the utterances.
  $beam_t \leftarrow \text{NBest}(beam_t, B - |outputs|)$
  Move full utterances from $beam_t$ to $outputs$
  if $beam_t$ *is empty* **then**
    return $outputs$
return $outputs$

When the non-terminal in the utterance-side production rule is at the end of the rule (e.g., $e → ⟨state $s, `State($s)`⟩), denoting the utterance-side production rule as $r_\beta = [w_1, w_2, ..., w_{L_r}, N]$, we can simply expand non-terminals in canonical utterances by this rule, and generate the canonical utterances from left to right with probabilities computed by:

$$P(c^{y \le t}|x) = P(c^{y<t}|x) \prod_{i=1}^{L_r} P_{\text{paraphrase}}(w_i|x, c^{y<t}, w_{<i}) \quad (1)$$

Otherwise, we generate the next production rules to expand this rule (i.e., rule with purple line), until there is no non-terminal on the left of words, or the generating step reaches the depth of K. We use beam search during the inference. The inference details are described in Algorithm 1.

3.2.2 Word-Level Inference

Except for rule-level inference, we also propose a word-level inference algorithm, which generates paraphrases word by word under the SCFG constraints.

Firstly, we construct a deterministic automaton using LR(1) parser (Knuth, 1965) from the CFG in utterance side. The automaton can transit from one state to another in response to an input. The inputs of the automaton are words and the states of it are utterance/logical form segments. LR(1) parser peeks ahead one lookahead input symbol, and the state transition table describes the acceptable inputs and the next states.

Then, in each decoding step we generate a word with a new state which is transited from previous state. An example is shown in Figure 3 (b). Only the acceptable words in the current state can be generated, and the end-of-sentence symbol can only be generated when reaching the final state. Beam search is also used in this inference.

4 Adaptive Fine-tuning

The above decoding algorithms only rely on a paraphrase generation model , which generates canonical utterance and logical form synchronously for semantic parsing. We can directly use general paraphrase generation models such as GPT-2(Radford et al., 2019), T5(Raffel et al., 2020) for SSD. However, as described in above, there exists a style bias between natural language sentences and canonical utterances, which hurts the performance of unsupervised semantic par-

ing. In this section, we describe how to alleviate this bias via adaptive fine-tuning. Given a text generation model, after pretraining it using paraphrase corpus, we fine-tune it using synthesized ⟨`sentence`, `canonical utterance`⟩ pairs.

Previous studies have shown that the pretraining on synthesized data can significantly improve the performance of semantic parsing (Xu et al., 2020a; Marzoev et al., 2020; Yu et al., 2020; Xu et al., 2020b). Specifically, we design three data synthesis algorithms:

1) **CUs** We sample CUs from SCFGs, and preserve executable ones. As we do not have the paired sentences, we only fine-tune the language model of the PLMs on CUs.

2) **Self Paras** We use the trained paraphrase model to get the natural language paraphrases of the sampled canonical utterances to form ⟨`sentence`, `canonical utterance`⟩ pairs.

3) **External Paras** We also use external paraphrase methods such as back translation to get the pairs.

5 Utterance Reranking

Adaptive fine-tuning resolves the style bias problem by fitting a better paraphrase model. In this section, we propose an utterance reranking algorithm to further alleviate the style bias by reranking and selecting the best canonical form.

Given the utterance x and top-N parsing results $(y_n, c_n), n = 1, 2, ..., N$, we rerank all candidates by focusing on semantic similarities between x and c_n, so that canonical utterances can be effectively selected. Reranking for semantic parsing has been exploited in many previous studies (Berant and Liang, 2014; Yin and Neubig, 2019). These works employ reranking for canonical utterances selection. Differently, our re-ranker does not need labeled data. Formally, we measure two similarities between x and c_n and the final reranking score is calculated by:

$$score(x, c) = \log p(c|x) + s_{rec}(x, c) + s_{asso}(x, c) \quad (2)$$

Reconstruction Score The reconstruction score measures the coherence and adequacy of the canonical utterances, using the probability of reproducing the original input sentence x from c with the trained paraphrasing model: $s_{rec}(x, c) = \log p_{pr}(x|c)$

Association Score The association score measures whether x and c contain words that are likely to be paraphrases. We calculate it as:

$$s_{asso}(x, c) = \log \prod_{i=1}^{|c|} \sum_{j=0}^{|x|} p(c_i|x_j)\, a(j|i) + \log \prod_{j=1}^{|x|} \sum_{i=0}^{|c|} p(x_j|c_i)\, a(i|j) \quad (3)$$

in which, $p(c_i|x_j)$ means the paraphrase probability from x_j to c_i, and $a(j|i)$ means the alignment probability. The paraphrase probability and alignment are trained and inferred as the translation model in SMT IBM model 2.

6 Experiments

6.1 Experimental Settings

Datasets We conduct experiments on three datasets: OVERNIGHT(λ-DCS), GEO(FunQL), and GEOGRANNO, which use different meaning representations and on different domains. Our implementations are public available[2].

OVERNIGHT This is a multi-domain dataset, which contains natural language paraphrases paired with lambda DCS logical forms across eight domains. We use the same train/test splits as Wang et al. (2015).

GEO(FunQL) This is a semantic parsing benchmark about U.S. geography (Zelle and Mooney, 1996) using the variable-free semantic representation FunQL (Kate et al., 2005). We extend the FunQL grammar to SCFG for this dataset. We follow the standard 600/280 train/test splits.

GEOGRANNO This is another version of GEO (Herzig and Berant, 2019), in which lambda DCS logical forms paired with canonical utterances are produced from SCFG. Instead of paraphrasing sentences, crowd workers are required to select the correct canonical utterance from candidate list. We follow the split (train/valid/test 487/59/278) in original paper.

Paraphrase Model We obtain the paraphrase model by training T5 and GPT2.0 on WikiAnswer Paraphrase[3], we train 10 epochs with learning rate as 1e-5. Follow Li et al. (2019), we sample 500K pairs of sentences in WikiAnswer corpus as training set and 6K as dev set. We generate adaptive fine-tuning datasets proportional to their labeled datasets, and back-translation(from English

[2]https://github.com/lingowu/ssd

[3]http://knowitall.cs.washington.edu/ paralex

	Bas.	Blo.	Cal.	Hou.	Pub.	Rec.	Res.	Soc.	Avg.
Supervised									
RECOMBINATION (Jia and Liang, 2016)	85.2	58.1	78.0	71.4	76.4	79.6	76.2	81.4	75.8
CROSSDOMAIN (Su and Yan, 2017)	86.2	60.2	79.8	71.4	78.9	84.7	81.6	82.9	78.2
SEQ2ACTION (Chen et al., 2018b)	88.2	61.4	81.5	74.1	80.7	82.9	80.7	82.1	79.0
DUAL (Cao et al., 2019)	87.5	63.7	79.8	73.0	81.4	81.5	81.6	83.0	78.9
TWO-STAGE (Cao et al., 2020)	87.2	65.7	80.4	75.7	80.1	86.1	82.8	82.7	**80.1**
SSD (Word-Level)	86.2	64.9	81.7	72.7	82.3	81.7	81.5	82.7	79.2
SSD (Grammar-Level)	86.2	64.9	81.7	72.7	82.3	81.7	81.5	82.7	79.0
Unsupervised (with nonparallel data)									
TWO-STAGE (Cao et al., 2020)	64.7	53.4	58.3	59.3	60.3	68.1	73.2	48.4	60.7
WMDSAMPLES (Cao et al., 2020)	31.9	29.0	36.1	47.9	34.2	41.0	53.8	35.8	38.7
SSD-SAMPLES (Word-Level)	71.7	58.7	60.1	61.7	57.6	64.3	70.9	46.0	61.4
SSD-SAMPLES (Grammar-Level)	71.3	58.8	60.6	62.2	58.8	65.4	71.1	49.1	**62.2**
Unsupervised									
Cross-domain Zero Shot	-	28.3	53.6	52.4	55.3	60.2	61.7	-	-
GENOVERNIGHT	15.6	27.7	17.3	45.9	46.7	26.3	61.3	9.7	31.3
SYNTH-SEQ2SEQ	16.1	23.6	16.1	30.2	36.6	26.9	43.1	9.2	25.2
SYNTHPARA-SEQ2SEQ	28.4	37.3	33.9	38.1	39.1	41.7	62.7	23.3	38.1
SSD (Word-Level)	68.3	54.9	51.2	55.0	54.7	60.2	65.4	33.6	55.4
SSD (Grammar-Level)	68.8	58.1	56.5	56.1	57.8	59.3	66.9	37.1	**57.6**

Table 1: Overall results on OVERNIGHT.

to Chinese then translate back) is used to obtain external paraphrases data. On average, we sample 423 CUs per domain, and synthesize 847 instances per domain in Self Paras and 1252 in External Paras.

Unsupervised settings In unsupervised settings, we do not use any annotated semantic parsing data. The paraphrase generation models are fixed after the paraphrasing pre-training and the adaptive fine-tuning. The models are employed to generate canonical utterances and MRs synchronously via rule-level or word-level inference. In rule-level inference, the leftmost nonterminators are eliminated by cyclically expanded and the maximum depth K is set to 5, the beam size is set to 20. SSD uses T5 as the pre-trained language model in all the proposed components, including adaptive fine-tuning, reranking and the two decoding constraints. Ablation experiments are conducted over all components with rule-level inference.

Unsupervised settings (with external nonparallel data) Cao et al. (2020) have shown that external nonparallel data (including nonparallel natural language utterances and canonical utterances) can be used to build unsupervised semantic parsers. For fair comparison, we also conduct unsupervised experiments with external unparallel data. Specifically, we enhance the original SSD using the SAMPLES methods (Cao et al., 2020): we label each input sentences with the most possible outputs in the nonparallel corpus and use these samples as peusdo training data – we denote this setting as SSD-SAMPLES.

Supervised settings Our SSD method can be further enhanced using annotated training instances. Specifically, given the annotated ⟨utterance, logical form⟩ instances, we first transform logical form to its canonical form, then use them to further fine-tune our paraphrase models after unsupervised pre-training.

Baselines We compare our method with the following unsupervised baselines: 1) Cross-domain Zero Shot(Herzig and Berant, 2018), which trains on other source domains and then generalizes to target domains in OVERNIGHT and 2) GENOVERNIGHT(Wang et al., 2015) in which models are trained on synthesized ⟨CU, MR⟩ pairs; 3) We also implement SEQ2SEQ baseline on the synthesized data as SYNTH-SEQ2SEQ. 4) SYNTHPARA-SEQ2SEQ is trained on the synthesized data and ⟨CU paraphrase, MR⟩ pairs, the paraphrases are obtained in the same way in Section 4.

6.2 Experimental Results

6.2.1 Overall Results

The overall results of different baselines and our method are shown in Table 1 and Table 3 (We also demonstrate several cases in Appendix). For our

	Bas.	Blo.	Cal.	Hou.	Pub.	Rec.	Res.	Soc.	OVERN. Avg.	GEO GRANNO	GEO (FUNQL)
COMPLETEMODEL	68.8	58.1	56.5	56.1	57.8	59.3	66.9	37.1	**57.6**	**58.5**	**63.2**
Constraints											
- SEMANTIC	65.5	54.4	52.4	51.9	56.5	57.4	62.0	35.7	54.5	56.5	61.1
- GRAMMAR	63.9	52.1	47.6	50.3	45.3	52.3	56.3	29.9	49.7	50.7	53.9
Adaptive Fine-tuning											
- EXTERNAL PARAS	66.8	56.6	51.6	54.0	48.4	56.9	63.3	32.4	53.8	56.5	61.1
- PARAS (Only CUs)	64.5	55.4	50.0	51.3	47.8	55.6	62.0	31.7	52.3	54.3	59.6
- FINE-TUNING	63.9	53.6	48.4	47.6	44.9	53.2	62.5	31.4	50.7	51.8	55.4
Reranking											
- RERANKING	58.2	57.2	56.3	50.2	55.7	58.0	62.9	37.7	54.6	57.2	62.5
ORACLE (R@20)	71.2	83.2	86.9	76.9	82.7	86.9	88.1	62.8	79.8	70.9	81.4
Pretrained Language Models											
GPT-2	67.0	54.6	53.7	55.7	56.1	58.9	66.4	32.7	55.6	58.3	62.1
RAND	58.3	48.6	45.8	47.6	50.3	55.6	54.5	30.3	48.9	51.4	54.3

Table 2: Albation results of our model with different settings on the three datasets.

	GEO GRANNO	GEO (FUNQL)
Supervised		
DEPHT (Jie and Lu, 2018)	-	89.3
COPYNET (Herzig and Berant, 2019)	72.0	-
One-stage (Cao et al., 2020)	71.9	-
Two-stage (Cao et al., 2020)	71.6	-
SEQ2SEQ (Guo et al., 2020)	-	87.1
SSD (Word-Level)	72.9	88.3
SSD (Grammar-Level)	72.0	87.9
Unsupervised (with nonparallel data)		
Two-stage (Cao et al., 2020)	63.7	-
WMDSAMPLES (Cao et al., 2020)	35.3	-
SSD-SAMPLES (Word-Level)	64.0	64.3
SSD-SAMPLES (Grammar-Level)	**64.4**	**65.0**
Unsupervised		
SYNTH-SEQ2SEQ	32.7	36.1
SYNTHPARA-SEQ2SEQ	41.4	45.4
SSD (Word-Level)	57.2	62.8
SSD (Grammar-Level)	**58.5**	**63.2**

Table 3: Overall results on GEOGRANNO and GEO(FunQL).

method, we report its performances on three settings. We can see that:

1. **By synchronously decoding canonical utterances and meaning representations, SSD achieves competitive unsupervised semantic parsing performance.** In all datasets, our method outperforms other baselines in the unsupervised settings. These results demonstrate that unsupervised semantic parsers can be effectively built by simultaneously exploit semantic and structural constraints, without the need of labeled data.

2. **Our model can achieve competitive performance on different datasets with different settings.** In supervised settings, our model can achieve competitive performance with SOTA. With nonparallel data, our model can outperform Two-stage. On GEO(FunQL) our model also obtains a significant improvement compared with baselines, which also verifies that our method is not limited to specific datasets (i.e., OVERNIGHT and GEOGRANNO, which are constructed with SCFG and paraphrasing.)

3. **Both rule-level inference and word-level inference can effectively generate paraphrases under the grammar constraints.** The rule-level inference can achieve better performance, we believe this is because rule-level inference is more compact than word-level inference, therefore the rule-level inference can search wider space and benefit beam search more.

6.2.2 Detailed Analysis

Effect of Decoding Constraints To analyze the effect of decoding constraints, we conduct ablation experiments with different constraint settings and the results are shown in Table 2: -SEMANTIC denotes removing the semantic constraint, -GRAMMAR denotes all constraints are removed at the same time, the decoding is unrestricted. We can see that the constrained decoding is critical for our paraphrasing-based semantic parsing, and both grammar constraints and semantic constraints contribute to the improvement.

Effect of Adaptive Fine-tuning To analyze the effect of adaptive fine-tuning, we show the results with different settings by ablating a fine-tuning corpus at a time (see Table 2). We can see that adaptive fine-tuning can significantly improve the performance. And the paraphrase generation model can be effectively fine-tuned only using CUs or Self Paras, which can be easily constructed.

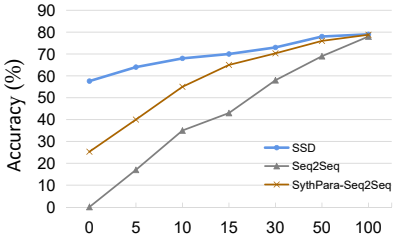

Figure 4: Semi-supervised results of different ratios of labeled data on OVERNIGHT.

Effect of Reranking To analyze the effect of reranking, we compare the settings with/without reranking and its upper bound – Oracle, which can always select the correct logical form if it is within the beam. Experimental results show that reranking can improve the semantic parsing performance. Moreover, there is still a large margin between our method and Oracle, i.e., the unsupervised semantic parsing can be significantly promoted by designing better reranking algorithms.

Effect of Adding Labeled Data To investigate the effect of adding labeled data, we test our method by varying the size of the labeled data on OVERNIGHT from 0% to 100%. In Fig. 4, we can see that our method can outperform baselines using the same labeled data. And a small amount of data can produce a good performance using our method.

Effect of Pretrained Language Models To analyze the effect of PLMs, we show the results with different PLM settings: instead of T5 we use GPT-2 or randomly initialized transformers to construct paraphrasing models. Experimental results show that powerful PLMs can improve the performance. Powered by the language generation models to do semantic parsing, our method can benefit from the rapid development of PLMs.

7 Related Work

Data Scarcity in Semantic Parsing. Witnessed the labeled data bottleneck problem, many techniques have been proposed to reduce the demand for labeled logical forms. Many weakly supervised learning are proposed (Artzi and Zettlemoyer, 2013; Berant et al., 2013; Reddy et al., 2014; Agrawal et al., 2019; Chen et al., 2020), such as denotation-base learning (Pasupat and Liang, 2016; Goldman et al., 2018), iterative searching (Dasigi et al., 2019). Semi-supervised semantic parsing is also proposed(Chen et al., 2018a). Such as variational auto-encoding (Yin et al., 2018), dual learning framework for semantic parsing (Cao et al., 2019), dual information maximization method (Ye et al., 2019), and back-translation (Sun et al., 2019). One other strategy is to generate data for semantic parsing, e.g., Wang et al. (2015) construct a semantic parsing dataset from grammar rules and crowdsourcing paraphrase. Guo et al. (2018) produce pseudo-labeled data. Jia and Liang (2016) create new "recombinant" training examples with SCFG. The domain transfer techniques are also used to reduce the cost of data collecting for the unseen domain (Su and Yan, 2017; Herzig and Berant, 2018; Lu et al., 2019; Zhong et al., 2020). Goldwasser et al. (2011); Poon and Domingos (2009); Schmitt et al. (2020) leverage external resources or techniques for unsupervised learning.

Constrained Decoding. After neural parsers model semantic parsing as a sentence to logical form translation task (Yih et al., 2015; Krishnamurthy et al., 2017; Iyyer et al., 2017; Jie and Lu, 2018; Lindemann et al., 2020), many constrained decoding algorithms are also proposed, such as type constraint-based illegal token filtering (Krishnamurthy et al., 2017); Lisp interpreter-based method (Liang et al., 2017); type constraints for generating valid actions (Iyyer et al., 2017).

Paraphrasing in Semantic Parsing. Paraphrase models have been widely used in semantic parsing. ParaSempre (Berant and Liang, 2014) use paraphrase model to rerank candidate logical forms. Wang et al. (2015) employ SCFG grammar rules to produce MR and canonical utterance pairs, and construct OVERNIGHT dataset by paraphrasing utterances. Dong et al. (2017) use paraphrasing to expand the expressions of query sentences. Compared with these methods, we combine paraphrasing with grammar-constrained decoding, therefore SSD can further reduce the requirement of labeled data and achieve unsupervised semantic parsing.

8 Conclusions

We propose an unsupervised semantic parsing method – Synchronous Semantic Decoding, which leverages paraphrasing and grammar-constrained decoding to simultaneously resolve the semantic gap and the structure gap. Specifically, we design

two synchronous semantic decoding algorithms for paraphrasing under grammar constraints, and exploit adaptive fine-tuning and utterance reranking to alleviate the style bias in semantic parsing. Experimental results show that our approach can achieve competitive performance in unsupervised settings.

Acknowledgments

We sincerely thank the reviewers for their insightful comments and valuable suggestions. Moreover, this work is supported by the National Key Research and Development Program of China(No. 2020AAA0106400), the National Natural Science Foundation of China under Grants no. 61906182 and 62076233, and in part by the Youth Innovation Promotion Association CAS(2018141).

References

Priyanka Agrawal, Ayushi Dalmia, Parag Jain, Abhishek Bansal, Ashish R. Mittal, and Karthik Sankaranarayanan. 2019. Unified semantic parsing with weak supervision. In *Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28- August 2, 2019, Volume 1: Long Papers*, pages 4801–4810.

Yoav Artzi and Luke Zettlemoyer. 2013. Weakly supervised learning of semantic parsers for mapping instructions to actions. *TACL*, 1:49–62.

Jonathan Berant, Andrew Chou, Roy Frostig, and Percy Liang. 2013. Semantic parsing on freebase from question-answer pairs. In *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing, EMNLP 2013, 18-21 October 2013, Grand Hyatt Seattle, Seattle, Washington, USA, A meeting of SIGDAT, a Special Interest Group of the ACL*, pages 1533–1544.

Jonathan Berant and Percy Liang. 2014. Semantic parsing via paraphrasing. In *Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics, ACL 2014, June 22-27, 2014, Baltimore, MD, USA, Volume 1: Long Papers*, pages 1415–1425.

Ruisheng Cao, Su Zhu, Chen Liu, Jieyu Li, and Kai Yu. 2019. Semantic parsing with dual learning. In *Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28- August 2, 2019, Volume 1: Long Papers*, pages 51–64.

Ruisheng Cao, Su Zhu, Chenyu Yang, Chen Liu, Rao Ma, Yanbin Zhao, Lu Chen, and Kai Yu. 2020. Unsupervised dual paraphrasing for two-stage semantic parsing. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, ACL 2020, Online, July 5-10, 2020*, pages 6806–6817. Association for Computational Linguistics.

Bo Chen, Bo An, Le Sun, and Xianpei Han. 2018a. Semi-supervised lexicon learning for wide-coverage semantic parsing. In *Proceedings of the 27th International Conference on Computational Linguistics, COLING 2018, Santa Fe, New Mexico, USA, August 20-26, 2018*, pages 892–904. Association for Computational Linguistics.

Bo Chen, Xianpei Han, Ben He, and Le Sun. 2020. Learning to map frequent phrases to sub-structures of meaning representation for neural semantic parsing. In *The Thirty-Fourth AAAI Conference on Artificial Intelligence, AAAI 2020, The Thirty-Second Innovative Applications of Artificial Intelligence Conference, IAAI 2020, The Tenth AAAI Symposium on Educational Advances in Artificial Intelligence, EAAI 2020, New York, NY, USA, February 7-12, 2020*, pages 7546–7553. AAAI Press.

Bo Chen, Le Sun, and Xianpei Han. 2018b. Sequence-to-action: End-to-end semantic graph generation for semantic parsing. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, ACL 2018, Melbourne, Australia, July 15-20, 2018, Volume 1: Long Papers*, pages 766–777.

Pradeep Dasigi, Matt Gardner, Shikhar Murty, Luke Zettlemoyer, and Eduard H. Hovy. 2019. Iterative search for weakly supervised semantic parsing. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2019, Minneapolis, MN, USA, June 2-7, 2019, Volume 1 (Long and Short Papers)*, pages 2669–2680.

Li Dong and Mirella Lapata. 2016. Language to logical form with neural attention. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics, ACL 2016, August 7-12, 2016, Berlin, Germany, Volume 1: Long Papers*.

Li Dong, Jonathan Mallinson, Siva Reddy, and Mirella Lapata. 2017. Learning to paraphrase for question answering. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, EMNLP 2017, Copenhagen, Denmark, September 9-11, 2017*, pages 875–886.

Omer Goldman, Veronica Latcinnik, Ehud Nave, Amir Globerson, and Jonathan Berant. 2018. Weakly supervised semantic parsing with abstract examples. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, ACL 2018, Melbourne, Australia, July 15-20, 2018, Volume 1: Long Papers*, pages 1809–1819.

Dan Goldwasser, Roi Reichart, James Clarke, and Dan Roth. 2011. Confidence driven unsupervised semantic parsing. In *The 49th Annual Meeting of the Asso-*

ciation for Computational Linguistics: Human Language Technologies, Proceedings of the Conference, 19-24 June, 2011, Portland, Oregon, USA, pages 1486–1495.

Daya Guo, Yibo Sun, Duyu Tang, Nan Duan, Jian Yin, Hong Chi, James Cao, Peng Chen, and Ming Zhou. 2018. Question generation from SQL queries improves neural semantic parsing. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, Brussels, Belgium, October 31 - November 4, 2018*, pages 1597–1607.

Jiaqi Guo, Qian Liu, Jian-Guang Lou, Zhenwen Li, Xueqing Liu, Tao Xie, and Ting Liu. 2020. Benchmarking meaning representations in neural semantic parsing. In *EMNLP*.

Jonathan Herzig and Jonathan Berant. 2018. Decoupling structure and lexicon for zero-shot semantic parsing. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, Brussels, Belgium, October 31 - November 4, 2018*, pages 1619–1629.

Jonathan Herzig and Jonathan Berant. 2019. Don't paraphrase, detect! rapid and effective data collection for semantic parsing. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing, EMNLP-IJCNLP 2019, Hong Kong, China, November 3-7, 2019*, pages 3808–3818. Association for Computational Linguistics.

Mohit Iyyer, Wen-tau Yih, and Ming-Wei Chang. 2017. Search-based neural structured learning for sequential question answering. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, ACL 2017, Vancouver, Canada, July 30 - August 4, Volume 1: Long Papers*, pages 1821–1831.

Robin Jia and Percy Liang. 2016. Data recombination for neural semantic parsing. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics, ACL 2016, August 7-12, 2016, Berlin, Germany, Volume 1: Long Papers*.

Zhanming Jie and Wei Lu. 2018. Dependency-based hybrid trees for semantic parsing. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, Brussels, Belgium, October 31 - November 4, 2018*, pages 2431–2441.

Rohit J. Kate, Yuk Wah Wong, and Raymond J. Mooney. 2005. Learning to transform natural to formal languages. In *Proceedings, The Twentieth National Conference on Artificial Intelligence and the Seventeenth Innovative Applications of Artificial Intelligence Conference, July 9-13, 2005, Pittsburgh, Pennsylvania, USA*, pages 1062–1068.

Donald E. Knuth. 1965. On the translation of languages from left to right. *Inf. Control.*, 8(6):607–639.

Jayant Krishnamurthy, Pradeep Dasigi, and Matt Gardner. 2017. Neural semantic parsing with type constraints for semi-structured tables. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, EMNLP 2017, Copenhagen, Denmark, September 9-11, 2017*, pages 1516–1526.

Zichao Li, Xin Jiang, Lifeng Shang, and Qun Liu. 2019. Decomposable neural paraphrase generation. In *Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28- August 2, 2019, Volume 1: Long Papers*, pages 3403–3414.

Chen Liang, Jonathan Berant, Quoc Le, Kenneth D. Forbus, and Ni Lao. 2017. Neural symbolic machines: Learning semantic parsers on freebase with weak supervision. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics, ACL 2017, Vancouver, Canada, July 30 - August 4, Volume 1: Long Papers*, pages 23–33.

Matthias Lindemann, Jonas Groschwitz, and Alexander Koller. 2020. Fast semantic parsing with well-typedness guarantees. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, EMNLP 2020, Online, November 16-20, 2020*, pages 3929–3951. Association for Computational Linguistics.

Wei Lu, Hwee Tou Ng, Wee Sun Lee, and Luke S. Zettlemoyer. 2008. A generative model for parsing natural language to meaning representations. In *2008 Conference on Empirical Methods in Natural Language Processing, EMNLP 2008, Proceedings of the Conference, 25-27 October 2008, Honolulu, Hawaii, USA, A meeting of SIGDAT, a Special Interest Group of the ACL*, pages 783–792.

Zhichu Lu, Forough Arabshahi, Igor Labutov, and Tom M. Mitchell. 2019. Look-up and adapt: A one-shot semantic parser. *CoRR*, abs/1910.12197.

Alana Marzoev, Samuel Madden, M. Frans Kaashoek, Michael J. Cafarella, and Jacob Andreas. 2020. Unnatural language processing: Bridging the gap between synthetic and natural language data. *CoRR*, abs/2004.13645.

Panupong Pasupat and Percy Liang. 2016. Inferring logical forms from denotations. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics, ACL 2016, August 7-12, 2016, Berlin, Germany, Volume 1: Long Papers*.

Hoifung Poon and Pedro M. Domingos. 2009. Unsupervised semantic parsing. In *Proceedings of the 2009 Conference on Empirical Methods in Natural Language Processing, EMNLP 2009, 6-7 August 2009, Singapore, A meeting of SIGDAT, a Special Interest Group of the ACL*, pages 1–10.

Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. 2019. Language models are unsupervised multitask learners.

Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. 2020. Exploring the limits of transfer learning with a unified text-to-text transformer. *J. Mach. Learn. Res.*, 21:140:1–140:67.

Siva Reddy, Mirella Lapata, and Mark Steedman. 2014. Large-scale semantic parsing without question-answer pairs. *Transactions of the Association for Computational Linguistics*, 2:377–392.

Martin Schmitt, Sahand Sharifzadeh, Volker Tresp, and Hinrich Schütze. 2020. An unsupervised joint system for text generation from knowledge graphs and semantic parsing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, EMNLP 2020, Online, November 16-20, 2020*, pages 7117–7130. Association for Computational Linguistics.

Bo Shao, Yeyun Gong, Weizhen Qi, Nan Duan, and Xiaola Lin. 2020. Multi-level alignment pretraining for multi-lingual semantic parsing. In *Proceedings of the 28th International Conference on Computational Linguistics, COLING 2020, Barcelona, Spain (Online), December 8-13, 2020*, pages 3246–3256. International Committee on Computational Linguistics.

Yu Su and Xifeng Yan. 2017. Cross-domain semantic parsing via paraphrasing. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, EMNLP 2017, Copenhagen, Denmark, September 9-11, 2017*, pages 1235–1246.

Yibo Sun, Duyu Tang, Nan Duan, Yeyun Gong, Xiaocheng Feng, Bing Qin, and Daxin Jiang. 2019. Neural semantic parsing in low-resource settings with back-translation and meta-learning. *CoRR*, abs/1909.05438.

Yushi Wang, Jonathan Berant, and Percy Liang. 2015. Building a semantic parser overnight. In *Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing of the Asian Federation of Natural Language Processing, ACL 2015, July 26-31, 2015, Beijing, China, Volume 1: Long Papers*, pages 1332–1342.

Yuk Wah Wong and Raymond J. Mooney. 2007. Learning synchronous grammars for semantic parsing with lambda calculus. In *ACL 2007, Proceedings of the 45th Annual Meeting of the Association for Computational Linguistics, June 23-30, 2007, Prague, Czech Republic*.

Chunyang Xiao, Marc Dymetman, and Claire Gardent. 2016. Sequence-based structured prediction for semantic parsing. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics, ACL 2016, August 7-12, 2016, Berlin, Germany, Volume 1: Long Papers*.

Dongqin Xu, Junhui Li, Muhua Zhu, Min Zhang, and Guodong Zhou. 2020a. Improving AMR parsing with sequence-to-sequence pre-training. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, EMNLP 2020, Online, November 16-20, 2020*, pages 2501–2511. Association for Computational Linguistics.

Silei Xu, Sina J. Semnani, Giovanni Campagna, and Monica S. Lam. 2020b. Autoqa: From databases to QA semantic parsers with only synthetic training data. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, EMNLP 2020, Online, November 16-20, 2020*, pages 422–434. Association for Computational Linguistics.

Hai Ye, Wenjie Li, and Lu Wang. 2019. Jointly learning semantic parser and natural language generator via dual information maximization. In *Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28- August 2, 2019, Volume 1: Long Papers*, pages 2090–2101.

Wen-tau Yih, Ming-Wei Chang, Xiaodong He, and Jianfeng Gao. 2015. Semantic parsing via staged query graph generation: Question answering with knowledge base. In *Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing of the Asian Federation of Natural Language Processing, ACL 2015, July 26-31, 2015, Beijing, China, Volume 1: Long Papers*, pages 1321–1331.

Pengcheng Yin and Graham Neubig. 2017. A syntactic neural model for general-purpose code generation. In *ACL 2017*, pages 440–450. ACL 2017.

Pengcheng Yin and Graham Neubig. 2019. Reranking for neural semantic parsing. In *Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28- August 2, 2019, Volume 1: Long Papers*, pages 4553–4559.

Pengcheng Yin, Chunting Zhou, Junxian He, and Graham Neubig. 2018. Structvae: Tree-structured latent variable models for semi-supervised semantic parsing. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, ACL 2018, Melbourne, Australia, July 15-20, 2018, Volume 1: Long Papers*, pages 754–765.

Tao Yu, Chien-Sheng Wu, Xi Victoria Lin, Bailin Wang, Yi Chern Tan, Xinyi Yang, Dragomir R. Radev, Richard Socher, and Caiming Xiong. 2020. Grappa: Grammar-augmented pre-training for table semantic parsing. *CoRR*, abs/2009.13845.

John M. Zelle and Raymond J. Mooney. 1996. Learning to parse database queries using inductive logic programming. In *Proceedings of the Thirteenth National Conference on Artificial Intelligence and*

Eighth Innovative Applications of Artificial Intelligence Conference, AAAI 96, IAAI 96, Portland, Oregon, USA, August 4-8, 1996, Volume 2., pages 1050–1055.

Luke S. Zettlemoyer and Michael Collins. 2005. Learning to map sentences to logical form: Structured classification with probabilistic categorial grammars. In *UAI '05, Proceedings of the 21st Conference in Uncertainty in Artificial Intelligence, Edinburgh, Scotland, July 26-29, 2005*, pages 658–666.

Yuanyuan Zhao, Weiwei Sun, Junjie Cao, and Xiaojun Wan. 2020. Semantic parsing for english as a second language. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, ACL 2020, Online, July 5-10, 2020*, pages 6783–6794. Association for Computational Linguistics.

Victor Zhong, Mike Lewis, Sida I. Wang, and Luke Zettlemoyer. 2020. Grounded adaptation for zero-shot executable semantic parsing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, EMNLP 2020, Online, November 16-20, 2020*, pages 6869–6882. Association for Computational Linguistics.

A Appendix

A.1 Case Study

In Table 4, we present the cases generated from SSD. Cases show that SSD can output semantics-similar and grammar-legal utterances. In case 1, "take-out" does not appear in paraphrase dataset, we can still efficiently generate the utterances containing it, which shows our constrained-paraphrasing based semantic parser has the generalization ability on unseen words. We found that the parser maintains high recall, covering the correct canonical utterances in our n-best list of predictions. As case 2 shows the designed utterance reranking score can select the best canonical utterances by focusing on coherence and adequacy. With adaptive fine-tuning (case 3), our model can generate the utterances focusing more on semantics to alleviate the style bias.

Cases	$x \rightarrow c$ $logP(c\|x)$	$x \leftarrow c$ $s_{rec}(x,c)$	$x \leftrightarrow c$ $s_{asso}(x,c)$	Overall Reranking Score
Input: restaurants that accept credit cards and offer takeout				
Outputs: restaurant that takes credit cards and that has take-out	-54.2	-3.1	-20.3	**-77.6**
restaurant that has take-out and that takes credit cards	-72.0	-8.8	-20.3	-101.1
restaurant that takes credit cards	-77.2	-22.4	-31.9	-131.5
restaurant that takes credit cards and that takes credit cards	-84.2	-26.7	-28.1	-139.0
Input: meetings held in the same place as the weekly standup meeting				
Outputs: meeting whose date is date of weekly standup	-62.2	-40.2	-67.1	-169.5
meeting whose location is location of weekly standup	-62.7	-22.1	-62.4	**-147.2**
meeting whose location is location that is location of weekly standup	-65.0	-21.1	-63.5	149.6
meeting whose date is at most date of weekly standup	-67.2	-35.8	-73.3	-176.3
Input: meetings held in the same place as the weekly standup meeting				
Outputs: meeting whose location is location of weekly standup	-2.7	-22.1	-62.4	**-86.2**
meeting whose location is location that is location of weekly standup	-6.0	-21.1	-63.5	-90.6
location that is location of weekly standup	-18.0	-32.6	-62.8	-113.4
meeting whose date is date of weekly standup	-31.2	-40.2	-67.1	-138.5

Table 4: Output cases from SSD on OVERNIGHT. The outputs are sorted by the generation score $logP(c|x)$. The underlined canonical utterances are correct. Adaptive fine-tuning is employed in the third case, and not employed in the first two cases. Accuracies on OVERNIGHT. In GENOVERNIGHT Wang et al. (2015), all the canonical utterances are also generated without manual annotation. The previous methods with superscript $*$ means they use different unsupervised settings.

Distant Supervision based Machine Reading Comprehension for Extractive Summarization in Customer Service

Bing Ma[1,2], Cao Liu[2], Jingyu Wang[*,1], Shujie Hu[2],
Fan Yang[2], Xunliang Cai[2], Guanglu Wan[2], Jiansong Chen[2], Jianxin Liao[1]
[1]State Key Laboratory of Networking and Switching Techonology,
Beijing University of Posts and Telecommunications, Beijing 100876, China
[2]Meituan, Beijing 100102, China
{mabing,wangjingyu,liaojianxin}@ebupt.com
{liucao,hushujie,yangfan79,caixunliang,wanguanglu,chenjiansong}@meituan.com

ABSTRACT

Given a long text, the summarization system aims to obtain a shorter highlight while keeping important information on the original text. For customer service, the summaries of most dialogues between an agent and a user focus on several fixed key points, such as user's question, user's purpose, the agent's solution, and so on. Traditional extractive methods are difficult to extract all predefined key points exactly. Furthermore, there is a lack of large-scale and high-quality extractive summarization datasets containing key points. In order to solve the above challenges, we propose a Distant Supervision based Machine Reading Comprehension model for extractive Summarization (DSMRC-S). DSMRC-S transforms the summarization task into the machine reading comprehension problem, to fetch key points from the original text exactly according to the predefined questions. In addition, a distant supervision method is proposed to alleviate the lack of eligible extractive summarization datasets. We conduct experiments on a large-scale summarization dataset collected in customer service scenarios, and the results show that the proposed DSMRC-S outperforms the strong baseline methods by 4 points on ROUGE$_L$.

CCS CONCEPTS

• **Computing methodologies** → **Information extraction**; *Discourse, dialogue and pragmatics*; Supervised learning by classification.

KEYWORDS

Extractive Summarization, Machine Reading Comprehension, Distant Supervision, Customer Service

ACM Reference Format:
Bing Ma[1,2], Cao Liu[2], Jingyu Wang[*,1], Shujie Hu[2], and Fan Yang[2], Xunliang Cai[2], Guanglu Wan[2], Jiansong Chen[2], Jianxin Liao[1]. 2021. Distant Supervision based Machine Reading Comprehension for Extractive Summarization in Customer Service. In *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '21), July 11–15, 2021, Virtual Event, Canada.* ACM, New York, NY, USA, 5 pages. https://doi.org/10.1145/3404835.3463046

*Jingyu Wang is the corresponding author.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
SIGIR '21, July 11–15, 2021, Virtual Event, Canada
© 2021 Copyright held by the owner/author(s). Publication rights licensed to ACM.
ACM ISBN 978-1-4503-8037-9/21/07…$15.00
https://doi.org/10.1145/3404835.3463046

1 INTRODUCTION

In the customer service scenario, automatic text summarization is becoming more and more attractive to researchers. Given a long text, the summarization system aims to obtain a shorter highlight while keeping important information on the original text. It is of great commercial value. For example, after an agent receives a complaint call, the summary system can provide a short summary that contains salient information. This will help his colleagues get the highlights of the dialogue quickly and improve the efficiency of the subsequent steps. Such a requirement is universal in internet business. In other words, an excellent text summary system can save a lot of human resources in the customer service scenario.

Recently, text summarization methods are mainly divided into generative summarization and extractive summarization. The former encodes the entire document and then generates a summary word by word [3, 6, 9, 14]. The extractive summarization methods [2, 17, 20, 21] score semantic units of different granularity and put them together to obtain a summary. Because the generative summarization methods are easy to lose stability and logicality, this paper focuses on the extractive summarization method.

However, in some specific scenarios, there are still some major challenges to use extractive summarization methods. For the customer service scenario, the summaries of most dialogues between an agent and a user focus on several fixed key points [9]. Take the example [1] in Table 1, the dialogue can be summarized into four key points: background, purpose, key, and solution. Traditional extractive methods fetch the fragments containing salient information from the original text, but it is hard for them to extract all predefined key points exactly. Therefore, it is easy to lose important information in the output summary.

Furthermore, in the customer services scenario, there is a lack of large-scale and high-quality extractive summarization datasets containing key points. It is very time-consuming and laborious to link each key point to the original dialogue.

In order to solve the above challenges, we propose a **D**istant **S**upervision based **M**achine **R**eading **C**omprehension model for extractive **S**ummarization (DSMRC-S). In DSMRC-S, for extracting the content of different key points exactly, we transform the

[1]In this paper, all samples are translated from Chinese to English manually.

Table 1: A sample in dataset. For the prediction of first key point "background", given a question "What is the background of the dialogue", our proposed method can extract the underlined segment as the answer.

Dialogue	
Agent:	Hello, can I help you?
User:	Hello, my **shopping vouchers** have **expired**, but I bought them on your platform yesterday. This is bullying, you have to compensate me for the unused shopping vouchers.
Agent:	Lady, I found your order, the reason why the shopping vouchers are expired is that your membership card is invalid today.
Users:	there was no hint when I bought them, and this is the first time I placed an order on this APP.
Agent:	Hmm, I'd like to explain to you that the prerequisite for the validity of our shopping vouchers is that you are our member. Because yo u are a new user, we can apply for half of the cost of your unused shopping vouchers.
Users:	It's OK.
Agent:	Thank you for your understanding. Is there anything else I can help you with?
Users:	that is all, thanks.
Key point	**Sub-summary**
background	**User complain about her expired shopping vouchers**
purpose	Compensation for the unused shopping vouchers
key	Shopping vouchers are only valid for members
solution	Compensation for half of the cost of the unused shopping vouchers
gold summary	User complain about her expired shopping vouchers, asking for compensation for the unused shopping vouchers, the key factors of the question is that shopping vouchers are only valid for members, so our solution is compensation for half of the cost of the unused shopping vouchers.
model summary	Shopping vouchers have expired, asking for compensate me for the unused shopping vouchers, the key factor of the question is that the prerequisite for the validity of our shopping vouchers is that you are our member, so our solution is apply for half of the cost of your unused shopping vouchers.

summarization task as a machine reading comprehension (MRC) problem, where answers extracted from the original text will be combined into a summary. Take Table 1 as an example, given a predefined question *"What is the background of the dialogue"*, the MRC module fetches the key segment from the dialogue corresponding to the key point *"background"*. In addition, a distant supervision method is used to establish the connection between the key point and the dialogue without annotated samples. Specifically, we label the tokens appearing in the sub-summary as 1 (the red tokens in Table 1) and others as 0, then the MRC module is trained to predict the probability of each token appearing in the sub-summary.

To verify the effectiveness of DSMRC-S, we collected a Chinese summary dataset from the logs in a customer service platform, named CS-Summary corpus. Experiments conducted on the CS-Summary corpus indicate that the proposed DSMRC-S performs significantly better than the strong baselines.

The contributions of this paper are as follows:

(1) DSMRC-S transforms the summarization task as the MRC problem, to fetch the key segment from the original text exactly according to the predefined question.

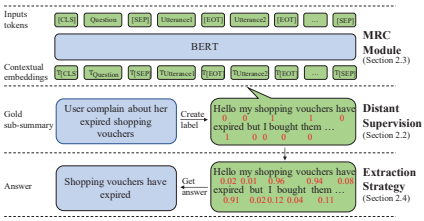

Figure 1: The overall architecture of DSMRC-S. The key point "background" is taken as an example in this figure.

(2) A distant supervision method is proposed to alleviate the lack of large-scale and high-quality extractive summarization dataset containing key points.

(3) DSMRC-S outperforms strong baseline methods more than 4 points on ROUGE$_L$ on the CS-Summary corpus.

2 METHOD

2.1 Model Overview

DSMRC-S consists of a BERT-based [4] MRC module and a density-based extraction strategy, the overview of DSMRC-S is shown in Figure 1. In preprocessing, we label the tokens in the dialogue according to each key point. Given a predefined question corresponding to a specific key point, the MRC module is trained to predict the probability of each token appearing in the key point. After that, the most appropriate span is extracted as the answer according to the density-based extraction strategy. In the inference, we repeat the above steps several times to extract all key points. Finally, all extracted key points will be combined into an output summary.

Let $G = \{u_1, u_2, ..., u_M\}$ be the dialogue with M utterances, where u_i is the i-th utterance in the dialogue. $S = \{k_1, k_2, ..., k_N\}$ is the corresponding summary where k_i is the i-th key point, N is the number of key points. Each key point contains a list of word tokens which is written by the agent manually, and each key point is assigned a corresponding predefined question. For example, the question "*What is the background of the dialogue*" is paired with the "*background*" key point.

2.2 Distant Supervision

In DSMRC-S, an MRC module is employed to extract key points from the dialogue. However, the key points in the summary are not quoted from the original dialogue text generally. It is difficult to locate the key point in the original text, so a distant supervision method is proposed to solve this problem.

As shown in Figure 1, given a predefined question "*What is the background of the dialogue*", the coresponding gold sub-summary is "*User complain about her expired shopping vouchers*". Then we label each token in the dialogue according to the principle: **the tokens appearing in the gold sub-summary are labeled as 1, and the others are labeled as 0**, i.e., the dialogue "*... my shopping vouchers have expired but ...*" is labeled as "*... 0 1 1 0 1 0 ...*". The

MRC module is required to output the probability of each token appearing in the sub-summary. Finally, DSMRC-S can extract the segment "*shopping vouchers have expired*" from the dialogue as the answer.

2.3 MRC Module

As shown in Figure 1, the general architecture of BERT is employed in MRC module. Question and dialogue are entered into BERT in pairs. Keeping the original BERT settings, [SEP] token is added at the end of question and dialogue to indicate the boundary, [CLS] token is inserted at the beginning of the text as an aggregation vector containing the whole sequence information. Dong et al. [5] proves that segmentation tokens play an important role for multi-turn response selection, so we add an [EOT] token at the end of a turn to represent the alternation of turns in the dialogue. Each token in the input text is assigned three kinds of embeddings: token embeddings, segment embeddings, and position embeddings. The input is composed of the sum of these three embeddings, and then it is fed to a Transformer with multiple layers. Due to limited space, we omit more description of BERT and recommend readers to refer to [4].

After obtaining the hidden state $\mathbf{h}$ of the last layer, we compute the cross entropy loss as:

$$\mathbf{p} = softmax(ReLU(W\mathbf{h} + b)) \tag{1}$$

$$\mathcal{L}(\mathbf{y}, \mathbf{p}) = -\sum_j \mathbf{y}_j log \mathbf{p}_j \tag{2}$$

where W and b are the parameters updated during training, $\mathbf{y}$ is the labels created in section 2.2.

2.4 Extraction Strategy

As shown in Figure 1, the extraction module is designed to extract answer from the dialogue based on output probability of the MRC module. Given the output probability $\mathbf{p} = \{p_1, p_2, ..., p_m\}$, for a span $\{x_{i:i+l}\}$ of the whole tokens sequence $\{x_1, x_2, ..., x_m\}$, we define the density of this span as :

$$d_i^{i+l} = (l)^{\alpha-1} \cdot \sum_{k=i}^{k=i+l} p_k \tag{3}$$

where α is a hyper-parameter in $[0, 1]$. We go through all the possible spans in each utterance, and choose the span with the highest density as the answer. When $\alpha = 0$, the token with the maximum probability will be returned, and the longest utterance will be selected when $\alpha = 1$. We choose an appropriate value of α through experiments. In this way, the segment like "shopping vouchers have expired" in Table 1 can be extracted, although not all tokens are labeled as 1 in section 2.2.

3 EXPERIMENTS

3.1 Dataset

Due to the lack of the extractive summary dataset containing key points, we collected a large-scale Chinese dialogue summary dataset from the logs in a customer service platform, called CS-Summary corpus. CS-Summary corpus contains more than 400k dialogues, each dialogue followed by four sub-summaries which are written by the agent manually, and the summary is combined by these sub-summaries. The statistics of the dataset are shown in Table 2.

Table 2: Statistics of the CS-Summary corpus

Dataset	train	valid	test
#dialogue-summary pairs	404k	9k	9k
Avg #words per summay	41.61	42.39	42.97
Avg #turns per dialogue	18.89	18.96	18.97
Avg #words per utterance	23.76	23.81	23.83

3.2 Implementation Details and Metrics

We use the base version of BERT to implement our models. The total losses are minimized by an Adam optimizer with the settings $\{\beta_1 = 0.9, \beta_2 = 0.999, lr = 10^{-4}\}$. We select the best checkpoint based on ROUGE_L on the validation set. The batch size is set to 32, α in Equation 3 is set to 0.4.

We employ the commonly used evaluation metrics: ROUGE [8] and BLEU [12], which analyze the co-occurrences of n-gram between the output summary and the reference. These two metrics are calculated on the Chinese characters to eliminate the influence of Chinese tokenization. Besides, Distinct [7] is used to measure the diversity of the output summary.

Table 3: Model comparison. +Att means to use attention mechanism, +Pointer means to use the pointer mechanism, (w) means to predict the whole summary at one time, the others predict the sub-summary first, and then combine them into the summary.

Models	BLEU	ROUGE_L	ROUGE_1	ROUGE_2	Dist_1	Dist_2
S2S+Att	14.46	33.73	35.87	17.13	49.51	65.92
S2S+Att+Pointer (w)	14.63	34.11	36.14	17.67	48.23	65.76
S2S+Att+Pointer	16.03	35.14	37.42	18.55	48.81	65.82
Trans+Att+Pointer (w)	17.07	36.29	38.31	19.65	51.25	65.93
Trans+Att+Pointer	19.21	39.43	42.74	22.44	51.33	66.34
Leader+Writer	19.37	40.57	42.89	23.41	53.26	67.18
DSMRC-S (Ours)	**23.24**	**44.68**	**46.69**	**28.40**	**57.68**	**67.54**

3.3 Overall Comparisons

Comparison Settings. We compare DSMRC-S with the following methods:

(1) **S2S+Att** is a RNN-based Sequence-to-Sequence [15] model with attention mechanisms [1].
(2) **S2S+Att+Pointer** adds the pointer mechanism [14], which decides whether to generate a token or copy a token from the original text.
(3) **Trans+Att+Pointer** replaces the RNN with Transformer [16].
(4) **Leader+Writer**[2] is a hierarchical transformer structure [9]. The Leader net predicts the key point sequence, and the Writer net predicts the summary guided by the prediction of the Leader net.

For the fake of fairness, in **S2S** and **Trans**, we predict the sub-summary one by one through adding the corresponding predefined question at the end of the dialogue. Finally, the summary combined by multiple output sub-summaries will be used for comparison.

[2]To make Leader+Writer net comparable with our model, we set the key point sequences to be known.

Comparison Results. The overall results are reported in Table 3. These results support the following statements:

(1) Our DSMRC-S achieves the highest performance and outperforms the best baseline method by about 4 points on BLEU and ROUGE$_L$ on the CS-Summary corpus.
(2) Predicting each key point separately is significantly higher than the corresponding version of predicting the whole summary (marked as "(w)" in Table 3), Trans+Att+Pointer outperforms Trans+Att+Pointer (w) obviously (+3.26% ROUGE$_L$), which indicates that it is necessary to predict each sub-summary separately in the customer service scenario.
(3) From the perspective of diversity, DSMRC-S achieves significantly higher performance than the best baseline (+4.42% Dist$_1$), which indicates that the introduction of MRC task is very helpful for modeling each key point separately.

3.4 Performance on different Key Points

To explore the advantages of DSMRC-S more clearly, we record the performance for the prediction of the different key points. As shown in Figure 2, DSMRC-S outperforms other baseline methods consistently in all key points, which demonstrates that the combination of the MRC model and density-based extraction strategy is better at grasping the characteristics of key points. More specifically, DSMRC-S performs significantly better in predicting user's purposes, which may be due to the fact that the user's purpose written by the agents is more frequently quoted from the original dialogue text.

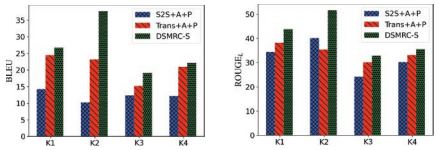

(a) BLEU on each key point (b) ROUGE$_L$ on each key point

Figure 2: The performance for prediction of different key points. K1, K2, K3 and K4 are the corresponding four key points in the CS-Summary corpus.

3.5 Performance on different Dialogue Turns and Reference Length

To explore the effects of dialogue turns and reference length, we record the performance for different dialogue turns and reference lengths. As shown in Figure 3, with the increase of dialogue turns or the length of reference, the performance of all the models decreases. Our proposed DSMRC-S is consistently better than other baseline methods, whether for longer references or dialogues with more turns.

4 RELATED WORKS

Generative summarization methods encode the entire document and then generate a summary word by word [3, 6, 9, 14]. The neural encoder-decoder architecture is first applied in text summarization [13]. Then a pointer-generator network [14] is proposed to enable the model to copy words from the original text. Gehrmann et al. [6] propose a content selector to improve the copy attention distribution in the pointer-generator network. A Leader-Writer network [9] is proposed to generate more logical and integrated summaries in the customer service scenario.

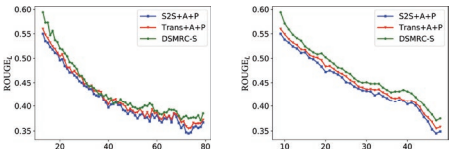

(a) Dialogue turns (b) Reference length

Figure 3: The performance on different dialogue turns and reference length.

Extractive summarization methods score semantic units of different granularity and put them together to achieve a summary [10, 17, 20?]. The extractive summarization task is regarded as a sequence labeling problem in [11]. Except in sentence level, A discourse-aware neural summarization model [18] to generate a concise and informative summary on discourse unit level. Zhong and Liu et al. [19] formulate the extractive summarization task as a text matching problem, proposed a summary-level extractive method based on the powerful ability of semantic matching on BERT.

5 CONCLUSION

In the customer service scenario, most dialogue between an agent and a user can be summarized into several key points. Thus, in this paper, we transform the summarization task as an MRC problem for extracting the content of different key points exactly. In addition, a distant supervision method is proposed to establish the connection between the key sub-summaries and the dialogue without annotated samples. Experiments on CS-Summary corpus demonstrate that DSMRC-S outperforms the best baseline method significantly.

6 ACKNOWLEDGMENTS

This work was supported in part by the National Key R&D Program of China 2020YFB1807800, 2020YFB1807804, in part by the National Natural Science Foundation of China under Grants 62071067, 62001054 and 61771068, in part by the Beijing Municipal Natural Science Foundation under Grant 4182041, and in part by the National Postdoctoral Program for Innovative Talents under Grant BX20200067, and in part by the Ministry of Education and China Mobile Joint Fund MCM20180101, and in part by the Beijing University of Posts and Telecommunications-China Mobile Research Institute Joint Innovation Center.

REFERENCES

[1] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. 2015. Neural Machine Translation by Jointly Learning to Align and Translate. In ICLR, Yoshua Bengio

and Yann LeCun (Eds.).
[2] Jianpeng Cheng and Mirella Lapata. 2016. Neural Summarization by Extracting Sentences and Words. In ACL. The Association for Computer Linguistics.
[3] Sumit Chopra, Michael Auli, and Alexander M. Rush. 2016. Abstractive Sentence Summarization with Attentive Recurrent Neural Networks. In NAACL. The Association for Computational Linguistics, 93–98.
[4] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. [n.d.]. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In NAACL. Association for Computational Linguistics, 4171–4186.
[5] Jianxiong Dong and Jim Huang. 2018. Enhance word representation for out-of-vocabulary on Ubuntu dialogue corpus. CoRR abs/1802.02614 (2018).
[6] Sebastian Gehrmann, Yuntian Deng, and Alexander M. Rush. 2018. Bottom-Up Abstractive Summarization. In EMNLP. Association for Computational Linguistics, 4098–4109.
[7] Jiwei Li, Michel Galley, Chris Brockett, Jianfeng Gao, and Bill Dolan. 2016. A Diversity-Promoting Objective Function for Neural Conversation Models. In NAACL. The Association for Computational Linguistics, 110–119.
[8] Chin-Yew Lin. 2004. ROUGE: A Package for Automatic Evaluation of Summaries. In Text Summarization Branches Out. Association for Computational Linguistics, Barcelona, Spain, 74–81.
[9] Chunyi Liu, Peng Wang, Jiang Xu, Zang Li, and Jieping Ye. 2019. Automatic Dialogue Summary Generation for Customer Service. In KDD. ACM, 1957–1965.
[10] Yishu Miao and Phil Blunsom. 2016. Language as a Latent Variable: Discrete Generative Models for Sentence Compression. In EMNLP, Jian Su, Xavier Carreras, and Kevin Duh (Eds.). The Association for Computational Linguistics, 319–328.
[11] Ramesh Nallapati, Feifei Zhai, and Bowen Zhou. 2017. SummaRuNNer: A Recurrent Neural Network Based Sequence Model for Extractive Summarization of Documents. In AAAI. AAAI Press, 3075–3081.
[12] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. Bleu: a Method for Automatic Evaluation of Machine Translation. In ACL. 311–318.
[13] Alexander M. Rush, Sumit Chopra, and Jason Weston. 2015. A Neural Attention Model for Abstractive Sentence Summarization. In EMNLP. The Association for Computational Linguistics, 379–389.
[14] Abigail See, Peter J. Liu, and Christopher D. Manning. 2017. Get To The Point: Summarization with Pointer-Generator Networks. In ACL. Association for Computational Linguistics, 1073–1083.
[15] Ilya Sutskever, Oriol Vinyals, and Quoc V. Le. 2014. Sequence to Sequence Learning with Neural Networks. In NIPS. 3104–3112.
[16] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is All you Need. In NIPS. 5998–6008.
[17] Danqing Wang, Pengfei Liu, Yining Zheng, Xipeng Qiu, and Xuanjing Huang. 2020. Heterogeneous Graph Neural Networks for Extractive Document Summarization. In ACL. Association for Computational Linguistics, 6209–6219.
[18] Jiacheng Xu, Zhe Gan, Yu Cheng, and Jingjing Liu. 2020. Discourse-Aware Neural Extractive Text Summarization. In ACL. Association for Computational Linguistics, 5021–5031.
[19] Ming Zhong, Pengfei Liu, Yiran Chen, Danqing Wang, Xipeng Qiu, and Xuanjing Huang. 2020. Extractive Summarization as Text Matching. In ACL. 6197–6208.
[20] Ming Zhong, Danqing Wang, Pengfei Liu, Xipeng Qiu, and Xuanjing Huang. [n.d.]. A Closer Look at Data Bias in Neural Extractive Summarization Models. ([n. d.]).
[21] Qingyu Zhou, Nan Yang, Furu Wei, Shaohan Huang, Ming Zhou, and Tiejun Zhao. 2018. Neural Document Summarization by Jointly Learning to Score and Select Sentences. In ACL. Association for Computational Linguistics, 654–663.

User Consumption Intention Prediction in Meituan

Yukun Ping[1,2], Chen Gao[1], Taichi Liu[1,2], Xiaoyi Du[2], Hengliang Luo[2], Depeng Jin[1], Yong Li[1]
[1]Beijing National Research Center for Information Science and Technology (BNRist)
Department of Electronic Engineering, Tsinghua University, Beijing, China
[2]Meituan Inc., Beijing, China

ABSTRACT

For online life service platforms, such as Meituan, user consumption intention, as the internal driving force of consumption behaviors, plays a significant role in understanding and predicting users' demand and purchase. However, user consumption intention prediction is quite challenging. Different from consumption behaviors, consumption intention is implicit and always not reflected by behavioral data. Moreover, it is affected by both user intrinsic preference and spatio-temporal context. To overcome these challenges, in Meituan, we design a real-world system consisting of two stages, intention detection and prediction. Specifically, at the intention-detection stage, we combine the knowledge of human experts and consumption information to obtain explicit intentions and match consumption with intentions based on user review data. At the intention-prediction stage, to collectively exploit the rich heterogeneous influencing factors, we design a graph neural network-based intention prediction model GRIP, which can capture user intrinsic preference and spatio-temporal context. Extensive offline evaluations demonstrate that our prediction model outperforms the best baseline by 10.26% and 33.28% for two metrics and online A/B tests on millions of users validate the effectiveness of our system.

KEYWORDS

Consumption Intention Prediction, Graph Neural Networks

1 INTRODUCTION

Meituan[1], similar as Yelp[2], is one of the largest consumption portal-platforms around the world connecting more than 100 million of daily consumers and various local services, including food, entertainment, shopping, etc. Users find and browse local services in Meituan before consumption, and complete digital payment in Meituan after consumption. The platform collects users' consumption behaviors and provides personalized experiences, including personalized recommendation, itinerary planning, etc., supported by understanding and predicting of users' consumption behaviors. The current solutions for consumption prediction is to directly learn from users' historical behaviors, such as collaborative filtering [10, 15, 23] based on the similarity of historical behaviors.

However, directly and merely learning from consumption behaviors is suffering from two limitations at two perspectives. First, the consumption behavior on a specific service may happen by coincidence. In other words, there are many replaceable services for the user, and the consumed one may be chosen accidentally. On a deeper level, the consumption behavior is internally driven by the user's demand. For example, a user wants to *have a rest* at a coffee bar and coincidentally choose Starbucks, although Costa is also a promising choice. A model directly learning from consumption behaviors may think the user dislike Costa. Second, the same service may satisfy different types of demands for different users. For example, a user consumes at Starbucks to *have a rest*, while another user is due to *hold a remote meeting*. Thus, predicting users' future consumption behaviors merely and directly based on historical behaviors may cause biases, leading to sub-optimal prediction results.

As a result, understanding and predicting users' demand, which can be formally named as *user consumption intention prediction*, is a convincing and reasonable approach to aid the prediction of user consumption behavior. In general, the problem of consumption intention prediction can be defined as predicting a user's desire or demand that driven him/her to consume a kind of service or product, such as to *have a rest* or *hold a remote meeting*. Nevertheless, developing prediction models of user consumption intention for real-world scenarios is quite challenging due to three aspects.

- **First, the consumption intention is always implicit and hard to capture.** Compared with the consumption behaviors, consumption intention reflects a more fine-grained user preference. As mentioned above, it serves as the internal driving force, and the same consumption behavior may be driven by different consumption intentions. As a result, consumption intention is not explicitly reflected by the behavioral data, which is the most critical issue in intention prediction.
- **Second, the consumption intention is highly affected by user intrinsic preference and spatio-temporal context.** In the real world, the consumption intention is dynamic and can be largely affected by the spatio-temporal context, besides user intrinsic preference such as taste style, consumption level, etc. For example, a consumption intention of having a rest is more likely to happen at weekends and entertainment areas. Thus, combining the modeling of user intrinsic preference and spatio-temporal context is essential but challenging.
- **Third, the internal structure of consumption intention is complex.** Consumption intention itself is in a complex structure, making it difficult to learn. Some kinds of consumption intentions, although not the same, are highly correlated, such as to *have lunch* and *have dinner*. More specifically, these intentions can be classified into the clustering structure, of which the intentions belonging to one same cluster are highly correlated and similar, while there are great contrasts among the intentions belonging to different clusters.

There is seldom work well exploring the problem of consumption intention prediction due to these above-mentioned challenges.

[1]https://about.meituan.com/en
[2]https://www.yelp.com

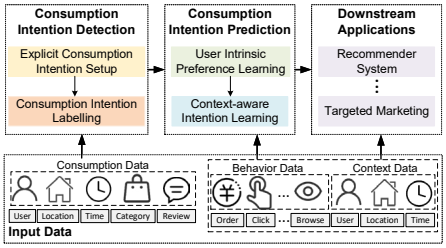

Figure 1: The framework of our user consumption intention detection and prediction system.

There are some works using the term, intention, to refer to the behavior [20, 30, 31], product category [4] or query word [7], which do not conform to the precise definition of consumption intention. There are some other works [19, 29, 33] using the term, intention, to refer to user latent factor in behavior-prediction models, while the concept of intention in these works is still vague and unseen.

We develop the Meituan's intention prediction system in a two-stage manner, as shown in Figure 1, to address these three challenges.

- The first stage is ***consumption intention detection***. Although the consumption intention is not explicitly reflected by user behavioral data, users tend to write reviews mentioning why they consume the product or service. Thus, taking advantage of the user review data, we propose a simple yet effective keyword matching method for detecting and classifying consumption intentions.
- The second stage is ***consumption intention prediction***. To model both the user intrinsic static preferences and spatio-temporal dynamic context, we build a dual-stage graph neural network model ***GRIP***, namely ***GRaph neural network for Intention Prediction***, which can not only learn from users' long-term interactions but also capture the effect of spatio-temporal context. To be more specific, with shared embedding layers between two graph neural networks, we design two graph convolutional layers to extract two kinds of effects, respectively. As for the third challenge of the complex internal structure of intention, we propose to disentangle the latent representations of intentions, with the disentangling loss that supervises the learning to meet the clustering structure.

The contribution of this work can be summarized as follows.

- To the best of our knowledge, we take the first step into the problem of consumption intention prediction, which is a real-world problem with high value and wide applications. The consumption intention serves as the driving force of consumption behavior, and we detect and define 19 types of consumption intentions in Meituan.
- We develop a system in Meituan consisting of consumption intention detection and prediction. We first propose to explicitly reveal consumption intentions from users' review data. We then design a dual graph convolutional network model GRIP for capturing both the users' intrinsic preferences and the effect of spatio-temporal context. We develop a disentangling loss function for modeling the clustering-structure of intentions to enhance the intention's representation learning.
- We evaluate our system via both offline experiments and online A/B tests. The experimental results show that our consumption intention prediction model, GRIP, effectively outperforms a group of state-of-the-art prediction methods and shows vigorous contribution on 6%-66% improvements in prediction performance. The online industrial results reveal that even with a simple prediction method, our system achieves average relative improvements of about 1.55% on *Page View* and 5.15% on *Page View for Cold-start Customers*. Moreover, compared with baseline prediction method, our GRIP achieves 44.72% improvements on prediction precision and 84.96% improvements on *Customer Growth*.

.

The remainder of this paper is as follows. For the system, we detail the consumption intention detection method in Section 2 and the prediction method GRIP in Section 3. We present offline experimental results of prediction and online industrial results in Section 4 and Section 5, respectively. We then discuss related works in Section 6. Last, we conclude this work in Section 7.

2 CONSUMPTION INTENTION DETECTION

To discover users' explicit desire or demand from their consumption data, we propose an effective method to detect consumption intentions and match consumption with intentions based on reviews. It has been shown that reviews, as a natural source of data to exploit, can be intended to 'explain' the underlying dimensions behind users' decisions [1, 21, 33, 38]. Reviews are much more expressive with text and useful to infer the consumption intention of users, compared with interaction data, which may be sparse or noisy. Specifically, we first set a series of classifications of consumption intentions with the help of human experts and historical consumption data. Then, we propose a keyword matching method to match each consumption with a intention. The architecture of this process is illustrated in Figure 2, and we elaborate on the design of these two stages as following.

2.1 Explicit Consumption Intention Setup

We aim to set explicit consumption intention utilizing consumption data on the life service platform. For different kinds of users, their consumption intentions are highly related to their preference or habits. For example, white-collar workers may have higher demand for cooking at home than students. In addition, the consumption intentions for life service are strongly relevant to location and time of users' visits. For example, users tend not to have the desire to do car maintenance in the morning of a working day. So to consider the influence of all these factors, we use a tuple of (user attributes, time, location) to objectively describe the conditions of each consumption, and we name it as, *user scene*.

As showing in Figure 2, with the consumption data, including a user purchased a certain category of products at a certain time and location, we obtain a set of user scenes, for example, (female, plaza, weekend afternoon). Then for each user scene, we combine the knowledge of human experts and consumption information (e.g. category, price, etc.) to set the detailed consumption intentions. For example, the consumption on cosmetic makeover is related to

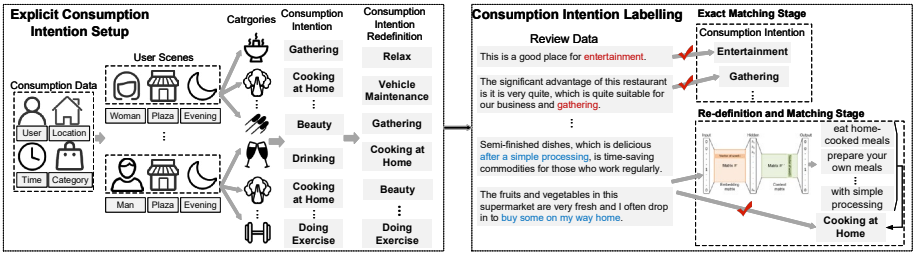

Figure 2: The architecture of our proposed user consumption intention detection method.

Table 1: 19 types of explicit consumption intention.

Explicit Consumption Intention	Gathering, Cooking at home, Entertainment, Drinking, Business trip, Beauty, Housewares, Doing exercise, Pets, Snack, Family life, Vehicle maintenance, Leisure activities, Massage, Traveling, Grab a bite, Childcare, Dainty morsel, Training and learning

the intentions of `Beauty` while board games is related to `Leisure Activities`. We further redefine the consumption intentions via merging and differentiating them in different user scenes and obtain the final 19 classes of consumption intentions, showing in Table 1.

It can be observed that the consumption intentions we set include all kinds of life service consumption. Moreover, for the consumption of some categories with complex desires, e.g. dining, there are multiple related intentions in detail, each of which focuses on different aspects, e.g. `Grab a bite` relates to food that can be eaten quickly while `Dainty morsel` relates to food that is greatly pleasing to the taste. But for those relatively limited consumption categories, where the desire is simple and unified, we summarize a generalized intention for each kind, e.g. `Pets`, `Vehicle maintenance`.

2.2 Consumption Intention Labelling

After obtaining the classifications of intentions, we use reviews written by consumers based on their experience to match each consumption with a intention, i.e., user consumption intention labelling. It can be treated as a keywords matching task, where we need to search whether each review contains the keywords of the intentions. If the keywords of an intention is included, the consumption data related to the review can be matched with the intention. Thus, we design a two-stage matching method for consumption labelling, showing in Figure 2. In the first stage, *Exact Matching Stage*, we directly use each intention, which is a word or a list of words, as the keywords, to do exact matching with the reviews. For most intentions, such as `Entertainment` and `Gathering`, we can directly find the words in the review for matching. However, for the rest of the intentions where the keywords rarely appear and hard to be found directly in reviews, we need the second stage, *Re-definition and Matching Stage*. In this stage, we utilize Word2Vec [16, 22] to obtain the re-defined keywords for each intention. The training set of Word2Vec also comes from reviews. For each sentence in reviews, we use a sliding window with a length of $2 \times c + 1$, which select c words before and after, to obtain phrases. Here we use $c = 2$ since our intentions are no more than 3 words. We put the phrase gotten each time in the training set and use Skip-gram [16, 22] to find the most related phrases for each intention. For example, reviews like `eat home-cooked meals`, `prepare your own meals` and `with simple process` are all corresponding to the intention of `Cooking at home`. We utilize these phrases as keywords and do the matching operation again.

With the above proposed consumption intention labelling method, we can not only label the consumption data related to common intentions, but further explore those intentions with relatively rare occurrences or more diverse expressions.

By introducing the objective formulation of user scene as (user attributes, time, location) and incorporating it with categories and reviews of consumption data, we enrich the semantics and rationality of consumption intentions which sets up the dataset for following prediction task. This method will be further evaluated by online evaluation in Section 5.

3 CONSUMPTION INTENTION PREDICTION

To predict the consumption intention of users, we need to comprehensively model all the influencing factors. In general, there are two major types of factors. a) *User intrinsic preference* implies higher attention or interests of users for certain aspects of the item, such as taste style, consumption level, etc. It can be represented in the interactions between users and items on the platform. b) *Spatio-temporal context* implies the current spatio-temporal factor of the scene and users' intention could change greatly in different scenes, as introduced in Section 2.1. Such context information can be very helpful because most users go to a place with a certain degree of intention rather than completely wandering around.

To fully utilize all these heterogeneous factors as well as their attributes for consumption intention prediction, we design a dual-stage GCN framework, ***GRIP*** for short, to first model user intrinsic preference according to users' historical interactions with different categories, and then learn a context-aware intention embedding with spatio-temporal information, as showing in Figure 3. In GRIP, the attributes of users are used in both graphs and thus these embeddings are shared in two graphs. Now we introduce the detailed design of the prediction model.

3.1 User Intrinsic Preference Modeling

In the first GCN model, we aim to model user intrinsic preference for consumption intention prediction, which is represented in their

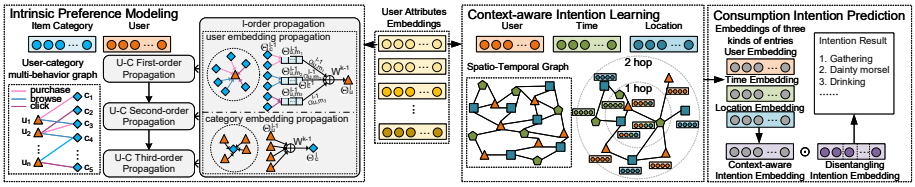

Figure 3: The architecture of our proposed user consumption intention prediction method GRIP.

historical behaviors, especially interactions with different items. For example, if a user only has browsed and purchased high-priced items on the platform, it means that (s)he is serious about the quality so may tend not to have the consumption intention of Grab a bite.

However, item-wise preference may be difficult to fully generalize because of the sparsity of observable user-item pairs. In addition, different behaviors, e.g., clicking, collecting,purchasing, etc., help to exploit different types of feedback of users intrinsic preference. To capture the category-wise users intrinsic preference based on multi-behaviors, we build a heterogeneous graph consisting of two kinds of nodes of users and categories and multiple types of edges, where an edge connecting user node and category node refers to a specific type of user-category interaction behavior.

As showing in Figure 3, we utilize three types of behavior: clicking, browsing and purchasing and three interaction matrices Y^1, Y^2, Y^3 to denote if user has interacted with categories under these three behaviors, respectively. Specifically, each interaction matrice Y^m is in the binary form, of which each entry has value 1 or 0, defined as follows for user u and category c,

$$y_{uc}^m = \begin{cases} 1, \text{if } u \text{ has interacted with } c \text{ under behavior } m, \\ 0, \text{otherwise.} \end{cases} \tag{1}$$

We represent the interaction data by an undirected graph $\mathbf{G} = (\mathbf{V}, \mathbf{E}, \mathbf{X})$, where nodes are $\mathbf{V}$ consisting of user nodes $u \in U$ and category nodes $c \in C$. The edges in $\mathbf{E}$ contain different user-category interaction edges of different behaviors, namely $(u, c)_m, m \in N_r$, where N_r is the set of all behavior types. $X = \left(\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_{|V|}\right)$ represents the feature vector of each nodes. For users, the feature information is indicated by the profiles of users (e.g., age, gender, marital, etc.). We represent each profile with a set of embeddings for different values and denote each user node as $\mathbf{u}_q = [u_{q1}, u_{q2}, ..., u_{qP}]$ with P profiles. For categories, the feature information is the ID of the category. There will be an edge $(u, c)_m$ built when $y_{uc}^m = 1$. Similar to the message-passing architecture in [11], we utilize a behavior-aware user-category propagation method for better utilization of multi-behavior information. In the category-to-user embedding propagation module, we learn the importance of different behaviors automatically and assign different weights to categories interacted under different behaviors. In the user-to-category embedding propagation module, we aggregate the information of neighbor user for each category directly.

3.1.1 User Embedding Propagation. To consider categories' influence on users according to the behavior type, we assign a weight for each behavior, namely w_m for behavior m and the propagation weight for a particular behavior m for user u denoted as α_{um}:

$$\alpha_{um} = \frac{w_m \cdot n_{um}}{\sum_{t \in N_r} w_t \cdot n_{um}}, \tag{2}$$

where w_m is a behavior-wised importance weight of behavior m, and n_{um} is the total number of behavior m operated by user u. To be specific, behavior with larger w will be of higher importance comparing to behavior with smaller w. α_{um} is the final propagation weight of behavior m for user u, which will be used in propagation layer and $\sum_m \alpha_{um} = 1$. w_t is learned by the model so that the importance of each behavior can be learned automatically.

For each user u, we aggregate the categories that have the same behavior interaction together to obtain one embedding for each behavior, namely $\Theta_{u,m}^{(l)}$ under behavior m, which is defined as follows,

$$\Theta_{u,m}^{(l)} = \text{aggregate}\left(\Theta_c^{(l)} \mid c \in N_m^Y(u)\right), \tag{3}$$

where l refers to the l-th layer, $N_m^Y(u)$ is the set of categories that user u has interacted under behavior m. $\Theta_c^{(l)}$ is the embedding of category c on l-th layer and $\Theta_{u,m}^{(l)}$ is the category aggregated embedding for user u under behavior m on l-th layer. We aggregate them together according to weight α_{um} and go through an encoder matrix to obtain the final neighbor category aggregation for user u, as follows,

$$\Theta_u^{(l+1)} = W^{(l)} \cdot \left(\sum_{m \in N_r} \alpha_{um} \Theta_{u,m}^{(l)}\right), \tag{4}$$

where $\Theta_u^{(l+1)}$ is the embedding of use u in the $(l+1)$-th layer and $W^{(l)}$ is the encoding matrix for information aggregation in the l-th layer.

3.1.2 Category Embedding Propagation. Generally different users have the same contribution to one category. Thus we aggregate user embedding $\Theta_{uj}^{(l)}$ for the next layer category embedding $\Theta_{ci}^{(l+1)}$ as follows,

$$\Theta_c^{(l+1)} = W^{(l)} \cdot \text{aggregate}\left(\Theta_j^{(l)} \mid j \in N^U(c)\right), \tag{5}$$

where $N^U(c)$ is the set of users that category c has connected with, $\Theta_{uj}^{(l)}$ is the embedding for user j and $W^{(l)}$ is the encoding matrix for information aggregation on the l-th layer.

After propagating through L layers, we obtain the multiple representations, namely $\left\{\Theta_u^{(0)}, \ldots, \Theta_u^{(L)}\right\}$ for user and namely $\left\{\Theta_c^{(0)}, \ldots, \Theta_c^{(L)}\right\}$ for category. We utilize the representations obtained in the last layer as the final embedding for users and categories. To learn the parameters in this graph, we employ inner

product to calculate the score based on user-category propagation, as follows,

$$y_(u,c) = \Theta_u^L \cdot \Theta_c^L, \tag{6}$$

Then, we use BPR loss [23] to emphasize that the observed interaction, which is instructional for user intrinsic preference learning, should be assigned a higher score than unobserved ones for this graph. The loss function is defined as follows,

$$\text{loss}_{\text{bpr}} = \sum_{(u,c_j,c_k)\in O} -\ln \sigma(y(u,c_j) - y(u,c_k)), \tag{7}$$

where $O = \{(u, c_j, c_k) \mid (u, c_j) \in R^+, (u, c_k) \in R^-\}$ denotes the set of training data, R^+ represents observed links, R^- represents unobserved links, and $\sigma(\cdot)$ is the sigmoid function.

3.2 Spatio-temporal Context Modeling

Although the consumption intention is affected by the intrinsic preference of users, it is also strongly relevant to location and time of the scene. Thus we aim to model these factors together to obtain a context-aware intention representation for intention prediction.

To figure out the interior relation between intrinsic preference, time and location, we construct a graph $\mathbf{G} = (\mathbf{V}, \mathbf{E}, \mathbf{X})$ to encode the connections. With the user feature vector from Section 3.1, which reflects the user intrinsic preference, the nodes $\mathbf{V}$ in the graph consist of user nodes $u \in U$, time nodes $t \in T$ and location nodes $l \in L$. Edges $\mathbf{E}$ representing the co-occurrence relationship between different nodes which can be generalized as three edge types in the graph: a)*time-location* edge, b)*user-time* edge and c)*user-location* edge. To effectively model the strength of different connections among nodes, each edge is assigned with a weight. Here we employ min-max normalization to calculate weights between nodes. we denote the co-occurrence matrix as C and the maximum weight for *Time-Location* edge as C^{tl}_{max}, *User-Time* edge as C^{ut}_{max} and *User-Location* edge as C^{ul}_{max} respectively. Then, the normalized weight of edge between node p and q is defined as:

$$A_{pq} = \begin{cases} C_{pq}/C^{tl}_{max} & (p,q) \text{ is time-location edge,} \\ C_{pq}/C^{ut}_{max} & (p,q) \text{ is user-time edge,} \\ C_{pq}/C^{ul}_{max} & (p,q) \text{ is user-location edge,} \\ 1 & p = q, \\ 0 & \text{otherwise.} \end{cases} \tag{8}$$

$X = \left(\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_{|V|}\right)$ represents the feature vector of each nodes and consists of three types of vector: user feature vector $\boldsymbol{u}$, location feature vector $\boldsymbol{l}$, and time feature vector $\boldsymbol{t}$. For users, the feature information is indicated by the profiles of users (e.g., age, gender, marital, etc.) and each user node is denoted as $\mathbf{u}_q = [u_{q1}, u_{q2}, ..., u_{qP}]$ for P profiles. The feature vector of these user profiles are shared in user intrinsic preference modeling graph and this spatio-temporal modeling graph. For times, we categorize the time slots as working days and non-working days since people's lifestyles differ a lot between these two types of days. Then, we discretize the time in one day into N units for better modeling. For locations, the feature information is indicated by the location id. Since each node possesses only one type (user/time/location), for types which are different from the node type, the corresponding feature is set to be zero vectors and the overall feature vector for each node is $\boldsymbol{x} = [\boldsymbol{u}, \boldsymbol{l}, \boldsymbol{t}] \in \mathbb{R}^D$

Based on the built graph, the representation learning method is based on Graph Convolutional Network (GCN)[14]. Let $\Theta^{(l)} = \left(\boldsymbol{\theta}_1^{(l)}, \boldsymbol{\theta}_2^{(l)}, \ldots, \boldsymbol{\theta}_{|V|}^{(l)}\right)$ be the matrix of all node embedding vectors at step l, where $\Theta^{(0)} = \mathbf{X}$, the aggregation function is calculated as:

$$\Theta^{(l)} = \sigma\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}\Theta^{(l-1)}W^{(l)}\right), \tag{9}$$

where $\tilde{A} = A + I_N$, and A is the adjacency matrix with the identity matrix, D is a diagonal matrix with $D_{ii} = \sum_j \tilde{A}_{ij}$ and σ represents the non-linear activation function. Input node feature X serves as the initial embedding $\Theta^{(0)}$ and $W^{(l)}$ is the trainable parameters in the l-th layer. In this way, for each node, the embedding is updated to the weighted average of itself and its neighbors in the graph. Since the neighborhood relationship in the graph indicates co-occurrence in records, via aggregating the high-order neighborhood information for each node, we can utilize the contextualized information for each consumption.

After propagating through L layers, we obtain the representations for users Θ_u, locations Θ_l and time Θ_t. We utilize the representations obtained in the last layer as the final embedding and the context-aware intention representation for user scene v can be computes as follows,

$$\mathbf{r}_v = \frac{(\boldsymbol{\theta}(u_v) + \boldsymbol{\theta}(t_v) + \boldsymbol{\theta}(l_v))}{3}. \tag{10}$$

3.3 Consumption Intention Disentangling

For different intentions, they are not isolated but have certain relations with each other. For example, the consumption intention of *Gathering* and *Drinking* although not the same, are highly correlated, however, the correlation between *Gathering* and *Training and learning* is relatively weaker. Thus, the consumption intentions can be classified into the clustering structure, where intentions belonging to one same cluster are similar, while there are great contrasts among the intentions belonging to different clusters. To capture the inter-cluster difference and inner-cluster closeness of consumption intentions, we introduce latent representations for 19 types of intentions $\mathbf{e}_i = \mathbf{e}_i^1, \mathbf{e}_i^2, \ldots, \mathbf{e}_i^{19}$ and generate disentangled representations. More formally, for the j-th consumption intention, we disentangle its latent representations $\mathbf{e}_i^j$ into K independent parts as follows,

$$\mathbf{e}_i^j = \left(\mathbf{e}_{1i}^j, \mathbf{e}_{2i}^j, \ldots, \mathbf{e}_{Ki}^j\right), \tag{11}$$

where $\mathbf{e}_{ki}$ is the k-th latent intent influence for consumption intention. All these K parts are in the same dimension $\frac{D}{K}$ where D is the dimension of each context-aware intention representation $\mathbf{r}_v$. To make the different parts of intention representations to be independent, we utilize the distance correlation [25, 26], which is able to characterize independence of any two vectors and is zero if and only if these vectors are independent. So the loss function can be computed as follows,

$$\text{loss}_{\text{dis}} = \sum_{k=1}^{K}\sum_{k'=k+1}^{K} d_{Cor}(\mathbf{E}_k, \mathbf{E}_{k'}), \tag{12}$$

where $\mathbf{E}_k = \left[\mathbf{e}_{ki}^1, \mathbf{e}_{ki}^2, ;\mathbf{e}_{ki}^{19}\right] \in N \times \mathbb{R}^{\frac{D}{K}}$ is the k-th disentangled embedding of the 19 consumption intention representations and

d_{Cor} is the function of distance correlation defined as:

$$d_{Cor}\left(\mathbf{E}_k, \mathbf{E}_{k'}\right) = \frac{d_{Cov}\left(\mathbf{E}_k, \mathbf{E}_{k'}\right)}{\sqrt{d_{Var}\left(\mathbf{E}_k\right) \cdot d_{Var}\left(\mathbf{E}_{k'}\right)}}, \tag{13}$$

where d_{Cov} represents the distance covariance between two matrices; d_{Var} is the distance variance of each matrix.

3.4 Consumption Intention Prediction

To predict the consumption intention of a user with the spatio-temporal context, we compare the context-aware intention representation r_v with 19 disentangled embeddings of consumption intentions. The scores for different consumption intentions $\mathbf{e}_i^j$ can be computed as follows,

$$s_{vj} = \frac{\boldsymbol{r}_v \cdot \mathbf{e}_i^j}{\|\boldsymbol{r}_v\| \cdot \left\|\mathbf{e}_i^j\right\|}. \tag{14}$$

We take the consumption intention with the maximum scores as the prediction result.

3.5 Training and Model Optimization

To overcome the class imbalance of different consumption intentions, we design a multi-class focal loss [17] to down-weight the data from those consumption intentions of a large amounts of training data in the total prediction loss. Thus the prediction loss is defined as follows:

$$\text{loss}_{\text{pred}} = -\sum_{v \in O}\left(\sum_{j=1}^{19}\left(1-p_{vj}\right)^{\gamma} q_{vj} \log\left(p_{vj}\right)\right), \tag{15}$$

where O denotes the set of training data, $p_{vj} = \text{Softmax}\left(s_{vj}\right) = e^{s_{vj}} / \sum_k e^{s_{vk}}$, γ is a adjustable parameter and $q_{vj} = 1$ if $\boldsymbol{r}_v$ belongs to the true label, else it is 0.

The entire model with the aforementioned four parts is trained with standard backpropagation as an end-to-end framework. Thus, the entire loss function is:

$$\text{Loss} = \lambda_1 \text{loss}_{\text{bpr}} + \lambda_2 \text{loss}_{\text{pred}} + \lambda_3 \text{loss}_{\text{dis}}, \tag{16}$$

where λ_1, λ_2 and λ_3 are three defined hyper-parameters. During the training, we alternatively optimize the parameters in user intrinsic preference modeling GCN and that in context-aware intention learning GCN.

To evaluate the effectiveness of the system, including consumption intention detection and prediction, we conduct both offline experiments and online A/B test. We first evaluate the prediction performance of GRIP on offline dataset in Section 4. Then we deploy the system based on Meituan mobile App's Homepage for online evaluation in Section 5.

4 EVALUATION OF INTENTION PREDICTION

4.1 Experimental Settings

Dataset We collect large-scale user behavior logs and consumption data from Meituan ranging from Jun. 30 to Sep. 24 2020. There are three types of behaviors, including clicking, browsing and purchasing in user behavior logs. With the consumption intention labelling method, we label each piece of consumption data with review to a type of consumption intentions listed in Table 1. We utilize the *user scene*, including user attributes, location and time currently as the input to predict which type the user's consumption intention belongs to. Then, to evaluate the performance of our intention prediction model GRIP, we divide the data based on the time span into training set and test set. More statistics are provided in Table 2.

Table 2: Summary of statistics of the dataset. '# Locations' indicates the number of location scene we use in spatio-temporal graph. '# Category' indicates the number of item categories we use in user intrinsic preference modeling graph. '# Users' indicates the number of users in the training or test data.

	Time Span	#Users	#Location	#Category
Training set	6/30-8/31/2020	339,982	12	824
Test set	9/1-9/24/2020	97,947		

Baselines We compare our GRIP with three categories of baseline methods, feature-based models, graph embedding-based models, and graph neural network-based models. The details of these baseline methods are provided in Appendix A.1.

The two most representative feature-based prediction models are:

- **XGBoost** [3]: It is a gradient boosted classification tree approach based on the gradient boosting machine.
- **DeepFM** [8]: It combines FM and deep neural network to low and high order feature combinations simultaneously.

Two graph embedding based models are as follows,

- **ReconEmbed** [37]: It is a general representation learning model for spatio-temporal activity prediction and samples random-walks from the graph to learn embedding vectors for nodes.
- **GraphEmbed** [37]: It is a general representation learning model for spatio-temporal activity prediction and learns low-dimensional representations by preserving first and second-order proximities in the graph.

Four graph neural network based models are as follows,

- **SA-GCN** [35]: It is a state-of-the-art method in spatio-temporal prediction and adopts Graph Convolutional Network (GCN) with meta path-based objective function to combine the structure of graoh and the attribute of nodes.
- **SA-LightGCN** [9]: It is a state-of-the-art method to learn node representations with pair-wise interaction for single-typed edge.
- **HAN** [32]: It is a general heterogeneous graph learning method to obtain representations of the nodes by aggregating information from the features of their neighboring nodes with different type-level attention and node-level attention.
- **HetGNN** [36]: It is a stat-of-the-art heterogeneous graph learning method. For each node, it first aggregate the features of its neighbors of each type, and then aggregate the neighbors information of different types with attention.

Metrics To evaluate the performance of prediction model, we use two widely used metrics, Precision and NDCG [11, 12, 34]. Specifically, for each case in test set, with the prediction scores for different consumption intentions, we form a ranked list by sorting these 19 consumption intentions according to their scores in a descending order, where we use $rank(s_g)$ to denote the position

Table 3: Comparison of overall intention prediction performance of GRIP and baselines.

	Prec@1	Prec@3	Prec@5	NDCG@3	NDCG@5
XGBoost	0.1120	0.2887	0.3182	0.2103	0.2457
DeepFM	0.1157	0.3010	0.3402	0.2257	0.2816
ReconEmbed	0.1213	0.3125	0.4103	0.2473	0.3019
GraphEmbed	0.1274	0.3306	0.4405	0.2556	0.3228
SA-GCN	0.1336	0.3219	0.4302	0.2157	0.2916
SA-LightGCN	0.1573	0.3527	0.4457	0.2331	0.3005
HAN	0.2620	0.3471	0.5391	0.2411	0.3039
HetGNN	0.1747	0.3836	0.6443	0.2651	0.3861
GRIP	**0.2903**	**0.4356**	**0.6857**	**0.3809**	**0.4744**

of the ground-truth intention in the ranking list. Then, we form a top-K intention list by picking the K top ranked intentions from the list. With this ranking list, the two metrics are defined as follows,

- **Prec@K.** If $rank(s_g) \leq K$, we have a *True Positive* case. To avoid biases from consumption intentions with a large amount, we computes the precision for each intention type and then compute the mean for all intention types.
- **NDCG@K.** If $rank(s_g) \leq K$, we have a hit and otherwise, we have a miss. It assigns higher scores to hits at a higher position in the ranking list, which emphasizes that for each test case, the right intention should be ranked as higher as possible.

In our experiments, we use the popular setting of $K = 1, 3, 5$ [12, 34] for evaluation.

4.2 Overall Performance

We start by comparing the performance of our proposed GRIP with all other baselines. The result is reported in Table 3. From the result, we have the following observations.

- **Our proposed GRIP outperforms all the baselines significantly.** Benefiting from the interaction graph with multi-behaviors and spatio-temporal graph for dynamic context, GRIP is capable of modeling user intrinsic preference and context-aware consumption intentions. Compared to all baseline methods, GRIP obtains the best performance in terms of Prec@K and NDCG@K. Specifically, its relative improvements over the strongest baselines are 10.80% for Prec@1, 13.56% for Prec@3, 6.43% for Prec@5, 43.68% for NDCG@3 and 22.87% for NDCG@5. On average, it outperforms the best baseline by 10.26% for Prec and 33.28% for NDCG. Such improvements on various metrics demonstrate the effectiveness of GRIP.
- **Traditional feature-based prediction models perform worse than graph-based models.** We can observe that those feature-based methods achieve a worse performance compared with graph embedding based models and graph neural network based models. The average performance of graph-based models is higher than the best performance of feature-based models in terms of 6.52% for Prec@1, 5.39% for Prec@3, 17.35% for Prec@5, 4.13% for NDCG@3 and 6.14% for NDCG@5, wihch indicates the graph's power to model the complex relationship among different influencing factors in our problem.
- **Graph convolutional methods achieve better performance compared with normal graph embedding models.** SA-GCN and SA-LightGCN, which derive the node representation by aggregating the features appearing in the neighborhood, perform better than ReconEmbed and GraphEmbed, which learn representations for nodes only to preserve their correlations. This indicates that high-order structure information can benefit the intention prediction.
- **User intrinsic preference modeling is essential.** The performance of the three models, ReconEmbed, GraphEmbed and SA-GCN, which are not able to make use of the interaction between users and item categories and only take spatio-temporal context information into account, drops significantly compared with other graph-based models. This demonstrates that modeling users intrinsic preference from interaction-data is essential for consumption intention prediction.

In general, the prediction performance not only justifies the effectiveness of our model, but also demonstrates the rationality of our design to model both user intrinsic preference and spatio-temporal context information for consumption intention prediction.

4.3 Ablation Study

In GRIP, we utilize a dual-stage graph neural network to combine intrinsic preference of users and spatio-temporal context influence to predict users' consumption intentions. An intuitive question is whether the designed component really help in our model?

To answer it, we conduct experiments on two types of degenerative methods of GRIP. The first type is to remove the utilized components from the full model, which is called model ablation, while the second type is to remove some types of data we use, which is called data ablation. We adopt the same evaluation methods with above experiments, and the performance comparison is shown in Figure 4.

Model Ablation Study In order to evaluate the effect of user intrinsic preference learning and disentangling intention embedding, we remove these two parts from the full prediction model, respectively. The result is shown in Figure 4(a).

It is shown that the complete model outperforms the model without user intrinsic preference learning and the model without disentangling intention embedding by 16.85% and 5.6% on Prec@3 and 18.51% and 6.67% on NDCG@3, respectively. This demonstrates that both the intrinsic preference learning and disentangling intention embedding are essential in users' consumption intention prediction.

Data Ablation Study We use multi-behavior data in user intrinsic preference learning, including clicking, browsing and purchasing. In order to evaluate the effect of the importance of different behaviors and the effectiveness of multi-behavior information, we use only one type of behavior in the interaction graph each time and the performance is shown in Figure 4(b).

It is shown that multi-behavior data performs better than any single-behavior data by at least 8.25% on Prec@3 and 9.71% on NDCG@3. Besides, comparing the performance of single-behavior data, we can find that clicking data leads to the best performance of learning user intrinsic preference while purchasing data performs worst. This demonstrates that single-behavior data leads to the loss of some of the information in user intrinsic preference modeling.

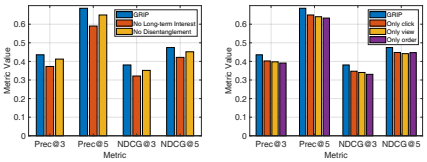

(a) Model Ablation (b) Data Ablation

Figure 4: Performance comparison of ablation study.

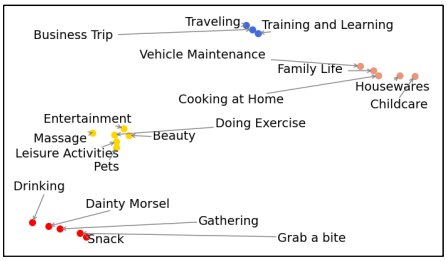

Figure 5: Visualization of the learned t-SNE transformed representations derived for disentangled embedding of consumption intentions.

Moreover, compared with the sparse purchasing data, clicking and browsing data can better reflect the intrinsic preference of users.

4.4 Case Study

To analyze the effectiveness of disentangling and the representation of consumption intentions, we perform their visualization for embeddings showing in Figure 5. We set the number of disentangled independent parts $K = 4$ and record the output embeddings. Then, we project them to 2D for visualization using t-SNE [27] where the 2D result will be more clustered if the embedding vectors are more similar. As we can observe, the intentions are well separated into four clusters, which demonstrates that the intentions are not isolated but have certain relations, specifically, clustering structure. For example, the first category, which contains Snack, Grab a bite, Gathering , Dainty Morsel and Drinking are intentions related to eating or drinking outside. This verifies that although the internal structure of consumption intention is complex, GRIP is capable of capturing their relations and structure with the help of disentangled representations of consumption intentions.

5 INDUSTRIAL RESULTS

We conduct online A/B tests to evaluate the effectiveness of our designed system's online performance, including consumption intention detection and prediction. Specifically, we deploy it at the recommendation engine for Meituan mobile App's Homepage, which is the page with the most user behaviors. At the App's Homepage, as shown in Figure 6(a), a personalized list of local services can be exposed to user. As we have mentioned above, consumption intention, as the internal driving force of users' consumption behaviors,

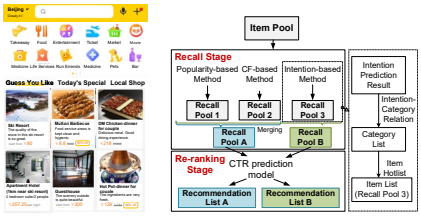

(a) Meituan App's homepage. (b) Online recommendation engine

Figure 6: Illustration of Meituan App's homepage and its recommendation engine.

can well support predicting the behaviors, which is consistent with the goal of the recommendation scenario at the Home Page. The user intention can be correlated to a list of services by matching with services' profiles. Specifically, we first get the category list related to the intentions with top prediction scores and then for each category, we select the items with top real-time sales to generate the recall pool. That is, our consumption intention system can generate a list of services (Recall Pool B in Figure 6(b)). This pool, together with other two pools generated by two other strategies of popularity and collaborative filtering (CF), can be fed into the re-ranking stage for obtaining the final recommendation list. The online A/B tests are conducted from October 31st to November 7th, 2020, involving about 8 millions of users.

We first evaluate the intention prediction module of our system. To ensure the results can reflect the effect of intention detection, for intention prediction we only adopt a very simple DeepFM model [8]. We randomly divide users into two buckets, each of which has similar amount of users, and assign them different recall strategies. Specifically, for the first bucket we adopt popularity-based and CF-based recall. For the second bucket, there is an additional intention-based recall. Note that we keep all the other modules exactly the same for fair comparison. Two important metrics measuring the quality of recommendation list, *Page View* (PV) and *Page View for Cold-start Customer* (PV-CC) are used, of which PV-CC emphasizes whether the recommendation list can attract users to consume a new kind of service. The relative improvements in different Business Units (BUs) of the second bucket (of which our system are introduced) compared with the first one are shown in Table 4.

From the result, we can observe that for all BUs there are average relative improvements of about 1.55% on PV and 5.15% on PV-CC. Such improvement can lead to great increase in consumption amount of the platform. Among these BUs, PV improves most in `Holidays` by 4.01%, while PV-CC improves most in `Flash Sale`, which is a new BU launched by Meituan in 2018, by 11.79%. This shows the intention-based recall can help customers explore types of services that has not consumed before greatly. This further validates that directly learning from the behavior data may cause the model highly constrained by the historical behaviors, as we mentioned in Introduction. Moreover, the slightly decreases of 0.91% on PV and 0.51% on PV-CC for `Catering` and 0.83% on PV and 0.92% on PV-CC for `Hotel`, are also within the normal fluctuation range of the market.

We further evaluate our proposed intention prediction model GRIP. We randomly divide users into three buckets, each of which has similar amount of users, and assign them different intention prediction models. Specifically, we deploy MLP (Multi-layer perceptrons), DeepFM, and our proposed GRIP as the intention-prediction model, respectively. We also keep all the other modules the exactly same. Two metrics, Prec@3 (precision of intention prediction) and *Customer Growth of All Business Units, shorted as CG* are used. The reason of using CG, instead of PV or PV-CC, is that CG is a more critical metric that can better distinguish good or ordinary intention prediction models. The results of different buckets are shown in Figure 7. We can observe that our proposed GRIP can bring about relative improvement of about 44.7% on Prec@3 and 83.9% on CG compared with the DeepFM model. This demonstrates the effectiveness of our proposed GRIP in accurately predicting user consumption intention and then generating higher-quality recommendation results.

In short, we conduct extensive online A/B tests on million-level users to evaluate the real-world performance of our system. The results demonstrate that a) intention prediction can largely benefit the personalized recommendation, especially in recommending cold-start service types, and b) our proposed intention prediction model, GRIP, can achieve promising results of customer growth.

BU	PV	PV-CC
Holidays	+4.01%	+7.33%
Catering	-0.91%	-0.51%
Flash Sale	+1.73%	+11.79%
Kids	+3.16%	+10.10%
Beauty	+2.17%	+3.11%
Hotel	-0.83%	-0.92%

Table 4: Result of online A/B experiments for our recall model.

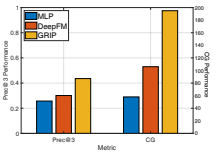

Figure 7: Result of online A/B experiments for intention prediction model.

6 RELATED WORK

Consumption Intention Prediction Consumption intention of users is an important factor to be considered nowadays, especially for recommender systems. The focus of some recent studies has turned to what users want (user intention) from what users like (user behavior) and these studies can be divided into two types. The first type is to use the term intention to refer to the behavior [4, 30, 31], product category [4] or query words [7]. Wang and Hu [30, 31] indicate the complex relations between user behaviour and intentions that intentions are the driving factors of actions and one intention requires a series of relevant actions to accomplish with psychological theories. So they use the series of relevant actions to represent the intention. Chen and Yin [4] claim that user intention carries two aspects of information: the category of products that a user tends to interact with and the way the user wants to perform the interaction. Thus, they formulate user intention as a tuple of action type (e.g., click, purchase, etc.) and product category tag, i.e., (action, category). Fan and Zhu [7] present several words describing the product in the search box without any input from users as the result of their intent recommendation.

In another type of researches, they utilize latent representation for intentions [19, 29, 33] to improve the accuracy of recommender systems. Wang and Jin [33] establish as set of intent-aware graphs, based on the fact that a user generally has multiple intents to adopt certain items and different intents could motivate different user behaviors, to learn latent representations for intents and distill the signals of user intents. Liu and Chen [19] set an intent embedding for the instant intent of users' current browsing and employ the intent embedding for online recommender systems.

Different from the researches above, in this work, we propose to explicitly express the desire or demand of users to consume a kind of service or product as the consumption intention.

Heterogeneous Graph Recently, the heterogeneous graph, consisting of multiple types of nodes and/or links, has been leveraged as a powerful modeling method to fuse complex information and applied to many tasks such as recommender system [7, 24, 32] and natural language processing [2, 18]. The usage of semi-supervised models [14, 28, 32, 36], where there exist some labeled vertices for representation learning enriches the representation ability in heterogeneous graphs. For example, GCN [14] proposed a localized graph convolutions to improve the performance in a classification task. GAT [28] used self-attention network for information propagation, which leverages a multi-head attention mechanism. GCN and GAT are popular architectures of the general graph networks and can be regarded as plug-in graph representation modules in heterogeneous graph, such as HetGNN [36], HAN [32]. In this work, we take advantage of heterogeneous graph to model different kinds of influencing factors for consumption intention prediction and learn representations for them.

Disentangled Representation Learning In consumption intention prediction task, the internal structure of consumption intention is complex, which makes it difficult to learn. Recently, some works [5, 33, 39] utilize the disentangled representation learning method for capturing different influencing factors, respectively. In this work, we target at exploiting the relations and structure of intentions rather than the influencing factors to learn disentangled representations for consumption intentions. The result demonstrates that there is indeed a clustering structure of which the intentions belonging to one cluster are highly correlated and similar, while there are great contrasts among the intentions belonging to different clusters for consumption intentions. Moreover, the disentangled representation is able to capture the inter-cluster difference and inner-cluster closeness.

7 CONCLUSION

In this work, we build a system consisting of consumption intention detection and prediction to understand the internal driven force of user consumption behaviors. The consumption intention detection method aims to explicitly reveal intentions of users' consumption from their reviews. For prediction, we design a dual-stage graph convolutional network model. Offline experimental results demonstrate that our prediction model can improve the performance by 6%-43% over state-of-the-art prediction models. Our system has also been successfully deployed on the Meituan's mobile App's Home Page. Results on the billion-scale industrial dataset further confirm the effectiveness of our system in practice.

REFERENCES

[1] Chong Chen, Min Zhang, Yiqun Liu, and Shaoping Ma. 2018. Neural attentional rating regression with review-level explanations. In *WWW*. 1583–1592.

[2] Kunlong Chen, Weidi Xu, Xingyi Cheng, Zou Xiaochuan, Yuyu Zhang, Le Song, Taifeng Wang, Yuan Qi, and Wei Chu. 2020. Question Directed Graph Attention Network for Numerical Reasoning over Text. *arXiv preprint arXiv:2009.07448* (2020).

[3] Tianqi Chen and Carlos Guestrin. 2016. XGBoost: A Scalable Tree Boosting System. *SIGKDD* (2016), 785–794.

[4] Tong Chen, Hongzhi Yin, Hongxu Chen, Rui Yan, Quoc Viet Hung Nguyen, and Xue Li. 2019. Air: Attentional intention-aware recommender systems. In *ICDE*. IEEE, 304–315.

[5] Weiguang Chen, Wenjun Jiang, Xueqi Li, Kenli Li, Albert Zomaya, and Guojun Wang. 2020. Semi-Disentangled Representation Learning in Recommendation System. *arXiv preprint arXiv:2010.13282* (2020).

[6] Zhiyong Cheng, Ying Ding, Xiangnan He, Lei Zhu, Xuemeng Song, and Mohan S Kankanhalli. 2018. Aˆ 3NCF: An Adaptive Aspect Attention Model for Rating Prediction.. In *IJCAI*. 3748–3754.

[7] Shaohua Fan, Junxiong Zhu, Xiaotian Han, Chuan Shi, Linmei Hu, Biyu Ma, and Yongliang Li. 2019. Metapath-guided heterogeneous graph neural network for intent recommendation. In *KDD*. 2478–2486.

[8] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He. 2017. DeepFM: a factorization-machine based neural network for CTR prediction. *arXiv preprint arXiv:1703.04247* (2017).

[9] Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, and Meng Wang. 2020. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. *arXiv preprint arXiv:2002.02126* (2020).

[10] Xiangnan He, Lizi Liao, Hanwang Zhang, Liqiang Nie, Xia Hu, and Tat-Seng Chua. 2017. Neural collaborative filtering. In *Proceedings of the 26th international conference on world wide web*. 173–182.

[11] Bowen Jin, Chen Gao, Xiangnan He, Depeng Jin, and Yong Li. 2020. Multi-behavior recommendation with graph convolutional networks. In *SIGIR*. 659–668.

[12] Manas R Joglekar, Cong Li, Mei Chen, Taibai Xu, Xiaoming Wang, Jay K Adams, Pranav Khaitan, Jiahui Liu, and Quoc V Le. 2020. Neural input search for large scale recommendation models. In *SIGKDD*. 2387–2397.

[13] Diederik P Kingma and Jimmy Ba. 2014. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980* (2014).

[14] Thomas N Kipf and Max Welling. 2016. Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907* (2016).

[15] Yehuda Koren, Robert Bell, and Chris Volinsky. 2009. Matrix factorization techniques for recommender systems. *Computer* 42, 8 (2009), 30–37.

[16] Quoc Le and Tomas Mikolov. 2014. Distributed representations of sentences and documents. In *ICML*. 1188–1196.

[17] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. 2017. Focal loss for dense object detection. In *ICCV*. 2980–2988.

[18] Hu Linmei, Tianchi Yang, Chuan Shi, Houye Ji, and Xiaoli Li. 2019. Heterogeneous graph attention networks for semi-supervised short text classification. In *(EMNLP-IJCNLP*. 4823–4832.

[19] Zhaoyang Liu, Haokun Chen, Fei Sun, Xu Xie, Jinyang Gao, Bolin Ding, and Yanyan Shen. 2020. Intent Preference Decoupling for User Representation on Online Recommender System. In *IJCAI*.

[20] Jianxin Ma, Chang Zhou, Peng Cui, Hongxia Yang, and Wenwu Zhu. 2019. Learning disentangled representations for recommendation. *arXiv preprint arXiv:1910.14238* (2019).

[21] Julian McAuley and Jure Leskovec. 2013. Hidden factors and hidden topics: understanding rating dimensions with review text. In *RecSys*. 165–172.

[22] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. 2013. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781* (2013).

[23] Steffen Rendle, Christoph Freudenthaler, Zeno Gantner, and Lars Schmidt-Thieme. 2012. BPR: Bayesian personalized ranking from implicit feedback. *arXiv preprint arXiv:1205.2618* (2012).

[24] Chuan Shi, Binbin Hu, Wayne Xin Zhao, and S Yu Philip. 2018. Heterogeneous information network embedding for recommendation. *TKDE* 31, 2 (2018), 357–370.

[25] Gábor J Székely, Maria L Rizzo, et al. 2009. Brownian distance covariance. *The annals of applied statistics* 3, 4 (2009), 1236–1265.

[26] Gábor J Székely, Maria L Rizzo, Nail K Bakirov, et al. 2007. Measuring and testing dependence by correlation of distances. *The annals of statistics* 35, 6 (2007), 2769–2794.

[27] Laurens Van der Maaten and Geoffrey Hinton. 2008. Visualizing data using t-SNE. *Journal of machine learning research* 9, 11 (2008).

[28] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Lio, and Yoshua Bengio. 2017. Graph attention networks. *arXiv preprint arXiv:1710.10903* (2017).

[29] Chenyang Wang, Weizhi Ma, Min Zhang, Chong Chen, Yiqun Liu, and Shaoping Ma. 2020. Toward Dynamic User Intention: Temporal Evolutionary Effects of Item Relations in Sequential Recommendation. *TOIS* 39, 2 (2020), 1–33.

[30] Shoujin Wang, Liang Hu, Yan Wang, Quan Z Sheng, Mehmet Orgun, and Longbing Cao. 2020. Intention nets: psychology-inspired user choice behavior modeling for next-basket prediction. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 34. 6259–6266.

[31] Shoujin Wang, Liang Hu, Yan Wang, Quan Z Sheng, Mehmet Orgun, and Longbing Cao. 2020. Intention2Basket: A Neural Intention-driven Approach for Dynamic Next-basket Planning. In *IJCAI*. 2333–2339.

[32] Xiao Wang, Houye Ji, Chuan Shi, Bai Wang, Yanfang Ye, Peng Cui, and Philip S Yu. 2019. Heterogeneous graph attention network. In *WWW*. 2022–2032.

[33] Xiang Wang, Hongye Jin, An Zhang, Xiangnan He, Tong Xu, and Tat-Seng Chua. 2020. Disentangled Graph Collaborative Filtering. In *SIGIR*. 1001–1010.

[34] Su Yan, Xin Chen, Ran Huo, Xu Zhang, and Leyu Lin. 2020. Learning to Build User-tag Profile in Recommendation System. In *CIKM*. 2877–2884.

[35] Yue Yu, Tong Xia, Huandong Wang, Jie Feng, and Yong Li. 2020. Semantic-aware spatio-temporal app usage representation via graph convolutional network. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies* 4, 3 (2020), 1–24.

[36] Chuxu Zhang, Dongjin Song, Chao Huang, Ananthram Swami, and Nitesh V Chawla. 2019. Heterogeneous graph neural network. In *KDD*. 793–803.

[37] Chao Zhang, Keyang Zhang, Quan Yuan, Haoruo Peng, Yu Zheng, Tim Hanratty, Shaowen Wang, and Jiawei Han. 2017. Regions, periods, activities: Uncovering urban dynamics via cross-modal representation learning. In *WWW*. 361–370.

[38] Lei Zheng, Vahid Noroozi, and Philip S Yu. 2017. Joint deep modeling of users and items using reviews for recommendation. In *ACM WSDM*. 425–434.

[39] Yu Zheng, Chen Gao, Xiang Li, Xiangnan He, Yong Li, and Depeng Jin. 2020. Disentangling user interest and popularity bias for recommendation with causal embedding. *arXiv preprint arXiv:2006.11011* (2020).

A APPENDIX FOR REPRODUCIBILITY

In the appendix, we give the details of baseline models and parameter settings in the experiment of intention prediction. The hyper-parameter study of our proposed consumption intention prediction method, GRIP is then given.

A.1 Baseline Model

We give the implementation details about all compared methods as follows.

- **XGBoost** [3]: It is a gradient boosted classification tree approach based on the gradient boosting machine. The weight for each factor is updated during training and the forecasting result is calculated as the weighted sum of all factor values.
- **DeepFM** [8]: It combines FM and deep neural network to low and high order feature combinations simultaneously. We utilize a fully-connected layer for prediction with the concatenation of all feature combinations as the input.
- **ReconEmbed** [37]: It is a general representation learning model for spatio-temporal activity prediction and samples random-walks from the graph to learn embedding vectors for nodes. We adapt this method to a graph with three kinds of nodes: time, location and intention. We utilize time and location embedding to generate context-aware intention representation and the prediction function of inner product to calculate the score for different consumption intentions.
- **GraphEmbed** [37]: It is a general representation learning model for spatio-temporal activity prediction and learns low-dimensional representations by preserving first and second-order proximities in the graph. We adapt this method to a graph with three kinds of nodes: time, location and intention and three types of edge types for the co-occurrence relations. We utilize time and location embedding to generate context-aware intention representation and the prediction function of inner product to calculate the score for different consumption intentions.
- **SA-GCN** [35]: It is a state-of-the-art method in spatio-temporal prediction and adopts Graph Convolutional Network (GCN) with meta path-based objective function to combine the structure of graoh and the attribute of nodes. We adapt this method to the graph with three kinds of nodes: time, location and intention and three types of edge for the co-occurrence relations. We utilize time and location embedding to generate context-aware intention representation and the prediction function of inner product to calculate the score for different consumption intentions.
- **SA-LightGCN** [9]: It is a state-of-the-art method to learn node representations and capture interactions between nodes. We adapt this method to the graph with four kinds of nodes: user, item category, time and location and four types of edge for the co-occurrence relations and use pair-wise interaction for each single-typed edge with the transformation methods in LightGCN. We utilize user, time and location embedding to generate context-aware intention representation and the prediction function of inner product to calculate the score for different consumption intentions.
- **HAN** [32]: It is a general heterogeneous graph learning method to obtain representations of the nodes by aggregating information from the features of their neighboring nodes with different type-level attention and node-level attention. We adapt this method to the graph with four kinds of nodes: user, item category, time and location. We utilize user, time and location embedding to generate context-aware intention representation and the prediction function of inner product to calculate the score for different consumption intentions.
- **HetGNN** [36]: It is a stat-of-the-art heterogeneous graph learning method. For each node, it first aggregate the features of its neighbors of each type, and then aggregate the neighbors information of different types with attention. We adapt this method to the graph with four kinds of nodes: user, item category, time and location. We utilize user, time and location embedding to generate context-aware intention representation and the prediction function of inner product to calculate the score for different consumption intentions.

A.2 Parameter Setting

For above baselines, we explore hyper-parameters similarly as the original paper. For our dual graph neural network consumption intention prediction model, GRIP, we list the parameters in the user intrinsic preference modeling graph and the spatio-temporal context modeling graph respectively in following. For user intrinsic preference modeling graph, the node embedding size is set to 32, which is suitable to learn a strong representation embedding for users and item category [6, 11]. We try several layers for this graph and find $L = 3$ to be the best. For spatio-temporal context modeling graph, the node embedding size is set to be 96 (where the embedding size for each type of feature vector is 32). The number of discrete time units in one day is set to 24. We try several layers for this graph and find $L = 2$ to be the best.

We optimize all deep learning models with Adam optmize [13], having batch size fixed to 2048. We search L_2 regularizer and learning rate in $[10^{-6}, 10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}]$ and [0.001, 0.005, 0.01, 0.05, 0.1], respectively. Furthermore, we use early stop to detect over-fitting, and the training process will be stopped if Prec@3 on the validation set does not increase for 20 epochs.

A.3 Hyper-Parameter Study

We analyze the effects of two hyper-parameters used in our consumption intention prediction model, GRIP, including the number of disentangled independent parts of intention representations and the coefficient in the joint loss.

- **Number of disentangled independent parts of intention representations.** We vary it in [1,6] (where 1 means) and compare the intention performance of all metrics, which is shown in Figure 8. We can observe that even only one selected series to be used in the decoding stage, the forecasting performance can have a huge improvement, compared with not using OMN. Furthermore, within a certain range [1-6] (where K = 1 means not restricting the latent representation of intentions to be disentangled), the forecasting precision continuously increase as number of independent components gets larger but tends to get worse when it exceeds 4.
- **Coefficient in the joint loss.** It controls the weight of each component in GRIP and is a very important parameter of

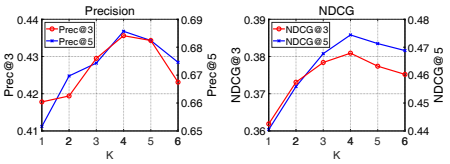

(a) Precission (b) NDCG

Figure 8: Impact of number of disentangled parts of intention embeddings.

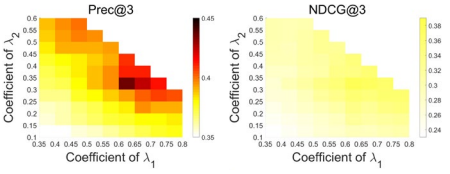

(a) Prec@3 (b) NDCG@3

Figure 9: Impact of coefficient in the joint loss.

our method. Note that $\lambda_1 + \lambda_2 + \lambda_3 = 1$, we tune λ_1 in $[0.1, 0.15, 0.2, 0.25, 0.3, 0.35, 0.4, 0, 45, 0.5, 0.55, 0.6]$ and λ_2 in $[0.35, 0.4, 0.45, 0.5, 0.55, 0.6, 0.65, 0.7, 0.75, 0.8]$. Then we plot the performance of Acc@3 and NDCG@3 in Figure 9. When λ_1 and λ_2 are given, then value of λ_3 is determined. Therefore each block represents a setting of $(\lambda_1, \lambda_2, \lambda_3)$. And in these three figures, deeper blocks means better performance. The best performance of GRIP is achieved at the same setting, $(0.3, 0.6, 0.1)$ for both metrics, which represent a relatively large λ_2 which is the coefficient of prediction loss and a relatively low coefficient of disentangling loss. This is also consistent with the findings in our ablation study. The result is shown in Figure 9.

Learning Self-Modulating Attention in Continuous Time Space with Applications to Sequential Recommendation

Chao Chen [1] **Haoyu Geng** [1 2] **Nianzu Yang** [1 2] **Junchi Yan** [1 2] **Daiyue Xue** [3] **Jianping Yu** [3] **Xiaokang Yang** [1 2]

Abstract

User interests are usually dynamic in the real world, which poses both theoretical and practical challenges for learning accurate preferences from rich behavior data. Among existing user behavior modeling solutions, attention networks are widely adopted for its effectiveness and relative simplicity. Despite being extensively studied, existing attentions still suffer from two limitations: i) conventional attentions mainly take into account the spatial correlation between user behaviors, regardless the distance between those behaviors in the continuous time space; and ii) these attentions mostly provide a dense and undistinguished distribution over all past behaviors then attentively encode them into the output latent representations. This is however not suitable in practical scenarios where a user's future actions are relevant to a small subset of her/his historical behaviors. In this paper, we propose a novel attention network, named *self-modulating attention*, that models the complex and non-linearly evolving dynamic user preferences. We empirically demonstrate the effectiveness of our method on top-N sequential recommendation tasks, and the results on three large-scale real-world datasets show that our model can achieve state-of-the-art performance.

1. Introduction

Preference learning is of critical importance in modern machine learning applications, such as online advertising, E-commerce and social media. Often, users' preferences are not static and evolve over time due to a variety of reasons. For example, a user's interest in a particular brand might fade away due to maturity or a change in lifestyle. Nonetheless, it is difficult to model all causal aspects explicitly (Widmer & Kubat, 1996; Koren, 2009; Wu et al., 2017).

To model the dynamics in user preferences, many research works (Kang & McAuley, 2018; Ying et al., 2018; Zhou et al., 2018; Zhang et al., 2019) develop different attention mechanisms to learn the sequential patterns of how users' future actions are interacted with previous behaviors, and so far have achieved state-of-the-art performance on many benchmark datasets. The majority of these attentions (implicitly) assume that the underlying sequential patterns are time independent(Kumar et al., 2019; Li et al., 2020; Chang et al., 2020). This is however contradicted with the fact that more recent behaviors will have more impact on the future actions, or more specifically identical behavior sequences of two users with different time intervals should have different implications on their current and future decisions.

To tackle the challenging problem, recent approaches generalize the notion of positional embedding to continuous time (Xu et al., 2019; Shukla & Marlin, 2021). The idea behind these approaches is to encode periodic patterns dependent on the progression of time into a high-dimensional vector space (i.e., time embedding), then by using translation-invariant random Fourier features (Rahimi & Recht, 2007; Yu et al., 2016) to approximately measure the temporal distance between user behaviors in the sequence.

Orthogonal to prior studies, we focus on two pertinent questions fundamental to attention-based preference learning in continuous time space: (i) *how can attentions model the impact of both sequential positions and continuous timestamps in an explicit manner?* — This matters a lot for business, as it helps to better understand users and their needs (Zhang & Chen, 2020; Arrieta et al., 2020; Chen et al., 2021a); and (ii) *how can attentions identify sparse behaviors interacted with future actions?* — Existing techniques in this direction mainly base on sparsemax (Martins & Astudillo, 2016; Niculae & Blondel, 2017) to yield sparse distributions over past behaviors. These approaches tend to preserve very limited temporal information which leads to the difficulty to capture complex and fine-grained temporal dynamics.

In this paper, we propose a novel attention mechanism,

[1]MoE Key Lab of Artificial Intelligence, AI Institute, Shanghai Jiao Tong University, Shanghai, China [2]Department of Computer Science and Engineering, Shanghai Jiao Tong University, Shanghai, China [3]Meituan, Beijing, China. Correspondence to: Junchi Yan <yanjunchi@sjtu.edu.cn>.

Proceedings of the 38^{th} International Conference on Machine Learning, PMLR 139, 2021. Copyright 2021 by the author(s).

named self-modulating attention, to model the complex evolution of user preferences over time. More specifically, our attention explicitly digests temporal dynamics via a conditional intensity function that specifies whether the observed behaviors are relevant with users' future interests at a given time point: high (low) intensities of the behaviors amplify (attenuate) their contributions in the output representations. Here the term *self-modulating* is meant to encompass above positive and negative effects of a single sequence to compute the representation of the same sequence. We further propose continuous time regularization to penalize intensities, as the source of supervised signal for preference learning is mostly coming from the behavior data that is independent of time.

Intuition. Existing attention mechanism is based on the correlation between the query and keys (or between the past and current events for sequential behavior modeling), while such correlation is not modeled as a function of time. However, for real-world behavior modeling e.g. sequential recommendation in the continuous time space, a user's behavior pattern may vary over time.

Theoretical Motivation. More interestingly, in this paper we theoretically show (see details in Theorem 1) under a bounded impact of the past behavior to future actions, more sparse behaviors can lead to higher generalization ability for a prediction model. This theory motivates us to design a mechanism for more effectively uncovering such truly useful past behaviors in a more discriminative manner.

Technical Implementation. Based on the above intuitive and theoretical analysis, in this paper we aim to develop a time sensitive attention mechanism to adaptively and predictively re-weight the past behaviors for their impact to current scoring. The temporal point process is used for its interpretable and rigorous Bayesian nature. The conditional intensity function is used to modulate and soften the time-varying attention in continuous time space.

The key contributions of this paper are as follows:

- We establish a theoretical bound for attention based approaches in preference learning, showing the benefits of bounded and sparsified impact of behavior history.
- To better explore the behavior history, we develop a notion of self-modulating attention, with the classic attention as a special case of our model. Our work concerns modeling attentions informed by time-dependent uncertainties.
- To effectively incorporate the temporal model into preference learning, we develop a continuous time regularizer to fill the gap between traditional preference learning and continuous-time temporal process modeling.
- Top-N recommendation results on benchmark datasets demonstrate that our self-modulating attention outperforms state-of-the-art methods by a notable margin, and it can also be reused as an orthogonal plug-in for existing methods.

2. Related Work

User modeling is of crucial importance in many online applications such as advertising, E-commerce and social media. In general, the goal of user modeling is to learn user representations from the complex and abundant behavior data (Adomavicius & Tuzhilin, 2005; Su & Khoshgoftaar, 2009).

Traditional Recommendation Approaches. Traditional approaches usually assume that user preference is static, and collaborative filtering (CF) (Herlocker et al., 1999; Sarwar et al., 2001) is one of the most popular approaches due to ease of implementation and quality of recommendation. Among existing CF solutions, matrix approximation based methods (Koren, 2008; Koren et al., 2009; Chen et al., 2015; Li et al., 2017; 2021) have achieved state-of-the-art performance in many benchmark datasets, especial for Netflix prize data (Bennett & Lanning, 2007). However, in practice, user preferences often drift over time due to various reasons.

Sequential Recommendation Approaches. To address the problem, FPMC (He & McAuley, 2016) and its hierarchical version HRM (Wang et al., 2015), propose to use Markov chains to model sequential patterns by learning user-specific transition matrices. These approaches have been proved to be able to capture short-term patterns. The major concern behind them is the potential state space explosion intractability in face of different possible sequences over items (He et al., 2017a; Wu et al., 2017; Chen et al., 2021b).

Another emerging line focuses on modeling sequential patterns by using recurrent neural networks. For example, RRN (Wu et al., 2017) and GRU4REC (Hidasi et al., 2016) exploit LSTM (Hochreiter & Schmidhuber, 1997) or GRU (Chung et al., 2014) module to capture dynamic user preferences dependent on sequence positions. Meanwhile, SHAN (Ying et al., 2018), RUM (Chen et al., 2018), DIN (Zhou et al., 2018) and SASREC (Kang & McAuley, 2018) introduce attention mechanisms to sequential recommendation problems. Compared with recurrent networks, attentions have shorter path to access distant positions, and thereby achieve superior performance in many cases (Vaswani et al., 2017).

Temporal Recommendation Approaches. Compared to sequential recommendation problem that has been well studied, relatively less attention has been paid to temporal recommendation algorithms. The prominent work timeSVD++ (Koren, 2009) proposes the use of explicit temporal bias to model the discrete time dynamics. Apart from hand engineered features, the authors in (Lu et al., 2016) develop a vector auto-regressive model to predict future user preferences. Empirical results have shown state-of-the-art performance on many benchmark datasets, but the costly computational overhead and memory use make it hard to support large-scale industrial applications.

Another line of works follow the idea of positional em-

bedding which designs time embedding to capture temporal information, with attention mechanisms for end-to-end learning (Liu et al., 2020). The authors in (Li et al., 2020) divide the time into intervals and project them to low-dimensional space. This treatment discretizes the time and reduces the power of modeling fine-grained temporal information (Trivedi et al., 2019; Chang et al., 2020). By contrast, the works (Xu et al., 2019; Shukla & Marlin, 2021) learn functions of continuous time to capture the dynamics.

Distinct from the above approaches, our method involves reweighting of attention coefficients according to the intensity function of temporal point processes (Daley & Vere-Jones, 2003), such that self-modulation can be achieved based on continuous time information. Thanks to the intensity powered by neural networks, our self-modulating attention is enabled to model complex evolving dynamics in continuous time space.

Temporal point process has been shown powerful for temporal modeling. The work (Zhou et al., 2013) deals with mutual-excitation of event sequences, with a regularizer on the sparseness and low-rank assumption of mutual correlations. As the rise of deep learning, recurrent neural networks are widely adopted to model temporal dynamics (Mei & Eisner, 2017; Trivedi et al., 2017; Xiao et al., 2017), which are further replaced or enhanced by attentions (Zhang et al., 2020; Zuo et al., 2020). We argue that these works are in general orthogonal to ours, as they focus on the modeling of event times rather than preference learning. In fact, our work can enjoy the advances in (Zhang et al., 2020; Zuo et al., 2020) to improve the expressiveness.

This paper focuses on developing a new attention dependent on both sequential positions and continuous timestamps. More specifically, we generalize the formulation of existing attentions by introducing the intensity function, which specifies if user tastes on the items are changed or not. Compared to existing sequential recommendation models, the difference lies in the ability to model temporal dynamics in the continuous time space.

3. Notations and Preliminaries

Throughout this paper, we denote scalars by either lowercase or uppercase letters, vectors by boldface lowercase letters, and matrices by boldface uppercase letters. Unless otherwise specified, all the vectors are column vectors.

Let $\mathcal{S} = \{(t_j, i_j)\}_{j=1}^{L}$ be a user behavior sequence, each pair (t_j, i_j) denotes that item i_j is rated at time t_j. Then the attentions can be generally defined by, given any query vector $\mathbf{q}$ and the sequence $\mathcal{S}$:

$$\mathrm{Att}(\mathbf{q}|\mathcal{S}) = \sum_{j'=1}^{n} p(\mathbf{v}_{j'}|\mathcal{S})\mathbf{v}_{j'} = \mathbb{E}_{p(\mathbf{v}|\mathcal{S})}\mathbf{v}, \qquad (1)$$

where n is the number of items and the distribution $p(\mathbf{v}|\mathcal{S})$ attentively aggregates all the value vectors $\{\mathbf{v}_{j'}\}_{j'=1}^{n}$.

In the scaled dot-product attention (Vaswani et al., 2017), $p(\mathbf{v}_{j'}|\mathcal{S})$ equals to $\eta \exp(\mathbf{q}^\top \mathbf{k}_{j'}/\sqrt{d})$ if the item j' is in the sequence $\mathcal{S}$ and equals to zero otherwise, where η is used for normalization i.e., $\eta^{-1} = \sum_{(t,i)\in\mathcal{S}} \exp(\mathbf{q}^\top \mathbf{k}_i/\sqrt{d})$. In the masked version, we should use $p(\mathbf{v}_{j'}|\mathcal{H}_t)$ where $\mathcal{H}_t = \{(t_j, i_j)|t_j < t\}$ signifies the history up to time t.

In the vast literature of sequential recommendation, attention mechanisms have been widely adopted to capture the dynamic user preferences. Most of these approaches (Ying et al., 2018; Kang & McAuley, 2018; Ma et al., 2019) can be generally formulated as follows:

$$\hat{\mathbf{R}} = \mathbf{PVB} \quad \text{and} \quad \mathbf{P}_{u,i} = p(\mathbf{v}_i|\mathcal{H}_t^{(u)}), \qquad (2)$$

where $\hat{\mathbf{R}}$ denotes the estimate of the underlying matrix $\mathbf{R}$ with m users and n items, $\mathbf{P} \in \mathbb{R}^{m\times n}$ signifies the correlations between the past behaviors and future actions, $\mathbf{V} \in \mathbb{R}^{n\times d}$ denotes the value matrix, and $\mathbf{B} \in \mathbb{R}^{d\times n}$ acts as the output transformation matrix and can also be viewed as item feature matrix. Notably, the nonlinear projection $\phi(\mathbf{PV}, \mathbf{B})$ as in (He et al., 2017b), can also be formed as Eq. (2). This is because the ranking score is usually a non-negative measure, so that it can be approximated by the inner product of random Fourier feature matrices (Rahimi & Recht, 2007; Yu et al., 2016; Choromanski et al., 2020).

Remark. We continue to study the generalization bound of attention-based models in the form of Eq. (2). Mathematically, we set ρ to bound the number of non-zero entries in $\mathbf{P}$ that characterizes sequential patterns, and μ to bound the impact of each historical behavior. As proved in Theorem 1, the generalization error of these models decreases with both ρ and μ. This result is consistent with (Lee et al., 2013; Li et al., 2016) — penalizing the model parameters with ℓ_2-norm can usually improve the model performance by avoiding overfitting. Perhaps more importantly, the theorem shows that it is beneficial to limit a user's future action correlated with a small subset of past behaviors.

Theorem 1 (Generalization Bound). *Suppose that the loss function ℓ is L-Lipschitz, and for the estimate $\hat{\mathbf{R}}$ on an random example set Ω we bound $\rho|\Omega| = \sup_{\mathbf{P}\in\mathcal{F}} \sum_{(u,i)\in\Omega} \|\mathbf{P}_{i,*}\|_0$ and $\mu = \sup_{(u,i,k)\in\Omega} |\mathbf{P}_{u,k}(\mathbf{VB})_{k,j}|$, then with probability at least $1-\delta$, we have the bound:*

$$\mathbf{E}\Big[\ell(\mathbf{R}, \hat{\mathbf{R}})\Big] \le \mathbf{E}_\Omega\Big[\ell(\mathbf{R}, \hat{\mathbf{R}})\Big] + \mathcal{O}\Big(L\mu\sqrt{\frac{C\rho\ln|\Omega|}{|\Omega|}} + \sqrt{\frac{\ln(1/\delta)}{|\Omega|}}\Big) \qquad (3)$$

where $C = d(m+n)\log(48emn)$.

4. Methodology

In this section, we first formulate the generalized attention in continuous time space, which has been rarely studied before. Then we introduce a specific implementation, called self-modulating layer (SMLayer), followed by a continuous time regularization for preference learning, making it more tailored to the sequential recommendation problem.

4.1. Notations

Recall that $\mathcal{S} = \{(t_j, i_j)\}_{j=1}^{L}$ denote a user's behavior sequence of size L, in which each pair (t_j, i_j) means that the given user clicks/likes/views item i_j at time t_j. Then, we further define $\mathcal{H}_t = \{(t_j, i_j)|t_j < t\}$ that signifies the history up to time t. The goal of self-modulating attention is to model the impact of sequential positions as well as continuous timestamps.

We recall that user preferences evolve over time and the interests on the items might wane, such that some past behaviors should not make contributions to the output user representations at some time, even though they are semantically correlated. To remedy such challenge, one straightforward idea is to directly inform the correlation $p(\mathbf{v}_{i_j}|\mathcal{H}_t)$ with the expected number of occurrence $\mathbb{E}[\mathrm{N}(t, t+\mathrm{d}t)|\mathcal{H}_{t-}, \mathbf{v}_{i_j}]$ conditional on the history $\mathcal{H}_{t-}$, where $\mathcal{H}_{t-} = \mathcal{H}_t \cup \{t_{j+1} \notin (t_j, t)\}$ and $\mathrm{N}(t, t+\mathrm{d}t) \in \{0, 1\}$ denotes the number of occurrences for item i_j in an infinitesimal interval.

4.2. Generalizing Attention to Continuous Time Space

Following this idea, we make an adjustment for classic attentions (Chorowski et al., 2015; Vaswani et al., 2017; Xu et al., 2019) to capture both sequential and temporal dynamics, which is devised as follows:

$$\begin{aligned}
&\mathbb{E}_{p(\mathbf{v}|\mathcal{H}_t)}\Big[\mathbb{E}\Big[\mathrm{N}(t, t+\mathrm{d}t)\Big|\mathcal{H}_{t-}, \mathbf{v}\Big]\mathbf{v}\Big] \\
\overset{(a)}{=}&\mathbb{E}_{p(\mathbf{v}|\mathcal{H}_t)}\Big[p\Big(t_{j+1} \in [t, t+\mathrm{d}t]\Big|\mathcal{H}_{t-}, \mathbf{v}\Big)\mathbf{v}\Big] \\
\overset{(b)}{=}&\mathbb{E}_{p(\mathbf{v}|\mathcal{H}_t)}\frac{p\Big(t_{j+1} \in [t, t+\mathrm{d}t]\Big|\mathcal{H}_t, \mathbf{v}\Big)}{p\Big(t_{j+1} \notin (t_j, t)\Big|\mathcal{H}_t, \mathbf{v}\Big)}\mathbf{v} \\
\overset{(c)}{=}&\mathbb{E}_{p(\mathbf{v}|\mathcal{H}_t)}\frac{f(t|\mathcal{H}_t, \mathbf{v})\mathrm{d}t}{S(t|\mathcal{H}_t, \mathbf{v})}\mathbf{v} \\
\overset{(d)}{=}&\mathbb{E}_{p(\mathbf{v}|\mathcal{H}_t)}\mathbf{v}\lambda^*(t|\mathcal{H}_t, \mathbf{v})\mathrm{d}t,
\end{aligned} \tag{4}$$

in which (a) holds due to the fact that $\mathrm{N}(t_j, t_j + \mathrm{d}t)$ is either zero or one in the infinitesimal interval; (b) holds due to Bayes' theorem; and (c) - (d) hold due to

$$\begin{aligned}
p\Big(t_{j+1} \in [t, t+\mathrm{d}t]\Big|\mathcal{H}_t, \mathbf{v}\Big) &= f(t|\mathcal{H}_t, \mathbf{v})\mathrm{d}t \\
p\Big(t_{j+1} \notin (t_j, t)\Big|\mathcal{H}_t, \mathbf{v}\Big) &= S(t|\mathcal{H}_t, \mathbf{v}) \\
\frac{f(t|\mathcal{H}_t, \mathbf{v})}{S(t|\mathcal{H}_t, \mathbf{v})}. &= \lambda^*(t|\mathcal{H}_t, \mathbf{v}),
\end{aligned} \tag{5}$$

where $S(t|\mathcal{H}_t, \mathbf{v})$ and $\lambda^*(t|\mathcal{H}_t, \mathbf{v})$ are called survival function and conditional intensity function respectively, in the literature of temporal point process (Aalen et al., 2008; Kleinbaum & Klein, 2010).

In general, dynamic processes will be characterized by the conditional intensity function $\lambda^*(t|\mathcal{H}_t)$. Within a short time window $[t, t+dt)$, $\lambda^*(t)$ represents the occurrence rate of a new event given history $\mathcal{H}_t$ that

$$\lambda^*(t|\mathcal{H}_t) = \frac{p(\mathrm{N}(t+\mathrm{d}t) - \mathrm{N}(t) = 1|\mathcal{H}_t)}{\mathrm{d}t}, \tag{6}$$

where $\mathrm{N}(t)$ is the counting process and $*$ reminds it is history dependent. Here we omit $\mathbf{v}$ for its generality.

Using the generalized formulation of conventional attentions, we can deal with the uncertainty over time and are able to predict future user preferences at time t by

$$\widetilde{\mathrm{Att}}(\mathbf{q}, |\mathcal{H}_t) = \mathbb{E}_{p(\mathbf{v}|\mathcal{H}_t)}\mathbf{v}\lambda^*(t|\mathcal{H}_t, \mathbf{v}), \tag{7}$$

or future user preferences during time interval $(t_j, t]$ by

$$\widetilde{\mathrm{Att}}(\mathbf{q}, |\mathcal{H}_t) = \mathbb{E}_{p(\mathbf{v}|\mathcal{H}_t)}\mathbf{v}\int_{t_j}^{t}\lambda^*(s|\mathcal{H}_t, \mathbf{v})\,\mathrm{d}s, \tag{8}$$

where the integral is challenging to compute and proper approximations are needed which will be discussed later.

Remark. We here discuss the characteristics of our proposed self-modulating attention: (i) the conditional intensity function $\lambda^*(t|\mathcal{H}_t, \mathbf{v})$ models temporal dynamics in an explicit manner, which acts as a role of time-dependent modulating factor, amplifying or attenuating the impact of past behaviors. This helps to derive the explanations behind the model predictions and the results are highlighted in the experiment sections; (ii) The intensities equal to zero can help to detect the sparse structures in the correlations between past behaviors and future actions, while the intensities less than one, can help to reduce the contribution of the behaviors when computing the predictions. As shown in Theorem 1, these two properties provide improved model generalization ability.

4.3. Self-modulating Layer

The conditional intensity of a temporal point process is often designed to capture the phenomena of interest, for

example Poisson process, Hawkes process (Hawkes, 1971; Mei & Eisner, 2017; Zhou et al., 2013) and Self-correction process (Isham & Westcott, 1979). In our case, we implement the intensity function as a neural layer, named self-modulating layer (SMLayer), which can be stacked on the attentions. By doing so, intermediate representations of the attentions can be reused for computational efficiency, and moreover this makes SMLayer a general building block for the broader applications.

We use $\mathbf{Y} \in \mathbb{R}^{L\times d}$ to denote the embeddings of the input sequence $\mathcal{S} = \{(t_j, i_j)\}_{j=1}^{L}$. As our model still needs to be aware of positional information, we choose to use the positional encoding as adopted in (Vaswani et al., 2017):

$$\mathbf{Z}_{i,j} = \begin{cases} \sin(i/10000^{j/d}), & \text{if } i \text{ is even,} \\ \cos(i/10000^{j-1/d}), & \text{if } i \text{ is odd.} \end{cases} \tag{9}$$

After the initial embedding and positional encoding layer, we will have the input embedding $\mathbf{X}$, which is then passed to the self-attention module to compute the intermediate representations

$$\mathbf{X} = \text{concat}\big([\mathbf{Y}, \mathbf{Z}]\big)$$
$$\mathbf{Q} = \mathbf{X}\mathbf{W}^{Q}, \quad \mathbf{K} = \mathbf{X}\mathbf{W}^{K}, \quad \mathbf{V}^{\text{seq}} = \mathbf{X}\mathbf{W}^{V}$$
$$\mathbf{H} = \text{softmax}(\frac{\mathbf{Q}\mathbf{K}^{\top}}{\sqrt{d}})\mathbf{V}^{\text{seq}}.$$

where all $\mathbf{W}$ are projection matrices, $\mathbf{Q}, \mathbf{K}, \mathbf{V}^{\text{seq}}$ are separately the query, key and values matrices obtained by different transformations of the input $\mathbf{X}$, and $\mathbf{H}$ is the output representations of conventional attentions, where each row corresponds to a particular user behavior. Note that to ensure causality, we mask the future information.

Before the next step, we first denote the j^{th} row of the self-attention output $\mathbf{H}$ by $\mathbf{h}(t_j)$, which corresponds to the representation of the sub-sequence $\{(i_{j'}, t_{j'})\}_{j'=1}^{j}$ up to the time t_j. To model the continuous time temporal dynamics, the intermediate representation $\mathbf{h}(t_j)$ is fed through item-wise feed-forward neural network

$$\mathbf{g}_k(t) = \sigma\left(\underbrace{\mathbf{W}_k^G \mathbf{h}(t_j)}_{\text{Endogenous}} + \underbrace{\mathbf{b}_k^G(t-t_j)}_{\text{Exogenous}}\right), \tag{10}$$

where the endogenous correlation with the potential next item k is captured by the term $\mathbf{W}_k^G\mathbf{h}(t_j)$, which evolves in the embedding space with respect to its previous behaviors in the sequence and not in a random fashion. In the meantime, $\mathbf{b}_k^G(t-t_j)$ are used to capture the exogenous force that reacts on the potential next item k during the time interval $[t_j, t)$. By combining $\mathbf{W}_k^G\mathbf{h}(t_j)$ and $\mathbf{b}_k^G(t-t_j)$ together, the output representation $\mathbf{g}_k(t)$ is expressive to better characterize both of the sequential and temporal dynamics in the continuous time space.

Lastly, the conditional intensity of each potential next item k can be computed in the following function

$$\lambda^*(t|\mathcal{H}_t, \mathbf{v}_k) = f_k(\mathbf{w}_k^{\top}\mathbf{g}_k(t) + \mu_k), \tag{11}$$

where $\mathbf{w}_k$ is the model parameter that serves for the item k, μ_k signifies the base rate that the item k appears in the future, and f_k is the activation function. We notice that the choice of activation function should consider two critical criteria: i) the intensity should be non-negative and ii) the dynamics on different items evolve at different scales. To account for this, we adopt the softplus function

$$f_k(x) = \phi_k \log\left(1 + \exp(x/\phi_k)\right), \tag{12}$$

where the parameter ϕ_k captures the timescale difference.

Remark. In practice because the number of items is always very large, Eq. (10 - 11) require considerable computational time and memory use, not suitable for large-scale online systems. One of the feasible solutions is to cluster the items into groups using spectral clustering techniques (Shi & Malik, 2000; Chen et al., 2010), and replace the item-wise feed-forward neural networks with group-wise feed-forward neural networks. This makes sense because the items in the same group are densely connected to each other but sparsely connected to the items from different groups.

4.4. Continuous Time Regularization for Preference Learning

In preference learning, the model parameters are usually optimized by minimizing the reconstruction error (Mackey et al., 2011; Lee et al., 2013; Li et al., 2016; Chen et al., 2016). The only source of supervised signal is from the behavior data (i.e., $\mathbf{R}$) that is independent of time. Hence, the intensity function learned in such protocol might probably diverge from the complex continuous-time patterns contained in the data.

To remedy the problem, we propose the continuous time regularization $R(\Theta)$ which maximizes the log-likelihood of the timestamps $\{t_j\}_{j=1}^{L}$ in the given sequence, defined by

$$R(\Theta; u) = \sum_{j=1}^{L} \log \lambda_{k_j}^*(t_j|\mathcal{H}_j^{(u)}) - \int_{t_1}^{t_L} \lambda^*(t_j|\mathcal{H}_j^{(u)})\mathrm{d}t$$

where $\mathcal{H}_j^{(u)} = \{(t_i, i_i)|t_i < t_j\}$ is the subsequence up to time t_j. The first term in the right hand signifies the log-likelihood of the behavior history, where k_j signifies the identity of item i_j or the group it belongs to. The second term represents the log-survival probabilities where $\lambda^*(t_j|\mathcal{H}_{t_j}^{(u)}) = \sum_k \lambda_k^*(t_j|\mathcal{H}_j^{(u)})$. Concretely, if we are given the sequences of m users, the model parameters can be optimized by minimizing the following objective function

$$\min_{\Theta} \ell(\mathbf{R}, \hat{\mathbf{R}}) - \gamma\mathbb{E}_{u\in[1,m]}\, R(\Theta; u), \tag{13}$$

Table 1. Statistics of the public datasets for evaluation.

Dataset	#Users	#Items	#Interactions
Amazon	211,384	18,490	1.6M
Koubei	212,831	10,213	1.8M
Tmall	320,497	21,876	7,6M

where γ is the regularization parameter.

The challenge in optimizing Eq. (13) is to compute the integral $\Lambda = \int_{t_1}^{t_L} \lambda^*(t_j|\mathcal{H}_j^{(u)})\mathrm{d}t$. Due to the softplus used in Eq. (11), there is no closed-form solution for this integral.

We consider two techniques to approximate the integral Λ.

1) Monte Carlo integration (Metropolis & Ulam, 1949; Robert & Casella, 2013). It randomly draws a set of samples $\{v_i\}_{i=1}^N$ in each interval (t_{j-1}, t_j) to yield an unbiased estimation of Λ, i.e., $\mathbb{E}\,\widetilde{\Lambda}_{\mathrm{MC}} = \Lambda$

$$\widetilde{\Lambda}_{\mathrm{MC}} = \sum_{j=2}^{L}(t_j - t_{j-1})\Big(\frac{1}{N}\sum_{i=1}^{N}\lambda^*(v_i|\mathcal{H}_j^{(u)})\Big); \quad (14)$$

2) Numerical integration method (Stoer & Bulirsch, 2013). It is usually biased but fast due to the elimination of sampling. For example, trapezoidal rule approximates the integral using linear functions

$$\widetilde{\Lambda}_{\mathrm{NU}} = \sum_{j=2}^{L}\frac{t_j - t_{j-1}}{2}\Big(\lambda^*(t_j|\mathcal{H}_j^{(u)}) + \lambda^*(t_{j-1}|\mathcal{H}_{j-1}^{(u)})\Big). \quad (15)$$

In our experiments, we find that the approximation defined in Eq. (15) performs comparable to Eq. (14) while consuming less training time. Hence we choose the numerical integration in our main approach. We conjecture the reason is that the softplus function is highly smoothed and the bias introduced by linear approximations is relatively small.

5. Experiments

This section evaluates the quantitative and qualitative results of our self-modulating attention against many state-of-the-art baselines on three large-scale real-world datasets. All experiments are run on a machine with E5-2678 CPU, RTX 2080 and 188G RAM.

5.1. Benchmark Datasets

We use three real-world datasets which are processed in line with (Weimer et al., 2007; Liang et al., 2018; Steck, 2019): (1) Amazon Electronics[1] is a user review dataset, where we binarize the explicit data and only keep users and items who have at least 5 historical records; (2) Koubei[2] is a user behavior dataset, where we keep users with at least 5 records and items that have been purchased by at least 100 users; and (3) Tmall[3] is a user click dataset, where we keep users who click at least 10 items and items which have been seen by at least 200 users. Table 1 shows the statistics.

5.2. Evaluation Protocol

We study the performance using strong generalization protocol (Weimer et al., 2007; Liang et al., 2018; Steck, 2019), where the models are evaluated on the users that are not present at training time. To do so, we split the users into training/validation/test sets with the ratio $8:1:1$. Then, we use all the data from the training users to optimize the model parameters, whereas for validation/test users, we keep the last record of each user to test and the rest to learn necessary representations for the model. In addition, we select model hyper-parameters and architectures using the validation users, and we report the results on test users for the model that achieves the best results on the validation users.

Two ranking-based metrics are used: Hit Rate (HR) and normalized discounted cumulative gain (NDCG). Notably, in our experiment protocol, the metrics Precision and Recall have the same tendency with Hit Rate. In the following, we report HR@10 and NDCG@10 for all the models.

5.3. Comparing Methods

We compare our proposed attention to state-of-the-art baselines, where we select the continuous time regularization parameter over {1e-4, 1e-5, 1e-6}. For the sake of fairness, the embedding size of all attentions are set to 50. In addition, we summarize the implementation details of the compared baselines as follows:

- **GRU4REC** (Hidasi et al., 2016) is one of state-the-of-art sequential recommendation approaches, which relies on GRU module (Chung et al., 2014) to capture the sequential patterns in user preferences. We use the program provided by the author[4]. Grid search of factor size over {50, 100, ..., 300}, learning rate over {1e-4, 1e-3, 1e-2} and dropout rate over {0.1, ... ,0.5} is performed to select the best parameters.
- **DIN** (Zhou et al., 2018) is among the best sequential recommendation models that build upon attentions. The implementation is public and provided by the authors[5]. We finetune the model by grid search learning rate and dropout rate over {0.5, 1.0, 1.5, 2.0} and {0.1, ... ,0.5}.
- **SHAN** (Ying et al., 2018) proposes hierarchical attentions

[1] http://jmcauley.ucsd.edu/data/amazon/

[2] https://tianchi.aliyun.com/dataset/dataDetail?dataId=53

[3] https://tianchi.aliyun.com/dataset/dataDetail?dataId=35680

[4] https://github.com/hidasib/GRU4Rec

[5] https://github.com/zhougr1993/DeepInterestNetwork

Table 2. Ablation study on the Amazon, Koubei and Tmall datasets. The proposed self-modulating layer (SMLayer) and continuous-time regularization (CTReg) are adapted to attention-based DIN (Zhou et al., 2018) and SASREC (Kang & McAuley, 2018) models. The performance is evaluated in terms of HR@10 and NDCG@10.

		DIN			SASREC		
	Dataset	Origin	+SMLayer	+CTReg	Origin	+SMLayer	+CTReg
HR	**Amazon**	0.21955	**0.22065**	0.21985	0.25595	**0.26545**	0.26058
	Koubei	0.32665	**0.33940**	0.33780	0.35455	0.36194	**0.36235**
	Tmall	0.48460	0.49033	**0.49157**	0.50433	0.51218	**0.51347**
NDCG	**Amazon**	0.13443	**0.13383**	0.13296	0.16131	0.16475	**0.16529**
	Koubei	0.24186	**0.25444**	0.25411	0.27070	0.27862	**0.28083**
	Tmall	0.33855	0.34580	**0.35062**	0.34326	0.35214	**0.35811**

Table 3. Performance comparison between the baselines and our proposed method on the Amazon, Koubei and Tmall datasets in terms of HR@10 and NDCG@10. Boldfaces mean that the method performs statistically significantly better under t-tests, at the level of 95% confidence level. We emphasize the comparison against SASREC+, a variant of SASREC equipped with functional time embedding (Xu et al., 2019) which captures continuous-time temporal dynamics.

	Amazon		Koubei		Tmall	
Model	HR	NDCG	HR	NDCG	HR	NDCG
SHAN (Ying et al., 2018)	0.19250	0.11724	0.28150	0.20256	0.37316	0.25840
DIN (Zhou et al., 2018)	0.21955	0.13443	0.32665	0.24186	0.48460	0.33855
GRU4REC (Hidasi et al., 2016)	0.24380	0.15822	0.32655	0.27052	0.46877	0.33746
SASREC (Kang & McAuley, 2018)	0.25595	0.16131	0.35455	0.27070	0.50433	0.34326
SASREC+ (Xu et al., 2019)	0.25820	0.16204	0.35690	0.27148	0.50607	0.34328
SASREC w/ ours.	**0.26545**	**0.16529**	**0.36235**	**0.28083**	**0.51347**	**0.35811**

to model multi-level user representations. The source code is also provided by the authors[6]. After grid search, we find the parameter settings in the original paper provide the best results in our experiments.

• **SASREC** (Kang & McAuley, 2018) applies the Transformer (Vaswani et al., 2017) into the sequential recommendation task and has achieved state-of-the-art performance in many benchmark datasets. We use the software provided by the authors in our experiments[7]. We adopt the default architecture used in its original paper where three transformer blocks are used. We further search the optimal hyper-parameters by ranging learning rate over {1e-4, 5e-4, ..., 1e-2} and dropout rate from 0.1 to 0.5.

• **SASREC+** (Xu et al., 2019) equips SASREC with time embedding[8], analogous to positional embedding. This approach models continuous-time dynamics in the form of random Fourier features. In our experiments, we concatenate both time and positional embedding with the attention input embedding for the improved model accuracy. We emphasize the comparison to SASREC+, since it is probably most closely related to our work.

[6]https://github.com/uctoronto/SHAN

[7]https://github.com/kang205/SASRec

[8]https://github.com/StatsDLMathsRecomSys/Self-attention-with-Functional-Time-Representation-Learning

5.4. Ablation Study

We evaluate each of the two components of self-modulating attention in continuous time space, namely continuous time regularization (CTReg) and self-modulating layer (SMLayer). Ideally, our attention can be used to improve any attention mechanisms by simply stacking SMLayer and adjusting loss function with CTReg. To demonstrate the adaptability of our proposed attention, we equip DIN and SASREC progressively with SMLayer and CTReg.

Table 3 reports the results of HR@10 and NDCG@10 on the Amazon, Koubei and Tmall datasets. We can see that SMLayer achieves the consistent improvement in both HR@10 and NDCG@10 over both DIN and SASREC across all the three datasets. Especially, SMLayer helps to improve HR@10 and NDCG@10 of DIN by a margin greater than

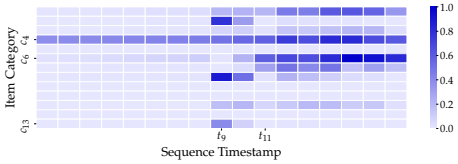

Figure 1. Example of user preference intensities on Koubei. The user usually purchases the items from category c_4 for all the time, and he/she starts to repeatedly buy the items from category c_6 after time t_9. The darker color corresponds to the higher intensity.

0.01. On the other hand, CTReg can also boost the performance in most cases. One exception is on the Amazon dataset. The reason is perhaps due to the fact that Amazon is made of user reviews, and there are nearly 5.39% users wrote the reviews of all the purchased items at the same time. Meanwhile, with using CTReg, the conditional intensity has to be enforced to fit such nuisance patterns. This will inevitably make the optimization procedure prone to overfitting, leading to the degradation of the performance.

The above experiments indicate that both the continuous time self-modulating layer and regularization are flexible and have the ability to improve the model performance. In our analysis, the reasons why our proposed attentions can further improve the recommendation accuracy is mainly due to (1) continuous time self-modulating layer models the impact of both sequential positions and continuous timestamps, so that the model expressiveness is improved; and (2) continuous time regularization enforces the intensity function dependent on the sequence timestamps, so that the intensities can accurately modulate historical behaviors to make attentive contributions to the predictions of the model.

5.5. Quantitative Study

This study evaluates the accuracy of the proposed method by comparing it with five state-of-the-art methods summarized previously, i.e., SHAN (Ying et al., 2018), DIN (Zhou et al., 2018), GRU4REC (Hidasi et al., 2016), SASREC (Kang & McAuley, 2018) and SASREC+ (Xu et al., 2019). Each of the methods is configured by using default parameters provided in the original paper or optimal parameters which produce the best results in grid search. We note again that for the sake of fairness, the embedding size d of query, key, value matrix is set to 50 for all attentions.

Table 3 presents HR@10 and NDCG@10 of all models on the Amazon, Koubei and Tmall datasets. This study shows that the SASREC method with our self-modulating attention outperforms on all the datasets. Note that DIN and SHAN perform worse than the results reported in their origin paper. The difference is caused by the experiment protocol. We evaluate the models on the users that are not present at training time. This setup is more difficult than that where test users and training users are overlapped.

More importantly, we emphasize the comparison between our method and SASREC+ which employs functional time embedding (Xu et al., 2019) to capture temporal dynamics. The empirical results demonstrate the superiority of our self-modulating attention. We believe this is owed to the design of intensity function, powered by neural networks, which is expressive enough to model complex evolving dynamics in the continuous time space.

5.6. Qualitative Study

We also qualitatively analyze the self-modulating attention outputs. Fig. 1 shows the intensities of a user on Koubei evolve alone the time. We note that the reported user usually purchases the items from the category c_4 for all the time, start to repeatedly buy the items from category c_6 after t_9.

At the first glimpse, the intensities are relatively sparse and most of them are less than one. We recall that intensities less than one will attenuate the corresponding past behavior making contributions to the output ranking score, whereas intensities equal to zero can help to derive sparse interactions between the past behaviors and future actions. As demonstrated in Theorem 1, this makes potentials for the improved generalization capacity.

One can see that for category c_4, intensity function assigns larger weights to more recent behaviors. This coincides with a common experience that more recent behaviors have more impact on the future actions. On the other hand, the intensities for category c_{13} remain zero for a long time, then increase to nearly 0.4 during (t_9, t_{11}), and finally diminish back to zero after time t_{11}. This demonstrates the our self-modulating attention takes the timestamps into account and has the ability to cancel the impact of the items that the user might not be interested in during certain time interval.

6. Conclusion

We have proposed a novel attention mechanism in continuous time space, entitled self-modulating attention, to model the non-linearly evolving dynamics, especially for user preferences. The key contribution lies in the generalized formulation of conventional attentions, and the development of self-modulating layer and continuous time regularization. We also provide theoretical generalization bound showing the advantage of our method. Extensive experiments on the top-N recommendation task have demonstrated the effectiveness and flexibility of our proposed self-modulating attention mechanism in continuous time space.

Acknowledgements

This research was supported by Shanghai Municipal Science and Technology Major Project (2021SHZDZX0102), NSFC (U19B2035, 61972250, 72061127003), and Meituan.

References

Aalen, O., Borgan, O., and Gjessing, H. *Survival and event history analysis: a process point of view*. Springer Science & Business Media, 2008.

Adomavicius, G. and Tuzhilin, A. Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engeering*, 17(6):734–749, 2005.

Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., García, S., Gil-López, S., Molina, D., Benjamins, R., et al. Explainable artificial intelligence (xai): Concepts, taxonomies, opportunities and challenges toward responsible ai. *Information Fusion*, 58:82–115, 2020.

Bennett, J. and Lanning, S. The netflix prize. In *KDD Cup*, pp. 35–35, 2007.

Chang, X., Liu, X., Wen, J., Li, S., Fang, Y., Song, L., and Qi, Y. Continuous-time dynamic graph learning via neural interaction processes. In *Proceedings of the ACM International Conference on Information and Knowledge Management (CIKM '20)*, pp. 145–154, 2020.

Chen, C., Li, D., Zhao, Y., Lv, Q., and Shang, L. Wemarec: Accurate and scalable recommendation through weighted and ensemble matrix approximation. In *Proceedings of the International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '15)*, pp. 303–312, 2015.

Chen, C., Li, D., Lv, Q., Yan, J., Chu, S. M., and Shang, L. MPMA: Mixture probabilistic matrix approximation for collaborative filtering. In *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI '16)*, pp. 1382–1388, 2016.

Chen, C., Li, D., Yan, J., Huang, H., and Yang, X. Scalable and explainable 1-bit matrix completion via graph signal learning. In *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI '21)*, 2021a.

Chen, C., Li, D., Yan, J., and Yang, X. Modeling dynamic user preference via dictionary learning for sequential recommendation. *IEEE Transactions on Knowledge and Data Engineering*, pp. 1–1, 2021b. doi: 10.1109/TKDE.2021.3050407.

Chen, W.-Y., Song, Y., Bai, H., Lin, C.-J., and Chang, E. Y. Parallel spectral clustering in distributed systems. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 33(3):568–586, 2010.

Chen, X., Xu, H., Zhang, Y., Tang, J., Cao, Y., Qin, Z., and Zha, H. Sequential recommendation with user memory networks. In *Proceedings of the ACM International Conference on Web Search and Data Mining (WSDM '18)*, pp. 108–116, 2018.

Choromanski, K., Likhosherstov, V., Dohan, D., Song, X., Gane, A., Sarlos, T., Hawkins, P., Davis, J., Mohiuddin, A., Kaiser, L., et al. Rethinking attention with performers. In *Proceedings of the International Conference on Learning Representations (ICLR '21)*, 2020.

Chorowski, J. K., Bahdanau, D., Serdyuk, D., Cho, K., and Bengio, Y. Attention-based models for speech recognition. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NIPS '15)*, pp. 577–585, 2015.

Chung, J., Gulcehre, C., Cho, K., and Bengio, Y. Empirical evaluation of gated recurrent neural networks on sequence modeling. In *NIPS Workshop on Deep Learning*, 2014.

Daley, D. J. and Vere-Jones, D. *An introduction to the theory of point processes: volume I: elementary theory and methods*. Springer, 2003.

Hawkes, A. G. Spectra of some self-exciting and mutually exciting point processes. *Biometrika*, 58(1):83–90, 1971.

He, R. and McAuley, J. Fusing similarity models with markov chains for sparse sequential recommendation. In *Proceedings of the IEEE International Conference on Data Mining (ICDM '16)*, pp. 191–200, 2016.

He, R., Kang, W.-C., and McAuley, J. Translation-based recommendation. In *Proceedings of the ACM Conference on Recommender Systems (RecSys '17)*, pp. 161–169, 2017a.

He, X., Liao, L., Zhang, H., Nie, L., Hu, X., and Chua, T.-S. Neural collaborative filtering. In *Proceedings of the International Conference on World Wide Web (WWW '17)*, pp. 173–182, 2017b.

Herlocker, J. L., Konstan, J. A., Borchers, A., and Riedl, J. An algorithmic framework for performing collaborative filtering. In *Proceedings of the International ACM SIGIR Conference on Research and D in Information Retrieval (SIGIR '99)*, pp. 230–237, 1999.

Hidasi, B., Karatzoglou, A., Baltrunas, L., and Tikk, D. Session-based recommendations with recurrent neural networks. In *Proceedings of the International Conference on Learning Representations (ICLR '16)*, 2016.

Hochreiter, S. and Schmidhuber, J. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.

Isham, V. and Westcott, M. A self-correcting point process. *Stochastic Processes and Their Applications*, 8(3):335–347, 1979.

Kang, W.-C. and McAuley, J. Self-attentive sequential recommendation. In *Proceedings of the IEEE International Conference on Data Mining (ICDM '18)*, pp. 197–206. IEEE, 2018.

Kleinbaum, D. G. and Klein, M. *Survival analysis*. Springer, 2010.

Koren, Y. Factorization meets the neighborhood: a multifaceted collaborative filtering model. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '08)*, pp. 426–434, 2008.

Koren, Y. Collaborative filtering with temporal dynamics. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '09)*, pp. 447–456, 2009.

Koren, Y., Bell, R., and Volinsky, C. Matrix factorization techniques for recommender systems. *Computer*, 42(8): 30–37, 2009.

Kumar, S., Zhang, X., and Leskovec, J. Predicting dynamic embedding trajectory in temporal interaction networks. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '19)*, 2019.

Lee, J., Kim, S., Lebanon, G., and Singer, Y. Local low-rank matrix approximation. In *Proceedings of the International Conference on Machine Learning (ICML '13)*, pp. 82–90, 2013.

Li, D., Chen, C., Lv, Q., Yan, J., Shang, L., and Chu, S. Low-rank matrix approximation with stability. In *Proceedings of the International Conference on Machine Learning (ICML '16)*, pp. 295–303, 2016.

Li, D., Chen, C., Liu, W., Lu, T., Gu, N., and Chu, S. Mixture-rank matrix approximation for collaborative filtering. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NIPS '17)*, pp. 477–485, 2017.

Li, D., Chen, C., Lu, T., Chu, S., and Gu, N. Mixture matrix approximation for collaborative filtering. *IEEE Transactions on Knowledge and Data Engineering*, 33 (06):2640–2653, 2021.

Li, J., Wang, Y., and McAuley, J. Time interval aware self-attention for sequential recommendation. In *Proceedings of the International Conference on Web Search and Data Mining (WSDM '20)*, pp. 322–330, 2020.

Liang, D., Krishnan, R. G., Hoffman, M. D., and Jebara, T. Variational autoencoders for collaborative filtering. In *Proceedings of the Web Conference (WWW '18)*, pp. 689–698, 2018.

Liu, H., Lu, J., Zhao, X., Xu, S., Peng, H., Liu, Y., Zhang, Z., Li, J., Jin, J., Bao, Y., et al. Kalman filtering attention for user behavior modeling in ctr prediction. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NeurIPS '20)*, 2020.

Lu, Z., Pan, S. J., Li, Y., Jiang, J., and Yang, Q. Collaborative evolution for user profiling in recommender systems. In *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI '16)*, pp. 3804–3810, 2016.

Ma, C., Kang, P., and Liu, X. Hierarchical gating networks for sequential recommendation. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '19)*, pp. 825–833, 2019.

Mackey, L. W., Jordan, M. I., and Talwalkar, A. Divide-and-conquer matrix factorization. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NIPS '13)*, pp. 1134–1142, 2011.

Martins, A. and Astudillo, R. From softmax to sparsemax: A sparse model of attention and multi-label classification. In *Proceedings of the International Conference on Machine Learning (ICML '16)*, pp. 1614–1623, 2016.

Mei, H. and Eisner, J. The neural hawkes process: a neurally self-modulating multivariate point process. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NIPS '17)*, pp. 6757–6767, 2017.

Metropolis, N. and Ulam, S. The monte carlo method. *Journal of the American Statistical Association*, 44(247): 335–341, 1949.

Niculae, V. and Blondel, M. A regularized framework for sparse and structured neural attention. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NIPS '17)*, pp. 3340–3350, 2017.

Rahimi, A. and Recht, B. Random features for large-scale kernel machines. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NIPS '07)*, pp. 1177–1184, 2007.

Robert, C. and Casella, G. *Monte Carlo statistical methods*. Springer Science & Business Media, 2013.

Sarwar, B., Karypis, G., Konstan, J., and Riedl, J. Item-based collaborative filtering recommendation algorithms. In *Proceedings of the International Conference on World Wide Web (WWW '01)*, pp. 285–295, 2001.

Shi, J. and Malik, J. Normalized cuts and image segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(8):888–905, 2000.

Shukla, S. N. and Marlin, B. M. Multi-time attention networks for irregularly sampled time series. In *Proceedings of the International Conference on Learning Representations (ICLR '21)*, 2021.

Steck, H. Markov random fields for collaborative filtering. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NeurIPS '19)*, pp. 5474–5485, 2019.

Stoer, J. and Bulirsch, R. *Introduction to numerical analysis*, volume 12. Springer Science & Business Media, 2013.

Su, X. and Khoshgoftaar, T. M. A survey of collaborative filtering techniques. *Advances in Artificial Intelligence*, 2009.

Trivedi, R., Dai, H., Wang, Y., and Song, L. Know-evolve: Deep temporal reasoning for dynamic knowledge graphs. In *Proceedings of the International Conference on Machine Learning (ICML '17)*, pp. 3462–3471, 2017.

Trivedi, R., Farajtabar, M., Biswal, P., and Zha, H. Dyrep: Learning representations over dynamic graphs. In *Proceedings of the International Conference on Learning Representations (ICLR '19)*, 2019.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. Attention is all you need. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NIPS '17)*, pp. 6000–6010, 2017.

Wang, P., Guo, J., Lan, Y., Xu, J., Wan, S., and Cheng, X. Learning hierarchical representation model for nextbasket recommendation. In *Proceedings of the International ACM SIGIR conference on Research and Development in Information Retrieval (SIGIR '15)*, pp. 403–412, 2015.

Weimer, M., Karatzoglou, A., Le, Q., and Smola, A. Cofirank-maximum margin matrix factorization for collaborative ranking. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NIPS '07)*, pp. 222–230, 2007.

Widmer, G. and Kubat, M. Learning in the presence of concept drift and hidden contexts. *Machine learning*, 23 (1):69–101, 1996.

Wu, C.-Y., Ahmed, A., Beutel, A., Smola, A. J., and Jing, H. Recurrent recommender networks. In *Proceedings of the ACM International Conference on Web Search and Data Mining (WSDM '17)*, pp. 495–503, 2017.

Xiao, S., Yan, J., Yang, X., Zha, H., and Chu, S. Modeling the intensity function of point process via recurrent neural networks. In *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI '17)*, 2017.

Xu, D., Ruan, C., Kumar, S., Korpeoglu, E., and Achan, K. Self-attention with functional time representation learning. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NeurIPS '19)*, pp. 15915–15925, 2019.

Ying, H., Zhuang, F., Zhang, F., Liu, Y., Xu, G., Xie, X., Xiong, H., and Wu, J. Sequential recommender system based on hierarchical attention networks. In *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI '18)*, 2018.

Yu, F. X., Suresh, A. T., Choromanski, K., Holtmann-Rice, D., and Kumar, S. Orthogonal random features. In *Proceedings of the Annual Conference on Neural Information Processing Systems (NIPS '16)*, pp. 1983–1991, 2016.

Zhang, Q., Lipani, A., Kirnap, O., and Yilmaz, E. Self-attentive hawkes process. In *Proceedings of the International Conference on Machine Learning (ICML '20)*, pp. 11183–11193, 2020.

Zhang, T., Zhao, P., Liu, Y., Sheng, V. S., Xu, J., Wang, D., Liu, G., and Zhou, X. Feature-level deeper self-attention network for sequential recommendation. In *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI'19)*, pp. 4320–4326, 2019.

Zhang, Y. and Chen, X. Explainable recommendation: A survey and new perspectives. *Foundations and Trends in Information Retrieval*, 14(1):1–101, 2020.

Zhou, G., Zhu, X., Song, C., Fan, Y., Zhu, H., Ma, X., Yan, Y., Jin, J., Li, H., and Gai, K. Deep interest network for click-through rate prediction. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '18)*, pp. 1059–1068, 2018.

Zhou, K., Zha, H., and Song, L. Learning social infectivity in sparse low-rank networks using multi-dimensional hawkes processes. In *Proceedings of the International Conference on Artificial Intelligence and Statistics (AISTATS '13)*, pp. 641–649, 2013.

Zuo, S., Jiang, H., Li, Z., Zhao, T., and Zha, H. Transformer hawkes process. In *Proceedings of the International Conference on Machine Learning (ICML '20)*, pp. 11692–11702, 2020.

Signed Graph Neural Network with Latent Groups

Haoxin Liu*
Tsinghua University
China
liu-hx20@mails.tsinghua.edu.cn

Ziwei Zhang*
Tsinghua University
China
zw-zhang16@mails.tsinghua.edu.cn

Peng Cui
Tsinghua University
China
cuip@tsinghua.edu.cn

Yafeng Zhang
Qiang Cui
Meituan
China
zhangyafeng@meituan.com
cuiqiang04@meituan.com

Jiashuo Liu
Tsinghua University
China
liujiashuo77@gmail.com

Wenwu Zhu
Tsinghua University
China
wwzhu@tsinghua.edu.cn

ABSTRACT

Signed graph representation learning is an effective approach to analyze the complex patterns in real-world signed graphs with the co-existence of positive and negative links. Most previous signed graph representation learning methods resort to balance theory, a classic social theory that originated from psychology as the core assumption. However, since balance theory is shown equivalent to a simple assumption that nodes can be divided into two conflicting groups, it fails to model the structure of real signed graphs. To solve this problem, we propose Group Signed Graph Neural Network (GS-GNN) model for signed graph representation learning beyond the balance theory assumption. GS-GNN has a dual GNN architecture that consists of the global and the local module. In the global module, we adopt a more generalized assumption that nodes can be divided into multiple latent groups and that the groups can have arbitrary relations and propose a novel prototype-based GNN to learn node representations based on the assumption. In the local module, to give the model enough flexibility in modeling other factors, we do not make any prior assumptions, treat positive links and negative links as two independent relations, and adopt a relational GNN to learn node representations. Both modules can complement each other, and the concatenation of two modules is fed into downstream tasks. Extensive experimental results demonstrate the effectiveness of our GS-GNN model on both synthetic and real-world signed graphs by greatly and consistently outperforming all the baselines and achieving new state-of-the-art results. Our implementation is available in PyTorch[1].

CCS CONCEPTS

• **Information systems** → **Social networks**; *Data mining*.

*Both authors contributed equally to this research
[1]https://github.com/haoxin1998/GS-GNN

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
KDD '21, August 14–18, 2021, Virtual Event, Singapore
© 2021 Association for Computing Machinery.
ACM ISBN 978-1-4503-8332-5/21/08…$15.00
https://doi.org/10.1145/3447548.3467355

KEYWORDS

Signed Graphs, Graph Neural Networks, Balance Theory

ACM Reference Format:
Haoxin Liu, Ziwei Zhang, Peng Cui, Yafeng Zhang, Qiang Cui, Jiashuo Liu, and Wenwu Zhu. 2021. Signed Graph Neural Network with Latent Groups. In *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '21), August 14–18, 2021, Virtual Event, Singapore.* ACM, New York, NY, USA, 10 pages. https://doi.org/10.1145/3447548.3467355

1 INTRODUCTION

With the prevalence of social media, social interactions are created every moment. People create positive relationships such as friendships, agreements, and supports, as well as negative relationships such as foes, disagreements, and boycotts. For example, most customer review sites allow users to express both positive and negative comments. Signed graphs are popular data structures to simultaneously represent these positive and negative relationships by assigning signs to the links, i.e., co-existence of positive and negative links. Compared with unsigned graphs, signed links can reflect more complex social relationships [23].

To mine the rich value underlying graph data, graph representation learning techniques have been boosted recently. By learning a low-dimensional representation for each node, various graph analytical tasks such as node classification and link prediction can be performed. Among different methods, graph neural networks (GNNs) demonstrate great potentials by designing deep neural networks in learning node representations. When generalizing representation learning methods to signed graphs, modeling the co-existence of positive and negative links becomes the principle design. Most existing GNNs for signed graphs [4, 5] resort to balance theory, a well-known social theory originating from psychology, in designing learning frameworks. In a nutshell, balance theory indicates that "the foe of my foe is my friend" [10].

However, does balance theory perfectly model real signed graphs? To answer this question, we find it has been shown [9, 12] that balance theory is equivalent to a simple assumption that the nodes can be partitioned into two groups and the signs of links are completely determined by the group structure, i.e., nodes form positive links if they are in the same group and negative links if they are in different groups. Clearly, such an assumption is too ideal for real signed graphs. Taking social networks as examples, people form

positive and negative links based on various reasons rather than a dichotomy. The existing signed graphs representation learning methods do not consider these complex relationships, thus failing to model the true underlying structure of real signed graphs. As a result, the performance of the learned representations in signed graph analytical tasks is seriously harmed.

A natural generalization to the balance theory is that there exist multiple groups underlying the signed graph structure [3, 29]. Taking one step further, the groups can also form complex relationships, i.e., not every two groups are in conflicts and only form negative links. Such a generalized assumption can better model the real underlying structure of signed graphs, which we term such as the *k-group theory*. It is easy to see that the k-group theory includes the balance theory as a special case when the number of groups equals two and the two groups are in conflict.

Nevertheless, when adopting the k-group theory as the major inductive bias in designing a representation learning method, we should also give the model enough flexibility to accommodate other factors such as the micro-structures within groups, influences of node features, or even tolerate the randomness in people's behaviors or noises in the data. Such flexibility is critical since the observed data may not perfectly fit the k-group theory, even when it is the prime underlying mechanism of forming a signed graph. Otherwise, the model can be easily affected by these other factors and fails to discover the latent group structures.

Motivated by these analyses, we propose Group Signed Graph Neural Network (GS-GNN), a novel signed GNN that goes beyond the balance theory. Specifically, GS-GNN adopts a dual architecture that learns two representations for each node. For the first representation, we utilize the k-group theory and propose a novel prototype-based GNN to jointly learn the representation for each group and the affiliation of nodes to different groups. The representation of a node is composed of a linear combination of the group representations weighed by the node affiliations. Since this representation depicts the node relationships with all the groups, we name it the *global representation* of nodes. For the second representation, we do not make any prior assumption on the generative mechanism of signs and adopt a multi-relational GNN to model positive and negative links separately for node presentation learning. It complements the global representation by capturing information exceeding the k-group theory, e.g., structures within groups or information related to node features. Accordingly, we name such a representation as to the *local representation*. Finally, we concatenate the global and local representation to handle downstream tasks. By adopting this decoupled dual architecture, GS-GNN can capture various latent factors and the complex generative mechanism underlying the formation of signed graphs.

We conduct extensive experiments on four publicly available real signed graphs for the link sign prediction task. The experimental results show that our proposed method significantly and consistently outperforms all the existing methods, including signed network embedding methods and signed GNNs. Experimental results on simulation datasets and ablation studies further verify that the design of our method can indeed capture more complex structures than the balance theory.

The main contributions of the paper are summarized as follows.

- We study representation learning methods for signed graphs using the k-group theory, a general and more realistic assumption beyond the usual balance theory.
- We propose GS-GNN, a novel signed GNN with a dual architecture to learn global and local representations simultaneously. Our proposed method can fully leverage the k-group theory and is flexible to capture extra information beyond the theory.
- Extensive experimental results on real signed graphs demonstrate the superiority of our proposed method. GS-GNN outperforms all the existing methods and achieves new state-of-the-art, to the best of our knowledge.

2 RELATED WORK

In this section, we review related works. First, we review graph representation learning methods for unsigned graphs. Then, we review signed graph representation learning methods based on the balance theory and their relationships with the k-group theory. Finally, we review other signed graph representation learning methods.

Graph representation learning techniques, which learn low-dimensional vectors for nodes, have shown successes in various graph analysis tasks, such as node classification [27], link prediction [30], and network visualization [11]. Initial random-walk based methods such as DeepWalk [26], LINE [28], and Node2vec [8] regard nodes as words and generate random walks to preserve the graph structure. Other works such as SDNE [30] and SDAE [1] adopt deep neural networks and also achieve good performance. Recently, graph neural networks (GNNs) based methods have become increasingly popular [7, 18, 32, 37]. The message-passing framework [7] of GNNs propagates and aggregates information between neighbors. However, these methods are designed for unsigned graphs and thus not directly applicable to signed graphs.

Most of the existing signed graph representation learning methods [4, 5, 16, 17, 22, 25, 31] are designed based on the balance theory [10]. For example, SiNE [31] first learns signed network embedding with an objective function guided by the balance theory. SIDE [17] and SIGNet [15] use specifically designed random walks to model the balance theory. SGCN [5] first utilizes GNNs to model signed networks and uses the balance theory in designing the aggregating strategy. Similarly, SNEA [25] uses the attention mechanism to reveal the importance of neighbors and SGDN [16] uses feature diffusion to take high-order neighbors into consideration.

As mentioned in [9], the balance theory is equivalent to a simple assumption that the nodes can be partitioned into two conflicting groups and the signs of links are completely determined by the group structure. The weak balance theory is proposed in [2] and considers more than two conflicting groups. Based on this assumption, several signed graph clustering methods [3, 19] are proposed to discover the signed graph partition. However, these methods all assume the groups are in conflicts. Besides, they do not utilize the advantages of representation learning. To the contrary, our proposed GS-GNN can utilize GNNs and also model arbitrary relations between groups.

There are also signed representation learning methods [13, 14] based on another theory, the social status theory [23]. However, the social status theory is only applicable to directed graphs, while we only consider undirected graphs in this paper.

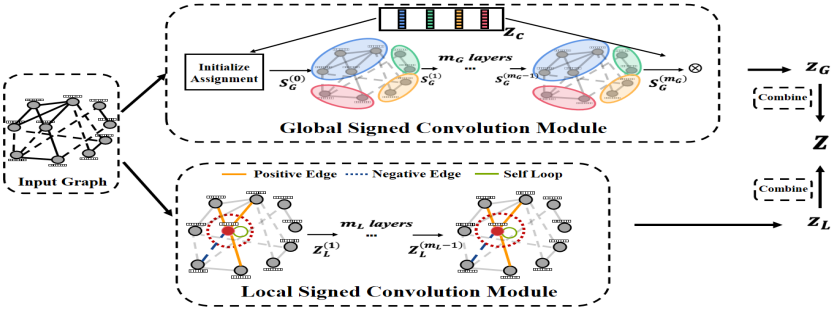

Figure 1: The overall framework of our GS-GNN model.

Table 1: Main notations used throughout the paper

Notations	Descriptions
$\mathcal{G}$	A signed graph
$\mathcal{V}$	A set of nodes
$\mathcal{E}^+(\mathcal{E}^-)$	A set of positive (negative) links
$\mathcal{N}_i^+(\mathcal{N}_i^-)$	The positive (negative) neighbors of node v_i
$\mathbf{X}$	An input features matrix
$\mathbf{Z}_G \in \mathbb{R}^{\|V\|\times d_L}$	The global embedding matrix of nodes
$\mathbf{Z}_L \in \mathbb{R}^{\|V\|\times d_G}$	The local embedding matrix of nodes
$d_G(d_L)$	The dimensionality of the global (local) embedding
$\mathbf{Z} = [\mathbf{Z}_G, \mathbf{Z}_L]$	The final embedding matrix of nodes
K	The number of groups
$\mathbf{Z}_C$	The embedding matrix of groups
$\mathbf{S}^{(m)}$	The assignment matrix of the m^{th} global layer
$M_G(M_L)$	The number of layers in the global (local) module
$\mathbf{W}_G^{(m)}, \mathbf{W}_G^{(m)\prime}$	The weight matrices in the m^{th} layer of the global module
$\mathbf{W}_L^{(m)}$ $\left(b_L^{(m)}\right)$	The weight matrix (bias vector) in the m^{th} layer of the local module

3 PROPOSED GS-GNN METHOD

3.1 Notations

First, we introduce some notations used throughout the paper. We consider a signed graph $\mathcal{G} = (\mathcal{V}, \mathcal{E}^+, \mathcal{E}^-)$ where $\mathcal{V} = \{v_1, v_2, ..., v_{|V|}\}$ denotes the set of nodes, $\mathcal{E}^+ \subseteq \mathcal{V} \times \mathcal{V}$ denotes the positive links, and $\mathcal{E}^- \subseteq \mathcal{V} \times \mathcal{V}$ denotes the negative links. $\mathcal{E}^+ \bigcap \mathcal{E}^- = \emptyset$, i.e., a link is either positive or negative. The nodes also have input features denoted as $X \in \mathbb{R}^{|V|\times d_{in}}$, where d_{in} is the number of features. In Table 1, we summarize the main notations.

3.2 Overall Framework

The overall framework of GS-GNN is shown in Figure 1. The major design of GS-GNN is that we use a dual architecture to learn a global embedding matrix $\mathbf{Z}_G \in \mathbb{R}^{|V|\times d_G}$ and a local embedding matrix $\mathbf{Z}_L \in \mathbb{R}^{|V|\times d_L}$ as the node representations. The global embedding utilizes the k-group theory that signed graphs have a latent k-group structure and the relations between groups are unknown. On the other hand, the local embedding aims to incorporate the individual information not captured by the k-group theory. Both embeddings are learned with GNNs using specifically designed convolution layers. To keep it simple, we set the final embedding $\mathbf{Z}$ as the concatenation of the local and global embeddings, though more advanced methods such as using a gating or attention mechanism can be explored in the future.

3.3 Global Signed Convolutional Module

Next, we explain the details for the global signed convolution module and local signed convolution module, respectively. Finally, we introduce our objective function.

The goal of the global signed convolution module is to discover the latent community structure of signed graphs based on the k-group theory. There are several challenges for designing such an architecture. First, we need to model the complex relationships between groups beyond simple heuristic assumptions, e.g., all groups are in conflict. Second, we need to represent nodes in a view of the groups, i.e., discovering the affiliation between nodes and groups. Lastly, we do not want to increase the amount of parameters and time complexity so that out model can apply to large-scale graphs.

With the above goals in mind, we propose a novel prototype-based GNN as our global signed convolutional module. The framework is shown in Figure 2. We denote an embedding matrix for the groups as $\mathbf{Z}_C = [\mathbf{Z}_{C_1}, \mathbf{Z}_{C_2}, ..., \mathbf{Z}_{C_K}] \in \mathbb{R}^{K\times d_G}$, where $\mathbf{Z}_{C_k} \in \mathbb{R}^{d_G}$ is the embedding of the k^{th} group. $\mathbf{Z}_C$ is randomly initialized and then optimized through our learning framework. In this way, we can freely model the relationships between different groups in the hidden space using their embedding vectors. Then, by regarding these group embeddings as prototypes, we can represent nodes from the group view as a linear combination of the group embeddings. The weights for the combination are learned by a learnable group assignment matrix. Similarly, graph pooling methods [21, 35]

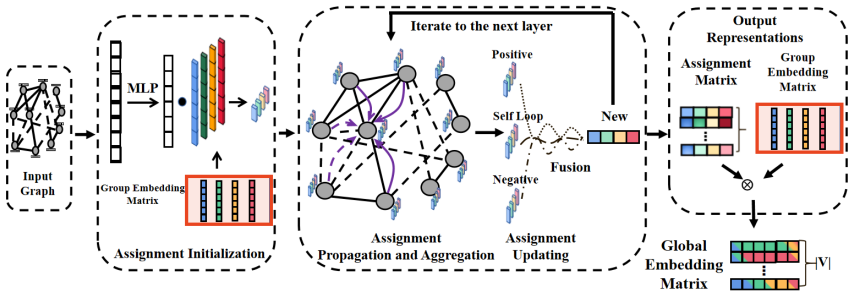

Figure 2: The detailed designs of the global module in GS-GNN. There are four major steps. First, we initialize the assignment matrix of nodes to different groups by transforming the node features into a latent space using an MLP and calculating the attention score with the group embedding matrix. Second, we conduct message-passing on the assignment matrix to propagate the aggregate information from both positive and negative neighbors. Third, we fuse the received messages and update the assignment matrix. After iterating steps two and three, i.e. multiple message-passing layers, we calculate the final global embedding matrix as a linear combination of the group embedding using the assignment as weights.

designed for the unsigned graph classification task also adopt learnable assignment matrices. Specifically, we decompose the procedure into the following four steps.

3.3.1 Assignment Initialization. The goal of this step is to generate the initial assignment probability of nodes to the K groups. We donate the initial assignment matrix as $\mathbf{S}^{(0)} \in \mathbb{R}_{\geq 0}^{|\mathcal{V}|\times K}$, where $\mathbf{S}^{(0)}_{v,C_i}$ is the probability of node v belong to the i^{th} group. To calculate $\mathbf{S}^{(0)}$, we first transform the input node features into hidden representations through a multilayer perceptron (MLP), i.e.,

$$\mathbf{X}'_v = \text{MLP}(\mathbf{X}_v), \forall v \in \mathcal{V} \tag{1}$$

where $\mathbf{X}'_v \in \mathbb{R}^{d_G}$. The parameters for different nodes are shared in the MLP and the output dimensionality matches the group embedding matrix. Next, we calculate the inner product, i.e., a simple attention value $\mathbf{Q}^{(0)}_{v,C_i}$ between the representation of node v and the i^{th} group embedding:

$$\mathbf{Q}^{(0)}_{v,C_i} = \mathbf{Z}^T_{C_i}\mathbf{X}'_v. \tag{2}$$

We then normalize the initial attention values with the softmax function to get the initial assignment probability

$$\mathbf{S}^{(0)}_{v,C_i} = \frac{\exp\left(\mathbf{Q}^{(0)}_{v,C_i}\right)}{\sum_{j=1}^{K}\exp\left(\mathbf{Q}^{(0)}_{v,C_j}\right)}. \tag{3}$$

3.3.2 Assignment Propagation and Aggregation. Simply adopting $\mathbf{S}^{(0)}$ cannot model the complex relationships between nodes. Following the message-passing framework of GNNs, we next conduct assignment propagation and aggregation to update the assignment matrix while incorporating the neighborhood information of nodes. In the message-passing mechanism, the aggregation function plays an important role in obtaining high-quality representations. Previous works of signed GNNs usually adopt the mean aggregation function [5, 13]. However, we find that the mean aggregation function cannot effectively model the neighborhood structure of nodes. We show a toy example in Figure 3. We can easily see that the neighborhoods of node a and b are different. However, the mean aggregator cannot differentiate these two cases and thus produce identical neighborhood messages. Similar phenomenons are observed in unsigned GNNs and it is shown that the sum aggregator can achieve the maximum expressiveness [32]. Therefore, we adopt the sum aggregator instead of the mean aggregator in all our message-passing layers.

We aggregate positive and negative neighbors separately

$$\mathbf{p}_v^{(m)} = \sum\nolimits_{u\in\mathcal{N}_v^+}\mathbf{S}_u^{(m-1)}, \mathbf{n}_v^{(m)} = \sum\nolimits_{u\in\mathcal{N}_v^-}\mathbf{S}_u^{(m-1)}, \tag{4}$$

where $\mathbf{p}_v^{(m)}$ and $\mathbf{n}_v^{(m)}$ denotes the information for node v from positive and neighbors neighbors in the m^{th} layer, respectively.

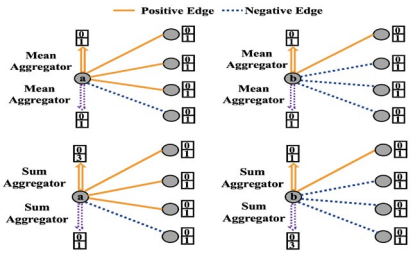

Figure 3: A toy example when the sum aggregator outperforms the mean aggregator. Though node a and b have different neighborhood structures, the mean aggregator cannot differentiate these two nodes, while the sum aggregator can.

3.3.3 Assignments Updating. After aggregating the messages from neighborhoods, we update the assignment matrix of node v by fusing three sources of information: the assignment matrix in the last layer, the information from positive neighbors, and the information from negative neighbors. Specifically, we set

$$\begin{aligned}\mathbf{S}_v^{(m)} &= \mathcal{F}^{(m)}\left(\mathbf{S}_v^{(m-1)}, \mathbf{p}_v^{(m)}, \mathbf{n}_v^{(m)}\right) \\ &= \text{softmax}\left(\sigma\left(\left[\mathbf{S}_v^{(m-1)}, \mathbf{p}_v^{(m)}, \mathbf{n}_v^{(m)}\right]\mathbf{W}_G^{(m)\prime}\right)\mathbf{W}_G^{(m)}\right)\end{aligned} \tag{5}$$

where $\mathbf{W}_G^{(m)\prime} \in \mathbb{R}^{3K\times d_{\text{hidden}}}$, $\mathbf{W}_G^{(m)} \in \mathbb{R}^{d_{\text{hidden}}\times K}$ are learnable weight matrices, d_{hidden} is the dimensionality of the hidden representation, and σ is ac activation function. We empirically find that additional bias terms do not lift the performance and thus remove the bias terms to reduce the number of parameters.

3.3.4 Obtaining Global Representations. After repeating the steps in Section 3.3.2 and Section 3.3.3 M_G times, i.e., adopting M_G message-passing layers, we have obtained the final assignment matrix $\mathbf{S} = \mathbf{S}^{(M_G)}$. We calculate the global representation of nodes

$$\mathbf{Z}_G = \mathbf{S}\mathbf{Z}_C, \tag{6}$$

i.e., the global representation is a linear combination of the group embeddings $\mathbf{Z}_C$ with weights defined in the assignment matrix $\mathbf{S}$.

Notice that in the global signed convolutional module, the number of parameters is linear with respect to the number of groups K and the dimensionality of hidden representations d_G and d_{hidden}, but is not related to $|\mathcal{V}|$.

3.4 Local Signed Convolutional Module

In the local module, we do not adopt any assumption on the relations between positive and negative links. Instead, we simply treat self connections, positive links, and negative links as three independent relations. In this way, we can capture information not modeled by the K-group theory such as structures within each group or information more related to node features. Such a module is important to complement the global module, especially when the real-world signed graphs do not strictly follow the K-group theory.

We also adopt message-passing layers in learning the local representations. Specifically, we denote the hidden representation of node v in the m^{th} layer of the local module as $\mathbf{z}_v^{(m)}$. The node representations are updated by aggregating information from neighborhoods as follows

$$\begin{aligned}\mathbf{h}_v^{(m)} &= \left[\sum\nolimits_{u\in\mathcal{N}_v^+}\mathbf{z}_u^{(m-1)}, \sum\nolimits_{u\in\mathcal{N}_v^-}\mathbf{z}_u^{(m-1)}\right] \\ \mathbf{z}_v^{(m)} &= \sigma\left(\left[\mathbf{z}_v^{(m-1)}, \mathbf{h}_v^{(m)}\right]\mathbf{W}_L^{(m)} + \mathbf{b}_L^{(m)}\right),\end{aligned} \tag{7}$$

where $\mathbf{h}_v^{(m)}$ is the message of node v by concatenating the information from positive neighbors and negative neighbors, $\mathbf{W}_L^{(m)}$ and $\mathbf{b}_L^{(m)}$ are learnable parameters for the local module, and $\sigma(\cdot)$ is the activation function. Note that, the aggregating functions used in the local module are also the sum function.

After conduct message-passing for M_L layers, the final local embeddings of nodes are

$$\mathbf{Z}_L = \left[\mathbf{z}_1^{(M_L)}, \mathbf{z}_2^{(M_L)}, ..., \mathbf{z}_{|\mathcal{V}|}^{(M_L)}\right]. \tag{8}$$

3.5 Objective Function and Discussions

Finally, we obtain the node embedding by concatenating global and local embeddings

$$\mathbf{Z} = [\mathbf{Z}_G, \mathbf{Z}_L]. \tag{9}$$

It is easy to see that our model can be trained end-to-end for a given task. In this paper, we adopt link sign prediction, which is a widely adopted task in signed graph representation learning. Specifically, link sign prediction is a binary edge classification problem. Therefore, we use the binary cross-entropy (BCE) loss as follows

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{|\mathcal{E}^+\cup\mathcal{E}^-|}\left(\sum_{(u,v)\in\mathcal{E}^+}\log p(u,v) + \sum_{(u,v)\in\mathcal{E}^-}(1-\log p(u,v))\right), \tag{10}$$

where $p(u,v)$ denotes the probability of node u and v forms an link. We use another MLP as the predictor with node embeddings as inputs:

$$p(u,v) = \text{Sigmoid}\left(\text{MLP}\left([\mathbf{Z}_u, \mathbf{Z}_v]\right)\right). \tag{11}$$

The final objective function $\mathcal{L}$ is defined as:

$$\mathcal{L} = \mathcal{L}_{\text{BCE}} + \lambda\mathcal{L}_{\text{reg}}, \tag{12}$$

where $\mathcal{L}_{\text{reg}}$ is the L_2 regularization term and λ is a hyper-parameter to control the weights of the regularization.

4 EXPERIMENTS

In this section, we conduct experiments to demonstrate the merits of GS-GNN. We aim to answer the following questions:

- **Q1**: Can GS-GNN fully utilize the k-group theory and discover the underlying structure of signed graphs?
- **Q2**: How does GS-GNN perform compared with other state-of-the-art signed graphs representation learning methods?
- **Q3**: Do both the global and local representation contribute to our proposed GS-GNN method and how do essential parameters affect the model?

To answer **Q1**, we first conduct experiments on synthetic datasets. Then, we compare GS-GNN with various baselines on four real signed graphs to answer **Q2**. Finally, ablation studies and parameter studies are reported to answer **Q3**.

Table 2: The statistics of datasets. We count each undirected link once in calculating the number of links.

Datasets	# Nodes	# Links	# Positive Links	# Negative Links
Bitcoin-Alpha	3,775	14,120	12,721	1,399
Bitcoin-OTC	5,875	21,489	18,230	3,259
Slashdot	37,626	419,072	313,543	105,529
Epinions	45,003	616,031	513,851	102,180

4.1 Experimental Settings

4.1.1 Real-world Datasets. We adopt the following four public signed graphs in our experiments:

- **Bitcoin-Alpha**[2][20] and **Bitcoin-OTC**[3][20] are two signed graphs extracted from bitcoin trading platforms. Since bitcoin

[2]http://www.btc-alpha.com
[3]http://www.bitcoin-otc.com

Table 3: The results of different methods on the synthetic dataset. K_S is the ground-truth number of groups in generating the synthetic graph and K is the assumed number of groups, i.e., a hyper-parameter, in our GS-GNN and SPONGE.

Assumption		Method	$K_S = 2$	$K_S = 3$	$K_S = 4$	$K_S = 5$	$K_S = 6$
Balance Theory		SGCN	0.442	0.398	0.362	0.334	0.357
		SGDN	0.791	0.682	0.612	0.530	0.495
K-Group	K=K_S	SPONGE	0.983	0.989	0.990	0.990	0.989
		GS-GNN	0.984	0.991	0.991	0.989	0.982
	K=2	SPONGE	0.983	0.853	0.749	0.670	0.600
		GS-GNN	0.984	0.991	0.988	0.984	0.889
	K=6	SPONGE	0.463	0.662	0.848	0.940	0.989
		GS-GNN	0.986	0.988	0.990	0.989	0.980

tradings are anonymous, people give trust or not-trust tags to others in order to enhance security.
- **Slashdot**[4] [23] is a technology-related news website where users can create friend or foe relationships with others.
- **Epinions**[5] [23] is a consumer review site with trust and distrust relationships between users.

Following [13], we use undirected versions of the datasets, i.e., neglecting the directions of links. We summarize the statistics of datasets in Table 2. We can see from the table that the positive and negative links are highly imbalanced in real-world signed graphs.

4.1.2 Task and Evaluation Metrics. Following previous works [5, 13], we adopt link sign prediction as our task, i.e., predicting the polar of the given links. Specifically, we randomly split the edges into a training set and a testing set with the ratio 8:2. For evaluation metrics, since positive and negative links are imbalanced, we adopt the following four metrics: area under curve (AUC), macro-averaged F1 score (Macro-F1), micro-average F1 score (Micro-F1), and binary-average F1 score (Binary-F1) [5]. For all the metrics, higher values indicate better performance. We repeat all experiments five times with dift random dataset splits, and report the averageferen results.

4.1.3 Baselines. We choose the following methods as baselines, including three signed network embedding methods (SPONGE, SLF, SIDE), one GNN method for unsigned graphs (GCN), and three GNNs for signed graphs (SGCN, SNEA, SGDN).

- **SPONGE** [3]: A k-way clustering method for signed graphs based on a generalized eigen-problem. All clusters are assumed to be in conflicts.
- **SLF** [33]: A signed network embedding method based on signed latent factor.
- **SIDE** [17]: A signed network embedding method that adopts random walks based on the balance theory.
- **GCN** [18]: A representative GNN originally designed for unsigned graph based on the message passing mechanism. We neglect the signs of the links.
- **SGCN** [5]: It generalizes GCN to signed graphs by learning two node representations based on the balance theory.
- **SNEA** [13]: It adopts attention-based aggregators in message-passing steps and is also based on the balance theory.
- **SGDN** [16]: It proposes a signed random walk diffusion method to consider multi-hop neighbors, which is also based on the balance theory.

For SPONGE, we make link sign prediction based on the cluster assignments of nodes. For network embedding methods, since these models are not trained in an end-to-end fashion, we first obtain the node presentations and then adopt a logistic regression as the classifier, as suggested in these papers. For the rest of the baselines, we adopt the standard end-to-end training.

4.1.4 Hyper-parameters. For SPONGE, we grid search the cluster number from $\{2, 3, ..., 20\}$. For other baselines and our proposed GS-GNN, we uniformly set the dimensionality of node representations as 64 (for GS-GNN, it includes both modules, i.e., $d_G + d_L = 64$). For all the baselines, other hyper-parameters are set as suggested in their papers. For our proposed method, we search the number of layers from $\{2, 3\}$ for the local module and from $\{3, 4, 5, 6, 7, 8\}$ for the global module. We adopt the Adam optimizer with both the learning rate and weight decay searched from $\{0.01, 0.005, 0.001\}$. As no node feature is available, we follow previous works [13, 16] and use the top 64-dimensional vectors of truncated Singular Value Decomposition[6] as node features.

4.2 Results on Synthetic Dataset

Before reporting the results of real-world datasets, we first conduct experiments on the synthetic dataset aiming to answer **Q1**, i.e., verify our proposed GS-GNN can indeed model the k-group structure underlying signed graphs. We generate synthetic signed graphs using the signed stochastic block model (SSBM)[34] as follows. A set of nodes $\mathcal{V}_S$ are divided into a set of K_S groups with equal sizes, i.e., each group has $\frac{|\mathcal{V}_S|}{K_S}$ nodes. Then, nodes within the same group have a probability p_{pos} to form a positive edge. All groups are assumed to be in conflicts with each other and thus nodes in different groups have a probability p_{neg} to form a negative edge. To further taking noises into consideration, the sign of all the links have a probability p_{noise} to be flipped. For the detailed parameters for our adopted SSBM, we set the number of nodes as $|\mathcal{V}_S| = 3,000$, the number of groups K_S is varied from $\{2, 3, 4, 5, 6\}$, $p_{\text{pos}} = 0.05$, $p_{\text{neg}} = 0.0125$, and $p_{\text{noise}} = 0.01$.

For brevity, we only adopt SPONGE [3], SGCN [5], and SNEA [13] that are most competitive as the baselines in this setting. Since both our proposed GS-GNN and SPONGE have the number of groups K

[4] http://www.slashdot.com
[5] http://www.epinions.com

Table 4: The results of link sign prediction on real world signed datasets. The best results and the second-best results for each dataset using each metric are in bold and underlined, respectively. The last column is the relative improvement of GS-GNN compared to the best-performing baseline.

Dataset	Metric	SPONGE	SLF	SIDE	GCN	SGCN	SNEA	SGDN	GS-GNN	
Bitcoin-Alpha	AUC	0.513	0.847	0.797	0.806	0.856	0.866	0.840	**0.898**	+3.70%
	Macro-F1	0.504	0.668	0.665	0.546	0.701	0.728	0.663	**0.798**	+9.62%
	Micro-F1	0.901	0.819	0.824	0.902	0.865	0.873	0.894	**0.932**	+3.33%
	Binary-F1	0.948	0.892	0.896	0.948	0.915	0.926	0.942	**0.962**	+1.48%
Bitcoin-OTC	AUC	0.700	0.874	0.828	0.845	0.847	0.863	0.863	**0.922**	+5.49%
	Macro-F1	0.644	0.735	0.713	0.675	0.752	0.760	0.734	**0.843**	+10.92%
	Micro-F1	0.763	0.828	0.820	0.878	0.847	0.858	0.871	**0.923**	+5.13%
	Binary-F1	0.850	0.892	0.889	0.932	0.908	0.914	0.926	**0.955**	+2.47%
Slashdot	AUC	0.500	0.888	0.820	0.819	0.873	0.888	0.887	**0.917**	+3.27%
	Macro-F1	0.432	0.773	0.725	0.670	0.757	0.769	0.769	**0.822**	+6.34%
	Micro-F1	0.752	0.812	0.773	0.797	0.811	0.812	0.838	**0.869**	+3.70%
	Binary-F1	0.861	0.867	0.840	0.875	0.859	0.868	0.896	**0.916**	+2.23%
Epinions	AUC	0.508	0.928	0.878	0.869	0.920	0.931	0.930	**0.959**	+3.01%
	Macro-F1	0.474	0.795	0.746	0.685	0.807	0.819	0.819	**0.874**	+6.72%
	Micro-F1	0.832	0.865	0.829	0.864	0.901	0.888	0.903	**0.934**	+3.43%
	Binary-F1	0.908	0.915	0.891	0.922	0.916	0.931	0.942	**0.961**	+2.02%

as a hyper-parameter, we consider three settings: (1) The ground-truth K_S is known to the method, i.e., $K = K_S$; (2) We set the number of groups as the smallest possible value of the ground-truth number, i.e., $K = 2$; (3) We set the number of groups as the largest possible value of the ground-truth number, i.e., $K = 6$. We only report the results using Macro-F1 as the metric, while other metrics show similar patterns.

The results are shown in Table 3. We have the following findings. In all three settings, both GS-GNN and SPONGE greatly outperform SGCN and SGDN. Recall that SGCN and SGDN are based on the balance theory, and SPONGE and our GS-GNN are based on the k-group theory. The results clearly show that balance theory fails to model the generative mechanism of the synthetic dataset and the k-group theory is strictly more general. Notice that even for $K_S = 2$, SPONGE and GS-GNN outperform SGCN and SGDN (though the margins are smaller than other K_S), indicating that the previous signed GNNs even cannot fully utilize the balance theory.

In the first setting, i.e., when the ground-truth K_S is known, both GS-GNN and SPONGE report nearly perfect results, demonstrating that they can discover the underlying structure of the synthetic dataset. Notice that SPONGE has assumed that all groups are in conflicts and only form negative links, which is in consistent with our generative mechanism. On the other hand, GS-GNN does not have such an assumption and only infer from the observed data.

In the second setting, i.e., when the number of groups is assumed minimum, GS-GNN generally outperforms SPONGE. The improvement of GS-GNN over SPONGE grows larger as there are more ground-truth groups. Even when the number of ground-truth groups is more than twice than the assumption in our model , i.e., $K_S = 5$ and $K = 2$, the performance of GS-GNN is nearly perfect. The results indicate that SPONGE cannot discover more groups than its assumption, while our proposed GS-GNN model is much more capable. We attribute this advantage to fusing the k-group theory and representation learning, which greatly enhances the model capacity. For example, when $K < K_S$, our proposed GS-GNN can possibly learn to decompose different dimensions of one group representation to model more than one group.

In the third setting, i.e., when the number of groups is assumed maximum, GS-GNN again shows better performance compared to SPONGE in most cases. In this setting, the margin between GS-GNN and SPONGE has a negative relation with the ground-truth number of groups. The results indicate that SPONGE cannot function well if its assumed groups outnumber the ground-truth. In contrast, the results of GS-GNN are impressively stable, showing that our proposed method is not sensitive to the setting of K (more results of parameter sensitivity on real graphs are provided in Section 4.5).

The above results well demonstrate the superiority of GS-GNN in modeling the synthetic dataset and utilizing the k-group theory, which is much more general than the usual assumption of balance theory. Besides, GS-GNN even outperforms the SPONGE, which uses the ground-truth group number as input.

4.3 Results on Real Graphs

Next, we present the experimental results on real signed graphs. The performance of all the methods for the link sign prediction task is shown in Table 4. We have the following observations. GS-GNN consistently outperforms all the baselines on all datasets with all evaluation metrics. On average, the improvement of GS-GNN compared to the most competent baseline is approximately 5% and in some cases, the improvement can be as large as 10%. The results clearly demonstrate the superiority of GS-GNN and the importance of extending the balance theory to the k-group theory as well as jointly learning the global and local node representations.

Notice that the positive links and negative links are imbalanced and thus different evaluation metrics focus on different aspects of the prediction results. For example, though SNEA achieves impressive results in terms of AUC and Macro-F1, SGDN and GCN report better results when we adopt Micro-F1 and Binary-F1. Nevertheless,

GS-GNN reports the best results in all aspects. The performance gains of GS-GNN are especially significant in terms of Macro-F1. Since Macro-F1 treats two classes equally and there are considerably fewer negative links, the results indicate that GS-GNN can better model the negative links, which are more vital information sources in signed graphs.

The performance of a representative unsigned graph representation learning methods GCN is worse than our proposed GS-GNN model, indicating that modeling the sign of links can be beneficial. However, GCN outperforms SGCN in some cases, showing that the capability of SGCN is somewhat limited by the simple assumption of balance theory.

SPONGE does not work as well as in the synthetic graph, especially in terms of the Macro-F1 metric. The results show that the formation of real-world signed graphs is considerably more complicated than in our synthetic graph. For example, the relationships between different groups may be far more than simple conflicts. Compared to SPONGE, our proposed GS-GNN model has more freedom to model such structures, thanks to the dual architecture of jointly learning global and local representations and the integration of k-group theory deep representation learning models.

4.4 Ablation Studies

4.4.1 The global and the local module. To verify our dual architecture design of jointly learning the global and local representations, we design two variants of GS-GNN . In GS-GNN$_L$, we only learn the local representation, $\mathbf{Z}_L$, as the final node representation, and in GS-GNN$_G$, we only utilize the global representation, $\mathbf{Z}_G$, for the downstream task. Other experimental settings are the same as Section 4. We only report the results on Bitcoin-Alpha and Bitcoin-OTC for brevity in Table 5. Overall, both modules contribute to our proposed GS-GNN, showing that the local and global representations of nodes are complementary.

4.4.2 The aggregation function. We also conduct ablation studies on the aggregation function adopted in GS-GNN. As analyzed in Section 3.3.2, the sum aggregator is more expressive than the mean aggregator. To provide empirical analyses, we replace all the aggregation functions in GS-GNN with the mean aggregator and name such a method as GS-GNN$_{\text{mean}}$. The results are shown in Table 6. GS-GNN $_{\text{sum}}$ greatly outperforms GS-GNN$_{\text{mean}}$, verifying our analyses and demonstrating the importance of choosing an expressive aggregator like the sum.

Table 5: The ablation study results of only using the global and the local component of GS-GNN.

Dataset	Metric	GS-GNN$_L$	GS-GNN$_G$	GS-GNN
Bitcoin-Alpha	AUC	0.875	0.889	0.898
	Macro-F1	0.754	0.731	0.798
	Micro-F1	0.922	0.916	0.932
	Binary-F1	0.958	0.954	0.962
Bitcoin-OTC	AUC	0.891	0.906	0.922
	Macro-F1	0.801	0.786	0.843
	Micro-F1	0.901	0.899	0.923
	Binary-F1	0.946	0.942	0.956

Table 6: The ablation study results of using different aggregators for GS-GNN.

Dataset	Metric	GS-GNN$_{\text{mean}}$	GS-GNN$_{\text{sum}}$
Bitcoin-Alpha	AUC	0.844	0.898
	Macro-F1	0.712	0.798
	Micro-F1	0.915	0.932
	Binary-F1	0.954	0.962
Bitcoin-OTC	AUC	0.900	0.922
	Macro-F1	0.812	0.843
	Micro-F1	0.914	0.923
	Binary-F1	0.950	0.956

4.5 Parameter Sensitivities

In this section, we investigate the parameter sensitivities of our GS-GNN. There are three important parameters in our proposed method: the number of layers in the local module M_L, the number of layers in the global module M_G, and the number of groups K. We conduct three controlled experiments to investigate the effects of three parameters. For brevity, we only report the results on Bitcoin-OTC and Bitcoin-Alpha.

4.5.1 The number of layers in the local module M_L. We fix M_G to 5, K to 3, and vary M_L from $\{2, 3, 4, 5, 6\}$. The results are shown in Figure 4. Overall, $M_L = 2$ is a suitable choice for both datasets, indicating that we do not need a deep architecture for the local module. A plausible reason for the performance decay as the local module grows deeper is the over-smoothing problem widely known in GNNs [24, 36]. We leave improving the local module using studies to alleviate the over-smoothing problem as future works.

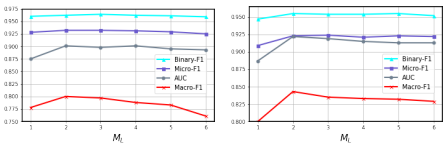

(a) Bitcoin-Alpha (b) Bitcoin-OTC

Figure 4: The parameter sensitivity results of varying M_L.

4.5.2 The number of layers in the global module M_G. We fix M_L to 2 and K to 3, and vary M_G from $\{2, 3, 4, 5, 6\}$. The results are shown in Figure 5. Contrary to the local module, the performance of GS-GNN increases as M_G grows larger. We achieve the best performance when M_G is approximately 5. The results show that a deeper architecture is needed for the global module. The global module is not affected by the over-smoothing problem. We attribute this merit to the design of a prototype-based GNN, which has a mechanism different from the existing GNNs .

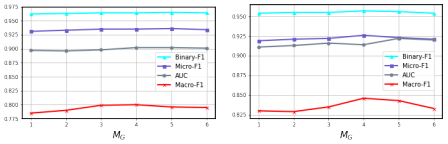

(a) Bitcoin-Alpha (b) Bitcoin-OTC

Figure 5: The parameter sensitivity results of M_G.

4.5.3 The number of groups K. To better understand the effectiveness of K, we only adopt the global module here and fix M_G as 5, and vary K from $\{2, 3, 4, 5, 6\}$. The results shown in Figure 6 suggest a consistent pattern as in the synthetic graph that our proposed GS-GNN model is not sensitive to the setting of K. In general, setting K from 3 to 5 leads to the best results.

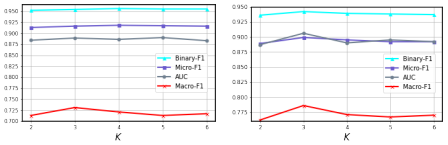

(a) Bitcoin-Alpha (b) Bitcoin-OTC

Figure 6: The parameter sensitivity results of K.

5 CONCLUSION

In this paper, we propose a novel GS-GNN model for signed graph representation learning beyond the usual balance theory assumption. Specifically, we adopt a dual GNN architecture, with the global module learning node representations based on the k-group theory, a more generalized assumption than the balance theory, and the local module complementing the global module using a relational GNN with no prior assumption. Extensive experimental results on both synthetic and real-world signed graphs demonstrate the effectiveness of GS-GNN by achieving new state-of-the-art.

ACKNOWLEDGEMENTS

This work was supported in part by National Key R&D Program of China (No. 2018AAA0102004, No. 2020AAA0106300), National Natural Science Foundation of China (No. U1936219, 61521002, 61772304), Beijing Academy of Artificial Intelligence (BAAI), and a grant from the Institute for Guo Qiang, Tsinghua University.All opinions, findings, conclusions and recommendations in this paper are those of the authors and do not necessarily reflect the views of the funding agencies. Peng Cui and Yafeng Zhang are corresponding authors.

REFERENCES

[1] Shaosheng Cao, Wei Lu, and Qiongkai Xu. 2016. Deep neural networks for learning graph representations. In *AAAI*.
[2] Kai-Yang Chiang, Joyce Jiyoung Whang, and Inderjit S Dhillon. 2012. Scalable clustering of signed networks using balance normalized cut. In *CIKM*.
[3] Mihai Cucuringu, Peter Davies, Aldo Glielmo, and Hemant Tyagi. 2019. SPONGE: A generalized eigenproblem for clustering signed networks. In *AISTATS*.
[4] Tyler Derr, Charu Aggarwal, and Jiliang Tang. 2018. Signed network modeling based on structural balance theory. In *CIKM*.
[5] Tyler Derr, Yao Ma, and Jiliang Tang. 2018. Signed graph convolutional networks. In *ICDM*.
[6] Carl Eckart and Gale Young. 1936. The approximation of one matrix by another of lower rank. *Psychometrika* (1936).
[7] Justin Gilmer, Samuel S Schoenholz, Patrick F Riley, Oriol Vinyals, and George E Dahl. 2017. Neural message passing for quantum chemistry. In *ICML*.
[8] Aditya Grover and Jure Leskovec. 2016. node2vec: Scalable feature learning for networks. In *KDD*.
[9] Frank Harary et al. 1953. On the notion of balance of a signed graph. *Michigan Mathematical Journal* (1953).
[10] Fritz Heider. 1982. *The psychology of interpersonal relations.*
[11] Ivan Herman, Guy Melançon, and M Scott Marshall. 2000. Graph visualization and navigation in information visualization: A survey. *TVCG* (2000).
[12] Paul W Holland and Samuel Leinhardt. 2013. *Perspectives on social network research.* Elsevier.
[13] Junjie Huang, Huawei Shen, Liang Hou, and Xueqi Cheng. 2019. Signed graph attention networks. In *ICANN*.
[14] Junjie Huang, Huawei Shen, Liang Hou, and Xueqi Cheng. 2021. SDGNN: Learning Node Representation for Signed Directed Networks. *arXiv:2101.02390* (2021).
[15] Mohammad Raihanul Islam, B Aditya Prakash, and Naren Ramakrishnan. 2018. Signet: Scalable embeddings for signed networks. In *Pacific-Asia Conference on Knowledge Discovery and Data Mining*.
[16] Jinhong Jung, Jaemin Yoo, and U Kang. 2020. Signed Graph Diffusion Network. *arXiv:2012.14191* (2020).
[17] Junghwan Kim, Haekyu Park, Ji-Eun Lee, and U Kang. 2018. Side: representation learning in signed directed networks. In *WWW*.
[18] Thomas N Kipf and Max Welling. 2017. Semi-supervised classification with graph convolutional networks. In *ICLR*.
[19] Andrew V Knyazev. 2017. Signed Laplacian for spectral clustering revisited. *arXiv:1701.01394* (2017).
[20] Srijan Kumar, Francesca Spezzano, VS Subrahmanian, and Christos Faloutsos. 2016. Edge weight prediction in weighted signed networks. In *ICDM*.
[21] Junhyun Lee, Inyeop Lee, and Jaewoo Kang. 2019. Self-Attention Graph Pooling. In *ICML*.
[22] Yeon-Chang Lee, Nayoun Seo, Kyungsik Han, and Sang-Wook Kim. 2020. Asine: Adversarial signed network embedding. In *SIGIR*.
[23] Jure Leskovec, Daniel Huttenlocher, and Jon Kleinberg. 2010. Signed networks in social media. In *SIGCHI*.
[24] Qimai Li, Zhichao Han, and Xiao-Ming Wu. 2018. Deeper insights into gvolutional networks for semi-supervised learning. In *AAAI*.
[25] Yu Li, Yuan Tian, Jiawei Zhang, and Yi Chang. 2020. Learning signed network embedding via graph attention. In *AAAI*.
[26] Bryan Perozzi, Rami Al-Rfou, and Steven Skiena. 2014. Deepwalk: Online learning of social representations. In *KDD*.
[27] al. Prithviraj Sen, et. 2008. Collective classification in network data. *AI magazine* (2008).
[28] Jian Tang, Meng Qu, Mingzhe Wang, Ming Zhang, Jun Yan, and Qiaozhu Mei. 2015. Line: Large-scale information network embedding. In *WWW*.
[29] Ruo-Chun Tzeng, Bruno Ordozgoiti, and Aristides Gionis. 2020. Discovering conflicting groups in signed networks. (2020).
[30] Daixin Wang, Peng Cui, and Wenwu Zhu. 2016. Structural deep network embedding. In *KDD*.
[31] Suhang Wang, Jiliang Tang, Charu Aggarwal, Yi Chang, and Huan Liu. 2017. Signed network embedding in social media. In *ICDM*.
[32] Keyulu Xu, Weihua Hu, Jure Leskovec, and Stefanie Jegelka. 2018. How Powerful are Graph Neural Networks?. In *ICLR*.
[33] Pinghua Xu, Wenbin Hu, Jia Wu, and Bo Du. 2019. Link prediction with signed latent factors in signed social networks. In *KDD*.
[34] Bo Yang, Xuehua Zhao, and Xueyan Liu. 2015. Bayesian approach to modeling and detecting communities in signed network. In *AAAI*.
[35] Zhitao Ying, Jiaxuan You, Christopher Morris, Xiang Ren, William L Hamilton, and Jure Leskovec. 2018. Hierarchical Graph Representation Learning with Differentiable Pooling. In *NeurIPS*.
[36] Ziwei Zhang, Peng Cui, and Wenwu Zhu. 2020. Deep learning on graphs: A survey. *TKDE* (2020).
[37] Chenyi Zhuang and Qiang Ma. 2018. Dual graph convolutional networks for graph-based semi-supervised classification. In *WWW*.

A EXPERIMENTAL DETAILS FOR REPRODUCIBILITY

A.1 Datasets and Codes

We adopt the following publicly available source codes and datasets.

- Datasets: https://github.com/liyu1990/data
- SPONGE [3]: https://github.com/alan-turing-institute/SigNet
- SLF [33]: https://github.com/WHU-SNA/SLF
- SIDE [17]: https://datalab.snu.ac.kr/side/resources/side.zip
- GCN [18]: https://github.com/tkipf/pygcn
- SGCN [5]: https://github.com/benedekrozemberczki/SGCN
- SNEA [13]: https://github.com/liyu1990/snea
- SGDN [16]: https://openreview.net/attachment?id=YPm0fzy_z6R&name=supplementary_material

A.2 Software and Hardware Configurations

All experiments are conducted on a server with the following configurations.

- Operating System: Ubuntu 18.04.1 LTS
- CPU: Intel(R) Xeon(R) Gold 5218 CPU @ 2.30GHz
- GPU: GeForce GTX TITAN X
- Software: Python 3.7.9, Cuda 10.2, PyTorch 1.7.1, TenfowFlow 1.13.2

Structure Guided Lane Detection

Jinming Su*, **Chao Chen**, **Ke Zhang**, **Junfeng Luo***, **Xiaoming Wei** and **Xiaolin Wei**
Meituan
{sujinming, chenchao60, zhangke21, luojunfeng, weixiaoming, weixiaolin02}@meituan.com

Abstract

Recently, lane detection has made great progress with the rapid development of deep neural networks and autonomous driving. However, there exist three mainly problems including characterizing lanes, modeling the structural relationship between scenes and lanes, and supporting more attributes (*e.g.*, instance and type) of lanes. In this paper, we propose a novel structure guided framework to solve these problems simultaneously. In the framework, we first introduce a new lane representation to characterize each instance. Then a top-down vanishing point guided anchoring mechanism is proposed to produce intensive anchors, which efficiently capture various lanes. Next, multi-level structural constraints are used to improve the perception of lanes. In the process, pixel-level perception with binary segmentation is introduced to promote features around anchors and restore lane details from bottom up, a lane-level relation is put forward to model structures (*i.e.*, parallel) around lanes, and an image-level attention is used to adaptively attend different regions of the image from the perspective of scenes. With the help of structural guidance, anchors are effectively classified and regressed to obtain precise locations and shapes. Extensive experiments on public benchmark datasets show that the proposed approach outperforms state-of-the-art methods with 117 FPS on a single GPU.

1 Introduction

Lane detection, which aims to detect lanes in road scenes, is a fundamental perception task and has a wide range of applications (*e.g.*, ADAS [Butakov and Ioannou, 2014], autonomous driving [Chen and Huang, 2017] and high-definition map production [Homayounfar *et al.*, 2019]). Over the past years, lane detection has made significant progress and it is also used as an important element for tasks of road scene understanding, such as driving area detection [Yu *et al.*, 2020].

To address the task of lane detection, lots of learning-based methods [Pan *et al.*, 2018; Qin *et al.*, 2020] have been proposed in recent years, achieving impressive performance on existing benchmarks [TuSimple, 2017; Pan *et al.*, 2018]. However, there still exist several challenges that hinder the development of lane detection. Frist, there lacks a unified and effective lane representation. As shown in (a) of Fig. 1, there exist various definitions including point [TuSimple, 2017], mask [Pan *et al.*, 2018], marker [Yu *et al.*, 2020] and grid [Lee *et al.*, 2017], which are quite different in form for different scenarios. Second, it is difficult to model the structural relationship between scenes and lanes. As displayed in (b) of Fig. 1, the structural information depending on scenes, such as location of vanishing points and parallelism of lanes, is very useful, but there is no scheme to describe it. Last, while predicting lanes, it is also important to predict other attributes including instance and type (see (c) of Fig. 1), but it is not easy to extend these for existing methods. These three difficulties are especially difficult to deal with and greatly slow down the development of lane detection. Due to these difficulties, lane detection remains a challenging vision task.

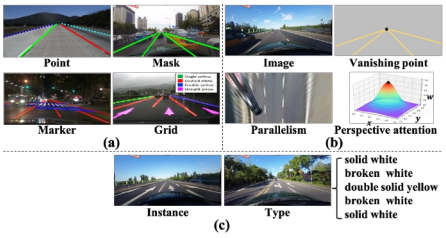

Figure 1: Challenges of lane detection. (a) Various representation. There exist many kinds of annotations [TuSimple, 2017; Pan *et al.*, 2018; Yu *et al.*, 2020; Lee *et al.*, 2017], which makes it difficult to characterize lanes in a unified way. (b) Underresearched scene structures. Lane location are strongly dependent on structural information, such as vanishing point (black point), parallelism in bird's eye view and distance attention caused by perspective. (c) More attributes to support. Lanes have more attributes such as instance and type, which should be predicted.

To deal with the first difficulty, many methods characterize lanes with simple fitted curves or masks. For examples, SCNN [Pan *et al.*, 2018] treats the problem as a semantic

* Co-corresponding author.

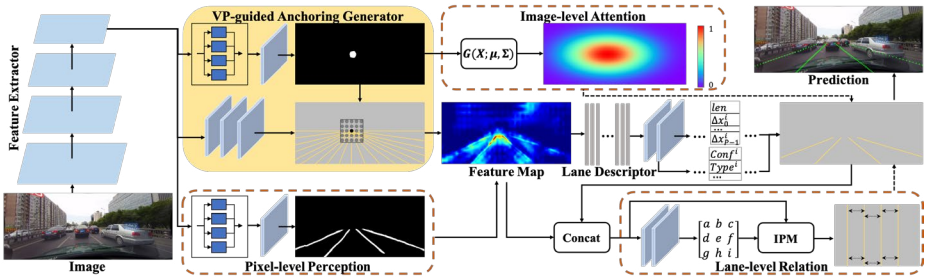

Figure 2: Framework of our approach. We first extract the common features by the extractor, which provides features for vanishing point guided anchoring and pixel-level perception. The anchoring produces intensive anchors and perception utilizes binary segmentation to promote features around lanes. Promoted features are used to classify and regress anchors with the aid of lane-level relation and image-level attention. The dashed arrow indicates the supervision, and the supervision of vanishing point and lane segmentation is omitted in the figure.

segmentation task, and introduces slice-by-slice convolutions within feature maps, thus enabling message passing. For these methods, lanes are characterized as a special form (*e.g.*, point, curve or mask), so it is difficult to support the format of marker or grid that usually has an uncertain number. Similarly, those who support the latter [Lee *et al.*, 2017] do not support the former well. To address the second problem, some methods use vanishing point or parallel relation as auxiliary information. For example, a vanishing point prediction task [Lee *et al.*, 2017] is utilized to implicitly embed a geometric context recognition capability. In these methods, they usually only pay attention to a certain kind of structural information or do not directly use it end-to-end, which leads to the structures not fully functioning and the algorithm complicated. For the last problem, some clustering- or detection-based methods are used to distinguish or classify instances. Line-CNN [Li *et al.*, 2019] utilizes line proposals as references to locate traffic curves, which forces the method to learn the feature of lanes. To these methods, they can distinguish instances and even extend to more attributes, but they usually need extra computation and have many manually designed super-parameters, which leads to poor scalability.

Inspired by these observations and analysis, we propose a novel structure guided framework for lane detection, as shown in Fig. 2. In order to characterize lanes, we propose a box-line based proposal method. In this method, the minimum circumscribed rectangle of the lane is used to distinguish instance, and its center line is used for structured positioning. For the sake of further improving lane detection by utilizing structural information, the vanishing point guided anchoring mechanism is proposed to generate intensive anchors (*i.e.*, as few and accurate anchors as possible). In this mechanism, vanishing point is learned in a segmentation manner and used to produce structural anchors top-down, which can efficiently capture various lanes. Meanwhile, we put forward multi-level structure constraints to improve the perception of lanes. In the process, the pixel-level perception is used to improve lane details with the help of lane binary segmentation, the lane-level relation aims at modeling the parallelism properties of inter-lanes by Inverse Perspective Mapping (IPM) via a neural network, and image-level attention is to attend the image with adaptive weights from the perspective of scenes. Finally, features of lane anchors under structural guidance are extracted for accurate classification, regression and the prediction of other attributes. Experimental results on CULane and Tusimple datasets verify the effectiveness of the proposed method which achieves state-of-the-art performance and run efficiently at 117 FPS.

The main contributions of this paper include: 1) we propose a structure guided framework for lane detection, which characterize lanes and can accurately class, locate and restore the shape of unlimited lanes. 2) we introduce a vanishing point guided anchoring mechanism, in which the vanishing point is predicted and used to produce intensive anchors, which can precisely capture lanes. 3) we put forward the multi-level structural constraints, which are used to sense pixel-level unary details, model lane-level pair-wise relation and adaptively attend image-level global information.

2 Related Work

In this section, we review the related works that aim to resolve the challenges of lane detection in two aspects.

2.1 Traditional Methods

To solve the problem of lane detection, traditional methods are usually based on hand-crafted features by detecting shapes of markings and fitting the spline. [Veit *et al.*, 2008] presents a comprehensive overview of features used to detect road markings. And [Wu and Ranganathan, 2012] uses Maximally Stable Extremal Regions features and performs the template matching to detect multiple road markings. However, there approaches often fail in unfamiliar conditions.

2.2 Deep Learning based Methods

With the development of deep learning, methods [Pizzati and García, 2019; Van Gansbeke *et al.*, 2019; Guo *et al.*, 2020] based on deep neural networks achieve progress in lane detection. SCNN [Pan *et al.*, 2018] generalizes traditional deep

layer-by-layer convolutions to enable message passing between pixels across rows and columns. ENet-SAD [Hou *et al.*, 2019] presents a knowledge distillation approach, which allows a model to learn from itself without any additional supervision or labels. PolyLaneNet [Tabelini *et al.*, 2020] adopts a polynomial representation for the lane markings, and outputs polynomials via the deep polynomial regression. UltraFast [Qin *et al.*, 2020] treats the process of lane detection as a row-based selecting problem using global features. CurveLanes [Xu *et al.*, 2020] proposes a lane-sensitive architecture search framework to automatically capture both long-ranged coherent and accurate short-range curve information.

In these methods, different lane representations are adopted and some structural information is considered for performance improvement. However, these methods are usually based on the powerful learning ability of neural networks to learn the fitting or shapes of lanes, and the role of scene-related structural information for lanes has not been paid enough attention to and discussed.

3 The Proposed Approach

To address these difficulties (i.e., characterizing lanes, modeling the relationship between scenes and lanes, and supporting more attributes), we propose a novel structure guided framework for lane detection, denoted as **SGNet**. In this framework, we first introduce a new lane representation. Then a top-down vanishing point guided anchoring mechanism is proposed, and next multi-level structure constraints is used. Details of the proposed approach are described as follows.

3.1 Representation

For adapting to different styles of lane annotation, we introduce a new box-line based method for lane representation. Firstly, we calculate the minimum circumscribed rectangle R ("box") with the height h and width w for the lane instance L_{lane}. For this rectangle, center line L_{center} ("line") perpendicular to the short side is obtained. And the angle between the positive X-axis and L_{center} in clockwise direction is θ. In this manner, L_{center} provides the position of the lane instance, and h and w restrict the areas involved. Based on R and L_{center} , lane prediction based on points, masks, markers, grids and other formats can be performed. In this paper, the solution based on key points of lane detection is taken just because of the point-based styles of lane annotation in public datasets (*e.g.*, CULane [TuSimple, 2017] and Tusimple [Pan *et al.*, 2018]).

Inspired by existing methods [Li *et al.*, 2019; Chen *et al.*, 2019; Qin *et al.*, 2020], we define key points of the lane instance with equally spaced y coordinates $Y = \{y_i\}$ and $y_i = \frac{H}{P-1} \cdot i (i = 1, 2, ..., P-1)$, where P means the number of all key points through image height, which is fixed on images with same height H and width W. Accordingly, the x coordinates of the lane is expressed as $X = \{x_i\}$. For the convenience of expression, the straight line equation of L_{center} is defined as

$$ax + by + c = 0, a \neq 0 \ or \ b \neq 0 \tag{1}$$

where a, b and c can be easily computed by θ and any point on L_{center}. Next, when the y coordinate of the center line is

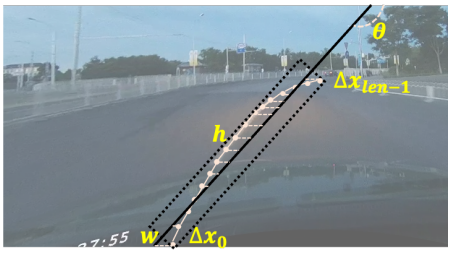

Figure 3: Lane representation.

y_i, we can compute the corresponding x coordinate as

$$x_i = L_{center}(y_i) = \frac{-c - by_i}{a}, a \neq 0. \tag{2}$$

Then, we define the offset of x coordinate ΔX between the lane L_{lane} and center line L_{center} as

$$\begin{aligned} \Delta X &= \{\Delta x_i\} = \{x_i - \frac{-c - by_i}{a}\}, \\ X &= \{\frac{-c - by_i}{a}\} + \Delta X. \end{aligned} \tag{3}$$

Therefore, based on L_{center} and ΔX, we can calculate the lane instance L_{lane}. Usually, it is easier to learn L_{center} and ΔX than the directly fitting key points of L_{lane}.

3.2 Feature Extractor

To see Fig. 2, SGNet takes ResNet [He *et al.*, 2016] as the feature extractor, which is modified to remove the last global pooling and fully connected layers for the pixel-level prediction task. Feature extractor has five residual modules for encoding, named as $\mathcal{E}_i(\pi_i)$ with parameters $\pi_i (i = 1, 2, ..., 5)$. To obtain larger feature maps, we convolve $\mathcal{E}_5(\pi_5)$ by a convolutional layer with 256 kernels of 3×3 and then $\times 2$ upsample the features, followed by an element-wise summation with $\mathcal{E}_4(\pi_4)$ to obtain $\mathcal{E}'_4(\pi'_4)$. Finally, for a $H \times W$ input image, a $\frac{H}{16} \times \frac{W}{16}$ feature map is output by the feature extractor.

3.3 Vanishing Point Guided Anchoring

In order to learn the lane representation, there are two main ways to learn the center line L_{center} and x offset ΔX. The first way is to learn the determined L_{center} directly with angle, number and position regression, which is usually difficult to achieve precise results because of the inherent difficulty of regression tasks. The second way is based on mature detection tasks, using dense anchors to classify, regress and then obtain proposals representing the lane instance. And the second one has been proved to work well in general object detection tasks, so we choose it as our base model.

To learn the center line L_{center} and x offset ΔX well, we propose a novel vanishing point guided anchoring mechanism (named as VPG-Anchoring). The vanishing point (VP) provides strong characterization of geometric scene, representing the end of the road and also the "virtual" point where

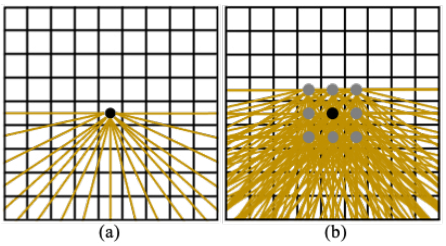

Figure 4: VP-guided anchoring mechanism. Anchors (golden lines) generated based on (a) the vanishing point (black point) and (b) the area around vanishing point (black and gray points).

the lanes intersect in the distance. Since VP is the intersection point of lanes, lanes in the scene must pass through VPs, and lines that do not pass through VPs are not lanes in the scene with high probability. Therefore, dense lines radiated from VPs can theoretically cover all lanes in the image, which is equivalent to reducing the generation space of anchors from $\mathbb{R}^{H\times W\times N_{proposal}}$ to $\mathbb{R}^{N_{proposal}}$. $N_{proposal}$ represents the number of anchors generated at one pixel.

As shown in Fig. 2, the features map $\mathcal{E}_4'(\pi_4')$ is feed to VPG-Anchoring. In the mechanism, VP is predicted by a simple branch, which is implemented by a multi-scale context-aware atrous spatial pyramid pooling (ASPP) [Chen *et al.*, 2018] followed by a convolutional layer with 256 kernels of 3×3 and a softmax activation. The VP prediction branch is denoted as $\phi_{\mathcal{V}}(\pi_{\mathcal{V}})$ with parameters $\pi_{\mathcal{V}}$.

Usually, VP is not annotated in lane datasets, such as CULane [Pan *et al.*, 2018], so we average the intersection points of the center lines of all lane instances and get the approximate VP. In addition, a single point is usually difficult to predict, so we expand the area of VP to a radius of 16 pixels and use segmentation algorithm to predict. To achieve this, we expect the output of $\phi_{\mathcal{V}}(\pi_{\mathcal{V}})$ to approximate the ground-truth masks of VP (represented as $G_{\mathcal{V}}$) by minimizing the loss

$$\mathcal{L}_{\mathcal{V}} = BCE(\phi_{\mathcal{V}}(\pi_{\mathcal{V}}), G_{\mathcal{V}}), \tag{4}$$

where $BCE(\cdot,\cdot)$ represents the pixel-level binary cross-entropy loss function.

In order to ensure that generated anchors are dense enough, we choose a $W_{anchor} \times W_{anchor}$ rectangular area with VP as the center, and take one point every S_{anchor} to generate anchors. For each point, anchors are generated every A_{anchor} angle ($A_{anchor} \in [0, 180]$) as shown in Fig. 4. In this way, anchors are targeted, intensive and not redundant, compared with general full-scale uniform generation and even specially designed methods for lanes [Li *et al.*, 2019]. Note that anchors run through the whole image, and only the part below VP is shown for convenient display in Figs. 2 and 4.

3.4 Classification and Regression

In order to classify and regress the generated anchors, we extract high-level feature maps based on $\mathcal{E}_4(\pi_4)$ with several convolutional layers. The feature map is named as $\mathrm{F}_{\mathcal{A}} \in \mathbb{R}^{H'\times W'\times C'}$, where H', W' and C' are the height, width and channel of $\mathrm{F}_{\mathcal{A}}$. For each anchor L_{lane}, the channel-level features of each point on anchors are extracted from $\mathrm{F}_{\mathcal{A}}$ to obtain lane descriptor $\mathrm{D}_{\mathcal{A}} \in \mathbb{R}^{H'\times C'}$, which are used to classify the existence $Conf^{L_{lane}}$ and regress x offsets $\Delta X^{L_{lane}}$ including the length len of lanes. To learn these, we expect the output to approximate the ground-truth existence $GConf^{L_{lane}}$ and x offsets $G\Delta X^{L_{lane}}$ by minimizing the loss

$$\begin{aligned}\mathcal{L}_{\mathcal{C}} &= \sum_{L_{lane}=0}^{L-1} BCE(Conf^{L_{lane}}, GConf^{L_{lane}}),\\ \mathcal{L}_{\mathcal{R}} &= \sum_{L_{lane}=0}^{L-1} SL1(\Delta X^{L_{lane}}, G\Delta X^{L_{lane}}),\end{aligned} \tag{5}$$

where $SL1(\cdot,\cdot)$ means smooth L1 loss and L means the number of proposals. Finally, Line-NMS [Li *et al.*, 2019] is used to obtain the finally result with confidence thresholds.

3.5 Multi-level Structure Constraints

In order to further improve lane perception, we ask for the structural relationship between scenes and lanes, and deeply explore the pixel-level, lane-level and image-level structures.

Pixel-level Perception. The top-down VPG-Anchoring mechanism covers the structures and distribution of lanes. At the same time, there is a demand of bottom-up detail perception, which ensures that lane details are restored and described more accurately. For the sake of improving the detail perception, we introduce lane segmentation branch to location lane locations and promote pixel-level unary details. As shown in Fig. 2, the lane segmentation branch has the same input and similar network structure with the VP prediction branch. The lane segmentation branch is denoted as $\phi_{\mathcal{P}}(\pi_{\mathcal{P}})$ with parameters $\pi_{\mathcal{P}}$. To segment lanes, we expect the output of $\mathrm{P}_{\mathcal{P}} = \phi_{\mathcal{P}}(\pi_{\mathcal{P}})$ to approximate the ground-truth masks of binary lane mask (represented as $G_{\mathcal{P}}$) by minimizing the loss

$$\mathcal{L}_{\mathcal{P}} = BCE(\mathrm{P}_{\mathcal{P}}, G_{\mathcal{P}}). \tag{6}$$

To promote the pixel-level unary details, we weight the input features $\mathrm{F}_{\mathcal{A}}$ by the following operation

$$\mathrm{M}_{\mathcal{A}} = \mathrm{F}_{\mathcal{A}} \otimes \mathrm{P}_{\mathcal{P}} + \mathrm{F}_{\mathcal{A}}, \tag{7}$$

where $M_{\mathcal{A}}$ are feed to classify and regress instead of $\mathrm{F}_{\mathcal{A}}$.

Lane-level Relation. In fact, lanes conform to certain rules in the construction process, and the most important one is that the lanes are parallel. Due to imaging reasons, this relationship is no longer maintained after perspective transformation, but it can be modeled potentially. To model the lane-level relation, we conduct IPM by the H Matrix [Neven *et al.*, 2018] via a neural network. After learning H, the lane instance L_{lane} can be transformed to L'_{lane} on bird's eye view, where different instances are parallel. Formally, we define the relationship between lanes as follows. For two lane instances L_{lane1} and L_{lane2} in the image, they are projected to the bird's-eye view through the learned H matrix, and the corresponding instance L'_{lane1} and L'_{lane2} are obtained. The two instances can be fitted to the following linear equations:

$$\begin{aligned}a_1 * x + b_1 * y + c_1 = 0,\\ a_2 * x + b_2 * y + c_2 = 0.\end{aligned} \tag{8}$$

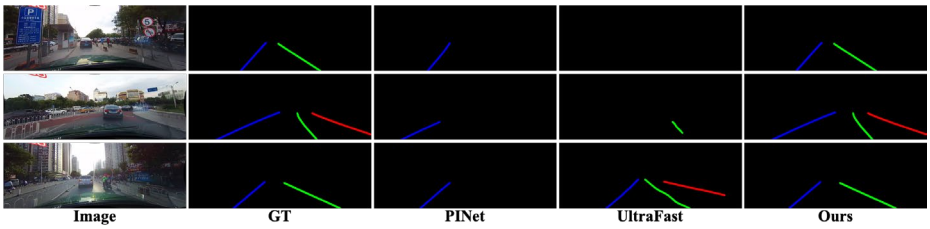

Figure 5: Qualitative comparisons of the state-of-the-art algorithms and our approach.

	Total	Normal	Crowd	Dazzle	Shadow	No line	Arrow	Curve	Cross	Night	FPS
DeepLabV2-50	66.70	87.40	64.10	54.10	60.70	38.10	79.00	59.80	2505	60.60	-
SCNN	71.60	90.60	69.70	58.50	66.90	43.40	84.10	64.40	1990	66.10	8
FD	-	85.90	63.60	57.00	59.90	40.60	79.40	65.20	7013	57.80	-
ENet-SAD	70.80	90.10	68.80	60.20	65.90	41.60	84.00	65.70	1998	66.00	75
PointLane	70.20	88.00	68.10	61.50	63.30	44.00	80.90	65.20	1640	63.20	-
RONELD	72.90	-	-	-	-	-	-	-	-	-	-
PINet	74.40	90.30	72.30	66.30	68.40	**49.80**$_3$	83.70	65.60	**1427**$_3$	67.70	25
ERFNet-E2E	74.00	**91.00**$_3$	**73.10**$_3$	64.50	**74.10**$_2$	46.60	**85.80**$_3$	**71.90**$_1$	2022	67.90	-
IntRA-KD	72.40	-	-	-	-	-	-	-	-	-	98
UltraFast-18	68.40	87.70	66.00	58.40	62.80	40.20	81.00	57.90	1743	62.10	**323**$_1$
UltraFast-34	72.30	90.70	70.20	59.50	69.30	44.40	85.70	**69.50**$_3$	2037	66.70	**175**$_2$
CurveLanes	**74.80**$_3$	90.70	72.30	**67.70**$_2$	70.10	49.40	**85.80**$_3$	68.40	1746	**68.90**$_3$	-
Ours-Res18	**76.12**$_2$	**91.42**$_2$	**74.05**$_2$	**66.89**$_3$	**72.17**$_3$	**50.16**$_2$	**87.13**$_2$	67.02	**1164**$_1$	**70.67**$_2$	**117**$_3$
Ours-Res34	**77.27**$_1$	**92.07**$_1$	**75.41**$_1$	**67.75**$_1$	**74.31**$_1$	**50.90**$_1$	**87.97**$_1$	**69.65**$_2$	**1373**$_2$	**72.69**$_1$	92

Table 1: Comparisons with state-of-the-art methods on CULane dataset. F1-measure score ("%" is omitted) is used to evaluate the results of total and 8 sub-categories. For Cross, only FP are shown. The top three results are in **red**$_1$, **green**$_2$ and **blue**$_3$ fonts with a footnote.

In these two equations, under the condition that y is equal, the difference of x is always constant. Thus we can get that $a_1 * b_2 = a_2 * b_1$. Expanding to all instances, lane-level relation can be formulated as

$$L_{\mathcal{L}} = \sum_{i=0,j=0,i\neq j}^{L-1} L1(a_i b_j - a_j b_i). \tag{9}$$

Image-level Attention. In the process of camera imaging, distant objects are small after projection. Usually, the distant information of lanes is not prominent visually, but they are equally important. After analysis, it is found that the distance between lanes and VP reflects the inverse proportion to scales in imaging. Therefore, we generate perspective attention map PAM based on VP, which is based on the strong assumption that the attention and distance after imaging satisfies two-dimensional gaussian distribution. PAM ensures the attention of different regions by adaptively restricting the classification and regression loss (from Eq. 5) as follows.

$$\begin{aligned} L_{\mathcal{I}} = \sum_{L_{lane}=0}^{L-1} \sum_{p=0}^{P-1} & L1(\Delta x_p^{L_{lane}}, G\Delta x_p^{L_{lane}}) \\ & \cdot (1 + |E(x_p^{L_{lane}}, y_p^{L_{lane}})|), \end{aligned} \tag{10}$$

where $|\cdot|$ means normalized to [0, 1].

By taking the losses of Eqs.(4),(5),(6),(9) and (10), the overall learning objective can be formulated as follows:

$$\min_{\mathbb{P}} \mathcal{L}_{\mathcal{V}} + \mathcal{L}_{\mathcal{C}} + \mathcal{L}_{\mathcal{R}} + \mathcal{L}_{\mathcal{P}} + \mathcal{L}_{\mathcal{L}} + \mathcal{L}_{\mathcal{I}}, \tag{11}$$

where $\mathbb{P}$ is the set of $\{\{\pi_i\}_{i=1}^5, \pi'_4, \pi_{\mathcal{V}}, \pi_{\mathcal{C}}, \pi_{\mathcal{R}}, \pi_{\mathcal{P}}, \pi_{\mathcal{L}}\}$, and $\pi_{\mathcal{C}}, \pi_{\mathcal{R}}$ and $\pi_{\mathcal{L}}$ are the parameters of classification, regression and lane-level relation subnetworks, respectively.

4 Experiments and Results

4.1 Experimental Setup

Dataset. To evaluate the performance of the proposed method, we conduct experiments on CULane [Pan *et al.*, 2018] and Tusimple [TuSimple, 2017] dataset. CULane dataset has a split with 88,880/9,675/34,680 images for train/val/test and Tusimple dataset is divided into three parts: 3,268/358/2,782 for train/val/test.

Metrics. For CULane, we use F1-measure score as the evaluation metric. Following [Pan *et al.*, 2018], we treat each lane as a line with 30 pixel width and compute the intersection-over-union (IoU) between groundtruths and predictions with a threshold of 0.5 to For Tusimple, the official metric (Accuracy) is used as the evaluation criterion, which evaluates the correction of predicted lane points.

Training and Inference. We use Adam optimization algorithm to train our network end-to-end by optimizing the loss in Eq. (11). In the optimization process, the parameters of

	Accuracy	FPS
DeepLabV2-18	92.69	40
DeepLabV2-34	92.84	20
SCNN	**96.53**$_2$	8
FD	94.90	-
ENet-SAD	**96.64**$_1$	**75**$_3$
Cascaded-CNN	95.24	60
PolyLaneNet	93.36	**115**$_1$
Ours-Res34	**95.87**$_3$	**92**$_2$

Table 2: Comparisons with state-of-the-arts on Tusimple.

	VPG-A	Pixel	Lane	Image	Total
Base					71.98
Base+V-F	✓				74.08
Base+V	✓				74.27
Base+V+P	✓	✓			76.30
Base+V+P+L	✓	✓	✓		76.70
SGNet	✓	✓	✓	✓	77.27

Table 3: Performance of different settings of the proposed method. "-A" means "Anchoring".

feature extractor are initialized by the pre-trained ResNet-18/34 model and "poly" learning rate policy are employed for all experiments. The training images are resized to the resolution of 360×640 for faster training, and applied affine and flipping. And we train the model for 10 epochs on CULane and 60 epochs on TuSimple. Moreover, we empirically and experimentally set the number of points $P = 72$, the width of rectangular $W_{anchor} = 40$, anchor strides $S_{anchor} = 5$ and anchor angle interval $A_{anchor} = 5$.

4.2 Comparisons with State-of-the-art Methods

We compare our approach with state-of-the-arts including DeeplabV2 [Chen *et al.*, 2017], SCNN [Pan *et al.*, 2018], FD [Philion, 2019], ENet-SAD [Hou *et al.*, 2019] , PointLane [Chen *et al.*, 2019], RONELD [Chng *et al.*, 2020], PINet [Ko *et al.*, 2020], ERFNet-E2E [Yoo *et al.*, 2020], IntRA-KD [Hou *et al.*, 2020], UltraFast [Qin *et al.*, 2020], CurveLanes [Xu *et al.*, 2020], Cascaded-CNN [Pizzati *et al.*, 2019] and PolyLaneNet [Tabelini *et al.*, 2020].

We compare our approach with 10 state-of-the-art methods on CULane dataset, as listed in Tab. 1. Comparing our ResNet34-based method with others, we can see that the proposed method consistently outperforms other methods across total and almost all categories. For the total dataset, our method is noticeably improved from 74.80% to 77.27% compared with the second best method. Also, it is worth noting that our method is significantly better on Crowd (+2.31%), Arrow (+2.17%) and Night (+3.79%) compared with second best methods, respectively. In addition, we also obviously lower FP on Cross by 3.78% relative to the second best one. As for Curve, we are slightly below the best method (ERFNet-E2E), which conducts special treatment for curve points while maybe damaging other categories. Moreover, our method has a faster FPS than almost all results. These observations present the efficiency and robustness of our proposed method and validate that VPG-Anchoring and multi-level structures are useful for the task of lane detection.

Some examples generated by our approach and other state-of-the-art algorithms are shown in Fig. 5. We can see that lanes can be detected with accurate location and precise shape by the proposed method, even in complex situations. These visualizations indicate that the proposed lane representation has a good characterization of lanes, and also show the superiority of the proposed method.

Moreover, we list the comparisons on Tusimple as shown in Tab. 2. It can be seen that our method is competitive in highway scenes without adjustment, which further proves the effectiveness of structural information for lane detection.

4.3 Ablation Analysis

To validate the effectiveness of different components of the proposed method, we conduct several experiments on CULane to compare the performance variations of our methods.

Effectiveness of VPG-Anchoring. To investigate the effectiveness of the proposed VPG-Anchoring, we conduct ablation experiments and introduce three different models for comparisons. The first setting is only the feature extractor and the subnetwork of classification and regression, which is regarded as "Base" model. In Base, anchor is generated uniformly at all positions of the feature map, and A_{anchor} is lowered to ensure the same number with SGNet. In addition, we conduct another model ("Base+V") by adding VPG-Anchor. And we also replace the L_{center} by straight line fitted directly by key points as the "Base+V-F" to explore the importance of VP. The comparisons of above models are listed in Tab. 3. We can observe that the VPG-Anchoring greatly improve the performance of Base model, which verifies the effectiveness of this mechanism. In addition, comparing Base+V with Base+V-F, we find the proposed approximate VP in lane presentation is better than the one by direct fitting.

Effectiveness of Multi-level Structures. To explore the effectiveness of the pixel-level, lane-level and image-level structures, we conduct another experiments by combining the pixel-level perception with "Base+V" as "Base+V+P" and adding lane-level relation to "Base+V+P" as "Base+V+P+L". From the last four rows of Tab. 3, we can find that the performance of lane detection can be continuously improved by pixel-, lane- and image-level structures, which validates that the three levels of constrains are compatible with each other, and can be used together to gain performance.

5 Conclusion

In this paper, we rethink the difficulties that hinder the development of lane detection and propose a structure guided framework. In this framework, we introduce a new lane representation to meet the demands of various lane representations. Based on the representation, we propose a novel vanishing point guided anchoring mechanism to generate intensive anchors for efficiently capturing lanes. In addition, multi-level structure constraints is modeled to improve lane perception. Extensive experiments on benchmark datasets validates the effectiveness of the proposed approach with fast inference and shows that the perspective of modeling and utilization of structure information is useful for lane detection.

References

[Butakov and Ioannou, 2014] Vadim A Butakov and Petros Ioannou. Personalized driver/vehicle lane change models for adas. *IEEE TVT*, 64(10):4422–4431, 2014.

[Chen and Huang, 2017] Zhilu Chen and Xinming Huang. End-to-end learning for lane keeping of self-driving cars. In *IEEE IV*, 2017.

[Chen *et al.*, 2017] Liang-Chieh Chen, George Papandreou, Iasonas Kokkinos, Kevin Murphy, and Alan L Yuille. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs. *IEEE TPAMI*, 40(4):834–848, 2017.

[Chen *et al.*, 2018] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation. In *ECCV*, 2018.

[Chen *et al.*, 2019] Zhenpeng Chen, Qianfei Liu, and Chenfan Lian. Pointlanenet: Efficient end-to-end cnns for accurate real-time lane detection. In *IEEE IV*, 2019.

[Chng *et al.*, 2020] Zhe Ming Chng, Joseph Mun Hung Lew, and Jimmy Addison Lee. Roneld: Robust neural network output enhancement for active lane detection. *arXiv preprint arXiv:2010.09548*, 2020.

[Guo *et al.*, 2020] Yuliang Guo, Guang Chen, Peitao Zhao, Weide Zhang, Jinghao Miao, Jingao Wang, and Tae Eun Choe. Gen-lanenet: A generalized and scalable approach for 3d lane detection. In *ECCV*, 2020.

[He *et al.*, 2016] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, 2016.

[Homayounfar *et al.*, 2019] Namdar Homayounfar, Wei-Chiu Ma, Justin Liang, Xinyu Wu, Jack Fan, and Raquel Urtasun. Dagmapper: Learning to map by discovering lane topology. In *ICCV*, 2019.

[Hou *et al.*, 2019] Yuenan Hou, Zheng Ma, Chunxiao Liu, and Chen Change Loy. Learning lightweight lane detection cnns by self attention distillation. In *ICCV*, 2019.

[Hou *et al.*, 2020] Yuenan Hou, Zheng Ma, Chunxiao Liu, Tak-Wai Hui, and Chen Change Loy. Inter-region affinity distillation for road marking segmentation. In *CVPR*, 2020.

[Ko *et al.*, 2020] Yeongmin Ko, Jiwon Jun, Donghwuy Ko, and Moongu Jeon. Key points estimation and point instance segmentation approach for lane detection. *arXiv preprint arXiv:2002.06604*, 2020.

[Lee *et al.*, 2017] Seokju Lee, Junsik Kim, Jae Shin Yoon, Seunghak Shin, Oleksandr Bailo, Namil Kim, Tae-Hee Lee, Hyun Seok Hong, Seung-Hoon Han, and In So Kweon. Vpgnet: Vanishing point guided network for lane and road marking detection and recognition. In *ICCV*, 2017.

[Li *et al.*, 2019] Xiang Li, Jun Li, Xiaolin Hu, and Jian Yang. Line-cnn: End-to-end traffic line detection with line proposal unit. *IEEE Transactions on Intelligent Transportation Systems*, 21(1):248–258, 2019.

[Neven *et al.*, 2018] Davy Neven, Bert De Brabandere, Stamatios Georgoulis, Marc Proesmans, and Luc Van Gool. Towards end-to-end lane detection: an instance segmentation approach. In *IEEE IV*, 2018.

[Pan *et al.*, 2018] Xingang Pan, Jianping Shi, Ping Luo, Xiaogang Wang, and Xiaoou Tang. Spatial as deep: Spatial cnn for traffic scene understanding. In *AAAI*, 2018.

[Philion, 2019] Jonah Philion. Fastdraw: Addressing the long tail of lane detection by adapting a sequential prediction network. In *CVPR*, 2019.

[Pizzati and García, 2019] Fabio Pizzati and Fernando García. Enhanced free space detection in multiple lanes based on single cnn with scene identification. In *IEEE IV*, 2019.

[Pizzati *et al.*, 2019] Fabio Pizzati, Marco Allodi, Alejandro Barrera, and Fernando García. Lane detection and classification using cascaded cnns. In *International Conference on Computer Aided Systems Theory*, 2019.

[Qin *et al.*, 2020] Zequn Qin, Huanyu Wang, and Xi Li. Ultra fast structure-aware deep lane detection. In *ECCV*, 2020.

[Tabelini *et al.*, 2020] Lucas Tabelini, Rodrigo Berriel, Thiago M Paixão, Claudine Badue, Alberto F De Souza, and Thiago Oliveira-Santos. Polylanenet: Lane estimation via deep polynomial regression. *arXiv preprint arXiv:2004.10924*, 2020.

[TuSimple, 2017] TuSimple. Tusimple lane detection challenge. http://benchmark.tusimple.ai/#/, 2017. Accessed: 2017.

[Van Gansbeke *et al.*, 2019] Wouter Van Gansbeke, Bert De Brabandere, Davy Neven, Marc Proesmans, and Luc Van Gool. End-to-end lane detection through differentiable least-squares fitting. In *ICCV Workshops*, 2019.

[Veit *et al.*, 2008] Thomas Veit, Jean-Philippe Tarel, Philippe Nicolle, and Pierre Charbonnier. Evaluation of road marking feature extraction. In *IEEE Conference on Intelligent Transportation Systems*, 2008.

[Wu and Ranganathan, 2012] Tao Wu and Ananth Ranganathan. A practical system for road marking detection and recognition. In *IEEE IV*, 2012.

[Xu *et al.*, 2020] Hang Xu, Shaoju Wang, Xinyue Cai, Wei Zhang, Xiaodan Liang, and Zhenguo Li. Curvelane-nas: Unifying lane-sensitive architecture search and adaptive point blending. In *ECCV*, 2020.

[Yoo *et al.*, 2020] Seungwoo Yoo, Hee Seok Lee, Heesoo Myeong, Sungrack Yun, Hyoungwoo Park, Janghoon Cho, and Duck Hoon Kim. End-to-end lane marker detection via row-wise classification. In *CVPR Workshops*, 2020.

[Yu *et al.*, 2020] Fisher Yu, Haofeng Chen, Xin Wang, Wenqi Xian, Yingying Chen, Fangchen Liu, Vashisht Madhavan, and Trevor Darrell. Bdd100k: A diverse driving dataset for heterogeneous multitask learning. In *CVPR*, 2020.

Twins: Revisiting the Design of Spatial Attention in Vision Transformers

Xiangxiang Chu[1], **Zhi Tian**[2], **Yuqing Wang**[1], **Bo Zhang**[1],
Haibing Ren[1], **Xiaolin Wei**[1], **Huaxia Xia**[1], **Chunhua Shen**[2]*

[1] Meituan Inc. [2] The University of Adelaide, Australia

[1] {chuxiangxiang,wangyuqing06,zhangbo97,renhaibing,weixiaolin02,xiahuaxia}@meituan.com
[2] zhi.tian@outlook.com, chunhua@me.com

Abstract

Very recently, a variety of vision transformer architectures for dense prediction tasks have been proposed and they show that the design of spatial attention is critical to their success in these tasks. In this work, we revisit the design of the spatial attention and demonstrate that a carefully devised yet simple spatial attention mechanism performs favorably against the state-of-the-art schemes. As a result, we propose two vision transformer architectures, namely, Twins-PCPVT and Twins-SVT. Our proposed architectures are highly efficient and easy to implement, only involving matrix multiplications that are highly optimized in modern deep learning frameworks. More importantly, the proposed architectures achieve excellent performance on a wide range of visual tasks including image-level classification as well as dense detection and segmentation. The simplicity and strong performance suggest that our proposed architectures may serve as stronger backbones for many vision tasks. Our Code is available at: https://git.io/Twins.

1 Introduction

Recently, Vision Transformers [1–3] have received increasing research interest. Compared to the widely-used convolutional neural networks (CNNs) in visual perception, Vision Transformers enjoy great flexibility in modeling long-range dependencies in vision tasks, introduce less inductive bias, and can naturally process multi-modality input data including images, videos, texts, speech signals, and point clouds. Thus, they have been considered to be a strong alternative to CNNs. It is expected that vision transformers are likely to replace CNNs and serve as the most basic component in the next-generation visual perception systems.

One of the prominent problems when applying transformers to vision tasks is the heavy computational complexity incurred by the spatial self-attention operation in transformers, which grows quadratically in the number of pixels of the input image. A workaround is the *locally-grouped self-attention* (or self-attention in non-overlapped windows as in the recent Swin Transformer [4]), where the input is spatially grouped into non-overlapped windows and the standard self-attention is computed only within each sub-window. Although it can significantly reduce the complexity, it lacks the connections between different windows and thus results in a limited receptive field. As pointed out by many previous works [5–7], a sufficiently large receptive field is crucial to the performance, particularly for dense prediction tasks such as image segmentation and object detection. Swin [4] proposes a shifted window operation to tackle the issue, where the boundaries of these local windows are gradually moved as the network proceeds. Despite being effective, the shifted windows may have uneven sizes. The uneven windows result in difficulties when the models are deployed with ONNX or TensorRT,

*Corresponding author.

35th Conference on Neural Information Processing Systems (NeurIPS 2021), Sydney, Australia.

which prefers the windows of equal sizes. Another solution is proposed in PVT [8]. Unlike the standard self-attention operation, where each query computes the attention weights with all the input tokens, in PVT, each query only computes the attention with a sub-sampled version of the input tokens. Although its computational complexity in theory is still quadratic, it is already manageable in practice.

From a unified perspective, the core in the aforementioned vision transformers is how the spatial attention is designed. Thus, in this work, we revisit the design of the spatial attention in vision transformers. Our first finding is that the global sub-sampled attention in PVT is highly effective, and with the applicable positional encodings [9], its performance can be on par or even better than state-of-the-art vision transformers (*e.g.*, Swin). This results in our first proposed architecture, termed *Twins-PCPVT*. On top of that, we further propose a *carefully-designed yet simple spatial attention* mechanism, making our architectures more efficient than PVT. Our attention mechanism is inspired by the widely-used separable depthwise convolutions and thus we name it *spatially separable self-attention* (SSSA). Our proposed SSSA is composed of two types of attention operations—(i) *locally-grouped self-attention* (LSA), and (ii) *global sub-sampled attention* (GSA), where LSA captures the fine-grained and short-distance information and GSA deals with the long-distance and global information. This leads to the second proposed vision transformer architecture, termed *Twins-SVT*. It is worth noting that both attention operations in the architecture are *efficient and easy-to-implement* with matrix multiplications in a few lines of code. Thus, all of our architectures here have great applicability and can be easily deployed.

We benchmark our proposed architectures on a number of visual tasks, ranging from image-level classification to pixel-level semantic/instance segmentation and object detection. Extensive experiments show that both of our proposed architectures perform favorably against other state-of-the-art vision transformers with similar or even reduced computational complexity.

2 Related Work

Convolutional neural networks. Characterized by local connectivity, weight sharing, shift-invariance and pooling, CNNs have been the *de facto* standard model for computer vision tasks. The top-performing models [10–13] in image classification also serve as the strong backbones for downstream detection and segmentation tasks.

Vision Transformers. Transformer was firstly proposed by [14] for machine translation tasks, and since then they have become the state-of-the-art models for NLP tasks, overtaking the sequence-to-sequence approach built on LSTM. Its core component is multi-head self-attention which models the relationship between input tokens and shows great flexibility.

In 2020, Transformer was introduced to computer vision for image and video processing [1–3, 9, 15–17, 17–32]. In the image classification task, ViT [1] and DeiT [2] divide the images into patch embedding sequences and feed them into the standard transformers. Although vision transformers have been proved compelling in image classification compared with CNNs, a challenge remains when it is applied to dense prediction tasks such as object detection and segmentation. These tasks often require feature pyramids for better processing objects of different scales, and take as inputs the high-resolution images, which significantly increase the computational complexity of the self-attention operations.

Recently, Pyramid Vision Transformer (PVT) [8] is proposed and can output the feature pyramid [33] as in CNNs. PVT has demonstrated good performance in a number of dense prediction tasks. The recent Swin Transformer [4] introduces non-overlapping window partitions and restricts self-attention within each local window, resulting in linear computational complexity in the number of input tokens. To interchange information among different local areas, its window partitions are particularly designed to shift between two adjacent self-attention layers. The semantic segmentation framework OCNet [34] shares some similarities with us and they also interleave the local and global attention. Here, we demonstrate this is a general design paradigm in vision transformer backbones rather than merely an incremental module in semantic segmentation.

Grouped and Separable Convolutions. Grouped convolutions are originally proposed in AlexNet [35] for distributed computing. They were proved both efficient and effective in speeding up the networks. As an extreme case, depthwise convolutions [12, 36] use the number of groups that is

equal to the input or output channels, which is followed by point-wise convolutions to aggregate the information across different channels. Here, the proposed spatially separable self-attention shares some similarities with them.

Positional Encodings. Most vision transformers use absolute/relative positional encodings, depending on downstream tasks, which are based on sinusoidal functions [14] or learnable [1, 2]. In CPVT [9], the authors propose the conditional positional encodings, which are dynamically conditioned on the inputs and show better performance than the absolute and relative ones.

3 Our Method: Twins

We present two simple yet powerful spatial designs for vision transformers. The first method is built upon PVT [8] and CPVT [9], which only uses the global attention. The architecture is thus termed Twins-PCPVT. The second one, termed Twins-SVT, is based on the proposed SSSA which interleaves local and global attention.

3.1 Twins-PCPVT

PVT [8] introduces the pyramid multi-stage design to better tackle dense prediction tasks such as object detection and semantic segmentation. It inherits the absolute positional encoding designed in ViT [1] and DeiT [2]. All layers utilize the global attention mechanism and rely on spatial reduction to cut down the computation cost of processing the whole sequence. It is surprising to see that the recently-proposed Swin transformer [4], which is based on shifted local windows, can perform considerably better than PVT, even on dense prediction tasks where a sufficiently large receptive field is even more crucial to good performance.

In this work, we surprisingly found that the less favored performance of PVT is mainly due to the *absolute positional encodings* employed in PVT [8]. As shown in CPVT [9], the absolute positional encoding encounter difficulties in processing the inputs with varying sizes (which are common in dense prediction tasks). Moreover, this positional encoding also breaks the *translation invariance*. On the contrary, Swin transformer makes use of the relative positional encodings, which bypasses the above issues. Here, we demonstrate that this is the main cause why Swin outperforms PVT, and we show that if the appropriate positional encodings are used, PVT can actually achieve on par or even better performance than the Swin transformer.

Here, we use the conditional position encoding (CPE) proposed in CPVT [9] to replace the absolute PE in PVT. CPE is conditioned on the inputs and can naturally avoid the above issues of the absolute encodings. The position encoding generator (PEG) [9], which generates the CPE, is placed after the first encoder block of each stage. We use the simplest form of PEG, *i.e.*, a 2D depth-wise convolution without batch normalization. For image-level classification, following CPVT, we remove the class token and use global average pooling (GAP) at the end of the stage [9]. For other vision tasks, we follow the design of PVT. Twins-PCPVT inherits the advantages of both PVT and CPVT, which makes it easy to be implemented efficiently. Our extensive experimental results show that this simple design can match the performance of the recent state-of-the-art Swin transformer. We have also attempted to replace the relative PE with CPE in Swin, which however does not result in noticeable performance gains, as shown in our experiments. We conjecture that this maybe due to the use of shifted windows in Swin, which might not work well with CPE.

Architecture settings We report the detailed settings of Twins-PCPVT in Table 9 (in supplementary), which are similar to PVT [8]. Therefore, Twins-PCPVT has similar FLOPs and number of parameters to [8].

3.2 Twins-SVT

Vision transformers suffer severely from the heavy computational complexity in dense prediction tasks due to high-resolution inputs. Given an input of $H \times W$ resolution, the complexity of self-attention with dimension d is $\mathcal{O}(H^2W^2d)$. Here, we propose the spatially separable self-attention (SSSA) to alleviate this challenge. SSSA is composed of locally-grouped self-attention (LSA) and global sub-sampled attention (GSA).

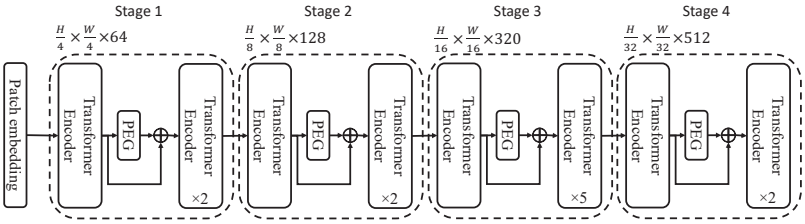

Figure 1 – Architecture of Twins-PCPVT-S. "PEG" is the positional encoding generator from CPVT [9].

Locally-grouped self-attention (LSA). Motivated by the group design in depthwise convolutions for efficient inference, we first equally divide the 2D feature maps into sub-windows, making self-attention communications only happen within each sub-window. This design also resonates with the multi-head design in self-attention, where the communications only occur within the channels of the same head. To be specific, the feature maps are divided into $m \times n$ sub-windows. Without loss of generality, we assume $H \% m = 0$ and $W \% n = 0$. Each group contains $\frac{HW}{mn}$ elements, and thus the computation cost of the self-attention in this window is $\mathcal{O}(\frac{H^2W^2}{m^2n^2}d)$, and the total cost is $\mathcal{O}(\frac{H^2W^2}{mn}d)$. If we let $k_1 = \frac{H}{m}$ and $k_2 = \frac{W}{n}$, the cost can be computed as $\mathcal{O}(k_1 k_2 HWd)$, which is significantly more efficient when $k_1 \ll H$ and $k_2 \ll W$ and grows linearly with HW if k_1 and k_2 are fixed.

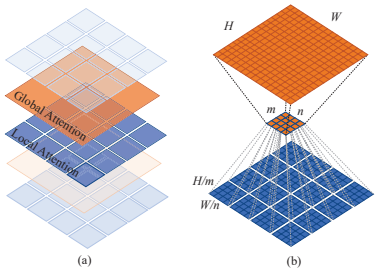

Figure 2 – **(a)** Twins-SVT interleaves locally-grouped attention (LSA) and global sub-sampled attention (GSA). **(b)** Schematic view of the locally-grouped attention (LSA) and global sub-sampled attention (GSA).

Although the locally-grouped self-attention mechanism is computation friendly, the image is divided into non-overlapping sub-windows. Thus, we need a mechanism to communicate between different sub-windows, as in Swin. Otherwise, the information would be limited to be processed locally, which makes the receptive field small and significantly degrades the performance as shown in our experiments. This resembles the fact that we cannot replace all standard convolutions by depth-wise convolutions in CNNs.

Global sub-sampled attention (GSA). A simple solution is to add extra standard global self-attention layers after each local attention block, which can enable cross-group information exchange. However, this approach would come with the computation complexity of $\mathcal{O}(H^2W^2d)$.

Here, we use a single representative to summarize the important information for each of $m \times n$ sub-windows and the representative is used to communicate with other sub-windows (serving as the key in self-attention), which can dramatically reduce the cost to $\mathcal{O}(mnHWd) = \mathcal{O}(\frac{H^2W^2d}{k_1k_2})$. This is essentially equivalent to using the sub-sampled feature maps as the key in attention operations, and thus we term it global sub-sampled attention (GSA). If we alternatively use the aforementioned LSA and GSA like separable convolutions (depth-wise + point-wise). The total computation cost is $\mathcal{O}(\frac{H^2W^2d}{k_1k_2} + k_1k_2HWd)$. We have $\frac{H^2W^2d}{k_1k_2} + k_1k_2HWd \geq 2HWd\sqrt{HW}$. The minimum is obtained when $k_1 \cdot k_2 = \sqrt{HW}$. We note that $H = W = 224$ is popular in classification. Without loss of generality, we use square sub-windows, *i.e.*, $k_1 = k_2$. Therefore, $k_1 = k_2 = 15$ is close to the global minimum for $H = W = 224$. However, our network is designed to include several stages with variable resolutions. Stage 1 has feature maps of 56×56, the minimum is obtained when $k_1 = k_2 = \sqrt{56} \approx 7$. Theoretically, we can calibrate optimal k_1 and k_2 for each of the stages. For simplicity, we use $k_1 = k_2 = 7$ everywhere. As for stages with lower resolutions, we control the summarizing window-size of GSA to avoid too small amount of generated keys. Specifically, we use the size of 4, 2 and 1 for the last three stages respectively.

As for the sub-sampling function, we investigate several options including average pooling, depth-wise strided convolutions, and regular strided convolutions. Empirical results show that regular strided convolutions perform best here. Formally, our spatially separable self-attention (SSSA) can be written as

$$\begin{aligned}
\hat{\mathbf{z}}_{ij}^{l} &= \text{LSA}\left(\text{LayerNorm}\left(\mathbf{z}_{ij}^{l-1}\right)\right) + \mathbf{z}_{ij}^{l-1}, \\
\mathbf{z}_{ij}^{l} &= \text{FFN}\left(\text{LayerNorm}\left(\hat{\mathbf{z}}_{ij}^{l}\right)\right) + \hat{\mathbf{z}}_{ij}^{l}, \\
\hat{\mathbf{z}}^{l+1} &= \text{GSA}\left(\text{LayerNorm}\left(\mathbf{z}^{l}\right)\right) + \mathbf{z}^{l}, \\
\mathbf{z}^{l+1} &= \text{FFN}\left(\text{LayerNorm}\left(\hat{\mathbf{z}}^{l+1}\right)\right) + \hat{\mathbf{z}}^{l+1}, \\
i &\in \{1, 2, ..., m\}, j \in \{1, 2, ..., n\}
\end{aligned} \tag{1}$$

where LSA means locally-grouped self-attention within a sub-window; GSA is the global sub-sampled attention by interacting with the representative keys (generated by the sub-sampling functions) from each sub-window $\hat{\mathbf{z}}_{ij} \in \mathcal{R}^{k_1 \times k_2 \times C}$. Both LSA and GSA have multiple heads as in the standard self-attention.The PyTorch code of LSA is given in Algorithm 1 (in supplementary).

Again, we use the PEG of CPVT [9] to encode position information and process variable-length inputs on the fly. It is inserted after the first block in each stage.

Model variants. The detailed configure of Twins-SVT is shown in Table 10 (in supplementary). We try our best to use the similar settings as in Swin [4] to make sure that the good performance is due to the new design paradigm.

Comparison with PVT. PVT entirely utilizes global attentions as DeiT does while our method makes use of spatial separable-like design with LSA and GSA, which is more efficient.

Comparison with Swin. Swin utilizes the alternation of local window based attention where the window partitions in successive layers are shifted. This is used to introduce communication among different patches and to increase the receptive field. However, this procedure is relatively complicated and may not be optimized for speed on devices such as mobile devices. Swin Transformer depends on torch.roll() to perform cyclic shift and its reverse on features. This operation is memory unfriendly and rarely supported by popular inference frameworks such as NVIDIA TensorRT, Google Tensorflow-Lite, and Snapdragon Neural Processing Engine SDK (SNPE), etc. This hinders the deployment of Swin either on the server-side or on end devices in a production environment. In contrast, Twins models don't require such an operation and only involve matrix multiplications that are already optimized well in modern deep learning frameworks. Therefore, it can further benefit from the optimization in a production environment. For example, we converted Twins-SVT-S from PyTorch to TensorRT , and its throughput is boosted by 1.7×. Moreover, our local-global design can better exploit the global context, which is known to play an important role in many vision tasks.

Finally, one may note that the network configures (*e.g.*, such as depths, hidden dimensions, number of heads, and the expansion ratio of MLP) of our two variants are sightly different. This is intended because we want to make fair comparisons to the two recent well-known transformers PVT and Swin. PVT prefers a slimmer and deeper design while Swin is wider and shallower. This difference makes PVT have slower training than Swin. Twins-PCPVT is designed to compare with PVT and shows that a proper positional encoding design can greatly boost the performance and make it on par with recent state-of-the-art models like Swin. On the other hand, Twins-SVT demonstrates the potential of a new paradigm as to spatially separable self-attention is highly competitive to recent transformers.

4 Experiments

4.1 Classification on ImageNet-1K

We first present the ImageNet classification results with our proposed models. We carefully control the experiment settings to make fair comparisons against recent works [2, 8, 9]. All our models are trained for 300 epochs with a batch size of 1024 using the AdamW optimizer [37]. The learning rate is initialized to be 0.001 and decayed to zero within 300 epochs following the cosine strategy. We use a linear warm-up in the first five epochs and the same regularization setting as in [2]. Note that we do not utilize extra tricks in [26, 28] to make fair comparisons although it may further improve the

performance of our method. We use increasing stochastic depth [38] augmentation of 0.2, 0.3, 0.5 for small, base and large model respectively. Following Swin [4], we use gradient clipping with a max norm of 5.0 to stabilize the training process, which is especially important for the training of large models.

We report the classification results on ImageNet-1K [39] in Table 1. Twins-PCPVT-S outperforms PVT-small by 1.4% and obtains similar result as Swin-T with 18% fewer FLOPs. Twins-SVT-S is better than Swin-T with about 35% fewer FLOPs. Other models demonstrate similar advantages.

It is interesting to see that, without bells and whistles, Twins-PCPVT performs *on par* with the recent state-of-the-art Swin, which is based on much more sophisticated designs as mentioned above. Moreover, Twins-SVT also achieves similar or better results, compared to Swin, indicating that the spatial separable-like design is an effective and promising paradigm.

One may challenge our improvements are due to the use of the better positional encoding PEG. Thus, we also replace the relative PE in Swin-T with PEG [9], but the Swin-T's performance cannot be improved (being 81.2%).

4.2 Semantic Segmentation on ADE20K

We further evaluate the performance on segmentation tasks. We test on the ADE20K dataset [42], a challenging scene parsing task for semantic segmentation, which is popularly evaluated by recent Transformer-based methods. This dataset contains 20K images for training and 2K images for validation. Following the common practices, we use the training set to train our models and report the mIoU on the validation set. All models are pretrained on the ImageNet-1k dataset.

Twins-PCPVT vs. PVT. We compare our Twins-PCPVT with PVT [8] because they have similar design and computational complexity. To make fair comparisons, we use the Semantic FPN framework [43] and exactly the same training settings as in PVT. Specifically, we train 80K steps with a batch size of 16 using AdamW [37]. The learning rate is initialized as 1×10^{-4} and scheduled by the 'poly' strategy with the power coefficient of 0.9. We apply the drop-path regularization of 0.2 for the backbone and weight decay 0.0005 for the whole network. Note that we use a stronger drop-path regularization of 0.4 for the large model to avoid over-fitting. For Swin, we use their official code and trained models. We report the results in Table 2. With comparable FLOPs, Twins-PCPVT-S outperforms PVT-Small with a large margin (+4.5% mIoU), which also surpasses ResNet-50 by 7.6% mIoU. It also outperforms Swin-T with a clear margin. Besides, Twins-PCPVT-B also achieves 3.3% higher mIoU than PVT-Medium, and Twins-PCPVT-L surpasses PVT-Large with 4.3% higher mIoU.

Twins-SVT vs. Swin. We also compare our Twins-SVT with the recent state-of-the-art model Swin [4]. With the Semantic FPN framework and the above settings, Twins-SVT-S achieves better performance (+1.7%) than Swin-T. Twins-SVT-B obtains comparable performance with Swin-S and Twins-SVT-L outperforms Swin-B by 0.7% mIoU (left columns in Table 2). In addition, Swin evaluates its performance using the UperNet framework [44]. We transfer our method to this framework and use exactly the same training settings as [4]. To be specific, we use the AdamW optimizer to train all models for 160k iterations with a global batch size of 16. The initial learning rate is 6×10^{-5} and linearly decayed to zero. We also utilize warm-up during the first 1500 iterations. Moreover, we apply the drop-path regularization of 0.2 for the backbone and weight decay 0.01 for the whole network. We report the mIoU of both single scale and multi-scale testing (we use scales from 0.5 to 1.75 with step 0.25) in the right columns of Table 2. Both with multi-scale testing, Twins-SVT-S outperforms Swin-T by 1.3% mIoU. Moreover, Twins-SVT-L achieves new state of the art result 50.2% mIoU under comparable FLOPs and outperforms Swin-B by 0.5% mIoU. Twins-PCPVT also achieves comparable performance to Swin [4].

4.3 Object Detection and Segmentation on COCO

We evaluate the performance of our method using two representative frameworks: RetinaNet [46] and Mask RCNN [47]. Specifically, we use our transformer models to build the backbones of these detectors. All the models are trained under the same setting as in [8]. Since PVT and Swin report their results using different frameworks, we try to make fair comparison and build consistent settings for future methods. Specifically, we report standard $1\times$-schedule (12 epochs) detection results on the COCO 2017 dataset [48] in Tables 3 and 4. As for the evaluation based on RetinaNet, we train

Table 1 – Comparisons with state-of-the-art methods for ImageNet-1K classification. Throughput is tested on the batch size of 192 on a single V100 GPU. All models are trained and evaluated on 224×224 resolution on ImageNet-1K dataset. †: w/ CPVT's position encodings [9].

Method	Param (M)	FLOPs (G)	Throughput (Images/s)	Top-1 (%)
ConvNet				
RegNetY-4G [40]	21	4.0	1157	80.0
RegNetY-8G [40]	39	8.0	592	81.7
RegNetY-16G [40]	84	16.0	335	82.9
Transformer				
DeiT-Small/16 [2]	22.1	4.6	437	79.9
CrossViT-S [30]	26.7	5.6	-	81.0
T2T-ViT-14 [27]	22	5.2	-	81.5
TNT-S [15]	23.8	5.2	-	81.3
CoaT Mini [17]	10	6.8	-	80.8
CoaT-Lite Small [17]	20	4.0	-	81.9
PVT-Small [8]	24.5	3.8	820	79.8
CPVT-Small-GAP [9]	23	4.6	817	81.5
Twins-PCPVT-S (**ours**)	24.1	3.8	815	81.2 (+1.3)
Swin-T [4]	29	4.5	766	81.3
Swin-T + CPVT†	28	4.4	766	81.2
Twins-SVT-S (**ours**)	24	2.9	1059	81.7 (+1.8)
T2T-ViT-19 [27]	39.2	8.9	-	81.9
PVT-Medium [8]	44.2	6.7	526	81.2
Twins-PCPVT-B(ours)	43.8	6.7	525	82.7 (+0.8)
Swin-S [4]	50	8.7	444	83.0
Twins-SVT-B (**ours**)	56	8.6	469	83.2 (+1.3)
ViT-Base/16 [1]	86.6	17.6	86	77.9
DeiT-Base/16 [2]	86.6	17.6	292	81.8
T2T-ViT-24 [27]	64.1	14.1	-	82.3
CrossViT-B [30]	104.7	21.2	-	82.2
TNT-B [15]	66	14.1	-	82.8
CPVT-B [9]	88	17.6	292	82.3
PVT-Large [8]	61.4	9.8	367	81.7
Twins-PCPVT-L(**ours**)	60.9	9.8	367	83.1 (+5.2)
Swin-B [4]	88	15.4	275	83.3
Twins-SVT-L (**ours**)	99.2	15.1	288	83.7 (+5.8)
Hybrid				
BoTNet-S1-59 [29]	33.5	7.3	-	81.7
BossNet-T1 [41]	-	7.9	-	81.9
CvT-13 [31]	20	4.5	-	81.6
BoTNet-S1-110 [29]	54.7	10.9	-	82.8
CvT-21 [31]	32	7.1	-	82.5

all the models using AdamW [37] optimizer for 12 epochs with a batch size of 16. The initial learning rate is 1×10^{-4}, started with 500-iteration warmup and decayed by 10× at the 8th and 11th epoch, respectively. We use stochastic drop path regularization of 0.2 and weight decay 0.0001. The implementation is based on MMDetection [49]. For the Mask R-CNN framework, we use the initial learning rate of 2×10^{-4} as in [8]. All other hyper-parameters follow the default settings in MMDetection. As for 3× experiments, we follow the common multi-scale training in [3, 4], *i.e.*, randomly resizing the input image so that its shorter side is between 480 and 800 while keeping longer one less than 1333. Moreover, for 3× training of Mask R-CNN, we use an initial learning rate of 0.0001 and weight decay of 0.05 for the whole network as [4].

For 1× schedule object detection with RetinaNet, Twins-PCPVT-S surpasses PVT-Small with 2.6% mAP and Twins-PCPVT-B exceeds PVT-Medium by 2.4% mAP on the COCO `val2017` split. Twins-SVT-S outperforms Swin-T with 1.5% mAP while using 12% fewer FLOPs. Our method outperform the others with similar advantage in 3× experiments.

Table 2 – Performance comparisons with different backbones on ADE20K validation dataset. FLOPs are tested on 512×512 resolution. All backbones are pretrained on ImageNet-1k except SETR [45], which is pretrained on ImageNet-21k dataset.

Backbone	Semantic FPN 80k (PVT [8] setting) FLOPs (G)	Param (M)	mIoU (%)	Upernet 160k (Swin [4] setting) FLOPs (G)	Param (M)	mIoU/MS mIoU (%)
ResNet50 [10]	45	28.5	36.7	-	-	-
PVT-Small [8]	40	28.2	39.8	-	-	-
Twins-PCPVT-S (ours)	40	28.4	44.3 (+7.6)	234	54.6	46.2/47.5
Swin-T [4]	46	31.9	41.5	237	59.9	44.5/45.8
Twins-SVT-S (ours)	37	28.3	43.2 (+6.5)	228	54.4	46.2/47.1
ResNet101 [10]	66	47.5	38.8	258	86	-/44.9
PVT-Medium [8]	55	48.0	41.6	-	-	-
Twins-PCPVT-B (ours)	55	48.1	44.9 (+6.1)	250	74.3	47.1/48.4
Swin-S [4]	70	53.2	45.2	261	81.3	47.6/49.5
Twins-SVT-B (ours)	67	60.4	45.3 (+6.5)	261	88.5	47.7/48.9
ResNetXt101-64×4d [13]	-	86.4	40.2	-	-	-
PVT-Large [8]	71	65.1	42.1	-	-	-
Twins-PCPVT-L (ours)	71	65.3	46.4 (+6.2)	269	91.5	48.6/49.8
Swin-B [4]	107	91.2	46.0	299	121	48.1/49.7
Twins-SVT-L (ours)	102	103.7	46.7 (+6.5)	297	133	48.8/50.2
Backbone	PUP (SETR [45] setting)			MLA (SETR [45] setting)		
T-Large (SETR) [45]	-	310	50.1	-	308	48.6/50.3

For 1× object segmentation with the Mask R-CNN framework, Twins-PCPVT-S brings similar improvements (+2.5% mAP) over PVT-Small. Compared with PVT-Medium, Twins-PCPVT-B obtains 2.6% higher mAP, which is also on par with that of Swin. Both Twins-SVT-S and Twins-SVT-B achieve better or slightly better performance compared to the counterparts of Swin. As for large models, our results are shown in Table 8 (in supplementary) and we also achieve better performance with comparable FLOPs.

Table 3 – Object detection performance on the COCO `val2017` split using the RetinaNet framework. 1× is 12 epochs and 3× is 36 epochs. "MS": Multi-scale training. FLOPs are evaluated on 800×600 resolution.

Backbone	FLOPs (G)	Param (M)	RetinaNet 1× AP	AP_{50}	AP_{75}	AP_S	AP_M	AP_L	RetinaNet 3× + MS AP	AP_{50}	AP_{75}	AP_S	AP_M	AP_L
ResNet50 [10]	111	37.7	36.3	55.3	38.6	19.3	40.0	48.8	39.0	58.4	41.8	22.4	42.8	51.6
PVT-Small [8]	118	34.2	40.4	61.3	43.0	25.0	42.9	55.7	42.2	62.7	45.0	26.2	45.2	57.2
Twins-PCPVT-S (ours)	118	34.4	43.0(+6.7)	64.1	46.0	27.5	46.3	57.3	45.2(+6.2)	66.5	48.6	30.0	48.8	58.9
Swin-T [4]	118	38.5	41.5	62.1	44.2	25.1	44.9	55.5	43.9	64.8	47.1	28.4	47.2	57.8
Twins-SVT-S (ours)	104	34.3	43.0(+6.7)	64.2	46.3	28.0	46.4	57.5	45.6(+6.6)	67.1	48.6	29.8	49.3	60.0
ResNet101 [10]	149	56.7	38.5	57.8	41.2	21.4	42.6	51.1	40.9	60.1	44.0	23.7	45.0	53.8
ResNeXt101-32×4d [13]	151	56.4	39.9	59.6	42.7	22.3	44.2	52.5	41.4	61.0	44.3	23.9	45.5	53.7
PVT-Medium [8]	151	53.9	41.9	63.1	44.3	25.0	44.9	57.6	43.2	63.8	46.1	27.3	46.3	58.9
Twins-PCPVT-B (ours)	151	54.1	44.3(+5.8)	65.6	47.3	27.9	47.9	59.6	46.4(+5.5)	67.7	49.8	31.3	50.2	61.4
Swin-S [4]	162	59.8	44.5	65.7	47.5	27.4	48.0	59.9	46.3	67.4	49.8	31.1	50.3	60.9
Twins-SVT-B (ours)	163	67.0	45.3(+6.8)	66.7	48.1	28.5	48.9	60.6	46.9(+6.0)	68.0	50.2	31.7	50.3	61.8

4.4 Ablation Studies

Configurations of LSA and GSA blocks. We evaluate different combinations of LSA and GSA based on our small model and present the ablation results in Table 5. The models with only locally-grouped attention fail to

Table 5 – Classification performance for different combinations of LSA (L) and GSA (G) blocks based on the small model.

Function Type	Params (M)	FLOPs (G)	Top-1 (%)
(L, L, L)	8.8	2.2	76.9
(L, LLG, LLG, G)	23.5	2.8	81.5
(L, LG, LG, G)	24.1	2.8	81.7
(L, L, L, G)	22.2	2.9	80.5
PVT-small (G, G, G, G) [8]	24.5	3.8	79.8

Table 4 – Object detection and instance segmentation performance on the COCO `val2017` dataset using the Mask R-CNN framework. FLOPs are evaluated on a 800×600 image.

Backbone	FLOPs (G)	Param (M)	Mask R-CNN 1×						Mask R-CNN 3× + MS					
			AP^b	AP^b_{50}	AP^b_{75}	AP^m	AP^m_{50}	AP^m_{75}	AP^b	AP^b_{50}	AP^b_{75}	AP^m	AP^m_{50}	AP^m_{75}
ResNet50 [10]	174	44.2	38.0	58.6	41.4	34.4	55.1	36.7	41.0	61.7	44.9	37.1	58.4	40.1
PVT-Small [8]	178	44.1	40.4	62.9	43.8	37.8	60.1	40.3	43.0	65.3	46.9	39.9	62.5	42.8
Twins-PCPVT-S (ours)	178	44.3	42.9 (+4.9)	65.8	47.1	40.0 (+5.6)	62.7	42.9	46.8 (+5.8)	69.3	51.8	42.6	66.3	46.0
Swin-T [4]	177	47.8	42.2	64.6	46.2	39.1	61.6	42.0	46.0	68.2	50.2	41.6	65.1	44.8
Twins-SVT-S (ours)	164	44.0	43.4 (+5.4)	66.0	47.3	40.3 (+5.9)	63.2	43.4	46.8 (+5.8)	69.2	51.2	42.6	66.3	45.8
ResNet101 [10]	210	63.2	40.4	61.1	44.2	36.4	57.7	38.8	42.8	63.2	47.1	38.5	60.1	41.3
ResNeXt101-32×4d [13]	212	62.8	41.9	62.5	45.9	37.5	59.4	40.2	44.0	64.4	48.0	39.2	61.4	41.9
PVT-Medium [8]	211	63.9	42.0	64.4	45.6	39.0	61.6	42.1	44.2	66.0	48.2	40.5	63.1	43.5
Twins-PCPVT-B (ours)	211	64.0	44.6 (+4.2)	66.7	48.9	40.9 (+4.5)	63.8	44.2	47.9 (+5.1)	70.1	52.5	43.2	67.2	46.3
Swin-S [4]	222	69.1	44.8	66.6	48.9	40.9	63.4	44.2	47.6	69.4	52.5	42.8	66.5	46.4
Twins-SVT-B (ours)	224	76.3	45.2 (+4.8)	67.6	49.3	41.5 (+5.1)	64.5	44.8	48.0 (+5.2)	69.5	52.7	43.0	66.8	46.6

obtain good performance (76.9%)
because this setting has a limited and small receptive field. An extra global attention layer in the last stage can improve the classification performance by 3.6%. Local-Local-Global (*abbr.* LLG) also achieves good performance (81.5%), but we do not use this design in this work.

Sub-sampling functions. We further study how the different sub-sampling functions affect the performance. Specifically, we compare the regular strided convolutions, separable convolutions and average pooling based on the 'small' model and present the results in Table 6. The first option performs best and therefore we choose it as our default implementation.

Table 6 – ImageNet classification performance of different forms of sub-sampled functions for the global sub-sampled attention (GSA).

Function Type	Top-1(%)
2D Conv.	81.7
2D Separable Conv.	81.2
Average Pooling	81.2

Positional Encodings. We replace the relative positional encoding with CPVT for Swin-T and report the detection performance on COCO with RetinaNet and Mask R-CNN in Table 7. The CPVT-based Swin cannot achieve improved performance with both frameworks, which indicates that our performance improvements should be owing to the paradigm of Twins-SVT instead of the positional encodings.

Table 7 – Object detection performance on the COCO using different positional encoding strategies.

Backbone	RetinaNet					Mask RCNN				
	FLOPs(G)	Param(M)	AP	AP_{50}	AP_{75}	FLOPs(G)	Param(M)	AP	AP_{50}	AP_{75}
Swin-T [4]	245	38.5	41.5	62.1	44.2	264	47.8	42.2	64.6	46.2
Swin-T+CPVT	245	38.5	41.3	62.4	44.1	263	47.8	42.0	64.5	45.9

5 Conclusion

In this paper, we have presented two powerful vision transformer backbones for both image-level classification and a few downstream dense prediction tasks. We dub them as twin transformers: Twins-PCPVT and Twins-SVT. The former variant explores the applicability of conditional positional encodings [9] in pyramid vision transformer [8], confirming its potential for improving backbones in many vision tasks. In the latter variant we revisit current attention design to proffer a more efficient attention paradigm. We find that interleaving local and global attention can produce impressive results, yet it comes with higher throughputs. *Both transformer models set a new state of the art in image classification, objection detection and semantic/instance segmentation.*

References

[1] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *Proc. Int. Conf. Learn. Representations*, 2021.

[2] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. *arXiv preprint arXiv:2012.12877*, 2020.

[3] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In *Proc. Eur. Conf. Comp. Vis.*, pages 213–229. Springer, 2020.

[4] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. *arXiv preprint arXiv:2103.14030*, 2021.

[5] Liang-Chieh Chen, George Papandreou, Iasonas Kokkinos, Kevin Murphy, and Alan L Yuille. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs. *IEEE Trans. Pattern Anal. Mach. Intell.*, 40(4):834–848, 2017.

[6] Chao Peng, Xiangyu Zhang, Gang Yu, Guiming Luo, and Jian Sun. Large kernel matters–improve semantic segmentation by global convolutional network. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 4353–4361, 2017.

[7] Wei Liu, Andrew Rabinovich, and Alexander C Berg. Parsenet: Looking wider to see better. *arXiv preprint arXiv:1506.04579*, 2015.

[8] Wenhai Wang, Enze Xie, Xiang Li, Deng-Ping Fan, Kaitao Song, Ding Liang, Tong Lu, Ping Luo, and Ling Shao. Pyramid vision transformer: A versatile backbone for dense prediction without convolutions. *arXiv preprint arXiv:2102.12122*, 2021.

[9] Xiangxiang Chu, Zhi Tian, Bo Zhang, Xinlong Wang, Xiaolin Wei, Huaxia Xia, and Chunhua Shen. Conditional positional encodings for vision transformers. *arXiv preprint arXiv:2102.10882*, 2021.

[10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 770–778, 2016.

[11] Mingxing Tan and Quoc Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *Proc. Int. Conf. Mach. Learn.*, pages 6105–6114. PMLR, 2019.

[12] François Chollet. Xception: Deep learning with depthwise separable convolutions. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 1251–1258, 2017.

[13] Saining Xie, Ross Girshick, Piotr Dollár, Zhuowen Tu, and Kaiming He. Aggregated residual transformations for deep neural networks. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 1492–1500, 2017.

[14] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Proc. Advances in Neural Inf. Process. Syst.*, pages 6000–6010, 2017.

[15] Kai Han, An Xiao, Enhua Wu, Jianyuan Guo, Chunjing Xu, and Yunhe Wang. Transformer in transformer. *arXiv preprint arXiv:2103.00112*, 2021.

[16] Prajit Ramachandran, Niki Parmar, Ashish Vaswani, Irwan Bello, Anselm Levskaya, and Jon Shlens. Stand-alone self-attention in vision models. In *Proc. Advances in Neural Inf. Process. Syst.*, volume 32, pages 68–80, 2019.

[17] Weijian Xu, Yifan Xu, Tyler Chang, and Zhuowen Tu. Co-scale conv-attentional image transformers, 2021.

[18] Yuqing Wang, Zhaoliang Xu, Xinlong Wang, Chunhua Shen, Baoshan Cheng, Hao Shen, and Huaxia Xia. End-to-end video instance segmentation with transformers. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 2021.

[19] Hanting Chen, Yunhe Wang, Tianyu Guo, Chang Xu, Yiping Deng, Zhenhua Liu, Siwei Ma, Chunjing Xu, Chao Xu, and Wen Gao. Pre-trained image processing transformer. *arXiv preprint arXiv:2012.00364*, 2020.

[20] Fuzhi Yang, Huan Yang, Jianlong Fu, Hongtao Lu, and Baining Guo. Learning texture transformer network for image super-resolution. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 5791–5800, 2020.

[21] Yanhong Zeng, Jianlong Fu, and Hongyang Chao. Learning joint spatial-temporal transformations for video inpainting. In *Proc. Eur. Conf. Comp. Vis.*, pages 528–543. Springer, 2020.

[22] Zhigang Dai, Bolun Cai, Yugeng Lin, and Junying Chen. UP-DETR: Unsupervised pre-training for object detection with transformers. *arXiv preprint arXiv:2011.09094*, 2020.

[23] Aravind Srinivas, Tsung-Yi Lin, Niki Parmar, Jonathon Shlens, Pieter Abbeel, and Ashish Vaswani. Bottleneck transformers for visual recognition. *arXiv: Comp. Res. Repository*, 2021.

[24] Sixiao Zheng, Jiachen Lu, Hengshuang Zhao, Xiatian Zhu, Zekun Luo, Yabiao Wang, Yanwei Fu, Jianfeng Feng, Tao Xiang, Philip HS Torr, et al. Rethinking semantic segmentation from a sequence-to-sequence perspective with transformers. *arXiv preprint arXiv:2012.15840*, 2020.

[25] Niki Parmar, Ashish Vaswani, Jakob Uszkoreit, Lukasz Kaiser, Noam Shazeer, Alexander Ku, and Dustin Tran. Image transformer. In *Proc. Int. Conf. Mach. Learn.*, volume 80, pages 4055–4064, 2018.

[26] Hugo Touvron, Matthieu Cord, Alexandre Sablayrolles, Gabriel Synnaeve, and Hervé Jégou. Going deeper with image transformers. *arXiv preprint arXiv:2103.17239*, 2021.

[27] Li Yuan, Yunpeng Chen, Tao Wang, Weihao Yu, Yujun Shi, Francis Tay, Jiashi Feng, and Shuicheng Yan. Tokens-to-token ViT: Training vision transformers from scratch on imagenet. *arXiv preprint arXiv:2101.11986*, 2021.

[28] Zihang Jiang, Qibin Hou, Li Yuan, Daquan Zhou, Xiaojie Jin, Anran Wang, and Jiashi Feng. Token labeling: Training an 85.4% top-1 accuracy vision transformer with 56M parameters on ImageNet. *arXiv: Comp. Res. Repository*, 2021.

[29] Aravind Srinivas, Tsung-Yi Lin, Niki Parmar, Jonathon Shlens, Pieter Abbeel, and Ashish Vaswani. Bottleneck transformers for visual recognition. *arXiv preprint arXiv:2101.11605*, 2021.

[30] Chun-Fu Chen, Quanfu Fan, and Rameswar Panda. CrossViT: Cross-attention multi-scale vision transformer for image classification. *arXiv preprint arXiv:2103.14899*, 2021.

[31] Haiping Wu, Bin Xiao, Noel Codella, Mengchen Liu, Xiyang Dai, Lu Yuan, and Lei Zhang. CvT: Introducing convolutions to vision transformers. *arXiv: Comp. Res. Repository*, 2021.

[32] Xizhou Zhu, Weijie Su, Lewei Lu, Bin Li, Xiaogang Wang, and Jifeng Dai. Deformable detr: Deformable transformers for end-to-end object detection. In *Proc. Int. Conf. Learn. Representations*, 2021.

[33] Tsung-Yi Lin, Piotr Dollár, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 2117–2125, 2017.

[34] Yuhui Yuan, Lang Huang, Jianyuan Guo, Chao Zhang, Xilin Chen, and Jingdong Wang. OCNet: Object context network for scene parsing. *arXiv: Comp. Res. Repository*, 2021.

[35] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. ImageNet classification with deep convolutional neural networks. In *Proc. Advances in Neural Inf. Process. Syst.*, volume 25, pages 1097–1105, 2012.

[36] Laurent Sifre and Stéphane Mallat. Rigid-motion scattering for texture classification. *arXiv preprint arXiv:1403.1687*, 2014.

[37] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *Proc. Int. Conf. Learn. Representations*, 2019.

[38] Gao Huang, Yu Sun, Zhuang Liu, Daniel Sedra, and Kilian Weinberger. Deep networks with stochastic depth. In *Proc. Eur. Conf. Comp. Vis.*, pages 646–661. Springer, 2016.

[39] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, et al. Imagenet large scale visual recognition challenge. *International journal of computer vision*, 115(3):211–252, 2015.

[40] Ilija Radosavovic, Raj Prateek Kosaraju, Ross Girshick, Kaiming He, and Piotr Dollár. Designing network design spaces. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10428–10436, 2020.

[41] Changlin Li, Tao Tang, Guangrun Wang, Jiefeng Peng, Bing Wang, Xiaodan Liang, and Xiaojun Chang. Bossnas: Exploring hybrid cnn-transformers with block-wisely self-supervised neural architecture search. *arXiv preprint arXiv:2103.12424*, 2021.

[42] Bolei Zhou, Hang Zhao, Xavier Puig, Sanja Fidler, Adela Barriuso, and Antonio Torralba. Scene parsing through ADE20k dataset. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 633–641, 2017.

[43] Alexander Kirillov, Ross Girshick, Kaiming He, and Piotr Dollár. Panoptic feature pyramid networks. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 6399–6408, 2019.

[44] Tete Xiao, Yingcheng Liu, Bolei Zhou, Yuning Jiang, and Jian Sun. Unified perceptual parsing for scene understanding. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 418–434, 2018.

[45] Sixiao Zheng, Jiachen Lu, Hengshuang Zhao, Xiatian Zhu, Zekun Luo, Yabiao Wang, Yanwei Fu, Jianfeng Feng, Tao Xiang, Philip H.S. Torr, and Li Zhang. Rethinking semantic segmentation from a sequence-to-sequence perspective with transformers. In *CVPR*, 2021.

[46] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proc. IEEE Int. Conf. Comp. Vis.*, pages 2980–2988, 2017.

[47] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask R-CNN. In *Proc. IEEE Int. Conf. Comp. Vis.*, pages 2961–2969, 2017.

[48] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C Lawrence Zitnick. Microsoft coco: Common objects in context. In *Proc. Eur. Conf. Comp. Vis.*, pages 740–755, 2014.

[49] Kai Chen, Jiaqi Wang, Jiangmiao Pang, Yuhang Cao, Yu Xiong, Xiaoxiao Li, Shuyang Sun, Wansen Feng, Ziwei Liu, Jiarui Xu, Zheng Zhang, Dazhi Cheng, Chenchen Zhu, Tianheng Cheng, Qijie Zhao, Buyu Li, Xin Lu, Rui Zhu, Yue Wu, Jifeng Dai, Jingdong Wang, Jianping Shi, Wanli Ouyang, Chen Change Loy, and Dahua Lin. MMDetection: Open MMLab detection toolbox and benchmark. *arXiv preprint arXiv:1906.07155*, 2019.

A Experiment

Table 8 – Large models' object detection performance on the COCO `val2017` split using 1× schedule.

Backbone	RetinaNet 1×				Mask R-CNN 1×		
	Param(M)	AP	AP_{50}	AP_{75}	Param(M)	AP^b	AP^m
ResNeXt101-64×4d [13]	95.5	41.0	60.9	44.0	101.9	42.8	38.4
PVT-Large [8]	71.1	42.6	63.7	45.4	81.0	42.9	39.5
Twins-PCPVT-L (ours)	71.2	45.1 (+4.1)	66.4	48.4	81.2	45.4 (+2.6)	41.5
Swin-B [4]	98.4	44.7	65.9	47.8	107.2	45.5	41.3
Twins-SVT-L (ours)	110.9	45.7 (+4.7)	67.1	49.2	119.7	45.9 (+3.1)	41.6

B Algorithm

Algorithm 1 PyTorch snippet of LSA.

```
class GroupAttention(nn.Module):
    def __init__(self, dim, num_heads=8, qkv_bias=False, qk_scale=None, attn_drop=0., proj_drop=0., k1=7,
         k2=7):
        super(GroupAttention, self).__init__()
        self.dim = dim
        self.num_heads = num_heads
        head_dim = dim // num_heads
        self.scale = qk_scale or head_dim ** -0.5
        self.qkv = nn.Linear(dim, dim * 3, bias=qkv_bias)
        self.attn_drop = nn.Dropout(attn_drop)
        self.proj = nn.Linear(dim, dim)
        self.proj_drop = nn.Dropout(proj_drop)
        self.k1 = k1
        self.k2 = k2

    def forward(self, x, H, W):
        B, N, C = x.shape
        h_group, w_group = H // self.k1, W // self.k2
        total_groups = h_group * w_group
        x = x.reshape(B, h_group, self.k1, w_group, self.k2, C).transpose(2, 3)
        qkv = self.qkv(x).reshape(B, total_groups, -1, 3, self.num_heads, C // self.num_heads).permute(3, 0,
              1, 4, 2, 5)
        q, k, v = qkv[0], qkv[1], qkv[2]
        attn = (q @ k.transpose(-2, -1)) * self.scale
        attn = attn.softmax(dim=-1)
        attn = self.attn_drop(attn)
        attn = (attn @ v).transpose(2, 3).reshape(B, h_group, w_group, self.k1, self.k2, C)
        x = attn.transpose(2, 3).reshape(B, N, C)
        x = self.proj(x)
        x = self.proj_drop(x)
        return x
```

C Architecture Setting

Table 9 – Configuration details of Twins-PCPVT.

	Output Size	Layer Name	Twins-PCPVT-S	Twins-PCPVT-B	Twins-PCPVT-L
Stage 1	$\frac{H}{4} \times \frac{W}{4}$	Patch Embedding	$P_1 = 4; C_1 = 64$		
		Transformer Encoder with PEG	$\begin{bmatrix} R_1 = 8 \\ N_1 = 1 \\ E_1 = 8 \end{bmatrix} \times 3$	$\begin{bmatrix} R_1 = 8 \\ N_1 = 1 \\ E_1 = 8 \end{bmatrix} \times 3$	$\begin{bmatrix} R_1 = 8 \\ N_1 = 1 \\ E_1 = 8 \end{bmatrix} \times 3$
Stage 2	$\frac{H}{8} \times \frac{W}{8}$	Patch Embedding	$P_2 = 2; C_2 = 128$		
		Transformer Encoder with PEG	$\begin{bmatrix} R_2 = 4 \\ N_2 = 2 \\ E_2 = 8 \end{bmatrix} \times 3$	$\begin{bmatrix} R_2 = 4 \\ N_2 = 2 \\ E_2 = 8 \end{bmatrix} \times 3$	$\begin{bmatrix} R_2 = 4 \\ N_2 = 2 \\ E_2 = 8 \end{bmatrix} \times 8$
Stage 3	$\frac{H}{16} \times \frac{W}{16}$	Patch Embedding	$P_3 = 2; C_3 = 320$		
		Transformer Encoder with PEG	$\begin{bmatrix} R_3 = 2 \\ N_3 = 5 \\ E_3 = 4 \end{bmatrix} \times 6$	$\begin{bmatrix} R_3 = 2 \\ N_3 = 5 \\ E_3 = 4 \end{bmatrix} \times 18$	$\begin{bmatrix} R_3 = 2 \\ N_3 = 5 \\ E_3 = 4 \end{bmatrix} \times 27$
Stage 4	$\frac{H}{32} \times \frac{W}{32}$	Patch Embedding	$P_4 = 2; C_4 = 512$		
		Transformer Encoder with PEG	$\begin{bmatrix} R_4 = 1 \\ N_4 = 8 \\ E_4 = 4 \end{bmatrix} \times 3$	$\begin{bmatrix} R_4 = 1 \\ N_4 = 8 \\ E_4 = 4 \end{bmatrix} \times 3$	$\begin{bmatrix} R_4 = 1 \\ N_4 = 8 \\ E_4 = 4 \end{bmatrix} \times 3$

Table 10 – Configuration details of Twins-SVT.

	Output Size	Layer Name	Twins-SVT-S	Twins-SVT-B	Twins-SVT-L
Stage 1	$\frac{H}{4} \times \frac{W}{4}$	Patch Embedding	$P_1 = 4; C_1 = 64$	$P_1 = 4; C_1 = 96$	$P_1 = 4; C_1 = 128$
		Transformer Encoder w/ PEG	$\begin{bmatrix} LSA \\ GSA \end{bmatrix} \times 1$	$\begin{bmatrix} LSA \\ GSA \end{bmatrix} \times 1$	$\begin{bmatrix} LSA \\ GSA \end{bmatrix} \times 1$
Stage 2	$\frac{H}{8} \times \frac{W}{8}$	Patch Embedding	$P_2 = 2; C_2 = 128$	$P_2 = 2; C_2 = 192$	$P_2 = 2; C_2 = 256$
		Transformer Encoder w/ PEG	$\begin{bmatrix} LSA \\ GSA \end{bmatrix} \times 1$	$\begin{bmatrix} LSA \\ GSA \end{bmatrix} \times 1$	$\begin{bmatrix} LSA \\ GSA \end{bmatrix} \times 1$
Stage 3	$\frac{H}{16} \times \frac{W}{16}$	Patch Embedding	$P_3 = 2; C_3 = 256$	$P_3 = 2; C_3 = 384$	$P_3 = 2; C_3 = 512$
		Transformer Encoder w/ PEG	$\begin{bmatrix} LSA \\ GSA \end{bmatrix} \times 5$	$\begin{bmatrix} LSA \\ GSA \end{bmatrix} \times 9$	$\begin{bmatrix} LSA \\ GSA \end{bmatrix} \times 9$
Stage 4	$\frac{H}{32} \times \frac{W}{32}$	Patch Embedding	$P_4 = 2; C_4 = 512$	$P_4 = 2; C_4 = 768$	$P_4 = 2; C_4 = 1024$
		Transformer Encoder w/ PEG	$\begin{bmatrix} GSA \end{bmatrix} \times 4$	$\begin{bmatrix} GSA \end{bmatrix} \times 2$	$\begin{bmatrix} GSA \end{bmatrix} \times 2$

Partial Feature Selection and Alignment for Multi-Source Domain Adaptation

Yangye Fu[1], Ming Zhang[1,2], Xing Xu[1]*, Zuo Cao[2], Chao Ma[2], Yanli Ji[1], Kai Zuo[2], and Huimin Lu[3]
[1]Center for Future Media & School of Computer Science and Engineering
University of Electronic Science and Technology of China, China [2]MeiTuan
[3]Department of Mechanical and Control Engineering, Kyushu Institute of Technology, Japan

Abstract

Multi-Source Domain Adaptation (MSDA), which dedicates to transfer the knowledge learned from multiple source domains to an unlabeled target domain, has drawn increasing attention in the research community. By assuming that the source and target domains share consistent key feature representations and identical label space, existing studies on MSDA typically utilize the entire union set of features from both the source and target domains to obtain the feature map and align the map for each category and domain. However, the default setting of MSDA may neglect the issue of "partialness", i.e., 1) a part of the features contained in the union set of multiple source domains may not present in the target domain; 2) the label space of the target domain may not completely overlap with the multiple source domains. In this paper, we unify the above two cases to a more generalized MSDA task as Multi-Source Partial Domain Adaptation (MSPDA). We propose a novel model termed Partial Feature Selection and Alignment (PFSA) to jointly cope with both MSDA and MSPDA tasks. Specifically, we firstly employ a feature selection vector based on the correlation among the features of multiple sources and target domains. We then design three effective feature alignment losses to jointly align the selected features by preserving the domain information of the data sample clusters in the same category and the discrimination between different classes. Extensive experiments on various benchmark datasets for both MSDA and MSPDA tasks demonstrate that our proposed PFSA approach remarkably outperforms the state-of-the-art MSDA and unimodal PDA methods.

1. Introduction

Domain adaptation methods focus on reducing the domain shift [21, 30] between a single labeled source domain and an unlabeled target domain. Recently, a more practical task termed Multi-Source Domain Adaptation (MSDA), which dedicates to transfer the knowledge learned from multiple source domains to an unlabeled target domain, has drawn much attention in the research community.

With MSDA datasets [20, 22], a variety of approaches have been proposed aiming at different application scenarios, *e.g.*, text classification [8], semantic segmentation [33], person re-identification [7], and visual sentiment classification [13]. Recently, different MSDA strategies, such as adversarial learning [24, 32], and source distilling [34], have been proposed to improve the performance on target domain using labeled source domains. However, most of the existing MSDA methods conduct feature alignment on the entire common features, ignoring the fact that some of the source features may not present in the target domain, which may contribute to negative transfer especially when the target domain only shares a part of features with distinct source domains. More practically, the label space of the target domain is unknown, *i.e.*, the label shift between the source and the target domain is ubiquitous.

Although several partial domain adaptation (PDA) researches [2, 3, 4, 31] have reported promising results, very few previous works have paid attention to the situation where multiple source domains are introduced while the target domain does not share the identical label space as the source domains. Thus, we raise a more challenging but practical research topic named *Multi-Source Partial Domain Adaptation (MSPDA)*: Leveraging multiple source domains with distinct label spaces, and perform tasks on the target domain that does not share an identical label space with any specific source domain. As illustrated in Figure 1, we make a comparison between the problem settings of MSDA and MSPDA tasks. In MSDA tasks, all source domains and the target domain share an identical label space, so all circles completely overlap each other. As for MSPDA tasks, any pair of domains do not perfectly share the label space, so some domain-specific labels can be witnessed. In other words, the MSDA task can be considered as a special case of the MSPDA task.

In this paper, we propose a novel end-to-end trainable model termed Partial Feature Selection and Alignment (PFSA) to jointly tackle both MSDA and MSPDA problems. Based on the assumption that all of the target's in-

*Corresponding author.

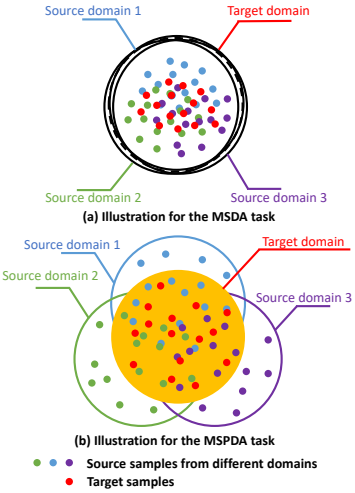

Figure 1: Illustration of the different settings for the MSDA and MSPDA tasks.

formative features are contained in the union set of multiple source domains, we introduce a selecting vector in PFSA to derive the refined feature map that can reduce the discrepancy between the source and the target features. The selected partial features are highly associated with the target domain and further improve the adaptation performance with three effective feature alignment losses, which are respectively derived from the class-level, domain-level, and discrimination aspects. We conduct extensive experiments on various benchmark datasets to exhibit its superior capability of adapting multiple domains for both MSDA and MSPDA tasks comparing to the state-of-the-art MSDA and PDA approaches.

We summarize our contributions in this paper as follows: (1) We propose a general framework termed Partial Feature Selection and Alignment (PFSA) that is capable of tackling both MSDA and MSPDA problems. (2) We utilize the similarity between the source and the target domain to derive feature selection vectors, aiming at preserving the features that are highly related to the target domain. (3) Three novel feature alignment losses are proposed to further align the selected features, aiming to improve the model's capability of generating discriminative feature representations.

2. Related Work

Multi-Source Domain Adaptation. Due to the lack of variety in single-source domain adaptation and practical demands, multi-source domain adaptation (MSDA) has been raised as a novel research area, which is tougher but more practical and valuable than single-source UDA tasks. With theoretical analysis done by [1, 9, 18], multiple trending strategies have been designed for MSDA tasks, such as adversarial and GAN-based approaches [13, 24, 32, 33]. Latent space learning and domain generation are also applied [17]. Other techniques such as source distilling [34] are proposed to select related source samples as training data. In [8], different distance-based metrics are compared and data samples are chosen dynamically during training according to the correlation between source and target domain. [20] aligns features using high-order moment distance. Class confusion is utilized as a novel metric in [11]. In our work, we dig further into the process of feature alignment and derive partial features that are related to the target domain.

Partial Domain Adaptation. Ordinary domain adaptation stands on the assumption that source and target domains share an identical label space, while practically, the label space of the target domain is unknown, but the abundant source samples can cover the entire label space of the target domain. In recent years, partial domain adaptation (PDA) approaches have been proposed [2, 3, 4, 31], concentrating on tackling situations where the target domain only contains a part of the source labels. Previous works of PDA have been focusing on different aspects, *e.g.*, [2] applies a selective weighting mechanism to multiple adversarial networks and [3] uses one adversarial network and class-level weight to judge source samples. In [31], an auxiliary domain classifier is utilized to derive the possibility that a source sample is contained in the target label space. A domain discriminator is also introduced to qualify the sample transferability and to re-weight source examples [4].

In this paper, we introduce multiple source domains to PDA, aiming at opening a novel topic named Multi-Source Partial Domain Adaptation (MSPDA) to the research community. Note that our MSPDA setting differs from the one proposed in [11], *i.e.*, we don't assume that the source domains share an identical label space.

3. Proposed Method

3.1. Problem Definition

Suppose that there are N source domains $\mathcal{D}_{S_1}$, $\mathcal{D}_{S_2}$, $\mathcal{D}_{S_3}$, $\ldots$, $\mathcal{D}_{S_N}$ with label spaces $\mathcal{Y}_{S_1}$, $\mathcal{Y}_{S_2}$, $\ldots$, $\mathcal{Y}_{S_N}$ and one target domain $\mathcal{D}_T$ without labels. $f_{\mathcal{D}}$ represents the feature map of domain $\mathcal{D}$ (extracted by common feature extractors such as ResNet) and $F_{\mathcal{D}}$ stands for the refined features through our proposed model (note that F is derived through source-target pairs). We use $\mathcal{Y}_T$ to represent the target label space. According to the illustration in Figure 1, the problem settings of the MSDA and MSPDA tasks are as follows: (1) **MSDA**. All domains share an identical label space: $\mathcal{Y}_{S_1} = \mathcal{Y}_{S_2} = \cdots = \mathcal{Y}_{S_N} = \mathcal{Y}_T$. (2) **MSPDA**. Any pair of source domains or source-target pair does not share the label space, but the union set of source domains contains the

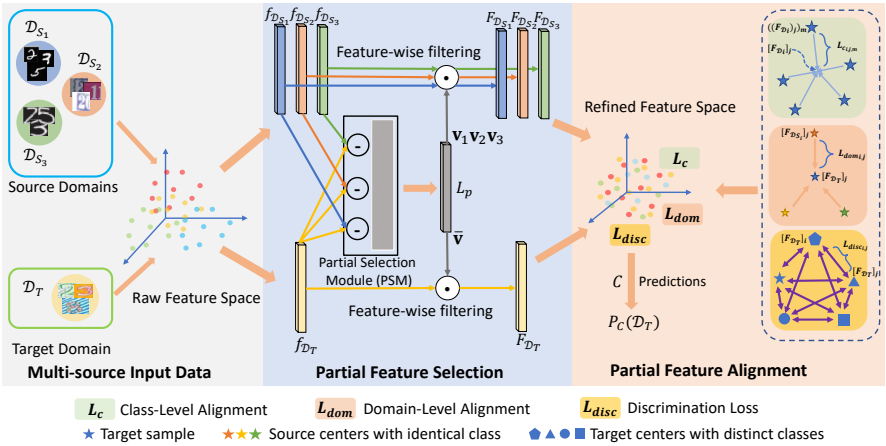

Figure 2: The general framework of the proposed PFSA method, which consists of two parts: partial feature selection and partial feature alignment. A selection vector is firstly derived to refine the extracted feature maps of multiple source domains and target domain samples. Three advanced feature alignment losses are jointly integrated to learn refined feature maps for the adaptation for target domain samples.

entire target label space: $\mathcal{Y}_{S_1} \neq \mathcal{Y}_{S_2} \neq \ldots \neq \mathcal{Y}_{S_N} \neq \mathcal{Y}_T$, $\mathcal{Y}_T \subseteq \bigcup_i^N \mathcal{Y}_{S_i}$.

Our goal is to predict the category labels of the target sample given the extracted features of the labeled samples in the multiple source domains and the unlabeled examples in the target domain.

3.2. Our PFSA Approach

As the overall framework shown in Figure 2, our proposed PFSA model has two major steps: partial feature selection and partial feature alignment. The first step derives filtering vectors for refining the feature map given the extracted features of multiple source domains and the target domain. Then in the second step, three novel feature alignment losses focusing on three different aspects in classification tasks are jointly considered to learn refined feature maps that eliminate the discrepancy of different domains.

3.2.1 Partial Feature Selection

In practice, different pairs of domains share distinct common features. If we compulsively align the features that do not exist in the target domain, the negative transfer will occur. So pair-wise selecting vectors are in demand to refine the features. We use the L_1 distance (to keep the sparsity of output) to represent the similarity between $f_{\mathcal{D}_S}$ and $f_{\mathcal{D}_T}$:

$$\Delta(\mathcal{D}_T, \mathcal{D}_{S_i}) = \left| f_{\mathcal{D}_T} - f_{\mathcal{D}_{S_i}} \right| \in \mathbb{R}^n \tag{1}$$

For convenience, we use Δ_i to represent $\Delta(\mathcal{D}_T, \mathcal{D}_{S_i})$. Ideally, a specific dimension of Δ_i denotes the similarity between $\mathcal{D}_T$ and $\mathcal{D}_{S_i}$ on the feature level, and the smaller the value is, the closer it is to the target. For instance, if the j^{th} dimension of Δ_i, namely $(\Delta_i)_j$, has the minimum value, we infer that the j^{th} dimension of the feature appears to be the most related feature among the source and the target domain. We can select r dimensions with the smallest L_1 distance as the refined features. To extract partial features, a selection vector can be applied to the original feature map (suppose that the dimension of the raw feature space is n):

$$\mathbf{v}_i = [(v_i)_1, (v_i)_2, \ldots, (v_i)_n] \in \mathbb{R}^n, \tag{2}$$

where $\mathbf{v}_i$ is the selecting vector conducted from $\mathcal{D}_T$ and $\mathcal{D}_{S_i}$, $(v_i)_j = 1$ if the j^{th} feature is selected (one of the r dimensions with the smallest values), otherwise, $(v_i)_j = 0$. However, the ability of the trivial version of the method illustrated above is limited, because practically partial features should be conducted through weighted combinations of the raw features, instead of completely sparse selections. So a partial selection module (PSM) that is built on a two-layer fully-connected neural network is utilized to automatically learn and derive the filtering vector of Δ_i, and the refined features of the source domains can be represented as follows:

$$F_{\mathcal{D}_{S_i}} = F(\mathcal{D}_T, \mathcal{D}_{S_i}) = f_{\mathcal{D}_{S_i}} \cdot \mathbf{v}_i, \tag{3}$$

where $\mathbf{v}_i = PSM(\Delta_i)$ is the output of PSM. Note that we take the L_1 distance between the source and the target do-

main as the input of PSM, which is different from previous approaches, *e.g.*, the domain attention strategy proposed by Wang *et al*. [27] uses the feature map as the input of the global pooling layer. The output of PSM (represented as $\mathbf{v}_i$ for domain $\mathcal{D}_{S_i}$) is regarded as the filtering vector instead of refined features. In the training procedure, we use the average value $\bar{\mathbf{v}} = \frac{1}{N}\sum_{i=1}^{N}\mathbf{v}_i$ to filter target domain, while no selecting vector is applied in testing procedure.

To improve the effectiveness of domain adaptation, we use the high-order moment distance proposed in [20] as the loss function of PSM:

$$MD^2(\mathcal{D}_S, \mathcal{D}_T) = \frac{1}{N}\sum_{i=1}^{N}\|\mathbb{E}(F^k_{\mathcal{D}_{S_i}}) - \mathbb{E}(F^k_{\mathcal{D}_T})\|_2 + \binom{N}{2}^{-1}\sum_{i=1}^{N-1}\sum_{j=i+1}^{N}\|\mathbb{E}(F^k_{\mathcal{D}_{S_i}}) - \mathbb{E}(F^k_{\mathcal{D}_{S_j}})\|_2, \quad (4)$$

where $F_{\mathcal{D}_T} = f_{\mathcal{D}_T} \cdot \bar{\mathbf{v}}$ represents the refined features of the target domain, and $\mathbb{E}(F^k)$ denotes the k-order moment of F. To avoid the zero or infinite trivial solutions, we apply a L_2 regularization to restrict the output of PSM to be close to 1 as:

$$R(\bar{\mathbf{v}}) = \sum_{i=1}^{n}(1 - \bar{\mathbf{v}})_i^2. \quad (5)$$

Finally, the partial selection loss can be represented as follows:

$$L_p = MD^2(\mathcal{D}_S, \mathcal{D}_T) + \lambda_{reg}R(\bar{\mathbf{v}}), \quad (6)$$

where λ_{reg} is the trade-off parameter of regularization.

3.2.2 Partial Feature Alignment

To align the features on the refined feature map, we propose three feature alignment loss functions to redistribute the samples of different domains, focusing on three distinct aspects (*i.e.*, domain-level, class-level, and discrimination) in the classification task.

Suppose that n_b represents the batch size, and n_c is the number of samples that belong to class c in a batch. To construct alignment losses, we define the center of class as $[F_{\mathcal{D}_{S_i}}]_c = \frac{1}{n_c}\sum_{j=1}^{n_c}(F_{\mathcal{D}_{S_i}})_j$ (only the refined features of samples that belongs to class c is used in calculating $[F_{\mathcal{D}_{S_i}}]_c$). We use symbol $[F_{\mathcal{D}}]_c$ to denote the center of class c in domain $\mathcal{D}$. Note that the centers are maintained for each category in each domain. For example, if there are 4 categories and 3 domains, 4×3 centers of class will be calculated. For the target domain, we generate pseudo labels to indicate target samples' categories. In order to preserve the information learned from previous batches, the centers are updated through exponential moving average [28]:

$$[F_{\mathcal{D}}]_{c,1} = \frac{1}{n_c}\sum_{j=1}^{n_c}(F_{\mathcal{D}})_{j,1}, \quad (7)$$

$$[F_{\mathcal{D}}]_{c,b} = \beta_c[F_{\mathcal{D}}]_{c,b-1} + (1-\beta_c)\frac{1}{n_c}\sum_{j=1}^{n_c}(F_{\mathcal{D}})_{j,b}, \quad (8)$$

where b denotes the current number of batch and β_c is the trade-off hyper-parameter for formal and novel centers. The centers are maintained every batch.

Considering that the pseudo labels generated from the model are not credible initially, we use self-entropy as a metric to judge the reliability of pseudo labels. For each target sample, we conduct the prediction probabilities of each category (represented as p_i), and compute the self-entropy:

$$H(p) = -\sum_i p_i \log p_i. \quad (9)$$

Then we sort the target samples in a batch according to H and remain only $\alpha\%$ of the target samples in the batch with lower self-entropy (indicating that the model is confident with the prediction of these samples).

Class-Level Alignment Loss. Inspired by the local Relation Alignment Loss (RAL) proposed by [26], we require the samples of the same category to be mapped close to the respective center, and such constraint can be represented in the following form using moment distance:

$$L_c = \sum_{i=1}^{N}\sum_{j=1}^{C}\sum_{m=1}^{n_c}\|\mathbb{E}([F_{\mathcal{D}_{S_i}}]^k_{j,b}) - \mathbb{E}(((F_{\mathcal{D}_{S_i}})_{j,b})^k_m)\| + \sum_{j=1}^{C}\sum_{m=1}^{n_c}\|\mathbb{E}([F_{\mathcal{D}_T}]^k_{j,b}) - \mathbb{E}(((F_{\mathcal{D}_T})_{j,b})^k_m)\|, \quad (10)$$

where $[F_{\mathcal{D}_{S_i}}]_{j,b}$ and $((F_{\mathcal{D}_{S_i}})_{j,b})_m$ represent the center of class, and data sample m, of domain i, class j, at batch b, respectively. $[F_{\mathcal{D}_T}]_{j,b}$ and $((F_{\mathcal{D}_T})_{j,b})_m$ denote the target center of class, and data sample m, of class j at batch b, respectively. $\mathbb{E}(F^k)$ is the k-order moment of F, and N, C, n_c represent the number of source domains, the number of total categories, and the number of samples that belong to class j, respectively. As a consequence, this loss function creates a restriction on data samples that images of the identical category should be aligned correctly to the respective center by the feature extractor.

Domain-Level Alignment Loss. In addition to class-level alignment, it is also expected that the source domains "follow" the route of the target domain, which alleviates the negative influence caused by the misalignment between each pair of the source domain and the target domain. Instead of aligning the entire data samples of the source domains and the target domain, we calculate the L_2 distance between the source centers and the target centers as the

domain-level alignment loss:

$$L_{dom} = \sum_{i=1}^{N}\sum_{j=1}^{C}([F_{\mathcal{D}_T}]_{j,b} - [F_{\mathcal{D}_{S_i}}]_{j,b})^2, \quad (11)$$

where $[F_{\mathcal{D}_T}]_{j,b}$ represents the center of class j at batch b in target domain $\mathcal{D}_T$, and $[F_{\mathcal{D}_{S_i}}]_{j,b}$ stands for the center of class j at batch b in source domain $\mathcal{D}_{S_i}$.

Discrimination Loss. Leveraging the centers of the target domain, we construct a metric that describes the degree of dispersion. First, a Euclidean distance is calculated between each pair of the centers for the target domain. Considering that the centers of different categories are required to isolate from each other, we set a hyper-parameter B to control the sparsity of class centroids, *i.e.*, keep the distance between different centers close to B. The discrimination loss can be written as follows:

$$L_{disc} = \sum_{i=1}^{C-1}\sum_{j=i+1}^{C}(B - \|[F_{\mathcal{D}_T}]_{i,b} - [F_{\mathcal{D}_T}]_{j,b}\|_2)^2, \quad (12)$$

where C denotes the total number of categories, $[F_{\mathcal{D}_T}]_{i,b}$ and $[F_{\mathcal{D}_T}]_{j,b}$ are the i^{th} and the j^{th} category's center of the target domain at batch b, respectively. From Eq. 12, the classification error rate can be reduced by isolating target domain samples with different pseudo labels.

3.3. Optimization

For the training procedure, we introduce an auxiliary classifier C_2 to strengthen the robustness of feature extraction and classification by utilizing the adversarial training strategy proposed in [23], *i.e.*, training two classifiers by maximizing the discrepancy of the predictions with a fixed feature extractor, and then updating the parameters of the feature extractor when keeping the two classifiers fixed.

Specifically, the entire PFSA framework introduces three major components, G (general feature extractor), C (C_1 and C_2, the main and the auxiliary classifiers, respectively), and PSM (inferring selecting vector). We first forward the network as illustrated above and calculate the proposed losses $L_p, L_c, L_{dom}, L_{disc}$, note that only the main classifier C_1 is used for gaining pseudo labels of the target domain. The network (G, C and PSM) is updated with the following objective function:

$$\min L_s + \lambda_p L_p + \lambda_c L_c + \lambda_{dom} L_{dom} + \lambda_{disc} L_{disc}, \quad (13)$$

where L_s is the cross-entropy loss of the two classifiers, and $\lambda_p, \lambda_c, \lambda_{dom}, \lambda_{disc}$ are trade-off hyper-parameters of each loss function.

And then the discrepancy between the target predictions of C_1 and C_2, namely $P_{C_1}(\mathcal{D}_T)$ and $P_{C_2}(\mathcal{D}_T)$, is calculated through absolute distance. We expect the two classifiers to enlarge the discrepancy of the predictions and minimize the cross-entropy loss L_s, while the feature extractor reduces the discrepancy during the adversarial training. As the model converges, the discrepancy approaches 0, indicating that the feature extractor successfully derives invariant features with respect to the classifiers. The objective function can be written as follows:

$$\min_C L_s - |P_{C_1}(\mathcal{D}_T) - P_{C_2}(\mathcal{D}_T)|, \quad (14)$$

$$\min_G |P_{C_1}(\mathcal{D}_T) - P_{C_2}(\mathcal{D}_T)|. \quad (15)$$

The entire training procedure of our proposed PFSA method is summarized in Algorithm 1.

Algorithm 1 Training procedure of our proposed PFSA method.

Input: data samples $\mathcal{D}_T, \mathcal{D}_{S_1}, \mathcal{D}_{S_2}, \ldots, \mathcal{D}_{S_N}$, hyper-parameters $\lambda_{reg}, \lambda_p, \beta_c, \lambda_c, \lambda_{dom}, \lambda_{disc}, B$.
Output: Model parameters $\theta_G, \theta_{PSM}, \theta_{C_1}, \theta_{C_2}$

repeat
- Generate feature map $f_{\mathcal{D}_T} = G(\mathcal{D}_T)$, $f_{\mathcal{D}_{S_1}} = G(\mathcal{D}_{S_1})$, $f_{\mathcal{D}_{S_2}} = G(\mathcal{D}_{S_2})$, $\ldots$, $f_{\mathcal{D}_{S_N}} = G(\mathcal{D}_{S_N})$.
- Derive refined feature $F_{\mathcal{D}_T}, F_{\mathcal{D}_{S_1}}, F_{\mathcal{D}_{S_2}}, \ldots, F_{\mathcal{D}_{S_N}}$ using Eq. 3.
- Conduct predictions $P_{C_1}(\mathcal{D}_T)$, $P_{C_2}(\mathcal{D}_T)$ and calculate the cross-entropy loss L_s for C_1 and C_2.
- Predict pseudo labels for the target domain utilizing $P_{C_1}(\mathcal{D}_T)$ and select credible predictions according to Eq. 9.
- Update class centers using Eq. 8.
- Calculate L_c, L_{dom}, L_{disc}, L_p using Eq. 10, 11, 12, 6, respectively.
- Update $\theta_G, \theta_{PSM}, \theta_{C_1}, \theta_{C_2}$ with Eq. 13.
- Regenerate refined feature map $F_{\mathcal{D}_T}$, $F_{\mathcal{D}_{S_1}}$, $F_{\mathcal{D}_{S_2}}$, $\ldots$, $F_{\mathcal{D}_{S_N}}$ with Eq. 3.
- Conduct predictions $P_{C_1}(\mathcal{D}_T)$, $P_{C_2}(\mathcal{D}_T)$ and calculate the cross-entropy loss L_s for C_1 and C_2.
- Update $\theta_G, \theta_{C_1}, \theta_{C_2}$ with Eq. 15.

until Reach the maximum iterations or convergence.

4. Experiments

4.1. Experimental Setup

Datasets and Features. We perform multiple experiments on three prevailing MSDA datasets to evaluate our model: (1) **Digit-Five** is collected from five different digit classification datasets, including MNIST-M [5], MNIST [12], USPS [10], SVHN [19], and Synthetic Digits [5]. Each domain contains ten classes corresponding to digits ranging from 0 to 9. Specifically, we use the data generated by [20]. In MSPDA scenario, we choose 5 classes out of the entire 10 classes for each source domain and 7 classes for the target domain. (2) **Office-31** [22] is a conventional MSDA dataset containing 4652 images in 31 categories. Images are collected from the office environment and are presented in

Standards	Models	→ **mm**	→ **mt**	→ **up**	→ **sv**	→ **sy**	Avg
Single-Best	DAN (2015) [14]	63.8±0.7	96.3±0.5	94.2±0.9	62.5±0.7	85.4±0.8	80.4
	DANN (2016) [6]	71.3±0.6	97.6±0.8	92.3±0.9	63.5±0.8	85.4±0.8	82.0
	ADDA (2017) [25]	71.6±0.5	97.9±0.8	92.8±0.7	75.5±0.5	86.5±0.6	84.8
Source-Combine	DAN (2015) [14]	67.9±0.8	97.5±0.6	93.5±0.8	67.8±0.6	86.9±0.5	82.7
	DANN (2016) [6]	70.8±0.8	97.9±0.7	93.5±0.8	68.5±0.5	87.4±0.9	83.6
	JAN (2017) [15]	65.9±0.7	97.2±0.7	95.4±0.8	75.3±0.7	86.6±0.6	84.1
	ADDA (2017) [25]	72.3±0.7	97.9±0.6	93.1±0.8	75.0±0.8	86.7±0.6	85.0
	MCD (2018) [23]	72.5±0.7	96.2±0.8	95.3±0.7	78.9±0.8	87.5±0.7	86.1
Multi-Source	MDAN (2018) [32]	69.5±0.3	98.0±0.9	92.4±0.7	69.2±0.6	87.4±0.5	83.3
	DCTN (2018) [29]	70.5±1.2	96.2±0.8	92.8±0.3	77.6±0.4	86.8±0.8	84.8
	M^{3}SDA(2019) [20]	72.8±1.1	98.4±0.7	96.1±0.8	81.3±0.9	89.6±0.6	87.7
	MDDA (2020) [34]	78.6±0.6	98.8±0.4	93.9±0.5	79.3±0.8	89.7±0.7	88.1
	LtC-MSDA (2020) [26]	85.6±0.8	99.0±0.4	98.3±0.4	83.2±0.6	93.0±0.5	91.8
	PFSA (Ours)	**89.6**±1.2	**99.4**±0.1	**98.6**±0.1	**84.1**±1.1	**95.7**±0.3	**93.5**

Table 1: Experiment results on Digit-Five dataset. **mm**, **mt**, **up**, **sv**, and **sy** represents MNIST-M, MNIST, USPS, SVHN and Synthetic Digits, respectively. The result of maximum accuracy is marked in bold.

three domains: Amazon, Webcam, and DSLR. We choose 21 categories for each source domain and 21 categories for the target domain when performing MSPDA experiments. (3) **DomainNet** [20] is currently the largest and the most challenging dataset in MSDA. It comes with around 0.6 million images in 6 domains: clipart, infograph, painting, quickdraw, real, and sketch. Within each domain, images of 345 categories are collected.

In each experiment, we use symbol "→ **A**" to indicate that the target domain is **A**, while other domains are used as source domains. For fair comparisons, we use the MSDA settings reported in [26]. The choice of categories in MSPDA experiments follows the **MSPDA** setting discussed in Section 3.1.

Implementation Details. As for the parameter settings, we set the four trade-of hyper-parameters $\lambda_p = 0.005, \lambda_c = 0.05, \lambda_{dom} = 0.008, \lambda_{disc} = 1.5 \times 10^{-6}$. β_c is set to 0.5 and $B = 10^3$. Experiments are done under identical settings of hyper-parameters except for the learning rate. In the training procedure of Digit-Five, we set the learning rate to 0.001. As for Office-31 and DomainNet, the learning rate is set to 5×10^{-5} for the pretrained backbone while the rest of the model updates with learning rate 0.001.

Compared Methods and Evaluation Metric. To examine the effectiveness of our model, we take the following MSDA models as our *Multi-Source* baselines: MDAN [32], DCTN [29], M^{3}SDA [20], MDDA [34], and LtC-MSDA [26]. We also conduct *Single-Best* (the best performance of single-source domain adaptation among all source domains) and *Source-Combine* (all source domains are combined as a single source domain) standards to compare our model with typical single-source methods, *e.g.*, DAN [14], DANN [6], JAN [15], ADDA [25], and MCD [23].

As for MSPDA experiments, we migrate MSDA models MDAN [32], DCTN [29], M^{3}SDA [20], LtC-MSDA [26] and PDA models PADA [3], SAN [2], ETN [4] to MSPDA setting as our MSPDA baselines. Specifically, few changes are needed for MSDA models other than the label spaces among source domains and target domain are not shared anymore. While for PDA models, we combine all the source domains as one single domain to adapt to the conventional PDA settings. We do not conduct single-best criterion as MSDA settings, because a single source domain in MSPDA does not contain the entire label space of the target, which doesn't fit the conventional problem setting of PDA.

Standards	Models	→ D	→ W	→ A	Avg
Single-Best	DAN (2015) [14]	99.0	96.0	54.0	83.0
	ADDA (2017) [25]	99.4	95.3	54.6	83.1
Source-Combine	DAN (2015) [14]	98.8	96.2	54.9	83.3
	JAN (2017) [15]	99.4	95.9	54.6	83.3
	ADDA (2017) [25]	99.2	96.0	55.9	83.7
	MCD (2018) [23]	99.5	96.2	54.4	83.4
Multi-Source	MDAN (2018) [32]	99.2	95.4	55.2	83.3
	DCTN (2018) [29]	99.6	96.9	54.9	83.8
	M^{3}SDA (2019) [20]	99.4	96.2	55.4	83.7
	MDDA (2020) [34]	99.2	97.1	56.2	84.2
	LtC-MSDA (2020) [26]	99.6	97.2	56.9	84.6
	PFSA (Ours)	**99.7**	**97.4**	**57.0**	**84.7**

Table 2: Results on Office-31 dataset. A, W, and D stands for domain Amazon, Webcam, and DSLR, respectively. The best results are marked in bold.

4.2. Overall Comparison on MSDA Task

Results on Digit-Five Dataset. Experiment results on Digit-Five is reported in Table 1. According to Table 1, our model achieves an average accuracy of 93.5%, which outperforms current MSDA approaches by a large margin. Especially, a performance gain of 4% is presented in "→ **mm**" task. Notice that we also get some slight but steady performance gain on tasks where accuracies are relatively high, which indicates our model's efficiency in the circumstance where pseudo labels are approximately reliable.

Results on Office-31 Dataset. According to Table 2, the result is much lower in "→ A" task than others, mainly because domain DSLR (D) and Webcam (W) are highly similar but differ from Amazon (A), which may not meet our assumption that the union set of source domain features contains the target's features. In other words, only a part of target (Amazon) features are aligned with source domains (DSLR and Webcam), and some key features of the target domain may be ignored by the model because they do not present in source features.

Results on DomainNet Dataset. In Table 3, we report our results on DomainNet. Generally, a performance gain of

Standards	Models	→ clp	→ inf	→ pnt	→ qdr	→ rel	→ skt	Avg
Single-Best	DAN (2015) [14]	39.1±0.5	11.4±0.8	33.3±0.6	16.2±0.4	42.1±0.7	29.7±0.9	28.6
	DANN (2016) [6]	37.9±0.7	11.4±0.9	33.9±0.6	13.7±0.6	41.5±0.7	28.6±0.6	27.8
	JAN (2017) [15]	35.3±0.7	9.1±0.6	32.5±0.7	14.3±0.6	43.1±0.8	25.7±0.6	26.7
	ADDA (2017) [25]	39.5±0.8	14.5±0.7	29.1±0.8	14.9±0.5	41.9±0.8	30.7±0.7	28.4
	MCD (2018) [23]	42.6±0.3	19.6±0.8	42.6±1.0	3.8±0.6	50.5±0.4	33.8±0.9	32.2
Source-Combine	DAN (2015) [14]	45.4±0.5	12.8±0.9	36.2±0.6	15.3±0.4	48.6±0.7	34.0±0.5	32.1
	DANN (2016) [6]	45.5±0.6	13.1±0.7	37.0±0.7	13.2±0.8	48.9±0.7	31.8±0.6	32.6
	JAN (2017) [15]	40.9±0.4	11.1±0.6	35.4±0.5	12.1±0.7	45.8±0.6	32.3±0.6	29.6
	ADDA (2017) [25]	47.5±0.8	11.4±0.7	36.7±0.5	14.7±0.5	49.1±0.8	33.5±0.5	32.2
	MCD (2018) [23]	54.3±0.6	22.1±0.7	45.7±0.6	7.6±0.5	58.4±0.7	43.5±0.6	38.5
Multi-Source	MDAN (2018) [32]	52.4±0.6	21.3±0.8	46.9±0.4	8.6±0.6	54.9±0.6	46.5±0.7	38.4
	DCTN (2018) [29]	48.6±0.7	23.5±0.6	48.8±0.6	7.2±0.5	53.5±0.6	47.3±0.5	38.2
	M^3SDA (2019) [20]	58.6±0.5	26.0±0.9	52.3±0.6	6.3±0.6	62.7±0.5	49.5±0.8	42.6
	MDDA (2020) [34]	59.4±0.6	23.8±0.8	53.2±0.6	12.5±0.6	61.8±0.5	48.6±0.8	43.2
	LtC-MSDA (2020) [26]	63.1±0.5	28.7±0.7	56.1±0.5	16.3±0.5	66.1±0.6	53.8±0.6	47.4
	PFSA (Ours)	**64.5**±0.8	**29.2**±0.8	**57.6**±0.5	**17.2**±0.6	**67.2**±0.6	**55.1**±0.7	**48.5**

Table 3: Results on DomainNet. clp, inf, pnt, qdr, rel, skt reprecents clipart, infograph, painting, quickdraw, real, sketch, respectively. Results of maximum accuracy scores are marked in bold.

Standards	Models	Digit-Five						Office-31			
		→mm	→mt	→up	→sv	→sy	Avg	→D	→W	→A	Avg
MSDA	MDAN (2018) [32]	55.4	79.8	73.1	35.4	43.1	57.4	74.2	71.9	28.6	58.2
	M3SDA (2019) [20]	69.3	98.0	96.3	47.8	78.3	77.9	78.2	71.0	32.9	60.7
	LtC-MSDA (2020) [26]	60.0	97.6	97.7	43.5	83.7	76.5	83.3	76.2	31.0	63.5
PDA	PADA (2018) [3]	63.9	90.4	93.1	40.5	62.8	70.1	75.6	73.8	38.0	62.5
	SAN (2018) [2]	55.4	96.1	96.5	32.6	55.1	67.1	83.1	77.8	39.8	66.9
	ETN (2019) [4]	48.7	93.6	93.4	36.6	64.6	67.4	83.9	78.5	**41.1**	**67.8**
MSPDA	**PFSA (Ours)**	**69.5**	**98.2**	**99.0**	**68.7**	**86.9**	**84.5**	**84.2**	**79.0**	40.2	**67.8**

Table 4: Overall comparison of our PFSA approach and state-of-the-art MSDA and PDA approaches in MSPDA task.

1.1% is produced by our model. In particular, we achieve an accuracy of 64.5% and 55.1% on task "→ clp" and "→ skt", respectively, outperforming existing approaches by a large margin. According to the results, the dataset is quite challenging, especially on "→ qdr" task. We think the dataset is difficult due to the following reasons: First, DomainNet contains 345 categories of images in each domain, which is much more than any other MSDA dataset. The large number of categories makes it difficult for feature extractors to derive unique features, and it is harder for classifiers to discern certain samples. Second, significant distribution shift presents from domain to domain, especially among quickdraw and others. Such distribution shift increases the difficulty of refining informative features since misalignment can occur when pseudo labels are not credible.

4.3. Overall Comparison on MSPDA Task

The results with the experimental setting of MSPDA problem on Digit-Five and Office-31 are presented in Table 4. It can be found that our proposed method performs significantly better than all MSDA methods on both datasets. Besides, our approach outperforms the existing PDA models by a large margin on Digit-Five and reaches SOTA on Office-31. Specifically, compared with MSDA baselines, our method produces a performance gain of 6.6% on Digit-Five dataset and a performance gain of 4.3% on Office-31 dataset. In comparison with PDA approaches, a performance gain of 14.4% is presented on Digit-Five. Dramatic drops in performance can be witnessed compared with conventional MSDA or PDA settings, we think this is because other methods only take either *multi-source domain adaptation* or *partial domain adaption* into consideration, while our approach is capable of handling both scenarios.

4.4. Further Analysis

Effect of the Key Components. To further interpret the efficiency of each component of partial feature extracting strategy and alignment losses, we conduct ablation study on Digit-Five and the result is presented in Figure 3.

By reducing the loss terms used in the model, different degrees of performance drop can be witnessed according to Figure 3. Particularly, a significant performance drop is presented in situation *No FA*, i.e., all three alignment losses are removed from our model, either in MSDA or MSPDA. It demonstrates that the alignment mechanism makes a great contribution to the performance of our method. Other than the alignment losses, the PSM structure also plays a vital role, especially in MSDA scenario where"→ **mm**" task and "→ **sv**" task suffer a great loss without PSM. We state that the proposed structures contribute in different aspects to the overall task, and the combination of all loss functions reaches the best performance on all five tasks.

Parameter Sensitiveness Analysis. Furthermore, we investigate the effect of the hyper-parameters β_c in Eq. 8 and λ_p, λ_c, λ_{dom}, λ_{disc} in Eq. 13. In this experiment, we set the numerical range of β_c in the range $[0.1, 0.9]$ and increase it by step. For the hyper-parameters λ_*, we set their range in $[10^{-6}, 10^{-1}]$. We change the value of one specific parameter and fix the others in each experiment. The sensitivity analysis of the five parameters of PFSA on task "→ **mm**" is shown in Figure 4. In particular, the optimal value for β_c is 0.5. As the value gets lower, the accuracy drops, indicating that placing too much reliance on novel centers

will bring more instability, which does harm to the performance. If β_c is too high, *e.g.*, 0.9, the performance also drops, since the centers update slowly with high β_c, and the model may ignore some crucial information from novel batches in this case. Furthermore, the optimal values for $\lambda_p, \lambda_c, \lambda_{dom}, \lambda_{disc}$ are $0.005, 0.05, 0.008$, and 1.5×10^{-6}, respectively. Thus it indicates that the loss terms behind the four hyper-parameters have different contributions. When the values of the four hyper-parameters are too large ($e.g.$, lager than 0.1), some performance drops are presented due to the ignorance of the conventional cross-entropy loss for classification tasks. As the four hyper-parameters get too low (less than 10^{-6}), nevertheless, the performance generally falls as the impacts of these loss terms become trivial. In practice, we can efficiently search for suitable settings of hyper-parameters on the validation set for different application scenarios.

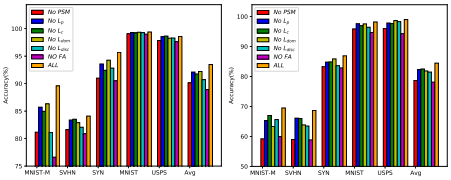

(a) Effect of different components in MSDA task. (b) Effect of different components in MSPDA task.

Figure 3: Ablation study of PFSA in MSDA and MSPDA tasks on Digit-Five dataset.

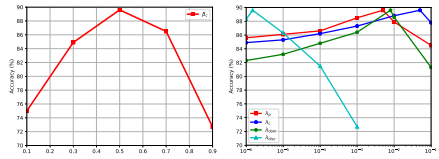

(a) β_c (b) λ_p, λ_c, λ_{disc} and λ_{dom}

Figure 4: Sensitivity analysis on the five parameters.

Visualization of Selected Features Subspace. To illustrate our method's capability of selecting the features associated with the target domain and aligning the target domain to source domains, we visualize the feature spaces of the source domains and the target domain using t-SNE [16] feature embedding when executing "→ **sv**" task. The visualization result is presented in Figure 5. As Figure 5(a) demonstrates, some outlier target samples can be witnessed, indicating that the model without PFSA can confuse with the domain and the category information. Without PFSA, the misalignment among the target and the source domains occurs, which contributes to the presence of discrete target features. In Figure 5(b), nevertheless, clear clusters are generated through our proposed PFSA approach in the universal feature space and target features are well-aligned with all source samples within the identical category. The centers of different categories are discernable after PFSA refinement and the outlier samples are filtered out, which demonstrates that partial features are correctly extracted and aligned through our PFSA strategy. Besides, the cluster centers of the target domain are also closer to those of the source domains, indicating the effectiveness of our PFSA approach in domain adaptation.

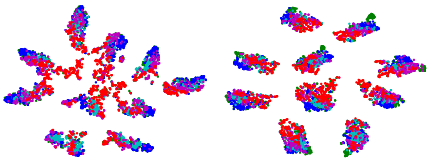

(a) Without PFSA (b) With PFSA

Figure 5: Feature space t-SNE [16] visualization of the model trained with and without PFSA in "→ **sv**" task. The target domain SVHN is marked in red and the source domains are presented in other colors.

5. Conclusion

In this paper, we proposed a novel Partial Feature Selection and Alignment (PFSA) scheme to refine and align the feature map extracted by conventional feature generators. We regarded the L_1 distance between the source and target features as the similarity among features, and selecting vectors are derived through partial selection module (PSM) for each pair of source and target domain using L_1 distance as the input. The selecting vectors are applied to the original feature map to conduct a more informative feature space. Three alignment losses are calculated on the basis of the novel feature space, concentrating on three different requirements in classification tasks. Extensive experiments on MSDA and MSPDA tasks show that our model is capable of tackling both distribution shift and label shift problems.

6. Acknowledgement

This work was supported in part by the National Natural Science Foundation of China under grants No. 61976049, 61632007, U20B2063; the Fundamental Research Funds for the Central Universities under Project ZYGX2019Z015 and the Sichuan Science and Technology Program 2018GZDZX0032, 2019ZDZX0008 and 2019YFG0003.

References

[1] John Blitzer, Koby Crammer, Alex Kulesza, Fernando Pereira, and Jennifer Wortman. Learning bounds for domain adaptation. In *Advances in Neural Information Processing Systems*, pages 129–136, 2007. 2

[2] Zhangjie Cao, Mingsheng Long, Jianmin Wang, and Michael I. Jordan. Partial transfer learning with selective adversarial networks. In *2018 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2018, Salt Lake City, UT, USA, June 18-22, 2018*, pages 2724–2732, 2018. 1, 2, 6, 7

[3] Zhangjie Cao, Lijia Ma, Mingsheng Long, and Jianmin Wang. Partial adversarial domain adaptation. In *Computer Vision - ECCV 2018 - 15th European Conference, Munich, Germany, September 8-14, 2018, Proceedings, Part VIII*, pages 139–155, 2018. 1, 2, 6, 7

[4] Zhangjie Cao, Kaichao You, Mingsheng Long, Jianmin Wang, and Qiang Yang. Learning to transfer examples for partial domain adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition, CVPR*, pages 2985–2994, 2019. 1, 2, 6, 7

[5] Yaroslav Ganin and Victor S. Lempitsky. Unsupervised domain adaptation by backpropagation. In Francis R. Bach and David M. Blei, editors, *International Conference on Machine Learning, ICML*, volume 37, pages 1180–1189, 2015. 5

[6] Yaroslav Ganin, Evgeniya Ustinova, Hana Ajakan, Pascal Germain, Hugo Larochelle, François Laviolette, Mario Marchand, and Victor S. Lempitsky. Domain-adversarial training of neural networks. *J. Mach. Learn. Res.*, 17:59:1–59:35, 2016. 6, 7

[7] Yixiao Ge, Dapeng Chen, and Hongsheng Li. Mutual mean-teaching: Pseudo label refinery for unsupervised domain adaptation on person re-identification. In *International Conference on Learning Representations, ICLR*, 2020. 1

[8] Han Guo, Ramakanth Pasunuru, and Mohit Bansal. Multi-source domain adaptation for text classification via distancenet-bandits. In *AAAI Conference on Artificial Intelligence, AAAI*, pages 7830–7838, 2020. 1, 2

[9] Judy Hoffman, Mehryar Mohri, and Ningshan Zhang. Algorithms and theory for multiple-source adaptation. In *Advances in Neural Information Processing Systems*, pages 8256–8266, 2018. 2

[10] Jonathan J. Hull. A database for handwritten text recognition research. *IEEE Trans. Pattern Anal. Mach. Intell.*, 16:550–554, 1994. 5

[11] Ying Jin, Ximei Wang, Mingsheng Long, and Jianmin Wang. Minimum class confusion for versatile domain adaptation. In *Computer Vision - ECCV 2020 - 16th European Conference, Glasgow, UK, August 23-28, 2020, Proceedings, Part XXI*, volume 12366, pages 464–480. Springer, 2020. 2

[12] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86:2278–2324, 1998. 5

[13] Chuang Lin, Sicheng Zhao, Lei Meng, and Tat-Seng Chua. Multi-source domain adaptation for visual sentiment classification. In *AAAI Conference on Artificial Intelligence, AAAI*, pages 2661–2668, 2020. 1, 2

[14] Mingsheng Long, Yue Cao, Jianmin Wang, and Michael I. Jordan. Learning transferable features with deep adaptation networks. In *International Conference on Machine Learning, ICML*, volume 37, pages 97–105, 2015. 6, 7

[15] Mingsheng Long, Han Zhu, Jianmin Wang, and Michael I. Jordan. Deep transfer learning with joint adaptation networks. In *International Conference on Machine Learning, ICML*, volume 70, pages 2208–2217, 2017. 6, 7

[16] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of machine learning research*, 9(Nov):2579–2605, 2008. 8

[17] Massimiliano Mancini, Lorenzo Porzi, Samuel Rota Bulò, Barbara Caputo, and Elisa Ricci. Boosting domain adaptation by discovering latent domains. In *IEEE Conference on Computer Vision and Pattern Recognition, CVPR*, pages 3771–3780, 2018. 2

[18] Yishay Mansour, Mehryar Mohri, and Afshin Rostamizadeh. Domain adaptation with multiple sources. In *Advances in Neural Information Processing Systems*, pages 1041–1048, 2008. 2

[19] Yuval Netzer, Tao Wang, Adam Coates, Alessandro Bissacco, Bo Wu, and Andrew Y Ng. Reading digits in natural images with unsupervised feature learning. In *Advances in Neural Information Processing Systems Workshops*, 2011. 5

[20] Xingchao Peng, Qinxun Bai, Xide Xia, Zijun Huang, Kate Saenko, and Bo Wang. Moment matching for multi-source domain adaptation. In *IEEE/CVF International Conference on Computer Vision, ICCV*, pages 1406–1415, 2019. 1, 2, 4, 5, 6, 7

[21] Joaquin Quionero-Candela, Masashi Sugiyama, Anton Schwaighofer, and Neil D Lawrence. *Dataset shift in machine learning*. The MIT Press, 2009. 1

[22] Kate Saenko, Brian Kulis, Mario Fritz, and Trevor Darrell. Adapting visual category models to new domains. In *European Conference on Computer Vision*, pages 213–226, 2010. 1, 5

[23] Kuniaki Saito, Kohei Watanabe, Yoshitaka Ushiku, and Tatsuya Harada. Maximum classifier discrepancy for unsupervised domain adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition, CVPR*, pages 3723–3732, 2018. 5, 6, 7

[24] Alice Schoenauer Sebag, Louise Heinrich, Marc Schoenauer, Michèle Sebag, Lani F. Wu, and Steven J. Altschuler. Multi-domain adversarial learning. In *International Conference on Learning Representations, ICLR*, 2019. 1, 2

[25] Eric Tzeng, Judy Hoffman, Kate Saenko, and Trevor Darrell. Adversarial discriminative domain adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition, CVPR*, pages 2962–2971, 2017. 6, 7

[26] Hang Wang, Minghao Xu, Bingbing Ni, and Wenjun Zhang. Learning to combine: Knowledge aggregation for multi-source domain adaptation. *CoRR*, abs/2007.08801, 2020. 4, 6, 7

[27] Xudong Wang, Zhaowei Cai, Dashan Gao, and Nuno Vasconcelos. Towards universal object detection by domain attention. In *IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2019, Long Beach, CA, USA, June 16-20, 2019*, pages 7289–7298, 2019. 4

[28] Shaoan Xie, Zibin Zheng, Liang Chen, and Chuan Chen. Learning semantic representations for unsupervised domain adaptation. In Jennifer G. Dy and Andreas Krause, editors, *International Conference on Machine Learning, ICML*, volume 80, pages 5419–5428, 2018. 4

[29] Ruijia Xu, Ziliang Chen, Wangmeng Zuo, Junjie Yan, and Liang Lin. Deep cocktail network: Multi-source unsupervised domain adaptation with category shift. In *IEEE Conference on Computer Vision and Pattern Recognition, CVPR*, pages 3964–3973, 2018. 6, 7

[30] Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. How transferable are features in deep neural networks? In *Advances in Neural Information Processing Systems*, pages 3320–3328, 2014. 1

[31] Jing Zhang, Zewei Ding, Wanqing Li, and Philip Ogunbona. Importance weighted adversarial nets for partial domain adaptation. In *2018 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2018, Salt Lake City, UT, USA, June 18-22, 2018*, pages 8156–8164, 2018. 1, 2

[32] Han Zhao, Shanghang Zhang, Guanhang Wu, José M. F. Moura, João Paulo Costeira, and Geoffrey J. Gordon. Adversarial multiple source domain adaptation. In *Advances in Neural Information Processing Systems*, pages 8568–8579, 2018. 1, 2, 6, 7

[33] Sicheng Zhao, Bo Li, Xiangyu Yue, Yang Gu, Pengfei Xu, Runbo Hu, Hua Chai, and Kurt Keutzer. Multi-source domain adaptation for semantic segmentation. In *Advances in Neural Information Processing Systems, NeurIPS*, pages 7285–7298, 2019. 1, 2

[34] Sicheng Zhao, Guangzhi Wang, Shanghang Zhang, Yang Gu, Yaxian Li, Zhichao Song, Pengfei Xu, Runbo Hu, Hua Chai, and Kurt Keutzer. Multi-source distilling domain adaptation. In *AAAI Conference on Artificial Intelligence, AAAI*, pages 12975–12983, 2020. 1, 2, 6, 7

A Deep Learning Method for Route and Time Prediction in Food Delivery Service

Chengliang Gao, Fan Zhang, Guanqun Wu, Qiwan Hu,
Qiang Ru, Jinghua Hao, Renqing He, Zhizhao Sun
Meituan, Beijing, China
{gaochengliang,zhangfan59,wuguanqun,huqiwan,ruqiang,haojinghua,herenqing,sunzhizhao}@meituan.com

ABSTRACT

Online food ordering and delivery service has widely served people's daily demands worldwide, e.g., it has reached a number of 34.9 million online orders per day in Q3 of 2020 in Meituan food delivery platform. For the food delivery service, accurate estimation of the driver's delivery route and time, defined as the FD-RTP task, is very significant to customer satisfaction and driver experience. In the paper, we apply deep learning to the FD-RTP task for the first time, and propose a deep network named FDNET. Different from traditional heuristic search algorithms, we predict the probability of each feasible location the driver will visit next, through mining a large amount of food delivery data. Guided by the probabilities, FDNET greatly reduces the search space in delivery route generation, and the calculation times of time prediction. As a result, various kinds of information can be fully utilized in FDNET within the limited computation time. Careful consideration of the factors having effect on the driver's behaviors and introduction of more abundant spatiotemporal information both contribute to the improvements. Offline experiments over the large-scale real-world dataset, and online A/B test demonstrate the effectiveness of our proposed FDNET.

CCS CONCEPTS

• **Information systems** → **Data mining**; • **Computing methodologies** → **Neural networks**; • **Applied computing** → *Forecasting*.

KEYWORDS

Food delivery service; Route and time prediction; Deep learning

ACM Reference Format:
Chengliang Gao, Fan Zhang, Guanqun Wu, Qiwan Hu, and Qiang Ru, Jinghua Hao, Renqing He, Zhizhao Sun. 2021. A Deep Learning Method for Route and Time Prediction in Food Delivery Service. In *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '21), August 14–18, 2021, Virtual Event, Singapore.* ACM, New York, NY, USA, 11 pages. https://doi.org/10.1145/3447548.3467068

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
KDD '21, August 14–18, 2021, Virtual Event, Singapore
© 2021 Association for Computing Machinery.
ACM ISBN 978-1-4503-8332-5/21/08…$15.00
https://doi.org/10.1145/3447548.3467068

1 INTRODUCTION

1.1 Background

With the rapid development of Internet and e-commerce, online food ordering and delivery service has widely served people's daily demands worldwide. Food ordering platforms, such as Uber Eats, GrubHub and Meituan provide millions of customers with convenient food delivery service each day. As a leading food ordering and delivery platform in China, Meituan food delivery platform [5] delivers 34.9 million online orders per day in Q3 of 2020[1].

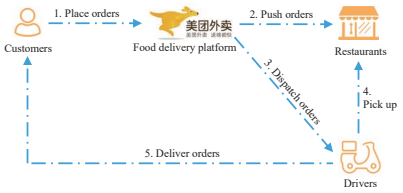

Figure 1: Food ordering and delivery procedure.

Fig. 1 shows a typical food ordering, pickup and delivery procedure. After a customer orders a meal from the online food ordering and delivery platform, the platform pushes the order to the restaurant, and dispatches the order to an appropriate driver at the same time. The driver will fetch food from the restaurant and deliver it to the customer. From the customers' point of view, they hope the meal to be delivered punctually. For the drivers, the primary goal is completing delivery tasks with the least driving cost (total driving distance etc.). As a result, predicting the driver's delivery route and time accurately is very significant to customer satisfaction and driver experience, denoted as the FD-RTP (Food Delivery Route and Time Prediction) task. Based on the information of context, driver and several orders to deliver, FD-RTP aims to predict the driver's delivery route (the sequence of pickup and delivery locations of orders), and the time on the driver arriving at each location in the route. FD-RTP is a basic system module used to guide dispatching orders to the drivers in the food delivery platform. An actual food delivery route is exampled in Fig. 2 to help understand and the problem formulation will be introduced in Sec. 3.

The FD-RTP task is quite complicated. At first, one driver needs to fetch and deliver several orders (over 10 orders at rush hour) synchronously. The solution space of feasible delivery routes is very

[1]http://media-meituan.todayir.com/20210107114424170948830 1_tc.pdf

Figure 2: An example of food delivery route. The driver delivers 3 orders together, where order #1 and #2 have been fetched already. He deliveries order #1 at 10:21 to the customer and arrives at the restaurant of order #3 at 10:27, waits the meal to be prepared and fetches at 10:30. Then he finishes the delivery of order #2 at 10:43 and order #3 at 11:03.

huge, reaching 2.376×10^{15} for 10 orders to fetch and deliver. The route prediction involves the consideration of driving distance and punctuality of each order. In addition, time prediction of the whole route involves driving time on the road, walking time while pickup and delivery, and waiting time in the restaurant. The uncertainty in time prediction is huge as well, and will increase along with the route length. Finally, as an online algorithm, the prediction procedure of FD-RTP has to be finished within milliseconds, so as to be run millions of times a day.

Previous works treat the FD-RTP task as the single vehicle PDPTW (pickup and delivery problem with time windows) problem, which focus on the improvement of search algorithms, aiming to minimize the heuristic cost related to time delay and delivery distance [15, 23]. These works are rarely devoted to improving the accuracy of time prediction, which has equally importance as the route in food delivery service. The heuristic search algorithms have to go through thousands of iterations, and need to predict time of the whole route each iteration. As a result, the time prediction is required to be so extremely fast, that it is very challenging to fully utilize the related influential factors. However, these factors are beneficial to the accuracy of time prediction a lot, such as the context information when and where the delivery occurs, the driver information reflecting the delivery habits and abilities, and other spatiotemporal information and historical experience information. Besides, as a part of the cost function, the inaccuracy of time prediction will further lead to the accuracy decrease of the searched delivery route.

1.2 Our approach: FDNET

We propose FDNET (Food Delivery Route and Time Prediction Deep Network), a deep learning method to tackle the FD-RTP task. With FDNET, we pursue a different approach: we predict the probability of each feasible location the driver will visit next, through mining a large amount of delivery data accumulated in history. Guided by probabilities, FDNET greatly reduces the search space of delivery route generation, and the calculation times of time prediction. We only generate one or several routes with highest probabilities and predict the time duration between two locations at the same time. Less calculation allows us to take more relevant factors mentioned above into consideration, and further improves the accuracy of FD-RTP task.

We design FDNET with two main modules, the RP (route prediction) module and TP (time prediction) module in the same network. The RP module is used to predict the probability of each feasible location the driver will visit next, and generate the complete delivery route. We analyze features affecting drivers' behaviors and then design a model based on RNN (Recurrent Neural Network) and Attention to depict the behavior decision process of drivers. The TP module is used to predict the travel time duration between two adjacent locations (from leaving the previous location to arriving at the next one) in the route, and generate the time on arriving at each location combined with the given earliest pickup time of each order. We treat the TP module as a variant of the ETA (Estimated Time of Arrival) problem in this paper. Inspired by the related researches on the ETA problem, we design a Wide & Deep model to predict the time duration based on the built context, driver and spatiotemporal features. The two modules are combined reasonably in FDNET. For each step, input locations of the TP module are produced by the RP module and the result of TP module will be used to update features for predicting the driver's future behaviors. Meanwhile, the personalized information of each driver is introduced into FDNET, to mine drivers' delivery habits and abilities. The offline experimental results over the large-scale real-world dataset collected from Meituan food delivery platform and online A/B test demonstrate the effectiveness of our proposed FDNET.

2 RELATED WORK

The FD-RTP task is rarely studied in the existing literatures and several previous works are all based on heuristic search algorithms mentioned in Sec. 1. In this section, we will introduce the works related to FDNET, specifically RR (Route Recommendation) problem for the RP module and ETA problem for the TP module.

2.1 Route Recommendation

The route prediction task in food delivery service is similar with the RR problem to some extent, where we get inspiration for implementation of the RP module. The RR problem aims to produce appropriate routes (sequence of route segments) given the OD (origin-destination) pair, based on the user-generated trajectory data. Early studies treat RR as a pathfinding problem on graphs and focus on developing heuristic search algorithms to reduce the search space [11, 18]. Heuristic search algorithms minimize the cost function by lots of iterations, and how to develop an effective cost function is the algorithms' key point. However, most studies set the cost function heuristically, which results in limited application. Besides, it is difficult to fully utilize various kinds of context information during the search process, which faces similar drawbacks as the FD-RTP task mentioned above. To construct more flexible approaches, many researches apply machine learning to draw more information inference. Chen et al. propose a Maximum Probability Product algorithm based on the Absorbing Markov Chain to discover the most popular route between two locations [4]. In [22], the authors adopt probabilistic models incorporating both temporal dynamics and spatial dynamics and address the data sparsity challenge for route recovery. The development of deep learning

sheds light on the RR problem using neural networks, especially the promising effectiveness of RNN for modeling sequential trajectory data. In [1], the authors propose Space Time Features-based RNN to predict people next movement by discovering the mobility patterns. Wu et al. design two RNN based models to capture variable length sequence of trajectory data and address the constraints of topological structure on trajectory modeling [21]. Compared with the RR problem, the FD-RTP task is more complicated involving the punctuality of multiple orders and the overall driving cost.

2.2 Estimated Time of Arrival

As mentioned in Sec. 1, we treat the TP module as a variant of the ETA problem. The ETA problem aims to evaluate the required travel time of bus or car between an OD pair, and there are two typical scenarios: OD-based and route-based. The OD based methods mainly extract the features of origin and destination, predicting the travel time without route information. Jindal et al. propose ST-NN (Spatio-Temporal Neural Network), predicting the travel distance between OD and further predict the travel time combined with other time information [9]. In [14], Wang et al. propose TEMP+R, which estimates the time duration as the weighted average travel times of similar historical trips. Based on availability of route segments data, the route-based methods estimate travel time for a specific route. Most of the researches focus on estimating and then aggregating travel times for route segments in the route [2, 16]. Among these works, BusTr infers bus delays combining real-time road traffic forecasts and contextual information [2]. Using a restricted feature set, BusTr can be generated to cities without training data. Besides, formulating ETA as a pure regression problem, Wang et al. propose a Wide Deep Recurrent learning model to capture global spatiotemporal and route segment information in [17]. Hong et al. further employ an Attention based GNN (Graph Neural Network) to embed road network data, and model temporal heterogeneous information, beyond the state-of-the-art methods [8]. Compared with the traditional ETA problem, the time prediction in food delivery service is more complicated, where walking time while pickup and delivery should also be considered, apart from the driving time. For implementation of the TP module, we borrow ideas from the ETA researches in respect of feature extraction and modeling.

3 PROBLEM FORMULATION

The FD-RTP task assumes a set of orders $O = \{o_1, o_2, ..., o_n\}$ to be delivered by one driver u in the context information c. Specifically, the orders can be divided into two categories. The first category of orders have already been fetched from the restaurant by the driver and only have the delivery location, denoted as $O^1 = \{o_1^1, o_2^1, ..., o_{n_1}^1\}$. The orders in the second category have both pickup location and delivery location, denoted as $O^2 = \{o_1^2, o_2^2, ..., o_{n_2}^2\}$. Then we have $O = O^1 \cup O^2$ and $n = n_1 + n_2$. Besides, each order o is attached with an earliest pickup time PT_o and a due time DT_o promised to the customer by the food delivery platform. Let l_o^p denote the pickup location of order o, and l_o^d be the corresponding delivery location. Then we have the set of all pickup locations $P = \{l_o^p | o \in O^2\}$, and all delivery locations $D = \{l_o^d | o \in O\}$. The driver's start location is denoted as l_0. Based on the information of context, driver and orders to deliver, the FD-RTP task aims to produce an accurate prediction of the driver's delivery route, which is the permutation of all the locations in $P \cup D \cup \{l_0\}$, along with the estimated time t_l for the driver arriving at each location l. In addition, the time duration spent leaving from location l_i to arriving at l_{i+1} is denoted as $TD_{i,i+1}$. Definitions of notations used in the paper can be found in Tab. 1. A feasible route has three constraints: (1) the route must start from the driver's start location l_0; (2) the pickup location of one order must be visited before its delivery location; (3) each order o can not be fetched early than PT_o, before which the order can not be prepared by the restaurant.

Table 1: The notations.

Notation	Defination
c	Current context (temporal and spatial) information
u	A driver
o	An order
PT_o	Earliest pickup time of order o
DT_o	Due time promised to the customer of order o
O	Set of orders to be delivered by one driver
O^1	Set of orders which have been fetched already
O^2	Set of orders which have not been fetched
l_0	Start location of the driver
l_o^p	Pickup location of order o
l_o^d	Delivery location of order o
P	Set of all pickup locations in one delivery route
D	Set of all delivery locations in one delivery route
t_l	The time when the driver arrives at the location l
$TD_{i,i+1}$	Time duration leaving from location l_i to arriving at l_{i+1}

4 DATASET

We extract a real-world delivery dataset from Meituan food delivery platform, containing over 430 million orders and 1.6 million drivers. Drivers' actual delivery routes can not fit the FD-RTP task exactly, as the driver can be dispatched new orders during the delivery process which will affect his following behaviors. As a result, we split the delivery route of one driver into samples according to the dispatch times, when the driver receives new dispatched orders. Taking Fig. 3 as an example, the driver is dispatched a new order o_4 after delivering order o_3, then he chooses to fetch order o_4 and continue to deliver other orders. Although the orders o_1 and o_2 are dispatched to the driver from the beginning, the delivery route and time do change due to the new dispatched order o_4. In this situation, the driver's delivery route is split into two samples. The first one takes $\{o_1, o_2, o_3\}$ (not fetched) as input, and the label contains $\{l_0, l_{o_1}^p, l_{o_2}^p, l_{o_3}^p, l_{o_3}^d\}$ and the corresponding time. The other takes $\{o_1, o_2, o_4\}$ (o_1 and o_2 are fetched) as input, and the label contains $\{l_0', l_{o_4}^p, l_{o_1}^d, l_{o_2}^d, l_{o_4}^d\}$, where l_0' is the dispatch time of o_4. It is worth mentioning that the way of data generation is just for model training and evaluation offline. When used for prediction, FDNET produces the complete delivery route including $l_{o_1}^d$ and $l_{o_2}^d$ for the first sample, supposing the driver only delivers orders $\{o_1, o_2, o_3\}$ and finishes all the delivery tasks.

During data processing, we filter outliers that the driving speed of drivers is higher than the threshold. Then we get a normal dataset containing over 135 million samples. Tab. 2 shows the information each sample carries and whether the information is used in the RP

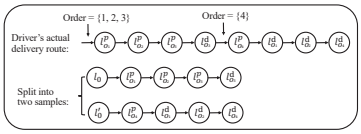

Figure 3: An example: split the driver's delivery route into samples.

Table 2: The information one sample carries.

Information	Description	RP	TP
Context info	Day of a week Period of a day (10 minutes per period) City index	Y	Y
Driver info	Start location (GPS coordinate) Several statistics (Average speed, Punctuality etc.)	Y	Y
Basic info of each order	Due time promised to the customer	Y	N
Restaurant related info of each order	Earliest pickup time Pickup location (GPS coordinate)	Y	Y
Customer related info of each order	Drop-off duration (estimated delivery walking time) Delivery location (GPS coordinate)	Y	Y
TD related info	Different granularity statistics of TDs	N	Y
Label	Actual delivery route and time	Y	Y

module or TP module. Some information is worth detailed explanation. Through the aggregation of delivery data generated by each driver in the past two weeks, we get several statistics information to depict the driver's delivery habit and ability. The statistics information contains the average driving speed, the punctuality, the average number of orders delivered per day and so on. In the final stage of each order's delivery, the driver will stop driving and walk towards the customer, and need go upstairs in most cases. The drop-off duration denotes the estimated time consumed during the final stage, which is provided by another prediction system deployed in Meituan food delivery platform. Together with the earliest pickup time and the due time, we use the drop-off duration as available information. The different granularity statistics of TDs are designed OD-based information for the TP module, and the details will be introduced in Sec. 5.3. We use a restricted information set in the RP module and TP module to enhance the model's generalization ability.

5 METHOD

We propose an approach based on deep learning, named Food Delivery Route and Time Prediction Deep Network (FDNET), to tackle the FD-RTP task. In this section, we first describe the overall model architecture. Then we introduce the strategies we adopt for route and time prediction respectively, including fine selection of features and model details. Finally, we give the training and prediction process of FDNET along with cooperation of the RP module and TP module.

5.1 Framework of FDNET

The overall architecture of FDNET is illustrated in Fig. 4, which is made up of the RP module and TP module, as mentioned in Sec. 1. The RP module predicts the probability of each feasible location the driver will visit next steply, and generates the complete

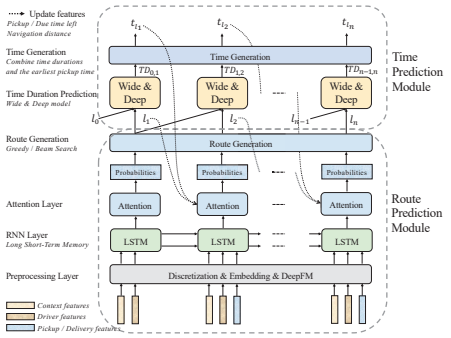

Figure 4: Overall architecture of FDNET.

delivery route through some optimization strategies, e.g., the greedy strategy or the Beam Search strategy. The TP module predicts the time duration between two adjacent locations, used to generate the time on arriving at each location combined with the earliest pickup time of each order. Considering the differences between the two tasks themselves, we design the model architecture and features for the two modules separately.

5.2 Route Prediction Module

Utilizing the information of context c, driver u and orders to deliver O, the RP module will produce a feasible route. Further refining the task, RP module predicts the probability of each feasible location the driver will visit next, based on the past behaviors and current condition. Formally, the RP module calculates

$$P(l_{i+1}|l_0, l_1, ..., l_i; X_i^r), \tag{1}$$

and generates the complete delivery route through optimization strategies, where X_i^r denotes the available information at location l_i. For implementation, we first analyze and select the features which affect the driver's decision on which location to visit next. Then, we design a model based on LSTM [7] and Attention [12], considering their effectiveness on modeling sequential trajectory data [1, 21].

5.2.1 The features. We consider the factors affecting the driver's decision on which location to visit and design the relevant features. The result of our analysis is illustrated in Fig. 5. (1) **Due time left**: for the sake of punctuality, drivers prefer to fetch/deliver the orders with less due time left intuitively, confirmed by Fig. 5(a). (2) **Navigation distance**: intuitively, the driving distance is drivers' another concern, and we calculate the navigation distance from current location. From Fig. 5(b) we observe that drivers prefer to visit closer locations. (3) **Earliest pickup time**: when having several orders to fetch together, drivers should refer to the earliest pickup time of each order provided by the food delivery platform. Fig. 5(c) also indicates that drivers fetch early prepared orders firstly to avoid long time waiting. (4) **Drop-off duration**: the drop-off duration of

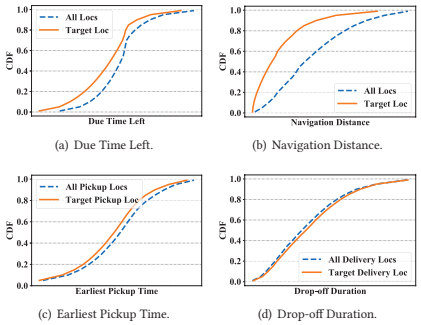

(a) Due Time Left. (b) Navigation Distance.

(c) Earliest Pickup Time. (d) Drop-off Duration.

Figure 5: Analysis of features for route prediction. Each figure calculates the CDF curves of feature values for all the candidate locations and the target location (the actual location visited next) respectively.

some order can be fairly long, even more than 15 minutes. Experienced drivers usually choose to delivery orders with long drop-off duration first to avoid timeout, which is evidenced in Fig. 5(d).

Based on the analysis above, we build meaningful features for the RP module. At first, we get the global personalized features, including the **context features** and **driver features** mentioned in Tab. 2. In addition, for step i when the driver is at location l_{i-1}, we design the **pickup features** of each order containing the due time left from $t_{l_{i-1}}$, the earliest pickup time left from $t_{l_{i-1}}$, and the navigation distance from l_{i-1} to the restaurant. Similarly, we design the **delivery features** of each order containing the due time left from $t_{l_{i-1}}$, the drop-off duration and the navigation distance from l_{i-1} to the customer.

5.2.2 The model. Model architecture of the RP module is shown in the bottom part of Fig. 4. For preprocessing, we discretize the dense features and embedding them with other discrete features out of two considerations: (1) we consider tiny change of the values of dense features would not change the driver's decision, and the discretization can enhance the model's stability; (2) we expect to encourage our model to learn more nuanced representations than using numerical values alone. Fully considering the low order and high order feature interactions, we utilize the deepFM model [6] to encode each category of features, whose calculation details can be found in Appendix A.1.1. Through feature preprocessing, we get the m-dimensional vector representation of context features as v_c, driver features as v_u, pickup features of order o as v_o^p and delivery features of order o as v_o^d. We further leverage a LSTM based RNN to process sequential data and Attention to calculate the probability of the driver visiting each feasible location next. In addition, the implementation details that how to guarantee the first two route constraints mentioned in Sec. 3 can be found in Appendix A.1.3.

The RNN layer. At step i, the LSTM cell takes the vector representation of the location l_{i-1}, the memory state and hidden state at step $i-1$ as input,

$$h_i, c_i = \text{LSTM}(v_{l_{i-1}}, h_{i-1}, c_{i-1}), \tag{2}$$

where c_{i-1} is the memory state and h_{i-1} is the hidden state and output as well. The mathematical formulations of LSTM cell can be found in Appendix A.1.2. $v_{l_{i-1}}$ denotes the vector representation of the location l_{i-1}, which is the concatenation of context features, driver features and pickup or delivery features of the corresponding order. Especially, v_{l_0} only contains context features, driver features for the driver's start location. We carry the context features and driver features each step to emphasize their significance. As the output of LSTM cell at step i, vector $h_i \in \mathbb{R}^m$ contains all the information of the sequence ahead, and we use h_i to calculate the probabilities. In addition, we adopt the dropout strategy on LSTM states between two adjacent steps to avoid overfitting [13], which is proved to be effective.

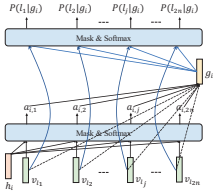

Figure 6: Attention layer.

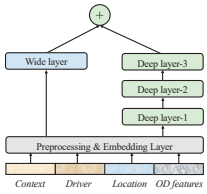

Figure 7: TP model.

The attention layer. At each location, the driver may fully consider all the pickup and delivery tasks, and then decide which location to go. We use the Attention mechanism to depict the driver's decision process, and the detail is illustrated in Fig. 6. For each step i, the driver has an available set of feasible locations to visit next, denoted as C_i. The set is made up of pickup locations of unfetched orders and delivery locations of fetched orders. At step i, we first get the driver's global view, and then calculate the probability $P(l)$ of each location $l \in C_i$ the driver will visit at step $i+1$. To get the driver's global view, we refer to the idea of global attention [12] and calculate as follows,

$$a_{ij} = \begin{cases} \frac{\exp(h_i \cdot v_{l_j})}{\sum_{l_k \in C_i} \exp(h_i \cdot v_{l_k})}, & l_j \in C_i \\ 0, & l_j \notin C_i \end{cases}, \tag{3}$$

$$g_i = \sum_j a_{ij} \cdot v_{l_j}. \tag{4}$$

Got the driver's global view g_i, we further calculate the probabilities as follows,

$$P(l_j|g_i) = \begin{cases} \frac{\exp(g_i \cdot v_{l_j})}{\sum_{l_k \in C_i} \exp(g_i \cdot v_{l_k})}, & l_j \in C_i \\ 0, & l_j \notin C_i \end{cases}. \tag{5}$$

Based on the probabilities, we try two optimization strategies to generate the complete delivery route, i.e., the greedy strategy (choosing the location with maximum probability each step), and the Beam Search strategy (considering the probability of the complete

route) [20]. The comparative experimental results will be detailed in Sec. 6.

5.3 Time Prediction Module

The TP module aims to produce the estimated time on the driver arriving at each location in the delivery route. We take the third route constraint mentioned in Sec. 3 into consideration, that each order can not be fetched before the earliest pickup time. The task is refined to predict the time duration leaving from the previous location to arriving at the successive one. Combining the time durations and the earliest pickup time of each order, we can generate the final estimated time. If the driver arrives at the restaurant before the earliest pickup time, he needs to wait for the meal to be prepared. Otherwise, the driver can fetch the order immediately. Formally, the TP module calculates

$$TD_{i-1,i} = f(l_{i-1}, l_i; X_i^t), \tag{6}$$

where X_i^t denotes the available information at step i for time prediction. We implement the TP module as a pure regression task. Similar with the RP module, we introduce the built features at first, and then the Wide & Deep model designed to predict the time duration.

5.3.1 The features. Same with the RP module, the **context features** and **driver features** are used in the TP module as well. Besides, we are mainly concerned with the relevant spatiotemporal features, which can be divided into two groups as follows. (1) **Location features**: we utilize embeddings of the GPS coordinate as the spatial information of each location, which is proposed in the drop-off duration prediction system[2]. The mathematical formulations can be found in Appendix A.2.2. In addition, the drop-off duration is used as the temporal information for the delivery location. (2) **OD features**: apart from the navigation distance, we calculate different granularity statistics of time durations from the origin to the destination in historical data mentioned in Tab. 2. Taking data sparsity into consideration, we calculate the time durations between the two Geohash codes. We average the time durations of yesterday, the past 7 days, and the same period in the past 7 days respectively, to portray information at different granularities.

5.3.2 The model. We design a Wide & Deep model as illustrated in Fig. 7, and the calculation details can be found in Appendix A.2.1. The deep part is expert in extracting location related latent information, while the wide part can express the addition of features better. Different from the RP module, we use the numerical values of dense features, as the time duration changes continuously with these features, e.g., the navigation distance. In addition, we divide the data into six groups according to the type of the origin and destination, i.e., start, pickup or delivery, for two reasons: (1) The task characters change among different groups. For example, the driver needs to walk from the restaurant, drive on the road, and walk to the customer in the PD (Pickup – Delivery) group. The travel behaviors are different in other groups; (2) The distributions of different groups of actual time durations change a lot, as illustrated in Fig. 8. Therefore, we adopt separated parameters in the Wide & Deep model for different groups of the data.

[2]https://tech.meituan.com/2019/10/10/distribution-time-prediction-practice.html

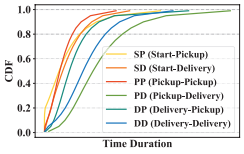

Figure 8: Distributions of six groups of time duration.

5.4 Model Training and Prediction

In this part, we will introduce the training and prediction process of FDNET, and explain the dataflow between the two modules.

5.4.1 Training. We use the teacher forcing strategy [19] when training the model. That is to say, the RP module and TP module both take the actual sequence of locations the driver visits as input. In the RP module, the time related features at each step i are calculated based on the actual time when the driver leaves from the location l_{i-1}. We use the cross entropy loss function commonly used in classification tasks for the RP module, which is calculated by

$$\mathcal{L}^r(\Theta^r; \mathcal{D}) = -\frac{1}{|\mathcal{D}|} \sum_{\mathcal{D}} \Big(\sum_{i=1}^{\dot{n}} log(P(l_i^{label} | g_i)) \Big). \tag{7}$$

$\mathcal{D}$ denotes the training dataset, and l_i^{label} is the actual location the driver will visit at step i. $\dot{n}$ denotes the length of each data sample (without the start location) mentioned in Sec. 4. For the TP module, we adopt the MAE (Mean Absolute Error) loss as follows,

$$\mathcal{L}^t(\Theta^t; \mathcal{D}) = \frac{1}{|\mathcal{D}|} \sum_{\mathcal{D}} \Big(\sum_{i=1}^{\dot{n}} \| \hat{TD}_{i-1,i} - TD_{i-1,i} \| \Big). \tag{8}$$

$\hat{TD}_{i-1,i}$ is the estimated value, and $TD_{i-1,i}$ is the label. We train the two modules with separate Adam optimizers [10] and learning rates, which means the two modules are independent during training.

5.4.2 Prediction. When used for prediction, the RP and TP modules cooperate closely. At each step i, the RP module takes the location generated at step $i-1$ as input, and the features (earliest pickup/due time left and navigation distance) are updated using the time produced by the TP module at step $i-1$. At the same time, the TP module takes the locations produced by the RP module as input, and then predicts the time further. Through $n + n_2$ steps, FDNET can produce a feasible delivery route along with the time together.

6 EXPERIMENTS

In this section, we evaluate and analyze the performance of our proposed FDNET, through offline experiments, online A/B test and the case study.

6.1 Offline Experiments

At first, we conduct experiments based on offline dataset to evaluate the performance of the two modules. Specifically, we evaluate the ranking accuracy of the RP module, the regression accuracy of the TP module. Then we generate the complete delivery route, and

Table 3: Ranking accuracy of route prediction.

	Short Routes		Long Routes	
	HR@1	MRR	HR@1	MRR
Logistic Regression	87.22%	0.9424	75.36%	0.8603
Random Forest	86.53%	0.9415	74.11%	0.8531
XGBoost	86.44%	0.9428	73.07%	0.8464
FDNET	**91.59%**	**0.9611**	77.77%	**0.8742**
... w/o context features	91.53 %	0.9607	**77.79%**	0.8741
... w/o driver features	91.33%	0.9598	77.53%	0.8726

Table 4: Feature weights in XGBoost. The values can reflect feature importance to some extent, but are not exactly equivalent to the gain of evaluation metrics.

Route Prediction		Time Prediction	
Features	Weights	Features	Weights
Context features	267	Context features	671
Driver features	80	Driver features	141
Pickup features	522	Location features	476
Delivery features	609	OD features	511

evaluate the accuracy of the pickup and delivery time of each order which benefits from the two modules.

6.1.1 Route prediction module. As mentioned in Sec. 5.2, the RP module predicts the probability of the driver visiting each feasible location next at each step. Training objective of the RP module is to maximize the probability of the actual next location, then rank before other locations. In this part, we evaluate the ranking accuracy of the RP module.

Compared methods. With same settings as our implementation, we choose the point-wise based ranking methods to compare, which predict the probability of each feasible location and rank based on the probabilities further. Specifically, we choose several frequently-used traditional classification models (LR (Logistic Regression), RF (Random Forest) and XGBoost [3]) to implement the point-wise ranking methods. To ensure the consistence of features used with FDNET, we specially generate the dataset for compared methods. Each sample carries the context features, driver features, current location features, next candidate location features, the navigation distance and the label (True or False).

Metrics. We focus on the accuracy metric, i.e., HR (hit ratio), and ranking metric, i.e., MRR (mean reciprocal rank) in the experiments. HR@k is defined as the fraction of cases where the actual location is among the top k locations, and we use HR@1 here. MRR measures whether the model can predict the actual next location with a higher probability, calculated by averaging the reciprocal of the actual locations' ranks.

Results. Tab. 3 shows the experimental results. The prediction difficulty changes along with length of the delivery route, as longer route means greater decision space and uncertainty. As a result, we divide the routes into two groups according to the length and evaluate separately (length of short routes is less than or equal to 8 without the start location, and the remaining are long routes). From the results, we observe that the accuracy of short routes is much higher than that of long routes, over 13pp (percentage point) on HR@1 and 0.08 on MRR, which is intuitive. Among the traditional models, LR performs better than the ensemble models (RF and XGBoost) overall, which is a bit out of our expectation. We consider the restricted features used in the RP module limit the performance of ensemble models, which are especially good at utilizing statistical information. The performance of FDNET is better than the compared methods, outperforming 4.37pp/2.41pp on HR@1 and 0.0187/0.0139 on MRR for short/long routes than LR. We consider the improvement is from the RNN used to extract behavior sequence information and Attention to depict the decision process of drivers. In addition, we consider ablating the context features and driver features to illustrate the effectiveness of personalized information. The results are in the last two rows of Tab. 3. For the route prediction, the context features bring weak improvement, because of the weak effect on drivers' decisions. The driver features leads to higher improvement, 0.26pp/0.24pp on HR@1 and 0.0013/0.0016 on MRR for short/long routes. We consider the driver's fine-grained past behavior sequence information will bring more improvement than statistical information for route prediction, which can be tried in the future work. Besides, we show the weights of features produced by the XGBoost model in Tab. 4, meaning how many times the feature is used to split the tree nodes. The weight values can reflect feature importance to some extent, and we can observe that pickup and delivery features are most important for route prediction.

6.1.2 Time prediction module. As mentioned in Sec. 5.3, the TP module predicts the time duration between two adjacent locations. In this part, we evaluate the corresponding regression accuracy.

Compared methods. Several frequently-used traditional regression models are chosen to compare with FDNET, including the Linear Regression, RF and XGBoost. Except for the GPS coordinate which is very difficult to be introduced in traditional models, we keep the consistence of features used, including the context features, driver features, location features and OD features.

Metrics. We adopt MAPE (Mean Absolute Percentage Error) to measure the accuracy of time duration, which is the most common metric for the ETA problem [2].

Results. Tab. 5 shows the experimental results, where different groups of time duration are evaluated separately. Different from the route prediction, XGBoost outperforms other traditional models, due to more features utilized in time prediction. Generally, the accuracy of FDNET is better than compared methods among all groups and MAPE decreases 0.0769 compared with XGBoost overall. We consider the powerful expression ability of depth network and the effective processing of discrete features (the context features, the GPS embeddings etc.) bring the improvement mostly. In addition, we conduct an extended experiment to verify effectiveness of the wide part in the Wide & Deep model. We ablate the wide part from FDNET, the accuracy declines to varying degrees among different groups except for the DD (Delivery – Delivery) group. Overall, the accuracy without wide part declines 0.0057 on MAPE, which proves the validity of low-order information in the Wide & Deep model. Similar with RP module, we ablate the context features and driver features to illustrate the effectiveness of personalized information.

Table 5: Regression accuracy (MAPE) of time duration prediction (Abbr.: S for Start, P for Pickup and D for Delivery).

	SP	SD	PP	PD	DP	DD	All
Linear Regression	0.9137	0.8934	0.7011	0.3442	0.4476	0.5701	0.6256
Random Forest	0.8901	0.8808	0.6598	0.3195	0.5030	0.4742	0.5900
XGBoost	0.8362	0.7505	0.5042	0.3082	0.5109	0.4525	0.5404
FDNET	**0.7437**	**0.6051**	**0.4183**	**0.2682**	0.3965	0.3694	**0.4635**
... w/o wide part	0.7630	0.6380	0.4276	0.2683	0.4035	**0.3549**	0.4692
... w/o context features	0.8224	0.6139	0.4447	0.2751	**0.3898**	0.4020	0.4980
... w/o driver features	0.8707	0.6274	0.4426	0.2856	0.4183	0.3826	0.5130

The context features contain coarse-grained spatiotemporal information, and the driver features can depict the driver's delivery habit and ability, e.g., the delivery speed. From the results, context features bring 0.0345 improvement and driver features bring 0.0495 improvement on MAPE. Different from route prediction, the personalized information is more meaningful for time prediction, and more relevant features should be introduced in the future. The weights of features in Tab. 4 indicate the effectiveness of features utilized in time prediction.

Table 6: Accuracy of the estimated time from start location in the route (relative decreasing value to the traditional search algorithm on MAPE).

	Pickup Locations		Delivery Locations	
	Short	Long	Short	Long
FDNET (Greedy)	**0.6725**	0.1038	0.0731	0.2126
FDNET (Beam Search)	0.6626	**0.1073**	**0.0735**	**0.2223**

6.1.3 The estimated time on arriving at each location in the route. Combining the RP and TP modules, we get the estimated time on arriving at each location in the route. In the part, we evaluate the accuracy of the estimated time which can reflect both effectiveness of the RP and TP modules. As mentioned in Sec. 5.2, we adopt two strategies for generating the complete delivery route, i.e., the greedy strategy and Beam Search strategy. For the Beam Search strategy, we always record two routes with the highest probabilities during the process of route generation. Tab. 6 shows the relative accuracy of FDNET against the traditional heuristic search algorithm used in Meituan food delivery platform. From the results, we observe that FDNET outperforms the search algorithm for pickup and delivery locations in both short and long routes. Specifically, the MAPE of FDNET with greedy strategy decreases 0.6725/0.1038 for pickup locations and 0.0731/0.2126 for delivery locations in short/long routes. In addition, we compare the two optimization strategies. For long routes, the greedy strategy can be short sighted, and the Beam Search strategy gets higher accuracy. Especially for the delivery location, the MAPE of FDNET based on the Beam Search strategy decreases 0.0097 than the greedy strategy. However, for short routes, the Beam Search strategy has no advantage, as the decision space is relatively small. As a result, we adopt the greedy strategy for short routes and the Beam Search strategy for long routes respectively. The experimental results show the effectiveness of FDNET, compared to the traditional heuristic search algorithm.

6.2 Online A/B Test

Motivated by the encouraging offline evaluation results, we deploy FDNET in Meituan food delivery platform and test its performance online. From the results of A/B test, FDNET gains the 0.08pp improvement for order punctuality, and the average order fulfillment cycle time (time duration from the customer placing the order to finishing delivery) decreases over 20 seconds. In addition, the average distance travelled by drivers to deliver one order decreases over 60 meters. FDNET brings the improvement of user satisfaction and driver experience.

6.3 Case Study

To analyze the performance of FDNET more intuitively, we conduct an empirical case study shown in Fig. 9. In the actual environment, there is lots of uncertainty for drivers' behaviors. We analyze cases to illustrate the advantages of FDNET over the traditional heuristic search algorithm, and more significantly, for directing further improvements.

Case #1. Fig. 9(a) shows two delivery routes produced by FDNET and the search algorithm respectively. The driver has two orders to delivery, of which o_1 has been fetched. FDNET predicts the driver will fetch the order o_2 and then deliver o_2 and o_1 to the customers, which agrees with the driver's actual delivery route. From the map, we observe this delivery route is convenient for the driver considering the delivery distance. However, the search algorithm produces a different result, which predicts the driver will deliver order o_1 to the customer, then fetch and deliver o_2. As mentioned in Sec. 1, the search algorithm aims to optimize a heuristic cost function, considering the punctuality of each order and the total delivery distance. In the case, the search algorithm considers the due time left of order o_1 is short, and the risk of timeout is larger if the driver first fetches and delivers order o_2. We consider the less consideration for personalized information and the empirical heuristic cost function limit the performance of the search algorithm. FDNET performs better through taking more personalized information into consideration and predicting the most probable delivery route based on historical data.

Case #2. Fig. 9(b) shows a typical case, where FDNET and the search algorithm both make mistakes usually. In the case, the driver has three orders to fetch and deliver and the restaurants of order o_1 and o_2 are near. For the pickup locations, FDNET considers the driver will fetch order o_1 firstly according to the earliest pickup time. However, the driver first fetches order o_2 in fact, causing the inconsistency. We consider there are two reasons for the case: (1) the meal preparation time has lots of uncertainty, and the earliest pickup time given by another system may have deviations; (2) the two pickup locations are very close and which order the driver will fetch first is with some randomness. We can introduce more information about the restaurant to improve the accuracy in the future.

Case #3. Fig. 9(c) shows a special case, where the driver has two orders (with close due time) to deliver, and the delivery route predicted by FDNET looks more convenient. However, the driver chooses to deliver the far order o_1 firstly and then drives back to the near one o_2. In the case, we consider the drop-off difficulty of the two orders matters a lot. The delivery location of o_1 is near

(a) Case #1. (b) Case #2. (c) Case #3.

Figure 9: Three actual cases produced by FDNET.

the road, and the driver can finish the delivery once he arrives. However, the delivery location of o_2 is in the community, and the driver needs to stop driving and walk upstairs to the customer. As a result, the driver chooses to drive straight to deliver o_1 first and then turn back. The specific case contradicts our statistics shown in Fig. 5(d). To further improve FDNET, we should consider more driver's personalized information, such as, the driver's familiarity with the delivery location, the sequence of driver's past behaviors and so on.

7 CONCLUSION AND FUTURE WORK

This paper proposes a deep network — FDNET, to tackle the FD-RTP task in food delivery service. FDNET adopts the RNN and Attention–based RP module to predict the probability of each feasible location the driver will visit next, and generate the most probable delivery route. In addition, the TP module utilizes more abundant personalized, statistical and spatiotemporal information to enhance the accuracy of time prediction. The offline experiments show the effectiveness compared to frequently-used machine learning models, and the online A/B test shows the superiority of FDNET for the FD-RTP task.

In the future work, more information should be introduced to further enhance the accuracy, including but not limited to the following: (1) fine grained driver personalized information (sequence of drivers' past behaviors); (2) drivers' familiarity with the restaurants and delivery locations; (3) more abundant context information for the TP module, e.g., the real-time traffic conditions; (4) route links information for the TP module.

REFERENCES

[1] Abdulrahman Al-Molegi, Mohammed Jabreel, and Baraq Ghaleb. 2016. STF-RNN: Space Time Features-based Recurrent Neural Network for predicting people next location. In *2016 IEEE Symposium Series on Computational Intelligence (SSCI)*. IEEE, 1–7.

[2] Richard Barnes, Senaka Buthpitiya, James Cook, Alex Fabrikant, Andrew Tomkins, and Fangzhou Xu. 2020. BusTr: Predicting Bus Travel Times from Real-Time Traffic. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 3243–3251.

[3] Tianqi Chen and Carlos Guestrin. 2016. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*. 785–794.

[4] Zaiben Chen, Heng Tao Shen, and Xiaofang Zhou. 2011. Discovering popular routes from trajectories. In *2011 IEEE 27th International Conference on Data Engineering*. IEEE, 900–911.

[5] Xuetao Ding, Runfeng Zhang, Zhen Mao, Ke Xing, Fangxiao Du, Xingyu Liu, Guoxing Wei, Feifan Yin, Renqing He, and Zhizhao Sun. 2020. Delivery Scope: A New Way of Restaurant Retrieval for On-demand Food Delivery Service. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 3026–3034.

[6] Huifeng Guo, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He. 2017. DeepFM: a factorization-machine based neural network for CTR prediction. In *Proceedings of the 26th International Joint Conference on Artificial Intelligence*. 1725–1731.

[7] Sepp Hochreiter and Jürgen Schmidhuber. 1997. Long short-term memory. *Neural computation* 9, 8 (1997), 1735–1780.

[8] Huiting Hong, Yucheng Lin, Xiaoqing Yang, Zang Li, Kung Fu, Zheng Wang, Xiaohu Qie, and Jieping Ye. 2020. HetETA: Heterogeneous information network embedding for estimating time of arrival. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 2444–2454.

[9] Ishan Jindal, Xuewen Chen, Matthew Nokleby, Jieping Ye, et al. 2017. A unified neural network approach for estimating travel time and distance for a taxi trip. *arXiv preprint arXiv:1710.04350* (2017).

[10] Diederik P Kingma and Jimmy Ba. 2014. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980* (2014).

[11] Wuman Luo, Haoyu Tan, Lei Chen, and Lionel M Ni. 2013. Finding time period-based most frequent path in big trajectory data. In *Proceedings of the 2013 ACM SIGMOD international conference on management of data*. 713–724.

[12] Minh-Thang Luong, Hieu Pham, and Christopher D Manning. 2015. Effective Approaches to Attention-based Neural Machine Translation. In *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*. 1412–1421.

[13] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. 2014. Dropout: a simple way to prevent neural networks from overfitting. *The journal of machine learning research* 15, 1 (2014), 1929–1958.

[14] Hongjian Wang, Xianfeng Tang, Yu-Hsuan Kuo, Daniel Kifer, and Zhenhui Li. 2019. A simple baseline for travel time estimation using large-scale trip data. *ACM Transactions on Intelligent Systems and Technology (TIST)* 10, 2 (2019), 1–22.

[15] Xing Wang, Shengyao Wang, Ling Wang, Huanyu Zheng, Jinghua Hao, Renqing He, and Zhizhao Sun. 2020. An Effective Iterated Greedy Algorithm for Online Route Planning Problem. In *2020 IEEE Congress on Evolutionary Computation (CEC)*. IEEE, 1–8.

[16] Yilun Wang, Yu Zheng, and Yexiang Xue. 2014. Travel time estimation of a path using sparse trajectories. In *Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining*. 25–34.

[17] Zheng Wang, Kun Fu, and Jieping Ye. 2018. Learning to estimate the travel time. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 858–866.

[18] Ling-Yin Wei, Yu Zheng, and Wen-Chih Peng. 2012. Constructing popular routes from uncertain trajectories. In *Proceedings of the 18th ACM SIGKDD international conference on Knowledge discovery and data mining*. 195–203.

[19] Ronald J Williams and David Zipser. 1989. A learning algorithm for continually running fully recurrent neural networks. *Neural computation* 1, 2 (1989), 270–280.

[20] Sam Wiseman and Alexander M Rush. 2016. Sequence-to-Sequence Learning as Beam-Search Optimization. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*. 1296–1306.

[21] Hao Wu, Ziyang Chen, Weiwei Sun, Baihua Zheng, and Wei Wang. 2017. Modeling trajectories with recurrent neural networks. IJCAI.

[22] Hao Wu, Jiangyun Mao, Weiwei Sun, Baihua Zheng, Hanyuan Zhang, Ziyang Chen, and Wei Wang. 2016. Probabilistic robust route recovery with spatio-temporal dynamics. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 1915–1924.

[23] Huanyu Zheng, Shengyao Wang, Ying Cha, Feng Guo, Jinghua Hao, Renqing He, and Zhizhao Sun. 2019. A Two-Stage Fast Heuristic for Food Delivery Route Planning Problem. (2019).

A IMPLEMENTATION DETAILS OF FDNET

In this appendix, we introduce some implementation details of FDNET, including the RP module and TP module respectively.

A.1 Route Prediction Module

A.1.1 Feature preprocessing. In Sec. 5.2.2, we refer to the deepFM model [6] to encode each category of features to the vector representation $v \in \mathbb{R}^m$. The origin deepFM model is consist of two components. The FM component extracts the first-order information v^1 and second-order feature interactions v^2, while the deep component models high-order feature interactions v^{deep}. The vector representation of each category of features $x \in \mathbb{R}^{d_x}$ is the concatenation of these informations as follows,

$$\begin{aligned} v &= [v^1; v^2; v^{deep}], \\ v^1 &= \sum_{i=1}^{d_x} w_i \cdot x_i, \\ v^2 &= \sum_{i=1}^{d_x} \sum_{j=i+1}^{d_x} x_i \cdot x_j \cdot (V_i \odot V_j), \\ v^{deep} &= \mathrm{DNN}^3(x). \end{aligned} \tag{9}$$

In the formula, w_i and V_i are parameters, $\odot$ denotes the element-wise multiplication between two vectors, and DNN^k means a neural network with k FC (fully-connected) layers. The FC layer is calculated by

$$\mathrm{FC}_f(x) = f(Wx + b), \tag{10}$$

where $f(\cdot)$ denotes the non-linear activation function, Leaky Rectified Linear Unit used here and W and b are the parameters. Controlling the dimension of V and v^{deep} in the calculation, we can get the fixed m-dimensional vector representation, no matter how many values the category of features x contains.

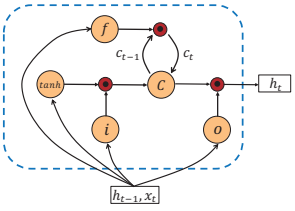

Figure 10: Structure of LSTM cell.

A.1.2 LSTM. We adopt the LSTM based RNN to process the sequential data, whose structure is illustrated in Fig. 10. LSTM alleviates the gradient vanishing and exploding problem of RNN by using an additive memory cell and several gates to control the information flow. At each step t, the input gate, forget gate, output gate and modulated input are updated as

$$\begin{aligned} f_t &= \sigma(W_f[h_{t-1}; x_t] + b_f), \\ i_t &= \sigma(W_i[h_{t-1}; x_t] + b_i), \\ o_t &= \sigma(W_o[h_{t-1}; x_t] + b_o), \\ \widetilde{C}_t &= tanh(W_C[h_{t-1}; x_t] + b_C), \end{aligned} \tag{11}$$

where $\sigma(\cdot)$ is the Sigmoid function, $\sigma(x) = 1/(1 + e^{-x})$, and x_t is the input. Then the memory cell and hidden state are updated as

$$\begin{aligned} C_t &= f_t \odot C_{t-1} + i_t \odot \widetilde{C}_t, \\ h_t &= o_t \odot tanh(C_t), \end{aligned} \tag{12}$$

where h_t is the output of the LSTM cell at step t as well.

A.1.3 How to guarantee route constraints in the model. In the process of route prediction, the key to guarantee route constraints is how to maintain the feasible location set C_i at step i. The set is made up of pickup locations of unfetched orders and delivery locations of fetched orders. In the part, we introduce how to initialize and update C_i dynamically along with model calculation. At first, we build the mask array according to the orders' statuses. Then we do the full calculation of each location in the implementation of Equ. 3 and Equ. 5, whether the location is in C_i or not. Finally, we mask the unnecessary values by element-wise multiplication between the mask array and the computed results. At the next step $i + 1$, we update the orders' statuses and repeat the above calculation. A demo in Fig. 11 shows the calculation process of a delivery route containing 3 orders to help understand. Through these calculations, we promise the generated route must satisfy the first two constraints mentioned in Sec. 3.

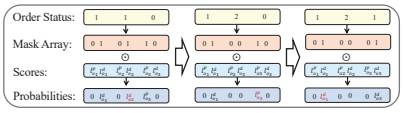

Figure 11: A demo of the route calculation (the first two steps) to guarantee constraints. The mask array is generated through one-hot encoding of the order status (0 for unfetched order, and 1 for fetched order) with depth 2. $\odot$ denotes the element-wise multiplication, which is used to mask the scores of locations to calculate probabilities. Status of the chosen order increases 1 at the next step and the calculation repeats further.

A.2 Time Prediction Module

A.2.1 Wide & Deep model. We design a Wide & Deep model for the TP module as mentioned in Sec. 5.3.2. The model's output is generated by adding the results of the wide part and deep part:

$$y(x) = y^{wide}(x) + y^{deep}(x), \tag{13}$$

where x is the vector generated by preprocessing of all the input features. The preprocessing including normalizing the dense features and embedding the discrete features. The implement of the two parts are as follows,

$$\begin{aligned} y^{wide}(x) &= \sum_{i=1}^{d_x} w_i \cdot x_i + b, \\ y^{deep}(x) &= \mathrm{DNN}^3(x). \end{aligned} \tag{14}$$

The wide part is equivalent to the Linear Regression, while the deep part is a 3-layer DNN. The first two layers are activated by the Leaky Rectified Linear Unit and the last layer only has one neure without activation function.

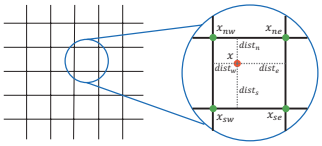

Figure 12: The embeddings for GPS coordinate.

A.2.2 Embeddings for GPS coordinate. For TP module, the GPS coordinate which precisely characterizes the location is used in the **Location features**. We will introduce the implementation of the embeddings for GPS coordinate. As shown in Fig. 12, we partition the entire geographical space into many grids, with equal lengths along the longitude and latitude. We first initialize the embeddings of grid vertexes. For the fine-grained embeddings of a specific GPS coordinate x, we find the four vertexes of the grid where x locates, named $x_{ne}, x_{nw}, x_{se}, x_{sw}$, and then calculate the spherical distances from x to the four vertexes along longitude and latitude, denoted as $dist_n$, $dist_s$, $dist_w$, $dist_e$. Based on the embeddings of vertexes and the distances, we calculate the fine-grained embeddings of the GPS coordinate x by

$$\begin{aligned} v_x^{gps} =& (dist_n dist_e v_{x_{ne}}^{gps} + dist_n dist_w v_{x_{nw}}^{gps} + \\ & dist_s dist_e v_{x_{se}}^{gps} + dist_s dist_w v_{x_{sw}}^{gps}) / dist^2, \end{aligned} \tag{15}$$

where $dist$ means the spherical distance of the grids along longitude or latitude, and 300m is adopted in the paper.

A.3 Parameter Selection

Table 7: The hyper parameters setup of FDNET.

Hyper parameters	Value
Dimension of discrete feature embeddings	16
Dimension of feature's vector representation	$m = 32$
# of nodes in FC hidden layers	32
Adam optimizer	$\beta_1 = 0.9, \beta_2 = 0.999$
Learning rate of the RP module	0.003
Learning rate of the TP module	0.001

Tab. 7 shows the hyper-parameters setup of FDNET, and some parameters can be tuned according to the situation.

A Semantic Segmentation based POI Coordinates Generating Framework for On-demand Food Delivery Service

Yatong Song *
Jiawei Li *
songyatong@meituan.com
lijiawei21@meituan.com
Meituan
Beijing, China

Liying Chen
chenliying03@meituan.com
Meituan
Beijing, China

Shuiping Chen†
chenshuiping@meituan.com
Meituan
Beijing, China

Renqing He
herenqing@meituan.com
Meituan
Beijing, China

Zhizhao Sun
sunzhizhao@meituan.com
Meituan
Beijing, China

ABSTRACT

Nowadays, on-demand food delivery service has become fashionable in China. The efficiency of food delivery relies heavily on accurate coordinates of destination Points of Interest (POI). However, the coordinates of the destination POIs from the existing geospatial data warehouses still have many problems that perplex couriers severely. The major problems can be concluded in two categories: 1) the deviation of POI coordinates; 2) the lack of POI coordinates. To address these problems, we propose a POI-coordinate-generating framework based on couriers' and users' behavioral data of historical waybills. In particular, we start with a combinatorial strategy to assign waybills to Areas of Interest (AOI). Second, we generate a destination POI name by processing the user address for each waybill, and all waybills are grouped by the corresponding POI name. Then, a data density image of the behavioral data is generated for each group, with the ground-truth location of the POI labeled. Finally, a U-Net is trained by using the images generated in the previous step to infer locations of the POIs. We evaluated this framework by launching experiments and case studies on large-scale datasets, and the result shows our framework can predict coordinates of POIs accurately. These predicted coordinates can be used to calibrate deviated coordinates of many POIs and complement the geospatial data warehouse.

CCS CONCEPTS

• **Computing methodologies** → **Image segmentation**; • **Software and its engineering** → *E-commerce infrastructure*; • **Information systems** → Data mining.

KEYWORDS

POI Generation, Address Parsing, Text Similarity, U-Net, Geospatial Data

ACM Reference Format:
Yatong Song, Jiawei Li, Liying Chen, Shuiping Chen, Renqing He, and Zhizhao Sun. 2021. A Semantic Segmentation based POI Coordinates Generating Framework for On-demand Food Delivery Service. In *29th International Conference on Advances in Geographic Information Systems (SIGSPATIAL '21), November 2–5, 2021, Beijing, China.* ACM, New York, NY, USA, 10 pages. https://doi.org/10.1145/3474717.3483986

1 INTRODUCTION

Recently on-demand food delivery service has become popular in China. The daily order volume of take-out has exceeded 40 million on Meituan APP, the largest on-demand food delivery platform in China [4]. As shown in Fig.1, users can explore the online restaurant marketplace, choose restaurants and order their favorite foods. Then, the delivery system will dispatch waybills to some couriers who will deliver the foods to corresponding users in about 30 minutes.

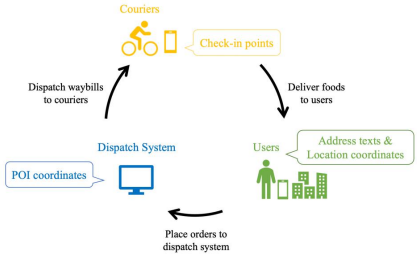

Figure 1: System, Couriers and Users Relations

The efficient delivery system relies on high intelligence algorithms and accurate geographic data such as the coordinates of POIs.

*Both authors contributed equally to this research.
†Corresponding author.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
SIGSPATIAL '21, November 2–5, 2021, Beijing, China
© 2021 Association for Computing Machinery.
ACM ISBN 978-1-4503-8664-7/21/11…$15.00
https://doi.org/10.1145/3474717.3483986

These coordinates are used as destinations of navigation routes for couriers and play important roles in downstream businesses such as the delivery cost, delivery time, delivery scope, and order allocation.

Nonetheless, the existing data has some vital drawbacks. The most severe problem is coordinates deviation. The reasons for the deviated coordinates in geospatial data warehouses could vary — from GPS drift to human error, obsolescent collection, and so on. Due to this problem, couriers often complain about being directed to the wrong destinations as shown in Fig.2(a). What's worse, this problem directly leads to some mistakes in the delivery system, such as incorrectly estimated delivery cost, delivery time, or delivery scope.

Meanwhile, lacking coordinates of fine-grained address text is also a problem that damages couriers' experience greatly as shown in Fig.2(b). Compared with the driving scenario of ride-hailing platforms such as Uber, users' addresses on food delivery platforms are different. The addresses given to Uber drivers are usually names of places nearby the users' truly expected destinations, which will not hurt user experiences. Hence, the addresses are not necessarily fine-grained. As for food delivery, users usually provide more fine-grained addresses to the platforms, which are generally closer to the expected destinations than in ride-hailing scenarios, expecting to receive their food timely and soundly without extra work. This phenomenon causes the route in the instant delivery scenario to be significantly different from ride-hailing platforms, and couriers always ride electric bicycles on low-grade roads where cars can't get on. Therefore, precise coordinates of fine-grained addresses are significantly important for couriers to find their destinations.

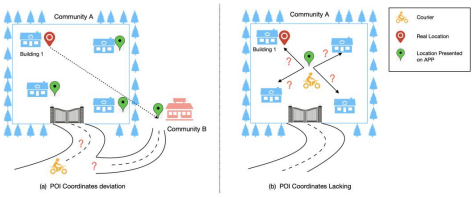

Figure 2: Problems of POI Coordinates

To tackle the above problems, we propose a framework to inference POI coordinates from the courier and user behavioral data. The proposed framework consists of four steps:

First, we applied a waybill-AOI mapping algorithm to judge which AOI the historical waybills belong to. This algorithm uses three categories of data: check-in points, user locations, and raw POI coordinates from the data warehouse. Precisely, check-in points are static GPS positioning points couriers report after they deliver foods to users. Check-in points are always located surrounding the user address yet a few of them have large deviations as shown in Fig.3(a). A user location point as shown in Fig.3(b) is where the user places an order, which may be near the user address on the waybill, or far from it when the user places an order for someone else far away.

(a) Check-in Points (b) User Location Points (c) Comparison of 2 Sources of Points

Figure 3: Check-in Points and User Location Points of a POI

Second, an address text parser is utilized to obtain hierarchically structured user addresses containing AOIs, buildings, and so forth. All waybill data, including check-in points and user locations, are then grouped into several subsets according to the hierarchical structure denoted as address groups. Our object is to generate coordinates for each address group, and addresses in the same address group will share the same final coordinate. These final coordinates will be generated in the next two steps.

Further, inspired by [5], we combine the courier check-in points and user locations to be a 2-channel image for each subset. This process is called data density image generation. Specifically, we apply GeoHashes [1] to represent the pixels of the images. The generated images are composed of GeoHashes with data density information. We use a statistical method to mark the true values of buildings on the images.

The last step is called delivery point inference, we take advantage of U-Net, a well-known architecture in image semantic segmentation to process the data density images and predict probability heatmaps indicating the most possible target building locations.

Our framework is not only meant to mine the most proper POI coordinate for each address group but also meant to infer the most likely places for couriers to deliver foods to users. Therefore, the coordinates predicted do not always refer exactly to the center point of the target buildings on the map. Instead, they usually refer to places nearby the buildings where both couriers and users can meet conveniently. In conclusion, our contributions are listed as follows:

- **Potential Impact On Other Services.** We built a geographic hierarchical structure to model the physical world by parsing the address texts, which can also be used as a macroscopic user profile for any service correlated to users.
- **Potential Impact On Other Researches.** We use GeoHashes to bridge geospatial data with deep learning computer vision techniques in our research, revealing the great potential of applying these popular techniques directly to geospatial data.
- **Empirical Evaluation Using Real-World Data.** We evaluate the proposed framework by conducting a comprehensive evaluation and case studies on two large-scale real-world datasets from the Meituan delivery system, which demonstrates the effectiveness to tackle the following challenges:

[1] GeoHash is a geocode algorithm that encodes a geographic location into a short string of letters and digits. GeoHash8 is applied in our experiments, which encodes a point into a 38.2 m × 19 m grid.

- For POI lacking problem: The delivery points supplement an amount of more than 10% of the total POIs to the geospatial database.
- For POI coordinates deviation problem: The delivery points calibrate more than 8% POI coordinates and outperform the coordinates inferred from other typical clustering methods.

2 RELATED WORK

Recent years have witnessed the popularity of smart mobile devices which can provide rich geospatial data, resulting in rapidly developing geo-information systems and location-based services. Millions of check-in data flourished from these services and systems, making it possible to study personalized location recommendation and POI location mining, which have been popular research themes for a long period[7].

Many early studies concerning POIs have suffered from the sparsity problem of the user check-in data[12]. Although smart mobile devices can offer a rather accurate user position, most users were not voluntary data offerers considering their privacy and convenience[9]. What's worse, the accuracy of these limited check-in coordinates is influenced by various factors like signal intensity. [16] tries to generate new POIs based on geo-referenced images and tags, which rely heavily on user-generated pictures and label information crawled from the online platforms. Some images may be unrelated to geographic locations, introducing much noise into the labels. [8] detects POIs from online geo-referenced comments. Yet analyzing user reviews which are short texts with sparse, temporal, and informal nature is also a great challenge.

In our scenario, we take advantage of the courier check-in data from the take-out delivery business, which is naturally rich and dense. And with the iteration of the algorithm and user feedback, the quantity and quality of data can be improved in the future. A variety of high-quality data sources have laid a solid foundation for our POI mining task. In addition, recent studies also introduce deep learning techniques into the POI predicting task, [15] utilizes the sequence modeling method to model the relations between multiple geographic locations. In this way, the natural geospatial structural relations might not be well encoded. We consider this task as a mutant of the image semantic segmentation task, trying to encode geospatial relations with convolution operations and predicting better geospatial coordinates.

3 PRELIMINARIES

Definition 1 (Waybill). A waybill is a parcel delivery task assigned to a courier, denoted as a 5-tuple: $b = (a; l; u; c; F)$, a is the destination address written by users, l is the coordinate of the destination address record in the data warehouse, u is the coordinate where the user places an order, c is the courier's check-in point, F are features of the parcel, including the price and the numbers.

Definition 2 (Address Group). An address group r refers to a group of addresses that share the same AOI name and POI name after address parsing. The address parsing result contains three parts, which denotes as (α, ρ, θ), α is the AOI name in the address, ρ is the POI name, and θ is other useful information such as unit, floor, or room. Examples are shown in Table 1.

Definition 3 (Delivery Point). A delivery point is a point that we infer from geospatial data, which denotes as $p = (r, d)$. d is the coordinate of the delivery point, which is denoted as (x, y). Delivery points can represent accurate locations where couriers hand over foods or parcels to users.

Definition 4 (Data Density Image). A data density image M is a two-channel image, in which the value of each pixel in each channel is the number of points a single GeoHash contains. Specifically, two channels of the image consist of the data density of courier check-in points and user location points respectively.

Problem Definition. We aim to infer the delivery point for each address group based on users' location points and check-in points. The problem of this paper is defined as:

Given a set of waybills $B = \{b_0, b_1, \dots\}$, parse a in each b_i and assign b_i to an address group according to the parse result; generate M from u and c of b in each address group, and infer p.

4 DELIVERY POINT INFERENCE FRAMEWORK

4.1 Overview

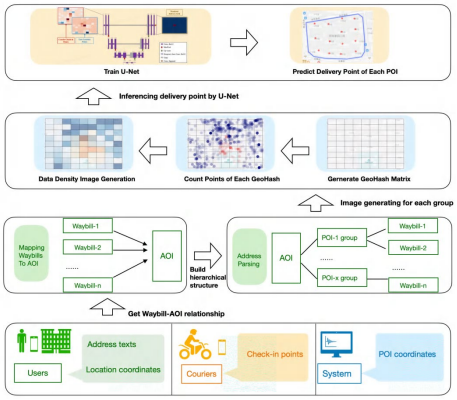

Figure 4: Delivery Point Inference Framework

The delivery point inference framework is elaborated in Fig.4, consisting of four modules:

Waybill-AOI Mapping. In this module, all the historical waybills are mapped to AOIs where the corresponding recipients locate. To achieve this, we make use of courier check-in coordinates, user location coordinates, and existing POI coordinates from the geospatial database. First, a voting mechanism is designed to determine which AOIs a waybill can be mapped to. Next, the text-similarity scores between the address text on the waybill and the names of candidate AOIs are computed. Finally, the waybill is mapped to a specific AOI with the highest similarity score. If a waybill fails to be mapped to any existing AOI, it is treated as invalid data.

Table 1: Address Group Examples

Address Groups	Raw Address Texts	AOI(α)	POI(ρ)	Other(θ)
r_1	Room 5××, Floor ××, Building **2**, ××× **Garden**	××× Garden	Building 2	Room 5××, Floor ××
	Left side of ××× **Garden**, at **2nd** Building, Room 4××.	××× Garden	Building 2	Room 4××
	Rm 3××, Bld **2**, ××× **Garden**	××× Garden	Building 2	Room 3××
r_2	Room 2××, Unit 2××, Building **NO.8**, ××× **Garden**	××× Garden	Building 8	Room 2××, Unit 2××
r_3	Room 1××, **Experiment Building**, ××× **School**	××× School	Experiment Building	Room 1××

Address Parsing. This module takes users' addresses and waybills and performs two main tasks: 1) Address Parsing. Analyze users' addresses and extract AOI names and POI names; 2) Waybill Grouping. Waybills having the same address parsing results are assigned to the same address group.

Data Density Image Generation. This module generates two-channel data density images from users' location points and couriers' check-in points. Concretely, it consists of two tasks: 1) Data Density Analysis with GeoHash. We analyze the density of users' location points and couriers' check-in points within each GeoHash; 2) Data Density Images Generation. For each address group, a zero matrix of the same shape is prepared. The density value in each GeoHash is calculated and filled into the corresponding position of the matrix to replace the initial value. Eventually, the data density matrices of users' location points and couriers' check-in points are stacked to be two-channel images, which are the inputs for the next module.

Delivery Point Inference. This module aims to predict the concrete coordinates of the delivery points for each address group and includes two procedures: 1) Training U-Net. Each training sample contains a two-channel data density image and the label of its corresponding address group. 2) Predicting delivery points. We use the trained U-Net to predict probability heatmaps revealing the GeoHashes where the true delivery points lie in and take the center points coordinate as the target POI coordinates.

4.2 Waybill-AOI Mapping Algorithm

The waybill-AOI mapping algorithm has two goals. One is to clean the multi-source dataset. The other is to find an AOI corresponding to the address on each waybill and determine a rough range for the coordinates corresponding to each address.

The attributions of waybills are determined according to 4 types of data, namely courier check-in points, users' positions when ordering, coordinates of POIs from data warehouses, and addresses on waybills. The specific steps of the waybill-AOI mapping algorithm can be summarized as follows:

Step 1: AOIs are voted by multi-source coordinates to determine which one the waybill maps to. We know that most of the courier check-in points, users' positions, and POI coordinates provided by data warehouses are relatively close to actual locations, but about 10% to 20% points deviating from actual locations by more than 100m still exist. Therefore, we need a voting algorithm to select the actual AOI of every waybill. The three coordinates of these sources of each waybill are judged respectively to which AOI they fall into. For a waybill, if more than one coordinates fall into the same AOI, then this waybill ought to map to this AOI, as shown in Fig.5. However, if each coordinate falls into a different AOI, such waybills are dealt with in the second step.

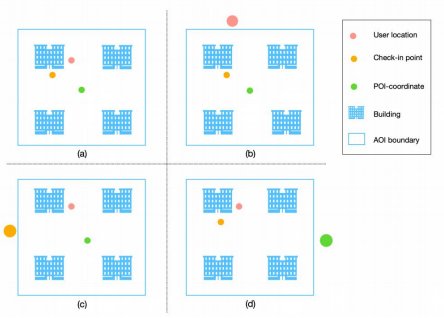

Figure 5: Waybill-AOI Mapping Algorithm

Step 2: The text similarity between the address and the AOI name is calculated. For the waybills matched with several AOIs according to the coordinates, we design an algorithm to compute the text similarities between the waybill addresses and the AOI names. The AOI with the highest similarity is chosen as the ultimate matched AOI for each waybill.

In the takeaway delivery scenario, the users' address texts have several characteristics:

※ User addresses and AOI names are mostly short texts.
※ The user address and the belonging AOI name mostly have more overlapping characters.
※ The order of overlapping characters is likely to be the same.

Based on that, the calculation of text similarity in our scenario may not be a complicated task. Although many great methods in natural language processing can capture rich semantic information in texts, such as CNN[19], RNN[2], or the state-of-the-art hybrid CNN-RNN model[20], we find that a simple and relatively lightweight refined string-matching algorithm is good enough to meet our needs.

The text similarity algorithm is a combinatorial strategy that scores the similarities between texts based on word frequencies,

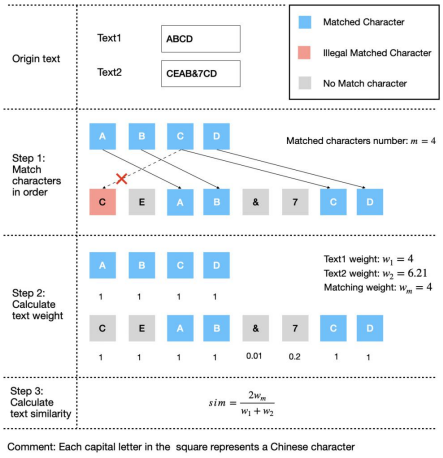

Figure 6: Text Similarity Calculation Algorithm.

word orders, word weights, and text lengths, and the similarity scores are normalized into [0, 1].

The text similarity algorithm, as shown in Fig.6, is mainly divided into three steps. First, we calculate the largest common subsequence (LCS) of address and AOI name.

Next, we compute a heuristically weighted sum of texts of the AOI name, address, and the LCS respectively. Suppose the total weight of the text is W, and the weight of each character is w_{ci}, then the calculation formula of W is as follows:

$$W = \sum_{i=1}^{n} w_{c_i}, w_{c_i} = \begin{cases} 1 & \text{if } c_i \text{ is normal characters} \\ 0.2 & \text{if } c_i \text{ is numbers} \\ 0.01 & \text{if } c_i \text{ is special characters} \end{cases} \quad (1)$$

Finally, based on the result of the formula (2). We set the LCS as w_m, the total weight of AOI name is w_1, and the total weight of address is w_2, then the similarity sim is:

$$sim = \frac{2w_m}{w_1 + w_2} \quad (2)$$

After the similarity score is calculated, the waybill will be mapped to the AOI with the highest text similarity score.

If the corresponding AOI of a waybill cannot be determined through the coordinate voting and text similarity comparison, that is to say, the three coordinates fail to fall in any existing AOI or the text similarities between the address and AOIs is 0, then such waybill is discarded as invalid data.

4.3 Address Parsing

After all valid waybills are successfully mapped to AOIs, we start to exploit the information on them. Each waybill records a detailed address, which is normally edited by a user on APP, indicating where the user expects to receive the ordered food. These address texts are not always intact or clean. A clean address text like example 1 below is similar to a structured form containing some AOIs, POIs(buildings), specific floor numbers, and room numbers. Yet in most real-world cases, the addresses are highly complex or redundant as example 2 below. To group these waybills according to the recipients' addresses, it is necessary to remove the redundant information and find out an exact target POI. For this purpose, a simple additional network module is added to our framework, which has not much difference from the widely-used named-entity-recognition methods.

Address Texts Examples:

1. *Room ×××, Floor ××, Building* ***4****,* ××× ***Garden****, Chaoyang Dist.*
2. *Enter the front gate of* ××× ***Garden****, and behind the big statue there is a building number* ***4****. At Room ×××.*

Plenty of previous works apply deep neural networks to tackle the problem of named-entity-recognition. N.Abid et al. [1] trained a bidirectional LSTM network to parse postal addresses and shows a good performance based on rather large data sets. More recently, Devlin et al. [3] released an even better model architecture with less training data required, known as BERT. In this work, we simply fine-tune an address parsing BERT model on the recipient address data and use it as our address parsing module. What's more, to ensure the restrictions on the transformation between different labels, a conditional random field layer(CRF) is added to process BERT outputs. The model structure is shown in Fig.7.

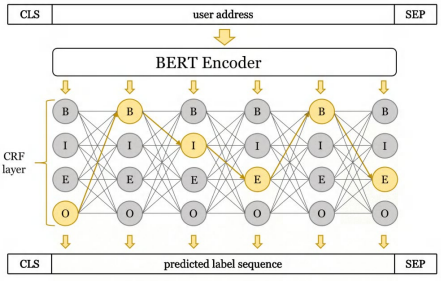

Figure 7: Structure of our address parsing model

The fine-tuned BERT reaches an average macro F1 value of 97.12 on our labeled recipient address dataset with a size close to 1,000. As an inner module of the whole system, such performance is good enough to ensure the quality of our downstream tasks, thus we cease to continue optimizing the model.

After addresses on the waybills are parsed, these waybills are divided into different address groups as shown in Table 1.

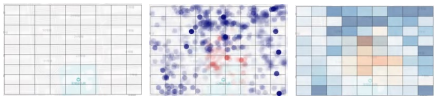

(a) GeoHash Packet (b) Density of Points (c) Data Density Image

Figure 8: Data Density Image Generation

4.4 Data Density Image Generation

At this stage, most of the data preparation and preprocessing works are accomplished. We then start to generate training samples for our delivery point inferencing network model.

First, we need to obtain the data density within GeoHashes. Through visualization, we find that the true values of delivery points are not only closely related to the data density in its address group but also somehow related to the data density in neighboring address groups. Specifically, the relationships between the true values of delivery points and data density can be summarized as follows:

- ※ The GeoHash with the highest data density in the current address group is more likely to be the true value of the delivery point;
- ※ In general, the true value of the delivery point will not locate in the area where neighboring groups and the current group data overlap;
- ※ If the data of the current group is sparse, the true value of the delivery point can still be inferred from the data density of the neighboring groups.

Based on the above observations, we introduce the data of neighboring address groups to help us to infer the delivery point of the current group. Specifically, we treat the points in neighboring address groups as negative signals and points in the current address group as positive signals, as shown in Fig.8(b). The blue points represent negative signals, and the red points represent positive signals. Next, inverted indices are set to store signal density in each GeoHash.

Second, a fix-sized GeoHash packet is established for each address group. And we take the GeoHash with the highest density as the packet center. Meanwhile, a matrix of the same size is used to record the data density of GeoHashes. As shown in Fig.8(a), the GeoHash score can be calculated from the inverted indices established in the previous two steps and put into the corresponding position of the matrix. The data density $S_{\text{GeoHash}(i)}$ of each GeoHash is calculated as follows:

$$S_{\text{GeoHash}(i)} = N_{\text{current}_{(i)}} - N_{\text{neighbor}_{(i)}}, \text{i} \in [0, N_{\text{GeoHashes}}] \quad (3)$$

where N_{current} is the number of points in current group, N_{neighbor} refers to the number of points in the neighboring groups, and $N_{\text{GeoHashes}}$ refers to the number of GeoHashes.

Couriers' check-in points and users' location points are processed into data density images respectively by the algorithm described in Algorithm 1. Fig.8(c) shows the density of each GeoHash. The darker the color is, the higher density of the GeoHash.

In our framework, GeoHash8, which is 38.2m × 19m and relatively close to the areas covered by most POIs, such as buildings, is applied. We use the center point of GeoHash8 to fit the location of a POI.

Algorithm 1 Data Density Image Generation.

Input: The set of AOIs **O**; The set of POI address groups **R**; The set of waybills **B**; The set of GeoHash **G**, which are encoded from check-in points **C** (or user locations **U**); An AOI o corresponds to $\mathbf{G_o}$, $\mathbf{R_o}$, $\mathbf{C_o}$ (or $\mathbf{U_o}$) in $\mathbf{B_o}$;
Output: The data density image matrix **M** of address groups in **A**;

```
for each AOI o in O do
    for each POI address group r in R_o do
        for each Geohash g in G_o do
            the given points ← C_o (or U_o) in B_o
            N_current(g) ← Count(point), point ∈ r
            N_neighbor(g) ← Count(point), point ∈ R_o − r
            M_r[g] ← N_current(g) − N_neighbor(g)
        end for
    end for
end for
return the data density image matrix M
```

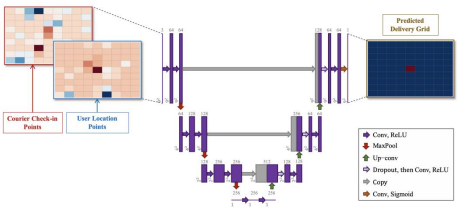

Figure 9: U-Net for Delivery Point Inference

4.5 Delivery Point Inference

4.5.1 Semantic Segmentation. Semantic Segmentation is an important research sub-field in computer vision[6, 21]. Unlike image classification or object detection tasks, image semantic segmentation usually outputs a probability data density image of the same size as the input, in which each pixel is classified into a particular class.

In our scenario, we innovatively encode the courier check-in points and user locations into GeoHashes to generate two-channel data density images. And the delivery point inference task can be roughly considered that it requires discrimination at the pixel level in the image. Therefore, we define our delivery point inference task as a kind of semantic segmentation task on data density images.

4.5.2 U-Net. Many previous works such as U-Net[17], Mask R-CNN[10], Feature Pyramid Network[11], have done great contributions to the field of semantic segmentation. U-Net is undoubtedly one of the most successful methods, which incorporates down-sampling, up-sampling, and skip connections[14, 18]. It is a classical method whose architecture contains two paths. The first path is the

contraction path which is used to capture the contextual information in the image, also known as the encoder. The encoder consists of convolutional and max-pooling layers. The other path is the symmetric expanding path, known as the decoder, enabling precise localization using transposed convolutions. U-Net accepts images of any size, and thus it is a mutant of FCN. In our framework, we adjust the layers in U-Net to fit the geographical data. The adjusted U-Net architecture is shown in Fig.9.

The distributed maps of GeoHashes are seen as the inputs images with GeoHash8 as its pixels. The U-Net extracts hidden features from the images and predicts a feature map in which the predicted logit value in each pixel indicating the probability of the target locating in that GeoHash. To ensure the stability of training, we use Binary Cross-Entropy Loss to generate the supervising signals and check the dice coefficient of the predicted results when evaluating the model.

$$BCELoss = -y_{\text{true}} \log\left(y_{\text{pred}}\right) - (1 - y_{\text{true}}) \log\left(1 - y_{\text{pred}}\right) \quad (4)$$

5 EXPERIMENT

5.1 Data Preprocessing

We use more than 10 million waybills in December 2020 which belong to 20 thousand POIs from Beijing and Shanghai as the experimental datasets. Each POI address group has 500 historical waybills on average. And each waybill of the dataset has a courier's check-in point, a user's location point, a detailed address of the destination, and a POI coordinate from the geospatial database. After AOI mapping, address parsing, and waybills grouping according to address parsing results, we got thousands of samples of address groups. Specifically, the total volume of GeoHash8s is 204,537. The dataset is divided into approximately 70% for training, 20% for validating, and 10% for testing.

We use a statistical method to mark the true value of each POI address group:

First, the courier check-in points and user location points of the POI are combined into one dataset and mapped to the corresponding GeoHash.

Second, the number of points contained in each GeoHash is calculated, and only GeoHashes with more than 2 points are kept for the next step.

Third, the largest connected set of GeoHash is found. The definition of connectivity is that given a GeoHash g_{center}, then each of the four neighboring GeoHashes (g_n, g_s, g_e, g_w) are defined as adjacent GeoHash with g_{center}. If any two GeoHashes in a given GeoHash set are directly or indirectly adjacent, then we say that this set of GeoHash sets is connected. The largest connected set refers to the GeoHash set that contains more than 50% historical waybills of the POI address group. After we find the largest connected set of GeoHash, we also make a restriction on the number of this set. The goal is to determine the possible region of POI true value. We sort the GeoHashes in the set according to the number of contained points. For the set with more than 12 GeoHashes, only the first 12 are selected, and for the set with less than or equal to 12 GeoHashes, all GeoHashes are reserved. Last, the valid POI coordinates from the geospatial database of the address groups are labeled. If the POI coordinate falls in the region of the largest connected GeoHash set, we consider this POI coordinate as the true value of the sample. Otherwise, this sample is discarded. An example of truth values filtered by the largest connected GeoHash set is shown in Fig.10(a), GeoHash set of building 5 contains 4 GeoHashes, as the blue area shown in the figure. The position of the marker symbol is the POI coordinate given by the database, and this coordinate is within the scope of the GeoHash set. We take this location as the true value of this POI. As a contrast, the coordinates of building 1 are out of the scope of its GeoHash set, as shown in Fig.10(b). Hence, this sample is discarded.

(a) Valid Sample (b) Invalid Sample

Figure 10: Examples of True Value Setting

5.2 Hyper-parameter Settings

In our experiment, we set the learning rate as 1e-5, training batch size as 1,024, and use Adam optimizer. We set the training epoch to 1 since the volume of the training data is big enough. In addition, we set a 1,000 steps warm-up period. After that, we evaluate the model every 100 steps of training and observe its performance.

5.3 Evaluation

With the same evaluation datasets and evaluation metrics, we compare our framework against several baselines. These baselines include Using Raw POIs, Using GeoHash Density Center, and Isolation Forest Clustering [13].

5.3.1 Evaluation Metrics. For each prediction, we compute the deviation distance between the predicted delivery points and the real couriers' check-in points to assess the precision and the practicability from the perspective of couriers. Hence, the general performance of our framework in large practices can be assessed according to the following formula:

$$\beta = \frac{\text{Numbers of } (\delta < \delta_{\text{thresh}})}{\text{Numbers of } (\delta)}, \quad \delta_{\text{thresh}} \in \{50, 100\} \quad (5)$$

where δ refers to a deviation distance, δ_{thresh} refers to the distance thresholds, which are, 50m or 100m in our scenario. β refers to a ratio of deviation distances less than a certain threshold.

In the POI mining task of the takeaway scene, POIs are usually buildings. According to observations on many real-world communities and statistical analysis on how the distance deviation impacts the delivery process, we find that the delivery is hardly affected if the deviation is less than 50m. A certain impact on the delivery process emerges when the deviation is between 50m and 100m. If the deviation is over 100m, the delivery process for the courier will become extremely difficult or even impossible. This analysis result

comes from the online business, and it is our prior knowledge towards the takeaway scene. Therefore, deviation thresholds, which are 50m and 100m, are applied in our evaluation.

5.3.2 Using Raw POIs from Geospatial Databases. The POI coordinates in the geospatial database are either manually collected or offered by third-party map providers. In general scenarios, most of these coordinates are accurate, but some of them perform poorly in the takeaway scene.

5.3.3 Using GeoHash Density Center. First, a GeoHash with the most coordinates is selected and then its density center is computed as the final prediction. In this way, the influence of some noises can be relieved, yet only the most high-heat GeoHash is taken into account, leading to a loss in information.

5.3.4 Isolation Forest Clustering. The principle of Isolation Forest Clustering is computing the geometric center of coordinates after denoising the raw coordinates in the largest GeoHash set by 20% by Isolation Forest. The advantages of this method are few parameters, strong generalization ability, and good performance in eliminating the influence of noise.

5.3.5 Comparison against Baselines. To make a fair evaluation, we build two evaluation datasets with data originated from two cities, namely Beijing and Shanghai, to reduce the bias from different regions. In each city, we extract waybills data with valid couriers' check-in points in a week and assess the performance of our framework and the baselines. The result is shown in Table 2. We use β_{Beijing} to indicate the results on the Beijing dataset, and β_{Shanghai} the results on the Shanghai dataset.

The results clearly show that delivery points predicted by our framework are much closer to the real couriers' check-in points, which indicates the real places where couriers deliver foods to users. In addition, the same trend is found in both Beijing and Shanghai datasets, revealing the robustness and good generalization of our method.

What's more, we also applied the predicted delivery points to supplement and calibrate the POI coordinates of Beijing and Shanghai in the geospatial database. Statistical analysis was performed on 508,441 POIs in total. We find that the delivery points generated by our framework can calibrate 42,537 POIs, accounting for 8.37%; and supplement 63,021 incremental building POIs that do not exist in the database before, accounting for 11.03% of the supplementary POIs.

5.4 Discussion

From the experiment results, we can infer that the delivery points have excellent performances in coordinates calibration. In this section, we discuss some interesting findings.

I. The unsatisfactory performance of raw POIs

a) The updates of geospatial databases traditionally rely on manual collections, which require long periods of work and have poor timeliness. With the rapid development of modern cities, new communities raging emerge, and the coordinates of many new buildings cannot be updated in time. Hence, POI coordinates lacking becomes a big issue.

b) The accuracy of the existing POIs is not high enough to meet our demand: After checking the positive and negative examples of the POI coordinates in the geospatial database. We discover that the deviations of the positive examples are relatively low and generally meet the demand. However, the negative examples have relatively large deviations, with much worse performance than the clustering algorithms and our framework in the long-tail cases.

c) Though using data from third-party map providers is an alternative, the high-precision data are often not provided due to commercial reasons.

d) Some user addresses are not clear or wrong. Vague addresses, addresses with extraneous information, and incomplete data in the geospatial database will complicate the geocoding process of user addresses, leading to wrong POI coordinates of these addresses.

Table 2: Comparison between Our Framework Against Different Baselines

Methods	δ_{thresh}	β_{Beijing}	β_{Shanghai}
Using Raw POIs	50m	43.42%	36.75%
	100m	71.91%	66.87%
GeoHash Density Center	50m	79.16%	86.64%
	100m	93.03%	**94.68**%
Isolation Forest	50m	79.55%	87.02%
	100m	93.40%	94.49%
Our Framework	50m	**85.83**%	**89.00**%
	100m	**94.40**%	93.37%

II. Our POI generation framework versus baseline methods

From the last section, we find that both our framework and typical clustering methods outperform the raw POI coordinates.

On the one hand, our framework shows the best performance within a 50m deviation distance. Two main reasons are accounting for this result. Our model not only extracts features from the distribution of waybills coordinates corresponding to the current address group but also considers the nearby address groups, avoiding the deviation caused by a few heavy users in the current address group. Plus, our framework is based on supervised learning with solid ground-truth labels, which is naturally stronger in performance than unsupervised clustering methods based on denoising or data density in a specific scenario.

On the other hand, we find that GeoHash Density Center and Isolation Forest partially outperform our framework in 100m deviation distance. To the best of our knowledge, the farther away from the true POI location, the more likely the courier check-in points are GPS noise. Hence, noise in check-in points between 50m and 100m away from true POI is significantly more than that within 50m. To tackle this problem, our proposed framework takes data of neighboring address groups as negative signals during training, and these negative signals neutralize the false-positive signals caused by the noise effectively. However, for the baseline methods, they can not leverage the negative signals to neutralize noise autonomously, and simply take all the clustered check-in points into account to calculate the current POI coordinate, thus overfitting the noisy data

(a) Case of a Small-Size AOI with Few POIs (b) Case of a Large-Size AOI with Many POIs

Figure 11: Overall Distribution Comparison between Delivery Point and True Value

Figure 12: General Results of Our Framework

and performing better than our proposed method in 100m deviation distance.

5.5 Case Analysis

As shown in Fig.11, the blue points are the delivery points generated by the framework, and the red points indicate the true value of those POIs. It's easy to find that the delivery points are close to the true value of those POIs. And these cases show delivery points have an excellent performance in indicating POIs of an AOI. What's more, we can also discover that the prediction performance of the model is stable, and is insensitive to area size and POI number of an AOI. We also make a large scope visualization of delivery points in Fig.12 which shows the general effectiveness of our framework. Fig.13 is two cases of delivery points calibrating deviated POIs in a geospatial database. Fig.13(a) is a case of a residential area, the user address parsing result is building 8, but the coordinate in the geospatial database locates at building 7 (the green marker symbol). In the actual delivery process, this kind of wrong coordinates will mislead the couriers and cause unnecessary detours. Luckily, our

(a) Case of a Residential Area (b) Case of an Industrial Park

Figure 13: Cases of Calibrating Deviated POIs in Geospatial Database

delivery point (the blue marker symbol) is located in the right place, and most of the courier check-in points (orange points) and user location points (purple points) are located around this delivery point. Fig.13(b) is a case of an industrial park. The coordinates in the geospatial database are shifted to building 15, but the user's real address is building 7. Our predicted delivery point location is consistent with the actual address described.

Two typical cases analyzed above demonstrate the effectiveness of delivery points to calibrate deviated POI coordinates.

6 POI SERVICE SYSTEM DEPLOYMENT

Our POI service system is demonstrated in Fig.14. POI generating framework obtains waybill data from the waybill data warehouse to generate POIs. If the generated POI has the same name as the origin POI from the POI data warehouse and is far away from each other, the origin POI will be replaced by generated POI as calibrated POI. If the generated POI name does not exist in the POI data warehouse, it will be taken as a new POI to complement the POI data warehouse. Making use of the calibrated POIs and new POIs, our POI service system will offer the final high-quality POI to the user interface.

In industrial practices, the lack of POI coordinates and text information on the map frontend makes users hard to select a correct position, hence results in difficulties for couriers to deliver food. As shown in Fig.15(a), before our POI Service System is deployed, users can not figure out the precise POIs as their addresses. Our POI Service System overcomes this problem by offering plenty of accurate POIs for users to choose from, as shown in Fig.15(b).

7 CONCLUSION

In this paper, we make the first attempt to infer the accurate coordinates of POIs by using behavioral data from users and couriers. We take advantage of an address parsing model to get rich users' addresses information and reorganize them according to two-level geographic hierarchies, which is also helpful for establishing user portrait. Leveraging on these preprocessing methods, we generate images of data distribution for each address group by density analysis of points within each GeoHash and then feed these images into U-Net to infer the accurate POI coordinates which are called delivery points. In the end, the results of two evaluative criteria show that the delivery points have a marvelous performance in reflecting

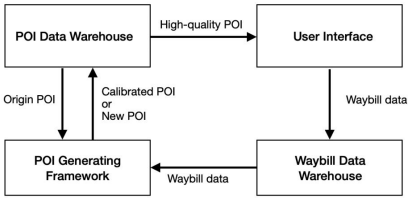

Figure 14: POI Service System Architecture

(a) Before Deployment (b) After Deployment

Figure 15: The Comparison of Before and After System Deployment

the actual locations where couriers deliver foods to users, much better than the original coordinates we used from the geospatial data warehouse. Similar results received in the experiments on different cities and AOIs reveal the robustness and good generalization of our framework.

In a word, we believe the entire framework developed presents a good example of combining image semantic segmentation and geospatial data mining, encouraging further works in geospatial data construction.

REFERENCES

[1] N. Abid, A. ul Hasan, and F. Shafait. 2018. DeepParse: A Trainable Postal Address Parser. In *2018 Digital Image Computing: Techniques and Applications (DICTA)*. 1–8. https://doi.org/10.1109/DICTA.2018.8615844

[2] Jindong Chen, Yizhou Hu, Jingping Liu, Yanghua Xiao, and Haiyun Jiang. 2019. Deep short text classification with knowledge powered attention. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 33. 6252–6259.

[3] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv:1810.04805 [cs.CL]

[4] Xuetao Ding, Runfeng Zhang, Zhen Mao, Ke Xing, Fangxiao Du, Xingyu Liu, Guoxing Wei, Feifan Yin, Renqing He, and Zhizhao Sun. 2020. Delivery Scope: A New Way of Restaurant Retrieval for On-demand Food Delivery Service. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 3026–3034.

[5] Tao-yang Fu and Wang-Chien Lee. 2019. DeepIST: Deep Image-based Spatio-Temporal Network for Travel Time Estimation. In *Proceedings of the 28th ACM International Conference on Information and Knowledge Management*. 69–78.

[6] Alberto Garcia-Garcia, Sergio Orts-Escolano, Sergiu Oprea, Victor Villena-Martinez, and José García Rodríguez. 2017. A Review on Deep Learning Techniques Applied to Semantic Segmentation. *CoRR* abs/1704.06857 (2017). arXiv:1704.06857 http://arxiv.org/abs/1704.06857

[7] Mengyue Hang, Ian Pytlarz, and Jennifer Neville. 2018. Exploring Student Check-In Behavior for Improved Point-of-Interest Prediction. *CoRR* abs/1811.06912 (2018). arXiv:1811.06912 http://arxiv.org/abs/1811.06912

[8] Mengyue Hang, Ian Pytlarz, and Jennifer Neville. 2018. Exploring student check-in behavior for improved point-of-interest prediction. In *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 321–330.

[9] Jing He, Xin Li, Lejian Liao, Dandan Song, and William K. Cheung. 2016. Inferring a Personalized next Point-of-Interest Recommendation Model with Latent Behavior Patterns. In *Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence* (Phoenix, Arizona) *(AAAI'16)*. AAAI Press, 137–143.

[10] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. 2017. Mask r-cnn. In *Proceedings of the IEEE international conference on computer vision*. 2961–2969.

[11] Tsung-Yi Lin, Piotr Dollár, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. 2017. Feature pyramid networks for object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2117–2125.

[12] Bin Liu and Hui Xiong. 2013. *Point-of-Interest Recommendation in Location Based Social Networks with Topic and Location Awareness*. 396–404. https://doi.org/10.1137/1.9781611972832.44

[13] Fei Tony Liu, Kai Ming Ting, and Zhi-Hua Zhou. 2008. Isolation Forest. In *2008 Eighth IEEE International Conference on Data Mining*. 413–422. https://doi.org/10.1109/ICDM.2008.17

[14] Jonathan Long, Evan Shelhamer, and Trevor Darrell. 2015. Fully Convolutional Networks for Semantic Segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.

[15] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. 2013. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781* (2013).

[16] Mor Naaman, Shane Ahern, Simon P King, and Rahul Nair. 2019. Location-based visualization of geo-referenced context. US Patent 10,318,110.

[17] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. 2015. U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical image computing and computer-assisted intervention*. Springer, 234–241.

[18] P. Wang, P. Chen, Y. Yuan, D. Liu, Z. Huang, X. Hou, and G. Cottrell. 2018. Understanding Convolution for Semantic Segmentation. In *2018 IEEE Winter Conference on Applications of Computer Vision (WACV)*. 1451–1460.

[19] Peng Wang, Bo Xu, Jiaming Xu, Guanhua Tian, Cheng-Lin Liu, and Hongwei Hao. 2016. Semantic expansion using word embedding clustering and convolutional neural network for improving short text classification. *Neurocomputing* 174 (2016), 806–814.

[20] Jingyun Xu, Yi Cai, Xin Wu, Xue Lei, Qingbao Huang, Ho-fung Leung, and Qing Li. 2020. Incorporating context-relevant concepts into convolutional neural networks for short text classification. *Neurocomputing* 386 (2020), 42–53.

[21] Hang Zhang, Kristin Dana, Jianping Shi, Zhongyue Zhang, Xiaogang Wang, Ambrish Tyagi, and Amit Agrawal. 2018. Context Encoding for Semantic Segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.

Learning Motion-Appearance Co-Attention for Zero-Shot Video Object Segmentation

Shu Yang[1], Lu Zhang[1], Jinqing Qi[1], Huchuan Lu[1], Shuo Wang[2], Xiaoxing Zhang[2]
[1]Dalian University of Technology, China
[2]Meituan, China
{yangshua, luzhang_dut}@mail.dlut.edu.cn, {jinqing, lhchuan}@dlut.edu.cn,
{wangshuo28, zhangxiaoxing}@meituan.com

Abstract

How to make the appearance and motion information interact effectively to accommodate complex scenarios is a fundamental issue in flow-based zero-shot video object segmentation. In this paper, we propose an Attentive Multi-Modality Collaboration Network (AMC-Net) to utilize appearance and motion information uniformly. Specifically, AMC-Net fuses robust information from multi-modality features and promotes their collaboration in two stages. First, we propose a Multi-Modality Co-Attention Gate (MCG) on the bilateral encoder branches, in which a gate function is used to formulate co-attention scores for balancing the contributions of multi-modality features and suppressing the redundant and misleading information. Then, we propose a Motion Correction Module (MCM) with a visual-motion attention mechanism, which is constructed to emphasize the features of foreground objects by incorporating the spatio-temporal correspondence between appearance and motion cues. Extensive experiments on three public challenging benchmark datasets verify that our proposed network performs favorably against existing state-of-the-art methods via training with fewer data. The code is released at `https://github.com/isyangshu/AMC-Net`.

1. Introduction

Zero-shot Video Object Segmentation (ZVOS) aims to automatically separate the primary object(s) from the background in a video sequence without any human interaction. Since ZVOS does not require manual intervention, it has significant value in a wide range of applications, such as video compression [11], visual tracking [45], and person re-identification [51]. How to distinguish the target object(s) from complex and diverse background without any prior knowledge is an open challenge in ZVOS.

To address this issue, several methods [38, 21, 1, 19, 53] design various multi-modality interaction schemes to leverage external object motion information, which hypothesizes that the object moving across the video sequence is highly related to the primary object. Despite the impressive performance, there remain some issues in existing interaction approaches. Early methods [38, 21, 1] directly execute feature alignment such as concatenation or addition to produce object masks (see Figure 1 (a)). Due to the redundant and invalid information in flow maps and video frames, the direct feature alignment of multi-modality features would limit the accuracy of segmentation (see the third column in Figure 2). Several methods [53, 19] propose to build a motion-based attention mechanism to enhance the feature learning of object appearance (see Figure 1 (b)). These methods learn to

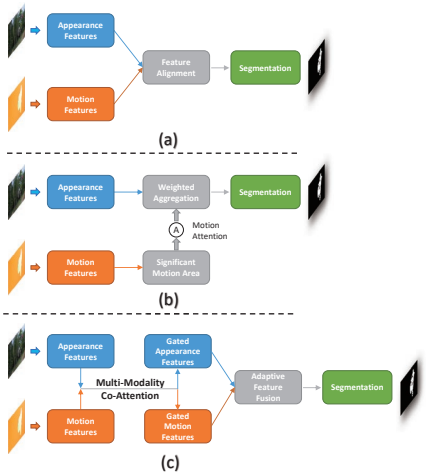

Figure 1. Illustration of various multi-modality interaction approaches for fusing appearance and motion information.

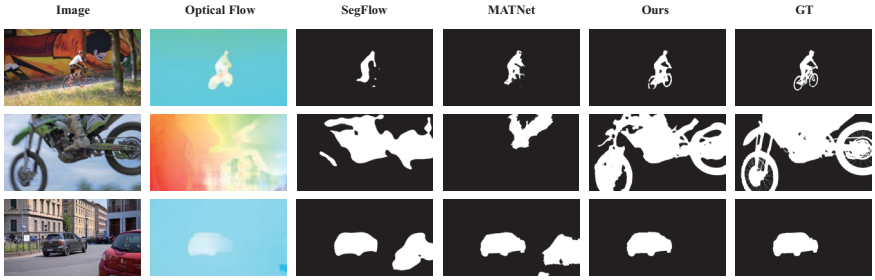

Figure 2. Visual comparison of different flow-based methods. We show the video frames, optical flow maps, SegFlow [1] predictions, MATNet [53] predictions, and our predictions in the ***bmx-trees***, ***motocross-jump***, and ***car-roundabout*** video sequences. The optical flow maps are predicted by PWCNet [35].

enhance the appearance features of the significant motion areas, which makes them rely on the quality of optical flow. However, when complex motion conditions (e.g., deformation, motion blur, fast motion, and clutters) occur in the video sequence, optical flow might fail to capture the object location and influence the accuracy of object segmentation (see the fourth column in Figure 2).

Motivated by the above observations, in this paper, we propose an Attentive Multi-Modality Collaboration Network (AMC-Net) for zero-shot video object segmentation, which builds a novel co-attention mechanism for effective multi-modality interaction. AMC-Net adaptively fuses robust spatio-temporal representations from multi-modality features and promotes their collaboration in two stages to thoroughly combine the merits of appearance and motion features (see Figure 1 (c)). In the first stage, we propose a Multi-Modality Co-Attention Gate (MCG), which is used to unify the appearance and motion information into valid spatio-temporal feature representations. Considering the disparity of the contributions of different modality features, we utilize a gate function to predict the co-attention scores, which are used to balance the contributions of multi-modality features and suppress the redundant and misleading information. In the second stage, we propose a Motion Correction Module (MCM) to perform adaptive feature fusion, in which a visual-motion attention mechanism is constructed to emphasize the features of foreground objects by incorporating the spatio-temporal correspondence between appearance and motion cues. Specifically, different from the single-directional attention guidance from motion to appearance, we model the attention based on visual saliency and motion saliency to facilitate the feature learning of foreground objects.

To investigate the effectiveness of our proposed model, we conduct comprehensive experiments including overall comparison and ablation studies on three benchmark datasets [31, 33, 29]. The results show that our proposed method can achieve superior performance against the state-of-the-arts by using only DAVIS-16 [31] for training.

Our contributions can be summarized as follows:

• We propose an Attentive Multi-Modality Collaboration Network for zero-shot video object segmentation, which promotes deep collaboration of appearance and motion information to generate accurate object segmentation.

• We propose a Multi-Modality Co-Attention Gate to unify the multi-modality information. A gate function is used to produce co-attention scores to adaptively balance the contributions of appearance and motion information.

• Our proposed method performs favorably against the state-of-the-art methods on three public challenging benchmark datasets (DAVIS-16 [31], Youtube-Objects [33], and FBMS [29]).

2. Related work

According to whether the manual intervention is required during testing, video object segmentation (VOS) can be broadly categorized into *zero-shot* (ZVOS) and *one-shot* (OVOS). In this paper, we focus on an object-level ZVOS setting (i.e., do not discriminate different instances), which extracts primary object(s) without manual annotation.

Zero-shot video object segmentation aims to automatically generate masks of the primary objects in the video sequence without any human interaction, which is also called unsupervised video object segmentation (UVOS) [14, 18, 32, 49, 21]. Early non-learning methods based on hand-crafted features leverage low-level cues, such as visual saliency information [42, 9, 5, 39], object proposals [18, 27, 49, 14, 6], or optical flow [16, 21, 13, 20, 30], which are used as reliable prior knowledge to guide object segmentation. Later, inspired by the success of deep learning on segmentation tasks, more research efforts focus on

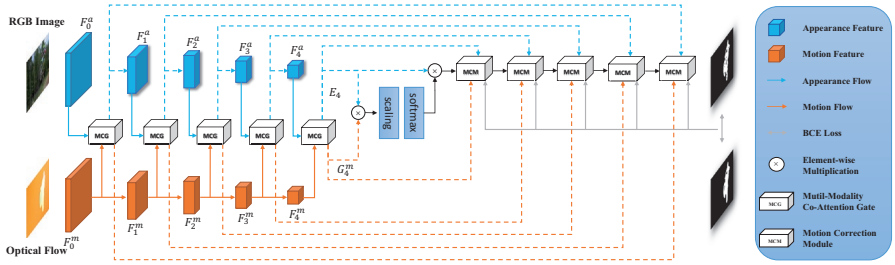

Figure 3. Overview of Attentive Multi-Modality Collaboration Network (AMC-Net). Given an input frame and the corresponding optical flow map, we first use bilateral encoder branches to extract multi-modality features. Then we adopt multi-level MCG on multiple encoder side outputs to filter information and unify robust information into spatio-temporal feature representations. Finally, we stack multiple MCMs in a coarse-to-fine manner to produce final predictions.

fully convolutional networks based ZVOS models. For example, several methods [34, 38, 43] use variants of recurrent neural networks to store previously computed segmentation information implicitly. Inspired by the non-local operation, COSNet [26], AGNN [41] and AnDiff [48] model the long-term correlations between frames to explore global information and gain a more comprehensive understanding of the video contents. WCS [50] encodes the pixel-wise correspondence between frames and takes object hotspots as guidance to enhance the influence of salient regions. 3DC-Seg [28] leverages 3D convolution to jointly learn spatial and temporal features. Recent method [25] proposes episodic graph memory to store cross-frame correlations and learn to update the segmentation model.

An alternative choice is to extract effective guidance about motion information from optical flow. LMP [37] discards the modeling of appearance features and purely relies on optical flow to predict foreground motion, which results in incorrect results for static foreground objects. To address this issue, several flow-based approaches [38, 1, 12, 19, 53] generally adopt dual-branch full convolution networks with feature fusion schemes, e.g., concatenation or attention mechanism, to aggregate appearance and motion information. Without considering the disparity of the contributions of multi-modality features, recent flow-based methods [19, 53] only consider the one-directional attention guidance from motion to appearance and enhance the appearance features of significant motion areas. When motion or appearance information is not significant from the background, these methods can not achieve satisfactory results which are shown in Figure 2. In this work, we consider the importance of deep collaboration between appearance and motion in learning richer spatio-temporal feature representations. We propose an Attentive Multi-Modality Collaboration Network (AMC-Net) to fuse robust information from multi-modality features and promote their collaboration for accurate zero-shot video object segmentation.

3. Method

3.1. Architecture Overview

In this work, we propose an Attentive Multi-Modality Collaboration Network (AMC-Net) for accurate zero-shot video object segmentation, which constructs a two-stage multi-modality integration system. The framework of our AMC-Net is shown in Figure 3. Specifically, given an input frame $I \in \mathbb{R}^{H\times W\times 3}$ and the corresponding flow map $O \in \mathbb{R}^{H\times W\times 3}$, we employ parallel encoder branches to capture the multi-level appearance and motion features, which are represented as $\{F_i^a\}_{i=0}^4$ and $\{F_i^m\}_{i=0}^4$. In the first stage, with the appearance feature F_i^a and motion feature F_i^m as input, a Multi-Modality Co-Attention Gate (MCG) is proposed to suppress the interference from redundant and invalid information and obtain effective spatio-temporal feature representations. We implement MCG on multi-level encoder side outputs to integrate the multi-modality features and propagate more valuable feature representations to the decoder. In the second stage, we use Motion Correction Module (MCM) to further emphasize the features of foreground objects by constructing a visual-motion attention mechanism. We stack multiple MCMs in a coarse-to-fine manner to facilitate the feature learning of foreground objects and generate the final segmentation results.

3.2. Multi-Modality Co-Attention Gate

Recent flow-based methods [19, 53] explore the appearance features of significant motion areas and utilize single-directional attention guidance from motion to appearance, which makes them rely on the dominant motion in the scene and ignore inherent noises in optical flow maps or images. In this paper, we propose a Multi-Modality Co-Attention Gate (MCG) for attentive motion-appearance interaction. We identify effective information from motion and appearance, and integrate cross-modality features into unified spatio-temporal feature representations.

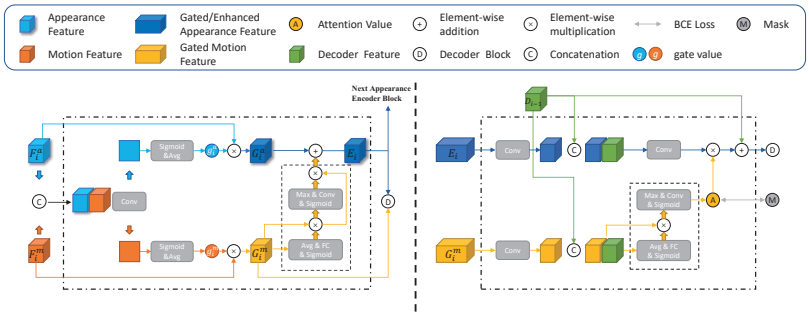

Figure 4. Frameworks of Multi-Modality Co-Attention Gate (*left*) and Motion Correction Module (*right*).

The framework of MCG is shown in Figure 4. Given an appearance feature F_i^a and a motion feature F_i^m at level i, we first combine them using cross-channel concatenation and convolution operation for implicit interaction, which aligns the motion feature with the appearance feature and helps to capture the relative relationship between multi-modality features. Then we obtain the fused feature $H \in \mathbb{R}^{h\times w\times 2}$ and spilt the channel-wise feature maps to two sub-branches. We perform the sigmoid function and global average pooling on each channel to obtain a pair of co-attention scores g_i^a and g_i^m, which reflect the importance of each modality feature on the final result. Specifically, we integrate the features from appearance and motion to formulate gate function, which plays the role of modality-wise attention and models the overall distribution of the contributions of multi-modality features in the network from global perspective. The entire gate function can be formulated as

$$g_i = Avg(\sigma(Conv(Cat(F_i^a, F_i^m)))), \tag{1}$$

where g_i contains a pair of co-attention scores g_i^a and g_i^m. $Avg(\cdot)$ is the global average pooling. σ denotes sigmoid function scaling the weight value into (0, 1). $Conv(\cdot)$ refers to the convolution layer with output channel 2 and $Cat(\cdot)$ is the concatenation operation among channel axis. In Figure 5, we give some visual examples of the co-attention scores in various videos. The tagged values show the disparity of the contributions of images and corresponding optical flow maps. A higher co-attention score indicates that the corresponding modality feature contains effective information for accurate segmentation. On the contrary, the modality feature with a lower score may contain noise that affects performance.

We apply the co-attention scores to the corresponding features to generate gated appearance feature G_i^a and gated motion feature G_i^m,

$$G_i^a = F_i^a * g_i^a, G_i^m = F_i^m * g_i^m, \tag{2}$$

which can be viewed as suppressing redundant and misleading information and enhancing more effective information. By assigning reliability scores for appearance and motion features, the network would not rely too much on either of the two information. It learns to adaptively exploit the merits of appearance and motion information to obtain satisfactory results. Considering the uncertainty of the predicted flow maps, we use channel-wise and spatial-wise attentions on motion features to emphasize the motion areas. Instead of treating all channels equally, we first build the inter-channel relationship of G_i^m,

$$M' = \sigma(MLP_{fc}(Avg(G_i^m))) * G_i^m, \tag{3}$$

where MLP_{fc} denotes fully connected layers. By doing this, we strengthen the responses of multi-level attributes, including texture, boundaries, color and semantics. Then we utilize the inter-spatial relationship of M' to emphasize the spatial locations of salient motion areas,

$$M'' = \sigma(MLP_{conv}(Max(M')) * M', \tag{4}$$

where MLP_{conv} denotes convolution layers and $Max(\cdot)$ is the global max pooling. We emphasize the features closely associated with motion-salient objects, which can take advantage of more effective salient motion information and temporal features. With the implicit interaction of appearance and motion information, we can aggregate features complementarily to obtain unified spatio-temporal feature representations. We devise the aggregation operation as an element-wise addition of the two modalities,

$$E_i = G_i^a + M''. \tag{5}$$

E_i is fed to the next stage of the appearance branch and exploited in the decoder for mask generation. In particular, G_i^m is applied to the decoder instead of the next stage

Figure 5. Visual samples of the co-attention scores. We show various video frames and the corresponding flow maps, along with the tagged scores to characterize the disparity of the contributions in *motocross-jump*, *blackswan*, *bmx-trees* and *soapbox*.

of the motion branch, ensuring the effectiveness of motion features during the long-term spread.

In order to capture the global features of primary objects, we compute the similarity between temporal and spatial information on the last encoder block. Specifically, we calculate a similarity matrix P to establish dense correspondences between each pair of pixels from gated motion feature G_4^m and enhanced appearance feature E_4. Similarly to [44], we combine the similarity matrix P with E_4 to yield the attention-enhanced feature map $\hat{E}_4$,

$$\hat{E}_4 = softmax(\frac{1}{\sqrt{c}} G_4^m \odot E_4^T) \odot E_4, \tag{6}$$

where $\odot$ indicates matrix multiplication. Following [23, 40], we scale the dot product by $\frac{1}{\sqrt{c}}$, where c is the channel size of G_4^m and E_4.

3.3. Motion Correction Module

With the adaptively multi-modality interaction by MCG, we obtain effective spatial-temporal correspondence encoder features, which may be well-aligned with the primary foreground objects in frames. Considering the complex scenes in video sequences, we unify the visual and motion significant areas to correct the intermediate features. We employ Motion Correction Module (MCM) to leverage appearance and motion features to supplement effective details and suppress the activation of non-salient regions. Besides, we construct visual-motion attention to emphasize the features of foreground objects by combining visual and motion cues. The details of MCM are shown in Figure 4.

Taking the gated motion feature G_i^m, enhanced appearance feature E_i from MCG and the decoder feature D_{i-1} from the previous decoder block as input, MCM aims to promote deep collaboration further to generate accurate results. When the previous decoding step is not available, we use $\hat{E}_4$ as the decoder feature to provide global information. One branch of the parallel branch aims to fuse visual saliency and motion saliency to extract visual-motion attention. This operations could be formulated as

$$F = Cat(Up(D_{i-1}), G_i^m), \tag{7}$$

where $Up(\cdot)$ is the upsampling operation with stride 2. Then we exploit the inter-channel relationship of fused feature F to improve the channel response of the significant information (visual or motion),

$$F' = \sigma(MLP_{fc}(Avg(F))) * F. \tag{8}$$

We select and strengthen the responses with higher significance. Then we utilize the inter-spatial relationship to calculate the comprehensive responses (visual and motion) of each pixel to generate attention maps,

$$A = \sigma(MLP_{conv}(Max(F')), \tag{9}$$

where A refers to the visual-motion attention, which can be viewed as salient areas to suppress the activation of background and facilitate the feature learning of foreground objects. We argue these attention maps should be consistent with the final mask and equally weigh the cross-entropy loss for both the intermediate attention maps and the final prediction.

The other branch is designed as a residual structure, which is used to enhance the details of D_{i-1} by encoder features E_i with higher resolution. Finally, we combine A with the fused feature to correct feature and add D_{i-1} to obtain D_i. The entire process can be formulated as

$$D_i = Conv(Cat(Up(D_{i-1}), E_i)) \cdot A + D_{i-1}, \tag{10}$$

where $\cdot$ refers to element-wise multiplication.

3.4. Training and Inference

Implementation details. Following the most state-of-the-art flow-based methods, we take the ResNet-101 [8] pre-trained on ImageNet [3] as backbone. Given the current frame I_t and next frame I_{t+1}, we adopt PWCNet [35] to formulate optical flow maps O_t. Unlike the training strategy of other methods, we only use DAVIS-16 for training without applying any image datasets [47, 2, 22].

Training. Given images and optical flow maps as input, we train the model for 100 epochs with a mini-batch size as 4. We resize the images and flow maps to 384×384 for the balance between speed and performance. We adopt stochastic gradient descent (SGD) to train our AMC-Net, where the momentum, weight decay, and initial learning rate are set as 0.9, 0.0005 and 0.001. We use the "poly" policy [24] with the power of 0.9 to adjust the learning rate during training. We conduct data augmentation with random horizontally flipping and random rotation to avoid over-fitting and make the learned model more robust.

Inference. We use the same resolution 384×384 for each testing video sequence without any data augmentation and human interaction. Following the common protocol in ZVOS, we employ the fully-connected CRF [17] to obtain the final binary segmentation results.

Method	$\mathcal{J}$ mean ↑	$\mathcal{F}$ mean ↑	$\mathcal{J}\&\mathcal{F}$ ↑
Baseline	77.4	77.4	77.4
+ Multi-Modality Co-Attention Gate			
w/o gate	78.5(+1.1)	78.9(+1.5)	78.7(+1.3)
w/ gate	80.7(+3.3)	81.3(+3.9)	81.0(+3.6)
+ Motion Correction Module			
single MCM	81.1(+0.4)	81.7(+0.4)	81.4(+0.4)
3 stacked MCMs	81.9(+1.2)	83.9(+2.6)	82.9(+1.9)
5 stacked MCMs	83.0(+2.3)	84.3(+3.0)	83.7(+2.7)
+ Fully-Connected CRF			
AMC_{pwc} w/ crf	84.2(+1.2)	84.5(+0.2)	84.4(+0.7)
+ Better Quality Optical Flow			
AMC_{raft} w/ crf	84.5(+0.3)	84.6(+0.1)	84.6(+0.2)

Table 1. Ablation analysis of our proposed AMC-Net on DAVIS-16, measured by the $\mathcal{J}$ mean, $\mathcal{F}$ mean and $\mathcal{J}\&\mathcal{F}$. Red indicates the performance improvement compared to the previous setting.

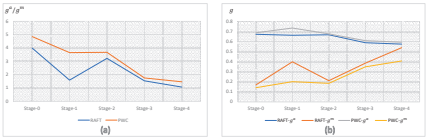

Figure 6. Distribution of the co-attention scores at each stage. With the convolution stage as the horizontal axis, we statistically demonstrate the curves about g^a/g^m in (a), evaluating the relative importance between multi-modality features. Meanwhile, we demonstrate the curves of co-attention scores g_i^a and g_i^m in (b).

Runtime. For each test image of size 384 × 384 × 3, the forward inference of our AMC-Net takes about 0.057s with a single Nvidia 1080Ti GPU.

4. Experiments

4.1. Dataset and Metrics

To evaluate the performance of our proposed method AMC-Net, we conduct comparison experiments on three public challenging benchmark datasets, including DAVIS-16 [31], Youtube-Objects [33] and FBMS [29].

DAVIS-16 consists of total 50 high-quality video sequences with 3455 densely annotated frames. We use 30 video sequences for training and the remaining 20 for testing. Each frame contains pixel-precise annotation of only one foreground object.

Youtube-Objects contains 126 video sequences of 10 object categories. The ground-truth in Youtube-Objects is sparsely labeled in every ten frames.

FBMS is comprised of 59 video sequences, with only 720 frames sparsely annotated. Certain video sequences are annotated with multiple target foreground objects.

Stage	w/o	0	0-1	0-2	0-3	0-4
$\mathcal{J}\&\mathcal{F}$	81.1	82.7	82.8	83.2	83.5	83.7

Table 2. Effectiveness of the Multi-Modality Co-Attention Gate (MCG) at multiple encoder side on DAVIS-16.

Supervision	0	1	2	3	4	5
$\mathcal{J}\&\mathcal{F}$	81.5	82.6	82.7	82.7	83.5	83.7

Table 3. Performance comparisons with different numbers of supervision for visual-motion attention on DAVIS-16.

Model	MATNet [53]	AMC-Net	AMC-Net	AMC-Net
Flow Model	PWCNet [35]	FlowNetS [4]	FlowNet2CS [10]	PWCNet [35]
$\mathcal{J}\&\mathcal{F}$	81.6	80.5	83.1	84.4

Table 4. Performance comparisons with different quality of optical flow maps on DAVIS-16.

4.2. Ablation Study

In this section, we conduct ablation studies of AMC-Net on the DAVIS-16. We add each component into the network in turn to verify the effectiveness. In Table 1, we report detailed results in terms of $\mathcal{J}$ mean, $\mathcal{F}$ mean and their average $\mathcal{J}\&\mathcal{F}$. To analyze the contribution of each component, we implement a simple baseline by employing bilateral encoder branches with performing a concatenation to integrate the multi-modality cues (as shown in Figure 1 (a)).

Effectiveness of Multi-Modality Co-Attention Gate. By adding MCG into the baseline, the model ("w/ gate") significantly outperforms the baseline by 3.6% on $\mathcal{J}\&\mathcal{F}$. To investigate the effect of our proposed gate function, we implement a variant ("w/o gate") without the gate function. This variant encounters a huge performance degradation (2.2% in $\mathcal{J}$ mean and 2.4% in $\mathcal{F}$ mean), which demonstrates the effectiveness of the gate function. Furthermore, we add MCG into the bilateral encoder branches in turn from the first stage and use simple feature aggregation at other stages. As shown in Table 2, MCG propagates more valuable information while minimizing interference.

Effectiveness of Motion Correction Module. To explore the impact of the number of stacked MCMs on performance, we first deploy a single MCM on the last decoder block, which has an improvement of 0.4% on $\mathcal{J}\&\mathcal{F}$. The variant ("3 stacked MCMs") with MCMs staked at last three decoder blocks achieves gains of 1.2% and 2.6% on $\mathcal{J}$ mean and $\mathcal{F}$ mean, respectively. When we use MCMs on all decoder blocks, the variant ("5 stacked MCMs") achieves the highest performance with a $\mathcal{J}$ mean score of 83.0. In addition, we explore the impact of the visual-motion attention mechanism on performance with five stacked MCMs. In Table 3, we report the results of adding supervision for visual-motion attention in turn from the first decoder block.

Effect of the quality of optical flow maps. To verify the effect of the optical flow quality on our full model, we first implement a variant (AMC_{raft}) by using the op-

Model	Operations				Metrics $\mathcal{J}$			Metrics $\mathcal{F}$			$\mathcal{J}$ & $\mathcal{F}$
	S	D	Y	PP	Mean ↑	Recall ↑	Decay ↓	Mean ↑	Recall ↑	Decay ↓	
SFL [1]		✓		✓	67.4	81.4	6.2	66.7	77.1	5.1	67.1
LMP [37]	✓	✓		✓	70.0	85.0	1.3	65.9	79.2	2.5	68.0
PDB [34]	✓	✓		✓	77.2	90.1	0.9	74.5	84.4	-0.2	75.9
ARP [14]		✓			76.2	89.1	7.0	70.6	83.5	7.9	73.4
AGS [43]	✓	✓		✓	79.7	91.1	1.9	77.4	85.8	1.6	78.6
COSNet [26]	✓	✓		✓	80.5	93.1	4.4	79.5	89.5	5.0	80.0
AGNN [41]	✓	✓		✓	80.7	94.0	**0.0**	79.1	90.5	**0.0**	79.9
ANDiff [48]	✓	✓		✓	81.7	90.9	2.2	80.5	85.1	0.6	81.1
MATNet [53]		✓	✓*	✓	82.4	94.5	5.5	80.7	90.2	4.5	81.6
EGMN [25]	✓	✓		✓	82.5	94.3	4.2	81.2	90.3	5.6	81.9
WCS [50]	✓	✓			82.2	-	-	80.7	-	-	81.5
DFNet [52]	✓	✓		✓	83.4	-	-	81.8	-	-	82.6
3DC-Seg [28]		✓			-	-	-	-	-	-	82.2
3DC-Seg* [28]	✓	✓	✓		84.3	95.7	7.4	**84.7**	92.6	5.2	84.5
Ours		✓		✓	84.2	96.0	3.5	84.5	**94.4**	2.2	84.4
Ours-$raft$		✓		✓	**84.5**	**96.4**	2.8	84.6	93.8	2.5	**84.6**

Table 5. Overall comparison with the state-of-the-arts on DAVIS-16 validation dataset. Use "✓" in the table to indicate whether the method uses the static segmentation datasets (S), DAVIS-16 (D), Youtube-VOS (Y) or Post-processing (PP). The "✓*" in the Y-column indicates that MATNet uses a subset of 12K frames selected from the training set of Youtube-VOS.

Model	Aeroplane	Bird	Boat	Car	Cat	Cow	Dog	Horse	Motorbike	Train	Avg ↑
ARP [14]	73.6	56.1	57.8	33.9	30.5	41.8	36.8	44.3	48.9	39.2	46.2
FST [30]	70.9	70.6	42.5	65.2	52.1	44.5	65.3	53.5	44.2	29.6	53.8
SFL [1]	65.6	65.4	59.9	64.0	58.9	51.1	54.1	64.8	52.6	34.0	57.0
PDB [34]	78.0	80.0	58.9	76.5	63.0	64.1	70.1	67.6	58.3	35.2	65.4
FSEG [12]	81.7	63.8	72.3	74.9	68.4	68.0	69.4	60.4	62.7	62.2	68.4
MATNet [53]	72.9	77.5	66.9	79.0	73.7	67.4	75.9	63.2	62.6	51.0	69.0
AGS [43]	87.7	76.7	72.2	78.6	69.2	64.6	73.3	64.4	62.1	48.2	69.7
COSNet [26]	81.1	75.7	71.3	77.6	66.5	69.8	76.8	67.4	67.7	46.8	70.5
AGNN [41]	81.1	75.9	70.7	78.1	67.9	69.7	77.4	67.3	68.3	47.8	70.8
WCS [50]	81.8	81.2	67.6	79.5	65.8	66.2	73.4	69.5	69.3	49.7	70.9
EGMN [25]	86.1	75.7	68.6	82.4	65.9	70.5	77.1	72.2	63.8	47.8	**71.4**
Ours	78.9	80.9	67.4	82.0	69.0	69.6	75.8	63.0	63.4	57.8	71.1

Table 6. Overall comparison with the state-of-the-arts on Youtube-Objects dataset. We report the per-category performance and the average result of the 10 categories with $\mathcal{J}$ mean.

tical flow maps generated by a more accurate network RAFT [36]. Compared to AMC_{pwc}, AMC_{raft} has an improvement of 0.3%, 0.1% in terms of the $\mathcal{J}$ mean and $\mathcal{F}$ mean, respectively. Furthermore, we implement several variants to use the optical flow maps in slightly inferior quality calculated by FlowNetS [4] and FlowNet2CS [10]. As shown in Table 4, all of the network variants produce competitive results, which demonstrates that our proposed model can benefit from optical flow of different quality and adaptively fuse multi-modality features.

Effect of optical flow quality on co-attention scores. In order to qualitatively measure the effect of optical flow quality on co-attention scores, we calculate the average scores of appearance and motion features from AMC_{pwc} and AMC_{raft}. As shown in Figure 6 (a), we compute g^a/g^m to evaluate the relative importance between appearance and motion features. For both AMC_{pwc} and AMC_{raft}, the high-level ratios g^a/g^m are significantly smaller than the low-level ones. The relative importance of optical flow maps gradually increases with the promotion of levels. More importantly, compared to AMC_{pwc}, AMC_{raft} gets lower ratios at low-level. In Figure 6 (b), we statistically demonstrate the curves of co-attention scores g_i^a and g_i^m. It can be seen that the high-level motion features contribute more effective guidance than low-level ones. This trend is just the opposite of the appearance features. Since AMC_{raft} uses flow maps with more precise image boundary details, its gate values corresponding to low-level motion features significantly increase. It can be seen that AMC-Net can adaptively and fully combine the merits of appearance and motion features.

Figure 7. Qualitative results on three video sequences from DAVIS-16. From top to bottom: *motocross-jump*, *dance-twirl*, *horsejump-high*.

Method	NLC [5]	FST [30]	SFL [1]	ARP [14]
$\mathcal{J}$ mean ↑	44.5	55.5	56.0	59.8
Method	MSTP [9]	FSEG [12]	IET [20]	OBN [21]
$\mathcal{J}$ mean ↑	60.8	68.4	71.9	73.9
Method	PDB [34]	COSNet [26]	MATNet [53]	Ours
$\mathcal{J}$ mean ↑	74.0	75.6	76.1	**76.5**

Table 7. Overall comparison with the state-of-the-arts on FBMS. We use the mean region similarity ($\mathcal{J}$ mean) to measure the segmentation performance.

4.3. Quantitative and Qualitative Results

Evaluation on DAVIS-16. We compare the performance of our proposed method with the state-of-the-art methods. In Table 5, we list comparison results with ZVOS methods. We list the datasets widely used in existing methods, including DAVIS-16 [31], Youtube-VOS [46], and static segmentation datasets (DUT [47], MSRA10k [2], COCO [22], etc). Besides, we provide the indicator of post-processing (PP) in the existing methods. Compared with the existing ZVOS methods, our model outperforms the best performance 3DC-Seg [28] by 0.1% on $\mathcal{J}\&\mathcal{F}$. In addition, compared to our proposed method, 3DC-Seg uses pre-trained weights from much larger video datasets IG-65M [7] and Kinetics [15] (65.8M video clips), and further fine-tunes jointly on three datasets [22, 46, 31] to yield the best score.

Evaluation on Youtube-objects. Table 6 illustrates the results of all compared methods for different categories. Our proposed method is comparable with recent ZVOS methods AGS [43], AGNN [41] and WCS [50] across all categories. Since memory mechanism can better handle static objects in video sequences, EGMN [25] achieves a higher $\mathcal{J}\&\mathcal{F}$ score (0.3%) on YTB-Objects.

Evaluation on FBMS. Multiple target objects labeled in the video sequence share a similar appearance but have different motion patterns (moving or non-moving), which weakens the role of optical flow in the corresponding scene. In order to deal with the above problem, we design a variant by adding a separate FCN-like decoder that uses the gated appearance features from MCG. We train the entire network variant on DAVIS-16 and combine two decoder branches to produce the final results. Table 7 shows that our proposed method performs better than the state-of-the-art methods.

Qualitative results. As shown in Figure 7, we illustrate the segmentation results of our proposed method on three video sequences. These three video sequences contain some tough challenges: *Deformation*, *Scale-Variation*, etc. The qualitative results show that our method can cope well with the tough challenges posed by the tricky motion conditions in the video sequences and generate precise segmentation masks with well-defined details.

5. Conclusion

In this paper, we propose an Attentive Multi-Modality Collaboration Network for ZVOS, which adopts a novel mechanism to achieve deep collaboration between appearance and motion. AMC-Net adaptively fuses robust information from multi-modality features and promotes their collaboration in two stages. We first adopt multi-level MCG to balance the contributions of multi-modality features at each stage and suppress redundant and misleading information, propagating valid spatio-temporal feature representations while minimizing interference. Then we adopt five stacked MCMs with a visual-motion attention mechanism to emphasize the features of foreground objects utilizing the spatio-temporal correspondence between appearance and motion cues. The experimental results on three benchmarks demonstrate that AMC-Net learns from fewer data and outperforms existing competitors. We yield a neat yet effective framework with a novel strategy for the interaction of motion and appearance information, which will generalize well to ZVOS in complex scenes.

Acknowledgments

The paper is supported by the National Natural Science Foundation of China under Grant No.U1903215, No.61829102, No.61725202, and the Dalian Innovation leader's support Plan under Grant No.2018RD07. This research is also supported by Meituan.

References

[1] Jingchun Cheng, Yi-Hsuan Tsai, Shengjin Wang, and Ming-Hsuan Yang. Segflow: Joint learning for video object segmentation and optical flow. In *ICCV*, pages 686–695, 2017.

[2] Ming-Ming Cheng, Niloy J Mitra, Xiaolei Huang, Philip HS Torr, and Shi-Min Hu. Global contrast based salient region detection. *IEEE transactions on pattern analysis and machine intelligence*, 37(3):569–582, 2014.

[3] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *CVPR*, pages 248–255, 2009.

[4] Alexey Dosovitskiy, Philipp Fischer, Eddy Ilg, Philip Hausser, Caner Hazirbas, Vladimir Golkov, Patrick Van Der Smagt, Daniel Cremers, and Thomas Brox. Flownet: Learning optical flow with convolutional networks. In *ICCV*, pages 2758–2766, 2015.

[5] Alon Faktor and Michal Irani. Video segmentation by non-local consensus voting. In *BMVC*, page 8, 2014.

[6] Huazhu Fu, Dong Xu, Bao Zhang, and Stephen Lin. Object-based multiple foreground video co-segmentation. In *CVPR*, pages 3166–3173, 2014.

[7] Deepti Ghadiyaram, Du Tran, and Dhruv Mahajan. Large-scale weakly-supervised pre-training for video action recognition. In *CVPR*, pages 12046–12055, 2019.

[8] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, pages 770–778, 2016.

[9] Yuan-Ting Hu, Jia-Bin Huang, and Alexander G Schwing. Unsupervised video object segmentation using motion saliency-guided spatio-temporal propagation. In *ECCV*, pages 786–802, 2018.

[10] Eddy Ilg, Nikolaus Mayer, Tonmoy Saikia, Margret Keuper, Alexey Dosovitskiy, and Thomas Brox. Flownet 2.0: Evolution of optical flow estimation with deep networks. In *CVPR*, pages 2462–2470, 2017.

[11] Laurent Itti. Automatic foveation for video compression using a neurobiological model of visual attention. *IEEE transactions on image processing*, 13(10):1304–1318, 2004.

[12] Suyog Dutt Jain, Bo Xiong, and Kristen Grauman. Fusionseg: Learning to combine motion and appearance for fully automatic segmentation of generic objects in videos. In *CVPR*, pages 2117–2126, 2017.

[13] Won-Dong Jang, Chulwoo Lee, and Chang-Su Kim. Primary object segmentation in videos via alternate convex optimization of foreground and background distributions. In *CVPR*, pages 696–704, 2016.

[14] Yeong Jun Koh and Chang-Su Kim. Primary object segmentation in videos based on region augmentation and reduction. In *CVPR*, pages 3442–3450, 2017.

[15] Will Kay, Joao Carreira, Karen Simonyan, Brian Zhang, Chloe Hillier, Sudheendra Vijayanarasimhan, Fabio Viola, Tim Green, Trevor Back, Paul Natsev, et al. The kinetics human action video dataset. *arXiv preprint arXiv:1705.06950*, 2017.

[16] Margret Keuper, Bjoern Andres, and Thomas Brox. Motion trajectory segmentation via minimum cost multicuts. In *ICCV*, pages 3271–3279, 2015.

[17] Philipp Krähenbühl and Vladlen Koltun. Efficient inference in fully connected crfs with gaussian edge potentials. In *Advances in neural information processing systems*, pages 109–117, 2011.

[18] Yong Jae Lee, Jaechul Kim, and Kristen Grauman. Key-segments for video object segmentation. In *ICCV*, pages 1995–2002, 2011.

[19] Haofeng Li, Guanqi Chen, Guanbin Li, and Yizhou Yu. Motion guided attention for video salient object detection. In *ICCV*, pages 7274–7283, 2019.

[20] Siyang Li, Bryan Seybold, Alexey Vorobyov, Alireza Fathi, Qin Huang, and C-C Jay Kuo. Instance embedding transfer to unsupervised video object segmentation. In *CVPR*, pages 6526–6535, 2018.

[21] Siyang Li, Bryan Seybold, Alexey Vorobyov, Xuejing Lei, and C-C Jay Kuo. Unsupervised video object segmentation with motion-based bilateral networks. In *ECCV*, pages 207–223, 2018.

[22] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C Lawrence Zitnick. Microsoft coco: Common objects in context. In *ECCV*, pages 740–755, 2014.

[23] Tsung-Yu Lin, Aruni RoyChowdhury, and Subhransu Maji. Bilinear cnn models for fine-grained visual recognition. In *ICCV*, pages 1449–1457, 2015.

[24] Wei Liu, Andrew Rabinovich, and Alexander C Berg. Parsenet: Looking wider to see better. *arXiv preprint arXiv:1506.04579*, 2015.

[25] Xinkai Lu, Wenguan Wang, Martin Danelljan, Tianfei Zhou, Jianbing Shen, and Luc Van Gool. Video object segmentation with episodic graph memory networks. In *ECCV*, 2020.

[26] Xiankai Lu, Wenguan Wang, Chao Ma, Jianbing Shen, Ling Shao, and Fatih Porikli. See more, know more: Unsupervised video object segmentation with co-attention siamese networks. In *CVPR*, pages 3623–3632, 2019.

[27] Tianyang Ma and Longin Jan Latecki. Maximum weight cliques with mutex constraints for video object segmentation. In *CVPR*, pages 670–677, 2012.

[28] Sabarinath Mahadevan, Ali Athar, Aljoša Ošep, Sebastian Hennen, Laura Leal-Taixé, and Bastian Leibe. Making a case for 3d convolutions for object segmentation in videos. In *BMVC*, 2020.

[29] Peter Ochs, Jitendra Malik, and Thomas Brox. Segmentation of moving objects by long term video analysis. *IEEE transactions on pattern analysis and machine intelligence*, 36(6):1187–1200, 2013.

[30] Anestis Papazoglou and Vittorio Ferrari. Fast object segmentation in unconstrained video. In *ICCV*, pages 1777–1784, 2013.

[31] Federico Perazzi, Jordi Pont-Tuset, Brian McWilliams, Luc Van Gool, Markus Gross, and Alexander Sorkine-Hornung. A benchmark dataset and evaluation methodology for video object segmentation. In *ICCV*, pages 724–732, 2016.

[32] Federico Perazzi, Oliver Wang, Markus Gross, and Alexander Sorkine-Hornung. Fully connected object proposals for video segmentation. In *ICCV*, pages 3227–3234, 2015.

[33] Alessandro Prest, Christian Leistner, Javier Civera, Cordelia Schmid, and Vittorio Ferrari. Learning object class detectors from weakly annotated video. In *CVPR*, pages 3282–3289, 2012.

[34] Hongmei Song, Wenguan Wang, Sanyuan Zhao, Jianbing Shen, and Kin-Man Lam. Pyramid dilated deeper convlstm for video salient object detection. In *ECCV*, pages 715–731, 2018.

[35] Deqing Sun, Xiaodong Yang, Ming-Yu Liu, and Jan Kautz. Pwc-net: Cnns for optical flow using pyramid, warping, and cost volume. In *CVPR*, pages 8934–8943, 2018.

[36] Zachary Teed and Jia Deng. Raft: Recurrent all-pairs field transforms for optical flow. In *ECCV*, pages 402–419, 2020.

[37] Pavel Tokmakov, Karteek Alahari, and Cordelia Schmid. Learning motion patterns in videos. In *CVPR*, pages 3386–3394, 2017.

[38] Pavel Tokmakov, Karteek Alahari, and Cordelia Schmid. Learning video object segmentation with visual memory. In *ICCV*, pages 4481–4490, 2017.

[39] Yi-Hsuan Tsai, Guangyu Zhong, and Ming-Hsuan Yang. Semantic co-segmentation in videos. In *ECCV*, pages 760–775, 2016.

[40] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in neural information processing systems*, pages 5998–6008, 2017.

[41] Wenguan Wang, Xiankai Lu, Jianbing Shen, David J Crandall, and Ling Shao. Zero-shot video object segmentation via attentive graph neural networks. In *ICCV*, pages 9236–9245, 2019.

[42] Wenguan Wang, Jianbing Shen, and Fatih Porikli. Saliency-aware geodesic video object segmentation. In *CVPR*, pages 3395–3402, 2015.

[43] Wenguan Wang, Hongmei Song, Shuyang Zhao, Jianbing Shen, Sanyuan Zhao, Steven CH Hoi, and Haibin Ling. Learning unsupervised video object segmentation through visual attention. In *CVPR*, pages 3064–3074, 2019.

[44] Xiaolong Wang, Ross Girshick, Abhinav Gupta, and Kaiming He. Non-local neural networks. In *CVPR*, pages 7794–7803, 2018.

[45] Hefeng Wu, Guanbin Li, and Xiaonan Luo. Weighted attentional blocks for probabilistic object tracking. *The Visual Computer*, 30(2):229–243, 2014.

[46] Ning Xu, Linjie Yang, Yuchen Fan, Jianchao Yang, Dingcheng Yue, Yuchen Liang, Brian Price, Scott Cohen, and Thomas Huang. Youtube-vos: Sequence-to-sequence video object segmentation. In *ECCV*, pages 585–601, 2018.

[47] Chuan Yang, Lihe Zhang, Huchuan Lu, Xiang Ruan, and Ming-Hsuan Yang. Saliency detection via graph-based manifold ranking. In *CVPR*, pages 3166–3173, 2013.

[48] Zhao Yang, Qiang Wang, Luca Bertinetto, Weiming Hu, Song Bai, and Philip HS Torr. Anchor diffusion for unsupervised video object segmentation. In *ICCV*, pages 931–940, 2019.

[49] Dong Zhang, Omar Javed, and Mubarak Shah. Video object segmentation through spatially accurate and temporally dense extraction of primary object regions. In *CVPR*, pages 628–635, 2013.

[50] Lu Zhang, Jianming Zhang, Zhe Lin, Radomír Měch, Huchuan Lu, and You He. Unsupervised video object segmentation with joint hotspot tracking. In *ECCV*, 2020.

[51] Rui Zhao, Wanli Ouyang, and Xiaogang Wang. Unsupervised salience learning for person re-identification. In *CVPR*, pages 3586–3593, 2013.

[52] Mingmin Zhen, Shiwei Li, Lei Zhou, Jiaxiang Shang, Haoan Feng, Tian Fang, and Long Quan. Learning discriminative feature with crf for unsupervised video object segmentation. *ECCV*, 2020.

[53] Tianfei Zhou, Jianwu Li, Shunzhou Wang, Ran Tao, and Jianbing Shen. Matnet: Motion-attentive transition network for zero-shot video object segmentation. *IEEE Transactions on Image Processing*, 29:8326–8338, 2020.

Topic-aware Heterogeneous Graph Neural Network for Link Prediction

Siyong Xu[1], Cheng Yang[1], Chuan Shi[1], Yuan Fang[2], Yuxin Guo[1], Tianchi Yang[1]
Luhao Zhang[3], Maodi Hu[3]
[1]Beijing University of Posts and Telecommunications
[2]Singapore Management University, [3]Meituan
{xusiyong, yangcheng, shichuan, gyxx, yangtianchi}@bupt.edu.cn
{yfang}@smu.edu.sg, {zhangluhao, humaodi}@meituan.com

ABSTRACT

Heterogeneous graphs (HGs), consisting of multiple types of nodes and links, can characterize a variety of real-world complex systems. Recently, heterogeneous graph neural networks (HGNNs), as a powerful graph embedding method to aggregate heterogeneous structure and attribute information, has earned a lot of attention. Despite the ability of HGNNs in capturing rich semantics which reveal different aspects of nodes, they still stay at a coarse-grained level which simply exploits structural characteristics. In fact, rich unstructured text content of nodes also carries latent but more fine-grained semantics arising from multi-facet topic-aware factors, which fundamentally manifest why nodes of different types would connect and form a specific heterogeneous structure. However, little effort has been devoted to factorizing them.

In this paper, we propose a **T**opic-aware **H**eterogeneous **G**raph **N**eural **N**etwork, named THGNN, to hierarchically mine topic-aware semantics for learning multi-facet node representations for link prediction in HGs. Specifically, our model mainly applies an alternating two-step aggregation mechanism including intra-metapath decomposition and inter-metapath mergence, which can distinctively aggregate rich heterogeneous information according to the inferential topic-aware factors and preserve hierarchical semantics. Furthermore, a topic prior guidance module is also designed to keep the quality of multi-facet topic-aware embeddings relying on the global knowledge from unstructured text content in HGs. It helps to simultaneously improve both performance and interpretability. Experimental results on three real-world HGs demonstrate that our proposed model can effectively outperform the state-of-the-art methods in the link prediction task, and show the potential interpretability of learnt multi-facet topic-aware representations.

CCS CONCEPTS

• **Computing methodologies** → **Neural networks**.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.
CIKM '21, November 1–5, 2021, Virtual Event, QLD, Australia
© 2021 Association for Computing Machinery.
ACM ISBN 978-1-4503-8446-9/21/11…$15.00
https://doi.org/10.1145/3459637.3482485

KEYWORDS

Heterogeneous graph, graph neural networks, representation learning, link prediction

ACM Reference Format:
Siyong Xu[1], Cheng Yang[1], Chuan Shi[1], Yuan Fang[2], Yuxin Guo[1], Tianchi Yang[1], Luhao Zhang[3], Maodi Hu[3], [1]Beijing University of Posts and Telecommunications, [2]Singapore Management University, [3]Meituan, {xusiyong, yangcheng, shichuan, gyxx, yangtianchi}@bupt.edu.cn, {yfang}@smu.edu.sg, {zhangluhao, humaodi}@meituan.com . 2021. Topic-aware Heterogeneous Graph Neural Network for Link Prediction. In *Proceedings of the 30th ACM International Conference on Information and Knowledge Management (CIKM '21), November 1–5, 2021, Virtual Event, QLD, Australia.* ACM, New York, NY, USA, 10 pages. https://doi.org/10.1145/3459637.3482485

1 INTRODUCTION

Heterogeneous graphs (HGs), which are composed of different types of nodes and relations, also known as heterogeneous information network, exist in a variety of real-world scenarios, ranging from bibliographic networks [4, 32], social networks [33] to recommendation systems [23]. For example, as shown in Fig.1 (a), an academic network has multiple types of nodes (author, paper, conference, and term) and edges defined by their relations (e.g., author-paper, paper-conference). Due to its heterogeneity in both graph structure and node attributes, HGs often carry immensely rich and diverse semantics. Thus, much effort has been devoted to heterogeneous graph embedding to map HGs into a low-dimension vector space [5, 7, 22] for downstream tasks. Among the tasks in HGs, link prediction is a fundamental and important problem that estimates the existence probability of a link between two nodes, which serves as the basis in many data mining tasks like recommendation[23, 27].

Recently, graph neural networks (GNNs), as a powerful family of deep representation learning method to combine both structures and node features for graph data, has attained considerable success [17, 26]. Inspired by the well-designed mechanisms in GNNs for homogeneous graphs, heterogeneous graph neural networks (HGNNs) [6, 8, 28] have also attracted a lot of attention in recent years. One major line of HGNNs defines and leverages metapaths [24] to preserve semantics and model heterogeneous structure [8, 28], since different metapaths are able to reveal different aspects of target nodes from a global perspective. For example, in an academic network shown in Fig. 1(a), Author-Paper-Author (APA) and Author-Paper-Conference-Paper-Author (APCPA) are metapaths describing two different relations among authors. The APA metapath associates two co-authors, while the APCPA metapath associates two

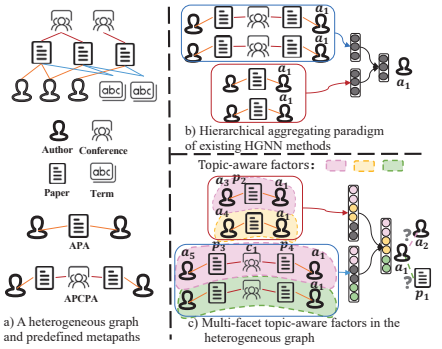

Figure 1: An illustration for heterogeneous graph (node types, metapaths) and comparison between our model and previous HGNNs.

authors who published papers in the same conference. Specifically, a classical paradigm of HGNNs is to adopt a hierarchical aggregation at node and semantic level, to fuse information from different metapaths, which can be intuitively shown in Fig. 1(b).

In spite of the informativeness of heterogeneous structure like metapaths, rich unstructured text content carried by nodes such as paper abstracts, descriptions or reviews, are also pervasive in HGs. Furthermore, text content is often a mixture of semantics arising from multi-facet topic-aware factors, which fundamentally manifest why nodes of different types would connect and form a specific heterogeneous structure. Such topic-aware semantics are more fine-grained than structural semantics for link prediction. For example, an author node a_1 in Fig. 1(c), may have multi-facet research interest on different topics, which can be reflected in a variety of local heterogeneous context. Along her APA-based context, she works with author a_3 due to their mutual interest on the topic of "Graph Mining" (shown in red), while builds a co-author relation with author a_4 stemming from the shared aim of "NLP Application" (shown in yellow). Similarly, along a_1's APCPA-based context, it can be inferred that both a_1's and a_5's papers are accepted by the same conference also related to "Graph Mining" topic (also shown in red). If we do not consider such fine-grained semantics through identifying the latent multi-facet topic-aware factors, and simply fuse derived confounding features, it will inevitably limit the performance of node representations for link prediction.

Recently, there are some attempts at disentangled learning to identify the latent explanatory factors behind the data with some promising results. Most prior efforts related to disentangled learning are devoted mainly in the field of image representation learning [9, 11, 16]. In order to tackle the non-Euclidean graph data, there are also a couple of works that explore the potential factors of edge formation between a pair of nodes for homogeneous graphs [18, 19, 31]. Although disentangled representation learning has been adopted in HGNNs [30], it only focuses on a coarse-grained and also local level aiming to automatically factorize structural semantics and avoid metapath selection only from neighbor nodes, but cannot further recognize and unveil more fined-grained semantics underlying the bare node connections.

Given the above limitations in current approaches, in this paper, we exploit both heterogeneous structures and unstructured text content in HGs. Specifically, we look deeper into identifying the potential but fundamental topic-aware factors based on the rich structural semantics in HGs, in order to learn multi-facet topic-aware representations for nodes while preserving such hierarchical semantics for link prediction. However, it imposes several challenges and thus can not be a straightforward extension of existing solutions. Firstly, HGs usually contain complex interactions and diverse attribute information among nodes, but there are no explicit labels indicating the latent and subtle topic-aware factors. This poses difficulties to distinguish the mixed information and factorize the feature vector into multi-facet topic-aware components. Secondly, after identifying potential topic-aware factors, an appropriate mechanism is required to combine both structural and topic-aware semantics. Thirdly, to keep up with the structural semantics at the global level, it is also important to preserve the global characteristics of topic-aware semantics and maintain the quality of multi-facet topic-aware embeddings, thus simultaneously improving both performance and interpretability.

To address the above challenges, we introduce a new model for link prediction, **T**opic-aware **H**eterogeneous **G**raph **N**eural **N**etwork (THGNN), that aims to further mine fine-grained topic-aware semantics based on structural semantics for multi-facet topic-aware representations learning in HGs. More precisely, THGNN applies a multi-facet transformation matrix to project the features of different types of nodes into the multiple topic-aware subspaces. For the first two challenges, THGNN applies an alternating two-step aggregation mechanism including intra-metapath decomposition and inter-metapath mergence, in order to learn multi-facet topic-aware embeddings for each target node. Specifically, the main goal of intra-metapath decomposition step is to infer the topic-aware distribution of metapath-based contexts and aggregate the context information according to the distribution to form multi-facet representations, so as to capture the fine-grained topic-aware semantics. On the other hand, inter-metapath mergence step adopts a multi-facet attention mechanism to fuse different metapaths for the final multi-facet embeddings, thus preserving both structural and topic-aware semantics for link prediction. For the last challenge, we introduce another module named topic prior guidance, which leverages topic modeling to obtain global statistical knowledge from unstructured textual content and helps to guide the context aggregation. In this way, it serves as a regularizer to encourage the inferential topic-aware subspaces to be more orthogonal and improve the interpretability of learnt multi-facet topic-aware representations.

To summarize, this work makes the following main contributions:

- From a fresh point of view, we propose to identify multi-facet topic-aware factors underlying the bare connections between associated nodes, making full use of both heterogeneous structures and unstructured text content for link prediction in HGs.

- We introduce a novel model THGNN for link prediction, which can distinctively aggregates rich heterogeneous information according to the inferred multi-facet topic-aware factors, so as to generate multi-facet topic-aware representations preserving both structural and topic-aware semantics. Besides, the topic prior guidance module is further designed to leverage the global knowledge from unstructured textual content, further keeping the quality of multi-facet topic-aware embeddings.
- Experiments on real heterogeneous graph datasets demonstrate that our proposed model significantly outperforms state-of-the-art methods in link prediction task, and also show the potential interpretability of our learnt multi-facet topic-aware embeddings.

2 RELATED WORK

In this section, we will review the most related work to ours, including graph neural networks and heterogeneous graph embedding.

2.1 Graph Neural Networks

Graph neural networks (GNNs) are a set of methods that apply deep learning to arbitrary graph-structured data. They generally fall into two categories: spectral and spatial methods. Based on spectral graph theory, Joan Bruna et al. [3] proposed a way to perform convolution in the spectral domain using the Fourier basis of a given graph. Kipf et al. [17] proposed a spectral approach, named Graph Convolutional Network, which simplified GNNs by involving the first-order approximation of the spectral graph convolution. A major limitation of traditional graph convolutional methods is that the filters are learned on the entire graph Laplacian, which lacks feasibility and scalability when graph is changed. Therefore, spatial approaches are proposed to define convolution operations directly on the graph, operating on groups of spatially close neighbors. Hamilton et al. [10] proposed GraphSage to summarize neighborhood information and a variety of solutions have been designed based on more advanced spatial-based filters. Inspired by Transformer [25], GAT [26] incorporated node features to measure the relative importance of neighbors via a multi-head self-attention mechanism.

Motivated by disentangled representation learning [1] successfully applied in the field of computer vision [9, 12, 16], Ma et al. [19] firstly proposed to learn disentangled representations in graph-structured data, employing neighborhood routing to automatically discover the independent latent factors of edges connecting a given node to its neighbors. As a follow up, IPGDN [18] improved disentangled GCNs by enforcing independence between the latent representations. Unlike prior efforts on decoding only a single attribute for a neighboring node, FactorGCN [31] enabled multi-relation disentangling, producing block-wise interpretable node features by analyzing the global-level topological semantics. Despite the results of the previous works on discovering latent factors in graphs, they are either built for homogeneous graphs, or designed for specific applications such as recommendation systems [15, 29].

2.2 Heterogeneous Graph Embedding

Heterogeneous graph embedding (i.e., HGE), aiming to learn a function that maps input space into a lower-dimension space while preserving the heterogeneous structures and semantics, has drawn considerable attentions and been applied to various scenarios in recent years [6, 13, 14, 34]. One of the classical paradigms is to leverage metapath for semantic-preserving embeddings. Metapath2vec [5] and HERec [23] generated random walks guided by selected metapaths and adopted skip-gram to perform HGE. HIN2vec [7] carries out multiple prediction training tasks and learns latent embeddings of nodes and metapaths simultaneously. Recent studies have attempted to extend GNNs for modeling HGs. HAN [28] utilized metapaths to convert a heterogeneous graph to multiple metapath-based homogeneous graphs, but adopted hierarchical attention mechanism (including both of the node-level and semantic-level attentions) to aggregate information. MAGNN [8] improved HAN by considering node information along the metapaths instead of only two end nodes, and thus exploited more comprehensive information in HGs.

Recently, disentangled representation learning is also applied in HGNNs. DisenHAN [30] was proposed to identify the major aspect of the relation between node pairs and propagate corresponding information semantically so as to automatically extract metapaths. Although mining such rich structural semantics in HGs is able to reflect multiple aspects of nodes in existing methods, there is still a room for improvement by exploiting the multi-facet topic-aware factors hidden by pervasive unstructured text content from a gloval perspective in HGs. These fine-grained topic-aware semantics can essentially bring insight into node connections and heterogeneous structure formation, which suggests us to identify the hidden multi-facet factors and model HGs more distinctively.

3 PRELIMINARY

In this section, we formalize some important definitions related to heterogeneous graphs.

Definition 3.1. **Heterogeneous Graph [24].** A heterogeneous graph is defined as a graph $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ with an object type mapping function $\varphi : \mathcal{V} \rightarrow \mathcal{A}$ and a link type mapping function $\psi : \mathcal{E} \rightarrow \mathcal{R}$. $\mathcal{A}$ and $\mathcal{R}$ denote the sets of predefined object types and link types, where$|\mathcal{A}| + |\mathcal{R}| > 2$.

Definition 3.2. **Metapath [24].** A metapath M is a path denoted in the form of $A_1 \xrightarrow{R_1} A_2 \xrightarrow{R_2} \dots \xrightarrow{R_l} A_{l+1}$, which defines a composite relation $R = R_1 \circ R_2 \circ \dots \circ R_l$ between objects A_1 and A_{l+1}, where $\circ$ denotes the composition operator on relations.

Definition 3.3. **Metapath Instance.** Given a metapath M of a heterogeneous graph, a metapath instance m of M is defined as a node sequence in the graph matching the sequence of types in M. A metapath instance connecting node u and v where node u is a target node is denoted as m_u.

Definition 3.4. **Metapath-based Context.** Given a metapath instance m_u, the metapath-based context c of the target node u is defined as the node sequence in the rest of metapath instance without node u, denoted as c_u=$m_u \backslash \{u\}$, in which there exists nodes that contain text content. More specifically, the set of metapath M-based contexts with a target node u is denoted as C_u^M. The text-related node sequence in c_u denoted as c_u^{text}.

Example. As shown in Figure 1(a), we construct a HG to model DBLP. It consists of multiple types of objects (Author (A), Paper (P), Term (T), Conference (C)) and relations (P-A, P-T and P-C).

Two authors can be connected based on multiple metapaths, e.g., Author-Paper-Author (APA) and Author-Paper-Conference-Paper-Author (APCPA). Given a metapath APA, a_3-p_2-a_1 is a metapath instance related to the target node a_1. The author a_1 connects with other authors via different metapaths, and then node sequences (a_3, p_2) (APA-based) and (a_5, p_3, c_1, p_4) (APCPA-based) constitute the context of a_1, different metapath-based contexts may reveal different topic-aware semantics as paper nodes in metapath-based contexts carry rich text content.

4 METHODOLOGY

To guide information aggregation for nodes with multi-facet factors by the hidden topic-aware semantics underlying HGs, we propose a unified topic-aware heterogeneous graph neural network (THGNN). In this section, we will give a detailed description about the architecture of THGNN, whose three basic components are: multi-facet projection, multi-facet heterogeneous graph neural network, topic prior guidance. The multi-facet projection component serves as a preprocessing stage to facilitate the aggregation process of THGNN. The key building block "multi-facet heterogeneous graph neural network" consists of two steps: intra-metapath decomposition and inter-metapath mergence, to learn multi-facet topic-aware embeddings for nodes with multi-facet factors iteratively. A topic prior guidance is also introduced to guide context aggregation, further keeping the quality of multi-facet topic-aware embedding. Figure 2 illustrates the overall topic-aware embedding generation.

4.1 Multi-facet Projection

Due to the heterogeneity of nodes in HGs, different types of nodes and edges have different attributes, which are usually located in totally different feature spaces. With the goal of mining potential topic-aware subspaces in a HG, we need to project different types of node features into the same shared latent vector subspaces that indicates multi-facet topic-aware semantics.

Therefore, assuming that there exists K potential topic-aware subspaces in the HG, for each type of nodes we apply K type-specific linear transformation by projecting feature vectors into K latent topic-aware subspaces before feeding node vectors. As shown in Fig. 2 (a), for a node $u \in \mathcal{V}$ of type $\varphi(u) \in \mathcal{A}$, the multi-facet projection process can be shown as follows:

$$\mathbf{h}_{u,k} = \mathbf{P}_k^{\varphi(u)} \cdot \mathbf{x}_u, \tag{1}$$

where $k = 1, 2, \cdots, K$. $\mathbf{x}_u \in \mathbb{R}^{d_{\varphi(u)}}$ is the original feature vector of node u and $\mathbf{h}_{u,k} \in \mathbb{R}^{\frac{D}{K}}$ is the projected feature in the k^{th} latent topic-aware subspace. $\mathbf{P}_k^{\varphi(u)} \in \mathbb{R}^{\frac{D}{K} \times d_{\varphi(u)}}$ is the k^{th} training weight matrix for nodes of type $\varphi(u)$.

After multi-facet projection, all nodes features share the same D dimension with K components, which is convenient for the multi-facet heterogeneous graph neural network in Section 4.2.

Sampling Strategy Given a node u with multi-facet factors in the HG, we firstly need to sample some metapath-based contexts via different metapaths. For the sake of identifying multi-facet topic-aware factors, we employ a sampling strategy to pay more attention to those metapath-based contexts containing more than one text-related node with high topic consistency. The sampling process is as follows:

$$p_{c_u} = \frac{\sum_{v_s, v_{s+1} \in c_u^{text}} \cos(\boldsymbol{\lambda}_{v_s}^{c_u}, \boldsymbol{\lambda}_{v_{s+1}}^{c_u})}{\sum_{c'_u \in C_u^M} \sum_{v_s, v_{s+1} \in c_u'^{text}} \cos(\boldsymbol{\lambda}_{v_s}^{c'_u}, \boldsymbol{\lambda}_{v_{s+1}}^{c'_u})}, \tag{2}$$

where p_{c_u} is the sampling probability of metapath M-based context c_u, and $\boldsymbol{\lambda}_{v_s}^{c_u}$ is the pre-calculated topic distribution of text content carried by node v_s in context c_u through topic model LDA.

4.2 Multi-facet Heterogeneous Graph Neural Network

In the ensuing discussion, we shall zoom into the key building block of THGNN, which is composed of two steps: intra-metapath decomposition to capture topic-aware semantics and inter-metapath mergence to preserve structural semantics. The aim of intra-metapath decomposition step is to infer topic-aware distribution of the metapath M-based context in C_u^M preliminarily and aggregate the context information based on the inferred distribution to form the multi-facet representation. Inter-metapath mergence step aims to fuse different metapaths to generate the final multi-facet embedding preserving structural and topic-aware semantics at current iteration. The above two steps are conducted alternatively, which can be summarized as follows:

$$\mathbf{y}_u = g(\{\mathbf{h}_{u,k} | 1 \le k \le K\}, \{\mathbf{h}_{u,k}^{c_u} | 1 \le k \le K, c_u \in C_u^{M_i}, M_i \in \mathcal{M}\}), \tag{3}$$

where $g(\cdot)$ is the aggregation function to learn the final multi-facet topic-aware representation $\mathbf{y}_u$ of u, and $\mathbf{h}_{u,k}^{c_u}$ indicates embedding of the metapath-based context c_u in the k^{th} topic-aware subspace. $\mathcal{M}$ is the set of selected metapaths. As assuming that there exist K latent topic-aware subspaces, we would like to let $\mathbf{y}_u$ be composed of K topic-aware components $\mathbf{y}_u = [\mathbf{z}_{u,1}, \mathbf{z}_{u,2}, \cdots, \mathbf{z}_{u,K}]$, where $\mathbf{z}_{u,k} \in \mathbb{R}^{\frac{D}{K}}$ is able to characterize the k^{th} topic-aware factor of u.

4.2.1 Intra-metapath Decomposition. As shown in Fig. 2 (b)-1), given a metapath $M_i \in \mathcal{M}$, the goal of this step is to infer which topic that each sampled metapath-based context pertain to. Recall that we expect $\mathbf{h}_{u,k}^{c_u}$ to capture the k^{th} facet topic-aware of target node u by leveraging the current metapath-based context. The context encoder can be shown in the following manner:

$$\mathbf{h}_{u,k}^{c_u} = f(\{\mathbf{h}_{v,k}, \forall v \in c_u\}), \tag{4}$$

where $c_u \in C_u^{M_i}$, and we choose the average pooling operation in experiments for $f(\cdot)$ in consideration of simplicity and efficiency.

After encoding the metapath-based context into multi-facet representations in topic-aware subspaces, we adopt a cosine similarity between multi-facet representations of target node and its current metapath-based context, to infer the most related topic-aware subspace both of them share. The inferential topic distribution is given by:

$$p_{k|c_u} = \frac{\exp(\cos(\mathbf{h}_{u,k}, \mathbf{h}_{u,k}^{c_u}))}{\sum_{k'=1}^{K} \exp(\cos(\mathbf{h}_{u,k'}, \mathbf{h}_{u,k'}^{c_u}))}, \tag{5}$$

where $k = 1, 2, \cdots, K$ and $c_u \in C_u^{M_i}$. $C_u^{M_i}$ indicates a set of sampled metapath M_i-based contexts of u. Naturally, the probability $p_{k|c_u}$ should be high if the target node u is related to the current metapath-based context c_u in the k^{th} topic-aware subspace. Meanwhile, it

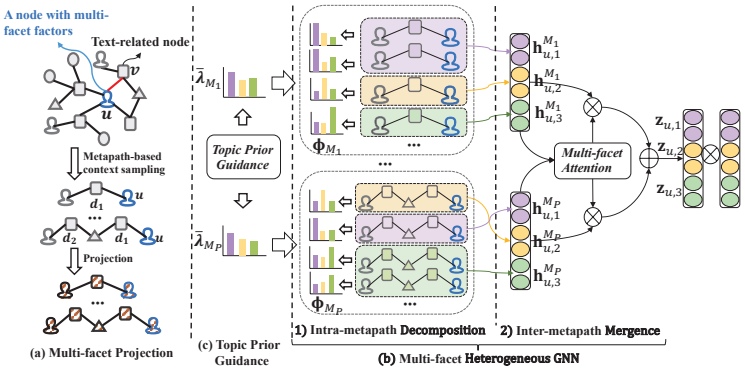

Figure 2: The overall framework of the proposed model THGNN.

also serves as the importance weight of the current metapath-based context information when propagating it to the target node in the k^{th} topic-aware subspace. Therefore, we can obtain the metapath-specific multi-facet topic-aware representation of target node u:

$$\mathbf{h}_{u,k}^{M_i} = L2_Norm(\sum_{c \in C_u^{M_i}} p_{k|c_u} \cdot \mathbf{h}_{u,k}^{c_u}), \tag{6}$$

where $k = 1, 2, \cdots, K$ and $M_i \in \mathcal{M}$.

In summary, given the multi-facet projected feature vectors of the target node u, and the set of selected metapaths $\mathcal{M} = (M_1, M_2, \cdots, M_P)$ for u, the intra-metapath decomposition generates P groups of metapath-specific multi-facet topic-aware representations for u, denoted as $\{[\mathbf{h}_{u,1}^{M_1}, \mathbf{h}_{u,2}^{M_1}, \cdots, \mathbf{h}_{u,K}^{M_1}], [\mathbf{h}_{u,1}^{M_2}, \mathbf{h}_{u,2}^{M_2}, \cdots, \mathbf{h}_{u,K}^{M_2}], \cdots, [\mathbf{h}_{u,1}^{M_P}, \mathbf{h}_{u,2}^{M_P}, \cdots, \mathbf{h}_{u,K}^{M_P}]\}$.

As the topic-aware distributions and multi-facet topic-aware representations derived from the intra-metapath decomposition step aim to be as diverse as possible, the inter-metapath mergence step, is designed to find overall importance of multi-facet information conditioned on certain structure semantic.

4.2.2 Inter-metapath Mergence. Since every node in a HG contains multiple types of structural semantic information which can be revealed by metapaths, we propose a multi-facet attention to learn the importance of different metapaths and merge them to generate the final multi-facet topic-aware representation for the target node u, which is shown at Fig. 2(b)-2).

To learn the importance of given metapath M_i, firstly we transform the metapath-specific single-facet representations with a weight matrix $\mathbf{W}$, then we summarize metapath M_i in the k^{th} topic-aware subspace by averaging the transformed metapath-specific single-facet representations for target nodes in a batch:

$$\mathbf{s}_k^{M_i} = \frac{1}{|B|} \sum_{u \in B} \tanh(\mathbf{W} \cdot \sigma(\mathbf{h}_{u,k}^{M_i})), \tag{7}$$

where $k = 1, 2, \cdots, K$, $\mathbf{W} \in \mathbb{R}^{\frac{D}{K} \times \frac{D}{K}}$ is learnable parameter and $|B|$ is size of batch.

Then we use multi-facet attention vectors $(\mathbf{q}_1^T, \mathbf{q}_2^T, \cdots, \mathbf{q}_K^T)$ to measure the relative importance of the metapath M_i in each topic-aware subspace. Since different metapaths describe various semantics behind a HG at structural level, the overall importance of different metapaths should be shared in all topic-aware subspaces, and thus we sum up multi-facet relative importance as the overall importance for the metapath M_i:

$$e^{M_i} = \sum_{k=1}^{K} \mathbf{q}_k^T \cdot \mathbf{s}_k^{M_i}, \tag{8}$$

$$\beta^{M_i} = \frac{\exp(e^{M_i})}{\sum_{M \in \mathcal{M}} \exp(e^M)}, \tag{9}$$

where $\mathbf{q}_k \in \mathbb{R}^{\frac{D}{K}}$, and β^{M_i} can be interpreted as the contribution of the metapath M_i.

With the computed coefficients $(\beta^{M_1}, \beta^{M_2}, \cdots, \beta^{M_P})$, we can merge all the metapath-specific multi-facet representations to obtain final multi-facet topic-aware representation in current iteration:

$$\hat{\mathbf{h}}_{u,k} = \sum_{M_i \in \mathcal{M}} \beta^{M_i} \cdot \mathbf{h}_{u,k}^{M_i}, \tag{10}$$

where $k = 1, 2, \cdots, K$.

The above two steps are performed together as an iteration and the current output $\{\hat{\mathbf{h}}_{u,k}, k = 1, 2, \cdots, K\}$ will in turn serve as guidance of the next topic-aware distribution inference, which can be also interpreted as updated K topic-aware cluster centers for different types of metapath-based contexts of the target node u. After T iterations, THGNN outputs K final enriched representations for $\mathbf{y}_u$ in Eq.(3) going through an activation function: $\{\mathbf{z}_{u,k} = \sigma(\hat{\mathbf{h}}_{u,k}^{(T)}) | k = 1, \cdots, K\}$(for a text-related node v, let $\mathbf{z}_{v,k} = \sigma(\mathbf{h}_{v,k})$ without any iteration), and also final inferential topic-aware distribution of all the sampled metapath-based contexts, denoted as $\{\mathbf{\Phi}_u^{M_i}, M_i \in \mathcal{M}\}$.

Here $\mathbf{\Phi}_u^{\mathcal{M}_i} \in \mathbb{R}^{|C_u^{\mathcal{M}_i}| \times K}$ can be interpreted as a soft cluster assignment matrix of metapath M_i-based contexts, and each row of $\mathbf{\Phi}_u^{\mathcal{M}_i}$ contains K elements calculated through Eq.(5) at the last iteration.

4.3 Topic Prior Guidance

In spite of the iterative process in multi-facet heterogeneous graph neural network inferring topic-aware distribution for metapath-based context and generating chunked representations for the target nodes, there are still two points needing to go further: (1) due to the heterogeneity of metapath-based context, there might be still confounding among different topic-aware subspaces, even leading to an extreme collapse case; (2) the intra-metapath decomposition step is performed essentially as a kind of local clustering, making it difficult to capture global knowledge from K potential topic-aware subspaces we assume. The first suggests the inferential topic-aware subspaces to be more independent and each one to maintain a convenient size. Another means global prior knowledge is necessary to keep the globality of topic-aware subspaces. To meet the two requirements, we introduce another module named topic prior guidance to encourage the inferential topic-aware subspaces to be more orthogonal and improve interpretability.

As shown in Fig.2 (c), inspired by the orthogonality loss term for graph clustering [2], the added module will serve as a regularizer, ingeniously leveraging topic model to obtain global statistical knowledge from unstructured textual content, to guide context aggregation among the HG, which has the following form:

$$\mathcal{L}_T = \frac{1}{|\mathcal{M}|} \sum_{M_i \in \mathcal{M}} \| \frac{\mathbf{\Phi}_{M_i}^T \mathbf{\Phi}_{M_i}}{\| \mathbf{\Phi}_{M_i}^T \mathbf{\Phi}_{M_i} \|_F} - \frac{\overline{\boldsymbol{\lambda}}_{M_i}}{\| \overline{\boldsymbol{\lambda}}_{M_i} \|_F} \|_F, \quad (11)$$

$$\overline{\boldsymbol{\lambda}}_{M_i} = \frac{1}{|C^{M_i}|} \sum_{c \in C^{M_i}} \boldsymbol{\lambda}_{d_1}^c, \quad (12)$$

where each row of $\mathbf{\Phi}^{M_i}$ indicates the inferential topic-aware distribution of metapath M_i-based context from Eq.(5), while $\boldsymbol{\lambda}_{d_1}^c$ means the pre-calculated topic distribution of the first document node d_1 along the single metapath-based context c obtained from LDA. Note that in experiments, we concatenate all the sampled metapath M_i-based contexts of target nodes in the current mini-batch to form the matrix $\mathbf{\Phi}_{M_i}$, instead of a single target node, due to the sparsity of data and so as to save computation. Similarly, C^{M_i} also indicates all the sampled metapath M_i-based contexts of target nodes in the current mini-batch. In this way, $\overline{\boldsymbol{\lambda}}_{M_i}$ plays a prior guiding role in context aggregation by the hidden topic-aware subspaces underlying the HG.

4.4 Model Training

After applying above described three basic components, we obtain multi-facet topic-aware representations for nodes, the forward propagation process is shown in Algorithm 1. We estimate the similarity for a training pair (u, v) through inner product in multi-facet topic-aware subspaces, and then we sum all of them as the final matching score for link prediction:

$$s_{uv} = \sum_{k=1}^{K} \mathbf{z}_{u,k}^T \cdot \mathbf{z}_{v,k}, \quad (13)$$

We construct the loss function of graph reconstruction using mini-batch gradient in two major learning paradigms:

Algorithm 1 The forward propagation of THGNN.

Require:
The heterogeneous graph $\mathcal{G} = (\mathcal{V}, \mathcal{E})$,
node types $\mathcal{A}$={$A_1, A_2, \cdots, A_{|\mathcal{A}|}$},
the type of nodes with multi-facet factors A,
metapaths $\mathcal{M}$={$M_1, M_2, \cdots, M_{\mathcal{M}}$},
node features $\{\mathbf{x}_v, \forall v \in \mathcal{V}\}$,
the number of multi-facet topic-aware factors K
Ensure:
$\{\mathbf{z}_{v,k} | 1 \le k \le K, \forall v \in \mathcal{V}\}$;
for node type $A_i \in \mathcal{A}$ **do**
  for $k = 1, 2, \cdots, K$ **do**
    Multi-facet projection $\mathbf{h}_{v,k} = \mathbf{P}_k^{A_i} \cdot \mathbf{x}_v, \forall v \in \mathcal{V}_{A_i}$;
  end for
end for
for T iterations **do**
  for metapath $M_i \in \mathcal{M}$ **do**
    for $u \in \mathcal{V}_A$ **do**
      for $k = 1, 2, \cdots, K$ **do**
        Calculate $\mathbf{h}_{u,k}^{c_u}$ for all $c_u \in C_u^{M_i}$ with Eq. 4;
        Infer the topic-aware distribution $p_{k|c_u}$ with Eq. 5;
        Obtain $\mathbf{h}_{u,k}^{M_i}$ with Eq. 6;
      end for
    end for
  end for
  Calculate β^{M_i} of metapath $M_i \in \mathcal{M}$ with Eq. 7 8, 9;
  Obtain $\hat{\mathbf{h}}_{u,k}, \mathbf{h}_{u,k} \leftarrow \hat{\mathbf{h}}_{u,k}, k = 1, 2, ...K$ with Eq. 10;
end for
return $\{\mathbf{z}_{v,k} = \sigma(\mathbf{h}_{v,k}) | k = 1, \cdots, K, \forall v \in \mathcal{V}\}$

- Only one node with multi-facet factors in training pair (u, v): assuming that u is the only node with multi-facet factors , then

$$\mathcal{L}_{G,\mathcal{B}} = -\sum_{(u,v) \in \mathcal{B}^+} \log \sigma(s_{uv}) - \sum_{(u,v') \in \mathcal{B}^-} \log \sigma(-s_{uv'}), \quad (14)$$

  where $\mathcal{B}$ ={$\mathcal{B}^+ \cup \mathcal{B}^-$} denotes the training pairs involving the observed edges $\mathcal{B}^+$ and unobserved edges $\mathcal{B}^-$.
- Both are nodes with multi-facet factors in training pair (u, v):

$$\mathcal{L}_{G,\mathcal{B}} = -\sum_{(u,v) \in \mathcal{B}^+} \log \sigma(\frac{1}{K} s_{uv}) - \sum_{(u',v') \in \mathcal{B}^-} \log \sigma(-\frac{1}{K} s_{u'v'}), \quad (15)$$

  where $\mathcal{B}$ ={$\mathcal{B}^+ \cup \mathcal{B}^-$}. Here we take the average of the final matching score because THGNN outputs the final multi-facet representations after l2 normalization operation.

The overall training loss which combines the loss of graph reconstruction and regularizer term can be rewritten as:

$$\mathcal{L}_{\mathcal{B}} = \mathcal{L}_{G,\mathcal{B}} + \gamma \mathcal{L}_T. \quad (16)$$

Table 1: Description of datasets.

Dataset	Relation (A-B)	#A	#B	#A-B
DBLP	Paper-Author	11,248	11,569	32,534
	Paper-Conference	11,248	16	11,248
	Paper-Term	11,248	2,463	65,818
YELP	Business-User	2,203	1,430	27,793
	Business-City	2,203	66	2,157
	Business-Category	2,203	347	9,787
Amazon	Movie-User	1,754	2,476	34,042
	Movie-Brand	1,754	293	734
	Movie-Category	1,754	95	4,913

5 EXPERIMENTS

In this section, we evaluate the effectiveness of THGNN on three real-world graph datasets, namely, DBLP, YELP and Amazon, whose nodes carry a wealth of text content. A comparative evaluation against a wide variety of baselines is performed in the link prediction task to evaluate the model. Besides, we also visualize the quality of the learned multi-facet topic-aware embeddings to demonstrate the discovered topic-aware semantics. The experiments aim to address the following questions:

- Q1: How does THGNN perform in link prediction task compared with state-of-the-art methods?
- Q2: How does topic prior guidance affect the result of THGNN?
- Q3: Can THGNN capture multi-facet topic-aware semantics?

5.1 Experimental Setup

Datasets The detailed descriptions of the HGs used in our experiments are shown in Table 1.

- **DBLP**: We extract a subset of DBLP which contains 11,569 authors (A), 11,248 papers (P), 16 conferences (C), 2,463 terms (T) between year 2000 to 2010, to build an academic graph. The contents of papers consist of abstracts and titles and are transformed into bag-of-word representations of keywords for author features. Here we employ the metapath set {APA, APCPA, APTPA} to perform experiments. For DBLP dataset, we split training and test data sequentially with a split year 2008 and predict both author-paper links and co-author hyper-links. Due to the temporality of DBLP dataset, we train the topic model LDA only using papers before split year. We also randomly sample disconnected node pairs of the given form as negative instances.
- **YELP**: We extract a subset of YELP which contains 1,430 users (U), 2,230 businesses (B), 66 cities (Ci), 347 categories (Ca), to build a review graph. Business nodes carry text content from some useful reviews. Here we employ the metapath set {UBU, UBCiBU, UBCaBU} to perform experiments. We randomly hide 25% of user-business links as the ground truth positives, and randomly sample disconnected node pairs of the given form as negative instances. All the text content carried by business nodes is used to train the topic model LDA. The ground truth serves as our test set of YELP dataset.
- **Amazon**: We extract a subset of Amazon which contains 2,476 users (U), 1,754 movies (M), 293 brands (Br), 95 categories (Ca), to build a review graph. Movie nodes carry text content from some useful reviews and descriptions. Here we employ the metapath set {UMU, UMBrMU, UMCaMU} to perform experiments. All the text content carried by movie nodes is used to train the topic model. Similar to YELP dataset, we randomly hide 25% of user-movie links as the ground truth positives.

Baselines We compare THGNN against three categories of graph embedding methods: random walk-based, GNN-based, HGNN-based. **DeepWalk** [21] is a traditional random walk-based homogeneous method employing the skip-gram model [20]. Here we ignore the heterogeneity of nodes and perform DeepWalk on the whole heterogeneous graphs. **Mp2vec** [5] is a random walk-based heterogeneous method, which generates node embeddings by feeding metapath-based random walks and also employs the skip-gram model. Here we test all the metapaths for metapath2vec and report the best performance. **HERec** [23] is a random walk-based heterogeneous method which designs a type-constrained strategy to o filter the node sequence and utilizes skip-gram to embed the HGs. **GraphSage** [10] is a classical GNNs which leverages sampler and aggregator to encode homogeneous graph. **GAT** [26] is a homogeneous GNN method which adopts multi-head additive attention on neighbors. **DisenGCN** [19] is a homogeneous disentangled GNN method which designs a neighborhood routing mechanism and embedding propagation to disentangle latent factors underlying edges between nodes and their neighbors. **HAN** [28] is a HGNN-based method which extracts metapath-based homogeneous graphs and adopts hierarchical attentions to aggregate neighobor information via different metapaths. **DisenHAN** [30] is a HGNN-based method which can iteratively identify the major aspect of meta relations and aggregate corresponding aspect features from each meta relation for target nodes. **MAGNN** [8] is a HGNN-based method which also adopts hierarchical attentions but to aggregate metapath instances leveraging node content features. **THGNN**$_{\backslash MA}$ is a variant of THGNN, which removes the multi-facet attention and employs the simple average strategy on all metapaths.

Parameter Settings For all the GNN-based and HGNN-based methods including our model, we search the dimension of output node embeddings in {64, 128, 256} and report the best performance, and we unify them in an inductive version. For our method, the number of metapath-based context samples is 30 and the number of iterations is 3 in default setting. We fix the dimension of output node embedding for each task and search the number of latent topic-aware factors in {4, 8, 16, 32}. To prevent overfitting, we employ dropout where the ratio is tuned among {0.0, 0.1, $\cdots$, 0.5}. We optimize THGNN with Adam optimizer by setting the learning rate to 1e-7 $\sim$ 1e-4. We use AUC and average precision (AP) to evaluate performance of models. For all methods, we run 5 times with the same partition and report the average results. We will release the codes after the paper is accepted.

5.2 Link Prediction (Q1)

In link prediction, the goal is to predict potential or missing links connecting pairwise nodes in a graph. It is a widely used task to evaluate the quality of learnt node representations, and it is also a demanding task in real world scenarios with multi-facet characteristic. The prediction performance of all models on the three datasets is summarized in Table 2. Analyzing such performance comparison, we have the following observations:

Table 2: The performance comparison of link prediction. The underlined means the best performance in baselines.

	DBLP (A-P)		DBLP (A-A)		YELP (U-B)		Amazon (U-M)	
Models	AUC	AP	AUC	AP	AUC	AP	AUC	AP
DeepWalk	0.7754	0.7782	0.7488	0.7568	0.6200	0.6281	0.7684	0.7840
Mp2vec	0.7213	0.7243	0.7600	0.7484	0.6792	0.6872	0.7812	0.7834
HERec	0.8186	0.7927	0.7565	0.7871	0.8383	0.8215	0.8085	0.8083
GraphSage	0.8218	0.8341	0.8524	0.8817	0.8874	0.8810	0.8236	0.8327
GAT	0.8322	0.8367	0.8579	0.8805	0.8915	0.8847	0.8329	0.8343
DisenGCN	0.8301	0.8352	0.8692	0.8936	0.8957	0.8838	0.8435	0.8390
HAN	0.8535	0.8719	0.8744	0.9046	0.9013	0.8722	0.8418	0.8414
DisenHAN	0.8496	0.8654	0.8868	0.8947	0.8976	0.8843	0.8426	0.8419
MAGNN	0.8543	0.8727	0.8671	0.9035	0.9123	0.8926	0.8378	0.8278
THGNN$_{\backslash MA}$	0.8546	0.8683	0.8712	0.8939	0.9154	0.8945	0.8578	0.8502
THGNN	**0.8807**	**0.9000**	**0.8996**	**0.9174**	**0.9243**	**0.9037**	**0.8634**	**0.8515**

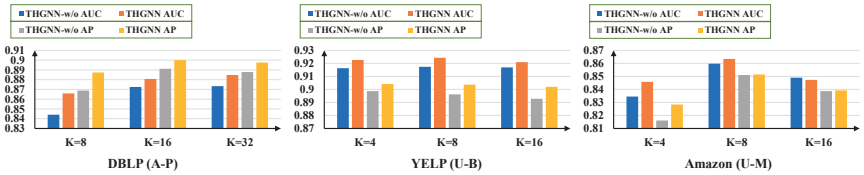

Figure 3: Effect of the topic prior guidance module. THGNN-w/o means THGNN without topic prior guidance.

It is clear that our model consistently performs better than all baselines on three datasets. Compared to the best performance of baselines, THGNN achieves improvements in terms of both AUC (up to 1.32% ∼ 3.09%) and AP (up to 1.14% ∼ 3.13%), which indicates the effectiveness of the delicate designs for factorizing multi-facet topic-aware semantics in THGNN. The results of its variant also achieve competitive performance compared to baselines, it is still significantly worse than the complete THGNN. It indicates the effectiveness of both structural and topic-aware semantics.

Comparing across baselines, we can observe that GNNs often obtain better performance against random walk-based methods since they combine the structures and features information in different ingenious ways. HGNNs further outperform GNNs by better capturing HGs' complex structures and rich semantic information.

DisenGCN substantially outperforms other homogeneous GNNs in most cases. It is reasonable since it is capable of dynamically recognizing and disentangling the latent factors that cause edges through a neighbor routing mechanism. The improvements of DisenHAN is not obvious. Possible reasons are that the main goal of DisenHAN is to automatically factorize structural semantics, which further confirms the necessity and benefits of mining fine-grained topic-aware semantics in HGs.

5.3 Analysis of Topic Prior Guidance (Q2)

To investigate the effect of topic prior guidance module on improving performance, we test THGNN and THGNN without topic prior guidance (THGNN-w/o) with topic-aware factors in {4, 8, 16, 32} on DBLP (A-P), YELP (U-B) and Amazon (U-M). As shown in Fig. 3, a better performance on AUC and AP is substantially coupled with topic prior guidance especially when K is set to be relatively small. This is because a small K with higher dimension for each factor easily leads to collapse and the topic prior guidance can help to relieve and keep the quality of multi-facet topic-aware embeddings. We also notice that the improvements on Amazon when $K = 8$ and $K = 16$ is much less than that on others. This might suggest that, the inferential process is performed well enough and THGNN still achieves competitive performance against baselines without topic prior guidance since users' preference on movies are diverse.

5.4 Multi-facet Embedding Visualization (Q3)

To analyze the quality of the multi-facet topic-aware embeddings learned by THGNN intuitively, we visualize the correlation analysis between the elements of multi-facet node embeddings learned in DBLP (A-P) task and Amazon (U-M) task. The number of multi-facet topic-aware factors is set to $K = 16$ in DBLP and $K = 8$ in Amazon. Fig. 4 (a), Fig. 4 (b) and Fig. 4 (c, d) show the results derived from MAGNN, THGNN without topic prior guidance and THGNN respectively. The latent features learned by MAGNN are still hiddenly entangled. It can be explained that the multi-head attention mechanism [25] adopted by MAGNN has little ability to capture more fine-grained multi-facet semantics, and its main function is to reflect in stabilizing the training process. According to Fig. 4 (c, d) we can also observe on both DBLP and Amazon dataset that THGNN is able to extract independent multi-facet representations especially on Amazon dataset, as the correlation plot exhibits K clear diagonal blocks. Comparing the quality of Fig. 4 (b) and Fig. 4 (c), we can further make a conclusion that the topic prior guidance plays an important role on giving more orthogonality and keeping the quality of multi-facet topic-aware embeddings, and thus THGNN achieves a better performance in the link prediction task.

Table 3: Case study of the author u198's top 2 papers by the probability in her three most concerned factors on DBLP (A-P).

Factor	Text Content (Title) of Top 2 Papers	Probability
9	BibFinder/StatMiner: Effectively Mining and Using Coverage and Overlap Statistics in Data Intergration.	0.1327
	Improving text collection selection with coverage and overlap statistics.	0.1621
14	When is Temporal Planning Really Temporal?	0.1404
	Parallelizing State Space Plans Online.	0.1480
16	Query Processing over Incomplete Autonomous Databases.	0.2782
	Answering Imprecise Queries over Autonomous Web Databases.	0.2632

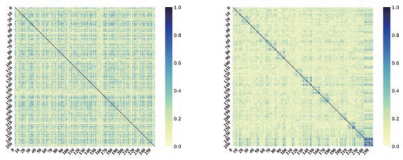

(a) MAGNN DBLP (A-P). (b) THGNN-w/o DBLP (A-P).

(c) THGNN DBLP (A-P). (d) THGNN Amazon (U-M).

Figure 4: The magnitude of the correlations between the elements of the 256-dimensional representations for DBLP (A-P), and 128-dimensional representations for Amazon (U-B).

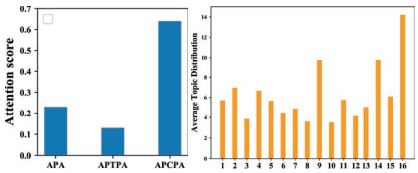

(a) Attention scores of metapaths. (b) Average topic distribution.

Figure 5: Attention values on metapaths and average topic-aware distribution of APA-based context of u198 on DBLP (A-P).

5.5 Semantics Analysis: Case Study

In order to investigate the semantics in both structural level and topic-aware level, we further present a case study for a deeper understanding. We randomly select an author $u198$ from DBLP (A-P) task, and the attention score of metapaths as well as her average topic distribution of APA-based context are shown in Fig. 5. Fig. 5 (a) shows the metapath APCPA is given the largest weight which means that $u198$ considers the APCPA as the most critical metapath when she connects with a paper node. It suggests that a conference may represent a research topic. From Fig. 5 (b) we can find that

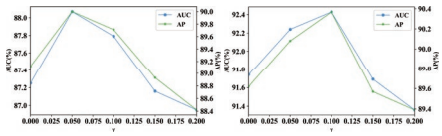

(a) DBLP (A-P). (b) YELP (U-B).

Figure 6: Analysis of parameter γ.

$u198$ mainly focus on topic-aware factor 9, 14 and 16. For each one, we visualize the title of top 2 papers in her metapath-based context as well as their probability. As shown in Table 3, for example, factor 9 is probably related to "Overlap statistics" topic, factor 16 may indicate the "Database" research field.

5.6 Parameter Study

Finally, we perform a sensitivity analysis of the parameter γ on DBLP and YELP datasets to explore how topic prior guidance influences model performance. The results are shown in Fig. 6. As the topic prior coefficient increases, the performance increases initially as the guidance is beneficial to the multi-facet topic-aware representation learning. However, it will drop quickly if γ is larger than 0.1 on both DBLP and YELP because too sharp topic-aware distribution inference which cannot maintain topic relevance will negatively affect the model.

6 CONCLUSIONS

In this paper, we proposed to identify and reason multi-facet topic-aware factors underlying the bare connections between associated nodes, by taking advantage of both heterogeneous structures and unstructured text content in HGs. Specifically, we proposed a novel framework THGNN for link prediction to distinctively aggregate rich heterogeneous information according to the inferential multi-facet topic-aware factors, so as to generate multi-facet topic-aware representations preserving both structural and topic-aware semantics. Moreover, we incorporated a topic prior guidance module, which aims to leverage global knowledge from unstructured text content, to further improving the quality of multi-facet topic-aware embeddings. Experiments show that the learned multi-facet topic-aware node embeddings are more predictive and interpretable.

7 ACKNOWLEDGMENTS

This research is supported in part by the National Natural Science Foundation of China (No. U20B2045, 61772082, 62002029), the Fundamental Research Funds for the Central Universities 2020RC23, and Meituan.

REFERENCES

[1] Yoshua Bengio, Aaron Courville, and Pascal Vincent. 2013. Representation learning: A review and new perspectives. *IEEE transactions on pattern analysis and machine intelligence* 35, 8 (2013), 1798–1828.

[2] Filippo Maria Bianchi, Daniele Grattarola, and Cesare Alippi. 2020. Spectral clustering with graph neural networks for graph pooling. In *ICML*. PMLR, 874–883.

[3] Joan Bruna, Wojciech Zaremba, Arthur Szlam, and Yann LeCun. 2013. Spectral networks and locally connected networks on graphs. *arXiv preprint arXiv:1312.6203* (2013).

[4] Ting Chen and Yizhou Sun. 2017. Task-guided and path-augmented heterogeneous network embedding for author identification. In *WSDM*. 295–304.

[5] Yuxiao Dong, Nitesh V Chawla, and Ananthram Swami. 2017. metapath2vec: Scalable representation learning for heterogeneous networks. In *KDD*. 135–144.

[6] Shaohua Fan, Junxiong Zhu, Xiaotian Han, Chuan Shi, Linmei Hu, Biyu Ma, and Yongliang Li. 2019. Metapath-guided heterogeneous graph neural network for intent recommendation. In *KDD*. 2478–2486.

[7] Tao-yang Fu, Wang-Chien Lee, and Zhen Lei. 2017. Hin2vec: Explore meta-paths in heterogeneous information networks for representation learning. In *CIKM*. 1797–1806.

[8] Xinyu Fu, Jiani Zhang, Ziqiao Meng, and Irwin King. 2020. MAGNN: metapath aggregated graph neural network for heterogeneous graph embedding. In *WWW*. 2331–2341.

[9] Spyros Gidaris, Praveer Singh, and Nikos Komodakis. 2018. Unsupervised representation learning by predicting image rotations. *arXiv preprint arXiv:1803.07728* (2018).

[10] William L Hamilton, Rex Ying, and Jure Leskovec. 2017. Inductive representation learning on large graphs. *arXiv preprint arXiv:1706.02216* (2017).

[11] Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, and Alexander Lerchner. 2016. beta-vae: Learning basic visual concepts with a constrained variational framework. (2016).

[12] Jun-Ting Hsieh, Bingbin Liu, De-An Huang, Li Fei-Fei, and Juan Carlos Niebles. 2018. Learning to decompose and disentangle representations for video prediction. *arXiv preprint arXiv:1806.04166* (2018).

[13] Binbin Hu, Chuan Shi, Wayne Xin Zhao, and Philip S Yu. 2018. Leveraging meta-path based context for top-n recommendation with a neural co-attention model. In *KDD*. 1531–1540.

[14] Binbin Hu, Zhiqiang Zhang, Chuan Shi, Jun Zhou, Xiaolong Li, and Yuan Qi. 2019. Cash-out user detection based on attributed heterogeneous information network with a hierarchical attention mechanism. In *AAAI*. 946–953.

[15] Linmei Hu, Siyong Xu, Chen Li, Cheng Yang, Chuan Shi, Nan Duan, Xing Xie, and Ming Zhou. 2020. Graph neural news recommendation with unsupervised preference disentanglement. In *ACL*. 4255–4264.

[16] Hyunjik Kim and Andriy Mnih. 2018. Disentangling by factorising. In *ICML*. PMLR, 2649–2658.

[17] Thomas N Kipf and Max Welling. 2016. Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907* (2016).

[18] Yanbei Liu, Xiao Wang, Shu Wu, and Zhitao Xiao. 2020. Independence promoted graph disentangled networks. In *AAAI*. 4916–4923.

[19] Jianxin Ma, Peng Cui, Kun Kuang, Xin Wang, and Wenwu Zhu. 2019. Disentangled graph convolutional networks. In *ICML*. PMLR, 4212–4221.

[20] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. 2013. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781* (2013).

[21] Bryan Perozzi, Rami Al-Rfou, and Steven Skiena. 2014. Deepwalk: Online learning of social representations. In *KDD*. 701–710.

[22] Jingbo Shang, Meng Qu, Jialu Liu, Lance M Kaplan, Jiawei Han, and Jian Peng. 2016. Meta-path guided embedding for similarity search in large-scale heterogeneous information networks. *arXiv preprint arXiv:1610.09769* (2016).

[23] Chuan Shi, Binbin Hu, Wayne Xin Zhao, and S Yu Philip. 2018. Heterogeneous information network embedding for recommendation. *IEEE Transactions on Knowledge and Data Engineering* 31, 2 (2018), 357–370.

[24] Yizhou Sun, Jiawei Han, Xifeng Yan, Philip S Yu, and Tianyi Wu. 2011. Pathsim: Meta path-based top-k similarity search in heterogeneous information networks. *Proceedings of the VLDB Endowment* 4, 11 (2011), 992–1003.

[25] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. *arXiv preprint arXiv:1706.03762* (2017).

[26] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Lio, and Yoshua Bengio. 2017. Graph attention networks. *arXiv preprint arXiv:1710.10903* (2017).

[27] Xiang Wang, Xiangnan He, Meng Wang, Fuli Feng, and Tat-Seng Chua. 2019. Neural graph collaborative filtering. In *Proceedings of the 42nd international ACM SIGIR conference on Research and development in Information Retrieval*. 165–174.

[28] Xiao Wang, Houye Ji, Chuan Shi, Bai Wang, Yanfang Ye, Peng Cui, and Philip S Yu. 2019. Heterogeneous graph attention network. In *WWW*. 2022–2032.

[29] Xiang Wang, Hongye Jin, An Zhang, Xiangnan He, Tong Xu, and Tat-Seng Chua. 2020. Disentangled Graph Collaborative Filtering. In *SIGIR*. 1001–1010.

[30] Yifan Wang, Suyao Tang, Yuntong Lei, Weiping Song, Sheng Wang, and Ming Zhang. 2020. DisenHAN: Disentangled Heterogeneous Graph Attention Network for Recommendation. In *CIKM*. 1605–1614.

[31] Yiding Yang, Zunlei Feng, Mingli Song, and Xinchao Wang. 2020. Factorizable graph convolutional networks. *arXiv preprint arXiv:2010.05421* (2020).

[32] Chuxu Zhang, Chao Huang, Lu Yu, Xiangliang Zhang, and Nitesh V Chawla. 2018. Camel: Content-aware and meta-path augmented metric learning for author identification. In *WWW*. 709–718.

[33] Jiawei Zhang, Congying Xia, Chenwei Zhang, Limeng Cui, Yanjie Fu, and S Yu Philip. 2017. BL-MNE: emerging heterogeneous social network embedding through broad learning with aligned autoencoder. In *ICDM*. IEEE, 605–614.

[34] Yizhou Zhang, Yun Xiong, Xiangnan Kong, Shanshan Li, Jinhong Mi, and Yangyong Zhu. 2018. Deep collective classification in heterogeneous information networks. In *WWW*. 399–408.

AdaSGN: Adapting Joint Number and Model Size for Efficient Skeleton-Based Action Recognition

Lei Shi[1,2] Yifan Zhang[1,2*] Jian Cheng[1,2,3] Hanqing Lu[1,2]
[1]National Laboratory of Pattern Recognition, Institute of Automation, Chinese Academy of Sciences
[2]University of Chinese Academy of Sciences
[3]CAS Center for Excellence in Brain Science and Intelligence Technology
{lei.shi, yfzhang, jcheng, luhq}@nlpr.ia.ac.cn

Abstract

Existing methods for skeleton-based action recognition mainly focus on improving the recognition accuracy, whereas the efficiency of the model is rarely considered. Recently, there are some works trying to speed up the skeleton modeling by designing light-weight modules. However, in addition to the model size, the amount of the data involved in the calculation is also an important factor for the running speed, especially for the skeleton data where most of the joints are redundant or non-informative to identify a specific skeleton. Besides, previous works usually employ one fix-sized model for all the samples regardless of the difficulty of recognition, which wastes computations for easy samples. To address these limitations, a novel approach, called AdaSGN, is proposed in this paper, which can reduce the computational cost of the inference process by adaptively controlling the input number of the joints of the skeleton on-the-fly. Moreover, it can also adaptively select the optimal model size for each sample to achieve a better trade-off between the accuracy and the efficiency. We conduct extensive experiments on three challenging datasets, namely, NTU-60, NTU-120 and SHREC, to verify the superiority of the proposed approach, where AdaSGN achieves comparable or even higher performance with much lower GFLOPs compared with the baseline method.

1. Introduction

Action recognition is a popular research topic due to its wide range of application scenarios such as human-computer interaction and video surveillance [2, 29, 7, 25]. Recently, different with conventional approaches that use RGB sequences for input, exploiting the skeleton data for action recognition has drawn increasingly more attention [38, 4, 27, 19]. Biologically, human is able to recognize the action category by observing only the motion of joints even without the appearance information [10]. Skeleton is such a data modality that consists of only the 2D/3D positions of the human key joints. Compared with the RGB data, it has smaller amount of data, higher-level semantic information and stronger robustness for complicated environment.

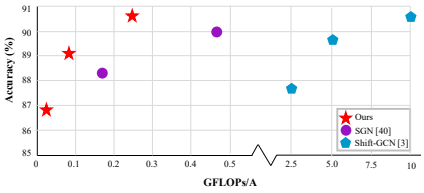

Figure 1. GFLOPs v.s. accuracy on NTU-60 (CS) dataset for state-of-the-art methods.

In early stage, approaches for skeleton-based action recognition mainly focus on designing various hand-crafted features [33]. With the success of the deep learning, various deep networks have been proposed for skeleton-based action recognition [39, 14, 12, 1, 38, 27]. However, the computational complexity of the state-of-the-art deep networks are too heavier, most of which are higher than 15 GFLOPs [3]. For example, the representative GCN-based work, i.e., ST-GCN [38], costs 16.2 GFLOPs for one action sample. In the practical application scenario, speed is an important factor. Thus, how to speed up the current methods is a valuable-researched topic.

Recently, some works propose to speed up the skeleton modeling by designing light-weight models, such as Shift-GCN [3] and SGN [40]. However, in addition to the model size, the amount of the data involved in the calculation is also an important factor affecting the running time, which

*Corresponding Author

is rarely considered in previous works. Especially for the skeleton data, to identify a specific action, many of the joints in the skeleton sequence are actually redundant. For example, to recognize the action "swipe right", the global motion information is the key factor, which means the trajectory of the central point is discriminative enough for recognition. Thus, for various samples, it is unnecessary to always use all the joints for computation. Besides, for a specific action sequence, there are multiple stages, such as the starting stage, the course stage and the ending stage [41]. Some of the stages are always non-informative, e.g., the beginning and the ending, which should not been exhaustively analysed with all of the joints. Furthermore, the difficulty of recognition varies for different actions. Previous works employ one fix-sized model for all the samples, which wastes computations for easy samples. For example, it is obvious that distinguishing the "walking" vs. "lying" is easier than distinguishing the "brushing hair" vs. "brushing teeth", so instead of using the same model, it is better to apply big models for hard samples whereas applying small models for easy samples.

To address these limitations, we propose a novel approach, called adaptive SGN (AdaSGN), for efficient skeleton-based action recognition. SGN [40] is already a very light-weight (only 0.7M) model for skeleton-based action recognition and is the baseline method in this paper. Compared with SGN, our AdaSGN can further reduce more than half of the GFLOPs with even higher performance. In detail, AdaSGN learns a policy network to adaptively select the optimal joint number and the optimal model size to control the trade-off between the accuracy and the efficiency. The policy network is designed as a light-weight module and is calculated with the features of the smallest number of joints, which costs nearly no additional computational cost. It outputs policies according to the input sample to decide on-the-fly which model size and which joint number should be used for each skeleton. Because the decisions are in a discrete distribution and the decision process is non-differentiable, we employ the Straight-Through (ST) Gumbel Estimator [9] to back-propagate gradients. Thus, the proposed method is a fully differentiable framework and can be trained in an end-to-end manner. The training loss is the combination of an efficiency loss and an accuracy loss, where the proportions of the two terms can be adjusted to control the accuracy-efficiency trade-off.

To verify the superiority of the proposed approaches, extensive experiments are performed on three popular datasets, namely, NTU-60, NTU-120 and SHREC, where our method achieves comparable or even higher performance with much lower GFLOPs. For example, we achieve +0.5%/+0.4% improvements of accuracy using only 39.6%/31.3% GFLOPs on CS/CV benchmarks of the NTU-60 dataset compared with the baseline method. Figure 1 shows the GFLOPs vs. accuracy diagram on the CS benchmark of the NTU-60 dataset.

Our contributions can be summarized as follows:

1. We propose a novel approach that can adaptively select both the optimal joint number and the optimal model size for efficient skeleton modeling.
2. We design a light-weight policy network and train it with the ST Gumbel Estimator to make it highly efficient.
3. We conduct extensive experiments on three benchmark datasets to demonstrate the superiority of our approach over state-of-the-art methods. Code will be released.

2. Related Work

2.1. Skeleton-based action recognition

Early-stage approaches for skeleton-based action recognition focus on designing various hand-crafted features [33]. With the success of the deep learning in the computer vision field, the data-driven methods have become the mainstream, which can be roughly divided into three kinds: RNN-based methods [39, 14, 31, 30], CNN-based methods [12, 18, 1] and GCN-based methods [38, 32, 27, 26]. Recently, GCN-based methods have shown significant performance boost compared with other methods, indicating the necessity of the semantic human skeleton for action recognition. ST-GCN [38] is the first work to use GCN for skeleton-based action recognition, which aggregates the information of joints in a local area according to a predefined human body graph. After that, Shi et al. [27] propose an adaptive graph convolutional network to adapt the graph building process with the self-attention mechanism. They also introduce a two-stream framework to use both the joint information and the bone information. Peng et al. [22] turn to Neural Architecture Search (NAS) to automatically design GCN for skeleton-based action recognition. Liu et al. [19] disentangle the importance of nodes in different neighborhoods for effective long-range modeling. They also leverage the features of adjacent frames to capture complex spatial-temporal dependencies. However, these works did not consider an important factor for practical applications, i.e., the speed of the model. In contrast, our approach considers both the accuracy and the efficiency, which can adaptively adjust their trade-offs on demand.

2.2. Efficient Skeleton-based action recognition

Recently, there are some works trying to design efficient models for skeleton-based action recognition [3, 40]. Cheng et al. [3] (ShiftGCN) introduce two kinds of spatial shift graph operations to replace the heavy regular graph convolutions, which is more efficient and achieves strong performance. They also propose two kinds of temporal shift graph

operation to outperform regular temporal models with less computational complexity. Zhang et al. [40] (SGN) propose to explicitly exploit the high-level information, i.e., the joint type and the frame index, to enhance the feature representation capability. Thus, they can use a smaller model to achieve a comparable performance compared with previous works. These methods mainly focus on designing light-weight modules. In contrast, our proposed method not only reduce the parameters of the model, but also reduce the amount of the data being processed, which is more efficient than previous works.

2.3. Efficient RGB-based Action Recognition

For efficient RGB-based action recognition, there are mainly two streams of methods. One stream is to design light-weight or light-GFLOPs modules [23, 37, 15, 6]. For example replacing the 3D convolution with the 2+1D convolutional operation [23] or replacing the temporal convolution with the temporal shift operation [15]. Another stream is the key-frame-based methods, which selects a small number of frames instead of all sequence for recognition to reduce the overall computational cost [42, 36, 11, 35, 20]. For example, Wu et al. [36] propose to adaptively decide where to look next in an action sequence and whether the current prediction credible enough based on the current frame. They use recurrent models for policy network and use Reinforcement Learning methods to train it. Wu et al. [34] propose a multi-agent reinforcement learning framework, where each agent sample one frame based on the move instructions made by the policy network. Korbar et al. [11] introduce a lightweight "clip-sampling" model to identify the most salient temporal clips for a long video. Meng et al. [20] propose to adaptively select frames with the optimal resolution. They also use the recurrent models for policy network but train it with the Gumbel-Softmax tricks [9], which has lower variance.

While our approach is inspired by the key-frame-based methods, it is specially designed for the skeleton data, which can adaptively select not only the key skeletons (frames), but also the optimal model size and the optimal joint number for each human skeleton.

3. Methods

3.1. Preliminaries

Notations. A human action in skeleton format is represented as a skeleton sequence, which is denoted as $\mathcal{X} = \{X_t\}_{t=0}^{T-1}$. $X_t \in \mathbb{R}^{N \times C}$ is the 2D/3D coordinates of N human key joints at time t. T is the length of the sequence. C denotes the coordinate dimension. If there are multiple persons, they are processed separately and the classification scores are averaged [38, 27].

GCN. Graph convolutional network (GCN) has been widely used for skeleton-based action recognition [38, 26]. A graph convolutional operation can be formulated as

$$Y_t = A_t X_t W \tag{1}$$

where $A_t \in \mathbb{R}^{N \times N}$ is the normalized adjacency matrix, which denotes the graph topology. $W \in \mathbb{R}^{C_{in} \times C_{out}}$ denotes the convolutional weight. $X_t \in \mathbb{R}^{N \times C_{in}}$ and $Y_t \in \mathbb{R}^{N \times C_{out}}$ denote the input and output. One GCN layer consists of one graph convolutional operation, one BN operation [8] and one ReLu activation function [21]. Multiple GCN layers can be stacked to enable further message passing among nodes with the same adjacency matrix.

In order to make the graph topology more flexible, A_t can be adaptively learned to form the adaptive GCN layer [26] as

$$A_t = SoftMax(\theta(X_t)\phi(X_t)^T) \tag{2}$$

where θ and ϕ denote two linear transformation functions, e.g., two 1-D convolutional layers whose kernel size is 1.

SGN. Semantics-guided neural network (SGN) [40] is a light-weight GCN-based model for efficient skeleton-based action recognition, which is used as the baseline method in this paper. As shown in Figure 2 (left), SGN consists of multiple spatial modules (SM) and one temporal module (TM). SM (blue blocks) consists of three stacked adaptive GCN layers with the same adjacent matrix introduced in the last section, followed with a spatial max-pooling layer to aggregate joint features into one feature vector. The parameters of all SMs are shared. They are designed for exploiting the intra-frame correlations of joints. TM (green block) is designed for exploiting the correlations across the frames. It first concatenates the output features of SMs into one $T \times C$ matrix. Then two temporal convolutional layers (convolution along the temporal dimension) are appended to model the temporal dependency. After the TM, the feature maps are global-averaged and fed into a fully-connected layer for classification. More details that are irrelevant with our works such as the semantics embedding can refer to the original paper [40].

3.2. AdaSGN

Pipeline overview. Given a skeleton sequence, our goal is to select the optimal joint number and the optimal network size for each skeleton to efficiently extract features and predict actions. In this work, we use SGN [40] as the baseline model because it is already very efficient, which can better exhibit the effectiveness of the proposed method. For SGN, most of the computational costs come from SMs, so we modify the size of SM to control the computations of the whole model.

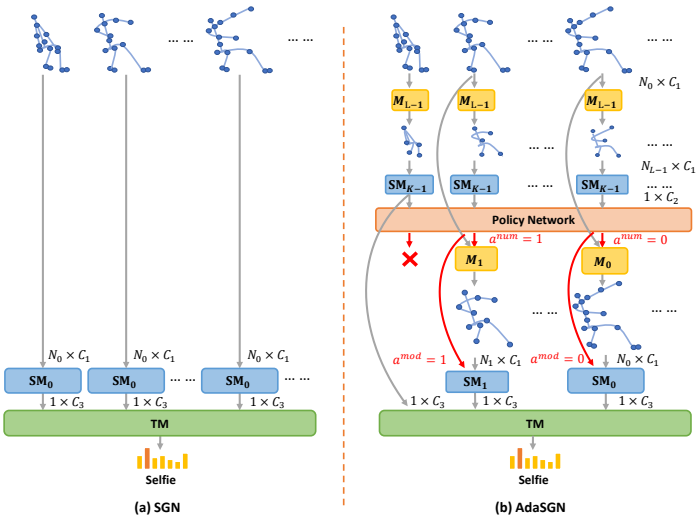

Figure 2. Pipeline of the SGN and the proposed AdaSGN. SM and TM denote the spatial module and the temporal module of the SGN. C denotes the channel number. For AdaSGN, we assume that there are K choices of joint number and L choices of SM size. Firstly, the raw input skeletons are aggregated into the skeletons with the smallest joint number (N_{L-1}) by transformation matrix M_{L-1}, which are fed into the smallest SM (i.e., SM$_{K-1}$) to extract policy features. These policy features are fed into the policy network (orange box) to output actions (a^{num} and a^{mod}) to decide the optimal joint number and SM size for each skeleton. Then, each skeleton is transformed into the skeleton with the optimal joint number and modeled with the optimal-size SM to extract classification features. Finally, the classification features of all skeletons are fed into the temporal network and the classifier to predict the final action label.

Figure 2 (right) illustrates the overview of the proposed method called adaptive SGN (AdaSGN). Firstly, the raw input skeletons are transformed into the smallest-joint-number format, which are fed into the smallest SM to extract policy features. These policy features are fed into a light-weight policy network to output actions to decide the optimal joint number and the optimal SM size for every skeleton in the later steps. Note that this step brings nearly no additional computational cost compared with the later steps because of the light-weight modules and less joint number. Then, according to the decisions of the policy network, each skeleton is transformed into the skeleton with the optimal joint number and is modeled with the optimal-size SM to extract classification features. Finally, the classification features of all skeletons are fed into the temporal network to aggregate temporal correlations, whose outputs are used by the classifier to predict the final action label.

Skeleton transformation. A skeleton sequence is denoted as $\mathcal{X} = \{X_t \in \mathbb{R}^{N \times C}\}$, where each frame consists of N joints. AdaSGN adaptively chooses different joint numbers and model sizes to achieve efficiency. For different joint numbers, we define a sequence of joint numbers in descending orders as $\{N_i\}_{i=0}^{L-1}$. $N_0 = N$ is the maximum number of joints. For different model sizes, we design K SMs with different size in descending order, denoted as $\{\text{SM}_i\}_{i=0}^{K-1}$. SM$_0$ is the original SM in SGN.

To transform the original skeleton with N_0 joints into skeletons with N_i joints, we design a sequence of transformation matrices $\{M_i \in \mathbb{R}^{N_i \times N_0}\}$ as

$$X_t^{N_i} = M_i X_t^{N_0} \tag{3}$$

where $X_t^{N_i}$ denotes skeleton X_t with N_i joints. The design principles of these transformation matrices are grouping semantics-adjacent joints (e.g., the hand and wrist) and average their coordinates. However, it is hard to ensure the optimality of the hand-crafted transformation matrix. Thus, we propose to set these transformation matrices as the model parameters and let the model to adaptively learn them. To stabilize the training in the beginning stage, we manually initialize these matrices and fixed them in the first several training epochs.

Policy Network. Through the combination of different models and different joint numbers, there are totally $K \times L$ choices with different GFLOPs for each skeleton, which formulates our action space. We first use the smallest number of joints, i.e., N_{L-1}, and the smallest SM, i.e., SM_{K-1}, to extract the policy features of each skeleton as

$$F_t^{pol} = \text{SM}_{K-1}(M_{L-1}X_t^{N_0}) \tag{4}$$

The policy features of all frames are concatenated as a $T \times C$ matrix, which is fed into the policy network f to output the action probabilities $P \in \mathbb{R}^{T\times(KL)}$ as

$$P = SoftMax(f(Concat(\{F_t^{pol}\}_{t=0}^{T-1}))) \tag{5}$$

Here, we tried different modules for f, such as LSTM, Transformer and temporal convolution. The temporal convolution (convolution along the temporal dimension) is used in the final because it achieves the best performance.

Given the probabilities, we can get the discrete actions a through $\arg\max$. However, directly perform $\arg\max$ is not differentiable. Here, we use the Straight-Through (ST) Gumbel Estimator [9] to solve this problem. In detail, during the forward process, we use Gumbel-Max to sample a skeleton-level action according to the action probabilities

$$a_t = \arg\max_i(logP_{t,i} + G_{t,i}) \tag{6}$$

where $G_{t,i} = -log(-logU_{t,i})$ is a standard Gumbel distribution. $U_{t,i}$ is sampled from a uniform i.i.d distribution, i.e., $U_{t,i} \sim Uniform(0, 1)$. Because $\arg\max$ is non-differentiable, in order to back-propagating gradients to the policy network, the continuous Gumbel-SoftMax is used to relax the Gumbel-Max in the back-propagation process as

$$\tilde{a_t} = \frac{\exp(logP_{t,i} + G_{t,i})/\tau}{\sum_{j=0}^{KL}\exp(logP_{t,j} + G_{t,j})/\tau} \tag{7}$$

By denoting $\hat{a_t} = one_hot(a_t)$ as the one-hot action vector, we treat $\tilde{a_t}$ as the continuous approximation of $\hat{a_t}$, i.e., $\nabla_\theta \tilde{a_t} \approx \nabla_\theta \hat{a_t}$. τ is the temperature parameter. For small temperatures, samples from the Gumbel-SoftMax are close to one-hot, i.e., it is more similar with the Gumbel-Max, but the variance of the gradients is large. For large temperatures, the gradients of samples from Gumbel-SoftMax have small variance, but it is more smooth and is more biased compared with the Gumbel-Max in the forward process. In practice, to balance the trade-off between the variance and bias, we initialize the τ to a high value and gradually anneal it down to a small value during the training as in [9].

Classification After obtaining the action a_t for each skeleton, we split it into the model action a_t^{mod} and the joint number action a_t^{num}, where $a_t = a_t^{mod} \times L + a_t^{num}$. Then we calculate the classification features of each skeleton by

$$F_t^{cls} = \text{SM}_{a_t^{mod}}(M_{a_t^{num}}X_t^{N_0}) \tag{8}$$

If $a_t^{num} = L - 1$ and $a_t^{mod} = K - 1$, we directly use the policy features F_t^{pol} instead of computing it again to reduce the computational cost (like the red fork in Figure 2, right). The classification features are fed into the TM and the classifier g to get the final output as

$$Y = SoftMax(g(\text{TM}(\{F_t^{cls}\}_{t=0}^{T-1}))) \tag{9}$$

where g consists of one global-max-pooling layer and one fully-connected layer.

3.3. Loss Function

The total loss function consists of two terms: one accuracy loss ($\mathcal{L}^{acc}$) and one efficiency loss ($\mathcal{L}^{eff}$) as

$$\mathcal{L} = \mathcal{L}^{acc} + \alpha\mathcal{L}^{eff} \tag{10}$$

where α is used to control the trade-off between the accuracy and the efficiency.

$\mathcal{L}^{acc}$ is the standard cross-entropy loss as

$$\mathcal{L}^{acc} = \mathbb{E}_{(\mathcal{X},y)} \sim \mathcal{D}^{train}(-ylog(\mathcal{F}(\mathcal{X};\Theta))) \tag{11}$$

where $(\mathcal{X}, y)$ is the training skeleton sequences and the associate one-hot action label. $\mathcal{F}$ denotes the model and Θ denotes the model parameters. $\mathcal{D}^{train}$ denotes the training data. $\mathcal{L}^{acc}$ only effect the classification quality of the model.

$\mathcal{L}^{eff}$ controls the computational cost of the model. Because we use different sizes of networks and different number of joints based on the choices of the policy network, we calculate the GFLOPs of all these choices and use the mean GFLOPs as the loss term to encourage the less-computation operations as

$$\mathcal{L}^{eff} = \mathbb{E}_{(\mathcal{X},y)} \sim \mathcal{D}^{train}(\frac{1}{T}\sum_{t=0}^{T-1} GFLOPS^{\mathcal{F}}(a_t)) \tag{12}$$

where $GFLOPs^{\mathcal{F}}$ is the pre-build GFLOPs lookup table for all action choices.

4. Experiments

4.1. Dataset

We perform extensive experiments on NTU-60 [24], NTU-120 [17] and SHREC [5]. NTU-60 recommends two benchmarks: cross-subject (CS) and cross-view (CV). NTU-120 recommends two benchmarks: cross-subject (CS) and cross-setup (CE). SHREC recommends two benchmarks: 14 gestures (14G) and 28 gestures (28G). Details of these datasets are provided in the supplementary material.

4.2. Implement Details

Due to the space limitation, the complete training scheme and the architecture details are provided in the supplement material. We choose three ($L = 3$) joint numbers ($N_i = \{1, 9, 25\}$ for NTU-60/120 and $N_i = \{1, 11, 22\}$ for SHREC) and two ($K = 2$) model sizes (SM_0 and SM_1). Thus, there are totally six choices, i.e., $a_t = \{0, 1, 2, 3, 4, 5\}$, for policy network. When training, we first pretrain the single models with different number of joints. We show the GFLOPs and accuracies of the six choices on NTU-60 on Table 1. * denotes adding the transform matrix as introduced in Eq. 3. Compared with the original SGN, adaptively learning the transform matrix (SGN*) brings consistent improvements on both CS and CV benchmarks. It means it is better to appropriately adjust the original input skeletons. Besides, using less joints (9 or 1) reduce the GFLOPs of the model, but it also causes the drop of the accuracy.

Table 1. Recognition accuracy and GFLOPS of single models (%) with different number of joints on NTU-60. * denotes adaptively transforming the number of joints into target numbers.

Methods	#joints	CS(%)	CV(%)	GFLOPs
SM_1	25	87.1	92.9	0.078
SM_1*	25	87.9	93.3	0.078
SM_1*	9	86.7	92.3	0.033
SM_1*	1	63.6	74.1	0.009
SM_0	25	88.4	94.1	0.160
SM_0*	25	88.9	94.5	0.160
SM_0*	9	87.2	92.9	0.062
SM_0*	1	64.9	74.7	0.013

After pretraining the single models, we first load the pretrained parameters of the transform matrices and the SMs of these single models for AdaSGN. Then, it is trained using the same training schemes as the single models. For policy network, the τ of the Gumbel-SoftMax is initialized to 5 and linearly reduced ($\times 0.096$) at each epoch. α is gradually increased from 0 to the target value during the first 5 epochs. It is because we hope the model can focus more on the accuracy in the beginning training stage. Table 2 shows the importance of the pretraining on NTU-60 dataset. We set $\alpha = 4$ when not using pretrained models (i.e., "w/o pretrain") for both CS and CV benchmarks. To keep the same GFLOPS for fair comparison, we set $\alpha = 4$ and $\alpha = 1$ when using pretrained models (i.e., "w/ pretrain") for CS benchmark and CV benchmark, respectively. It shows using pretrained models can bring more than 2% improvement of the accuracy with the same GFLOPs.

Table 2. Recognition accuracy (%) and GFLOPS of Ada-Ske using different training scheme on NTU-60. "w/o" and "w/" denote "without" and "with".

Strategy	CS		CV	
	ACC(%)	GFLOPS	ACC(%)	GFLOPS
w/o pretrain	87.0	0.07	92.2	0.10
w/ pretrain	89.1	0.07	94.7	0.10

4.3. Trade-Off between ACC(%) and Efficiency

By adjusting the α, we can control the trade-off between accuracy and efficiency. We show the accuracy, GFLOPS and the percent of action choices for different α on Table 3. B and S denote using the big SM (SM_0) and the small SM (SM_1), respectively. With the increase of α, the GFLOPS decreases, and the accuracy first increases and then decreases. It is because most of the joints in the skeleton data are redundant, appropriately reducing the joint points can reduce the noise and make the model pay more attention to the important features. When $\alpha = 0$, only the loss of accuracy works, so AdaSGN uses only the biggest model (SM_0) and all of the joints (25). When increasing α, it chooses different number of joints and different models for different samples and frames to balance the accuracy and efficiency. For CS benchmark, when set $\alpha = 4$, it achieves a good trade-off between the accuracy and efficiency. It achieves 0.3% improvement of accuracy with only 43.8% GFLOPS compared with $\alpha = 0$. For CV benchmark, when set $\alpha = 0.5$, it obtains 0.2% improvement of accuracy with only 62.5% GFLOPS compared with $\alpha = 0$.

Besides, we test two other policies, i.e., "rand" and "fuse". "rand" denotes randomly selecting the actions, where the probability of every action choice is 16.7%. It achieves lowest performance with medium GFLOPs. Compared with $\alpha = 4$ setting, it needs nearly the same GFLOPs (0.06 vs. 0.07), but it achieves much lower accuracies (85.6% vs. 89.1% on CS and 91.2% vs. 94.6% on CV). "fuse" denotes directly fusing the scores of all the models, where the probability of every action choice is 100%. It needs much more GFLOPs because it calculates all models. Compared with $\alpha = 4$, it brings only $0.2\%/0.3\%$ improvements on CS/CV benchmark, but it requires 4.6 times GFLOPs. These two comparisons confirm the necessary of adaptively selecting suitable actions for different samples and frames.

For better visualization, we plot the accuracy-efficiency trade-off of NTU-60 on Figure 3. Using this curve we can better set a good α depending on the demand. We also plot similar curves for NTU-120 and SHREC in the supplement material, which shows consistent results.

Table 3. Recognition accuracy (%), GFLOPS and Percentages (%) of the actions of Ada-Ske using different weights (α) for efficient loss on NTU-60. "S" and "B" denotes S-SGCN and SM_0, repectively. 1, 9 and 25 is the number of joints. "rand" denotes randomly select

α	CS								CV							
	ACC(%)	GFLOPs	Actions(%)						ACC(%)	GFLOPs	Actions(%)					
			S-1	B-1	S-9	B-9	S-25	B-25			S-1	B-1	S-9	B-9	S-25	B-25
0.0	88.8	0.16	0.01	0.01	0.00	0.01	0.01	99.96	94.6	0.16	0.01	0.01	0.01	0.01	0.01	99.95
0.1	88.9	0.12	0.08	0.05	33.96	0.06	0.12	65.72	94.7	0.16	0.02	0.01	0.01	0.01	0.01	99.94
0.5	88.9	0.10	24.55	0.12	16.28	0.09	0.07	58.90	94.8	0.10	40.68	0.01	0.01	0.01	0.01	59.29
1.0	88.9	0.10	41.04	0.01	0.01	0.01	0.01	58.91	94.7	0.10	42.75	0.03	0.68	0.03	0.02	56.49
2.0	89.0	0.09	44.70	0.02	0.02	0.02	0.02	55.23	94.7	0.09	44.18	0.05	0.01	7.77	0.00	47.98
4.0	89.1	0.07	48.36	0.01	0.01	16.47	0.01	35.14	94.6	0.07	52.98	4.07	0.03	0.02	0.02	42.89
8.0	87.2	0.04	52.76	0.01	0.01	47.21	0.01	0.00	93.0	0.05	48.16	1.17	0.02	50.65	0.00	0.01
10.0	86.9	0.03	56.73	0.01	0.01	43.25	0.01	0.00	92.8	0.04	52.09	1.40	0.01	46.49	0.01	0.00
20.0	85.9	0.02	73.27	0.03	0.00	26.68	0.00	0.00	91.6	0.03	77.40	3.41	0.00	14.45	0.00	4.74
rand	85.6	0.06	16.7	16.7	16.7	16.7	16.7	16.7	91.2	0.06	16.7	16.7	16.7	16.7	16.7	16.7
fuse	89.3	0.32	100	100	100	100	100	100	94.9	0.32	100	100	100	100	100	100

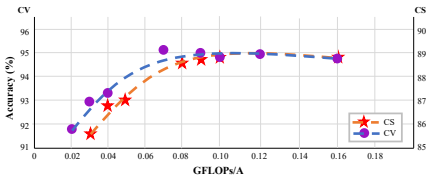

Figure 3. GFLOPs v.s. accuracy for AdaSGN on NTU-60 dataset.

4.4. Comparison with SOTA

Table 4. Comparison with the state-of-the-arts on NTU-60.

Methods	CS		CV	
	ACC(%)	GFLOPS	ACC(%)	GFLOPS
ST-GCN [38]	81.5	16.3	88.3	16.3
ASGCN [13]	86.8	27.0	94.2	27.0
AGCN [27]	88.5	35.8	95.1	35.8
MS-G3D [19]	91.5	48.8	96.2	48.8
DSTA-Net [28]	91.5	55.6	96.4	55.6
ShiftGCN [3]	90.7	10.0	96.5	10.0
SGN [40]	89.0	0.80	94.5	0.80
1s-SGN [40]	88.4	0.16	94.1	0.16
1s-AdaSGN	89.1	0.07	94.6	0.07
3s-SGN [40]	90.0	0.48	94.9	0.48
3s-AdaSGN	90.5	0.19	95.3	0.15

We compare the proposed AdaSGN with the other state-of-the-art approaches on NTU-60/120 and SHREC datasets as shown in Table 4 and Table 6. Original SGN randomly select 5 sequences and average the scores to obtain the prediction. It is denoted as "SGN". We implement it using one sequence for fair comparison and denote it as "1s-SGN". Because the "bone" and "velocity" information has been shown great complementarity with the original data [27, 28], we fuse them in a three-stream framework, which is denoted as"3s-SGN". In detail, we train three models using the "joint", "bone" and "velocity" respectively and average their classification scores for prediction. "1s-AdaSGN" and "3s-AdaSGN" are named in the same manner.

Results of NTU-60 are shown in Table 4. The first group of approaches, i.e., ST-GCN [38], ASGCN [13], etc, only consider the performance; thus, they use a large amount of computational budgets. The second group of approaches, i.e., ShiftGCN [3] and SGN [40], are designed for both accuracy and efficiency. They achieve slightly lower accuracy but much faster speed. Our methods (AdaSGN) are based on SGN. Compared with 1s-SGN, 1s-AdaSGN ($\alpha = 4$) achieves higher accuracy ($+0.7\%/+0.5\%$) with less than half of the GFLOPS (43.8%/43.8%) on CS/CV benchmarks. Similarly, 3s-AdaSGN also brings $+0.5\%/+0.4\%$ improvements with nearly a third of the GFLOPS (39.6%/31.3%) on CS/CV benchmarks. Compared with the DSTA-Net [28] which achieves highest accuracy, our method is 200 times faster with only 1% drop of accuracy. We also plot the scatter diagram on Figure 1, which intuitively shows the superiority of our method.

We also compared our method with the state-of-the-arts on NTU-120, which is larger and more challenging compared with NTU-60, and SHREC, which is used for skeleton-based hand gesture recognition. As shown in Ta-

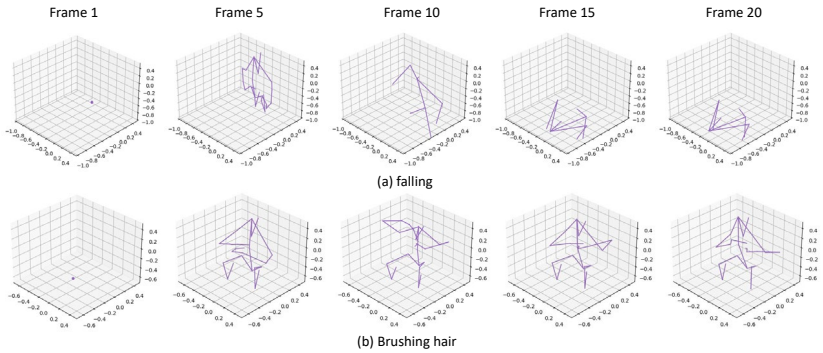

Figure 4. Qualitative examples from NTU-60. Each sample has 20 frames and we show 5 of them evenly. Non-informative skeletons are transformed into skeletons with less points while other informative skeletons are kept with the original point numbers.

Table 5. Comparison with the state-of-the-arts on NTU-120.

Methods	CS		CE	
	ACC(%)	GFLOPS	ACC(%)	GFLOPS
AGCN [27]	82.9	35.8	84.9	35.8
MS-G3D [19]	86.9	48.8	88.4	48.8
DSTA-Net [28]	86.6	55.6	89.0	55.6
ShiftGCN [3]	85.9	10.0	87.6	10.0
SGN [40]	79.2	0.80	81.5	0.80
1s-SGN [40]	82.1	0.16	82.2	0.16
1s-AdaSGN	83.3	0.08	83.6	0.08
3s-SGN [40]	85.5	0.48	86.3	0.48
3s-AdaSGN	85.9	0.21	86.8	0.26

Table 6. Comparison with the state-of-the-arts on SHREC.

Methods	14G		28G	
	ACC(%)	GFLOPS	ACC(%)	GFLOPS
ST-GCN [38]	92.7	7.2	87.7	7.2
HPEV [16]	94.9	1.46	92.3	1.46
DSTA-Net [28]	97.0	14.4	93.9	14.4
1s-SGN [40]	94.8	0.15	92.3	0.15
1s-AdaSGN	94.9	0.05	92.3	0.05
3s-SGN [40]	96.3	0.45	93.8	0.45
3s-AdaSGN	96.3	0.21	94.0	0.23

ble 5 and Table 6, these two datasets show consistent results with NTU-60, which further verified the effectiveness and generalizability of our method.

4.5. Qualitative Results

Figure 4 shows some qualitative examples from NTU-60 dataset. We uniformly sample 5 skeletons from each skeleton sequence and show them in the 3-dimension coordinate system. Note that the coordinates of the human joints are transformed by the adaptively learned transformation matrix. They are a little different with the original joints in the camera coordinate system.

It shows the policy network choose different number of joints for different samples and different skeletons. For example, the first skeleton of the skeleton sequence in NTU is always the action independent preparation stage; thus, the policy network skip these skeletons. For action "falling", the action is mainly determined by the posture of the whole body. So the policy network uses a part of joints (9-joint) for later skeletons. But for action "brushing hair", the action is recognized based on the details of the hand and head. Thus, the policy network keeps the original number of joints (25-joint) for later skeletons. More qualitative results are provided in the supplement material.

5. Conclusion

In this paper, we propose a novel approach, called AdaSGN, for efficient skeleton-based action recognition. It can adaptively select the optimal joint number and the optimal model size for each skeleton to balance the trade-off between the accuracy and the efficiency. A light-weight policy network is designed to generate such selections and is trained with the ST Gumbel Estimator to make this process highly efficient. To verify the superiority of the proposed methods, extensive experiments are performed on three challenging datasets, where our method achieves consistent improvement in accuracy and significant savings in

GFLOPs.

Future works can explore how to adaptively select the specific joint instead of the number of joints, which should be more flexible for various samples. Besides, it is also worth to exploring how to achieve the stepless adjustment for both the model size and the joint numbers, which can avoid the manual settings of the candidates.

References

[1] C. Cao, C. Lan, Y. Zhang, W. Zeng, H. Lu, and Y. Zhang. Skeleton-Based Action Recognition with Gated Convolutional Neural Networks. *IEEE Transactions on Circuits and Systems for Video Technology*, pages 3247–3257, 2018. 1, 2

[2] Joao Carreira and Andrew Zisserman. Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 6299–6308, July 2017. 1

[3] Ke Cheng, Yifan Zhang, Xiangyu He, Weihan Chen, Jian Cheng, and Hanqing Lu. Skeleton-Based Action Recognition With Shift Graph Convolutional Network. pages 183–192, 2020. 1, 2, 7, 8

[4] Sangwoo Cho, Muhammad Hasan Maqbool, Fei Liu, and Hassan Foroosh. Self-Attention Network for Skeleton-based Human Action Recognition. In *2020 IEEE Winter Conference on Applications of Computer Vision (WACV)*, pages 624–633, Snowmass Village, CO, USA, Mar. 2020. IEEE. 1

[5] Quentin De Smedt, Hazem Wannous, Jean-Philippe Vandeborre, Joris Guerry, Bertrand Le Saux, and David Filliat. SHREC'17 Track: 3D Hand Gesture Recognition Using a Depth and Skeletal Dataset. In I. Pratikakis, F. Dupont, and M. Ovsjanikov, editors, *Eurographics Workshop on 3D Object Retrieval*, pages 1–6, 2017. 5

[6] Christoph Feichtenhofer. X3D: Expanding Architectures for Efficient Video Recognition. pages 203–213, 2020. 3

[7] Christoph Feichtenhofer, Haoqi Fan, Jitendra Malik, and Kaiming He. Slowfast networks for video recognition. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 6202–6211, 2019. 1

[8] Sergey Ioffe and Christian Szegedy. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. In *International Conference on Machine Learning (ICML)*, pages 448–456, 2015. 3

[9] Eric Jang, Shixiang Gu, and Ben Poole. Categorical Reparameterization with Gumbel-Softmax. *arXiv:1611.01144 [cs, stat]*, Aug. 2017. arXiv: 1611.01144. 2, 3, 5

[10] Gunnar Johansson. Visual perception of biological motion and a model for its analysis. *Perception & psychophysics*, 1973. 1

[11] Bruno Korbar, Du Tran, and Lorenzo Torresani. SCSampler: Sampling Salient Clips From Video for Efficient Action Recognition. pages 6232–6242, 2019. 3

[12] Chao Li, Qiaoyong Zhong, Di Xie, and Shiliang Pu. Skeleton-based Action Recognition with Convolutional Neural Networks. In *IEEE International Conference on Multimedia & Expo Workshops (ICMEW)*, pages 597–600, 2017. 1, 2

[13] Maosen Li, Siheng Chen, Xu Chen, Ya Zhang, Yanfeng Wang, and Qi Tian. Actional-Structural Graph Convolutional Networks for Skeleton-Based Action Recognition. pages 3595–3603, 2019. 7

[14] Shuai Li, Wanqing Li, Chris Cook, Ce Zhu, and Yanbo Gao. Independently recurrent neural network (indrnn): Building A longer and deeper RNN. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5457–5466, 2018. 1, 2

[15] Ji Lin, Chuang Gan, and Song Han. TSM: Temporal Shift Module for Efficient Video Understanding. *arXiv:1811.08383 [cs]*, Aug. 2019. arXiv: 1811.08383. 3

[16] Jianbo Liu, Yongcheng Liu, Ying Wang, Veronique Prinet, Shiming Xiang, and Chunhong Pan. Decoupled Representation Learning for Skeleton-Based Gesture Recognition. pages 5751–5760, 2020. 8

[17] Jun Liu, Amir Shahroudy, Mauricio Perez, Gang Wang, Ling-Yu Duan, and Alex C. Kot. NTU RGB+D 120: A Large-Scale Benchmark for 3D Human Activity Understanding. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pages 1–1, 2019. 5

[18] Mengyuan Liu, Hong Liu, and Chen Chen. Enhanced skeleton visualization for view invariant human action recognition. *Pattern Recognition*, 68:346–362, 2017. 2

[19] Ziyu Liu, Hongwen Zhang, Zhenghao Chen, Zhiyong Wang, and Wanli Ouyang. Disentangling and Unifying Graph Convolutions for Skeleton-Based Action Recognition. pages 143–152, 2020. 1, 2, 7, 8

[20] Yue Meng, Chung-Ching Lin, Rameswar Panda, Prasanna Sattigeri, Leonid Karlinsky, Aude Oliva, Kate Saenko, and Rogerio Feris. AR-Net: Adaptive Frame Resolution for Efficient Action Recognition. *arXiv:2007.15796 [cs]*, July 2020. arXiv: 2007.15796. 3

[21] Vinod Nair and Geoffrey E. Hinton. Rectified Linear Units Improve Restricted Boltzmann Machines. Jan. 2010. 3

[22] Wei Peng, Xiaopeng Hong, Haoyu Chen, and Guoying Zhao. Learning Graph Convolutional Network for Skeleton-based Human Action Recognition by Neural Searching. In *AAAI*, 2020. 2

[23] Zhaofan Qiu, Ting Yao, and Tao Mei. Learning Spatio-Temporal Representation with Pseudo-3D Residual Networks. In *The IEEE International Conference on Computer Vision (ICCV)*, pages 5533–5541, Oct. 2017. 3

[24] Amir Shahroudy, Jun Liu, Tian-Tsong Ng, and Gang Wang. NTU RGB+D: A Large Scale Dataset for 3D Human Activity Analysis. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1010–1019, 2016. 5

[25] Lei Shi, Yifan Zhang, Jian Cheng, and Hanqing Lu. Action Recognition via Pose-Based Graph Convolutional Networks with Intermediate Dense Supervision. *arXiv:1911.12509*, Nov. 2019. 1

[26] Lei Shi, Yifan Zhang, Jian Cheng, and Hanqing Lu. Skeleton-Based Action Recognition With Directed Graph Neural Networks. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 7912–7921, June 2019. 2, 3

[27] Lei Shi, Yifan Zhang, Jian Cheng, and Hanqing Lu. Two-Stream Adaptive Graph Convolutional Networks for Skeleton-Based Action Recognition. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 12026–12035, 2019. 1, 2, 3, 7, 8

[28] Lei Shi, Yifan Zhang, Jian Cheng, and Hanqing Lu. Decoupled Spatial-Temporal Attention Network for Skeleton-Based Action-Gesture Recognition. 2020. 7, 8

[29] Lei Shi, Yifan Zhang, Cheng Jian, and Lu Hanqing. Gesture Recognition using Spatiotemporal Deformable Convolutional Representation. In *IEEE International Conference on Image Processing (ICIP)*, Oct. 2019. 1

[30] Chenyang Si, Wentao Chen, Wei Wang, Liang Wang, and Tieniu Tan. An Attention Enhanced Graph Convolutional LSTM Network for Skeleton-Based Action Recognition. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1227–1236, 2019. 2

[31] Chenyang Si, Ya Jing, Wei Wang, Liang Wang, and Tieniu Tan. Skeleton-Based Action Recognition with Spatial Reasoning and Temporal Stack Learning. In *The European Conference on Computer Vision (ECCV)*, pages 103–118, Sept. 2018. 2

[32] Yansong Tang, Yi Tian, Jiwen Lu, Peiyang Li, and Jie Zhou. Deep Progressive Reinforcement Learning for Skeleton-Based Action Recognition. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5323–5332, 2018. 2

[33] Raviteja Vemulapalli, Felipe Arrate, and Rama Chellappa. Human action recognition by representing 3d skeletons as points in a lie group. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 588–595, 2014. 1, 2

[34] Wenhao Wu, Dongliang He, Xiao Tan, Shifeng Chen, and Shilei Wen. Multi-Agent Reinforcement Learning Based Frame Sampling for Effective Untrimmed Video Recognition. pages 6222–6231, 2019. 3

[35] Zuxuan Wu, Caiming Xiong, Yu-Gang Jiang, and Larry S Davis. LiteEval: A Coarse-to-Fine Framework for Resource Efficient Video Recognition. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d\textquotesingle Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems 32*, pages 7780–7789. Curran Associates, Inc., 2019. 3

[36] Zuxuan Wu, Caiming Xiong, Chih-Yao Ma, Richard Socher, and Larry S Davis. AdaFrame: Adaptive Frame Selection for Fast Video Recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019. 3

[37] Saining Xie, Chen Sun, Jonathan Huang, Zhuowen Tu, and Kevin Murphy. Rethinking Spatiotemporal Feature Learning: Speed-accuracy Trade-offs in Video Classification. In *The European Conference on Computer Vision (ECCV)*, pages 305–321, 2018. 3

[38] Sijie Yan, Yuanjun Xiong, and Dahua Lin. Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition. In *AAAI*, pages 1–9, 2018. 1, 2, 3, 7, 8

[39] Pengfei Zhang, Cuiling Lan, Junliang Xing, Wenjun Zeng, Jianru Xue, and Nanning Zheng. View Adaptive Recurrent Neural Networks for High Performance Human Action Recognition From Skeleton Data. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2117–2126, 2017. 1, 2

[40] Pengfei Zhang, Cuiling Lan, Wenjun Zeng, Junliang Xing, Jianru Xue, and Nanning Zheng. Semantics-Guided Neural Networks for Efficient Skeleton-Based Human Action Recognition. pages 1112–1121, 2020. 1, 2, 3, 7, 8

[41] Yue Zhao, Yuanjun Xiong, Limin Wang, Zhirong Wu, Xiaoou Tang, and Dahua Lin. Temporal Action Detection with Structured Segment Networks. *arXiv:1704.06228 [cs]*, Apr. 2017. arXiv: 1704.06228. 2

[42] Wangjiang Zhu, Jie Hu, Gang Sun, Xudong Cao, and Yu Qiao. A key volume mining deep framework for action recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 1991–1999, 2016. 3

End-to-End Video Instance Segmentation with Transformers

Yuqing Wang[1], Zhaoliang Xu[1], Xinlong Wang[2], Chunhua Shen[2], Baoshan Cheng[1], Hao Shen[1]*, Huaxia Xia[1]
[1] Meituan [2] The University of Adelaide, Australia
{wangyuqing06, shenhao04}@meituan.com

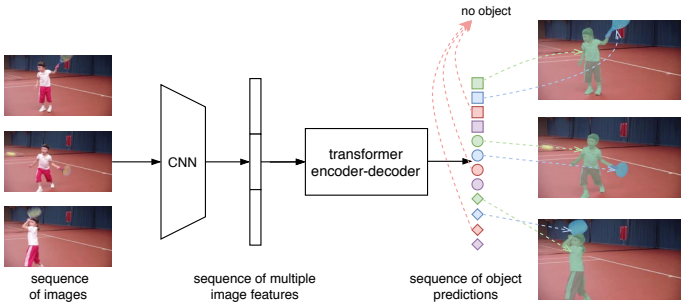

Figure 1 – Overall pipeline of VisTR. The model takes a sequence of images as input and outputs a sequence of instance predictions. Here same shapes represent predictions in one image, and same colors represent predictions of the same object instance. Note that the overall predictions follow the input frame order, and the order of object predictions for different images keeps the same (Best viewed on screen).

Abstract

Video instance segmentation (VIS) is the task that requires simultaneously classifying, segmenting and tracking object instances of interest in video. Recent methods typically develop sophisticated pipelines to tackle this task. Here, we propose a new video instance segmentation framework built upon Transformers, termed VisTR*, which views the VIS task as a direct end-to-end parallel sequence decoding/prediction problem. Given a video clip consisting of multiple image frames as input, VisTR outputs the sequence of masks for each instance in the video in order directly. At the core is a new, effective instance sequence matching and segmentation strategy, which supervises and segments instances at the sequence level as a whole. VisTR frames the instance segmentation and tracking in the same perspective of similarity learning, thus considerably simplifying the overall pipeline and is significantly different from existing approaches.*

Without bells and whistles, VisTR achieves the highest speed among all existing VIS models, and achieves the best result among methods using single model on the YouTube-VIS dataset. For the first time, we demonstrate a much simpler and faster video instance segmentation framework built upon Transformers, achieving competitive accuracy. We hope that VisTR can motivate future research for more video understanding tasks.

Code is available at: https://git.io/VisTR

*Corresponding author.

1. Introduction

Instance segmentation is one of the fundamental tasks in computer vision. While significant progress has been witnessed in instance segmentation of images [5, 9, 22, 25–27], much less effort was spent on segmenting instances in videos. Here we propose a new video instance segmentation framework built upon Transformers. Video instance segmentation (VIS), recently proposed in [30], requires one to simultaneously classify, segment and track object instances of interest in a video sequence. It is more challenging in that one needs to perform instance segmentation for each indi-

vidual frame and at the same time to establish data association of instances across consecutive frames, *a.k.a.*, tracking.

State-of-the-art methods typically develop sophisticated pipelines to tackle this task. Top-down approaches [2, 30] follow the tracking-by-detection paradigm, relying heavily on image-level instance segmentation models [6, 9] and complex human-designed rules to associate the instances. Bottom-up approaches [1] separate object instances by clustering learned pixel embeddings. Due to heavy reliance on the dense prediction quality, these methods often need multiple steps to generate the masks iteratively, which makes them slow. Thus, a simple, end-to-end trainable VIS framework is highly desirable.

Here, we take a deeper look at the video instance segmentation task. Video frames contain richer information than single images such as motion patterns and temporal consistency of instances, offering useful cues for instance segmentation, and classification. At the same time, the better learned instance features can help tracking of instances. In essence, the instance segmentation and instance tracking are both concerned with similarity learning: instance segmentation is to learn the pixel-level similarity and instance tracking is to learn the similarity between instances. Thus, it is natural to solve these two sub-tasks in a single framework and benefit each other. Here we aim to develop such an end-to-end VIS framework. The framework needs to be simple and achieves strong performance without whistles and bells. To this end, we propose to employ the Transformers [23]. Importantly, for the first time we demonstrate that, as the Transformers provide building blocks, *it enables one to design a simple and clean framework for VIS, and possibly for a much wider range of video processing tasks in computer vision*. Thus potentially, it is possible to unify most vision tasks of different input modalities—such as image, video and point clouds processing—into the Transformer framework. Transformers are widely used for sequence to sequence learning in NLP [23], and start to show promises in vision [4, 8]. Transformers are capable of modeling long-range dependencies, and thus can be naturally applied to video for learning temporal information across multiple frames. In particular, the core mechanism of Transformers, self-attention, is designed to learn and update the features based on all pairwise similarities between them. The above characteristics of Transformers make them great candidates for the VIS task.

In this paper, we propose the Video Instance Segmentation TRansformer (VisTR), which views the VIS task as a parallel sequence decoding/prediction problem. Given a video clip that consists of multiple image frames as input, the VisTR outputs the sequence of masks for each instance in the video in order directly. The output sequence for each instance is referred to as *instance sequence* in this paper. The overall VisTR pipeline is illustrated in Fig. 1. In the first stage, given a sequence of video frames, a standard CNN module extracts features of individual image frames, then the multiple image features are concatenated in the frame order to form the clip-level feature sequence. In the second stage, the Transformer takes the clip-level feature sequence as input, and outputs a sequence of object predictions in order. In Fig. 1 same shapes represent predictions for the same image, and the same colors represent the same instance of different images. The sequence of predictions follow the order of input images, and the predictions of each image follows the same instance order. Thus, instance tracking is achieved *seamlessly and naturally* in the same framework of instance segmentation.

To achieve this goal, there are two main challenges: 1) how to maintain the order of outputs and 2) how to obtain the mask sequence for each instance out of the Transformer network. Correspondingly, we introduce the *instance sequence matching* strategy and the *instance sequence segmentation* module. The instance sequence matching performs bipartite graph matching between the output instance sequence and the ground-truth instance sequence, and supervises the sequence as a whole. Thus, the order can be maintained directly. The instance sequence segmentation accumulates the mask features for each instance across multiple frames through self-attention and segments the mask sequence for each instance through 3D convolutions.

Our main contributions are summarized as follows.

- We propose a new video instance segmentation framework built upon Transformers, termed **VisTR**, which views the VIS task as a *direct end-to-end* parallel sequence decoding/prediction problem. The framework is significantly different from existing approaches, considerably simplifying the overall pipeline.
- VisTR solves the VIS from a new perspective of similarity learning. Instance segmentation is to learn the pixel-level similarity and instance tracking is to learn the similarity between instances. Thus, instance tracking is achieved *seamlessly and naturally* in the same framework of instance segmentation.
- The key to the success of VisTR is a new strategy for *instance sequence matching and segmentation*, which is tailored for our framework. This carefully-designed strategy enables us to supervise and segment instances at the sequence level as a whole.
- VisTR achieves strong results on the YouTube-VIS dataset, achieving 38.6% in mask mAP at the speed of 57.7 FPS , which is the best and fastest among methods that use a single model.

2. Related work

Video object segmentation. VOS [18] is closely related to VIS. Analogue to object tracking, which is detecting

boxes of foreground objects in a class-agnostic fashion, VOS is segmenting masks of foreground class-agnostic objects. Same as in tracking, usually one is allowed to use only the first few frames' annotations for training. In contrast, VIS requires to segment and track all instance masks of a fixed category set of objects in a video sequence.

Video instance segmentation. The VIS task [30] requires classifying, segmenting instances in each frame and linking the same instance across frames. State-of-the-art methods typically develop sophisticated pipelines to tackle it. MaskTrack R-CNN [30] extends the Mask R-CNN [9] with a tracking branch and external memory that saves the features of instances across multiple frames. Maskprop [2] builds on the Hybrid Task Cascade Network [6], and re-uses the predicted masks to crop the extracted features, then propagates them temporally to improve the segmentation and tracking. STEm-Seg [1] proposes to model video clips as 3D space-time volumes and then separates object instances by clustering learned embeddings. Note that the above approaches either rely on complex heuristic rules to associate the instances or require multiple steps to generate and optimize the masks iteratively. In contrast, here we aim to build a *simple and end-to-end trainable* VIS framework.

Transformers. Transformers were first proposed in [23] for the sequence-to-sequence machine translation task, and since then have become the *de facto* method in most NLP tasks. The core mechanism of Transformers, self-attention, makes it particularly suitable for modeling long-range dependencies. Very recently, Transformers start to show promises in solving computer vision tasks. DETR [4] builds an object detection systems based on Transformers, which largely simplifies the traditional detection pipeline, and achieves *on par* performances compared with highly-optimized CNN based detectors [19]. Our work here is inspired by DETR. ViT [8] introduces the Transformer to image recognition and models an image as a sequence of patches, which attains excellent results compared to state-of-the-art convolutional networks. The above works show the effectiveness of Transformers in image understanding tasks. To our knowledge, thus far there are no prior applications of Transformers to video instance segmentation. It is intuitive to see that the Transformers' advantage of modeling long-range dependencies makes it an ideal candidate for learning temporal information across multiple frames for video understanding tasks. Here, we propose the VisTR method and provide an affirmative answer to that. As the original Transformers are auto-regressive models, which generate output tokens one by one, for efficiency, VisTR employs a non-auto-regressive variant of the Transformer to achieve parallel sequence generation.

3. Our Method: VisTR

We tackle the video instance segmentation task by modeling it as a direct sequence prediction problem. Given a video clip that consists of multiple image frames as input, the VisTR outputs the sequence of masks for each instance in the video in order. To achieve this goal, we introduce the instance sequence matching and segmentation strategy to supervise and segment the instances at the sequence level as a whole. In this section, we first introduce the overall architecture of the proposed VisTR in Sec. 3.1, then the details of the instance sequence matching and segmentation module will be described in Sec. 3.2 and Sec. 3.3 respectively.

3.1. VisTR Architecture

The overall VisTR architecture is depicted in Fig. 2. It contains four main components: a CNN backbone to extract compact feature representations of multiple frames, an encoder-decoder Transformer to model the similarity of pixel-level and instance-level features, an instance sequence matching module for supervising the model, and an instance sequence segmentation module.

Backbone. The backbone extracts the original pixel-level feature sequence of the input video clip. Assume that the initial video clip with T frames of resolution $H_0 \times W_0$ is denoted by $x_{clip} \in \mathbb{R}^{T\times 3\times H_0\times W_0}$. First, a standard CNN backbone generates a lower-resolution activation map for each frame, then the features for each frame are concatenated to form the clip level feature map $f_0 \in \mathbb{R}^{T\times C\times H\times W}$.

Transformer encoder. The Transformer encoder is employed to model the similarities among all the pixel level features in the clip. First, a 1×1 convolution is applied to the above feature map, reducing the dimension from C to d ($d < C$), resulting in a new feature map $f_1 \in \mathbb{R}^{T\times d\times H\times W}$. To form a clip level feature sequence that can be fed into the Transformer encoder, we flatten the spatial and temporal dimensions of f_1 into one dimension, resulting in a 2D feature map of size $d \times (T \cdot H \cdot W)$. Note that the temporal order is always in accordance with that of the initial input. Each encoder layer has a standard architecture that consists of a multi-head self-attention module and a fully connected feed forward network (FFN).

Temporal and spatial positional encoding. The Transformer architecture is permutation-invariant, while the segmentation task requires precise position information. To compensate for this, we supplement the features with fixed positional encodings information that contains the three dimensional (temporal, horizontal and vertical) positional information in the clip. Here we adapt the positional encoding in the original Transformer [23] for our 3D case. Specifically, for the coordinates of each dimension we independently use $d/3$ sine and cosine functions with different fre-

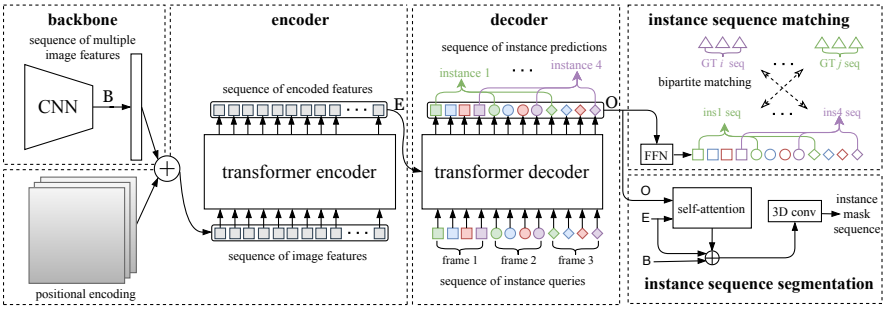

Figure 2 – The overall architecture of VisTR. It contains four main components: 1) a CNN backbone that extracts feature representation of multiple images; 2) an encoder-decoder Transformer that models the relations of pixel-level features and decodes the instance-level features; 3) an instance sequence matching module that supervises the model; and 4) an instance sequence segmentation module that outputs the final mask sequences (Best viewed on screen).

quencies:

$$\mathrm{PE}(\mathrm{pos}, i) = \begin{cases} \sin\big(\mathrm{pos} \cdot \omega_k\big), & \text{for } i = 2k, \\ \cos\big(\mathrm{pos} \cdot \omega_k\big), & \text{for } i = 2k+1; \end{cases} \tag{1}$$

where $\omega_k = 1/10000^{2k/\frac{d}{3}}$; 'pos' is the position in the corresponding dimension. Note that the d should be divisible by 3, as the positional encodings of the three dimensions should be concatenated to form the final d channel positional encoding. These encodings are added to the input of each attention layer.

Transformer decoder. The Transformer decoder aims to decode the top pixel features that can represent the instances of each frame, which is called instance level features. Motivated by DETR [4], we also introduce a fixed number of input embeddings to query the instance features from pixel features, termed as *instance queries*. Suppose that the model decodes n instances each frame, then for T frames the instance query number is $N = n \cdot T$. The instance queries are learned by the model and have the same dimension with the pixel features. Taking the output of encoder E and N instance queries Q as input, the Transformer decoder outputs N instance features, denoted by O in Fig. 2. The overall predictions follow the input frame order, and the order of instance predictions for different images is the same. Thus, the tracking of instances in different frames could be realized by linking the items of the corresponding indices directly.

3.2. Instance Sequence Matching

VisTR infers a fixed-size sequence of N predictions, in a single pass through the decoder. One of the main challenges for this framework is to maintain the relative position of predictions for the same instance in different images, *a.k.a.*, *instance sequence*. In order to find the corresponding ground truth and supervise the instance sequence as a whole, we introduce the instance sequence matching strategy.

As the VisTR decode n instances each frame, the number of instance sequence is also n. Let us denote by $\hat{y} = \{\hat{y}_i\}_{i=1}^{n}$ the predicted instance sequences, and y the ground truth set of instance sequences. Assuming n is larger than the number of instances in the video clip, we consider y also as a set of size n padded with $\emptyset$. In order to find a bipartite graph matching between the two sets, we search for a permutation of n elements $\sigma \in S_n$ with the lowest cost:

$$\hat{\sigma} = \arg\min_{\sigma \in S_n} \sum_{i}^{n} \mathcal{L}_{\text{match}}\left(y_i, \hat{y}_{\sigma(i)}\right) \tag{2}$$

where $\mathcal{L}_{\text{match}}\left(y_i, \hat{y}_{\sigma(i)}\right)$ is a pair-wise *matching cost* between ground truth y_i and an instance sequence prediction with index $\sigma(i)$. The optimal assignment could be computed efficiently by the Hungarian algorithm [11], following prior work (*e.g.*, [21]).

As computing the mask sequence similarity directly is computationally intensive, we find a surrogate, the box sequence to perform the matching. To obtain the box predictions, we apply a 3-layer feed forward network (FFN) with ReLU activation function and a linear projection layer to the object predictions O of Transformer decoder. Following the same practice of DETR [4], the FFN predicts the normalized center coordinates, height and width of the box w.r.t. input image, and the linear layer predicts the class label using a softmax function. We also add a "background" class to represent that no object is detected.

Given the $N = n \cdot T$ bounding box predictions for the object predictions sequence, we could associate n box sequences for each instance by their indices, referred to as

ins1 box seq...ins4 box seq in Fig. 2. The matching loss takes both the class predictions and the similarity of predicted and ground truth boxes into account. Each element i of the ground truth set can be seen as

$$y_i = \{(c_i, c_i..., c_i), (b_{i,0}, b_{i,1}..., b_{i,T})\} \tag{3}$$

where c_i is the target class label (which may be $\emptyset$) for this instance, and $b_{i,t} \in [0,1]^4$ is a vector that defines ground truth box center coordinates and its relative height and width in the frame t. T represent the number of input frames. Thus, for the predictions of instance with index $\sigma(i)$ we denoted the probability of class c_i as

$$\hat{p}_{(\sigma(i))}(c_i) = \{\hat{p}_{(\sigma(i),0)}(c_i)..., \hat{p}_{(\sigma(i),T)}(c_i)\} \tag{4}$$

and the predicted box sequence as

$$\hat{b}_{\sigma(i)} = \left\{\hat{b}_{(\sigma(i),0)}, \hat{b}_{(\sigma(i),1)}..., \hat{b}_{(\sigma(i),T)}\right\} \tag{5}$$

With the above notation, we define

$$\mathcal{L}_{\text{match}}\left(y_i, \hat{y}_{\sigma(i)}\right) = -\hat{p}_{\sigma(i)}\left(c_i\right) + \mathcal{L}_{\text{box}}\left(b_i, \hat{b}_{\sigma(i)}\right), \tag{6}$$

where $c_i \neq \emptyset$. Based on the above criterion, we could find the one-to-one matching of the sequences by the Hungarian algorithm. Given the optimal assignment, we could compute the loss function, the *Hungarian loss* for all pairs matched in the previous step. The loss is a linear combination of a negative log-likelihood for class prediction, a box loss and mask loss for the instance sequences:

$$\begin{aligned}\mathcal{L}_{\text{Hung}}(y, \hat{y}) = \sum_{i=1}^{N}\Big[&(-\log \hat{p}_{\hat{\sigma}(i)}(c_i)) + \mathcal{L}_{\text{box}}\left(b_i, \hat{b}_{\hat{\sigma}}(i)\right) \\ &+ \mathcal{L}_{\text{mask}}\left(m_i, \hat{m}_{\hat{\sigma}}(i)\right)\Big].\end{aligned} \tag{7}$$

Here $c_i \neq \emptyset$, and $\hat{\sigma}$ is the optimal assignment computed in Eq. (2). The *Hungarian loss* is used to train the whole framework.

The second part of the matching cost and the Hungarian loss is $\mathcal{L}_{\text{box}}$ that scores the bounding boxes. We use a linear combination of the sequence level $\mathcal{L}_1$ loss and the generalized IOU loss [20]:

$$\begin{aligned}\mathcal{L}_{\text{box}}\left(b_i, \hat{b}_{\sigma(i)}\right) = \frac{1}{T}\sum_{t=1}^{T}\Big[&\lambda_{\text{iou}} \cdot \mathcal{L}_{\text{iou}}\left(b_{i,t}, \hat{b}_{\sigma(i),t}\right) \\ &+ \lambda_{\text{L1}}\left\|b_{i,t} - \hat{b}_{\sigma(i),t}\right\|_1\Big].\end{aligned} \tag{8}$$

Here $\lambda_{\text{iou}}, \lambda_{\text{L1}} \in \mathbb{R}$ are hyper-parameters. These two losses are normalized by the number of instances inside the batch. In the sequel, we present the details.

3.3. Instance Sequence Segmentation

The instance sequence segmentation module aims to predict the mask sequence for each instance. To realize that, the model needs to accumulate the mask features of multiple frames for each instance firstly, then the mask sequence segmentation is performed on the accumulated features.

The mask features are obtained by computing the similarity map between the object predictions O and the Transformer encoded features E. To simplify the calculation, we only compute with the features of its corresponding frame for each object prediction. For each frame, the object predictions O and the corresponding encoded feature maps E are fed into the self-attention module to obtain the initial attention maps. Then the attention maps will be fused with the initial backbone features B and the transformed encoded features E of the corresponding frames, following a similar practice with the DETR [4]. The last layer of the fusion is a deformable convolution layer [7]. In this way, the mask features for each instance of different frames are obtained.

Following the same spirit of taking the instance sequence as a whole, the mask features of the same instance in different frames should be propagated and reinforce each other. We propose to utilize the 3D convolution to realize that. Assume that the mask feature for instance i of frame t is $g_{i,t} \in \mathbb{R}^{1\times a\times \frac{H_0}{4}\times \frac{W_0}{4}}$, where a is the channel number, then we concatenate the features of T frames to form the $G_i \in \mathbb{R}^{1\times a\times T\times \frac{H_0}{4}\times \frac{W_0}{4}}$. The *instance sequence segmentation* module takes the instance sequence mask feature G_i as input, and output the mask sequence $m_i \in \mathbb{R}^{1\times 1\times T\times \frac{H_0}{4}\times \frac{W_0}{4}}$ for the instance directly. This module contains three 3D convolutional layers and Group Normalization [29] layers with ReLU activation function. No normalization or activation is performed after the last convolution layer, and the output channel number of the last layer is 1. In this way, the masks of the instance for T frames are obtained. The mask loss for supervising the predictions in Eq. (7) is defined as a combination of the Dice [16] and Focal loss [13]:

$$\begin{aligned}\mathcal{L}_{\text{mask}}\left(m_i, \hat{m}_{\sigma(i)}\right) = \lambda_{\text{mask}}\frac{1}{T}\sum_{t=1}^{T}\Big[&\mathcal{L}_{\text{Dice}}(m_{i,t}, \hat{m}_{\sigma(i),t}) \\ &+ \mathcal{L}_{\text{Focal}}(m_{i,t}, \hat{m}_{\sigma(i),t})\Big].\end{aligned} \tag{9}$$

4. Experiments

In this section, we conduct experiments on the YouTube-VIS [30] dataset, which contains 2238 training, 302 validation and 343 test video clips. Each video of the dataset is annotated with per pixel segmentation mask, category and instance labels. The object category number is 40. As the test set evaluation is closed, we evaluate our method in the validation set. The evaluation metrics are average precision

(AP) and average recall (AR), with the video Intersection over Union (IoU) of the mask sequences as the threshold.

4.1. Implementation Details

Model settings. As the largest number of the annotated video length for YouTube-VIS [30] is 36, we take this value as the default input video clip length T. Thus, no post-processing is needed to associate different clips from one video, which makes our model totally end-to-end trainable. The model predicts 10 objects for each frame, thus the total object query number is 360. For the Transformer we use 6 encoder, 6 decoder layers of width 384 with 8 attention heads. Unless otherwise specified, ResNet-50 [10] is used as our backbone networks and the same hyper-parameters of DETR [4] are used.

Training. The model is implemented with PyTorch-1.6 [17], trained with AdamW [15] of initial Transformer's learning rate being 10^{-4} , the backbone's learning rate being 10^{-4}. The models are trained for 18 epochs, with the learning rate decays by 10x at 12 epochs. We initialize our backbone networks with the weights of DETR pretrained on COCO [14]. The models are trained on 8 V100 GPUs of 32G RAM, with 1 video clip per GPU. The frame sizes are downsampled to 300×540 to fit the GPU memory.

Inference. During inference, we follow the same scale setting as training. No post-processing is needed for associating instances. Instances with scores larger than 0.001 are kept. The mean score for all the frames is used as the instance score. For instances that have been classified to different categories in different frames, we use the most frequently predicted category as the final instance category.

4.2. Ablation Study

In this section we conduct extensive ablation experiments to study the core factors of VisTR. Comparison results are reported in Table 1.

The main difference between video and image is that video contains temporal information. How to effectively learn and exploit temporal information is the key to video understanding. Firstly, we study the importance of temporal information to VisTR in two dimensions: the amount and the order.

Video sequence length. To evaluate the importance of the amount of temporal information to VisTR, we experiment with models trained with different input video sequence lengths. As reported in Table 1a, with the length varying from 18 to 36, the AP increases monotonically from 29.7% to 33.3%. This result shows that more temporal information indeed helps the model learn better. As the largest video length of the dataset is 36, we argue that, if with a larger dataset, VisTR can achieve even better results. Note that for this experiment, if the clip length is less than the video length, instance matching in overlapping frames is used for associating them from different clips.

Video sequence order. As the movement of objects in real scenes are continuous, we believe that the order of temporal information is also important. To evaluate, we perform a comparison of the model trained with input video sequence in random order vs. time order. Results in Table 1c show that the model learned according to the time order information achieves 1 point higher, which verifies the importance of the temporal order.

Positional encoding. Position information is important for the dense prediction problem of VIS. As the original feature sequence contains no positional information, we supplement with the spatial and temporal positional encodings, which indicate the relative positions in the video sequence. Experiments of models with and without positional encoding are presented in Table 1d. The model without positional encoding manages to achieve 28.4% AP. Our explanation is that the ordered format of the sequence supervision and the correspondence between the input and output order of the Transformer provide some relative positional information *implicitly*. In the second experiment, the performance improves by about 5 points, which verifies the necessity of explicit positional encoding.

Instance queries. The instance queries are learned embeddings for decoding the representative instance predictions. In this experiment, we study the effect of instance queries and attempt to exploit the inner connections among them by varying the embedding number. Suppose the model decode n instances each frame, and the frame number is T. The input instance query number should be $n \times T$ to decode the same number for predictions. In the default setting, one embedding is responsible for one prediction, the model directly learns $n \times T$ unique embeddings, termed as 'prediction level' in Table 1b. In the 'video level setting', one embedding is learned for all the instance predictions, *i.e.*, the same embedding is repeated $n \times T$ times as the input of decoder. In the 'frame-level' setting, the model only learns T unique embeddings and repeats them by n times. In the 'instance level' setting, the model only learns n unique embeddings and repeats them by T times. The n and T corresponds to the value of 10 and 36 in the table respectively. The result is 8.4% AP and 13.7% AP for 'video level' and 'frame level' settings respectively. Surprisingly, the 'instance level' queries can achieve 32.0% AP, which is only 1.3 points lower than the default setting. The result shows that the queries for one instance can be shared for the VisTR model, which makes the tracking natural. But the queries for one frame can not be shared.

Transformers for feature encoding. As illustrated in the 'instance sequence segmentation' module of Fig. 2. The module takes three types of features as input: the features 'B' from the backbone, the feature 'E' from the encoder and the attention map computed by the feature 'E' and

Length	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
18	29.7	50.4	31.1	29.5	34.4
24	30.5	47.8	33.0	29.5	34.4
30	31.7	53.2	32.8	31.3	36.0
36	33.3	53.4	35.1	33.1	38.5

(a) Video sequence length. The performance improves as the sequence length increases.

	#	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
video level	1	8.4	13.2	9.5	20.0	20.8
frame level	36	13.7	23.3	14.5	30.4	35.1
ins. level	10	32.0	52.8	34.0	31.6	37.2
pred. level	360	33.3	53.4	35.1	33.1	38.5

(b) Instance query embedding. Instance-level query is only 1.3% lower in AP than the prediction-level query with 36× fewer embeddings.

time order	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
random	32.3	52.1	34.3	33.8	37.3
in order	33.3	53.4	35.1	33.1	38.5

(c) Video sequence order. Sequence in time order is 1.0% better in AP than sequence in random order.

	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
w/o	28.4	50.1	29.5	29.6	33.3
w	33.3	53.4	35.1	33.1	38.5

(d) Position encoding. Position encoding brings about 5% AP gains to VisTR.

	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
CNN	32.0	54.5	31.5	31.6	37.7
Transformer	33.3	53.4	35.1	33.1	38.5

(e) CNN-encoded feature vs. Transformer-encoded feature for mask prediction. The transformer improves the feature quality.

	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
w/o	33.3	53.4	35.1	33.1	38.5
w	34.4	55.7	36.5	33.5	38.9

(f) Instance sequence segmentation module. The module with 3D convolutions brings 1.1% AP gains.

Table 1 – Ablation experiments for VisTR. All models are trained on YouTubeVIS `train` for 10 epochs and tested on YouTubeVIS `val`, using the ResNet-50 backbone.

'O'. To show the superiority of Transformers in feature encoding, we compare the results of using the original input 'O' vs. output 'E' of the encoder for the second feature, *a.k.a.*, CNN-encoded features vs. Transformer-encoded features. As reported in Table 1e, the CNN-encoded features achieves 32.0% AP, and the Transformer-encoded features achieve 1.3 points higher. This demonstrates that features are learned better after the Transformer updates them based on all pairwise similarities between them through self-attention. The result also shows the superiority of modeling the spatial and temporal features as a whole.

Instance sequence segmentation. The segmentation process contains both the instance mask feature accumulation and instance sequence segmentation modules. The instance sequence segmentation module takes the instance sequence as a whole. We expect that it can strengthen the mask prediction by learning the temporal information through 3D convolutions. Thus, when objects are in challenging situations such as occlusions or motion blurs, the module can learn to propagate information from other frames to help the segmentation. Besides, the features of the same instance from multiple frames could help the network recognize the instance better. In this experiment, we perform a study of models with or without the 3D instance sequence segmentation module. For the former case, we apply a 2D convolutional layer with the output channel being 1 to the mask features for each instance of each frame to obtain the masks. The comparison is shown in Table 1f. The instance sequence segmentation module improves the result by 1.1 points, which verifies the effectiveness of the proposed module.

With these ablation studies, we conclude that in VisTR design: the temporal information, positional encodings, instance queries, global self-attention in the encoder and the instance sequence segmentation module, all play important roles *w.r.t.* the final performance.

4.3. Main Results

We compare VisTR against some state-of-the-art methods in video instance segmentation in Table 2. The comparison is performed in terms of both accuracy and speed. The methods in the first three rows are originally proposed for tracking or VOS. We have cited the results reported by the re-implementations in [30] for VIS. Other methods including the MaskTrack RCNN, MaskProp [2] and STEmSeg [1] are originally proposed for the VIS task in the temporal order.

For the accuracy measured by AP, *VisTR achieves the best result among methods using a single model without any bells and whistles*. Using the same backbone of ResNet-50 [10], VisTR achieves about 5 points higher in AP than the MaskTrack R-CNN and the recently proposed STEmSeg method. Besides, we argue the AP gap between VisTR and MaskProp mainly comes from its combination of multiple networks, *i.e.*, Spatiotemporal Sampling Network [3], Feature Pyramid Network [12], Hybrid Task Cascade Network [6] and the High-Resolution Mask Refinement post-processing. Since our aim is to design a conceptually simple and end-to-end framework, many improvements methods, such as complex video data augmentation and multi-stage mask refinement are beyond the scope of this work. For the speed measured by FPS (frames per second), VisTR shows a significant advantage among all the reported results, achieving 27.7 FPS with the ResNet-101 backbone. If excluding the data loading process of multiple images, the speed can achieve 57.7 FPS. Note that, as we load the

Method	backbone	FPS	AP	AP_{50}	AP_{75}	AR_1	AR_{10}
DeepSORT [28]	ResNet-50	-	26.1	42.9	26.1	27.8	31.3
FEELVOS [24]	ResNet-50	-	26.9	42.0	29.7	29.9	33.4
OSMN [31]	ResNet-50	-	27.5	45.1	29.1	28.6	33.1
MaskTrack R-CNN [30]	ResNet-50	20.0	30.3	51.1	32.6	31.0	35.5
STEm-Seg [1]	ResNet-50	-	30.6	50.7	33.5	31.6	37.1
STEm-Seg [1]	ResNet-101	2.1	34.6	55.8	37.9	34.4	41.6
MaskProp [2]	ResNet-50	-	40.0	-	42.9	-	-
MaskProp [2]	ResNet-101	-	42.5	-	45.6	-	-
VisTR	ResNet-50	30.0/69.9	35.6	56.8	37.0	35.2	40.2
VisTR	ResNet-101	27.7/57.7	38.6	61.3	42.3	37.6	44.2

Table 2 – Video instance segmentation AP (%) on the YouTube-VIS [30] validation dataset. Note that, for the first three methods, we have cited the results reported by the re-implementations in [30] for VIS. Other results are adopted from their original paper. For the speed of VisTR we report the FPS results with and without the data loading process. Here we naively load the images serially, taking unnecessarily long time. The data loading process can be much faster by parallelizing.

Figure 3 – Visualization of VisTR on the YouTube-VIS [30] validation dataset. Each row contains images from the same video. For each video, here the same colors depict the mask sequences of the same instances (Best viewed on screen).

images in serial, the data loading process can be easily parallelized. The fast speed of VisTR owes to its design of parallel decoding and no post-processing.

The visualization of VisTR on the YouTube-VIS [30] validation dataset is shown in Fig. 3, with each row containing images sampled from the same video. VisTR can track and segment instances well in challenging situations such as: (a) instances overlapping, (b) changes of relative positions between instance, (c) confusion by the same category instances that are close together and (d) instances in various poses.

5. Conclusion

In this paper, we have proposed a new video instance segmentation framework built upon Transformers, which views the VIS task as a direct end-to-end parallel sequence decoding/prediction problem. In this way, instance tracking is achieved *seamlessly and naturally* in the same framework of instance segmentation, which is significantly different from and simpler than existing approaches, considerably simplifying the overall pipeline. Without bells and whistles, VisTR achieves the best result and the highest speed among methods using a single model on the YouTube-VIS dataset. To our knowledge, our work is the first one that applies the Transformer to video instance segmentation. We hope that similar approaches can be applied to many more video understanding tasks in the future.

Acknowledgements This work was in part supported by Beijing Science and Technology Project (No. Z181100008-918018). CS and his employer received no financial support for the research, authorship, and/or publication of this article.

References

[1] Ali Athar, Sabarinath Mahadevan, Aljoša Ošep, Laura Leal-Taixé, and Bastian Leibe. Stem-seg: Spatio-temporal embeddings for instance segmentation in videos. In *Proc. Eur. Conf. Comp. Vis.*, 2020.

[2] Gedas Bertasius and Lorenzo Torresani. Classifying, segmenting, and tracking object instances in video with mask propagation. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 9739–9748, 2020.

[3] Gedas Bertasius, Lorenzo Torresani, and Jianbo Shi. Object detection in video with spatiotemporal sampling networks. In *Proc. Eur. Conf. Comp. Vis.*, pages 331–346, 2018.

[4] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In *Proc. Eur. Conf. Comp. Vis.*, 2020.

[5] Hao Chen, Kunyang Sun, Zhi Tian, Chunhua Shen, Yongming Huang, and Youliang Yan. Blendmask: Top-down meets bottom-up for instance segmentation. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 8573–8581, 2020.

[6] Kai Chen, Jiangmiao Pang, Jiaqi Wang, Yu Xiong, Xiaoxiao Li, Shuyang Sun, Wansen Feng, Ziwei Liu, Jianping Shi, Wanli Ouyang, et al. Hybrid task cascade for instance segmentation. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 4974–4983, 2019.

[7] Jifeng Dai, Haozhi Qi, Yuwen Xiong, Yi Li, Guodong Zhang, Han Hu, and Yichen Wei. Deformable convolutional networks. In *Proc. IEEE Int. Conf. Comp. Vis.*, pages 764–773, 2017.

[8] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*, 2020.

[9] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask R-CNN. In *Proc. IEEE Int. Conf. Comp. Vis.*, pages 2961–2969, 2017.

[10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 770–778, 2016.

[11] Harold W. Kuhn. The Hungarian method for the assignment problem. *Naval research logistics quarterly*, 2(1-2):83–97, 1955.

[12] Tsung-Yi Lin, Piotr Dollár, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 2117–2125, 2017.

[13] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollar. Focal loss for dense object detection. In *Proc. IEEE Int. Conf. Comp. Vis.*, Oct 2017.

[14] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and Lawrence Zitnick. Microsoft COCO: Common objects in context. In *Proc. Eur. Conf. Comp. Vis.*, pages 740–755, 2014.

[15] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *Proc. Int. Conf. Learn. Representations*, 2018.

[16] Fausto Milletari, Nassir Navab, and Seyed-Ahmad Ahmadi. V-net: Fully convolutional neural networks for volumetric medical image segmentation. In *Proc. Int. Conf. 3D Vis.*, pages 565–571, 2016.

[17] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. Pytorch: An imperative style, high-performance deep learning library. In *Proc. Advances in Neural Inf. Process. Syst.*, pages 8026–8037, 2019.

[18] Federico Perazzi, Jordi Pont-Tuset, Brian McWilliams, Luc Van Gool, Markus Gross, and Alexander Sorkine-Hornung. A benchmark dataset and evaluation methodology for video object segmentation. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 2016.

[19] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster r-cnn: Towards real-time object detection with region proposal networks. In *Proc. Advances in Neural Inf. Process. Syst.*, pages 91–99, 2015.

[20] Hamid Rezatofighi, Nathan Tsoi, JunYoung Gwak, Amir Sadeghian, Ian Reid, and Silvio Savarese. Generalized intersection over union: A metric and a loss for bounding box regression. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 658–666, 2019.

[21] Russell Stewart, Mykhaylo Andriluka, and Andrew Y Ng. End-to-end people detection in crowded scenes. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 2325–2333, 2016.

[22] Zhi Tian, Chunhua Shen, and Hao Chen. Conditional convolutions for instance segmentation. In *Proc. Eur. Conf. Comp. Vis.*, 2020.

[23] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Proc. Advances in Neural Inf. Process. Syst.*, pages 5998–6008, 2017.

[24] Paul Voigtlaender, Yuning Chai, Florian Schroff, Hartwig Adam, Bastian Leibe, and Liang-Chieh Chen. Feelvos: Fast end-to-end embedding learning for video object segmentation. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 9481–9490, 2019.

[25] Xinlong Wang, Tao Kong, Chunhua Shen, Yuning Jiang, and Lei Li. SOLO: Segmenting objects by locations. In *Proc. Eur. Conf. Comp. Vis.*, 2020.

[26] Xinlong Wang, Rufeng Zhang, Tao Kong, Lei Li, and Chunhua Shen. SOLOv2: Dynamic and fast instance segmentation. In *Proc. Advances in Neural Inf. Process. Syst.*, 2020.

[27] Yuqing Wang, Zhaoliang Xu, Hao Shen, Baoshan Cheng, and Lirong Yang. Centermask: single shot instance segmentation with point representation. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, 2020.

[28] Nicolai Wojke, Alex Bewley, and Dietrich Paulus. Simple online and realtime tracking with a deep association metric. In *Proc. IEEE Int. Conf. Image Process.*, pages 3645–3649, 2017.

[29] Yuxin Wu and Kaiming He. Group normalization. In *Proc. Eur. Conf. Comp. Vis.*, pages 3–19, 2018.

[30] Linjie Yang, Yuchen Fan, and Ning Xu. Video instance segmentation. In *Proc. IEEE Int. Conf. Comp. Vis.*, 2019.

[31] Linjie Yang, Yanran Wang, Xuehan Xiong, Jianchao Yang, and Aggelos K Katsaggelos. Efficient video object segmentation via network modulation. In *Proc. IEEE Conf. Comp. Vis. Patt. Recogn.*, pages 6499–6507, 2018.

Trash to Treasure: Harvesting OOD Data with Cross-Modal Matching for Open-Set Semi-Supervised Learning

Junkai Huang[1*] Chaowei Fang[2*] Weikai Chen[3] Zhenhua Chai[4]
Xiaolin Wei[4] Pengxu Wei[1] Liang Lin[1] Guanbin Li[1†]
[1]Sun Yat-sen University [2]Xidian University [3]Tencent America [4]Meituan

Abstract

Open-set semi-supervised learning (open-set SSL) investigates a challenging but practical scenario where out-of-distribution (OOD) samples are contained in the unlabeled data. While the mainstream technique seeks to completely filter out the OOD samples for semi-supervised learning (SSL), we propose a novel training mechanism that could effectively exploit the presence of OOD data for enhanced feature learning while avoiding its adverse impact on the SSL. We achieve this goal by first introducing a warm-up training that leverages all the unlabeled data, including both the in-distribution (ID) and OOD samples. Specifically, we perform a pretext task that enforces our feature extractor to obtain a high-level semantic understanding of the training images, leading to more discriminative features that can benefit the downstream tasks. Since the OOD samples are inevitably detrimental to SSL, we propose a novel cross-modal matching strategy to detect OOD samples. Instead of directly applying binary classification [39], we train the network to predict whether the data sample is matched to an assigned one-hot class label. The appeal of the proposed cross-modal matching over binary classification is the ability to generate a compatible feature space that aligns with the core classification task. Extensive experiments show that our approach substantially lifts the performance on open-set SSL and outperforms the state-of-the-art by a large margin.

1. Introduction

"One man's trash is another man's treasure."
– Hector Urquhart

Semi-supervised learning (SSL) provides an effective way of leveraging massive unlabeled data to improve the performance of deep neural network when only limited labeled samples are available. Most existing SSL methods assume that labeled and unlabeled data share the same category space. However, this assumption is difficult to satisfy since it still requires tedious efforts to confirm the purity of the unlabeled data. Very recently, Yu *et al.* [39] proposed a more realistic setting called open-set semi-supervised learning (open-set SSL). Open-set SSL considers a more challenging but practical scenario where outliers, that do not belong to the categories of the labeled data, may exist in the unlabeled data. Resolving the open-set SSL problem has crucial practical meanings as it can significantly reduce the workload of data preparation in the actual applications.

A straightforward approach to cope with the out-of-distribution (OOD) samples is to completely remove them

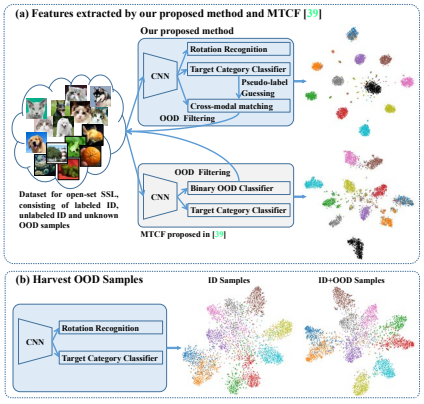

Figure 1: t-SNE [26] visualization of image features extracted from CIFAR100 [20]. Images of the same category are shown in the same color. (a) Features learned by our method are more compact and cleaner than those learned by MTCF [39]. (b) By leveraging OOD samples in the proposed pretext training, we have achieved more discriminative feature space than using ID samples only.

*Equal contribution.
†Corresponding author.

from the SSL training, as the prior works [28] have shown that including OOD unlabeled data can severely impact the performance of SSL. While there exist a diverse collection of approaches for OOD sample detection, they typically require a large corpus of in-distribution (ID) data with class labels. However, due to the scarcity of the labeled data in SSL, the existing OOD detection methods would fail to achieve satisfactory performance and are hence not suitable to be deployed in the open-set SSL.

In order to eliminate the influence of OOD samples, [39] devises a multi-task curriculum framework (MTCF) with a binary OOD classification head that strives to filter out all the OOD samples. The classification of in-distribution (ID) samples and the detection of OOD samples are unified into a joint optimization framework, where unlabeled samples with lower OOD scores will be gradually added for semi-supervised training. However, the proposed binary OOD classification task and the ID classification have conflicting goals in terms of feature learning. Specifically, the training of OOD detection aims to cluster all ID samples (regardless of their categories) into one category (i.e., ID data) while the task of ID classification tends to enhance the category discrimination between ID samples. Unifying the contradictory optimization goals into one framework that shares a backbone network could compromise the final performance and increase the difficulty of training.

In this paper, we present a novel training framework for open-set SSL that can effectively exploit the presence of OOD data for enhanced feature learning while avoiding its adverse impact to the SSL. First, instead of completely discarding the OOD data, we introduce a warm-up training that makes full use of all the unlabeled data, including the OOD samples, to enhance the representation learning of our backbone network. Unlike the conventional pre-training, our warm-up training performs a pretext task that deviates from the target application. In particular, we ask the network to predict the rotation of the rotationally augmented data in a self-supervised manner. This enforces our backbone model to obtain high-level semantic understanding of the images and hence leads to more discriminative features that could benefit the downstream applications, e.g. the classification task. Particularly, as shown in Figure 1(b), OOD samples, which are outliers in SSL algorithms, turn out to be treasures that can enhance feature learning when fully utilized in the proposed self-supervised pretext training. The idea of leveraging self-supervised techniques for boosting the performance of semi-supervised learning has been shown effective in the previous work [41]. However, it is only verified in the traditional SSL, where the unlabeled data share the same category space with the labeled ones. We are the first to investigate this idea in the open-set setting and show that the self-supervised auxiliary task could be beneficial to open-set SSL with properly designed training strategy.

Second, we propose a more effective approach for detecting and filtering OOD samples based on a novel cross-modal matching mechanism. First of all, each unlabeled sample is assigned the category with the highest predicted probability of the model as a pseudo label. We then propose a cross-modal matching head to infer whether the embedding of the image and its pseudo-label are matched. Once trained, OOD samples can be screened out due to its low confidence with all the ID categories. Unlike the binary classification based OOD detection [39], the feature learning of cross-modal matching aligns well with that of the target ID classification task, as both strive to achieve better discrimination between the image features of different categories. We show in Figure 1(a) that our method can obtain features with much more compact and purified clusters than that of [39]. Furthermore, we can effectively detect ID samples with incorrect pseudo labels, also coded "hard" samples, via cross-modal matching. This helps to further improve the performance of the trained model since hard samples could harm the model training especially at the early stage when the prediction accuracy of pseudo labels is relatively low. We propose an adaptive training mechanism which gradually involves more hard samples as the model proceeds to achieve better performance.

Our proposed approach is a general training framework that can be easily implemented into existing SSL methods. We show that our method greatly improves the state-of-the-art performance in extensive open-set semi-supervised image recognition benchmarks including CIFAR-10 [20], Animals-10, CIFAR-100, and TinyImageNet [22]. We summarize our contributions as follows:

- A novel training pipeline for open-set SSL that leverages the presence of OOD samples for enhanced feature learning while avoiding their adverse impact.
- A specially tailored warm-up training method that uses self-supervised learning to boost the performance of open-set SSL.
- A novel OOD and hard sample detection algorithm based on cross-modal matching, which achieves compatible feature space with the target classification task.
- New state-of-the-art performance on open-set SSL over extensive benchmarks including CIFAR-10, CIFAR-100, TinyImageNet, and Animals-10.

2. Related Works

Semi-Supervised Learning. Semi-supervised learning (SSL) generally refers to a series of methods that aim to use both labeled and unlabeled data from the similar distribution for model training. There are a vast number of classic works on SSL across various disciplines [16, 5, 17]. Among them, semi-supervised image classification has been a long-term and extensive research topic. The most classic solution

for the SSL problem is self-training, which iteratively enlarges the labeled set via guessing labels of unknown samples. We refer interested readers to [35] for a detailed survey. Other techniques including co-training [3], label propagation [31] and graphical model are also widely used in this task [43, 36, 1, 13].

Benefiting from deep learning, breakthrough achievements have been achieved in SSL. Traditional semi-supervised techniques are re-implemented with deep CNN, such as self-labeling [35], multi-view training [30, 8], label propagation [15] and graph-based method [18]. These methods focus on assigning pseudo hard/soft labels to unknown samples or clustering samples with similar semantics. Considering the sample density is low nearby the decision boundary, a training sample is assumed to share the same label with a synthesized sample close to it. Motivated by this intuition, consistency regularization can be exerted to spread labels of known samples and confident predictions of unknown samples. In [21], two models including π-model and temporal ensembling model are proposed to regularize the predictions on two different augmentations of a training sample. Unlike the temporal ensembling model which averages the prediction in every iteration, the mean teacher [34] aggregates model weights through the exponential moving average. MixMatch [2] introduces mixup [42] to explore inter-class relations in SSL. [37, 33] employ two variants of augmentations and propagate the prediction of the weakly augmented image to the strongly augmented counterpart. Most of the mainstream SSL algorithms mentioned above are based on the assumption that the labeled and unlabeled samples share the category space. We break this assumption and focus on the new setting of open-set SSL.

Self-supervised Learning. Self-supervised learning is an emerging technology which is widely considered to have the potential to initialize CNN with powerful representation capacity. It cleverly designs *pretext* tasks, which can be formulated using only unlabeled data but requiring high-level semantic understanding. As a result, the intermediate layers of convolutional neural networks trained for solving these *pretext* tasks encode high-level semantic representation that can be universally applied to downstream tasks, e.g., image classification. The most commonly-used pretext tasks include transformation based regularization [9], patch based jigsaw puzzle [27], relative location inference [7], and rotation recognition [10], etc. [19] revisits these self-supervised methods and provides comprehensive quantitative comparisons. Recently, Zhai *et al.* [41] proved that extra self-supervisions such as rotation recognition and transformation based regularization can benefit the classification performance in semi-supervised image classification. However, it is under explored whether the performance gains obtained by self-supervision will be exhausted by the interference caused by OOD samples in the process of open-set SSL. In this paper, rotation recognition is introduced as an auxiliary task to make full usage of all samples including OOD samples for feature representation enhancement.

Open-set Semi-supervised Learning. Recently, researchers have gradually focused on settling the open-set SSL problem. [6] proposes to solve the problem in which the categories of labeled and unlabeled samples are not completely matched. In [39], the concept of open-set SSL is put forward for the first time. With the help of a binary OOD classifier, a curriculum framework is proposed to solve this problem. We argue that the OOD classification does not benefit to learn discriminative feature representations for the core category recognition task but actually have conflicting targets with the target category classification. Based on this concern, we propose a novel method to filter out OOD samples based on self-labeling and cross-modal matching between images and labels. UASD [6] temporally accumulates the network predictions for self-distillation, and uses a simple threshold on the largest prediction score to detect OOD samples. However, its detection of OOD data is highly sensitive to the performance of the final classifier. Our proposed cross-modal matching strategy removes the dependency on the outcome of the classifier by inferring whether the embedding of the input image is matched to an assigned pseudo-label. It also helps detect ID samples with incorrect pseudo labels ("hard" samples) that cannot be handled by UASD. DS3L [12] introduces meta-learning to suppress the weight of OOD samples. Instead of directly filtering out OOD samples, [25] attempts to remove the distribution divergence between ID and OOD samples based on style transfer, and then explore the OOD samples during training via the unsupervised data augmentation [37]. The distribution gap between ID and OOD samples is caused by category difference. Style transfer can only change the style of OOD images but not the semantic content. Hence, it remains difficult for style transfer technique to fully eliminate the feature discrepancy between the ID and OOD samples.

3. Method

Similar to the SSL problem, the training dataset of the open-set SSL problem contains a small subset of labeled samples $\mathbb{D}^l = \left\{(\mathbf{x}_i^l, y_i^l)\right\}_{i=1}^{n=N}$ and a large subset of unlabeled samples $\mathbb{D}^u = \{\mathbf{x}_i^u\}_{i=1}^{M}$. Here, $\mathbf{x}_i^l$ or $\mathbf{x}_i^u$ represents a labeled or unlabeled image. y_i^l denotes the ground-truth category of $\mathbf{x}_i^l$. Assuming that there are K target categories, $y_i^l \in \{1, \cdots, K\}$. The 'open-set' setting indicates that there exists OOD samples in the unlabeled training set. Namely, $\mathbf{x}_i^u$ may not belong to any one of the K target categories. We assume that a single training batch is consisting of n labeled images and m unlabeled images. The overall framework of our method is illustrated in Figure 2.

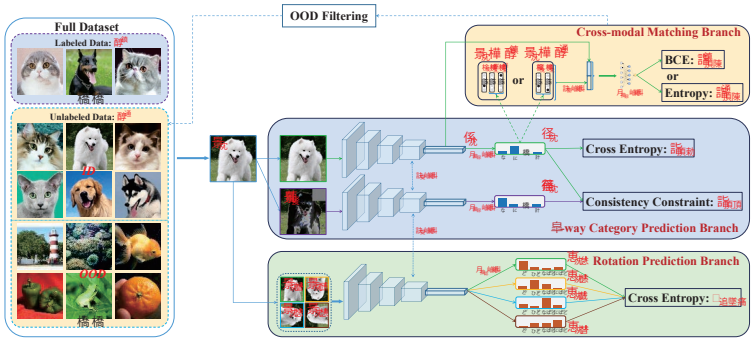

Figure 2: Overall architecture of our proposed method for open-set semi-supervised classification. It is composed of a multi-task framework, including a core category prediction branch, a rotation prediction branch for self-supervised feature learning, and a cross-modal matching branch for filtering out OOD samples within unlabeled data.

3.1. K-way Category Prediction

A convolutional neural network is chosen as the backbone for extracting feature representations from input images. It is used to extract a 128-dimensional feature $\mathbf{f}_i$ from an input image $\mathbf{x}_i$, namely $\mathbf{f}_i = g_\theta(\mathbf{x}_i)$. θ represents the network parameters, and $g_\theta(\cdot)$ denotes the calculation function of the backbone model. To obtain the prediction scores for the K target categories, a linear and a softmax layer is attached to the backbone, giving rise to a K-dimensional class probability vector $\mathbf{p}_i = h_{\omega_c}(\mathbf{f}_i) = h_{\omega_c}(g_\theta(\mathbf{x}_i))$. ω_c contains the weights and biases of the linear layer. During training, cross entropy is used to regularize the class probability vectors of labeled images,

$$L_{ce} = -\frac{1}{n}\sum_{i=1}^{n}\ln(p_i^l[y_i^l]). \tag{1}$$

Here, $p_i^l[k]$ indicates the k-th element of $\mathbf{p}_i^l$ which refers to the predicted probability vector of $\mathbf{x}_i^l$. Inspired by [37], the unsupervised consistency constraint is employed to pull close the distances between the predictions of every sample and its vicinal points. A strongly augmented counterpart $\tilde{\mathbf{x}}_i$ is synthesized for the training image $\mathbf{x}_i$. Denote the category prediction of $\mathbf{x}_i$ and $\tilde{\mathbf{x}}_i$ be $\mathbf{p}_i$ and $\tilde{\mathbf{p}}_i$ respectively. The KL divergence is adopted to calculate the distance between the two predictions, and the loss function of the consistency constraint is as below,

$$L_{cc} = \frac{1}{n+m}\sum_{i=1}^{n+m}\sum_{j=1}^{K} p_i[j]\ln(\frac{p_i[j]}{\tilde{p}_i[j]}). \tag{2}$$

3.2. Self-Supervised Representation Enhancement

For the sake of enhancing the representation capacity of the backbone with all training samples including both ID and OOD samples, the rotation recognition is introduced as an auxiliary task. In details, an extra 4-way rotation classification head consisting of 1 linear layer and 1 softmax function is attached to the backbone as shown in Figure 2. We denote the calculation process of the rotation classification head as $h_{w_r}(\cdot)$, where w_r represents related parameters. For every training image, four counterparts are generated through rotating it by $0°$, $90°$, $180°$ and $270°$, respectively. We denote images generated via rotating $\mathbf{x}_i$ by $(j-1)*90°$ as $\mathbf{x}_{i,j}$, and its rotation prediction as $\mathbf{q}_{i,j} = h_{w_r}(g_\theta(\mathbf{x}_{i,j}))$. The following loss function is added during the training stage,

$$L_{rot} = -\frac{1}{4(n+m)}\sum_{i=1}^{n+m}\sum_{j=1}^{4}\ln(q_{i,j}[j]). \tag{3}$$

This rotation prediction branch is critical to take advantage of large amounts of unlabed samples, especially OOD samples, to improve the representation learning.

3.3. Cross-Modal Matching

In order to protect the learning of the K-way category recognition task from being distorted by OOD samples, a cross-modal matching branch is devised to purify unlabeled samples. For an unlabeled sample $\mathbf{x}_i^u$, we assume the predicted probability vector be $\mathbf{p}_i^u$. The category having the most confident probability value is allocated as the pseudo label of $\mathbf{x}_i^u$, namely, $\hat{y}_i^u = \arg\max_j p_i^u[j]$. The target of the cross-modal matching branch is trained to judge whether an ID image and a label from the set of target categories are matched. It can be used to identify out OOD samples since they are not belonging to any of target categories, namely they are not matched to any target category.

Given a pair of an input sample $\mathbf{x}$ and a category label y, we first extract a feature vector $\mathbf{f} = g_\theta(\mathbf{x})$ for $\mathbf{x}$. y is transformed into a one hot vector which is subsequently transformed into a 128-dimensional embedding vector via a linear layer, $\mathbf{e} = g_\phi(y)$. Afterwards, $\mathbf{e}$ and $\mathbf{f}$ are concatenated and fed into a multi-layer perceptron consisting of a hidden layer with 128-dimensional output followed by the ReLU function and a linear layer attached with the Sigmoid function, giving rise to a matching score $s(\mathbf{x}, y) = h_{\omega_m}(\mathbf{f}, \mathbf{e}) = h_{\omega_m}(g_\theta(\mathbf{x}), g_\phi(y))$. The matching score $s(\mathbf{x}, y)$ measures whether y is the correct category label of $\mathbf{x}$. When training the cross-modal matching head, positive samples can be easily collected from labeled images. Negative samples are synthesized through making pairs of images and categories which are not identical to the ground-truth label. For every training image, negative training samples are constructed in two manners: 1) Inspired by hard example mining [32], a so-called hardest label which is different from the ground-truth but having the largest prediction score is chosen; 2) The other relatively simple label is randomly selected from the category set excluding the ground-truth label and the mined hardest label. The following loss function is used for training the cross-modal matching head,

$$\begin{aligned} L_{cm}^{l} = \; & -\tfrac{1}{n}\textstyle\sum_{i=1}^{n}[\ln(s(\mathbf{x}_i^l, y_i^l)) + \ln(1 - s(\mathbf{x}_i^l, \bar{y}_i^{l,h})) \\ & + \ln(1 - s(\mathbf{x}_i^l, \bar{y}_i^{l,s}))]. \end{aligned} \tag{4}$$

Here, $\bar{y}_i^{l,h}$ and $\bar{y}_i^{l,s}$ indicates the hardest and a relatively simple negative label, respectively,

$$\bar{y}_i^{l,h} = \arg\max_{y \neq y_i^l} p_i[y], \tag{5}$$

$$\bar{y}_i^{l,s} = \text{rand}(\{y \in [1, K] \mid y \neq y_i^l;\; y \neq \bar{y}_i^{l,h}\}). \tag{6}$$

Considering the labeled samples are limited in open-set SSL, the unlabeled samples are employed to further strengthen the cross-modal matching head with entropy minimization [11],

$$\begin{aligned} L_{cm}^{u} = \; & -\frac{1}{m}\sum_{i=1}^{m}[s(\mathbf{x}_i^u, \hat{y}_i^u)\ln(s(\mathbf{x}_i^u, \hat{y}_i^u)) + \\ & (1 - s(\mathbf{x}_i^u, \hat{y}_i^u))\ln(1 - s(\mathbf{x}_i^u, \hat{y}_i^u)) + \\ & s(\mathbf{x}_i^u, \bar{y}_i^u)\ln(s(\mathbf{x}_i^u, \bar{y}_i^u)) + \\ & (1 - s(\mathbf{x}_i^u, \bar{y}_i^u))\ln(1 - s(\mathbf{x}_i^u, \bar{y}_i^u))], \end{aligned} \tag{7}$$

where, $\bar{y}_i^u = \text{rand}(\{y \in [1, K] \mid y \neq \hat{y}_i^u\})$.

Apart from identifying OOD samples, the other utility of the cross-modal matching head is to preclude parts of misclassified ID samples. This is essential to reduce the instability of training the core classification task, especially when the classification performance of the model is still unfavorable in the early iterations. The cross-modal matching branch is used to estimate the matching scores of all unlabeled samples and their pseudo labels inferred with the K-way category prediction branch. The Otsu algorithm [29] is used to select the threshold for cleaning away samples with relatively low matching scores w.r.t their pseudo labels.

3.4. Training Process

The training process consists of two stages. In the first stage, we take a warm-up training stage for optimizing the complete architecture with loss function $L = L_{ce} + L_{cm}^{l} + L_{rot}$. In the second stage, the cross-modal matching head is used to periodically clean unlabeled samples. The consistency constraint (2) and entropy minimization (7) are added to train the K-way category prediction branch and the cross-modal matching branch, respectively. The loss function of this stage is $L = L_{ce} + L_{cm}^{l} + L_{cm}^{u} + L_{rot} + L_{cc}$. In such a manner, OOD samples are precluded after they are fully exploited for feature enhancement in the first stage.

4. Experiments

4.1. Datasets

The following four public datasets are used to validate the performance of open-set SSL algorithms.

CIFAR-10 [20] consists of 60,000 images of size 32×32 which belong to 10 categories. Following the original split, 10,000 images are used for testing. The same splits in [39] are adopted for training and validating. The number of labeled training images varies in {250, 1,000, 4,000}.

Animals-10 which is obtained from Kaggle, contains 26,179 images of 10 animal categories. 500/1,000, 1,000 and 2,000 images are selected as labeled training, validating, and testing samples respectively. The remaining images are used as unlabeled samples.

CIFAR-100 has 100 classes and each class contains 600 images. We choose 25,000 images of the first 50 classes as in-distribution samples, forming the CIFAR-ID-50 dataset. They are split into 22,500 samples for training and 2,500 samples for validating. The number of labeled training images is 2,000 or 2,500.

TinyImageNet (TIN) [22] is composed of 120,000 images belonging to 200 classes. Similar to CIFAR-100, 27,500 images of the first 50 categories are regarded as in-distribution samples, which are separated into 22,500 samples for training, 2,500 samples for validating, and 2,500 samples for testing. We name the above subset of TIN as TIN-ID-50. In experiments below, 2,000/2,500 training images are selected as labeled samples.

The following inter-dataset and intra-dataset OOD settings are used in our experiments.

Inter-Dataset OOD Setting For the CIFAR-10 dataset, we follow [39] to synthesize OOD samples. 10,000 images are sampled from each of the TIN dataset, the Large-scale

Alg.	TIN			LSUN			Gaussian Noise			Uniform Noise		
	250	1000	4000	250	1000	4000	250	1000	4000	250	1000	4000
MixM	$82.42_{0.70}$	$88.03_{0.22}$	$91.25_{0.13}$	$76.32_{4.19}$	$87.03_{0.41}$	$91.18_{0.33}$	$75.76_{3.49}$	$85.71_{1.14}$	$91.51_{0.35}$	$72.90_{0.96}$	$84.49_{1.06}$	$90.47_{0.38}$
UDA	$88.83_{0.49}$	$91.75_{0.12}$	$93.63_{0.11}$	$88.54_{1.10}$	$91.12_{0.31}$	$93.25_{0.12}$	$88.93_{0.73}$	$89.23_{0.41}$	$92.35_{0.18}$	$88.69_{0.93}$	$89.74_{0.42}$	$92.74_{0.35}$
UASD	83.53	-	-	80.87	-	-	-	-	-	-	-	-
DS3L	-	$70.10_{0.47}$	$82.58_{0.14}$	-	$69.74_{0.08}$	$82.89_{0.69}$	-	$62.86_{0.67}$	$80.44_{0.01}$	-	$62.89_{1.65}$	$80.59_{0.03}$
MTCF	$86.44_{0.64}$	$89.85_{0.11}$	$93.03_{0.05}$	$86.65_{0.41}$	$90.19_{0.47}$	$92.91_{0.03}$	$87.34_{0.13}$	$89.80_{0.26}$	$92.53_{0.08}$	$85.54_{0.11}$	$89.87_{0.08}$	$92.83_{0.04}$
OTCT	-	$91.10_{0.65}$	$93.84_{0.10}$	-	$91.30_{0.36}$	$94.27_{0.21}$	-	$92.33_{0.59}$	$94.52_{0.07}$	-	$91.82_{0.04}$	$94.50_{0.13}$
Ours	$91.52_{0.11}$	$93.26_{0.14}$	$94.71_{0.06}$	$91.13_{0.21}$	$94.43_{0.10}$	$94.97_{0.10}$	$90.81_{0.12}$	$93.63_{0.06}$	$94.38_{0.12}$	$89.95_{0.18}$	$94.12_{0.14}$	$94.83_{0.15}$

Table 1: Comparisons with the conventional SSL and open-set SSL algorithms, including MixM (short for MixMatch) [2], UDA [37], UASD [6] DS3L [12], MTCF [39], and OTCT [25], on variants of CIFAR-10 which are respectively corrupted with two real-world OOD datasets (TIN and LSUN) and two synthetic OOD datasets (Gaussian Noise and Uniform Noise). Accuracy (%) is used for evaluating algorithms. The subscript of the accuracy value indicates its standard deviation. 250, 1000, and 4000 labeled images are used for training respectively. We use the reported results of [39] for UASD and that of [25] for DS3L and OTCT.

Scene Understanding (LSUN) dataset [38], Gaussian noise dataset, and uniform noise dataset, forming into 4 OOD settings. For the Animals-10 and CIFAR-ID-50 datasets, 10,000 images from TIN are used as OOD samples.

Intra-Dataset OOD Setting For CIFAR-ID-50, we select 100 images from each of the other 50 classes of CIFAR-100 as OOD images. For TIN-ID-50, 50 images from each of the other 150 classes of TIN are chosen as OOD images.

4.2. Implementation details

Existing methods including MixMatch [2], UDA [37] FixMatch [33], UASD [6], DS3L [12], OTCT [25] and MTCF [39], are used for comparison. For UDA, FixMatch and our method, SGD is used to optimize network weights. The learning rate is initially set to 0.03 and adjusted via the cosine decay strategy [37, 33]. The momentum is set to 0.9. In each training batch, $n = 64$, and $m = 320$. For our method, the first stage costs 50,000 iterations, and the second stage takes 200,000 iterations. Without specification, the cycle length of using the crossmodal matching head to clean unlabeled data is 2×10^4. For UDA and FixMatch, models are trained with 250,000 iterations for a fair comparison. When training MixMatch and MTCF, we follow the original settings of [39] in which models are trained with 1,024 epochs, and each epoch contains 1,024 iterations. During the training stage, network weights are saved every 1,000 iterations. The averaged classification accuracy of the last 20 copies is used to evaluate the performance of all methods. For all experiments, we use the Wide-ResNet28-2 [40] as the backbone model.

4.3. Experimental Results

4.3.1 Comparison with Other Methods

Inter-Dataset OOD Setting As introduced in Section 4.1, three datasets including CIFAR-10 (Table 1), Animals-10 (Table 2), and CIFAR-ID-50 (Table 2) are used to validate the classification performance under the inter-dataset OOD setting. For all inter-dataset OOD settings of CIFAR-10, our method surpasses all compared methods by significant margins. As shown in Table 1, when 250 labeled images are provided and images of TIN are used as OOD samples,

Method	Animals-10		CIFAR-ID-50	
	500	1000	2000	2500
MixMatch [2]	78.35	83.15	62.10	64.78
UDA [37]	83.30	84.74	64.34	66.65
MTCF [39]	73.50	75.83	63.22	65.10
MTCF+UDA	79.85	85.60	65.20	67.30
FixMatch [33]	89.06	91.00	68.98	72.92
Ours+UDA	87.86	89.70	71.58	73.19
Ours+FixMatch	**89.43**	**91.50**	**72.06**	**73.80**

Table 2: Accuracy (%) for Animals-10 and CIFAR-ID-50. Images of TIN are used as OOD samples. On Animals-10 dataset, 500 or 1000 labeled images are used for training. On CIFAR-ID-50 dataset, 2000 or 2500 labeled images are used for training.

Method	CIFAR-ID-50		TIN-ID-50	
	2000	2500	2000	2500
MixMatch [2]	60.20	66.17	48.12	50.52
UDA [37]	66.02	67.82	54.03	55.39
MTCF [39]	63.48	65.38	49.64	52.08
MTCF+UDA	60.06	63.08	47.32	51.20
FixMatch [33]	68.06	71.01	56.82	60.33
Ours+UDA	67.36	69.14	54.87	57.08
Ours+FixMatch	**68.65**	**73.14**	**57.48**	**62.64**

Table 3: Accuracy (%) for CIFAR-ID-50 and TIN-ID-50 under the intra-dataset OOD setting. On both datasets, 2000 or 2500 labeled images are used for training.

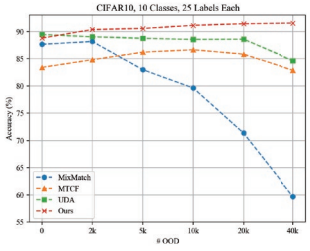

Figure 3: Impact of different number of OOD samples on baselines and our approach.

our method achieves an average accuracy of 91.52% which is 5.08% and 3.69% higher than MTCF and UDA, respectively. Compared with two synthetic noise OOD datasets, the rich semantic information of real-world datasets is beneficial to our proposed method. For instance, the accuracy of our method achieves 91.13% on the LSUN OOD setting, which is 1.28% higher than the accuracy on the uniform noise OOD setting.

Table 2 reports the results of Animals-10 and CIFAR-ID-50 under the inter-dataset OOD setting in which images of TIN are added as OOD samples. Our method is capable of improving existing SSL methods, e.g. UDA and FixMatch, and performs much better than MTCF.

We further study the impact of the number of OOD samples on SSL and open-set SSL algorithms. In this experiment, we use CIFAR-10 as the ID dataset and LSUN as the OOD dataset. The number of OOD samples varies from 0 to 4×10^4. 25 labeled samples are provided for each class The results are presented in Figure 3. Our method achieves better performance with even more OOD samples, and consistently outperforms all the other methods in all settings.

Intra-Dataset OOD Setting The CIFAR-ID-50 and TIN-ID-50 datasets are adopted in this experiment. Images of the same dataset but having categories different from those ID categories are regarded as OOD samples. The experimental results are shown in Table 3. Our method consistently performs better than other methods.

We try to modify MTCF [39] via using UDA [37] for semi-supervised learning, which forms a new open-set SSL algorithm denoted by 'UDA+MTCF'. In MTCF, the learning of the target category classifier is in conflict with the learning of the binary OOD classifier, thus the features learned by MTCF is not discriminative enough. Meanwhile, UDA depends on the label propagation from the weakly augmented image to the strongly augmented counterpart, which is sensitive to a confused feature space. The incorporation of MTCF only brings marginal improvement

ID	OOD	ODIN	SUF	MTCF	Ours
CIFAR-10	LSUN	98.47	99.03	99.82	**99.98**
Animals-10	TIN	76.35	90.01	92.59	**93.51**
CIFAR-ID-50	TIN	88.82	97.98	98.17	**99.85**
CIFAR-ID-50	CIFAR-50	69.47	72.32	69.75	**74.13**
TIN-ID-50	TIN-150	59.83	65.59	63.92	**65.67**

Table 4: The comparison of our method against ODIN [24], SUF [23], and MTCF [39] on the task of OOD detection. The evaluation metric is AUROC(%). ODIN and SUF are implemented based on the classifier model learnt by UDA. For CIFAR-10 and Animals-10, 250 labels and 500 labels are used during training respectively. For other datasets, 2500 labels are used during training.

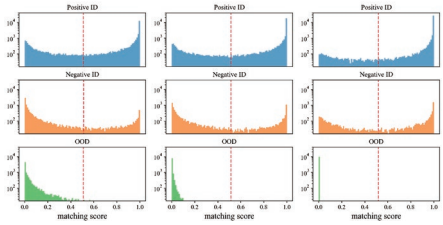

1000-th iteration 19000-th iteration 28000-th iteration

Figure 4: Visualization of the matching scores in different iterations. The number of samples are showcased in logarithmic coordinates (vertical axis) with base of 10. 'Positive ID'/'Negative ID' means ID samples having correct/incorrect classification results. The threshold value obtained via OTSU is indicated by the dashed vertical line.

(e.g. CIFAR-ID-50 in Table 2) or even causes severe performance degradation (e.g. both datasets in Table 3) to UDA.

OOD Detection Performance In Table 4, we compare our method against ODIN [24], Mahalanobis [23] and MTCF [39] under extensive combinations of ID and OOD datasets, to validate the efficacy of the cross-modal matching branch in detecting OOD images. In our method, the matching score of an image and its pseudo label is regarded as the probability value of the image belonging to ID samples. The area under the receiver operating characteristic (AUROC) is used to measure the performance of OOD detection algorithms. Our method outperforms ODIN, Mahalanobis and MTCF under all settings.

4.3.2 Ablation Study

We carry out an extensive ablation study on the CIFAR-10 and CIFAR-ID-50 to tease apart the experimental factors that are most important to the success of our method, as

M-#	Settings	CIFAR-10	CIFAR-ID-50
1	Supervised	39.66	53.18
2	Supervised+SS	75.69	59.82
3	UDA	88.83	64.78
4	UDA+SS	90.69	70.10
5	UDA+SS+CT	90.81	71.16
6	UDA+SS+CMF-w/o-L_{cm}^{u}	91.09	72.38
7	UDA+SS+CMF-w/o-WU	89.45	71.81
8	UDA+SS+CMF-full	**91.52**	**73.19**

Table 5: Ablation Study on CIFAR-10 and CIFAR-ID-50. TIN is chosen as the OOD dataset. 250 and 2500 labeled images are for CIFAR-10 and CIFAR-ID-50, respectively. Abbreviations: unsupervised data augmentation (UDA) [37], crossmodal matching based filtering (CMF), self-supervision based on rotation recognition (SS), warming-up (WU), confidence-based thresholding (CT).

shown in Table 5.

Self-supervised Learning in Open-set SSL M-2 and M-4 in Table 5 represent the variant of the simple supervised learning and UDA respectively, which employs rotation recognition as the auxiliary task. The accuracy of M-2 and M-4 on CIFAR-ID-50 is 5.32% and 6.64% higher than that of M-1 and M-3 respectively. This indicates that the feature enhancement brought by the rotation recognition task can significantly improve the classification accuracy. This is the first time to prove that self-supervised representation learning based on rotation recognition is effective in open-set SSL. We have tried other self-supervised learning methods, like SimCLR [4] and MoCo [14], and empirically find that they perform much worse than the rotation prediction approach. Both SimCLR and MoCo strive to distinguish the features of different samples while our task requires samples of the same class to stay closer in the feature space. The conflicting goals make them unsuitable for our task.

Different Variants of OOD Sample Filtering The full version of our method (M-8 in Table 5) outperforms M-4 without cross-modal matching head by 3.09% and 0.83% on CIFAR-ID-50 and CIFAR-10 respectively. This validates that our proposed OOD sample filtering algorithm based on cross-modal matching is complementary to self-supervised learning, and it further benefits the classification performance of in-distribution categories. On the other hand, merely using the supervised loss function (4) to train the cross-modal matching branch (M-6) leads to performance degradation to a certain extent. The accuracy on CIFAR-ID-50 is decreased by 0.81%, compared to the results of M-8 in which both function (4) and (7) are adopted for training. We also attempt to replace the cross-modal matching based filtering with the confidence-based thresholding via precluding unlabeled samples with maximum prediction scores lower than the OTSU threshold . The resulted method (M-5) achieves the accuracy of 90.81% and 71.16% on CIFAR10 and CIFAR-ID-50 respectively, which is much inferior to that of our method. This indicates the superiority of the proposed cross-modal matching based filtering to the confidence-based thresholding, since the former can simultaneously implement the OOD sample filtering and promote the discrimination between features of different categories.

Efficacy of Warming Up Stage The warm-up stage plays a crucial role in fully leveraging all ID and OOD samples for representation learning, providing a decent initialization for the K-way category prediction and the cross-modal matching tasks. Without the warm-up stage (M-7 in Table 5), the classification accuracy is reduced by 2.07% and 1.38% on CIFAR-10 and CIFAR-ID-50, respectively.

4.3.3 Justification of Cross-modal Matching

The performance of the cross-modal matching in identifying OOD samples and misclassified ID samples at different training iterations is visualized in Figure 4. The cross-modal matching head can effectively separate correctly classified samples from OOD samples, throughout the training process. In early iterations, the head is capable of precluding most of the misclassified samples. This helps prevent these misclassified samples from misleading the optimization process. As the iteration progresses, the core classifier gradually becomes better and the number of correctly classified samples continues to increase.

5. Conclusions

In this paper, we propose a novel framework for open-set SSL which can harvest the OOD samples for enhanced feature learning while avoiding its adverse impact on the SSL training. Our key insight is that OOD samples, if exploited in a pretext task of rotation recognition, can be "treasures" for learning more discriminative features that can benefit the final classification task. After the value of OOD samples in representation learning has been explored, the cross-modal matching branch is further utilized to filter out OOD samples without causing much interference to the core category prediction task. Our proposed method can be easily integrated into existing SSL algorithms, and achieves state-of-the-art in open-set SSL on extensive public benchmarks.

Acknowledgments This work was supported in part by the Guangdong Basic and Applied Basic Research Foundation under Grant No.2020B1515020048, in part by the National Natural Science Foundation of China under Grant No.61976250, No.U1811463 and No.62003256, and in part by the Guangzhou Science and technology project under Grant No.202102020633.

References

[1] Mikhail Belkin and Partha Niyogi. Semi-supervised learning on riemannian manifolds. *Machine learning*, 56(1):209–239, 2004. 3

[2] David Berthelot, Nicholas Carlini, Ian Goodfellow, Nicolas Papernot, Avital Oliver, and Colin A Raffel. Mixmatch: A holistic approach to semi-supervised learning. In *Advances in Neural Information Processing Systems*, pages 5049–5059, 2019. 3, 6

[3] Avrim Blum and Tom Mitchell. Combining labeled and unlabeled data with co-training. In *Proceedings of the eleventh annual conference on Computational learning theory*, pages 92–100, 1998. 3

[4] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *International conference on machine learning*, pages 1597–1607. PMLR, 2020. 8

[5] Xing Chen and Gui-Ying Yan. Semi-supervised learning for potential human microrna-disease associations inference. *Scientific reports*, 4:5501, 2014. 2

[6] Yanbei Chen, Xiatian Zhu, Wei Li, and Shaogang Gong. Semi-supervised learning under class distribution mismatch. In *Proceedings of the AAAI Conference on Artificial Intelligence.*, pages 3569–3576, 2020. 3, 6

[7] C. Doersch, A. Gupta, and A. A. Efros. Unsupervised visual representation learning by context prediction. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 1422–1430, 2015. 3

[8] WeiWang Dong-Dong Chen and Zhi-Hua Zhou WeiGao. Tri-net for semi-supervised deep learning. In *Proceedings of the International Joint Conferences on Artificial Intelligence*, pages 2014–2020, 2018. 3

[9] Alexey Dosovitskiy, Jost Tobias Springenberg, Martin Riedmiller, and Thomas Brox. Discriminative unsupervised feature learning with convolutional neural networks. In *Advances in Neural Information Processing Systems*, 2014. 3

[10] Spyros Gidaris, Praveer Singh, and Nikos Komodakis. Unsupervised representation learning by predicting image rotations. In *Proceedings of the International Conference on Learning Representations*, 2018. 3

[11] Yves Grandvalet and Yoshua Bengio. Semi-supervised learning by entropy minimization. In *Advances in Neural Information Processing Systems*, 2005. 5

[12] Lan-Zhe Guo, Zhen-Yu Zhang, Yuan Jiang, Yu-Feng Li, and Zhi-Hua Zhou. Safe deep semi-supervised learning for unseen-class unlabeled data. In *International Conference on Machine Learning*, pages 3897–3906. PMLR, 2020. 3, 6

[13] Jingrui He, Jaime Carbonell, and Yan Liu. Graph-based semi-supervised learning as a generative model. In *Proceedings of the International Joint Conferences on Artificial Intelligence*, pages 2492–2497, 01 2007. 3

[14] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In *Proceedings of the IEEE conference on Computer Vision and Pattern Recognition*, pages 9729–9738, 2020. 8

[15] Ahmet Iscen, Giorgos Tolias, Yannis Avrithis, and Ondrej Chum. Label propagation for deep semi-supervised learning. In *Proceedings of the IEEE conference on Computer Vision and Pattern Recognition*, pages 5070–5079, 2019. 3

[16] Lukas Käll, Jesse D Canterbury, Jason Weston, William Stafford Noble, and Michael J MacCoss. Semi-supervised learning for peptide identification from shotgun proteomics datasets. *Nature methods*, 4(11):923–925, 2007. 2

[17] Hisashi Kashima, Tsuyoshi Kato, Yoshihiro Yamanishi, Masashi Sugiyama, and Koji Tsuda. Link propagation: A fast semi-supervised learning algorithm for link prediction. In *Proceedings of the SIAM International Conference on Data Mining*, pages 1100–1111. SIAM, 2009. 2

[18] Thomas N. Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. In *Proceedings of the International Conference on Learning Representations*, 2017. 3

[19] Alexander Kolesnikov, Xiaohua Zhai, and Lucas Beyer. Revisiting self-supervised visual representation learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, June 2019. 3

[20] A. Krizhevsky and G. Hinton. Learning multiple layers of features from tiny images. *Master's thesis, Department of Computer Science, University of Toronto*, 2009. 1, 2, 5

[21] Samuli Laine and Timo Aila. Temporal ensembling for semi-supervised learning. In *Proceedings of the International Conference on Learning Representations*, 2016. 3

[22] Ya Le and Xuan Yang. Tiny imagenet visual recognition challenge. *CS 231N*, 7, 2015. 2, 5

[23] Kimin Lee, Kibok Lee, Honglak Lee, and Jinwoo Shin. A simple unified framework for detecting out-of-distribution samples and adversarial attacks. In *Advances in neural information processing systems*, volume 31, 2018. 7

[24] Shiyu Liang, Yixuan Li, and Rayadurgam Srikant. Enhancing the reliability of out-of-distribution image detection in neural networks. In *Proceedings of the International Conference on Learning Representations*, 2017. 7

[25] Huixiang Luo, Hao Cheng, Yuting Gao, Ke Li, Mengdan Zhang, Fanxu Meng, Xiaowei Guo, Feiyue Huang, and Xing Sun. On the consistency training for open-set semi-supervised learning. *arXiv preprint arXiv:2101.08237*, 2021. 3, 6

[26] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of machine learning research*, 9(Nov):2579–2605, 2008. 1

[27] Mehdi Noroozi and Paolo Favaro. Unsupervised learning of visual representations by solving jigsaw puzzles. In *Proceedings of the European Conference on Computer Vision*, volume 9910, pages 69–84, 10 2016. 3

[28] Avital Oliver, Augustus Odena, Colin Raffel, Ekin D Cubuk, and Ian J Goodfellow. Realistic evaluation of deep semi-supervised learning algorithms. In *Advances in Neural Information Processing Systems*, 2018. 2

[29] N Ostu, O Nobuyuki, and N Otsu. A threshold selection method from gray- level histogram ieee transactions on systems. *IEEE Trans.syst.man. & Cybern*, 9(1):62–66, 1979. 5

[30] Siyuan Qiao, Wei Shen, Zhishuai Zhang, Bo Wang, and Alan Yuille. Deep co-training for semi-supervised image recognition. In *Proceedings of the European Conference on Computer Vision*, pages 135–152, 2018. 3

[31] U. Raghavan, R. Albert, and S. Kumara. Near linear time algorithm to detect community structures in large-scale networks. *Physical review. E, Statistical, nonlinear, and soft matter physics*, 76 3 Pt 2:036106, 2007. 3

[32] Abhinav Shrivastava, Abhinav Gupta, and Ross Girshick. Training region-based object detectors with online hard example mining. In *Proceedings of the IEEE conference on Computer Vision and Pattern Recognition*, pages 761–769, 2016. 5

[33] Kihyuk Sohn, David Berthelot, Chun Liang Li, Zizhao Zhang, Nicholas Carlini, Ekin D. Cubuk, Alex Kurakin, Han Zhang, and Colin Raffel. Fixmatch: Simplifying semi-supervised learning with consistency and confidence. In *Advances in Neural Information Processing Systems*, 2020. 3, 6

[34] Antti Tarvainen and Harri Valpola. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results. In *Advances in Neural Information Processing Systems*, 2017. 3

[35] Isaac Triguero, Salvador García, and Francisco Herrera. Self-labeled techniques for semi-supervised learning: taxonomy, software and empirical study. *Knowledge and Information systems*, 42(2):245–284, 2015. 3

[36] Bo Wang, Zhuowen Tu, and John K Tsotsos. Dynamic label propagation for semi-supervised multi-class multi-label classification. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 425–432, 2013. 3

[37] Qizhe Xie, Zihang Dai, Eduard Hovy, Thang Luong, and Quoc Le. Unsupervised data augmentation for consistency training. In H. Larochelle, M. Ranzato, R. Hadsell, M. F. Balcan, and H. Lin, editors, *Advances in Neural Information Processing Systems*, volume 33, pages 6256–6268. Curran Associates, Inc., 2020. 3, 4, 6, 7, 8

[38] Fisher Yu, Ari Seff, Yinda Zhang, Shuran Song, Thomas Funkhouser, and Jianxiong Xiao. Lsun: Construction of a large-scale image dataset using deep learning with humans in the loop. *arXiv preprint arXiv:1506.03365*, 2015. 6

[39] Qing Yu, Daiki Ikami, Go Irie, and Kiyoharu Aizawa. Multi-task curriculum framework for open-set semi-supervised learning. In *Proceedings of the European Conference on Computer Vision*, 2020. 1, 2, 3, 5, 6, 7

[40] Sergey Zagoruyko and Nikos Komodakis. Wide residual networks. *arXiv preprint arXiv:1605.07146*, 2016. 6

[41] Xiaohua Zhai, Avital Oliver, Alexander Kolesnikov, and Lucas Beyer. S4l: Self-supervised semi-supervised learning. In *Proceedings of the IEEE International Conference on Computer Vision*, October 2019. 2, 3

[42] Hongyi Zhang, Moustapha Cisse, Yann N Dauphin, and David Lopez-Paz. mixup: Beyond empirical risk minimization. In *Proceedings of the International Conference on Learning Representations*, 2017. 3

[43] Xiaojin Zhu and Zoubin Ghahramani. Learning from labeled and unlabeled data with label propagation. 2002. 3

Feature Decomposition and Reconstruction Learning for Effective Facial Expression Recognition

Delian Ruan[1,2], Yan Yan[1,*], Shenqi Lai[2], Zhenhua Chai[2], Chunhua Shen[3], Hanzi Wang[1]
[1]Xiamen University, China [2]Vision Intelligence Center, Meituan [3]University of Adelaide

Abstract

In this paper, we propose a novel Feature Decomposition and Reconstruction Learning (FDRL) method for effective facial expression recognition. We view the expression information as the combination of the shared information (expression similarities) across different expressions and the unique information (expression-specific variations) for each expression. More specifically, FDRL mainly consists of two crucial networks: a Feature Decomposition Network (FDN) and a Feature Reconstruction Network (FRN). In particular, FDN first decomposes the basic features extracted from a backbone network into a set of facial action-aware latent features to model expression similarities. Then, FRN captures the intra-feature and inter-feature relationships for latent features to characterize expression-specific variations, and reconstructs the expression feature. To this end, two modules including an intra-feature relation modeling module and an inter-feature relation modeling module are developed in FRN. Experimental results on both the in-the-lab databases (including CK+, MMI, and Oulu-CASIA) and the in-the-wild databases (including RAF-DB and SFEW) show that the proposed FDRL method consistently achieves higher recognition accuracy than several state-of-the-art methods. This clearly highlights the benefit of feature decomposition and reconstruction for classifying expressions.

1. Introduction

Facial expression is one of the most natural and universal signals for human beings to express their inner states and intentions [4]. Over the past few decades, Facial Expression Recognition (FER) has received much attention in computer vision, due to its various applications including virtual reality, intelligent tutoring systems, health-care, *etc.* [29]. According to psychological studies [9], the FER task is to classify an input facial image into one of the following seven categories: angry (AN), disgust (DI), fear (FE), happy (HA), sad (SA), surprise (SU), and neutral (NE).

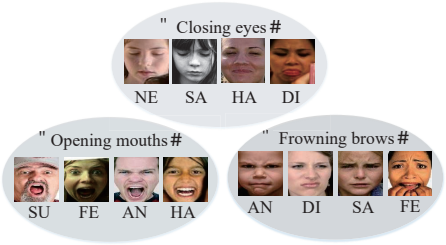

Figure 1 – The images in each group show a similar facial action, but they are from different expressions. Images are from the RAF-DB database [13].

A variety of FER methods [3, 13, 20, 26] have been proposed to learn holistic expression features by disentangling the disturbance caused by various disturbing factors, such as pose, identity, illumination, and so on. However, these methods neglect the fact that the extracted expression features corresponding to some expressions may still not be easily distinguishable, mainly because of high similarities across different expressions.

An example is shown in Figure 1. We can observe that some facial images corresponding to the NE, SA, HA, and DI expressions exhibit closing eyes. The facial images corresponding to the SU, FE, AN, and HA expressions all show opening mouths, while those corresponding to the AN, DI, SA, and FE expressions show frowning brows. The images from different facial expressions in each group give a similar facial action, where the distinctions between some expressions are subtle. Therefore, how to learn effective fine-grained expression features to identify subtle differences in expressions by considering similar facial actions is of great importance.

The expression information is composed of the shared information (expression similarities) across different expressions and the unique information (expression-specific variations) for each expression. The expression similari-

*Corresponding author (email: yanyan@xmu.edu.cn).

ties can be characterized by shared latent features between different expressions, while the expression-specific variations can be reflected by importance weights for latent features. Therefore, the expression features can be represented by combining a set of latent features associated with their corresponding importance weights. Traditional FER methods [15, 18, 31, 5] adopt Principal Component Analysis (PCA) or Linear Discriminant Analysis (LDA) to extract eigenvectors (corresponding to latent features) and eigenvalues (corresponding to importance weights). However, these eigenvectors only capture holistic structural information rather than fine-grained semantic information of facial images, which is critical for FER.

Motivated by the success of deep learning in various vision tasks, here we propose a novel Feature Decomposition and Reconstruction Learning (FDRL) method for effective FER. FDRL is mainly comprised of two crucial networks, including a Feature Decomposition Network (FDN) and a Feature Reconstruction Network (FRN). The two networks are tightly combined and jointly trained in an end-to-end manner.

Specifically, a backbone convolutional neural network is first used to extract basic features. Then, FDN decomposes the basic feature into a set of facial action-aware latent features, which effectively encode expression similarities across different expressions. In particular, a compactness loss is developed to obtain compact latent feature representations. Next, FRN, which includes an Intra-feature Relation Modeling module (Intra-RM) and an Inter-feature Relation Modeling module (Inter-RM), models expression-specific variations and reconstructs the expression feature. Finally, an expression prediction network is employed for expression classification.

In summary, our main contributions are summarized as follows.

- A novel FDRL method is proposed to perform FER. In FDRL, FDN and FRN are respectively developed to explicitly model expression similarities and expression-specific variations, enabling the extraction of fine-grained expression features. Thus, the subtle differences between facial expressions can be accurately identified.
- Intra-RM and Inter-RM are elaborately designed to learn an intra-feature relation weight and an inter-feature relation weight for each latent feature, respectively. Therefore, the intra-feature and inter-feature relationships between latent features are effectively captured to obtain discriminative expression features.
- Our FDRL method is extensively evaluated on both the in-the-lab and the in-the-wild FER databases. Experimental results show that our method consistently outperforms several state-of-the-art FER methods. In particular, FDRL achieves 89.47% and 62.16% recognition accuracy on the RAF-DB and SFEW databases, respectively. This convincingly shows the great potentials of feature decomposition and reconstruction for FER.

2. Related work

With the rapid development of deep learning, extensive efforts have been made to perform FER. State-of-the-art deep learning-based FER methods mainly focus on two aspects: 1) disturbance disentangling, and 2) expression feature extraction.

2.1. Disturbance Disentangling

Many FER methods have been proposed to predict expressions by disentangling the disturbance caused by various disturbing factors, such as pose, identity, illumination, and so on. Wang *et al.* [22] propose an adversarial feature learning method to tackle the disturbance caused by facial identity and pose variations. Ruan *et al.* [20] propose a novel Disturbance-Disentangled Learning (DDL) method to simultaneously disentangle multiple disturbing factors. Note that the above methods depend largely on the label information of disturbing factors. A few methods address the occlusion problem of FER. Wang and Peng [24] propose a novel Region Attention Network (RAN) to adaptively adjust the importance of facial regions to mitigate the problems of occlusion and variant poses for FER.

Recently, some methods are concerned with the noisy label problem in the FER databases. Zeng *et al.* [28] propose an Inconsistent Pseudo Annotations to Latent Truth (IPA2LT) method to deal with the problem of inconsistency in different FER databases. Wang *et al.* [23] introduce a Self-Cure Network (SCN) to prevent the trained model from over-fitting uncertain facial images.

The above methods perform FER by alleviating the influence caused by disturbing factors or noisy labels. However, they do not take into account subtle differences between different facial expressions. In this paper, we formulate the FER problem from the perspective of feature decomposition and reconstruction, which successfully models expression similarities and expression-specific variations. Therefore, high-level semantic information can be effectively encoded to classify facial expressions.

2.2. Expression Feature Extraction

Some FER methods design effective network architectures and loss functions to reduce inter-class similarities and enhance intra-class compactness for expression feature extraction. Li *et al.* [13] propose a deep locality-preserving loss based method, which extracts discriminative expression features by preserving the locality closeness. Cai *et*

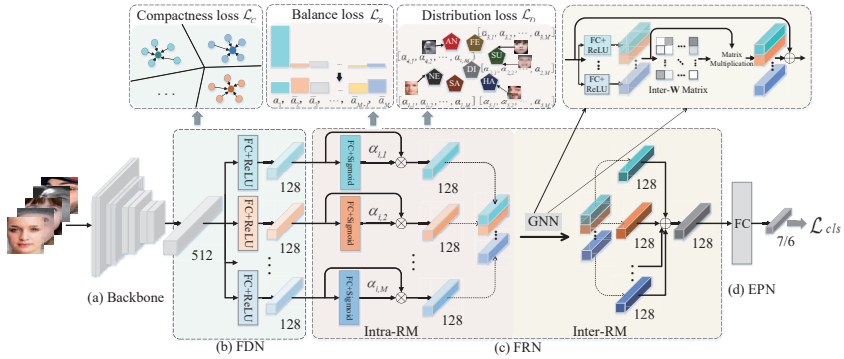

Figure 2 – Overview of our proposed FDRL method. (a) The backbone network (ResNet-18) that extracts basic CNN features; (b) A Feature Decomposition Network (FDN) that decomposes the basic feature into a set of facial action-aware latent features; (c) A Feature Reconstruction Network (FRN) that learns an intra-feature relation weight and an inter-feature relation weight for each latent feature, and reconstructs the expression feature. FRN contains two modules: an Intra-feature Relation Modeling module (Intra-RM) and an Inter-feature Relation Modeling module (Inter-RM); (d) An Expression Prediction Network (EPN) that predicts an expression label.

al. [3] design a novel island loss to simultaneously increase inter-class separability and intra-class compactness.

A few FER methods employ attention mechanisms [26] to improve the discriminative ability of expression features. Xie *et al.* [26] design an attention layer to focus on salient regions of a facial expression. Wang *et al.* [24] determine the importance of different facial regions by leveraging an attention network.

The above methods enhance the discriminative capability of expression features by designing different loss functions or attention mechanisms. These methods consider the expression features as holistic features. In contrast, we decompose the basic features into a set of facial action-aware latent features and then model the intra-feature and inter-feature relationships for latent features. Compared with holistic features used in traditional methods, the latent feature representations developed in our method are more fine-grained and facial action-aware. Such a manner is beneficial to learn expression features for identifying subtle differences between facial expressions.

3. Our Method

Overview. The proposed FDRL method consists of a backbone network, a Feature Decomposition Network (FDN), a Feature Reconstruction Network (FRN), and an Expression Prediction Network (EPN). An overview of the proposed method is shown in Figure 2.

Given a batch of facial images, we first feed them into a backbone network (in this paper, we use ResNet-18 [11] as the backbone) to extract basic CNN features. Then, FDN decomposes the basic features into a set of facial action-aware latent features, where a compactness loss is designed to extract compact feature representations. Next, FRN learns an intra-feature relation weight and an inter-feature relation weight for each latent feature, and reconstructs the expression feature. Finally, EPN (a simple linear fully-connected layer) predicts a facial expression label.

In particular, FRN consists of two modules: an Intra-feature Relation Modeling module (Intra-RM) and an Inter-feature Relation Modeling module (Inter-RM). To be specific, Intra-RM is first introduced to assign an intra-feature relation weight to each latent feature according to the importance of the feature, and thus an intra-aware feature is obtained. To ensure similar distributions of intra-feature relation weights for facial images from the same expression category, a distribution loss and a balance loss are employed in Intra-RM. Then, Inter-RM computes an inter-feature relation weight by investigating the relationship between intra-aware features, and thus an inter-aware feature is extracted. At last, the expression feature is represented by a combination of the intra-aware feature and the inter-aware feature. FRN exploits both the contribution of each latent feature and the correlations between intra-aware features, enabling the extraction of discriminative expression features.

3.1. Feature Decomposition Network (FDN)

Given the i-th facial image, the basic feature extracted by the backbone network is denoted as $\mathbf{x}_i \in \mathbf{R}^P$, where P is the dimension of the basic feature. As men-

tioned previously, FDN decomposes the basic feature into a set of facial action-aware latent features. Let $\mathbf{L}_i = [\mathbf{l}_{i,1}, \mathbf{l}_{i,2}, \cdots, \mathbf{l}_{i,M}] \in \mathbf{R}^{D \times M}$ denote a facial action-aware latent feature matrix, where $\mathbf{l}_{i,j} \in \mathbf{R}^D$ represents the j-th latent feature for the i-th facial image. D and M represent the dimension of each latent feature and the number of latent features, respectively.

Specifically, to extract the j-th latent feature, we employ a linear Fully-Connected (FC) layer and a ReLU activation function, which can be formulated as:

$$\mathbf{l}_{i,j} = \sigma_1(\mathbf{W}_{d_j}^{\mathrm{T}} \mathbf{x}_i) \quad \text{for } j = 1, 2, \cdots, M, \tag{1}$$

where $\mathbf{W}_{d_j}$ denotes the parameters of the FC layer used for extracting the j-th latent feature and σ_1 represents the ReLU function.

Compactness Loss. Since different facial expressions share the same set of latent features, it is expected that a set of compact latent feature representations are extracted. In other words, the j-th latent feature extracted from one basic feature should be similar to that extracted from another basic feature. To achieve this, inspired by the center loss [25], we develop a compactness loss. The compactness loss $\mathcal{L}_C$ learns a center for the same latent features and penalizes the distances between the latent features and their corresponding centers, which can be formulated as:

$$\mathcal{L}_C = \frac{1}{N} \sum_{i=1}^{N} \sum_{j=1}^{M} \| \mathbf{l}_{i,j} - \mathbf{c}_j \|_2^2, \tag{2}$$

where N denotes the number of images in a mini-batch. $\| \cdot \|_2$ indicates the L_2 norm. $\mathbf{c}_j \in \mathbf{R}^D$ denotes the center of the j-th latent features, and is updated based on a mini-batch. Thus, the intra-latent variations are minimized and a set of compact latent features are effectively learned.

To visually demonstrate the interpretation of latent features, we collect a group of images that corresponds to the highest intra-feature relation weight (see Section 3.2) of the same latent feature and then visualize them. In Figure 3, we can observe that the images from each group show a specific facial action. The images from the nine groups show the facial actions of "Neutral", "Lip Corner Puller", "Staring", "Opening Mouths", "Lips Part", "Closing Eyes", "Grinning", "Frowning Brows", and "Lip Corner Depressor", respectively. Therefore, the latent features obtained by FDN are fine-grained and facial action-aware features, which can be useful for subsequent expression feature extraction.

3.2. Feature Reconstruction Network (FRN)

In this section, FRN, which models expression-specific variations, is carefully designed to obtain discriminative expression features. FRN contains two modules: Intra-RM and Inter-RM.

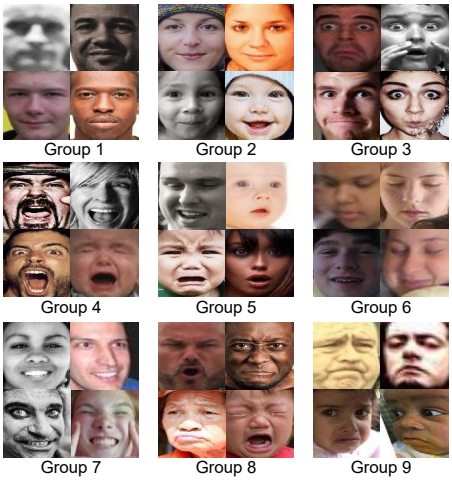

Figure 3 – Visualization of the image groups from the RAF-DB database when M is set to 9. Each group corresponds to the highest intra-feature relation weight of the same latent feature.

Intra-feature Relation Modeling Module (Intra-RM). Intra-RM consists of multiple intra-feature relation modeling blocks, where each block is designed to model the intra-feature relationship between feature elements.

To be specific, each block is composed of an FC layer and a sigmoid activation function, that is:

$$\boldsymbol{\alpha}_{i,j} = \sigma_2(\mathbf{W}_{s_j}^{\mathrm{T}} \mathbf{l}_{i,j}) \quad \text{for } j = 1, 2, \cdots, M, \tag{3}$$

where $\boldsymbol{\alpha}_{i,j} \in \mathbf{R}^D$ denotes the importance weights for the j-th latent feature corresponding to the i-th facial image, $\mathbf{W}_{s_j}$ represents the parameters of the FC layer, and σ_2 indicates the sigmoid function.

With Eq. (3), we compute the L_1 norm of $\boldsymbol{\alpha}_{i,j}$ as the Intra-feature relation Weight (Intra-W) to determine the importance of the j-th latent feature, that is:

$$\alpha_{i,j} = \| \boldsymbol{\alpha}_{i,j} \|_1 \quad \text{for } j = 1, 2, \cdots, M, \tag{4}$$

where $\| \cdot \|_1$ denotes the L_1 norm.

It is desirable that the distributions of Intra-Ws corresponding to different images from the same expression category are as close as possible. Therefore, similarly to the compactness loss, a distribution loss is used to learn a center for each expression category and penalize the distances between the Intra-Ws from one class and the corresponding center. Hence, the variations caused by different disturbing factors are alleviated.

Suppose that the i-th facial image belongs to the k_i-th expression category. Mathematically, the distribution loss $\mathcal{L}_D$ is formulated as:

$$\mathcal{L}_D = \frac{1}{N}\sum_{i=1}^{N} \parallel \mathbf{w}_i - \mathbf{w}_{k_i} \parallel_2^2, \tag{5}$$

where $\mathbf{w}_i = [\alpha_{i,1}, \alpha_{i,2}, \cdots, \alpha_{i,M}]^{\mathrm{T}} \in \mathbf{R}^M$ represents the Intra-W vector for the i-th facial image. $\mathbf{w}_{k_i} \in \mathbf{R}^M$ denotes the class center corresponding to the k_i-th expression category.

By optimizing the distribution loss, the Intra-W vectors corresponding to different images from the same expression category are closely distributed. Thus, they are able to focus on expression-specific variations.

In practice, as shown in Figure 2, some Intra-Ws (corresponding to one or two latent features) usually show much higher values than the other Intra-Ws in the Intra-W vector for each image, since these Intra-Ws are individually computed. To alleviate this problem, we further design a balance loss to balance the distributions of elements in each Intra-W vector as:

$$\mathcal{L}_B = \parallel \overline{\mathbf{w}} - \mathbf{w}_u \parallel_1, \tag{6}$$

where $\overline{\mathbf{w}} = [\overline{\alpha}_1, \overline{\alpha}_2, \cdots, \overline{\alpha}_M]^{\mathrm{T}} \in \mathbf{R}^M$ represents the mean Intra-W vector for a batch of samples (i.e., $\overline{\mathbf{w}} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{w}_i$). $\mathbf{w}_u = [\frac{1}{M}, \frac{1}{M}, \cdots, \frac{1}{M}]^{\mathrm{T}} \in \mathbf{R}^M$ denotes a uniformly-distributed weight vector.

After computing an Intra-W for each latent feature, we assign this weight to the corresponding feature and obtain an intra-aware feature for the i-th facial image as:

$$\mathbf{f}_{i,j} = \alpha_{i,j}\mathbf{l}_{i,j} \quad \text{for } j = 1, 2, \cdots, M, \tag{7}$$

where $\mathbf{f}_{i,j} \in \mathbf{R}^D$ represents the j-th intra-aware feature for the i-th facial image.

Inter-feature Relation Modeling Module (Inter-RM). Intra-RM learns an Intra-W for each individual latent feature. However, these Intra-Ws are independently extracted. Although the distribution loss imposes consistency regularization on the Intra-W, it does not fully consider the inter-relationship between latent features. In fact, for each facial expression, different kinds of facial actions usually simultaneously appear. For example, the FE expression often involves the facial actions of frowning brows and opening mouths. The HA expression contains the facial actions of stretching brows, closing eyes, and opening mouths. Therefore, it is critical to exploit the correlations between different facial action-aware latent features. To achieve this, we further introduce Inter-RM to learn an Inter-feature Relation Weight (Inter-W) between intra-aware features based on Graph Neural Network (GNN) [2, 21].

Inter-RM learns a set of relation messages and estimates the Inter-Ws between these messages. Specifically, for each $\mathbf{f}_{i,j}$, it is first fed into a message network for feature encoding. In this paper, the message network is composed of an FC layer and a ReLU activation function, which is:

$$\mathbf{g}_{i,j} = \sigma_1(\mathbf{W}_{e_j}^{\mathrm{T}}\mathbf{f}_{i,j}) \quad \text{for } j = 1, 2, \cdots, M, \tag{8}$$

where $\mathbf{W}_{e_j}$ denotes the parameters of the FC layer used for feature encoding and σ_1 represents the ReLU function. $\mathbf{g}_{i,j} \in \mathbf{R}^D$ denotes the j-th relation message for the i-th facial image.

Then, a relation message matrix $\mathbf{G}_i = [\mathbf{g}_{i,1}, \mathbf{g}_{i,2}, \cdots, \mathbf{g}_{i,M}] \in \mathbf{R}^{D\times M}$ is represented as nodes in the graph $G(\mathbf{G}_i, E)$. In our formulation, G is an undirected complete graph and E represents the set of relationships between different relation messages. $\omega_i(j, m)$ is the Inter-W which denotes the relation importance between the node $\mathbf{g}_{i,j}$ and the node $\mathbf{g}_{i,m}$. It can be calculated as:

$$\omega_i(j, m) = \begin{cases} \sigma_3(S(\mathbf{g}_{i,j}, \mathbf{g}_{i,m})) & j \neq m \\ 0 & j = m \end{cases}, \tag{9}$$

where $\mathbf{g}_{i,j}$ and $\mathbf{g}_{i,m}$ are the j-th and the m-th relation messages for the i-th facial image, respectively. S is a distance function, which estimates the similarity score between $\mathbf{g}_{i,j}$ and $\mathbf{g}_{i,m}$. In our paper, we use the Euclidean distance function. Since the results of $S(\cdot)$ are all positive, we further adopt the tanh activation function σ_3 to normalize the positive distance value to [0,1). The purpose of setting $\omega_i(j, j)$ to 0 is to avoid self-enhancing. According to Eq. (9), an Inter-W matrix $\mathbf{W}_i = \{\omega_i(j, m)\} \in \mathbf{R}^{M\times M}$ can be obtained.

Hence, the j-th inter-aware feature $\hat{\mathbf{f}}_{i,j} \in \mathbf{R}^D$ for the i-th facial image can be formulated as:

$$\hat{\mathbf{f}}_{i,j} = \sum_{m=1}^{M} \omega_i(j, m)\mathbf{g}_{i,m} \quad \text{for } j = 1, 2, \cdots, M. \tag{10}$$

By combining the j-th intra-aware feature and the j-th inter-aware feature, the j-th importance-aware feature $\mathbf{y}_{i,j} \in \mathbf{R}^D$ for the i-th facial image is calculated as:

$$\mathbf{y}_{i,j} = \delta\mathbf{f}_{i,j} + (1 - \delta)\hat{\mathbf{f}}_{i,j} \quad \text{for } j = 1, 2, \cdots, M, \tag{11}$$

where δ represents the regularization parameter that balances the intra-aware feature and the inter-aware feature.

Finally, a set of importance-aware features are added to obtain the final expression feature, that is,

$$\mathbf{y}_i = \sum_{j=1}^{M} \mathbf{y}_{i,j}, \tag{12}$$

where $\mathbf{y}_i \in \mathbf{R}^D$ represents the expression feature for the i-th facial image.

3.3. Joint Loss Function

In the proposed FDRL, the backbone network, FDN, FRN, and EPN are jointly trained in an end-to-end manner. The whole network minimizes the following joint loss function:

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda_1 \mathcal{L}_C + \lambda_2 \mathcal{L}_B + \lambda_3 \mathcal{L}_D, \tag{13}$$

where $\mathcal{L}_{cls}$, $\mathcal{L}_C$, $\mathcal{L}_B$, and $\mathcal{L}_D$ represent the classification loss, the compactness loss, the balance loss, and the distribution loss, respectively. In this paper, we use the cross-entropy loss as the classification loss. λ_1, λ_2, and λ_3 denote the regularization parameters. By optimizing the joint loss, FDRL is able to extract discriminative fine-grained expression features for FER.

4. Experiments

We first briefly introduce five public FER databases. Then, we describe the implementation details, and perform ablation studies with qualitative and quantitative results to show the importance of each component in FDRL. Finally, we compare FDRL with state-of-the-art FER methods.

4.1. Databases

CK+ [14] contains 327 video sequences, which are captured in controlled lab environments. We choose the three peak expression frames from each expression sequence to construct the training set and the test set, thus resulting in a total of 981 images. **MMI [19]** is also a lab-controlled database, containing 205 video sequences with six basic expressions. We choose the three peak frames from each sequence to construct the training set and the test set, thus resulting in a total of 615 images. **Oulu-CASIA [30]** contains videos captured in controlled lab conditions. We select the last three frames in each sequence captured with the visible light and strong illumination to construct the training set and the test set (consisting of 1,440 images in total). Similarly to [8, 17, 27, 32], we employ the subject-independent ten-fold cross-validation protocol for evaluation on all the three in-the-lab databases.

RAF-DB [13] is a real-world FER database, which contains 30,000 images labeled with basic or compound expressions by 40 trained human labelers. The images with six basic expressions and one neutral expression are used in our experiment. RAF-DB involves 12,271 images for training and 3,068 images for testing. **SFEW [6]** is created by selecting static frames from Acted Facial Expressions in the Wild (AFEW) [7]. The images in SFEW are labeled with six basic expressions and one neutral expression. We use 958 images for training and 436 images for testing.

4.2. Implementation Details

For each database, all the facial images are detected and cropped according to eye positions, and the cropped images are further resized to the size of 256×256. During the training process, the facial images are randomly cropped to the size of 224×224, and then a random horizontal flip is applied for data augmentation. During the test process, the input image is center cropped to the size of 224×224 and then fed into the trained model. The FDRL method is implemented with the Pytorch toolbox and the backbone network is a lightweight ResNet-18 model [11]. Similarly to [23], the ResNet-18 is pre-trained on the MS-Celeb-1M face recognition database [10].

The dimension of the basic feature is 512. The dimensions of both the latent feature and the expression feature are 128. The value of δ in Eq. (11) is empirically set to 0.5. We train our FDRL in an end-to-end manner with a single TITAN X GPU for 40 epochs, and the batch size for all the databases is set to 64. The model is trained using the Adam algorithm [12] with the initial learning rate of 0.0001, $\beta_1 = 0.500$, and $\beta_2 = 0.999$. The learning rate is further divided by 10 after 10, 18, 25, and 32 epochs.

4.3. Ablation Studies

To show the effectiveness of our method, we perform ablation studies to evaluate the influence of key parameters and components on the final performance. For all the experiments, we use one in-the-lab database (MMI) and one in-the-wild database (RAF-DB) to evaluate the performance.

Influence of the number of latent features. As shown in Figure 4, we can see that the proposed method achieves the best recognition accuracy when the number of latent features is set to 9. On one hand, when a small number of latent features are used, the expression similarities cannot be effectively modeled. On the other hand, when a large number of latent features are used, there exist redundancy and noise among latent features, thus leading to a performance decrease. In the following experiments, we set the number of latent features to 9.

Influence of the parameters. We evaluate the recognition performance of the proposed method with the different values of λ_1, λ_2, and λ_3 in Eq. (13), as shown in Table 1.

Specifically, we first fix $\lambda_2 = 1.0$ and $\lambda_3 = 0.0001$, and set the value of λ_1 from 0 to 0.01. Experimental results are given in Table 1 (a). We can observe that our method achieves the best performance when the value of λ_1 is set to 0.0001. When $\lambda_1 = 0$, our method is trained without using the compactness loss, and the performance decreases. Table 1 (b) shows the recognition performance obtained by our method, when the values of λ_1 and λ_3 are both set to 0.0001, and the value of λ_2 varies from 0 to 2.0. When the value of λ_2 is set to 1.0, our method achieves the top performance. Then, we fix $\lambda_1 = 0.0001$ and $\lambda_2 = 1.0$, and set the value

Table 1 – Ablation studies for the different values of λ_1, λ_2, and λ_3 (represent the balance parameters for compactness loss, balance loss, and distribution loss, respectively) on MMI and RAF-DB. The recognition accuracy (%) is used for performance evaluation.

(a) Influence of λ_1.

λ_1	MMI	RAF-DB
0	84.64	88.75
0.00001	85.02	89.02
0.0001	**85.23**	**89.47**
0.001	82.67	88.82
0.01	82.24	88.63

(b) Influence of λ_2.

λ_2	MMI	RAF-DB
0	82.66	88.23
0.5	83.68	88.89
1.0	**85.23**	**89.47**
1.5	84.94	88.92
2.0	83.23	88.63

(c) Influence of λ_3.

λ_3	MMI	RAF-DB
0	84.96	89.15
0.00001	85.07	88.89
0.0001	**85.23**	**89.47**
0.001	82.66	88.95
0.01	81.64	88.49

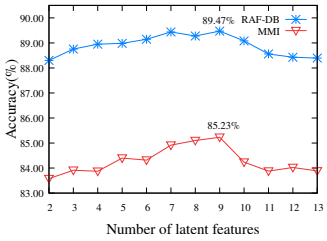

Figure 4 – Ablation studies for the different numbers of latent features on the MMI and RAF-DB databases.

Table 2 – Ablation studies for three key modules of our FDRL on the MMI and RAF-DB databases. The recognition accuracy (%) is used for performance evaluation.

FDN	FRN		MMI	RAF-DB
	Intra-RM	Inter-RM		
×	×	×	79.69	86.93
√	×	×	81.23	87.71
√	×	√	83.44	88.76
√	√	×	84.74	89.34
√	√	√	**85.23**	**89.47**

of λ_3 from 0 to 0.01. Experimental results are given in Table 1 (c). Our method obtains the top performance when $\lambda_3 = 0.0001$. In the following, we set the values of both λ_1 and λ_3 to 0.0001, and set the value of λ_2 to 1.0.

Influence of the key modules. To evaluate the effectiveness of the key modules in FDRL, we perform ablation studies for FDN, Intra-RM, and Inter-RM on the MMI and RAF-DB databases, respectively. Experimental results are reported in Table 2.

We can see that incorporating FDN into the backbone network improves the performance, which shows the importance of FDN. Moreover, by employing Intra-RM or Inter-RM in FRN, we are able to achieve better recognition accuracy than the method combining FDN and the backbone network. This is because the features extracted by FDN are not distinguishable enough to classify different expressions, since FDN does not take expression-specific variations into account. In contrast, Intra-RM and Inter-RM effectively model the intra-feature relationship of each latent feature and the inter-feature relationship between intra-aware features, respectively, leading to performance improvements. Our proposed FDRL method, which combines the backbone network, FDN, and FRN in an integrated network, achieves the best results among all the variants.

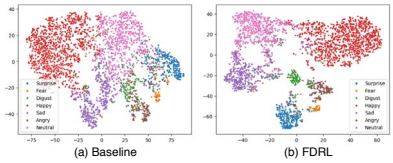

Figure 5 – Visualization of the expression features using t-SNE. Features are extracted from the RAF-DB database.

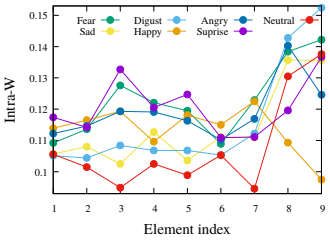

Figure 6 – Visualization of distribution of mean Intra-W vectors for seven basic expression categories on the RAF-DB database.

4.4. Visualization

2D feature visualization. We use t-SNE [16] to visualize the expression features extracted by the baseline method (which only adopts ResNet-18) and the proposed FDRL method on the 2D space, respectively, as shown in Figure 5. We can observe that the expression features extracted from

Table 3 – Performance comparisons among different methods on several public FER databases. The best results are boldfaced. ‡ and † respectively denote that seven expression categories and six expression categories are used in CK+.

(a) Comparisons on the in-the-lab databases.

Methods	Accuracy (%)		
	CK+	MMI	Oulu-CASIA
PPDN [32]	97.30†	-	72.40
IACNN [17]	95.37‡	71.55	-
DLP-CNN [13]	95.78†	78.46	-
IPA2LT [28]	92.45‡	65.61	61.49
DeRL [27]	97.37‡	73.23	88.00
FN2EN [8]	98.60†	-	87.71
DDL [20]	99.16‡	83.67	**88.26**
Baseline	97.15‡	79.69	86.18
FDRL (proposed)	**99.54** ‡	**85.23**	**88.26**

(b) Comparisons on the in-the-wild databases.

Methods	Accuracy (%)	
	RAF-DB	SFEW
IACNN [17]	-	50.98
DLP-CNN [13]	84.13	51.05
IPA2LT [28]	86.77	58.29
SPDNet [1]	87.00	58.14
RAN [24]	86.90	56.40
SCN [23]	87.01	-
DDL [20]	87.71	59.86
Baseline	86.93	58.03
FDRL (proposed)	**89.47**	**62.16**

the baseline method are not easily distinguishable for different facial expressions. In contrast, the features extracted from our proposed method can effectively reduce intra-class differences and enhance inter-class separability for different expressions. Especially, compared with baseline, the differences between fear and surprise, disgust and sadness are more distinct for FDRL.

Distribution of mean Intra-W vectors. We visualize the distribution of mean Intra-W vectors (corresponding to nine latent features) for seven basic expression categories on the RAF-DB database, as shown in Figure 6. Generally, each expression shows relatively high weights on the latent features associated with facial actions (as shown in Figure 3) closely related to this expression. Nevertheless, we can observe that some latent features (such as 2nd and 6th, 1st and 4th) have similar weights for different expressions. Hence, we further develop Inter-RM to exploit the inter-feature relationship between different intra-aware features.

4.5. Comparison with State-of-the-Art Methods

Table 3 shows the comparison results between our method and several state-of-the-art FER methods on the in-the-lab databases and the in-the-wild databases.

Among all the competing methods, IACNN, DDL, and RAN aim to disentangle the disturbing factors in facial expression images. SCN and IPA2LT are proposed to solve the noise label problem. FN2EN, DTAGN, and SPDNet improve the model performance by designing new network architectures. DLP-CNN alleviates intra-class variations by using a novel loss function. The above methods improve the FER performance by suppressing the influence of different disturbing factors or noise labels, but they ignore large expression similarities among different expressions. In contrast, our method explicitly models expression similarities and expression-specific variations with FDN and FRN, respectively, leading to performance improvements.

PPDN is developed to focus on the differences between expression images. DeRL claims that a facial expression is composed of the expression component and the neutral component. These two methods extract coarse-grained expression features. On the contrary, our proposed FDRL extracts more fine-grained features based on feature decomposition and reconstruction. Such a manner is beneficial to discriminate subtle differences between facial expressions, especially similar expression categories (such as fear and surprise). The above experimental results show the effectiveness of our proposed method.

5. Conclusion

In this paper, we have proposed a novel FDRL method for effective FER. FDRL consists of two main networks: FDN and FRN. FDN effectively models the shared information across different expressions based on a compactness loss. FRN accurately characterizes the unique information for each expression by taking advantage of Intra-RM and Inter-RM, and reconstructs the expression feature. In particular, Intra-RM encodes the intra-feature relationship of each latent feature and obtains an intra-aware feature. Inter-RM exploits the inter-feature relationship between different intra-aware features and extracts an inter-aware feature. The expression feature is represented by combining the intra-aware feature and the inter-aware feature. Experimental results on both the in-the-lab and the in-the-wild databases have shown the superiority of our method to perform FER.

Acknowledgements

This work was in part supported by the National Natural Science Foundation of China under Grants 62071404 and 61872307, by the Natural Science Foundation of Fujian Province under Grant 2020J01001, by the Youth Innovation Foundation of Xiamen City under Grant 3502Z20206046, and by the Beijing Science and Technology Project under Grant Z181100008918018.

References

[1] Dinesh Acharya, Zhiwu Huang, Danda Pani Paudel, and Luc Van Gool. Covariance pooling for facial expression recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops*, pages 367–374, 2018.

[2] Joan Bruna, Wojciech Zaremba, Arthur Szlam, and Yann LeCun. Spectral networks and locally connected networks on graphs. *arXiv preprint arXiv:1312.6203*, 2013.

[3] Jie Cai, Zibo Meng, Ahmed Shehab Khan, Zhiyuan Li, James O'Reilly, and Yan Tong. Island loss for learning discriminative features in facial expression recognition. In *Proceeding of IEEE International Conference on Automatic Face & Gesture Recognition*, pages 302–309, 2018.

[4] Charles Darwin and Phillip Prodger. *The expression of the emotions in man and animals*. Oxford University Press, USA, 1998.

[5] Hong-Bo Deng, Lian-Wen Jin, Li-Xin Zhen, Jian-Cheng Huang, et al. A new facial expression recognition method based on local gabor filter bank and PCA plus LDA. *International Journal of Information Technology*, 11(11):86–96, 2005.

[6] Abhinav Dhall, Roland Goecke, Simon Lucey, and Tom Gedeon. Static facial expression analysis in tough conditions: Data, evaluation protocol and benchmark. In *Proceeding of IEEE International Conference on Computer Vision Workshops*, pages 2106–2112, 2011.

[7] Abhinav Dhall, Roland Goecke, Simon Lucey, and Tom Gedeon. Collecting large, richly annotated facial-expression databases from movies. *IEEE Multimedia*, (3):34–41, 2012.

[8] Hui Ding, Shaohua Kevin Zhou, and Rama Chellappa. FaceNet2ExpNet: Regularizing a deep face recognition net for expression recognition. In *Proceeding of IEEE International Conference on Automatic Face & Gesture Recognition*, pages 118–126, 2017.

[9] Paul Ekman and Wallace V Friesen. Constants across cultures in the face and emotion. *Journal of Personality and Social Psychology*, 17(2):124, 1971.

[10] Yandong Guo, Lei Zhang, Yuxiao Hu, Xiaodong He, and Jianfeng Gao. Ms-celeb-1m: A dataset and benchmark for large-scale face recognition. In *Proceedings of the European Conference on Computer Vision*, pages 87–102, 2016.

[11] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778, 2016.

[12] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.

[13] Shan Li and Weihong Deng. Reliable crowdsourcing and deep locality-preserving learning for unconstrained facial expression recognition. *IEEE Transactions on Image Processing*, 28(1):356–370, 2018.

[14] Patrick Lucey, Jeffrey F Cohn, Takeo Kanade, Jason Saragih, Zara Ambadar, and Iain Matthews. The Extended Cohn-Kanade Dataset (CK+): A complete dataset for action unit and emotion-specified expression. In *2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops*, pages 94–101, 2010.

[15] Yuan Luo, Cai-ming Wu, and Yi Zhang. Facial expression recognition based on fusion feature of PCA and LBP with SVM. *Optik-International Journal for Light and Electron Optics*, 124(17):2767–2770, 2013.

[16] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of Machine Learning Research*, 9(Nov):2579–2605, 2008.

[17] Zibo Meng, Ping Liu, Jie Cai, Shizhong Han, and Yan Tong. Identity-aware convolutional neural network for facial expression recognition. In *Proceeding of IEEE International Conference on Automatic Face & Gesture Recognition)*, pages 558–565, 2017.

[18] Mohammad Reza Mohammadi, Emad Fatemizadeh, and Mohammad H Mahoor. PCA-based dictionary building for accurate facial expression recognition via sparse representation. *Journal of Visual Communication and Image Representation*, 25(5):1082–1092, 2014.

[19] Maja Pantic, Michel Valstar, Ron Rademaker, and Ludo Maat. Web-based database for facial expression analysis. In *2005 IEEE International Conference on Multimedia and Expo*, pages 5–15, 2005.

[20] Delian Ruan, Yan Yan, Si Chen, Jing-Hao Xue, and Hanzi Wang. Deep disturbance-disentangled learning for facial expression recognition. In *Proceedings of the 28th ACM International Conference on Multimedia*, pages 2833–2841, 2020.

[21] Yantao Shen, Hongsheng Li, Shuai Yi, Dapeng Chen, and Xiaogang Wang. Person re-identification with deep similarity-guided graph neural network. In *Proceedings of the European Conference on Computer Vision*, pages 486–504, 2018.

[22] Can Wang, Shangfei Wang, and Guang Liang. Identity-and pose-robust facial expression recognition through adversarial feature learning. In *Proceedings of the 27th ACM International Conference on Multimedia*, pages 238–246, 2019.

[23] Kai Wang, Xiaojiang Peng, Jianfei Yang, Shijian Lu, and Yu Qiao. Suppressing uncertainties for large-scale facial expression recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 6897–6906, 2020.

[24] Kai Wang, Xiaojiang Peng, Jianfei Yang, Debin Meng, and Yu Qiao. Region attention networks for pose and occlusion robust facial expression recognition. *IEEE Transactions on Image Processing*, 29:4057–4069, 2020.

[25] Yandong Wen, Kaipeng Zhang, Zhifeng Li, and Yu Qiao. A discriminative feature learning approach for deep face recognition. In *Proceedings of the European Conference on Computer Vision*, pages 499–515, 2016.

[26] Siyue Xie, Haifeng Hu, and Yongbo Wu. Deep multi-path convolutional neural network joint with salient region attention for facial expression recognition. *Pattern Recognition*, 92:177–191, 2019.

[27] Huiyuan Yang, Umur Ciftci, and Lijun Yin. Facial expression recognition by de-expression residue learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 2168–2177, 2018.

[28] Jiabei Zeng, Shiguang Shan, and Xilin Chen. Facial expression recognition with inconsistently annotated datasets. In *Proceedings of the European Conference on Computer Vision*, pages 222–237, 2018.

[29] Feifei Zhang, Tianzhu Zhang, Qirong Mao, and Changsheng Xu. Joint pose and expression modeling for facial expression recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3359–3368, 2018.

[30] Guoying Zhao, Xiaohua Huang, Matti Taini, Stan Z Li, and Matti PietikäInen. Facial expression recognition from near-infrared videos. *Image and Vision Computing*, 29(9):607–619, 2011.

[31] Lihong Zhao, Guibin Zhuang, and Xinhe Xu. Facial expression recognition based on PCA and NMF. In *2008 7th World Congress on Intelligent Control and Automation*, pages 6826–6829, 2008.

[32] Xiangyun Zhao, Xiaodan Liang, Luoqi Liu, Teng Li, Yugang Han, Nuno Vasconcelos, and Shuicheng Yan. Peak-piloted deep network for facial expression recognition. In *Proceedings of the European Conference on Computer Vision*, pages 425–442, 2016.

Rethinking BiSeNet For Real-time Semantic Segmentation

Mingyuan Fan*, Shenqi Lai*, Junshi Huang†, Xiaoming Wei†, Zhenhua Chai,
Junfeng Luo, Xiaolin Wei
Meituan
{fanmingyuan, laishenqi, huangjunshi, weixiaoming, chaizhenhua,
luojunfeng, weixiaolin02}@meituan.com

Abstract

*BiSeNet [28, 27] has been proved to be a popular two-stream network for real-time segmentation. However, its principle of adding an extra path to encode spatial information is time-consuming, and the backbones borrowed from pretrained tasks, e.g., image classification, may be inefficient for image segmentation due to the deficiency of task-specific design. To handle these problems, we propose a novel and efficient structure named Short-Term Dense Concatenate network (STDC network) by removing structure redundancy. Specifically, we gradually reduce the dimension of feature maps and use the aggregation of them for image representation, which forms the basic module of STDC network. In the decoder, we propose a Detail Aggregation module by integrating the learning of spatial information into low-level layers in single-stream manner. Finally, the low-level features and deep features are fused to predict the final segmentation results. Extensive experiments on Cityscapes and CamVid dataset demonstrate the effectiveness of our method by achieving promising trade-off between segmentation accuracy and inference speed. On Cityscapes, we achieve 71.9% mIoU on the test set with a speed of **250.4 FPS** on NVIDIA GTX 1080Ti, which is **45.2% faster** than the latest methods, and achieve **76.8% mIoU** with 97.0 FPS while inferring on higher resolution images. Code is available at https://github.com/MichaelFan01/STDC-Seg.*

1. Introduction

Semantic segmentation is a classic and fundamental topic in computer vision, which aims to assign pixel-level labels in images. The prosperity of deep learning greatly promotes the performance of semantic segmentation by making various breakthroughs [18, 27, 22, 4], coming with fast-growing demands in many applications, *e.g.*, autonomous driving, video surveillance, robot sensing, and so on. These applications motivate researchers to explore effective and efficient segmentation networks, particularly for mobile field.

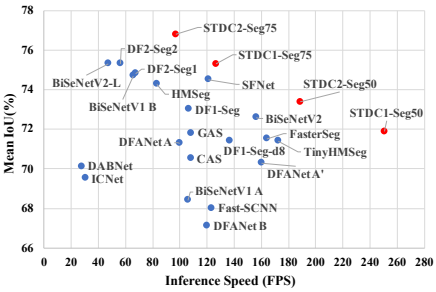

Figure 1. Speed-Accuracy performance comparison on the Cityscapes *test* set. Our methods are presented in red dots while other methods are presented in blue dots. Our approaches achieve state-of-the-art speed-accuracy trade-off.

To fulfill those demands, many researchers propose to design low-latency, high-efficiency CNN models with satisfactory segmentation accuracy. These real-time semantic segmentation methods have achieved promising performance on various benchmarks. For real-time inference, some works, *e.g.*, DFANet [18] and BiSeNetV1 [28] choose the lightweight backbones and investigate ways of feature fusion or aggregation modules to compensate for the drop of accuracy. However, these lightweight backbones borrowed from image classification task may not be perfect for image segmentation problem due to the deficiency of task-specific design. Besides the choice of lightweight backbones, restricting the input image size is another commonly used method to promote the inference speed. Smaller input resolution seems to be effective, but it can easily neglect the detailed appearance around boundaries and small objects. To tackle this problem, as shown in Figure 2(a), BiSeNet [28, 27] adopt multi-path framework to combine the low-level details and high-level semantics. However,

*Equal contribution.
†Co-corresponding author.

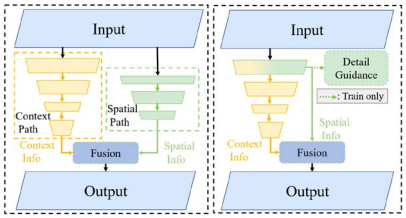

(a) BiSeNet (b) Ours

Figure 2. Illustration of architectures of BiSeNet [28] and our proposed approach. (a) presents Bilateral Segmentation Network (BiSeNet [28]), which use an extra *Spatial Path* to encode spatial information. (b) demonstrates our proposed method, which use a *Detail Guidance* module to encode spatial information in the low-level features without an extra time-cosuming path.

adding an additional path to get low-level features is time-consuming, and the auxiliary path is always lack of low-level information guidance.

To this end, we propose a novel hand-craft network for the purpose of faster inference speed, explainable structure, and competitive performance to that of existing methods. First, we design a novel structure, called Short-Term Dense Concatenate module (STDC module), to get variant scalable receptive fields with a few parameters. Then, the STDC modules are seamlessly integrated into U-net architecture to form the STDC network, which greatly promote network performance in semantic segmentation task.

In details, as shown in Figure 3, we concatenate response maps from multiple continuous layers, each of which encodes input image/feature in different scales and respective fields, leading to multi-scale feature representation. To speed up, the filter size of layers is gradually reduced with negligible loss in segmentation performance. The details structure of STDC networks can be found in Table 2.

In the phase of decoding, as shown in Figure 2(b), instead of utilizing an extra time-consuming path, Detail Guidance are adopted to guide the low-level layers for the learning of spatial details. We first utilize Detail Aggregation module to generate detail ground-truth. Then, the binary cross-entropy loss and dice loss are employed to optimize the learning task of detail information, which is considered as one type of side-information learning. It should be noted that this side-information is not required in the inference time. Finally, the spatial details from low-level layers and semantic information from deep layers are fused to predict the semantic segmentation results. The whole architecture of our method is shown in Figure 4.

Our main contributions can be summarized as follows:

- We design a Short-Term Dense Concatenate module (STDC module) to extract deep features with scalable receptive field and multi-scale information. This module promotes the performance of our STDC network with affordable computational cost.
- We propose the Detail Aggregation module to learn the decoder, leading to more precise preservation of spatial details in low-level layers without extra computation cost in the inference time.
- We conduct extensive experiments to present the effectiveness of our methods. The experiment results present that STDC networks achieve new state-of-the-art results on ImageNet, Cityscapes and CamVid. Specifically, our STDC1-Seg50 achieves 71.9% mIoU on the Cityscapes *test* set at a speed of **250.4 FPS** on one NVIDIA GTX 1080Ti card. Under the same experiment setting, our STDC2-Seg75 achieves **76.8% mIoU** at a speed of 97.0 FPS.

2. Related Work

2.1. Efficient Network Designs

Model design plays an important role in computer vision tasks. SqueezeNet [16] used the fire module and certain strategies to reduce the model parameters. MobileNet V1 [13] utilized depth-wise separable convolution to reduce the FLOPs in inference phase. ResNet [9] [10] adopted residual building layers to achieve outstanding performance. MobileNet V2 [25] and ShuffleNet [29] used group convolution to reduce computation cost while maintaining comparable accuracy. These works are particularly designed for the image classification tasks, and their extensions to semantic segmentation application should be carefully tuned.

2.2. Generic Semantic Segmentation

Traditional segmentation algorithms, *e.g.*, threshold selection, super-pixel, utilized the hand-crafted features to assign pixel-level labels in images. With the development of convolution neural network, methods [3, 1, 32, 14] based on FCN [23] achieved impressive performance on various benchmarks. The Deeplabv3 [3] adopted an atrous spatial pyramid pooling module to capture multi-scale context. The SegNet [1] utilized the encoder-decoder structure to recover the high-resolution feature maps. The PSPNet [32] devised a pyramid pooling to capture both local and global context information on the dilation backbone. Both dilation backbone and encoder-decoder structure can simultaneously learn the low-level details and high-level semantics. However, most approaches require large computation cost due to the high-resolution feature and the complicate network connections. In this paper, we propose an efficient and effective architecture which achieves good trade-off between speed and accuracy.

2.3. Real-time Semantic Segmentation

Recently, there are fast-growing practical applications for real-time semantic segmentation. In this circumstance,

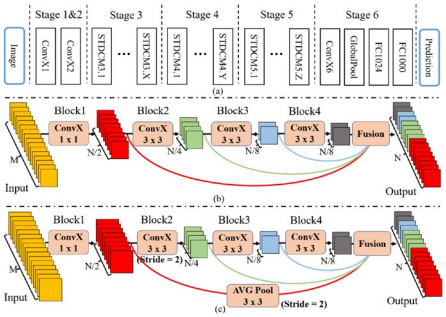

Figure 3. (a) General STDC network architecture. *ConvX* operation refers to the Conv-BN-ReLU. (b) Short-Term Dense Concatenate module (STDC module) used in our network. *M* denotes the dimension of input channels, *N* denotes the dimension of output channels. Each block is a *ConvX* operation with different kernel size. (c) STDC module with stride=2.

there are two mainstreams to devise efficient segmentation methods. (i) *lightweight backbone.* DFANet [18] adopted a lightweight backbone to reduce computation cost and devised a cross-level feature aggregation module to enhance performance. DFNet [21] utilized "Partial Order Pruning" algorithm to obtain a lightweight backbone and efficient decoder. (ii) *multi-branch architecture.* ICNet [31] devised the multi-scale image cascade to achieve good speed-accuracy trade-off. BiSeNetV1 [28] and BiSeNetV2 [27] proposed two-stream paths for low-level details and high-level context information, separately. In this paper, we propose an efficient lightweight backbone to provide scalable receptive field. Furthermore, we set a single path decoder which uses detail information guidance to learn the low-level details.

3. Proposed Method

BiSeNetV1 [28] utilizes lightweight backbones, *e.g.*, ResNet18 and spatial path as encoding networks to form two-steam segmentation architecture. However, the classification backbones and two-stream architecture may be inefficient due to the structure redundancy. In this section, we first introduce the details of our proposed STDC network. Then we present the whole arhitecture of our single-stream method with detail guidance.

3.1. Design of Encoding Network

3.1.1 Short-Term Dense Concatenate Module

The key component of our proposed network is the Short-Term Dense Concatenate module (STDC module). Figure 3(b) and (c) illustrate the layout of STDC module. Specifically, each module is separated into several blocks,

STDC module	Block1	Block2	Block3	Block4	Fusion
RF(S = 1)	1×1	3×3	5×5	7×7	$1 \times 1, 3 \times 3$ $5 \times 5, 7 \times 7$
RF(S = 2)	1×1	3×3	7×7	11×11	3×3 $7 \times 7, 11 \times 11$

Table 1. Receptive Field of blocks in our STDC module. *RF* denotes Receptive Field, *S* means stride, Note that if stride=2, the 1×1 *RF* of Block1 is turned into 3×3 *RF* by Average Pool operation.

and we use $ConvX_i$ to denote the operations of i-th block. Therefore, the output of i-th block is calculated as follows:

$$x_i = ConvX_i(x_{i-1}, k_i) \tag{1}$$

where x_{i-1} and x_i are the input and output of i-th block, separately. ConvX includes one convolutional layer, one batch normalization layer and ReLU activation layer, and k_i is the kernel size of convolutional layer.

In STDC module, the kernel size of first block is 1, and the rest of them are simply set as 3. Given the channel number of STDC module's output N, the filter number of convolutional layer in i-th block is $N/2^i$, except the filters of last convolutional layer, whose number is the same to that of previous convolutional layer. In image classification tasks, its a common practice to using more channels in higher layers. But in semantic segmentation tasks, we focus on scalable receptive field and multi-scale informations. Low-level layers need enough channels to encode more fine-grained informations with small receptive field, while high-level layers with large receptive field focus more on high-level information induction, setting the same channel with low-level layers may cause information redundancy. Down-sample is only happened in Block2. To enrich the feature information, we concatenate x_1 to x_n feature maps as the output of STDC module by skip-path. Before concatenation, the response maps of different blocks in STDC module is down-sampled to the same spatial size by average pooling operation with 3×3 pooling size, as shown in Figure 3(c). In our setting, the final output of STDC module is:

$$x_{output} = F(x_1, x_2, ..., x_n) \tag{2}$$

where x_{output} denotes the STDC module output, F is the fusion operation in our method, while $x_1, x_2, ..., x_n$ are feature maps from all n blocks. In the consideration of efficiency, we adopt concatenation as our fusion operation. In our method, we use the STDC module in 4 blocks.

Table 1 presents the receptive field of blocks in STDC module, and x_{output} thus gathers multi-scale information from all blocks, We claim that our STDC module has two advantages: (1) we elaborately tune the filter size of blocks by gradually decreasing in geometric progression manner, leading to significant reduction in computation complexity. (2) the final output of STDC module is concatenated from

Stages	Output size	KSize	S	STDC1		STDC2	
				R	C	R	C
Image	224×224				3		3
ConvX1	112×112	3×3	2	1	32	1	32
ConvX2	56×56	3×3	2	1	64	1	64
Stage3	28×28 28×28		2 1	1 1	256	1 3	256
Stage4	14×14 14×14		2 1	1 1	512	1 4	512
Stage5	7×7 7×7		2 1	1 1	1024	1 2	1024
ConvX6	7×7	1×1	1	1	1024	1	1024
GlobalPool	1×1	7×7					
FC1					1024		1024
FC2					1000		1000
FLOPs				813M		1446M	
Params				8.44M		12.47M	

Table 2. Detailed architecture of STDC networks. Note that *ConvX* shown in the table refers to the Conv-BN-ReLU. The basic module of Stage 3, 4 and 5 is STDC module. KSize mean kernel size. S, R, C denote stride, repeat times and output channels respectively.

all blocks, which preserves scalable respective fields and multi-scale information.

Given the input channel dimension M and output channel dimension N, the parameter number of STDC module is:

$$\begin{aligned} S_{param} &= M \times 1 \times 1 \times \frac{N}{2^1} + \sum_{i=2}^{n-1} \frac{N}{2^{i-1}} \times 3 \times 3 \times \frac{N}{2^i} + \\ &\quad \frac{N}{2^{n-1}} \times 3 \times 3 \times \frac{N}{2^{n-1}} \\ &= \frac{NM}{2} + \frac{9N^2}{2^3} \times \sum_{i=0}^{n-3} \frac{1}{2^{2i}} + \frac{9N^2}{2^{2n-2}} \\ &= \frac{NM}{2} + \frac{3N^2}{2} \times (1 + \frac{1}{2^{2n-3}}) \end{aligned} \tag{3}$$

As shown in Equation 3, the parameter number of STDC module is dominated by the predefined input and output channel dimension, while the number of blocks has slight impact on the parameter size. Particularly, if n reaches the maximum limit, the parameter number of STDC module almost keeps constant, which is only defined by M and N.

3.1.2 Network Architecture

We demonstrate our network architecture in Figure 3(a). It consists of 6 stages except input layer and prediction layer. Generally, Stage 1∼5 down-sample the spatial resolution of the input with a stride of 2, respectively, and the Stage 6 outputs the prediction logits by one ConvX, one global average pooling layer and two fully connected layer.

The Stage 1&2 are usually regarded as low-level layers for appearance feature extraction. In pursuit of efficiency, we only use one convolutional block in each of Stage 1&2, which is proved to be sufficient according to our experiences. The number of STDC module in Stage 3, 4, 5 is carefully tuned in our network. Within those stages, the first STDC module in each stage down-samples the spatial resolution with a stride of 2. The following STDC modules in each stage keep the spatial resolution unchanged.

We denote the output channel number of stage as N_l, where l is the index of stage. In practice, we empirically set N_6 as 1024, and carefully tune the channel number of rest stages, until reaching a good trade-off between accuracy and efficiency. Since our network mainly consists of Short-Term Dense Concatenate modules, we call our network STDC network. Table 2 shows the detailed structure of our STDC networks.

3.2. Design of Decoder

3.2.1 Segmentation Architecture

We use the pretrained STDC networks as the backbone of our encoder and adopt the context path of BiSeNet [28] to encode the context information. As shown in Figure 4(a), we use the Stage 3, 4, 5 to produce the feature maps with down-sample ratio 1/8, 1/16, 1/32, respectively. Then we use global average pooling to provide global context information with large receptive field. The U-shape structure are deployed to up-sample the features stem from global feature, and combine each of them with the counterparts from last two stages (Stage 4&5) in our encoding phase. Following BiSeNet [28], we use *Attention Refine module* to refine the combination features of every two stages. For the final semantic segmentation prediction, we adopt *Feature Fusion module* in BiSeNet [28] to fuse the 1/8 down-sampled feature from Stage 3 in the encoder and the counterpart from the decoder. We claim that the features of these two stages are in different levels of feature representation. The feature from the encoding backbone preserves rich detail information, while the feature from the decoder contains context information due to the input from global pooling layer. Specifically, the *Seg Head* includes a 3×3 Conv-BN-ReLU operator followed with a 1×1 convolution to get the output dimension N, which is set as the number of classes. We adopt cross-entry loss with Online Hard Example Mining to optimize the semantic segmentation learning task.

3.2.2 Detail Guidance of Low-level Features

We visualize the features of BiSeNet's spatial path in Figure 5(b). Compared with the backbone's low-level layers(Stage 3) of same downsample ratio, spatial path can encode more spatial detail, *e.g.*, boundary, corners. Based on this observation, we propose a Detail Guidance module to guide the low-level layers to learn the spatial information in single-stream manner. We model the detail prediction

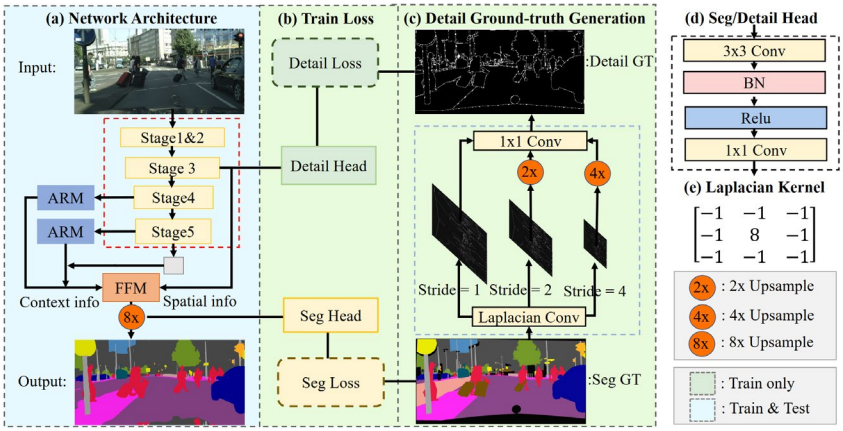

Figure 4. Overview of the STDC Segmentation network. *ARM* denotes *Attention Refine module*, and *FFM* denotes *Feature Fusion Module* in [28]. The operation in the dashed red box is our STDC network. The operation in the dashed blue box is *Detail Aggregation Module*.

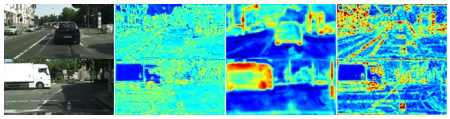

(a) Input (b) Spatial Path (c) Stage3 (d) $\text{Stage3}_{\mathbf{D}}$

Figure 5. Visual explanations for features in the spatial path and Stage 3 without and with *Detail Guidance*. The column with subscript **D** denotes results with *Detail Guidance*. The visualization shows that spatial path can encode more spatial detail,*e.g.*, boundary, corners, than backbone's low-level layers, while our *Detail Guidance* module can do the same thing without extra computation cost.

as a binary segmentation task. We first generate the detail map ground-truth from the segmentation ground-truth by Laplacian operator as shown in Figure 4 (c). As illustrated in Figure 4(a), we insert the *Detail Head* in Stage 3 to generate the detail feature map. Then we use the detail ground-truth as the guidance of detail feature map to guide the low-level layers to learn the feature of spatial details. As shown in Figure 5(d), the feature map with detail guidance can encode more spatial details than aforementioned result presented in Figure 5(c). Finally, the learned detail features are fused with the context features from the deep block of the decoder for segmentation prediction.

Detail Ground-truth Generation: We generate the binary detail ground-truth from the semantic segmentation ground-truth by our Detail Aggregation module, as shown in dashed blue box of Figure 4(c). This operation can be carried out by 2-D convolution kernel named Laplacian kernel and a trainable 1×1 convolution. We use the Laplacian operator shown in Figure 4(e) to produce soft thin detail feature maps with different strides to obtain mult-scale detail informations. Then we upsample the detail feature maps to the original size and fuse it with a trainable 1×1 convolution for dynamic re-wegihting. Finally, we adopt a threshold 0.1 to convert the predicted details to the final binary detail ground-truth with boundary and corner informations.

Detail Loss: Since the number of detail pixels is much less than the non-detail pixels, detail prediction is a class-imbalance problem. Because weighted cross-entropy always leads to coarse results, following [7], we adopt binary cross-entropy and dice loss to jointly optimize the detail learning. Dice loss measures the overlap between predict maps and ground-truth. Also, it is insensitive to the number of foreground/background pixels, which means it can alleviating the class-imbalance problem. So for the predicted detail map with the height H and the width W, the detail loss L_{detail} is formulated as follows:

$$L_{detail}(p_d, g_d) = L_{dice}(p_d, g_d) + L_{bce}(p_d, g_d) \quad (4)$$

where $p_d \in \mathbb{R}^{H \times W}$ denotes the predicted detail and $g_d \in \mathbb{R}^{H \times W}$ denotes the corresponding detail ground-truth. L_{bce} denotes the binary cross-entropy loss while L_{dice} denotes the dice loss, which is given as follows:

$$L_{dice}(p_d, g_d) = 1 - \frac{2\sum_i^{H \times W} p_d^i g_d^i + \epsilon}{\sum_i^{H \times W} (p_d^i)^2 + \sum_i^{H \times W} (g_d^i)^2 + \epsilon} \quad (5)$$

where i denotes the i-th pixel and ϵ is a Laplace smoothing item to avoid zero division. In this paper we set $\epsilon = 1$.

As shown in Figure 4(b), we use a *Detail Head* to produce the detail map, which guide the shallow layer to encode spatial information. *Detail Head* includes a 3×3

Conv-BN-ReLU operator followed with a 1×1 convolution to get the output detail map. In the experiment, the *Detail Head* is proved to be effective to enhance the feature representation. Note that this branch is discarded in the inference phase. Therefore, this side-information can easily boost the accuracy of segmentation task without any cost in inference.

4. Experimental Results

We implement our method on three datasets: ImageNet [6], Cityscapes [5] and CamVid [2] to evaluate the effectiveness of our proposed backbone and segmentation network, respectively. We first introduce the datasets and implementation details. Then, we report our accuracy and speed results on different benchmarks compared with other algorithms. Finally, we discuss the impact of components in our proposed approach.

4.1. Benchmarks and Evaluation Metrics

ImageNet. The ILSVRC [6] 2012 is the most popular image classification dataset. It contains 1.2 million images for training, and 50,000 for validation with 1,000 categories. It is also widely used for training a pretrained model for downstream tasks, like object detection or semantic segmentation.

Cityscapes. Cityscapes [5] is a semantic scene parsing dataset, which is taken from a car perspective. It contains 5,000 fine annotated images and split into training, validation and test sets, with 2,975, 500 and 1,525 images respectively. The annotation includes 30 classes, 19 of which are used for semantic segmentation task. The images have a high resolution of $2,048 \times 1,024$, thus it is challenging for the real-time semantic segmentation. For fair comparison, we only use the fine annotated images in our experiments.

CamVid. Cambridge-driving Labeled Video Database (Camvid) [2] is a road scene dataset, which is taken from a driving automobile perspective. This dataset contains 701 annotated images extracted from the video sequence, in which 367 for training, 101 for validation and 233 for testing. The images have a resolution of 960×720 and 32 semantic categories, in which the subset of 11 classes are used for segmentation experiments.

Evaluation Metrics. For classification evaluation, we use evaluate top-1 accuracy as the evaluation metrics following [9]. For segmentation evaluation, we adopt mean of class-wise intersection over union (mIoU) and Frames Per Second (FPS) as the evaluation metrics.

4.2. Implementation Details

Image Classification. We use mini-batch stochastic gradient descent (SGD) with batch size 64, momentum 0.9 and weight decay $1e^{-4}$ to train the model. Three training methods from [11] are adopted, including learning rate warmup, cosine learning rate policy and label smoothing. The total epochs is 300 with warmup strategy at the first 5 epochs, within which the learning rate starts from 0.001 to 0.1. The dropout before classification block is set to 0.2. We do not use other special data augmentations, and all of them are the same as [9].

Backbone	Resolution	mIoU(%)	FPS
GhostNet [8]	512×1024	67.8	135.0
MobileNetV3 [12]	512×1024	70.1	148.3
EfficientNet-B0 [26]	512×1024	72.2	99.9
STDC2	512×1024	**74.2**	**188.6**
GhostNet [8]	768×1536	71.3	60.9
MobileNetV3 [12]	768×1536	73.0	70.4
EfficientNet-B0 [26]	768×1536	73.9	45.9
STDC2	768×1536	**77.0**	**97.0**

Table 3. Lightweight backbone comparison on Cityscapes *val* set. All experients utilize the same decoder and same experiment settings.

Semantic Segmentation. We use mini-batch stochastic gradient descent (SGD) with momentum 0.9, weight decay $5e^{-4}$. The batch size is set as 48, 24 for the Cityscapes, CamVid dataset respectively. As common configuration, we utilize "poly" learning rate policy in which the initial rate is multiplied by $(1 - \frac{iter}{max_iter})^{power}$. The power is set to 0.9 and the initial learning rate is set as 0.01. Besides, we train the model for $60,000$, $10,000$ iterations for the Cityscapes, CamVid dataset respectively, in which we adopt warmup strategy at the first 1000, 200 iterations.

Data augmentation contains color jittering, random horizontal flip, random crop and random resize. The scale ranges in [0.125, 1.5] and cropped resolution is 1024×512 for training Cityscapes. For training CamVid, the scale ranges in [0.5, 2.5] and cropped resolution is 960×720.

In all experiments, we conduct our experiments base on pytorch-1.1 on a docker. We perform all experiments under CUDA 10.0, CUDNN 7.6.4 and TensorRT 5.0.1.5 on NVIDIA GTX 1080Ti GPU with batch size 1 for benchmarking the computing power of our method.

4.3. Ablation Study

This section introduces the ablation experiments to validate the effectiveness of each component in our method.

Effectiveness of STDC Module. We adjust the block number of STDC module in STDC2 and present the result in Figure 7. According to our Equation 3, as the group number increases, the FLOPs decrease obviously. And the best performance is in 4 blocks. The benefits of more blocks become very small and a deeper network is bad for the parallel calculation and FPS. Hence, in this paper, we set the block number in STDC1 and STDC2 to 4.

Effectiveness of Our backbone. To verify the effectiveness of our backbone designed for real-time segmentation, we adopt the latest lightweight backbones which has com-

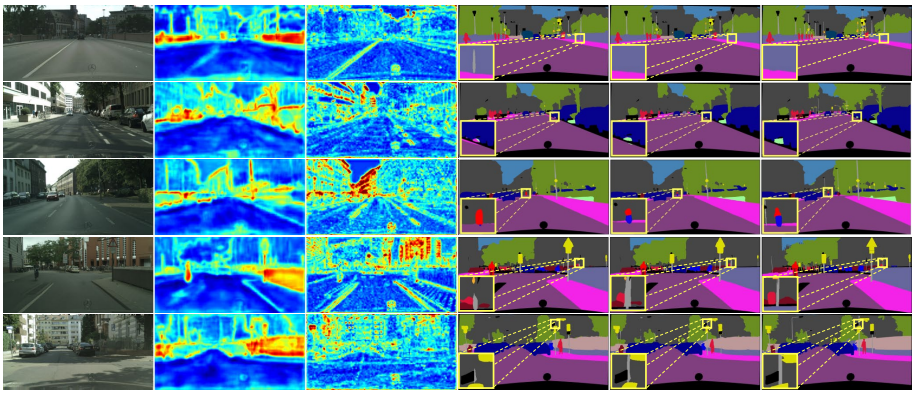

(a) Input (b) Stage3 (c) Stage3$_D$ (d) Prediction (e) Prediction$_D$ (f) Groundtruth

Figure 6. Visual comparison of our *Detail Guidance* on Cityscapes *val* set. The column with subscript **D** denotes results with *Detail Guidance*. The first row (a) shows the input images. (b) and (c) illustrate the heatmap of Stage 3 without and with *Detail Guidance*. (d) and (e) demonstrate the predictions without and with *Detail Guidance*. (f) is the ground-truth of input images.

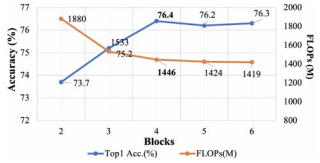

Figure 7. Comparisons with different block number of STDC2 on ImageNet.

Method	SP	DG			mIoU(%)	FPS
		4x	2x	1x		
BiSeNetV1 [28]	✓				69.0	105.8
STDC2-50	✓				73.7	171.6
STDC2-50					73.0	188.6
STDC2-50		✓			73.4	188.6
STDC2-50			✓		73.6	188.6
STDC2-50				✓	73.8	188.6
STDC2-50			✓	✓	73.9	188.6
STDC2-50		✓	✓	✓	**74.2**	188.6

Table 4. Detail information comparison on Cityscapes *val* set. *SP* means method with *Spatial Path* and *DG* indicates *Detail Guidance*, inwhich *1x, 2x, 4x* denotes detail features with different down-sample strides in *Detail Aggregation* module.

parable classification performance compared with STDC2 to formulate a semantic segmentation network with our decoder. As show in Table. 3, our STDC2 yield the best speed-accuracy trade-off comapred with other lightweight backbones.

Effectiveness of Detail Guidance. We first visualize the heatmap of the feature map of Stage 3 as shown in Figure 6. The features of Stage 3 with detail guidance encode more spatial information comparing to that of Stage 3 without detail guidance. Hence the final prediction of small objects and boundaries are more precise. We show some quantitative results in Table 4. To verify the effectiveness of our Detail Guidance, we show the comparison of different detail guidance strategies of STDC2-Seg on Cityscapes *val* dataset. To further demonstrate the capability of Detail Guidance, we first use the Spatial Path in BiSeNetV1 [28] to encode the spatial information, then use the features generated from the Spatial Path to replace the features from Stage 3_D. The setting of experiment with Spatial Path are exactly the same with other experiments. As shown in Table 4, Detail Guidance in STDC2-Seg can improve the mIoU without harming the inference speed. Adding Spatial Path to encode spatial information can also improve the performance on accuracy, but it increases the computation cost at the same time. Also we find our Detail Aggregation module encode the abundant detail information and yield the highest mIoU with aggregation of *1x, 2x, 4x* detail features.

4.4. Compare with State-of-the-arts

In this part, we compare our methods with other existing state-of-the-art methods on three benchmarks, ImageNet, Cityscapes and CamVid.

Results on ImageNet. As shown in Table 5, our STDC networks achieves higher speed and accuracy compared with other lightweight backbones. Compared with the lightweight backbones used in real-time segmentation, *e.g.*, DF1Net, the top-1 classification accuracy of our STDC1 network is 4.1% higher than baseline on the ImageNet *validation* set. Compared with populuar lightweight networks,

Model	Top1 Acc.	Params	FLOPs	FPS
ResNet-18 [9]	69.0%	11.2M	1800M	1058.7
ResNet-50 [9]	75.3%	23.5M	3800M	378.7
DF1 [21]	69.8%	8.0M	746M	1281.3
DF2 [21]	73.9%	17.5M	1770M	713.2
DenseNet121 [15]	75.0%	9.9M	2882M	363.6
DenseNet161 [15]	76.2%	28.6M	7818M	255.0
GhostNet(x1.0) [8]	73.9%	5.2M	141M	699.1
GhostNet(x1.3) [8]	75.7%	7.3M	226M	566.2
MobileNetV2 [25]	72.0%	3.4M	300M	998.8
MobileNetV3 [12]	75.2%	5.4M	219M	661.2
EfficientNet-B0 [26]	76.3%	5.3M	390M	443.0
STDC1	73.9%	8.4M	813M	**1289.0**
STDC2	**76.4%**	12.5M	1446M	813.6

Table 5. Comparisons with other popular networks on ImageNet Classification.

Model	Resolution	Backbone	mIoU(%)		FPS
			val	test	
ENet [24]	512 × 1024	no	-	58.3	76.9
ICNet [31]	1024 × 2048	PSPNet50	-	69.5	30.3
DABNet [17]	1024 × 2048	no	-	70.1	27.7
DFANet B [18]	1024 × 1024	Xception B	-	67.1	120
DFANet A' [18]	512 × 1024	Xception A	-	70.3	160
DFANet A [18]	1024 × 1024	Xception A	-	71.3	100
BiSeNetV1 [28]	768 × 1536	Xception39	69.0	68.4	105.8
BiSeNetV1 [28]	768 × 1536	ResNet18	74.8	74.7	65.5
CAS [30]	768 × 1536	no	-	70.5	108.0
GAS [22]	769 × 1537	no	-	71.8	108.4
DF1-Seg-d8 [21]	1024 × 2048	DF1	72.4	71.4	136.9
DF1-Seg[21]	1024 × 2048	DF1	74.1	73.0	106.4
DF2-Seg1[21]	1024 × 2048	DF2	75.9	74.8	67.2
DF2-Seg2[21]	1024 × 2048	DF2	76.9	75.3	56.3
SFNet [20]	1024 × 2048	DF1	-	74.5	121
HMSeg [19]	768 × 1536	no	-	74.3	83.2
TinyHMSeg [19]	768 × 1536	no	-	71.4	172.4
BiSeNetV2 [27]	512 × 1024	no	73.4	72.6	156
BiSeNetV2-L [27]	512 × 1024	no	75.8	75.3	47.3
FasterSeg [4]	1024 × 2048	no	73.1	71.5	163.9
STDC1-Seg50	512 × 1024	STDC1	72.2	71.9	**250.4**
STDC2-Seg50	512 × 1024	STDC2	74.2	73.4	188.6
STDC1-Seg75	768 × 1536	STDC1	74.5	75.3	126.7
STDC2-Seg75	768 × 1536	STDC2	**77.0**	**76.8**	97.0

Table 6. Comparisons with other state-of-the-art methods on Cityscapes. *no* indicates the method do not have a backbone.

e.g. EfficientNet-B0, the FPS of STDC2 network is 83.7% higher than that of baseline with competitive classification result.

Results on Cityscapes. As shown in Table 6, we present the segmentation accuracy and inference speed of our proposed method on Cityscapes *validation* and *test* set. Following the previous methods [27, 22], we use the training set and validation set to train our models before submitting to Cityscapes online server. At test phase, we first resize the image into the fixed size 512 × 1024 or 768 × 1536 to inference, then we up-sample the results to 1024 × 2048. Overall, our methods get the best speed-accuracy trade-off among all methods. We use 50 and 75 after the method name to represent the input size 512 × 1024 and 768 × 1536 respectively. For example, with the STDC1 backbone and 512 × 1024 input size, we name the method STDC1-Seg50. As shown in Table 6, our STDC1-Seg50 achieves a significantly faster speed than baselines, *i.e.*, **250.4 FPS**, and still has 71.9% mIoU on *test* set, which is over **45.2%** faster than the runner-up. Our STDC2-Seg50 using 512 × 1024 input size achieves 73.4% mIOU with 188.6 FPS, which is the state-of-the-art trade-off between performance and speed. For 768 × 1536 input size, our STDC2-Seg75 achieves the best mIOU 77.0% in *validation* set and **76.8%** on *test* set at 97.0 FPS.

Model	Resolution	Backbone	mIoU(%)	FPS
ENet [24]	720 × 960	no	51.3	61.2
ICNet [31]	720 × 960	PSPNet50	67.1	34.5
BiSeNetV1 [28]	720 × 960	Xception39	65.6	175
BiSeNetV1 [28]	720 × 960	ResNet18	68.7	116.3
CAS [30]	720 × 960	no	71.2	169
GAS [22]	720 × 960	no	72.8	153.1
BiSeNetV2 [27]	720 × 960	no	72.4	124.5
BiSeNetV2-L [27]	720 × 960	no	73.2	32.7
STDC1-Seg	720 × 960	STDC1	73.0	**197.6**
STDC2-Seg	720 × 960	STDC2	**73.9**	152.2

Table 7. Comparisons with other state-of-the-art methods on CamVid. *no* indicates the method do not have a backbone.

Results on CamVid. We also evaluate our method on CamVid dataset. Table 7 shows the comparison results with other methods. With the input size 720 × 960, STDC1-Seg achieves 73.0% mIoU with 197.6 FPS which is the state-of-the-art trade-off between performance and speed. This further demonstrates the superior capability of our method.

5. Conclusions

In this paper, we revisit the classical segmentation architecture BiSeNet [28, 27] for structure optimization. Generally, the classification backbone and extra spatial path of BiSeNet greatly hinder the inference efficiency. Therefore, we propose a novel Short-Term Dense Concatenate Module to extract deep features with scalable receptive field and multi-scale information. Based on this module, STDC networks are designed and achieve competitive accuracy with high FPS in image classification.Using STDC networks as backbone, our detail-guided STDC-Seg achieves state-of-the-art speed-accuracy trade-off in real-time semantic segmentation. Extensive experiments and visualization results indicates the effectiveness of our proposed STDC-Seg networks. In future, we extend our method by following directions: (i) the backbone will be validated in more tasks, *e.g.*, object detection. (ii) we will explore deeper on the utilization of spatial boundary in semantic segmentation tasks.

Acknowledgements This research is supported by Beijing Science and Technology Project. (No.Z181100008918018).

References

[1] Vijay Badrinarayanan, Alex Kendall, and Roberto Cipolla. Segnet: A deep convolutional encoder-decoder architecture for image segmentation. *IEEE transactions on pattern analysis and machine intelligence*, 39(12):2481–2495, 2017. 2

[2] Gabriel J. Brostow, Jamie Shotton, Julien Fauqueur, and Roberto Cipolla. Segmentation and recognition using structure from motion point clouds. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 44–57, 2008. 6

[3] Liang-Chieh Chen, George Papandreou, Florian Schroff, and Hartwig Adam. Rethinking atrous convolution for semantic image segmentation. *arXiv preprint arXiv:1706.05587*, 2017. 2

[4] Wuyang Chen, Xinyu Gong, Xianming Liu, Qian Zhang, Yuan Li, and Zhangyang Wang. Fasterseg: Searching for faster real-time semantic segmentation. In *International Conference on Learning Representations*, 2020. 1, 8

[5] Marius Cordts, Mohamed Omran, Sebastian Ramos, Timo Rehfeld, Markus Enzweiler, Rodrigo Benenson, Uwe Franke, Stefan Roth, and Bernt Schiele. The cityscapes dataset for semantic urban scene understanding. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3213–3223, 2016. 6

[6] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE conference on computer vision and pattern recognition*, pages 248–255. Ieee, 2009. 6

[7] Ruoxi Deng, Chunhua Shen, Shengjun Liu, Huibing Wang, and Xinru Liu. Learning to predict crisp boundaries. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 562–578, 2018. 5

[8] Kai Han, Yunhe Wang, Qi Tian, Jianyuan Guo, Chunjing Xu, and Chang Xu. Ghostnet: More features from cheap operations. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1580–1589, 2020. 6, 8

[9] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016. 2, 6, 8

[10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Identity mappings in deep residual networks. In *European conference on computer vision*, pages 630–645. Springer, 2016. 2

[11] Tong He, Zhi Zhang, Hang Zhang, Zhongyue Zhang, Junyuan Xie, and Mu Li. Bag of tricks for image classification with convolutional neural networks. In *IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2019, Long Beach, CA, USA, June 16-20, 2019*, pages 558–567, 2019. 6

[12] Andrew Howard, Mark Sandler, Grace Chu, Liang-Chieh Chen, Bo Chen, Mingxing Tan, Weijun Wang, Yukun Zhu, Ruoming Pang, Vijay Vasudevan, et al. Searching for mobilenetv3. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 1314–1324, 2019. 6, 8

[13] Andrew G Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, and Hartwig Adam. Mobilenets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*, 2017. 2

[14] Ping Hu, Fabian Caba, Oliver Wang, Zhe Lin, Stan Sclaroff, and Federico Perazzi. Temporally distributed networks for fast video semantic segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 8818–8827, 2020. 2

[15] Gao Huang, Zhuang Liu, Laurens Van Der Maaten, and Kilian Q Weinberger. Densely connected convolutional networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 4700–4708, 2017. 8

[16] Forrest N Iandola, Song Han, Matthew W Moskewicz, Khalid Ashraf, William J Dally, and Kurt Keutzer. Squeezenet: Alexnet-level accuracy with 50x fewer parameters and <0.5mb model size. *arXiv preprint arXiv:1602.07360*, 2016. 2

[17] Gen Li and Joongkyu Kim. Dabnet: Depth-wise asymmetric bottleneck for real-time semantic segmentation. In *British Machine Vision Conference*, 2019. 8

[18] Hanchao Li, Pengfei Xiong, Haoqiang Fan, and Jian Sun. Dfanet: Deep feature aggregation for real-time semantic segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 9522–9531, 2019. 1, 3, 8

[19] Peike Li, Xuanyi Dong, Xin Yu, and Yi Yang. a. when humans meet machines: Towards efficient segmentation networks. In *Proceedings of the British Machine Vision Conference (BMVC)*, 2020. 8

[20] Xiangtai Li, Ansheng You, Zhen Zhu, Houlong Zhao, Maoke Yang, Kuiyuan Yang, and Yunhai Tong. Semantic flow for fast and accurate scene parsing. *arXiv preprint arXiv:2002.10120*, 2020. 8

[21] Xin Li, Yiming Zhou, Zheng Pan, and Jiashi Feng. Partial order pruning: for best speed/accuracy trade-off in neural architecture search. In *Proceedings of the IEEE Conference on computer vision and pattern recognition*, pages 9145–9153, 2019. 3, 8

[22] Peiwen Lin, Peng Sun, Guangliang Cheng, Sirui Xie, Xi Li, and Jianping Shi. Graph-guided architecture search for real-time semantic segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 4203–4212, 2020. 1, 8

[23] Jonathan Long, Evan Shelhamer, and Trevor Darrell. Fully convolutional networks for semantic segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3431–3440, 2015. 2

[24] Adam Paszke, Abhishek Chaurasia, Sangpil Kim, and Eugenio Culurciello. Enet: A deep neural network architecture for real-time semantic segmentation. *arXiv preprint arXiv:1606.02147*, 2016. 8

[25] Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov, and Liang-Chieh Chen. Mobilenetv2: Inverted residuals and linear bottlenecks. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 4510–4520, 2018. 2, 8

[26] Mingxing Tan and Quoc V Le. Efficientnet: Rethinking model scaling for convolutional neural networks. *arXiv preprint arXiv:1905.11946*, 2019. 6, 8

[27] Changqian Yu, Changxin Gao, Jingbo Wang, Gang Yu, and Nong Sang. Bisenet v2: Bilateral network with guided aggregation for real-time semantic segmentation. *arXiv preprint arXiv:2004.02147*, 2020. 1, 3, 8

[28] Changqian Yu, Jingbo Wang, Chao Peng, Changxin Gao, Gang Yu, and Nong Sang. Bisenet: Bilateral segmentation network for real-time semantic segmentation. In *Proceedings of the European conference on computer vision (ECCV)*, pages 325–341, 2018. 1, 2, 3, 4, 5, 7, 8

[29] Xiangyu Zhang, Xinyu Zhou, Mengxiao Lin, and Jian Sun. Shufflenet: An extremely efficient convolutional neural network for mobile devices. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 6848–6856, 2018. 2

[30] Yiheng Zhang, Zhaofan Qiu, Jingen Liu, Ting Yao, Dong Liu, and Tao Mei. Customizable architecture search for semantic segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 11641–11650, 2019. 8

[31] Hengshuang Zhao, Xiaojuan Qi, Xiaoyong Shen, Jianping Shi, and Jiaya Jia. Icnet for real-time semantic segmentation on high-resolution images. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 405–420, 2018. 3, 8

[32] Hengshuang Zhao, Jianping Shi, Xiaojuan Qi, Xiaogang Wang, and Jiaya Jia. Pyramid scene parsing network. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2881–2890, 2017. 2

Selective Wavelet Attention Learning for Single Image Deraining

Huaibo Huang[1,3,4] · Aijing Yu[1,3,4] · Zhenhua Chai[5] · Ran He[1,2,3,4] · Tieniu Tan[1,2,3,4]

Received: 16 March 2020 / Accepted: 19 December 2020 / Published online: 23 January 2021
© The Author(s), under exclusive licence to Springer Science+Business Media, LLC part of Springer Nature 2021

Abstract
Single image deraining refers to the process of restoring the clean background scene from a rainy image. Current approaches have resorted to deep learning techniques to remove rain from a single image by leveraging some prior information. However, due to the various appearances of rain streaks and accumulation, it is difficult to separate rain and background information in the embedding space, which results in inaccurate deraining. To address this issue, this paper proposes a selective wavelet attention learning method by learning a series of wavelet attention maps to guide the separation of rain and background information in both spatial and frequency domains. The key aspect of our method is utilizing wavelet transform to learn the content and structure of rainy features because the high-frequency features are more sensitive to rain degradations, whereas the low-frequency features preserve more of the background content. To begin with, we develop a selective wavelet attention encoder–decoder network to learn wavelet attention maps guiding the separation of rainy and background features at multiple scales. Meanwhile, we introduce wavelet pooling and unpooling to the encoder–decoder network, which shows superiority in learning increasingly abstract representations while preserving the background details. In addition, we propose latent alignment learning to supervise the background features as well as augment the training data to further improve the accuracy of deraining. Finally, we employ a hierarchical discriminator network based on selective wavelet attention to adversarially improve the visual fidelity of the generated results both globally and locally. Extensive experiments on synthetic and real datasets demonstrate that the proposed approach achieves more appealing results both quantitatively and qualitatively than the recent state-of-the-art methods.

Keywords Deraining · Wavelet transform · Selective attention · Wavelet pooling and unpooling

1 Introduction

Adverse weather conditions, such as rain, snow, and fog, are traditional challenges in real-world outdoor computer vision systems. The accompanying visibility degradations of captured images and videos may result in severe drops in the performance of many applications, such as autonomous cars and video surveillance. Hence, it is important to seek solutions to acquire high-quality images under adverse weather conditions. In this paper, we address the problem of single image deraining, i.e., restoring clean and rain-free background from a single rainy image. This is a widely known ill-posed problem because degraded images suffer from integrated information of rain and the background scene.

Communicated by Dengxin Dai.

✉ Ran He
rhe@nlpr.ia.ac.cn

Huaibo Huang
huaibo.huang@cripac.ia.ac.cn

Aijing Yu
aijing.yu@cripac.ia.ac.cn

Zhenhua Chai
chaizhenhua@meituan.com

Tieniu Tan
tnt@nlpr.ia.ac.cn

[1] National Laboratory of Pattern Recognition, CASIA, Beijing, China

[2] Center for Excellence in Brain Science and Intelligence Technology, CAS, Beijing, China

[3] Center for Research on Intelligent Perception and Computing, CASIA, Beijing, China

[4] School of Artificial Intelligence, University of Chinese Academy of Sciences, Beijing, China

[5] Vision Intelligence Center, AI Platform, Meituandianping Group, Beijing, China

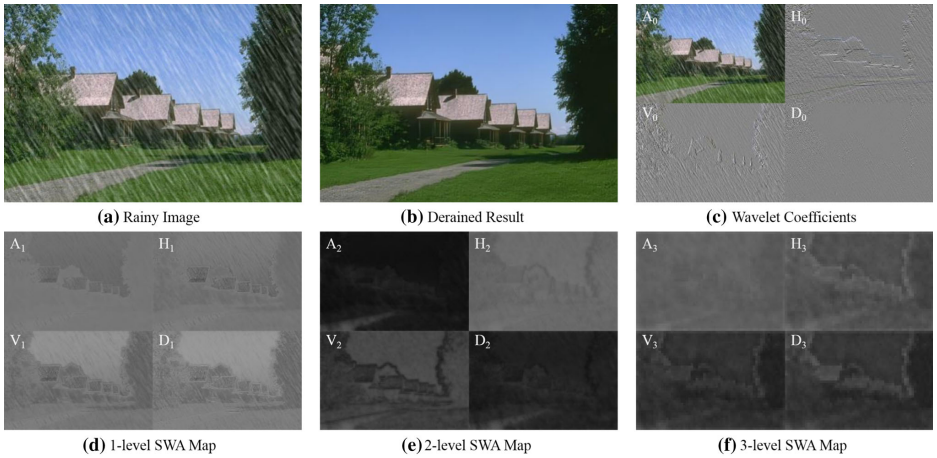

(a) Rainy Image **(b)** Derained Result **(c)** Wavelet Coefficients

(d) 1-level SWA Map **(e)** 2-level SWA Map **(f)** 3-level SWA Map

Fig. 1 Illustration of selective wavelet attention learning. **a** Rainy image, **b** derained result, **c** 1-level wavelet decomposition of the input rainy image, and **d–f** selective wavelet attention (SWA) maps learned at the 1–3 level, respectively. In the top-left of each patch in **c–f** are the letters that denote the types of the wavelet coefficients, respectively. It should be noted that the approximation wavelets of the sky region in (**d**) and most of the region in (**e**) are dark, implying that the low-frequency wavelet preserves more background information

Single image deraining is a difficult problem since degraded images in the wild may contain rain streaks or raindrops of various sizes, shapes, directions, densities, etc. Current deraining methods resort to deep learning techniques to learn rainy-to-clean image translation via some prior information. Fu et al. (2017b) use a priori image domain knowledge by focusing on high-frequency details. Yang et al. (2017b) construct a joint rain detection and removal network to predict rain locations and densities. Following these studies, many CNN-based methods have been proposed to remove rain streaks by employing some rain related priors, such as rain density (Zhang and Patel 2018), scene depth (Hu et al. 2019; Li et al. 2019), and confidence maps (Yasarla and Patel 2019). In addition, many methods take advantage of advanced deep network architectures, such as ResNet (Fan et al. 2018), DenseNet (Zhang and Patel 2018; Yang et al. 2019a), Pyramid network (Fu et al. 2019), U-Net (Qian et al. 2018), and Recursive network (Li et al. 2018b, 2017; Ren et al. 2019), to exploit different scale features and facilitate rain removal. Although existing approaches, including those attention-based methods (Qian et al. 2018; Li et al. 2018a, b; Hu et al. 2019; Wang et al. 2019b), provide the state-of-the-art results, it is still challenging to separate rain and background, which may intrinsically overlap not only in the image pixel domain but also in the semantic embedding space (Yang et al. 2019b), leaving much room for improvement.

Wavelet transform has been proven to be an efficient technique to represent both spatial and frequency statistics of multi-scale images (Mallat 1996). The low-frequency wavelets (i.e., the approximation coefficients) capture the global content information of an image, while the high-frequency wavelets (i.e., the detail coefficients) depict the structure and edge details. This fact motivates us to employ wavelet transform for single image deraining, because rain may alter the spatial content and frequency characteristics of a degraded image. For example, as illustrated in Fig. 1a, rain streaks may add high-frequency edges in the foreground and smooth the texture details in the background scene. Figure 1c demonstrates a 1-level wavelet decomposition of the rainy image using the Haar wavelet. The approximation coefficient A_0 encodes the most global content information of the background scene and reduces the edge intensity of the rain streaks. The horizontal and vertical detail coefficients H_0 and V_0 reveal the structure and texture information with the highlight of the rain streaks. The diagonal detail coefficient D_0 exposes the edge and textures of the background scene, including trees and grasses, and almost neglects the rain streaks, implying that the directions of most rain streaks are diagonal. In addition, raindrops may also damage the background scenes both spatially and frequencially. Hence, rain removal may benefit from wavelet transform to accurately estimate the spatial and frequency features of rain, such as size, shape, direction and density.

To take full advantage of wavelet transform, this paper proposes a Selective Wavelet Attention Learning (SWAL) method for single image rain removal. The key idea of SWAL is progressively learning the wavelet attention maps in the embedding space to capture and select rain and background features for further processing and skip preserving, respectively. It is motivated by the way that the human visual system adopts selective attention to process different spatial-frequency information, where a local region with finer details is gated for further processing, while the other regions are inhibited (Treisman and Gelade 1980; Treisman 1982; Deco and Zihl 2001). The proposed method learns the wavelet attention maps to denote the rainy degree of features in the spatial and frequency domains. Specifically, the rainy degree illustrates how much the features are altered by rain degradations. The higher the value of a point in the wavelet attention map, the heavier degradations from rain streaks or raindrops upon the embedding space. Therefore, using the wavelet attention maps, the network is able to gate the features of high rainy degree (i.e., the rain components) to a higher level of processing, while keeping the features of low rainy degree (i.e., the background components) for the reconstruction of clean features. Due to this selection process, we refer to our method as selective wavelet attention learning. We utilize SWAL in the hierarchical feature spaces of convolutional neural networks to exploit rain semantic embedding at different scales. Taking the sky in Fig. 1d for example, the corresponding region in the approximation coefficient is dark and those in the detail coefficients are light, which demonstrates that the low-frequency wavelet preserves more information of the background scene than the high-frequency wavelet. In Fig. 1e, most of the regions in the approximation coefficient are dark, implying that the low-frequency features at the current scale consist of little rain information. Hence, the learned attention maps in Fig. 1 verify that SWAL facilitates the separation of rain and background information in the embedding space and is beneficial to restoring clean background scenes from degraded images with various rain appearances.

The proposed method develops a selective wavelet attention encoder–decoder network (SWAED) as the baseline rainy-to-clean image translation network. It consists of an encoder to extract increasingly abstract features and a decoder to synthesize clean and rain-free images. The basic component of the encoder is selective wavelet attention encoding (SWAE) block, which consists of four parts: a wavelet embedding block to obtain and process wavelet coefficients, an attention estimation block to predict wavelet attention maps, an attentive selection block to separate rain and background features, and a wavelet pooling block to generate the input for the next layer. Symmetrically, the corresponding component of the decoder is selective wavelet attention generative (SWAG) block, which consists of three parts: a wavelet unpooling block to generate wavelet coefficients, a wavelet fusion block to fuse the wavelet coefficients and the corresponding background features learned in the encoder, and a wavelet refinement block to process and compose the wavelets. Note that most of the existing methods (Qian et al. 2018; Yasarla and Patel 2019; Wang et al. 2019a) adopt downsampling operations, such as max-pooling, average-pooling, and strided-convolution, to learn multiscale features, as well as upsampling operations, such as interpolation and deconvolution, to recover the spatial size of features. Such operations may degrade high-frequency components and introduce aliasing (Zhang 2019) so that the details of background textures are often missed during the forward process of neural networks. The proposed wavelet pooling and unpooling facilitate the preservation of high-frequency components of the features, thus leading to accurate recovery of background details.

In addition, we propose latent alignment learning to further increase the accuracy of deraining, which provides an additional effective supervision for the background features. The motivation is aligning the background features learned in the aforementioned SWAE blocks to uncorrupted features, thus leading to more accurate recovery of background details. However, it is difficult to produce such uncorrupted features because it makes no sense to feed clean images directly to the proposed network designed for the separation of rain and background. To alleviate this issue, we utilize *cleaner* features instead of *clean* features as the target for latent alignment. Specifically, we make use of a mixed cleaner image, i.e., a random interpolation of the original rainy image and its groundtruth in the pixel space, as the input to produce the target features. The objective function of latent alignment is a sum of regression losses between the hierarchical background features from the original and mixed rainy images, respectively. In addition, along with an additional pixel-wise regression loss, the mixed images also augment the training data and make the network more robust for rain intensities.

Finally, we construct the proposed selective wavelet attention learning in the framework of Conditional Generative Adversarial Network (Goodfellow et al. 2014; Mirza and Osindero 2014). The generator is designed according to the above discussion and the discriminator is built using the same network architecture as the encoder part of the generator. The selective wavelet attention maps in the discriminator reveal the degree to which the features confuse the network to distinguish between the real and generated clean images at a certain scale. The negative-attention features (corresponding to the background features in the generator) at multiple scales are used to predict the difference between the real and synthetic images conditioned on the input rainy image. With the guidance of multiscale selective wavelet attention maps, the proposed discriminator is capable of distinguishing the image both globally and locally in spatial and frequency domains.

The main contributions are summarized as follows:

- A novel selective wavelet attention learning method is proposed for single image deraining. To the best of our knowledge, this is the first attempt to learn wavelet attention maps to guide the separation of rain and background information at different scales in the embedding space.
- A novel rainy-to-clean image translation network is proposed based on selective wavelet attention learning. Wavelet pooling and unpooling are developed to improve the recovery of background scene details.
- A novel latent alignment learning mechanism is proposed to supervise the background features as well as augment the training data. It further improves the accuracy of deraining.
- A conditional generative adversarial network is constructed based on selective wavelet attention learning. It provides a promising generative adversarial approach for visually realistic image synthesis.
- The experimental results on synthetic and real datasets, demonstrate that the proposed approach outperforms state-of-the-art methods both quantitatively and qualitatively.

2 Related Works

In this section, we briefly review some related advances in single image deraining, attention learning in the field of computer vision and wavelet transform in image-to-image translation tasks.

2.1 Single Image Deraining

Single image deraining has witnessed great progress. In traditional methods, Kang et al. (2011) decompose the rain image into high- and low-frequency components, and then the rain streaks of the high-frequency layers are removed by dictionary learning. Discriminative sparse coding (DSC) is introduced in Luo et al. (2015) to accurately separate the rain streaks from the background, which could preserve the texture details of the image. To guide the process of separation, Zhu et al. (2017) employ the layer-specific priors to determine the rain-dominant parts of the image. Li et al. (2016) utilize Guassian mixture models (GMM) to separately model the rain streak layer and the background.

Recent plentiful and impressive works have emerged based on deep learning. Yang et al. (2017b) build up a deep network to jointly detect the rain locations and remove the rain streaks. Fu et al. (2017b) propose a deep detail network to use high-frequency details as input and reduce the mapping range from input to output. There are various CNN-based derainers following (Yang et al. 2017b; Fu et al. 2017a). For instance, Li et al. (2018b) add a squeeze-and-excitation block (Hu et al. 2018) to the recurrent network in order to remove the rain streaks iteratively. Zhang et al. (2018) exploit a multistream dense network to classify the density of rain streaks and then guide the rain removal. Pan et al. (2018) establish a dual convolutional neural network (DualCNN) to handle low-level vision tasks, including rain removal. Li et al. (2017) create parallel subnetworks to manage different scales of rain streaks. Li et al. (2018a) employ a non-locally enhanced autoencoder network to better preserve details of the background. Fan et al. (2018) build a residual-guide network that adopts residuals generated from shallower blocks to guide deeper blocks, which is able to deal with various rainy conditions. The attention mechanism is fused into the network (Hu et al. 2019; Wang et al. 2019b) to focus on the rainy parts of images.

With the development of generative adversarial techniques (Goodfellow et al. 2014), GAN-based approaches are proposed to generate more realistic clean images. Zhang et al. (2019) apply the conditional GAN to remove the rain streaks and produce clean images with high fidelity. To deal with the heavy rain streaks removal issue, Li et al. (2019) design a two-stage network that integrates a physics-based backbone and a depth-guided GAN refinement. Wang et al. (2019a) take the rain removal task as a rainy-to-clean image translation problem and propose an entangled representation learning formulation.

In addition, adherent raindrop removal has attracted extensive attention. To overcome various problems (i.e. different shapes,blur, glare), You et al. (2015) present a pixel-based method to detect raindrops. Eigen et al. (2013) use raindrop degraded-clean image pairs to train CNN networks and achieve satisfactory results in small raindrops tasks. Qian et al. (2018) employ a visual attention mechanism to preserve the local consistency of the restored raindrop parts and the contextual information surrounding the raindrop regions.

2.2 Attention Learning

Attention learning, inspired by the human attention mechanism (Rensink 2000), has been proven effective to improve the performance of computer vision by focusing on more relevant regions or features. Zagoruyko and Komodakis (2016) utilize the attention from the teacher CNN to improve the performance of the student CNN. Kuen et al. (2016) propose a recurrent attentional conv-deconv network to detect the saliency in a progressive way. A residual attention network is introduced in Wang et al. (2017) to incorporate a forward network for the image classification issue. In addition, GAN models combined with attention blocks have been recently developed. Xu et al. (2018) propose an Attentional Generative Adversarial Network (AttnGAN) to deal with the text-to-image generation issue. Zhang et al. (2018)

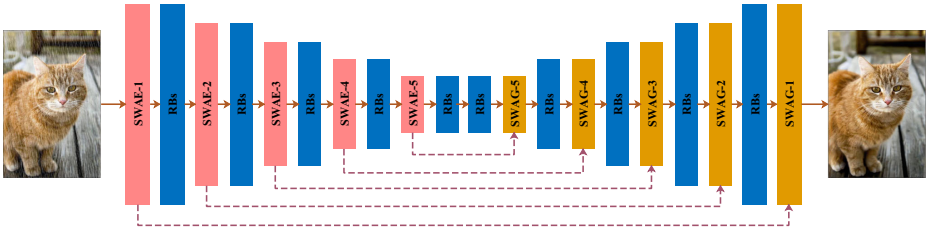

Fig. 2 Overview of the proposed selective wavelet attention encoder–decoder network (SWAED). RBs represents a stack of residual blocks and the dashed lines are skip-connections

employ self-attention mechanism for image synthesis. Yang et al. (2017a) build up LR-GAN to learn the background and foreground of images separately and recursively. Chen et al. (2018) add the attention mechanism to the detection framework and improve the performance of object transfiguration in wild images. Note that our method learns attention in the wavelet domain to guide the separation of features at multiple scales, which is different from most of the previous attention-based methods.

2.3 Wavelet Domain Image Synthesis

Wavelet (Mallat 1989) has been widely applied in various issues (Szu et al. 1992; Zhang and Benveniste 1992; Billings and Wei 2005) as a serviceable signal processing tool. Recently, the combination of deep neural networks and the wavelet has been studied in the image analysis field (Liu et al. 2018; Yuan et al. 2019; De Silva et al. 2020). In this section, we focus on the wavelet application of image synthesis, which is one of the most attractive issues in the community. Yoo et al. (2019) propose a wavelet corrected transfer based on whitening and coloring transforms (WCT2) which encourages the transfer network to generate visually realistic images. Provenzi et al. (2014) design a wavelet-based perceptually inspired color correction variational model to deal with both the color enhancement and color cast removal. To increase the high-frequency information, several methods (Huang et al. 2017; Zhong et al. 2018; Huang et al. 2019; Deng et al. 2019) exploit wavelet transform in the network architecture and improve the performance of super-resolution. Recently, a few works have explored the application of wavelet transform in image deraining. Yang et al. (2019a) propose a recurrent rain removal method by embedding a hierarchical representation of wavelet transform for multiscale images. The authors attempt to progressively recover clean images in a coarse-to-fine manner in image pixel space. In contrast, our method employs wavelet transform in the embedding space to capture global content and local textures of rain and background features, and it further introduces a selective wavelet attention learning mechanism to imitate human attentions that are focused on both spatial and frequency information.

3 Proposed Method

We propose a novel conditional generative adversarial method for single image deraining, named selective wavelet attention learning. The overall architectures of its generative network and discriminator are outlined in Figs. 2 and 3, respectively. To guide the separation of rain and background information, we design the selective wavelet attention (SWA) block as the basic component in our network architecture. We integrate two types of SWA blocks, i.e., SWAE and SWAG, to estimate rain information and recover clean background features in the encoder and decoder of the generative network, respectively. In addition, the discriminator is designed in a similar way as the encoder of the generative network to distinguish the differences between real and generated clean images both globally and locally. In the following, we provide a detailed introduction to each component of the proposed method.

3.1 Wavelet Transform

Our method is based on wavelet transform, more specifically 2D discrete wavelet transform (2D-DWT), which decomposes a two-dimensional signal into a series of subbands at different frequencies. As illustrated in Fig. 4, 1D-DWT employs low-pass and high-pass filters to separate the signal into low-frequency and high-frequency components, respectively. 2D-DWT is conducted by iteratively utilizing 1D-DWT along the columns and rows of the input signal. In this paper, we choose the 1-level Haar wavelet, where the filters $h_{low} = (1/\sqrt{2}, 1/\sqrt{2})$ and $h_{high} = (1/\sqrt{2}, -1/\sqrt{2})$, to conduct wavelet transform in the feature space. There are three key strengths for the Haar wavelet: firstly, it is very simple and easy to implement and compute the Haar

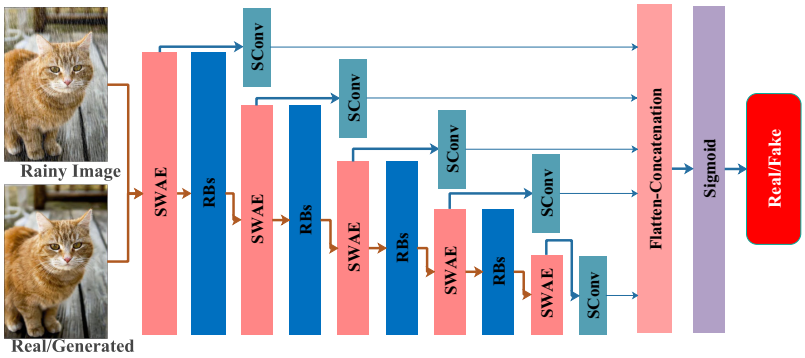

Fig. 3 Overview of the proposed selective wavelet attention discriminator (SWAD). SConv and RBs indicate strided convolution and residual blocks, respectively

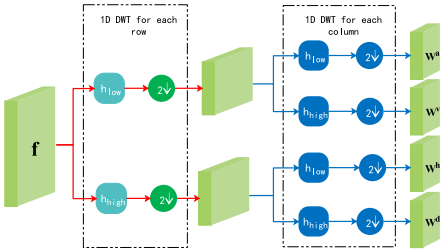

Fig. 4 Illustration of the 2D discrete wavelet transform

wavelet; secondly, the directional detail coefficients of the Haar wavelet are suitable to learn the directions of rain degradations, as demonstrated in Fig. 1c; lastly, the original signal can be exactly recovered from the decomposed Haar wavelets without information loss.

We conduct 1-level 2D-DWT independently on per channel of a given 3D feature map $f \in R^{c\times h\times w}$. The produced wavelets W consist of four components, namely, the approximation coefficient W^a, the vertical, horizontal and diagonal detail coefficients W^v, W^h, W^d. Each of them has a reduced size of $c \times \frac{h}{2} \times \frac{w}{2}$. Example results of wavelet transform in the image space are shown in Fig. 1c. It can be seen that the approximation coefficient captures low-frequency content information while the vertical, horizontal and diagonal detail coefficients extract high-frequency structure and texture information of different directions.

In addition, our method is related to wavelet reconstruction, which is the inverse version of wavelet transform, specifically 2D inverse discrete wavelet transform (2D-IDWT). We use wavelet decomposition and reconstruction in the encoder and decoder of the proposed generative network, respectively. Following Huang et al. (2017), the proposed network employs convolution and deconvolution layers with fixed parameters of Haar filters to separately conduct wavelet decomposition and reconstruction.

3.2 Selective Wavelet Attention

Current attention-based deraining methods (Qian et al. 2018; Hu et al. 2019; Wang et al. 2019b) mostly learn attention maps in the image or feature space to highlight the spatial region of rain. The proposed selective wavelet attention differs from them in two respects. First, considering that rain may change a degraded image's frequency properties as well as spatial content, we learn an attention map in the wavelet domain to locate the rain region in both spatial and frequency domains. The second respect is that we utilize an attention map to guide the separation of rain and background in the embedding space. That is our method pays attention not only to rain regions for deraining but also to rain-free regions for preserving the information of the background scene.

Corresponding to the encoder–decoder architecture adopted in the generative network, we develop two types of SWA block. One is SWAE for the encoder to estimate the wavelet attention map and separate rain and background information, and the other is SWAG for the decoder to fuse rain-free features in the previous layer and background features skipped from the encoder. In addition, to accurately preserve textural details of the back-ground scene, we employ wavelet pooling and unpooling in SWAE and SWAG against common downsampling and upsampling operations.

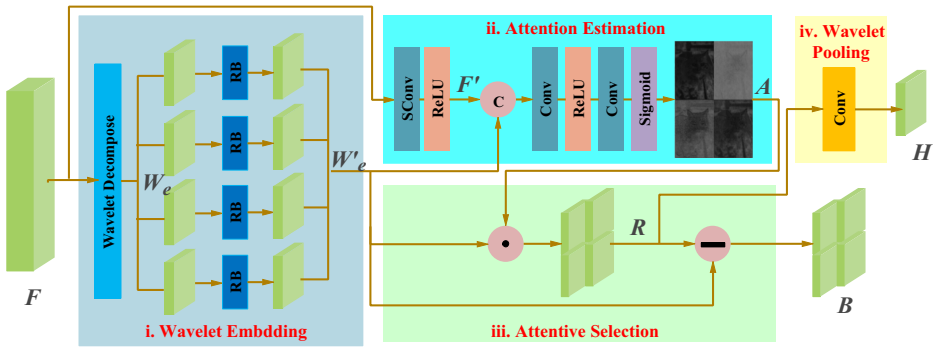

Fig. 5 Overview of the selective wavelet attention block in the encoder (SWAE). ©, ⊙ and ⊖ are the operations of channel-wise concatenation, wavelet-wise multiplication and element-wise subtraction, respectively. SConv and RB indicate strided convolution and residual block, respectively

3.2.1 SWAE Block

As outlined in Fig. 5, each SWAE block consists of four subblocks: wavelet embedding block, attention estimation block, attentive selection block, and wavelet pooling block. The wavelet embedding block decomposes the input features into a set of wavelet coefficients and processes them independently. Then the attention estimation block predicts the wavelet attention map using the original input features and the processed wavelet coefficients. Furthermore, the attentive selection block utilizes the estimated attention map to separate rain and background information. Finally, the wavelet pooling block reduces the dimensions of the features for the next layer.

The wavelet embedding block first transforms the image features $F \in \mathbb{R}^{c_{in}\times h\times w}$ into a set of wavelet coefficients $W_e \in \mathbb{R}^{4\times c_{in}\times \frac{h}{2}\times \frac{w}{2}}$ using 1-level wavelet transform. We then extract features of each wavelet coefficient independently using a set of parallel residual blocks. Through the wavelet embedding block, the input F is mapped to feature maps $W'_e \in \mathbb{R}^{4\times c_{out}\times \frac{h}{2}\times \frac{w}{2}}$, where c_{out} is the output channel size of the residual block. The extracted features W'_e reveal the information of rainy features in spatial and frequency domains, with expanded channel size and downsampled spatial size.

The attention estimation block predicts wavelet attention $A \in \mathbb{R}^{4\times \frac{h}{2}\times \frac{w}{2}}$ from the input features F and the wavelet embedding W'_e. Note that A has a first dimension equal to 4 to assign one attention map to each band of wavelets. F is first mapped to feature space $F' \in \mathbb{R}^{c_{out}\times \frac{h}{2}\times \frac{w}{2}}$, which has the same size as a single coefficient of W'_e using a stride convolution followed by ReLU. Then, wavelet attention A is calculated using the concatenation of F' and W'_e through a sequence of convolution, ReLU, convolution and Sigmoid layers. Wavelet attention A allows the network to know where and on which frequency the removal should be focused. Example results of wavelet attention maps are shown in Fig. 1d–f. As seen, the learned attention maps differ not only in spatial regions but also in frequency bands, implying that rain degrades both the spatial content and frequency properties.

The attentive selection block produces rain features $R \in \mathbb{R}^{4\times c_{out}\times \frac{h}{2}\times \frac{w}{2}}$ and rain-free background features $B \in \mathbb{R}^{4\times c_{out}\times \frac{h}{2}\times \frac{w}{2}}$ with the guidance of wavelet attention A. Since A consists of four sub-attention maps, each of which indicates the rainy degree of the corresponding coefficient of W'_e, we implement element-wise multiplication between every sub-attention map and each feature map of its corresponding coefficient, which is referred to as wavelet-wise multiplication. Hence, we obtain the rain features R, in which rain regions and frequencies are kept and non-rain components are decreased. In addition, removing rain features R from wavelet embedding W'_e leads to background features B. The definition of attentive selection can be formulated as

$$R = W'_e \odot A, \tag{1}$$

and

$$B = W'_e - R, \tag{2}$$

where $\odot$ is wavelet-wise multiplication. It expands A to the same size with W'_e and then conducts a Hadamard product between them.

The wavelet pooling block compresses the dimensions of rain features R to reduce the computing complexity of subsequent blocks. We employ a 1×1 convolution to map R into feature space $H \in \mathbb{R}^{c_{out}\times \frac{h}{2}\times \frac{w}{2}}$. Note that we call this block as wavelet pooling for simplicity. The whole process

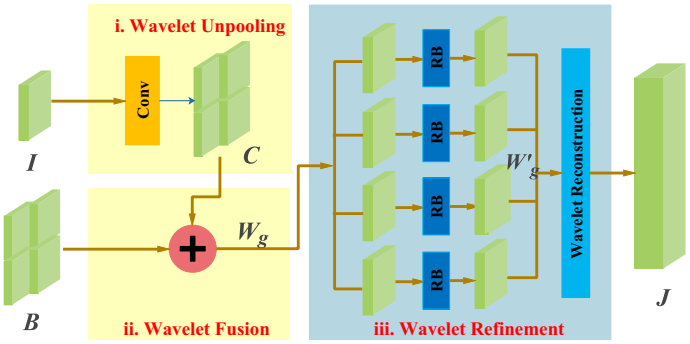

Fig. 6 Overview of the selective wavelet attention block of the decoder (SWAG). $\oplus$ represents the operation of element-wise summation, and RB indicates the residual block

of wavelet pooling consists of two stages: the first is wavelet transform to reduce the spatial size of the features while increasing the channel size; the second is this block to reduce the channel size. The operations between them are utilized to learn and separate rainy and clean features as discussed above. Similar to other downsampling operations, wavelet pooling transforms the input feature $F \in \mathbb{R}^{c_{in} \times h \times w}$ to output feature space $H \in \mathbb{R}^{c_{out} \times \frac{h}{2} \times \frac{w}{2}}$ but may preserve better high-frequency components. More details are discussed in Sect. 3.3.2.

3.2.2 SWAG Block

As outlined in Fig. 6, each SWAG block consists of three subblocks: a wavelet unpooling block to produce wavelet coefficients from the input features, a wavelet fusion block to fuse the produced wavelet coefficients and the background features skipped from the encoder, and a wavelet refinement block to refine the fused features and perform wavelet reconstruction.

The wavelet unpooling block transforms the input feature $I \in \mathbb{R}^{c_{in} \times h \times w}$ from the previous layer into wavelet coefficient space $C \in \mathbb{R}^{4 \times c_{in} \times h \times w}$. We adopt a 1×1 convolution to project I to C, scattering the information into a set of wavelet coefficients. This block is reversed to the wavelet pooling block in SWAE, and more discussions are provided in Sect. 3.3.2.

The wavelet fusion block integrates the produced wavelet coefficients C and the background features B skipped from the corresponding SWAE block in the encoder. Assuming that rain has been accurately removed by the previous layers and that C is clean, rain-free features $W_g \in \mathbb{R}^{4 \times c_{in} \times h \times w}$ with rich background details can be obtained via a simple element-wise summation, which is defined as

$$W_g = C + B. \tag{3}$$

The wavelet refinement block employs a set of parallel residual blocks to independently refine the fused wavelet coefficients W_g. It projects W_g into wavelet feature space $W'_g \in \mathbb{R}^{4 \times c_{out} \times h \times w}$, where c_{out} is the output channel size of the residual blocks. The final clean features $J \in \mathbb{R}^{c_{out} \times (2 \times h) \times (2 \times w)}$ of an upsampled size are generated using 1-level wavelet reconstruction. Similar to wavelet pooling in SWAE, the wavelet unpooling block, wavelet reconstruction in this block, and the functions between them constitute the whole process of wavelet unpooling, which may outperform other upsampling operations.

3.3 Generative Network

As mentioned above, advanced network architectures, such as UNet, ResNet and DenseNet, are employed in recent deraining methods (Qian et al. 2018; Fan et al. 2018; Zhang and Patel 2018; Yang et al. 2019a). Among them, UNet is superior with respect to fusing the information at different scales to capture global information while keeping local details. Similar to UNet, we develop a selective wavelet attention encoder–decoder network (SWAED) as the baseline generative network. It is injected with SWA blocks at different scales to explore multiscale rain and background information. In addition, we adopt wavelet pooling and unpooling to implement downsampling and upsampling in the encoder–decoder architecture to better preserve high-frequency details.

3.3.1 SWAED

As illustrated in Fig. 2, the proposed SWAED is composed of three types of basic blocks: SWAE block, SWAG block, and residual blocks. The architectures of SWAE and SWAG blocks are discussed in Sect. 3.2. As shown in Fig. 7, inspired by the state-of-the art super-resolution method EDSR (Lim et al. 2017), we employ a residual block architecture in which

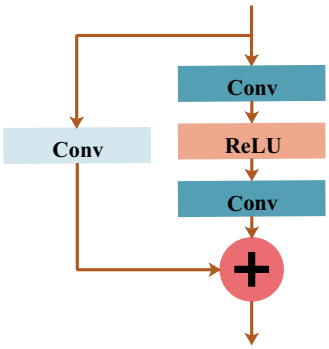

Fig. 7 Overview of the residual block (RB). The side convolution layer is ignored when the output features have the same channel number as the input

normalization layers, such as BatchNorm, and the last nonlinear activation are ignored.

The encoder takes the rainy image as input. It utilizes the SWAE block to extract rain and background features in the wavelet domain, and further processes the rain features by residual blocks. Since the rain features have been downsampled via the SWAE block, iteratively repeating the above process allows for progressively exploiting rain and background information at multiple scales. The decoder takes the rain features at the highest level in the encoder as input. It applies residual blocks to extract rain-free features, and employs the SWAG block to recover clean background features from rain-free features and the separated background features in the corresponding SWAE block. As the features are upsampled through the SWAG block, iteratively repeating the above process would finally recover a clean image of the same size as the input rainy image. Note that the features transferred via skip-connections in Fig. 2 are background features at a specific scale. They have an explicit physical meaning, which is different from those in traditional encoder–decoder architectures.

3.3.2 Wavelet Pooling and Unpooling

As mentioned in Sect. 3.2, we make use of wavelet pooling and unpooling to conduct downsampling and upsampling in the encoder–decoder architecture. Most of the existing methods employ average pooling or strided convolution to reduce the size of feature map, which may lose high-frequency information of rain features and result in blurry results in rainy regions. Different from those methods, the background features extracted by wavelet pooling preserve high-frequency details as well as low-frequency information of the background. In addition, wavelet reconstruction can exactly recover the input signal from the decomposed wavelets. This makes it possible for wavelet unpooling to accurately recover both the low-frequency content and the high-frequency details of the background scene, as long as the rain-free features cleaned by the network are as accurate as possible. The deep multi-scale architecture assists in learning such features essential for rain removal.

3.3.3 Loss Function

We employ a pixel-wise regression loss to supervise the generative network G to produce a clean image $G(x)$ that is close to the ground-truth image y in pixel space, which is formulated as

$$L_{pixel} = \|G(x) - y\|_1. \tag{4}$$

3.4 Latent Alignment Learning

To further improve the accuracy of deraining, we propose latent alignment learning to provide an additional supervision on the background features B learned in the attentive selection block of the encoder in the generative network G. It aims to align the background features B to clean features uncorrupted by rain degradations, consequently improving the recovery quality of background details. Due to the difficulty in directly producing corresponding clean features, we employ cleaner features $\hat{B}$ to approximate to clean features as the target of latent alignment. $\hat{B}$ is generated by the same generative network G from an image $\hat{x}$, which has such rain degradations that are similar with but lighter than the original rainy image x. For simplicity, $\hat{x}$ is obtained by a linear interpolation between the original rainy image x and its groundtruth image y in the pixel space, which is defined as

$$\hat{x} = (1 - \alpha)x + \alpha y, \tag{5}$$

where α is a random value sampled from the uniform distribution $U(0, b)$. b is set to less than one, specially 0.5 in this paper, to ensure that $\hat{x}$ is corrupted by rain degradations.

Given a pair of rainy image x and its cleaner version $\hat{x}$, the objective function of latent alignment is defined in the hierarchical embedding space as

$$L_{align} = \sum_{i=1}^{K} \|B_i - sg\{\hat{B}_i\}\|_1, \tag{6}$$

where B_i and $\hat{B}_i$ are the background features in Eq. (2) in the ith SWAE block of G for x and $\hat{x}$, respectively. K is the number of SWAE blocks. $sg(\cdot)$ indicates stopping the back

propagation of gradients at this point. The reason for the stopping is that we conduct a directional alignment to improve the rainy features B_i by a supervision from the cleaner features $\hat{B}_i$.

Additionally, we employ a pixel-wise regression loss to recover the clean image y from the mixed image $\hat{x}$, which leads to data augmentation. It may improve the robustness of G towards rain intensities. The loss is defined as

$$L_{aug} = \|G(\hat{x}) - y\|_1. \tag{7}$$

3.5 Conditional Adversarial Learning

Following Qian et al. (2018), we introduce conditional adversarial learning (Mirza and Osindero 2014) into the proposed SWAL method to further improve the visual reality of the rain removal image. We develop an additional discriminator network to compete with the generative network, where the discriminator attempts to distinguish between the real clean image and the generated derained image, and the generative network attempts to fool the discriminator. Different from the original GAN (Goodfellow et al. 2014), the discriminator takes the input rainy image into consideration when predicting real/fake possibilities of the clean image, which ensures that the details synthesized by the generative network are conditioned on the input rainy image. The optimization objective for the discriminator D and generative network G is defined as

$$\begin{aligned}\min_G \max_D \ & \mathbb{E}_{x,y\sim p_{data}}[\log D(x, y)] \\ & + \mathbb{E}_{x\sim p_{data}}[\log(1 - D(x, G(x)))],\end{aligned} \tag{8}$$

where x is the input rainy image, y is the real clean image, and $G(x)$ is the produced clean image.

As outlined in Fig. 3, the discriminator network D is designed in a similar way to the encoder of SWAED. It employs a stack of SWAE blocks followed by residual blocks to exploit multiscale features. A convolution layer is added to each SWAE block in the side of D (we refer to it as a side convolution in the following) to predict whether the input image is real or fake using the background features B at the current scale. Here, B captures such information that may reveal the difference between real and generated images at a specific scale. Hence, the wavelet attention maps A estimated by SWAE blocks could help D to separate the information in the embedding space according to the feature scales. Finally, the features embedded by the side convolutions are concatenated after being flattened to one-dimension, and then transformed into the value range of [0, 1] via a sigmoid layer. Each point in the final output predicts the probability of the regions within a certain receptive field belonging to a real clean image. This makes the proposed D capable of regularizing the generated results both globally and locally, which differs from most of the previous works of adversarial deraining (Qian et al. 2018).

We adopt the objective of Least Squares Generative Adversarial Networks (LSGANs) (Mao et al. 2017) to train our network. The adversarial loss functions for the discriminator and generative network are defined as

$$L_D = \frac{1}{2N}\|D(x, y) - 1\|_F^2 + \frac{1}{2N}\|D(x, G(x)) - 0\|_F^2, \tag{9}$$

$$L_{adv} = \frac{1}{2N}\|D(x, G(x)) - 1\|_F^2, \tag{10}$$

where N is the size of the output feature map of D.

3.6 Total Loss Functions

To summarize, the full objective for the proposed generative network is a weighted sum of the pixel-wise loss, the latent alignment loss, the augmentation loss, and the adversarial loss, which is defined as

$$L_G = L_{pixel} + \lambda_1 L_{align} + \lambda_2 L_{aug} + \lambda_3 L_{adv}, \tag{11}$$

where $\lambda_{1\sim3}$ are hyperparameters to balance each item.

Note that there are neither explicit nor implicit constraints on the proposed selective wavelet attention, which is different from other attention-based works (Qian et al. 2018; Wang et al. 2019b; Hu et al. 2019). Example results of selective wavelet attention maps are provided in Fig. 1, demonstrating the effectiveness of the proposed method in learning meaningful attention maps in an unsupervised way.

3.7 Implementation Details

3.7.1 Network Architectures

Let `C5s2p0-k` denote a 5×5 convolution with `k` filters, stride 2, and padding 0, `Rk` denote a residual block whose output channel size is k, `R6-k` denote a sequence of 6 `Rk` residuals stacked together, `SWAEk` denote a SWAE block with output channel size $c_{out} = k$, and `SWAGk` denote a SWAG block with output channel size $c_{out} = k$.

As outlined in Fig. 7, for each `Rk`, the convolutions in the mainstream are `C3s1p1-k` and `C3s1p1-k`; the convolution in the skip-connection is `C1s1p0-k`, which is ignored when the output has the same channel size as the input. As outlined in Fig. 5, for each `SWAEk`, the residual block in the wavelet embedding block is `Rk`; the convolutions in the attention estimation block are `C3s2p1-k`, `C1s1p0-32`, and `C1s1p0-4`, respectively; the convolution in the wavelet pooling block is `C1s1p0-k`. As outlined in Fig. 6, for each `SWAGk`, the residual block in the wavelet refinement block

is Rk, and the convolution in the wavelet unpooling block is C1s1p0-4k′, where k' is the input channel size.

As outlined in Fig. 2, the encoder architecture of SWAED is the following: SWAE16, R16-16, SWAE32, R16-32, SWAE64, R16-64, SWAE64, R16-64, SWAE64, and R16-64. The decoder architecture is the following: R16-64, SWAG64, R16-64, SWAG64, R16-64, SWAG32, R16-32, SWAG16, R16-16, and SWAG3. As outlined in Fig. 3, the architecture of the discriminator in the mainstream is the following: SWAE64, R1-64, SWAE128, R1-128, SWAE256, R1-256, SWAE256, R1-256, and SWAE256. All the side convolutions are C5s2p0-1.

3.7.2 Training Details

The proposed method is trained on the images of pixel size 320 × 320, randomly cropped in the training set, and evaluated on images of arbitrary size in the testing set. For the hyperparameters in Eq. (11), we empirically set λ_1 to be 0.01, λ_2 to be 1, and λ_3 to be 0.001 to make the network focus on learning the mapping between rainy and clean images. We train the presented network using Adam algorithm with a batch size of 32 and a fixed learning rate of 0.0001. It takes approximately 100,000 iterations for our network to converge. Code and results will be released.

4 Experiments

In this section, we evaluate the proposed method on both synthetic and real images of rain streaks and raindrops. Four synthetic rain datasets are employed for training and testing our models. Visual inspection of the learned selective wavelet attention maps are conducted to verify its effectiveness in depicting the spatial and frequency information of rain degradations. Quantitative metrics, such as Peak-Signal-to-Noise Ratio (PSNR) and Structural Similarity index (SSIM), are utilized to compare the performance of our method against other state-of-the-art methods. The visual results on both synthetic and real images are reported to compare the qualitative performance. Ablation experiments are also conducted to study the role of each part of the presented network.

4.1 Datasets and Metrics

We consider four challenging synthetic rain datasets, i.e., the Rain100H dataset and the Rain100L dataset proposed by Zhu et al. (2017), the Rain12 dataset created by Li et al. (2016), the DDN-Data built by Fu et al. (2017b), and the DID-Data provided by Zhang and Patel (2018), for rain streak removal experiments. For raindrop removal, we utilize a large-scale raindrop dataset created by Qian et al. (2018), which is denoted as AGAN Data. The proposed method is trained and evaluated on the above datasets (except for the Rain12 dataset) following the standard protocols released by the authors. We employ the model trained on the Rain100L to evaluate the performance on the Rain12 dataset. PSNR and SSIM are calculated on the luminance channel of YCbCr space using the scikit-image library in Python. In addition, we conduct ablation study on Rain100H and AGAN Data to evaluate the effectiveness of each part of our method. The performance of deraining on real images is compared through visual observation, since no ground-truth labels exist for rainy images in the real world.

4.2 Comparison with State-of-the-Art Methods

We compare the proposed method against several recent state-of-the-art methods. For rain streak removal, we compare against Gaussian Mixture Model(GMM) based method (Li et al. 2016), Deep Detail Network (DDN) (Fu et al. 2017b), Joint Rain Detection and Removal (JORDER) (Yang et al. 2017b), Density-aware Image Deraining (DID) (Zhang and Patel 2018), Recurrent Squeeze-and-Excitation Context Aggregation Net (RESCAN) (Li et al. 2018b), Non-locally Enhanced encoder–decoder (NLEDN) (Li et al. 2018a), SPatial Attentive Network (SPANet) (Wang et al. 2019b), Uncertainty guided Multi-scale Residual Learning (UMRL) (Yasarla and Patel 2019), Progressive Image Deraining Networks (PReNet) (Ren et al. 2019), Entangled Representation Learning Network (ERL-Net) (Wang et al. 2019a) on rain streak removal. For raindrop removal, we compare against the 3-layered network proposed by Eigen et al. (2013), Pixel2Pixel (Isola et al. 2017), Attentive Generative Adversarial Network (AGAN) (Qian et al. 2018) and ERL-Net (Wang et al. 2019a) on raindrop removal.

4.2.1 Quantitative Comparison

The quantitative results of PSNR and SSIM for the tasks of rain streak removal and raindrop removal are reported in Tables 1 and 2, respectively. It can be seen that the proposed method achieves better or comparable performance against the state of the art. As shown in Table 1, our method obtains the best results of rain streak removal in most cases, except that the SSIMs compared on DDN Data and DID Data are slightly lower than that with ERL-Net (Wang et al. 2019a). ERL-Net improves the deraining results via a three-stage training strategy, while our network is trained end-to-end. In addition, aside from ERL-Net, our method outperforms the existing methods by a large margin on the adopted three challenging datasets for rain streak removal, and even on the heavy rain streak dataset Rain100H. For raindrop removal, as shown in Table 2, compared to other methods, the proposed method achieves the best performance. Note that the proposed SWAL aims to learn attention

Table 1 Average PSNR and SSIM results on the synthetic rain streak datasets

Dataset	Metric	GMM	DDN	JORDER	DID	RESCAN	NLEDN	SPA-NET	UMRL	PReNet	ERL-Net	Ours
Rain100H	PSNR	15.31	24.92	24.44	23.05	26.79	30.38	25.32	26.01	29.46	*34.57*	**35.15**
	SSIM	0.4285	0.7577	0.8172	0.7734	0.8270	0.8939	0.8317	0.8606	0.8935	*0.9387*	**0.9449**
Rain100L	PSNR	28.05	32.97	36.69	30.48	36.18	36.57	33.89	32.03	*37.48*	–	**38.56**
	SSIM	0.8392	0.9413	0.9735	0.9323	0.9694	0.9747	0.9581	0.9700	*0.979*	–	**0.9804**
Rain12	PSNR	32.04	33.77	36.25	32.93	*37.09*	36.92	35.88	30.73	36.66	–	**37.57**
	SSIM	0.9083	0.9354	0.9621	0.9249	0.9607	*0.9646*	0.9607	0.9308	0.961	–	**0.9698**
DDN Data	PSNR	26.87	28.00	28.98	26.38	32.03	29.79	29.83	30.18	32.60	*33.92*	**34.10**
	SSIM	0.8080	0.8730	0.8658	0.8355	0.9174	0.8976	0.9045	0.9136	0.9458	**0.9502**	*0.9444*
DID Data	PSNR	25.66	27.93	29.88	29.66	32.25	33.16	30.05	30.24	33.48	*34.62*	**34.74**
	SSIM	0.8176	0.8535	0.8762	0.8990	0.9078	0.9192	0.9342	0.9062	0.9229	**0.9403**	*0.9391*

Bold and italic indicate the best and second-best results, respectively

Table 2 Average PSNR and SSIM results on the synthetic raindrop dataset

Metrics	Eigen	Pix2Pix	AGAN	ERL-Net	Ours
PSNR	28.59	30.14	31.57	*32.96*	**33.03**
SSIM	0.6726	0.8299	0.9023	*0.9458*	**0.9511**

Bold and italic indicate the best and second-best results, respectively

maps in the wavelet domain to guide the separation of rain and background information in the embedding space. The superior quantitative performance for these challenging datasets verifies that SWAL can separate the overlapped information of rain and background so that accurate single image deraining is achieved.

Table 3 lists the number of parameters and FLOPS of different methods. It can be seen that the proposed method achieves a low computation cost with a medium model size. For rain streak removal, our model is the second-biggest but much faster and more accurate than most of other methods. Our method has a slightly bigger number of FLOPS than DDN (Fu et al. 2017b) but achieves better performance of PSNR and SSIM by a large margin as shown in Table 1. The competing methods, such as PReNet (Ren et al. 2019) and RESCAN (Li et al. 2018b), employ the recurrent neural network to reduce model size but increase computation complexity. For raindrop removal, our method has a medium model size while achieving fast and accurate deraining compared against others. Eigen (Eigen et al. 2013) is much faster and smaller than others because it has a shallow network of three layers. In addition, it should be noted that the code of ERL-Net is not available. So we cannot compare it on model size and computation complexity. Aside from ERL-Net (Wang et al. 2019a), the proposed method achieves the best performance in the quantitative metrics of PSNR and SSIM in all cases. Therefore, we believe that the current model size of our method is acceptable considering its promising performance with a low cost of computation. We will further study model compression for the proposed method in future works.

4.2.2 Qualitative Comparison

The visual results of image deraining on synthetic and real rainy images are reported in Figs. 8, 9, and 10. It can be observed that the proposed method produces the most appealing results compared with recent state-of-the-art methods. As illustrated in Fig. 8, the existing methods either fail to synthesize globally visual plausible images or tend to generate local artifacts in the regions that are heavily degraded. In contrast, our method can recover clean background scenes with abundant local textures while preserving the global content. For example, our method synthesizes the most plausible human faces without apparent artifacts and recovers texture details even in the challenging regions, such as trees in the mountain image and the dim head region of the horse image. These results demonstrate that the proposed selective wavelet attention learning is effective in capturing and recovering both the global content and local details of background scenes.

Table 3 Comparisons on the number of parameters and FLOPS on an image of pixel size 512 × 512

Metrics	DDN	JORDER	DID	RESCAN	NLEDN	SPA-NET	UMRL	PReNet	Eigen	Pix2Pix	AGAN	ERL-Net	Ours
Params (M)	0.573	0.406	66.0	0.150	1.00	0.210	0.982	0.169	0.754	54.4	6.24	–	9.79
FLOPS (G)	15.0	106.6	44.2	129.3	88.6	68.3	65.7	265.8	0.717	72.6	358.2	–	39.0

Fig. 8 Visual comparison on synthetic heavy rain streak images. Zoom in to observe the details better

Fig. 9 Visual comparison on synthetic raindrop images. The results of ERL-Net are copied from the referenced paper (Wang et al. 2019a)

Fig. 10 Visual comparison on the real rainy images. The comparison results are copied from the referenced paper (Wang et al. 2019a)

Table 4 Average PSNR and SSIM results of the ablation study.

Dataset	Metric	w/o RBs	w/o WT + AvgPool	w/o WT + SConv	w/o Att	Learned transform	Fine-tuned transform	Baseline	+ LA w/o L_{aug}	+ LA	Ours
Rain100H	PSNR	30.48	32.86	32.80	32.49	33.05	34.11	34.13	34.67	**35.23**	*35.15*
	SSIM	0.8890	0.9217	0.9225	0.9174	0.9267	0.9332	0.9396	0.9404	**0.9454**	*0.9449*
AGAN	PSNR	31.27	32.62	32.55	32.41	32.49	32.86	32.76	32.95	**33.06**	*33.03*
	SSIM	0.9394	0.9488	0.9491	0.9485	0.9454	0.9507	0.9502	0.9505	**0.9513**	*0.9511*

Bold and italic indicate the best and second-best results, respectively

Fig. 11 Example results of the ablation study

As illustrated in Fig. 9, the proposed method also achieves promising results for the task of removing raindrops. Taking the images in the bottom row as examples, our method shows superiority in recovering the structures and edges of semantic regions, such as the pole and bin. This finding implies that SWA maps tend to focus on such regions at a specific level. In addition, a large amount of texture details are recovered by our method, such as the iron bars of the well cover in the top row. This result further proves that the proposed SWA learning helps the recovery of high-frequency details of background scenes.

We compare the proposed method against recent state-of-the-art methods on the real-world rainy images employed by ERL-Net (Wang et al. 2019a). The model trained on Rain100H is utilized to test on such images. As illustrated in Fig. 10, our method can still generate visual realistic images of clean background scenes, which are better or comparable to state-of-the-art methods.

4.3 Ablation Study

In this section, we conduct an ablation study to gain insight into the respective roles of each part of our model in image

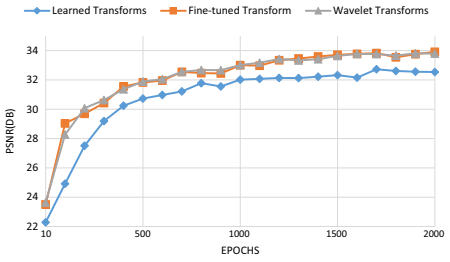

Fig. 12 Comparison on PSNR (higher is better) between learned, fine-tuned and pre-defined transforms along with the training epochs

deraining. We utilize Rain100H and AGAN Data to evaluate the performance on rain streak and raindrop removals, respectively. The quantitative and qualitative results are reported in Table 4 and Fig. 11. The proposed network without latent alignment (LA) and conditional adversarial learning is considered as the baseline model. Several variants of the baseline model are compared to study the roles of the residual blocks (RBs), wavelet transform, wavelet pool-

Table 5 Comparisons of different wavelet filters on the Rain100H dataset

Metric	Db1	Bior1.1	Rbio1.1	Haar
PSNR	34.15	34.20	34.17	34.13
SSIM	0.9379	0.9385	0.9387	0.9396

ing and unpooling, and selective attention. In addition, the baseline model is also compared with its variant with LA as well as the full version of our method to study the influences of LA and conditional adversarial learning. Note that we adjust the number of residual blocks in RBs of the generative network for the ablations (except for the one to study RBs) to ensure each could have a roughly same number of parameters with the full version of our method.

Residual Blocks (RBs) As shown in Fig. 2, the residual blocks are the basic components in the generative network. RBs in the encoder are supposed to project features to such space that is easy for SWAE to distinguish between rain and background features, and RBs in the decoder are supposed to extract more clean features with abundant background details. As shown in Table 4 and Fig. 11c, the removal of RBs in the generative network results in a significant degradation in both quantitative and qualitative performance.

Wavelet Transform The presented network implements wavelet transform, including decomposition and reconstruction, separately by fixed convolutions and deconvolutions, both with predefined parameters. To better understand the role of predefined wavelet transform, we compare the baseline model against its variant with learned transform, where the parameters of the transform layers are optimized together with the network. To better understand the role of predefined wavelet transform, we compare the baseline model against its two variants, one of which is learned transform to learn the parameters of the transform layers from scratch, and the other is fine-tuned transforms to update those parameters from the predefined wavelet filters. As illustrated in Fig. 11e, h as well as Table 4, wavelet transform outperforms learned transform both qualitatively and quantitatively, especially for rain streak removal. Fine-tuning the parameters of wavelet transform achieves comparable results against fixed wavelet transform layers, implying that there is no need to update the layers of wavelet transform. Figure 12 plots the training curves of PSNR during the first 2000 epochs on the Rain100H dataset. As seen, wavelet transform always outperforms learned transform during the training process, especially in the early stage, while fine-tuned transform consistently achieves comparable performance with wavelet transform.

Compared with the learned transform, the major advantages of predefined wavelet transform include three aspects. Firstly, wavelet transform can explicitly split the original signal into channels that capture different frequency components. As aforementioned, incorporating with selective attention, it can help separate rain and background in the embedding space. Secondly, wavelet transform, i.e., Haar wavelet in this paper, can exactly reconstruct the original signal by wavelet reconstruction. Specifically, wavelet decomposition in SWAE and wavelet reconstruction in SWAG are a pair of inverse functions, thus leading to minimal information loss and accurate recovery of background details. Lastly, wavelet transform can directly provide a plausible initialization or might one of optimal solutions for the proposed SWAL method, which can help the training of the networks. These aspects may explain the superiority of wavelet transform to learned transform in the performance of image deraining.

In addition, we conduct experiments on the Rain100H dataset using the baseline model with different wavelet filters, such as Daubechies (Db1), Biorthogonal (Bior1.1), and ReverseBior (Rbio1.1). We report the experimental results in Table 5. It can be observed that all the wavelet filters can achieve comparable results against the Haar wavelet utilized in the previous manuscript. Since the focus of the proposed method is not selecting the optimal wavelet filters for deraining, we choose the Haar wavelet in the manuscript for its simplicity.

Furthermore, we conduct experiments on limited training data, more specifically training the networks with pre-defined or learned filters on 10%, 20%, 40%, 60% and 100% of the Rain100H training set. As outlined in Table 6, pre-defined filters can achieve consistently better results than learned filters. The pre-defined filters can achieve comparable deraining performance utilizing fewer data (10%) against the learned filters utilizing more data (20%). This demonstrates that compared with learned filters, pre-defined wavelet transforms can obtain more appealing results of image deraining on limited training data.

Wavelet Pooling and Unpooling To verify the effectiveness of wavelet pooling and unpooling in image deraining, we develop two variants of SWAE and SWAG blocks. For the first variant, as shown in Figs. 5 and 6, we remove the wavelet decomposition subblock in the wavelet embedding block (which equals implementing 0-level wavelet transform) and replace the 1×1 convolutions in the wavelet pooling and unpooling blocks with average pooling and interpolation upsample, respectively. For the other variant, we change the network in a similar way unless we operate downsampling and upsampling with a 3×3 convolution and a 3×3 deconvolution, both with stride size 2. The significant decrease in Table 4 and the damage of texture details (in the girl's hair and collar) demonstrate that removing rain in the wavelet domain along with wavelet pooling and unpooling plays an important role in accurate recovery of the background details.

Selective Attention To better understand the role of selective attention learning, We remove the attention estimation

Table 6 Comparisons on limited training data of the Rain100H dataset

Percentage	Metric	Learned transform	Pre-defined transform
10%	PSNR	26.84	27.91
	SSIM	0.8456	0.8684
20%	PSNR	27.88	28.70
	SSIM	0.8654	0.8789
40%	PSNR	28.99	30.19
	SSIM	0.8802	0.9006
60%	PSNR	31.66	32.94
	SSIM	0.9073	0.9254
100%	PSNR	33.05	34.13
	SSIM	0.9267	0.9396

subblock as well as the attentive selection subblock in SWAE block in Fig. 5. The learned wavelet embedding W_e' is directly transferred to the wavelet pooling subblock and the skip-connection for SWAG. It can be determined that both quantitative and qualitative performance degrade, verifying the importance of selective attention learning to separate rain and background in the embedding space.

Latent Alignment We compare two variants of the proposed method to study the role of latent alignment learning. One is the baseline model with the latent alignment loss in Eq. (6) but without the augmentation loss in Eq. (7), and the other is with both the two losses. As reported in Table 4, both the latent alignment loss and the augmentation loss can help improve the quantitative performance of deraining. As shown in Fig. 11, the latent alignment learning can further enhance the texture details of background scenes.

Conditional Adversarial Learning As illustrated in Table 4, training the proposed generative network without adversarial loss may slightly improve the quantitative performance. This is reasonable because the PSNR and SSIM measure the pixel similarity between the prediction and its ground truth; they are consistent with the optimization objective of the pixel regression loss in Eq. (4). However, as shown in Fig. 11i, j (zoom in to observe the collar textures of the girl), the adversarial training may generate more high-frequency details so that the results appears more realistic. In addition, we observe that training with adversarial loss still outperforms recent state-of-the-art methods. We choose conditional adversarial learning for more realistic results at the cost of a slight decrease in the quantitative performance.

5 Conclusion

We proposed a novel selective wavelet attention learning method for single image deraining, which attempts to learn attention maps in the wavelet domain to guide the separation of rain and background information in the embedding space. A novel image-to-image translation network has been presented, which has an encoder–decoder architecture injected with SWAE and SWAG blocks. In the encoder, features containing rain and background information are first transformed into the wavelet domain and factored out into rain and background spaces according to the estimated selective wavelet attention before downsampling by wavelet pooling. In the decoder, clean features from the previous layer and skipped background features are integrated in the wavelet domain and upsampled by wavelet unpooling. Furthermore, latent alignment learning is proposed to increase the accuracy of deraining through regularizing the background features as well as augmenting the training data. Finally, conditional adversarial learning is introduced to improve the visual quality of rain removal. Extensive experiments on both synthetic and real datasets verify the effectiveness of the proposed method. Since the architecture of our model is a variant of the encoder–decoder network, it may be easily extended to various image-to-image translation tasks to explore the full potentials of selective wavelet attention learning.

Acknowledgements This work is partially funded by National Natural Science Foundation of China (Grant No. 62006228, 61721004, U20A20223).

References

Billings, S. A., & Wei, H. L. (2005). A new class of wavelet networks for nonlinear system identification. *IEEE Transactions on Neural Networks*, *16*(4), 862–874.

Chen, X., Xu, C., Yang, X., & Tao, D. (2018). Attention-gan for object transfiguration in wild images. In *European conference on computer vision*, pp. 164–180.

De Silva, D., Vithanage, H., Fernando, K., & Piyatilake, I. (2020). Multi-path learnable wavelet neural network for image classification. In *International conference on machine vision*, vol. 11433, p. 1143310.

Deco, G., & Zihl, J. (2001). A neurodynamical model of visual attention: Feedback enhancement of spatial resolution in a hierarchical system. *Journal of Computational Neuroscience*, *10*(3), 231–253.

Deng, X., Yang, R., Xu, M., & Dragotti, P. L. (2019). Wavelet domain style transfer for an effective perception-distortion tradeoff in single image super-resolution. In *IEEE international conference on computer vision*, pp. 3076–3085.

Eigen, D., Krishnan, D., & Fergus, R. (2013). Restoring an image taken through a window covered with dirt or rain. In *IEEE international conference on computer vision*, pp. 633–640.

Fan, Z., Wu, H., Fu, X., Huang, Y., & Ding, X. (2018). Residual-guide network for single image deraining. In *ACM international conference on multimedia*, pp. 1751–1759.

Fu, X., Huang, J., Ding, X., Liao, Y., & Paisley, J. (2017a). Clearing the skies: A deep network architecture for single-image rain removal. *IEEE Transactions on Image Processing*, *26*(6), 2944–2956.

Fu, X., Huang, J., Zeng, D., Huang, Y., Ding, X., & Paisley, J. (2017b). Removing rain from single images via a deep detail network. In *IEEE conference on computer vision and pattern recognition*, pp. 3855–3863.

Fu, X., Liang, B., Huang, Y., Ding, X., & Paisley, J. (2019). Lightweight pyramid networks for image deraining. *IEEE Transactions on Neural Networks and Learning Systems*.

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Generative adversarial nets. In *Advances in neural information processing systems*, pp. 2672–2680.

Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. In *IEEE conference on computer vision and pattern recognition*, pp. 7132–7141.

Hu, X., Fu, C. W., Zhu, L., & Heng, P. A. (2019). Depth-attentional features for single-image rain removal. In *IEEE conference on computer vision and pattern recognition*, pp. 8022–8031.

Huang, H., He, R., Sun, Z., & Tan, T. (2017). Wavelet-srnet: A wavelet-based cnn for multi-scale face super resolution. In *IEEE international conference on computer vision*, pp. 1689–1697.

Huang, H., He, R., Sun, Z., & Tan, T. (2019). Wavelet domain generative adversarial network for multi-scale face hallucination. *International Journal of Computer Vision*, *127*(6–7), 763–784.

Isola, P., Zhu, J. Y., Zhou, T., & Efros, A. A. (2017). Image-to-image translation with conditional adversarial networks. In *IEEE conference on computer vision and pattern recognition*, pp. 1125–1134.

Kang, L. W., Lin, C. W., & Fu, Y. H. (2011). Automatic single-image-based rain streaks removal via image decomposition. *IEEE Transactions on Image Processing*, *21*(4), 1742–1755.

Kuen, J., Wang, Z., & Wang, G. (2016). Recurrent attentional networks for saliency detection. In *IEEE conference on computer vision and pattern recognition*, pp. 3668–3677.

Li, G., He, X., Zhang, W., Chang, H., Dong, L., & Lin, L. (2018a). Non-locally enhanced encoder-decoder network for single image de-raining. In *ACM international conference on multimedia*, pp. 1056–1064.

Li, R., Cheong, L. F., & Tan, R. T. (2017). Single image deraining using scale-aware multi-stage recurrent network. arXiv:1712.06830.

Li, R., Cheong, L. F., & Tan, R. T. (2019). Heavy rain image restoration: Integrating physics model and conditional adversarial learning. In *IEEE conference on computer vision and pattern recognition*, pp. 1633–1642.

Li, X., Wu, J., Lin, Z., Liu, H., & Zha, H. (2018b). Recurrent squeeze-and-excitation context aggregation net for single image deraining. In *European conference on computer vision*, pp. 254–269.

Li, Y., Tan, R. T., Guo, X., Lu, J., & Brown, M. S. (2016). Rain streak removal using layer priors. In *IEEE conference on computer vision and pattern recognition*, pp. 2736–2744.

Lim, B., Son, S., Kim, H., Nah, S., & Mu Lee, K. (2017). Enhanced deep residual networks for single image super-resolution. In *IEEE conference on computer vision and pattern recognition workshops*, pp. 136–144.

Liu, P., Zhang, H., Zhang, K., Lin, L., & Zuo, W. (2018). Multi-level wavelet-cnn for image restoration. In *IEEE conference on computer vision and pattern recognition workshops*, pp. 773–782.

Luo, Y., Xu, Y., & Ji, H. (2015). Removing rain from a single image via discriminative sparse coding. In *IEEE international conference on computer vision*, pp. 3397–3405.

Mallat, S. (1996). Wavelets for a vision. *Proceedings of the IEEE*, *84*(4), 604–614.

Mallat, S. G. (1989). A theory for multiresolution signal decomposition: The wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *11*(7), 674–693.

Mao, X., Li, Q., Xie, H., Lau, R. Y., Wang, Z., & Smolley, S. P. (2017). Least squares generative adversarial networks. In *IEEE international conference on computer vision*, pp. 2813–2821.

Mirza, M., & Osindero, S. (2014). Conditional generative adversarial nets. arXiv:1411.1784.

Pan, J., Liu, S., Sun, D., Zhang, J., Liu, Y., Ren, J., Li, Z., Tang, J., Lu, H., Tai, Y. W., et al. (2018). Learning dual convolutional neural networks for low-level vision. In *IEEE conference on computer vision and pattern recognition*, pp. 3070–3079.

Provenzi, E., & Caselles, V. (2014). A wavelet perspective on variational perceptually-inspired color enhancement. *International Journal of Computer Vision*, *106*(2), 153–171.

Qian, R., Tan, R. T., Yang, W., Su, J., & Liu, J. (2018). Attentive generative adversarial network for raindrop removal from a single image. In *IEEE conference on computer vision and pattern recognition*, pp. 2482–2491.

Ren, D., Zuo, W., Hu, Q., Zhu, P., & Meng, D. (2019). Progressive image deraining networks: A better and simpler baseline. In *IEEE conference on computer vision and pattern recognition*, pp. 3937–3946.

Rensink, R. A. (2000). The dynamic representation of scenes. *Visual Cognition*, *7*(1–3), 17–42.

Szu, H. H., Telfer, B. A., & Kadambe, S. L. (1992). Neural network adaptive wavelets for signal representation and classification. *Optical Engineering*, *31*(9), 1907–1917.

Treisman, A. (1982). Perceptual grouping and attention in visual search for features and for objects. *Journal of Experimental Psychology: Human Perception and Performance*, *8*(2), 194.

Treisman, A. M., & Gelade, G. (1980). A feature-integration theory of attention. *Cognitive Psychology*, *12*(1), 97–136.

Wang, F., Jiang, M., Qian, C., Yang, S., Li, C., Zhang, H., Wang, X., & Tang, X. (2017). Residual attention network for image classification. In *IEEE conference on computer vision and pattern recognition*, pp. 3156–3164.

Wang, G., Sun, C., & Sowmya, A. (2019a). Erl-net: Entangled representation learning for single image de-raining. In *IEEE international conference on computer vision*, pp. 5644–5652.

Wang, T., Yang, X., Xu, K., Chen, S., Zhang, Q., & Lau, R. W. (2019b). Spatial attentive single-image deraining with a high quality real rain dataset. In *IEEE conference on computer vision and pattern recognition*, pp. 12270–12279.

Xu, T., Zhang, P., Huang, Q., Zhang, H., Gan, Z., Huang, X., & He, X. (2018). Attngan: Fine-grained text to image generation with attentional generative adversarial networks. In *IEEE conference on computer vision and pattern recognition*, pp. 1316–1324.

Yang, J., Kannan, A., Batra, D., & Parikh, D. (2017a). Lr-gan: Layered recursive generative adversarial networks for image generation. arXiv:1703.01560.

Yang, W., Tan, R. T., Feng, J., Liu, J., Guo, Z., & Yan, S. (2017b). Deep joint rain detection and removal from a single image. In *IEEE conference on computer vision and pattern recognition*, pp. 1357–1366.

Yang, W., Liu, J., Yang, S., & Guo, Z. (2019a). Scale-free single image deraining via visibility-enhanced recurrent wavelet learning. *IEEE Transactions on Image Processing*, *28*(6), 2948–2961.

Yang, W., Tan, R. T., Wang, S., Fang, Y., & Liu, J. (2019b). Single image deraining: From model-based to data-driven and beyond. arXiv:1912.07150.
Yasarla, R., & Patel, V. M. (2019). Uncertainty guided multi-scale residual learning-using a cycle spinning cnn for single image de-raining. In *IEEE conference on computer vision and pattern recognition*, pp. 8405–8414.
Yoo, J., Uh, Y., Chun, S., Kang, B., & Ha, J. W. (2019). Photorealistic style transfer via wavelet transforms. In *IEEE international conference on computer vision*, pp. 9036–9045.
You, S., Tan, R. T., Kawakami, R., Mukaigawa, Y., & Ikeuchi, K. (2015). Adherent raindrop modeling, detectionand removal in video. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *38*(9), 1721–1733.
Yuan, B., Wang, C., Jiang, F., Long, M., Yu, P. S., & Liu, Y. (2019). Waveletfcnn: A deep time series classification model for wind turbine blade icing detection. arXiv:1902.05625.
Zagoruyko, S., & Komodakis, N. (2016). Paying more attention to attention: Improving the performance of convolutional neural networks via attention transfer. arXiv:1612.03928.
Zhang, H., & Patel, V. M. (2018). Density-aware single image de-raining using a multi-stream dense network. In *IEEE conference on computer vision and pattern recognition*, pp. 695–704.
Zhang, H., Goodfellow, I., Metaxasm D., & Odena, A. (2018). Self-attention generative adversarial networks. arXiv:1805.08318.
Zhang, H., Sindagi, V., & Patel, V. M. (2019). Image de-raining using a conditional generative adversarial network. *IEEE Transactions on Circuits and Systems for Video Technology*.
Zhang, Q., & Benveniste, A. (1992). Wavelet networks. *IEEE Transactions on Neural Networks*, *3*(6), 889–898.
Zhang, R. (2019). Making convolutional networks shift-invariant again. In *International conference on machine learning*, pp. 7324–7334.
Zhong, Z., Shen, T., Yang, Y., Linm Z., & Zhang, C. (2018). Joint sub-bands learning with clique structures for wavelet domain super-resolution. In *Advances in neural information processing systems*, pp. 165–175.
Zhu, L., Fu, C. W., Lischinski, D., & Heng, P. A. (2017). Joint bi-layer optimization for single-image rain streak removal. In *IEEE international conference on computer vision*, pp. 2526–2534.

Publisher's Note Springer Nature remains neutral with regard to jurisdictional claims in published maps and institutional affiliations.

虎年大吉